


**ANALISIS PERBANDINGAN METODE SIMILARITY PADA
CONTENT-BASED RECOMMENDATION
PRODUK LIQUID VAPE**



**MUHAMMAD RAIS
H01119022**



**PROGRAM STUDI MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**ANALISIS PERBANDINGAN METODE SIMILARITY PADA
CONTENT-BASED RECOMMENDATION
PRODUK LIQUID VAPE**

**MUHAMMAD RAIS
H011191022**



**PROGRAM STUDI MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**ANALISIS PERBANDINGAN METODE SIMILARITY PADA
CONTENT-BASED RECOMMENDATION
PRODUK LIQUID VAPE**

MUHAMMAD RAIS
H011191022

Skripsi

sebagai salah satu syarat untuk memperoleh gelar sarjana

Program Studi Matematika

pada

**PROGRAM STUDI MATEMATIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "Analisis Perbandingan Metode Similarity Pada Content-Based Recommendation Produk Liquid Vape" adalah benar karya saya dengan arahan dari pembimbing Dr. Khaeruddin, M.Si. sebagai Pembimbing Utama. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Makassar, 17 Juli 2026

Yang Menyatakan



Muhammad Rais
H0111091022

LEMBAR PENGESAHAN SKRIPSI

ANALISIS PERBANDINGAN METODE SIMILARITY PADA CONTENT-BASED RECOMMENDATION PRODUK LIQUID VAPE

MUHAMMAD RAIS

H011191022

Skripsi,

telah dipertahankan di depan Panitia Ujian Sarjana Matematika pada 11 Agustus
2026 dan dinyatakan telah memenuhi syarat kelulusan
pada

Program Studi Matematika
Departemen Matematika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:

Mengesahkan:
Pembimbing tugas akhir,

Dr. Khaeruddin, M.Sc

NIP. 196509141991031003



Mengetahui:
Ketua Program Studi Matematika,

Dr. Firman, S.Si., M.Si.

NIP. 196804292002121001

UCAPAN TERIMA KASIH

Alhamdulillah, penulis panjatkan puji syukur ke hadirat Allah SWT atas segala limpahan rahmat, nikmat, dan karunia-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul "**Analisis Perbandingan Metode Similarity pada Content-Based Recommendation Produk Liquid Vape**". Pada kesempatan ini, penulis menyampaikan ucapan terima kasih kepada semua pihak yang telah memberikan bantuan, doa, dukungan, dan motivasi selama proses penyusunan skripsi ini, khususnya kepada:

1. Allah SWT, Tuhan Yang Maha Esa, Yang telah memberikan kekuatan, kesehatan serta kemudahan dalam setiap langkah penyelesaian tugas akhir ini.
2. Kedua orang tua tercinta, Arifin Achmad dan Hasnah yang selalu memberikan pikiran, tenaga, arahan, doa dan dukungan mulai dari awal akan masuk kuliah hingga pada sampai ditahap ini.
3. Bapak Prof. Dr. Ir. Jamaluddin Jompa, M.Sc. selaku Rektor Universitas Hasanuddin beserta seluruh jajarannya, serta Bapak Dr. Sci. Muhammad Zakir, S.Si., M.Si selaku Dekan Fakultas Matematika Dan Ilmu Pengetahuan Alam beserta jajarannya.
4. Bapak Dr. Firman, S.Si., M.Si. selaku Ketua Departemen Matematika Fakultas Matematika Dan Ilmu Pengetahuan Alam Universitas Hasanuddin, beserta Bapak dan Ibu Dosen dan Staff Departemen Matematika yang telah membantu dan memudahkan penulis dalam berbagai hal administrasi.
5. Bapak Dr. Khaeruddin, M.Sc. selaku dosen pembimbing yang telah dengan penuh kesabaran memberikan bimbingan, arahan, ilmu, serta motivasi kepada penulis selama proses penyusunan skripsi ini.
6. Bapak Prof. Agustinus Ribal, S.Si., M.Sc., PhD dan Prof. Dr. Syamsuddin Toaha, M.Sc. selaku dosen penguji I dan dosen penguji II yang telah memberikan saran-saran yang membangun demi kesempurnaan skripsi yang telah disusun untuk menjadi lebih baik lagi.
7. Teman-teman seperjuangan, Prodi Matematika 2019 dan Pengurus Himatika, yang telah membantu dan memberi semangat dalam menyusun skripsi ini.
8. Saudara Risal Rusli yang selalu menemani dalam penyusunan Skripsi ini.
9. Semua pihak yang terlibat dalam penulisan skripsi ini yang telah membantu dalam doa serta mendukung dalam proses penulisan skripsi ini.
10. Terimah kasih yang luar biasa kepada diri saya sendiri yang pantang menyerah dan telah berjuang hingga di titik ini.

Semoga Allah SWT senantiasa melimpahkan rahmat dan karunia-Nya kepada semua pihak yang telah membantu penulis dalam menyelesaikan skripsi ini serta membalas segala kebaikan dengan balasan yang lebih baik. Penulis menyadari bahwa skripsi ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan

kritik dan saran yang membangun demi penyempurnaan skripsi ini. Semoga skripsi ini dapat memberikan manfaat bagi para pembaca.

Makassar, 17 Juli

Muhammad Rais

ABSTRAK

MUHAMMAD RAIS. **Analisis Perbandingan Metode Similarity Pada Content-Based Recommendation Produk Liquid Vape** (dibimbing oleh Dr. Khaeruddin, M.Sc.)

Perkembangan industri *liquid vape* menyebabkan semakin banyaknya variasi produk yang tersedia, sehingga pengguna sering mengalami kesulitan dalam menentukan produk yang sesuai dengan preferensinya. Salah satu solusi yang dapat diterapkan adalah sistem rekomendasi berbasis *Content-Based Recommendation* yang memanfaatkan karakteristik produk tanpa memerlukan data interaksi pengguna. Penelitian ini bertujuan untuk membangun sistem rekomendasi produk *liquid vape* menggunakan pendekatan *Content-Based Recommendation* serta membandingkan performa empat metode *similarity*, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity*, dalam menghasilkan rekomendasi produk.

Dataset yang digunakan terdiri dari 996 produk *liquid vape* yang diperoleh dari Clouds Heaven Perintis Makassar dengan atribut nama produk, *brand*, *flavor*, volume, dan harga. Tahapan penelitian meliputi *preprocessing* data, pembentukan *feature vector* menggunakan *TF-IDF*, *One-Hot Encoding*, dan normalisasi *Min-Max*, dilanjutkan dengan perhitungan *similarity* menggunakan keempat metode. Hasil rekomendasi kemudian dievaluasi menggunakan metrik *Average Similarity*, *Precision@5*, *Recall@5*, *F1-Score*, *Mean Reciprocal Rank (MRR)*, *Runtime*, dan *Memory Usage*. Penentuan metode terbaik dilakukan menggunakan pembobotan terhadap seluruh metrik evaluasi.

Hasil penelitian menunjukkan bahwa *Jaccard Similarity* memperoleh skor evaluasi tertinggi dibandingkan metode lainnya. Metode ini menghasilkan tingkat kemiripan produk yang lebih baik serta memiliki performa evaluasi yang paling optimal berdasarkan kombinasi *Average Similarity*, *Precision@5*, *Recall@5*, *F1-Score*, *MRR*, *Runtime*, dan *Memory Usage*. Dengan demikian, *Jaccard Similarity* merupakan metode yang paling sesuai untuk diterapkan pada sistem rekomendasi produk *liquid vape* berbasis *Content-Based Recommendation* pada penelitian ini.

Kata kunci: Sistem Rekomendasi, Content-Based Recommendation, Similarity Measure, Distance Measure, Liquid Vape.

ABSTRACT

MUHAMMAD RAIS. **Comparative Analysis of Similarity Methods in a Content-Based Recommendation System for Vape E-Liquid Products** (Supervised by Dr. Khaeruddin, M.Sc.)

The rapid growth of the liquid vape industry has resulted in an increasing variety of products, making it difficult for consumers to select products that match their preferences. A Content-Based Recommendation system provides a solution by generating recommendations based on product characteristics without requiring user interaction data. This study aims to develop a Content-Based Recommendation system for liquid vape products and compare the performance of four similarity methods: Cosine Similarity, Jaccard Similarity, Euclidean Similarity, and Manhattan Similarity.

The dataset consists of 996 liquid vape products collected from Clouds Heaven Perintis Makassar, using product attributes including product name, brand, flavor, volume, and price. The research process includes data preprocessing, feature vector construction using TF-IDF, One-Hot Encoding, and Min-Max normalization, followed by similarity computation using the four similarity methods. The recommendation results were evaluated using Average Similarity, Precision@5, Recall@5, F1-Score, Mean Reciprocal Rank (MRR), Runtime, and Memory Usage. The best method was determined using a weighted evaluation of all performance metrics.

The results show that Jaccard Similarity achieved the highest evaluation score compared with the other methods. It produced better product similarity and the best overall performance based on the combined evaluation metrics of Average Similarity, Precision@5, Recall@5, F1-Score, MRR, Runtime, and Memory Usage. Therefore, Jaccard Similarity is the most suitable method for implementing a Content-Based Recommendation system for liquid vape products in this study.

Keywords: Recommendation System, Content-Based Filtering, Similarity Measure, Distance Measure, E-Liquid Vape.

DAFTAR ISI

	Halaman
UCAPAN TERIMA KASIH	v
ABSTRAK	viii
ABSTRACT	ix
DAFTAR ISI	x
DAFTAR GAMBAR	xi
DAFTAR TABEL	xii
DAFTAR LAMPIRAN	xiii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Batasan Masalah	4
1.4 Tujuan Penelitian	5
1.5 Manfaat Penelitian	5
1.6 Landasan Teori	6
BAB II METODOLOGI PENELITIAN	34
2.1 Jenis Penelitian	34
2.2 Waktu dan Tempat Penelitian	34
2.3 Variabel Penelitian	35
2.4 Asumsi Penelitian	37
2.5 Tahapan Penelitian	38
2.6 <i>Preprocessing Data</i>	40
2.7 Formulasi Matematis	43
2.8 Implementasi Metode <i>Similarity</i>	45
2.9 Evaluasi Kinerja	49
2.10 Analisis Hasil	52
BAB III HASIL DAN PEMBAHASAN	56
3.1 Deskripsi Dataset	56
3.2 Hasil <i>Preprocessing Data</i>	59
3.3 Hasil Implementasi <i>Cosine Similarity</i>	65
3.4 Hasil Implementasi <i>Jaccard Similarity</i>	74
3.5 Hasil Implementasi <i>Euclidean Distance</i>	80
3.6 Hasil Implementasi <i>Manhattan Distance</i>	88
3.7 Perbandingan Nilai <i>Similarity</i>	94
3.8 Hasil Evaluasi	102
BAB IV KESIMPULAN	106
4.1 Kesimpulan	106
4.2 Saran	107
DAFTAR PUSTAKA	108
LAMPIRAN	111

DAFTAR GAMBAR

Nomor Urut	Halaman
Gambar 1. Model sistem rekomendasi (Ko et al., 2022)	7
Gambar 2. Komponen umum sistem rekomendasi	8
Gambar 3. Arsitektur content-based recommendation	11
Gambar 4. Tahapan <i>feature engineering</i>	13
Gambar 5. Hubungan konseptual antara <i>similarity</i> dan <i>distance</i>	22
Gambar 6. Hubungan antarvariabel.....	37
Gambar 7. Diagram alir tahapan penelitian	39
Gambar 8. Tahapan <i>preprocessing</i> data	40
Gambar 9. Tahapan <i>feature engineering</i>	41
Gambar 10. Diagram formulasi matematis penelitian.....	45
Gambar 11. Alur implementasi metode <i>similarity</i>	45
Gambar 12. Diagram proses evaluasi kinerja.....	49
Gambar 13. Analisis hasil penelian.....	55
Gambar 14. Visualisasi distribusi nilai <i>similarity</i>	71
Gambar 15. Visualisasi hasil rekomendasi <i>cosine similarity</i>	73
Gambar 16. Visualisasi kompleksitas komputasi <i>cosine similarity</i>	73
Gambar 17. Hasil distribusi nilai <i>jaccard similarity</i>	77
Gambar 18. Visualisasi hasil rekomendasi <i>jaccard similarity</i>	79
Gambar 19. Visualisasi hasil kompleksitas komputasi <i>jaccard similarity</i>	79
Gambar 20. Visualisasi distribusi nilai <i>similarity euclidean distance</i>	85
Gambar 21. Visualisasi hasil rekomendasi <i>euclidean distance</i>	87
Gambar 22. Visualisasi hasil kompleksitas komputasi euclidean distance	87
Gambar 23. Visualisasi hasil distribusi nilai <i>manhattan similarity</i>	91
Gambar 24. Visualisasi hasil rekomendasi <i>euclidean distance</i>	93
Gambar 25. Visualisasi hasil kompleksitas kompuasi <i>manhattan similarity</i>	94
Gambar 26. Perbandingan distribusi <i>similarity</i> antar metode	96
Gambar 27. Visualisasi korelasi ranking antar metode similarity	101
Gambar 28. Hasil evaluasi akurasi rekomendasi antar metode	103
Gambar 29. Perbandingan hasil evaluasi kinerja antar metode	104

DAFTAR TABEL

Nomor Urut	Halaman
Tabel 1. Contoh nilai <i>similarity</i> produk	18
Tabel 2. Perbedaan karakteristik antara <i>similarity</i> dan <i>distance</i>	23
Tabel 3. Spesifikasi perangkat keras	35
Tabel 4. Spesifikasi perangkat lunak	35
Tabel 5. Variabel <i>input</i> penelitian	35
Tabel 6. Variabel <i>output</i> penelitian	36
Tabel 7. Bobot penentuan metode terbaik	52
Tabel 8. Statistik deskriptif atribut numerik	56
Tabel 9. Distribusi produk berdasarkan <i>brand</i>	57
Tabel 10. Distribusi produk berdasarkan kategori rasa	57
Tabel 11. Distribusi produk berdasarkan volume	58
Tabel 12. Distribusi harga	58
Tabel 13. Hasil data cleaning	59
Tabel 14. Hasil tokenisasi	60
Tabel 15. Hasil pembobotan <i>term frequency</i>	60
Tabel 16. Hasil perhitungan <i>inverse document frequency</i> (IDF)	61
Tabel 17. Hasil pembobotan tf-idf pada setiap produk	61
Tabel 18. Statistik <i>one-hot encoding</i>	62
Tabel 19. Hasil <i>one-hot encoding</i>	62
Tabel 20. Hasil normalisasi data	63
Tabel 21. Hasil <i>feature vector</i>	64
Tabel 22. Data produk perhitungan <i>cosine similarity</i>	65
Tabel 23. Representasi <i>feature vector</i> perhitungan <i>cosine similarity</i>	65
Tabel 24. Hasil <i>dot product</i> perhitungan <i>cosine similarity</i>	67
Tabel 25. Hasil panjang (norma) perhitungan <i>cosine similarity</i>	67
Tabel 26. Hasil perhitungan norma vector p2	68
Tabel 27. Statistik nilai <i>cosine similarty</i>	69
Tabel 28. Hasil <i>top-k recommendation cosine similarity</i>	71
Tabel 29. Data produk perhitungan <i>jaccard similarity</i>	74
Tabel 30. Representasi <i>vector biner jaccard similarity</i>	75
Tabel 31. Statistik nilai <i>jaccard similarity</i>	76
Tabel 32. Hasil <i>top-k recommendation jaccard similarty</i>	77
Tabel 33. Data produk perhitungan <i>euclidean distance</i>	80
Tabel 34. Representasi <i>feature vector</i> perhitungan <i>Euclidean distance</i>	80
Tabel 35. Nilai selisih perhitungan <i>euclidean distance</i>	81
Tabel 36. Hasil kuadrat selisih perhitungan <i>euclidean distance</i>	82
Tabel 37. Statistik nillai <i>euclidean distance</i>	83
Tabel 38. Hasil <i>top-k recommendation euclidean distance</i>	85
Tabel 39. Data produk perhitungan <i>Manhattan distance</i>	88
Tabel 40. Representasi <i>feature vector</i> perhitungan <i>manhattan distance</i>	88
Tabel 41. Hasil selisih produk perhitungan <i>manhattan distance</i>	89
Tabel 42. Statistik <i>manhattan distance</i>	90
Tabel 43. Hasil <i>top-k recommendation manhattan similarity</i>	92
Tabel 44. Perbandingan statistik nilai <i>similarity</i> antar metode	95
Tabel 45. Hasil perbandingan <i>top-k recommendation</i> antar metode	98
Tabel 46. Hasil analisis korelasi rangking antar metode	100

DAFTAR LAMPIRAN

Lampiran 1. Source Code Penelitian di Github.....	111
---	-----

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah mengubah cara masyarakat memperoleh informasi dan mengambil keputusan dalam memilih suatu produk. Meningkatnya penggunaan *platform* digital menyebabkan konsumen dihadapkan pada jumlah produk yang sangat besar dengan karakteristik yang semakin beragam. Kondisi tersebut memberikan keuntungan berupa semakin banyaknya pilihan produk, namun pada saat yang sama juga menimbulkan permasalahan baru berupa *information overload*, yaitu keadaan ketika pengguna mengalami kesulitan menentukan pilihan karena terlalu banyak alternatif yang tersedia (Ko et al., 2022). Fenomena tersebut terjadi pada berbagai sektor perdagangan, termasuk industri rokok elektrik (*electronic cigarette*) atau *vape*, yang dalam beberapa tahun terakhir menunjukkan perkembangan yang cukup pesat.

Perkembangan industri *vape* ditandai dengan semakin banyaknya produsen yang menawarkan berbagai produk *liquid vape* dengan karakteristik yang berbeda-beda, seperti merek (*brand*), varian rasa, *volume* kemasan, kadar nikotin, serta harga. Banyaknya variasi produk tersebut memberikan kebebasan kepada konsumen dalam memilih produk sesuai preferensi masing-masing. Namun demikian, semakin beragamnya pilihan produk justru menyebabkan proses pengambilan keputusan menjadi lebih sulit, khususnya bagi pengguna baru maupun pengguna yang ingin mencoba produk baru. Konsumen sering kali harus membandingkan puluhan hingga ratusan produk yang memiliki karakteristik hampir serupa sebelum menentukan produk yang akan dibeli.

Salah satu pendekatan yang banyak digunakan untuk mengatasi permasalahan tersebut adalah Sistem Rekomendasi (*Recommendation System*). Sistem rekomendasi merupakan salah satu cabang penting dalam *Artificial Intelligence*, *Machine Learning*, dan *Information Retrieval* yang bertujuan membantu pengguna menemukan produk atau layanan yang paling relevan berdasarkan informasi yang tersedia (Insan et al., 2025). Sistem rekomendasi telah diterapkan secara luas pada berbagai *platform* digital, seperti *Amazon*, *Netflix*, *Spotify*, *YouTube*, maupun berbagai *platform e-commerce*, karena terbukti mampu meningkatkan pengalaman pengguna sekaligus membantu proses pengambilan keputusan (De Biasio et al., 2024).

Menurut (Ko et al., 2022), secara umum sistem rekomendasi dibedakan menjadi tiga pendekatan utama, yaitu *Collaborative Filtering*, *Content-Based Recommendation*, dan *Hybrid Recommendation*. Pendekatan *Collaborative Filtering* menghasilkan rekomendasi berdasarkan perilaku pengguna lain, seperti riwayat pembelian, penilaian (*rating*), maupun histori penggunaan produk. Sebaliknya, *Content-Based Recommendation* menghasilkan rekomendasi berdasarkan karakteristik intrinsik yang dimiliki oleh setiap produk (Februariyanti et al., 2021). Pendekatan ketiga, yaitu

Hybrid Recommendation, mengombinasikan kedua metode tersebut untuk memperoleh kualitas rekomendasi yang lebih baik.

Meskipun *Collaborative Filtering* merupakan salah satu metode yang paling banyak digunakan dalam sistem rekomendasi, penerapannya sangat bergantung pada ketersediaan data interaksi pengguna dalam jumlah yang memadai (Roy & Dutta, 2022). Data tersebut dapat berupa riwayat pembelian, data klik, maupun penilaian (*rating*) terhadap produk. Pada kondisi ketika data tersebut belum tersedia atau jumlahnya sangat terbatas, metode *Collaborative Filtering* akan mengalami permasalahan *cold-start* maupun *data sparsity*, sehingga kualitas rekomendasi yang dihasilkan menjadi kurang optimal (Al Ghifari et al., 2021).

Berdasarkan hasil observasi awal yang dilakukan di Clouds Heaven Perintis Makassar, data yang tersedia sebagian besar berupa data produk, seperti nama produk, merek (*brand*), kategori rasa, *volume* kemasan, dan harga. Sementara itu, data interaksi pelanggan, seperti riwayat pembelian maupun data *rating* produk, belum terdokumentasi secara sistematis. Kondisi tersebut menyebabkan pendekatan *Collaborative Filtering* kurang sesuai untuk diterapkan karena memerlukan data historis pengguna sebagai dasar dalam menghasilkan rekomendasi. Oleh karena itu, penelitian ini menggunakan pendekatan *Content-Based Recommendation*, yang dapat memberikan rekomendasi berdasarkan karakteristik produk tanpa memerlukan data riwayat pengguna.

Pada pendekatan *Content-Based Recommendation*, setiap produk direpresentasikan sebagai sekumpulan atribut atau fitur, kemudian dilakukan pengukuran tingkat kemiripan (*similarity*) antarproduk. Produk-produk yang memiliki tingkat kemiripan tinggi terhadap suatu produk acuan akan direkomendasikan kepada pengguna. Dengan demikian, fungsi pengukuran *similarity* merupakan inti utama dalam *Content-Based Recommendation*, karena kualitas rekomendasi sangat dipengaruhi oleh kemampuan metode tersebut dalam merepresentasikan tingkat kedekatan antarproduk (Jesse et al., 2023).

Berbagai metode *similarity* telah dikembangkan dalam literatur, di antaranya *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*. Keempat metode tersebut memiliki karakteristik matematis yang berbeda. *Cosine Similarity* mengukur kesamaan arah dua buah vektor tanpa memperhatikan besar magnitudonya sehingga banyak digunakan pada data berdimensi tinggi (Kurniaji & Santi, 2023). *Jaccard Similarity* lebih sesuai digunakan pada data kategorikal maupun data biner karena mengukur proporsi atribut yang dimiliki secara bersama-sama. Sementara itu, *Euclidean Distance* dan *Manhattan Distance* mengukur kedekatan antarobjek berdasarkan konsep jarak geometris pada ruang multidimensi, sehingga lebih sensitif terhadap distribusi nilai numerik yang digunakan (Stitini et al., 2022). Perbedaan karakteristik matematis tersebut memungkinkan setiap metode menghasilkan nilai kemiripan maupun urutan rekomendasi yang berbeda walaupun menggunakan data produk yang sama.

Berbagai penelitian terdahulu telah menerapkan metode *Content-Based Recommendation* pada berbagai objek, seperti rekomendasi *film*, musik, buku, maupun produk perdagangan elektronik. Namun demikian, sebagian besar penelitian tersebut hanya menggunakan satu metode *similarity* tertentu sehingga belum memberikan gambaran mengenai pengaruh pemilihan metode *similarity* terhadap kualitas rekomendasi yang dihasilkan. Selain itu, penelitian mengenai analisis komparatif beberapa metode *similarity* pada data produk *liquid vape* masih relatif terbatas. Padahal, produk *liquid vape* memiliki karakteristik yang unik karena tersusun atas kombinasi atribut kategorikal dan numerik, seperti merek, varian rasa, *volume* kemasan, dan harga, yang memungkinkan setiap metode *similarity* memberikan hasil yang berbeda.

Berdasarkan kondisi tersebut, terdapat dua alasan utama yang melatarbelakangi penelitian ini. Pertama, dari sisi praktis, data yang tersedia pada toko *liquid vape* hanya berupa atribut produk sehingga pendekatan *Content-Based Recommendation* merupakan metode yang paling sesuai dibandingkan *Collaborative Filtering*. Kedua, dari sisi akademik, belum terdapat kajian yang secara khusus membandingkan beberapa metode *similarity* pada data produk *liquid vape* untuk mengetahui metode mana yang paling sesuai dalam menghasilkan rekomendasi berbasis atribut produk. Oleh karena itu, penelitian ini diharapkan dapat memberikan kontribusi baik terhadap pengembangan sistem rekomendasi maupun terhadap kajian matematis mengenai pengukuran tingkat kemiripan (*similarity measure*).

Pemilihan produk *liquid vape* sebagai objek penelitian didasarkan pada kebutuhan untuk mengimplementasikan dan membandingkan metode *similarity* pada sistem rekomendasi berbasis *Content-Based Recommendation*. Penggunaan objek tersebut hanya untuk kepentingan akademis dan tidak bertujuan mempromosikan maupun mendorong penggunaan produk *liquid vape*. Mengingat produk *liquid vape* umumnya mengandung nikotin yang dapat menyebabkan ketergantungan atau kecanduan, penelitian ini difokuskan pada aspek pengembangan dan evaluasi metode *similarity* dalam sistem rekomendasi.

Berdasarkan uraian tersebut, penelitian ini mengangkat judul "Analisis Perbandingan Metode *Similarity* pada *Content-Based Recommendation* Produk *Liquid Vape*." Penelitian ini bertujuan membandingkan kinerja beberapa metode *similarity*, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*, dalam menghasilkan rekomendasi produk *liquid vape* berdasarkan atribut produk yang tersedia. Hasil penelitian diharapkan dapat memberikan rekomendasi mengenai metode *similarity* yang paling sesuai untuk karakteristik data produk *liquid vape*, sekaligus menjadi referensi bagi pengembangan sistem rekomendasi berbasis atribut produk pada penelitian-penelitian selanjutnya.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana merepresentasikan atribut produk *liquid vape* ke dalam bentuk fitur yang dapat digunakan pada sistem *Content-Based Recommendation*?
2. Bagaimana menerapkan metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance* untuk mengukur tingkat kemiripan antarproduk *liquid vape*?
3. Bagaimana perbandingan hasil rekomendasi yang dihasilkan oleh masing-masing metode *similarity* berdasarkan karakteristik data produk *liquid vape*?
4. Metode *similarity* manakah yang memberikan kinerja terbaik dalam menghasilkan rekomendasi produk *liquid vape* berdasarkan hasil analisis yang dilakukan?

1.3 Batasan Masalah

Agar penelitian lebih terarah dan sesuai dengan tujuan yang ingin dicapai, maka penelitian ini dibatasi pada hal-hal sebagai berikut.

1. Data yang digunakan dalam penelitian merupakan data produk *liquid vape* yang diperoleh dari toko Clouds Heaven Perintis Makassar, meliputi atribut nama produk, merek (*brand*), varian rasa, *volume* kemasan, dan harga.
2. Penelitian hanya memanfaatkan atribut produk sebagai dasar penyusunan fitur (*feature representation*), tanpa menggunakan data interaksi pengguna seperti riwayat pembelian, data klik, maupun data *rating*.
3. Sistem rekomendasi yang dikembangkan menggunakan pendekatan *Content-Based Recommendation*, sehingga rekomendasi dihasilkan berdasarkan tingkat kemiripan karakteristik antarproduk.
4. Metode pengukuran kemiripan yang digunakan dalam penelitian ini dibatasi pada empat metode, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*.
5. Representasi atribut kategorikal dilakukan menggunakan teknik pengkodean (*encoding*), sedangkan atribut numerik dinormalisasi sebelum proses perhitungan *similarity*.
6. Hasil rekomendasi yang dihasilkan berupa *Top-k* produk dengan tingkat kemiripan tertinggi terhadap produk acuan.
7. Evaluasi penelitian difokuskan pada perbandingan karakteristik hasil rekomendasi yang dihasilkan oleh masing-masing metode *similarity*, meliputi nilai *similarity*, konsistensi hasil rekomendasi, korelasi peringkat rekomendasi, serta waktu komputasi.
8. Penelitian tidak membahas pengembangan sistem transaksi penjualan, pengelolaan stok, pembayaran, maupun integrasi dengan sistem informasi toko.

1.4 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dikemukakan, maka tujuan penelitian ini adalah sebagai berikut.

1. Merepresentasikan atribut produk *liquid vape* ke dalam bentuk fitur yang dapat digunakan pada sistem *Content-Based Recommendation*.
2. Menerapkan metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance* untuk mengukur tingkat kemiripan antarproduk *liquid vape*.
3. Menganalisis karakteristik nilai *similarity* yang dihasilkan oleh masing-masing metode berdasarkan atribut produk *liquid vape*.
4. Membandingkan kinerja metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance* dalam menghasilkan rekomendasi produk *liquid vape*.
5. Menentukan metode *similarity* yang paling sesuai untuk diterapkan pada sistem *Content-Based Recommendation* berdasarkan hasil analisis yang dilakukan.

1.5 Manfaat Penelitian

1.5.1 Manfaat Teoritis

1. Memberikan kontribusi terhadap pengembangan kajian di bidang Matematika Terapan, khususnya yang berkaitan dengan pengukuran kemiripan (*similarity measures*) pada sistem *Content-Based Recommendation*.
2. Menambah referensi ilmiah mengenai karakteristik matematis beberapa metode *similarity*, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*, dalam merepresentasikan tingkat kemiripan antarproduk.
3. Menjadi referensi bagi penelitian selanjutnya yang berkaitan dengan analisis metode *similarity*, sistem rekomendasi berbasis atribut (*Content-Based Recommendation*), maupun penerapan metode pengukuran kemiripan pada berbagai objek penelitian lainnya.

1.5.2 Manfaat Praktis

1. Bagi pengelola toko Clouds Heaven Perintis Makassar, hasil penelitian ini dapat menjadi acuan dalam memilih metode *similarity* yang paling sesuai untuk diterapkan pada sistem rekomendasi produk berbasis atribut.
2. Bagi konsumen, hasil penelitian ini diharapkan dapat membantu memperoleh rekomendasi produk *liquid vape* yang memiliki karakteristik serupa dengan produk yang menjadi preferensinya sehingga proses pemilihan produk menjadi lebih mudah.

3. Bagi pengembang sistem rekomendasi, penelitian ini dapat menjadi bahan pertimbangan dalam memilih metode *similarity* yang sesuai dengan karakteristik data produk yang terdiri atas kombinasi atribut kategorikal dan numerik.
4. Bagi Program Studi Matematika, penelitian ini dapat menjadi contoh penerapan konsep representasi data, pengukuran kemiripan, dan analisis komputasi dalam menyelesaikan permasalahan nyata di bidang sistem rekomendasi.


1.6 Landasan Teori

1.6.1 Sistem Rekomendasi (*Recommendation System*)

1.6.1.1 Definisi Sistem Rekomendasi

Sistem rekomendasi merupakan sistem atau aplikasi yang dibuat untuk dapat menyediakan dan memberikan rekomendasi dari suatu *item* untuk membuat suatu keputusan yang diinginkan oleh pengguna sistem (Hariri & Rochim, 2022). Sistem rekomendasi juga dapat diartikan sebagai perangkat lunak yang memberikan prediksi terhadap *item* yang kemungkinan disukai oleh pengguna berdasarkan karakteristik *item* maupun preferensi pengguna, sehingga dapat berfungsi sebagai sistem pendukung keputusan dalam proses pemilihan suatu *item* (Februariyanti et al., 2021). Pada dasarnya, sistem rekomendasi bekerja dengan menganalisis informasi yang tersedia untuk menghasilkan daftar *item* yang dianggap paling relevan bagi pengguna. Informasi tersebut dapat berupa karakteristik *item*, riwayat interaksi pengguna, maupun kombinasi keduanya. Hasil analisis tersebut kemudian digunakan untuk menyusun rekomendasi yang diharapkan sesuai dengan kebutuhan atau preferensi pengguna.

Seiring dengan semakin banyaknya pilihan produk dan informasi yang tersedia di berbagai platform digital, sistem rekomendasi menjadi semakin penting karena dapat membantu pengguna menemukan *item* yang relevan dengan lebih mudah dan efisien. Penerapan sistem rekomendasi juga telah banyak digunakan pada berbagai platform digital, seperti *e-commerce*, layanan streaming *film* dan musik, media sosial, serta *marketplace*, untuk meningkatkan pengalaman pengguna sekaligus membantu proses pengambilan keputusan. Dalam pengembangan sistem rekomendasi, terdapat tiga pendekatan utama yang umum digunakan, yaitu *Content-Based Filtering*, *Collaborative Filtering*, dan *Hybrid Filtering* (Ko et al., 2022). Ketiga pendekatan tersebut memiliki mekanisme yang berbeda dalam menghasilkan rekomendasi sesuai dengan karakteristik data yang digunakan. Berikut merupakan gambaran umum model sistem rekomendasi:



Gambar 1. Model sistem rekomendasi (Ko et al., 2022)

1.6.1.2 Komponen Sistem Rekomendasi

Pada dasarnya sistem rekomendasi terdiri atas beberapa komponen utama yang saling berinteraksi dalam menghasilkan rekomendasi produk. Menurut (Ko et al., 2022), komponen utama sistem rekomendasi meliputi data masukan (*input data*), representasi data (*data representation*), algoritma rekomendasi (*recommendation algorithm*), serta daftar rekomendasi (*recommendation list*).


Data masukan merupakan informasi yang digunakan sebagai dasar pembentukan rekomendasi. Jenis data yang digunakan bergantung pada pendekatan sistem rekomendasi yang diterapkan. Pada *Collaborative Filtering*, data masukan berupa riwayat pembelian, data klik, atau penilaian (*rating*) pengguna. Sebaliknya, pada *Content-Based Recommendation*, data yang digunakan berupa atribut intrinsik yang dimiliki setiap produk, seperti nama produk, merek, kategori, spesifikasi, maupun harga.

Tahap berikutnya adalah representasi data (*feature representation*). Pada tahap ini setiap produk direpresentasikan menjadi sekumpulan atribut atau vektor fitur sehingga dapat diproses secara komputasional. Representasi fitur merupakan salah satu tahapan yang sangat penting karena kualitas representasi data akan memengaruhi kualitas rekomendasi yang dihasilkan (Februariyanti et al., 2021).

Komponen berikutnya adalah algoritma rekomendasi. Algoritma ini bertugas menghitung hubungan atau tingkat kemiripan antar *item* maupun antar pengguna sesuai dengan pendekatan yang digunakan. Hasil dari proses tersebut berupa daftar *item* yang memiliki tingkat relevansi tertinggi terhadap *item* acuan maupun terhadap preferensi pengguna.

Tahap terakhir adalah penyajian hasil rekomendasi kepada pengguna. Umumnya sistem akan menampilkan sejumlah *item* dengan nilai relevansi tertinggi (*Top-k Recommendation*), misalnya lima atau sepuluh produk yang paling sesuai dengan karakteristik *item* yang dipilih pengguna.

Secara umum, alur kerja sistem rekomendasi dapat digambarkan pada gambar 2.



Gambar 2. Komponen umum sistem rekomendasi

1.6.1.3 Pendekatan Sistem Rekomendasi

Dalam pengembangan sistem rekomendasi, terdapat tiga pendekatan utama yang umum digunakan, yaitu *Content-Based Filtering*, *Collaborative Filtering*, dan *Hybrid Filtering* (Ko et al., 2022).

a. *Content-Based Filtering*

Content-Based Filtering merupakan metode yang mengekstrak informasi yang terdapat pada suatu *item* untuk membandingkannya dengan informasi *item* yang dicari oleh *user* untuk merekomendasikan *item* dengan konten yang mirip (Kurniaji & Santi, 2023). *Content-Based Filtering* merekomendasikan berdasarkan pada atribut, karakteristik, atau fitur yang dimiliki oleh sebuah *item* (Februariyanti et al., 2021). Atribut-atribut yang pernah mengalami interaksi dengan *user* akan dijadikan dasar untuk mencari *item* yang memiliki atribut yang serupa sehingga sistem dapat memberikan rekomendasi kepada pengguna.

b. *Collaborative Filtering*

Collaborative Filtering merupakan salah satu teknik dalam sistem rekomendasi yang digunakan untuk memperkirakan preferensi atau minat pengguna terhadap suatu *item* dengan memanfaatkan data dari pengguna lain, seperti penilaian atau *rating* (Imelda Lubis et al., 2020). Metode ini bekerja dengan membandingkan preferensi atau perilaku pengguna untuk memberikan rekomendasi berdasarkan kesamaan dengan pengguna lain. Pada dasarnya, metode *Collaborative Filtering* membangun model yang merepresentasikan hubungan antara preferensi pengguna dan *item*. Metode *Collaborative Filtering* memberikan rekomendasi berdasarkan pendapat, minat, dan ketertarikan beberapa *user* lain yang biasanya diberikan dalam bentuk *rating* yang diberikan *user* terhadap suatu *item* (Hariri & Rochim, 2022).

c. *Hybrid Recommendation*

Hybrid Filtering merupakan metode dalam sistem rekomendasi yang menggabungkan beberapa teknik atau pendekatan untuk meningkatkan kualitas rekomendasi. Pendekatan ini menggabungkan dua atau lebih metode seperti *Content Based Filtering* dan *Collaborative Filtering* dalam satu sistem rekomendasi (Imelda Lubis et al., 2020). *Content Based Filtering* memiliki kekurangan karena hanya merekomendasikan *item* yang serupa dengan preferensi sebelumnya, sehingga *item* diluar kategori yang biasa disukai oleh pengguna tidak akan direkomendasikan oleh sistem. Sementara itu, *Collaborative Filtering* bergantung pada data *rating*, sehingga jika terdapat *item* baru yang belum memiliki *rating*, sistem tidak dapat merekomendasikannya kepada pengguna (Roy & Dutta, 2022).

1.6.2 *Content-Based Recommendation*

1.6.2.1 Pengertian *Content-Based Recommendation*

Content-Based Recommendation merupakan salah satu pendekatan dalam sistem rekomendasi yang menghasilkan rekomendasi berdasarkan karakteristik atau atribut yang dimiliki oleh suatu *item* (Februariyanti et al., 2021). Berbeda dengan *Collaborative Filtering* yang memanfaatkan data interaksi pengguna, pendekatan ini membandingkan atribut setiap *item* untuk menentukan tingkat kemiripan antaritem. *Item* yang memiliki karakteristik paling mirip dengan *item* yang dipilih atau disukai pengguna kemudian direkomendasikan sebagai alternatif yang relevan.

Menurut *Recommender Systems Handbook*, *Content-Based Recommendation* membangun rekomendasi berdasarkan deskripsi *item* (*item description*) dan profil preferensi pengguna (*user profile*). Setiap *item* direpresentasikan sebagai sekumpulan atribut atau fitur, kemudian dihitung tingkat kemiripannya menggunakan suatu fungsi *similarity*. Oleh karena itu, kualitas rekomendasi sangat dipengaruhi oleh kualitas representasi fitur dan metode pengukuran *similarity* yang digunakan.

Selain itu, *Recommender Systems: The Textbook* menjelaskan bahwa *Content-Based Recommendation* berkembang dari konsep *information retrieval*, yaitu merepresentasikan setiap *item* sebagai vektor fitur (*feature vector*) pada suatu ruang fitur (*feature space*). Representasi tersebut memungkinkan setiap item dibandingkan secara matematis sehingga item dengan tingkat kemiripan tertinggi dapat direkomendasikan kepada pengguna. Dengan demikian, *Content-Based Recommendation* merupakan pendekatan yang memanfaatkan karakteristik intrinsik setiap *item* untuk menghasilkan rekomendasi tanpa bergantung pada data interaksi pengguna dalam jumlah besar.

1.6.2.2 Prinsip Dasar *Content-Based Recommendation*

Prinsip utama *Content-Based Recommendation* adalah bahwa *item* yang memiliki karakteristik serupa cenderung memiliki tingkat kemiripan yang tinggi. Oleh karena itu, rekomendasi dibangun dengan membandingkan atribut atau fitur yang dimiliki

setiap *item*. Semakin tinggi tingkat kemiripan antara dua *item*, semakin besar kemungkinan *item* tersebut direkomendasikan kepada pengguna.

Misalkan terdapat himpunan *item*

$$P = \{p_1, p_2, \dots, p_n\}$$

Setiap item direpresentasikan sebagai sekumpulan atribut

$$p_i = (a_1, a_2, \dots, a_m)$$

dengan $a_1, a_2, \dots, a_m$ menyatakan atribut yang mendeskripsikan karakteristik suatu *item*. Selanjutnya, atribut-atribut tersebut direpresentasikan ke dalam bentuk numerik sehingga diperoleh suatu vektor fitur

$$x_i = (x_{i1}, x_{i2}, \dots, x_{im})$$

Representasi vektor fitur tersebut kemudian digunakan sebagai dasar untuk menghitung tingkat kemiripan antaritem menggunakan suatu fungsi *similarity*

$$S(x_i, x_j) \tag{1.1}$$

Semakin besar nilai *similarity* yang diperoleh, semakin tinggi tingkat kemiripan antara kedua *item*, sehingga semakin besar pula peluang *item* tersebut direkomendasikan.

1.6.2.3 Arsitektur *Content-Based Recommendation*

Proses *Content-Based Recommendation* diawali dengan data produk sebagai sumber informasi. Selanjutnya dilakukan tahap *Feature Extraction* untuk mengambil atribut-atribut yang merepresentasikan karakteristik setiap produk. Atribut tersebut kemudian diubah ke dalam bentuk yang dapat diproses secara komputasional melalui tahap *Feature Representation* sehingga diperoleh representasi dalam bentuk vektor fitur (*feature vector*). Tahap berikutnya adalah *Similarity Computation*, yaitu menghitung tingkat kemiripan antarproduk menggunakan metode *similarity* tertentu. Hasil perhitungan kemudian diurutkan berdasarkan nilai kemiripan tertinggi pada tahap *Ranking*, sehingga diperoleh daftar produk yang paling relevan. Terakhir, sistem menampilkan sejumlah produk dengan nilai kemiripan tertinggi sebagai hasil *Top-k Recommendation*.



Gambar 3. Arsitektur content-based recommendation

Sebagai salah satu pendekatan dalam sistem rekomendasi, *Content-Based Recommendation* memiliki beberapa kelebihan, di antaranya mampu menghasilkan rekomendasi tanpa memerlukan data interaksi pengguna, mudah diinterpretasikan karena didasarkan pada karakteristik produk, serta tetap dapat diterapkan selama atribut produk tersedia. Namun demikian, pendekatan ini juga memiliki keterbatasan, seperti sangat bergantung pada kualitas representasi fitur, memerlukan proses *feature engineering* yang baik, serta cenderung menghasilkan rekomendasi yang memiliki karakteristik serupa (*overspecialization*) (Imelda Lubis et al., 2020).

1.6.3 Representasi Fitur (*Feature Representation*)

1.6.3.1 Konsep Representasi Fitur

Representasi fitur (*feature representation*) merupakan salah satu tahapan penting dalam *Content-Based Recommendation*. Tahap ini bertujuan mengubah karakteristik suatu *item* ke dalam bentuk yang dapat diproses secara komputasional sehingga memungkinkan dilakukan pengukuran kemiripan antaritem. Setiap *item* direpresentasikan sebagai sekumpulan atribut atau fitur yang menggambarkan karakteristiknya (Zebua et al., 2026).

Kualitas sistem rekomendasi berbasis konten sangat dipengaruhi oleh kualitas representasi fitur. Representasi yang baik akan menghasilkan pengukuran kemiripan yang lebih akurat sehingga rekomendasi yang dihasilkan menjadi lebih relevan. Representasi *item* merupakan komponen fundamental dalam *Content-Based Recommendation* karena seluruh proses pengukuran kemiripan bergantung pada informasi yang direpresentasikan pada setiap *item* (Srilakshmi et al., 2022).

1.6.3.2 Ruang Fitur

Dalam pendekatan matematis, setiap *item* direpresentasikan sebagai sebuah titik pada ruang berdimensi banyak (*feature space*). Misalkan terdapat himpunan *item*

$$P = \{p_1, p_2, \dots, p_n\}$$

dengan setiap *item* memiliki sejumlah atribut

$$A = \{a_1, a_2, \dots, a_m\}$$

Setiap *item* kemudian direpresentasikan sebagai suatu vektor fitur

$$x_i = (x_{i1}, x_{i2}, \dots, x_{im})$$

dengan

$$x_i \in \mathbb{R}^m$$

Seluruh vektor fitur selanjutnya membentuk matriks fitur

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1m} \\ x_{21} & x_{22} & \dots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nm} \end{bmatrix} \quad (1.2)$$

yang menjadi dasar dalam proses pengukuran kemiripan antaritem.

1.6.3.3 Representasi Numerik Fitur

Sebelum dilakukan pengukuran kemiripan, atribut setiap *item* perlu direpresentasikan ke dalam bentuk numerik. Atribut kategorikal umumnya dikonversi menggunakan teknik *One-Hot Encoding*, yaitu mengubah setiap kategori menjadi variabel biner tanpa mengasumsikan adanya hubungan ordinal antar kategori (Chen et al., 2020). Sementara itu, atribut numerik seperti harga atau *volume* dapat dinormalisasi agar memiliki rentang nilai yang sebanding. Salah satu metode normalisasi yang banyak digunakan adalah *Min-Max Normalization*, yang dirumuskan sebagai berikut.

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (1.3)$$

Setelah seluruh atribut direpresentasikan dalam bentuk numerik, setiap *item* dinyatakan sebagai sebuah vektor fitur sehingga berbagai metode *similarity* dapat diterapkan untuk menghitung tingkat kemiripan antaritem.

1.6.4 Feature Engineering pada Content-Based Recommendation

1.6.4.1 Pengertian Feature Engineering

Feature engineering merupakan proses mengubah data mentah (*raw data*) menjadi sekumpulan fitur (*features*) yang lebih representatif sehingga dapat digunakan secara efektif dalam proses analisis maupun pemodelan (Forke & Tropmann-Frick, 2021). Pada sistem rekomendasi berbasis konten (*Content-Based Recommendation*), *feature engineering* bertujuan membangun representasi numerik dari setiap *item* berdasarkan atribut-atribut yang dimilikinya sehingga memungkinkan dilakukan pengukuran tingkat kemiripan antar-*item*.

Kualitas sistem rekomendasi berbasis konten sangat dipengaruhi oleh kualitas fitur yang digunakan. Fitur yang mampu merepresentasikan karakteristik *item* secara baik akan menghasilkan pengukuran kemiripan yang lebih akurat sehingga meningkatkan kualitas rekomendasi (Srilakshmi et al., 2022). Oleh karena itu, *feature engineering* merupakan salah satu tahapan yang paling penting dalam pengembangan sistem rekomendasi berbasis atribut. Dalam penelitian ini, data yang tersedia berasal dari katalog produk *liquid vape* yang memuat atribut nama produk, merek (*brand*), varian rasa, volume kemasan, dan harga. Data tersebut belum dapat langsung digunakan untuk menghitung kemiripan antarproduk sehingga diperlukan serangkaian proses *feature engineering*.

1.6.4.2 Tahapan *Feature Engineering*

Secara umum, *feature engineering* terdiri atas beberapa tahapan yang saling berkaitan. Tahapan tersebut diawali dengan *data cleaning*, yaitu proses memperbaiki kualitas data melalui penghapusan data duplikat, penanganan data yang tidak lengkap, serta penyeragaman format data. Setelah data siap digunakan, dilakukan *feature extraction* untuk memperoleh informasi penting yang merepresentasikan karakteristik setiap *item*.

Selanjutnya, atribut kategorikal direpresentasikan ke dalam bentuk numerik melalui proses *feature encoding*, sedangkan atribut numerik dapat dinormalisasi agar memiliki skala yang sebanding. Tahap akhir adalah pembentukan *feature vector*, yaitu representasi setiap *item* dalam bentuk vektor numerik yang siap digunakan pada proses pengukuran kemiripan.

Secara umum, *feature engineering* pada penelitian ini terdiri atas lima tahapan utama sebagaimana ditunjukkan pada gambar 4.



Gambar 4. Tahapan *feature engineering*

Tahapan tersebut bertujuan menghasilkan representasi numerik yang konsisten sehingga seluruh produk dapat dibandingkan menggunakan fungsi *similarity*.

1.6.4.3 Teknik Representasi Fitur

Atribut kategorikal umumnya direpresentasikan menggunakan teknik *One-Hot Encoding*, yaitu mengubah setiap kategori menjadi variabel biner sehingga setiap kategori memiliki representasi yang unik tanpa mengasumsikan adanya hubungan ordinal (Chen et al., 2020). Sementara itu, atribut numerik biasanya dinormalisasi agar berada pada rentang nilai yang sebanding. Salah satu metode normalisasi yang banyak digunakan adalah *Min–Max Normalization*, yang dirumuskan sebagai

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (1.4)$$

Normalisasi bertujuan mengurangi pengaruh perbedaan skala antaratribut sehingga proses pengukuran kemiripan menjadi lebih representatif, terutama pada metode berbasis jarak seperti *Euclidean Distance* dan *Manhattan Distance*. Setelah seluruh atribut direpresentasikan dalam bentuk numerik, setiap *item* dinyatakan sebagai sebuah *feature vector* yang digunakan sebagai masukan pada proses perhitungan *similarity*.

1.6.4.4 Feature Extraction

Feature extraction merupakan proses memperoleh informasi atau atribut yang relevan dari data mentah sehingga dapat digunakan sebagai fitur dalam proses analisis maupun pemodelan (Cramer et al., 2022). Pada sistem *Content-Based Recommendation*, *feature extraction* bertujuan mengidentifikasi karakteristik penting yang dimiliki setiap *item* agar dapat direpresentasikan dalam bentuk fitur yang menggambarkan karakteristik *item* tersebut. Menurut (Zebari et al., 2020) Kualitas fitur yang dihasilkan pada tahap ini sangat memengaruhi representasi *item* serta hasil pengukuran kemiripan, sehingga *feature extraction* menjadi salah satu tahapan penting dalam proses *feature engineering*. Melalui proses ekstraksi tersebut, data yang semula berupa teks bebas diubah menjadi atribut-atribut terstruktur yang selanjutnya digunakan sebagai fitur dalam sistem rekomendasi.

Secara umum, *feature extraction* dapat diterapkan pada berbagai jenis data, seperti data teks, citra, maupun data terstruktur, dengan menyesuaikan karakteristik data yang digunakan. Pada penelitian ini, proses *feature extraction* dilakukan untuk memperoleh atribut-atribut penting dari produk *liquid vape*, seperti *brand*, kategori rasa, *volume*, dan atribut lainnya yang digunakan sebagai dasar pembentukan representasi fitur. Fitur-fitur tersebut selanjutnya diproses pada tahap *feature encoding* agar dapat digunakan dalam perhitungan *similarity* antarproduk.

1.6.4.5 Feature Encoding

Feature encoding merupakan proses mengubah atribut yang bersifat kategorikal menjadi representasi numerik agar dapat diproses oleh algoritma komputasi. Pada

sistem *Content-Based Recommendation*, proses ini diperlukan karena sebagian besar metode pengukuran similarity bekerja menggunakan data numerik. Menurut (Lombu et al., 2022), salah satu teknik *encoding* yang paling banyak digunakan adalah *One-Hot Encoding*, yaitu teknik yang mengubah setiap kategori menjadi sekumpulan variabel biner tanpa mengasumsikan adanya hubungan ordinal antarkategori. Melalui *One-Hot Encoding*, setiap kategori direpresentasikan secara unik sehingga informasi yang terkandung pada atribut tetap dipertahankan tanpa memberikan bobot atau urutan tertentu.

1.6.4.6 Normalisasi Fitur Numerik

Normalisasi merupakan proses mengubah nilai atribut numerik ke dalam rentang skala tertentu agar setiap atribut memiliki kontribusi yang seimbang dalam proses pengolahan data. Menurut (Permana & Nur Salisah, 2022), normalisasi diperlukan ketika atribut yang digunakan memiliki rentang nilai yang berbeda, sehingga tidak terjadi dominasi atribut dengan nilai yang lebih besar terhadap atribut lainnya. Salah satu metode normalisasi yang banyak digunakan adalah *Min-Max Normalization*, yang memetakan setiap nilai ke dalam interval $[0, 1]$ menggunakan persamaan berikut.

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (1.5)$$

Keterangan:

x_i = nilai asli atribut

$x_{\min}$ = nilai minimum atribut

$x_{\max}$ = nilai maksimum atribut

Melalui proses normalisasi, seluruh atribut numerik memiliki skala yang sebanding sehingga proses pengukuran kemiripan dapat dilakukan secara lebih representatif. Pada penelitian ini, normalisasi diterapkan pada atribut numerik, seperti *volume* dan harga, sebelum dilakukan perhitungan *similarity*. Tahap ini menjadi penting terutama pada metode berbasis jarak, seperti *Euclidean Distance* dan *Manhattan Distance*, karena kedua metode tersebut sensitif terhadap perbedaan skala data (Syauqi et al., 2023).

1.6.5 Similarity Measure

1.6.5.1 Pengertian Similarity Measure

Similarity measure atau ukuran kemiripan merupakan suatu fungsi matematis yang digunakan untuk mengukur tingkat kemiripan antara dua objek berdasarkan karakteristik atau atribut yang dimilikinya. Dalam bidang *data mining*, *machine learning*, *information retrieval*, dan *recommendation system*, *similarity measure* memiliki peranan yang sangat penting karena menjadi dasar dalam proses pengelompokan data (*clustering*), pencarian informasi (*information retrieval*), klasifikasi, deteksi anomali, hingga sistem rekomendasi (López-García et al., 2022).

Pada sistem rekomendasi berbasis konten (*Content-Based Recommendation*), *similarity measure* digunakan untuk menentukan tingkat kemiripan antara dua produk berdasarkan atribut-atribut yang dimiliki. Semakin tinggi nilai kemiripan yang diperoleh, semakin besar kemungkinan kedua produk memiliki karakteristik yang serupa sehingga salah satu produk dapat direkomendasikan sebagai alternatif bagi pengguna yang menyukai produk lainnya (Februariyanti et al., 2021).

Menurut Supiyanto & Sriyono (2023), *similarity measure* merupakan fungsi yang memetakan dua buah objek ke dalam suatu nilai numerik yang menggambarkan tingkat kedekatan kedua objek tersebut. Nilai tersebut biasanya berada pada interval tertentu, misalnya

$$0 \leq S(x_i, x_j) \leq 1 \quad (1.6)$$

Keterangan

$S(x_i, x_j) = 1$ menunjukkan kedua objek identik

$S(x_i, x_j) = 0$ menunjukkan kedua objek tidak memiliki kemiripan.

Namun demikian, terdapat pula beberapa ukuran *similarity* yang menghasilkan nilai pada interval

$$-1 \leq S(x_i, x_j) \leq 1$$

seperti *Pearson Correlation Coefficient*.

Dalam penelitian ini, seluruh metode *similarity* yang digunakan menghasilkan nilai pada interval

$$0 \leq S(x_i, x_j) \leq 1$$

sehingga interpretasi nilai *similarity* menjadi lebih sederhana.

a. Representasi Matematis *Similarity*

Misalkan terdapat himpunan objek

$$X = \{x_1, x_2, \dots, x_n\}$$

dengan

$$x_i \in \mathbb{R}^m$$

menyatakan representasi vektor dari objek ke- i .

Similarity measure didefinisikan sebagai suatu fungsi

$$S: X \times X \rightarrow \mathbb{R} \quad (1.7)$$

yang memberikan nilai

$$S(x_i, x_j)$$

untuk setiap pasangan objek.

Pada penelitian ini,

$$x_i = (x_{i1}, x_{i2}, \dots, x_{im})$$

merupakan representasi fitur produk *liquid vape* yang terdiri atas

menghasilkan nilai jarak, biasanya dilakukan proses transformasi menjadi nilai *similarity* menggunakan persamaan berikut.

$$S = \frac{1}{1 + D} \quad (1.8)$$

Keterangan:

S = nilai *similarity*

D = nilai jarak antarobjek

d. Karakteristik *Similarity Measure*

Suatu ukuran *similarity* yang baik sebaiknya memiliki beberapa karakteristik berikut.

1. **Non-negativity**

Nilai *similarity* tidak negatif

$$S(x_i, x_j) \geq 0 \quad (1.9)$$

2. **Identity**

Objek identik mempunyai *similarity* maksimum

$$S(x_i, x_i) = 1 \quad (1.10)$$

3. **Symmetry**

Urutan objek tidak memengaruhi *similarity*

$$S(x_i, x_j) = S(x_j, x_i) \quad (1.11)$$

4. **Interpretability**

Nilai *similarity* harus mudah diinterpretasikan. Semakin besar nilainya, semakin mirip kedua objek.

d. *Similarity Measure* pada *Content-Based Recommendation*

Pada *Content-Based Recommendation*, *similarity measure* merupakan inti dari seluruh proses rekomendasi. Setelah setiap produk direpresentasikan sebagai vektor fitur, sistem menghitung *similarity* antara produk acuan dengan seluruh produk lainnya. Nilai *similarity* tersebut kemudian diurutkan sehingga diperoleh daftar rekomendasi berdasarkan tingkat kemiripan tertinggi (Februariyanti et al., 2021). Sebagai ilustrasi, misalkan terdapat empat produk dengan nilai *similarity* terhadap produk acuan sebagai berikut.

Tabel 1. Contoh nilai *similarity* produk

Produk	Similarity
A	0,96
B	0,91
C	0,87
D	0,73

Apabila sistem menggunakan *Top-3 Recommendation*, maka produk A, B, dan C akan direkomendasikan kepada pengguna. Dengan demikian, kualitas rekomendasi yang dihasilkan sangat dipengaruhi oleh metode *similarity* yang digunakan. Perbedaan formulasi matematis pada setiap metode dapat menghasilkan nilai

similarity yang berbeda sehingga urutan rekomendasi yang diperoleh juga dapat berubah.

1.6.5.2 Konsep *Distance Measure*

Distance measure atau ukuran jarak merupakan suatu fungsi matematis yang digunakan untuk mengukur tingkat perbedaan atau keterpisahan antara dua objek dalam suatu ruang fitur (*feature space*). Berbeda dengan *similarity measure* yang memberikan nilai semakin besar ketika dua objek semakin mirip, *distance measure* menghasilkan nilai yang semakin kecil apabila kedua objek semakin mirip (Stitini et al., 2022). Dalam bidang *data mining*, *machine learning*, *pattern recognition*, dan *information retrieval*, *distance measure* merupakan salah satu konsep fundamental yang digunakan pada berbagai algoritma, seperti *K-Nearest Neighbor* (KNN), *K-Means Clustering*, *Hierarchical Clustering*, *Outlier Detection*, dan *Recommendation System* (Yadav et al., 2023). Pemilihan ukuran jarak yang tepat akan memengaruhi kualitas hasil analisis maupun performa model yang dibangun. Pada sistem *Content-Based Recommendation*, setiap produk direpresentasikan sebagai sebuah vektor fitur dalam ruang berdimensi banyak. Oleh karena itu, pengukuran jarak antarproduk dapat digunakan untuk menentukan tingkat kemiripan produk. Produk yang memiliki jarak paling kecil terhadap suatu produk acuan dianggap mempunyai karakteristik yang paling mirip sehingga layak direkomendasikan kepada pengguna (Syauqi et al., 2023).

a. Representasi Matematis *Distance Measure*

Misalkan terdapat himpunan objek $X = \{x_1, x_2, \dots, x_n\}$ dengan $x_i = (x_{i1}, x_{i2}, \dots, x_{im})$ merupakan representasi vektor dari objek ke- i . Suatu fungsi jarak (*distance function*) didefinisikan sebagai $D: X \times X \rightarrow \mathbb{R}$ yang memetakan setiap pasangan objek (x_i, x_j) ke suatu nilai $D(x_i, x_j) \geq 0$. Semakin kecil nilai $D(x_i, x_j)$ maka semakin dekat kedua objek tersebut. Sebaliknya, semakin besar nilai $D(x_i, x_j)$ maka semakin berbeda karakteristik kedua objek.

b. Sifat-Sifat *Distance Measure*

Suatu fungsi dikatakan sebagai metrik (*metric distance*) apabila memenuhi empat aksioma berikut.

1. *Non-negativity*

Sifat *Non-negativity* menyatakan bahwa nilai jarak antara dua objek selalu bernilai tidak negatif. Secara matematis, sifat ini dinyatakan sebagai berikut.

$$D(x_i, x_j) \geq 0 \quad (1.12)$$

untuk setiap $x_i, x_j \in X$.

Artinya, nilai jarak yang dihasilkan tidak akan pernah bernilai negatif. Semakin kecil nilai jarak, semakin tinggi tingkat kemiripan antara kedua objek.

2. Identity of Indiscernibles

Sifat *Identity of Indiscernibles* menyatakan bahwa jarak antara dua objek akan bernilai nol jika kedua objek tersebut identik. Secara matematis, sifat ini dinyatakan sebagai berikut.

$$D(x_i, x_j) = 0 \Leftrightarrow x_i = x_j \quad (1.13)$$

Artinya, apabila dua objek memiliki nilai jarak sama dengan nol, maka kedua objek tersebut identik. Sebaliknya, jika nilai jaraknya lebih besar dari nol, maka kedua objek tersebut tidak identik.

3. Symmetry

Sifat *Symmetry* menyatakan bahwa urutan objek tidak memengaruhi nilai jarak yang dihasilkan. Secara matematis, sifat ini dinyatakan sebagai berikut.

$$D(x_i, x_j) = D(x_j, x_i) \quad (1.14)$$

Artinya, jarak dari objek x_i ke objek x_j akan sama dengan jarak dari objek x_j ke objek x_i . Sebagai contoh, jarak dari produk A ke produk B akan sama dengan jarak dari produk B ke produk A.

4. Triangle Inequality

Sifat *Triangle Inequality* menyatakan bahwa jarak langsung antara dua objek tidak akan lebih besar daripada jarak yang ditempuh melalui objek lain. Secara matematis, sifat ini dinyatakan sebagai berikut.

$$D(x_i, x_k) \leq D(x_i, x_j) + D(x_j, x_k) \quad (1.15)$$

untuk setiap $x_i, x_j, x_k \in X$.

Artinya, jarak langsung dari objek x_i ke objek x_k selalu lebih pendek atau sama dengan jarak yang ditempuh melalui objek x_j . Sifat ini menunjukkan bahwa lintasan langsung merupakan jarak terpendek dibandingkan melalui objek lain.

c. Interpretasi Geometris Distance Measure

Secara geometris, *distance measure* menyatakan panjang lintasan yang menghubungkan dua titik pada ruang berdimensi banyak. Misalkan $x_i = (x_{i1}, x_{i2})$ dan $x_j = (x_{j1}, x_{j2})$ merupakan dua titik pada bidang Kartesius. Jarak antara kedua titik tersebut dapat dihitung menggunakan beberapa ukuran jarak, seperti *Euclidean Distance*, *Manhattan Distance*, *Minkowski Distance*, dan *Chebyshev Distance*. Setiap ukuran jarak memiliki konsep perhitungan dan interpretasi geometris yang berbeda, sehingga nilai jarak yang dihasilkan juga dapat berbeda.

d. Distance Measure pada Ruang Berdimensi Tinggi

Pada penelitian sistem rekomendasi, setiap produk biasanya direpresentasikan oleh puluhan bahkan ratusan atribut. Akibatnya, objek tidak lagi berada pada ruang dua dimensi, melainkan pada ruang berdimensi m dengan $m \gg 2$. Dalam kondisi tersebut, *distance measure* dihitung berdasarkan seluruh komponen vektor. Misalkan $x_i = (x_{i1}, x_{i2}, \dots, x_{im})$ dan $x_j = (x_{j1}, x_{j2}, \dots, x_{jm})$ maka fungsi *distance* mempertimbangkan seluruh pasangan komponen (x_{ik}, x_{jk}) untuk $k = 1, 2, \dots, m$. Karena itu, jumlah atribut yang digunakan akan memengaruhi hasil pengukuran jarak.

e. Peranan Distance Measure pada Content-Based Recommendation

Meskipun penelitian ini membahas *Content-Based Recommendation*, metode yang dibandingkan, yaitu *Euclidean Distance* dan *Manhattan Distance*, termasuk ke dalam kelompok *distance measure*, bukan *similarity measure*. Oleh karena itu, nilai jarak yang dihasilkan perlu dikonversi menjadi nilai kemiripan (*similarity*) agar dapat dibandingkan secara langsung dengan metode *Cosine Similarity* dan *Jaccard Similarity*.

Konversi nilai jarak menjadi nilai kemiripan dapat dilakukan menggunakan persamaan berikut.

$$S(x_i, x_j) = \frac{1}{1 + D(x_i, x_j)} \quad (1.16)$$

Melalui persamaan tersebut diperoleh rentang nilai *similarity* sebagai berikut.

$$0 < S(x_i, x_j) \leq 1$$

Nilai *similarity* yang semakin mendekati 1 menunjukkan bahwa kedua produk memiliki tingkat kemiripan yang semakin tinggi. Sebaliknya, nilai *similarity* yang semakin mendekati 0 menunjukkan bahwa kedua produk semakin tidak mirip. Dengan demikian, semakin kecil nilai jarak (*distance*), maka semakin besar nilai *similarity* yang diperoleh. Transformasi ini banyak digunakan dalam sistem rekomendasi karena memungkinkan metode berbasis jarak dibandingkan secara langsung dengan metode berbasis *similarity* (Imelda Lubis et al., 2020).

1.6.5.3 Hubungan antar Similarity Measure dan Distance Measure

Similarity measure dan *distance measure* merupakan dua konsep yang banyak digunakan dalam bidang *pattern recognition*, *data mining*, *machine learning*, dan *information retrieval*. Kedua konsep tersebut digunakan untuk membandingkan dua objek berdasarkan karakteristik yang dimilikinya, tetapi memiliki cara interpretasi yang berbeda (López-García et al., 2022).

Similarity measure menunjukkan tingkat kemiripan antara dua objek, sehingga semakin besar nilai *similarity* yang diperoleh, semakin tinggi pula tingkat kemiripan kedua objek tersebut. Sebaliknya, *distance measure* menunjukkan tingkat

perbedaan atau jarak antara dua objek, sehingga semakin kecil nilai *distance* yang diperoleh, semakin mirip karakteristik kedua objek tersebut. Dengan demikian, kedua konsep ini saling berkaitan karena sama-sama digunakan untuk membandingkan objek, tetapi memiliki arah interpretasi yang berlawanan.

Misalkan diberikan dua objek $x_i, x_j \in X$, dengan $S(x_i, x_j)$ menyatakan nilai *similarity* dan $D(x_i, x_j)$ menyatakan nilai *distance*. Secara konseptual, hubungan antara *similarity* dan *distance* dapat dinyatakan sebagai berikut.

$$S(x_i, x_j) \uparrow \Leftrightarrow D(x_i, x_j) \downarrow \quad (1.17)$$

Artinya, semakin besar nilai *similarity*, maka semakin kecil nilai *distance* yang dihasilkan. Sebaliknya, semakin kecil nilai *similarity*, maka semakin besar nilai *distance* antara kedua objek. Hubungan tersebut dapat dilihat pada gambar 5.



Gambar 5. Hubungan konseptual antara *similarity* dan *distance*

Dalam penelitian ini, metode yang digunakan terdiri atas *Cosine Similarity* dan *Jaccard Similarity* sebagai metode berbasis *similarity measure*, serta *Euclidean Distance* dan *Manhattan Distance* sebagai metode berbasis *distance measure*. Oleh karena itu, nilai *distance* perlu dikonversi menjadi nilai *similarity* agar seluruh metode dapat dibandingkan menggunakan skala yang sama.

a. Transformasi *Distance* menjadi *Similarity*

Dalam sistem rekomendasi, terdapat beberapa metode yang menghasilkan nilai *similarity*, sedangkan metode lainnya menghasilkan nilai *distance*. Agar seluruh metode dapat dibandingkan menggunakan skala yang sama, nilai *distance* perlu ditransformasikan menjadi nilai *similarity* (Fkih, 2022). Transformasi *distance* menjadi *similarity* di rumuskan sebagai berikut.

$$S(x_i, x_j) = \frac{1}{1 + D(x_i, x_j)} \quad (1.18)$$

dengan:

$$D(x_i, x_j) \geq 0$$

di mana $S(x_i, x_j)$ menyatakan nilai *similarity* dan $D(x_i, x_j)$ menyatakan nilai *distance* antara objek x_i dan x_j .

Persamaan tersebut mengubah nilai *distance* ke dalam rentang nilai *similarity* antara 0 dan 1, sehingga semakin kecil nilai *distance*, semakin besar nilai *similarity* yang dihasilkan. Sebaliknya, semakin besar nilai *distance*, semakin kecil nilai *similarity*. Persamaan tersebut memiliki beberapa sifat penting sebagai berikut.

1. Jika $D = 0$, maka $S = 1$. Artinya, dua objek yang identik memiliki nilai *similarity* maksimum.
2. Jika $D \rightarrow \infty$, maka $S \rightarrow 0$. Artinya, semakin besar jarak antara dua objek, semakin kecil nilai *similarity* yang dihasilkan.
3. Jika $0 < D_1 < D_2$, maka $S(D_1) > S(D_2)$. Artinya, apabila suatu objek memiliki jarak yang lebih kecil dibandingkan objek lainnya, maka objek tersebut akan memiliki nilai *similarity* yang lebih besar.

b. Perbandingan Karakteristik *Similarity* dan *Distance*

Perbedaan karakteristik antara *similarity measure* dan *distance measure* dapat dilihat pada tabel 2.

Tabel 2. Perbedaan karakteristik antara *similarity* dan *distance*

Karakteristik	<i>Similarity Measure</i>	<i>Distance Measure</i>
Makna	Mengukur tingkat kemiripan	Mengukur tingkat perbedaan atau jarak
Interpretasi	Semakin besar nilainya, semakin mirip	Semakin kecil nilainya, semakin mirip
Nilai optimum	Maksimum	Minimum
Objek identik	<i>Similarity</i> = 1	<i>Distance</i> = 0
Contoh metode	<i>Cosine Similarity</i> , <i>Jaccard Similarity</i>	<i>Euclidean Distance</i> , <i>Manhattan Distance</i>

Berdasarkan tabel, *similarity measure* dan *distance measure* memiliki tujuan yang sama, yaitu membandingkan dua objek berdasarkan karakteristik yang dimilikinya. Perbedaannya terletak pada cara menginterpretasikan hasil perhitungan.

c. Hubungan Geometris

Misalkan terdapat dua buah vektor $x_i = (x_{i1}, x_{i2})$ dan $x_j = (x_{j1}, x_{j2})$. *Distance measure* menghitung panjang lintasan atau jarak antara kedua titik tersebut. Sebaliknya, *Cosine Similarity* mengukur besar sudut antara kedua vektor sehingga lebih menekankan kesamaan arah daripada jarak antar titik. Akibatnya, dua vektor dapat memiliki jarak yang relatif kecil tetapi arah yang berbeda, atau memiliki arah yang hampir sama tetapi jaraknya cukup besar. Perbedaan interpretasi geometris tersebut menyebabkan setiap metode dapat menghasilkan nilai kemiripan yang berbeda.

1.6.5.4 Sifat-Sifat Matematis *Similarity Measure*

Similarity measure merupakan suatu fungsi matematis yang digunakan untuk mengukur tingkat kemiripan antara dua objek berdasarkan atribut atau karakteristik yang dimilikinya. Dalam berbagai bidang, seperti *pattern recognition*, *machine learning*, *data mining*, dan *content-based recommendation*, fungsi similarity berperan penting dalam menentukan hubungan antarobjek sehingga hasil pengukuran dapat digunakan sebagai dasar proses pengelompokan, pencarian, maupun rekomendasi (Fkih, 2022).

Secara umum, *similarity measure* didefinisikan sebagai fungsi

$$S: X \times X \rightarrow \mathbb{R} \quad (1.19)$$

Keterangan:

X = merupakan himpunan objek

$S(x_i, x_j)$ = menyatakan nilai kemiripan antara objek x_i dan x_j .

Pada banyak metode *similarity*, nilai fungsi berada pada interval

$$0 \leq S(x_i, x_j) \leq 1$$

Semakin besar nilai *similarity*, semakin tinggi tingkat kemiripan antara kedua objek. Sebaliknya, semakin kecil nilai *similarity*, semakin rendah tingkat kemiripan yang dimiliki kedua objek tersebut.

1. *Non-negativity* (Tidak Negatif)

Sifat pertama yang diharapkan dimiliki oleh *similarity measure* adalah *non-negativity*, yaitu nilai kemiripan tidak bernilai negatif. Sifat ini menyatakan bahwa untuk setiap pasangan objek x_i dan x_j pada himpunan X , berlaku

$$S(x_i, x_j) \geq 0, \forall x_i, x_j \in X. \quad (1.20)$$

Sifat *non-negativity* menjamin bahwa nilai similarity selalu bernilai nol atau positif sehingga hasil pengukuran dapat diinterpretasikan secara konsisten. Pada metode similarity yang menghasilkan nilai pada interval $[0, 1]$, nilai yang semakin besar menunjukkan tingkat kemiripan yang semakin tinggi, sedangkan nilai yang semakin kecil menunjukkan tingkat kemiripan yang semakin rendah.

2. *Boundedness* (Memiliki Batas Nilai)

Salah satu sifat yang umum dimiliki oleh *similarity measure* adalah *boundedness*, yaitu nilai kemiripan berada pada suatu interval tertentu sehingga hasil pengukuran memiliki batas yang jelas. Pada banyak metode *similarity* yang digunakan dalam sistem rekomendasi, nilai kemiripan dinyatakan pada interval

$$0 \leq S(x_i, x_j) \leq 1 \quad (1.21)$$

Nilai $S(x_i, x_j) = 0$ menunjukkan bahwa kedua objek memiliki tingkat kemiripan yang sangat rendah atau tidak memiliki kemiripan, sedangkan nilai $S(x_i, x_j) = 1$ menunjukkan bahwa kedua objek memiliki tingkat kemiripan maksimum. Adanya

batas nilai tersebut mempermudah proses interpretasi serta memungkinkan hasil pengukuran dari berbagai metode dibandingkan pada skala yang sama.

3. Identity (Reflexivity)

Sifat *identity* atau *reflexivity* menyatakan bahwa setiap objek memiliki tingkat kemiripan maksimum terhadap dirinya sendiri. Secara matematis, sifat ini dinyatakan sebagai

$$S(x_i, x_i) = 1, \forall x_i \in X \quad (1.22)$$

Sifat ini menunjukkan bahwa suatu objek selalu identik dengan dirinya sendiri sehingga nilai similarity yang dihasilkan merupakan nilai maksimum. Pada metode *similarity* yang menggunakan rentang nilai $[0, 1]$, nilai tersebut sama dengan 1.

4. Symmetry (Simetri)

Sifat *symmetry* menyatakan bahwa nilai kemiripan antara dua objek tidak dipengaruhi oleh urutan objek yang dibandingkan. Dengan demikian, untuk setiap pasangan objek x_i dan x_j berlaku

$$S(x_i, x_j) = S(x_j, x_i), \forall x_i, x_j \in X \quad (1.23)$$

Sifat ini menunjukkan bahwa pertukaran posisi objek tidak mengubah nilai *similarity* yang dihasilkan. Oleh karena itu, apabila suatu metode memenuhi sifat *symmetry*, maka hasil pengukuran kemiripan akan tetap sama meskipun urutan objek dibalik.

1.6.5.5 Kriteria Pemilihan *Similarity Measure*

Pemilihan *similarity measure* merupakan salah satu aspek penting dalam pengembangan sistem *Content-Based Recommendation*. Meskipun berbagai metode *similarity* memiliki tujuan yang sama, yaitu mengukur tingkat kemiripan antarobjek, setiap metode memiliki karakteristik matematis yang berbeda sehingga pemilihannya perlu disesuaikan dengan jenis data, representasi fitur, tujuan analisis, dan efisiensi komputasi (Stitini et al., 2022)

Pada penelitian ini, produk *liquid vape* direpresentasikan menggunakan kombinasi atribut kategorikal dan numerik. Oleh karena itu, pemilihan metode *similarity* menjadi penting agar proses pengukuran kemiripan dapat dilakukan secara tepat sesuai dengan karakteristik data yang digunakan.

1. Jenis Data

Kriteria pertama yang perlu diperhatikan adalah jenis data yang digunakan. Secara umum, data dapat berupa numerik, kategorikal, biner, ordinal, maupun kombinasi dari beberapa jenis data (*mixed data*). Setiap jenis data memiliki karakteristik yang berbeda sehingga memerlukan metode pengukuran kemiripan yang sesuai. Pada penelitian ini, atribut produk *liquid vape* terdiri atas atribut kategorikal, seperti *brand* dan kategori rasa, serta atribut numerik, seperti *volume* dan harga. Oleh karena itu,

seluruh atribut perlu direpresentasikan dalam bentuk yang sesuai sebelum dilakukan proses pengukuran *similarity* (Ravikanth et al., 2024).

2. Sensivitas terhadap Skala Data

Kriteria berikutnya adalah sensitivitas metode terhadap skala data. Beberapa metode, terutama yang berbasis jarak, dipengaruhi oleh perbedaan rentang nilai antaratribut sehingga diperlukan proses normalisasi agar setiap atribut memiliki kontribusi yang seimbang. Dengan demikian, pemilihan metode *similarity* perlu mempertimbangkan apakah data yang digunakan memerlukan proses normalisasi sebelum dilakukan perhitungan (Permana & Nur Salisah, 2022).

3. Interpretasi Hasil

Kemudahan dalam menginterpretasikan hasil juga menjadi pertimbangan dalam memilih *similarity measure*. Metode yang menghasilkan nilai kemiripan pada rentang tertentu, misalnya antara 0 hingga 1, umumnya lebih mudah dipahami karena semakin besar nilainya menunjukkan tingkat kemiripan yang semakin tinggi. Sebaliknya, metode berbasis jarak menghasilkan nilai yang menunjukkan tingkat perbedaan sehingga sering kali memerlukan interpretasi atau transformasi lebih lanjut sebelum digunakan sebagai dasar rekomendasi.

4. Kompleksitas Komputasi

Selain kualitas hasil, efisiensi komputasi juga perlu dipertimbangkan. Pada sistem rekomendasi, proses pengukuran *similarity* dilakukan terhadap banyak pasangan produk sehingga waktu komputasi akan meningkat seiring bertambahnya jumlah data. Oleh karena itu, metode yang digunakan sebaiknya mampu memberikan hasil yang baik dengan kebutuhan komputasi yang tetap efisien.

5. Tujuan Analisis

Kriteria terakhir adalah tujuan analisis. Setiap metode *similarity* memiliki karakteristik yang berbeda sehingga pemilihannya perlu disesuaikan dengan kebutuhan penelitian. Pada penelitian ini, tujuan utama bukan hanya menghasilkan rekomendasi produk, tetapi juga membandingkan karakteristik empat metode *similarity*, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*. Oleh karena itu, keempat metode tersebut dipilih sebagai objek analisis untuk mengetahui metode yang paling sesuai dalam sistem rekomendasi produk *liquid vape* berbasis *Content-Based Recommendation*.

1.6.6 Cosine Similarity

1.6.6.1 Pengertian Cosine Similarity

Cosine Similarity merupakan salah satu metode pengukuran kemiripan (*similarity measure*) yang banyak digunakan dalam bidang *information retrieval*, *text mining*, *machine learning*, dan *recommendation system* (Chowdhury & Sinha, 2024). Berbeda dengan metode berbasis jarak (*distance-based methods*), *Cosine Similarity*

mengukur tingkat kemiripan berdasarkan sudut (*angle*) yang dibentuk oleh dua buah vektor pada ruang multidimensi. Semakin kecil sudut antara kedua vektor, semakin besar nilai *Cosine Similarity* yang diperoleh, sehingga menunjukkan bahwa kedua objek memiliki karakteristik yang semakin mirip (Ristias et al., 2024).

Pada *Content-Based Recommendation*, setiap *item* direpresentasikan sebagai sebuah vektor yang terdiri atas sejumlah fitur atau atribut. Selanjutnya, *Cosine Similarity* digunakan untuk menghitung tingkat kemiripan antara suatu *item* dengan item lainnya berdasarkan representasi vektor tersebut. Karena hanya memperhatikan arah vektor, metode ini sesuai digunakan untuk membandingkan data berdimensi tinggi yang memiliki perbedaan skala nilai pada setiap atribut (Kurniaji & Santi, 2023).

Misalkan terdapat dua buah vektor fitur $x = (x_1, x_2, \dots, x_m)$ dan $y = (y_1, y_2, \dots, y_m)$ yang merepresentasikan dua objek pada ruang fitur berdimensi m . Nilai *Cosine Similarity* dihitung menggunakan persamaan berikut.

$$\text{CosSim}(x, y) = \frac{\sum_{i=1}^m x_i y_i}{\sqrt{\sum_{i=1}^m x_i^2} \sqrt{\sum_{i=1}^m y_i^2}} \quad (1.24)$$

Keterangan:

$\text{CosSim}(x, y)$ = nilai *Cosine Similarity* antara dua objek

x_i = nilai atribut ke- i pada objek pertama

y_i = nilai atribut ke- i pada objek kedua

m = jumlah atribut atau fitur

Persamaan tersebut menunjukkan bahwa nilai *Cosine Similarity* diperoleh dari perbandingan antara hasil kali titik kedua vektor dengan hasil kali panjang masing-masing vektor.

Secara geometris, *Cosine Similarity* mengukur nilai kosinus dari sudut yang dibentuk oleh dua buah vektor. Pada data yang memiliki nilai atribut non-negatif, seperti pada penelitian ini, nilai *Cosine Similarity* berada pada rentang

$$0 \leq \text{CosSim}(x, y) \leq 1$$

Nilai yang semakin mendekati 1 menunjukkan bahwa kedua objek memiliki tingkat kemiripan yang semakin tinggi, sedangkan nilai yang mendekati 0 menunjukkan bahwa kedua objek memiliki tingkat kemiripan yang rendah.

Cosine Similarity memiliki beberapa karakteristik, antara lain mengukur kemiripan berdasarkan arah vektor, tidak sensitif terhadap perbedaan magnitudo, serta sesuai digunakan pada data berdimensi tinggi. Oleh karena itu, metode ini banyak diterapkan pada sistem pencarian dokumen maupun sistem rekomendasi berbasis konten (Supiyanto & Sriyono, 2023).

Meskipun demikian, *Cosine Similarity* juga memiliki beberapa keterbatasan. Metode ini tidak mempertimbangkan besar nilai absolut setiap atribut sehingga kualitas hasil perhitungan sangat dipengaruhi oleh representasi fitur yang digunakan. Selain itu, apabila representasi fitur kurang tepat, nilai kemiripan yang dihasilkan dapat menjadi kurang representatif.

1.6.6.2 Karakteristik *Cosine Similarity*

Cosine Similarity memiliki karakteristik utama berupa pengukuran tingkat kemiripan berdasarkan sudut (*angle*) yang dibentuk oleh dua vektor pada ruang fitur. Metode ini tidak memperhatikan besar kecilnya nilai atau magnitudo vektor, melainkan berfokus pada kesamaan arah vektor sehingga sangat sesuai digunakan pada data berdimensi tinggi (*high-dimensional data*) (Ristias et al., 2024). Pada data yang seluruh atributnya bernilai non-negatif, seperti pada penelitian ini, nilai *Cosine Similarity* berada pada rentang 0 sampai 1. Semakin mendekati nilai satu, semakin tinggi tingkat kemiripan antara kedua objek, sedangkan nilai yang mendekati nol menunjukkan bahwa kedua objek memiliki karakteristik yang semakin berbeda.

1.6.6.3 Kelebihan dan Kekurangan *Cosine Similarity*

Cosine Similarity memiliki beberapa kelebihan, antara lain mampu mengukur kemiripan berdasarkan pola distribusi atribut tanpa dipengaruhi oleh perbedaan magnitudo vektor. Metode ini juga relatif stabil ketika diterapkan pada data berdimensi tinggi, mudah diimplementasikan, serta memiliki kompleksitas komputasi yang efisien sehingga banyak digunakan pada *information retrieval*, *text mining*, dan *Content-Based Recommendation*.

Di samping berbagai kelebihannya, *Cosine Similarity* juga memiliki beberapa keterbatasan. Metode ini tidak memperhatikan besar nilai absolut setiap atribut sehingga dua objek dengan arah vektor yang sama tetapi memiliki nilai atribut yang sangat berbeda masih dapat menghasilkan nilai kemiripan yang tinggi. Selain itu, kualitas hasil pengukuran sangat bergantung pada proses representasi fitur yang digunakan. Oleh karena itu, pemilihan atribut serta teknik *feature engineering* yang tepat menjadi faktor penting agar nilai *similarity* yang dihasilkan benar-benar mencerminkan tingkat kemiripan antarproduk.

1.6.7 Jaccard Similarity

1.6.7.1 Pengertian *Jaccard Similarity*

Jaccard Similarity merupakan salah satu metode pengukuran kemiripan (*similarity measure*) yang didasarkan pada konsep teori himpunan (*set theory*). Metode ini diperkenalkan oleh *Paul Jaccard* untuk mengukur tingkat kesamaan antara dua himpunan berdasarkan jumlah elemen yang dimiliki secara bersama. Dalam perkembangannya, *Jaccard Similarity* banyak digunakan pada berbagai bidang, seperti *information retrieval*, *data mining*, *machine learning*, dan *recommendation system* untuk mengukur kemiripan antarobjek berdasarkan atribut yang dimiliki (Leonardo et al., 2026).

Berbeda dengan *Cosine Similarity* yang mengukur kesamaan arah dua vektor, *Jaccard Similarity* membandingkan banyaknya atribut yang sama terhadap seluruh atribut yang dimiliki oleh kedua objek. Oleh karena itu, metode ini lebih sesuai digunakan pada data kategorikal atau data biner yang hanya memperhatikan keberadaan suatu atribut tanpa mempertimbangkan besar nilainya. Pada sistem

Content-Based Recommendation, *Jaccard Similarity* digunakan untuk menentukan tingkat kemiripan antarproduk berdasarkan atribut yang dimiliki secara bersama sehingga semakin banyak atribut yang sama, semakin tinggi nilai kemiripan yang dihasilkan (Ristias et al., 2024).

Secara matematis, apabila terdapat dua himpunan A dan B , maka *Jaccard Similarity* didefinisikan sebagai berikut.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (1.25)$$

Keterangan:

$|A \cap B|$:= menyatakan jumlah elemen yang dimiliki bersama oleh kedua himpunan

$|A \cup B|$:= menyatakan jumlah seluruh elemen unik pada kedua himpunan

Nilai *Jaccard Similarity* berada pada interval

$$0 \leq J(A, B) \leq 1$$

Nilai yang semakin mendekati satu menunjukkan bahwa kedua objek memiliki tingkat kemiripan yang semakin tinggi, sedangkan nilai yang mendekati nol menunjukkan bahwa kedua objek memiliki sedikit atau bahkan tidak memiliki atribut yang sama.

1.6.7.2 Karakteristik *Jaccard Similarity*

Jaccard Similarity memiliki karakteristik utama berupa pengukuran kemiripan berdasarkan proporsi atribut yang dimiliki secara bersama oleh dua objek. Metode ini hanya memperhitungkan atribut yang muncul pada kedua objek sehingga sangat sesuai digunakan untuk data kategorikal maupun data biner yang telah direpresentasikan menggunakan teknik seperti *One-Hot Encoding*. Selain itu, nilai *Jaccard Similarity* selalu berada pada rentang 0 sampai 1 sehingga hasil perhitungan mudah diinterpretasikan dan dibandingkan antarobjek.

1.6.7.3 Kelebihan dan Kekurangan *Jaccard Similarity*

Jaccard Similarity memiliki beberapa kelebihan, antara lain sederhana, mudah diimplementasikan, mudah diinterpretasikan, serta efektif digunakan untuk data kategorikal dan data biner. Metode ini juga mengabaikan atribut yang sama-sama tidak muncul sehingga lebih representatif dalam membandingkan keberadaan atribut pada dua objek.

Di sisi lain, *Jaccard Similarity* memiliki beberapa keterbatasan. Metode ini tidak mempertimbangkan besar nilai atribut sehingga kurang sesuai diterapkan pada data numerik kontinu. Selain itu, hasil pengukurannya sangat bergantung pada proses representasi atau *encoding* data. Oleh karena itu, pemilihan teknik representasi fitur yang tepat menjadi salah satu faktor penting dalam memperoleh hasil pengukuran kemiripan yang akurat.

1.6.8 Euclidean Distance

1.6.8.1 Pengertian *Euclidean Distance*

Euclidean Distance merupakan salah satu metode pengukuran jarak (*distance measure*) yang banyak digunakan dalam matematika, statistika, *machine learning*, *data mining*, dan sistem rekomendasi. Metode ini mengukur jarak garis lurus (*straight-line distance*) antara dua objek yang direpresentasikan sebagai titik pada ruang berdimensi banyak (*Euclidean space*). Semakin kecil nilai jarak yang dihasilkan, semakin tinggi tingkat kemiripan antara kedua objek (Ermy Pily et al., 2025).

Dalam *Content-Based Recommendation*, setiap produk direpresentasikan sebagai sebuah vektor fitur. *Euclidean Distance* digunakan untuk mengukur tingkat perbedaan antarproduk berdasarkan seluruh atribut yang dimiliki. Secara matematis, jika terdapat dua vektor fitur $x = (x_1, x_2, \dots, x_m)$ dan $y = (y_1, y_2, \dots, y_m)$, maka *Euclidean Distance* dirumuskan sebagai berikut.

$$D_E(x, y) = \sqrt{\sum_{i=1}^m (x_i - y_i)^2} \quad (1.26)$$

Keterangan:

$D_E(x, y)$ = jarak *Euclidean* antara dua vektor fitur

x_i = nilai atribut ke- i pada produk pertama

y_i = nilai atribut ke- i pada produk kedua

m = jumlah atribut atau fitur yang digunakan

Karena metode ini menghasilkan nilai jarak (*distance*), pada penelitian ini nilai *Euclidean Distance* ditransformasikan menjadi nilai *similarity* agar dapat dibandingkan secara langsung dengan metode *Cosine Similarity* dan *Jaccard Similarity*.

1.6.8.2 Karakteristik *Euclidean Distance*

Euclidean Distance memiliki karakteristik utama berupa pengukuran kedekatan antarobjek berdasarkan jarak geometris pada ruang fitur. Metode ini mempertimbangkan seluruh atribut yang dimiliki objek sehingga setiap perbedaan nilai atribut akan memengaruhi hasil perhitungan jarak. Semakin kecil nilai jarak yang diperoleh, semakin tinggi tingkat kemiripan antara kedua objek. Selain itu, *Euclidean Distance* sensitif terhadap perbedaan skala data. Oleh karena itu, atribut numerik umumnya perlu dinormalisasi terlebih dahulu agar tidak terjadi dominasi atribut tertentu dalam proses perhitungan. Metode ini banyak digunakan pada berbagai algoritma analisis data karena memiliki konsep matematis yang sederhana dan mudah diinterpretasikan.

1.6.8.3 Transformasi Menjadi *Similarity*

Metode *Euclidean Distance* menghasilkan nilai berupa jarak (*distance*) yang menunjukkan tingkat perbedaan antara dua *item*. Semakin kecil nilai jarak yang diperoleh, semakin tinggi tingkat kemiripan kedua *item*. Oleh karena itu, diperlukan proses transformasi untuk mengubah nilai jarak menjadi nilai *similarity* yang berada pada rentang 0 hingga 1. Transformasi yang digunakan dalam penelitian ini dirumuskan sebagai berikut.

$$S_E = \frac{1}{1 + D_E} \quad (1.27)$$

Keterangan:

S_E = nilai *similarity* berdasarkan *Euclidean Distance*

D_E = nilai *Euclidean Distance* antara dua *item*

Sebagai contoh, jika diperoleh nilai *Euclidean Distance* sebesar

$$D_E = 0.2245$$

maka nilai *similarity* dihitung sebagai berikut.

$$\begin{aligned} S_E &= \frac{1}{1 + 0.2245} \\ &= \frac{1}{1.2245} \\ &= 0.817 \end{aligned}$$

Hasil perhitungan menunjukkan bahwa nilai *similarity* yang diperoleh adalah sebesar 0,817 atau sekitar 81,7%. Nilai tersebut mengindikasikan bahwa kedua *item* memiliki karakteristik yang cukup mirip. Semakin mendekati nilai 1, semakin tinggi tingkat kemiripan antaritem, sedangkan nilai yang semakin mendekati 0 menunjukkan bahwa kedua *item* memiliki karakteristik yang semakin berbeda.

1.6.8.4 Kelebihan dan Kekurangan *Euclidean Distance*

Euclidean Distance memiliki beberapa kelebihan, antara lain mudah dipahami dan diimplementasikan, memiliki interpretasi geometris yang jelas, serta sesuai digunakan untuk data numerik yang telah direpresentasikan dalam ruang fitur. Selain itu, metode ini banyak digunakan sebagai ukuran jarak standar pada berbagai algoritma *machine learning* sehingga telah teruji pada berbagai bidang aplikasi. Di samping kelebihannya, *Euclidean Distance* juga memiliki beberapa keterbatasan. Metode ini sensitif terhadap perbedaan skala data sehingga memerlukan proses normalisasi apabila atribut memiliki rentang nilai yang berbeda. Selain itu, penggunaan kuadrat selisih pada setiap atribut menyebabkan metode ini lebih peka terhadap nilai pencilan (*outlier*). Pada data berdimensi sangat tinggi, kemampuan metode ini dalam membedakan tingkat kedekatan antarobjek juga dapat menurun akibat fenomena *curse of dimensionality*.

1.6.9 *Manhattan Distance*

1.6.9.1 Pengertian *Manhattan Distance*

Manhattan Distance merupakan salah satu metode pengukuran jarak (*distance measure*) yang menghitung jarak antara dua objek berdasarkan jumlah selisih absolut dari setiap atribut yang dimiliki. Metode ini dikenal pula sebagai *City Block Distance*, *Taxicab Distance*, atau *Rectilinear Distance* karena konsepnya menyerupai jarak yang ditempuh kendaraan pada tata kota berbentuk *grid*, seperti Kota *Manhattan* di *New York* (Uyanik & Orman, 2023).

Dalam bidang *machine learning*, *data mining*, dan *Content-Based Recommendation*, *Manhattan Distance* digunakan untuk mengukur tingkat perbedaan antarobjek yang direpresentasikan sebagai vektor fitur. Berbeda dengan *Euclidean Distance* yang mengukur jarak garis lurus, *Manhattan Distance* menghitung total perpindahan pada setiap dimensi sehingga lebih toleran terhadap perubahan nilai ekstrem (*outlier*) (Abualhaj et al., 2024). Secara matematis, jika terdapat dua vektor fitur $x = (x_1, x_2, \dots, x_m)$ dan $y = (y_1, y_2, \dots, y_m)$, maka *Manhattan Distance* dirumuskan sebagai berikut.

$$D_M(x, y) = \sum_{i=1}^m |x_i - y_i| \quad (1.28)$$

$D_M(x, y)$ = nilai *Manhattan Distance* antara vektor x dan y

x_i = nilai atribut ke- i pada vektor x

y_i = nilai atribut ke- i pada vektor y

m = jumlah atribut yang digunakan

Karena metode ini menghasilkan nilai jarak (*distance*), pada penelitian ini nilai *Manhattan Distance* ditransformasikan menjadi nilai *similarity* agar dapat dibandingkan secara langsung dengan metode *Cosine Similarity*, *Jaccard Similarity*, dan *Euclidean Distance*.

1.6.9.2 Karakteristik *Manhattan Distance*

Manhattan Distance memiliki karakteristik utama berupa pengukuran jarak berdasarkan jumlah selisih absolut setiap atribut (Abualhaj et al., 2024). Setiap atribut memberikan kontribusi secara proporsional terhadap nilai jarak tanpa melalui proses pengkuadratan, sehingga pengaruh nilai yang sangat besar tidak diperkuat sebagaimana pada *Euclidean Distance*. Semakin kecil nilai *Manhattan Distance* yang diperoleh, semakin tinggi tingkat kemiripan antara dua objek yang dibandingkan.

Selain itu, *Manhattan Distance* tetap memerlukan representasi data numerik dan sensitif terhadap perbedaan skala antaratribut. Oleh karena itu, atribut numerik umumnya dinormalisasi sebelum proses perhitungan dilakukan agar setiap atribut memberikan kontribusi yang seimbang terhadap hasil pengukuran.

1.6.9.3 Transformasi Menjadi *Similarity*

Metode *Manhattan Distance* menghasilkan nilai berupa jarak (*distance*) antara dua *item*. Semakin kecil nilai jarak yang diperoleh, semakin tinggi tingkat kemiripan kedua *item*. Oleh karena itu, diperlukan proses transformasi untuk mengubah nilai jarak

menjadi nilai *similarity* yang berada pada rentang 0 hingga 1. Transformasi yang digunakan dalam penelitian ini dirumuskan sebagai berikut.

$$S_M = \frac{1}{1 + D_M} \quad (1.29)$$

Keterangan:

S_M = nilai *similarity* berdasarkan *Manhattan Distance*.

D_M = nilai *Manhattan Distance* antara dua item.

Sebagai contoh, jika diperoleh nilai *Manhattan Distance* sebesar

$$D_M = 0.32$$

maka nilai *similarity* dihitung sebagai berikut.

$$\begin{aligned} S_M &= \frac{1}{1 + 0.32} \\ &= \frac{1}{1.32} \\ &= 0.758 \end{aligned}$$

Hasil tersebut menunjukkan bahwa kedua *item* memiliki tingkat kemiripan sebesar 0,758 atau sekitar 75,8%. Semakin mendekati nilai 1, semakin tinggi tingkat kemiripan antaritem, sedangkan nilai yang semakin mendekati 0 menunjukkan bahwa kedua *item* memiliki karakteristik yang semakin berbeda.

1.6.9.4 Kelebihan dan Kekurangan *Manhattan Distance*

Manhattan Distance memiliki beberapa kelebihan, antara lain mudah dihitung karena hanya menggunakan operasi penjumlahan nilai absolut tanpa melibatkan akar kuadrat. Metode ini juga lebih *robust* terhadap pencilan (*outlier*) dibandingkan *Euclidean Distance*, efisien secara komputasi, serta sesuai digunakan pada data berdimensi tinggi. Selain itu, penggunaan nilai absolut membuat pengaruh perubahan ekstrem pada suatu atribut tidak diperbesar melalui proses kuadrat.

Di samping berbagai kelebihannya, *Manhattan Distance* juga memiliki beberapa keterbatasan. Metode ini tetap sensitif terhadap skala data sehingga memerlukan proses normalisasi sebelum dilakukan perhitungan. Selain itu, *Manhattan Distance* tidak mempertimbangkan hubungan geometris diagonal antarobjek sehingga kurang sesuai apabila struktur data mengikuti ruang *Euclidean*. Metode ini juga tidak memperhatikan arah perubahan atribut, sehingga hasil pengukuran kemiripan dapat berbeda dibandingkan *Euclidean Distance*. Oleh karena itu, pemilihan *Manhattan Distance* perlu disesuaikan dengan karakteristik data dan kebutuhan analisis.

BAB II

METODOLOGI PENELITIAN

2.1 Jenis Penelitian

Pendekatan kuantitatif dipilih karena seluruh proses penelitian didasarkan pada analisis matematis dan pengolahan data numerik. Setiap produk direpresentasikan sebagai sebuah vektor fitur yang dibangun dari atribut produk, yaitu merek (*brand*), kategori rasa, *volume* kemasan, dan harga. Selanjutnya, masing-masing metode *similarity* diterapkan pada *dataset* yang sama untuk memperoleh nilai kemiripan antarproduk.

Penelitian ini menggunakan metode eksperimen komputasional karena setiap metode diimplementasikan menggunakan bahasa pemrograman *Python*, kemudian dilakukan pengujian terhadap *dataset* yang sama sehingga hasil yang diperoleh dapat dibandingkan secara objektif. Perbandingan dilakukan berdasarkan nilai *similarity* yang dihasilkan, urutan (*ranking*) rekomendasi, serta efisiensi komputasi masing-masing metode.

Hasil penelitian diharapkan dapat memberikan informasi mengenai karakteristik masing-masing metode *similarity* serta menentukan metode yang paling sesuai untuk diterapkan pada sistem *Content-Based Recommendation* berbasis atribut produk *liquid vape*.

2.2 Waktu dan Tempat Penelitian

Penelitian ini dilaksanakan pada periode Januari 2026 sampai Juni 2026. Kegiatan penelitian meliputi pengumpulan data produk *liquid vape*, proses *preprocessing* data, implementasi algoritma *Content-Based Recommendation*, pengujian empat metode *similarity measure*, analisis hasil, serta penyusunan laporan penelitian.

Pengumpulan data dilakukan pada toko Clouds Heaven Perintis Makassar yang bersedia memberikan informasi mengenai katalog produk. Data yang diperoleh berupa atribut produk, meliputi nama produk, merek (*brand*), kategori rasa, *volume* kemasan, dan harga. Seluruh proses pengolahan data, implementasi algoritma, dan analisis hasil dilakukan di Laboratorium Komputer Departemen Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin menggunakan perangkat komputer pribadi peneliti.

Implementasi algoritma dilakukan menggunakan bahasa pemrograman *Python* karena menyediakan berbagai pustaka (*library*) yang mendukung pengolahan data dan komputasi numerik. Beberapa pustaka yang digunakan dalam penelitian ini antara lain *NumPy* untuk komputasi numerik, *Pandas* untuk pengelolaan data, serta *Matplotlib* untuk visualisasi hasil. Selain itu, aplikasi *Flask* digunakan untuk membangun antarmuka sederhana sebagai media demonstrasi sistem rekomendasi yang dikembangkan. Penggunaan *Flask* dalam penelitian ini hanya sebagai sarana implementasi dan tidak menjadi objek utama penelitian.

Spesifikasi perangkat keras dan perangkat lunak yang digunakan selama penelitian disajikan pada tabel 3 dan tabel 4.

Tabel 3. Spesifikasi perangkat keras

Komponen	Spesifikasi
Prosesor	Intel Core i5 Generasi ke-10
RAM	8 GB
Media Penyimpanan	SSD minimal 256 GB
Sistem Operasi	Windows 11

Tabel 4. Spesifikasi perangkat lunak

Perangkat Lunak	Fungsi
<i>Python 3.14.3</i>	Implementasi algoritma
<i>NumPy</i>	Komputasi numerik
<i>Pandas</i>	Pengolahan data
<i>Matplotlib</i>	Visualisasi data
<i>Flask</i>	Implementasi antarmuka sistem
<i>Visual Studio Code</i>	Lingkungan pengembangan program

2.3 Variabel Penelitian

Variabel penelitian merupakan karakteristik atau atribut yang digunakan sebagai dasar dalam proses analisis. Pada penelitian ini, variabel dibedakan menjadi tiga kelompok, yaitu variabel *input*, variabel proses, dan variabel *output*.

2.3.1 Variabel *Input*

Variabel *input* merupakan atribut produk *liquid vape* yang digunakan sebagai dasar pembentukan *feature vector*. Seluruh atribut diperoleh dari data katalog produk dan selanjutnya diproses melalui tahapan *feature engineering*. Variabel *input* yang digunakan dalam penelitian ini disajikan pada tabel 5.

Tabel 5. Variabel *input* penelitian

Variabel	Jenis Data	Keterangan
Nama Produk	String	Digunakan untuk identifikasi produk
Brand	Kategorikal	Merek produk <i>liquid vape</i>
Kategori Rasa	Kategorikal	Kategori utama rasa terdiri atas Fruit, Dessert, Tobacco, Coffee, Menthol, Creamy, Beverage, Candy, dan Nuts
Volume	Kategorikal	Isi kemasan produk (mL)
Harga	Numerik	Harga jual produk (Rupiah)

Atribut *brand* dan kategori rasa akan dikonversi ke dalam bentuk numerik menggunakan teknik *One-Hot Encoding*, sedangkan atribut *volume* dan harga akan

dinormalisasi menggunakan metode *Min–Max Normalization* sebelum digunakan dalam perhitungan *similarity*.

2.3.2 Variabel Proses

Variabel proses merupakan komponen yang digunakan dalam proses pengukuran kemiripan antarproduk. Pada penelitian ini, variabel proses terdiri atas empat metode pengukuran kemiripan yang akan dibandingkan, yaitu:

1. *Cosine Similarity*
2. *Jaccard Similarity*
3. *Euclidean Distance*
4. *Manhattan Distance*

Keempat metode tersebut diterapkan pada *dataset* yang sama sehingga hasil yang diperoleh dapat dibandingkan secara objektif.

2.3.3 Variabel Output

Variabel *output* merupakan hasil yang diperoleh setelah proses pengukuran kemiripan dilakukan. Variabel *output* dalam penelitian ini meliputi:


Tabel 6. Variabel *output* penelitian

Variabel	Keterangan
Nilai <i>Similarity</i>	Nilai kemiripan antara dua produk
<i>Ranking</i> Produk	Urutan produk berdasarkan nilai <i>similarity</i>
<i>Top-k Recommendation</i>	Daftar <i>k</i> produk dengan nilai <i>similarity</i> tertinggi
Waktu Komputasi	Lama waktu yang diperlukan untuk proses perhitungan masing-masing metode

Nilai *similarity* digunakan sebagai dasar untuk menyusun daftar rekomendasi produk. Selanjutnya, hasil rekomendasi dari masing-masing metode dibandingkan untuk mengetahui karakteristik dan kinerja setiap metode dalam sistem *Content-Based Recommendation*.

2.3.4 Hubungan Antarvariabel

Hubungan antara variabel *input*, variabel proses, dan variabel *output* dalam penelitian ini dapat digambarkan sebagai berikut.



Gambar 6. Hubungan antarvariabel

Gambar 6 menunjukkan alur proses penelitian yang diawali dari *Variabel Input* yang terdiri atas nama produk, *brand*, kategori *flavor*, volume, dan *price*. Seluruh variabel input tersebut terlebih dahulu diproses melalui tahap *feature engineering* untuk membentuk *feature vector* produk sebagai representasi numerik dari setiap produk. Selanjutnya, *feature vector* tersebut digunakan sebagai masukan pada tahap *Metode Similarity*, yang terdiri atas *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*, untuk menghitung tingkat kemiripan antarproduk. Hasil dari proses tersebut berupa *Variabel Output* yang meliputi nilai *similarity*, *ranking*, *top-k recommendation*, serta waktu komputasi.

2.4 Asumsi Penelitian

Penelitian ini dilakukan berdasarkan beberapa asumsi untuk membatasi ruang lingkup penelitian serta menjaga konsistensi proses analisis. Asumsi-asumsi tersebut digunakan sebagai dasar dalam penerapan metode *Content-Based Recommendation* dan proses perbandingan empat metode *similarity measure*. Adapun asumsi yang digunakan dalam penelitian ini adalah sebagai berikut.

1. Data produk yang digunakan dianggap benar dan representatif. Seluruh informasi mengenai nama produk, merek (*brand*), kategori rasa, *volume* kemasan, dan harga diperoleh dari sumber data yang valid dan diasumsikan telah sesuai dengan kondisi produk yang sebenarnya.
2. Seluruh produk memiliki atribut yang lengkap. Setiap produk pada *dataset* memiliki nilai untuk seluruh atribut yang digunakan dalam penelitian sehingga tidak terdapat *missing value* yang dapat memengaruhi proses perhitungan.
3. Representasi fitur dilakukan secara konsisten. Seluruh atribut kategorikal dikonversi menggunakan teknik *One-Hot Encoding*, sedangkan atribut numerik


dinormalisasi menggunakan metode *Min–Max Normalization*. Proses tersebut diterapkan secara sama pada seluruh produk.

4. Bobot setiap atribut dianggap sama. Penelitian ini tidak memberikan pembobotan khusus terhadap atribut tertentu, sehingga setiap atribut memberikan kontribusi yang setara dalam proses pengukuran kemiripan.
5. Data bersifat statis selama penelitian berlangsung. *Dataset* produk tidak mengalami perubahan atribut maupun penambahan produk selama proses eksperimen sehingga seluruh metode dibandingkan menggunakan dataset yang identik.
6. Parameter implementasi dibuat sama untuk seluruh metode. Setiap metode similarity diterapkan pada *dataset* yang sama dengan proses *preprocessing* yang sama, sehingga perbedaan hasil yang diperoleh hanya disebabkan oleh karakteristik matematis masing-masing metode.
7. Jumlah rekomendasi (*Top-k*) ditetapkan tetap selama proses evaluasi. Nilai *k* ditentukan sebelum eksperimen dilakukan dan digunakan secara konsisten pada seluruh metode agar hasil perbandingan bersifat objektif.
8. Implementasi algoritma dilakukan dalam lingkungan komputasi yang sama. Seluruh eksperimen dijalankan menggunakan perangkat keras, perangkat lunak, dan konfigurasi sistem yang sama sehingga waktu komputasi dapat dibandingkan secara adil.

Berdasarkan asumsi-asumsi tersebut, penelitian ini memfokuskan analisis pada pengaruh perbedaan formulasi matematis *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance* terhadap hasil sistem *Content-Based Recommendation*. Dengan demikian, variasi hasil yang diperoleh diharapkan berasal dari karakteristik metode yang dibandingkan, bukan dari perbedaan kualitas data, proses *preprocessing*, atau lingkungan implementasi..

2.5 Tahapan Penelitian

Penelitian ini dilaksanakan melalui beberapa tahapan yang disusun secara sistematis mulai dari pengumpulan data hingga analisis hasil. Tahapan tersebut bertujuan untuk memastikan bahwa proses perbandingan metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance* dilakukan secara objektif menggunakan data dan prosedur yang sama. Secara umum, alur tahapan penelitian yang dilakukan dapat dilihat pada gambar 7.




Gambar 7. Diagram alir tahapan penelitian

1. Pengumpulan Data, yaitu mengumpulkan data produk *liquid vape* yang terdiri atas nama produk, *brand*, kategori rasa, *volume*, dan harga.
2. *Preprocessing Data*, meliputi proses *data cleaning*, *feature engineering*, *One-Hot Encoding* untuk atribut kategorikal, serta normalisasi atribut numerik sehingga seluruh data siap digunakan dalam proses perhitungan.
3. Pembentukan *Feature Vector*, yaitu mengubah setiap produk menjadi representasi vektor numerik yang digunakan sebagai dasar pengukuran kemiripan antarproduk.
4. Implementasi Metode *Similarity*, yaitu menghitung tingkat kemiripan antarproduk menggunakan empat metode yang dibandingkan, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*. Untuk metode berbasis jarak, nilai *distance* ditransformasikan menjadi *nilai similarity*.
5. Penyusunan Rekomendasi, yaitu mengurutkan nilai *similarity* dari yang terbesar hingga terkecil untuk menghasilkan daftar *Top-k Recommendation* bagi setiap produk.
6. Evaluasi dan Analisis Hasil, yaitu membandingkan kinerja keempat metode berdasarkan indikator evaluasi yang telah ditentukan, kemudian menginterpretasikan hasil untuk menentukan metode yang paling sesuai pada sistem *Content-Based Recommendation* produk *liquid vape*.

2.6 Preprocessing Data

Sebelum dilakukan proses pengukuran kemiripan, data produk *liquid vape* terlebih dahulu melalui tahap *preprocessing*. Tahap ini bertujuan untuk meningkatkan kualitas data, menyeragamkan format data, serta mengubah atribut produk menjadi representasi numerik yang dapat diproses oleh metode *similarity*. Seluruh tahapan *preprocessing* diterapkan secara konsisten pada seluruh data sehingga setiap metode yang dibandingkan menggunakan *dataset* yang sama. Tahapan *preprocessing* yang diterapkan pada penelitian ini ditunjukkan pada gambar 8.



Gambar 8. Tahapan *preprocessing* data


2.6.1 Data Cleaning

Pada tahap ini dilakukan pemeriksaan kualitas data untuk memastikan tidak terdapat data duplikat, data yang tidak lengkap (*missing values*), maupun kesalahan penulisan atribut produk. Selain itu, dilakukan penyeragaman format penulisan nama produk, *brand*, kategori rasa, *volume*, dan harga sehingga data memiliki format yang konsisten.

2.6.2 Feature Engineering

Feature engineering merupakan proses mengubah data mentah menjadi representasi numerik yang dapat diproses oleh algoritma sistem rekomendasi. Pada penelitian ini, *feature engineering* dilakukan terhadap atribut nama produk menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF). Metode ini mengubah teks nama produk menjadi vektor numerik berdasarkan tingkat kepentingan setiap kata dalam keseluruhan kumpulan *dokumen*. Tahapan pembobotan TF-IDF meliputi perhitungan *Term Frequency* (TF), *Inverse Document*

Frequency (IDF), dan pembentukan bobot TF-IDF. Sebelum dilakukan pembobotan, nama produk terlebih dahulu melalui proses tokenisasi untuk memisahkan teks menjadi kumpulan kata atau *token*. Tahapan *feature engineering* yang diterapkan pada penelitian ini ditunjukkan pada gambar 9.



Gambar 9. Tahapan *feature engineering*

2.6.2.1 Term Frequency (TF)

Term Frequency (TF) merupakan metode yang digunakan untuk menghitung frekuensi kemunculan suatu *token* pada sebuah *dokumen*. Semakin sering suatu *token* muncul dalam *dokumen*, maka semakin besar nilai TF yang dimilikinya. Pada penelitian ini, setiap nama produk dianggap sebagai satu *dokumen* sehingga nilai TF menunjukkan banyaknya kemunculan suatu *token* pada nama produk tersebut. Perhitungan TF dilakukan menggunakan persamaan berikut.

$$TF(t, d) = f(t, d) \quad (2.30)$$

Keterangan:

$TF(t, d)$ = nilai *Term Frequency* token t pada dokumen d

$f(t, d)$ = jumlah kemunculan token t pada dokumen d

Sebagai contoh, nama produk THE O RAMA STRAWBERRY CHEESECAKE 60ML setelah melalui proses tokenisasi menghasilkan *token* *the*, *o*, *rama*, *strawberry*, *cheesecake*, dan *60ml*. Karena setiap *token* hanya muncul satu kali, maka seluruh *token* memiliki nilai TF sebesar 1.

2.6.2.2 Inverse Document Frequency (IDF)

Inverse Document Frequency (IDF) merupakan metode yang digunakan untuk mengukur tingkat kepentingan atau keunikan suatu *token* berdasarkan seluruh kumpulan *dokumen* (*corpus*). Berbeda dengan TF yang hanya memperhatikan frekuensi kemunculan *token* pada satu *dokumen*, IDF mempertimbangkan jumlah *dokumen* yang mengandung *token* tersebut. *Token* yang muncul pada banyak *dokumen* akan memiliki nilai IDF yang lebih kecil karena dianggap kurang mampu membedakan karakteristik antar *dokumen*. Sebaliknya, *token* yang hanya muncul pada sedikit *dokumen* akan memiliki nilai IDF yang lebih besar sehingga dianggap lebih representatif dalam membedakan suatu *dokumen* dengan *dokumen* lainnya. Pada penelitian ini, setiap nama produk *liquid vape* dianggap sebagai satu *dokumen*. Nilai IDF dihitung untuk setiap *token* hasil tokenisasi berdasarkan jumlah produk yang mengandung *token* tersebut. Perhitungan IDF dilakukan menggunakan persamaan berikut.

$$IDF(t) = \log\left(\frac{N}{df(t)}\right) \quad (2.31)$$

Keterangan:

$IDF(t)$ = nilai *Inverse Document Frequency* token t

N = jumlah seluruh dokumen

$df(t)$ = jumlah dokumen yang mengandung *token* t

Berdasarkan persamaan tersebut, *token* yang muncul pada hampir seluruh nama produk akan memiliki nilai IDF yang rendah, sedangkan *token* yang hanya muncul pada beberapa produk akan memperoleh nilai IDF yang lebih tinggi. Dengan demikian, *token* yang bersifat unik akan memberikan kontribusi yang lebih besar dalam proses pembobotan.

2.6.2.3 Term Frequency-Inverse Document Frequency (TF-IDF)

Term Frequency-Inverse Document Frequency (TF-IDF) merupakan metode pembobotan yang menggabungkan nilai *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF). Tujuan dari metode ini adalah memberikan bobot yang tinggi pada *token* yang sering muncul dalam suatu dokumen tetapi jarang ditemukan pada dokumen lainnya. Dengan demikian, bobot TF-IDF mampu merepresentasikan tingkat kepentingan setiap *token* dalam membedakan karakteristik suatu dokumen. Nilai TF-IDF diperoleh dengan mengalikan nilai TF dan nilai IDF dari setiap *token*. Perhitungan TF-IDF dilakukan menggunakan persamaan berikut.

$$TF-IDF(t, d) = TF(t, d) \times IDF(t) \quad (2.32)$$

Keterangan:

$TF-IDF(t, d)$ = bobot TF-IDF token t pada dokumen d

$TF(t, d)$ = nilai *Term Frequency* token t

$IDF(t)$ = nilai *Inverse Document Frequency* token t

Pada penelitian ini, pembobotan TF-IDF diterapkan pada atribut nama produk sehingga setiap produk direpresentasikan dalam bentuk vektor numerik. Hasil

pembobotan tersebut digunakan sebagai salah satu komponen dalam pembentukan *feature vector* bersama atribut *brand*, *flavor*, *volume*, dan harga yang telah diproses pada tahapan berikutnya. *Feature vector* yang dihasilkan kemudian menjadi masukan dalam proses perhitungan *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity*.

Sebagai ilustrasi, apabila suatu *token* memiliki nilai TF sebesar 1 dan nilai IDF sebesar 2,30, maka bobot TF-IDF *token* tersebut adalah:

$$TF-IDF = 1 \times 2,30 = 2,30$$

Sebaliknya, apabila suatu token muncul pada hampir seluruh dokumen sehingga memiliki nilai IDF yang kecil, maka bobot TF-IDF yang dihasilkan juga akan lebih kecil. Oleh karena itu, metode TF-IDF mampu memberikan penekanan yang lebih besar pada *token-token* yang memiliki daya pembeda tinggi antar produk.

2.6.3 One-Hot Encoding

Atribut yang bersifat kategorikal, seperti *brand* kategori rasa dan *volume*, dikonversi menjadi bentuk numerik menggunakan teknik *One-Hot Encoding*. Teknik ini menghasilkan representasi biner sehingga setiap kategori dapat diproses oleh metode *similarity* tanpa memberikan hubungan ordinal yang tidak sesuai.

2.6.4 Normalisasi Data

Atribut numerik berupa harga dinormalisasi menggunakan metode *Min-Max Normalization* sehingga seluruh atribut berada pada rentang nilai yang sama. Normalisasi dilakukan untuk menghindari dominasi atribut yang memiliki skala nilai lebih besar pada proses perhitungan jarak maupun kemiripan.

2.6.5 Pembentukan Feature Vector

Tahap terakhir pada *preprocessing* adalah menyusun seluruh atribut yang telah diproses menjadi sebuah *feature vector*. Pada tahap ini, setiap produk direpresentasikan dalam bentuk vektor yang terdiri atas seluruh fitur hasil *preprocessing*. Representasi tersebut dapat dituliskan sebagai berikut.

$$x_i = (x_{i1}, x_{i2}, \dots, x_{im}),$$

dengan m menyatakan jumlah fitur yang digunakan. *Feature vector* ini kemudian menjadi masukan bagi metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance* untuk menghitung tingkat kemiripan antarproduk.

2.7 Formulasi Matematis

Tahap formulasi matematis bertujuan untuk membangun model matematika yang menjadi dasar implementasi sistem *Content-Based Recommendation*. Pada tahap ini, setiap produk *liquid vape* direpresentasikan sebagai sebuah vektor fitur (*feature vector*) yang memuat atribut-atribut produk, sehingga hubungan antarproduk dapat dianalisis menggunakan fungsi *similarity* maupun *distance*.

Misalkan terdapat himpunan produk

$$P = \{P_1, P_2, \dots, P_n\}$$

dengan n menyatakan jumlah seluruh produk yang digunakan dalam penelitian. Setiap produk direpresentasikan sebagai sebuah vektor berdimensi m ,

$$x_i = (x_{i1}, x_{i2}, \dots, x_{im}) \quad (2.33)$$

dengan:

$i = 1, 2, \dots, n$,

m = adalah jumlah fitur hasil proses *feature engineering*,

x_{ij} = adalah nilai fitur ke- j dari produk ke- i .

Seluruh produk kemudian disusun dalam bentuk matriks fitur

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix}$$

yang menjadi masukan bagi seluruh metode pengukuran kemiripan.

Untuk setiap pasangan produk (P_i, P_j) , dihitung nilai kemiripan menggunakan empat metode yang dibandingkan dalam penelitian ini, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*. Khusus untuk metode berbasis jarak, nilai *distance* ditransformasikan menjadi nilai *similarity* sehingga seluruh metode menghasilkan keluaran pada skala yang dapat dibandingkan.


Nilai *similarity* antarproduk disusun dalam bentuk matriks *similarity*

$$S = [s_{ij}]_{n \times n}$$

dengan

$$s_{ij} = S(x_i, x_j)$$


yang menyatakan tingkat kemiripan antara produk ke- i dan produk ke- j . Matriks ini selanjutnya digunakan sebagai dasar penyusunan daftar *Top-k Recommendation*. Secara umum, proses formulasi matematis dalam penelitian ini digambarkan pada gambar 10.



Gambar 10. Diagram formulasi matematis penelitian

2.8 Implementasi Metode *Similarity*

Setelah seluruh data produk melalui tahapan *preprocessing* dan direpresentasikan dalam bentuk *feature vector*, langkah berikutnya adalah menghitung tingkat kemiripan antarproduk menggunakan empat metode *similarity*, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*. Seluruh metode diterapkan pada *dataset* yang sama sehingga hasil yang diperoleh dapat dibandingkan secara objektif. Proses dimulai dari hasil *feature engineering* dan representasi vektor fitur, kemudian dilanjutkan dengan perhitungan tingkat kemiripan menggunakan masing-masing metode. Untuk metode berbasis *distance*, dilakukan transformasi nilai jarak menjadi nilai *similarity*. Selanjutnya, seluruh nilai *similarity* disusun ke dalam matriks *similarity* antarproduk yang menjadi dasar dalam pembentukan *Top-k Recommendation* dan proses perbandingan hasil setiap metode. Alur implementasi metode *similarity* pada penelitian ini ditunjukkan pada gambar 11.

Gambar 11. Alur implementasi metode *similarity*

2.8.1 Implementasi *Cosine Similarity*

Implementasi *Cosine Similarity* dilakukan terhadap setiap pasangan produk yang telah direpresentasikan sebagai *feature vector*. Misalkan terdapat dua produk yang dinyatakan sebagai

$$x_i = (x_{i1}, x_{i2}, \dots, x_{im})$$

dan

$$x_j = (x_{j1}, x_{j2}, \dots, x_{jm})$$

maka nilai *Cosine Similarity* dihitung menggunakan rumus Persamaan berikut.

$$S_C(x_i, x_j) = \frac{\sum_{k=1}^m x_{ik} x_{jk}}{\sqrt{\sum_{k=1}^m x_{ik}^2} \sqrt{\sum_{k=1}^m x_{jk}^2}} \quad (2.34)$$

Keterangan:

$S_C(x_i, x_j)$ = nilai *Cosine Similarity* antara produk i dan produk j

x_{ik} = nilai atribut ke- k pada produk ke- i

x_{jk} = nilai atribut ke- k pada produk ke- j

m = jumlah atribut yang digunakan.

Nilai *Cosine Similarity* dihitung untuk seluruh pasangan produk sehingga diperoleh matriks *similarity*

$$S_C = [s_{ij}]_{n \times n}$$

dengan setiap elemen s_{ij} menyatakan nilai *Cosine Similarity* antara produk ke- i dan produk ke- j . Semakin besar nilai *similarity* yang diperoleh, semakin tinggi tingkat kemiripan antara kedua produk.

2.8.2 Implementasi Jaccard Similarity

Sebelum menghitung *Jaccard Similarity*, atribut kategorikal terlebih dahulu dikonversi ke dalam bentuk data biner menggunakan teknik *One-Hot Encoding*. Proses ini bertujuan agar setiap atribut dapat direpresentasikan sebagai nilai 0 atau 1 sehingga memudahkan proses perhitungan kemiripan antarproduk. Selanjutnya, nilai kemiripan dihitung berdasarkan jumlah atribut yang dimiliki secara bersama oleh setiap pasangan produk. Nilai *Jaccard Similarity* dihitung menggunakan rumus persamaan berikut.

$$S_J = \frac{M_{11}}{M_{11} + M_{10} + M_{01}} \quad (2.35)$$

Keterangan:

M_{11} = jumlah atribut yang bernilai 1 pada kedua produk,

M_{10} = jumlah atribut yang bernilai 1 hanya pada produk pertama,

M_{01} = jumlah atribut yang bernilai 1 hanya pada produk kedua.

Semakin besar nilai *Jaccard Similarity*, semakin tinggi tingkat kemiripan antara kedua produk berdasarkan atribut yang dimilikinya.

2.8.3 Implementasi Euclidean Distance

Implementasi *Euclidean Distance* dilakukan terhadap data yang telah melalui proses normalisasi. Normalisasi bertujuan untuk menyamakan skala setiap atribut sehingga perbedaan rentang nilai antaratribut tidak memengaruhi hasil perhitungan jarak. Nilai *Euclidean Distance* dihitung menggunakan rumus persamaan berikut.

$$D_E = \sqrt{\sum_{k=1}^m (x_{ik} - x_{jk})^2} \quad (2.36)$$

Keterangan:

D_E = nilai *Euclidean Distance*

x_{ik} = nilai atribut ke- k pada produk ke- i

x_{jk} = nilai atribut ke- k pada produk ke- j

m = jumlah atribut yang digunakan.

Karena penelitian ini membandingkan nilai *similarity*, maka nilai *Euclidean Distance* selanjutnya ditransformasikan menjadi nilai *similarity* menggunakan persamaan berikut.

$$S_E = \frac{1}{1 + D_E} \quad (2.37)$$

Semakin kecil nilai *Euclidean Distance*, semakin besar nilai *similarity* yang diperoleh. Sebaliknya, semakin besar nilai *Euclidean Distance*, semakin kecil nilai *similarity* antara kedua produk.

2.8.4 Implementasi *Manhattan Distance*

Implementasi *Manhattan Distance* dilakukan terhadap data yang telah melalui proses normalisasi. Metode ini menghitung jarak antara dua produk berdasarkan jumlah selisih absolut dari setiap atribut yang dibandingkan. Nilai *Manhattan Distance* dihitung menggunakan persamaan berikut.

$$D_M = \sum_{k=1}^m |x_{ik} - x_{jk}| \quad (2.38)$$

Keterangan:

D_M = nilai *Manhattan Distance*,

x_{ik} = nilai atribut ke- k pada produk ke- i ,

x_{jk} = nilai atribut ke- k pada produk ke- j ,

m = jumlah atribut yang digunakan.

Karena penelitian ini membandingkan nilai *similarity*, maka nilai *Manhattan Distance* selanjutnya ditransformasikan menjadi nilai *similarity* menggunakan persamaan berikut.

$$S_M = \frac{1}{1 + D_M} \quad (2.39)$$

Semakin kecil nilai *Manhattan Distance*, semakin besar nilai *similarity* yang diperoleh. Sebaliknya, semakin besar nilai *Manhattan Distance*, semakin kecil nilai *similarity* antara kedua produk.

2.8.5 Penyusunan Matriks *Similarity*

Setelah seluruh metode diimplementasikan, diperoleh empat matriks *similarity*, yaitu *Cosine Similarity* (S_C), *Jaccard Similarity* (S_J), *Euclidean Similarity* (S_E), dan *Manhattan Similarity* (S_M). Setiap matriks berisi nilai kemiripan antara seluruh pasangan produk yang terdapat pada *dataset*.

Secara umum, setiap elemen s_{ij} pada matriks menyatakan tingkat kemiripan antara produk ke- i dan produk ke- j . Semakin besar nilai s_{ij} , semakin tinggi tingkat kemiripan antara kedua produk tersebut. Sebaliknya, nilai yang semakin kecil menunjukkan bahwa kedua produk memiliki karakteristik yang semakin berbeda. Sebagai contoh, sebuah matriks *similarity* dapat dituliskan sebagai berikut.

$$S = \begin{bmatrix} 1.00 & 0.91 & 0.72 \\ 0.91 & 1.00 & 0.81 \\ 0.72 & 0.81 & 1.00 \end{bmatrix}$$

Pada matriks tersebut, nilai diagonal selalu bernilai 1 karena setiap produk memiliki tingkat kemiripan sempurna terhadap dirinya sendiri. Sementara itu, nilai di luar diagonal menunjukkan tingkat kemiripan antarproduk yang selanjutnya digunakan sebagai dasar dalam proses pemeringkatan dan pembentukan rekomendasi.

2.8.6 Pembentukan Rekomendasi (*Top-k Recommendation*)

Setelah diperoleh matriks *similarity* dari masing-masing metode, langkah berikutnya adalah menyusun daftar rekomendasi berdasarkan nilai kemiripan tertinggi. Pada sistem *Content-Based Recommendation*, rekomendasi diberikan dengan memilih sejumlah produk yang memiliki nilai *similarity* terbesar terhadap produk acuan. Jumlah produk yang direkomendasikan dinyatakan dengan parameter k , sehingga metode ini dikenal sebagai *Top-k Recommendation*.

Misalkan tersedia himpunan produk

$$P = \{P_1, P_2, \dots, P_n\},$$

dengan setiap produk direpresentasikan sebagai vektor fitur

$$x_i = (x_{i1}, x_{i2}, \dots, x_{im}).$$

Untuk setiap produk P_i , sistem menghitung nilai *similarity* terhadap seluruh produk lainnya. Nilai *similarity* tersebut kemudian diurutkan dari yang terbesar hingga yang terkecil (*descending*). Dalam proses ini, nilai *similarity* produk terhadap dirinya sendiri tidak disertakan karena sistem tidak merekomendasikan produk yang sama sebagai hasil rekomendasi.

Selanjutnya, sebanyak k produk dengan nilai *similarity* tertinggi dipilih sebagai hasil rekomendasi. Secara matematis, proses tersebut dapat dinyatakan sebagai berikut.

$$Top_k(P_i) = \{P_{j_1}, P_{j_2}, \dots, P_{j_k}\}, \quad (2.40)$$

Keterangan:

$Top_k(P_i)$ = himpunan k produk yang direkomendasikan untuk produk P_i ,

P_i = produk acuan,


P_j = produk yang memiliki nilai *similarity* tertinggi terhadap P_i ,

k = jumlah produk yang direkomendasikan.

Hasil dari proses ini berupa daftar produk dengan nilai *similarity* tertinggi yang selanjutnya ditampilkan kepada pengguna sebagai rekomendasi.

2.9 Evaluasi Kinerja

Tahap evaluasi kinerja bertujuan untuk membandingkan performa empat metode *similarity measure*, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*, dalam menghasilkan rekomendasi produk *liquid vape*. Evaluasi dilakukan menggunakan beberapa indikator yang mencerminkan kualitas hasil rekomendasi maupun efisiensi komputasi. Seluruh metode dievaluasi menggunakan *dataset* yang sama sehingga hasil perbandingan bersifat objektif. Pada penelitian ini, evaluasi dilakukan berdasarkan lima aspek utama, yaitu kualitas nilai *similarity*, akurasi rekomendasi, stabilitas peringkat rekomendasi, efisiensi waktu komputasi, dan efisiensi penggunaan memori.



Gambar 12. Diagram proses evaluasi kinerja

2.9.1 Evaluasi Nilai *Similarity*

Indikator pertama yang digunakan dalam penelitian ini adalah rata-rata nilai *similarity* yang dihasilkan oleh setiap metode. Indikator ini digunakan untuk memberikan gambaran umum mengenai kecenderungan masing-masing metode dalam menghasilkan tingkat kemiripan antarproduk.

Misalkan S_i menyatakan nilai *similarity* untuk pasangan produk ke- i , maka rata-rata nilai *similarity* dihitung menggunakan rumus persamaan berikut.

$$\bar{S} = \frac{1}{N} \sum_{i=1}^N S_i \quad (2.41)$$

Keterangan:

$\bar{S}$ = rata-rata nilai *similarity*

S_i = nilai *similarity* pasangan produk ke- i

N = jumlah pasangan produk yang dibandingkan

Semakin besar nilai rata-rata *similarity* yang diperoleh, semakin tinggi kecenderungan metode tersebut dalam menghasilkan nilai kemiripan antarproduk. Nilai ini selanjutnya digunakan sebagai salah satu indikator untuk membandingkan karakteristik masing-masing metode.

2.9.2 Evaluasi Akurasi Rekomendasi

Apabila tersedia *ground truth* atau data referensi mengenai produk yang dianggap relevan, maka kualitas hasil rekomendasi dapat dievaluasi menggunakan beberapa metrik yang umum digunakan pada sistem rekomendasi, yaitu *Precision@k*, *Recall@k*, dan *F1-Score*. Metrik-metrik tersebut digunakan untuk mengukur tingkat ketepatan dan kelengkapan hasil rekomendasi.

a. *Precision@k*

Precision@k mengukur proporsi produk yang relevan di dalam daftar rekomendasi sebanyak k produk. Nilai *Precision@k* dihitung menggunakan rumus Persamaan berikut.

$$\text{Precision@k} = \frac{\text{Jumlah produk relevan yang direkomendasikan}}{k} \quad (2.42)$$

Semakin besar nilai *Precision@k*, semakin tinggi ketepatan sistem dalam memberikan rekomendasi yang relevan.

b. *Recall@k*

Recall@k mengukur kemampuan sistem dalam menemukan seluruh produk yang relevan dari data referensi. Nilai *Recall@k* dihitung menggunakan Persamaan berikut.

$$\text{Recall@k} = \frac{\text{Jumlah produk relevan yang direkomendasikan}}{\text{Jumlah seluruh produk relevan}} \quad (2.43)$$

Semakin besar nilai *Recall@k*, semakin banyak produk relevan yang berhasil direkomendasikan oleh sistem.

c. *F1-Score*

F1-Score merupakan rata-rata harmonik antara *Precision* dan *Recall*, sehingga mampu memberikan ukuran yang lebih seimbang terhadap performa sistem. Nilai *F1-Score* dihitung menggunakan rumus persamaan berikut.

$$F_1 = \frac{2PR}{P + R} \quad (2.44)$$

Keterangan:

P = *Precision*

R = *Recall*

Semakin besar nilai *F1-Score*, semakin baik keseimbangan antara ketepatan (*precision*) dan kelengkapan (*recall*) hasil rekomendasi.

2.9.3 Evaluasi *Ranking*

Selain menghasilkan nilai *similarity*, setiap metode juga menghasilkan urutan (*ranking*) rekomendasi berdasarkan nilai kemiripan tertinggi. Salah satu metrik yang umum digunakan untuk mengevaluasi kualitas *ranking* adalah *Mean Reciprocal Rank* (MRR). Nilai MRR dihitung menggunakan rumus persamaan berikut.

$$MRR = \frac{1}{Q} \sum_{i=1}^Q \frac{1}{rank_i} \quad (2.45)$$

Keterangan:

MRR= *Mean Reciprocal Rank*

Q= jumlah *query* atau pencarian yang dievaluasi

rank_i= posisi produk relevan pertama pada *query* ke-*i*

Semakin besar nilai MRR, semakin baik kualitas *ranking* yang dihasilkan karena menunjukkan bahwa produk yang relevan cenderung muncul pada posisi teratas dalam daftar rekomendasi.

2.9.4 Evaluasi Waktu Komputasi

Selain membandingkan nilai *similarity* yang dihasilkan, penelitian ini juga mengevaluasi efisiensi setiap metode berdasarkan waktu komputasi yang diperlukan untuk menghitung nilai *similarity*. Waktu komputasi dihitung sebagai selisih antara waktu mulai proses dan waktu selesai proses, yang dinyatakan dengan rumus persamaan berikut.

$$T = t_{finish} - t_{start} \quad (2.46)$$

Keterangan:

T= waktu komputasi

t_{start}= waktu mulai proses

t_{finish}= waktu selesai proses

Waktu komputasi diukur dalam satuan detik. Semakin kecil nilai *T*, semakin efisien metode tersebut dalam melakukan proses perhitungan.

2.9.5 Evaluasi Penggunaan Memori

Selain waktu komputasi, penelitian ini juga mengevaluasi efisiensi setiap metode berdasarkan penggunaan memori selama proses perhitungan *similarity*. Penggunaan memori dihitung sebagai selisih antara memori setelah proses selesai dan memori sebelum proses dimulai, yang dinyatakan dengan Persamaan berikut.

$$M = M_{after} - M_{before} \quad (2.47)$$

Keterangan:

M= penggunaan memori

M_{before}= penggunaan memori sebelum proses perhitungan

M_{after}= penggunaan memori setelah proses perhitungan

Penggunaan memori diukur dalam satuan *megabyte* (MB) atau satuan lain yang digunakan pada proses pengujian. Semakin kecil nilai M , semakin efisien metode tersebut dalam memanfaatkan sumber daya memori.

2.9.6 Penentuan Metode Terbaik

Penentuan metode terbaik dilakukan berdasarkan keseluruhan hasil evaluasi yang diperoleh pada setiap metode. Dalam penelitian ini, penilaian tidak hanya didasarkan pada satu indikator, tetapi mempertimbangkan kualitas nilai *similarity* yang dihasilkan serta efisiensi komputasi selama proses perhitungan. Secara umum, metode yang menghasilkan nilai *similarity* yang lebih baik dengan waktu komputasi dan penggunaan memori yang lebih rendah dapat dianggap memiliki kinerja yang lebih baik. Namun, apabila terdapat perbedaan performa pada masing-masing indikator, maka dilakukan analisis terhadap kelebihan dan keterbatasan setiap metode untuk memperoleh kesimpulan yang lebih komprehensif.

Setelah seluruh proses evaluasi dilakukan, hasil pengukuran dari setiap metode *similarity* direkapitulasi ke dalam satu tabel untuk memudahkan proses perbandingan kinerja. Rekapitulasi tersebut memuat nilai *Average Similarity*, *Precision@5*, *Recall@5*, *F1-Score*, *Mean Reciprocal Rank* (MRR), *Runtime*, dan *Memory Usage* dari masing-masing metode yang digunakan. Hasil rekapitulasi tersebut selanjutnya digunakan sebagai dasar dalam menentukan metode yang memberikan kinerja terbaik. Dalam penentuan metode terbaik kita memberikan memberikan pembobotan dan disajikan pada tabel berikut

Tabel 7. Bobot penentuan metode terbaik

Komponen	Bobot	Persentase	Arah
Average Similarity	0.20	20%	Semakin besar semakin baik
Precision@5	0.35	35%	Semakin besar semakin baik
Recall@5	0.15	15%	Semakin besar semakin baik
F1-Score@5	0.15	15%	Semakin besar semakin baik
MRR	0.10	10%	Semakin besar semakin baik
Runtime	0.03	3%	Semakin kecil semakin baik
Memory	0.02	2%	Semakin kecil semakin baik

2.10 Analisis Hasil

Tahap analisis hasil bertujuan untuk menginterpretasikan hasil yang diperoleh dari penerapan empat metode *similarity measure*, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*, pada sistem *Content-Based Recommendation*. Analisis dilakukan secara komparatif untuk mengetahui karakteristik, kelebihan, dan keterbatasan masing-masing metode berdasarkan indikator evaluasi yang telah ditetapkan. Analisis dilakukan setelah seluruh metode diterapkan pada *dataset* yang sama sehingga diperoleh matriks *similarity*, daftar *Top-k Recommendation*, serta hasil evaluasi setiap metode. Dengan menggunakan

dataset dan prosedur yang sama, perbedaan hasil yang diperoleh diharapkan mencerminkan karakteristik matematis dari masing-masing metode.

2.10.1 Analisis Nilai *Similarity*

Tahap pertama adalah menganalisis nilai *similarity* yang dihasilkan oleh masing-masing metode. Analisis ini bertujuan untuk mengetahui karakteristik setiap metode dalam mengukur tingkat kemiripan antarproduk.

Beberapa aspek yang dianalisis meliputi:

1. rentang nilai *similarity*
2. rata-rata (*average similarity*)
3. nilai maksimum dan minimum
4. penyebaran nilai *similarity*

Hasil analisis tersebut digunakan untuk membandingkan kecenderungan setiap metode dalam menghasilkan nilai kemiripan, sehingga dapat diketahui metode yang memberikan tingkat *similarity* lebih tinggi atau lebih rendah dibandingkan metode lainnya.

2.10.2 Analisis Hasil Rekomendasi

Tahap berikutnya adalah membandingkan hasil *Top-k Recommendation* yang dihasilkan oleh masing-masing metode. Tujuan analisis ini adalah untuk mengetahui persamaan dan perbedaan rekomendasi yang diberikan oleh setiap metode berdasarkan nilai *similarity*.

Beberapa aspek yang dianalisis meliputi:

1. kesamaan produk yang direkomendasikan
2. perbedaan urutan (*ranking*) rekomendasi
3. perubahan posisi produk dalam daftar rekomendasi

Hasil analisis digunakan untuk mengetahui sejauh mana perbedaan metode *similarity* memengaruhi hasil rekomendasi yang diberikan kepada pengguna.

2.10.3 Analisis Efisiensi Komputasi

Selain membandingkan hasil *similarity* dan rekomendasi yang dihasilkan, penelitian ini juga menganalisis efisiensi komputasi dari masing-masing metode. Analisis dilakukan untuk mengetahui kebutuhan sumber daya komputasi selama proses perhitungan *similarity*.

Beberapa aspek yang dianalisis meliputi:

1. waktu komputasi (*runtime*)
2. penggunaan memori (*memory usage*)

Perbandingan dilakukan menggunakan dataset dan prosedur yang sama sehingga hasil yang diperoleh dapat dibandingkan secara objektif.

2.10.4 Analisis Perbandingan Metode

Tahap selanjutnya adalah melakukan analisis komparatif terhadap keempat metode berdasarkan seluruh indikator evaluasi yang telah ditetapkan. Analisis ini bertujuan untuk mengidentifikasi karakteristik, kelebihan, dan keterbatasan masing-masing metode.

Perbandingan dilakukan berdasarkan beberapa aspek, yaitu:

1. nilai *similarity* yang dihasilkan
2. hasil *Top-k Recommendation*
3. waktu komputasi (*runtime*)
4. penggunaan memori (*memory usage*)
5. kesesuaian metode terhadap karakteristik data produk *liquid vape*.

Hasil analisis disajikan dalam bentuk tabel dan grafik untuk memudahkan proses interpretasi dan penarikan kesimpulan.

2.10.5 Analisi Studi Kasus

Untuk memberikan gambaran yang lebih jelas mengenai hasil rekomendasi, penelitian ini melakukan analisis terhadap beberapa produk sebagai studi kasus. Pada tahap ini, beberapa produk dipilih sebagai produk acuan, kemudian hasil *Top-k Recommendation* yang dihasilkan oleh keempat metode dibandingkan.


Analisis dilakukan dengan memperhatikan kesesuaian atribut produk yang direkomendasikan, meliputi:

1. kesamaan nama produk
2. kesamaan *brand*
3. kesamaan kategori rasa
4. kesamaan volume
5. kesamaan harga.

Hasil analisis studi kasus digunakan untuk memberikan interpretasi yang lebih mudah dipahami terhadap perbedaan hasil rekomendasi yang dihasilkan oleh masing-masing metode.

2.10.6 Penarikan Kesimpulan

Tahap terakhir adalah menyusun kesimpulan berdasarkan seluruh hasil analisis yang telah dilakukan. Kesimpulan disusun dengan mengintegrasikan hasil perbandingan keempat metode *similarity* sehingga diperoleh gambaran mengenai karakteristik, kelebihan, dan keterbatasan masing-masing metode. Penyusunan kesimpulan dilakukan dengan mempertimbangkan seluruh indikator evaluasi yang digunakan dalam penelitian, meliputi nilai *similarity*, hasil *Top-k Recommendation*, efisiensi komputasi, serta karakteristik matematis dari setiap metode. Secara umum, tahapan analisis hasil dalam penelitian ini dapat dilihat pada gambar 13.



Gambar 13. Analisis hasil penelitian

BAB III HASIL DAN PEMBAHASAN

3.1 Deskripsi Dataset

3.1.1 Statistik Deskriptif Dataset

Sebelum dilakukan proses *feature engineering* dan perhitungan *similarity*, dilakukan analisis statistik deskriptif terhadap atribut numerik pada *dataset*, yaitu *volume* dan harga. Analisis ini bertujuan untuk memberikan gambaran mengenai karakteristik data, seperti nilai minimum, nilai maksimum, nilai rata-rata, median, dan simpangan baku. Informasi tersebut juga digunakan sebagai dasar dalam proses normalisasi data sehingga setiap atribut numerik memiliki skala yang sebanding. Hasil analisis statistik deskriptif atribut numerik disajikan pada tabel 7.

Tabel 8. Statistik deskriptif atribut numerik

Statistik	Volume	Harga
Minimum	30	70.000
Maksimum	60	170.000
Rata-rata	46,8	125.845
Median	60	125.000
Simpangan Baku	14,9	22.332

Berdasarkan tabel 8, atribut *volume* memiliki rentang nilai antara 30 mL hingga 60 mL, sedangkan atribut harga berada pada rentang Rp70.000 sampai Rp170.000 dengan rata-rata Rp125.845. Informasi ini menunjukkan bahwa atribut numerik memiliki rentang nilai yang berbeda sehingga perlu dilakukan proses normalisasi sebelum digunakan dalam perhitungan *similarity*.

3.1.2 Distribusi *Brand*

Distribusi *brand* dianalisis untuk mengetahui sebaran jumlah produk pada setiap merek dalam *dataset* yang digunakan. Hasil analisis menunjukkan bahwa jumlah produk pada masing-masing *brand* tidak tersebar secara merata. Sebagian *brand* memiliki jumlah produk yang lebih banyak dibandingkan *brand* lainnya, sehingga memberikan gambaran mengenai komposisi *dataset* yang digunakan dalam penelitian ini. Distribusi produk berdasarkan brand disajikan pada tabel 8.

Tabel 9. Distribusi produk berdasarkan *brand*

No	Brand	Jumlah Produk	Persentase (%)
1	FOOM	63	6,3
2	PF	53	5,3
3	BEQU	30	3,0
4	BUAQITA	28	2,8
5	CRACKZ	23	2,3
6	JUTA	20	2,0
7	VOLX	18	1,8
8	VIRAL	17	1,7
9	RILLA	17	1,7
10	THE O RAMA	15	1,5

Berdasarkan tabel 9, brand FOOM memiliki jumlah produk terbanyak, yaitu sebanyak 63 produk (6,3%), diikuti oleh PF sebanyak 53 produk (5,3%) dan BEQU sebanyak 30 produk (3,0%). Sementara itu, brand THE O RAMA menempati urutan kesepuluh dengan 15 produk (1,5%). Hasil tersebut menunjukkan bahwa distribusi produk antarbrand tidak merata, di mana hanya beberapa brand memiliki jumlah produk yang relatif lebih banyak dibandingkan brand lainnya.

3.1.3 Distribusi Kategori Rasa

Distribusi kategori rasa dianalisis untuk mengetahui sebaran produk berdasarkan kategori rasa utama dalam dataset yang digunakan. Hasil analisis menunjukkan bahwa jumlah produk pada setiap kategori rasa memiliki distribusi yang berbeda. Informasi ini memberikan gambaran mengenai karakteristik dataset berdasarkan preferensi rasa yang tersedia serta menjadi dasar dalam proses pengukuran kemiripan pada sistem rekomendasi. Distribusi produk berdasarkan kategori rasa disajikan pada tabel 10.

Tabel 10. Distribusi produk berdasarkan kategori rasa

No	Kategori Rasa	Jumlah Produk	Persentase (%)
1	Fruit	352	35,4
2	Dessert	305	30,7
3	Beverage	101	10,2
4	Candy	89	9,0
5	Menthol	83	8,4
6	Creamy	29	2,9
7	Coffee	22	2,2
8	Nuts	7	0,7
9	Tobacco	6	0,6

Berdasarkan Tabel 10, kategori rasa Fruit mendominasi dataset dengan jumlah 352 produk atau 35,4% dari keseluruhan data. Kategori Dessert berada pada urutan kedua dengan 305 produk (30,7%), diikuti oleh Beverage sebanyak 101 produk (10,2%) dan Candy sebanyak 89 produk (9,0%). Sementara itu, kategori Nuts dan Tobacco memiliki jumlah produk paling sedikit, masing-masing sebanyak 7 produk (0,7%) dan 6 produk (0,6%). Hasil tersebut menunjukkan bahwa dataset didominasi oleh produk dengan kategori rasa Fruit dan Dessert, sehingga kedua kategori tersebut memiliki proporsi yang lebih besar dibandingkan kategori rasa lainnya.

3.1.4 Distribusi Volume

Distribusi *volume* dianalisis untuk mengetahui sebaran produk berdasarkan ukuran kemasan dalam dataset yang digunakan. Hasil analisis menunjukkan bahwa produk hanya tersedia dalam dua variasi *volume*, yaitu 30 mL dan 60 mL. Distribusi tersebut memberikan gambaran mengenai komposisi atribut *volume* yang digunakan dalam proses pengukuran *similarity*. Distribusi produk berdasarkan *volume* disajikan pada tabel 11.

Tabel 11. Distribusi produk berdasarkan volume

No	Volume (mL)	Jumlah Produk	Persentase (%)
1	30	437	44,0
2	60	557	56,0

Berdasarkan tabel 11, produk dengan volume 60 mL mendominasi dataset dengan jumlah 557 produk (56,0%), sedangkan produk dengan volume 30 mL berjumlah 437 produk (44,0%). Hasil tersebut menunjukkan bahwa distribusi volume relatif seimbang, meskipun produk berukuran 60 mL memiliki jumlah yang lebih banyak.

3.1.5 Distribusi Harga

Distribusi harga dianalisis untuk mengetahui sebaran produk berdasarkan rentang harga dalam dataset yang digunakan. Hasil analisis menunjukkan bahwa sebagian besar produk berada pada rentang harga menengah, sedangkan hanya sebagian kecil produk yang berada pada rentang harga rendah maupun tinggi. Distribusi produk berdasarkan rentang harga disajikan pada tabel 11.

Tabel 12. Distribusi harga

No	Rentang Harga (Rp)	Jumlah Produk	Persentase (%)
1	< 100.000	88	8,9
2	100.000–150.000	675	67,9
3	150.001–200.000	231	23,2
4	> 200.000	0	0,0

Berdasarkan tabel 12, sebagian besar produk berada pada rentang harga Rp100.000–Rp150.000, yaitu sebanyak 675 produk (67,9%). Produk dengan rentang harga Rp150.001–Rp200.000 berjumlah 231 produk (23,2%), sedangkan produk

dengan harga di bawah Rp100.000 sebanyak 88 produk (8,9%). Tidak terdapat produk dengan harga di atas Rp200.000 pada dataset yang digunakan.

3.2 Hasil *Preprocessing Data*

Sebelum dilakukan perhitungan *similarity*, dataset produk *liquid vape* terlebih dahulu melalui serangkaian proses *preprocessing*. Tahapan ini bertujuan untuk meningkatkan kualitas data, menyeragamkan format atribut, serta mengubah seluruh atribut menjadi representasi numerik yang dapat diproses oleh metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*.

3.2.1 Hasil *Data Cleaning*

Tahap pertama dalam *preprocessing* adalah *data cleaning*, yang bertujuan memastikan *dataset* memiliki kualitas yang baik sebelum digunakan pada proses perhitungan *similarity*. Proses ini meliputi pemeriksaan data duplikat, pemeriksaan *missing value*, serta penyeragaman format atribut seperti nama produk, *brand*, kategori rasa, *volume*, dan harga agar seluruh data memiliki format yang konsisten. Ringkasan hasil data *cleaning* disajikan pada tabel 12.

Tabel 13. Hasil data cleaning

Keterangan	Hasil
Jumlah Data Awal	1074
Jumlah Kolom	5
Total <i>Missing Value</i>	0
Jumlah Data Duplikat	78
Jumlah Data Setelah <i>Cleaning</i>	996
Volume Minimum	30
Volume Maksimum	60
Harga Minimum	Rp 70000
Harga Maksimum	Rp 170000

Berdasarkan tabel 13. hasil data *cleaning*, tidak ditemukan data yang memiliki *missing value*. Namun, terdapat 78 data duplikat yang dihapus sehingga jumlah data berkurang dari 1.074 produk menjadi 996 produk. Setelah proses pembersihan selesai, *dataset* terdiri atas lima atribut utama, yaitu *product_name*, *brand*, *flavor*, *volume*, dan *price*, yang selanjutnya digunakan pada tahapan *preprocessing* berikutnya.

3.2.2 Hasil *Feature Engineering*

Pada tahap *feature engineering*, atribut nama produk diubah menjadi representasi numerik menggunakan metode *Term Frequency-Inverse-Document Frequency* (TF-IDF). Sebelum dilakukan pembobotan, setiap nama produk terlebih dahulu melalui proses tokenisasi sehingga diperoleh kumpulan *token* yang mewakili karakteristik masing-masing produk. Selanjutnya dilakukan perhitungan nilai TF, IDF, dan TF-IDF untuk setiap token sehingga menghasilkan bobot numerik yang dapat digunakan dalam proses perhitungan *similarity*.

3.2.2.1 Hasil Tokenisasi

Tokenisasi merupakan proses memecah teks menjadi unit-unit kata (*token*) yang akan digunakan pada proses pembobotan *TF-IDF*. Pada penelitian ini, proses tokenisasi diterapkan pada atribut nama produk dengan tujuan memisahkan setiap nama produk menjadi kumpulan *token* yang mewakili karakteristik produk. Hasil tokenisasi disajikan pada Tabel 14.

Tabel 14. Hasil tokenisasi

No	Token
1	THE
2	O
3	RAMA
...	...
4150	ZOO

3.2.2.2 Hasil Perhitungan *Term Frequency* (TF)

Tahap pertama dalam pembobotan *TF-IDF* adalah menghitung *Term Frequency* (TF), yaitu jumlah kemunculan setiap *token* pada masing-masing nama produk. Karena sebagian besar nama produk *liquid vape* terdiri atas kata-kata yang unik dan tidak mengalami pengulangan dalam satu nama produk, maka nilai TF setiap *token* umumnya bernilai 1. Ringkasan hasil TF ditunjukkan pada tabel 15.

Tabel 15. Hasil pembobotan *term frequency*

No	Token	TF
1	CHEESECAKE	1
2	O	1
3	PF	1
4	...	...
...	...	...
4134	CHIZNANARILLA	1

Berdasarkan hasil tokenisasi terhadap 996 nama produk, diperoleh sebanyak 4.134 *token* dengan 603 *token* unik. Perbedaan antara jumlah *token* dan *token* unik menunjukkan bahwa terdapat *token* yang digunakan pada lebih dari satu nama produk. *Token-token* yang muncul berulang pada beberapa produk tetap memiliki

nilai *TF* sebesar 1 pada masing-masing dokumen, tetapi frekuensi kemunculannya di seluruh kumpulan dokumen akan memengaruhi nilai *IDF* pada tahap pembobotan berikutnya. Dengan demikian, *token* yang sering muncul pada banyak produk akan memperoleh bobot yang lebih kecil dibandingkan *token* yang lebih spesifik atau jarang digunakan.

3.2.2.3 Hasil Perhitungan *Inverse Document Frequency* (IDF)

Setelah nilai *TF* diperoleh, langkah berikutnya adalah menghitung *Inverse Document Frequency* (IDF) untuk mengetahui tingkat kepentingan setiap token berdasarkan seluruh kumpulan nama produk.

Token yang muncul pada banyak produk akan memiliki nilai *IDF* yang lebih kecil karena dianggap kurang mampu membedakan karakteristik produk. Sebaliknya, token yang hanya muncul pada sedikit produk akan memperoleh nilai *IDF* yang lebih besar. Ringkasan hasil perhitungan *IDF* ditunjukkan pada tabel 15.

Tabel 16. Hasil perhitungan *inverse document frequency* (IDF)

No	Token	Document Frequency	IDF
1	A	1	6,90
2	AB	3	5,81
3	ALA	14	4,26
...	...	...	...
603	ZOO	1	6,90

3.2.2.4 Hasil Pembobotan *TF-IDF*

Setelah nilai *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF) diperoleh, tahap selanjutnya adalah menghitung bobot *Term Frequency-Inverse Document Frequency* (TF-IDF) untuk setiap *token* pada masing-masing nama produk. Hasil pembobotan *TF-IDF* membentuk sebuah matriks, di mana setiap baris merepresentasikan satu produk, sedangkan setiap kolom merepresentasikan satu token unik hasil tokenisasi. Nilai pada setiap sel menunjukkan bobot *TF-IDF* suatu token terhadap produk tertentu. Semakin besar nilai *TF-IDF*, semakin besar kontribusi *token* tersebut dalam merepresentasikan karakteristik produk. Sebaliknya, *token* yang tidak terdapat pada suatu produk akan memiliki nilai *TF-IDF* sebesar 0. Ringkasan hasil pembobotan *TF-IDF* pada tabel 16.

Tabel 17. Hasil pembobotan tf-idf pada setiap produk

No	Nama Produk	A	AB	ALA	...	ZOO
1	THE O RAMA STRAWBERRY CHEESECAKE PF	0	0	0	...	0
2	SALT JACKPOT XTRA ICE PINEAPPLE 30ML	0	0	0	...	0
3	SALT JACKPOT XTRA ICE MANGO 30ML	0	0	0	...	0
...	...	...	...	...	...	...
996	CHIZNANARILLA 60ML 3MG	0	0	0	...	0

3.2.3 Hasil *One-Hot Encoding*

Setelah proses *feature engineering*, atribut *brand*, *flavor*, dan *volume* yang masih berbentuk kategorikal diubah menjadi data numerik menggunakan teknik *One-Hot Encoding*. Proses ini menghasilkan representasi biner, di mana setiap kategori direpresentasikan oleh satu kolom dengan nilai 1 apabila kategori tersebut dimiliki oleh suatu produk dan 0 apabila tidak dimiliki. Hasil *One-Hot Encoding* pada atribut *brand*, *flavor*, dan *volume*. Statistik hasil *One-Hot Encoding* disajikan pada tabel 17.

Tabel 18. Statistik *one-hot encoding*

No	Keterangan	Nilai
1	Jumlah Produk	996
2	Jumlah Brand	155
3	Jumlah <i>Flavor</i>	8
4	Jumlah <i>Volume</i>	2
5	Total Fitur <i>One-Hot Encoding</i>	165

Berdasarkan tabel 18, proses *One-Hot Encoding* menghasilkan representasi numerik terhadap atribut kategorikal yang terdiri atas *brand*, *flavor*, dan *volume*. *Dataset* yang digunakan berjumlah 996 produk, dengan 155 brand, 8 kategori *flavor*, dan 2 kategori *volume*. Masing-masing kategori diubah menjadi fitur biner sehingga setiap produk memiliki nilai 1 pada kategori yang dimiliki dan 0 pada kategori lainnya. Secara keseluruhan, proses ini menghasilkan 165 fitur *One-Hot*, yang terdiri dari 155 fitur brand, 8 fitur *flavor*, dan 2 fitur *volume*. Fitur-fitur tersebut kemudian digabungkan dengan fitur TF-IDF nama produk serta fitur harga yang telah dinormalisasi untuk membentuk *feature vector*. Hal ini menunjukkan bahwa setiap produk hanya memiliki satu *brand*, satu *flavor* dan satu *volume* sehingga hanya satu kategori yang aktif pada masing-masing atribut. Adapun hasil proses *One-Hot Encoding* disajikan pada tabel 19.

Tabel 19. Hasil *one-hot encoding*

Nama Produk	Brand_50/50	..	Flavor_FRUIT	..	Volume_300	Volume_600
THE O RAMA STRAWBERRY CHEESECAKE PF	0	..	0	..	1	0
SALT JACKPOT XTRA ICE PINEAPPLE 30ML	0	..	0	..	1	0
SALT JACKPOT	0	..	0	..	1	0

XTRA ICE						
MANGO 30ML						
...	...	..	...	..	...	...
CHIZNANARIL	0	..	1	..	0	1
LA 60ML 3MG		.		.		

3.2.4 Hasil Normalisasi

Setelah proses *One-Hot Encoding* selesai, dilakukan normalisasi terhadap atribut numerik, yaitu *price*, menggunakan metode *Min-Max Normalization*. Proses ini bertujuan untuk menyamakan skala nilai setiap atribut sehingga tidak terjadi dominasi atribut tertentu dalam proses perhitungan *similarity*. Dengan metode ini, seluruh nilai atribut numerik ditransformasikan ke dalam rentang 0 hingga 1. Hasil normalisasi beberapa data produk ditunjukkan pada tabel 19.

Tabel 20. Hasil normalisasi data

No	Nama Produk	Harga	Harga Normalisasi
1	THE O RAMA STRAWBERRY CHEESECAKE PF	100.000	0,30
2	SALT JACKPOT XTRA ICE PINEAPPLE 30ML	120.000	0,50
3	SALT JACKPOT XTRA ICE MANGO 30ML	120.000	0,50
...	...	...	...
996	CHIZNANARILLA 60ML 3MG	155.000	0,85

Berdasarkan tabel 20, atribut *price* ditransformasikan ke dalam rentang 0,0000 hingga 1,0000, di mana semakin tinggi harga produk maka semakin besar nilai normalisasinya. Hasil normalisasi tersebut menghasilkan skala nilai yang seragam sehingga atribut numerik dapat digunakan bersama atribut hasil *One-Hot Encoding* dalam proses perhitungan *similarity*.

3.2.5 Hasil Pembentukan Feature Vector

Tahap terakhir pada proses *preprocessing* adalah pembentukan *feature vector*, yaitu menggabungkan seluruh atribut hasil *One-Hot Encoding* dan normalisasi ke dalam satu representasi numerik untuk setiap produk. *Feature vector* inilah yang selanjutnya digunakan sebagai masukan dalam proses perhitungan *similarity* menggunakan metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance*. Berdasarkan hasil pembentukan *feature vector*, diperoleh representasi data dengan 996 sampel dan 773 fitur. Dimensi tersebut terdiri atas 603 fitur TF-IDF hasil ekstraksi nama produk, 165 fitur *One-Hot Encoding* yang berasal dari atribut *brand*, *flavor*, dan *volume*, serta 1 fitur numerik berupa hasil normalisasi *price*. Hasil pembentukan *feature vector* disajikan pada tabel 20.

Tabel 21. Hasil *feature vector*

Nama Produk	SALT	Brand_HERO57 X BLACKJACK	Flavor_DESSERT	Volume_30	Harga Normalisasi
THE ORAMA STRAWBERRY CHEESECAKE PF	0,00	0	1	1	0,30
SALT JACKPOT XTRA ICE PINEAPPLE 30ML	1,29	1	0	1	0,50
SALT JACKPOT XTRA ICE MANGO 30ML	1,29	1	0	1	0,50
...	...	...	...	...	...
CHIZNANARI LLA 60ML 3MG	0,00	0	0	0	0,85

Berdasarkan tabel 21, hasil pembentukan *feature matrix* menunjukkan representasi numerik setiap produk *liquid vape* yang akan digunakan sebagai masukan dalam proses perhitungan *similarity*. Setiap baris pada matriks merepresentasikan satu produk, sedangkan setiap kolom merepresentasikan fitur yang berasal dari hasil ekstraksi atribut produk.

Kolom pertama berisi nama produk (*product_name*) sebagai identitas produk. Selanjutnya, kolom SALT merupakan salah satu fitur hasil pembobotan *TF-IDF* yang berasal dari proses tokenisasi nama produk. Nilai 1,29 pada produk menunjukkan bahwa token SALT terdapat pada nama produk tersebut dan memiliki bobot berdasarkan perhitungan *TF-IDF*. Sebaliknya, nilai 0 pada produk menunjukkan bahwa token SALT tidak terdapat pada nama produk tersebut.

Kolom *Brand_HERO57 X BLACKJACK*, *Flavor_DESSERT*, dan *Volume_30* merupakan hasil proses *One-Hot Encoding*. Nilai 1 menunjukkan bahwa produk memiliki kategori tersebut, sedangkan nilai 0 menunjukkan bahwa produk tidak termasuk dalam kategori tersebut.

Kolom terakhir, yaitu *price_normalisasi*, merupakan hasil normalisasi atribut harga menggunakan metode *Min-Max Normalization* sehingga seluruh nilai berada pada rentang 0 hingga 1. Sebagai contoh, produk THE O RAMA STRAWBERRY CHEESECAKE PF memiliki nilai normalisasi harga sebesar 0,30, sedangkan produk CHIZNANARILLA 60ML 3MG memiliki nilai 0,85. Nilai ini menunjukkan posisi relatif harga setiap produk setelah proses normalisasi dan digunakan sebagai salah satu fitur numerik dalam perhitungan *similarity*.

Dengan demikian, *feature matrix* menggabungkan fitur tekstual hasil pembobotan *TF-IDF*, fitur kategorikal hasil *One-Hot Encoding*, dan fitur numerik hasil normalisasi harga ke dalam satu representasi vektor. Representasi ini selanjutnya digunakan sebagai dasar dalam proses perhitungan kemiripan antarproduk menggunakan metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity*.

3.3 Hasil Implementasi *Cosine Similarity*

3.3.1 Hasil Perhitungan *Cosine Similarity*

Cosine Similarity mengukur tingkat kemiripan antar produk berdasarkan sudut yang dibentuk oleh dua vektor fitur pada ruang multidimensi. Semakin kecil sudut antara kedua vektor, semakin besar nilai *Cosine Similarity* yang diperoleh, yang menunjukkan bahwa kedua produk memiliki karakteristik yang semakin mirip. Pada penelitian ini, setiap produk direpresentasikan sebagai *feature vector* terdiri atas representasi *TF-IDF* untuk nama produk, hasil *One-Hot Encoding* untuk atribut *brand*, *flavor* dan *volume* serta nilai numerik hasil normalisasi pada atribut *price*. Berdasarkan hasil *preprocessing* data, *feature vector* yang didapatkan berjumlah 769 *feature*, terdiri atas 603 *feature TF-IDF*, 155 *feature brand*, 8 *feature flavor*, 2 *feature volume*, dan 1 *feature price*. Sebagai contoh perhitungan, pada penelitian ini dipilih dua produk, yaitu P1 sebagai produk acuan dan P2 sebagai produk pembanding. Informasi kedua produk tersebut disajikan pada Tabel.

Tabel 22. Data produk perhitungan *cosine similarity*

Produk	Nama Produk	Brand	Flavor	Volume	Harga
P1	TAKIS ES POETAR KETAN HITAM SALT 30ML	TAKIS	TAKIS	30	70.000
P2	TAKIS ES POETAR JAGUNG SALT 30ML	TAKIS	TAKIS	30	70.000

Berdasarkan tabel 22, setelah melalui proses *One-Hot Encoding* dan normalisasi, kedua produk direpresentasikan dalam bentuk *feature vector* sebagaimana ditunjukkan pada tabel 23.

Tabel 23. Representasi *feature vector* perhitungan *cosine similarity*

No	Fitur	P1	P2
----	-------	----	----

1	30ML	2,627081	2,627081
2	ES	4,195697	4,195697
3	HITAM	6,903747	0
4	JAGUNG	0	6,903747
5	KETAN	6,210600	0
6	POETAR	5,294309	5,294309
7	SALT	1,286976	1,286976
8	TAKIS	4,601162	4,601162
9	Brand_TAKIS	1	1
10	Flavor_FRUIT	1	1
11	Volume_30	1	1
12	Price Normalisasi	0	0

Berdasarkan tabel 22, setiap produk direpresentasikan ke dalam bentuk *feature vector* yang merupakan hasil dari proses *feature engineering*. *Feature vector* tersebut terdiri atas bobot *TF-IDF* untuk setiap *token* pada atribut *product name* serta hasil *One-Hot Encoding* pada atribut *brand*, *flavor*, dan *volume*. Pada contoh ini hanya ditampilkan *feature* yang memiliki nilai aktif (tidak bernilai nol), sedangkan *feature* lainnya tidak ditampilkan karena tidak memberikan kontribusi terhadap proses perhitungan.

Pada atribut *product name*, kedua produk memiliki beberapa *token* yang sama, yaitu 30ML, ES, POETAR, SALT, dan TAKIS, sehingga bobot *TF-IDF* pada *token* tersebut muncul pada kedua produk. Sebaliknya, *token* HITAM dan KETAN hanya dimiliki oleh Produk P1, sedangkan *token* JAGUNG hanya dimiliki oleh Produk P2. Perbedaan *token* tersebut menyebabkan beberapa *feature* hanya aktif pada salah satu produk.

Pada atribut *brand*, kedua produk berasal dari *brand* TAKIS, sehingga hasil *One-Hot Encoding* menghasilkan *feature* Brand_TAKIS bernilai 1 pada kedua produk. Demikian pula pada atribut *flavor*, kedua produk berada pada kategori FRUIT, sehingga *feature* Flavor_FRUIT juga bernilai 1. Selain itu, kedua produk memiliki *volume* 30 ml, sehingga *feature* Volume_30 memiliki nilai yang sama pada kedua produk. Kesamaan pada atribut-atribut tersebut akan memberikan kontribusi terhadap nilai kemiripan ketika dilakukan proses perhitungan *Cosine Similarity*.

Berdasarkan *feature vector* pada Tabel 3.10, langkah pertama dalam menghitung *Cosine Similarity* adalah menghitung *dot product* atau hasil perkalian setiap pasangan *feature* yang bersesuaian antara Produk P1 dan Produk P2. Nilai *dot product* diperoleh menggunakan persamaan

$$P1 \cdot P2 = \sum_{i=1}^m P1_i P2_i$$

Menghitung *Dot Product* :

Tabel 24. Hasil *dot product* perhitungan *cosine similarity*

Fitur	P1	P2	P1 × P2
30ML	2,627081	2,627081	6,901555
ES	4,195697	4,195697	17,603874
HITAM	6,903747	0	0
JAGUNG	0	6,903747	0
KETAN	6,210600	0	0
POETAR	5,294309	5,294309	28,029711
SALT	1,286976	1,286976	1,656308
TAKIS	4,601162	4,601162	21,170693
Brand_TAKIS	1	1	1
Flavor_FRUIT	1	1	1
Volume_30	1	1	1
Harga Normalisasi	0	0	0
Total			78,362141

Tahap berikutnya adalah menghitung panjang (norma) vektor Produk P1. Norma vektor dihitung dengan menjumlahkan kuadrat seluruh nilai *feature* pada Produk P1. Nilai panjang (norma) vektor Produk P1 diperoleh menggunakan persamaan

$$\sqrt{\sum_{i=1}^m P1_i^2}$$

Menghitung panjang (norma) vektor Produk P1

Tabel 25. Hasil panjang (norma) perhitungan *cosine similarity*

Fitur	P1	P1 ²
30ML	2,627081	6,901555
ES	4,195697	17,603874
HITAM	6,903747	47,661726
JAGUNG	0	0
KETAN	6,210600	38,571553
POETAR	5,294309	28,029711
SALT	1,286976	1,656308
TAKIS	4,601162	21,170693

Brand_TAKIS	1	1
Flavor_FRUIT	1	1
Volume_30	1	1
Harga Normalisasi	0	0
Total		164,595421

Sehingga

$$\sqrt{\sum_{i=1}^{11} P1_i^2} = \sqrt{164.595421}$$

$$= 12.829475$$

Tahap berikutnya adalah menghitung panjang (norma) vektor Produk P2. Norma vektor dihitung dengan menjumlahkan kuadrat seluruh nilai *feature* pada Produk P2. Nilai panjang (norma) vektor Produk P2 diperoleh menggunakan persamaan

$$\sqrt{\sum_{i=1}^m P2_i^2}$$

Menghitung panjang (norma) vektor Produk P2

Menghitung Norma Vektor P2

Tabel 26. Hasil perhitungan norma vector p2

Fitur	P2	P2 ²
30ML	2,627081	6,901555
ES	4,195697	17,603874
HITAM	0	0
JAGUNG	6,903747	47,661726
KETAN	0	0
POETAR	5,294309	28,029711
SALT	1,286976	1,656308
TAKIS	4,601162	21,170693
Brand_TAKIS	1	1

Flavor_FRUIT	1	1
Volume_30	1	1
Harga Normalisasi	0	0
Total		126,023868

$$\sqrt{\sum_{i=1}^{11} P2_i^2} = \sqrt{126.023868}$$

$$= 11.226035$$

Menghitung *Cosine Similarity*

$$\begin{aligned}
 S_C(P1, P2) &= \frac{\sum_{i=1}^{11} P1_i P2_i}{\sqrt{\sum_{i=1}^{11} P1_i^2} \cdot \sqrt{\sum_{i=1}^{11} P2_i^2}} \\
 &= \frac{78.362141}{12.829475 \times 11.226035} \\
 &= \frac{78.362141}{144.024135} \\
 &= 0.544090
 \end{aligned}$$

Nilai 0.544090 menunjukkan bahwa kedua produk memiliki tingkat kemiripan sedang. Hal ini disebabkan kedua produk memiliki banyak *feature* yang sama, seperti *token* 30ML, ES, POETAR, SALT, dan TAKIS, serta memiliki *brand*, kategori *flavor*, dan *volume* yang identik. Meskipun demikian, perbedaan *token* HITAM, KETAN, dan JAGUNG menyebabkan masih terdapat beberapa *feature* yang tidak berkontribusi terhadap *dot product*, sehingga nilai *Cosine Similarity* tidak mencapai 1. Dengan demikian, kedua produk dapat dikatakan memiliki karakteristik yang cukup mirip berdasarkan representasi *feature* yang digunakan dalam penelitian.

3.3.2 Statistik Nilai *Cosine Similarity*

Setelah seluruh pasangan produk dihitung menggunakan metode *Cosine Similarity*, dilakukan analisis statistik terhadap nilai similarity yang dihasilkan. Analisis ini bertujuan untuk memberikan gambaran umum mengenai sebaran tingkat kemiripan antarproduk pada dataset. Hasil analisis statistik nilai *Cosine Similarity* ditunjukkan pada tabel 27.

Tabel 27. Statistik nilai *cosine similarty*

Statistik	Nilai
Jumlah Produk	996
Jumlah Pasangan	495510
Minimum	0

Maksimum	1
Mean	0,037952404
Median	0,021195624
Standar Deviasi	0,067201014

Berdasarkan tabel 27, diketahui bahwa dataset penelitian terdiri atas 996 produk. Seluruh produk dibandingkan satu sama lain sehingga menghasilkan 495.510 pasangan produk. Jumlah pasangan tersebut diperoleh menggunakan kombinasi dua produk tanpa memperhitungkan pasangan yang sama maupun pasangan terhadap dirinya sendiri.

Nilai minimum *Cosine Similarity* sebesar 0 menunjukkan bahwa terdapat pasangan produk yang tidak memiliki kesamaan feature aktif sehingga tidak menghasilkan kontribusi terhadap nilai dot product. Sedangkan untuk maksimum sebesar 1 menunjukkan adanya pasangan produk yang memiliki feature vector identik. Nilai similarity sebesar satu merupakan nilai tertinggi pada metode *Cosine Similarity* dan menunjukkan bahwa kedua produk memiliki arah vektor yang sama sehingga seluruh feature aktif memiliki nilai yang identik.

Nilai mean sebesar 0.037952404 menunjukkan bahwa secara rata-rata tingkat kemiripan antarproduk pada dataset relatif rendah. Hal ini mengindikasikan bahwa sebagian besar pasangan produk hanya memiliki sedikit feature yang sama. Kondisi tersebut dipengaruhi oleh banyaknya variasi nama produk, brand, kategori flavor, volume, serta harga sehingga hanya sebagian kecil pasangan produk yang memiliki karakteristik yang benar-benar mirip.

Nilai median sebesar 0.021195624 lebih kecil dibandingkan nilai mean. Hal ini menunjukkan bahwa lebih dari separuh pasangan produk memiliki nilai similarity di bawah 0.0212. Perbedaan antara nilai mean dan median juga mengindikasikan bahwa distribusi nilai similarity tidak simetris, melainkan dipengaruhi oleh sejumlah kecil pasangan produk dengan nilai similarity yang tinggi.


Nilai standar deviasi sebesar 0.067201014 menunjukkan bahwa penyebaran nilai similarity terhadap nilai rata-rata relatif kecil. Dengan kata lain, sebagian besar pasangan produk memiliki nilai similarity yang berada di sekitar nilai rata-rata, sedangkan hanya sebagian kecil pasangan produk yang memiliki nilai similarity sangat tinggi.

Secara keseluruhan, hasil analisis statistik menunjukkan bahwa metode *Cosine Similarity* menghasilkan distribusi nilai similarity yang didominasi oleh nilai rendah. Kondisi tersebut menunjukkan bahwa sebagian besar produk dalam dataset memiliki karakteristik yang berbeda berdasarkan representasi feature yang digunakan, yaitu kombinasi bobot TF-IDF pada nama produk, hasil *One-Hot Encoding* pada atribut brand, flavor, dan volume, serta nilai hasil normalisasi pada atribut price. Meskipun demikian, masih terdapat sejumlah pasangan produk dengan nilai similarity tinggi yang menunjukkan adanya produk-produk dengan karakteristik yang sangat mirip. Hasil statistik ini mengindikasikan bahwa metode *Cosine Similarity* mampu membedakan tingkat kemiripan antarproduk secara baik karena menghasilkan

rentang nilai similarity yang bervariasi sesuai dengan tingkat kesamaan feature antarproduk.

3.3.3 Distribusi Nilai *Similarity*

Selain dilakukan analisis statistik, distribusi nilai *Cosine Similarity* juga dianalisis untuk mengetahui penyebaran tingkat kemiripan antarproduk pada dataset. Distribusi ini memberikan gambaran mengenai frekuensi kemunculan nilai similarity pada setiap rentang nilai. Hasil distribusi nilai *Cosine Similarity* disajikan pada gambar 14.



Gambar 14. Visualisasi distribusi nilai *similarity*

Berdasarkan gambar 14, sebagian besar pasangan produk memiliki nilai similarity yang berada pada rentang rendah hingga sedang. Hal ini terlihat dari tingginya frekuensi data pada nilai similarity di bawah 0,3. Sementara itu, hanya sebagian kecil pasangan produk yang memiliki nilai similarity mendekati 1, yang menunjukkan bahwa produk-produk tersebut memiliki karakteristik yang sangat mirip.

3.3.4 Hasil *Top-k Recommendation*

Setelah nilai *Cosine Similarity* dihitung untuk seluruh pasangan produk, langkah berikutnya adalah menyusun daftar rekomendasi berdasarkan nilai similarity tertinggi. Pada penelitian ini digunakan Top-5 Recommendation, yaitu lima produk dengan nilai similarity tertinggi terhadap produk acuan. Produk dengan nilai similarity terbesar ditempatkan pada peringkat pertama karena memiliki tingkat kemiripan yang paling tinggi. Sebagai contoh, digunakan produk THE O RAMA STRAWBERRY CHEESECAKE PF sebagai produk acuan. Hasil rekomendasi menggunakan metode *Cosine Similarity* disajikan pada tabel berikut.

Tabel 28. Hasil *top-k recommendation cosine similarity*

Ranking	Nama Produk	Brand	Flavor	Volume	Similarity
---------	-------------	-------	--------	--------	------------


1	THE O RAMA STRAWBERRY CHEESECAKE 60ML	THE O RAMA	DESSERT	60	0,942989
2	THE O RAMA JUICE V2	THE O RAMA	MENTHOL	60	0,661782
3	THE O RAMA JUICE V1	THE O RAMA	MENTHOL	60	0,661062
4	THE O RAMA JUICE V3	THE O RAMA	MENTHOL	60	0,653570
5	THE O RAMA V1 9MG 30ML	THE O RAMA	FRUIT	30	0,625618

Berdasarkan tabel 28, Hasil rekomendasi menunjukkan bahwa produk dengan nilai *Cosine Similarity* tertinggi adalah THE O RAMA STRAWBERRY CHEESECAKE 60ML dengan nilai similarity sebesar 0.942989. Tingginya nilai similarity terutama disebabkan oleh kesamaan nama produk "THE O RAMA STRAWBERRY CHEESECAKE", penggunaan brand yang sama, kategori flavor yang sama, serta karakteristik fitur lainnya yang hampir identik. Pada peringkat kedua hingga keempat berturut-turut terdapat THE O RAMA JUICE V2, THE O RAMA JUICE V1, dan THE O RAMA JUICE V3 dengan nilai similarity masing-masing sebesar 0.661782, 0.661062, dan 0.653570. Meskipun ketiga produk tersebut memiliki kategori flavor yang berbeda dengan produk acuan, nilai similarity tetap relatif tinggi karena memiliki kesamaan brand serta sejumlah kata yang sama pada nama produk. Hal ini menunjukkan bahwa metode *Cosine Similarity* tidak hanya mempertimbangkan satu atribut tertentu, tetapi menghitung tingkat kemiripan berdasarkan keseluruhan kombinasi fitur yang terdapat pada feature vector. Selanjutnya, pada peringkat kelima terdapat THE O RAMA V1 9MG 30ML dengan nilai similarity sebesar 0.625618. Nilai tersebut masih menunjukkan tingkat kemiripan yang cukup tinggi dibandingkan produk lainnya dalam dataset.

Secara keseluruhan, hasil Top-5 Recommendation menunjukkan bahwa metode *Cosine Similarity* mampu mengidentifikasi produk-produk yang memiliki karakteristik paling mendekati produk acuan. Semakin besar nilai similarity yang diperoleh, semakin tinggi tingkat kemiripan antarproduk sehingga semakin relevan untuk direkomendasikan kepada pengguna.

3.3.5 Visualisasi Hasil Rekomendasi


Visualisasi dalam bentuk *bar chart* digunakan untuk memperjelas hasil peringkat *Top-5 Recommendation* berdasarkan nilai *similarity*. Setiap batang pada grafik merepresentasikan satu produk dengan panjang batang menunjukkan besar nilai kemiripan terhadap produk acuan. Semakin tinggi nilai batang, semakin besar tingkat kemiripan produk tersebut.



Gambar 15. Visualisasi hasil rekomendasi *cosine similarity*

3.3.6 Kompleksitas Komputasi

Selain menghasilkan rekomendasi, dilakukan pula pengukuran waktu komputasi untuk mengetahui lama proses perhitungan metode *Cosine Similarity* pada jumlah data yang berbeda. Hasil pengukuran waktu komputasi ditunjukkan pada gambar 16.



Gambar 16. Visualisasi kompleksitas komputasi *cosine similarity*

Berdasarkan gambar 16, terlihat bahwa waktu komputasi metode *Cosine Similarity* meningkat seiring dengan bertambahnya jumlah produk. Pada jumlah data sebanyak 100 produk, waktu komputasi yang diperoleh sebesar 0,002647 detik, kemudian meningkat menjadi 0,010425 detik pada 200 produk dan 0,023036 detik pada 300

produk. Selanjutnya, waktu komputasi terus mengalami peningkatan hingga mencapai sekitar 0,062521 detik pada 500 produk, 0,089982 detik pada 600 produk, 0,119654 detik pada 700 produk, 0,155988 detik pada 800 produk, dan 0,197630 detik pada 900 produk. Pada keseluruhan dataset sebanyak 996 produk, waktu komputasi mencapai 0,305808 detik. Peningkatan waktu komputasi tersebut terjadi karena perhitungan Cosine Similarity dilakukan dengan membandingkan setiap produk terhadap produk lainnya.

Berdasarkan hasil pengujian, metode Cosine Similarity masih mampu melakukan perhitungan terhadap **996 produk dengan waktu sekitar 0,306 detik**. Namun, grafik menunjukkan adanya kecenderungan peningkatan waktu komputasi yang semakin besar pada jumlah data yang lebih tinggi. Hal ini menunjukkan bahwa **ukuran dataset merupakan salah satu faktor yang memengaruhi efisiensi komputasi metode similarity**.

3.4 Hasil Implementasi *Jaccard Similarity*

3.4.1 Hasil Perhitungan *Jaccard Similarity*

Jaccard Similarity mengukur tingkat kemiripan antarproduk berdasarkan proporsi atribut yang sama terhadap seluruh atribut yang dimiliki oleh kedua produk. Berbeda dengan *Cosine Similarity* yang mempertimbangkan seluruh nilai pada vektor fitur, sebelum dilakukan perhitungan *Jaccard Similarity*, setiap produk terlebih dahulu direpresentasikan ke dalam vektor biner (*binary feature vector*). Pada representasi ini, setiap fitur hanya memiliki dua kemungkinan nilai, yaitu 1 atau 0. Nilai 1 menunjukkan bahwa suatu fitur dimiliki oleh produk, sedangkan nilai 0 menunjukkan bahwa fitur tersebut tidak dimiliki oleh produk. Fitur yang digunakan terdiri atas hasil *TF-IDF*, *One-Hot Encoding*, dan proses *Min-Max Normalization*. Pada nilai *price* yang semula berupa nilai kontinu hasil normalisasi kemudian dikonversi ke dalam bentuk biner agar dapat digunakan pada perhitungan *Jaccard Similarity*. Konversi dilakukan dengan memberikan pembobotan, nilai 1 apabila harga produk berada pada kategori atau rentang yang sama, sedangkan nilai 0 apabila berada pada kategori yang berbeda. Untuk mempermudah penjelasan proses perhitungan, digunakan dua produk sebagai contoh, yaitu P1 sebagai produk acuan dan P2 sebagai produk pembanding. Informasi kedua produk tersebut disajikan pada tabel 29.

Tabel 29. Data produk perhitungan *jaccard similarity*

Produk	Nama Produk	Brand	Flavor	Volume	Harga
P1	TAKIS ES POETAR KETAN HITAM SALT 30ML	TAKIS	TAKIS	30	70.000
P2	TAKIS ES POETAR JAGUNG SALT 30ML	TAKIS	TAKIS	30	70.000

Setelah setiap produk direpresentasikan dalam bentuk vektor biner, langkah berikutnya adalah menghitung tingkat kemiripan antarproduk menggunakan metode

Jaccard Similarity. Metode ini mengukur kemiripan berdasarkan banyaknya fitur yang dimiliki secara bersama oleh dua produk dibandingkan dengan seluruh fitur unik yang dimiliki kedua produk tersebut. Berdasarkan data biner yang telah dibentuk sebelumnya, diperoleh representasi fitur sebagai berikut.

Tabel 30. Representasi *vector biner jaccard similarity*

No	Fitur	P1	P2
1	30ML	1	1
2	ES	1	1
3	HITAM	1	0
4	JAGUNG	0	1
5	KETAN	1	0
6	POETAR	1	1
7	SALT	1	1
8	TAKIS	1	1
9	Brand_TAKIS	1	1
10	Flavor_FRUIT	1	1
11	Volume_30	1	1
12	Harga Normalisasi	1	1

Nilai 1 menunjukkan bahwa atribut tersebut dimiliki oleh produk, sedangkan nilai 0 menunjukkan atribut tersebut tidak dimiliki. Berdasarkan representasi tersebut, nilai *Jaccard Similarity* dihitung menggunakan tiga komponen utama, yaitu M_{11} , M_{10} , dan M_{01} . Selanjutnya nilai *Jaccard Similarity* dihitung menggunakan persamaan berikut.

$$J(P1, P2) = \frac{M_{11}}{M_{11} + M_{10} + M_{01}}$$

Dengan mensubstitusikan nilai yang diperoleh, maka

$$J(P_1, P_3) = \frac{9}{9 + 2 + 1}$$

$$J(P_1, P_3) = \frac{11}{14} = 0.75$$

Hasil perhitungan tersebut menunjukkan bahwa nilai Nilai *Jaccard Similarity* sebesar 0,75 menunjukkan bahwa kedua produk memiliki tingkat kemiripan yang tinggi. Dari 12 fitur yang dibandingkan, terdapat 9 fitur yang sama (M_{11}), 2 fitur yang hanya dimiliki produk pertama (M_{10}), dan 1 fitur yang hanya dimiliki produk kedua (M_{01}). Dengan demikian, sekitar 75% karakteristik kedua produk adalah sama, sedangkan 25% sisanya merupakan karakteristik yang berbeda, yaitu fitur HITAM, KETAN, dan JAGUNG.

3.4.2 Statistik Nilai *Jaccard Similarity*

Setelah seluruh pasangan produk dihitung menggunakan metode *Jaccard Similarity*, dilakukan analisis statistik terhadap nilai similarity yang dihasilkan. Analisis ini bertujuan untuk memberikan gambaran umum mengenai sebaran tingkat kemiripan antarproduk pada dataset. Hasil analisis statistik nilai *Jaccard Similarity* ditunjukkan pada tabel 31.

Tabel 31. Statistik nilai *jaccard similarity*

Statistik	Nilai
Jumlah Produk	996
Jumlah Pasangan	495.510
Minimum	0
Maksimum	1
Mean	0,116940100
Median	0,076923077
Standar Deviasi	0,111769040

Berdasarkan tabel 31, hasil analisis statistik, jumlah produk yang digunakan dalam penelitian sebanyak 996 produk, sehingga menghasilkan 495510 pasangan produk yang dibandingkan menggunakan metode *Jaccard Similarity*.

Nilai minimum sebesar 0 menunjukkan bahwa terdapat pasangan produk yang tidak memiliki kesamaan fitur sama sekali. Sebaliknya, nilai maksimum sebesar 1 menunjukkan adanya pasangan produk yang memiliki seluruh fitur yang sama.

Nilai mean sebesar 0.116940100 menunjukkan bahwa rata-rata tingkat kemiripan antarproduk pada seluruh dataset relatif rendah, yaitu sekitar 11.69%. Hal ini mengindikasikan bahwa sebagian besar pasangan produk hanya memiliki sedikit fitur yang sama dibandingkan dengan jumlah keseluruhan fitur yang dimiliki.

Nilai median sebesar 0.076923077 menunjukkan bahwa sebanyak 50% pasangan produk memiliki nilai similarity kurang dari atau sama dengan 0.076923077, sedangkan 50% pasangan lainnya memiliki nilai di atas nilai tersebut. Median yang lebih kecil dibandingkan nilai rata-rata menunjukkan bahwa sebagian besar pasangan produk memiliki tingkat kemiripan yang rendah, sementara hanya sebagian kecil pasangan produk yang memiliki nilai similarity tinggi.


Nilai standar deviasi sebesar 0.111769040 menunjukkan bahwa penyebaran nilai *Jaccard Similarity* terhadap nilai rata-ratanya masih tergolong cukup besar. Hal ini menunjukkan adanya variasi tingkat kemiripan antarproduk, mulai dari produk yang tidak memiliki kesamaan fitur hingga produk yang memiliki karakteristik yang sangat mirip. Variasi tersebut menunjukkan bahwa metode *Jaccard Similarity* mampu membedakan tingkat kemiripan antarproduk berdasarkan keberadaan fitur-fitur biner yang dimiliki oleh masing-masing produk.

Secara keseluruhan, hasil analisis statistik menunjukkan bahwa metode *Jaccard Similarity* menghasilkan distribusi nilai similarity yang didominasi oleh nilai rendah. Kondisi ini mencerminkan bahwa mayoritas produk dalam dataset memiliki karakteristik yang berbeda satu sama lain, sehingga metode *Jaccard Similarity* dapat

memberikan pembeda yang cukup baik dalam proses pencarian produk yang memiliki kemiripan berdasarkan atribut-atribut yang digunakan pada penelitian.

3.4.3 Distribusi Nilai *Similarity*

Selain dilakukan analisis statistik, distribusi nilai *Jaccard Similarity* juga dianalisis untuk mengetahui penyebaran tingkat kemiripan antarproduk pada dataset. Distribusi ini memberikan gambaran mengenai frekuensi kemunculan nilai similarity pada setiap rentang nilai. Hasil distribusi nilai *Jaccard Similarity* disajikan pada gambar 17.



Gambar 17. Hasil distribusi nilai *jaccard similarity*

Berdasarkan gambar 17, sebagian besar pasangan produk memiliki nilai similarity pada rentang yang rendah. Hal ini terlihat dari tingginya frekuensi data pada nilai similarity yang mendekati 0. Sementara itu, hanya sebagian kecil pasangan produk yang memiliki nilai similarity mendekati 1, yang menunjukkan bahwa produk-produk tersebut memiliki atribut yang sangat mirip.

3.4.4 Hasil *Top-k Recommendation*

Setelah nilai *Jaccard Similarity* dihitung untuk seluruh pasangan produk, langkah berikutnya adalah menyusun daftar rekomendasi berdasarkan nilai similarity tertinggi. Pada penelitian ini digunakan Top-5 Recommendation, yaitu lima produk dengan nilai similarity tertinggi terhadap produk acuan. Produk dengan nilai similarity terbesar ditempatkan pada peringkat pertama karena memiliki tingkat kesamaan atribut yang paling tinggi. Sebagai contoh, digunakan produk THE O RAMA STRAWBERRY CHEESECAKE 60ML sebagai produk acuan. Hasil rekomendasi menggunakan metode *Jaccard Similarity* disajikan pada tabel berikut.

Tabel 32. Hasil *top-k recommendation jaccard similarity*

Ranking	Nama Produk	Brand	Flavor	Volume	Similarity
---------	-------------	-------	--------	--------	------------


1	THE O RAMA STRAWBERRY CHEESECAKE 60ML	THE O RAMA	DESSERT	60	0,538462
2	THE O RAMA YUBARI MELON PF	THE O RAMA	FRUIT	30	0,538462
3	THE O RAMA JUICE V2 PODS	THE O RAMA	MENTHOL	30	0,428571
4	THE O RAMA JUICE V3 PODS	THE O RAMA	MENTHOL	30	0,428571
5	THE O RAMA JUICE V1 PODS	THE O RAMA	MENTHOL	30	0,428571

Berdasarkan tabel 32, Hasil rekomendasi menunjukkan bahwa produk dengan nilai *Jaccard Similarity* THE O RAMA STRAWBERRY CHEESECAKE 60ML dengan nilai similarity sebesar 0.538462. Nilai tersebut menunjukkan bahwa produk memiliki tingkat kemiripan atribut tertinggi terhadap produk acuan. Hasil rekomendasi tersebut menunjukkan bahwa metode *Jaccard Similarity* cenderung merekomendasikan produk yang memiliki atribut identik atau sangat mirip, terutama pada atribut brand, flavor, volume, token nama produk, serta atribut price yang telah direpresentasikan dalam bentuk biner. Karena metode Jaccard hanya mempertimbangkan keberadaan atau ketiadaan suatu fitur (binary matching), setiap atribut memiliki kontribusi yang sama dalam proses perhitungan similarity tanpa memperhatikan tingkat kepentingan atau bobot masing-masing atribut.

Secara keseluruhan, hasil recommendation menunjukkan bahwa metode *Jaccard Similarity* mampu mengidentifikasi produk-produk yang memiliki karakteristik paling mirip dengan produk acuan berdasarkan kesamaan atribut. Produk-produk yang direkomendasikan didominasi oleh brand yang sama, yaitu THE O RAMA, sehingga menunjukkan bahwa atribut brand dan atribut lain yang sama memberikan kontribusi besar terhadap nilai similarity. Dengan demikian, metode *Jaccard Similarity* dapat digunakan untuk menghasilkan rekomendasi produk yang memiliki tingkat kesamaan karakteristik yang tinggi berdasarkan representasi fitur biner yang digunakan pada penelitian ini.

3.4.5 Visualisasi Hasil Rekomendasi


Untuk mempermudah interpretasi hasil rekomendasi, nilai *Jaccard Similarity* pada lima produk dengan nilai tertinggi divisualisasikan dalam bentuk grafik batang. Visualisasi ini bertujuan untuk memperlihatkan perbedaan nilai similarity antarproduk secara lebih jelas. Hasil visualisasi rekomendasi menggunakan metode *Jaccard Similarity* ditunjukkan pada gambar 18.



Gambar 18. Visualisasi hasil rekomendasi *jaccard similarity*

3.4.6 Kompleksitas Komputasi

Selain menghasilkan rekomendasi, dilakukan pula pengukuran waktu komputasi untuk mengetahui lama proses perhitungan metode *Jaccard Similarity* pada jumlah data yang berbeda. Hasil pengukuran waktu komputasi ditunjukkan pada gambar 19.



Gambar 19. Visualisasi hasil kompleksitas komputasi *jaccard similarity*

Berdasarkan gambar 19, terlihat bahwa waktu komputasi metode Jaccard Similarity mengalami peningkatan seiring dengan bertambahnya jumlah produk yang diproses. Pada jumlah data sebanyak 100 produk, waktu komputasi yang diperoleh sebesar 0,009562 detik. Waktu tersebut meningkat menjadi 0,037223 detik pada 200 produk dan 0,081350 detik pada 300 produk. Selanjutnya, waktu komputasi meningkat menjadi 0,139604 detik pada 400 produk, 0,220541 detik pada 500 produk, dan

0,311185 detik pada 600 produk. Peningkatan tersebut terus terlihat pada jumlah data yang lebih besar, yaitu 0,434249 detik pada 700 produk, 0,560934 detik pada 800 produk, dan 0,720428 detik pada 900 produk. Pada keseluruhan dataset sebanyak 996 produk, waktu komputasi mencapai 1,096220 detik. Peningkatan waktu komputasi tersebut disebabkan oleh bertambahnya jumlah pasangan produk yang harus dibandingkan.

Berdasarkan hasil pengujian, metode Jaccard Similarity membutuhkan waktu sekitar 1,096220 detik untuk memproses keseluruhan dataset sebanyak 996 produk. Hasil tersebut menunjukkan bahwa waktu komputasi Jaccard Similarity meningkat cukup signifikan dibandingkan ketika jumlah data masih kecil.

3.5 Hasil Implementasi *Euclidean Distance*

3.5.1 Hasil Perhitungan *Euclidean Distance*

Euclidean Distance mengukur tingkat perbedaan antarproduk berdasarkan jarak garis lurus antara dua vektor fitur pada ruang multidimensi. Semakin kecil nilai *Euclidean Distance* yang diperoleh, semakin tinggi tingkat kemiripan antara kedua produk. Sebaliknya, semakin besar nilai *Euclidean Distance* menunjukkan bahwa karakteristik kedua produk semakin berbeda. Untuk mempermudah penjelasan proses perhitungan, digunakan dua produk sebagai contoh, yaitu P1 sebagai produk acuan dan P2 sebagai produk pembanding. Informasi kedua produk tersebut disajikan pada tabel berikut.

Tabel 33. Data produk perhitungan *euclidean distance*

Produk	Nama Produk	Brand	Flavor	Volume	Harga
P1	TAKIS ES POETAR KETAN HITAM SALT 30ML	TAKIS	TAKIS	30	70.000
P2	TAKIS ES POETAR JAGUNG SALT 30ML	TAKIS	TAKIS	30	70.000

Setelah melalui proses TF-IDF, *One-Hot Encoding*, dan normalisasi, kedua produk direpresentasikan dalam bentuk *feature vector* sebagaimana ditunjukkan pada tabel 33.

Tabel 34. Representasi *feature vector* perhitungan *Euclidean distance*

No	Fitur	P1	P2
1	30ML	2,627081	2,627081
2	ES	4,195697	4,195697
3	HITAM	6,903747	0
4	JAGUNG	0	6,903747
5	KETAN	6,210600	0
6	POETAR	5,294309	5,294309

7	SALT	1,286976	1,286976
8	TAKIS	4,601162	4,601162
9	Brand_TAKIS	1	1
10	Flavor_FRUIT	1	1
11	Volume_30	1	1
12	Price Normalisasi	0	0

Berdasarkan tabel 34, setiap produk direpresentasikan ke dalam bentuk *feature vector* yang merupakan hasil dari proses *feature engineering*. *Feature vector* tersebut terdiri atas bobot *TF-IDF* untuk setiap *token* pada atribut *product name* serta hasil *One-Hot Encoding* pada atribut *brand*, *flavor*, dan *volume*. Pada contoh ini hanya ditampilkan *feature* yang memiliki nilai aktif (tidak bernilai nol), sedangkan *feature* lainnya tidak ditampilkan karena tidak memberikan kontribusi terhadap proses perhitungan.

Pada atribut *product name*, kedua produk memiliki beberapa *token* yang sama, yaitu 30ML, ES, POETAR, SALT, dan TAKIS, sehingga bobot *TF-IDF* pada *token* tersebut muncul pada kedua produk. Sebaliknya, *token* HITAM dan KETAN hanya dimiliki oleh Produk P1, sedangkan *token* JAGUNG hanya dimiliki oleh Produk P2. Perbedaan *token* tersebut menyebabkan beberapa *feature* hanya aktif pada salah satu produk.

Pada atribut *brand*, kedua produk berasal dari *brand* TAKIS, sehingga hasil *One-Hot Encoding* menghasilkan *feature* Brand_TAKIS bernilai 1 pada kedua produk. Demikian pula pada atribut *flavor*, kedua produk berada pada kategori FRUIT, sehingga *feature* Flavor_FRUIT juga bernilai 1. Selain itu, kedua produk memiliki *volume* 30 ml, sehingga *feature* Volume_30 memiliki nilai yang sama pada kedua produk. Sedangkan pada atribut *price* setiap produk bernilai 0 karena proses normalisasi. Kesamaan pada atribut-atribut tersebut akan memberikan kontribusi terhadap nilai kemiripan ketika dilakukan proses perhitungan *Euclidean Similarity*. Berdasarkan *feature vector* pada tabel 33, langkah pertama dalam menghitung *Euclidean Distance* adalah menghitung selisih setiap pasangan *feature* yang bersesuaian antara Produk P1 dan Produk P2. Nilai selisih diperoleh menggunakan persamaan berikut.

$$\text{Nilai selisih} = (P_{1k} - P_{2k})$$

Menghitung nilai selisih h

Tabel 35. Nilai selisih perhitungan *euclidean distance*

Fitur	P1	P2	P1 - P2
30ML	2,627081139	2,627081139	0
ES	4,195697056	4,195697056	0
HITAM	6,903747258	0	6,903747258
JAGUNG	0	6,903747258	6,903747258
KETAN	6,210600077	0	6,210600077
POETAR	5,294309345	5,294309345	0
SALT	1,286976160	1,286976160	0

TAKIS	4,601162165	4,601162165	0
Brand_TAKIS	1	1	0
Flavor_FRUIT	1	1	0
Volume_30	0	0	0
Harga Normalisasi	0	0	0

Selanjutnya hasil dari selisih setiap produk di kuadrat menggunakan persamaan berikut:

$$\sum_{k=1}^{12} (P1_{ik} - P2_{ik})^2$$

Sehingga:

Tabel 36. Hasil kuadrat selisih perhitungan *euclidean distance*

Fitur	P1 – P2	(P1 – P2) ²
30ML	0	0
ES	0	0
HITAM	6,903747258	47,661726200
JAGUNG	6,903747258	47,661726200
KETAN	6,210600077	38,571553320
POETAR	0	0
SALT	0	0
TAKIS	0	0
Brand_TAKIS	0	0
Flavor_FRUIT	0	0
Volume_30	0	0
Harga Normalisasi	0	0
Total		133,895006

Selanjutnya adalah menghitung

$$\begin{aligned}
 D_E(P_1, P_2) &= \sqrt{\sum_{k=1}^{12} (P1_{ik} - P2_{ik})^2} \\
 &= \sqrt{133.895006} \\
 &= 11.571301
 \end{aligned}$$

Berdasarkan hasil perhitungan diperoleh nilai *Euclidean Distance* antara Produk P1 dan Produk P2 sebesar 11,571301. Nilai *distance* menunjukkan besarnya perbedaan antara kedua *feature vector*, sehingga semakin kecil nilai *distance* maka kedua produk semakin mirip, sedangkan semakin besar nilai *distance* maka tingkat kemiripannya semakin rendah. Nilai *distance* terutama dipengaruhi oleh perbedaan *token* pada atribut *product name*, yaitu HITAM dan KETAN yang hanya dimiliki oleh Produk P1, serta *token* JAGUNG yang hanya dimiliki oleh Produk P2. Ketiga *token* tersebut memiliki bobot TF-IDF yang relatif tinggi sehingga memberikan kontribusi

terbesar terhadap nilai *distance*. Sementara itu, atribut *brand*, *flavor*, *volume*, dan *price* memiliki nilai yang sama pada kedua produk sehingga tidak memberikan kontribusi terhadap penambahan *distance*.

3.5.2 Hasil Transformasi Menjadi *Similarity*

Nilai *Euclidean Distance* menunjukkan besarnya jarak antara dua produk. Semakin kecil nilai jarak yang diperoleh, semakin tinggi tingkat kemiripan kedua produk. Namun, agar hasil *Euclidean Distance* dapat dibandingkan secara langsung dengan metode *Cosine Similarity* dan *Jaccard Similarity*, nilai jarak tersebut terlebih dahulu ditransformasikan menjadi nilai *similarity*.

Transformasi dilakukan menggunakan persamaan berikut.

$$S_E(x_i, x_j) = \frac{1}{1 + D_E(x_i, x_j)}$$

Berdasarkan hasil perhitungan sebelumnya diperoleh nilai *Euclidean Distance* antara produk P1 dan P2 sebesar 11,571301. Selanjutnya dilakukan proses transformasi sebagai berikut.

$$\begin{aligned} S_E(P_1, P_2) &= \frac{1}{1 + 11,571301} \\ &= \frac{1}{12,571301} \\ &= 0,079546 \end{aligned}$$

Hasil transformasi tersebut menunjukkan bahwa nilai *similarity* antara produk P1 dan P2 adalah 0.079546. Berbeda dengan *Euclidean Distance* yang menginterpretasikan nilai kecil sebagai produk yang lebih mirip, pada hasil transformasi ini nilai *similarity* yang semakin mendekati 1 menunjukkan tingkat kemiripan yang semakin tinggi.

3.5.3 Statistik *Euclidean Distance*

Setelah seluruh pasangan produk dihitung menggunakan metode *Euclidean Similarity*, dilakukan analisis statistik terhadap nilai *similarity* yang dihasilkan. Analisis ini bertujuan untuk memberikan gambaran umum mengenai sebaran tingkat kemiripan antarproduk pada dataset. Hasil analisis statistik nilai *Euclidean Similarity* ditunjukkan pada tabel berikut.

Tabel 37. Statistik nilai *euclidean distance*

Statistik	Nilai
Jumlah Produk	996
Jumlah Pasangan	495.510
Minimum	0,04
Maksimum	1
Mean	0,08
Median	0,08
Standar Deviasi	0,01

Berdasarkan tabel 37, hasil analisis terdapat 996 produk yang menghasilkan 495510 pasangan produk untuk dihitung tingkat kemiripannya menggunakan metode *Euclidean Similarity*. Nilai similarity yang dihasilkan berada pada rentang 0.04 hingga 1.00.

Nilai minimum sebesar 0.04 menunjukkan adanya pasangan produk yang memiliki tingkat kemiripan paling rendah. Nilai tersebut diperoleh karena kedua produk memiliki banyak perbedaan pada feature vector, baik pada token hasil TF-IDF maupun atribut hasil One-Hot Encoding dan normalisasi, sehingga menghasilkan jarak Euclidean yang besar. Sebaliknya, nilai maksimum sebesar 1,00 menunjukkan pasangan produk yang memiliki feature vector identik. Nilai ini diperoleh ketika jarak Euclidean bernilai nol sehingga setelah dilakukan konversi menggunakan persamaan *Euclidean Similarity* menghasilkan nilai similarity sebesar satu.

Nilai mean sebesar 0.08 menunjukkan bahwa rata-rata tingkat kemiripan antarproduk pada dataset relatif rendah. Hal ini mengindikasikan bahwa sebagian besar produk memiliki karakteristik yang berbeda sehingga menghasilkan nilai similarity yang kecil. Nilai median sebesar 0.08 yang sama dengan nilai mean menunjukkan bahwa distribusi nilai similarity cukup terpusat pada kisaran tersebut dan tidak dipengaruhi secara signifikan oleh nilai-nilai ekstrem.


Sementara itu, standar deviasi sebesar 0.01 menunjukkan bahwa variasi nilai *Euclidean Similarity* relatif kecil. Dengan demikian, sebagian besar pasangan produk memiliki nilai similarity yang tidak jauh berbeda dari nilai rata-ratanya. Kondisi ini menunjukkan bahwa metode *Euclidean Similarity* memberikan hasil yang cukup konsisten dalam mengukur tingkat kemiripan antarproduk pada dataset penelitian.

Secara keseluruhan, hasil analisis statistik menunjukkan bahwa metode *Euclidean Similarity* mampu membedakan tingkat kemiripan produk berdasarkan jarak antar feature vector. Meskipun terdapat beberapa pasangan produk dengan nilai similarity tinggi, mayoritas pasangan produk memiliki nilai similarity yang rendah karena setiap produk memiliki kombinasi atribut dan token yang berbeda. Hal ini menunjukkan bahwa dataset memiliki tingkat keberagaman produk yang cukup tinggi sehingga metode *Euclidean Similarity* dapat memberikan variasi nilai kemiripan yang representatif distribusi nilai similarity.

Selain dilakukan analisis statistik, distribusi nilai *Euclidean Similarity* juga dianalisis untuk mengetahui penyebaran tingkat kemiripan antarproduk pada dataset. Distribusi ini memberikan gambaran mengenai frekuensi kemunculan nilai similarity pada setiap rentang nilai.

3.5.4 Distribusi Nilai Similarity

Selain dilakukan analisis statistik, distribusi nilai *Euclidean Similarity* juga dianalisis untuk mengetahui penyebaran tingkat kemiripan antarproduk pada dataset. Distribusi ini memberikan gambaran mengenai frekuensi kemunculan nilai similarity pada setiap rentang nilai. Hasil distribusi nilai *Euclidean Similarity* disajikan pada gambar 20.



Gambar 20. Visualisasi distribusi nilai *similarity euclidean distance*

3.5.5 Hasil *Top-k Recommendation*

Setelah nilai *Euclidean Similarity* dihitung untuk seluruh pasangan produk, langkah berikutnya adalah menyusun daftar rekomendasi berdasarkan nilai similarity tertinggi. Pada penelitian ini digunakan Top-5 Recommendation, yaitu lima produk dengan nilai similarity tertinggi terhadap produk acuan. Produk dengan nilai similarity terbesar ditempatkan pada peringkat pertama karena memiliki tingkat kemiripan yang paling tinggi. Sebagai contoh, digunakan produk THE O RAMA STRAWBERRY CHEESECAKE 60ML sebagai produk acuan. Hasil rekomendasi menggunakan metode *Euclidean Similarity* disajikan pada Tabel 37.

Tabel 38. Hasil *top-k recommendation euclidean distance*

Ranking	Nama Produk	Brand	Flavor	Volume	Similarity
1	THE O RAMA STRAWBERRY CHEESECAKE 60ML	THE O RAMA	DESSERT	60	0.240442
2	THE O RAMA JUICE V2	THE O RAMA	MENTHOL	60	0.115612
3	THE O RAMA JUICE V1	THE O RAMA	MENTHOL	60	0.115455
4	THE O RAMA JUICE V3	THE O RAMA	MENTHOL	60	0.113844
5	THE O RAMA V1 9MG 30ML	THE O RAMA	FRUIT	30	0.107170

Berdasarkan tabel 38, produk THE O RAMA STRAWBERRY CHEESECAKE 60ML memperoleh nilai similarity tertinggi sebesar 0,2404 dan menempati peringkat pertama. Selanjutnya, THE O RAMA JUICE V2 memperoleh nilai similarity sebesar


0,1156, THE O RAMA JUICE V1 sebesar 0,1155, THE O RAMA JUICE V3 sebesar 0,1138, dan THE O RAMA V1 9MG 30ML sebesar 0,1072. Hasil tersebut menunjukkan bahwa THE O RAMA STRAWBERRY CHEESECAKE 60ML memiliki tingkat kemiripan paling tinggi terhadap produk query dibandingkan dengan empat produk lainnya.

Perbedaan nilai similarity antara peringkat pertama dan peringkat berikutnya cukup besar. Nilai similarity pada peringkat pertama sebesar 0,2404, sedangkan peringkat kedua sebesar 0,1156. Hal ini menunjukkan bahwa produk pada peringkat pertama memiliki kedekatan karakteristik yang lebih tinggi terhadap produk query berdasarkan representasi fitur yang digunakan dalam penelitian. Sementara itu, nilai similarity pada peringkat kedua hingga kelima relatif berdekatan, yaitu berada pada rentang 0,1072 hingga 0,1156. Kondisi tersebut menunjukkan bahwa tingkat kemiripan keempat produk tersebut terhadap produk query relatif tidak jauh berbeda.

Berdasarkan hasil top-k rekomendasi tersebut, metode Euclidean Similarity menghasilkan urutan rekomendasi berdasarkan tingkat kedekatan antarvektor fitur. Produk dengan nilai similarity terbesar ditempatkan sebagai rekomendasi utama, sedangkan produk dengan nilai similarity yang lebih rendah ditempatkan pada peringkat berikutnya. Dengan demikian, visualisasi Top-5 dapat digunakan untuk memberikan gambaran mengenai produk yang paling dekat dengan produk query berdasarkan metode Euclidean Similarity.

3.5.6 Visualisasi Hasil Rekomendasi


Untuk mempermudah interpretasi hasil rekomendasi, nilai *Euclidean Similarity* pada lima produk dengan nilai tertinggi divisualisasikan dalam bentuk grafik batang. Visualisasi ini bertujuan untuk memperlihatkan perbedaan nilai similarity antarproduk secara lebih jelas. Hasil visualisasi rekomendasi menggunakan metode *Jaccard Similarity* ditunjukkan pada gambar 21.



Gambar 21. Visualisasi hasil rekomendasi *euclidean distance*

3.5.7 Kompleksitas Komputasi

Selain menghasilkan rekomendasi, dilakukan pula pengukuran waktu komputasi untuk mengetahui lama proses perhitungan metode *Euclidean Similarity* pada jumlah data yang berbeda. Hasil pengukuran waktu komputasi ditunjukkan pada gambar 22.



Gambar 22. Visualisasi hasil kompleksitas komputasi euclidean distance

Berdasarkan gambar 22, waktu komputasi Euclidean Similarity mengalami peningkatan seiring dengan bertambahnya jumlah produk. Pada 100 produk, waktu komputasi sebesar 0,003236 detik. Waktu tersebut meningkat menjadi 0,012875 detik pada 200 produk, 0,029359 detik pada 300 produk, dan 0,059370 detik pada 400 produk. Selanjutnya, waktu komputasi mencapai 0,085156 detik pada 500 produk, 0,120676 detik pada 600 produk, 0,163307 detik pada 700 produk, 0,213763 detik pada 800 produk, dan 0,307849 detik pada 900 produk. Pada keseluruhan dataset sebanyak 996 produk, waktu komputasi mencapai 0,389195 detik. Peningkatan waktu komputasi tersebut terjadi karena semakin banyak produk yang digunakan, semakin banyak pula pasangan produk yang harus dibandingkan dalam proses perhitungan similarity.

Berdasarkan hasil pengujian, metode Euclidean Similarity membutuhkan waktu 0,389195 detik untuk memproses 996 produk. Hasil tersebut menunjukkan bahwa waktu komputasi meningkat seiring dengan pertambahan jumlah data. Oleh karena itu, jumlah produk merupakan salah satu faktor yang memengaruhi efisiensi komputasi metode Euclidean Similarity.

3.6 Hasil Implementasi *Manhattan Distance*

3.6.1 Hasil Perhitungan *Manhattan Distance*

Manhattan Distance mengukur tingkat perbedaan antarproduk berdasarkan jumlah selisih absolut dari setiap atribut pada vektor fitur. Berbeda dengan *Euclidean Distance* yang menghitung jarak garis lurus, *Manhattan Distance* menghitung total jarak dengan menjumlahkan selisih setiap atribut. Semakin kecil nilai *Manhattan Distance* yang diperoleh, semakin tinggi tingkat kemiripan antara kedua produk.

Untuk mempermudah penjelasan proses perhitungan, digunakan dua produk sebagai contoh, yaitu P1 sebagai produk acuan dan P2 sebagai produk pembandingan. Informasi kedua produk tersebut disajikan pada tabel 38.

Tabel 39. Data produk perhitungan *Manhattan distance*

Produk	Nama Produk	Brand	Flavor	Volume	Harga
P1	TAKIS ES POETAR KETAN HITAM SALT 30ML	TAKIS	TAKIS	30	70.000
P2	TAKIS ES POETAR JAGUNG SALT 30ML	TAKIS	TAKIS	30	70.000

Berdasarkan tabel 38 setelah melalui proses *one-hot encoding* dan normalisasi, kedua produk direpresentasikan dalam bentuk *feature vector* sebagaimana ditunjukkan pada tabel berikut.

Tabel 40. Representasi feature vector perhitungan *manhattan distance*

No	Fitur	P1	P2
1	30ML	2,627081	2,627081
2	ES	4,195697	4,195697
3	HITAM	6,903747	0
4	JAGUNG	0	6,903747
5	KETAN	6,210600	0
6	POETAR	5,294309	5,294309
7	SALT	1,286976	1,286976
8	TAKIS	4,601162	4,601162
9	Brand_TAKIS	1	1
10	Flavor_FRUIT	1	1
11	Volume_30	1	1
12	Harga Normalisasi	0	0

Berdasarkan Tabel 40, setiap produk direpresentasikan ke dalam bentuk *feature vector* yang merupakan hasil dari proses *feature engineering*. *Feature vector* tersebut terdiri atas bobot *TF-IDF* untuk setiap *token* pada atribut *product name* serta hasil *one-hot encoding* pada atribut *brand*, *flavor*, dan *volume*, serta normalisasi untuk atribut *price*.

Pada atribut *product name*, kedua produk memiliki beberapa *token* yang sama, yaitu 30ML, ES, POETAR, SALT, dan TAKIS, sehingga bobot *TF-IDF* pada *token* tersebut muncul pada kedua produk. Sebaliknya, *token* HITAM dan KETAN hanya dimiliki oleh Produk P1, sedangkan *token* JAGUNG hanya dimiliki oleh Produk P2. Perbedaan *token* tersebut menyebabkan beberapa *feature* hanya aktif pada salah satu produk.

Pada atribut *brand*, kedua produk berasal dari *brand* TAKIS, sehingga hasil *One-Hot Encoding* menghasilkan *feature* Brand_TAKIS bernilai 1 pada kedua produk. Demikian pula pada atribut *flavor*, kedua produk berada pada kategori FRUIT, sehingga *feature* Flavor_FRUIT juga bernilai 1. Selain itu, kedua produk memiliki *volume* 30 ml, sehingga *feature* Volume_30 memiliki nilai yang sama pada kedua produk. Kesamaan pada atribut-atribut tersebut akan memberikan kontribusi terhadap nilai kemiripan ketika dilakukan proses perhitungan *Manhattan Similarity*.

$$D_M(P1, P2_i) = \sum_{k=1}^m |P1_k - P2_k|$$

mengitung selisih:

Tabel 41. Hasil selisih produk perhitungan *manhattan distance*

Fitur	P1	P2	P1 - P2
30ML	2,627081	2,627081	0
ES	4,195697	4,195697	0
HITAM	6,903747	0	6,903747
JAGUNG	0	6,903747	6,903747
KETAN	6,210600	0	6,210600
POETAR	5,294309	5,294309	0
SALT	1,286976	1,286976	0
TAKIS	4,601162	4,601162	0
Brand_TAKIS	1	1	0
Flavor_FRUIT	1	1	0
Volume_30	1	1	0
Harga Normalisasi	0	0	0
Total			20,018095

Sehingga perhitungan *Manhattan Distance*:

$$\begin{aligned}
 D_M(P1, P2_i) &= \sum_{k=1}^m |P1_k - P2_k| \\
 &= 20.018095
 \end{aligned}$$

Berdasarkan hasil perhitungan manual tersebut diperoleh nilai *Manhattan Distance* antara produk P1 dan P2 sebesar 20.018095.

3.6.2 Hasil Transformasi Menjadi *Similarity*

Nilai *Manhattan Distance* menunjukkan besarnya jarak antara dua produk berdasarkan jumlah selisih absolut dari setiap atribut. Semakin kecil nilai jarak yang diperoleh, semakin tinggi tingkat kemiripan kedua produk. Namun, agar hasil *Manhattan Distance* dapat dibandingkan secara langsung dengan metode *Cosine Similarity*, *Jaccard Similarity*, dan *Euclidean Distance*, nilai jarak tersebut terlebih dahulu ditransformasikan menjadi nilai *similarity*. Transformasi dilakukan menggunakan persamaan berikut.

$$S_M(P1_i, P2_i) = \frac{1}{1 + D_M(P1, P2_i)}$$

Berdasarkan hasil perhitungan sebelumnya diperoleh nilai *Manhattan Distance* antara produk P1 dan P2 sebesar 20.018095. Selanjutnya dilakukan proses transformasi sebagai berikut.

$$\begin{aligned} S_M(P_1, P_2) &= \frac{1}{1 + 20.018095} \\ &= \frac{1}{21.018095} \\ &= 0.04758095 \end{aligned}$$

Berdasarkan hasil transformasi tersebut diperoleh nilai *similarity* antara produk P1 dan P2 sebesar 0.04758095. Berbeda dengan *Manhattan Distance* yang menginterpretasikan nilai kecil sebagai produk yang lebih mirip, pada hasil transformasi ini nilai *similarity* yang semakin mendekati 1 menunjukkan tingkat kemiripan yang semakin tinggi.

3.6.3 Statistik *Manhattan Distance*

Setelah seluruh pasangan produk dihitung menggunakan metode *Manhattan Similarity*, dilakukan analisis statistik terhadap nilai *similarity* yang dihasilkan. Analisis ini bertujuan untuk memberikan gambaran umum mengenai sebaran tingkat kemiripan antarproduk pada dataset. Hasil analisis statistik nilai *Manhattan Distance* ditunjukkan pada tabel berikut.


Tabel 42. Statistik *manhattan distance*

Statistik	Nilai
Jumlah Produk	996
Jumlah Pasangan	495.510
Minimum	0,012302
Maksimum	1
Mean	0,030230
Median	0,028800
Standar Deviasi	0,008993

Berdasarkan tabel 42, nilai minimum *Manhattan Similarity* sebesar 0.012302 dan nilai maksimum sebesar 1.0000, yang menunjukkan adanya variasi tingkat kemiripan antarproduk. Nilai rata-rata sebesar 0.03023 dan median sebesar 0,0288 menunjukkan bahwa sebagian besar pasangan produk memiliki tingkat kemiripan yang relatif rendah. Sementara itu, standar deviasi sebesar 0,008993 mengindikasikan bahwa nilai similarity antarproduk memiliki penyebaran yang relatif kecil.

3.6.4 Distribusi Nilai *Similarity*

Selain dilakukan analisis statistik, distribusi nilai *Manhattan Similarity* juga dianalisis untuk mengetahui penyebaran tingkat kemiripan antarproduk pada dataset. Distribusi ini memberikan gambaran mengenai frekuensi kemunculan nilai similarity pada setiap rentang nilai. Hasil distribusi nilai *Manhattan Similarity* disajikan pada gambar 22.



Gambar 23. Visualisasi hasil distribusi nilai *manhattan similarity*

Gambar 22 menunjukkan distribusi nilai *Manhattan Similarity* yang dihasilkan dari seluruh pasangan produk pada dataset. Berdasarkan grafik tersebut terlihat bahwa sebagian besar pasangan produk terkonsentrasi pada nilai similarity yang sangat rendah, yaitu berada di sekitar 0.03 hingga 0.05. Hal ini ditunjukkan oleh batang histogram yang sangat tinggi di bagian kiri grafik, sedangkan frekuensi pasangan produk dengan nilai similarity yang lebih tinggi semakin sedikit.

Distribusi yang terkonsentrasi di sisi kiri menunjukkan bahwa mayoritas produk dalam dataset memiliki tingkat kemiripan yang rendah berdasarkan metode *Manhattan Similarity*. Kondisi ini terjadi karena setiap produk direpresentasikan oleh kombinasi fitur TF-IDF, brand, flavor, volume, dan harga. Perbedaan pada satu atau beberapa fitur akan meningkatkan nilai *Manhattan Distance*. Setelah distance dikonversi menjadi similarity menggunakan persamaan

nilai similarity menjadi semakin kecil ketika total perbedaan antarproduk semakin besar. Oleh karena itu, sebagian besar pasangan produk memperoleh nilai similarity yang rendah.

3.6.5 Hasil *Top-k Recommendation*

Setelah nilai *Manhattan Similarity* dihitung untuk seluruh pasangan produk, langkah berikutnya adalah menyusun daftar rekomendasi berdasarkan nilai similarity tertinggi. Pada penelitian ini digunakan Top-5 Recommendation, yaitu lima produk dengan nilai similarity tertinggi terhadap produk acuan. Produk dengan nilai similarity terbesar ditempatkan pada peringkat pertama karena memiliki tingkat kemiripan yang paling tinggi. Sebagai contoh, digunakan produk THE O RAMA STRAWBERRY CHEESECAKE PF sebagai produk acuan. Hasil rekomendasi menggunakan metode *Manhattan Similarity* disajikan pada tabel berikut

Tabel 43. Hasil *top-k recommendation manhattan similarity*

Ranking	Nama Produk	Brand	Flavor	Volume	Similarity
1	THE O RAMA STRAWBERRY CHEESECAKE 60ML	THE O RAMA	DESSERT	60	0,142274
2	THE O RAMA YUBARI MELON PF	THE O RAMA	FRUIT	30	0,049271
3	THE O RAMA JUICE V2	THE O RAMA	MENTHOL	60	0,046321
4	THE O RAMA JUICE V1	THE O RAMA	MENTHOL	60	0,046262
5	THE O RAMA JUICE V3	THE O RAMA	MENTHOL	60	0,045864


Berdasarkan tabel 43, Hasil Top-5 Recommendation menunjukkan bahwa THE O RAMA STRAWBERRY CHEESECAKE 60ML menempati peringkat pertama dengan nilai similarity sebesar 0,142274. Selanjutnya, THE O RAMA YUBI MELON PF menempati peringkat kedua dengan nilai similarity sebesar 0,049271, diikuti THE O RAMA JUICE V2 pada peringkat ketiga dengan nilai 0,046321, THE O RAMA JUICE V1 pada peringkat keempat dengan nilai 0,046262, dan THE O RAMA JUICE V3 pada peringkat kelima dengan nilai 0,045864.

Produk pada peringkat pertama memiliki nilai similarity yang paling tinggi dibandingkan produk lainnya, sehingga menjadi rekomendasi utama bagi produk query. Meskipun produk tersebut memiliki nama yang hampir sama dengan produk query, terdapat perbedaan pada volume kemasan, yaitu produk query memiliki volume 30 ml, sedangkan produk rekomendasi memiliki volume 60 ml. Hal tersebut menunjukkan bahwa sistem tidak hanya mempertimbangkan kesamaan nama produk, tetapi juga mempertimbangkan representasi fitur produk yang digunakan dalam perhitungan similarity.

Selain itu, produk-produk pada peringkat ketiga hingga kelima memiliki brand yang sama dengan produk query, yaitu THE O RAMA, serta memiliki flavor menthol dan volume 60 ml. Kesamaan sebagian atribut tersebut menyebabkan produk-produk tersebut memperoleh nilai similarity yang relatif berdekatan. Dengan demikian, hasil pada Tabel 43 menunjukkan bahwa metode Manhattan Similarity mampu menghasilkan urutan rekomendasi berdasarkan tingkat kemiripan produk terhadap produk yang dipilih sebagai query.

3.5.6 Visualisasi Hasil Rekomendasi


Untuk mempermudah interpretasi hasil rekomendasi, nilai *Euclidean Similarity* pada lima produk dengan nilai tertinggi divisualisasikan dalam bentuk grafik batang. Visualisasi ini bertujuan untuk memperlihatkan perbedaan nilai similarity antarproduk secara lebih jelas. Hasil visualisasi rekomendasi menggunakan metode *Jaccard Similarity* ditunjukkan pada gambar 24.



Gambar 24. Visualisasi hasil rekomendasi *euclidean distance*

3.6.7 Kompleksitas Komputasi

Selain menghasilkan rekomendasi, dilakukan pula pengukuran waktu komputasi untuk mengetahui lama proses perhitungan metode *Manhattan Similarity* pada jumlah data yang berbeda. Hasil pengukuran waktu komputasi ditunjukkan pada Gambar 23.



Gambar 25. Visualisasi hasil kompleksitas kompuasi *manhattan similarity*

Berdasarkan gambar 25, waktu komputasi Manhattan Similarity secara umum mengalami peningkatan seiring dengan bertambahnya jumlah produk. Pada 100 produk, waktu komputasi sebesar 0,004770 detik. Waktu tersebut meningkat menjadi 0,018804 detik pada 200 produk, 0,041043 detik pada 300 produk, dan 0,081854 detik pada 400 produk. Selanjutnya, waktu komputasi mencapai 0,122365 detik pada 500 produk, 0,164983 detik pada 600 produk, 0,226458 detik pada 700 produk, dan 0,293497 detik pada 800 produk. Pada 900 produk, waktu komputasi meningkat cukup tinggi menjadi 0,523460 detik. Sementara itu, pada keseluruhan dataset sebanyak 996 produk, waktu komputasi tercatat sebesar 0,472342 detik.

Berdasarkan hasil pengujian, waktu komputasi tertinggi pada grafik terjadi pada 900 produk, yaitu sebesar 0,523460 detik, sedangkan pada 996 produk waktu komputasi tercatat sebesar 0,472342 detik. Penurunan waktu pada 996 produk dibandingkan 900 produk tidak menunjukkan bahwa penambahan jumlah produk mengurangi kompleksitas algoritma. Perbedaan tersebut dapat terjadi karena faktor kondisi komputasi pada saat pengujian, seperti penggunaan sumber daya komputer, proses sistem operasi, dan variasi beban komputasi. Secara umum, pola grafik tetap menunjukkan kecenderungan peningkatan waktu komputasi seiring bertambahnya jumlah produk.

3.7 Perbandingan Nilai *Similarity*

Setelah seluruh metode similarity diimplementasikan, dilakukan perbandingan hasil untuk mengetahui perbedaan karakteristik masing-masing metode. Perbandingan dilakukan berdasarkan statistik nilai similarity, distribusi nilai similarity, hasil Top-k Recommendation, dan korelasi ranking.

3.7.1 Perbandingan Statistik Nilai *Similarity*

Setelah dilakukan perhitungan menggunakan metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity*, dilakukan perbandingan statistik terhadap nilai similarity yang dihasilkan. Perbandingan ini bertujuan untuk mengetahui perbedaan karakteristik nilai similarity yang dihasilkan oleh masing-masing metode. Hasil perbandingan statistik nilai similarity ditunjukkan pada tabel berikut.

Tabel 44. Perbandingan statistik nilai *similarity* antar metode

Statistik	Cosine	Jaccard	Euclidean	Manhattan
Minimum	0	0	0.044438	0.012302
Maksimum	1	1	1	1
Rata-rata	0.037952	0.116940	0.080441	0.030230
Median	0.021196	0.076923	0.079165	0.028800
Standar Deviasi	0.067201	0.111769	0.013257	0.008993

Berdasarkan tabel 44, terdapat perbedaan karakteristik nilai similarity yang dihasilkan oleh setiap metode. Pada nilai minimum, *Cosine Similarity* dan *Jaccard Similarity* memiliki nilai minimum sebesar 0, sedangkan *Euclidean Similarity* memiliki nilai minimum sebesar 0,044438 dan *Manhattan Similarity* sebesar 0,012302. Nilai minimum menunjukkan nilai similarity terendah yang diperoleh dari seluruh pasangan produk. Perbedaan ini menunjukkan bahwa rentang nilai yang dihasilkan setiap metode tidak sama karena masing-masing metode memiliki cara yang berbeda dalam mengukur kemiripan antarproduk.

Pada nilai maksimum, seluruh metode memiliki nilai maksimum sebesar 1. Nilai tersebut menunjukkan kondisi ketika suatu produk dibandingkan dengan dirinya sendiri atau terdapat pasangan produk dengan tingkat kemiripan maksimum. Nilai 1 merupakan nilai similarity tertinggi pada skala similarity yang digunakan.


Berdasarkan nilai rata-rata, *Jaccard Similarity* menghasilkan nilai rata-rata paling tinggi, yaitu sebesar 0,116940, diikuti *Euclidean Similarity* sebesar 0,080441, *Cosine Similarity* sebesar 0,037952, dan *Manhattan Similarity* sebesar 0,030230. Nilai rata-rata ini menunjukkan kecenderungan tingkat similarity yang dihasilkan oleh masing-masing metode pada seluruh pasangan produk. Namun, nilai rata-rata yang lebih tinggi tidak secara langsung menunjukkan bahwa suatu metode menghasilkan rekomendasi yang lebih baik, karena skala dan karakteristik perhitungan setiap metode berbeda.

Pada nilai median, *Jaccard Similarity* memiliki nilai median paling tinggi sebesar 0,076923, diikuti *Euclidean Similarity* sebesar 0,079165, *Cosine Similarity* sebesar 0,021196, dan *Manhattan Similarity* sebesar 0,028800. Median menunjukkan nilai tengah dari seluruh nilai similarity setelah data diurutkan. Nilai median memberikan gambaran mengenai nilai similarity yang berada di tengah distribusi dan dapat digunakan sebagai pembanding terhadap nilai rata-rata.

Berdasarkan standar deviasi, Euclidean Similarity memiliki nilai standar deviasi terbesar, yaitu sebesar 0,132577, diikuti Jaccard Similarity sebesar 0,111769, Cosine Similarity sebesar 0,067201, dan Manhattan Similarity sebesar 0,008993. Standar deviasi menunjukkan tingkat penyebaran nilai similarity terhadap nilai rata-ratanya. Semakin besar nilai standar deviasi, semakin besar variasi nilai similarity yang dihasilkan. Dengan demikian, Euclidean Similarity memiliki penyebaran nilai similarity paling besar, sedangkan Manhattan Similarity memiliki penyebaran paling kecil.

3.7.2 Perbandingan Distribusi *Similarity*

Selain membandingkan statistik nilai *similarity*, dilakukan pula perbandingan distribusi nilai *similarity*.. Hasil perbandingan distribusi *similarity* ditunjukkan pada gambar 26.



Gambar 26. Perbandingan distribusi *similarity* antar metode

Berdasarkan gambar 26, sebagian besar pasangan produk pada keempat metode memiliki nilai similarity pada interval 0,00–<0,25. Hal ini menunjukkan bahwa sebagian besar pasangan produk dalam dataset memiliki tingkat kemiripan yang relatif rendah. Kondisi tersebut terjadi karena setiap pasangan produk memiliki kombinasi atribut dan fitur yang berbeda, sehingga hanya sebagian kecil pasangan produk yang memiliki tingkat kemiripan yang tinggi.

Pada metode Cosine Similarity, sebagian besar pasangan produk berada pada interval 0,00–<0,25, sedangkan sebagian lainnya berada pada interval 0,25–<0,50. Terdapat pula sejumlah kecil pasangan produk yang berada pada interval 0,50–<0,75 dan 0,75–1,00. Hal ini menunjukkan bahwa Cosine Similarity menghasilkan variasi nilai similarity yang lebih tersebar dibandingkan dengan Euclidean dan Manhattan, meskipun sebagian besar nilainya tetap berada pada interval rendah.

Pada metode Jaccard Similarity, jumlah pasangan produk pada interval $0,00 - < 0,25$ juga merupakan yang terbesar. Namun, dibandingkan dengan metode lainnya, Jaccard menunjukkan jumlah pasangan yang relatif lebih banyak pada interval $0,25 - < 0,50$ serta masih terdapat pasangan produk pada interval $0,50 - < 0,75$ dan $0,75 - 1,00$. Hal tersebut menunjukkan bahwa Jaccard menghasilkan distribusi nilai similarity yang lebih beragam, yang sejalan dengan nilai rata-rata similarity Jaccard yang relatif lebih tinggi berdasarkan statistik pada Tabel 43.

Sementara itu, distribusi Euclidean Similarity dan Manhattan Similarity sangat terkonsentrasi pada interval $0,00 - < 0,25$. Pada grafik, hampir seluruh pasangan produk untuk kedua metode tersebut berada pada interval tersebut, sedangkan jumlah pasangan pada interval yang lebih tinggi sangat sedikit atau tidak terlihat secara signifikan. Kondisi ini menunjukkan bahwa sebagian besar pasangan produk memperoleh nilai similarity yang rendah pada kedua metode tersebut.

Secara keseluruhan, grafik menunjukkan bahwa distribusi nilai similarity keempat metode memiliki karakteristik yang berbeda. Jaccard Similarity memiliki penyebaran nilai yang relatif lebih luas ke interval similarity yang lebih tinggi, sedangkan Euclidean dan Manhattan lebih terkonsentrasi pada interval similarity rendah. Cosine Similarity berada di antara kedua karakteristik tersebut. Perbedaan distribusi ini menunjukkan bahwa masing-masing metode menghasilkan skala dan pola nilai similarity yang berbeda dalam mengukur kemiripan antarproduk..

Sebaliknya, *Euclidean Similarity* memiliki distribusi yang paling sempit. Kotak dan *whisker* yang relatif pendek menunjukkan bahwa sebagian besar nilai *similarity* terkonsentrasi pada rentang yang hampir sama. Hal ini mengindikasikan bahwa metode *Euclidean Similarity* menghasilkan nilai *similarity* yang lebih konsisten dengan variasi yang relatif kecil. Walaupun demikian, masih terdapat beberapa *outlier* dengan nilai *similarity* yang tinggi sebagai akibat adanya pasangan produk yang memiliki karakteristik sangat mirip.

Pada *Cosine Similarity*, sebagian besar nilai *similarity* terkonsentrasi pada nilai yang rendah dengan *median* yang juga relatif kecil. *Boxplot* menunjukkan banyak *outlier* yang tersebar hingga mendekati nilai 1. Hal ini menunjukkan bahwa walaupun mayoritas pasangan produk memiliki tingkat kemiripan yang rendah, terdapat sejumlah kecil pasangan produk yang memiliki kemiripan sangat tinggi sehingga muncul sebagai *outlier*.

Sementara itu, *Manhattan Similarity* juga menunjukkan distribusi yang relatif sempit dengan *median* yang rendah. Sebagian besar pasangan produk memiliki nilai *similarity* yang kecil, sedangkan beberapa pasangan produk dengan karakteristik yang hampir identik menghasilkan nilai *similarity* yang jauh lebih tinggi dan muncul sebagai *outlier*. Pola ini menunjukkan bahwa metode *Manhattan Similarity* mampu membedakan pasangan produk yang benar-benar mirip dari mayoritas pasangan produk yang memiliki banyak perbedaan.

Jika dibandingkan secara keseluruhan, *Jaccard Similarity* menghasilkan distribusi nilai *similarity* yang paling bervariasi, sedangkan *Euclidean Similarity* menghasilkan distribusi yang paling stabil. *Cosine Similarity* dan *Manhattan Similarity* memiliki pola distribusi yang cenderung terkonsentrasi pada nilai *similarity* rendah, yang menunjukkan bahwa sebagian besar pasangan produk dalam *dataset* memiliki tingkat kemiripan yang relatif kecil. Hasil visualisasi ini sejalan dengan nilai statistik yang diperoleh sebelumnya, yaitu rata-rata *similarity Jaccard Similarity* merupakan yang tertinggi, diikuti oleh *Euclidean Similarity*, *Cosine Similarity*, dan *Manhattan Similarity*.

3.7.3 Perbandingan *Top-k Recommendation*

Setelah diperoleh hasil *Top-5 Recommendation* dari masing-masing metode, dilakukan perbandingan untuk melihat perbedaan nilai *similarity* yang dihasilkan. Perbandingan ini bertujuan untuk mengetahui karakteristik setiap metode dalam memberikan rekomendasi terhadap produk THE O RAMA STRAWBERRY CHEESECAKE PF. Hasil perbandingan *Top-5 Recommendation* ditunjukkan pada Tabel berikut.

Tabel 45. Hasil perbandingan *top-k recommendation* antar metode

Rank	Cosine	Jaccard	Euclidean	Manhattan
1	THE O RAMA STRAWBERRY CHEESECAKE 60ML	THE O RAMA STRAWBERRY CHEESECAKE 60ML	THE O RAMA STRAWBERRY CHEESECAKE 60ML	THE O RAMA STRAWBERRY CHEESECAKE 60ML
2	THE O RAMA JUICE V2	THE O RAMA YUBARI MELON PF	THE O RAMA JUICE V2	THE O RAMA YUBARI MELON PF
3	THE O RAMA JUICE V1	THE O RAMA JUICE V2 PODS	THE O RAMA JUICE V1	THE O RAMA JUICE V2
4	THE O RAMA JUICE V3	THE O RAMA JUICE V3 PODS	THE O RAMA JUICE V3	THE O RAMA JUICE V1
5	THE O RAMA V1 9MG 30ML	THE O RAMA JUICE V1 PODS	THE O RAMA V1 9MG 30ML	THE O RAMA JUICE V3

Berdasarkan tabel 45, terlihat bahwa terdapat persamaan dan perbedaan hasil Top-5 Recommendation yang dihasilkan oleh metode Cosine Similarity, Jaccard Similarity, Euclidean Similarity, dan Manhattan Similarity. Perbandingan ini dilakukan berdasarkan urutan produk yang direkomendasikan pada setiap peringkat. Kesamaan produk pada peringkat tertentu menunjukkan bahwa beberapa metode memberikan rekomendasi yang serupa, sedangkan perbedaan produk menunjukkan

adanya perbedaan dalam cara masing-masing metode mengukur kemiripan antarproduk.

Pada peringkat pertama, seluruh metode menghasilkan produk yang sama, yaitu THE O RAMA STRAWBERRY CHEESECAKE 60ML. Kesamaan hasil pada peringkat pertama menunjukkan bahwa keempat metode memiliki kesepakatan dalam menentukan produk yang paling mirip terhadap produk query. Dengan demikian, produk tersebut merupakan rekomendasi yang paling konsisten di antara keempat metode.

Pada peringkat kedua, Cosine Similarity dan Euclidean Similarity menghasilkan produk yang sama, yaitu THE O RAMA JUICE V2. Sementara itu, Jaccard Similarity dan Manhattan Similarity menghasilkan THE O RAMA YUBARI MELON PF. Hal ini menunjukkan bahwa terdapat perbedaan dalam penentuan rekomendasi pada peringkat kedua antara kelompok metode tersebut.

Pada peringkat ketiga, Cosine Similarity dan Euclidean Similarity kembali menghasilkan produk yang sama, yaitu THE O RAMA JUICE V1. Jaccard Similarity menghasilkan THE O RAMA JUICE V2 PODS, sedangkan Manhattan Similarity menghasilkan THE O RAMA JUICE V2. Perbedaan tersebut menunjukkan bahwa metode Jaccard dan Manhattan memiliki kecenderungan menghasilkan urutan rekomendasi yang berbeda dibandingkan Cosine dan Euclidean pada beberapa peringkat.

Pada peringkat keempat, Cosine Similarity dan Euclidean Similarity kembali memberikan hasil yang sama, yaitu THE O RAMA JUICE V3. Jaccard Similarity menghasilkan THE O RAMA JUICE V3 PODS, sedangkan Manhattan Similarity menghasilkan THE O RAMA JUICE V1. Sementara itu, pada peringkat kelima, Cosine dan Euclidean kembali memiliki kesamaan, yaitu THE O RAMA V1 9MG 30ML. Jaccard menghasilkan THE O RAMA JUICE V1 PODS, sedangkan Manhattan menghasilkan THE O RAMA JUICE V3.

Secara keseluruhan, hasil pada Tabel 45 menunjukkan bahwa Cosine Similarity dan Euclidean Similarity memiliki pola rekomendasi yang paling serupa. Kedua metode menghasilkan produk yang sama pada peringkat 1 sampai 5. Perbedaannya hanya tidak terdapat pada urutan, melainkan berdasarkan tabel yang ditampilkan keduanya identik. Sementara itu, Jaccard Similarity dan Manhattan Similarity memiliki beberapa perbedaan dalam urutan dan jenis produk yang direkomendasikan.

Dengan demikian, perbandingan Top-5 menunjukkan bahwa setiap metode memiliki karakteristik ranking yang berbeda. Cosine Similarity dan Euclidean Similarity menunjukkan kesamaan hasil rekomendasi yang tinggi, sedangkan Jaccard Similarity dan Manhattan Similarity menghasilkan beberapa perbedaan pada urutan maupun produk yang direkomendasikan. Meskipun terdapat perbedaan pada beberapa peringkat, seluruh metode menghasilkan THE O RAMA STRAWBERRY

CHEESECAKE 60ML sebagai rekomendasi peringkat pertama. Hasil ini selanjutnya digunakan sebagai dasar untuk melakukan analisis kesesuaian ranking dan evaluasi kinerja masing-masing metode.

3.7.4 Analisis Korelasi *Ranking*

Untuk mengetahui tingkat kesamaan urutan rekomendasi yang dihasilkan oleh setiap metode, dilakukan analisis korelasi ranking. Analisis ini bertujuan untuk mengukur hubungan antara ranking produk yang dihasilkan oleh *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity*. Hasil analisis korelasi ranking disajikan pada tabel 46, sedangkan visualisasi korelasi ditampilkan pada gambar 27.

Tabel 46. Hasil analisis korelasi rangking antar metode

Metode	Cosine	Jaccard	Euclidean	Manhattan
Cosine	1	0.795426	0.447655	0.585557
Jaccard	0.795426	1	0.253853	0.462408
Euclidean	0.447655	0.253853	1	0.900806
Manhattan	0.585557	0.462408	0.900806	1

Berdasarkan Tabel 46, di atas menunjukkan korelasi Pearson antara nilai *similarity* yang dihasilkan oleh empat metode, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity*. Nilai korelasi berada pada rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan bahwa dua metode menghasilkan pola nilai *similarity* yang semakin mirip.


Euclidean dan *Manhattan* memiliki nilai korelasi tertinggi, yaitu 0,900806. Hal ini menunjukkan bahwa kedua metode menghasilkan pola nilai *similarity* yang sangat mirip. Kondisi ini wajar karena keduanya sama-sama merupakan metode berbasis perhitungan jarak (*distance-based*), sehingga memiliki karakteristik matematis yang hampir sama.

Cosine dan *Jaccard* memiliki korelasi sebesar 0,795426, yang menunjukkan hubungan kuat. Artinya, meskipun menggunakan konsep perhitungan yang berbeda, kedua metode masih menghasilkan pola nilai *similarity* yang relatif serupa pada data produk liquid vape.

Cosine dan *Manhattan* memiliki korelasi 0,585557, sedangkan *Jaccard* dan *Manhattan* sebesar 0,462408. Nilai ini menunjukkan hubungan sedang, sehingga terdapat beberapa perbedaan dalam cara kedua pasangan metode tersebut mengukur kemiripan antarproduk.

Cosine dan *Euclidean* memiliki korelasi 0,447655, sedangkan *Jaccard* dan *Euclidean* memiliki nilai terendah, yaitu 0,253853. Hal ini menunjukkan bahwa kedua pasangan metode menghasilkan pola nilai *similarity* yang cukup berbeda. Perbedaan tersebut disebabkan oleh konsep dasar yang digunakan, yaitu *Cosine* berfokus pada arah

vektor, Jaccard pada kesamaan atribut, sedangkan Euclidean mengukur jarak geometris antarobjek. Lebih



Gambar 27. Visualisasi korelasi ranking antar metode similarity

Berdasarkan gambar 27, visualisasi menunjukkan bahwa setiap metode menghasilkan karakteristik nilai similarity yang berbeda. Korelasi yang tinggi antara Euclidean dan Manhattan mengindikasikan bahwa keduanya cenderung memberikan hasil yang serupa, sedangkan korelasi yang lebih rendah pada pasangan metode lainnya menunjukkan adanya perbedaan dalam cara masing-masing metode mengukur kemiripan produk. Hasil ini mendukung bahwa pemilihan metode similarity berpengaruh terhadap hasil rekomendasi yang dihasilkan oleh sistem Content-Based Recommendation.

3.7.5 Analisis Perbandingan Karakteristik Metode

Analisis perbandingan karakteristik metode dilakukan untuk mengetahui perbedaan cara kerja masing-masing metode *similarity* dalam mengukur tingkat kemiripan antarproduk *liquid vape*. Setiap metode memiliki mekanisme perhitungan yang berbeda sehingga menghasilkan karakteristik nilai *similarity* yang berbeda pula. Perbedaan tersebut dapat memengaruhi hasil rekomendasi yang diberikan oleh sistem.

Cosine Similarity mengukur kemiripan berdasarkan sudut antara dua vektor fitur. Metode ini tidak dipengaruhi oleh besar kecilnya nilai vektor, tetapi lebih memperhatikan kesamaan pola distribusi fitur. Oleh karena itu, *Cosine Similarity* sangat sesuai digunakan pada data hasil pembobotan *TF-IDF* karena mampu mengidentifikasi kesamaan kata atau atribut meskipun memiliki bobot yang berbeda. *Jaccard Similarity* mengukur kemiripan berdasarkan jumlah fitur yang sama dibandingkan dengan keseluruhan fitur yang dimiliki kedua produk. Pada penelitian ini perhitungan dilakukan menggunakan fitur biner hasil *One-Hot Encoding* sehingga metode ini hanya memperhatikan keberadaan atau ketidakhadiran suatu atribut tanpa mempertimbangkan besar nilai atribut tersebut. Akibatnya, *Jaccard Similarity* lebih sensitif terhadap kesamaan atribut kategorikal seperti merek, kategori rasa, volume, dan kategori harga.

Euclidean Similarity mengukur kemiripan berdasarkan jarak geometris antarvektor fitur. Semakin kecil jarak *Euclidean* antara dua produk maka semakin tinggi nilai *similarity* setelah dilakukan konversi dari *distance* menjadi *similarity*. Metode ini mempertimbangkan seluruh nilai numerik pada setiap fitur sehingga perubahan kecil pada suatu atribut akan memengaruhi hasil perhitungan.

Manhattan Similarity juga berasal dari konsep pengukuran jarak, tetapi menggunakan jumlah selisih absolut setiap fitur. Setelah nilai *distance* dikonversi menjadi *similarity*, metode ini cenderung lebih stabil terhadap perubahan nilai yang ekstrem dibandingkan *Euclidean* karena tidak menggunakan proses perpangkatan pada perhitungan jaraknya. Oleh karena itu, *Manhattan Similarity* lebih toleran terhadap variasi nilai antarfitur.

3.8 Hasil Evaluasi

Setelah dilakukan perbandingan hasil *similarity* dari setiap metode, dilakukan evaluasi untuk mengukur kinerja masing-masing metode. Evaluasi dilakukan menggunakan metrik *Precision@k*, *Recall@k*, *F1-Score*, dan *Mean Reciprocal Rank (MRR)*. Selain itu, dilakukan pula perbandingan *Average Similarity* dan waktu komputasi untuk melihat performa setiap metode dalam menghasilkan rekomendasi.

3.8.1 Evaluasi Kinerja Metode *Similarity*

Untuk mengetahui kinerja masing-masing metode *similarity*, dilakukan evaluasi menggunakan metrik *Precision@k*, *Recall@k*, *F1-Score*, dan *Mean Reciprocal Rank (MRR)*. Evaluasi dilakukan pada beberapa nilai *k*, yaitu 1, 3, 5, dan 10. Hasil evaluasi kinerja setiap metode disajikan pada gambar 26.

A	T	B	T	C	T	D	T	E	T	F	T	G	T	H	T
Metode		k		Precision@k		Recall@k		F1-Score		MRR		Runtime(s)		Memory(MB)	
Cosine		1		0.51		0.14		0.19		0.66		55.14		139.51	
Cosine		3		0.47		0.36		0.33		0.66		61.37		139.55	
Cosine		5		0.42		0.47		0.35		0.66		73.35		139.53	
Cosine		10		0.33		0.59		0.33		0.66		71.46		139.53	
Jaccard		1		0.91		0.29		0.37		0.93		72.65		133.38	
Jaccard		3		0.73		0.53		0.50		0.93		66.93		133.47	
Jaccard		5		0.62		0.63		0.49		0.93		59.75		133.49	
Jaccard		10		0.46		0.74		0.44		0.93		69.93		133.49	
Euclidean		1		0.49		0.13		0.18		0.63		59.46		141.68	
Euclidean		3		0.44		0.32		0.30		0.63		80.57		141.81	
Euclidean		5		0.38		0.42		0.31		0.63		74.52		141.82	
Euclidean		10		0.27		0.51		0.28		0.63		72.25		141.93	
Manhattan		1		0.64		0.19		0.25		0.75		74.12		142.29	
Manhattan		3		0.56		0.41		0.38		0.75		76.35		142.43	
Manhattan		5		0.48		0.50		0.39		0.75		67.13		142.46	
Manhattan		10		0.36		0.61		0.35		0.75		55.48		142.46	

Gambar 28. Hasil evaluasi akurasi rekomendasi antar metode

Berdasarkan gambar 26, hasil evaluasi empat metode *similarity*, menggunakan beberapa nilai *Top-k* ($k = 1, 3, 5$, dan 10). Evaluasi dilakukan menggunakan metrik *Precision@k*, *Recall@k*, *F1-Score*, *Mean Reciprocal Rank (MRR)*, *Runtime*, dan *Memory Usage*.

Berdasarkan hasil evaluasi, terlihat bahwa perubahan nilai k memberikan pengaruh terhadap nilai *Precision*, *Recall*, dan *F1-Score* pada seluruh metode *similarity*. Secara umum, semakin besar nilai k , nilai *Precision* cenderung mengalami penurunan, sedangkan nilai *Recall* mengalami peningkatan. Hal ini terjadi karena semakin banyak produk yang direkomendasikan, semakin besar peluang sistem menemukan produk yang relevan, tetapi proporsi rekomendasi yang benar terhadap seluruh rekomendasi menjadi lebih kecil.

Pada metode *Cosine Similarity*, nilai *Precision* mengalami penurunan dari 0.51 pada $k = 1$ menjadi 0.33 pada $k = 10$. Sebaliknya, nilai *Recall* meningkat dari 0.14 menjadi 0.59 . Nilai *F1-Score* mencapai nilai tertinggi sebesar 0.35 pada $k = 5$, sedangkan nilai *MRR* tetap konstan sebesar 0.66 , yang menunjukkan bahwa posisi produk relevan pertama relatif konsisten pada seluruh variasi nilai k .

Metode *Jaccard Similarity* menghasilkan performa terbaik dibandingkan metode lainnya. Nilai *Precision* tertinggi diperoleh sebesar 0.91 pada $k = 1$ dan tetap menjadi yang tertinggi pada seluruh variasi nilai k . Nilai *Recall* meningkat dari 0.29 pada $k = 1$ menjadi 0.74 pada $k = 10$. Nilai *F1-Score* mencapai 0.50 pada $k = 3$ dan tetap tinggi pada $k = 5$ sebesar 0.49 , sedangkan nilai *MRR* sebesar 0.93 merupakan yang tertinggi di antara seluruh metode. Hal ini menunjukkan bahwa metode *Jaccard Similarity* mampu menempatkan produk yang relevan pada posisi rekomendasi yang lebih awal dibandingkan metode lainnya.

Pada metode *Euclidean Similarity*, nilai *Precision* menurun dari 0.49 menjadi 0.27 , sedangkan *Recall* meningkat dari 0.13 menjadi 0.51 . Nilai *F1-Score* tertinggi diperoleh sebesar 0.31 pada $k = 5$ dengan nilai *MRR* sebesar 0.63 . Dibandingkan metode lainnya, *Euclidean Similarity* menghasilkan performa yang relatif lebih rendah baik dari sisi *Precision* maupun *Recall*.

Sementara itu, metode *Manhattan Similarity* menunjukkan performa yang berada di antara *Cosine Similarity* dan *Jaccard Similarity*. Nilai *Precision* menurun dari 0.64 menjadi 0.36, sedangkan *Recall* meningkat dari 0.19 menjadi 0.61. Nilai *F1-Score* tertinggi sebesar 0.39 diperoleh pada $k = 5$ dengan nilai *MRR* sebesar 0.75. Hasil ini menunjukkan bahwa *Manhattan Similarity* memiliki kemampuan yang lebih baik dibandingkan *Euclidean Similarity*, tetapi masih berada di bawah *Jaccard Similarity*. Dari sisi efisiensi komputasi, waktu eksekusi (*Runtime*) keempat metode berada pada kisaran 55–80 detik, sedangkan penggunaan memori relatif stabil pada setiap metode. Metode *Jaccard Similarity* menggunakan memori paling kecil, yaitu sekitar 133 MB, diikuti *Cosine Similarity* sekitar 139 MB, *Euclidean Similarity* sekitar 142 MB, dan *Manhattan Similarity* sekitar 142 MB. Perbedaan *Runtime* antar nilai k relatif kecil karena proses utama yang memerlukan komputasi tinggi adalah pembacaan dan evaluasi terhadap seluruh matriks *similarity*.

Berdasarkan keseluruhan hasil evaluasi, *Jaccard Similarity* menunjukkan performa paling baik karena memperoleh nilai *Precision*, *Recall*, *F1-Score*, dan *MRR* yang lebih tinggi dibandingkan metode lainnya, serta memiliki penggunaan memori paling rendah. Oleh karena itu, metode *Jaccard Similarity* dipilih sebagai metode *similarity* terbaik pada sistem *Content-Based Recommendation* produk *liquid vape* yang dikembangkan dalam penelitian ini.

3.8.2 Perbandingan Hasil Evaluasi

Selain menggunakan metrik evaluasi, dilakukan pula perbandingan *Average Similarity* dan waktu komputasi untuk melihat perbedaan karakteristik masing-masing metode. Hasil perbandingan evaluasi disajikan pada gambar 29.

Metode	Precision@5	Recall@5	F1-Score	MRR	Runtime(s)	Memory(MB)	Average Similarity	Std Dev
Jaccard	0.62	0.63	0.49	0.93	69.34	134.59	0.12	0.11
Cosine	0.42	0.47	0.35	0.66	64.44	139.13	0.04	0.07
Manhattan	0.48	0.50	0.39	0.75	72.74	142.63	0.03	0.01
Euclidean	0.38	0.42	0.31	0.63	69.02	141.95	0.08	0.01

Gambar 29. Perbandingan hasil evaluasi kinerja antar metode

Berdasarkan gambar 29, hasil evaluasi empat metode *similarity* yang digunakan dalam penelitian ini, yaitu *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity*. Perbandingan dilakukan menggunakan nilai *Precision@5*, *Recall@5*, *F1-Score*, *Mean Reciprocal Rank (MRR)*, *Runtime*, *Memory Usage*, *Average Similarity*, dan *Standar Deviasi*. Nilai $k = 5$ dipilih sebagai acuan karena jumlah lima rekomendasi merupakan jumlah yang umum digunakan pada sistem rekomendasi dan memberikan keseimbangan antara ketepatan serta cakupan rekomendasi.

Berdasarkan hasil evaluasi, metode *Jaccard Similarity* memperoleh performa terbaik dibandingkan metode lainnya. Hal ini ditunjukkan oleh nilai *Precision@5* sebesar 0.62, yang berarti sekitar 62% dari lima produk yang direkomendasikan merupakan produk yang relevan berdasarkan *ground truth*. Selain itu, metode *Jaccard Similarity*

juga memperoleh *Recall@5* sebesar 0.63, yang menunjukkan bahwa metode ini mampu menemukan sekitar 63% dari seluruh produk yang relevan.

Nilai *F1-Score* yang diperoleh *Jaccard Similarity* sebesar 0.49, merupakan nilai tertinggi dibandingkan metode lainnya. Hal ini menunjukkan bahwa metode *Jaccard Similarity* memiliki keseimbangan terbaik antara *Precision* dan *Recall*. Selain itu, nilai *MRR* sebesar 0.93 mengindikasikan bahwa produk relevan umumnya muncul pada posisi teratas dalam daftar rekomendasi sehingga kualitas peringkat yang dihasilkan sangat baik.

Dari sisi efisiensi komputasi, metode *Cosine Similarity* memiliki waktu eksekusi paling cepat yaitu sekitar 64.44 detik, sedangkan metode *Manhattan Similarity* memerlukan waktu paling lama yaitu sekitar 72.74 detik. Perbedaan waktu eksekusi antar metode relatif kecil sehingga tidak memberikan pengaruh yang signifikan terhadap pemilihan metode terbaik.

Pada penggunaan memori, metode *Jaccard Similarity* juga menunjukkan efisiensi yang lebih baik dengan penggunaan memori sebesar 134.59 MB, lebih rendah dibandingkan *Cosine Similarity* (139.13 MB), *Euclidean Similarity* (141.95 MB), maupun *Manhattan Similarity* (142.63 MB).

Nilai *Average Similarity* menunjukkan rata-rata tingkat kemiripan antarproduk yang dihasilkan oleh masing-masing metode. *Jaccard Similarity* memperoleh nilai rata-rata tertinggi yaitu 0.12, diikuti *Euclidean Similarity* (0.08), *Cosine Similarity* (0.04), dan *Manhattan Similarity* (0.03). Hal ini menunjukkan bahwa metode *Jaccard Similarity* menghasilkan tingkat kemiripan antarproduk yang lebih tinggi dibandingkan metode lainnya.

Sementara itu, nilai *Standar Deviasi* menggambarkan tingkat penyebaran nilai *similarity* yang dihasilkan oleh setiap metode. *Jaccard Similarity* memiliki standar deviasi sebesar 0.11, lebih tinggi dibandingkan metode lainnya. Hal ini menunjukkan bahwa nilai *similarity* yang dihasilkan *Jaccard Similarity* memiliki variasi yang lebih besar sehingga lebih mampu membedakan pasangan produk yang sangat mirip dengan pasangan produk yang kurang mirip. Sebaliknya, *Euclidean Similarity* dan *Manhattan Similarity* memiliki standar deviasi sebesar 0.01, yang menunjukkan bahwa sebagian besar nilai *similarity* cenderung berkumpul pada rentang yang sempit sehingga kemampuan diskriminasinya relatif lebih rendah.

Secara keseluruhan, berdasarkan hasil evaluasi yang meliputi akurasi rekomendasi, kualitas peringkat, efisiensi penggunaan memori, serta karakteristik nilai *similarity* yang dihasilkan, *Jaccard Similarity* merupakan metode yang memberikan performa terbaik pada sistem *Content-Based Recommendation* produk *liquid vape* dalam penelitian ini. Meskipun *Cosine Similarity* memiliki waktu komputasi yang sedikit lebih cepat, keunggulan tersebut tidak mampu mengimbangi kualitas rekomendasi yang dihasilkan oleh metode *Jaccard Similarity*.

BAB IV KESIMPULAN

4.1 Kesimpulan

Berdasarkan hasil penelitian mengenai Perbandingan *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Distance*, dan *Manhattan Distance* pada Sistem *Content-Based Recommendation* Produk Liquid Vape, dapat diambil beberapa kesimpulan sebagai berikut:

1. Sistem *Content-Based Recommendation* berhasil dibangun menggunakan atribut brand, kategori rasa, volume, dan harga. Seluruh data berhasil melalui proses preprocessing yang meliputi data *cleaning*, *feature engineering*, One-Hot Encoding, dan normalisasi, sehingga dapat direpresentasikan dalam bentuk feature vector sebagai masukan bagi seluruh metode *similarity*.
2. Metode *Cosine Similarity*, *Jaccard Similarity*, *Euclidean Similarity*, dan *Manhattan Similarity* berhasil diterapkan pada dataset yang sama. Keempat metode mampu menghasilkan nilai *similarity*, daftar *Top-k Recommendation*, dan waktu komputasi sesuai dengan proses perhitungannya masing-masing.
3. Hasil penelitian menunjukkan bahwa setiap metode menghasilkan karakteristik nilai *similarity* yang berbeda. *Euclidean Similarity* memiliki nilai rata-rata *similarity* tertinggi, sedangkan *Jaccard Similarity* memiliki nilai rata-rata *similarity* terendah. Selain itu, *Cosine Similarity* memiliki penyebaran nilai *similarity* yang lebih beragam dibandingkan metode lainnya.
4. Hasil *Top-k Recommendation* menunjukkan bahwa keempat metode *similarity* mampu menghasilkan daftar rekomendasi berdasarkan tingkat kemiripan produk. Meskipun terdapat beberapa produk yang muncul secara bersamaan pada daftar rekomendasi, urutan (ranking) rekomendasi yang dihasilkan oleh setiap metode berbeda. Hasil analisis korelasi ranking menunjukkan bahwa *Euclidean Similarity* dan *Manhattan Similarity* menunjukkan bahwa kedua metode menghasilkan urutan rekomendasi yang identik. Sementara itu, *Cosine Similarity* memiliki tingkat korelasi yang sangat tinggi dengan *Euclidean* dan *Manhattan Similarity*, sedangkan *Jaccard Similarity* menghasilkan pola ranking yang berbeda sehingga memberikan karakteristik rekomendasi yang lebih beragam.
5. Berdasarkan hasil evaluasi menggunakan *Precision@5*, *Recall@5*, *F1-Score*, *Mean Reciprocal Rank (MRR)*, *Runtime*, *Memory Usage*, *Average Similarity*, dan Standar Deviasi, metode *Jaccard Similarity* memberikan performa terbaik dibandingkan metode lainnya. *Jaccard Similarity* memperoleh nilai *Precision@5* sebesar 0.62, *Recall@5* sebesar 0.63, *F1-Score* sebesar 0.49, dan MRR sebesar 0.93, yang menunjukkan kemampuan terbaik dalam menghasilkan rekomendasi yang relevan sekaligus menempatkan produk relevan pada posisi teratas. Selain itu, metode *Jaccard* juga memiliki penggunaan memori yang paling rendah dibandingkan metode lainnya.

4.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran untuk penelitian selanjutnya, yaitu sebagai berikut:

1. Menambahkan atribut produk, seperti kadar nikotin, rasio PG/VG, tingkat cooling, atau profil aroma agar informasi produk menjadi lebih lengkap dan hasil rekomendasi menjadi lebih baik.
2. Menerapkan pembobotan atribut sehingga atribut yang dianggap lebih penting memiliki pengaruh yang lebih besar dalam proses perhitungan similarity.
3. Membandingkan metode similarity lainnya, seperti Mahalanobis Distance, Minkowski Distance, Chebyshev Distance, Pearson Correlation, dan Hamming Distance, sehingga dapat diketahui metode yang paling sesuai untuk sistem rekomendasi berbasis atribut.
4. Mengembangkan sistem menjadi Hybrid Recommendation System dengan menggabungkan Content-Based Filtering dan Collaborative Filtering agar rekomendasi tidak hanya berdasarkan karakteristik produk, tetapi juga mempertimbangkan preferensi pengguna.
5. Menggunakan dataset yang lebih besar dan lebih beragam agar hasil penelitian dapat mewakili lebih banyak jenis produk.
6. Melakukan evaluasi menggunakan data interaksi pengguna, seperti riwayat pembelian, rating, atau ulasan, sehingga kualitas rekomendasi dapat dinilai menggunakan metrik evaluasi yang lebih lengkap.

DAFTAR PUSTAKA

- Abualhaj, M. M., Abu-Shareha, A. A., Shambour, Q. Y., Alsaaidah, A., Al-Khatib, S. N., & Anbar, M. (2024). Customized K-nearest neighbors' algorithm for malware detection. *International Journal of Data and Network Science*, 8(1), 431–438. <https://doi.org/10.5267/j.ijdns.2023.9.012>
- Al Ghifari, N. T., Sitohang, B., & Saptawati, G. A. P. (2021). Addressing Cold Start New User in Recommender System Based on Hybrid Approach: A review and bibliometric analysis. *IT Journal Research and Development*, 6(1), 1–16. [https://doi.org/10.25299/itjrd.2021.vol6\(1\).6118](https://doi.org/10.25299/itjrd.2021.vol6(1).6118)
- Chen, W. H., Hsu, C. C., Lai, Y. A., Liu, V., Yeh, M. Y., & Lin, S. De. (2020). Attribute-Aware Recommender System Based on Collaborative Filtering: Survey and Classification. In *Frontiers in Big Data* (Vol. 2). Frontiers Media S.A. <https://doi.org/10.3389/fdata.2019.00049>
- Chowdhury, P., & Sinha, B. B. (2024). Evaluating the Effectiveness of Collaborative Filtering Similarity Measures: A Comprehensive Review. *Procedia Computer Science*, 235, 2641–2650. <https://doi.org/10.1016/j.procs.2024.04.249>
- Cramer, S., Buschmann, D., & Schmitt, R. H. (2022). Comparison of Feature Extraction Algorithms for Prediction of Quality Characteristics. *Procedia CIRP*, 112, 579–584. <https://doi.org/10.1016/j.procir.2022.09.061>
- De Biasio, A., Navarin, N., & Jannach, D. (2024). Economic recommender systems – a systematic review. *Electronic Commerce Research and Applications*, 63. <https://doi.org/10.1016/j.elerap.2023.101352>
- Ermy Pily, A. K., Susanti, Rio, U., & Tashid. (2025). Komparasi K-Means Clustering dengan Euclidean dan Cosine Similarity untuk Segmentasi dan Rekomendasi Produk pada Data E-Commerce. *The Indonesian Journal of Computer Science*, 14(2). <https://doi.org/10.33022/ijcs.v14i2.4713>
- Februariyanti, H., Dwi Laksono, A., Sasongko Wibowo, J., & Siswo Utomo, M. (2021). *Sistem Rekomendasi Produk Skin Care Menggunakan Metode Hybrid (Content Based Filtering Dan Collaborative Filtering) Berbasis Android*. www.unisbank.ac.id
- Fkih, F. (2022). Similarity measures for Collaborative Filtering-based Recommender Systems: Review and experimental comparison. In *Journal of King Saud University - Computer and Information Sciences* (Vol. 34, Number 9, pp. 7645–7669). King Saud bin Abdulaziz University. <https://doi.org/10.1016/j.jksuci.2021.09.014>
- Forke, C.-M., & Tropmann-Frick, M. (2021). Feature Engineering Techniques and Spatio-Temporal Data Processing. *Datenbank-Spektrum*, 21(3), 237–244. <https://doi.org/10.1007/s13222-021-00391-x>
- Hariri, F. R., & Rochim, L. W. (2022). Sistem Rekomendasi Produk Aplikasi Marketplace Berdasarkan Karakteristik Pembeli Menggunakan Metode User Based Collaborative Filtering. *Teknika*, 11(3), 208–217. <https://doi.org/10.34148/teknika.v11i3.538>
- Imelda Lubis, Y., Josua Napitupulu, D., & Satia Dharma, A. (2020). *Implementation of Hybrid Filtering (Collaborative and Content-based) Methods for the Tourism Recommendation System*.
- Insan, R., Siagian, P., Khoiriah, N., Priscilia, S. A., Raffi, M., Tanjung, A., & Perdana, A. (2025). Penerapan Machine Learning untuk Rekomendasi Film Berdasarkan Preferensi Pengguna. In *Jurnal Mahasiswa Teknik Informatika* (Vol. 9, Number 4).

- Jesse, M., Bauer, C., & Jannach, D. (2023). Intra-list similarity and human diversity perceptions of recommendations: the details matter. *User Modeling and User-Adapted Interaction*, 33(4), 769–802. <https://doi.org/10.1007/s11257-022-09351-w>
- Ko, H., Lee, S., Park, Y., & Choi, A. (2022). A Survey of Recommendation Systems: Recommendation Models, Techniques, and Application Fields. In *Electronics (Switzerland)* (Vol. 11, Number 1). MDPI. <https://doi.org/10.3390/electronics11010141>
- Kurniaji, A., & Santi, R. C. N. (2023). Implementasi Metode Content Based Filtering Pada Pemilihan Komik. *Jurnal Informatika*, 10(2), 109–117. <https://doi.org/10.31294/inf.v10i2.16113>
- Leonardo, N., Arrasyid, A. Z., Natagama, M. A. B., Putro, R. A. A., & Tundjungsari, V. (2026). Analisis Kesesuaian Produk Skincare Berdasarkan Komposisi Bahan Menggunakan Metode Jaccard Similarity. *Jurnal Informatika Dan Teknik Elektro Terapan*, 14(1). <https://doi.org/10.23960/jitet.v14i1.8822>
- Lombu, A. S., Hidayat, S., & Hidayatullah, A. F. (2022). Pemodelan Klasifikasi Gaji Menggunakan Support Vector Machine. *Journal of Computer System and Informatics (JoSYC)*, 3(4), 363–370. <https://doi.org/10.47065/josyc.v3i4.2137>
- López-García, E. E., Batyrshin, I., & Sidorov, G. (2022). New Similarity Measures for Item-based Neighborhood Collaborative Filtering. In *Acta Polytechnica Hungarica* (Vol. 19, Number 10).
- Permana, I., & Nur Salisah, F. (2022). *The Effect of Data Normalization on the Performance of the Classification Results of the Backpropagation Algorithm*.
- Ravikanth, M., Korra, S., Mamidiseti, G., Goutham, M., & Bhaskar, T. (2024). An efficient learning based approach for automatic record deduplication with benchmark datasets. *Scientific Reports*, 14(1). <https://doi.org/10.1038/s41598-024-63242-1>
- Ristias, A. A., Wahyuni, E. D., & Wati, S. F. A. (2024). Komparasi Kinerja Metode Cosine dan Jaccard Similarity dalam Content-Based Recommendation Systems (CBRS) pada Aplikasi Eventhings. *Jurnal Informatika Dan Teknik Elektro Terapan*, 12(3). <https://doi.org/10.23960/jitet.v12i3.4738>
- Roy, D., & Dutta, M. (2022). A systematic review and research perspective on recommender systems. *Journal of Big Data*, 9(1). <https://doi.org/10.1186/s40537-022-00592-5>
- Srilakshmi, M., Chowdhury, G., & Sarkar, S. (2022). Two-stage system using item features for next-item recommendation. *Intelligent Systems with Applications*, 14, 70. <https://doi.org/10.1016/j.iswa.2022.20>
- Stitini, O., Kaloun, O., & Bencharef, O. (2022). Investigating Different Similarity Metrics Used in Various Recommender Systems Types: Scenario Cases. *International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences - ISPRS Archives*, 48(4/W3-2022), 187–193. <https://doi.org/10.5194/isprs-archives-XLVIII-4-W3-2022-187-2022>
- Supiyanto, & Sriyono. (2023). *Metode Cosine Similarity Untuk Mendeteksi Kemiripan Pada Dokumen Teks*. <https://ejournal.uncen.ac.id/index.php/SAINS>
- Syauqi, R. M., Nurul Sabrina, P., & Santikarama, I. (2023). K-Means Clustering with KNN and Mean Imputation on CPU Benchmark Compilation Data. In *Journal of Applied Informatics and Computing (JAIC)* (Vol. 7, Number 2). <http://jurnal.polibatam.ac.id/index.php/JAIC>
- Uyanik, B., & Orman, G. K. (2023). A Manhattan distance based hybrid recommendation system. *International Journal of Applied Mathematics*

- Electronics and Computers*, 11(1), 20–29.
<https://doi.org/10.18100/ijamec.1232090>
- Yadav, D. P., Kumar, N. K., & Sahani, S. K. (2023). Distance Metrics for Machine Learning and it's Relation with Other Distances. *Mikailalsys Journal of Mathematics and Statistics*, 1(1), 15–23.
<https://doi.org/10.58578/mjms.v1i1.1990>
- Zebari, R., Abdulazeez, A., Zeebaree, D., Zebari, D., & Saeed, J. (2020). A Comprehensive Review of Dimensionality Reduction Techniques for Feature Selection and Feature Extraction. *Journal of Applied Science and Technology Trends*, 1(1), 56–70. <https://doi.org/10.38094/jastt1224>
- Zebua, D. R. S., Aji, R. P., & Hermanto, N. (2026). Implementasi Content-Based Filtering untuk Rekomendasi Produk pada Website E-Commerce. *Rabit : Jurnal Teknologi Dan Sistem Informasi Univrab*, 11(2), 3121–3140.
<https://doi.org/10.36341/rabit.v11i2.8006>

LAMPIRAN

Lampiran 1 Source Code Penelitian di Github

<https://github.com/muhammadrasis66/skripsi-rekomendasi-liquid-vape.git>

