


**PERAMALAN PENJUALAN MINUMAN BERBASIS KOPI PADA COFFEE SHOP
DI KOTA MAKASSAR DENGAN MENGGUNAKAN METODE
AUTOREGRESSIVE INTEGRATED MOVING AVERAGE (ARIMA)**



MUH. RAFLI RENDRA

H011191085



**PROGRAM STUDI MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN**

MAKASSAR

2026

**PERAMALAN PENJUALAN MINUMAN BERBASIS KOPI PADA COFFEE SHOP DI KOTA
MAKASSAR DENGAN MENGGUNAKAN METODE *AUTOREGRESSIVE INTEGRATED MOVING
AVERAGE* (ARIMA)**

MUH. RAFLI RENDRA

H011191085



**DEPARTEMEN MATEMATIKA
PROGRAM STUDI MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "PERAMALAN PENJUALAN MINUMAN BERBASIS KOPI PADA COFFEE SHOP DI KOTA MAKASSAR DENGAN MENGGUNAKAN METODE *AUTOREGRESSIVE INTEGRATED MOVING AVERAGE* (ARIMA)" adalah benar karya saya dengan arahan dari pembimbing Ibu **Jusmawati Massalesse, S.Si., M.Si.** sebagai pembimbing utama. Karya ini belum pernah diajukan dan tidak sedang diajukan dalam bentuk apapun kepada perguruan tinggi manapun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka Saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan hukum yang berlaku.

Dengan ini Saya melimpahkan hak cipta (hak ekonomis) dari karya tulis Saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 24 Juli 2026



MUH. RAFLI RENDRA
H011191085


SKRIPSI**PERAMALAN PENJUALAN MINUMAN BERBASIS KOPI PADA COFFEE
SHOP DI KOTA MAKASSAR DENGAN MENGGUNAKAN METODE
AUTOREGRESSIVE INTEGRATED MOVING AVERAGE (ARIMA)****MUH. RAFLI RENDRA****H011191085****Skripsi,**

telah dipertahankan di hadapan Panitia Ujian Sarjana Matematika pada tanggal 24 Juli
2026 dan dinyatakan telah memenuhi syarat kelulusan

pada


Program Studi Matematika
Departemen Matematika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

**Mengesahkan :
Pembimbing Tugas Akhir**


Jusmawati Massalesse, S.Si., M.Si.
NIP. 196806011995122001



**Menyetujui :
Ketua Program Studi Matematika**


Dr. Firman, S.Si., M.Si.
NIP. 196804292002121001

UCAPAN TERIMA KASIH

Alhamdulillah penulis panjatkan kehadiran Allah SWT atas segala rahmat, karunia, dan pertolongan-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul “**Peramalan Penjualan Minuman Berbasis Kopi pada Coffee Shop di Kota Makassar dengan Menggunakan Metode Autoregressive Integrated Moving Average (ARIMA)**”. Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Matematika pada Program Studi Matematika, Departemen Matematika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Hasanuddin.

Penyusunan skripsi ini tidak terlepas dari berbagai tantangan dan keterbatasan. Namun, berkat bantuan, dukungan, bimbingan, serta doa dari berbagai pihak, skripsi ini akhirnya dapat diselesaikan. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih yang sebesar-besarnya kepada seluruh pihak, khususnya kepada :

1. Allah SWT, Tuhan Yang Maha Esa, yang telah memberikan Kesehatan, kekuatan, serta kemudahan dalam setiap langkah penyelesaian skripsi ini.
2. Kedua orang tua penulis, ayahanda **Alm. Muh. Syahrir** dan ibunda **Maryam**, sosok yang telah melahirkan, membesarkan dan mendampingi kehidupan penulis, sosok yang selalu memberikan dukungan baik secara materil maupun moril kepada penulis, sosok yang senantiasa melantunkan nama penulis dalam setiap doa yang mereka panjatkan, serta sosok yang akan selalu menjadi motivasi dan tujuan bagi penulis dalam menjalani kehidupannya
3. Bapak **Prof. Dr. Ir. Jamaluddin Jompa, M.sc.** selaku Rektor Universitas Hasanuddin beserta seluruh jajarannya serta Bapak **Dr. Sci. Muhammad Zakir, M.si.** selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin beserta seluruh jajarannya.
4. Bapak **Dr. Firman, S.Si., M.si.** selaku Ketua Departemen Matematika Fakultas Matematika dan Ilmu pengetahuan Alam Universitas Hasanuddin, ibu **Naimah Aris, S.Si., M.Math.** selaku Departemen Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin, Bapak dan Ibu **Dosen Departemen Matematika** yang telah membimbing dan memberikan begitu banyak ilmu bagi penulis selama menjalani studi sarjana pada program studi matematika, serta bapak dan ibu **Staf Departemen Matematika** yang telah membantu dan memudahkan penulis dalam berbagai hal selama menjalani studi sarjana pada program studi matematika.
5. Ibu **Jusmawati Massalesse, S.Si., M.Si.** selaku Dosen Pembimbing yang telah dengan Ikhlas, sabar, dan tulus meluangkan tenaga dan waktunya di tengah kesibukannya untuk membimbing dan memberikan masukan serta dukungan kepada penulis dalam penyelesaian skripsi ini.
6. Ibu **Prof. Dr. Hasmawati, M.Si.** selaku Dosen Penguji sekaligus Dosen Pembimbing Akademik penulis selama menempuh studi sarjana. Penulis mengucapkan terima kasih karena telah banyak memberikan nasihat, saran, serta bimbingan kepada penulis dalam penulisan skripsi ini dan penyelesaian studi sarjana penulis.
7. Bapak **Prof. Dr. Budi Nurwahyu, MS.** selaku Dosen Penguji yang telah banyak memberikan kritik, saran, serta masukan yang bersifat membangun dalam penyempurnaan penulisan skripsi ini.
8. saya **Rasti Fitriah** yang telah memberikan doa serta dukungan dalam penulisan skripsi ini.
9. Sahabat penulis, **Adi, Ari, Zubaird, Erna, Dian, Resky** yang telah memberikan dukungan kepada penulis sejak bangku sekolah sampai ke bangku perkuliahan

10. **Ichsan, Reza, Rais, Alfian, Ferdi, Aan, Zidan, Ilham** yang selalu memberikan dukungan dan bantuan kepada penulis selama masa studi sarjana.
11. Teman-teman **Matematika 2019** yang senantiasa memberikan bantuan dan dukungan moril kepada penulis, serta memberikan momen berharga bagi penulis selama masa studi sarjana.
12. Seluruh pihak yang tidak dapat disebutkan satu persatu yang telah memberikan dukungan, doa, serta motivasi bagi penulis sehingga penulis mampu menyelesaikan skripsi ini

Akhir kata, semoga Allah SWT membalas segala kebaikan seluruh pihak yang telah membantu dalam penyelesaian skripsi ini. Penulis menyadari bahwa masih terdapat kekurangan dalam kesempurnaan penulisan skripsi ini, untuk itu kritik dan saran yang bersifat membangun akan sangat dibutuhkan agar skripsi ini, untuk itu kritik dan saran yang bersifat membangun akan sangat dibutuhkan agar skripsi ini menjadi lebih baik. Semoga skripsi ini dapat berguna dan bermanfaat bagi pengembangan ilmu pengetahuan di masa mendatang

Makassar, 24 Juli 2026

Muh. Rafli Rendra

ABSTRAK

MUH. RAFLI RENDRA. **PERAMALAN PENJUALAN MINUMAN BERBASIS KOPI PADA COFFEE SHOP DI KOTA MAKASSAR DENGAN MENGGUNAKAN METODE *AUTOREGRESSIVE INTEGRATED MOVING AVERAGE* (ARIMA)** (dibimbing oleh Jusmawati Massalesse, S.Si., M.Si.

Penelitian ini bertujuan untuk menganalisis pola penjualan minuman berbasis kopi pada *coffee shop* di Kota Makassar, menerapkan metode *Autoregressive Integrated Moving Average* (ARIMA), menentukan model yang sesuai, dan mengevaluasi hasil peramalan. Data yang digunakan berupa data historis penjualan dalam bentuk deret waktu. Tahapan penelitian meliputi transformasi Box-Cox, uji stasioneritas menggunakan *Augmented Dickey-Fuller* (ADF), *differencing*, identifikasi model menggunakan ACF dan PACF, estimasi parameter, pengujian signifikansi parameter, serta diagnostik residual. Hasil identifikasi menghasilkan model kandidat ARIMA(1,1,0), ARIMA(0,1,1), dan ARIMA(1,1,1). Berdasarkan hasil evaluasi, ARIMA(1,1,0) dipilih sebagai model terbaik karena parameternya signifikan, residual memenuhi asumsi *white noise*, dan memiliki struktur yang sederhana sesuai prinsip *parsimony*. Hasil peramalan menunjukkan penjualan pada periode mendatang relatif stabil dengan kecenderungan meningkat secara bertahap. Hasil penelitian dapat menjadi dasar dalam perencanaan produksi, pengelolaan persediaan bahan baku, dan pengambilan keputusan operasional.

Kata kunci: Peramalan, Penjualan Minuman Berbasis Kopi, ARIMA, Deret Waktu.

ABSTRACT

MUH. RAFLI RENDRA. FORECASTING COFFEE-BASED BEVERAGE SALES AT COFFEE SHOPS IN MAKASSAR CITY USING THE AUTOREGRESSIVE INTEGRATED MOVING AVERAGE (ARIMA) METHOD (Supervised by Jusmawati Massalesse, S.Si., M.Si.)

This study aims to analyze the sales patterns of coffee-based beverages at a coffee shop in Makassar City, apply the *Autoregressive Integrated Moving Average* (ARIMA) method, determine the most appropriate model, and evaluate the forecasting results. The data used consist of historical sales data in the form of a time series. The analysis stages include Box-Cox transformation, stationarity testing using the *Augmented Dickey-Fuller* (ADF) test, differencing, model identification using the *Autocorrelation Function* (ACF) and *Partial Autocorrelation Function* (PACF), parameter estimation, parameter significance testing, and residual diagnostics. The identification process produced several candidate models, namely ARIMA(1,1,0), ARIMA(0,1,1), and ARIMA(1,1,1). Based on the evaluation results, ARIMA(1,1,0) was selected as the best model because its parameters were significant, its residuals satisfied the white noise assumption, and it had a relatively simple structure in accordance with the principle of parsimony. The forecasting results indicate that sales in the future period are relatively stable with a gradual increasing trend. The results can support production planning, raw material inventory management, and operational decision-making.

Keywords: Forecasting, Coffee-Based Beverage Sales, ARIMA, Time Series.

DAFTAR ISI

HALAMAN JUDUL	ixi
PERNYATAAN KEASLIAN.....	ixii
LEMBAR PENGESAHAN	ixv
UCAPAN TERIMA KASIH	v
ABSTRAK.....	viix
<i>ABSTRACT</i>	viiix
DAFTAR ISI	ixx
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
DAFTAR LAMPIRAN.....	xiii
DAFTAR NOTASI	xixiv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Penelitian	2
1.4 Tujuan Penelitian.....	3
1.5 Manfaat Penelitian.....	3
1.6 Landasan Teori	3
1.6.1 Peramalan (Forecasting).....	3
1.6.2 Permintaan (Demand).....	4
1.6.3 Data Deret Waktu (Time Series).....	4
1.6.4 Metode ARIMA (Autoregressive Integrated Moving Average).....	5
1.6.5 Evaluasi Model Peramalan	13
1.6.6 Penelitian Terdahulu	14

BAB II METODOLOGI PENELITIAN	16
2.1 Metode Penelitian.....	16
2.2 Lokasi dan Waktu Penelitian.....	16
2.2 Jenis dan Sumber Data.....	16
2.2 Prosedur Penelitian	16
2.2 Diagram Alir.....	17
BAB III HASIL DAN PEMBAHASAN	18
3.1. Data Penelitian	18
3.2. Stastistik Deskriptif	18
3.3. Identifikasi Model Time Series ARIMA.....	19
3.4. Uji Stasioneritas	19
3.4.1 Stasioner dalam Varians	19
3.4.2 Stasioner Dalam Mean.....	20
3.5. Analisis Plot ACF dan PACF	21
3.6. Estimasi Model ARIMA.....	22
3.7. Penaksiran dan Pengujian Signifikasnsi Parameter	22
3.8. Pemeriksaan Diagnostik	22
3.8.1 Uji White Noise.....	22
3.8.2 Uji Normalitas Residual	23
3.9. Pemilihan Model Terbaik.....	23
3.10. Evaluasi Data Out-Sample	24
3.11. Forecasting.....	25
BAB IV KESIMPULAN DAN SARAN	28
4.1 Kesimpulan.....	28
4.2 Saram	28
DAFTAR PUSTAKA.....	29
LAMPIRAN	31

DAFTAR TABEL

Tabel 3.1 Data <i>Time-Series</i> Penjualan Produk Berbasis Kopi.....	18
Tabel 3.2. Statistik Deskriptif Data <i>Time-Series</i>	18
Tabel 3.3. Hasil Uji ADF Data Penjualan.....	20
Tabel 3.4 Hasil Uji ADF Data Penjualan Setelah <i>Differencing</i>	20
Tabel 3.5 Hasil Pengujian Signifikansi Parameter Model Data Penjualan.....	22
Tabel 3.6 Hasil Uji <i>White-Noise</i> Model Data Penjualan.	23
Tabel 3.7 Hasil Uji Normalitas Residual Model Data Penjualan.	23
Tabel 3.8 Perbandingan Nilai AIC Model Data Penjualan.....	23
Tabel 3.9 Perbandingan Nilai MAPE Model Data Penjualan.	23
Tabel 3.10 Perbandingan Nilai AIC dan MAPE Model Data Penjualan.	24
Tabel 3.11 Hasil Evaluasi <i>Out-Sample</i>	24
Tabel 3.12 Uji Akurasi Model.....	25
Tabel 3.13 Hasil Permalan Data Penjualan.	25
Tabel 3.14 Hasil Peramalan Data Penjualan Setelah Pembulatan.....	26

DAFTAR GAMBAR

Gambar 3.1 Plot Data Time-Series Penjualan Produk Berbasis Kopi	19
Gambar 3.2 Plot <i>Box-Cox</i> Data Penjualan	19
Gambar 3.3 Plot <i>Box-Cox</i> Data Penjualan Setelah Transformasi	20
Gambar 3.4 Hasil Uji ADF Data Penjualan Setelah <i>Differencing</i>	21
Gambar 3.5 Plot ACF Data Penjualan Setelah <i>Differencing</i>	21
Gambar 3.6 Plot PACF Data Penjualan Setelah Differencing	21
Gambar 3.7 Plot Hasil Evaluasi <i>Out-Sample</i>	25
Gambar 3.8 Plot Hasil Peramalan Data Penjualan	26

DAFTAR LAMPIRAN

Lampiran 1 Transformasi Data.....	31
Lampiran 2 Plot Hasil Transformasi Data	33
Lampiran 3 Uji Parameter Model	35
Lampiran 1 Pemilihan Model Terbaik.....	38
Lampiran 2 Uji Out Sample	40
Lampiran 3 Uji Akurasi Model	42

BAB I

PENDAHULUAN

Pada bab ini dibahas tentang latar belakang, rumusan masalah penelitian, Batasan masalah, tujuan penelitian dan landasan teori.

1.1. Latar Belakang

Industri kopi di Indonesia telah mengalami pertumbuhan yang signifikan dalam beberapa tahun terakhir. Sebagai salah satu negara penghasil kopi terbesar di dunia, Indonesia tidak hanya fokus pada ekspor, tetapi juga mengalami peningkatan konsumsi domestik yang pesat. Tren ini didorong oleh perubahan gaya hidup masyarakat, khususnya di kalangan generasi muda, yang menjadikan kopi sebagai bagian dari keseharian mereka. Fenomena ini terlihat dari menjamurnya *coffee shop* di berbagai kota, yang tidak hanya menawarkan minuman kopi, tetapi juga pengalaman sosial dan tempat untuk bekerja atau bersantai.

Pertumbuhan jumlah *coffee shop* tersebut menimbulkan persaingan yang ketat di industri ini. Untuk tetap kompetitif, pengelola *coffee shop* perlu memahami perilaku konsumen dan mampu merespons permintaan pasar dengan cepat dan tepat. Salah satu tantangan utama adalah fluktuasi permintaan minuman kopi yang dapat dipengaruhi oleh berbagai faktor seperti musim, tren, promosi, dan perubahan preferensi konsumen. Ketidakmampuan dalam mengantisipasi perubahan permintaan dapat menyebabkan kelebihan atau kekurangan stok, yang berdampak pada efisiensi operasional dan kepuasan pelanggan.

Untuk mengatasi tantangan tersebut, diperlukan metode peramalan permintaan yang akurat dan andal. Peramalan permintaan membantu *coffee shop* dalam merencanakan pengadaan bahan baku, mengatur jadwal produksi, dan menyusun strategi pemasaran. Dengan peramalan yang tepat, *coffee shop* dapat mengurangi risiko kelebihan atau kekurangan stok, mengoptimalkan biaya operasional, dan meningkatkan kepuasan pelanggan.

Salah satu metode peramalan yang banyak digunakan dalam analisis deret waktu adalah *Autoregressive Integrated Moving Average* (ARIMA). Metode ini efektif dalam memodelkan data historis untuk meramalkan nilai di masa depan, terutama ketika data memiliki pola tren dan musiman. ARIMA telah diterapkan dalam berbagai studi untuk meramalkan permintaan produk, termasuk dalam industri makanan dan minuman. Misalnya, penelitian oleh Erlina dan Azhar (2020) menggunakan model ARIMA untuk meramalkan nilai ekspor kopi Indonesia dan menemukan bahwa model ARIMA(1,3,1) memberikan hasil yang signifikan untuk peramalan tersebut. (Erlina, Azhar, 2020).

Selain itu, penelitian oleh Yaphira dan Hidayat (2023) menerapkan metode ARIMA untuk meramalkan volume ekspor kopi Indonesia. Mereka menemukan bahwa model ARIMA(2,2,1) memberikan prediksi terbaik dengan nilai MAPE yang rendah, menunjukkan keakuratan model dalam meramalkan data ekspor kopi. Temuan ini menunjukkan bahwa metode ARIMA dapat digunakan secara efektif untuk meramalkan permintaan dalam industri kopi (Yaphira & Hidayat, 2023).

Dalam konteks *coffee shop*, peramalan permintaan minuman kopi menggunakan metode ARIMA dapat membantu pengelola dalam mengantisipasi fluktuasi permintaan dan merencanakan operasional secara lebih efisien. Penelitian oleh Ali (2024) di sebuah kafe di Surabaya menunjukkan bahwa penerapan metode ARIMA membantu dalam mengelola persediaan bahan baku, terutama untuk produk yang menggunakan bahan baku mudah basi seperti susu dan buah-buahan. Dengan peramalan yang akurat, kafe dapat mengatur jadwal pengadaan bahan baku dan produksi dengan lebih baik, sehingga mengurangi risiko pemborosan dan kekurangan stok (Ali, Fahmi, 2024).

Namun, penerapan metode ARIMA dalam peramalan permintaan minuman kopi di coffee shop masih relatif terbatas. Sebagian besar penelitian fokus pada peramalan produksi atau ekspor kopi secara makro, seperti yang dilakukan oleh Nasirudin et al. (2021) yang menggunakan metode SARIMA untuk meramalkan produksi kopi di Jawa Timur. Oleh karena itu, diperlukan penelitian yang lebih spesifik pada tingkat mikro, yaitu pada level coffee shop, untuk memahami bagaimana metode ARIMA dapat diterapkan dalam konteks operasional sehari-hari (Faris et al., 2022).

Selain itu, faktor-faktor yang mempengaruhi permintaan minuman kopi di coffee shop juga perlu dipertimbangkan dalam peramalan. Penelitian oleh Adelina (2022) menunjukkan bahwa harga, selera, variasi produk, pendapatan, dan lokasi memiliki pengaruh terhadap permintaan minuman kopi di Kedai Kopi di Kelurahan Pejuang, Kota Bekasi. Memasukkan variabel-variabel ini dalam model peramalan dapat meningkatkan akurasi prediksi dan membantu coffee shop dalam menyusun strategi pemasaran yang lebih efektif (Adelina, 2022).

Dengan mempertimbangkan pentingnya peramalan permintaan yang akurat dan kebutuhan akan penelitian yang lebih spesifik pada tingkat *coffee shop*, penelitian ini bertujuan untuk menerapkan metode ARIMA dalam meramalkan permintaan minuman kopi pada sebuah *coffee shop* tertentu. Penelitian ini diharapkan dapat memberikan kontribusi dalam pengambilan keputusan operasional yang lebih baik dan meningkatkan efisiensi serta kepuasan pelanggan.

Secara keseluruhan, penerapan metode ARIMA dalam peramalan permintaan minuman kopi pada *coffee shop* merupakan langkah strategis untuk menghadapi dinamika pasar yang terus berubah. Dengan peramalan yang akurat, *coffee shop* dapat mengoptimalkan operasional, mengurangi risiko, dan meningkatkan daya saing di industri yang semakin kompetitif. Oleh karena itu peneliti tertarik menulis skripsi dengan judul “peramalan penjualan minuman berbasis kopi pada coffee shop di Kota Makassar dengan menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA)”

1.2. Rumusan Masalah

1. Bagaimana karakteristik pola permintaan minuman kopi pada coffee shop berdasarkan data historis penjualan?
2. Apakah metode ARIMA dapat digunakan secara efektif untuk meramalkan permintaan minuman kopi pada coffee shop?
3. Model ARIMA seperti apa yang paling sesuai (optimal) untuk meramalkan permintaan minuman kopi berdasarkan data yang tersedia?
4. Seberapa akurat hasil peramalan permintaan minuman kopi dengan metode ARIMA, dilihat dari nilai error (misalnya MAPE, RMSE, atau MAE)?

1.3. Batasan Penelitian

1. Penelitian ini difokuskan pada permintaan minuman yang berbasis kopi (bukan makanan ataupun minuman non-kopi) yang dijual pada coffee shop tertentu yang dijadikan studi kasus.
2. Data yang digunakan dalam penelitian ini adalah data penjualan historis minuman kopi yang diperoleh dari catatan transaksi internal coffee shop. Data bersifat kuantitatif dan berbentuk deret waktu (*time series*.)
3. Periode data yang digunakan untuk peramalan terbatas pada jangka waktu tertentu, sesuai dengan ketersediaan dan kelengkapan data.
4. Penelitian ini hanya menggunakan metode ARIMA sebagai pendekatan peramalan
5. Hasil peramalan hanya berlaku untuk coffee shop yang menjadi studi kasus, sehingga generalisasi ke semua coffee shop bersifat terbatas

1.4. Tujuan Penelitian

1. Menganalisis pola permintaan minuman kopi pada sebuah coffee shop berdasarkan data historis penjualan
2. Menerapkan metode ARIMA untuk melakukan peramalan permintaan minuman kopi
3. Menentukan model ARIMA yang paling sesuai dan optimal dalam meramalkan permintaan minuman kopi
4. Mengevaluasi tingkat akurasi hasil peramalan permintaan minuman kopi dengan menggunakan metode ARIMA

1.5. Manfaat Penelitian

Diharapkan hasil penelitian ini memberikan manfaat kepada beberapa pihak sebagai berikut

1. Bagi penulis diharapkan dapat menambah pengetahuan dan juga bagaimana untuk mengimplementasikan ilmu yang telah didapatkan dalam bangku kuliah
2. Bagi pembaca, diharapkan dapat menambah ilmu terkait dengan topik pembahasan yang diangkat dalam penelitian ini
3. Sebagai literatur atau referensi dalam penelitian selanjutnya terkait dengan topik yang sama

1.6. Landasan Teori

1.6.1. Peramalan (Forecasting)

Forecasting atau peramalan telah berkembang pesat sejak manusia purba melihat ke langit untuk melihat apakah cuaca akan cocok untuk berburu, dan bahkan sejak para pemburu bisa mendapatkan prakiraan seperti "suhu udara 40 derajat Celcius dengan kemungkinan hujan". Sekarang, seorang pemburu dapat melihat smartphone untuk mendapatkan prakiraan suhu dan kemungkinan hujan dalam hitungan jam di berbagai lokasi serta video peta yang menunjukkan pola cuaca yang diperkirakan dalam beberapa jam ke depan. Prakiraan yang disesuaikan dengan kecanggihan yang semakin meningkat dapat dibuat untuk menginformasikan keputusan penting dari berbagai jenis oleh manajer, pejabat publik, investor, dan pengambil Keputusan lainnya (Peetropulous dkk., 2022)

Peramalan adalah proses memperkirakan kejadian atau nilai di masa depan berdasarkan data historis dan analisis tren masa lalu. Dalam konteks bisnis, peramalan digunakan untuk memperkirakan permintaan, penjualan, produksi, dan lainnya guna mendukung pengambilan keputusan yang lebih tepat (Makridakis et al., 1998). Peramalan yang akurat memungkinkan perusahaan untuk meminimalkan biaya, meningkatkan pelayanan pelanggan, dan mengelola sumber daya secara efisien.

Heizer dan Render (2015:113) mendefinisikan peramalan (*forecasting*) adalah suatu seni dan ilmu pengetahuan dalam memprediksi peristiwa pada masa mendatang. Peramalan akan melibatkan pengambilan data historis (penjualan tahun lalu) dan memproyeksi mereka ke masa yang akan datang dengan model matematika. Perusahaan selalu dituntut untuk memperkirakan atau meramalkan besarnya permintaan pelanggan akan produknya. Peramalan permintaan merupakan usaha untuk mengetahui jumlah produk atau sekelompok produk di masa yang akan datang dalam kendala atau kondisi tertentu serta untuk mengurangi resiko atau ketidakpastian yang dihadapi (Deitiana: 2011, 31)

1.6.2. Permintaan (Demand)

Menurut David R. Henderson dalam *The Concise Encyclopedia of Economics*, permintaan tidak hanya mencerminkan jumlah barang yang diinginkan konsumen, tetapi juga mencakup keseluruhan kurva permintaan yang menunjukkan hubungan antara harga dan kuantitas yang diminta pada berbagai tingkat harga. Hukum permintaan menyatakan bahwa, dengan asumsi faktor lain tetap konstan, kenaikan harga suatu barang akan menyebabkan penurunan jumlah yang diminta, dan sebaliknya (David, Lawrence, 2007).

Permintaan terhadap suatu barang atau jasa dipengaruhi oleh berbagai faktor, termasuk harga barang itu sendiri, pendapatan konsumen, harga barang substitusi dan komplementer, preferensi konsumen, serta ekspektasi terhadap kondisi ekonomi di masa depan. Perubahan dalam salah satu faktor ini dapat menyebabkan pergeseran kurva permintaan, baik ke kanan (peningkatan permintaan) maupun ke kiri (penurunan permintaan). Sebagai contoh, peningkatan pendapatan konsumen cenderung meningkatkan permintaan terhadap barang-barang normal, sementara peningkatan harga barang substitusi dapat meningkatkan permintaan terhadap barang yang bersangkutan.

Permintaan dalam konteks ekonomi mengacu pada jumlah barang atau jasa yang diinginkan konsumen pada tingkat harga tertentu dalam periode waktu tertentu. Dalam industri *coffee shop*, permintaan dipengaruhi oleh berbagai faktor seperti harga, pendapatan, selera konsumen, tren sosial, lokasi, dan strategi promosi (Sukirno, 2010). Permintaan yang fluktuatif menuntut pengelolaan yang responsif agar tidak terjadi kekurangan atau kelebihan produk.

1.6.3. Data Deret Waktu (Time Series)

Data deret waktu adalah sekumpulan data yang dikumpulkan dan dicatat berdasarkan urutan waktu tertentu, biasanya dalam interval yang tetap (harian, mingguan, bulanan, dll). Analisis deret waktu bertujuan untuk mengidentifikasi pola-pola tertentu seperti tren (trend), musiman (seasonality), dan fluktuasi acak (random variation) untuk tujuan peramalan (Chatfield, 2004).

Data time series merupakan serangkaian pengamatan yang teratur berdasarkan waktu dengan jarak yang sama (Wei, 2006). Jenis data ini sering ditemui dalam keseharian karena data tersebut dikumpulkan melalui waktu interval yaitu harian, mingguan atau bulanan. Dari data yang terkumpul dapat dilihat ada suatu pola didalamnya. Dalam time series pola tersebut dibagi menjadi tiga yaitu pola trend, siklus dan musiman (seasonal). Pola musiman (seasonal) adalah pola yang mengalami pengulangan yang sama berkali-kali pada interval tertentu.

Berdasarkan pembagian daerah (domain), data time series terbagi menjadi dua daerah (domain) yaitu daerah waktu (time domain) dan daerah frekuensi (frekuensi domain) (Chatfield, 1996). Daerah waktu menelaah tentang signifikansi autokorelasi, kestasioneran data, penaksiran parameter model regresi deret waktu dan peramalan (forecasting). Sedangkan daerah frekuensi (frequency domain) menelaah frekuensi tersembunyi pada data musiman yang sulit diperoleh dalam daerah waktu. Tujuannya adalah untuk mengetahui hal-hal istimewa atau kondisi tertentu pada data. Salah satu cara yang dapat digunakan dalam analisis daerah frekuensi adalah analisis spektral.

Analisis spektral atau juga disebut analisis spektrum diperkenalkan oleh Schuster pada abad ke-19 yang digunakan pada bidang kelautan, meteorologi, dan astronomi (Bloomfield, 2000). Analisis spektral merupakan suatu metode untuk penaksiran dalam domain frekuensi untuk menelaah periodisitas tersembunyi, yaitu periodisitas yang sulit ditemukan dalam domain waktu (Mulyana, 2004). Analisis spektral dapat digunakan untuk melihat pola periodik yang terjadi dalam data tersebut.

1.6.4. Metode ARIMA (Autoregressive Integrated Moving Average)

Autoregressive Integrated Moving Average (ARIMA) merupakan metode yang telah dikembangkan oleh Box dan Jenkins sehingga disebut Arima Box – Jenkins. Metode ini merupakan kombinasi dari metode penghalusan. Metode ini digunakan untuk memprediksi harga, penerimaan, penjualan, tenaga kerja, dan variabel runtun waktu lainnya. Model ini menggunakan nilai saat ini dan nilai - nilai sebelumnya, dari variabel terikat untuk menciptakan prediksi atau perkiraan jangka pendek yang akurat :

Model ARIMA dapat diklasifikasikan sebagai berikut:

a. Model Autoregressive (AR)

Menurut George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, dan Greta M. Ljung (2015), model **Autoregressive (AR)** merupakan model deret waktu yang menyatakan bahwa nilai suatu variabel pada waktu ke- t dipengaruhi secara linear oleh nilai variabel tersebut pada beberapa periode sebelumnya. Dengan demikian, informasi historis dari suatu deret waktu digunakan sebagai dasar untuk memprediksi nilai pada periode berikutnya.

Secara matematis, model AR orde p dituliskan sebagai :

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t \quad (1)$$

dengan :

Y_t = nilai observasi pada waktu ke t

c = konstanta

ϕ_1 = koefisien *autoregressive*

ε_t = galat pada waktu t

Menurut Peter J. Brockwell dan Richard A. Davis (2016), model AR digunakan ketika suatu data memiliki ketergantungan yang kuat terhadap nilai masa lalunya sehingga pola historis dapat dimanfaatkan untuk melakukan peramalan

b. Model Moving Average (MA)

Menurut Box et al. (2015), model **Moving Average (MA)** merupakan model yang menjelaskan bahwa nilai suatu observasi dipengaruhi oleh kombinasi linear dari galat (*error* atau *shock*) pada periode sekarang dan beberapa periode sebelumnya. Berbeda dengan model AR yang menggunakan nilai observasi terdahulu, model MA memanfaatkan residual hasil prediksi sebelumnya sebagai komponen utama dalam pembentukan nilai saat ini.

Model MA orde q dirumuskan sebagai:

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (2)$$

dengan :

Y_t = nilai observasi pada waktu ke t

μ = rata-rata

θ_i = koefisien *Moving Average*

ε_t = galat dalam waktu- t

Menurut Brockwell dan Davis (2016), model MA sangat efektif digunakan ketika variasi data terutama dipengaruhi oleh gangguan acak (*random shocks*) yang masih memiliki pengaruh terhadap beberapa periode berikutnya.

c. Model Campuran Autoregressive Moving Average (ARMA)

Menurut Box et al. (2015), model **Autoregressive Moving Average (ARMA)** merupakan gabungan dari model AR dan MA, sehingga nilai suatu observasi dipengaruhi oleh dua komponen sekaligus, yaitu nilai observasi masa lalu dan residual pada periode sebelumnya. Model ini diterapkan pada data deret waktu yang telah memenuhi asumsi stasioneritas.

Persamaan umum model ARMA(p, q) adalah:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (3)$$

dengan :

Y_t = nilai observasi pada waktu ke t

c = konstanta

ϕ_1 = koefisien *autoregressive*

ε_t = galat pada waktu t

θ_i = koefisien *Moving Average*

Menurut Rob J. Hyndman (2001), model ARMA merupakan dasar pembentukan model ARIMA, di mana komponen AR menggambarkan hubungan antara observasi sekarang dengan observasi sebelumnya, sedangkan komponen MA menggambarkan hubungan antara observasi sekarang dengan kesalahan prediksi pada periode sebelumnya. Model ARMA digunakan apabila data sudah stasioner sehingga tidak diperlukan proses differencing.

Selain itu, Makridakis dan Hibon (1997) menjelaskan bahwa model ARMA merupakan inti dari metodologi Box–Jenkins dalam analisis deret waktu karena mampu menggabungkan informasi historis dan struktur kesalahan untuk menghasilkan model peramalan yang lebih baik dibandingkan penggunaan model AR atau MA secara terpisah.

Prosedur pembentukan model **Autoregressive Integrated Moving Average (ARIMA)** pada dasarnya mengikuti metodologi **Box-Jenkins** yang dikembangkan oleh George E. P. Box dan Gwilym M. Jenkins. Metodologi ini terdiri atas empat tahapan utama, yaitu identifikasi model, estimasi parameter, pemeriksaan diagnostik, dan peramalan.

a. Identifikasi model

Tahap pertama, yaitu identifikasi model bertujuan untuk menentukan orde ARIMA(p, d, q). Adapun hal pertama yang perlu dilakukan adalah memvisualisasi data. Data time-series perlu di plot untuk mengetahui pola data, seperti

- Adanya tren
- Pola musiman
- Fluktuasi data
- Perubahan varians

Apabila data menunjukkan adanya tren atau varians yang tidak konstan, maka data belum memenuhi asumsi stasioner.

b. Uji stasioneritas

Model ARIMA mensyaratkan bahwa data harus bersifat stasioner. Ada beberapa tinjauan terkait stasioner, yaitu

1. Stasioner dalam Varians

Stasioner dalam variansi adalah kondisi di mana data time series tidak memperlihatkan adanya perubahan variansi yang jelas dari waktu ke waktu. Transformasi Box-Cox dapat digunakan untuk melakukan uji stasioneritas data pada varians. Apabila varians data tidak stasioner, transformasi dilakukan. Menurut Wei (2006), nilai lambda (λ) atau nilai pembulatan dari transformasi Box Cox dapat mengungkapkan apakah data stasioner dalam varians. Jika $\lambda = 1$, maka dapat dikatakan bahwa data telah stasioner dalam varians. Apabila varians data tidak stasioner, transformasi Box-Cox dapat dilakukan. Jika $T(Z_t)$ adalah fungsi transformasi dari Z_t , maka rumus berikut dapat diterapkan:

$$T(Y_t) = \begin{cases} \frac{Y_t^\lambda}{\lambda}, \lambda \neq 0 \\ \lim_{\lambda \rightarrow 0} \frac{Y_t^\lambda}{\lambda} = \ln Y_t, \lambda = 0 \end{cases} \quad (4)$$

dengan :

Y_t = data pada waktu ke- t

λ = nilai parameter transformasi

2. Stasioner dalam Mean

Stasioneritas merupakan salah satu asumsi utama dalam analisis deret waktu (time series), khususnya pada pembentukan model ARIMA. Menurut Box et al. (2015), suatu deret waktu dikatakan stasioner apabila karakteristik statistiknya, seperti rata-rata (mean), varians, dan kovarians, tidak berubah terhadap waktu. Dengan kata lain, perilaku data pada suatu periode memiliki karakteristik yang sama dengan periode lainnya sehingga pola historis dapat digunakan sebagai dasar untuk melakukan peramalan.

Secara matematis, suatu proses deret waktu $\{Y_t\}$ dikatakan stasioner dalam mean apabila memenuhi persamaan:

$$E(Y_t) = \mu \quad (5)$$

dengan:

$E(Y_t)$ = nilai harapan (*expected value*) pada waktu ke- t ,

μ = rata-rata yang konstan untuk seluruh periode pengamatan.

Persamaan tersebut menunjukkan bahwa nilai rata-rata data tidak berubah meskipun waktu terus berjalan. Apabila rata-rata data mengalami perubahan akibat adanya tren atau perubahan level, maka data dikatakan **tidak stasioner dalam mean**.

Menurut Brockwell dan Davis (2016), data yang tidak stasioner dapat menyebabkan hubungan statistik antarperiode menjadi tidak stabil sehingga parameter model yang diestimasi menjadi kurang akurat. Oleh karena itu, sebelum membentuk model ARIMA, perlu dipastikan bahwa data telah memenuhi asumsi stasioneritas dalam mean.

Uji stasioneritas dalam mean akan dilakukan menggunakan metode ADF (*Augmented Dickey-Fuller*). Uji ADF digunakan untuk mengetahui apakah suatu deret waktu mengandung *unit root*, yang merupakan penyebab utama ketidakstasioneran dalam mean. (Fuller, 1996)

Hipotesis yang digunakan adalah:

H_0 : data mengandung *unit root* (tidak stasioner dalam mean);

H_1 : data tidak mengandung *unit root* (stasioner dalam mean).

Kriteria pengambilan keputusan adalah sebagai berikut:

jika $p - value < 0,05$, maka H_0 ditolak sehingga data dinyatakan stasioner dalam mean;

jika $p - value \geq 0,05$, maka H_0 gagal ditolak sehingga data belum stasioner dan perlu dilakukan proses differencing.

Selain menggunakan *p-value*, keputusan juga dapat dilakukan dengan membandingkan nilai statistik ADF dengan nilai kritis (*critical value*). Apabila nilai statistik ADF lebih kecil (lebih negatif) daripada nilai kritis pada taraf signifikansi tertentu, maka data dinyatakan telah stasioner.

Apabila hasil uji menunjukkan bahwa data belum stasioner dalam mean, maka dilakukan proses *differencing*. Menurut Hyndman dan Athanasopoulos (2021), *differencing* merupakan metode utama dalam ARIMA untuk menghilangkan perubahan level dan tren sehingga rata-rata data menjadi konstan. Proses differencing pertama dinyatakan dengan persamaan:

$$\nabla Y_t = Y_t - Y_{t-1} \quad (6)$$

dengan :

∇Y_t = hasil *differencing* pertama

Y_t = nilai data pada periode ke- t

Y_{t-1} = nilai data pada periode sebelumnya

Apabila differencing pertama belum menghasilkan data yang stasioner, maka dapat dilakukan differencing orde kedua atau lebih hingga data memenuhi asumsi stasioneritas. Nilai orde differencing yang digunakan kemudian menjadi parameter d pada model ARIMA (p, d, q).

c. **Autocorrelation Function (ACF) dan Partial Autocorrelation Function (PACF)**

Setelah data deret waktu dinyatakan stasioner dalam varians dan rata-rata, tahapan berikutnya dalam pembentukan model ARIMA adalah identifikasi orde model, yaitu menentukan nilai parameter *autoregressive* (AR) yang dilambangkan dengan p dan *moving average* (MA) yang dilambangkan dengan q . Tahap ini merupakan bagian penting dalam metodologi Box-Jenkins, karena ketepatan dalam menentukan nilai p dan q akan memengaruhi kualitas model dan hasil peramalan.

Menurut Box et al. (2015), identifikasi model dilakukan dengan menganalisis pola *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF). Kedua grafik tersebut memberikan informasi mengenai hubungan antar pengamatan pada berbagai lag sehingga dapat digunakan untuk mengidentifikasi struktur model AR, MA, maupun ARMA.

Brockwell dan Davis (2016) menjelaskan bahwa *Autocorrelation Function* (ACF) mengukur keeratan hubungan antara suatu pengamatan dengan pengamatan sebelumnya pada berbagai lag, sedangkan *Partial Autocorrelation Function* (PACF) mengukur hubungan langsung antara dua pengamatan setelah pengaruh lag-lag di antaranya dihilangkan. Oleh karena itu, ACF dan PACF memiliki karakteristik yang berbeda dalam mengidentifikasi komponen model ARIMA.

1. **Autocorrelation Function (ACF)**

Autocorrelation Function (ACF) adalah suatu metode untuk mengevaluasi adanya hubungan atau korelasi pada suatu data time series yang terdapat antara waktu yang sama dengan lag waktu tertentu. ACF mengukur seberapa dekat korelasi antara Z_t dan Z_{t+k} pada data time series. ACF

berguna dalam mengidentifikasi model time 16 series yang sesuai dengan data dan juga untuk menentukan apakah data stasioner dalam mean.

Persamaan untuk menghitung ACF pada lag k adalah sebagai berikut: (Ruslan, Harahap, & Sembiring, 2013)

$$\hat{\rho}_k = \frac{\sum_{t=1}^{n-k} (Y_{t+k} - \bar{Y})(Y_t - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad (7)$$

dengan

$\hat{\rho}_k$ = koefisien autokorelasi pada lag-k

k = selisih waktu

n = jumlah observasi

$\bar{Y}$ = rata-rata dari pengamatan (Y_t)

Y_t = pengamatan pada waktu ke t

Y_{t+k} = pengamatan pada waktu $t + k, k = 1, 2, 3, \dots$

Pada diagram ACF digunakan untuk mengidentifikasi kestasioneran pada data. Data yang belum stasioner cenderung memiliki ciri-ciri seperti turunnya diagram ACF secara linier atau melambat. Jika ditemukan lag yang besar dalam model, pertimbangan untuk mengatasinya dapat dilakukan dengan menerapkan prinsip parsimony. Prinsip parsimony menyatakan bahwa semakin sederhana sebuah model statistik dengan jumlah variabel dependen yang cukup informatif untuk menjelaskan model, semakin baik pula model statistik tersebut. Dengan kata lain, dalam konteks ini, jika model yang lebih sederhana dapat memberikan penjelasan yang memadai terhadap fenomena yang diamati, maka model tersebut lebih disukai daripada model yang lebih kompleks dengan banyak variabel. Prinsip ini membantu mencegah overfitting dan memastikan bahwa model yang digunakan sesuai dengan data yang ada.. (Handayani, Wahyuningsih, & Yuniarti, 2018)

2. Partial Autocorrelation Function (PACF)

Partial Autocorrelation Function (PACF) merupakan fungsi yang digunakan untuk mengevaluasi korelasi parsial antara suatu variabel dengan variabel lag yang 18 telah dikontrol. PACF biasanya digunakan dalam analisis time series, terutama dalam model ARIMA (Autoregressive Integrated Moving Average), untuk menentukan jumlah lag yang harus dimasukkan ke dalam model. PACF merupakan fungsi yang menunjukkan korelasi antara suatu variabel dengan variabel lag tertentu setelah menghapus efek dari variabel lag yang ada di antara keduanya. Dalam model ARIMA, PACF dapat digunakan untuk menentukan jumlah variabel autoregresi (AR) yang harus dimasukkan ke dalam model. Jika PACF menunjukkan nilai yang signifikan pada lag tertentu, maka variabel autoregresi dengan lag tersebut harus dimasukkan ke dalam model. PACF biasanya diplot sebagai grafik dengan nilai korelasi parsial pada sumbu y dan lag pada sumbu x. Jika nilai korelasi parsial pada lag tertentu signifikan dan lebih besar dari interval kepercayaan, maka variabel autoregresi dengan lag tersebut harus dimasukkan ke dalam model (Hyndman & Athanasopoulos, 2018).

Secara matematis bentuk umum persamaan PACF adalah sebagai berikut. (Rufaidah & Effindi, 2019)

$$\phi_{k,k} = \text{Corr} \left(Y_k - \sum_{j=1}^{k-1} \phi_{k,j} Y_{k-j}, Y_0 \right) \quad (8)$$

dengan :

$\phi_{k,k}$ = PACF pada urutan ke-k

Y_k = Nilai pada urutan ke-k

$\phi_{k,j}$ = Koefisien PACF pada urutan ke-k
 Y_0 = Nilai rata-rata dari *time series*

d. Estimasi Parameter

Setelah diperoleh beberapa model kandidat melalui analisis **Autocorrelation Function (ACF)** dan **Partial Autocorrelation Function (PACF)**, tahapan selanjutnya dalam metodologi **Box-Jenkins** adalah **estimasi parameter** (*parameter estimation*). Tahap ini bertujuan untuk memperoleh nilai parameter model ARIMA yang paling sesuai dengan karakteristik data sehingga model mampu menggambarkan proses pembangkitan data secara optimal.

Menurut Box et al. (2015), estimasi parameter merupakan proses menentukan nilai koefisien model autoregressive (AR), moving average (MA), dan konstanta (apabila digunakan) berdasarkan data historis. Parameter yang diperoleh harus mampu menghasilkan residual yang bersifat acak (*white noise*) sehingga model layak digunakan untuk peramalan.

Senada dengan itu, Brockwell dan Davis (2016) dalam *Introduction to Time Series and Forecasting* menjelaskan bahwa tujuan utama estimasi parameter adalah memperoleh nilai parameter yang menghasilkan model dengan kesalahan prediksi sekecil mungkin dan mampu merepresentasikan struktur ketergantungan data deret waktu.

Menurut Hamilton (1994) dalam *Time Series Analysis*, proses estimasi parameter merupakan inti dari pembentukan model ARIMA karena seluruh proses inferensi statistik, pengujian hipotesis, dan peramalan sangat bergantung pada ketepatan parameter yang diestimasi.

Parameter yang Diestimasi

Pada model ARIMA, parameter yang diestimasi meliputi:

1. Parameter Autoregressive (AR)

Dilambangkan dengan

$$\phi_1, \phi_2, \dots, \phi_p$$

Parameter ini menunjukkan pengaruh nilai pengamatan sebelumnya terhadap nilai pengamatan saat ini.

2. Parameter Moving Average (MA)

Dilambangkan dengan

$$\theta_1, \theta_2, \dots, \theta_q$$

Parameter ini menggambarkan pengaruh galat (error) pada periode sebelumnya terhadap nilai pengamatan saat ini.

3. Konstanta (Constant/Intercept)

Pada beberapa model ARIMA ditambahkan parameter konstanta yang dilambangkan dengan (c). Menurut Hyndman dan Athanasopoulos (2021) dalam *Forecasting: Principles and Practice*, konstanta digunakan apabila proses deret waktu memiliki rata-rata yang tidak sama dengan nol setelah proses differencing. Sebaliknya, pada banyak model ARIMA, khususnya yang menggunakan differencing orde satu atau lebih, konstanta sering kali dihilangkan karena rata-rata data hasil differencing telah mendekati nol.

Metode yang paling banyak digunakan saat ini adalah **Maximum Likelihood Estimation (MLE)**.

Menurut Hamilton (1994), MLE merupakan metode estimasi yang memilih nilai parameter yang memaksimalkan fungsi likelihood, yaitu peluang munculnya data observasi berdasarkan parameter tertentu.

Secara umum,

$$L(\theta) = P(Y|\theta) \quad (9)$$

dengan:

$L(\theta)$ = fungsi likelihood

Y = data observasi

θ = vector parameter model

Parameter terbaik adalah parameter yang menghasilkan nilai likelihood terbesar.

Karena lebih mudah dihitung, optimasi biasanya dilakukan terhadap log-likelihood:

$$\ell(\theta) = \ln L(\theta) \quad (10)$$

Menurut Brockwell dan Davis (2016), hampir seluruh perangkat lunak statistik modern seperti **R**, **Python (statsmodels)**, **SAS**, **EViews**, dan **Minitab** menggunakan pendekatan Maximum Likelihood karena menghasilkan estimator yang konsisten, efisien, dan memiliki sifat asimtotik yang baik.

Menurut Box et al. (2015), setelah parameter diestimasi, setiap parameter harus diuji apakah berbeda secara signifikan dari nol.

Hipotesis yang digunakan adalah:

$$H_0: \beta = 0$$

$$H_1: \beta \neq 0$$

dengan:

H_0 : parameter tidak berpengaruh terhadap model

H_1 : parameter berpengaruh terhadap model

Statistik uji yang digunakan adalah:

$$t = \frac{\hat{\beta}}{SE(\hat{\beta})} \quad (11)$$

dengan :

t = nilai statistik uji (*t-statistic*)

β = nilai estimasi parameter (misalnya koefisien AR atau MA)

$SE(\beta)$ = *standard error* dari estimasi parameter.

atau pada estimasi MLE untuk sampel besar sering dilaporkan sebagai statistik **z**.

Kriteria keputusan:

jika **p-value < 0,05**, maka ditolak sehingga parameter signifikan;

jika **p-value $\geq$ 0,05**, maka gagal ditolak sehingga parameter tidak signifikan.

Menurut Hyndman dan Athanasopoulos (2021), model ARIMA yang baik umumnya memiliki seluruh parameter utama (AR dan MA) yang signifikan. Parameter yang tidak signifikan menunjukkan bahwa komponen tersebut mungkin tidak diperlukan dalam model.

e. Proses White Noise

White noise adalah suatu time series yang terdiri dari sekelompok variabel acak independen dan identik terdistribusi dengan mean dan varians terbatas. Apabila white noise tersebut terdistribusi secara normal dengan mean nol dan varians konstan, maka disebut sebagai white noise Gaussian. Ciri utama dari white noise adalah tidak adanya korelasi antara nilai-nilai pada time series tersebut, sehingga semua nilai korelasi pada ACF adalah nol. Oleh karena itu, jika ACF dari time series mendekati nol pada semua 20 lag, maka deret tersebut dapat dianggap sebagai white noise. Pengujian asumsi white noise dilakukan dengan menggunakan uji Ljung-Box. (Kafara et al., 2017)

Hipotesa :

$$H_0: \rho_1 = \rho_2 = \dots = \rho_l = 0$$

$$H_1: \text{Terdapat } \rho_i \neq 0$$

$$i = 1, 2, \dots, l$$

Dengan statistik uji Ljung-Box:

$$Q = n(n+2) \sum_{k=1}^m \frac{\rho_k^2}{n-k} n > l \quad (12)$$

Daerah penolakan : $Q > \chi^2(a; K - p - q)$

dengan :

m = lag maksimum

n = jumlah data (observasi)

l = lag ke- k

p dan q = order dari ARMA (p, q)

$\bar{\rho}_l$ = autokorelasi residual pada lag ke- k

f. Uji normalitas

Uji normalitas terhadap residual digunakan untuk menguji apakah residual dari model regresi atau analisis lainnya mengikuti distribusi normal. Residual adalah selisih 21 antara nilai yang diprediksi oleh model dan nilai yang diamati dalam data. Uji ini dapat dilakukan salah satunya dengan menggunakan uji Kolmogorov-Smirnov dengan hipotesis dan statistik uji sebagai berikut:

Hipotesis :

$$H_0 = \text{residual berdistribusi normal}$$

$$H_1 = \text{residual tidak berdistribusi normal}$$

Statistik uji :

$$D = \sup_x |s(x) - F_0(x)| \quad (13)$$

dimana :

$F_0(x)$ = fungsi distribusi kumulatif teoritis yang diuji

$s(x)$ = fungsi kumulatif empiris yang dihitung dari data yang diamati

Adapun kriteria pengambilan keputusan tolak H_0 jika $D > D_{(1-\alpha),n}$ atau jika $p - \text{value} > \text{taraf signifikansi } (\alpha)$. (Lestari & Wahyuningsih, 2012)

g. Pemilihan Model Peramalan Terbaik

Dalam proses analisis time series, terdapat banyak model yang dapat mewakili keadaan data. Untuk menentukan model terbaik, dapat dilakukan perhitungan model residual berdasarkan

kesalahan peramalan. Ada beberapa kriteria untuk memilih model terbaik berdasarkan residual, salah satunya adalah Akaike's Information Criterion (AIC). AIC digunakan untuk menentukan model yang paling optimal dari suatu data observasi. Ketika membandingkan dua atau lebih model regresi, model dengan nilai AIC terkecil dianggap sebagai model yang lebih baik. Rumus untuk menentukan nilai AIC dinyatakan dalam persamaan.: (Delsen et al., 2019)

$$AIC = n \log \left(\frac{RSS}{n} \right) + 2l \quad (14)$$

dengan :

AIC = nilai *Akaike Information Criterion*

n = jumlah observasi

RSS = Residual Sum of Square, yaitu jumlah kuadrat residual

l = jumlah parameter yang diestimasi dalam model

1.6.5. Evaluasi Model Peramalan

Setelah melalui proses pembentukan model ARIMA, akan diperoleh model ARIMA(p, d, q) terbaik. Model ARIMA akan diuji apakah model yang diperoleh akurat.

Dalam beberapa situasi, tingkat keakuratan dapat menjadi faktor penting dalam proses peramalan. Seperti yang diketahui, tidak ada metode peramalan yang dapat memprediksi kejadian di masa depan dengan akurasi mutlak. Oleh karena itu, dapat dikatakan bahwa setiap metode peramalan pasti akan menghasilkan kesalahan. Beberapa faktor yang dapat menyebabkan hasil peramalan menjadi tidak akurat meliputi adanya outlier, tren, pola musiman, atau pola siklus yang mungkin ada dalam 28 data yang sedang dianalisis. Hal ini menunjukkan bahwa metode yang digunakan tidak selalu cocok dengan situasi tertentu. (Sungkawa & Megasari, 2011)

a. Mean Absolute Percentage Error (MAPE)

Mean Absolute Percentage Error (MAPE) adalah nilai rata – rata perbedaan absolut yang ada diantara nilai dari prediksi dan nilai realisasi yang disebutkan sebagai hasil persenan dari nilai realisasi. Penggunaan Mean Absolute Percentage Error (MAPE) pada evaluasi dari hasil peramalan dapat melihat tingkat akurasi terhadap angka peramalan dan angka realisasi. Nilai Mean Absolute Percentage Error (MAPE) dapat dihitung dengan menggunakan persamaan berikut

$$MAPE = \left(\frac{100\%}{n} \right) \sum_{t=1}^n \left| \frac{Y_t - S_t}{Y_t} \right| \quad (15)$$

dengan :

Y_t = nilai aktual periode ke- t

S_t = nilai peramalan di periode ke- t

n = jumlah periode

Jika nilai MAPE yang diperoleh kurang dari 10% menunjukkan peramalan yang sangat baik dan memiliki peramalan yang baik jika nilai MAPE yang diperoleh kurang dari 20%

b. Mean Squared Error (MSE)

Mean Squared Error atau MSE dapat digunakan jika ada *outliers* yang perlu dideteksi. Pada dasarnya, MSE sangat bagus digunakan untuk mengaitkan bobot-bobot yang lebih besar ke titik-tertentu.

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - S_t)^2 \quad (16)$$

c. Root Mean Squared Error (RMSE)

RMSE (Root Mean Squared Error) dan MSE memiliki dua nilai yang saling berhubungan secara linear (melalui akar kuadrat). Pengurutan model berdasarkan RMSE akan identic dengan pengurutan model berdasarkan MSE

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - S_t)^2} \quad (17)$$

Ukuran-ukuran ini membantu menentukan seberapa dekat hasil peramalan dengan nilai aktual (Hyndman & Athanasopoulos, 2018).

1.6.6. Penelitian Terdahulu

Sejumlah penelitian telah membuktikan efektivitas metode ARIMA dalam peramalan permintaan di industri makanan dan minuman. Misalnya, Prasetyo dan Utami (2020) menemukan bahwa ARIMA memberikan hasil yang akurat dalam meramalkan permintaan minuman di sektor ritel. Demikian juga, Yaphira dan Hidayat (2023) berhasil menggunakan ARIMA untuk meramalkan ekspor kopi secara nasional. Hal ini menunjukkan bahwa metode ARIMA memiliki fleksibilitas tinggi dan dapat diadaptasikan pada skala mikro seperti *coffee shop*.

Penerapan model ARIMA dalam industri makanan dan minuman terbukti efektif dalam berbagai aspek, mulai dari peramalan penjualan, jumlah pengunjung, hingga harga komoditas. Model ini membantu pelaku industri dalam pengambilan keputusan yang lebih tepat dan efisien.

Penelitian terkait forecasting atau peramalan menggunakan metode ARIMA banyak digunakan dalam industri makanan dan minuman. Ida et al. (2022) menggunakan 3 model ARIMA yaitu model ARIMA (1,0,1), (1,0,0), (0,0,1) yang dibandingkan untuk memperoleh hasil peramalan terbaik dengan menggunakan 3 metode tersebut.

Berbeda dengan Ida et al. (2022), Hasby, dkk.(2023) menggunakan model ARIMA (0,1,1) dengan bantuan software minitab 18 untuk meramalkan penjualan beberapa produk berbeda oleh Huebee Indonesia dan memperoleh hasil peramalan dengan metode ARIMA (0,1,1) memiliki nilai MAPE yang terkecil sehingga dapat diperoleh kesimpulan bahwa model ARIMA (0,1,1) layak digunakan untuk prediksi data runtun waktu (time series) dari jumlah penjualan Huebee. Data yang diperoleh juga menunjukkan bahwa tidak semua produk menunjukkan trend peningkatan penjualan yang positif, ada beberapa produk tertentu khususnya produk lama yang mengalami penurunan penjualan.

Rais et al. (2024) meramalkan penjualan produk UMKM Jogja, khususnya produk Ice Cream dengan menggunakan metode Autoregressive dengan menggunakan data time series berupa data harian penjualan untuk digunakan dalam penelitian tersebut. Hasil dari penelitian ini dilakukan evaluasi error MSE dan RMSE and diperoleh hasil $MSE = 0,18$ dan $RMSE = 0,14$ yang menunjukkan bahwa metode peramalan Autoregressive (AR) berjalan cukup baik dalam peramalan penjualan produk UMKM di jogja karena evaluasi error MSE dan RMSE mendekati 0.

Radityo et al. (2025) meramalkan penjualan produk makanan restoran dengan studi kasus pada Waroeng Marisukakoi dengan batas peramalan hanya berlaku pada 4 menu utama, hasil yang diperoleh pada penelitian ini menunjukkan evaluasi error yang cukup tinggi dengan menggunakan MAPE, MSE, dan RMSE, namun metode ARIMA masih cukup layak digunakan karena nilai Mean Absolute Percentage Error (MAPE) kurang dari 50%, hal ini menunjukkan bahwa model ini masih bisa diterima atau cukup layak digunakan namun kurang baik akibat evaluasi error yang tidak terlalu minim.

Beberapa penelitian diatas menggunakan model ARIMA dengan parameter data yang berbeda tergantung dari data time series yang diperoleh. Data yang diperoleh akan memunculkan model ARIMA (p,d,q), namun evaluasi error yang digunakan tidak selalu sama tergantung dengan data yang diperoleh, seperti Ida et al. (2022) yang menggunakan MAPE, Rais et al. (2024) yang menggunakan MSE dan RMSE, serta Radityo et al. (2025) yang menggunakan ketiganya.

BAB II METODOLOGI PENELITIAN

a. Metode Penelitian

Penelitian ini merupakan penelitian **kuantitatif deskriptif** dengan pendekatan **studi kasus**, yang bertujuan untuk meramalkan permintaan minuman kopi menggunakan metode deret waktu ARIMA. Penelitian ini memfokuskan pada pengolahan dan analisis data historis penjualan untuk memperoleh model peramalan yang akurat dan aplikatif.

b. Lokasi dan Waktu Penelitian

Lokasi penelitian ini bertempat di beberapa *coffee shop* di Kota Makassar yang menjadi studi kasus dan di Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Hasanuddin, Kota Makassar dengan waktu penelitian berlangsung mulai dari Mei 2025.

c. Jenis dan Sumber Data

Penelitian menggunakan data penjualan produk minuman berbasis kopi yang diperoleh dari salah satu *coffee shop* di kota Makassar, yaitu Kofeynye. Periode data yang digunakan meliputi Januari 2024 hingga Maret 2025 dengan frekuensi mingguan, sehingga diperoleh 65 data hasil observasi.


Data yang digunakan merupakan data Primer yang langsung diperoleh dari Narasumber yang merupakan pemilik dari *coffee shop* yang digunakan sebagai studi kasus

d. Prosedur Penelitian

Adapun prosedur atau langkah-langkah yang dilakukan dalam penelitian ini adalah sebagai berikut:

1. Melakukan studi literatur terhadap referensi-referensi yang telah dikumpulkan yang berkaitan dengan topik yang diteliti sebagai tahap untuk menambah pengetahuan dasar peneliti.
2. Identifikasi model data berupa visualisasi data, uji stasioner dan transformasi data (differencing) apabila diperlukan.
3. Estimasi parameter (nilai p , d , dan q) serta membangun beberapa kombinasi model ARIMA.
4. Uji kelayakan model dengan mengevaluasi residual kemudian memilih model terbaik berdasarkan nilai kriteria tertentu.
5. Menggunakan model ARIMA yang terpilih untuk meramalkan permintaan minuman kopi mendatang.
6. Mengukur kinerja model dengan menghitung nilai kesalahan peramalan seperti MAPE, RMSE, MAE.

e. Diagram Alir



BAB III

HASIL DAN PEMBAHASAN

3.1. Data Penelitian

Data yang digunakan pada penelitian ini adalah data penjualan yang diperoleh langsung dari Kofeynye, yang merupakan sebuah coffeeshop yang berada di Kota Makassar yang terhitung mulai Januari 2024 hingga Maret 2025 dengan jumlah sebanyak 65 data. Secara keseluruhan, data dapat dilihat dari Tabel 3.1 berikut

Minggu	Jumlah Terjual	Item Terlaris	Minggu	Jumlah Terjual	Item Terlaris
1	214	Americano	34	340	Es Kopi Susu
2	230	Latte	35	329	Cappuccino
3	245	Es Kopi Susu	36	310	Americano
4	251	Cappuccino	37	300	Latte
5	234	Es Kopi Susu	38	289	Es Kopi Susu
6	219	Latte	39	295	Cappuccino
7	210	Americano	40	305	Es Kopi Susu
8	225	Es Kopi Susu	41	316	Latte
9	241	Cappuccino	42	324	Americano
10	259	Americano	43	330	Es Kopi Susu
11	276	Latte	44	320	Cappuccino
12	280	Es Kopi Susu	45	299	Americano
13	269	Cappuccino	46	290	Latte
14	249	Americano	47	280	Es Kopi Susu
15	236	Latte	48	294	Cappuccino
16	240	Es Kopi Susu	49	305	Es Kopi Susu
17	256	Cappuccino	50	316	Latte
18	265	Es Kopi Susu	51	325	Americano
19	281	Latte	52	339	Cappuccino
20	290	Americano	53	354	Es Kopi Susu
21	301	Es Kopi Susu	54	340	Latte
22	295	Cappuccino	55	325	Americano
23	309	Americano	56	310	Cappuccino
24	325	Latte	57	295	Es Kopi Susu
25	330	Es Kopi Susu	58	281	Latte
26	314	Cappuccino	59	265	Americano
27	301	Americano	60	251	Cappuccino
28	291	Latte	61	260	Es Kopi Susu
29	284	Es Kopi Susu	62	275	Latte
30	295	Cappuccino	63	290	Americano
31	304	Es Kopi Susu	64	305	Cappuccino
32	321	Latte	65	311	Es Kopi Susu
33	335	Americano			

Tabel 3.1 Data *Time-Series* Penjualan produk berbasis kopi

3.2. Statistik Deskriptif

Untuk memahami data analisis penelitian, berikut merupakan data analisis statistik deskriptif

Min	1st Qu..	Median	Mean	3rd Qu.	Max
210	265	295	288,3538	314	354

Tabel 3.2 Stastistik Deskriptif Data *Time-Series*

Pada Tabel 3.2 dapat dilihat bahwa nilai minimum penjualan berada pada angka 210 yang terjadi pada 12 – 18 Februari dan yang tertinggi terjadi pada 30 Desember hingga 5 Januari. Dapat dilihat juga nilai meannya atau rata-rata penjualannya ada pada angka 288.3538.

3.3. Identifikasi Model Time Series ARIMA

Untuk menghasilkan hasil ramalan jumlah penjualan produk minuman berbasis kopi maka data *in-sample* yang telah ditentukan menggunakan metode ARIMA (*Autoregressive Integrated Moving Average*). Plot *time series* penjualan produk minuman berbasis kopi mulai dari Januari 2024 hingga Maret 2025 sebagai mana pada Gambar 3.1 berikut



Gambar 3.1 Plot Data *Time-Series* Penjualan Produk Berbasis Kopi


Gambar 3.1 menunjukkan data penjualan yang cenderung bergerak naik atau meningkat dari awal tahun hingga akhir, namun tidak ada lonjakan yang ekstrim.

3.4. Uji Stasioneritas

Langkah awal yang harus dilakukan dalam menentukan model *time series* pada tahapan identifikasi adalah memeriksa kestasioneran data melalui diagram *time series*.

3.4.1. Stasioneritas dalam varians

Untuk memperoleh data yang stasioner dalam varians, diperlukan metode transformasi *Box-Cox*. Data akan dikatakan stasioner dalam varians apabila nilai *rounded Value* atau λ sama dengan 1. Adapun Gambar 3.2 berikut merupakan hasil pemeriksaan Transformasi *Box-Cox* dari data asli.



Gambar 3.2 Plot *Box-Cox* Data Penjualan

Diperoleh hasil dari proses Transformasi *Box-Cox* yaitu nilai dari *Rounded Value* (λ) = 2,568 yang berarti data belum stasioner dalam varians sehingga perlu dilakukan transformasi data untuk memperoleh nilai *Rounded Value* (λ) = 1. Adapun hasil transformasi data dapat dilihat pada Gambar 3.3 berikut



Gambar 3.3 Plot *Box-Cox* Data Penjualan Setelah Transformasi

Diketahui jika nilai dari proses transformasi *Box-Cox* telah memperoleh nilai *Rounded Value* (λ) = 1 yang artinya data telah stasioner terhadap varians.

3.4.2. Stasioner dalam Mean

Untuk memastikan apakah data stasioner terhadap mean, dapat diuji dengan menggunakan metode uji ADF (*Augmented Dickey-Fuller*). Adapun hasil uji ADF dapat dilihat pada Tabel 3.3 berikut :

<i>Dickey Fuller</i>	<i>p-value</i>	<i>Hypothesis</i>
-2,087	0,25	<i>Non-Stationary</i>

Tabel 3.3 Hasil Uji ADF Data Penjualan

Pada Tabel 3.3 diperoleh nilai ADF atau *Dickey-Fuller* sebesar $-2,087$ dan nilai dari *p-value* sebesar 0,25, dengan hipotesis :

H_0 = data memiliki akar unit (tidak stasioner)

H_1 = data tidak memiliki akar unit (stasioner)

Adapun kriteria tolak H_0 jika nilai *p-value* lebih besar dari tingkat signifikansi ($\alpha = 0.05$). Nilai *p-value* sebesar $0,25 > 0,05$ sehingga dapat ditarik Kesimpulan bahwa data belum stasioner. Untuk memperoleh data yang stasioner dalam *mean* maka perlu dilakukan proses *differencing*. Adapun hasil uji ADF setelah *differencing* dapat dilihat pada Tabel 3.4 berikut :

<i>Dickey Fuller</i>	<i>p-value</i>	<i>Hypothesis</i>
-6,18	$6,5 \times 10^{-8}$	<i>Stationary</i>

Tabel 3.4 Hasil Uji ADF Data Penjualan Setelah *Differencing*

Pada tabel diperoleh nilai ADF atau *Dickey-Fuller* sebesar $-6,180$ dan nilai *p-value* sebesar $6,5 \times 10^{-8}$ dengan hipotesis :

H_0 = mengandung kecenderungan atau tidak stasioner

H_1 = tidak mengandung kecenderungan atau stasioner

dimana kriteria keputusan H_0 ditolak jika nilai *Augmented Dickey-Fuller* lebih kecil dari nilai kritis atau nilai *p-value* lebih kecil dibanding tingkat signifikansi ($\alpha = 0.05$). Nilai ADF *p-value* sebesar $6,5 \times 10^{-8} < 0,05$ sehingga dapat ditarik kesimpulan bahwa data telah stasioner. Adapun plot data setelah *differencing* dapat dilihat pada Gambar 3.4 berikut




Gambar 3.4 Plot Data Penjualan Setelah *Differencing*


Berdasarkan grafik deret waktu, data berfluktuasi di sekitar nilai tengah yang relatif konstan dan tidak menunjukkan adanya tren meningkat maupun menurun. Selain itu, penyebaran data relatif konstan sepanjang periode pengamatan. Kondisi tersebut memberikan indikasi awal bahwa berdasarkan Gambar 3.4 data telah mencapai kondisi stasioner.

3.5. Analisis Plot ACF dan PACF

Berdasarkan hasil uji Augmented Dickey Fuller, data telah stasioner sehingga langkah selanjutnya adalah menemukan taksiran nilai ACF dan PACF. Berikut adalah plot ACF dan PACF dari data hasil *differencing* dapat dilihat pada Gambar 3.5 dan Gambar 3.6 berikut :



Gambar 3.5 Plot ACF Data Penjualan Setelah *Differencing*



Gambar 3.6 Plot PACF Data Penjualan Setelah *Differencing*

Berdasarkan Gambar 3.5 dan Gambar 3.6 dapat dilihat bahwa plot hanya signifikan pada lag 1. Setelah lag 1, nilai PACF langsung mendekati nol. Pola ini menunjukkan bahwa nilai AR(1) atau $p = 1$ karena PACF mengalami cut-off pada lag 1. Pada plot ACF terlihat bahwa nilainya menurun secara bertahap dan tidak langsung terpotong pada lag tertentu, yang mana pola ini juga merupakan karakteristik AR process dan kembali mendukung keberadaan komponen AR(1).

3.6. Estimasi Model ARIMA

Dari plot ACF dan PACF, kandidat yang paling memungkinkan adalah :

$$ARIMA(1,1,0)$$

Namun dalam praktik *Box-Jenkins*, kita akan tetap menguji beberapa model disekitar pola utama, yaitu :

$$ARIMA(1,1,0)$$

$$ARIMA(0,1,1)$$

$$ARIMA(1,1,1)$$

3.7. Penaksiran dan Pengujian Signifikansi Parameter

Setelah diperoleh model-model pada tahap identifikasi, maka selanjutnya akan dilakukan penaksiran parameter dan pemeriksaan diagnostic untuk model ARIMA data penjualan dengan menggunakan uji hipotesis sebagai berikut

$H_0: \theta = 0$ parameter model signifikansi

$H_1: \theta \neq 0$ minimal ada satu parameter model yang tidak signifikan

$$\text{Statistik uji : } t = \frac{\hat{\theta}}{se(\hat{\theta})}$$

Keputusan : H_0 ditolak jika $|t| > t_{\frac{\alpha}{2}, df=n-np}$

Kemudian dengan menggunakan tabel t , diperoleh nilai t ($df = n - 1 = 65 - 1 = 64; \frac{\alpha}{2} = 0,025$) = 1.998

Hasil penaksiran dan pengujian kesignifikanan parameter di atas dapat dirangkum sebagai mana yang terlihat pada Tabel 3.5 berikut :

Model	Parameter	Koefisien	Std Error	t_{hitung}	t_{tabel}	Keterangan
ARIMA(1,1,0)	AR(1)	0,6405	0,1558	4,112	1,998	Signifikan
ARIMA(0,1,1)	MA(1)	0,5753	0,14	4,11	1,998	Signifikan
ARIMA(1,1,1)	AR(1)	0,5038	0,2177	2,314	1,998	Signifikan
	MA(1)	0,2772	0,2085	1,33	1,998	Tidak Signifikan

Tabel 3.5 Hasil Pengujian Signifikansi Parameter Model Data Penjualan

Berdasarkan hasil estimasi parameter, seluruh parameter pada model ARIMA(1,1,0), ARIMA(0,1,1), dan ARIMA(1,1,1) memiliki nilai $|t \text{ hitung}|$ yang lebih besar daripada t tabel sebesar 1,999 pada taraf signifikansi 5%. Dengan demikian seluruh parameter pada ketiga model signifikan dan layak dipertimbangkan untuk tahap diagnostik model selanjutnya.

3.8. Pemeriksaan Diagnostik

Pada tahap ini terdiri atas Uji White Noise dan Uji normalitas Residual, adalah sebagai berikut :

3.8.1. Uji White Noise

Pada tahap uji *white noise* untuk model ARIMA digunakan uji *Ljung-Box* dengan hipotesis :

H_0 : residual merupakan *white noise*

H_1 : residual bukan *white noise*

Dengan kriteria tolak H_0 apabila $p - value \leq 0,05$

dengan menggunakan uji *Ljung-Box* maka didapatkan hasil sebagaimana pada Tabel 3.6 berikut

Model	$\chi^2(Q\text{-Stat})$	Df	$p\text{-value}$	Keterangan
ARIMA(1,1,0)	3,858	12	0,9859	White Noise
ARIMA(0,1,1)	3,981	12	0,9838	White Noise
ARIMA(1,1,1)	2,946	12	0,9959	White Noise

Tabel 3.6 Hasil Uji *White-Noise* Model Data Penjualan

Berdasarkan Tabel 3.6 , diketahui bahwa $p\text{-value}$ yang diperoleh dari ARIMA(1,1,0) sebesar 0,9859, untuk ARIMA (0,1,1) sebesar 0,9838, dan untuk ARIMA(1,1,1) sebesar 0,9959. Hal ini menunjukkan bahwa $p\text{-value}$ lebih besar dari nilai α , yaitu 0,05 sehingga dapat disimpulkan bahwa model telah memenuhi uji syarat *white noise*.

3.8.2. Uji Normalitas Residual

Statistik uji yang dapat digunakan untuk menguji normalitas pada residual data adalah uji *Jarque-Bera* dengan hipotesis :

H_0 : residual berdistribusi normal

H_1 : residual tidak berdistribusi normal

dengan kriteria tolak H_0 apabila $p - value \leq 0,05$

Model	$\chi^2(Jarque\text{-}Bera)$	Df	$p\text{-value}$	Keterangan
ARIMA(1,1,0)	6057,841	2	<0,01	Tidak Normal
ARIMA(0,1,1)	5854,156	2	<0,01	Tidak Normal
ARIMA(1,1,1)	6272,046	2	<0,01	Tidak Normal

Tabel 3.7 Hasil Uji Normalitas Residual Model Data Penjualan

Berdasarkan Tabel 3.7, diketahui bahwa nilai $p\text{-value}$ yang diperoleh dari ARIMA(1,1,0), ARIMA(0,1,1), dan ARIMA(1,1,1) memiliki nilai $p - value < 0,01$. Hal ini menunjukkan $p\text{-value}$ lebih kecil dari nilai $\alpha = 0,05$. Sehingga dapat disimpulkan residual ketiga model dapat dianggap tidak berdistribusi normal menurut uji *Jarque-Bera*. Dalam praktik *time-series*, hal ini tidak selalu menggugurkan model ARIMA, terutama apabila kriteria sebelumnya, yaitu parameternya sudah signifikan dan residual telah lulus uji *white noise* telah terpenuhi, dan juga tujuan utama yang kita inginkan adalah *forecasting*.

3.9. Pemilihan Model Terbaik

Pada tahap ini akan dilakukan pemilihan model terbaik dengan membandingkan nilai AIC (*Akaike Info Criterion*) untuk data *in-sample* dan nilai MAPE (*Mean Absolute Percentage Error*). Dengan ketentuan jika nilai AIC dan MAPE semakin kecil, maka semakin baik. Untuk nilai AIC dapat dilihat pada Tabel 3.8 berikut :

Model	AIC
-------	-----

ARIMA(1,1,0)	478,945
ARIMA(0,1,1)	483,447
ARIMA(1,1,1)	476,393

Tabel 3.8 Perbandingan Nilai AIC Model Data Penjualan

Setelah memperoleh nilai AIC, kemudian akan dihitung nilai MAPE yang kemudian akan dibandingkan. Perhitungan dilakukan dengan menggunakan :

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right|$$

Kemudian untuk perbandingan nilai MAPE dapat dilihat pada Tabel 3.9 berikut :

Model	MAPE
ARIMA(1,1,0)	2,795
ARIMA(0,1,1)	3,078
ARIMA(1,1,1)	2,655

Tabel 3.9 Perbandingan Nilai MAPE Model Data Penjualan

Dari tabel dapat dilihat bahwa ketiga model memiliki nilai $MAPE < 10\%$ sehingga dapat dinilai bahwa ketiga model memiliki kemampuan peramalan yang sangat baik. Pemilihan model terbaik dapat dilakukan dengan membandingkan ketiga model dengan menggunakan nilai AIC dan MAPE, dapat dilihat pada Tabel 3.10 berikut :

Model	AIC	MAPE
ARIMA(1,1,0)	478,945	2,795
ARIMA(0,1,1)	483,447	3,078
ARIMA(1,1,1)	476,393	2,655

Tabel 3.10 Perbandingan Nilai AIC dan MAPE Model Data Penjualan

Berdasarkan Tabel 3.10, model ARIMA(1,1,1) memiliki performa terbaik dibandingkan model kandidat lainnya. Model tersebut menghasilkan nilai AIC sebesar 478,945 dan nilai MAPE sebesar 2,655%, yang merupakan nilai terkecil di antara seluruh model yang diuji. Namun, karena parameter MA(1) pada model ARIMA(1,1,1) tidak signifikan sehingga model ini tidak dapat digunakan untuk proses *forecasting* yang akan kita lakukan.


3.10. Evaluasi Data Out-Sample

Evaluasi *out-sample* dilakukan untuk mengevaluasi kemampuan model ARIMA dalam melakukan peramalan pada data yang tidak digunakan dalam proses pembentukan model. Data *out-sample* merupakan data aktual pada periode pengujian yang dibandingkan dengan hasil peramalan dari model terpilih. Adapun data *out-sample* yang digunakan dalam penelitian ini disajikan pada tabel 3.13 berikut.

Minggu	Data Aktual	Data Prediksi (Out-Sample)	Selisih (Error)
51	325	323,04005	1.953995
52	339	330.764913	8.235087
53	354	347.967642	6.032358
54	340	363.608188	-23.608188
55	325	331.032358	-6.032358
56	310	315.391812	-5.391812
57	295	300.391812	-5.391812
58	281	285.391812	-4.391812
59	265	272.032358	-7.032358
60	251	254.751266	-3.751266
61	260	242.032358	17.967642

62	275	265.764913	9.235087
63	290	284.608188	5.391812
64	305	299.608188	5.391812
65	311	314.608188	-3.608188

Tabel 3.11 Hasil Evaluasi *Out-Sample*



Gambar 3.7 Plot Hasil Evaluasi *Out-Sample*

Berdasarkan Hasil Evaluasi *Out-Sample*, diperoleh hasil uji akurasi model ARIMA (1,1,0), yang dapat dilihat pada tabel 3.14 berikut :

ARIMA(1,1,0)	MAE	MAPE (%)	MSE	RMSE
	7.561039	2.524566	88.133508	9.387945


Tabel 3.12 Uji Akurasi Model

3.11. Forecasting

Pada tahap ini model terbaik akan digunakan untuk peramalan data hasil penjualan. Adapun model terbaik yang digunakan adalah model ARIMA(1,1,0). Dengan hasil prediksi diperoleh pada Tabel 3.13 berikut

Minggu	Forecast	Batas Bawah	Batas Atas
66	314,84	295,54	334,15
67	317,31	280,21	354,4
68	318,88	264,63	373,14
69	319,89	249,62	390,17
70	320,54	235,48	405,6
71	320,95	222,29	419,62
72	321,22	210	432,44
73	321,39	198,54	444,24
74	321,5	187,8	455,19
75	321,57	177,72	465,41
76	321,61	168,21	475,02
77	321,64	159,19	484,09

Tabel 3.13 Hasil Peramalan Data Penjualan



Gambar 3.8 Plot Hasil Peramalan Data Penjualan

Berdasarkan model $ARIMA(1,1,0)$, penjualan diperkirakan relative stabil selama 12 minggu kedepan dengan kecenderungan meningkat tipis sekitar 314,84 menjadi 321,64 unit. Dengan interval prediksi 95% semakin melebar seiring bertambahnya horizon peramalan, yang merupakan karakteristik normal model ARIMA akibat ketidakpastian prediksi meningkat pada periode yang lebih jauh. Dan karena ini merupakan peramalan untuk model penjualan, maka bentuk hasil peramalan akan diganti menjadi nilai yang bulat sehingga diperoleh hasil seperti yang terlihat pada tabel 3.14.

Minggu	Forecast	Batas Bawah	Batas Atas
66	315	295,54	334,15
67	317	280,21	354,4
68	319	264,63	373,14
69	320	249,62	390,17
70	321	235,48	405,6
71	321	222,29	419,62
72	321	210	432,44
73	321	198,54	444,24
74	322	187,8	455,19
75	322	177,72	465,41
76	322	168,21	475,02
77	322	159,19	484,09

Tabel 3.14 Hasil Peramalan Data Penjualan Setelah Pembulatan

Berdasarkan hasil analisis deret waktu menggunakan metode Autoregressive Integrated Moving Average (ARIMA), diperoleh bahwa data penjualan belum memenuhi asumsi stasioneritas pada kondisi awal sehingga dilakukan transformasi Box-Cox untuk menstabilkan varians. Selanjutnya dilakukan pengujian stasioneritas terhadap rata-rata menggunakan uji Augmented Dickey-Fuller (ADF) dan proses differencing hingga data memenuhi asumsi stasioneritas yang diperlukan dalam pemodelan ARIMA.

Tahap identifikasi model melalui analisis plot Autocorrelation Function (ACF) dan Partial Autocorrelation Function (PACF) menghasilkan beberapa model kandidat, yaitu $ARIMA(1,1,0)$, $ARIMA(0,1,1)$, dan $ARIMA(1,1,1)$. Seluruh model kemudian diestimasi dan dievaluasi berdasarkan signifikansi parameter, uji diagnostik residual, serta kriteria pemilihan model.

Hasil pengujian menunjukkan bahwa model ARIMA(1,1,0) memiliki parameter yang signifikan serta memenuhi asumsi residual white noise. Selain itu, model tersebut memiliki struktur yang lebih sederhana sehingga sesuai dengan prinsip parsimony dalam metode Box-Jenkins. Oleh karena itu, model ARIMA(1,1,0) dipilih sebagai model terbaik untuk digunakan dalam proses peramalan data penjualan.

Berdasarkan model ARIMA(1,1,0), dilakukan peramalan penjualan untuk periode 12 minggu ke depan. Hasil peramalan menunjukkan bahwa penjualan diperkirakan berada pada kondisi yang relatif stabil dengan kecenderungan mengalami peningkatan secara bertahap. Informasi tersebut dapat dimanfaatkan sebagai dasar dalam penyusunan rencana produksi, pengelolaan persediaan, serta pengambilan keputusan operasional sehingga perusahaan dapat mengantisipasi kebutuhan pasar pada periode mendatang.

BAB IV KESIMPULAN

4.1. Kesimpulan

Berdasarkan hasil penelitian mengenai peramalan penjualan minuman berbasis kopi pada coffee shop di Kota Makassar menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA), dapat disimpulkan bahwa data historis penjualan menunjukkan pola yang cenderung meningkat dengan fluktuasi yang masih relatif wajar, sehingga sebelum dilakukan pemodelan diperlukan transformasi Box-Cox dan proses *differentencing* untuk memenuhi asumsi kestasioneran data. Hasil identifikasi model melalui analisis plot ACF dan PACF menghasilkan beberapa model kandidat, yaitu ARIMA(1,1,0), ARIMA(0,1,1), dan ARIMA(1,1,1), yang selanjutnya dievaluasi berdasarkan signifikansi parameter, uji diagnostik residual, serta ukuran akurasi peramalan. Meskipun model ARIMA(1,1,1) memiliki nilai AIC dan MAPE yang paling kecil, model tersebut tidak dipilih karena salah satu parameternya tidak signifikan, sehingga model ARIMA(1,1,0) ditetapkan sebagai model terbaik karena seluruh parameternya signifikan, memenuhi asumsi residual *white noise*, memiliki struktur yang lebih sederhana sesuai prinsip *parsimony*, serta tetap menghasilkan tingkat kesalahan peramalan yang rendah dengan nilai MAE sebesar 8,41, MSE sebesar 118,62, RMSE sebesar 10,89, dan MAPE sebesar 2,795% yang menunjukkan kategori peramalan sangat baik. Berdasarkan model tersebut, hasil peramalan penjualan untuk 12 minggu ke depan diperkirakan berada pada kondisi yang relatif stabil dengan kecenderungan meningkat secara bertahap dari sekitar 315 unit menjadi 322 unit per minggu. Dengan demikian, metode ARIMA terbukti mampu memodelkan pola historis penjualan minuman berbasis kopi secara baik dan menghasilkan informasi peramalan yang dapat dimanfaatkan sebagai dasar dalam penyusunan rencana produksi, pengelolaan persediaan bahan baku, serta pengambilan keputusan operasional guna meningkatkan efisiensi dan kesiapan coffee shop dalam memenuhi permintaan pelanggan.

4.2. Saran

Berdasarkan hasil penelitian diperoleh saran berupa memproyeksi hasil peramalan yang diperoleh dengan hasil penjualan aktual yang terjadi untuk menilai apakah hasil peramalan memiliki akurasi yang tinggi, sehingga model peramalan yang digunakan dapat dinilai bahwa signifikan atau tidak tergantung dari hasil dari perbandingan hasil peramalan dan data hasil penjualan aktual yang sesuai dengan panjang data yang diramalkan.

DAFTAR PUSTAKA

- Ali, F. (2024). *Peramalan permintaan produk minuman pada sebuah kafe di Surabaya dengan pendekatan time series* [Master's thesis, Institut Teknologi Sepuluh Nopember].
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.
- Brockwell, P. J., & Davis, R. A. (2016). *Introduction to time series and forecasting* (3rd ed.). Springer.
- Chatfield, C. (2004). *The analysis of time series: An introduction* (6th ed.). Chapman & Hall/CRC.
- Erlina, R. R., & Azhar, R. (2020). Forecasting model of agriculture commodity of value export of coffee; application of ARIMA model. *Jurnal Teknik Pertanian Lampung (Journal of Agricultural Engineering)*, 9(3), 257–263.
- Fuller, W. A. (1996). *Introduction to statistical time series* (2nd ed.). John Wiley & Sons.
- Hamilton, J. D. (1994). *Time series analysis*. Princeton University Press.
- Hamas, R. D. P., Setiawan, N. Y., & Ratnawati, D. E. (2025). Prediksi penjualan makanan restoran menggunakan metode ARIMA: Studi kasus Waroeng Marisukakoi. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 9(5).
- Handayani, R., Wahyuningsih, S., & Yuniarti, D. (2018). Pemodelan Generalized Space Time Autoregressive (GSTAR) pada data inflasi di Kota Samarinda dan Kota Balikpapan. *Jurnal Ekspansional*, 9(2), 153–162.
- Heizer, J., & Render, B. (2015). *Manajemen operasi: Manajemen keberlangsungan dan rantai pasokan* (Edisi 11). Salemba Empat.
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2nd ed.).
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.).
- Makridakis, S., & Hibon, M. (1997). ARMA models and the Box–Jenkins methodology. *Journal of Forecasting*, 16(3), 147–163.
- Makridakis, S., Wheelwright, S. C., & Hyndman, R. J. (1998). *Forecasting: Methods and applications* (3rd ed.). John Wiley & Sons.
- Mahayana, I. B. B., Mulyadi, I., & Soraya, S. (2022). Peramalan penjualan helm dengan metode ARIMA (Studi kasus Bagus Store). *Inferensi*, 5(1), 45–52.
- Nasirudin, F., Pindianti, M., Said, D. I. S., & Widodo, E. (2022). Peramalan jumlah produksi kopi di Jawa Timur pada tahun 2020–2021 menggunakan metode Seasonal Autoregressive Integrated Moving Average (SARIMA). *AGRIUM: Jurnal Ilmu Pertanian*, 25(1).
- Ramadhani, M. R., Nurmalitasari, & Nurchim. (2024). Pengembangan model prediksi penjualan Ice Cream UMKM Jogja menggunakan metode autoregressive. *Jurnal Derivat: Jurnal Matematika dan Pendidikan Matematika*, 11(2), 113–122. <https://doi.org/10.31316/jderivat.v10i2.6289>

Wei, W. W. S. (2006). *Time series analysis: Univariate and multivariate methods* (2nd ed.). Pearson Addison Wesley.

Yaphira, V., & Hidayat, A. S. E. (2023). Forecasting Indonesian coffee exports using ARIMA. *Proceeding of The Symposium on Data Science (SDS)*.

Rufaidah, A., & Effindi, M. A. (2019). Analisis Time Series Untuk Menentukan Model Terbaik. *Jurnal Teori dan Terapan Matematika*.

LAMPIRAN

Lampiran 1 Transformasi Data

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from scipy.stats import boxcox
from scipy.stats import boxcox_llf

# =====

# Membaca data

# =====

df = pd.read_excel("/data penjualan.xlsx", header=1) # Menambahkan header=1

data = df["Jumlah Barang Terjual"]

data = data.dropna()

data_transform = data.copy()

# =====

# Transformasi pertama

# =====

data_bc, lambda1 = boxcox(data)

print(f"Lambda awal : {lambda1:.4f}")

# =====
```

```

# Menghitung kembali lambda pada data hasil transformasi

# =====

_, lambda2 = boxcox(data_bc)

print(f"Lambda setelah transformasi : {lambda2:.4f}")

# =====

# Menghitung log-likelihood untuk data hasil transformasi

# =====

lambda_values = np.linspace(-2, 4, 300)

loglik = []

for lam in lambda_values:
    ll = boxcox_llf(lam, data_bc)
    loglik.append(ll)

loglik = np.array(loglik)

# nilai maksimum

idx = np.argmax(loglik)

lambda_opt = lambda_values[idx]

loglik_opt = loglik[idx]

print(f"Lambda optimum hasil transformasi : {lambda_opt:.4f}")
print(f"Log Likelihood maksimum : {loglik_opt:.4f}")

```

Lampiran 2 Plot Hasil Transformasi Data

```
plt.figure(figsize=(8,5))

plt.plot(lambda_values,
         loglik,
         color="blue",
         linewidth=2)

plt.scatter(lambda_opt,
           loglik_opt,
           color="red",
           s=80)

plt.axvline(lambda_opt,
            color="red",
            linestyle="--",
            label=f"Lambda = {lambda_opt:.3f}")

plt.xlabel("Lambda")

plt.ylabel("Log-Likelihood")

plt.title("Box-Cox Plot Setelah Transformasi")

plt.legend()

plt.grid(True)
```

```
plt.show()
```

Lampiran 3 Uji Parameter Model

```

import pandas as pd

import numpy as np

from scipy.stats import t

from statsmodels.tsa.arima.model import ARIMA


# Re-reading the data to ensure 'ts' is correctly prepared

data_reloaded = pd.read_excel("data penjualan.xlsx")

ts_reloaded = data_reloaded['Unnamed: 2'].iloc[2:]

ts_reloaded = pd.to_numeric(ts_reloaded)

ts_reloaded = ts_reloaded.reset_index(drop=True)

ts_reloaded.name = "Penjualan"


# Daftar model yang akan diuji

model_list = [

    (0,1,1),

    (1,1,0),

    (1,1,1)

]


print("\n=====")

print("PERBANDINGAN UJI PARAMETER MODEL ARIMA")

print("=====")


for order in model_list:

```

```

print(f"\n--- Uji PARAMETER UNTUK ARIMA{order} ---")

model = ARIMA(ts_reloaded, order=order)

fit = model.fit()

koef = fit.params

std_error = fit.bse

z_hitung = fit.tvalues

p_value = fit.pvalues

# Recalculate t_tabel for each model as 'k' (number of parameters) might change

alpha = 0.05

n = len(ts_reloaded)

k = len(koef)

df = n - k

t_tabel = t.ppf(1 - alpha / 2, df)

hasil_estimasi_single = pd.DataFrame({

    "Parameter": koef.index,

    "Koefisien": koef.values,

    "Std Error": std_error.values,

    "Z Hitung": z_hitung.values,

    "P-value": p_value.values

})

```

```

hasil_estimasi_single["Keputusan (P-value)"] = np.where(
    hasil_estimasi_single["P-value"] < alpha,
    "Signifikan",
    "Tidak Signifikan"
)

```

```

hasil_estimasi_single["t Hitung"] = (
    hasil_estimasi_single["Koefisien"] / hasil_estimasi_single["Std Error"]
)

```

```

hasil_estimasi_single["Keputusan (t)"] = np.where(
    abs(hasil_estimasi_single["t Hitung"]) > t_tabel,
    "Signifikan",
    "Tidak Signifikan"
)

```

```

display(hasil_estimasi_single)
print(f"t tabel untuk ARIMA{order}: {round(t_tabel, 4)}")

```

Lampiran 4 Pemilihan Model Terbaik

```

import pandas as pd
import numpy as np
from sklearn.metrics import mean_absolute_error, mean_squared_error

# 1. Mengambil data dari DataFrame perbandingan yang sudah ada
# Kita mulai dari indeks 1 (baris kedua) untuk mengesampingkan Minggu pertama
df_filtered = df_fitted_comparison.iloc[1:].copy()

y_true_filtered = df_filtered['Data Aktual (Y)']
model_names = ['ARIMA(0, 1, 1)', 'ARIMA(1, 1, 0)', 'ARIMA(1, 1, 1)']

metrik_filtered_list = []

# 2. Hitung ulang metrik untuk setiap model
for name in model_names:
    y_hat_col = f'Y_hat {name}'
    y_pred_filtered = df_filtered[y_hat_col]

    mae = mean_absolute_error(y_true_filtered, y_pred_filtered)
    mse = mean_squared_error(y_true_filtered, y_pred_filtered)
    rmse = np.sqrt(mse)
    mape = np.mean(np.abs((y_true_filtered - y_pred_filtered) / y_true_filtered)) * 100

    # Ambil AIC/BIC dari hasil sebelumnya (karena nilai ini tidak berubah meskipun evaluasi error
    # difilter)

    aic = summary_perbandingan.loc[summary_perbandingan['Model'] == name, 'AIC'].values[0]
    bic = summary_perbandingan.loc[summary_perbandingan['Model'] == name, 'BIC'].values[0]

```

```

metrik_filtered_list.append({
    'Model': name,
    'MAE': mae,
    'MSE': mse,
    'RMSE': rmse,
    'MAPE (%)': mape,
    'AIC': aic,
    'BIC': bic
})

```

3. Tampilkan Tabel Perbandingan Baru

```

df_accuracy_filtered = pd.DataFrame(metrik_filtered_list)
print("PERBANDINGAN AKURASI (EKSKLUSI MINGGU PERTAMA)")
print("="*60)
display(df_accuracy_filtered)

```

Simpan ke Excel sebagai sheet baru atau file baru

```

with pd.ExcelWriter('Akurasi_Tanpa_Minggu_1.xlsx') as writer:

```

```

    df_accuracy_filtered.to_excel(writer, index=False)

```

```

print(f"\nKesimpulan: Model terbaik tetap {df_accuracy_filtered.loc[df_accuracy_filtered['MAPE (%)'].idxmin(), 'Model']} dengan MAPE yang lebih rendah yaitu {df_accuracy_filtered['MAPE (%)'].min():.4f}%")

```

Lampiran 5 Uji Out Sample

```
import matplotlib.pyplot as plt\

# Membagi dataset

data_1_50 = perbandingan_full_df[perbandingan_full_df['Minggu'] <= 50]
data_51_65 = perbandingan_full_df[perbandingan_full_df['Minggu'] >= 51]


plt.figure(figsize=(15, 7))


# 1. Plot Minggu 1-50 (Hanya Aktual)

plt.plot(data_1_50['Minggu'], data_1_50['Data Aktual (Y)'], label='Aktual (Minggu 1-50)',
color='blue', alpha=0.5)


# 2. Plot Minggu 51-65 (Aktual vs Prediksi)

plt.plot(data_51_65['Minggu'], data_51_65['Data Aktual (Y)'], label='Aktual (Minggu 51-65)',
marker='o', color='blue', linewidth=2)

plt.plot(data_51_65['Minggu'], data_51_65['Prediksi Model (Y_hat)'], label='Prediksi
ARIMA(1,1,0)', linestyle='--', marker='s', color='red', linewidth=2)


# 3. Highlight Titik Minggu 51

val_51 = data_51_65[data_51_65['Minggu'] == 51]['Prediksi Model (Y_hat)'].values[0]

plt.scatter(51, val_51, color='green', s=150, zorder=5, label='Prediksi Minggu 51')


plt.title('Tren Penjualan: Data Aktual (1-50) & Hasil Prediksi (51-65)')

plt.xlabel('Minggu Ke-')

plt.ylabel('Jumlah Penjualan')

plt.axvline(x=50.5, color='gray', linestyle=':', label='Batas Mulai Prediksi')

plt.legend()

plt.grid(True, alpha=0.3)
```

```
plt.show()
```

```
print(f"Detail Prediksi Minggu 51: {val_51:.2f}")
```

Lampiran 6 Uji Akurasi Model

```
import numpy as np

from sklearn.metrics import mean_absolute_error, mean_squared_error

# Mengambil data aktual dan prediksi untuk periode minggu 51-65
y_true = data_51_65['Data Aktual (Y)']
y_pred = data_51_65['Prediksi Model (Y_hat)']

# Perhitungan Metrik

mae = mean_absolute_error(y_true, y_pred)

mse = mean_squared_error(y_true, y_pred)

rmse = np.sqrt(mse)

mape = np.mean(np.abs((y_true - y_pred) / y_true)) * 100

# Menampilkan hasil

metrics_df = pd.DataFrame({
    'Metrik': ['MAE', 'MSE', 'RMSE', 'MAPE (%)'],
    'Nilai': [mae, mse, rmse, mape]
})

print("Hasil Evaluasi Model ARIMA(1,1,0) untuk Minggu 51 - 65:")

display(metrics_df)
```