

ANALISIS SENTIMEN BERITA SAHAM BERBAHASA INDONESIA MENGUNAKAN HYBRID LDA-INDOBERT BERBASIS FEATURE FUSION



NUR MADIA
H011221036



PROGRAM STUDI MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026

**ANALISIS SENTIMEN BERITA SAHAM BERBAHASA INDONESIA
MENGUNAKAN HYBRID LDA-INDOBERT BERBASIS FEATURE
FUSION**

**NUR MADIA
H011221036**



**PROGRAM STUDI MATEMATIKA DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**ANALISIS SENTIMEN BERITA SAHAM BERBAHASA INDONESIA
MENGUNAKAN HYBRID LDA-INDOBERT BERBASIS FEATURE
FUSION**

NUR MADIA
H011221036

Skripsi

Diajukan sebagai salah satu syarat memperoleh gelar Sarjana Matematika

Program Studi Matematika

pada

**PROGRAM STUDI MATEMATIKA DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

SKRIPSI
ANALISIS SENTIMEN BERITA SAHAM BERBAHASA INDONESIA
MENGGUNAKAN HYBRID LDA-INDOBERT BERBASIS FEATURE
FUSION

yang disusun dan diajukan oleh

NUR MADIA
H011221036

Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana Matematika pada tanggal 10
Agustus 2026 dan dinyatakan telah memenuhi syarat kelulusan

pada


Program Studi Matematika
Departemen Matematika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

PENGESAHAN

Mengesahkan:
Pembimbing Tugas Akhir,


Dr. Khaeruddin, M.Sc.
NIP. 19650914 199103 1 003

Mengetahui:
Ketua Program Studi,


Dr. Firman, S.Si., M.Si.
NIP. 19680429 200212 1 001



PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "Analisis Sentimen Berita Saham Berbahasa Indonesia Menggunakan Hybrid LDA-IndoBERT Berbasis Feature Fusion" adalah benar karya saya dengan arahan dari pembimbing Dr. Khaeruddin, M.Sc. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 10 Agustus 2026



Nur Madia
H011221036

UCAPAN TERIMA KASIH

Alhamdulillahirabbil'alamin. Segala puji syukur penulis panjatkan kehadirat Allah Subhanahu wa Ta'ala, atas nikmat, berkat dan rahmat-Nya sehingga penulis mampu menyelesaikan skripsi "Analisis Sentimen Berita Saham Berbahasa Indonesia Menggunakan Hybrid LDA-IndoBERT Berbasis Feature Fusion" dalam rangka memenuhi salah satu syarat untuk memperoleh gelar Sarjana Matematika. Penulis menyadari bahwa penyusunan skripsi ini tidak terlepas dari dukungan, bantuan, dan bimbingan berbagai pihak, sejak awal perkuliahan selesainya penyusunan skripsi. Oleh karena itu, pada kesempatan ini dengan segala kerendahan hati penulis mengucapkan terima kasih dan penghargaan setinggi-tingginya kepada:

1. Prof. Dr. Ir. Jamaluddin Jompa, M.Sc., selaku Rektor Universitas Hasanuddin dan Dr. Sci. Muhammad Zakir, M.Si., selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam beserta seluruh jajarannya.
2. Dr. Firman, S.Si, M.Si., selaku Ketua Departemen Matematika serta seluruh dosen pengajar Departemen Matematika atas ilmu, bimbingan, dan pengalaman berharga yang telah diberikan kepada penulis selama masa perkuliahan, serta seluruh staf Departemen matematika atas bantuan administrasi dan pelayanan yang diberikan.
3. Dr. Khaeruddin, M.Sc., selaku Dosen Pembimbing Utama atas kesediaan meluangkan waktu, kesabaran dalam membimbing, memberikan arahan, masukan, serta dukungan penuh kepada penulis selama proses penyusunan skripsi ini.
4. Prof. Dr. Budi Nurwahyu, MS., selaku Dosen Penguji, serta Dra. Nur Erawaty, M.Si., selaku Dosen Penguji sekaligus Penasehat Akademik, atas kesediaan, arahan, dan masukan yang sangat berarti demi penyempurnaan skripsi ini.
5. KIP-Kuliah yang telah memberikan dukungan berupa beasiswa pendidikan, serta menyediakan wadah pengembangan diri bagi penulis melalui organisasi IKAB-KIP Universitas Hasanuddin.
6. Kedua orang tua penulis, Bapak Madan Tumba dan Ibu Nuraini yang telah mengupayakan segala hal agar penulis dapat menempuh pendidikan tinggi dengan layak tanpa pernah merasakan kekurangan apapun. Terima kasih tak terhingga atas segala bentuk dukungan yang diberikan serta doa-doa tulus yang senantiasa dipanjatkan, sehingga penulis dapat bertahan sampai akhir perkuliahan dan menyelesaikan skripsi ini. Terima kasih pula untuk adik kandung penulis yaitu Muh. Ma'ruf dan Nurmaida yang telah menjadi motivasi bagi penulis untuk terus menjadi pribadi yang berilmu dan menjadi orang sukses kelak.
7. Keluarga besar penulis yang senantiasa memberikan dukungan moral dan doa-doa tulus demi kelancaran perkuliahan dan penyusunan skripsi ini.
8. Teman-teman seperantauan yang tidak sengaja dipersatukan dalam *group chat Bulu's Family*, Tantri, Zaza, Utti, Nini, Dora, Evan, June, Jheksen, dan Akhsan atas kebersamaanya sehingga penulis tidak pernah merasa sendiri selama

- menempuh perkuliahan, juga atas segala bantuan dan kesediaannya untuk selalu mendengarkan keluh kesah penulis sejak awal hingga akhir perkuliahan.
9. Teman-teman SUHU, Maya, Army, Irma, Dian, Warda, Rio, Fikry, Cheza, Wahyu, Rey, dan Jenas yang tanpa sengaja terbentuk melalui kebersamaan di sekret ANTARA.
 10. Teman-teman yang senantiasa menjadi tempat berbagi cerita dan keluh kesah mengenai proses penyusunan skripsi, Utti, Rio, Army, Belo, dan Nini. Terima kasih telah mendengarkan, memberi semangat, mendoakan, bahkan membantu memeriksa dan menyimpan berkas-berkas penting skripsi penulis.
 11. Teman-teman seperjuangan Matematika 2022 yang telah kebersamai dan memberikan kesan serta pengalaman berharga kepada penulis selama berkuliah di Program Studi Matematika Unhas.

Akhir kata, penulis berharap segala kebaikan dari seluruh pihak yang telah terlibat dicatat sebagai amal ibadah dan mendapatkan balasan terbaik dari Tuhan Yang Maha Esa. Penulis juga berharap skripsi ini dapat memberikan kontribusi dan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang matematika terapan.

Makassar, 10 Agustus 2026

Nur Madia

ABSTRAK

NUR MADIA. Analisis Sentimen Berita Saham Berbahasa Indonesia Menggunakan Hybrid LDA-IndoBERT Berbasis Feature Fusion (dibimbing oleh Dr. Khaeruddin, M.Sc.)

Peningkatan jumlah investor ritel di pasar modal Indonesia, dari sekitar 3,88 juta pada tahun 2020 menjadi 12,17 juta pada akhir tahun 2023 menurut data KSEI, mendorong pentingnya informasi publik seperti berita keuangan dalam pengambilan keputusan investasi. Namun, pendekatan analisis sentimen yang umum digunakan masih bersifat dokumen tunggal, padahal satu artikel berita sering memuat lebih dari satu topik dengan kecenderungan sentimen yang berbeda. Penelitian ini mengusulkan pendekatan analisis sentimen berbasis topik pada berita saham berbahasa Indonesia menggunakan model Hybrid LDA-IndoBERT dengan skema feature-level fusion, yaitu penggabungan distribusi topik hasil Latent Dirichlet Allocation (LDA) dengan representasi kontekstual token [CLS] dari IndoBERT. Data yang digunakan berupa 9.747 judul berita saham dari portal keuangan pada rentang Januari 2024 hingga Maret 2025 dengan tiga kelas sentimen, yaitu positif, negatif, dan netral. Hasil pemodelan topik menunjukkan jumlah topik optimal sebanyak empat topik ($K = 4$) dengan nilai topic coherence sebesar 0,5121, yang diinterpretasikan sebagai aspek Aktivitas Perusahaan dan Tokoh Bisnis, Sektor Perbankan dan BUMN, Pergerakan Pasar Saham dan Nilai Tukar, serta Regulasi dan Pengawasan Sektor Keuangan. Model Fine-tuned IndoBERT memperoleh akurasi 0,9046 dan F1-macro 0,9049, sedangkan model Hybrid LDA-IndoBERT memperoleh F1-macro 0,8989. Hasil studi ablasi menunjukkan bahwa penambahan fitur distribusi topik belum mampu meningkatkan kinerja klasifikasi dibandingkan model baseline, dengan selisih F1-macro sebesar 0,0060. Analisis sentimen berbasis aspek menunjukkan bahwa aspek Pergerakan Pasar Saham dan Nilai Tukar menjadi satu-satunya aspek yang didominasi sentimen negatif, dengan proporsi 47,84 persen, sedangkan aspek lain didominasi sentimen netral. Temuan ini menegaskan bahwa meskipun integrasi fitur topik belum meningkatkan akurasi klasifikasi, pemodelan topik tetap memberikan kontribusi penting sebagai dasar interpretasi aspek tematik dalam analisis sentimen berita saham berbahasa Indonesia.

Kata Kunci: *Analisis Sentimen, LDA, IndoBERT, Feature Fusion, Berita Saham, Bahasa Indonesia.*

ABSTRACT

NUR MADIA. **Sentiment Analysis of Indonesian Stock News Using Feature Fusion-Based Hybrid LDA-IndoBERT** (supervised by Dr. Khaeruddin, M.Sc.)

The rapid growth of retail investors in the Indonesian capital market, rising from approximately 3.88 million in 2020 to 12.17 million by the end of 2023 based on KSEI data, highlights the growing importance of public information such as financial news in investment decision making. However, commonly used sentiment analysis approaches remain limited to the document level, even though a single news article often covers more than one topic with differing sentiment tendencies. This study proposes a topic guided sentiment analysis approach for Indonesian language stock news using a Hybrid LDA-IndoBERT model with a feature level fusion scheme, combining the topic distribution generated by Latent Dirichlet Allocation (LDA) with the contextual [CLS] token representation from IndoBERT. The dataset consists of 9,747 stock news headlines collected from a financial portal between January 2024 and March 2025, labeled into three sentiment classes: positive, negative, and neutral. The topic modeling results identified four optimal topics ($K = 4$) with a topic coherence value of 0.5121, interpreted as Company Activity and Business Figures, Banking and State Owned Enterprises Sector, Stock Market and Exchange Rate Movement, and Financial Sector Regulation and Supervision. The Fine-tuned IndoBERT model achieved an accuracy of 0.9046 and an F1-macro of 0.9049, while the Hybrid LDA-IndoBERT model achieved an F1-macro of 0.8989. The ablation study showed that adding topic distribution features did not improve classification performance compared to the baseline model, with an F1-macro gap of 0.0060. The aspect based sentiment analysis revealed that the Stock Market and Exchange Rate Movement aspect was the only one dominated by negative sentiment, at a proportion of 47.84 percent, while the remaining aspects were dominated by neutral sentiment. These findings suggest that although the topic feature fusion did not improve classification accuracy, topic modeling still plays an important role as a foundation for thematic aspect interpretation in sentiment analysis of Indonesian stock news.

Keywords: Sentiment Analysis, LDA, IndoBERT, Feature Fusion, Stock News, Indonesian Language.

DAFTAR ISI

HALAMAN JUDUL	i
PERNYATAAN PENGAJUAN.....	ii
HALAMAN PENGAJUAN	ii
HALAMAN PENGESAHAN.....	iii
PERNYATAAN KEASLIAN SKRIPSI	iv
DAN PELIMPAHAN HAK CIPTA	iv
PERNYATAAN KEASLIAN.....	iv
UCAPAN TERIMA KASIH	v
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR TABEL.....	xii
DAFTAR GAMBAR	xiii
DAFTAR LAMPIRAN.....	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah.....	3
1.3 Batasan Penelitian.....	4
1.4 Tujuan Penelitian.....	4
1.5 Manfaat Penelitian.....	5
1.6 Landasan Teori.....	5
1.6.1 Pasar modal dan Saham.....	5
1.6.2 Efficient Market Hypothesis (Hipotesis Pasar efisien)	6
1.6.3 Analisis Sentimen	6
1.6.4 Analisis Sentimen Berbasis Aspek (ABSA).....	7
1.6.5 Bag of Words (BoW).....	8
1.6.6 Latent Dirichlet Allocation (LDA).....	8
1.6.7 Bidirectional Encoder Representations from Transformers (BERT)	12
1.6.8 IndoBERT	14
1.6.9 Feature Fusion.....	15
1.6.10Integrasi LDA dan IndoBERT sebagai Model Hybrid.....	15

1.6.11	Metrik Evaluasi	17
BAB II METODOLOGI PENELITIAN.....		21
2.1	Jenis dan Sumber Data	21
2.2	Variabel Penelitian.....	21
2.2.1	Variabel Masukan (Input)	21
2.2.2	Variabel Keluaran (Output).....	21
2.2.3	Skema Data Masukan dan Keluaran.....	22
2.3	Tahapan Penelitian.....	22
2.3.1	Identifikasi Masalah.....	22
2.3.2	Studi Literatur	22
2.3.3	Pengumpulan Data	22
2.3.4	Pengolahan Data Awal (Pre-processing Data).....	23
2.3.5	Implementasi Model.....	23
2.3.6	Pengujian dan Evaluasi	25
2.4	Diagram Alir.....	26
2.4.1	Diagram Alir Penelitian	26
2.4.2	Diagram Alir Pemodelan Hybrid LDA–IndoBERT	26
BAB III HASIL DAN PEMBAHASAN		28
3.1	Verifikasi dan Pembersihan Data	28
3.2	<i>Pre-Processing Data</i>	30
3.2.1	Pre-processing untuk Jalur LDA.....	30
3.2.2	Pre-processing untuk Jalur IndoBERT.....	32
3.3	Pemodelan Topik dengan <i>Latent Dirichlet Allocation</i> (LDA)	33
3.3.1	Penentuan Jumlah Topik Optimal (K)	33
3.3.2	Pembentukan Model LDA	35
3.3.3	Distribusi Probabilitas Kata per Topik.....	36
3.3.4	Validasi Koherensi Topik.....	37
3.3.5	Interpretasi Topik dan Pelabelan Aspek	42
3.3.6	Distribusi Aspek dan Penerapan Ambang Batas Probabilitas	44
3.4	Klasifikasi Sentimen dengan Model <i>Hybrid</i> LDA-IndoBERT	46
3.4.1	Konfigurasi Model dan Parameter Pelatihan.....	47
3.4.2	Mekanisme Eksekusi Model.....	49
3.4.3	Proses Pelatihan dan Kurva Training	54

3.4.4 Evaluasi Kinerja Model dan Analisis Confusion Matrix	56
3.5 Analisis Sentimen Berbasis Topik (<i>Topic-Guided ABSA</i>)	59
3.6 <i>Ablation Study</i> : Kontribusi Fitur Topik LDA terhadap Kinerja Klasifikasi	
62	
3.6.1 Pelatihan Model Baseline (Fine-tuned IndoBERT Tanpa Topik)	
.....	62
3.6.2 Pelatihan perbandingan Model Baseline dan Model Hybrid	64
3.7 Pembahasan	65
BAB IV KESIMPULAN DAN SARAN.....	69
4.1 Kesimpulan.....	69
4.2 Saran	70
DAFTAR PUSTAKA	71
LAMPIRAN.....	73

DAFTAR TABEL

Tabel 1. Verifikasi dan Pembersihan Data.....	28
Tabel 2. Distribusi Label Sentimen pada Dataset.....	28
Tabel 3. Perhitungan Class Weight	29
Tabel 4. Sampel Data Tahapan Pre-processing untuk LDA	30
Tabel 5. Sampel Data Tahapan Pre-processing untuk IndoBERT	32
Tabel 6. Nilai Coherence Untuk K=2 hingga K=15.....	34
Tabel 7. Distribusi Probabilitas Kata Pada Salah Satu Topik Hasil Pemodelan LDA.....	36
Tabel 8. Probabilitas Individual dan Probabilitas Bersama Antar Kata.....	38
Tabel 9. Nilai NPMI Antar Pasangan Kata Salah Satu Topik.....	40
Tabel 10. Nilai Coherence pada Setiap Topik.....	41
Tabel 11. Interpretasi Topik dan Pelabelan Aspek	42
Tabel 12. Distribusi Frekuensi Aspek Setelah Penentuan Topik Dominan.....	45
Tabel 13. Perbandingan Skema Pembagian Data Uji	46
Tabel 14. Konfigurasi Parameter Model LDA-IndoBERT.....	47
Tabel 15. Contoh Distribusi Probabilitas Topik pada Dokumen	51
Tabel 16. Perkembangan Training Loss, Validation Loss, Train F1, dan Val F1.....	55
Tabel 17. Hasil Evaluasi Klasifikasi Model Hybrid LDA-IndoBERT Error! Bookmark not defined.	
Tabel 18. Matriks Distribusi Sentimen per Aspek	60
Tabel 19. Perkembangan Pelatihan Model Baseline (Fine-tuned IndoBERT)	63
Tabel 20. Hasil Evaluasi Klasifikasi Model Baseline Fine-Tuned IndoBERT	63
Tabel 21. Perbandingan Kinerja Model Baseline dan Model Hybrid	64

DAFTAR GAMBAR

Gambar 1. Skema data masukan dan keluaran.....	22
Gambar 2. Diagram alir penelitian.....	26
Gambar 3. Diagram Alir Pemodelan Hybrid LDA-IndoBERT	27
Gambar 4. Grafik Jumlah Topik LDA Berdasarkan Nilai Coherence.....	34
Gambar 5. Distribusi Aspek (kiri) dan Distribusi Probabilistik Topik Dominan dengan Ambang Batas (kanan)	44
Gambar 6. Kurva Pembelajaran Model Hybrid LDA-IndoBERT.....	55
Gambar 7. Confusion Matrix Model Hybrid LDA-IndoBERT	57
Gambar 8. Distribusi Sentimen per Aspek	61

DAFTAR LAMPIRAN

Lampiran 1. Program.....	73
Lampiran 2. Data Penelitian	96
Lampiran 3. Klasifikasi Sentimen dengan Model Hybrid LDA-IndoBERT	97

BAB I PENDAHULUAN

1.1 Latar Belakang

Pasar modal berperan sebagai mekanisme utama dalam alokasi modal dari pihak yang memiliki surplus dana kepada pihak yang membutuhkan pendanaan. Perkembangan pasar modal menunjukkan peningkatan yang signifikan dalam beberapa tahun terakhir di Indonesia. Data Kustodian Sentral Efek Indonesia (KSEI) mencatat bahwa jumlah investor pasar modal mengalami peningkatan dari sekitar 3,88 juta pada tahun 2020 menjadi 12,17 juta pada akhir tahun 2023. Selain itu, komposisi investor didominasi oleh investor ritel yang mencapai 99,66 persen dan 56,43 persen di antaranya berusia di bawah 30 tahun (Data Statistik KSEI, 2023).

Dominasi investor ritel menunjukkan meningkatnya peran informasi publik dalam proses pengambilan keputusan investasi. Berbeda dengan investor institusional yang didukung dengan laporan riset internal, investor ritel umumnya mengandalkan informasi terbuka, termasuk berita dari media keuangan. Studi oleh (Alamsyah et al., 2025) mengungkapkan adanya hubungan antara sentimen dalam berita keuangan dan pergerakan harga saham pada perusahaan di Indonesia melalui analisis berbasis kecerdasan buatan terhadap korpus berita skala besar.

Secara teoritis, hubungan antara informasi publik dan harga saham dijelaskan dalam kerangka *Efficient Market Hypothesis* (Kerangka Hipotesis Pasar Efisien, EMH) yang dikemukakan oleh (Fama, 1970). Dalam bentuk setengah kuat, hipotesis ini menyatakan bahwa harga saham mencerminkan informasi publik yang tersedia di pasar secara cepat dan akurat. Dengan demikian, informasi yang dipublikasikan melalui media memiliki potensi untuk tercermin dalam harga saham. Bukti empiris diberikan oleh (Tetlock, 2007) mengemukakan bahwa sentimen negatif dalam media keuangan memiliki hubungan dengan pergerakan *return* saham dalam jangka pendek. Temuan ini memperkuat bahwa teks berita tidak hanya bersifat informatif, tetapi juga memiliki nilai prediktif terhadap dinamika pasar.

Berdasarkan peran penting informasi tersebut, diperlukan pendekatan analitis untuk mengolah dan mengekstraksi informasi dari teks berita secara sistematis. Salah satu pendekatan yang umum digunakan adalah analisis sentimen, yang bertujuan untuk mengidentifikasi orientasi opini dalam teks. Namun, pendekatan analisis sentimen yang banyak digunakan masih pada tingkat dokumen, yaitu satu dokumen diberikan satu label sentimen. Pendekatan ini memiliki keterbatasan karena satu artikel sering kali memuat lebih dari satu entitas topik pembahasan, sehingga satu label sentimen tidak selalu merepresentasikan keseluruhan isi informasi secara memadai. Dengan demikian, dikembangkan pendekatan *Aspect-Based Sentiment Analysis* (ABSA) untuk mengatasi keterbatasan tersebut. Menurut (Liu, 2012), ABSA bertujuan untuk mengidentifikasi aspek atau entitas spesifik dalam teks serta menentukan orientasi sentimen terhadap masing-masing aspek tersebut. Pendekatan ini memungkinkan analisis yang lebih rinci karena dapat menangkap variasi sentimen dalam satu dokumen.

Meskipun demikian, penerapan ABSA masih menghadapi keterbatasan dalam

konteks bahasa Indonesia dan keuangan. Studi oleh (Hua et al., 2024) menunjukkan bahwa penelitian ABSA masih didominasi oleh konteks bahasa Inggris, sementara penelitian bahasa lain masih relatif terbatas. Dalam konteks Indonesia, beberapa penelitian telah dilakukan dengan pendekatan yang beragam. Penelitian Dhanal & Ghorpade, (2024) menunjukkan bahwa identifikasi aspek secara manual menjadi kurang efisien pada korpus berskala besar sehingga memanfaatkan LDA untuk memperoleh topik yang selanjutnya digunakan sebagai representasi aspek sebelum proses klasifikasi sentimen. Di sisi lain, penelitian oleh (Apriliani et al., 2025) menerapkan model IndoBERT untuk analisis sentimen berbasis aspek, namun masih menggunakan aspek yang telah ditentukan sebelumnya melalui proses anotasi manual sehingga belum mengintegrasikan identifikasi aspek secara otomatis. Sementara itu, (Hartanto et al., 2025) mengembangkan dataset analisis sentimen pasar saham yang berasal dari media sosial, namun memiliki karakteristik yang berbeda dibandingkan teks berita yang lebih formal dan informatif.

Kondisi ini menunjukkan adanya kesenjangan dalam pendekatan yang digunakan, yaitu belum tersedia metode yang mampu mengintegrasikan pemodelan topik dan klasifikasi sentimen berbasis konteks dalam satu kerangka analisis sentimen berbasis topik. Padahal, dalam berita saham satu artikel sering kali memuat beberapa topik dengan kecenderungan sentimen yang berbeda sehingga diperlukan representasi topik yang dapat digunakan sebagai dasar analisis sentimen.

Pemodelan topik dapat dimanfaatkan sebagai alternatif untuk mengidentifikasi struktur topik secara otomatis dari kumpulan teks berskala besar tanpa memerlukan anotasi aspek secara manual seperti pada ABSA klasik. Dalam penelitian ini, dipilih metode *Latent Dirichlet Allocation* (LDA) karena merupakan metode pemodelan topik berbasis *unsupervised* yang mampu mengidentifikasi topik laten tanpa memerlukan label aspek selama proses pembelajaran. Karakteristik tersebut sesuai dengan dataset penelitian yang hanya menyediakan label sentimen pada tingkat dokumen, sehingga representasi aspek tematik perlu diperoleh melalui pemodelan topik secara otomatis. Selain itu, LDA merupakan salah satu metode pemodelan topik yang telah banyak digunakan dan terbukti efektif dalam mengidentifikasi struktur topik pada berbagai korpus teks (Blei et al., 2003). LDA merupakan model probabilistik generatif yang memodelkan dokumen sebagai campuran beberapa topik laten, dengan setiap topik dinyatakan melalui distribusi probabilitas atas kosakata. Perlu ditekankan bahwa keluaran LDA berupa topik, bukan aspek dalam pengertian ABSA menurut (Liu, 2012). Pada penelitian ini, topik hasil LDA diinterpretasikan sebagai representasi aspek tematik yang relevan dengan konteks berita saham.

Di sisi lain, model berbasis transformer seperti *Bidirectional Encoder Representations from Transformers* (BERT) telah menunjukkan kinerja yang unggul dalam klasifikasi sentimen, sebagaimana ditunjukkan oleh (Devlin et al., 2019). BERT mampu menangkap hubungan antarkata secara dua arah, sehingga lebih efektif dalam memahami konteks kalimat dibandingkan model LDA. Selain itu, Koto et al., (2020) mengembangkan IndoBERT menggunakan korpus berbahasa Indonesia berskala besar, dan model ini menunjukkan kinerja yang kuat pada berbagai tugas pemrosesan bahasa alami berdasarkan *benchmark IndoLEM*.

Berdasarkan uraian tersebut, penelitian ini mengusulkan pendekatan analisis sentimen berbasis topik (*topic-guided sentiment analysis*) pada berita saham berbahasa Indonesia. Berbeda dengan ABSA klasik yang mengidentifikasi *aspect term* secara eksplisit pada tingkat kata, penelitian ini memanfaatkan topik laten hasil pemodelan LDA sebagai representasi aspek tematik yang selanjutnya digunakan dalam proses klasifikasi sentimen. Dalam penelitian ini, model *hybrid* LDA-IndoBERT didefinisikan sebagai model klasifikasi sentimen yang menggabungkan distribusi topik hasil LDA dengan *embedding* kontekstual IndoBERT pada tingkat fitur (*feature-level fusion*). Distribusi topik setiap dokumen (θ_d) yang dihasilkan LDA dan representasi kontekstual token [CLS] (h_{CLS}) dari IndoBERT digabungkan menggunakan operasi konkatenasi menjadi satu vektor fitur sebelum diproses oleh lapisan klasifikasi. Dengan demikian, istilah *hybrid* dalam penelitian ini tidak merujuk pada penggunaan LDA dan IndoBERT secara berurutan sebagai dua tahap pemrosesan (*pipeline*), melainkan pada penggabungan representasi fitur dari kedua model dalam satu proses klasifikasi. Distribusi topik dari LDA merepresentasikan struktur tema pada tingkat korpus, sedangkan *embedding* IndoBERT menangkap informasi semantik kontekstual pada tingkat dokumen, sehingga penggabungan keduanya diharapkan menghasilkan fitur yang lebih komprehensif untuk klasifikasi sentimen. Pendekatan ini sejalan dengan penelitian Dhanal & Ghorpade, (2024) yang menggabungkan LDA dan model berbasis BERT untuk meningkatkan kinerja analisis sentimen berbasis aspek. Berbeda dengan penelitian tersebut, penelitian ini mengintegrasikan distribusi topik hasil LDA dan *embedding* kontekstual IndoBERT pada tingkat fitur (*feature-level fusion*) sebelum proses klasifikasi sentimen.

Berdasarkan pendekatan yang diusulkan, penelitian ini diharapkan mampu menghasilkan representasi fitur yang lebih komprehensif melalui integrasi distribusi topik dan *embedding* kontekstual. Selain itu, penelitian ini diharapkan dapat memberikan alternatif pendekatan analisis sentimen berbasis topik pada berita saham berbahasa Indonesia melalui pemanfaatan topik laten sebagai representasi aspek tematik tanpa memerlukan anotasi aspek secara manual. Pendekatan tersebut juga diharapkan dapat memberikan kontribusi terhadap pengembangan metodologi analisis sentimen berbasis topik pada domain keuangan berbahasa Indonesia.

1.2 Rumusan Masalah

Berdasarkan uraian latar belakang di atas, diperoleh rumusan masalah sebagai berikut.

1. Bagaimana kinerja model LDA dalam mengidentifikasi topik laten pada korpus berita saham berbahasa Indonesia serta menentukan jumlah topik optimal berdasarkan metrik *topic coherence*?
2. Bagaimana kinerja model IndoBERT dalam mengklasifikasi sentimen pada berita saham berbahasa Indonesia?
3. Bagaimana perbandingan performa model *Fine-tuned* IndoBERT dan *Hybrid* LDA-IndoBERT dalam klasifikasi sentimen berita saham berbahasa Indonesia?
4. Bagaimana distribusi sentimen positif, negatif, dan netral pada masing-masing

topik yang diinterpretasikan sebagai aspek tematik berdasarkan hasil pemodelan LDA?

1.3 Batasan Penelitian

Adapun batasan-batasan yang ditetapkan dalam penelitian ini adalah sebagai berikut.

1. Data yang digunakan adalah data sekunder berupa judul berita dari portal keuangan dengan rentang waktu pengumpulan data Januari 2024 hingga Maret 2025.
2. Klasifikasi sentimen yang dilakukan hanya mencakup tiga kelas polaritas, yaitu positif, negatif, dan netral.
3. Model klasifikasi sentimen menggunakan model pra-latih *indobenchmark/indobert-base-p1* yang tersedia secara publik melalui *HuggingFace* dan dilakukan proses *fine-tuning* pada dataset penelitian.
4. Pemodelan topik dilakukan menggunakan algoritma LDA berbasis representasi *Bag of Words* (BoW), sedangkan distribusi topik yang dihasilkan digunakan sebagai fitur tambahan pada model *Hybrid* LDA–IndoBERT melalui pendekatan *feature-level fusion*.
5. Perangkat lunak (*software*) yang digunakan adalah *Microsoft excel* untuk pengelolaan data dasar dan *Google Colaboratory (Python)* untuk implementasi dan evaluasi model.
6. Penelitian tidak bertujuan memprediksi pergerakan harga saham secara langsung.
7. Penelitian ini menggunakan hasil pemodelan topik LDA sebagai representasi aspek tematik (*topic-guided aspects*) dan tidak melakukan proses *aspect term extraction* secara eksplisit sebagaimana pada pendekatan *Aspect-Based Sentiment Analysis* (ABSA) klasik.
8. Metrik evaluasi dibatasi pada C_v , *topic coherence*, *weighted F1-score*, *macro F1-score*, *precision*, *recall*, *confusion matrix* serta *accuracy*.

1.4 Tujuan Penelitian

Dari permasalahan yang telah dirumuskan sebelumnya, maka tujuan dari penelitian ini adalah sebagai berikut.

1. Mengembangkan dan mengevaluasi model LDA untuk mengidentifikasi topik laten pada korpus berita saham Indonesia menggunakan metrik C_v *topic coherence*.
2. Menentukan jumlah topik K optimal pada model LDA.
3. Mengidentifikasi dan menginterpretasikan topik hasil pemodelan LDA sebagai representasi aspek tematik pada korpus berita saham Indonesia.
4. Mengevaluasi dan membandingkan kinerja model IndoBERT dan model *hybrid* LDA–IndoBERT menggunakan metrik *precision*, *recall*, *macro F1-score*, *weighted F1-score*, *accuracy*, dan *confusion matrix*.
5. Menganalisis distribusi sentimen positif, negatif, dan netral pada setiap topik yang

diinterpretasikan sebagai aspek tematik dalam berita saham berbahasa Indonesia.

1.5 Manfaat Penelitian

Beberapa manfaat yang diharapkan dari penelitian tugas akhir ini meliputi:

1. Menyediakan pendekatan analisis sentimen berbasis topik yang mampu memberikan informasi mengenai kecenderungan sentimen pada setiap topik dalam berita saham, sehingga dapat menjadi sumber informasi pendukung bagi investor ritel dalam memahami isu-isu yang berkembang di pasar modal serta menjadi fitur alternatif bagi pengembangan sistem pendukung keputusan atau sistem rekomendasi investasi.
2. Memberikan kontribusi terhadap pengembangan metodologi analisis sentimen berbasis topik pada domain keuangan berbahasa Indonesia melalui integrasi pemodelan topik LDA dan representasi kontekstual IndoBERT pada tingkat fitur (*feature-level fusion*).
3. Menjadi referensi bagi penelitian selanjutnya yang membahas integrasi pemodelan topik dan model bahasa pra-latih (*pre-trained language models*) untuk analisis teks keuangan berbahasa Indonesia maupun pengembangan metode analisis sentimen berbasis topik pada domain lainnya.

1.6 Landasan Teori

1.6.1 Pasar modal dan Saham

Pasar modal merupakan bagian dari sistem keuangan yang berperan dalam menyalurkan dana dari pihak yang memiliki kelebihan dana kepada pihak yang membutuhkan pembiayaan jangka panjang. (Keuangan, 2024) mendefinisikan pasar modal sebagai seluruh aktivitas yang berkaitan dengan penawaran umum, perdagangan efek, serta lembaga dan profesi yang terlibat di dalamnya. Pasar modal berfungsi sebagai wahana mobilisasi dana jangka panjang dari pihak yang memiliki surplus dana (investor) kepada pihak yang membutuhkan dana (emiten), sekaligus menjadi mekanisme pembentukan harga aset berbasis informasi (Fama, 1970).

Salah satu instrumen utama dalam pasar modal adalah saham, yang menunjukkan kepemilikan atas suatu perusahaan. Harga saham di pasar sekunder terbentuk melalui mekanisme penawaran dan permintaan yang dipengaruhi oleh berbagai faktor, antara lain kinerja keuangan perusahaan, kondisi makroekonomi, kebijakan pemerintah, dan sentimen pasar (Keuangan, 2024). Secara agregat, pergerakan harga saham di Indonesia tercermin dalam Indeks Harga Saham Gabungan (IHSG) yang dihitung berdasarkan kapitalisasi pasar seluruh saham yang tercatat di Bursa Efek Indonesia.

Dalam analisis keuangan, perubahan harga saham tidak hanya dilihat dalam bentuk nilai absolut, tetapi juga dinyatakan sebagai imbal hasil (*return*). *Return* memberikan ukuran yang lebih representatif terhadap keuntungan yang diperoleh investor dalam suatu periode (Fama, 1970). Return terdiri dari perubahan harga saham dan dividen yang diterima. Konsep ini menjadi dasar dalam berbagai model

keuangan karena mampu menggambarkan kinerja investasi secara lebih komprehensif dibandingkan dengan harga saham saja.

1.6.2 Efficient Market Hypothesis (Hipotesis Pasar efisien)

Hipotesis Pasar Efisien (*Efficient Market Hypothesis*, EMH) yang dirumuskan oleh Fama (1970) menyatakan bahwa harga aset pada pasar yang efisien mencerminkan seluruh informasi yang tersedia secara penuh dan instan. Fama (1970) membagi EMH ke dalam tiga bentuk berdasarkan jenis informasi yang tercermin dalam harga:

1. Bentuk lemah: harga saham mencerminkan seluruh informasi harga historis.
2. Bentuk setengah kuat: harga saham mencerminkan seluruh informasi publik yang tersedia, termasuk harga historis, laporan keuangan, dan berita media.
3. Bentuk kuat: harga saham mencerminkan seluruh informasi, termasuk informasi privat.

Apabila berita media yang merupakan bagian dari informasi publik, maka sentimen yang terkandung dalam berita seharusnya terserap ke dalam harga saham secara cepat. Namun, studi empiris menunjukkan adanya deviasi dari asumsi efisiensi sempurna. Studi oleh Tetlock (2007) menemukan bahwa sentimen negatif dalam berita keuangan berkorelasi dengan penurunan harga saham pada periode berikutnya. Hasil ini mengindikasikan bahwa proses penyerapan informasi tidak selalu instan. Temuan tersebut membuka ruang bagi analisis sentimen sebagai pendekatan kuantitatif untuk menangkap informasi yang terkandung dalam teks berita.

1.6.3 Analisis Sentimen

Analisis sentimen, atau yang juga dikenal sebagai *opinion mining*, merupakan bidang dalam Pemrosesan Bahasa Alami (*Natural Language Processing*, NLP) yang bertujuan untuk mengidentifikasi, mengekstraksi, dan mengkuantifikasi opini, sikap, emosi, dan evaluasi yang tersurat maupun tersirat dalam teks yang ditulis oleh manusia (Liu, 2012). Secara formal, Liu (2012) mendefinisikan sebuah opini sebagai tuple (e, a, s, h, t) di mana:

1. e adalah entitas target yang menjadi objek opini.
2. a adalah aspek dari entitas yang diopiniikan.
3. s adalah sentimen (polaritas) terhadap aspek a dari entitas e, biasanya dikategorikan sebagai positif, negatif, atau netral.
4. h adalah pemegang opini.
5. t adalah waktu ketika opini diekspresikan.

Model ini mendefinisikan opini sebagai kombinasi entitas, aspek, sentimen, sumber, dan waktu, sehingga memungkinkan analisis yang lebih sistematis terhadap teks. Analisis sentimen memiliki tiga tingkat granularitas, yaitu dokumen, kalimat, dan aspek (Liu, 2012) di mana:

1. Tingkat dokumen: mengklasifikasikan keseluruhan dokumen ke dalam satu kelas polaritas (positif, negatif, atau netral). Pendekatan ini mengasumsikan bahwa satu dokumen hanya mengekspresikan opini terhadap satu entitas tunggal.

2. Tingkat kalimat: mengklasifikasikan sentimen setiap kalimat secara terpisah. Tingkat ini lebih detail dari tingkat dokumen, namun masih tidak dapat menangkap multidimensi sentimen dalam satu kalimat yang membahas lebih dari satu aspek.
3. Tingkat aspek: mengidentifikasi aspek-aspek spesifik yang dibahas dalam teks dan mengklasifikasikan polaritas sentimen untuk masing-masing aspek. Tingkat aspek dianggap paling informatif karena mampu menangkap variasi sentimen dalam satu dokumen yang sama.

1.6.4 Analisis Sentimen Berbasis Aspek (ABSA)

Analisis Sentimen Berbasis Aspek (Aspect-Based Sentiment Analysis, ABSA) merupakan pengembangan analisis sentimen pada tingkat aspek (*aspect level sentiment analysis*) yang bertujuan mengidentifikasi aspek atau atribut yang dibahas dalam suatu teks serta menentukan polaritas sentimen terhadap masing-masing aspek tersebut. Berbeda dengan analisis sentimen pada tingkat dokumen yang hanya menghasilkan satu label sentimen untuk keseluruhan dokumen, ABSA mampu mengidentifikasi bahwa satu dokumen dapat memuat beberapa aspek dengan kecenderungan sentimen yang berbeda sehingga menghasilkan informasi yang lebih rinci mengenai opini yang terkandung dalam teks (Liu, 2012).

Menurut Pontiki et al., (2015), ABSA terdiri atas dua subtugas utama, yaitu *Aspect Term Extraction (ATE)* dan *Aspect Sentiment Classification (ASC)*. *Aspect Term Extraction* bertujuan mengidentifikasi kata atau frasa dalam teks yang merepresentasikan aspek atau target opini, sedangkan *Aspect Sentiment Classification* bertujuan menentukan polaritas sentimen, seperti positif, negatif, atau netral, terhadap setiap aspek yang telah diidentifikasi. Kedua subtugas tersebut saling berkaitan karena hasil identifikasi aspek menjadi masukan bagi proses klasifikasi sentimen.

Meskipun telah berkembang pesat, penerapan ABSA masih menghadapi beberapa tantangan. Salah satu tantangan utama adalah proses *Aspect Term Extraction* yang umumnya memerlukan anotasi aspek secara manual pada tingkat kata atau frasa. Proses anotasi tersebut membutuhkan waktu, biaya, dan sumber daya yang besar, terutama ketika diterapkan pada korpus berskala besar. Selain itu, penelitian ABSA masih didominasi oleh data berbahasa Inggris, sedangkan penelitian pada bahasa lain, termasuk bahasa Indonesia, masih relatif terbatas (Hua et al., 2024).

Untuk mengatasi keterbatasan tersebut, beberapa penelitian memanfaatkan *topic modelling* sebagai alternatif untuk memperoleh *representasi aspek secara otomatis*. Salah satu metode yang banyak digunakan adalah *Latent Dirichlet Allocation (LDA)*, yang mampu mengidentifikasi topik laten berdasarkan pola kemunculan kata dalam kumpulan dokumen tanpa memerlukan anotasi aspek selama proses pembelajaran. Dhanal & Ghorpade, (2024) menerapkan pendekatan berbasis *topic modelling* menggunakan LDA untuk memperoleh representasi topik yang selanjutnya dimanfaatkan dalam proses analisis sentimen. Hasil penelitian tersebut menunjukkan bahwa pemodelan topik dapat menjadi alternatif yang efektif untuk mendukung analisis sentimen tanpa bergantung pada proses anotasi aspek

secara manual. Topik yang dihasilkan oleh LDA tidak identik dengan *aspect term* sebagaimana pada ABSA klasik. LDA menghasilkan topik laten yang direpresentasikan melalui distribusi probabilitas kata, sedangkan *aspect term* merupakan kata atau frasa spesifik yang secara eksplisit muncul dalam teks (Liu, 2012). Oleh karena itu, topik hasil LDA tidak dipandang sebagai aspek dalam pengertian linguistik, melainkan sebagai representasi aspek tematik yang menggambarkan tema utama suatu dokumen.

1.6.5 Bag of Words (BoW)

Sebelum diproses oleh model komputasional, teks perlu dikonversi ke dalam bentuk numerik. Salah satu pendekatan yang paling umum digunakan adalah Bag of Words (BoW), yang juga menjadi masukan utama dalam model LDA (Blei et al., 2003). Model BoW merepresentasikan dokumen sebagai vektor yang mencatat frekuensi kemunculan setiap kata dalam kosakata tanpa mempertimbangkan urutan kata dalam kalimat (Daniel & Martin, 2026). Dalam pendekatan ini, dokumen diperlakukan sebagai kumpulan kata tanpa struktur sekuensial. Secara formal, misalkan $V = \{w_1, w_2, \dots, w_{|V|}\}$ adalah kosakata yang terdiri dari $|V|$ kata unik yang dibangun dari seluruh korpus. Setiap dokumen d direpresentasikan sebagai vektor frekuensi:

$$v(d) = [c(w_1, d), \dots, c(w_{|V|}, d)] \quad (1)$$

Di mana $c(w_i, d)$ menyatakan jumlah kemunculan kata w_i dalam dokumen d . Representasi Bag of Words menghasilkan vektor berdimensi tinggi karena setiap kata unik dalam kosakata direpresentasikan sebagai satu dimensi. Vektor tersebut juga bersifat jarang (*sparse*), karena dalam satu dokumen hanya sebagian kecil kata dalam kosakata yang muncul sehingga sebagian besar elemen vektor bernilai nol (Manning et al., 2008).

1.6.6 Latent Dirichlet Allocation (LDA)

Latent Dirichlet Allocation (LDA) merupakan model probabilistik generatif berbasis Bayesian. Model ini digunakan untuk mengidentifikasi struktur topik laten dalam kumpulan dokumen. LDA mengasumsikan bahwa setiap dokumen terbentuk dari kombinasi beberapa topik, sementara setiap topik direpresentasikan sebagai distribusi probabilitas atas kata-kata dalam kosakata (Blei et al., 2003).

LDA memanfaatkan distribusi Dirichlet sebagai prior atas distribusi multinomial. Distribusi Dirichlet berfungsi untuk mengontrol bagaimana proporsi topik dalam dokumen dan distribusi kata dalam topik terbentuk. LDA memodelkan proses pembentukan dokumen sebagai proses generatif acak. Misalkan terdapat D dokumen, K topik, dan kosakata berukuran V . Proses generatifnya dijelaskan sebagai berikut (Blei et al. 2003):

1. Untuk setiap topik k , dihasilkan distribusi kata $\phi_k \sim \text{Dir}(\beta)$. Vektor $\phi_k \in \mathbb{R}^V$ merepresentasikan probabilitas setiap kata muncul dalam topik tersebut.

2. Untuk setiap dokumen d , dihasilkan distribusi topik $\theta_d \sim \text{Dir}(\alpha)$.
3. Untuk setiap posisi kata ke- n pada dokumen d :
 - Diambil topik laten $z_{d,n} \sim \text{Multinomial}(\theta_d)$.
 - Diambil kata $w_{d,n} \sim \text{Multinomial}(\phi_{z_{d,n}})$.

Proses ini menghasilkan distribusi probabilitas bersama:

$$p(W, Z, \theta, \Phi | \alpha, \beta) = \prod_k p(\phi_k | \beta) \prod_d p(\theta_d | \alpha) \prod_n p(z_{d,n} | \theta_d) p(w_{d,n} | \phi_{z_{d,n}}) \quad (2)$$

Di mana $W = w_{d,n}$ adalah seluruh kata terobservasi, $Z = z_{d,n}$ adalah seluruh penugasan topik laten, $\theta = \theta_d$ Adalah distribusi topik per dokumen, $\Phi = \phi_k$ adalah distribusi kata per topik, α adalah hiperparameter prior Dirichlet untuk distribusi topik, dan β adalah hiperparameter prior Dirichlet untuk distribusi kata.

Untuk dapat memanfaatkan LDA dalam analisis teks, model perlu diestimasi berdasarkan data, yaitu dengan menghitung distribusi posterior atas variabel laten $p(Z, \theta, \Phi | W, \alpha, \beta)$. Distribusi posterior ini tidak dapat dihitung secara eksak (*closed form*) karena suku penyebutnya melibatkan penjumlahan atas seluruh kemungkinan konfigurasi penugasan topik Z , yang jumlahnya bertambah secara eksponensial terhadap ukuran korpus (Blei et al., 2003). Oleh karena itu, diperlukan metode inferensi untuk memperoleh pendekatan terhadap distribusi posterior tersebut.

Terdapat dua pendekatan aproksimasi yang umum digunakan dalam pemodelan topik, yaitu *Variational Bayes* (VB) dan metode berbasis *Markov Chain Monte Carlo* (MCMC), yang salah satunya melalui skema *Collapsed Gibbs Sampling* (Blei et al., 2003). Kedua pendekatan tersebut memiliki tujuan yang sama, yaitu memperoleh pendekatan terhadap distribusi posterior model LDA, tetapi menggunakan strategi komputasi yang berbeda. *Variational Bayes* melakukan inferensi melalui proses optimasi, sedangkan *Collapsed Gibbs Sampling* melakukan inferensi melalui proses pengambilan sampel (sampling) secara berulang hingga diperoleh estimasi distribusi posterior yang stabil.

Variational Bayes merupakan metode inferensi yang digunakan dalam model LDA yang diperkenalkan oleh Blei et al. (2003). Metode ini mengubah permasalahan inferensi Bayesian menjadi permasalahan optimasi dengan membangun suatu distribusi pendekatan terhadap distribusi posterior, kemudian mengoptimalkan distribusi tersebut agar mendekati distribusi posterior sebenarnya (Jordan et al., 1999). Dibandingkan dengan metode berbasis sampling, *Variational Bayes* memiliki keunggulan dalam efisiensi komputasi karena proses estimasi dilakukan melalui optimasi numerik, sehingga lebih sesuai untuk pemodelan topik pada korpus berukuran besar (Blei et al., 2003). Pengembangan lebih lanjut dilakukan oleh (Hoffman et al., 2010) melalui algoritma *Online Variational Bayes*, yaitu metode yang memperbarui estimasi parameter secara bertahap berdasarkan kelompok dokumen (mini-batch). Pendekatan ini meningkatkan efisiensi komputasi tanpa mengurangi kemampuan model dalam mengidentifikasi topik laten, sehingga banyak digunakan pada implementasi LDA modern. Pada implementasi *Latent Dirichlet Allocation* (LDA) menggunakan metode *Online Variational Bayes*, distribusi probabilitas kata

pada setiap topik tidak diperoleh secara langsung. Selama proses inferensi, algoritma terlebih dahulu mengestimasi parameter variational yang dinyatakan sebagai λ untuk setiap pasangan kata dan topik. Parameter λ merupakan parameter distribusi Dirichlet posterior yang merepresentasikan bobot setiap kata pada suatu topik. Nilai tersebut masih berupa parameter yang belum ternormalisasi (*unnormalized parameter*), sehingga belum dapat diinterpretasikan sebagai probabilitas kata pada topik tertentu. Berdasarkan hasil estimasi parameter tersebut, distribusi probabilitas kata pada setiap topik diperoleh melalui proses normalisasi terhadap seluruh nilai λ pada topik yang sama. Secara matematis, distribusi probabilitas kata dapat dinyatakan sebagai:

$$\phi_{wk} = \frac{\lambda_{wk}}{\sum_{v=1}^V \lambda_{vk}} \quad (3)$$

Dengan:

- ϕ_{wk} = probabilitas kata w pada topik ke- k
- λ_{wk} = parameter variational untuk kata w pada topik ke- k
- V = jumlah kosakata
- $\sum_{v=1}^V \lambda_{vk}$ = jumlah seluruh parameter variational pada topik ke- k

Setelah proses inferensi selesai, model LDA menghasilkan dua distribusi probabilitas utama, yaitu distribusi kata pada setiap topik (ϕ) dan distribusi topik pada setiap dokumen (θ). Distribusi ϕ digunakan untuk menggambarkan karakteristik suatu topik melalui kata-kata yang memiliki probabilitas tertinggi, sedangkan distribusi θ menunjukkan proporsi setiap topik pada suatu dokumen. Kedua distribusi tersebut merupakan keluaran utama model LDA yang digunakan untuk merepresentasikan hubungan antara kata, topik, dan dokumen (Blei et al., 2003).

Distribusi probabilitas kata pada setiap topik dinyatakan sebagai:

$$\phi_k = P(w|z = k) \quad (4)$$

dengan w menyatakan kata dan z menyatakan topik. Nilai ϕ_k menunjukkan peluang suatu kata muncul pada topik tertentu. Semakin besar nilai probabilitas suatu kata, semakin besar kontribusi kata tersebut dalam merepresentasikan karakteristik topik. Oleh karena itu, kata-kata dengan probabilitas tertinggi digunakan untuk menginterpretasikan tema yang dibentuk oleh suatu topik. Sementara itu, distribusi probabilitas topik pada setiap dokumen dinyatakan sebagai:

$$\theta_d = P(z|d) \quad (5)$$

dengan d menyatakan dokumen. Vektor θ_d menunjukkan proporsi setiap topik yang terkandung dalam suatu dokumen sehingga satu dokumen dapat memiliki lebih dari satu topik dengan proporsi yang berbeda. Distribusi ini digunakan untuk menggambarkan kecenderungan topik yang membentuk suatu dokumen.

Setelah model Latent Dirichlet Allocation (LDA) menghasilkan distribusi topik pada setiap dokumen (θ) dan distribusi kata pada setiap topik (ϕ), langkah berikutnya adalah mengevaluasi kualitas topik yang dihasilkan. Evaluasi ini diperlukan karena model LDA tidak hanya diharapkan mampu memodelkan distribusi probabilitas

dokumen dan kata, tetapi juga menghasilkan topik yang memiliki keterkaitan makna sehingga dapat diinterpretasikan secara semantik. Oleh karena itu, diperlukan ukuran evaluasi yang mampu mengukur tingkat koherensi antar kata dalam setiap topik.

Salah satu ukuran yang banyak digunakan untuk mengevaluasi kualitas topik adalah *topic coherence* yang dikembangkan oleh Röder., et al (2015). *Topic coherence* mengevaluasi sejauh mana kata-kata penyusun suatu topik saling berhubungan secara semantik. Nilai *coherence* yang lebih tinggi menunjukkan bahwa kata-kata dominan dalam suatu topik memiliki hubungan makna yang lebih kuat sehingga topik tersebut lebih mudah diinterpretasikan.

Misalkan $T^k = \{w_1^k, w_2^k, \dots, w_m^k\}$ menyatakan himpunan m kata teratas dengan probabilitas tertinggi pada topik ke- k . Nilai C_v untuk topik k dihitung sebagai:

$$C_v(K) = \frac{1}{K} \sum_k C_v(T^k) \quad (6)$$

Dengan $C_v(T^k)$ adalah skor coherence pada topik ke- k . Skor coherence topik dihitung menggunakan rata-rata seluruh nilai NPMI pasangan kata dengan persamaan:

$$C_v(T^k) = \frac{2}{m(m-1)} \sum_{i < j} NPMI(w_i, w_j) \quad (7)$$

Untuk membandingkan perubahan kualitas model pada setiap penambahan jumlah topik, dihitung pula selisih coherence antar model menggunakan:

$$\Delta C_v = C_v(K_i) - C_v(K_{i-1}) \quad (8)$$

Perhitungan $C_v(T^k)$ didasarkan pada keterkaitan makna antar pasangan kata dalam himpunan T^k . Hubungan ini diukur menggunakan *Normalized Poinwise Mutual Information* (NPMI), yang dirumuskan sebagai:

$$NPMI = \frac{\log \frac{p(w_i, w_j)}{p(w_i)p(w_j)}}{-\log p(w_i, w_j)} \quad (9)$$

Dalam persamaan tersebut, $p(w_i)$ menyatakan probabilitas kemunculan w_i dalam jendela konteks, sedangkan $p(w_i, w_j)$ menyatakan probabilitas kedua kata muncul secara bersamaan dalam jendela yang sama. Probabilitas ini dihitung menggunakan pendekatan *sliding window* pada korpus referensi. Probabilitas kemunculan individual suatu kata dihitung menggunakan persamaan:

$$p(w_i) = \frac{\text{count}(w_i)}{W_{total}} \quad (10)$$

Sedangkan probabilitas kemunculan bersama dua kata dihitung menggunakan:

$$p(w_i, w_j) = \frac{\text{count}(w_i, w_j)}{W_{total}} \quad (11)$$

Dengan

- $count(w_i)$ adalah jumlah dokumen yang kata w_i
- $count(w_i, w_j)$ adalah jumlah dokumen yang mengandung kedua kata secara bersamaan
- W_{total} adalah jumlah total dokumen

Secara umum, nilai C_v berada pada interval $[0,1]$. Nilai yang lebih tinggi menunjukkan bahwa kata-kata dalam suatu topik lebih konsisten secara makna, sehingga topik tersebut lebih mudah diinterpretasikan. Oleh karena itu, pemilihan jumlah K dilakukan dengan menguji beberapa kandidat nilai K dan memilih model yang menghasilkan nilai C_v tertinggi (Roder et al. 2015).

Topik dominan suatu dokumen ditentukan menggunakan operator argmax, yaitu dengan memilih indeks topik yang memiliki nilai probabilitas tertinggi pada distribusi θ_d . Secara matematis, penentuan topik dominan dirumuskan sebagai berikut:

$$\theta_{d,dominan} = \underset{k}{argmax} \theta_{dk} \quad (12)$$

dengan menyatakan probabilitas topik ke- k pada dokumen ke- d , sedangkan $k=1,2,...,K$ adalah jumlah topik hasil pemodelan LDA. Untuk menggambarkan kekuatan representasi topik dominan pada sekelompok dokumen, dapat dihitung rata-rata probabilitas topik dominan yang dikenal sebagai *Average Dominant Topic Probability* (AvgP). Metrik ini dirumuskan sebagai berikut:

$$AvgP = \frac{1}{n} \sum_{d=1}^n \theta_{d,dominan} \quad (13)$$

dengan n menyatakan jumlah dokumen pada suatu kelompok, sedangkan $\theta_{d,dominan}$ merupakan probabilitas topik dominan pada dokumen ke- d yang diperoleh dari Persamaan (12). Nilai AvgP yang tinggi menunjukkan bahwa dokumen-dokumen dalam kelompok tersebut secara konsisten memiliki satu topik yang dominan dengan probabilitas yang besar, sedangkan nilai AvgP yang rendah menunjukkan bahwa distribusi topik pada dokumen-dokumen tersebut cenderung lebih merata sehingga topik dominannya kurang menonjol.

1.6.7 Bidirectional Encoder Representations from Transformers (BERT)

Bidirectional Encoder Representations from Transformers (BERT) merupakan model bahasa pra-latih yang dikembangkan oleh Devlin et al. (2019) dengan memanfaatkan arsitektur transformer yang diperkenalkan oleh Vaswani et al. (2023). Model ini dirancang untuk memahami konteks kata dengan melihat seluruh kalimat secara bersamaan, bukan secara berurutan. Pendekatan ini membuat representasi kata menjadi lebih akurat karena mempertimbangkan kata sebelum dan sesudahnya. Berbeda dengan model seperti Word2Vec, GloVe, serta model berbasis RNN atau LSTM, BERT mampu menangkap konteks dua arah secara penuh. Hal ini membuat BERT lebih efektif dalam berbagai tugas pemrosesan bahasa alami, termasuk

klasifikasi sentimen (Devlin et al. 2019).

Arsitektur Transformer yang menjadi dasar BERT dibangun menggunakan mekanisme *Scaled Dot-Product Self-Attention*. Mekanisme ini memungkinkan setiap token memperhatikan seluruh token lain dalam satu sekuens, sehingga hubungan semantik antarkata dapat dipelajari secara langsung tanpa bergantung pada urutan pemrosesan. Nilai *attention* dihitung menggunakan persamaan berikut (Vaswani et al., 2023)

$$Attention(Q, K, V) = softmax \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (14)$$

Dalam persamaan ini, Q (*Query*) merepresentasikan token yang mencari informasi, K (*Key*) merepresentasikan token pembanding, dan V (*Value*) berisi informasi yang akan digabungkan. Skor *attention* dihitung melalui perkalian dot product antara *Query* dan *Key*, kemudian dinormalisasi menggunakan fungsi *softmax*. Faktor skala $\sqrt{d_k}$ digunakan untuk menjaga stabilitas numerik pada dimensi tinggi (Vaswani et al. 2023).

Penggunaan satu mekanisme attention hanya memungkinkan model mempelajari satu jenis hubungan antartoken. Oleh karena itu, Transformer menggunakan *Multi-Head Self-Attention* (MHSA), yaitu beberapa mekanisme attention yang bekerja secara paralel sehingga model dapat menangkap berbagai hubungan semantik maupun sintaktis secara bersamaan (Vaswani et al., 2023). Secara matematis, mekanisme tersebut dirumuskan sebagai:

$$MHSA(Q, K, V) = Concat(head_1, head_2, \dots, head_h)W^O \quad (15)$$

$$head_i = Attention(XW_i^Q, XW_i^K, XW_i^V), i = 1, \dots, h \quad (16)$$

Matriks $X \in \mathbb{R}^{n \times H}$ merepresentasikan input berupa n token dengan dimensi H . Untuk setiap *head* ke- i , digunakan tiga matriks bobot, yaitu W_i^Q , W_i^K , dan W_i^V , yang masing-masing berfungsi untuk memproyeksikan input menjadi *Query*, *Key*, dan *Value*. Hasil dari setiap *head* kemudian digabungkan dan diproyeksikan kembali menggunakan matriks W^O . Dimensi setiap *head* ditentukan sebagai $d_k = d_v = H/h$, sehingga total dimensi tetap konstan dan jumlah parameter tidak meningkat secara signifikan meskipun digunakan beberapa *head* (Vaswani et al., 2023). Setiap head mempelajari hubungan antartoken dari sudut pandang yang berbeda. Seluruh keluaran head kemudian digabungkan (*concatenate*) dan diproyeksikan kembali sehingga menghasilkan representasi kontekstual yang lebih kaya dibandingkan dengan penggunaan satu attention saja.

Sebelum diproses oleh encoder Transformer, setiap token terlebih dahulu diubah menjadi representasi vektor melalui penjumlahan tiga jenis embedding, yaitu token *embedding*, *segment embedding*, dan *position embedding*. Representasi input tersebut dirumuskan sebagai:

$$E_{input} = E_{token} + E_{segment} + E_{position} \quad (17)$$

Penjelasan masing-masing komponen adalah sebagai berikut:

- $E_{\text{token}} \in \mathbb{R}^{n \times H}$, merepresentasikan setiap kata atau sub kata yang diperoleh dari tokenisasi *WordPiece*. Embedding ini menggambarkan makna dasar kata.
- $E_{\text{segment}} \in \mathbb{R}^{n \times H}$, merepresentasikan informasi asal kalimat pada pasangan kalimat. Fungsinya adalah membantu model membedakan dua kalimat dalam satu input.
- $E_{\text{position}} \in \mathbb{R}^{n \times H}$, merepresentasikan posisi setiap token dalam urutan kalimat, mulai dari posisi 1 hingga maksimum 512. Komponen ini penting karena model tidak memproses teks secara berurutan.

Token khusus [CLS] ditambahkan di awal setiap input, dan token [SEP] ditambahkan di akhir setiap kalimat. Representasi *hidden* dari token [CLS] pada lapisan terakhir, $h_{CLS} \in \mathbb{R}^H$, digunakan sebagai representasi agregat dari seluruh sekuens untuk tugas klasifikasi (Devlin et al. 2019).

Pada proses pembentukan masukan, BERT menambahkan token khusus [CLS] di awal sekuens dan token [SEP] sebagai penanda akhir kalimat atau pemisah antarkalimat. Setelah seluruh encoder selesai diproses, setiap token memiliki representasi kontekstual (*hidden representation*). Untuk tugas klasifikasi, representasi token [CLS] pada lapisan encoder terakhir digunakan sebagai representasi keseluruhan dokumen. Jika $H^{(L)}$ menyatakan keluaran encoder terakhir, maka representasi dokumen dinyatakan sebagai:

$$h_{CLS} = H_0^{(L)} \quad (18)$$

Dengan $H_0^{(L)}$ merupakan vektor keluaran token [CLS] pada lapisan encoder ke-L. Representasi tersebut telah mengandung informasi kontekstual dari seluruh token hasil mekanisme *self-attention* sehingga banyak digunakan sebagai masukan bagi lapisan klasifikasi pada berbagai tugas pemrosesan bahasa alami, termasuk klasifikasi sentimen (Devlin et al., 2019).

1.6.8 IndoBERT

IndoBERT merupakan pengembangan dari *Bidirectional Encoder Representations from Transformers* (BERT) yang secara khusus dilatih menggunakan korpus berbahasa Indonesia. Model ini mempertahankan arsitektur Transformer encoder seperti pada BERT, sehingga mampu menghasilkan representasi kontekstual melalui mekanisme *self-attention* dua arah (*bidirectional self-attention*). Kemampuan tersebut memungkinkan IndoBERT memahami hubungan antarkata berdasarkan konteks kalimat secara lebih baik dibandingkan representasi kata statis (Koto et al., 2020). Pengembangan IndoBERT dilakukan oleh Koto et al. (2020) dalam proyek IndoLEM (*Indonesian Language Evaluation Montage*). Model ini dilatih menggunakan korpus berukuran lebih dari empat miliar token yang berasal dari berbagai sumber, seperti Wikipedia Bahasa Indonesia, artikel berita daring, dan teks web umum. Penggunaan korpus dalam jumlah besar dan beragam bertujuan agar model mampu mempelajari karakteristik sintaksis, semantik, serta variasi penggunaan bahasa Indonesia pada berbagai konteks.

Sebagai model bahasa pra-latih (*pre-trained language model*), IndoBERT dikembangkan melalui dua tahap pembelajaran, yaitu *pre-training* dan *fine-tuning* (Devlin et al., 2019). Tahap *pre-training* dilakukan menggunakan korpus teks dalam jumlah besar tanpa memerlukan data berlabel untuk mempelajari representasi bahasa secara umum. Selanjutnya, model disesuaikan dengan tugas tertentu melalui proses *fine-tuning*, yaitu melatih kembali model menggunakan data berlabel sehingga parameter model dapat beradaptasi dengan karakteristik tugas yang dihadapi. Pendekatan ini memungkinkan model memanfaatkan pengetahuan bahasa yang telah dipelajari pada tahap *pre-training*, sehingga umumnya menghasilkan kinerja yang lebih baik dibandingkan pelatihan model dari awal (*training from scratch*), terutama ketika jumlah data berlabel terbatas (Devlin et al., 2019).

1.6.9 Feature Fusion

Dalam pembelajaran mesin, informasi yang digunakan untuk merepresentasikan suatu objek dapat berasal dari lebih dari satu sumber atau lebih dari satu jenis representasi. Proses menggabungkan beberapa representasi tersebut dikenal sebagai *fusion*, yaitu strategi untuk mengintegrasikan informasi sehingga diperoleh representasi yang dapat digunakan dalam proses pembelajaran atau pengambilan keputusan. Strategi *fusion* banyak diterapkan pada berbagai bidang, seperti pengolahan citra, pengenalan suara, pemrosesan bahasa alami, dan pembelajaran multimodal (Baltrusaitis et al., 2019).

Baltrusaitis et al., (2019) mengelompokkan strategi *fusion* ke dalam tiga kategori utama berdasarkan tahap penggabungan informasi, yaitu *feature-level fusion* (*early fusion*), *decision-level fusion* (*late fusion*), dan *hybrid fusion*.

1. *Feature-level fusion* (*early fusion*) merupakan pendekatan yang menggabungkan representasi dari beberapa sumber pada tahap awal sehingga terbentuk satu representasi fitur gabungan sebelum diproses oleh model pembelajaran.
2. *Decision-level fusion* (*late fusion*) merupakan pendekatan yang menggabungkan keluaran atau hasil prediksi dari beberapa model yang diproses secara terpisah. Keputusan akhir diperoleh melalui mekanisme tertentu, seperti majority voting, rata-rata probabilitas, atau pembobotan.
3. *Hybrid fusion* merupakan pendekatan yang *mengombinasikan feature-level fusion* dan *decision-level fusion*, sehingga proses penggabungan dilakukan baik pada tingkat representasi fitur maupun pada tingkat keputusan.

Di antara ketiga pendekatan tersebut, *feature-level fusion* merupakan strategi yang paling umum digunakan ketika beberapa representasi akan dimanfaatkan secara bersamaan sebagai masukan bagi satu model pembelajaran. Pada pendekatan ini, setiap representasi digabungkan terlebih dahulu, umumnya melalui operasi *concatenation*, sehingga model menerima satu vektor fitur yang memuat seluruh informasi dari masing-masing representasi (Baltrusaitis et al., 2019).

1.6.10 Integrasi LDA dan IndoBERT sebagai Model Hybrid

Model *hybrid* dalam pembelajaran mesin merupakan pendekatan yang menggabungkan dua atau lebih metode dengan karakteristik yang berbeda ke dalam

satu kerangka pembelajaran untuk memanfaatkan keunggulan masing-masing metode. Penggabungan tersebut dilakukan karena setiap metode memiliki kemampuan yang berbeda dalam merepresentasikan data sehingga kombinasi beberapa representasi diharapkan dapat menghasilkan informasi yang lebih komprehensif dibandingkan penggunaan satu metode saja.

Pada analisis teks, *Latent Dirichlet Allocation* (LDA) dan *Bidirectional Encoder Representations from Transformers* (BERT) menghasilkan representasi dokumen yang memiliki karakteristik berbeda. LDA merupakan model probabilistik generatif yang merepresentasikan setiap dokumen sebagai distribusi probabilitas terhadap sejumlah topik laten sehingga mampu menggambarkan struktur tematik dokumen pada tingkat korpus (Blei et al., 2003). Sebaliknya, BERT menghasilkan representasi kontekstual yang dibangun melalui mekanisme *self-attention*, sehingga mampu menangkap hubungan semantik antar kata berdasarkan konteks kalimat secara dua arah (Devlin et al., 2019).

Perbedaan karakteristik tersebut menjadikan kedua model saling melengkapi dalam merepresentasikan informasi tekstual. Representasi topik yang dihasilkan LDA memberikan informasi mengenai tema utama yang terkandung dalam suatu dokumen, sedangkan representasi kontekstual BERT memberikan informasi mengenai makna teks berdasarkan hubungan antar kata dalam konteks kalimat. Oleh karena itu, integrasi kedua representasi tersebut dapat menghasilkan representasi dokumen yang lebih kaya karena memadukan informasi tematik dan informasi semantik secara bersamaan.

Dalam implementasinya, penggabungan representasi dari beberapa model umumnya dilakukan menggunakan pendekatan *feature-level fusion*, yaitu mengombinasikan beberapa representasi fitur menjadi satu vektor sebelum diproses pada tahap klasifikasi (Baltrusaitis et al., 2019). Pada penelitian ini, representasi kontekstual dokumen yang diperoleh dari IndoBERT digabungkan dengan distribusi topik dokumen hasil LDA, yaitu menggunakan operasi *concatenation*, sehingga diperoleh representasi fitur gabungan sebagai masukan bagi lapisan klasifikasi. Secara matematis, proses tersebut dinyatakan sebagai

$$h_{final} = Concat[h_{cls}; \theta_d] \in \mathbb{R}^{H+K} \quad (19)$$

di mana:

- $h_{cls} \in \mathbb{R}^H$: representasi kontekstual dari BERT
- $\theta_d \in \mathbb{R}^K$: distribusi topik dari LDA
- H : dimensi *BERT-base*
- K : jumlah topik

Setelah proses penggabungan selesai, vektor fitur hasil *concatenation* dinormalisasi menggunakan *Layer Normalization* untuk menjaga kestabilan distribusi nilai fitur sebelum diproses pada lapisan klasifikasi. Proses normalisasi dinyatakan sebagai

$$h_{norm} = LayerNorm(h_{final}) \in \mathbb{R}^{H+K} \quad (20)$$

Selanjutnya, representasi hasil normalisasi diproses menggunakan lapisan linear yang diikuti fungsi softmax untuk menghasilkan distribusi probabilitas setiap kelas sentimen. Proses tersebut dinyatakan sebagai

$$p(y | d) = \text{softmax}(W_{\text{cls}} \cdot h_{\text{norm}} + b_{\text{cls}}) \quad (21)$$

dengan:

- $W_{\text{cls}} \in \mathbb{R}^{c \times (H+K)}$: bobot klasifikasi
- $b_{\text{cls}} \in \mathbb{R}^c$: bias

Setelah probabilitas diperoleh, model belum memberikan label sentimen.

Karena itu digunakan operator

$$y = \arg \max_c p(y = c | d) \quad (22)$$

dengan:

- y : kelas sentimen hasil prediksi model
- $p(y = c | d)$: probabilitas dokumen d termasuk ke dalam kelas sentimen ke- c .
- c : indeks kelas sentimen (positif, negatif, atau netral)

Operator argmax hanya memilih kelas dengan probabilitas terbesar.

1.6.11 Metrik Evaluasi

Evaluasi kinerja model klasifikasi sentimen dalam penelitian ini menggunakan metrik standar dalam pembelajaran mesin yang dijelaskan oleh (Sokolova & Lapalme, 2009). Seluruh metrik diturunkan dari *confusion matrix*, yaitu tabel yang menunjukkan jumlah prediksi benar dan salah pada setiap kelas. Untuk klasifikasi tiga kelas ($C = 3$: positif, negatif, netral), digunakan matriks $M \in \mathbb{R}^{3 \times 3}$, di mana M_{ij} menyatakan jumlah data yang sebenarnya berada pada kelas i , tetapi diprediksi sebagai kelas j .

Untuk setiap kelas c , didefinisikan:

$$TP_c = M_{cc}, FP_c = \sum_{i \neq c} M_{ic}, FN_c = \sum_{j \neq c} M_{cj} \quad (23)$$

di mana:

- TP_c (*True Positive*): jumlah prediksi benar pada kelas c .
- FP_c (*False Positive*): jumlah data dari kelas lain yang salah diprediksi sebagai kelas c .
- FN_c (*False Negative*): jumlah data kelas c yang salah diprediksi ke kelas lain.

1.6.11.1 Precision, Recall, Accuracy, dan F1-score

Precision mengukur ketepatan prediksi mode pada suatu kelas:

$$Precision = \frac{TP}{TP + FP} \quad (24)$$

Recall mengukur kemampuan model dalam menemukan seluruh data pada kelas tersebut:

$$Recall = \frac{TP}{TP + FN} \quad (25)$$

F1-score merupakan rata-rata harmonik dari *precision* dan *recall*:

$$F1 = \frac{2PR}{P + R} \quad (26)$$

F1-score memberikan evaluasi yang lebih seimbang karena mempertimbangkan kesalahan tipe FP dan FN secara bersamaan (Sokolova & Lapalme, 2009).

Accuracy mengukur proporsi keseluruhan prediksi yang benar terhadap seluruh data uji, dihitung dari jumlah elemen diagonal confusion matrix M yang telah didefinisikan pada Persamaan (23):

$$Accuracy = \frac{\sum_{c=1}^C M_{cc}}{N} \quad (27)$$

dengan M_{cc} menyatakan elemen diagonal ke- c pada confusion matrix, C adalah jumlah kelas, dan N adalah jumlah seluruh data uji.

1.6.11.2 Weighted F1-score dan Macro F1-score

Support merupakan banyaknya observasi atau dokumen yang termasuk ke dalam suatu kelas berdasarkan label sebenarnya. Pada dataset yang tidak seimbang, *weighted F1-score* digunakan untuk menghitung rata-rata tertimbang dari nilai *F1-score* setiap kelas dengan mempertimbangkan nilai support masing-masing kelas, sehingga hasil evaluasi lebih merepresentasikan distribusi data yang sebenarnya (Manning et al., 2008):

$$F1_{weighted} = \sum \frac{|S_c|}{N} F1_c \quad (28)$$

Dimana:

- $|S_c|$, jumlah data pada kelas c .
- N , total data

Pendekatan ini memberikan bobot lebih besar pada kelas mayoritas sehingga lebih mencerminkan performa keseluruhan model.

Sementara itu, macro F1-score merupakan rata-rata aritmetika dari F1-score seluruh kelas tanpa memperhitungkan jumlah data (support) pada masing-masing kelas. Berbeda dengan weighted F1-score pada Persamaan (28), setiap kelas memperoleh bobot yang sama. Rumus macro F1-score dinyatakan sebagai berikut:

$$F1_{macro} = \frac{1}{C} \sum_{c=1}^C F1_c \quad (29)$$

dengan $F1_c$ merupakan F1-score kelas ke-c yang dihitung menggunakan Persamaan (26), sedangkan C adalah jumlah kelas. Karena tidak mempertimbangkan proporsi jumlah data pada setiap kelas, macro F1-score memberikan bobot yang sama terhadap seluruh kelas.

1.6.11.3 Weight Class

Pada permasalahan klasifikasi, distribusi jumlah data pada setiap kelas tidak selalu seimbang. Ketidakseimbangan kelas dapat menyebabkan model lebih cenderung mempelajari karakteristik kelas mayoritas sehingga performa klasifikasi pada kelas minoritas menjadi kurang optimal (He & Garcia, 2009). Salah satu pendekatan yang umum digunakan untuk mengatasi permasalahan tersebut adalah class weighting, yaitu memberikan bobot yang lebih besar pada kelas dengan jumlah data lebih sedikit agar kesalahan prediksi pada kelas tersebut memberikan penalti yang lebih besar selama proses pelatihan model. persamaannya sebagai berikut:

$$w_c = \frac{N}{K \times n_c} \quad (30)$$

Dengan w_c adalah bobot kelas ke-c, N adalah jumlah seluruh data, K adalah jumlah kelas, dan n_c adalah jumlah data pada kelas ke-c

1.6.11.4 Weighted Cross-Entropy Loss

Weighted cross-entropy loss merupakan pengembangan dari fungsi cross-entropy loss yang memberikan bobot berbeda pada setiap kelas sesuai dengan nilai bobot kelas yang telah ditentukan. Pendekatan ini banyak digunakan pada permasalahan klasifikasi dengan distribusi kelas yang tidak seimbang karena mampu meningkatkan kontribusi kesalahan prediksi pada kelas minoritas terhadap nilai loss (Manning et al., 2008). Secara matematis, fungsi weighted cross-entropy loss dinyatakan sebagai berikut.

$$L = -\frac{1}{N} \sum_{i=1}^N w_{ci} \log(p(y_i = c_i | d_i)) \quad (31)$$

Dimana:

- L = nilai loss
- N , jumlah data dalam satu batch pelatihan
- c_i = kelas sebenarnya dari data ke-i
- w_{ci} = bobot kelas sesuai persamaan
- $p(y_i = c_i | d_i)$ = probabilitas kelas sebenarnya yang diprediksi model

Nilai loss yang dihasilkan kemudian digunakan dalam proses backpropagation untuk menghitung gradien setiap parameter model. Selanjutnya, parameter model

diperbarui menggunakan algoritma optimasi sehingga nilai loss semakin kecil dan kemampuan klasifikasi model meningkat.

1.6.11.5 Loss dan F1-score pada Tingkat Epoch

Nilai training F1-score dan validation F1-score pada setiap epoch dihitung menggunakan Persamaan (29), yaitu berdasarkan hasil prediksi model terhadap seluruh data latih dan data validasi pada akhir epoch. Oleh karena itu, kedua metrik tersebut tidak memerlukan rumus tambahan karena hanya berbeda pada himpunan data yang digunakan.

Sementara itu, training loss dan validation loss pada setiap epoch diperoleh sebagai rata-rata nilai loss dari seluruh batch dalam epoch tersebut, yang dinyatakan sebagai

$$L_{epoch} = -\frac{1}{B} \sum_{b=1}^B L_b \quad (32)$$

dengan B menyatakan jumlah batch dalam satu epoch dan L_b adalah nilai loss pada batch ke-b yang dihitung menggunakan Persamaan (27). Training loss dihitung selama proses pelatihan ketika parameter model diperbarui melalui backpropagation dan optimizer AdamW, sedangkan validation loss dihitung pada mode evaluasi tanpa pembaruan parameter. Rata-rata loss per epoch digunakan untuk memberikan gambaran proses konvergensi model yang lebih stabil dibandingkan nilai loss pada satu batch (Manning et al., 2008).

BAB II

METODOLOGI PENELITIAN

2.1 Jenis dan Sumber Data

Data yang digunakan pada penelitian ini adalah data kuantitatif berupa teks pendek yang berasal dari judul berita saham yang dipublikasikan secara daring. Penelitian ini menggunakan data sekunder yang bersumber dari repositori “Kaggle” dengan judul *dataset CNBC Indonesia Stock News Sentiment (2024-2025Q1)*. Dataset ini berisi 9.819 judul berita saham yang dipublikasikan pada portal CNBC Indonesia dalam kategori pasar (*market*) selama periode Januari 2024 hingga Maret 2025. Setiap data telah dilengkapi dengan label sentimen pada tingkat dokumen yang terdiri atas tiga kategori, yaitu positif, negatif, dan netral. Adapun rincian data yang digunakan adalah sebagai berikut.

1. *Headline*, berupa judul berita saham. Bagian ini merupakan komponen utama yang dianalisis dalam proses klasifikasi sentimen. Judul berita dipilih karena mengandung informasi inti yang ringkas dan langsung mencerminkan sentimen pasar.
2. *Sentiment Label*, berupa kategori sentimen (positif, negatif, netral). Bagian ini digunakan sebagai variabel target dalam proses pelatihan dan evaluasi model klasifikasi sentimen.

2.2 Variabel Penelitian

Variabel dalam penelitian ini terbagi menjadi dua, yaitu variabel masukan (*input*) yang digunakan untuk proses pemodelan dan variabel keluaran (*output*) yang menjadi hasil evaluasi dari tahapan pemrosesan analisis berbasis integrasi LDA dan IndoBERT.

2.2.1 Variabel Masukan (*Input*)

Variabel masukan (X) atau variabel independen adalah data yang digunakan sebagai input dalam proses analisis sentimen. Data diolah melalui dua komponen utama, yaitu pemodelan topik menggunakan LDA dan klasifikasi sentimen menggunakan model *hybrid* LDA-IndoBERT. Variabel masukan tersebut dijabarkan sebagai berikut.

X_1 : *Headline* (judul berita saham)

X_2 : *Sentiment Label*

2.2.2 Variabel Keluaran (*Output*)

Variabel keluaran (Y) atau variabel dependen adalah hasil analisis yang diperoleh dari pemodelan dan evaluasi model. Variabel keluaran tersebut dijabarkan sebagai berikut.


Y_1 : Distribusi topik hasil pemodelan LDA

Y_2 : Label klasifikasi sentimen (positif, negatif, netral) hasil model *hybrid* LDA-IndoBERT

Y_3 : Nilai metrik kinerja model (*precision*, *recall*, *F1-score*) hasil evaluasi pada data uji

2.2.3 Skema Data Masukan dan Keluaran

Skema pola data masukan dan keluaran pada penelitian ini ditunjukkan pada gambar berikut.



Gambar 1. Skema data masukan dan keluaran

2.3 Tahapan Penelitian

Penelitian ini terdiri dari beberapa tahapan sistematis, mulai dari identifikasi masalah hingga evaluasi dan analisis statistik dengan rincian sebagai berikut.

2.3.1 Identifikasi Masalah

Tahap awal penelitian ini adalah identifikasi masalah untuk menentukan permasalahan yang menjadi fokus penelitian. Identifikasi dilakukan melalui pengamatan terhadap perkembangan penelitian di bidang analisis sentimen serta kajian terhadap berbagai literatur yang berkaitan dengan analisis sentimen pada berita keuangan. Berdasarkan hasil identifikasi, diketahui bahwa analisis sentimen pada berita saham umumnya masih dilakukan pada tingkat dokumen, yaitu setiap dokumen hanya diberikan satu label sentimen. Pendekatan tersebut memiliki keterbatasan karena satu judul berita saham dapat memuat lebih dari satu topik atau informasi, seperti pergerakan indeks saham, kebijakan pemerintah, maupun kinerja perusahaan. Setiap topik tersebut berpotensi memiliki kecenderungan sentimen yang berbeda sehingga pemberian satu label sentimen pada keseluruhan dokumen belum tentu mampu merepresentasikan seluruh informasi yang terkandung di dalamnya. Selain itu, pendekatan yang mampu mengidentifikasi aspek secara otomatis masih relatif terbatas, khususnya pada korpus berita saham berbahasa Indonesia. Oleh karena itu, diperlukan suatu pendekatan yang mampu merepresentasikan topik atau aspek secara lebih rinci dalam proses analisis sentimen.

2.3.2 Studi Literatur

Studi literatur dilakukan dengan mengumpulkan landasan teori dan meninjau penelitian terdahulu untuk memperdalam pemahaman penulis terkait penelitian yang akan dilakukan. Proses ini melibatkan pengumpulan sumber referensi ilmiah seperti artikel jurnal, skripsi, buku, dan lain sebagainya.

2.3.3 Pengumpulan Data

Tahap pengumpulan data dilakukan dengan memperoleh data sekunder yang digunakan sebagai objek penelitian. Data diperoleh dari repositori Kaggle dengan

judul dataset *CNBC Indonesia Stock News Sentiment (2024–2025Q1)*. Dataset tersebut berisi 9.819 judul berita saham yang dipublikasikan oleh CNBC Indonesia pada kategori market selama periode Januari 2024 hingga Maret 2025. Setiap data telah dilengkapi dengan label sentimen pada tingkat dokumen yang terdiri atas tiga kategori, yaitu positif, negatif, dan netral. Selanjutnya, data yang telah diperoleh digunakan sebagai masukan dalam proses pra-pemrosesan sebelum dilakukan pemodelan topik menggunakan LDA dan klasifikasi sentimen menggunakan model *hybrid* LDA-IndoBERT. Rincian karakteristik data yang digunakan telah dijelaskan pada Subbab 2.1.

2.3.4 Pengolahan Data Awal (*Pre-processing Data*)

Tahap pre-processing dilakukan untuk menyiapkan data sebelum digunakan pada proses pemodelan topik dan klasifikasi sentimen. Pada tahap ini, teks dibersihkan dan dinormalisasi agar sesuai dengan karakteristik model yang digunakan. Mengingat penelitian ini mengintegrasikan LDA dan IndoBERT, proses pre-processing dilakukan melalui dua jalur yang berbeda karena kedua model memiliki kebutuhan pemrosesan teks yang tidak sama.

Pada jalur LDA, *pre-processing* dilakukan secara bertahap, meliputi *case folding*, penghapusan URL, karakter nonalfabet, tanda baca, dan angka, kemudian dilanjutkan dengan tokenisasi. Selanjutnya dilakukan normalisasi istilah menggunakan kamus normalisasi, penghapusan *stopword* menggunakan pustaka Sastrawi, proses *stemming* untuk mengubah kata ke bentuk dasar, serta penyaringan token berdasarkan panjang karakter. Hasil pre-processing selanjutnya digunakan untuk membentuk representasi *Bag-of-Words* sebagai masukan pada proses pemodelan topik menggunakan LDA.

Pada jalur IndoBERT, *pre-processing* dilakukan secara lebih sederhana agar informasi kontekstual pada teks tetap dipertahankan. Tahapan yang dilakukan meliputi *case folding*, penghapusan karakter kontrol dan spasi berlebih, kemudian tokenisasi menggunakan *WordPiece* Tokenizer yang disediakan oleh model IndoBERT. Hasil tokenisasi selanjutnya dikonversi menjadi *token ID* dan *attention mask* sebagai masukan pada proses klasifikasi sentimen.

2.3.5 Implementasi Model

Tahap implementasi model merupakan inti dari penelitian ini. Pada tahap ini dilakukan proses pemodelan topik menggunakan *Latent Dirichlet Allocation* (LDA), klasifikasi sentimen menggunakan IndoBERT, serta integrasi kedua model melalui pendekatan *feature-level fusion*. Seluruh proses dilakukan setelah data melalui tahap *pre-processing* sehingga data telah sesuai dengan kebutuhan masing-masing model.

2.3.5.1 Pemodelan Topik Menggunakan LDA

Pemodelan topik dilakukan menggunakan metode *Latent Dirichlet Allocation* (LDA). Dokumen yang telah melalui tahap *pre-processing* terlebih dahulu direpresentasikan ke dalam bentuk *Bag of Words* menggunakan *dictionary* yang dibentuk dari kumpulan token hasil praproses. Selanjutnya dibangun beberapa model LDA dengan variasi jumlah topik (K). Kualitas setiap model dievaluasi

menggunakan nilai topic coherence untuk menentukan jumlah topik yang paling sesuai dengan karakteristik korpus. Penentuan jumlah topik dilakukan dengan mempertimbangkan nilai coherence serta pola perubahan nilai coherence pada setiap kandidat jumlah topik. Model dengan konfigurasi terbaik kemudian digunakan sebagai model akhir pada proses pemodelan topik. Hasil pemodelan LDA berupa distribusi probabilitas kata pada setiap topik (ϕ) dan distribusi probabilitas topik pada setiap dokumen (θ). Distribusi kata digunakan sebagai dasar untuk menginterpretasikan karakteristik setiap topik melalui kata-kata yang memiliki probabilitas tertinggi, sedangkan distribusi topik digunakan untuk merepresentasikan proporsi keterlibatan setiap topik pada suatu dokumen.

2.3.5.2 Penentuan Aspek Dominan

Setelah model LDA diperoleh, setiap dokumen direpresentasikan sebagai distribusi probabilitas terhadap seluruh topik yang dihasilkan model. Distribusi tersebut menunjukkan proporsi keterlibatan masing-masing topik dalam suatu dokumen, sehingga setiap dokumen memiliki probabilitas pada setiap topik. Penentuan aspek dilakukan dengan memilih topik yang memiliki probabilitas tertinggi pada distribusi topik setiap dokumen. Topik dengan probabilitas terbesar dianggap sebagai representasi aspek tematik yang paling dominan karena memiliki kontribusi terbesar dalam merepresentasikan isi dokumen. Dengan demikian, setiap dokumen diberikan satu label aspek berdasarkan topik dominan yang dimilikinya. Untuk meningkatkan kejelasan representasi aspek, diterapkan nilai ambang (threshold) terhadap probabilitas topik dominan. Dokumen yang memiliki probabilitas topik dominan di bawah nilai ambang dianggap belum memiliki representasi topik yang cukup jelas sehingga tidak disertakan dalam analisis berbasis aspek. Selanjutnya, setiap topik diinterpretasikan secara manual berdasarkan kata-kata yang memiliki probabilitas tertinggi untuk memperoleh label aspek tematik yang sesuai dengan konteks berita saham dan pasar modal.

2.3.5.3 Klasifikasi Sentimen Menggunakan IndoBERT

Tahap berikutnya adalah pembangunan model klasifikasi sentimen menggunakan IndoBERT. Data hasil *pre-processing* ditokenisasi menggunakan *WordPiece Tokenizer*, kemudian dikonversi menjadi *input IDs* dan *attention mask* sebagai masukan model. Selanjutnya, data dibagi menjadi data latih, data validasi, dan data uji. Model IndoBERT kemudian melalui proses *fine-tuning* menggunakan data latih yang telah memiliki label sentimen sehingga parameter model dapat menyesuaikan karakteristik berita saham berbahasa Indonesia. Untuk mengatasi ketidakseimbangan distribusi kelas pada data latih, diterapkan *class weighting* pada fungsi *cross-entropy loss*. Selama proses pelatihan, kinerja model dipantau menggunakan data validasi untuk memperoleh model dengan kemampuan generalisasi yang baik. Model hasil *fine-tuning* selanjutnya digunakan sebagai model dasar (*baseline*) sekaligus sebagai komponen pada model *hybrid*.

2.3.5.4 Integrasi Model *Hybrid* LDA-IndoBERT

Setelah model LDA dan IndoBERT diperoleh, dilakukan integrasi kedua model melalui pendekatan *feature-level fusion*. Pada tahap ini, distribusi topik hasil LDA digunakan sebagai representasi aspek tematik, sedangkan IndoBERT menghasilkan representasi kontekstual dokumen melalui vektor token [CLS]. Kedua representasi tersebut digabungkan menggunakan operasi konkatenasi sehingga membentuk satu vektor fitur yang memuat informasi topik dan informasi semantik secara bersamaan. Vektor hasil penggabungan selanjutnya digunakan sebagai masukan pada lapisan klasifikasi untuk menghasilkan prediksi sentimen berupa kelas positif, negatif, atau netral.

2.3.6 Pengujian dan Evaluasi

Setelah model diimplementasikan dan parameter ambang batas telah ditentukan, selanjutnya dilakukan tahap pengujian untuk mengevaluasi kinerja model dalam melakukan klasifikasi sentimen.

2.3.6.1 Skema Pembagian Data

Data hasil pemodelan aspek dibagi menjadi tiga subset, yaitu data latih (*training set*), data validasi (*validation set*), dan data uji (*test set*). Pembagian data dilakukan untuk melatih model, memantau proses pelatihan, serta mengevaluasi kemampuan generalisasi model terhadap data yang belum pernah digunakan selama proses pelatihan. Untuk menentukan proporsi pembagian data yang memberikan kinerja terbaik, dilakukan eksperimen pendahuluan dengan membandingkan beberapa skema pembagian data. Skema yang menghasilkan performa terbaik kemudian digunakan secara konsisten pada seluruh proses pelatihan dan evaluasi, baik pada model *hybrid* LDA-IndoBERT maupun model pembanding (*baseline*).

2.3.6.2 Metrik Evaluasi

Kinerja model klasifikasi sentimen dievaluasi menggunakan metrik *precision*, *recall*, dan *F1-score* yang dihitung berdasarkan *confusion matrix*. Mengingat distribusi kelas pada dataset penelitian ini tidak sepenuhnya seimbang, evaluasi juga menggunakan *macro average* dan *weighted average*. *Macro average* memberikan bobot yang sama pada setiap kelas sehingga mencerminkan kemampuan model pada seluruh kelas secara seimbang, sedangkan *weighted average* mempertimbangkan jumlah data pada setiap kelas (*support*) sehingga memberikan gambaran kinerja model sesuai dengan distribusi data yang sebenarnya. Selain itu, *confusion matrix* digunakan untuk menganalisis pola kesalahan klasifikasi antar kelas sentimen secara lebih rinci.

2.3.6.3 Ablation Study


Untuk mengevaluasi kontribusi representasi topik hasil LDA terhadap kinerja klasifikasi sentimen, dilakukan *ablation study* dengan membandingkan model *hybrid* LDA-IndoBERT terhadap model pembanding (*baseline*) yang hanya menggunakan IndoBERT tanpa integrasi distribusi topik LDA. Kedua model dilatih dan dievaluasi

menggunakan skema pembagian data, konfigurasi *hyperparameter*, serta prosedur pelatihan yang sama sehingga perbedaan kinerja yang diperoleh dapat diatribusikan pada penambahan representasi topik hasil LDA. Perbandingan dilakukan menggunakan metrik *precision*, *recall*, dan *F1-score* pada data uji. Hasil *ablation study* digunakan untuk menilai sejauh mana integrasi informasi topik mampu meningkatkan kinerja model klasifikasi sentimen dibandingkan penggunaan IndoBERT sebagai model tunggal.

2.4 Diagram Alir

2.4.1 Diagram Alir Penelitian

Berdasarkan penjelasan pada tahap penelitian, alur kerja penelitian ditunjukkan oleh diagram alir berikut.




Gambar 2. Diagram alir penelitian

Gambar 2 menunjukkan alur kerja penelitian secara sistematis dan berurutan, dimulai dari tahap identifikasi masalah hingga tahap pengujian dan evaluasi. Diagram ini berfungsi sebagai representasi visual dari tahapan penelitian yang telah dijelaskan secara rinci pada Subbab 2.3, sehingga memudahkan pemahaman terhadap urutan proses dan keterkaitan antar tahapan dalam penelitian ini.

2.4.2 Diagram Alir Pemodelan Hybrid LDA–IndoBERT

Diagram alir pemodelan *Hybrid* LDA-IndoBERT dapat dilihat pada Gambar 3.



Gambar 3. Diagram Alir Pemodelan Hybrid LDA-IndoBERT

BAB III

HASIL DAN PEMBAHASAN

3.1 Verifikasi dan Pembersihan Data

Dataset yang digunakan bersumber dari repositori *Kaggle* dengan judul *CNBC Indonesia Stock News Sentiment (2024–2025Q1)*, yang memuat judul berita saham dari portal CNBC Indonesia selama periode Januari 2024 hingga Maret 2025. Sebelum *dataset* dimasukkan ke dalam tahap pemodelan, peneliti melakukan proses verifikasi dan pembersihan data guna memastikan kualitas korpus. Proses ini mencakup identifikasi dan penghapusan data duplikat, penanganan nilai kosong (*missing value*), serta penyaringan teks yang terlalu pendek. Hasil selengkapnya disajikan pada Tabel 1.

Tabel 1. Verifikasi dan Pembersihan Data

Keterangan	Jumlah
Jumlah data awal	9.819
Duplikasi dihapus	72
Nilai kosong dihapus	0
Teks terlalu pendek dihapus	0
Jumlah data akhir	9.747

Sumber: diolah, 2026.

Tabel 1 menampilkan bahwa dari total 9.819 data awal, terdeteksi sebanyak 72 data duplikat yang kemudian dihapus, sehingga tersisa 9.747 data bersih untuk proses pemodelan. Selain itu, tidak ditemukan nilai kosong maupun teks dengan panjang yang terlalu pendek, sehingga kualitas dataset dapat dinilai baik sejak tahap awal pengumpulan data.

Sebelum masuk ke tahap pemodelan, dilakukan pemeriksaan distribusi label sentimen untuk memahami komposisi kelas. Pemahaman distribusi ini penting karena ketidakseimbangan kelas dapat memengaruhi kinerja model klasifikasi dan menjadi landasan strategi pelatihan yang tepat (He & Garcia, 2009).

Tabel 2. Distribusi Label Sentimen pada Dataset

Sentimen	Frekuensi	Persentase (%)
netral	4.301	44,13
Positif	2.887	29,62
negatif	2.559	26,25

Sumber: diolah, 2026.

Berdasarkan Tabel 2, kelas netral merupakan kelas dengan jumlah data terbesar, yaitu sebanyak 4.301 dokumen (44,13%), diikuti oleh kelas positif sebanyak 2.887 dokumen (29,62%), dan kelas negatif sebanyak 2.559 dokumen (26,25%). Rasio antara kelas terbesar dan kelas terkecil adalah 42 : 25, sehingga distribusi data menunjukkan ketidakseimbangan pada tingkat moderat. Dominasi sentimen netral ini sejalan dengan karakteristik pemberitaan keuangan yang umumnya disusun

secara objektif dan informatif sehingga lebih banyak menggunakan bahasa yang bersifat netral (Malo et al., 2014).

Karena tingkat ketidakseimbangan masih tergolong moderat, penelitian ini tidak menerapkan teknik penyeimbangan data pada tingkat sampel, seperti *oversampling* maupun *undersampling*. Sebagai gantinya, penyesuaian dilakukan pada tingkat fungsi *loss* melalui penerapan *class weighting* berbasis invers frekuensi. Pendekatan ini memberikan bobot yang lebih besar kepada kelas yang jumlah datanya lebih sedikit sehingga kesalahan klasifikasi pada kelas minoritas memperoleh penalti yang lebih besar selama proses pelatihan model (He & Garcia, 2009). Bobot setiap kelas dihitung menggunakan persamaan (26) berikut.

$$w_c = \frac{N}{K \times n_c}$$

Dengan w_c adalah bobot kelas ke-c, N adalah jumlah seluruh data, K adalah jumlah kelas, dan n_c adalah jumlah data pada kelas ke-c. Pada penelitian ini, jumlah data latih yang digunakan adalah sebanyak 7.797 data dengan tiga kelas sentimen (K=3). Bobot kelas netral dihitung dengan mensubstitusikan nilai N=7.797, K=3, dan $n_c=2.887$ ke dalam Persamaan (26), sehingga diperoleh:

$$w_{netral} = \frac{7.797}{3 \times 4401} = 0,7553$$

Berdasarkan persamaan tersebut, diperoleh bobot kelas sebagai berikut.

Tabel 3. Perhitungan Class Weight

Kelas	Frekuensi (n_c)	Proporsi (%)	Bobot Kelas (w_c)
Netral	4.301	44,13	0,7553
Positif	2.887	29,62	1,1256
Negatif	2.559	26,25	1,2697

Sumber: diolah, 2026.

Hasil pada Tabel 3 menunjukkan bahwa kelas negatif memperoleh bobot terbesar, yaitu 1,2697, sedangkan kelas netral memperoleh bobot terkecil, yaitu 0,7553. Hal ini sesuai dengan prinsip invers frekuensi, yaitu semakin sedikit jumlah data suatu kelas, semakin besar bobot yang diberikan pada kelas tersebut. Dengan demikian, kesalahan klasifikasi pada kelas negatif memberikan kontribusi yang lebih besar terhadap nilai *loss* dibandingkan kesalahan pada kelas netral, sehingga model terdorong untuk mempelajari seluruh kelas secara lebih seimbang selama proses *fine-tuning*. Bobot kelas yang diperoleh kemudian diterapkan pada fungsi *cross-entropy loss* selama pelatihan baik pada model *hybrid* LDA-IndoBERT maupun model *baseline* pada *ablation study*, sehingga kedua model dilatih menggunakan skema pembobotan yang sama dan dapat dibandingkan secara adil.

3.2 Pre-Processing Data

Pre-processing (pra-pemrosesan) menjadi tahapan penting sebelum data teks digunakan dalam proses komputasi. Pada penelitian ini, proses pra-pemrosesan dilakukan melalui dua jalur yang berbeda karena metode LDA dan IndoBERT memiliki karakteristik pemrosesan teks yang tidak sama.

3.2.1 *Pre-processing* untuk Jalur LDA

Jalur LDA memerlukan representasi teks dalam bentuk *Bag-of-Words* (BoW), sehingga diperlukan pembersihan teks yang lebih menyeluruh. Tahapan yang diterapkan adalah sebagai berikut.

1. *Case folding*: Seluruh teks dikonversi menjadi huruf kecil (lowercase) agar kata yang memiliki perbedaan kapitalisasi tetap dianggap sebagai token yang sama.
2. *Non-Text character removal*: Tanda baca, simbol khusus, serta angka dihilangkan karena elemen-elemen tersebut tidak memberikan kontribusi signifikan terhadap pembentukan topik pada model probabilistik.
3. *Tokenizing*: Teks kemudian dipecah menjadi token-token individual berdasarkan spasi maupun batas antar kata sehingga setiap dokumen direpresentasikan dalam bentuk daftar token.
4. *Normalization*: Tahapan normalisasi dilakukan menggunakan kamus normalisasi (*normalization dictionary*) yang memetakan token tidak baku ke bentuk standar. Pendekatan berbasis kamus dipilih karena efektif untuk menangani variasi istilah spesifik domain, terutama pada teks media sosial dan berita keuangan yang banyak menggunakan singkatan serta akronim.
5. *Stopword removal*: Token yang termasuk dalam daftar stopwords Bahasa Indonesia dihapus. Stopword adalah kata-kata umum yang muncul dengan frekuensi tinggi namun tidak membawa informasi semantik yang relevan untuk pembentukan topik, seperti "dan", "yang", "di", dan "ke" (Manning et al. 2008).
6. *Stemming*: Setiap token selanjutnya dikonversi ke bentuk kata dasar (root word) menggunakan algoritma Sastrawi yang dikembangkan untuk Bahasa Indonesia. Tahapan ini bertujuan untuk mengurangi variasi morfologis sehingga kata-kata yang berasal dari akar yang sama dapat direpresentasikan sebagai satu token.

Tabel 4. Sampel Data Tahapan *Pre-processing* untuk LDA

Tahapan	Hasil
<i>Judul</i>	Perdagangan Perdana 2024, IHSG Cetak Rekor Baru di 7.323,59
<i>Case Folding</i>	perdagangan perdana 2024, ihsg cetak rekor baru di 7.323,59
<i>Non-Text Character Removal</i>	perdagangan perdana ihsg cetak rekor baru di
<i>Tokenisasi</i>	['perdagangan', 'perdana', 'ihsg', 'cetak', 'rekor', 'baru', 'di']

<i>Normalisasi</i>	['perdagangan', 'perdana', 'indeks harga saham gabungan', 'cetak', 'rekor', 'baru', 'di']
<i>Stopword</i>	['perdagangan', 'perdana', 'indeks harga saham gabungan', 'cetak', 'rekor', 'baru']
<i>Stemming</i>	['dagang', 'perdana', 'indeks harga saham gabung', 'cetak', 'rekor', 'baru']

Sumber: diolah, 2026.

Tabel 4 menampilkan contoh hasil tahapan pre-processing pada data teks sebelum digunakan dalam pemodelan LDA. Setiap tahapan bertujuan untuk membersihkan serta menyederhanakan teks agar menghasilkan representasi kata yang lebih konsisten dan relevan.

Setelah tahap *pre-processing* selesai dilakukan, seluruh dokumen teks dikonversi ke dalam representasi *Bag of Words* (BoW) menggunakan pustaka Gensim. Pada metode ini, setiap dokumen direpresentasikan sebagai kumpulan kata beserta jumlah kemunculan masing-masing kata dalam dokumen tersebut, tanpa memperhatikan urutan kata. Menurut Manning et al., (2008), representasi dokumen dapat dinyatakan di persamaan (1):

$$v(d) = [c(w_1, d), \dots, c(w_{|V|}, d)]$$

di mana pada $c(w_i, d)$ menunjukkan frekuensi kemunculan kata w_i pada dokumen d , sedangkan V menyatakan jumlah seluruh kosakata dalam korpus. Melalui pendekatan ini, setiap dokumen diubah menjadi vektor numerik berdasarkan frekuensi kata.

Sebagai contoh, representasi BoW pada dokumen pertama ditunjukkan sebagai berikut:

['dagang', 'perdana', 'indeks harga saham gabung', 'cetak', 'rekor', 'baru']

Dokumen tersebut menunjukkan bahwa token dengan ID tertentu muncul sebanyak satu kali dalam dokumen. Berdasarkan pemetaan pada dictionary, token tersebut merepresentasikan kata:

- (0, 1) = 'dagang'
- (1, 1) = 'perdana'
- (2, 1) = 'indeks harga saham gabung'
- (3, 1) = 'cetak'
- (4, 1) = 'rekor'
- (5, 1) = 'baru'

Maka representasi BoW dokumen menjadi:

[(0, 1), (1, 1), (2, 1), (3, 1), (4, 1), (5, 1)]

Pada penelitian ini, Gensim digunakan untuk memetakan setiap kata ke indeks numerik tertentu melalui struktur *Dictionary*. Proses ini dilakukan secara otomatis

menggunakan fungsi *doc2bow()*. Fungsi tersebut membaca daftar token pada setiap dokumen, kemudian menghitung jumlah kemunculan masing-masing token dan mengubahnya menjadi format (*token_id*, *frequency*).

3.2.2 Pre-processing untuk Jalur IndoBERT

Berbeda dengan LDA, IndoBERT dirancang untuk memahami konteks bahasa secara langsung melalui mekanisme *self-attention*. Oleh karena itu, proses *pre-processing* pada jalur IndoBERT dilakukan secara lebih minimal agar informasi kontekstual dalam teks tetap terjaga (Devlin et al., 2019). Tahapan yang diterapkan adalah sebagai berikut.

1. *Case folding*: Seluruh teks dikonversi menjadi huruf kecil (lowercase) agar kata yang memiliki perbedaan kapitalisasi tetap dianggap sebagai token yang sama.
2. *Character cleaning*: Karakter non-alfabet, simbol khusus, dan tanda baca dibersihkan dari teks untuk mengurangi noise pada data. Proses ini dilakukan menggunakan regular expression sehingga hanya karakter huruf, angka, dan spasi yang dipertahankan.
3. *WordPiece tokenizing*: Teks yang telah dibersihkan kemudian diproses menggunakan tokenizer berbasis WordPiece dari model indobenchmark/indobert-base-p1. Tokenizer ini memecah kata yang tidak terdapat dalam kosakata menjadi beberapa subword sehingga mampu menangani variasi istilah pada domain keuangan (Koto et al., 2020). Pada tahap ini, tokenizer juga secara otomatis menambahkan token khusus [CLS] di awal sekuens dan [SEP] di akhir sekuens. Token [CLS] (classification token) digunakan sebagai representasi agregat dari seluruh teks yang nantinya dimanfaatkan dalam proses klasifikasi, sedangkan token [SEP] (separator token) berfungsi sebagai penanda akhir sekuens atau pemisah antar kalimat (Devlin et al., 2019).

Tabel 5. Sampel Data Tahapan *Pre-processing* untuk IndoBERT

<i>Tahapan</i>	<i>Hasil</i>
<i>Judul</i>	Perdagangan Perdana 2024, IHSG Cetak Rekor Baru di 7.323,59
<i>Case Folding</i>	perdagangan perdana 2024, ihsg cetak rekor baru di 7.323,59
<i>Character cleaning</i>	perdagangan perdana 2024 ihsg cetak rekor baru di 7 323 59
<i>WordPiece tokenizing</i>	['[CLS]', 'perdagangan', 'perdana', '2024', 'ihsg', 'cetak', 'rekor', 'baru', 'di', '7', '323', '59', '[SEP]']

Sumber: diolah, 2026.

Tabel 5 menampilkan contoh hasil tahapan *pre-processing* pada data teks sebelum digunakan dalam pemodelan IndoBERT. Berbeda dengan jalur LDA, proses *pre-processing* pada IndoBERT dilakukan secara lebih ringan untuk mempertahankan

struktur dan konteks kalimat asli. Hasil akhir pre-processing berupa teks bersih yang kemudian diproses menggunakan tokenizer WordPiece agar dapat dikonversi menjadi representasi numerik yang sesuai untuk model transformer IndoBERT.

3.3 Pemodelan Topik dengan *Latent Dirichlet Allocation* (LDA)

3.3.1 Penentuan Jumlah Topik Optimal (K)

Penentuan jumlah topik K merupakan salah satu tahap terpenting dalam pemodelan LDA karena nilai K secara langsung memengaruhi tingkat detail dan pemisahan aspek yang dapat diekstraksi dari corpus. LDA tidak memiliki mekanisme internal untuk memilih K secara otomatis, sehingga diperlukan kriteria evaluasi eksternal (Blei et al., 2003). Penentuan jumlah topik optimal (K) dilakukan dengan mengevaluasi beberapa kandidat jumlah topik menggunakan metrik *topic coherence*. Pada penelitian ini, pencarian jumlah topik dilakukan menggunakan pendekatan iteratif (*grid search*), yaitu dengan membangun model LDA secara berulang untuk setiap kandidat jumlah topik, mulai dari K=2 hingga K=15. Seluruh model dilatih menggunakan algoritma *Online Variational Bayes* dengan konfigurasi parameter yang sama sehingga perbedaan nilai coherence hanya dipengaruhi oleh variasi jumlah topik. Setelah proses pelatihan selesai, setiap model menghasilkan sekumpulan topik yang kemudian dievaluasi menggunakan metrik C_v Topic Coherence. Nilai C_v dari masing-masing model selanjutnya dibandingkan untuk menentukan jumlah topik yang menghasilkan kualitas topik terbaik.


Evaluasi ini bertujuan untuk mengetahui jumlah topik yang mampu menghasilkan struktur semantik paling konsisten pada korpus berita saham. Satu model LDA dapat menghasilkan lebih dari satu topik, maka kualitas model secara keseluruhan dihitung menggunakan rata-rata nilai coherence seluruh topik dalam persamaan (5):

$$C_v(K) = \frac{1}{K} \sum_k C_v(T^k),$$

Untuk mengamati perubahan kualitas model pada setiap penambahan jumlah topik, dihitung pula selisih coherence antar model menggunakan persamaan (7):

$$\Delta C_v = C_v(K_i) - C_v(K_{i-1})$$

Nilai ΔC_v digunakan untuk melihat apakah penambahan jumlah topik masih memberikan peningkatan kualitas yang signifikan atau mulai mengalami stagnasi. Hasil evaluasi coherence pada seluruh kandidat jumlah topik ditampilkan pada Tabel 6.



Gambar 4. Grafik Jumlah Topik LDA Berdasarkan Nilai *Coherence*

Tabel 6. Nilai *Coherence* Untuk K=2 hingga K=15

K	$C_v(K)$	ΔC_v
2	0.3212	—
3	0.4028	+0.0816
4	0.5121	+0.1093
5	0.4307	-0.0814
6	0.4871	+0.0564
7	0.4825	-0.0046
8	0.4892	+0.0067
9	0.4828	-0.0064
10	0.438	-0.0448
11	0.4237	-0.0143
12	0.4528	+0.0291
13	0.4645	+0.0117
14	0.464	-0.0005
15	0.4755	+0.0115

Sumber: diolah, 2026.

Berdasarkan Gambar 4 dan Tabel 6, nilai coherence mengalami peningkatan yang cukup tajam dari K=2 hingga K=4, yaitu dari 0,3212 menjadi 0,5121. Peningkatan tersebut menunjukkan bahwa penambahan jumlah topik pada rentang tersebut mampu meningkatkan kualitas topik yang dihasilkan model. Nilai coherence tertinggi dicapai pada K=4 dengan skor sebesar 0,5121. Menurut Röder et al., (2015), nilai coherence yang lebih tinggi menunjukkan tingkat keterkaitan semantik antar kata yang lebih baik sehingga topik yang dihasilkan cenderung lebih mudah diinterpretasikan.

Nilai *coherence* menurun menjadi 0,4307 dengan nilai sebesar -0,0814 ketika

jumlah topik ditingkatkan menjadi $K=5$. Penurunan ini merupakan perubahan pertama setelah fase peningkatan yang konsisten dari $K=2$ hingga $K=4$. Pada Gambar 4 terlihat bahwa setelah titik tersebut kurva tidak lagi menunjukkan tren peningkatan yang stabil, melainkan mulai mengalami fluktuasi. Pada rentang $K=6$ hingga $K=15$, nilai *coherence* mengalami kenaikan dan penurunan secara bergantian. Meskipun beberapa nilai *coherence* kembali meningkat, peningkatan tersebut relatif kecil dan tidak mampu melampaui nilai maksimum yang telah dicapai pada $K=4$. Kondisi ini menunjukkan bahwa penambahan jumlah topik setelah $K=4$ tidak lagi memberikan peningkatan kualitas model yang signifikan. Menurut Syed & Spruit, (2017), jumlah topik optimal dapat ditentukan dengan membandingkan nilai *coherence* pada berbagai model dan memilih jumlah topik yang menghasilkan kualitas topik terbaik berdasarkan nilai *coherence* yang diperoleh.

Berdasarkan pola kurva pada Gambar 4, titik *elbow* teridentifikasi pada $K=5$, yaitu titik ketika tren peningkatan *coherence* mulai berhenti dan berubah menjadi penurunan. Dalam analisis kurva *elbow*, titik tersebut menunjukkan bahwa penambahan kompleksitas model setelah titik tersebut tidak lagi menghasilkan peningkatan kualitas yang sebanding. Sementara itu, nilai *coherence* tertinggi diperoleh pada $K=4$. Oleh karena itu, jumlah topik optimal ditetapkan pada $K=4$ karena menghasilkan nilai *coherence* maksimum sekaligus berada tepat sebelum titik *elbow*. Dengan demikian, $K=4$ dianggap mampu memberikan keseimbangan yang lebih baik antara kualitas topik dan kompleksitas model (Röder et al., 2015; Syed & Spruit, 2017).

3.3.2 Pembentukan Model LDA

Model LDA yang dibangun untuk setiap kandidat jumlah topik $K=2$ hingga $K=15$ pada Subbab 3.3.1 hanya digunakan untuk mengevaluasi dan membandingkan nilai topik *coherence* sehingga bersifat sementara dan tidak digunakan pada tahap analisis berikutnya. Setelah jumlah topik optimal ditetapkan sebanyak empat topik ($K=4$), model LDA dibangun kembali menggunakan seluruh korpus dengan jumlah topik tersebut sehingga diperoleh satu model yang digunakan secara konsisten pada seluruh tahapan analisis selanjutnya, mulai dari pembentukan distribusi probabilitas kata dan distribusi probabilitas topik hingga penentuan aspek dominan dokumen.

Model dibangun menggunakan korpus hasil *pre-processing* yang terdiri atas 1.874 token unik setelah proses penyaringan kosakata dengan parameter *no_below*=5 dan *no_above*=0,5. Proses pelatihan dilakukan menggunakan algoritma inferensi *Online Variational Bayes* yang diimplementasikan pada pustaka Gensim dengan 30 *passes* dan 500 *iterations* agar estimasi parameter mencapai kondisi yang stabil. Sementara itu, *hyperparameter prior Dirichlet alpha* dan *beta* ditetapkan menggunakan opsi *auto* sehingga nilainya dioptimalkan secara otomatis berdasarkan karakteristik korpus.

Model yang telah terbentuk menghasilkan dua keluaran utama, yaitu distribusi probabilitas kata pada setiap topik (Φ) dan distribusi probabilitas topik pada setiap dokumen (θ). Pada penelitian ini, distribusi probabilitas kata (Φ) disajikan dan dianalisis untuk menginterpretasikan karakteristik setiap topik. Sementara itu,

distribusi probabilitas topik (θ) digunakan secara internal untuk menentukan topik atau aspek dominan pada setiap dokumen sehingga tidak ditampilkan secara keseluruhan mengingat jumlah dokumen yang cukup besar. Distribusi Φ memuat probabilitas setiap kata terhadap masing-masing topik, sehingga digunakan untuk mengidentifikasi kata-kata yang paling merepresentasikan karakteristik suatu topik. Sementara itu, distribusi θ menunjukkan proporsi setiap topik pada setiap dokumen sehingga menggambarkan tingkat keterlibatan masing-masing topik dalam dokumen tersebut. Dengan demikian, setiap dokumen memiliki satu vektor distribusi topik yang berbeda sesuai hasil inferensi model. Kedua keluaran ini menjadi dasar pada tahapan analisis berikutnya, yaitu analisis distribusi probabilitas kata, analisis distribusi probabilitas topik, interpretasi topik, serta penentuan aspek dominan dokumen.

3.3.3 Distribusi Probabilitas Kata per Topik

Distribusi probabilitas kata menunjukkan peluang kemunculan suatu kata pada topik tertentu. Semakin besar nilai probabilitas suatu kata, semakin besar kontribusi kata tersebut dalam merepresentasikan karakteristik topik yang bersangkutan. Oleh karena itu, kata-kata dengan probabilitas tertinggi pada setiap topik digunakan sebagai representasi utama untuk memahami tema yang dibentuk oleh model LDA. Distribusi probabilitas kata pada setiap topik diperoleh berdasarkan Persamaan (3)

$$\phi_{wk} = \frac{\lambda_{wk}}{\sum_{v=1}^V \lambda_{vk}}$$

Pada penelitian ini, nilai parameter λ diperoleh dari keluaran internal model LDA melalui fungsi `lda_model.state.get_lambda()` pada library Gensim. Selanjutnya, parameter λ dinormalisasi terhadap jumlah seluruh parameter pada topik yang sama sesuai dengan Persamaan (3), sehingga diperoleh distribusi probabilitas kata (ϕ). Nilai probabilitas tersebut menunjukkan peluang kemunculan suatu kata pada topik tertentu dan digunakan untuk menentukan kata-kata yang paling merepresentasikan karakteristik topik.

Sebagai contoh, berdasarkan keluaran model LDA, kata "saham" pada Topik 3 memiliki nilai parameter variational sebesar $\lambda_{wk} = 2.548,342041$, sedangkan jumlah seluruh parameter variational pada topik tersebut adalah $\sum_{v=1}^V \lambda_{vk} = 23.020,433594$. Dengan mensubstitusikan nilai tersebut ke dalam Persamaan (3), diperoleh distribusi probabilitas kata sebagai berikut.

$$\phi_{wk} = \frac{\lambda_{wk}}{\sum_{v=1}^V \lambda_{vk}} = \frac{2.548,342041}{23.020,433594} = 0,110699$$

Hasil perhitungan tersebut menunjukkan bahwa kata "saham" memiliki probabilitas sebesar 0,110699 pada Topik 3. Proses perhitungan yang sama diterapkan pada seluruh kata dalam topik tersebut sehingga diperoleh distribusi probabilitas kata sebagaimana disajikan pada Tabel 7.

Tabel 7. Distribusi Probabilitas Kata Pada Salah Satu Topik Hasil Pemodelan LDA

Rank	Kata (w)	ϕ_{wk}
------	----------	-------------

1	saham	0,11069
2	harga	0,06447
3	indeks	0,04997
4	gabung	0,04887
5	dolar	0,02691
6	rupiah	0,024
7	asing	0,01964
8	buka	0,01672
9	naik	0,013
10	turun	0,01173

Sumber: diolah, 2026.

Berdasarkan Tabel 7, kata saham memiliki probabilitas tertinggi, yaitu sebesar 0,11069. Nilai tersebut menunjukkan bahwa kata saham merupakan kata yang paling dominan dalam topik tersebut dibandingkan kata lainnya. Selanjutnya, kata harga, indeks, gabung, dolar, dan rupiah juga memiliki probabilitas yang relatif tinggi sehingga turut membentuk karakteristik topik. Terlihat bahwa nilai probabilitas mengalami penurunan secara bertahap dari peringkat pertama hingga kesepuluh. Pola ini menunjukkan bahwa distribusi probabilitas tidak tersebar secara merata pada seluruh kata, tetapi lebih terkonsentrasi pada sejumlah kata dominan. Dengan demikian, topik yang dihasilkan memiliki pusat semantik yang jelas sehingga lebih mudah diinterpretasikan pada tahap pelabelan topik.

3.3.4 Validasi Koherensi Topik

Setelah distribusi probabilitas kata pada setiap topik diperoleh sebagaimana ditunjukkan pada Subbab 3.3.3, langkah berikutnya adalah mengevaluasi kualitas semantik dari topik-topik yang dihasilkan. Evaluasi ini dilakukan untuk memastikan bahwa kata-kata dominan pada setiap topik tidak hanya memiliki probabilitas tinggi, tetapi juga memiliki keterkaitan makna yang baik sehingga topik yang terbentuk dapat diinterpretasikan secara konsisten. Perlu ditegaskan bahwa evaluasi pada subbab ini bukan digunakan untuk menentukan kembali jumlah topik optimal, karena jumlah topik telah ditetapkan pada Subbab 3.3.1 menggunakan *CoherenceModel* dari pustaka Gensim. Perhitungan yang dilakukan pada subbab ini bertujuan untuk memvalidasi kualitas topik hasil pemodelan melalui ilustrasi proses perhitungan *Normalized Pointwise Mutual Information* (NPMI) dan nilai *topic coherence* secara manual.

Perhitungan manual menggunakan pendekatan probabilitas pada tingkat dokumen, sedangkan *CoherenceModel* Gensim menggunakan mekanisme sliding window pada keseluruhan korpus, nilai *coherence* yang diperoleh tidak diharapkan identik secara numerik. Namun demikian, kedua pendekatan tersebut diharapkan

memberikan kecenderungan kualitas topik yang konsisten. Tahap pertama adalah menghitung probabilitas kemunculan masing-masing kata dan probabilitas kemunculan bersama setiap pasangan kata. Hasil estimasi probabilitas tersebut disajikan pada Tabel 8.

Tabel 8. Probabilitas Individual dan Probabilitas Bersama Antar Kata

W_i	W_j	$p(W_i)$	$p(W_j)$	$p(w_i, w_j)$
saham	harga	0,199	0,1428	0,1164
saham	indeks	0,199	0,1095	0,1058
saham	gabung	0,199	0,1068	0,1052
harga	indeks	0,1428	0,1095	0,1052
harga	gabung	0,1428	0,1068	0,1052
indeks	gabung	0,1095	0,1068	0,1052
saham	asing	0,199	0,0432	0,0345
Dolar	rupiah	0,0616	0,0559	0,0297
harga	asing	0,01428	0,0432	0,026
:	:	:	:	:
gabung	dolar	0,1068	0,0616	0,0002

Sumber: diolah, 2026.

Berdasarkan Tabel 8, terlihat bahwa probabilitas kemunculan bersama bervariasi antar pasangan kata. Nilai probabilitas kemunculan bersama yang tinggi menunjukkan bahwa dua kata cenderung muncul dalam dokumen yang sama, sedangkan nilai yang rendah menunjukkan bahwa kedua kata jarang muncul secara bersamaan. Pasangan kata saham-harga memiliki probabilitas kemunculan bersama tertinggi, yaitu sebesar 0,1164. Nilai ini menunjukkan bahwa kedua kata sangat sering muncul dalam konteks yang sama pada berita pasar modal. Kondisi tersebut mencerminkan hubungan yang erat antara informasi harga dan aktivitas perdagangan saham yang menjadi fokus utama dalam pemberitaan pasar saham. Pasangan kata saham-indeks, saham-gabung, harga-indeks, harga-gabung, dan indeks-gabung juga memiliki probabilitas kemunculan bersama yang relatif tinggi, yaitu berkisar antara 0,1052 hingga 0,1058. Tingginya nilai tersebut menunjukkan bahwa kata-kata tersebut sering digunakan secara bersamaan. Sebaliknya, pasangan gabungan-dolar hanya sebesar 0,0002. Nilai yang sangat kecil tersebut menunjukkan bahwa kedua pasangan kata relatif jarang muncul secara bersamaan dalam judul berita yang sama. Meskipun masing-masing kata memiliki keterkaitan dengan pasar keuangan, hubungan langsung antar kata dalam korpus berita yang dianalisis tidak sekuat pasangan kata lainnya.

Setelah probabilitas kemunculan individual dan probabilitas kemunculan

bersama diperoleh, langkah berikutnya adalah menghitung nilai *Normalized Pointwise Mutual Information* (NPMI). NPMI digunakan untuk mengukur seberapa besar keterkaitan dua kata dibandingkan jika kedua kata muncul secara independen. Perhitungan NPMI dilakukan menggunakan persamaan (9):

$$NPMI = \frac{\log \frac{p(w_i, w_j)}{p(w_i)p(w_j)}}{-\log p(w_i, w_j)}$$

Berdasarkan Tabel 8 pada pasangan kata saham dan harga diperoleh NPMI:

$$\begin{aligned} NPMI &= \frac{\log(\frac{(0,1164)}{(0,199)(0,1428)})}{-\log(0,1164)} \\ &= \frac{\log(\frac{(0,1164)}{(0,0284)})}{-\log(0,1164)} = \frac{\log(4,0946)}{-\log(0,1164)} = 0,6558 \end{aligned}$$

Pada pasangan kata indeks dan gabung diperoleh NPMI:

$$\begin{aligned} NPMI &= \frac{\log(\frac{(0,1052)}{(0,1095)(0,1068)})}{-\log(0,1052)} \\ &= \frac{\log(\frac{(0,1052)}{(0,0117)})}{-\log(0,1052)} = \frac{\log(8,9932)}{-\log(0,1052)} = 0,9753 \end{aligned}$$

Nilai NPMI sebesar 0,6558 pada pasangan kata saham dan harga menunjukkan bahwa kedua kata memiliki keterkaitan semantik yang cukup tinggi. Hal ini mengindikasikan bahwa pembahasan mengenai harga merupakan bagian yang tidak terpisahkan dari pemberitaan saham, sehingga kedua kata sering muncul dalam konteks yang sama. Keterkaitan tersebut mencerminkan fokus berita pada pergerakan harga saham sebagai indikator utama kondisi pasar modal (Bouma, 2009). Selanjutnya, pasangan kata indeks dan gabung memperoleh nilai NPMI sebesar 0,9753, yang merupakan salah satu nilai tertinggi pada topik ini. Tingginya nilai tersebut menunjukkan bahwa kedua kata hampir selalu muncul secara bersamaan dalam korpus berita. Kondisi ini dapat dijelaskan karena kedua kata merupakan bagian dari istilah Indeks Harga Saham Gabungan (IHSG) yang menjadi indikator utama kinerja pasar saham Indonesia. Oleh karena itu, pasangan kata ini memberikan kontribusi besar terhadap koherensi topik yang terbaik. Sedangkan pada pasangan kata gabung dan dolar diperoleh NPMI:

$$\begin{aligned} NPMI &= \frac{\log(\frac{(0,0002)}{(0,1068)(0,616)})}{-\log(0,0002)} \\ &= \frac{\log(\frac{(0,0002)}{(0,0657)})}{-\log(0,0002)} = \frac{\log 0,0304}{-\log(0,0002)} = -0,4083 \end{aligned}$$

Pasangan kata gabung dan dolar memperoleh nilai NPMI sebesar $-0,4083$. Nilai tersebut menunjukkan bahwa kedua kata relatif jarang muncul dalam konteks yang sama. Meskipun sama-sama berkaitan dengan kondisi ekonomi dan pasar keuangan, pembahasan mengenai IHSG dan nilai tukar dolar dalam korpus yang dianalisis cenderung muncul pada konteks berita yang berbeda sehingga hubungan semantiknya lebih lemah dibandingkan pasangan kata lainnya.

Hasil perhitungan menunjukkan bahwa setiap pasangan kata memiliki nilai NPMI yang berbeda sesuai dengan tingkat keterkaitan semantik antarkata. Pasangan kata yang sering muncul secara bersamaan menghasilkan nilai NPMI positif yang relatif tinggi, sedangkan pasangan kata yang jarang muncul bersama menghasilkan nilai NPMI yang lebih rendah, bahkan dapat bernilai negatif.

Pada penelitian ini, setiap topik direpresentasikan menggunakan 10 kata dengan probabilitas tertinggi ($m = 10$). Pemilihan nilai $m = 10$ didasarkan pada praktik yang umum digunakan dalam evaluasi topic coherence, karena jumlah tersebut dinilai mampu memberikan representasi topik yang memadai sekaligus mengurangi pengaruh kata-kata dengan kontribusi yang rendah. Sepuluh kata utama tersebut membentuk kombinasi pasangan kata yang akan dihitung nilai NPMI-nya. Jumlah pasangan kata dihitung menggunakan kombinasi:

$$\binom{10}{2} = \frac{10!}{2!(10-2)!}$$

$$= 45$$

Artinya, terdapat 45 pasangan kata yang digunakan dalam perhitungan coherence pada setiap topik. Masing-masing dari 45 pasangan kata tersebut kemudian dihitung nilai NPMI-nya. Sebagian hasil perhitungan NPMI ditampilkan pada Tabel 9.

Tabel 9. Nilai NPMI Antar Pasangan Kata Salah Satu Topik

<i>Pasangan kata</i>	<i>NPMI</i>
Saham-harga	0,6558
Saham-indeks	0,7033
Saham-gabung	0,7099
Harga-indeks	0,8463
Harga-gabung	0,8572
Indeks-gabung	0,9753
Dolar-rupiah	0,6121
Saham-asing	0,4124
Harga-asing	0,3935
:	:
Gabung-dolar	-0,4083

Sumber: diolah, 2026.

Berdasarkan hasil perhitungan diperoleh total akumulasi nilai $\sum NPMI = 5,7046$. Nilai ini merupakan total hubungan semantik seluruh pasangan kata dalam topik tersebut. Semakin besar total nilai NPMI, semakin kuat keterkaitan semantik antar kata sehingga topik menjadi lebih koheren. Setelah seluruh nilai *Normalized Pointwise Mutual Information* (NPMI) antar pasangan kata diperoleh, tahap berikutnya adalah menghitung skor *coherence* pada setiap topik. Skor *coherence* digunakan untuk mengukur tingkat konsistensi hubungan semantik antar kata dalam suatu topik. Skor coherence topik dihitung menggunakan rata-rata seluruh nilai NPMI pasangan kata dengan persamaan (6):

$$C_v(T^k) = \frac{2}{m(m-1)} \sum_{i < j} NPMI(w_i, w_j)$$

Karena digunakan $m=10$, maka:

$$\begin{aligned} C_v(T^k) &= \frac{2}{10(10-1)} \sum_{i < j} NPMI(w_i, w_j) \\ &= \frac{2}{90} \times 5,7046 = 0,02222 \times 57046 \\ &= 0,126768 \end{aligned}$$

Nilai coherence sebesar 0,126768 menunjukkan tingkat keterkaitan semantik rata-rata antar kata dalam topik yang terbentuk. Nilai ini digunakan sebagai ukuran koherensi topik dan diinterpretasikan secara relatif dengan membandingkannya terhadap nilai coherence dari jumlah topik lainnya. Semakin tinggi nilai coherence yang diperoleh, semakin baik kualitas topik yang dihasilkan (Röder et al., 2015).

Perhitungan coherence tidak hanya dilakukan pada satu topik, tetapi pada seluruh topik yang dihasilkan model LDA. Setiap topik dihitung menggunakan mekanisme yang sama, yaitu:

1. Menentukan 10 kata utama.
2. Membentuk seluruh pasangan kata.
3. Menghitung NPMI setiap pasangan.
4. Menjumlahkan seluruh nilai NPMI.
5. Menghitung rata-rata nilai NPMI untuk memperoleh skor coherence topik.

Hasil perhitungan coherence pada seluruh topik ditampilkan pada Tabel 10.

Tabel 10. Nilai Coherence pada Setiap Topik

<i>Topik</i>	$\sum NPMI$	$C_v(T^k)$
1	3,5537	0,078972
2	4,5880	0,101956
3	5,7046	0,126768
4	11,0953	0,246562

Sumber: diolah, 2026.

Berdasarkan Tabel 10, nilai coherence yang diperoleh pada setiap topik menunjukkan adanya variasi tingkat koherensi antar topik. Topik 4 memiliki nilai coherence tertinggi, yaitu sebesar 0,246562, diikuti oleh Topik 3 sebesar 0,126768 dan Topik 2 sebesar 0,101956. Sementara itu, Topik 1 memperoleh nilai coherence terendah, yaitu 0,078972. Hasil tersebut menunjukkan bahwa Topik 4 memiliki konsistensi kata yang paling baik dibandingkan topik lainnya, sedangkan Topik 1 merupakan topik dengan konsistensi kata yang paling rendah. Nilai coherence positif pada semua Topik mengindikasikan bahwa sebagian besar pasangan kata dalam topik-topik tersebut memiliki asosiasi semantik yang cenderung positif.

Perhitungan manual pada subbab ini bertujuan untuk memperlihatkan mekanisme pembentukan nilai topic coherence berdasarkan pasangan kata penyusun topik. Adapun penentuan jumlah topik optimal pada penelitian ini tetap mengacu pada nilai *CoherenceModel* yang dihitung menggunakan pustaka Gensim sebagaimana telah dibahas pada Subbab 3.3.1.

3.3.5 Interpretasi Topik dan Pelabelan Aspek

Interpretasi topik dilakukan secara manual berdasarkan kata-kata yang memiliki probabilitas tertinggi pada setiap topik, hubungan semantik antarkata, serta konteks berita saham dan pasar modal Indonesia. Pada penelitian ini, model LDA dengan jumlah topik optimal $K=4$ menghasilkan empat topik utama yang merepresentasikan tema-tema dominan dalam korpus berita saham. Setiap topik kemudian diberi label aspek berdasarkan tema yang paling sesuai dengan karakteristik kata-kata dominannya. Hasil interpretasi topik dan pelabelan aspek disajikan pada Tabel 11.

Tabel 11. Interpretasi Topik dan Pelabelan Aspek

<i>Topik</i>	<i>Kata Dominan & (ϕ_{wk})</i>	<i>Max(ϕ_{wk})</i>	<i>Label Aspek</i>
1	Daftar(0,03486) , usaha(0,0305), bursa(0,02834), jadi(0,0262), laba(0,02013), kaya(0,01951), orang(0,0144), harta(0,01256), sosok(0,0109), raja(0,01031)	0,03486	Aktivitas Perusahaan dan Tokoh Bisnis
2	Bank(0,09260) , negara(0,02879), usaha(0,01651), milik(0,01619), rakyat(0,01606),	0,09260	Sektor Perbankan dan BUMN

	jadi(0,01465), badan(0,01443), siap(0,0114), emas(0,00896), bos(0,00896)		
3	Saham(0,11069) , harga(0,06448), indeks(0,04997), gabung(0,04887), dolar(0,02691), rupiah(0,024), asing(0,01965), buka(0,01672), naik(0,013), turun(0,01173)	0,11069	Pergerakan Pasar Saham dan Nilai Tukar
4	Uang(0,5815) , jasa(0,04115), otoritas(0,03973), buka(0,02512), soal(0,01684), bos(0,01665), umum(0,0159), suara(0,01321), tawar(0,01207), perdana(0,0118)	0,05815	Regulasi dan Pengawasan Sektor Keuangan

Sumber: diolah, 2026.

Berdasarkan Tabel 11, model LDA menghasilkan empat topik yang masing-masing memiliki kelompok kata dominan dengan karakteristik yang berbeda. Pelabelan topik dilakukan secara manual berdasarkan keterkaitan semantik antar kata dominan serta konteks kemunculannya dalam korpus berita. Menurut Blei et al., (2003), setiap topik dalam LDA direpresentasikan oleh distribusi probabilitas kata, sehingga kata-kata dengan probabilitas tertinggi dapat digunakan untuk mengidentifikasi tema utama yang terkandung dalam suatu topik.


Topik 1 memiliki kata dominan daftar, usaha, bursa, jadi, laba, kaya, orang, harta, sosok, raja. Kehadiran kata-kata tersebut menunjukkan pembahasan yang berkaitan dengan aktivitas perusahaan, kinerja keuangan, serta keterlibatan perusahaan di pasar modal, sehingga topik ini diberi label *Aktivitas Perusahaan dan Tokoh Bisnis*. Topik 2 didominasi oleh kata bank, negara, usaha, milik, rakyat, jadi, badan, siap, emas, bos. Kata-kata tersebut banyak berkaitan dengan institusi perbankan dan aktivitas yang berhubungan dengan Badan Usaha Milik Negara (BUMN). Berdasarkan karakteristik tersebut, topik ini dilabeli *Sektor Perbankan dan BUMN*. Topik 3 memuat kata saham, harga, indeks, gabung, dolar, rupiah, asing,

buka, naik, turun. Kombinasi kata tersebut secara langsung menggambarkan aktivitas pasar modal dan pergerakan nilai tukar. Selain itu, kemunculan kata indeks dan gabung mengarah pada istilah Indeks Harga Saham Gabungan (IHSG), yang merupakan indikator utama kinerja pasar saham Indonesia. Berdasarkan hal tersebut, topik ini diberi label *Pergerakan Pasar Saham dan Nilai Tukar*. Selanjutnya, Topik 4 didominasi oleh kata uang, jasa, otoritas, dan tawar, yang menunjukkan keterkaitan dengan lembaga pengawas sektor jasa keuangan dan aktivitas regulasi, sehingga topik ini diberi label *Regulasi dan Pengawasan Sektor Keuangan*.

Ditinjau dari nilai $Max(\phi_{wk})$, Topik 3 memiliki nilai tertinggi sebesar 0,11069, diikuti oleh Topik 2 sebesar 0,0926 dan Topik 4 sebesar 0,0582. Nilai tersebut menunjukkan probabilitas kemunculan kata dominan tertinggi pada masing-masing topik. Sebaliknya, Topik 1 memiliki nilai $Max(\phi_{wk})$ terendah, yaitu 0,0349. Kondisi ini menunjukkan bahwa probabilitas kata pada Topik 1 lebih tersebar dibandingkan topik lainnya sehingga tidak terdapat satu kata yang memiliki dominasi yang kuat dalam merepresentasikan topik tersebut.

3.3.6 Distribusi Aspek dan Penerapan Ambang Batas Probabilitas

Setelah setiap topik diinterpretasikan dan diberi label aspek sebagaimana dijelaskan pada Subbab 3.3.5, tahap berikutnya adalah menentukan aspek dominan pada setiap dokumen berdasarkan probabilitas topik tertinggi yang dihasilkan model LDA. Untuk memastikan bahwa aspek yang diperoleh memiliki tingkat keyakinan yang memadai, diterapkan ambang batas probabilitas (*threshold*) sebesar 0,20. Hasil penelitian menunjukkan bahwa seluruh dokumen memiliki probabilitas topik dominan di atas nilai ambang tersebut sehingga tidak terdapat dokumen yang dieliminasi. Dengan demikian, seluruh 9.747 dokumen dipertahankan dan digunakan pada tahap analisis selanjutnya. Distribusi dokumen pada setiap aspek disajikan pada Tabel 12.



Gambar 5. Distribusi Aspek (kiri) dan Distribusi Probabilistik Topik Dominan dengan Ambang Batas (kanan)

Gambar 5 panel kanan menunjukkan histogram distribusi nilai *max_prob* seluruh dokumen. Terlihat bahwa sangat sedikit dokumen berada di bawah threshold 0,20 (garis merah putus-putus), artinya hampir seluruh dokumen memiliki topik dominan yang cukup kuat dan dapat dipertahankan dalam analisis ABSA.

Tabel 12. Distribusi Frekuensi Aspek Setelah Penentuan Topik Dominan

<i>Aspek</i>	<i>Frekuensi</i>	<i>Persentase (%)</i>	<i>Rata-rata max_prob</i>
Sektor Perbankan dan BUMN	3.055	31,34	0,7029
Pergerakan Pasar Saham dan Nilai Tukar	2.830	29,03	0,7723
Regulasi dan Pengawasan Sektor Keuangan	2.031	20,84	0,6736
Aktivitas Perusahaan dan Tokoh Bisnis	1.831	18,79	0,6794

Sumber: diolah, 2026.

Berdasarkan Tabel 12 dan Gambar 5, distribusi dokumen pada setiap aspek hasil pemodelan topik menunjukkan bahwa aspek *Sektor Perbankan dan BUMN* memiliki frekuensi tertinggi, yaitu sebanyak 3.055 dokumen atau 31,34% dari keseluruhan korpus. Posisi berikutnya ditempati oleh aspek *Pergerakan Pasar Saham dan Nilai Tukar* dengan 2.830 dokumen atau 29,03%. Kedua aspek tersebut merupakan aspek dengan jumlah dokumen terbesar dan secara bersama-sama mencakup lebih dari separuh dokumen yang dianalisis, yaitu sekitar 60,37%. Aspek *Regulasi dan Pengawasan Sektor Keuangan* memiliki frekuensi sebesar 2.031 dokumen atau 20,84%, Sementara aspek *Aktivitas Perusahaan dan Tokoh Bisnis* memiliki frekuensi terkecil, yaitu sebesar 1.831 dokumen atau 18,79%. Hasil ini menunjukkan bahwa keempat aspek hasil pemodelan LDA seluruhnya muncul dengan proporsi yang relatif seimbang dalam korpus, tanpa ada satu aspek yang mendominasi secara ekstrem.

Selain distribusi frekuensi aspek, Gambar 5 memperlihatkan distribusi nilai *max_prob*, yaitu probabilitas topik dominan pada setiap dokumen. Sebagian besar dokumen memiliki nilai *max_prob* yang berada pada rentang sekitar 0,4 hingga 0,9. Hal ini menunjukkan bahwa pada sebagian besar dokumen terdapat satu topik yang memiliki probabilitas lebih tinggi dibandingkan topik lainnya sehingga dapat ditetapkan sebagai topik dominan. Garis vertikal merah pada nilai 0,2 menunjukkan batas minimum (*threshold*) yang digunakan dalam proses evaluasi topik dominan. Berdasarkan histogram, hanya sebagian kecil dokumen yang berada di sekitar batas tersebut, sedangkan mayoritas dokumen memiliki nilai *max_prob* yang jauh lebih tinggi. Kondisi ini mengindikasikan bahwa sebagian besar dokumen dapat diklasifikasikan ke dalam aspek dominan dengan probabilitas yang relatif jelas. Gambar 5 juga konsisten dengan nilai rata-rata *max_prob* pada Tabel 12. Aspek *Pergerakan Pasar Saham dan Nilai Tukar* memiliki nilai rata-rata tertinggi sebesar 0,7723, yang menunjukkan bahwa dokumen-dokumen pada aspek ini memiliki tingkat dominasi topik yang paling kuat dibandingkan aspek lainnya. Aspek *Sektor Perbankan dan BUMN* berada pada posisi berikutnya dengan rata-rata *max_prob* sebesar 0,7029, diikuti oleh *Aktivitas Perusahaan dan Tokoh Bisnis* sebesar 0,6794

dan *Regulasi dan Pengawasan Sektor Keuangan* sebesar 0,6736.

Seluruh dokumen memiliki probabilitas topik dominan di atas ambang batas sebesar 0,20 sehingga tidak terdapat dokumen yang dieliminasi pada tahap penentuan aspek. Hasil ini menunjukkan bahwa model LDA mampu menghasilkan representasi aspek yang jelas pada seluruh dokumen dalam korpus. Oleh karena itu, hasil pelabelan aspek yang diperoleh layak digunakan sebagai masukan pada tahap klasifikasi sentimen menggunakan model *hybrid* LDA-IndoBERT.

3.4 Klasifikasi Sentimen dengan Model *Hybrid* LDA-IndoBERT

Setelah setiap dokumen memperoleh label aspek dominan melalui pemodelan LDA, tahap berikutnya adalah melakukan klasifikasi sentimen menggunakan model *hybrid* LDA-IndoBERT. Model ini menggabungkan informasi aspek hasil pemodelan topik dengan representasi kontekstual yang dihasilkan oleh IndoBERT melalui pendekatan *feature-level fusion*. Integrasi tersebut bertujuan agar model tidak hanya memahami konteks semantik dari teks, tetapi juga memanfaatkan informasi topik sebagai representasi aspek dalam proses klasifikasi sentimen. Sebelum proses pelatihan model dilakukan, terlebih dahulu ditentukan skema pembagian data yang akan digunakan. Pemilihan skema pembagian data bertujuan memperoleh model dengan kemampuan generalisasi yang baik terhadap data yang belum pernah dilihat sebelumnya. Oleh karena itu, dilakukan eksperimen pendahuluan terhadap beberapa skema pembagian data latih, validasi, dan uji. Hasil perbandingan disajikan pada Tabel 13.

Tabel 13. Perbandingan Skema Pembagian Data Uji

Skema Split	N Train	N Val	N Test	Support Negative (Test)	Accuracy	F1-macro
80:10:10	7.797	975	975	256	0,9046	0,9051
70:10:20	6.822	975	1.950	512	0,8928	0,8932
70:20:10	6.822	1.950	975	256	0,8872	0,8872
60:20:20	5.847	1.950	1.950	512	0,8903	0,8909

Sumber: diolah, 2026.

Berdasarkan Tabel 13, skema pembagian data 80:10:10 menghasilkan kinerja terbaik pada tahap uji cepat dengan nilai accuracy sebesar 0,9046 dan *F1-macro* sebesar 0,9051. Nilai tersebut lebih tinggi dibandingkan tiga skema pembagian data lainnya. Hasil ini menunjukkan bahwa proporsi data latih yang lebih besar memberikan informasi yang lebih memadai bagi model untuk mempelajari pola sentimen tanpa mengurangi representativitas data validasi dan data uji. Atas dasar tersebut, skema pembagian 80:10:10 dipilih sebagai konfigurasi akhir dan digunakan secara konsisten pada seluruh tahapan eksperimen, baik pada pelatihan model *hybrid* LDA-IndoBERT maupun pada model pembanding (baseline) dalam ablation study. Dengan skema tersebut, data dibagi menjadi 7.797 data latih, 975 data validasi, dan 975 data uji.

3.4.1 Konfigurasi Model dan Parameter Pelatihan

Model klasifikasi sentimen pada penelitian ini menggunakan pendekatan *hybrid* yang menggabungkan representasi kontekstual dokumen dari IndoBERT dengan distribusi topik hasil pemodelan *Latent Dirichlet Allocation* (LDA). Representasi kontekstual diperoleh dari keluaran token [CLS] pada IndoBERT, sedangkan distribusi topik diperoleh dari hasil inferensi LDA. Kedua representasi tersebut digabungkan melalui pendekatan *feature-level fusion* sehingga menghasilkan satu vektor fitur yang memuat informasi semantik dan informasi topikal secara bersamaan. Vektor hasil penggabungan selanjutnya digunakan sebagai masukan pada lapisan klasifikasi untuk memprediksi sentimen dokumen. Model bahasa yang digunakan adalah IndoBERT varian *indobenchmark/indobert-base-p1* yang dikembangkan oleh (Koto et al., 2020). Model ini dipilih karena telah dilatih pada korpus bahasa Indonesia berskala besar sehingga mampu menghasilkan representasi kontekstual yang sesuai dengan karakteristik bahasa Indonesia. Informasi aspek diperoleh dari model LDA dengan jumlah topik optimal sebanyak empat topik yang telah ditentukan melalui evaluasi nilai *topic coherence* dan analisis kurva *elbow* pada tahap sebelumnya. Sebelum proses pelatihan dilakukan, ditetapkan sejumlah parameter yang mengatur proses pemodelan topik maupun proses *fine-tuning* IndoBERT. Konfigurasi parameter yang digunakan dalam penelitian ini disajikan pada Tabel 14.

Tabel 14. Konfigurasi Parameter Model LDA-IndoBERT

<i>Parameter</i>	<i>Nilai</i>	<i>Keterangan</i>
Model IndoBERT	indobenchmark/indobert-base-p1	Model bahasa pralatih yang digunakan untuk menghasilkan representasi kontekstual dokumen berbahasa Indonesia.
K Topik LDA	4	Jumlah topik optimal hasil evaluasi nilai coherence dan analisis kurva elbow.
Threshold Aspek (θ)	0,20	Batas minimum probabilitas topik dominan untuk penentuan aspek dokumen.
<i>Max Length Tokenizer</i>	128	Jumlah maksimum token yang diproses untuk setiap dokumen.
<i>Batch Size</i>	16	Jumlah sampel yang diproses dalam satu iterasi pelatihan.

<i>Learning Rate</i>	2×10^{-5}	Laju pembelajaran pada proses <i>fine-tuning</i> .
<i>Weight Decay</i>	0,01	Parameter regularisasi untuk mengurangi risiko overfitting.
<i>Num Epochs</i>	10	Jumlah maksimum siklus pelatihan yang dilakukan pada data latih.
<i>Early Stopping Patience</i>	3	Jumlah epoch tanpa peningkatan performa validasi sebelum pelatihan dihentikan.
<i>LDA Passes</i>	30	Jumlah pengulangan korpus dalam proses pelatihan model LDA.
<i>LDA Iterations</i>	500	Jumlah iterasi optimasi pada setiap pass pelatihan LDA.
<i>LDA Alpha</i>	auto	Parameter distribusi topik per dokumen yang dioptimasi secara otomatis oleh model.
<i>LDA Beta (β)</i>	auto (β aktual = 0,01)	Parameter distribusi kata per topik yang dioptimasi otomatis oleh model dengan nilai akhir 0,01.
<i>BoW no_below</i>	5	Kata yang muncul kurang dari lima dokumen dihapus dari kosakata.
<i>BoW no_above</i>	0,5	Kata yang muncul pada lebih dari 50% dokumen dihapus dari kosakata.
<i>Split Config</i>	80 : 10 : 10	Proporsi pembagian data menjadi data latih, validasi, dan data uji.

Sumber: diolah, 2026.

Berdasarkan Tabel 14, proses *fine-tuning* IndoBERT menggunakan *learning rate* sebesar 2×10^{-5} , *batch size* sebesar 16, dan jumlah maksimum pelatihan sebanyak 10 *epoch*. Konfigurasi tersebut dipilih karena umum digunakan pada

proses *fine-tuning* model BERT dan mampu menghasilkan proses pembelajaran yang stabil. Untuk mengurangi risiko *overfitting*, diterapkan *weight decay* sebesar 0,01 serta mekanisme *early stopping* dengan nilai *patience* sebanyak 3 epoch, sehingga pelatihan dihentikan apabila kinerja model pada data validasi tidak lagi mengalami peningkatan.

Pada tahap pemodelan topik, model LDA menggunakan empat topik dengan 30 *passes* dan 500 *iterations* agar proses pembelajaran model mencapai kondisi yang stabil. *Hyperparameter* α dan β dioptimasi secara otomatis oleh Gensim sehingga distribusi topik pada dokumen dan distribusi kata pada setiap topik dapat menyesuaikan karakteristik data. Hasil optimasi menghasilkan nilai β aktual sebesar 0,01, yang menghasilkan distribusi kata yang lebih terpusat pada sejumlah kata dominan sehingga topik yang terbentuk lebih mudah diinterpretasikan. Selain itu, penyaringan kosakata dilakukan menggunakan parameter *no_below* = 5 dan *no_above* = 0,5 untuk menghilangkan kata yang terlalu jarang maupun terlalu sering muncul sehingga kualitas topik yang dihasilkan menjadi lebih baik.

3.4.2 Mekanisme Eksekusi Model

Setelah seluruh parameter model ditetapkan, proses selanjutnya adalah pelaksanaan klasifikasi sentimen menggunakan model hybrid LDA-IndoBERT. Pada tahap ini, setiap dokumen diproses secara bertahap mulai dari pembentukan representasi kontekstual oleh IndoBERT, penggabungan distribusi topik hasil LDA, hingga menghasilkan prediksi sentimen. Rangkaian proses tersebut diuraikan melalui delapan tahapan berikut.

Langkah 1: Pembentukan Embedding Input

Tahap pertama dimulai dengan mengubah setiap judul berita menjadi representasi numerik yang dapat diproses oleh model IndoBERT. Sebelum memasuki *encoder transformer*, setiap dokumen terlebih dahulu ditokenisasi menggunakan *WordPiece Tokenizer* dengan panjang maksimum 128 token sesuai konfigurasi model. Token khusus [CLS] ditempatkan pada awal sekuens sebagai representasi keseluruhan dokumen, sedangkan token [SEP] ditempatkan pada akhir sekuens sebagai penanda akhir kalimat. Setelah proses tokenisasi selesai, setiap token direpresentasikan sebagai penjumlahan token embedding, segment embedding, dan position embedding sebagaimana dinyatakan pada Persamaan (14). Hasil penjumlahan ketiga komponen tersebut menghasilkan matriks representasi masukan $E_{input} \in \mathbb{R}^{n \times 768}$ yang menjadi input bagi encoder IndoBERT.

Langkah 2: Pembentukan Representasi Kontekstual dengan *Multi-Head Self-Attention*

Representasi awal E_{input} Kemudian diproses oleh mekanisme *Multi-Head Self-Attention*. Pada setiap head dihitung nilai perhatian menggunakan Persamaan (11),

$$Attention(Q, K, V) = softmax \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Pada penelitian ini digunakan model IndoBERT bertipe BERT-base yang

memiliki 12 *attention head* sehingga $d_k = 64$. Matriks Q, K, dan V diperoleh dari proyeksi linier terhadap E_{input} . Nilai attention pada persamaan tersebut menunjukkan tingkat kontribusi setiap token terhadap token lainnya dalam satu dokumen. Selanjutnya keluaran seluruh head digabungkan menggunakan Persamaan (12),

$$MHSA(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2 \dots, \text{head}_h)W^o$$

dengan masing-masing *head* dihitung menggunakan Persamaan (13),

$$\text{head}_i = \text{Attention}(XW_i^Q, XW_i^K, XW_i^V).$$

Melalui mekanisme ini diperoleh representasi kontekstual yang mempertimbangkan hubungan antartoken secara menyeluruh sehingga informasi semantik dokumen dapat dipelajari secara lebih baik.

Langkah 3 : Ekstraksi Representasi Dokumen dari IndoBERT

Setelah seluruh lapisan encoder Transformer selesai diproses, diperoleh representasi kontekstual untuk setiap token pada lapisan terakhir. Pada penelitian ini, representasi dokumen diambil dari keluaran token khusus [CLS] sebagaimana dinyatakan pada Persamaan (16),

$$h_{CLS} = H_0^{(L)}$$

Pada persamaan tersebut, $H_0^{(L)}$ menyatakan representasi token [CLS] pada lapisan encoder ke-L, yaitu lapisan encoder terakhir pada arsitektur IndoBERT. Karena penelitian ini menggunakan arsitektur BERT-base yang terdiri atas 12 *encoder*, maka nilai $L=12$. Dengan demikian, $H_0^{(12)}$ merupakan representasi kontekstual akhir yang telah mengintegrasikan informasi dari seluruh token dalam judul berita.

Hasil ekstraksi tersebut berupa vektor

$$h_{CLS} \in \mathbb{R}^{768},$$

yang digunakan sebagai representasi semantik dokumen secara keseluruhan. Vektor ini selanjutnya menjadi salah satu masukan utama pada proses penggabungan fitur dengan distribusi topik hasil LDA.

Langkah 4: Inferensi Distribusi Topik Dokumen

Setelah model LDA selesai dilatih, setiap dokumen diinferensi untuk memperoleh distribusi probabilitas topik θ_d sebagaimana didefinisikan pada Persamaan (4),

$$\theta_d = P(z|d)$$

Pada pendekatan Online Variational Bayes, distribusi topik dokumen diperoleh melalui proses inferensi variational. Secara konseptual, proses tersebut menghasilkan parameter variational γ_{dk} untuk setiap topik pada dokumen. Parameter tersebut kemudian dinormalisasi untuk memperoleh distribusi probabilitas topik:

$$\theta_{dk} = \frac{\gamma_{dk}}{\sum_{j=1}^K \gamma_{dj}}$$

dengan γ_{dk} merupakan parameter variational untuk topik k pada dokumen d , sedangkan K merupakan jumlah topik yang digunakan. Karena penelitian ini menggunakan $K=4$, maka setiap dokumen memiliki empat nilai probabilitas topik yang membentuk vektor:

$$\theta_d = (\theta_{d1}, \theta_{d2}, \theta_{d3}, \theta_{d4})$$

Nilai θ_d tersebut diperoleh melalui fungsi `get_document_topics()` pada model LDA yang telah dilatih. Fungsi tersebut melakukan inferensi terhadap representasi Bag-of-Words dari dokumen menggunakan parameter model LDA yang telah diestimasi pada tahap pelatihan, sehingga menghasilkan probabilitas keterlibatan masing-masing topik pada dokumen.

Setiap dokumen memiliki nilai probabilitas pada seluruh topik sehingga aspek dominan ditentukan berdasarkan topik yang memiliki probabilitas terbesar. Penentuan aspek dominan dilakukan menggunakan operator `argmax` pada persamaan (12) sebagai berikut:

$$\theta_{d,dominan} = \arg \max_k \theta_{dk}$$

dengan θ_{dk} adalah topik ke- k pada dokumen d .

Tabel 15. Contoh Distribusi Probabilitas Topik pada Dokumen

Judul Dokumen	θ_1	θ_2	θ_3	θ_4	Aspek Dominan
Direktur Garuda Salman El Farisiy Meninggal, Ini Sosoknya!	0,8605	0,0554	0,0454	0,0387	Aktivitas Perusahaan dan Tokoh Bisnis
Ramalan Bitcoin Paling Gila 2024, Naik 1.000% Jadi US\$500.000	0,0255	0,6877	0,2593	0,0276	Sektor Perbankan dan BUMN
Asing Diam-Diam Borong 10 Saham Ini Kala IHSG Ambruk Pekan Lalu	0,0124	0,0192	0,9549	0,0135	Pergerakan Pasar Saham dan Nilai Tukar
Bos OJK Sebut PP Hapus Tagih Kredit Macet UMKM Tak Butuh POJK Turunan	0,0116	0,019	0,0151	0,9543	Regulasi dan Pengawasan Sektor Keuangan

Sumber: diolah, 2026.

Berdasarkan Tabel 15, ketiga contoh dokumen menunjukkan bahwa setiap dokumen memiliki distribusi probabilitas topik yang berbeda sesuai isi berita. Dokumen pertama memiliki probabilitas terbesar pada Topik 1 sebesar 0,8605 sehingga diklasifikasikan ke dalam aspek Aktivitas Perusahaan dan Tokoh Bisnis. Dokumen kedua memiliki probabilitas terbesar pada Topik 2 sebesar 0,6877 sehingga dikategorikan ke dalam aspek Sektor Perbankan dan BUMN. Hasil ini menunjukkan bahwa model LDA tidak hanya menghasilkan satu topik untuk setiap dokumen, tetapi memberikan distribusi probabilitas pada seluruh topik, kemudian aspek dominan ditentukan berdasarkan probabilitas terbesar melalui operator argmax .

Langkah 5: Penggabungan Representasi IndoBERT dan Distribusi Topik

Setelah diperoleh representasi kontekstual dokumen dari IndoBERT berupa vektor h_{CLS} serta distribusi probabilitas topik dokumen θ_d , kedua representasi tersebut digabungkan melalui operasi konkatenasi (*concatenation*) sebagaimana dirumuskan pada Persamaan (16), yaitu

$$h_{final} = \text{Concat}[h_{cls}; \theta^d]$$

dengan

$$h_{CLS} \in \mathbb{R}^{768+K}$$

Karena penelitian ini menggunakan empat topik ($K=4$), maka hasil konkatenasi menghasilkan vektor berdimensi $768+4= 772$.

Dengan demikian,

$$h_{final} \in \mathbb{R}^{772}$$

Apabila suatu dokumen memiliki representasi kontekstual

$$h_{CLS} = [h_1, h_2, \dots, h_{768}]$$

Dan distribusi topik

$$\theta_d = [0,8605, 0,0554, 0,0454, 0,0387]$$

maka hasil penggabungannya menjadi

$$h_{final} = [h_1, h_2, \dots, h_{768}, 0,8605, 0,0554, 0,0454, 0,0387].$$

Empat komponen terakhir merupakan informasi mengenai proporsi keterlibatan setiap topik pada dokumen, sedangkan 768 komponen pertama merupakan representasi kontekstual hasil IndoBERT. Vektor gabungan ini selanjutnya digunakan sebagai masukan pada tahap normalisasi fitur sebelum dilakukan proses klasifikasi sentimen.

Langkah 6: Normalisasi Vektor Fitur Gabungan

Setelah diperoleh vektor fitur gabungan h_{final} melalui operasi concatenation

pada Langkah 5, tahap berikutnya adalah melakukan normalisasi menggunakan *Layer Normalization* sebagaimana dinyatakan pada Persamaan (17). Proses ini bertujuan untuk menyesuaikan skala nilai pada setiap komponen vektor sehingga representasi hasil penggabungan memiliki distribusi yang lebih stabil sebelum diproses oleh lapisan klasifikasi.

Pada penelitian ini, vektor h_{final} terdiri atas representasi kontekstual IndoBERT berdimensi 768 dan distribusi topik LDA berdimensi 4, sehingga memiliki total dimensi sebesar 772. Kedua representasi tersebut berasal dari model yang berbeda dan memiliki karakteristik nilai yang tidak sama. Representasi h_{CLS} merupakan hasil transformasi bertingkat pada encoder IndoBERT, sedangkan θ_d merupakan distribusi probabilitas topik yang seluruh elemennya berada pada rentang 0 hingga 1 dengan jumlah probabilitas sama dengan satu. Perbedaan karakteristik tersebut menyebabkan kedua representasi memiliki distribusi numerik yang berbeda. Oleh karena itu, *Layer Normalization* diterapkan agar setiap komponen pada vektor h_{final} berada pada skala yang lebih seimbang. Dengan demikian, representasi kontekstual dari IndoBERT maupun informasi topik dari LDA dapat memberikan kontribusi yang proporsional pada proses klasifikasi sentimen.

Hasil normalisasi berupa vektor h_{norm} tetap memiliki dimensi 772. Dengan kata lain, proses *Layer Normalization* tidak mengubah ukuran vektor, tetapi hanya menyesuaikan distribusi nilai setiap komponennya sehingga proses pembelajaran pada lapisan klasifikasi menjadi lebih stabil.

Langkah 7: Klasifikasi Sentimen

Setelah diperoleh vektor hasil normalisasi h_{norm} , tahap berikutnya adalah melakukan klasifikasi sentimen menggunakan lapisan linear yang diikuti fungsi softmax sebagaimana dinyatakan pada Persamaan (18). Pada tahap ini, vektor h_{norm} diproyeksikan ke ruang keluaran yang terdiri atas tiga kelas sentimen, yaitu positif, negatif, dan netral. Selanjutnya, fungsi softmax mengubah hasil proyeksi tersebut menjadi distribusi probabilitas sehingga setiap dokumen memperoleh peluang untuk masing-masing kelas sentimen.

Pada penelitian ini, proses klasifikasi dilakukan terhadap seluruh dokumen pada data latih, data validasi, dan data uji. Untuk setiap dokumen, dihasilkan tiga nilai probabilitas yang masing-masing merepresentasikan peluang dokumen termasuk ke dalam kelas positif, negatif, dan netral. Label sentimen kemudian ditentukan berdasarkan probabilitas terbesar (*argmax*), sehingga setiap dokumen hanya memiliki satu kelas prediksi. Hasil prediksi tersebut selanjutnya digunakan untuk menghitung fungsi loss selama proses pelatihan serta dievaluasi menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score* pada tahap pengujian.

Langkah 8: Perhitungan Loss dan Pembaruan Bobot

Setelah label prediksi diperoleh pada Langkah 7, tahap berikutnya adalah menghitung nilai fungsi loss dengan membandingkan probabilitas hasil prediksi terhadap label sentimen aktual menggunakan *weighted cross-entropy loss*. Pada penelitian ini, pembobotan kelas diterapkan untuk mengatasi ketidakseimbangan distribusi data sentimen sehingga setiap kelas memberikan kontribusi yang

proporsional selama proses pelatihan.

Bobot kelas yang digunakan diperoleh berdasarkan distribusi data pada tahap prapemrosesan, yaitu sebesar 1,1256 untuk kelas positif, 1,2697 untuk kelas negatif, dan 0,7553 untuk kelas netral. Dengan pembobotan tersebut, kesalahan prediksi pada kelas negatif memberikan kontribusi loss yang lebih besar dibandingkan kelas netral karena jumlah data negatif lebih sedikit. Sebaliknya, kelas netral yang memiliki jumlah data terbesar memperoleh bobot lebih kecil sehingga tidak mendominasi proses pembelajaran model. Nilai *loss* yang diperoleh selanjutnya digunakan dalam proses *backpropagation* untuk menghitung gradien terhadap seluruh parameter model. Gradien tersebut kemudian dimanfaatkan oleh *optimizer AdamW* untuk memperbarui bobot model pada setiap batch hingga seluruh epoch pelatihan selesai atau mekanisme *early stopping* menghentikan proses pelatihan ketika performa validasi tidak lagi meningkat.

3.4.3 Proses Pelatihan dan Kurva Training

Proses pelatihan model dilakukan menggunakan skema pembagian data 80:10:10 yang terdiri atas data latih, data validasi, dan data uji. Selama proses pelatihan, model dilatih dengan maksimum 10 *epoch* menggunakan mekanisme *early stopping* dengan nilai *patience* sebesar 3. Mekanisme tersebut memungkinkan proses pelatihan dihentikan secara otomatis apabila nilai *validation F1-macro* tidak mengalami peningkatan selama tiga epoch berturut-turut.

Nilai *loss* pada setiap batch diperoleh menggunakan *weighted cross-entropy loss* sesuai Persamaan (31):

$$L = -\frac{1}{N} \sum_{i=1}^N w_{ci} \log(p(y_i = c_i | d_i))$$

Karena dalam satu epoch terdapat beberapa batch, nilai *loss* pada tingkat epoch tidak diambil dari satu batch tertentu, tetapi dihitung sebagai rata-rata seluruh *loss batch* dalam epoch tersebut sesuai Persamaan (32):

$$L_{epoch} = -\frac{1}{B} \sum_{b=1}^B L_b$$

Dengan demikian, Training Loss merupakan rata-rata *loss* dari seluruh batch pada data latih dalam satu epoch. Sementara itu, Validation Loss diperoleh dengan cara yang sama pada data validasi, tetapi tanpa pembaruan parameter model melalui *backpropagation*.

Berbeda dengan *loss*, nilai Train F1 dan Validation F1 diperoleh berdasarkan hasil prediksi model pada seluruh data dalam masing-masing subset pada akhir setiap epoch. Prediksi kelas diperoleh dari probabilitas keluaran softmax dengan memilih kelas yang memiliki probabilitas terbesar sesuai persamaan (22):

$$y = \underset{c}{\operatorname{arg\,max}} p(y = c | d)$$

Selanjutnya, seluruh prediksi dibandingkan dengan label aktual untuk membentuk confusion matrix. Dari confusion matrix tersebut dihitung *precision* dan *recall* untuk masing-masing dari tiga kelas sentimen, yaitu positif, negatif, dan netral.


Perkembangan nilai *training loss*, *validation loss*, *train F1-macro*, dan *validation*

F1-macro pada setiap epoch disajikan pada Tabel 16, sedangkan pola perubahannya ditunjukkan pada Gambar 6.

Tabel 16. Perkembangan Training Loss, Validation Loss, Train F1, dan Val F1

<i>Epoch</i>	<i>Train Loss</i>	<i>Val Loss</i>	<i>Train F1</i>	<i>Val F1</i>
1	0,673547	0,417698	0,684027	0,83494
2	0,334026	0,308059	0,8702771	0,876765
3	0,175404	0,429295	0,944021	0,888185
4	0,090158	0,534652	0,973966	0,892337
5	0,048407	0,725386	0,988923	0,889929
6	0,018444	0,798582	0,994817	0,900219
7	0,013584	0,851317	0,996706	0,897883
8	0,00568	0,824879	0,998474	0,898067
9	0,002217	0,864386	0,99949	0,899963

Sumber: diolah, 2026.



Gambar 6. Kurva Pembelajaran Model Hybrid LDA-IndoBERT

Berdasarkan Tabel 16 dan Gambar 6, nilai *training loss* mengalami penurunan secara konsisten dari 0,6735 pada epoch pertama menjadi 0,0022 pada epoch ke-9. Penurunan tersebut diikuti oleh peningkatan *train F1-macro* dari 0,6840 menjadi 0,9995. Hasil ini menunjukkan bahwa proses *fine-tuning* berhasil meningkatkan kemampuan model dalam mempelajari pola-pola yang terdapat pada data latih sehingga kesalahan prediksi selama pelatihan semakin kecil. Pada data validasi, *validation loss* mengalami penurunan pada dua epoch awal, yaitu dari 0,4177 menjadi 0,3081. Setelah itu, nilai *validation loss* meningkat secara bertahap hingga mencapai 0,8644 pada epoch ke-9. Peningkatan *validation loss* tersebut menunjukkan bahwa model mulai menyesuaikan diri secara lebih spesifik terhadap data latih. Meskipun demikian, *validation F1-macro* tetap berada pada kisaran 0,89–0,90 dan mencapai nilai tertinggi sebesar 0,9002 pada epoch ke-6. Kondisi ini menunjukkan bahwa meskipun nilai *loss* pada data validasi meningkat, kemampuan


model dalam mengklasifikasikan data validasi tetap terjaga dengan baik. Pola tersebut juga terlihat pada Gambar 6. Kurva *training loss* menunjukkan tren penurunan yang stabil sepanjang proses pelatihan, sedangkan kurva *validation loss* mulai meningkat setelah epoch kedua. Sebaliknya, kurva *train F1-macro* terus meningkat hingga mendekati nilai satu, sementara *validation F1-macro* meningkat pada beberapa *epoch* awal kemudian relatif stabil hingga akhir pelatihan. Pola ini mengindikasikan bahwa model telah mencapai kondisi konvergen sehingga penambahan epoch tidak lagi memberikan peningkatan kemampuan klasifikasi yang signifikan pada data validasi.

Perbedaan pola antara *training loss* yang terus menurun dan *validation loss* yang cenderung meningkat menunjukkan bahwa penurunan nilai loss tidak selalu diikuti oleh peningkatan kemampuan generalisasi model. Oleh karena itu, penelitian ini menggunakan *validation F1-macro* sebagai kriteria utama dalam menentukan model terbaik karena metrik tersebut memberikan gambaran yang lebih representatif mengenai keseimbangan kemampuan klasifikasi pada seluruh kelas sentimen dibandingkan hanya menggunakan nilai *validation loss*.

Berdasarkan hasil pelatihan, nilai *validation F1-macro* tertinggi sebesar 0,9002 diperoleh pada epoch ke-6. Oleh karena itu, parameter model pada epoch tersebut dipilih sebagai model terbaik dan selanjutnya digunakan pada tahap pengujian menggunakan data uji. Pemilihan model berdasarkan performa validasi bertujuan memperoleh model yang memiliki kemampuan generalisasi terbaik terhadap data yang belum pernah digunakan selama proses pelatihan.

3.4.4 Evaluasi Kinerja Model dan Analisis Confusion Matrix

Evaluasi kinerja model dilakukan menggunakan data uji (test set) yang tidak terlibat selama proses pelatihan maupun validasi. Tujuan evaluasi ini adalah mengukur kemampuan generalisasi model dalam mengklasifikasikan sentimen pada data yang belum pernah dilihat sebelumnya.



Gambar 7. Confusion Matrix Model Hybrid LDA-IndoBERT

Berdasarkan Gambar 7, dari 289 dokumen dengan label aktual positif, sebanyak 257 dokumen berhasil diprediksi dengan benar sebagai positif, sedangkan 6 dokumen diprediksi sebagai negatif dan 26 dokumen diprediksi sebagai netral. Dengan demikian, untuk kelas positif diperoleh *True Positive* (TP) sebesar 257, yaitu dokumen yang aktual dan diprediksi sebagai positif. *False Negative* (FN) sebesar 32 diperoleh dari 6 dokumen positif yang diprediksi sebagai negatif dan 26 dokumen positif yang diprediksi sebagai netral. Sementara itu, *False Positive* (FP) sebesar 22 diperoleh dari 3 dokumen aktual negatif dan 19 dokumen aktual netral yang diprediksi sebagai positif. Dengan demikian, ketiga komponen untuk kelas positif adalah $TP=257$, $FN=32$, dan $FP=22$.

Pada kelas negatif, dari 256 dokumen aktual negatif, sebanyak 233 dokumen berhasil diklasifikasikan dengan benar sebagai negatif, sementara 3 dokumen diprediksi sebagai positif dan 20 dokumen diprediksi sebagai netral. Oleh karena itu, TP untuk kelas negatif adalah 233, FN sebesar 23 diperoleh dari 3 dokumen negatif yang diprediksi sebagai positif dan 20 dokumen negatif yang diprediksi sebagai netral, dan FP sebesar 31 berasal dari 6 dokumen aktual positif dan 25 dokumen aktual netral yang diprediksi sebagai negatif. Dengan demikian, diperoleh $TP=233$, $FN=23$, dan $FP=31$ untuk kelas negatif.

Adapun pada kelas netral, dari 430 dokumen aktual netral, sebanyak 386 dokumen berhasil diprediksi dengan benar sebagai netral, sedangkan 19 dokumen diprediksi sebagai positif dan 25 dokumen diprediksi sebagai negatif. Dengan demikian, TP untuk kelas netral adalah 386, FN sebesar 44 diperoleh dari 19 dokumen netral yang diprediksi sebagai positif dan 25 dokumen yang diprediksi sebagai negatif, dan FP sebesar 46 berasal dari 26 dokumen aktual positif dan 20

dokumen aktual negatif yang diprediksi sebagai netral. Dengan demikian, diperoleh TP=386, FN=44, dan FP=46 untuk kelas netral.

Kinerja model dievaluasi menggunakan metrik *precision*, *recall*, dan *F1-score* untuk setiap kelas sentimen, serta *macro average* dan *weighted average* sebagai ukuran performa keseluruhan. Nilai *precision*, *recall*, dan *F1-score* diperoleh berdasarkan nilai pada confusion matrix pada Gambar 7. Untuk setiap kelas c, terlebih dahulu ditentukan *True Positive* (TP), *False Positive* (FP), dan *False Negative* (FN).

Berdasarkan confusion matrix, ketiga komponen untuk kelas positif adalah TP=257, FN=32, dan FP=22. Berdasarkan nilai tersebut, *precision* kelas positif dihitung menggunakan persamaan (24):

$$Precision = \frac{TP}{TP + FP} = \frac{257}{257 + 22} = \frac{257}{279} = 0,9211$$

Selanjutnya, *recall* kelas positif menggunakan persamaan (25):

$$Recall = \frac{TP}{TP + FN} = \frac{257}{257 + 32} = \frac{257}{289} = 0,8893$$

Kemudian, *F1-score* kelas positif dihitung menggunakan persamaan (26):

$$F1 = \frac{2PR}{P + R} = \frac{2(0,9211)(0,8893)}{0,9211 + 0,8893} = 0,9049$$

Selanjutnya, *macro F1-score* diperoleh dengan menghitung rata-rata aritmetika dari *F1-score* pada kelas positif, negatif, dan netral. Karena *macro average* memberikan bobot yang sama pada setiap kelas, jumlah data pada masing-masing kelas tidak digunakan sebagai pembobot.

$$F1_{macro} = \frac{F1_{positif} + F1_{negatif} + F1_{netral}}{3} = \frac{0,9049 + 0,8962 + 0,8956}{3} = 0,8989$$

Berbeda dengan *macro F1-score*, *weighted F1-score* memperhitungkan jumlah data atau support pada masing-masing kelas sebagai bobot. *weighted F1-score* dihitung menggunakan persamaan (28):

$$F1_{weighted} = \sum \frac{|S_c|}{N} F1_c$$

$N = 289 + 256 + 430 = 975$, sehingga

$$F1_{weighted} = \frac{(289 \times 0,9049) + (256 \times 0,8963) + (430 \times 0,8956)}{975} = 0,8985$$

Hasil evaluasi disajikan pada Tabel 17.

Tabel 17. Hasil Evaluasi Klasifikasi Model Hybrid LDA-IndoBERT

Kelas / Metrik	Precision	Recall	F1-Score	Support
positive	0,9211	0,8893	0,9049	289
negative	0,8826	0,9102	0,8962	256
neutral	0,8935	0,8977	0,8956	430
Accuracy			0,8985	975

macro avg	0,8991	0,8990	0,8989	975
weighted avg	0,8988	0,8985	0,8985	975

Sumber: diolah, 2026.

Berdasarkan Tabel 17, model *Hybrid* LDA-IndoBERT memperoleh akurasi sebesar 0,8985 (89,85%), dengan *macro precision* sebesar 0,8991, *macro recall* sebesar 0,8990, dan *macro F1-score* sebesar 0,8989. Selain itu, model memperoleh *weighted precision* sebesar 0,8988, *weighted recall* sebesar 0,8985, dan *weighted F1-score* sebesar 0,8985. Kedekatan nilai *macro average* dan *weighted average* menunjukkan bahwa performa model relatif konsisten pada seluruh kelas sentimen, sehingga tidak terdapat perbedaan kinerja yang signifikan antar kelas (Sokolova & Lapalme, 2009). Ditinjau dari masing-masing kelas, sentimen positif memperoleh *precision* sebesar 0,9211, *recall* sebesar 0,8893, dan *F1-score* sebesar 0,9049. Nilai tersebut menunjukkan bahwa model memiliki tingkat ketepatan yang tinggi dalam memprediksi sentimen positif, meskipun masih terdapat beberapa dokumen positif yang diklasifikasikan ke kelas lain. Pada kelas negatif, model memperoleh *precision* sebesar 0,8826, *recall* sebesar 0,9102, dan *F1-score* sebesar 0,8962, yang menunjukkan bahwa sebagian besar dokumen negatif berhasil dikenali meskipun masih terdapat prediksi negatif yang berasal dari kelas lain. Sementara itu, kelas netral memperoleh *precision* sebesar 0,8935, *recall* sebesar 0,8977, dan *F1-score* sebesar 0,8956. Nilai *precision*, *recall*, dan *F1-score* pada ketiga kelas yang relatif berdekatan menunjukkan bahwa model memiliki kemampuan yang cukup baik dan seimbang dalam mengidentifikasi berbagai kategori sentimen.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa model *Hybrid* LDA-IndoBERT mampu mengklasifikasikan sentimen berita keuangan ke dalam kelas positif, negatif, dan netral dengan performa yang baik. Hal ini ditunjukkan oleh akurasi sebesar 89,85%, nilai *precision*, *recall*, dan *F1-score* pada setiap kelas yang berada di kisaran 0,88–0,92, serta dominasi prediksi yang benar pada diagonal utama *confusion matrix*. Selain itu, kedekatan nilai *macro F1-score* (0,8989) dan *weighted F1-score* (0,8985) mengindikasikan bahwa performa model relatif konsisten pada seluruh kelas sentimen yang dievaluasi.

3.5 Analisis Sentimen Berbasis Topik (Topic-Guided ABSA)

Setelah aspek dominan setiap dokumen diperoleh melalui pemodelan *Latent Dirichlet Allocation* (LDA) sebagaimana dijelaskan pada Subbab 3.3 dan proses klasifikasi sentimen dilakukan pada Subbab 3.4, tahap berikutnya adalah menganalisis distribusi sentimen pada masing-masing aspek tematik. Pada penelitian ini, aspek diperoleh dari topik-topik hasil LDA yang telah diinterpretasikan secara manual, sedangkan label sentimen berasal dari dataset yang digunakan dalam proses klasifikasi. Dengan demikian, setiap dokumen memiliki satu aspek dominan dan satu label sentimen, sehingga distribusi sentimen dapat dianalisis untuk setiap aspek yang

terbentuk.

Distribusi sentimen pada setiap aspek diperoleh dengan mengelompokkan seluruh dokumen berdasarkan aspek dominan, kemudian menghitung jumlah dokumen pada masing-masing kategori sentimen, yaitu positif, negatif, dan netral. Selain jumlah dan persentase sentimen, disajikan pula nilai rata-rata probabilitas topik dominan (*Average Dominant Topic Probability*, AvgP) untuk menunjukkan tingkat kejelasan representasi aspek pada dokumen-dokumen yang termasuk ke dalam aspek tersebut. AvgP dihitung menggunakan persamaan (13):

$$AvgP = \frac{1}{n} \sum_{d=1}^n \theta_{d,dominan}$$


dengan n menyatakan jumlah dokumen pada suatu kelompok, sedangkan $\theta_{d,dominan}$ merupakan probabilitas topik dominan pada dokumen ke-d.

Hasil analisis sentimen berbasis aspek disajikan pada Tabel 18.

Tabel 18. Matriks Distribusi Sentimen per Aspek

Aspek	Pos	Neg	Net	Pos %	Neg %	Net %	Total	AvgP
Aktivitas Perusahaan dan Tokoh Bisnis	447	295	1.089	24,41	16,11	59,48	1.831	0,6794
Sektor Perbankan dan BUMN	942	457	1.656	30,83	14,96	54,21	3.055	0,7029
Pergerakan Pasar Saham dan Nilai Tukar	1.133	1.354	343	40,04	47,84	12,12	2.830	0,7723
Regulasi dan Pengawasan Sektor Keuangan	340	459	1.232	16,74	22,60	60,66	2.031	0,6736

Sumber: diolah, 2026.



Gambar 8. Distribusi Sentimen per Aspek

Berdasarkan Tabel 18 dan Gambar 8, aspek *Aktivitas Perusahaan dan Tokoh Bisnis* didominasi oleh sentimen netral sebanyak 1.089 dokumen (59,48%), diikuti oleh sentimen positif sebanyak 447 dokumen (24,41%) dan sentimen negatif sebanyak 295 dokumen (16,11%). Dominasi sentimen netral menunjukkan bahwa pemberitaan pada aspek ini lebih banyak berisi informasi mengenai aktivitas perusahaan, laporan keuangan, maupun profil tokoh bisnis yang disajikan secara deskriptif tanpa kecenderungan opini yang kuat. Aspek *Sektor Perbankan dan BUMN* juga didominasi oleh sentimen netral, yaitu sebanyak 1.656 dokumen (54,21%). Sentimen positif menempati urutan kedua dengan 942 dokumen (30,83%), sedangkan sentimen negatif berjumlah 457 dokumen (14,96%). Proporsi sentimen positif yang relatif lebih tinggi dibandingkan aspek lainnya mengindikasikan bahwa pemberitaan mengenai *sektor perbankan dan BUMN* lebih sering memuat informasi mengenai kinerja perusahaan, ekspansi usaha, maupun kebijakan yang dipersepsikan memberikan dampak positif terhadap sektor tersebut. Pada aspek *Regulasi dan Pengawasan Sektor Keuangan*, sentimen netral merupakan kategori yang paling dominan dengan 1.232 dokumen (60,66%), diikuti sentimen negatif sebesar 22,60% dan sentimen positif sebesar 16,74%. Dominasi sentimen netral pada aspek ini sejalan dengan karakteristik berita mengenai regulasi, kebijakan pemerintah, maupun pengumuman resmi dari otoritas yang umumnya disampaikan secara informatif dan objektif.

Berbeda dengan aspek lainnya, *Pergerakan Pasar Saham dan Nilai Tukar* menjadi satu-satunya aspek yang didominasi oleh sentimen negatif, yaitu sebesar 47,84%, lebih tinggi dibandingkan sentimen positif (40,04%) maupun sentimen netral (12,12%). Dominasi ini menunjukkan bahwa pemberitaan mengenai fluktuasi pasar saham dan nilai tukar lebih banyak berkaitan dengan kondisi pasar yang kurang menguntungkan, seperti penurunan indeks, pelemahan nilai tukar, maupun ketidakpastian ekonomi. Meskipun demikian, proporsi sentimen positif pada aspek ini juga relatif tinggi sehingga menunjukkan bahwa dinamika pasar tetap mencakup berita yang memberikan optimisme terhadap kondisi pasar. Selain memiliki proporsi sentimen negatif tertinggi, aspek *Pergerakan Pasar Saham dan Nilai Tukar* juga memiliki nilai rata-rata probabilitas topik dominan (AvgP) tertinggi, yaitu 0,7723. Nilai

tersebut menunjukkan bahwa dokumen-dokumen pada aspek ini memiliki keterkaitan tematik yang paling kuat dibandingkan aspek lainnya. Temuan ini sejalan dengan penelitian Tetlock (2007) yang menunjukkan bahwa sentimen negatif dalam berita keuangan berkaitan erat dengan dinamika pasar modal, serta konsisten *dengan Efficient Market Hypothesis* bentuk setengah kuat yang dikemukakan oleh Fama (1970), di mana informasi publik mengenai kondisi pasar akan segera direspons oleh pelaku pasar.

Visualisasi pada Gambar 8 memperjelas perbedaan karakteristik sentimen antar aspek. Warna abu-abu yang mendominasi pada tiga aspek menunjukkan tingginya proporsi sentimen netral, sedangkan warna merah pada aspek *Pergerakan Pasar Saham dan Nilai Tukar* tampak paling dominan dibandingkan aspek lainnya. Perbedaan pola tersebut menunjukkan bahwa kecenderungan sentimen dalam berita saham tidak tersebar secara merata pada seluruh aspek, melainkan dipengaruhi oleh tema pembahasan yang terkandung dalam berita.

Secara keseluruhan, hasil analisis pada Tabel 18 dan Gambar 8 menunjukkan bahwa pendekatan *topic-guided sentiment analysis* mampu memberikan informasi yang lebih komprehensif dibandingkan analisis sentimen pada tingkat dokumen. Dengan memanfaatkan hasil pemodelan topik LDA, penelitian ini tidak hanya mengidentifikasi polaritas sentimen suatu berita, tetapi juga mengungkap aspek-aspek tematik yang paling banyak diasosiasikan dengan sentimen positif, negatif, maupun netral. Informasi tersebut memberikan interpretasi yang lebih mendalam mengenai karakteristik pemberitaan saham di Indonesia serta menunjukkan bahwa kecenderungan sentimen negatif terutama terkonsentrasi pada aspek *Pergerakan Pasar Saham dan Nilai Tukar*, sedangkan aspek lainnya lebih didominasi oleh penyampaian informasi yang bersifat netral.

3.6 Ablation Study: Kontribusi Fitur Topik LDA terhadap Kinerja Klasifikasi

Studi ablasi (*ablation study*) dilakukan untuk mengevaluasi kontribusi distribusi topik hasil *Latent Dirichlet Allocation* (LDA) terhadap kinerja klasifikasi sentimen. Pada eksperimen ini, model *Hybrid* LDA-IndoBERT dibandingkan dengan model baseline berupa *Fine-tuned* IndoBERT yang hanya menggunakan representasi kontekstual dari token [CLS] tanpa penambahan fitur distribusi topik LDA. Perbandingan dilakukan menggunakan data latih, data validasi, dan data uji yang sama serta konfigurasi parameter pelatihan yang identik sehingga perbedaan kinerja yang diperoleh hanya disebabkan oleh keberadaan fitur topik LDA.

3.6.1 Pelatihan Model Baseline (Fine-tuned IndoBERT Tanpa Topik)

Model baseline menggunakan arsitektur IndoBERT yang sama dengan model hybrid, namun tanpa proses feature fusion. Dengan demikian, lapisan klasifikasi hanya menerima representasi kontekstual dokumen yang dihasilkan oleh token [CLS] pada lapisan encoder terakhir. Seluruh parameter pelatihan, seperti learning rate, batch size, jumlah epoch maksimum, mekanisme early stopping, serta konfigurasi pembagian data dibuat sama dengan model Hybrid LDA-IndoBERT agar hasil perbandingan bersifat objektif. Perkembangan proses pelatihan model baseline

disajikan pada Tabel 19.

Tabel 19. Perkembangan Pelatihan Model Baseline (Fine-tuned IndoBERT)

Epoch	Train Loss	Val Loss	Train F1	Val F1
1	0,6499	0,4882	0,7013	0,8077
2	0,3240	0,2950	0,8807	0,8844
3	0,1611	0,4297	0,9450	0,8884
4	0,0819	0,5320	0,9768	0,9089
5	0,0418	0,8008	0,9874	0,8926
6	0,0233	0,7799	0,9953	0,9036
7	0,0097	0,8183	0,9971	0,8941

Sumber: diolah, 2026.

Berdasarkan Tabel 19, *training loss* mengalami penurunan secara konsisten dari 0,6499 pada epoch pertama menjadi 0,0097 pada epoch ketujuh. Penurunan tersebut diikuti oleh peningkatan *train F1-macro* dari 0,7013 menjadi 0,9971, yang menunjukkan bahwa model semakin mampu mempelajari pola pada data latih. Pada data validasi, nilai *validation F1-macro* meningkat hingga mencapai nilai tertinggi sebesar 0,9089 pada epoch ke-4. Setelah epoch tersebut, nilai *validation F1-macro* tidak lagi mengalami peningkatan selama tiga epoch berturut-turut, sehingga mekanisme *early stopping* menghentikan proses pelatihan secara otomatis pada epoch ketujuh. Oleh karena itu, parameter model pada epoch ke-4 dipilih sebagai model baseline terbaik untuk tahap pengujian.

Selanjutnya, model terbaik dievaluasi menggunakan data uji yang terdiri atas 975 dokumen. Hasil evaluasi disajikan pada Tabel 20.

Tabel 20. Hasil Evaluasi Klasifikasi Model Baseline Fine-Tuned IndoBERT

Kelas / Metrik	Precision	Recall	F1-Score	Support
Positive	0,8882	0,9343	0,9106	289
Negative	0,9055	0,8984	0,9020	256
Neutral	0,9161	0,8884	0,9020	430
Accuracy			0,9046	975
Macro avg	0,9032	0,9070	0,9049	975
Weighted avg	0,9050	0,9046	0,9045	975

Sumber: diolah, 2026.

Berdasarkan Tabel 20, model Fine-tuned IndoBERT memperoleh *accuracy* sebesar 0,9046, *macro F1-score* sebesar 0,9049, dan *weighted F1-score* sebesar 0,9045. Ditinjau berdasarkan masing-masing kelas sentimen, model memperoleh F1-score sebesar 0,9106 untuk kelas positif, 0,9020 untuk kelas negatif, dan 0,9020 untuk kelas netral. Hasil tersebut menunjukkan bahwa model baseline memiliki

kemampuan klasifikasi yang baik dan relatif seimbang pada ketiga kelas sentimen.

3.6.2 Pelatihan perbandingan Model Baseline dan Model Hybrid

Setelah kedua model dievaluasi menggunakan data uji yang sama, dilakukan perbandingan terhadap beberapa metrik evaluasi untuk mengetahui pengaruh penambahan distribusi topik LDA terhadap performa klasifikasi sentimen. Hasil perbandingan kedua model disajikan pada Tabel 21.

Tabel 21. Perbandingan Kinerja Model Baseline dan Model Hybrid

<i>Model</i>	<i>Accuracy</i>	<i>Precision (macro)</i>	<i>Recall (macro)</i>	<i>F1-macro</i>	<i>F1-weighted</i>
Model 1: <i>Fine-tuned</i> IndoBERT (input: judul)	0,9046	0,9032	0,9070	0,9049	0,9045
Model 2: <i>Hybrid</i> LDA-IndoBERT (input: $h_{cls}; \theta_d$)	0,8985	0,8991	0,8990	0,8989	0,8985
Selisih (Model 1 – Model 2)	+0,0061	+0,0041	+0,0080	+0,0060	+0,0060

Sumber: diolah, 2026.

Berdasarkan Tabel 21, model *Fine-tuned* IndoBERT memperoleh *accuracy* sebesar 0,9046, sedangkan model *Hybrid* LDA-IndoBERT memperoleh *accuracy* sebesar 0,8985. Perbedaan tersebut menghasilkan selisih sebesar 0,0061 atau sekitar 0,61 poin persentase. Hasil yang serupa juga terlihat pada metrik *macro F1-score*, yaitu 0,9049 pada model *baseline* dan 0,8989 pada model *hybrid*, dengan selisih sebesar 0,0060. Pada metrik *weighted F1-score*, model *baseline* memperoleh nilai 0,9045, sedangkan model *hybrid* memperoleh nilai 0,8985, sehingga terdapat selisih sebesar 0,0060. Selain itu, nilai *precision* dan *recall* rata-rata pada model *baseline* juga sedikit lebih tinggi dibandingkan model *hybrid*.

Secara keseluruhan, hasil studi ablasi menunjukkan bahwa penambahan distribusi topik LDA sebagai fitur tambahan belum mampu meningkatkan kinerja klasifikasi sentimen pada dataset yang digunakan dalam penelitian ini. Sebaliknya, model *Fine-tuned* IndoBERT tanpa fitur topik memperoleh performa yang sedikit lebih tinggi pada seluruh metrik evaluasi. Salah satu faktor yang dapat memengaruhi hasil tersebut adalah karakteristik data yang digunakan berupa judul berita yang relatif singkat. Pada dokumen dengan panjang teks yang terbatas, representasi kontekstual yang dihasilkan oleh IndoBERT diduga telah mampu menangkap informasi semantik yang relevan untuk proses klasifikasi sentimen, sehingga informasi tambahan berupa distribusi topik LDA belum memberikan peningkatan performa yang berarti. Meskipun demikian, hasil studi ablasi ini tidak mengurangi kontribusi LDA dalam penelitian. Sebagaimana ditunjukkan pada Subbab 3.3, model LDA berhasil mengidentifikasi empat aspek tematik yang merepresentasikan struktur topik pada korpus berita saham Indonesia. Aspek-aspek tematik tersebut kemudian

menjadi dasar dalam analisis sentimen berbasis topik (*topic-guided sentiment analysis*) yang dibahas pada Subbab 3.5. Dengan demikian, kontribusi utama LDA dalam penelitian ini bukan terletak pada peningkatan kinerja klasifikasi sentimen, melainkan pada kemampuannya dalam mengungkap struktur tematik korpus sehingga analisis sentimen dapat dilakukan berdasarkan aspek yang lebih spesifik.

3.7 Pembahasan

Berdasarkan hasil analisis yang telah dilakukan pada seluruh tahapan penelitian, pendekatan yang mengintegrasikan pemodelan topik menggunakan *Latent Dirichlet Allocation* (LDA) dan klasifikasi sentimen berbasis IndoBERT mampu memberikan gambaran yang lebih komprehensif mengenai karakteristik berita saham Indonesia. Model LDA berhasil mengidentifikasi jumlah topik optimal sebanyak empat topik dengan nilai *coherence* tertinggi sebesar 0,5121, yang diperoleh melalui pola kenaikan tajam dari K=2 hingga K=4 sebelum akhirnya melandai dan berfluktuasi pada K=5 hingga K=15 tanpa pernah melampaui nilai tersebut. Pola kenaikan yang kemudian melandai ini merupakan ciri kurva *elbow* yang umum dijadikan pertimbangan dalam menentukan jumlah topik pada pemodelan LDA. Keempat topik tersebut kemudian diinterpretasikan sebagai empat aspek tematik utama, yaitu *Aktivitas Perusahaan dan Tokoh Bisnis*, *Sektor Perbankan dan BUMN*, *Pergerakan Pasar Saham dan Nilai Tukar*, serta *Regulasi dan Pengawasan Sektor Keuangan*. Interpretasi ini didasarkan pada kata-kata dominan yang saling berkaitan secara tematik pada tiap topik, misalnya kemunculan kata indeks dan gabung yang mengarah langsung pada istilah Indeks Harga Saham Gabungan, atau kata bank, negara, dan rakyat yang mengarah pada tema perbankan dan Badan Usaha Milik Negara. Pelabelan tema ini dilakukan secara manual oleh peneliti berdasarkan kata-kata dominan tersebut, sehingga hasilnya bersifat kualitatif dan belum melalui proses validasi oleh pihak lain.

Perhitungan manual NPMI turut mendukung validitas nilai *coherence* yang diperoleh dari *CoherenceModel* Gensim, karena pasangan kata yang secara intuitif berkaitan erat, seperti indeks dan gabung, menghasilkan nilai NPMI yang tinggi, sedangkan pasangan kata yang secara tematik lebih jauh, seperti gabung dan dolar, menghasilkan nilai yang jauh lebih rendah bahkan negatif. Dari sisi distribusi dokumen ke dalam tiap aspek, keempat aspek muncul dengan proporsi yang relatif seimbang, berkisar antara 18,79 persen hingga 31,34 persen, tanpa satu aspek yang mendominasi secara ekstrem. Nilai rata-rata probabilitas topik dominan pada seluruh aspek juga berada pada rentang yang cukup tinggi, menunjukkan bahwa topik dominan pada tiap dokumen cukup jelas terbedakan dari topik lainnya, sehingga penentuan aspek berdasarkan probabilitas topik tertinggi dapat dipertanggungjawabkan secara metodologis.

Berdasarkan analisis sentimen berbasis aspek, diperoleh bahwa distribusi sentimen berbeda pada setiap aspek. Tiga aspek, yaitu *Aktivitas Perusahaan dan Tokoh Bisnis*, *Sektor Perbankan dan BUMN*, serta *Regulasi dan Pengawasan Sektor Keuangan*, didominasi oleh sentimen netral dengan proporsi di atas 54 persen, yang sejalan dengan karakteristik pemberitaan keuangan yang cenderung disusun secara

objektif dan informatif sehingga lebih banyak menggunakan bahasa yang bersifat netral dibandingkan opini yang eksplisit. Meskipun demikian, ketiga aspek ini tetap menunjukkan karakter yang berbeda pada proporsi sentimen kedua terbesarnya. *Aspek Sektor Perbankan dan BUMN* misalnya memiliki proporsi sentimen positif sebesar 30,83 persen, lebih tinggi dibandingkan proporsi negatifnya yang hanya 14,96 persen, sedangkan aspek *Regulasi dan Pengawasan Sektor Keuangan* menunjukkan pola sebaliknya, dengan proporsi sentimen negatif sebesar 22,60 persen yang lebih tinggi dibandingkan proporsi positifnya sebesar 16,74 persen. Perbedaan pola ini menunjukkan bahwa meskipun ketiganya sama-sama didominasi sentimen netral, karakter pemberitaan pada tiap aspek tetap memiliki kecenderungan yang berbeda satu sama lain. Penjelasan mengenai penyebab perbedaan pola ini, misalnya kaitannya dengan jenis peristiwa yang diberitakan pada masing-masing aspek, belum ditelusuri lebih lanjut pada penelitian ini dan memerlukan analisis konten tambahan pada penelitian berikutnya.

Sebaliknya, aspek *Pergerakan Pasar Saham dan Nilai Tukar* memiliki proporsi sentimen negatif yang paling tinggi, yaitu sebesar 47,84 persen, sekaligus rata-rata probabilitas topik dominan tertinggi dibandingkan aspek lainnya. Kombinasi kedua angka ini menunjukkan bahwa dokumen pada aspek ini tidak hanya paling banyak bermuatan negatif, tetapi juga paling jelas secara tematik, dalam artian topik yang dibahas pada dokumen tersebut sangat terfokus pada isu pasar dan nilai tukar tanpa tercampur topik lain. Temuan ini konsisten dengan hasil Tetlock (2007) yang menunjukkan bahwa sentimen negatif dalam berita keuangan berkorelasi dengan pergerakan return saham dalam jangka pendek, serta relevan dengan bentuk setengah kuat *Efficient Market Hypothesis* yang dikemukakan Fama (1970), yang menyatakan bahwa harga saham mencerminkan informasi publik yang tersedia di pasar secara cepat. Secara keseluruhan, temuan ini menunjukkan bahwa kecenderungan sentimen dalam berita saham dipengaruhi oleh tema pemberitaan sehingga analisis berbasis aspek mampu memberikan informasi yang lebih rinci dibandingkan analisis sentimen pada tingkat dokumen secara keseluruhan.

Di sisi lain, hasil studi ablasi menunjukkan bahwa penambahan distribusi topik LDA sebagai fitur tambahan pada model *Hybrid* LDA-IndoBERT belum mampu meningkatkan performa klasifikasi dibandingkan model Fine-tuned IndoBERT. Model baseline memperoleh akurasi 0,9046 dan F1-macro 0,9049, sedangkan model hybrid memperoleh akurasi 0,8985 dan F1-macro 0,8989, dengan selisih yang konsisten terjadi pada seluruh metrik yang diuji, termasuk precision dan recall, bukan hanya pada satu metrik tertentu. Terdapat beberapa faktor yang dapat menjelaskan temuan ini, dengan tingkat dukungan bukti yang berbeda. Faktor yang didukung oleh landasan teori berkaitan dengan proporsi dimensi vektor fitur gabungan, karena distribusi topik LDA hanya menyusun sekitar 0,5 persen dari total dimensi vektor gabungan sebesar 772, sehingga kontribusinya terhadap keputusan akhir klasifikasi menjadi terbatas. Hal ini sejalan dengan catatan Baltrusaitis et al., (2019) bahwa *feature-level fusion* melalui concatenation merupakan strategi penggabungan yang paling sederhana dan tidak menyertakan mekanisme pembobotan adaptif antarsumber informasi, berbeda dengan pendekatan seperti *gating mechanism* atau

cross-attention yang memungkinkan model mempelajari kontribusi tiap sumber informasi secara proporsional.

Ditinjau dari manfaat penelitian yang diharapkan, hasil analisis sentimen berbasis aspek ini memberikan gambaran yang lebih terarah bagi investor ritel dalam memahami pemberitaan pasar modal. *Aspek Pergerakan Pasar Saham dan Nilai Tukar* dapat dijadikan acuan sebagai aspek dengan proporsi sentimen negatif tertinggi dan keterkaitan tematik yang paling kuat dengan dinamika harga saham, sehingga investor yang ingin memantau sentimen pasar dapat memfokuskan perhatian pada pemberitaan bertema ini sebagai sinyal yang lebih langsung terkait arah pergerakan harga. Sementara itu, pemberitaan pada aspek *Aktivitas Perusahaan dan Tokoh Bisnis* maupun *Sektor Perbankan dan BUMN* yang didominasi sentimen netral lebih tepat dipahami sebagai informasi deskriptif mengenai aktivitas korporasi, bukan sebagai indikator langsung mengenai arah pergerakan pasar. Pemilahan semacam ini menjadi salah satu nilai tambah pendekatan berbasis topik dibandingkan analisis sentimen pada tingkat dokumen secara keseluruhan yang tidak membedakan konteks tematik dari tiap berita.

Beberapa keterbatasan perlu diakui secara terbuka agar hasil penelitian ini dapat dimaknai secara proporsional. Dataset yang digunakan hanya memiliki label sentimen pada tingkat dokumen tanpa anotasi aspek maupun sentimen pada tingkat kata, sehingga pelabelan aspek hasil interpretasi topik LDA bersifat kualitatif dan belum dapat diverifikasi terhadap ground truth aspek yang sesungguhnya. Perbandingan performa antara model *hybrid* dan model *baseline* juga hanya menggunakan satu skema pembagian data tanpa pengujian signifikansi statistik seperti uji *McNemar* atau pendekatan *cross-validation*, sehingga selisih F1-macro sebesar 0,0060 antara kedua model belum dapat dipastikan signifikan secara statistik dan berpotensi dipengaruhi oleh variasi pada proses pembagian data maupun inisialisasi bobot model saat pelatihan. Selain itu, penelitian ini belum melakukan analisis kesalahan secara kualitatif terhadap dokumen yang salah diklasifikasikan pada confusion matrix, misalnya menelusuri pola kata atau struktur kalimat pada dokumen netral yang justru diprediksi sebagai positif atau negatif, yang sebenarnya dapat memberi wawasan lebih dalam mengenai sumber kesalahan model. Penelitian ini juga terbatas pada satu kombinasi model saja, yaitu IndoBERT sebagai representasi kontekstual dan LDA sebagai representasi topik, sehingga hasil yang diperoleh belum tentu berlaku pada kombinasi model bahasa maupun model topik lain.

Berdasarkan keseluruhan hasil yang diperoleh, integrasi LDA dan IndoBERT memberikan dua kontribusi yang saling melengkapi. IndoBERT berperan sebagai model utama dalam menghasilkan klasifikasi sentimen dengan performa yang tinggi, sedangkan LDA berperan dalam mengidentifikasi aspek-aspek tematik yang meningkatkan interpretabilitas hasil analisis. Kegagalan distribusi topik meningkatkan akurasi klasifikasi tidak mengurangi manfaat LDA secara keseluruhan, karena perannya dalam menyusun struktur aspek tematik tetap menjadi kontribusi yang berdiri sendiri terhadap pemahaman pola pemberitaan saham berbahasa Indonesia. Dengan demikian, pendekatan yang diusulkan tidak hanya menghasilkan

klasifikasi sentimen, tetapi juga memberikan informasi mengenai hubungan antara tema pemberitaan dan kecenderungan sentimen pada berita saham Indonesia. Temuan ini diharapkan dapat menjadi dasar bagi pengembangan analisis sentimen berbasis aspek pada korpus berita ekonomi maupun bidang lain yang memiliki karakteristik serupa, terutama pada konteks yang memiliki keterbatasan anotasi aspek secara manual seperti yang dihadapi pada penelitian ini.

BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan yang telah dilakukan, maka kesimpulan dari penelitian ini adalah sebagai berikut.

1. Pemodelan topik menggunakan *Latent Dirichlet Allocation* (LDA) berhasil mengidentifikasi struktur topik pada korpus judul berita saham berbahasa Indonesia dengan jumlah topik optimal sebanyak empat topik ($K = 4$) berdasarkan nilai *topic coherence* sebesar 0,5121. Keempat topik tersebut diinterpretasikan sebagai aspek *Aktivitas Perusahaan dan Tokoh Bisnis, Sektor Perbankan dan BUMN, Pergerakan Pasar Saham dan Nilai Tukar*, serta *Regulasi dan Pengawasan Sektor Keuangan*. Seluruh 9.747 dokumen memiliki topik dominan yang memenuhi ambang batas probabilitas, sehingga seluruh dokumen dapat digunakan dalam analisis sentimen berbasis aspek.
2. Model *Fine-tuned* IndoBERT mampu mengklasifikasikan sentimen berita saham berbahasa Indonesia dengan kinerja yang tinggi. Pada data uji, model memperoleh akurasi sebesar 0,9046, *precision macro* sebesar 0,9032, *recall macro* sebesar 0,9070, dan *F1-macro* sebesar 0,9049. Nilai evaluasi yang relatif seimbang pada ketiga kelas sentimen menunjukkan bahwa model memiliki kemampuan generalisasi yang baik dalam mengklasifikasikan sentimen positif, negatif, dan netral.
3. Hasil studi ablasi menunjukkan bahwa penambahan distribusi topik LDA sebagai fitur tambahan melalui pendekatan *feature-level fusion* belum mampu meningkatkan kinerja klasifikasi dibandingkan model *Fine-tuned* IndoBERT. Model *Hybrid* LDA-IndoBERT memperoleh *F1-macro* sebesar 0,8989, sedikit lebih rendah dibandingkan model *baseline* dengan selisih sebesar 0,0060. Hasil ini menunjukkan bahwa pada korpus berupa judul berita yang relatif singkat, representasi kontekstual yang dihasilkan oleh IndoBERT telah mampu menangkap informasi semantik yang diperlukan sehingga penambahan fitur topik belum memberikan peningkatan performa klasifikasi.
4. Analisis sentimen berbasis aspek menunjukkan bahwa distribusi sentimen berbeda pada setiap aspek tematik hasil pemodelan LDA. Aspek *Aktivitas Perusahaan dan Tokoh Bisnis, Sektor Perbankan dan BUMN*, serta *Regulasi dan Pengawasan Sektor Keuangan* didominasi oleh sentimen netral. Sebaliknya, aspek *Pergerakan Pasar Saham dan Nilai Tukar* merupakan satu-satunya aspek yang didominasi oleh sentimen negatif dengan proporsi sebesar 47,84% serta memiliki rata-rata probabilitas topik dominan tertinggi. Hasil ini menunjukkan bahwa kecenderungan sentimen dalam berita saham berbeda pada setiap aspek tematik sehingga analisis sentimen berbasis aspek mampu memberikan informasi yang lebih rinci dibandingkan analisis sentimen pada tingkat dokumen.
5. Penelitian ini menunjukkan bahwa integrasi LDA dan IndoBERT memberikan kontribusi yang saling melengkapi. Meskipun penambahan distribusi topik belum meningkatkan kinerja klasifikasi sentimen, pemodelan topik menggunakan LDA

berhasil mengidentifikasi struktur tematik korpus yang menjadi dasar analisis sentimen berbasis aspek. Dengan demikian, pendekatan yang diusulkan tidak hanya menghasilkan klasifikasi sentimen, tetapi juga memberikan interpretasi yang lebih komprehensif mengenai hubungan antara tema pemberitaan dan kecenderungan sentimen pada berita saham berbahasa Indonesia.

4.2 Saran

Berdasarkan hasil penelitian, saran yang dapat diberikan untuk pengembangan penelitian selanjutnya adalah sebagai berikut.

1. Penelitian selanjutnya disarankan mengeksplorasi mekanisme *feature fusion* yang lebih adaptif dibandingkan operasi concatenation, seperti *gating mechanism*, *cross-attention*, atau pendekatan integrasi fitur lainnya, sehingga informasi topik dan representasi kontekstual dFapat dimanfaatkan secara lebih optimal dalam proses klasifikasi.
2. Penelitian selanjutnya disarankan menggunakan korpus dengan teks yang lebih panjang, seperti isi artikel berita secara lengkap, untuk mengevaluasi pengaruh distribusi topik terhadap kinerja klasifikasi sentimen pada dokumen yang memiliki informasi semantik lebih kaya.
3. Penelitian selanjutnya dapat mengembangkan pendekatan ini menggunakan model topik berbasis *neural topic modeling*, seperti *BERTopic* atau *Contextualized Topic Model* (CTM), sehingga representasi topik yang dihasilkan memanfaatkan informasi kontekstual dan berpotensi meningkatkan integrasi dengan model berbasis Transformer.

DAFTAR PUSTAKA

- Alamsyah, A., Ramadhani, D. P., Kristanti, F. T., Nasution, A. H., Mohamad, M. S. bin, Sokkalingam, R., Widiyanesti, S., & Saputra, M. A. A. (2025). Deciphering news sentiment and stock price relationships in Indonesian companies: an AI-based exploration of industry affiliation and news co-occurrence. *Discover Artificial Intelligence*, 5(1). <https://doi.org/10.1007/s44163-025-00350-5>
- Apriliani, S., Erfina, A., & Warman, C. (2025). Fine-Tuned IndoBERT for Aspect-Based Sentiment Analysis of Indonesian Five-Star Hotel Reviews. *Jurnal Sisfokom (Sistem Informasi Dan Komputer)*, 14(4), 437–445. <https://doi.org/10.32736/sisfokom.v14i4.2491>
- Baltrusaitis, T., Ahuja, C., & Morency, L. P. (2019). Multimodal Machine Learning: A Survey and Taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), 423–443. <https://doi.org/10.1109/TPAMI.2018.2798607>
- Blei, D. M., Ng, A. Y., & Edu, J. B. (2003). Latent Dirichlet Allocation Michael I. Jordan. In *Journal of Machine Learning Research* (Vol. 3).
- Bouma, G. (2009). Normalized (Pointwise) Mutual Information in Collocation Extraction. *Proceedings of German Society for Computational Linguistics (GSCL 2009)*, 31–40.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. <http://arxiv.org/abs/1810.04805>
- Dhanal, R. J., & Ghorpade, V. R. (2024). Aspect-based sentiment-analysis using topic modelling and machine-learning. *International Journal of Electrical and Computer Engineering*, 14(6), 6689–6698. <https://doi.org/10.11591/ijece.v14i6.pp6689-6698>
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383. <https://doi.org/10.2307/2325486>
- Hartanto, J., Liundi, T., Sutoyo, R., & Andangsari, E. W. (2025). ID-SMSA: Indonesian stock market dataset for sentiment analysis. *Data in Brief*, 60. <https://doi.org/10.1016/j.dib.2025.111571>
- Hoffman, M. D., Blei, D. M., & Bach Francis. (2010). Online Learning for Latent Dirichlet Allocation. *Advances in Neural Information Processing Systems. Proceedings of the Society for Experimental Biology and Medicine*, 23(4), 856–864. <https://doi.org/10.3181/00379727-137-35757>
- Hua, Y. C., Denny, P., Wicker, J., & Taskova, K. (2024). A systematic review of aspect-based sentiment analysis: domains, methods, and trends. *Artificial Intelligence Review*, 57(11). <https://doi.org/10.1007/s10462-024-10906-z>
- Jordan, M. I., Ghahramani, Z., Jaakkola, T. S., & Saul, L. K. (1999). Introduction to variational methods for graphical models. *Machine Learning*, 37(2), 183–233. <https://doi.org/10.1023/A:1007665907178>
- Koto, F., Rahimi, A., Lau, J. H., & Baldwin, T. (2020). IndoLEM and IndoBERT: A Benchmark Dataset and Pre-trained Language Model for Indonesian NLP. In *COLING 2020 - 28th International Conference on Computational Linguistics*,

- Proceedings of the Conference.* Online.
<https://doi.org/10.18653/v1/2020.coling-main.66>
- Liu, B. (2012). *Sentiment analysis and opinion mining*. Springer.
- Malo, P., Sinha, A., Korhonen, P., & Wallenius, J. (2014). Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. *Journal of the American Society for Information Science and Technology*, 64(July), 1852–1863.
<https://doi.org/10.1002/asi>
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to information retrieval cambridge university press, 2008. *Cambridge University Press*, 377–401.
- Pontiki, M., Galanis, D., Papageorgiou, H., Manandhar, S., & Androutsopoulos, I. (2015). *SemEval-2015 Tugas 12: Analisis Sentimen Berbasis Aspek*.
www.onlinedoctranslator.com
- Röder, M., Both, A., & Hinneburg, A. (2015). Exploring the space of topic coherence measures. *WSDM 2015 - Proceedings of the 8th ACM International Conference on Web Search and Data Mining*, 399–408.
<https://doi.org/10.1145/2684822.2685324>
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing and Management*, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Syed, S., & Spruit, M. (2017). Full-Text or abstract? Examining topic coherence scores using latent dirichlet allocation. *Proceedings - 2017 International Conference on Data Science and Advanced Analytics, DSAA 2017, 2018-January*, 165–174. <https://doi.org/10.1109/DSAA.2017.61>
- Tetlock, P. C. (2007). Giving Content to Investor Sentiment: The Role of Media in the Stock Market. In *THE JOURNAL OF FINANCE • LXII* (Number 3).
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). *Attention Is All You Need*.
<http://arxiv.org/abs/1706.03762>
- Daniel, J., & Martin, J. H. (2026). Speech and Language Processing (3rd ed. draft).
 From <https://web.stanford.edu/~jrafsky/slp3/>
- He, H., & Garcia, E. (2009). Learning from Imbalanced Data. *Learning from Imbalanced Data*, 21(9), 1263-1284.
[doi:https://doi.org/10.1109/TKDE.2008.239](https://doi.org/10.1109/TKDE.2008.239)
- Indonesia, K. S. (2023). *Data Statistik KSEI*. From
https://web.ksei.co.id/publications/Data_Statistik_KSEI
- Keuangan, O. J. (2024). *Pasar Modal*. From <https://ojk.go.id/id/kanal/pasar-modal/>

LAMPIRAN

Lampiran 1. Program

```
# CELL 1 INSTALASI DEPENDENSI
!pip install --quiet \
    gensim \
    sastrawi \
    transformers \
    torch \
    pandas \
    numpy \
    matplotlib \
    seaborn \
    scikit-learn \
    openpyxl \

# CELL 2 KONFIGURASI GLOBAL
from google.colab import drive
import pandas as pd
import numpy as np
import re, os, warnings, time
from itertools import combinations
from collections import defaultdict
import torch
import matplotlib.pyplot as plt
import seaborn as sns
warnings.filterwarnings("ignore")

drive.mount("/content/drive")
DATASET_PATH = "/content/drive/MyDrive/Dataset-CNBCI-
Sentimented (1).csv"

# Nama kolom
COL_TEXT = "judul"
COL_LABEL = "sentimen"

# Label sentimen
LABEL_NAMES = ["positive", "negative", "neutral"]
LABEL_MAP = {"positive": 0, "negative": 1, "neutral": 2}

# Parameter LDA
LDA_K_RANGE = range(2, 16)
LDA_PASSES = 30
LDA_ITERATIONS = 500
LDA_TOP_WORDS = 10
LDA_RANDOM_STATE = 42
LDA_ALPHA = "auto"
LDA_ETA = "auto"
BETA_DEFAULT = 0.01
# Threshold probabilitas aspek
```

```

ASPECT_THRESHOLD = 0.20

# Parameter BoW / Dictionary
BOW_NO_BELOW = 5
BOW_NO_ABOVE = 0.5

# Parameter IndoBERT
INDOBERT_MODEL = "indobenchmark/indobert-base-pl"
MAX_LEN = 128
BATCH_SIZE = 16
LEARNING_RATE = 2e-5
WEIGHT_DECAY = 0.01
NUM_EPOCHS = 10
WARMUP_RATIO = 0.1
PATIENCE = 3
RANDOM_STATE = 42

# Konfigurasi split
SPLIT_CONFIGS = [
    {"train": 0.8, "val": 0.1, "test": 0.1, "label":
"80:10:10"},
    {"train": 0.7, "val": 0.1, "test": 0.2, "label":
"70:10:20"},
    {"train": 0.7, "val": 0.2, "test": 0.1, "label":
"70:20:10"},
    {"train": 0.6, "val": 0.2, "test": 0.2, "label":
"60:20:20"},
]
BEST_SPLIT = SPLIT_CONFIGS[0]

# Folder output
OUTPUT_DIR = "/content/drive/MyDrive/ABSA_Output"
FIG_DIR = os.path.join(OUTPUT_DIR, "figures")
RES_DIR = os.path.join(OUTPUT_DIR, "results")
MDL_DIR = os.path.join(OUTPUT_DIR, "model")
for d in [FIG_DIR, RES_DIR, MDL_DIR]:
    os.makedirs(d, exist_ok=True)

# Device
DEVICE = torch.device("cuda" if torch.cuda.is_available()
else "cpu")

# CELL 3 LOAD DAN VERIFIKASI DATASET

df = pd.read_csv(DATASET_PATH)

print("=" * 60)
print(" PENGUMPULAN DAN DESKRIPSI DATA")
print("=" * 60)

```

```

print(f"\n Jumlah baris : {len(df):,}")
print(f" Jumlah kolom : {df.shape[1]}")
print(f" Nama kolom : {list(df.columns)}")
display(df.head())

# CELL 4 VERIFIKASI INTEGRITAS DAN PEMBERSIHAN AWAL
n_awal = len(df)

df.drop_duplicates(subset=[COL_TEXT], inplace=True)
n_dup = n_awal - len(df)

df.dropna(subset=[COL_TEXT, COL_LABEL], inplace=True)
n_na = n_awal - n_dup - len(df)

df = df[df[COL_TEXT].str.split().str.len() >= 3].copy()
n_short = n_awal - n_dup - n_na - len(df)
df.reset_index(drop=True, inplace=True)
n_akhir = len(df)

# Normalisasi label ke format standar
label_map_raw = {"positif": "positive", "negatif":
"negative", "netral": "neutral"}
df[COL_LABEL] = (df[COL_LABEL].str.strip().str.lower()

.map(label_map_raw).fillna(df[COL_LABEL].str.strip().str.lower()))

# CELL 5 DISTRIBUSI LABEL SENTIMEN

# Distribusi sentimen
tabel_sentimen = (df[COL_LABEL].value_counts()
.reset_index()
.rename(columns={"index": "Sentimen",
COL_LABEL: "Frekuensi"}))
tabel_sentimen.columns = ["Sentimen", "Frekuensi"]
tabel_sentimen["Persentase (%)"] =
(tabel_sentimen["Frekuensi"] / n_akhir * 100).round(2)

print(f"\n Distribusi Label Sentimen pada Dataset")
display(tabel_sentimen)

# CELL 6 PRA-PEMROSESAN TEKS: JALUR LDA
from Sastrawi.StopWordRemover.StopWordRemoverFactory import
StopWordRemoverFactory
from Sastrawi.Stemmer.StemmerFactory import StemmerFactory

factory_stop = StopWordRemoverFactory()
stop_words = set(factory_stop.get_stop_words())

factory_stem = StemmerFactory()

```

```

stemmer          = factory_stem.create_stemmer()

# Tambahan stopwords domain keuangan
DOMAIN_STOPWORDS = {
    "rp", "triliun", "miliar", "juta", "ribu",
    "tahun", "bulan", "hari", "jam", "persen",
    "indonesia", "jakarta", "cnbc", "tbk",
}
stop_words.update(DOMAIN_STOPWORDS)

# Kamus normalisasi akronim keuangan domain
NORMALIZATION_DICT = {
    "ihsg" : "indeks harga saham gabungan",
    "ojk"  : "otoritas jasa keuangan",
    "bi"   : "bank indonesia",
    "bri"  : "bank rakyat indonesia",
    "bni"  : "bank negara indonesia",
    "bca"  : "bank central asia",
    "ipo"  : "penawaran umum perdana",
    "pdb"  : "produk domestik bruto",
    "gdp"  : "produk domestik bruto",
    "fed"  : "federal reserve",
    "eps"  : "laba per saham",
    "roe"  : "return on equity",
    "roa"  : "return on asset",
    "yoy"  : "year on year",
    "qtq"  : "quarter on quarter",
    "bumn" : "badan usaha milik negara",
    "emiten" : "perusahaan terdaftar bursa",
    "yg"   : "yang", "dgn": "dengan", "utk": "untuk",
    "dlm"  : "dalam", "tsb": "tersebut", "tdk": "tidak",
    "sdh"  : "sudah", "blm": "belum", "krn": "karena",
}

def preprocess_lda(text: str) -> list:
    """Pipeline praproses untuk jalur LDA (BoW input)."""
    # Case folding
    text = str(text).lower()
    # Hapus URL
    text = re.sub(r"http\S+|www\.\S+", "", text)
    # Hapus karakter non-alfabetik
    text = re.sub(r"[^a-z\s]", " ", text)
    text = re.sub(r"\s+", " ", text).strip()
    # Tokenisasi
    tokens = text.split()
    # Normalisasi akronim (multi-kata diexpand)
    expanded = []
    for t in tokens:
        expanded.extend(NORMALIZATION_DICT.get(t, t).split())
    # Stopword removal
    tokens = [t for t in expanded if t not in stop_words and

```

```

len(t) > 2]
    # Stemming
    tokens = [stemmer.stem(t) for t in tokens]
    return tokens

def preprocess_bert(text: str) -> str:
    """Pipeline praproses minimal untuk jalur IndoBERT."""
    # Case folding
    text = str(text).lower()
    # Hapus karakter kontrol dan simbol tidak perlu
    text = re.sub(r"^\w\s]", " ", text)
    text = re.sub(r"\s+", " ", text).strip()
    return text

# CELL 7 MEMBANGUN BAG OF WORDS DAN CORPUS GENSIM

import gensim
from gensim import corpora

dictionary = corpora.Dictionary(df["final_tokens"])
dictionary.filter_extremes(no_below=BOW_NO_BELOW,
no_above=BOW_NO_ABOVE)
corpus = [dictionary.doc2bow(text) for text in
df["final_tokens"]]

V = len(dictionary)    # ukuran kosakata setelah filter

for token_id, freq in corpus[0][:5]:
    print(f"      (id={token_id:4d}, freq={freq}) C2+'
'{dictionary[token_id]}")

# Representasi BoW
print(f"\n Representasi BoW dokumen pertama:")
sample_bow = corpus[0][:6]
kata_list = [dictionary[tid] for tid, _ in sample_bow]
print(f"      Token      : {kata_list}")
print(f"      BoW repr  : {sample_bow}")

# CELL 8 SELEKSI JUMLAH TOPIK K: COHERENCE Cv

from gensim.models import LdaModel, CoherenceModel

coherence_scores = []
for k in LDA_K_RANGE:
    lda_tmp = LdaModel(
        corpus           = corpus,
        id2word          = dictionary,
        num_topics       = k,
        passes           = LDA_PASSES,

```

```

        iterations      = LDA_ITERATIONS,
        random_state    = LDA_RANDOM_STATE,
        alpha           = LDA_ALPHA,
        eta              = LDA_ETA,
        per_word_topics = True,
    )
    cm = CoherenceModel(
        model      = lda_tmp,
        texts      = df["final_tokens"].tolist(),
        dictionary = dictionary,
        coherence   = "c_v",
        topn        = LDA_TOP_WORDS,
    )
    score = round(cm.get_coherence(), 4)
    coherence_scores.append(score)
    print(f" K={k:2d} | Coherence Cv: {score}")

k_values = list(LDA_K_RANGE)
deltas   = [None] + [round(coherence_scores[i] -
                           coherence_scores[i-1], 4)
                    for i in range(1,
len(coherence_scores))]

best_idx  = int(np.argmax(coherence_scores))
k_best_raw = k_values[best_idx]

elbow_idx = None
for i in range(best_idx + 1, len(coherence_scores)):
    if coherence_scores[i] < coherence_scores[i - 1]:
        elbow_idx = i
        break
if elbow_idx is None:
    elbow_idx = min(best_idx + 1, len(coherence_scores) - 1)

K_ELLOW  = k_values[elbow_idx]
K_OPTIMAL = k_best_raw

# CELL 9 VISUALISASI KURVA COHERENCE

fig, ax = plt.subplots(figsize=(9, 4))
ax.plot(k_values, coherence_scores, "o-", color="#1976D2",
        linewidth=2, markersize=7)
ax.axvline(x=K_OPTIMAL, color="#E53935", linestyle="--",
        linewidth=1.8,
        label=f"K optimal (Cv maks, sebelum elbow) =
{K_OPTIMAL}")
ax.axvline(x=K_ELLOW, color="#43A047", linestyle=":",
        linewidth=1.5,
        label=f"Titik elbow = K={K_ELLOW}")

```

```

for i, (k, cv) in enumerate(zip(k_values, coherence_scores)):
    ax.annotate(f"{cv:.4f}", (k, cv), textcoords="offset
points",
                xytext=(0, 7), ha="center", fontsize=7,
color="#424242")

ax.set_xlabel("Jumlah Topik (K)", fontsize=11)
ax.set_ylabel("Coherence Score (Cv)", fontsize=11)
ax.set_title("Grafik Jumlah Topik LDA Berdasarkan Nilai
Coherence",
             fontsize=11, fontweight="bold")
ax.set_xticks(k_values)
ax.legend(fontsize=9)
ax.grid(alpha=0.3)
plt.tight_layout()
plt.savefig(os.path.join(FIG_DIR, "fig_coherence_K.png"),
            dpi=150)
plt.show()

# CELL 10 TRAINING MODEL LDA FINAL

lda_model = LdaModel(
    corpus          = corpus,
    id2word         = dictionary,
    num_topics      = K_OPTIMAL,
    passes          = LDA_PASSES,
    iterations      = LDA_ITERATIONS,
    random_state    = LDA_RANDOM_STATE,
    alpha           = LDA_ALPHA,
    eta             = LDA_ETA,
    per_word_topics = True,
)

# CELL 10B DISTRIBUSI PROBABILITAS KATA

TOPIK_DEMO = 2    # ambil salah satu topik

phi_matrix = lda_model.get_topics()    # shape: (K_OPTIMAL, V)

print("=" * 60)
print("DERIVASI MATEMATIS PEMILIHAN K C2@2" TAHAP 1 s.d.
TAHAP 5")
print("=" * 60)

# Distribusi Probabilitas Kata pada Topik (Top-10)
print(f"\nDistribusi Probabilitas Kata Pada Topik
k={TOPIK_DEMO}")
print(f"Formula:  $Af_{\{wk\}} = (n_{\{kw\}} + Ae@6) /$ 
 $(Ae@8_{\{w'\}} n_{\{kw'\}} + VA2 \cdot Ae@6)$ ")
print(f"V = {V}, Ae@6 = {beta_val}\n")

```

```

# CELL 10C ESTIMASI PROBABILITAS MARGINAL DAN BERSAMA +
# PERHITUNGAN NPMI

WINDOW_SIZE = 110 # Default CoherenceModel Gensim
texts_clean = df["final_tokens"].tolist()

W_total = 0
count_single = defaultdict(int)
count_pair = defaultdict(int)

for doc_tokens in texts_clean:
    n = len(doc_tokens)
    if n == 0:
        continue
    for start in range(max(1, n - WINDOW_SIZE + 1)):
        window = doc_tokens[start: start + WINDOW_SIZE]
        window_set = set(window)
        W_total += 1
        for w in window_set:
            count_single[w] += 1
        for wi, wj in combinations(sorted(window_set), 2):
            count_pair[(wi, wj)] += 1

print(f" W_total (total window) = {W_total:,}")

def p_single(w: str) -> float:
    """Probabilitas marginal p(w)."""
    return count_single.get(w, 0) / W_total if W_total > 0
else 0.0

def p_pair(wi: str, wj: str) -> float:
    """Probabilitas bersama p(w_i, w_j) dengan additive
    smoothing Aeq."""
    key = (min(wi, wj), max(wi, wj))
    epsilon = 1.0 / (W_total + 1) # hindari p=0
    return (count_pair.get(key, 0) + epsilon) / W_total

def npmi(wi: str, wj: str) -> float:
    """
    
$$NPMI(w_i, w_j) = \frac{\log_2[p(w_i, w_j) / (p(w_i) \cdot p(w_j))]}{(-\log_2 p(w_i, w_j))}$$

    """
    pi = p_single(wi)
    pj = p_single(wj)
    pij = p_pair(wi, wj)
    if pi <= 0 or pj <= 0 or pij <= 0:
        return 0.0
    pmi_val = math.log2(pij / (pi * pj))
    denom = -math.log2(pij)

```

```

    return pmi_val / denom if abs(denom) > 1e-12 else 1.0

# Probabilitas individual dan bersama antar kata kunci
top_words_demo = [dictionary[wid] for wid in top_ids]

print(f"\nProbabilitas Individual dan Probabilitas Bersama
Antar Kata")
print(f"    (Top-{{LDA_TOP_WORDS}} kata Topik k={{TOPIK_DEMO}};
beberapa pasang representatif ditampilkan)\n")

# Nilai NPMI seluruh 45 pasang kata
n_pairs = len(pairs_all)
print(f"\nNilai NPMI Antar Pasangan Kata pada Topik
k={{TOPIK_DEMO}}")
print(f"    Jumlah pasang = C({{LDA_TOP_WORDS}},2) = {n_pairs}")
print(f"    Formula: NPMI =
logC2,, [p(wC1uŷ,wC2+j) / (p(wC1uŷ)A2 · p(wC2+j))] / (-logC2,,
p(wC1uŷ,wC2+j))\n")

# CELL 10D COHERENCE PER TOPIK
for k in range(K_OPTIMAL):
    top_words_k = [w for w, _ in lda_model.show_topic(k,
topn=LDA_TOP_WORDS)]
    pairs_k = list(combinations(top_words_k, 2))
    npmi_vals = [npmi(wi, wj) for wi, wj in pairs_k]
    sum_npmi_k = sum(npmi_vals)
    cv_k = (2.0 / (LDA_TOP_WORDS * (LDA_TOP_WORDS -
1))) * sum_npmi_k
    cv_per_topik.append(cv_k)
    tabel8_rows.append({
        "Topik k" : k,
        "Ae@8 NPMI" : round(sum_npmi_k, 4),
        "Cv(TC2,-)" : round(cv_k, 6),
    })

cv_model = np.mean(cv_per_topik)
sum_cv = sum(cv_per_topik)

# CELL 11 PEMETAAN TOPIK KE LABEL KONSEPTUAL
# Proses pelabelan dilakukan secara manual berdasarkan top-
words tiap topik.

print(f"\nTop-words setiap topik (untuk menentukan label
konseptual):\n")
for i in range(K_OPTIMAL):
    words = [w for w, p in lda_model.show_topic(i,
topn=LDA_TOP_WORDS)]
    phi_w = [round(p, 5) for w, p in lda_model.show_topic(i,

```

```

topn=LDA_TOP_WORDS)]
    print(f"    Topik {i}: {words}")
    print(f"        Af•={phi_w}\n")

ASPECT_LABEL_MAP = {
    0: "Aktivitas Perusahaan dan Tokoh Bisnis", #Label diisi
    manual berdasarkan output top words tiap topik
    1: "Sektor Perbankan dan BUMN",
    2: "Pergerakan Pasar Saham dan Nilai Tukar",
    3: "Regulasi dan Pengawasan Sektor Keuangan",
}

# Validasi: semua topic_id harus ada
missing = [i for i in range(K_OPTIMAL) if i not in
ASPECT_LABEL_MAP]
if missing:
    print(f"C2⌘    Topik belum diberi label: {missing}")
    for m in missing:
        ASPECT_LABEL_MAP[m] = f"Aspek Topik-{m}"
else:
    print("Semua topik sudah dipetakan ke label
konseptual\n")

for k, v in ASPECT_LABEL_MAP.items():
    print(f"    Topik {k}: {v}")

# CELL 12 EKSTRAKSI DISTRIBUSI TOPIK DAN PENENTUAN ASPEK
DOMINAN
topic_dists_list = []
dominant_topics = []
max_probs = []
aspek_labels = []

for doc_bow in corpus:
    topic_dist_sparse = dict(
        lda_model.get_document_topics(doc_bow,
minimum_probability=0)
    )
    theta = np.array([topic_dist_sparse.get(k, 0.0) for k
in range(K_OPTIMAL)])
    dominant = int(np.argmax(theta))
    max_p = float(theta[dominant])
    label = (ASPECT_LABEL_MAP.get(dominant, f"Topik-
{dominant}")
    if max_p >= ASPECT_THRESHOLD else "Tidak
Terdefinisi")

    topic_dists_list.append(theta)
    dominant_topics.append(dominant)
    max_probs.append(max_p)
    aspek_labels.append(label)

```

```

df["topic_dist"]      = topic_dists_list
df["dominant_topic"]  = dominant_topics
df["max_prob"]        = max_probs
df["aspek"]           = aspek_labels

n_terdefinisi = (df["aspek"] != "Tidak Terdefinisi").sum()
n_tidak_def   = (df["aspek"] == "Tidak Terdefinisi").sum()
pct_tidak_def = n_tidak_def / len(df) * 100

# CELL 13 VISUALISASI DISTRIBUSI ASPEK DAN MAX_PROB

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Panel kiri: distribusi aspek
ax1 = axes[0]
data_plot = tabel11[tabel11["Aspek"] != "Tidak
Terdefinisi"].copy()
sns.barplot(data=data_plot, x="Frekuensi", y="Aspek",
            palette="Blues_d", ax=ax1)
ax1.set_title("Distribusi Aspek (Topik Terdefinisi)",
             fontsize=11, fontweight="bold")
ax1.set_xlabel("Frekuensi")
ax1.set_ylabel("")
for bar in ax1.patches:
    ax1.text(bar.get_width() + 10, bar.get_y() +
bar.get_height()/2,
            f"{int(bar.get_width()):,}", va="center",
            fontsize=8)

# Panel kanan: distribusi max_prob
ax2 = axes[1]
ax2.hist(df["max_prob"], bins=30, color="#42A5F5",
        edgcolor="white")
ax2.axvline(x=ASPECT_THRESHOLD, color="red", linestyle="--",
            linewidth=1.8, label=f"Threshold =
{ASPECT_THRESHOLD}")
ax2.set_title("Gambar 4. Distribusi Probabilistik Topik
Dominan (max_prob)",
            fontsize=11, fontweight="bold")
ax2.set_xlabel("max_prob")
ax2.set_ylabel("Frekuensi")
ax2.legend()

plt.tight_layout()
plt.savefig(os.path.join(FIG_DIR,
"fig_distribusi_aspek_maxprob.png"), dpi=150)
plt.show()

# CELL 15 DEFINISI DATASET CLASS DAN FUNGSI EPOCH
import torch.nn as nn

```

```

from torch.utils.data import Dataset, DataLoader
from torch.optim import AdamW
from sklearn.metrics import f1_score

class HybridNewsDataset(Dataset):
    """
    Dataset yang menyertakan distribusi topik Aes_d di
    sampling teks.
    Digunakan untuk model hybrid IndoBERT + LDA.
    """
    def __init__(self, texts, topic_dists, labels, tokenizer,
max_len=MAX_LEN):
        self.texts = texts
        self.topic_dists = topic_dists # numpy array (N, K)
        self.labels = labels
        self.tokenizer = tokenizer
        self.max_len = max_len

    def __len__(self):
        return len(self.texts)

    def __getitem__(self, idx):
        enc = self.tokenizer(
            self.texts[idx],
            max_length = self.max_len,
            padding = "max_length",
            truncation = True,
            return_tensors = "pt",
        )
        return {
            "input_ids" : enc["input_ids"].squeeze(),
            "attention_mask" :
enc["attention_mask"].squeeze(),
            "topic_dist" :
torch.tensor(self.topic_dists[idx], dtype=torch.float),
            "label" : torch.tensor(self.labels[idx],
dtype=torch.long),
        }

def train_epoch_hybrid(model, loader, optimizer, scheduler,
criterion):
    model.train()
    total_loss, preds_all, labels_all = 0.0, [], []
    for batch in loader:
        input_ids = batch["input_ids"].to(DEVICE)
        attention_mask = batch["attention_mask"].to(DEVICE)
        topic_dist = batch["topic_dist"].to(DEVICE)
        labels = batch["label"].to(DEVICE)
        optimizer.zero_grad()
        logits = model(input_ids, attention_mask, topic_dist)

```

```

        loss = criterion(logits, labels)
        loss.backward()
        nn.utils.clip_grad_norm_(model.parameters(), 1.0)
        optimizer.step()
        scheduler.step()
        total_loss += loss.item()
        preds_all.extend(logits.argmax(dim=1).cpu().numpy())
        labels_all.extend(labels.cpu().numpy())
        f1 = f1_score(labels_all, preds_all, average="macro",
zero_division=0)
        return total_loss / len(loader), f1

def eval_epoch_hybrid(model, loader, criterion):
    model.eval()
    total_loss, preds_all, labels_all, probs_all = 0.0, [],
[], []
    with torch.no_grad():
        for batch in loader:
            input_ids = batch["input_ids"].to(DEVICE)
            attention_mask =
batch["attention_mask"].to(DEVICE)
            topic_dist = batch["topic_dist"].to(DEVICE)
            labels = batch["label"].to(DEVICE)
            logits = model(input_ids, attention_mask,
topic_dist)
            loss = criterion(logits, labels)
            total_loss += loss.item()
            probs = torch.softmax(logits,
dim=1).cpu().numpy()
            preds_all.extend(probs.argmax(axis=1))
            probs_all.extend(probs)
            labels_all.extend(labels.cpu().numpy())
            f1 = f1_score(labels_all, preds_all, average="macro",
zero_division=0)
        return total_loss / len(loader), f1, preds_all, probs_all

# CELL 16 C2@2" MODEL HYBRID: IndoBERT + LDA (h_final =
concat([h_CLS, Ae_d]))
from transformers import AutoModel

class HybridBERTLDA(nn.Module):
    """
    Model hybrid yang menggabungkan [CLS] representation
    IndoBERT (h_CLS)
    dengan distribusi topik LDA (Ae_d) via concatenation
    (feature-level fusion).

    Forward:
        h_final = concat([h_CLS, Ae_d])          C2€€
C2,,k^(H+K)

```

```

        h_norm = LayerNorm(h_final)
    C2,,K^(H+K)
    p(y|d) = softmax(W_clsA2 · h_norm + b_cls) C2€€
    C2,,K^3
    """

    def __init__(self, bert_model_name: str, num_topics: int,
                  num_labels: int = 3, dropout: float = 0.3):
        super().__init__()
        self.bert =
AutoModel.from_pretrained(bert_model_name)
        bert_dim = self.bert.config.hidden_size #
H=768 untuk bert-base
        self.dropout = nn.Dropout(dropout)
        self.layer_norm = nn.LayerNorm(bert_dim + num_topics)
        # Klasifikasi langsung dari h_norm C2†' 3 kelas
        self.classifier = nn.Linear(bert_dim + num_topics,
num_labels) # W_cls

    def forward(self, input_ids, attention_mask, topic_dist):
        """
        Args:
            input_ids      : (batch, seq_len)
            attention_mask : (batch, seq_len)
            topic_dist     : (batch, K) C2@2" distribusi
Aeë_d dari LDA
        Returns:
            logits         : (batch, 3)
        """
        bert_out = self.bert(input_ids=input_ids,
attention_mask=attention_mask)
        h_cls = bert_out.last_hidden_state[:, 0, :] #
[CLS] token: (batch, 768)

        # Persamaan h_final = concat([h_CLS, Aeë_d])
        h_final = torch.cat([h_cls, topic_dist], dim=1) #
(batch, 768+K)

        # Persamaan h_norm = LayerNorm(h_final)
        h_norm = self.layer_norm(h_final)
        h_drop = self.dropout(h_norm)

        # Persamaan logits = W_cls A2 · h_norm + b_cls
        logits = self.classifier(h_drop)
        return logits

# CELL 17A PERBANDINGAN SKEMA SPLIT DATASET (JUSTIFIKASI
PEMILIHAN SPLIT)
# 80:10:10 | 70:10:20 | 70:20:10 | 60:20:20

from sklearn.model_selection import train_test_split

```

```

from sklearn.utils.class_weight import compute_class_weight
from sklearn.metrics import accuracy_score
from transformers import get_linear_schedule_with_warmup

X_text = df["text_bert"].values
X_theta = np.stack(df["topic_dist"].values) # shape: (N,
K_OPTIMAL)
y = df["label_id"].values
idx_all = np.arange(len(df))

N_EPOCHS_SPLIT_TEST = 3 # epoch terbatas KHUSUS untuk uji
sensitivitas split
neg_id = LABEL_MAP["negative"]

# Fine-tuning cepat (epoch terbatas) untuk uji
sensitivitas
ds_tr_c = HybridNewsDataset(X_text[idx_train_c],
X_theta[idx_train_c], y[idx_train_c], tokenizer)
ds_te_c = HybridNewsDataset(X_text[idx_test_c],
X_theta[idx_test_c], y[idx_test_c], tokenizer)

dl_tr_c = DataLoader(ds_tr_c, batch_size=BATCH_SIZE,
shuffle=True, num_workers=2, pin_memory=True)
dl_te_c = DataLoader(ds_te_c, batch_size=BATCH_SIZE,
shuffle=False, num_workers=2, pin_memory=True)

classes_c = np.unique(y[idx_train_c])
weights_c = compute_class_weight("balanced",
classes=classes_c, y=y[idx_train_c])
cw_c = torch.tensor(weights_c,
dtype=torch.float).to(DEVICE)

model_c = HybridBERTLDA(INDOBERT_MODEL,
num_topics=K_OPTIMAL,
num_labels=3,
dropout=0.3).to(DEVICE)
criterion_c = nn.CrossEntropyLoss(weight=cw_c)
optimizer_c = AdamW(model_c.parameters(),
lr=LEARNING_RATE, weight_decay=WEIGHT_DECAY)
total_steps_c = len(dl_tr_c) * N_EPOCHS_SPLIT_TEST
scheduler_c = get_linear_schedule_with_warmup(
optimizer_c,
num_warmup_steps = int(total_steps_c *
WARMUP_RATIO),
num_training_steps = total_steps_c,
)

for ep in range(1, N_EPOCHS_SPLIT_TEST + 1):
    train_epoch_hybrid(model_c, dl_tr_c, optimizer_c,
scheduler_c, criterion_c)

```

```

_, _, preds_c, _ = eval_epoch_hybrid(model_c, dl_te_c,
criterion_c)
acc_c = accuracy_score(y[idx_test_c], preds_c)
f1_c = f1_score(y[idx_test_c], preds_c, average="macro",
zero_division=0)
print(f" C2+' Setelah {N_EPOCHS_SPLIT_TEST} epoch fine-
tuning cepat: "
f"Accuracy={acc_c:.4f} | F1-macro={f1_c:.4f}")

# Keputusan skema split final
BEST_SPLIT = SPLIT_CONFIGS[0]
winner_row =
df_split_comparison.loc[df_split_comparison["F1-macro (uji
cepat)"].idxmax()]
winner_label = winner_row["Skema Split"]
row_8010 =
df_split_comparison.loc[df_split_comparison["Skema Split"] ==
BEST_SPLIT["label"]].iloc[0]

print(f"\n[KEPUTUSAN] Skema split yang digunakan pada
eksperimen utama: {BEST_SPLIT['label']}")

# CELL 17 PERSIAPAN DATA SPLIT
from sklearn.model_selection import train_test_split
from sklearn.utils.class_weight import compute_class_weight

X_text = df["text_bert"].values
X_theta = np.stack(df["topic_dist"].values) # shape: (N,
K_OPTIMAL)
y = df["label_id"].values

test_size = BEST_SPLIT["test"]
val_size = BEST_SPLIT["val"] / (1 - test_size)

idx_all = np.arange(len(df))

idx_tv, idx_test = train_test_split(
idx_all, test_size=test_size, stratify=y,
random_state=RANDOM_STATE)
idx_train, idx_val = train_test_split(
idx_tv, test_size=val_size, stratify=y[idx_tv],
random_state=RANDOM_STATE)

print(f"Split ({BEST_SPLIT['label']}): "
f"Train={len(idx_train):,} | Val={len(idx_val):,} |
Test={len(idx_test):,}")

ds_train = HybridNewsDataset(X_text[idx_train],
X_theta[idx_train],
y[idx_train], tokenizer)

```

```

ds_val    = HybridNewsDataset(X_text[idx_val],
X_theta[idx_val],
                                y[idx_val],    tokenizer)
ds_test   = HybridNewsDataset(X_text[idx_test],
X_theta[idx_test],
                                y[idx_test],    tokenizer)

dl_train = DataLoader(ds_train, batch_size=BATCH_SIZE,
shuffle=True,
                                num_workers=2, pin_memory=True)
dl_val    = DataLoader(ds_val,    batch_size=BATCH_SIZE,
shuffle=False,
                                num_workers=2, pin_memory=True)
dl_test   = DataLoader(ds_test,  batch_size=BATCH_SIZE,
shuffle=False,
                                num_workers=2, pin_memory=True)

# Class weight untuk menangani imbalance
classes = np.unique(y[idx_train])
weights = compute_class_weight("balanced", classes=classes,
y=y[idx_train])
cw       = torch.tensor(weights, dtype=torch.float).to(DEVICE)

# CELL 18 INISIALISASI DAN TRAINING MODEL HYBRID
from transformers import get_linear_schedule_with_warmup

model = HybridBERTLDA(
    bert_model_name = INDOBERT_MODEL,
    num_topics      = K_OPTIMAL,
    num_labels      = 3,
    dropout         = 0.3,
).to(DEVICE)

criterion = nn.CrossEntropyLoss(weight=cw)
optimizer = AdamW(model.parameters(), lr=LEARNING_RATE,
weight_decay=WEIGHT_DECAY)

total_steps = len(dl_train) * NUM_EPOCHS
warmup_steps = int(total_steps * WARMUP_RATIO)
scheduler    = get_linear_schedule_with_warmup(
    optimizer,
    num_warmup_steps = warmup_steps,
    num_training_steps = total_steps,
)

# CELL 19 EVALUASI MODEL PADA TEST SET

from sklearn.metrics import classification_report,
confusion_matrix

model.load_state_dict(torch.load(os.path.join(MDL_DIR,

```

```

"best_hybrid_model.pt"))
model.eval()

_, test_f1, test_preds, test_probs = eval_epoch_hybrid(model,
dl_test, criterion)

print("=" * 60)
print("EVALUASI MODEL HYBRID PADA TEST SET")
print("=" * 60)
print(f"\n Test F1-macro: {test_f1:.4f}")
print()
print("[CLASSIFICATION REPORT]")
report_str = classification_report(
    y[idx_test], test_preds,
    target_names=LABEL_NAMES, digits=4,
)
print(report_str)

# Confusion Matrix
cm = confusion_matrix(y[idx_test], test_preds)
fig, ax = plt.subplots(figsize=(6, 5))
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
            xticklabels=LABEL_NAMES, yticklabels=LABEL_NAMES,
ax=ax,
            annot_kws={"size": 12})
ax.set_title("Confusion Matrix C2@2" Model Hybrid LDA-
IndoBERT",
            fontweight="bold", fontsize=11)
ax.set_ylabel("Label Aktual", fontsize=10)
ax.set_xlabel("Prediksi Model", fontsize=10)
plt.tight_layout()
plt.savefig(os.path.join(FIG_DIR,
"fig_confusion_matrix.png"), dpi=150)
plt.show()

# CELL 19 ABLATION STUDY: MODEL 1 (IndoBERT SAJA) vs MODEL 2
(HYBRID)
from sklearn.metrics import accuracy_score,
precision_recall_fscore_support

class SimpleBERTDataset(Dataset):
    """Dataset untuk Model 1 (baseline): hanya teks judul,
    tanpa Aeë_d."""
    def __init__(self, texts, labels, tokenizer,
max_len=MAX_LEN):
        self.texts = texts
        self.labels = labels
        self.tokenizer = tokenizer
        self.max_len = max_len

    def __len__(self):

```

```

        return len(self.texts)

    def __getitem__(self, idx):
        enc = self.tokenizer(
            self.texts[idx],
            max_length = self.max_len,
            padding = "max_length",
            truncation = True,
            return_tensors = "pt",
        )
        return {
            "input_ids" : enc["input_ids"].squeeze(),
            "attention_mask" :
enc["attention_mask"].squeeze(),
            "label" : torch.tensor(self.labels[idx],
dtype=torch.long),
        }
class IndoBERTBaseline(nn.Module):
    """
    Model 1 (baseline / ablation): Fine-tuned IndoBERT tanpa
informasi topik.
    Forward:
        h_cls = BERT(input_ids, attention_mask)[CLS]
        logits = W A2 · dropout(h_cls) + b
    """
    def __init__(self, bert_model_name: str, num_labels: int
= 3, dropout: float = 0.3):
        super().__init__()
        self.bert =
AutoModel.from_pretrained(bert_model_name)
        bert_dim = self.bert.config.hidden_size
        self.dropout = nn.Dropout(dropout)
        self.classifier = nn.Linear(bert_dim, num_labels)

    def forward(self, input_ids, attention_mask):
        bert_out = self.bert(input_ids=input_ids,
attention_mask=attention_mask)
        h_cls = bert_out.last_hidden_state[:, 0, :]
        logits = self.classifier(self.dropout(h_cls))
        return logits

def train_epoch_baseline(model, loader, optimizer, scheduler,
criterion):
    model.train()
    total_loss, preds_all, labels_all = 0.0, [], []
    for batch in loader:
        input_ids = batch["input_ids"].to(DEVICE)
        attention_mask = batch["attention_mask"].to(DEVICE)
        labels = batch["label"].to(DEVICE)

```

```

optimizer.zero_grad()
logits = model(input_ids, attention_mask)
loss = criterion(logits, labels)
loss.backward()
nn.utils.clip_grad_norm_(model.parameters(), 1.0)
optimizer.step()
scheduler.step()
total_loss += loss.item()
preds_all.extend(logits.argmax(dim=1).cpu().numpy())
labels_all.extend(labels.cpu().numpy())
f1 = f1_score(labels_all, preds_all, average="macro",
zero_division=0)
return total_loss / len(loader), f1

def eval_epoch_baseline(model, loader, criterion):
    model.eval()
    total_loss, preds_all, labels_all = 0.0, [], []
    with torch.no_grad():
        for batch in loader:
            input_ids = batch["input_ids"].to(DEVICE)
            attention_mask =
batch["attention_mask"].to(DEVICE)
            labels = batch["label"].to(DEVICE)
            logits = model(input_ids, attention_mask)
            loss = criterion(logits, labels)
            total_loss += loss.item()

    preds_all.extend(logits.argmax(dim=1).cpu().numpy())
    labels_all.extend(labels.cpu().numpy())
    f1 = f1_score(labels_all, preds_all, average="macro",
zero_division=0)
    return total_loss / len(loader), f1, preds_all

#Evaluasi Model 1 pada test set
model_baseline.load_state_dict(torch.load(BASELINE_MODEL_PATH
))
model_baseline.eval()
_, _, baseline_test_preds =
eval_epoch_baseline(model_baseline, dl_test_base,
criterion_base)

print("\n[CLASSIFICATION REPORT] Model 1 C2@2" IndoBERT saja
(input: judul)")
print(classification_report(y[idx_test], baseline_test_preds,
target_names=LABEL_NAMES,
digits=4))

# CELL 19C TABEL PERBANDINGAN ABLATION: MODEL 1 vs MODEL 2
def hitung_metrik_ablation(y_true, y_pred):
    acc = accuracy_score(y_true, y_pred)
    prec_w, rec_w, f1_w, _ = precision_recall_fscore_support(

```

```

    y_true, y_pred, average="weighted", zero_division=0)
    prec_m, rec_m, f1_m, _ = precision_recall_fscore_support(
        y_true, y_pred, average="macro", zero_division=0)
    return {
        "Accuracy"           : round(acc, 4),
        "Precision (macro)"   : round(prec_m, 4),
        "Recall (macro)"      : round(rec_m, 4),
        "F1-macro"           : round(f1_m, 4),
        "Precision (weighted)": round(prec_w, 4),
        "Recall (weighted)"   : round(rec_w, 4),
        "F1-weighted"        : round(f1_w, 4),
    }

metrik_model1 = hitung_metrik_ablation(y[idx_test],
baseline_test_preds)
metrik_model2 = hitung_metrik_ablation(y[idx_test],
test_preds)

df_ablation = pd.DataFrame([
    {"Model": "Model 1: Fine-tuned IndoBERT (input: judul)",
    **metrik_model1},
    {"Model": "Model 2: Hybrid LDA-IndoBERT (input: h_CLS
C2@9• Aeë_d)", **metrik_model2},
])

# CELL 20 KURVA TRAINING (LOSS DAN F1)
epochs_ran = len(history["train_loss"])

fig, axes = plt.subplots(1, 2, figsize=(13, 4))

ax1 = axes[0]
ax1.plot(range(1, epochs_ran+1), history["train_loss"],
        "o-", label="Train Loss", color="#1976D2",
        linewidth=2)
ax1.plot(range(1, epochs_ran+1), history["val_loss"],
        "s--", label="Val Loss", color="#F57C00",
        linewidth=2)
ax1.set_title("Training vs Validation Loss",
fontweight="bold")
ax1.set_xlabel("Epoch"); ax1.set_ylabel("Loss")
ax1.legend(); ax1.grid(alpha=0.3)

ax2 = axes[1]
ax2.plot(range(1, epochs_ran+1), history["train_f1"],
        "o-", label="Train F1", color="#388E3C",
        linewidth=2)
ax2.plot(range(1, epochs_ran+1), history["val_f1"],
        "s--", label="Val F1", color="#C62828", linewidth=2)
ax2.axhline(y=best_val_f1, color="gray", linestyle=":",
        linewidth=1,
        label=f"Best Val F1={best_val_f1:.4f}")

```

```

ax2.set_title("Training vs Validation F1-macro",
fontweight="bold")
ax2.set_xlabel("Epoch"); ax2.set_ylabel("F1-macro")
ax2.legend(); ax2.grid(alpha=0.3)

plt.tight_layout()
plt.savefig(os.path.join(FIG_DIR, "fig_training_curves.png"),
dpi=150)
plt.show()

# CELL 21 PREDIKSI SENTIMEN PADA SELURUH DATASET

ds_full = HybridNewsDataset(X_text, X_theta, y, tokenizer)
dl_full = DataLoader(ds_full, batch_size=BATCH_SIZE,
shuffle=False,
                    num_workers=2, pin_memory=True)

_, _, all_preds, all_probs = eval_epoch_hybrid(model,
dl_full, criterion)

id2label = {v: k for k, v in LABEL_MAP.items()}
df["prediksi_sentimen"] = [id2label[p] for p in all_preds]
df["prob_positive"] = [round(p[0], 4) for p in all_probs]
df["prob_negative"] = [round(p[1], 4) for p in all_probs]
df["prob_neutral"] = [round(p[2], 4) for p in all_probs]

# CELL 22 MATRIKS DISTRIBUSI SENTIMEN PER ASPEK

df_absa = df[df["aspek"] != "Tidak Terdefinisi"].copy()
print(f"Dokumen dengan aspek terdefinisi: {len(df_absa):,}")

ct = pd.crosstab(df_absa["aspek"],
df_absa["prediksi_sentimen"])
for col in LABEL_NAMES:
    if col not in ct.columns:
        ct[col] = 0
ct = ct[LABEL_NAMES]

# Frekuensi absolut
ct_abs = ct.copy()
ct_abs.columns = [f"{c} (n)" for c in LABEL_NAMES]

# Persentase
ct_pct = ct.div(ct.sum(axis=1), axis=0).mul(100).round(2)
ct_pct.columns = [f"{c} (%)" for c in LABEL_NAMES]

matriks_absa = pd.concat([ct_abs, ct_pct], axis=1)
matriks_absa["Total"] = ct.sum(axis=1)
matriks_absa = matriks_absa.reset_index()

avg_prob_absa =

```

```

df_absa.groupby("aspek")["max_prob"].mean().round(4).reset_index()
avg_prob_absa.columns = ["aspek", "Rata-rata max_prob"]
matriks_absa = matriks_absa.merge(avg_prob_absa, on="aspek",
how="left")

# CELL 23 VISUALISASI ABSA: DISTRIBUSI SENTIMEN PER ASPEK
ct_plot = ct_pct.copy()
ct_plot.columns = LABEL_NAMES

colors = {"positive": "#4CAF50", "negative": "#F44336",
"neutral": "#9E9E9E"}

fig, ax = plt.subplots(figsize=(12, max(5, len(ct_plot) *
0.7)))
ct_plot.plot(kind="barh", stacked=True,
             color=[colors[c] for c in LABEL_NAMES], ax=ax)
ax.set_title("Distribusi Sentimen per Aspek (Output ABSA)",
             fontsize=13, fontweight="bold")
ax.set_xlabel("Persentase (%)")
ax.set_ylabel("Aspek Tematik")
ax.axvline(x=50, color="black", linestyle="--",
linewidth=0.8, alpha=0.4)
ax.legend(loc="lower right", fontsize=9)
plt.tight_layout()
plt.savefig(os.path.join(FIG_DIR,
"fig_absa_sentimen_per_aspek.png"), dpi=150)
plt.show()

```

Lampiran 2. Data Penelitian

No	judul	tanggal	sentimen
1	Direktur Garuda Salman El Farisiy Meninggal, Ini Sosoknya!	1/1/2024	negatif
2	Catatan Sejarah 2023, Indonesia Luncurkan Bursa Karbon	1/1/2024	netral
3	Ramalan Bitcoin Paling Gila 2024, Naik 1.000% Jadi US\$500.000	1/1/2024	netral
4	Wah! Segini Harta Mantan Istri Prabowo Titiek Soeharto	1/1/2024	netral
5	Pensiun di Oktober 2024, Jokowi Kantongi Uang Pensiun Segini!	1/1/2024	netral
6	Gas! 8 Emiten Baru Bakal Melantai di Bursa 2024, Siapa Saja?	1/1/2024	positif
7	Wall Street Mengawali Tahun 2024 Dengan Tak Sumringah	1/2/2024	negatif
8	Jika Jiwasraya Dibubarkan, Aset Saham Bakal Dijual?	1/2/2024	negatif
9	Pernikahan Viral, Segini Harta Budisatrio Keponakan Prabowo	1/2/2024	netral
10	Satgas Pasti OJK Blokir 6.680 Pinjol Ilegal dan Pinpri	1/2/2024	negatif
⋮	⋮	⋮	⋮
9810	Dasco Yakin IHSG Lanjut Hijau Usai Lebaran, Ungkap Rencana Prabowo	3/31/2025	positif
9811	Saham Asia Rontok Jelang Pengumuman Tarif Trump, Nikkei Anjlok	3/31/2025	negatif
9812	Robert Kiyosaki Blak-blakan Sebut Warga RI Keliru Cara Siapkan Pensiun	3/31/2025	netral
9813	Terjerat Utang Bikin Kerja Sampai Tua, Jadikan Pelajaran!	3/31/2025	netral
9814	Harga Emas Cetak Rekor Terus, Kapan Waktu Terbaik Buat Beli?	3/31/2025	netral
9815	Trump Teriak Ancaman Baru ke Putin, Begini Nasib Harga Minyak	3/31/2025	negatif
9816	Bocoran Luhut, Prabowo Temui Investor Pasar Modal Usai Lebaran	3/31/2025	netral
9817	Beli Emas 15 Kg Pakai Uang Tunai, Wanita Ini Dikritik Habis-habisan	3/31/2025	netral
9818	Kisah Runtuhnya Raja Ritel RI di Balik Kelahiran Matahari	3/31/2025	netral
9819	Main di Sungai Ketemu Harta Karun Rp 6 Miliar, Langsung Kaya!	3/31/2025	netral

Lampiran 3. Klasifikasi Sentimen dengan Model Hybrid LDA-IndoBERT

No	judul	tanggal	sentimen	dominant_topic	max_prob	aspek	label_id	prediksi_sentimen
1	Direktur Garuda Salman El Farisiy Meninggal, Ini Sosoknya!	2024/01/01	negative	0	0.8605 16191	Aktivitas Perusahaan dan Tokoh Bisnis	1	negative
2	Catatan Sejarah 2023, Indonesia Luncurkan Bursa Karbon	2024/01/01	neutral	0	0.7051 01371	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
3	Ramalan Bitcoin Paling Gila 2024, Naik 1.000% Jadi US\$500.000	2024/01/01	neutral	1	0.6876 88947	Sektor Perbankan dan BUMN	2	neutral
4	Wah! Segini Harta Mantan Istri Prabowo Titiek Soeharto	2024/01/01	neutral	0	0.4126 13988	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
5	Pensiun di Oktober 2024, Jokowi Kantongi Uang Pensiun Segini!	2024/601/0 1	neutral	1	0.7549 49033	Sektor Perbankan dan BUMN	2	neutral
6	Gas! 8 Emiten Baru Bakal Melantai di Bursa 2024, Siapa Saja?	2024/01/01	positive	0	0.9304 85547	Aktivitas Perusahaan dan Tokoh Bisnis	0	neutral
7	Wall Street Mengawali Tahun 2024 Dengan Tak Sumringah	2024/01/02	negative	2	0.8909 90973	Pergerakan Pasar Saham dan Nilai Tukar	1	negative
8	Jika Jiwasraya Dibubarkan, Aset Saham Bakal Dijual?	2024/01/02	negative	3	0.5898 41366	Regulasi dan Pengawasan Sektor	1	negative

						Keuangan		
9	Pernikahan Viral, Segini Harta Budisatrio Keponakan Prabowo	2024/01/02	neutral	0	0.4718 15407	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
10	Satgas Pasti OJK Blokir 6.680 Pinjol Ilegal dan Pinpri	2024/01/02	negative	3	0.9163 41066	Regulasi dan Pengawasan Sektor Keuangan	1	negative
11	PTBA Gandeng KAI, Mau Angkut 20 Juta Ton Batu Bara	2024/01/02	positive	0	0.6421 37647	Aktivitas Perusahaan dan Tokoh Bisnis	0	positive
12	Kapan Kripto Diawasi OJK? Ini Bocorannya	2024/01/02	neutral	3	0.9150 0169	Regulasi dan Pengawasan Sektor Keuangan	2	neutral
13	Dapat Restu RKAB, Produksi Batu Bara BUMI Bisa Capai Segini	2024/01/02	neutral	0	0.5213 39118	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
14	Waktu Habis, Emiten Tak Penuhi Free Float 7,5% Dibuka Bursa	2024/01/02	negative	0	0.6928 11728	Aktivitas Perusahaan dan Tokoh Bisnis	1	negative
15	Perdagangan Perdana 2024, IHSG Cetak Rekor Baru di 7.323,59	2024/01/02	positive	2	0.6416 38935	Pergerakan Pasar Saham dan Nilai Tukar	0	positive
	:	:	:	:	:	:	:	:
9733	Sosok Muslim Terkaya, Berharta Rp 36 T Berkat Ikuti Nasihat Orang Tua	2025/03/30	neutral	0	0.9312 99984	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral

9734	Tukang Becak Dapat Uang Rp 50 Miliar Semalam, Mendadak Jadi Miliarder	2025/03/30	neutral	0	0.7710 02054	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
9735	Ramai-Ramai Demonstran AS-Eropa Kecam Elon Musk, Ini Biang Keroknya	2025/03/30	negative	2	0.5407 70829	Pergerakan Pasar Saham dan Nilai Tukar	1	negative
9736	Lo Kheng Hong Bongkar Kebiasaan Bikin Miskin, Ingatkan Investor Saham	2025/03/31	neutral	1	0.7071 08855	Sektor Perbankan dan BUMN	2	neutral
9737	Marina Budiman Kini Perempuan Terkaya Indonesia, Ini Bisnisnya	2025/03/31	neutral	0	0.8832 8445	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
9738	Dasco Yakin IHSG Lanjut Hijau Usai Lebaran, Ungkap Rencana Prabowo	2025/03/31	positive	2	0.5302 50311	Pergerakan Pasar Saham dan Nilai Tukar	0	positive
9739	Saham Asia Rontok Jelang Pengumuman Tarif Trump, Nikkei Anjlok	2025/03/31	negative	2	0.8134 26554	Pergerakan Pasar Saham dan Nilai Tukar	1	negative
9740	Robert Kiyosaki Blak-blakan Sebut Warga RI Keliru Cara Siapkan Pensiun	2025/03/31	neutral	1	0.6352 08607	Sektor Perbankan dan BUMN	2	neutral
9741	Terjerat Utang Bikin Kerja Sampai Tua, Jadikan Pelajaran!	2025/03/31	neutral	0	0.4745 51857	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
9742	Harga Emas Cetak Rekor Terus, Kapan Waktu Terbaik Buat Beli?	2025/03/31	neutral	1	0.6024 70636	Sektor Perbankan dan BUMN	2	neutral

9743	Trump Teriak Ancaman Baru ke Putin, Begini Nasib Harga Minyak	2025/03/31	negative	1	0.4804 55905	Sektor Perbankan dan BUMN	1	negative
9744	Bocoran Luhut, Prabowo Temui Investor Pasar Modal Usai Lebaran	2025/03/31	neutral	3	0.9303 05064	Regulasi dan Pengawasan Sektor Keuangan	2	neutral
9745	Beli Emas 15 Kg Pakai Uang Tunai, Wanita Ini Dikritik Habis-habisan	2025/03/31	neutral	3	0.4878 12638	Regulasi dan Pengawasan Sektor Keuangan	2	neutral
9746	Kisah Runtuhnya Raja Ritel RI di Balik Kelahiran Matahari	2025/03/31	neutral	0	0.5270 50078	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral
9747	Main di Sungai Ketemu Harta Karun Rp 6 Miliar, Langsung Kaya!	2025/03/31	neutral	0	0.7462 60166	Aktivitas Perusahaan dan Tokoh Bisnis	2	neutral