


Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dalam Pengelompokan Wilayah Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan



JULIANDA PUTRA MANSUR

H011221038

PROGRAM STUDI MATEMATIKA

DEPARTEMEN MATEMATIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS HASANUDDIN

MAKASSAR

2026



**Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan
Agglomerative Hierarchical Clustering dalam Pengelompokan Wilayah
Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan**

JULIANDA PUTRA MANSUR

H011221038



**PROGRAM STUDI MATEMATIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR**

2026

**Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan
Agglomerative Hierarchical Clustering dalam Pengelompokan Wilayah
Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan**

JULIANDA PUTRA MANSUR

H011221038

SKRIPSI

Sebagai salah satu syarat untuk mencapai gelar sarjana

Program Studi Matematika

Pada

**DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

SKRIPSI

Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan
Agglomerative Hierarchical Clustering dalam Pengelompokan Wilayah
Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan

Julianda Putra Mansur

H011221038

Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana pada tanggal 4
Agustus 2026 dan dinyatakan telah memenuhi syarat kelulusan
pada

Program Studi Matematika
Departemen Matematika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:
Pembimbing tugas akhir,

Dr. Khaeruddin, M.Sc.
NIP. 196509141991031003



Mengetahui:
Ketua Program Studi,

Dr. Firman, S.Si., M.Si
NIP 196804292002121001

**PERNYATAAN KEASLIAN SKRIPSI
DAN PELIMPAHAN HAK CIPTA**

Dengan ini saya menyatakan bahwa, skripsi berjudul "Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dalam Pengelompokan Wilayah Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan" adalah benar karya saya dengan arahan dari pembimbing Dr. Khaeruddin, M.Sc. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 4 Agustus 2026



Julianda Putra Mansur
NIM H011221038

UCAPAN TERIMA KASIH

Puji dan Syukur kehadiran Allah SWT. Tuhan Yang Maha Esa, atas berkat rahmat, hidayah, kemudahan, dan segala limpahan nikmat-Nya sehingga penulis dapat menyelesaikan skripsi ini dengan judul “Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dalam Pengelompokan Wilayah Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan” sebagai salah satu syarat untuk memperoleh gelar Sarjana Matematika pada Program Studi Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin. Shalawat serta salam senantiasa tercurahkan kepada Nabi Muhammad SAW sebagai suri tauladan bagi seluruh umatnya.

Penulis menyadari bahwa skripsi ini tidak mungkin terselesaikan tanpa adanya dukungan, bantuan, arahan, serta bimbingan dari berbagai pihak selama penyusunan skripsi ini. Oleh karena itu, dengan segala kerendahan hati penulis menyampaikan terima kasih yang setulus-tulusnya kepada:

1. Bapak Prof. Dr. Ir. Jamaluddin Jompa, M.Sc., selaku Rektor Universitas Hasanuddin beserta seluruh jajarannya, serta Bapak Dr. Sci. Muhammad Zakir, M.Si., selaku Dekan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin beserta jajarannya.
2. Bapak Dr. Firman, S.Si., M.Si., selaku Ketua Departemen Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin.
3. Bapak Dr. Khaeruddin, M.Sc., selaku dosen pembimbing penulis yang dengan sabar, tulus, banyak memberikan ilmu yang bermanfaat, meluangkan waktu untuk membimbing, memberi masukan, serta arahan dalam penulisan skripsi ini.
4. Bapak Dr. Muhammad Zakir, M.Si. dan Ibu Prof. Dr. Kasbawati, S.Si., M.Si., selaku tim penguji, terima kasih atas waktu yang telah diluangkan untuk memberikan masukan dan kritikan yang membangun terhadap penyempurnaan penulisan skripsi ini.
5. Bapak dan ibu Dosen Program Studi Matematika yang telah memberikan banyak ilmu dan pengetahuan, serta bapak dan ibu staf Departemen Matematika yang telah membantu penulis dalam berbagai hal administrasi.
6. Kedua orang tua penulis Ayah Mansur dan Ibu Murni serta seluruh keluarga penulis yang selalu memberikan kasih sayang tak terhingga, menyemangati, dan memberikan doa di setiap langkah penulis selama perkuliahan.
7. Teman terbaik penulis yang bernama Hendry dan Rifki yang dengan tulus membantu dan mendukung untuk berjuang selama perkuliahan.
8. Teman-Teman Matematika 2022, yang senantiasa memberikan bantuan dan dukungan selama masa perkuliahan penulis.
9. Teman-Teman Bemblajar Online yang selalu menemani penulis dari masa SMA hingga kuliah.
10. Teman-Teman Pengurus IKAB-KIP Unhas dan HIMATIKA yang memberikan penulis kesempatan untuk belajar lebih banyak tentang cara berorganisasi.

11. Teman-teman KKNT 114 Sidrap Lajonga yang telah memberikan pengalaman baru dan warna baru selama pelaksanaan KKN bagi penulis.

Terima kasih kepada semua pihak-pihak yang sudah memberi bantuannya. Semoga Allah SWT. membalas segala kebaikan yang telah diberikan. Semoga skripsi ini dapat menambahkan wawasan dan bermanfaat bagi penulis dan pembaca.

Penulis,

A handwritten signature in black ink, consisting of stylized, overlapping loops and a long horizontal stroke at the end.

Julianda Putra Mansur

ABSTRAK

JULIANDA PUTRA MANSUR. **Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dalam Pengelompokan Wilayah Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan** (dibimbing oleh Khaeruddin)

Latar belakang. Permasalahan gizi balita di Provinsi Sulawesi Selatan bersifat multidimensional, ditandai oleh kesenjangan prevalensi antarwilayah yang mencapai 20%, sehingga diperlukan pendekatan analitik yang mampu memetakan wilayah prioritas secara objektif dan presisi. **Tujuan.** Penelitian ini bertujuan menerapkan dan membandingkan kinerja algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dalam mengelompokkan 24 kabupaten/kota di Sulawesi Selatan berdasarkan lima indikator prevalensi status gizi balita dari data SSGI 2024, serta menentukan algoritma yang paling optimal. **Metode.** Data dinormalisasi menggunakan metode Min-Max sebelum diproses dengan ketiga algoritma. Penentuan jumlah kluster optimal untuk *K-Means* dan *K-Medoids* menggunakan *Silhouette Score*, sedangkan untuk *Agglomerative Hierarchical Clustering* menggunakan analisis celah dendrogram. Evaluasi kualitas pengelompokan dilakukan menggunakan *Silhouette Score*, *Davies-Bouldin Index*, *Calinski-Harabasz Index*, dan *Dunn Index*. **Hasil.** *K-Means* menghasilkan empat kluster dengan kategori prioritas intervensi sangat tinggi (6 daerah), tinggi (11 daerah), sedang (3 daerah), dan rendah (4 daerah). *K-Medoids* menghasilkan tiga kluster dengan kategori prioritas tinggi (4 daerah), sedang (14 daerah), dan rendah (6 daerah). *Agglomerative Hierarchical Clustering* menghasilkan empat kluster dengan kategori prioritas sangat tinggi untuk Kabupaten Jeneponto sebagai kluster tunggal akibat nilai *stunting* (37%) dan *underweight* (26,1%) paling ekstrem di provinsi, prioritas tinggi untuk 16 daerah dengan angka *wasting* tertinggi (8,44%), prioritas sedang untuk 3 daerah dengan pola *stunting* kronis, dan prioritas rendah untuk 4 daerah dengan indikator gizi terbaik. **Kesimpulan.** Berdasarkan pengujian multi-metrik, algoritma *K-Means* ($k=4$) dan *Agglomerative Hierarchical Clustering* ($k=4$) ditetapkan bersama sebagai algoritma paling optimal karena masing-masing unggul pada dua dari empat metrik validitas yang diuji. *K-Means* unggul pada kerapatan struktur global dengan nilai *Silhouette Score* = 0,3498 dan *Calinski-Harabasz Index* = 13,9704, sedangkan *Agglomerative Hierarchical Clustering* unggul pada ketegasan pemisahan kelompok dengan nilai *Davies-Bouldin Index* = 0,7655 dan *Dunn Index* = 0,3423. Integrasi dari kedua algoritma ini menghasilkan rumusan prioritas intervensi kesehatan yang lebih akurat dan menyeluruh berdasarkan data prevalensi gizi balita.

Kata kunci: malnutrisi anak; klusterisasi wilayah; indeks validitas; pengelompokan hierarki; partisi data; pemetaan kesehatan

ABSTRACT

JULIANDA PUTRA MANSUR. **Comparative Analysis of K-Means, K-Medoids, and Agglomerative Hierarchical Clustering Algorithms in Regional Grouping Based on Nutritional Status Indicators of Children Under Five in South Sulawesi** (supervised by Khaeruddin)

Background. The nutritional problem of children under five in South Sulawesi Province is multidimensional, characterized by a prevalence gap between regions reaching 20%, requiring an analytical approach capable of objectively and precisely mapping priority regions. **Aim.** This study aims to apply and compare the performance of *K-Means*, *K-Medoids*, and *Agglomerative Hierarchical Clustering* algorithms in grouping 24 districts/cities in South Sulawesi based on five nutritional status prevalence indicators of children under five from the 2024 SSGI data, and to determine the most optimal algorithm. **Methods.** Data were normalized using the Min-Max method before being processed with the three algorithms. The optimal number of clusters for *K-Means* and *K-Medoids* was determined using *Silhouette Score*, while dendrogram gap analysis was used for *Agglomerative Hierarchical Clustering*. Cluster quality was evaluated using *Silhouette Score*, *Davies-Bouldin Index*, *Calinski-Harabasz Index*, and *Dunn Index*. **Results.** *K-Means* produced four clusters with intervention priority categories of very high (6 regions), high (11 regions), moderate (3 regions), and low (4 regions). *K-Medoids* produced three clusters with priority categories of high (4 regions), moderate (14 regions), and low (6 regions). *Agglomerative Hierarchical Clustering* produced four clusters with a very high priority category for Jeneponto Regency as a singleton cluster due to its most extreme *stunting* (37%) and *underweight* (26.1%) values in the province, high priority for 16 regions with the highest *wasting* rate (8.44%), moderate priority for 3 regions with chronic *stunting* patterns, and low priority for 4 regions with the best nutritional indicators. **Conclusion.** Based on multi-metric testing, the *K-Means* (k=4) and *Agglomerative Hierarchical Clustering* (k=4) algorithms are jointly determined as the most optimal algorithms, as each excels in two out of the four validity metrics tested. *K-Means* outperforms in global structural density with a *Silhouette Score* of 0.3498 and a *Calinski-Harabasz Index* of 13.9704, whereas *Agglomerative Hierarchical Clustering* excels in the distinctness of cluster separation with a *Davies-Bouldin Index* of 0.7655 and a *Dunn Index* of 0.3423. The integration of these two algorithms provides a more accurate and comprehensive formulation of health intervention priorities based on under-five nutritional prevalence data.

Keywords: child malnutrition; regional clustering; validity index; hierarchical grouping; data partitioning; health mapping

DAFTAR ISI

HALAMAN JUDUL.....	i
PERNYATAAN PENGAJUAN.....	ii
LEMBAR PENGESAHAN.....	iii
PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA	iv
UCAPAN TERIMA KASIH.....	v
ABSTRAK.....	vii
ABSTRACT	viii
DAFTAR ISI.....	ix
DAFTAR TABEL.....	xi
DAFTAR GAMBAR.....	xii
DAFTAR LAMPIRAN.....	xiii
BAB I PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	3
1.3. Batasan Masalah	3
1.4. Tujuan Penelitian	4
1.5. Manfaat Penelitian	4
1.6. Landasan Teori	4
1.6.1. Status Gizi Balita	4
1.6.2. Analisis Kluster	5
1.6.3. Matriks Korelasi	5
1.6.4. Normalisasi Data	6
1.6.5. Jarak <i>Euclidean</i>	7
1.6.6. Algoritma Pengelompokan.....	8
1.6.7. Metrik Evaluasi Kluster	15
BAB II METODE PENELITIAN	19
2.1. Sumber Data.....	19
2.2. Deskripsi Variabel	19
2.3. Metode Analisis.....	19

2.4.	Diagram Alur Penelitian.....	20
BAB III HASIL DAN PEMBAHASAN		21
3.1.	Statistik Deskriptif.....	21
3.2.	Hasil Matriks Korelasi.....	21
3.3.	Hasil Normalisasi Data	23
3.4.	Implementasi Algoritma Klasterisasi	23
3.4.1.	Hasil Klasterisasi Algoritma <i>K-Means</i>	23
3.4.2.	Hasil Klasterisasi Algoritma <i>K-Medoids</i>	29
3.4.3.	Hasil Klasterisasi Algoritma <i>Agglomerative Hierarchical Clustering</i>	34
3.5.	Pemilihan Algoritma Terbaik dengan Melakukan Evaluasi Metrik	39
4.1.	Kesimpulan	41
4.2.	Saran	42
DAFTAR PUSTAKA.....		43
LAMPIRAN		44

DAFTAR TABEL

Tabel 1. Ringkasan statistik deskriptif atribut status gizi balita.....	21
Tabel 2. Sampel hasil normalisasi data status gizi balita	23
Tabel 3. Nilai rata-rata silhouette score pada algoritma K-Means untuk setiap	23
Tabel 4. Koordinat centroid awal algoritma K-Means menggunakan metode K-Means++.....	24
Tabel 5. Koordinat centroid akhir algoritma K-Means pada kondisi konvergen	25
Tabel 6. Distribusi keanggotaan klaster akhir algoritma K-Means ($k = 4$) ...	25
Tabel 7. Nilai rata-rata Silhouette Score pada algoritma K-Medoids untuk setiap skenario k	29
Tabel 8. Koordinat medoid awal algoritma K-Medoids.....	30
Tabel 9. Koordinat medoid akhir algoritma K-Medoids pada kondisi konvergen	30
Tabel 10. Distribusi keanggotaan klaster akhir algoritma K-Medoids ($k = 3$)	31
Tabel 11. Analisis celah vertikal dendrogram untuk penentuan jumlah klaster optimal.....	34
Tabel 12. Distribusi keanggotaan klaster akhir algoritma Agglomerative Hierarchical Clustering ($k = 4$)	36

DAFTAR GAMBAR

Gambar 1. Flowchart Algoritma K-Means	9
Gambar 2. Flowchart metode K-Means++	11
Gambar 3. Flowchart Algoritma K-Medoids	13
Gambar 4. Flowchart Algoritma Agglomerative Hierarchical Clustering	14
Gambar 5. Heatmap matriks korelasi antar variabel status gizi balita	22
Gambar 6. Kurva Silhouette Score pada setiap skenario k untuk algoritma K-Means	24
Gambar 7. Grafik Profil Rerata Indikator Gizi Per Klaster Algoritma K-Means	26
Gambar 8. Peta pemetaan wilayah prioritas Intervensi hasil algoritma K-Means (k=4).....	28
Gambar 9. Kurva Silhouette Score pada setiap skenario k untuk algoritma K-Medoids.....	29
Gambar 10. Grafik Profil Rerata Indikator Gizi Per Klaster Algoritma K-Medoids	32
Gambar 11. Peta pemetaan wilayah prioritas Intervensi hasil algoritma K-Medoids (k=3)	33
Gambar 12. Dendrogram hasil Agglomerative Hierarchical Clustering.....	34
Gambar 13. Dendrogram hasil Agglomerative Hierarchical Clustering dengan garis pemotongan pada ambang batas $y = 0,72$	35
Gambar 14. Grafik Profil Rerata Indikator Gizi Per Klaster Algoritma Agglomerative Hierarchical Clustering	37
Gambar 15. Peta pemetaan wilayah prioritas intervensi hasil algoritma Agglomerative Hierarchical Clustering (k=4).....	38

DAFTAR LAMPIRAN

Lampiran 1. Data prevalensi status gizi balita per kabupaten/kota di Provinsi Sulawesi Selatan tahun 2024 (Sumber: SSGI 2024)	44
Lampiran 2. Hasil normalisasi data menggunakan metode Min-Max	44
Lampiran 3. Hasil Iterasi pertama algoritma K-Means.....	45
Lampiran 4. Hasil centroid baru iterasi pertama algoritma K-Means	46
Lampiran 5. Hasil konvergen pada iterasi kedua algoritma K-Means.....	46
Lampiran 6. Hasil Iterasi pertama algoritma K-Medoids.....	46
Lampiran 7. Hasil Iterasi lengkap algoritma K-Medoids (proses pertukaran medoid hingga konvergen).....	47
Lampiran 8. Tahapan penggabungan lengkap algoritma Agglomerative Hierarchical Clustering	48
Lampiran 9. Kode program python untuk statistik deskriptif	49
Lampiran 10. Kode program Python untuk algoritma K-Means dengan menggunakan library python	50
Lampiran 11. Kode program Python untuk algoritma K-Medoids dengan menggunakan library python	54
Lampiran 12. Kode program Python untuk algoritma Agglomerative Hierarchical Clustering dengan menggunakan library python	58
Lampiran 13. Kode program Python untuk algoritma K-Means dengan menggunakan perhitungan.....	62
Lampiran 14. Kode program Python untuk algoritma K-Medoids dengan menggunakan perhitungan manual	63
Lampiran 15. Kode program Python untuk algoritma Agglomerative Hierarchical Clustering dengan menggunakan perhitungan manual.....	65
Lampiran 16. Kode program Python untuk perhitungan metrik evaluasi (Silhouette Score, DBI, Calinski-Harabasz Index, dan Dunn Index)	67
Lampiran 17. Kode program Python untuk normalisasi data	69
Lampiran 18. Kode program Python untuk menampilkan headmap	70
Lampiran 19. Kode program untuk membuat peta hasil clustering.....	72

BAB I PENDAHULUAN

1.1. Latar Belakang

Double Burden of Malnutrition (DBM) atau beban ganda malnutrisi pada balita telah menjadi tantangan kesehatan masyarakat global yang sangat kritis. Kondisi ini mencakup spektrum gangguan pertumbuhan yang luas, mulai dari kekurangan gizi (tengkes/*stunting*, berat badan kurang/*underweight*, gizi kurang/*wasting*, dan gizi buruk/*severe wasting*) hingga kelebihan berat badan (*overweight*), yang jika tidak ditangani akan berdampak pada kualitas sumber daya manusia di masa depan. Berdasarkan laporan terbaru *Joint Child Malnutrition Estimates* edisi tahun 2025, tercatat sebanyak 150,2 juta balita di seluruh dunia mengalami *stunting* pada tahun 2024. Selain itu, kondisi *wasting* masih mengancam nyawa sekitar 42,8 juta balita, sementara 35,5 juta lainnya hidup dengan berat badan berlebih atau *overweight* (UNICEF et al., 2025). Lambatnya kemajuan dalam penanggulangan beban ganda malnutrisi ini menjadi ancaman serius bagi realisasi agenda global dalam *Sustainable Development Goals* (SDGs) target 2.2, yang berkomitmen untuk mengakhiri segala bentuk malnutrisi pada tahun 2030.

Sejalan dengan upaya global tersebut, Pemerintah Indonesia melalui Rencana Pembangunan Jangka Menengah Nasional telah menetapkan target penurunan prevalensi *stunting* nasional hingga angka 14,2% pada tahun 2029. Merujuk pada hasil Survei Status Gizi Indonesia (SSGI) tahun 2024 yang dirilis secara resmi oleh Kementerian Kesehatan pada Mei 2025, prevalensi *stunting* nasional saat ini telah berhasil ditekan ke angka 19,8% (Kementerian Kesehatan RI, 2025b). Meskipun tren ini menunjukkan kemajuan positif, angka tersebut masih berada di atas ambang batas standar yang ditetapkan. Selain itu, fokus pada penurunan *stunting* tidak boleh mengabaikan indikator malnutrisi lainnya seperti *underweight* dan *wasting* yang masih fluktuatif, serta ancaman meningkatnya prevalensi *overweight* pada balita (Kementerian Kesehatan RI, 2025a).

Merepresentasikan kondisi tersebut, Provinsi Sulawesi Selatan menjadi salah satu wilayah yang menghadapi tantangan gizi yang cukup kompleks. Hasil analisis berdasarkan data SSGI 2024 menunjukkan bahwa rata-rata prevalensi *stunting* di provinsi ini masih mencapai 25,08%, *underweight* sebesar 21,11%, *wasting* sebesar 7,25%, *severe wasting* sebesar 1,28% dan *overweight* sebesar 2,89%. Perbedaan yang nyata terlihat dari rentang data antar kabupaten/kota yang mencapai 20%, di mana terdapat wilayah dengan angka *stunting* terendah 17% namun ada pula yang mencapai 37% (Kementerian Kesehatan RI, 2025a). Tingginya variasi dan kompleksitas indikator gizi ini menuntut adanya strategi pengelompokan wilayah prioritas yang presisi menggunakan pendekatan matematika, guna memastikan alokasi sumber daya dan intervensi kesehatan tepat sasaran.

Dalam lingkup analisis data, kompleksitas indikator gizi ini dapat disederhanakan melalui teknik analisis kluster. Analisis kluster merupakan pendekatan dalam *unsupervised learning* yang bertujuan untuk menemukan pola tersembunyi pada data dengan cara mengelompokkan objek ke dalam beberapa kumpulan berdasarkan tingkat kemiripan tertentu. Melalui metode ini, kabupaten atau kota di Sulawesi Selatan dipetakan sehingga objek dalam satu kelompok memiliki tingkat keseragaman karakteristik yang tinggi, namun memiliki perbedaan yang nyata dengan objek di kelompok lainnya. Pengelompokan wilayah secara objektif ini sangat penting untuk meminimalisir bias subjektif dalam pengambilan keputusan, sehingga pemerintah dapat merancang program intervensi kesehatan yang lebih spesifik dan tepat sasaran sesuai dengan profil beban malnutrisi di setiap kelompok wilayah tersebut (Ananta dan Sofro, 2025).

Meskipun analisis kluster menawarkan solusi yang efektif, pemilihan algoritma yang tepat menjadi tantangan kritis karena setiap metode memiliki karakteristik yang berbeda. Algoritma *K-Means* bekerja dengan mengelompokkan data berdasarkan kedekatan dengan rata-rata kelompok (*centroid*), namun sangat sensitif terhadap pencilan. Sebagai alternatif yang lebih tangguh pencilan, algoritma *K-Medoids* menggunakan objek nyata sebagai pusat kelompok (*medoids*) sehingga lebih tahan terhadap pengaruh data ekstrem dibandingkan *K-Means* (Ananta dan Sofro, 2025). Selain metode berbasis partisi tersebut, pendekatan *Agglomerative Hierarchical Clustering* dapat digunakan untuk membentuk struktur kelompok secara bertahap melalui pendekatan *bottom-up* yang divisualisasikan dalam bentuk dendrogram. Penggunaan metode hierarki ini terbukti efektif dalam mengidentifikasi wilayah dengan permasalahan gizi yang tinggi guna membantu evaluasi kebijakan secara berkala (Raihannabil, 2024).

Penelitian mengenai analisis Kluster pada indikator kesehatan dan gizi di Indonesia telah berkembang pesat dengan berbagai pendekatan algoritma. Ananta dan Sofro (2025) melakukan studi komparatif antara algoritma *K-Means* dan *K-Medoids* untuk mengelompokkan provinsi berdasarkan Indeks Penanganan *Stunting* (IKPS) tahun 2022. Hasil penelitian tersebut menunjukkan bahwa algoritma *K-Medoids* menghasilkan kualitas kluster yang lebih baik dibandingkan *K-Means*, yang ditunjukkan dengan nilai *Davies-Bouldin Index* yang lebih rendah serta hasil kelompok yang lebih kuat terhadap pencilan. Selain metode berbasis partisi, penggunaan metode hierarki juga telah diterapkan oleh Raihannabil (2024) untuk klusterisasi provinsi berdasarkan indikator status gizi anak bawah dua tahun (*baduta*) tahun 2023. Penelitian tersebut menegaskan bahwa algoritma *Agglomerative Hierarchical Clustering* efektif dalam mengidentifikasi wilayah dengan permasalahan gizi buruk. Pendekatan lain yang juga relevan adalah penggunaan logika *fuzzy* oleh Andriany, Kusnandar, dan Perdana (2021) yang menerapkan metode *Fuzzy Subtractive Clustering* untuk mengelompokkan provinsi berdasarkan prevalensi gizi tahun 2019, guna membantu identifikasi perbedaan angka permasalahan gizi akibat kondisi geografis yang kompleks.

Berbagai studi tersebut menunjukkan bahwa setiap algoritma memiliki kekuatan tersendiri dalam menangani data kesehatan, baik dari segi ketahanan terhadap pencilan maupun kemampuan visualisasi struktur wilayah. Namun, mayoritas penelitian terdahulu masih berfokus pada skala nasional. Di sisi lain, karakteristik prevalensi gizi di tingkat kabupaten/kota di Sulawesi Selatan memiliki variasi yang sangat dinamis, sehingga

memerlukan analisis yang lebih spesifik. Penelitian ini memposisikan diri sebagai pengembangan dari studi-studi tersebut dengan melakukan analisis komparatif tiga metode sekaligus, yaitu *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering*. Penggunaan metode *K-Medoids* didasarkan pada sifatnya yang lebih kuat terhadap pencilon, sementara algoritma *Agglomerative Hierarchical Clustering* digunakan untuk mendapatkan struktur pengelompokan yang lebih detail.

Kebaruan utama dalam penelitian ini terletak pada penggunaan dataset terbaru dari hasil SSGI 2024 yang difokuskan pada pemetaan kabupaten dan kota di Provinsi Sulawesi Selatan. Untuk menjamin validitas dan objektivitas hasil pengelompokan, penelitian ini menerapkan pendekatan komparatif dengan menguji kualitas kluster melalui empat metrik evaluasi yaitu *Silhouette Score*, *Davies-Bouldin Index*, *Calinski-Harabasz Index* dan *Dunn Index*. Penggunaan keempat metrik ini diharapkan dapat memberikan landasan matematis yang presisi dan komprehensif bagi Pemerintah Daerah dalam menentukan wilayah prioritas intervensi kesehatan secara lebih efektif. Atas dasar pemikiran tersebut, penulis menyusun tugas akhir dengan judul "**Analisis Perbandingan Algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dalam Pengelompokan Wilayah Berdasarkan Indikator Status Gizi Balita di Sulawesi Selatan**".

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana hasil pengelompokan kabupaten dan kota di Provinsi Sulawesi Selatan berdasarkan indikator status gizi balita menggunakan algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering*?
2. Bagaimana perbandingan performa ketiga algoritma tersebut berdasarkan metrik evaluasi *Silhouette Score*, *Davies-Bouldin Index*, *Calinski-Harabasz Index* dan *Dunn Index*?
3. Manakah algoritma yang paling optimal dalam mengelompokkan wilayah berdasarkan karakteristik sebaran prevalensi gizi balita di Sulawesi Selatan?

1.3. Batasan Masalah

Ruang lingkup penelitian ini difokuskan pada analisis pengelompokan 24 kabupaten dan kota di Provinsi Sulawesi Selatan menggunakan indikator prevalensi status gizi balita yang bersumber dari laporan Survei Status Gizi Indonesia tahun 2024. Perbandingan performa dibatasi pada tiga algoritma, yaitu *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dengan penerapan jarak *Euclidean* sebagai ukuran kemiripan antar objek. Adapun validasi terhadap kualitas kluster yang terbentuk dilakukan secara objektif melalui empat metrik evaluasi matematis, yakni *Silhouette Score*, *Davies-Bouldin Index*, *Calinski-Harabasz Index* dan *Dunn Index*.

1.4. Tujuan Penelitian

Berdasarkan rumusan masalah, maka tujuan penelitian ini sebagai berikut:

1. Menerapkan algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* dalam mengelompokkan kabupaten dan kota di Sulawesi Selatan berdasarkan indikator prevalensi status gizi balita pada data SSGI 2024.
2. Menganalisis perbandingan kualitas hasil pengelompokan dari ketiga algoritma tersebut menggunakan empat metrik evaluasi, yaitu *Silhouette Score*, *Davies-Bouldin Index*, *Calinski-Harabasz Index* dan *Dunn Index*.
3. Menentukan algoritma yang paling optimal dalam memetakan wilayah prioritas intervensi kesehatan di Provinsi Sulawesi Selatan berdasarkan empat metrik evaluasi.

1.5. Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi teoritis bagi pengembangan literatur matematika terapan dan statistika, khususnya sebagai referensi dalam studi perbandingan algoritma *unsupervised learning* untuk pengolahan data. Bagi penulis, studi ini menjadi sarana penguatan kompetensi dalam mengimplementasikan teknik analisis kluster pada permasalahan kesehatan masyarakat secara nyata. Secara praktis, luaran penelitian ini diharapkan mampu menjadi instrumen rujukan bagi Pemerintah Provinsi Sulawesi Selatan dan instansi terkait untuk menentukan strategi intervensi kesehatan balita yang lebih akurat, tepat sasaran, dan berbasis pada hasil analisis data yang valid.

1.6. Landasan Teori

1.6.1. Status Gizi Balita

Status gizi balita merupakan kondisi kesehatan yang ditentukan oleh derajat keberhasilan pemenuhan kebutuhan nutrisi dasar untuk menunjang proses pertumbuhan dan perkembangan fisik anak (Raihannabil, 2024). Berdasarkan dataset dalam penelitian ini, terdapat lima indikator utama parameter status gizi yang digunakan untuk memetakan kondisi gizi balita di Sulawesi Selatan diantaranya yaitu Kelima indikator tersebut meliputi tengkes (*stunting*) yang merupakan gangguan pertumbuhan linear akibat kekurangan gizi jangka panjang, berat badan kurang (*underweight*) yang mencerminkan massa tubuh relatif terhadap usia, serta gizi kurang (*wasting*) yang menunjukkan kondisi kekurangan gizi akut. Selain itu, terdapat gizi buruk (*severe wasting*) sebagai bentuk malnutrisi akut tingkat parah yang memerlukan penanganan medis segera, dan gizi lebih (*overweight*) yang mencerminkan akumulasi lemak berlebih berdasarkan perbandingan berat terhadap tinggi badan. Kelima indikator ini merupakan instrumen krusial dalam mengidentifikasi variasi profil kesehatan antar wilayah.

Kelima indikator tersebut merupakan instrumen krusial dalam mengidentifikasi variasi profil kesehatan antar wilayah. Melalui analisis kluster, prevalensi dari kelima indikator ini dapat digunakan untuk memetakan kabupaten dan kota yang memiliki

karakteristik gizi buruk serupa sehingga strategi intervensi dapat dilakukan secara lebih efektif dan tepat sasaran.

1.6.2. Analisis Klaster

Analisis klaster adalah teknik untuk mengelompokkan data ke dalam beberapa grup berdasarkan tingkat kemiripannya. Tujuan utama dari teknik ini adalah memastikan data yang berada dalam satu kelompok yang sama memiliki kemiripan yang tinggi, sementara data antar kelompok yang berbeda memiliki perbedaan yang sangat nyata. Dalam bidang analisis data, metode ini disebut sebagai pembelajaran tidak diawasi (*unsupervised learning*) karena algoritma akan mencari sendiri pola atau struktur tersembunyi tanpa membutuhkan label kelas di awal.

Menurut Han et al. (2011), analisis klaster dapat dipandang sebagai alat untuk klasifikasi taksonomi, yaitu proses menghasilkan hierarki klasifikasi pada kumpulan observasi berdasarkan kemiripannya. Dalam penelitian ini, analisis klaster digunakan secara fungsional untuk mengelompokkan data prevalensi status gizi dari Survei Status Gizi Indonesia (SSGI), di mana setiap kabupaten atau kota diperlakukan sebagai objek data yang dikelompokkan berdasarkan kemiripan profil risiko gizinya.

Secara teoritis, Han et al. (2011) mengklasifikasikan algoritma clustering ke dalam empat kategori utama, yaitu metode partisi, metode hierarki, metode berbasis kepadatan, dan metode berbasis grid. Namun, penelitian ini secara khusus berfokus pada penerapan dan analisis algoritma dari dua kategori utama, yakni *K-Means* dan *K-Medoids* yang merepresentasikan metode partisi, serta *Agglomerative Hierarchical Clustering* yang merepresentasikan metode hierarki.

Efektivitas dari analisis klaster dipengaruhi oleh pemilihan metrik jarak yang tepat dan algoritma yang mampu menangani karakteristik data, termasuk keberadaan pencilan dan variasi skala antar atribut. Hasil dari pengelompokan ini diharapkan dapat memberikan pemahaman mendalam mengenai struktur data kesehatan di Sulawesi Selatan guna mendukung pengambilan keputusan yang lebih tepat sasaran.

1.6.3. Matriks Korelasi

Matriks korelasi merupakan representasi tabel yang menyajikan hubungan antar-variabel dalam sebuah dataset, di mana koefisien korelasi pearson digunakan sebagai ukuran linear untuk menentukan kekuatan dan arah hubungan tersebut. Nilai koefisien ini berkisar antara -1 hingga 1, nilai 1 menunjukkan korelasi positif sempurna, 0 menandakan tidak adanya korelasi, dan -1 menunjukkan korelasi negatif sempurna. Menurut Amiruddin dan Ishak (2025), penghitungan matriks korelasi sangat penting untuk memahami keterkaitan antar-fitur serta mengidentifikasi potensi redundansi informasi yang dapat memengaruhi performa algoritma pengelompokan. Secara matematis, penentuan angka indeks korelasi antara variabel independen (x) dan variabel dependen (y) dihitung melalui persamaan:

$$r_{xy} = \frac{n\Sigma xy - (\Sigma x)(\Sigma y)}{\sqrt{[n\Sigma x^2 - (\Sigma x)^2][n\Sigma y^2 - (\Sigma y)^2]}} \quad (1)$$

di mana, r_{xy} adalah nilai koefisien korelasi, n adalah total sampel data, x adalah variabel independen dan y adalah variabel dependen.

Sebagai contoh simulasi analisis hubungan antar variabel, digunakan skenario pengujian dengan total sampel sebanyak $n = 5$ objek data untuk mengukur keeratan hubungan linear antara variabel independen x dan variabel dependen y . Berdasarkan hasil tabulasi data awal, diperoleh nilai akumulasi parameter statistik berupa jumlah total nilai x (Σx) sebesar 15, jumlah total nilai y (Σy) sebesar 20, jumlah hasil perkalian kedua variabel (Σxy) sebesar 76, serta jumlah kuadrat dari masing-masing variabel yaitu Σx^2 sebesar 55 dan Σy^2 sebesar 106. Seluruh parameter numerik tersebut kemudian dimasukkan ke dalam rumus koefisien korelasi Pearson untuk menguji kekuatan asosiasi linear antar-variabel. proses perhitungannya sebagai berikut:

$$r_{xy} = \frac{(5 \times 76) - (15 \times 20)}{\sqrt{(5 \times 55 - (15)^2)(5 \times 106 - (20)^2)}} = 0,992$$

Berdasarkan tahapan perhitungan di atas, nilai koefisien korelasi Pearson r_{xy} yang diperoleh adalah 0,992. Nilai yang mendekati 1 ini menunjukkan adanya hubungan linear positif yang sangat kuat dan signifikan antara variabel x dan variabel y . Hal ini berarti setiap kenaikan nilai pada variabel x akan diikuti oleh kenaikan nilai variabel y secara konsisten dan berbanding lurus.

Untuk mempermudah proses deteksi pola hubungan tersebut, matriks korelasi divisualisasikan menggunakan *heatmap*. *Heatmap* adalah representasi grafis yang menunjukkan nilai melalui gradasi warna, di mana warna yang lebih terang atau gelap mencerminkan kekuatan korelasi antar-variabel. Penggunaan teknik ini memungkinkan peneliti untuk secara cepat mengidentifikasi variabel yang paling berpengaruh terhadap hasil klastering dan membantu dalam mengoptimalkan kinerja algoritma.

1.6.4. Normalisasi Data

Normalisasi data merupakan salah satu tahapan dalam pra-pemrosesan data yang bertujuan untuk memastikan bahwa setiap variabel memiliki kontribusi yang seimbang dalam proses analisis. Tambunan et al. (2026) menjabarkan bahwa tujuan utama dari normalisasi adalah untuk menyamakan skala data sehingga variabel dengan rentang nilai yang besar tidak mendominasi algoritma dalam perhitungan jarak. Hal ini terbukti dapat meningkatkan kualitas kluster yang dihasilkan, terutama ketika dataset mengandung fitur numerik dengan skala yang sangat berbeda secara signifikan.

Salah satu teknik yang sering digunakan dalam analisis data adalah normalisasi *Min-Max*. Teknik ini bekerja dengan cara mentransformasikan setiap variabel numerik ke dalam rentang nilai tertentu, yang umumnya berada di antara 0 sampai 1. Normalisasi data dapat dilakukan melalui persamaan berikut:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (2)$$

di mana, x' adalah nilai hasil normalisasi, x adalah nilai awal, x_{min} adalah nilai minimum pada variabel dan x_{max} adalah nilai maksimum pada variabel.

Sebagai contoh, diberikan sebuah variabel dengan lima nilai data yaitu 10, 20, 30, 40, dan 50. Dari data tersebut, diperoleh nilai minimum sebesar 10 dan nilai maksimum sebesar 50. Normalisasi menggunakan metode *Min-Max* untuk nilai $x = 30$ dihitung sebagai berikut:

$$x' = \frac{30 - 10}{50 - 10} = 0,5$$

Hasil normalisasi sebesar 0,5 menunjukkan bahwa nilai 30 berada tepat di tengah rentang data, yaitu pada posisi 50% dari keseluruhan rentang. Dengan cara yang sama, seluruh nilai dalam variabel tersebut akan ditransformasikan ke dalam interval $[0, 1]$, sehingga tidak ada satu variabel pun yang mendominasi perhitungan jarak akibat perbedaan skala.

Penerapan normalisasi menggunakan metode *Min-Max* menjamin bahwa setiap atribut, baik yang memiliki prevalensi tinggi maupun rendah, diperlakukan secara adil dalam perhitungan jarak *Euclidean* pada algoritma *clustering*. Hal ini memungkinkan hasil pengelompokan wilayah di Sulawesi Selatan menjadi lebih objektif dan sistematis berdasarkan pola sebaran gizi yang sebenarnya.

1.6.5. Jarak *Euclidean*

Jarak *Euclidean* merupakan metrik jarak yang paling umum digunakan dalam algoritma *unsupervised learning* untuk mengukur kesamaan antar-data. Menurut Amiruddin dan Ishak (2025), fungsi utama dari metrik ini adalah untuk menghitung jarak antara setiap titik data dengan titik data lain yang telah ditentukan. Semakin kecil nilai jarak *Euclidean* yang dihasilkan, maka semakin tinggi tingkat kemiripan antara data tersebut dengan pusat klasternya.

Secara matematis, Tambunan et al. (2026) menjelaskan bahwa perhitungan jarak *Euclidean* dilakukan dengan menjumlahkan kuadrat selisih antar-titik pada setiap dimensi, kemudian menarik akar kuadrat dari total tersebut. Jarak *Euclidean* antara objek melalui persamaan:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (3)$$

di mana, $d(x, y)$ adalah jarak *Euclidean* antara objek/titik x dan y , n adalah jumlah variabel pada data, x_i adalah nilai variabel ke- i dari objek x , dan y_i adalah nilai variabel ke- i dari objek y .

Sebagai contoh, diberikan dua titik data dalam ruang dua dimensi, yaitu $P_1(2, 4)$ dan $P_2(5, 8)$. Jarak *Euclidean* antara kedua titik tersebut dihitung sebagai berikut:

$$d(P_1, P_2) = \sqrt{(2 - 5)^2 + (4 - 8)^2} = 5$$

Nilai jarak sebesar 5 menunjukkan tingkat kemiripan antara P_1 dan P_2 . Semakin kecil nilai jarak *Euclidean* yang dihasilkan, semakin mirip kedua objek data tersebut, sehingga keduanya berpotensi masuk ke dalam klaster yang sama.

Dalam penelitian ini, jarak *Euclidean* berperan sebagai indikator utama dalam proses iterasi algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical Clustering* untuk

menentukan keanggotaan wilayah di Sulawesi Selatan ke dalam klaster tertentu berdasarkan kemiripan karakteristik gizinya. Penggunaan metrik ini setelah tahap normalisasi Min-Max memastikan bahwa setiap variabel gizi memberikan kontribusi yang seimbang dalam perhitungan jarak tanpa ada dominasi fitur tertentu.


1.6.6. Algoritma Pengelompokan

1.6.6.1. *K-Means*

K-Means merupakan salah satu algoritma pengelompokan berbasis partisi yang bekerja dengan membagi kumpulan data menjadi sejumlah k kelompok berdasarkan titik pusat. Dalam algoritma ini, setiap kelompok diwakili oleh nilai rata-rata dari seluruh objek yang tergabung di dalamnya. Fokus utama dari algoritma ini adalah memperkecil tingkat variasi di dalam setiap klaster sehingga data dalam satu kelompok memiliki karakteristik yang serupa, sementara perbedaan antar kelompok tetap terjaga secara signifikan. Proses perbaikan kelompok dilakukan secara berulang melalui skema pembaruan posisi objek agar mencapai hasil partisi yang optimal. Berdasarkan metodologi yang dikembangkan oleh Han et al. (2011), berikut adalah langkah-langkah sistematis algoritma *K-Means*:

1. Menentukan k buah objek secara acak dari kumpulan data sebagai titik pusat klaster awal.
2. Menghitung jarak dengan menggunakan jarak *Euclidean* antara setiap objek data dengan semua *centroid*, lalu memasukkan objek tersebut ke dalam klaster yang memiliki pusat paling dekat atau paling mirip.
3. Menghitung ulang nilai rata-rata (*mean*) dari seluruh objek yang telah masuk ke dalam masing-masing klaster untuk menetapkan posisi *centroid* yang baru.
4. Mengulangi langkah ke-2 dan ke-3 secara terus-menerus hingga mencapai kondisi stabil, yaitu ketika posisi *centroid* tidak lagi berubah atau tidak ada lagi objek yang berpindah klaster.

Secara visual, alur kerja umum dari algoritma *K-Means* dapat dilihat pada Gambar 1.



Gambar 1. Flowchart Algoritma *K-Means*

Meskipun langkah-langkah sistematis di atas menunjukkan sudah cukup efisien, namun penentuan sejumlah k objek sebagai centroid awal secara acak total pada langkah pertama memiliki kelemahan. Pemilihan acak tersebut sangat bergantung pada faktor keberuntungan, sehingga rentan memilih titik-titik pusat yang letaknya saling berdekatan. Kondisi ini dapat memperlambat proses konvergensi iterasi, dan menyebabkan hasil akhir klusterisasi tidak konsisten karena algoritma terjebak pada solusi minimum lokal. Untuk mengatasi keterbatasan fungsional tersebut, penelitian ini mengintegrasikan metode *K-Means++* yang dikembangkan oleh Arthur dan Vassilvitskii (2007). Prinsip dasar dari metode *K-Means++* adalah melakukan pengkondisian stokastik pada tahap inisialisasi dengan memilih pusat kluster awal satu per satu secara probabilistik, bukan acak total sekaligus. Melalui skema distribusi probabilitas berbasis

kuadrat jarak terjauh, setiap *centroid* awal yang terpilih memiliki posisi yang saling berjauhan di dalam ruang dimensi data. Secara matematis, integrasi mekanisme inisialisasi *K-Means++* ke dalam rangkaian tahapan iterasi *K-Means* pada penelitian ini dijabarkan sebagai berikut:

1. Memilih satu objek data x_i secara acak dari total populasi data X untuk ditetapkan sebagai titik pusat kluster (*centroid*) pertama (c_1).
2. Untuk setiap objek data x_i yang belum terpilih, hitung jarak terdekatnya menuju ke seluruh *centroid* yang telah terbentuk sebelumnya menggunakan metrik jarak kuadrat *Euclidean* yang dinotasikan dengan $D(x_i)^2$:

$$D(x_i)^2 = \min_{c_j \neq c} \{ |x_i - c_j|^2 \} \quad (4)$$

di mana, $D(x_i)^2$ adalah jarak kuadrat terkecil dari objek data ke pusat kluster terdekat yang sudah ada, c_j adalah pusat kluster j dan C adalah kluster yang sudah terpilih sebelumnya.

3. Menentukan bobot peluang atau probabilitas $P(x_i)$ bagi setiap objek data untuk terpilih menjadi *centroid* berikutnya. Nilai probabilitas ini dihitung berdasarkan rasio jarak kuadrat *Euclidean* objek tersebut terhadap total seluruh jarak kuadrat objek yang tersedia, yang dirumuskan sebagai:


$$P(x_i) = \frac{D(x_i)^2}{\sum_{i=1}^n D(x_i)^2} \quad (5)$$

di mana, $P(x_i)$ adalah nilai peluang atau probabilitas objek data ke- i untuk terpilih menjadi pusat kluster berikutnya dan $D(x_i)^2$ adalah jarak kuadrat *Euclidean* terkecil dari objek data ke- i menuju ke pusat kluster terdekat yang sudah terbentuk sebelumnya.

Melalui persamaan ini, objek data yang memiliki jarak *Euclidean* semakin jauh dari *centroid* yang sudah ada akan mendapatkan bobot peluang yang semakin besar untuk terpilih pada tahap berikutnya.

4. Memilih satu objek data baru sebagai *centroid* berikutnya dengan memilih peluang terpilihnya objek tersebut didasarkan pada bobot nilai probabilitas $P(x_i)$ yang telah dihitung pada langkah ke-3.
5. Ulangi Mengulangi langkah ke-2, ke-3, dan ke-4 secara berurutan hingga sejumlah K titik *centroid* awal yang dibutuhkan telah lengkap terpenuhi dan letaknya tersebar secara optimal di dalam ruang data.

Secara visual, alur kerja umum dari algoritma *K-Means++* ini dapat dilihat pada Gambar 2.

Gambar 2. Flowchart metode *K-Means++*

Sebagai contoh, terdapat 4 titik data di ruang dua dimensi yaitu $A(1,1)$, $B(2,1)$, $C(4,3)$, $D(5,4)$ dan ingin memilih $k = 2$ *centroid* awal. Langkah pertama yang dilakukan adalah dengan memilih titik A sebagai *centroid* pertama (c_1). Selanjutnya, untuk mendapatkan *centroid* kedua dilakukan dengan menghitung jarak masing-masing titik lainnya ke *centroid* pertama. Berikut merupakan mekanisme perhitungannya di masing-masing titik:

Jarak titik A ke titik B: $D(B)^2 = |(2 - 1)|^2 + |(1 - 1)|^2 = 1$

Jarak titik A ke titik C: $D(C)^2 = |(4 - 1)|^2 + |(3 - 1)|^2 = 13$

Jarak titik A ke titik D: $D(D)^2 = |(5 - 1)|^2 + |(4 - 1)|^2 = 25$

Total Jumlah Jarak Kuadrat:

$$\sum_{i=1}^3 D(x_i)^2 = 1 + 13 + 25 = 39$$

Setelah menghitung jarak masing-masing titik ke centroid pertama, selanjutnya menghitung probabilitas masing-masing titik. Berikut merupakan probabilitas yang didapatkan pada masing-masing titik:

probabilitas titik B terpilih: $P(B) = \frac{1}{39} \approx 0.026$

probabilitas titik C terpilih: $P(C) = \frac{13}{39} \approx 0.333$

probabilitas titik D terpilih: $P(D) = \frac{25}{39} \approx 0.641$


Karena titik D memiliki bobot probabilitas terbesar yaitu 0.641, maka secara statistik titik D memiliki peluang paling tinggi untuk terpilih sebagai pusat kelompok berikutnya. Sehingga diperoleh *centroid* pertama yaitu titik A dan *centroid* kedua yaitu titik D.

1.6.6.2. *K-Medoids*

Algoritma *K-Medoids* merupakan algoritma pengelompokan berbasis partisi yang menggunakan objek nyata di dalam kumpulan data sebagai pusat kluster, yang dikenal sebagai *medoid* atau objek representatif. Berbeda dengan *K-Means* yang menggunakan nilai rata-rata sebagai pusat, *K-Medoids* menentukan pusat kluster berdasarkan objek yang letaknya paling sentral. Karakteristik ini membuat *K-Medoids* memiliki keunggulan dalam hal ketangguhan terhadap data pencilan, karena keberadaan nilai ekstrem tidak secara langsung mendistorsi posisi *medoid* sebagaimana memengaruhi nilai rata-rata (Han et al., 2011). Algoritma ini bekerja secara iteratif melalui langkah-langkah berikut:

1. Memilih secara acak sejumlah k objek dari himpunan data untuk dijadikan sebagai *medoid* awal.
2. Mengalokasikan setiap objek non-representatif ke dalam kluster yang memiliki *medoid* terdekat berdasarkan fungsi jarak.
3. Memilih secara acak sebuah objek non-representatif untuk diuji sebagai kandidat pengganti *medoid* yang ada.
4. Mengevaluasi total nilai kesalahan absolut kelompok, yaitu jumlah total jarak dari seluruh objek ke masing-masing *medoid* penampungnya, kemudian menghitung selisih nilai antara susunan *medoid* lama dengan susunan kandidat *medoid* yang baru.
5. Jika hasil evaluasi menunjukkan bahwa pertukaran tersebut mampu menurunkan total jarak atau mengecilkan nilai jarak kluster (menghasilkan tingkat efisiensi yang lebih baik), maka sistem akan melakukan pertukaran antara *medoid* lama dengan kandidat *medoid* baru untuk membentuk susunan pusat kelompok yang diperbarui.
6. Mengulangi langkah 2 hingga 5 sampai kondisi stabil tercapai, yaitu ketika proses pengujian pertukaran tidak ada lagi yang mampu menurunkan nilai total jarak di dalam kluster.

Secara visual, alur kerja umum dari algoritma *K-Medoids* ini dapat dilihat pada Gambar 2.

Gambar 3. Flowchart Algoritma *K-Medoids*

1.6.6.3. *Agglomerative Hierarchical Clustering*

Agglomerative Hierarchical Clustering merupakan algoritma pengelompokan yang mengadopsi pendekatan *bottom-up* (dari bawah ke atas). Prosedur ini diawali dengan menganggap setiap objek data sebagai sebuah klaster mandiri. Secara bertahap dan iteratif, klaster-klaster yang memiliki tingkat kemiripan tertinggi atau jarak terdekat akan digabungkan menjadi satu kelompok yang lebih besar. Proses ini terus berlangsung hingga seluruh objek menyatu dalam satu klaster tunggal yang merepresentasikan akar dari struktur hierarki tersebut, atau hingga kriteria penghentian tertentu terpenuhi (Han et al., 2011). Langkah-langkah sistematis dalam algoritma ini direpresentasikan sebagai berikut:

1. Menempatkan setiap objek data ke dalam klasternya masing-masing secara individual.
2. Menghitung dan mencari pasangan klaster yang memiliki jarak terpendek dengan menggunakan jarak *Euclidean*.

3. Menyatukan dua klaster terdekat tersebut menjadi satu klaster baru yang lebih besar.
4. Mengulangi langkah kedua dan ketiga secara berkesinambungan. Karena setiap langkah menggabungkan dua klaster, maka proses ini memerlukan maksimal sejumlah n iterasi.
5. Algoritma berhenti saat semua objek telah tergabung menjadi satu klaster besar. Struktur hasil pengelompokan ini umumnya divisualisasikan menggunakan diagram pohon yang disebut dengan dendrogram.

Secara visual, alur kerja umum dari algoritma *Agglomerative Hierarchical Clustering* dapat dilihat pada Gambar 4.



Gambar 4. Flowchart Algoritma *Agglomerative Hierarchical Clustering*

Dalam menentukan klaster mana yang akan digabungkan, terdapat beberapa rumus keterkaitan (*linkage*) yang umum digunakan, antara lain *Single Linkage* (jarak terdekat), *Complete Linkage* (jarak terjauh), dan *Centroid Linkage* (jarak antar pusat klaster). Namun, pada penelitian ini, menggunakan metode *Average Linkage*. Metode *Average Linkage* mengukur jarak antara dua klaster dengan menghitung rata-rata dari seluruh pasangan jarak objek antar kedua klaster tersebut. Keunggulan metode ini adalah

kemampuannya dalam menghasilkan struktur klaster yang lebih stabil karena tidak hanya bergantung pada satu pasang objek ekstrem seperti pada single atau complete linkage, melainkan mempertimbangkan seluruh distribusi anggota di dalam klaster. Secara matematis, rumus keterkaitan *Average Linkage* antara klaster C_i dan C_j dinyatakan sebagai berikut:

$$dist_{avg}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{p \in C_i} \sum_{p' \in C_j} d(p, p') \quad (6)$$

di mana, $dist_{avg}(C_i, C_j)$ adalah jarak rata-rata antara klaster C_i dan C_j , n_i adalah jumlah objek pada klaster C_i , n_j adalah jumlah objek pada klaster C_j , $d(p, p')$ adalah jarak antara objek p dan objek p' .

Sebagai contoh, diberikan sebuah kasus eksperimen menggunakan tiga objek, yaitu objek A , objek B , dan objek C . Asumsikan matriks jarak awal dengan menggunakan rumus jarak *Euclidean* antara ketiga objek tersebut telah diketahui, di mana jarak objek A ke B adalah 2 dan jarak C ke D adalah 5. Berdasarkan data tersebut, proses pengelompokan menggunakan metode *Average Linkage* sebagai berikut.

$$dist_{avg}(AB, CD) = \frac{d(A, B) + d(C, D)}{2} = \frac{2 + 5}{2} = 3,5$$

1.6.7. Metrik Evaluasi Klaster

1.6.7.1. *Silhouette score*

Metrik ini digunakan untuk mengukur sejauh mana kecocokan suatu titik data dengan klasternya sendiri dibandingkan dengan klaster terdekat lainnya, dengan rentang nilai antara -1 hingga 1 dimana nilai mendekati 1 menunjukkan pemisahan yang baik (Hasugian et al., 2025). metrik ini dihitung dengan persamaan berikut:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (7)$$

di mana $s(i)$ merupakan nilai koefisien *Silhouette* untuk objek data ke- i . Komponen $a(i)$ mengukur rata-rata jarak internal objek i terhadap seluruh objek dalam klaster yang sama (C_A), yang dirumuskan sebagai:

$$a(i) = \frac{1}{C_A} \sum_{j \in C_A} d(i, j) \quad (8)$$

di mana C_A menyatakan jumlah total anggota objek pada klaster A (termasuk objek i), serta $d(i, j)$ menyatakan jarak Euclidean antara objek i dan objek j dalam klaster yang sama dengan nilai $d(i, i) = 0$. Sementara itu, komponen $b(i)$ mengukur rata-rata jarak terdekat antara objek i terhadap objek-objek pada klaster tetangga terdekat ($C_B \neq C_A$), yang dirumuskan sebagai:

$$b(i) = \min_{C_B \neq C_A} \left\{ \frac{1}{C_B} \sum_{j \in C_B} d(i, j) \right\} \quad (9)$$

dimana C_B menyatakan jumlah anggota pada kluster tetangga B , dan $d(i, j)$ menyatakan jarak Euclidean antara objek i pada kluster C_A dengan objek j pada kluster C_B .

Selanjutnya, untuk mengevaluasi kualitas klusterisasi secara keseluruhan pada dataset, nilai *Silhouette Score* akhir (S) dihitung melalui rata-rata nilai koefisien *Silhouette* dari seluruh N sampel data:

$$S = \frac{1}{N} \sum_{i=1}^N s(i) \quad (10)$$

di mana S merupakan nilai rata-rata *Silhouette Score* yang mewakili tingkat kebaikan struktur klusterisasi secara menyeluruh, dan N adalah jumlah total data.

Sebagai contoh, diberikan objek P yang masuk ke dalam Kluster 1. Rata-rata jarak P terhadap seluruh anggota kluster 1 adalah $a(i) = 0,25$, sedangkan rata-rata jarak P terhadap seluruh anggota kluster terdekat lainnya yaitu Kluster 2 adalah $b(i) = 0,72$. Nilai *Silhouette* objek P dihitung sebagai berikut:

$$s(i) = \frac{0,72 - 0,25}{0,72} = 0,6528$$

Nilai positif sebesar 0,6528 yang mendekati 1 menunjukkan bahwa objek P sudah ditempatkan pada kluster yang tepat. Artinya, objek P jauh lebih mirip dengan anggota klasternya sendiri dibandingkan dengan anggota kluster lain.

1.6.7.2. Davies-Bouldin index

Metrik ini mengevaluasi kualitas kluster berdasarkan tingkat kekompakan di dalam kluster dan pemisahan antar kluster, di mana nilai DBI yang semakin kecil menunjukkan pemisahan kluster yang semakin baik (Hasugian et al., 2025). metrik ini dihitung dengan persamaan sebagai berikut:

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{i \neq j} \left\{ \frac{s_i + s_j}{d_{ij}} \right\} \quad (11)$$

di mana, DBI adalah nilai *Davies Bouldin Index* yang digunakan untuk mengevaluasi kualitas hasil klusterisasi, k adalah jumlah kluster, s_i adalah rata-rata jarak (dispersi) seluruh objek terhadap centroid pada kluster i , s_j adalah rata-rata jarak (dispersi) seluruh objek terhadap centroid pada kluster j , d_{ij} adalah jarak antara centroid kluster i dan centroid kluster j , dan $\max_{i \neq j}$ adalah nilai maksimum rasio antara dispersi dalam kluster dan jarak antar centroid untuk setiap pasangan kluster.

Nilai dispersi internal kluster s_i dan s_j dihitung menggunakan rata-rata jarak *Euclidean* seluruh objek terhadap centroid-nya:

$$s_i = \frac{1}{B_i} \sum_{x \in C_i} d(x, C_i) \quad (12)$$

Sedangkan jarak pemisahan antar-centroid d_{ij} dihitung menggunakan rumus jarak *Euclidean* antara dua titik centroid:

$$d_{ij} = \sqrt{\sum_{f=1}^p (i_f - j_f)^2} \quad (13)$$

di mana B_i merupakan jumlah anggota pada kluster i , x adalah objek data dalam kluster i , dan p adalah total variabel yang dianalisis.

Sebagai contoh simulasi evaluasi hasil pengelompokan, digunakan skenario pengujian dengan dua kluster. Kluster pertama memiliki titik pusat $p_1 = (2, 2)$ dengan nilai dispersi internal sebesar $s_2 = 1,14$. Sementara itu, kluster kedua memiliki titik pusat $p_2 = (7, 7)$ dengan nilai dispersi internal sebesar $s_2 = 1$. Nilai dispersi internal pada masing-masing kluster tersebut merepresentasikan rata-rata jarak *Euclidean* dari setiap anggota data terhadap titik pusat klasternya, yang sekaligus menunjukkan tingkat kepadatan objek di dalam kelompok tersebut. selanjutnya, menghitung Jarak antara pusat Kluster 1 (p_1) dan pusat Kluster 2 (p_2) dihitung menggunakan rumus jarak *euclidean* sebagai berikut:

$$d_{12} = \sqrt{(7-2)^2 + (7-2)^2} = 7,07$$

Setelah menghitung jarak *euclidean* antara kedua titik, selanjutnya menghitung nilai *Davies-Bouldin index* dengan menghitung maksimal rasio kedekatan dengan membandingkan jumlah dispersi internal kedua kluster terhadap jarak pusatnya. Karena pengujian ini hanya melibatkan dua buah kluster, maka nilai DBI akhir ditentukan berdasarkan nilai rasio maksimum yang terbentuk pada kedua kluster tersebut. nilai DBI dihitung sebagai berikut:

$$DBI = \max \left\{ \frac{1,14 + 1}{7,07} \right\} = 0,303$$

1.6.7.3. Calinski-Harabasz index

Indeks ini menilai rasio antara varians antar-kluster dengan varians dalam-kluster, di mana nilai yang tinggi menandakan bahwa kluster-kluster tersebut terpisah secara jelas (Hasugian et al., 2025). metrik ini dihitung menggunakan persamaan sebagai berikut:

$$CH = \frac{B_k}{W_k} \times \frac{N - k}{k - 1} \quad (14)$$

di mana, CH adalah nilai mengevaluasi kualitas kluster, k adalah jumlah kluster, B_k adalah varians antar-kluster dan W_k varians dalam-kluster. Komponen varians antar-kluster (B_k) dirumuskan berdasarkan selisih antara titik pusat rata-rata tiap kluster (E_q) dengan titik rata-rata keseluruhan dataset (E):

$$B_k = \sum_{q=1}^k C_q \cdot d(E_q, E)^2 \quad (15)$$

dimana C_q menyatakan jumlah anggota pada kluster ke- q , dan $d(E_q, E)$ menyatakan jarak *Euclidean* antara centroid kluster q dengan pusat data global. Sementara itu, komponen varians dalam-kluster (W_k) dirumuskan sebagai jumlah kuadrat jarak antara seluruh objek data terhadap centroid klasternya masing-masing:

$$W_k = \sum_{q=1}^k \sum_{x \in C_q} d(x, E_q)^2 \quad (16)$$

di mana x menyatakan titik objek data yang tergolong dalam kluster C_q .

Sebagai contoh, diberikan hasil pengelompokan dengan $n = 10$ objek data dan $k = 2$ klaster. Apabila nilai varians antar klaster $B_k = 8$ dan nilai varians dalam klaster $W_k = 4$, maka nilai *Calinski-Harabasz Index* dihitung sebagai berikut:

$$CH = \frac{(10 \times 8) - (2 \times 8)}{(4 \times 2) - 4} = 16$$

Nilai *Calinski-Harabasz Index* sebesar 16,00 ini kemudian dibandingkan dengan nilai *Calinski-Harabasz Index* pada skenario k lainnya. Skenario k dengan nilai *Calinski-Harabasz Index* tertinggi mengindikasikan bahwa klaster-klaster yang terbentuk paling terpisah satu sama lain sekaligus paling padat secara internal.

1.6.7.4. *Dunn Index*

Index ini digunakan untuk menilai sejauh mana klaster-klaster saling berjauhan satu sama lain dan seberapa padat titik data di dalam klaster tersebut secara internal, di mana nilai yang tinggi mengindikasikan struktur klaster yang baik (Hasugian et al., 2025). metrik ini dihitung dengan rumus:

$$DI = \frac{\min_{i \neq j} \{d(c_i, c_j)\}}{\max_k \{\Delta(C_k)\}} \quad (17)$$

di mana, DI adalah nilai evaluasi kualitas klaster, $d(c_i, c_j)$ adalah jarak antar klaster i dan j , dan $\Delta(C_k)$ adalah diameter klaster terbesar di antara seluruh klaster yang terbentuk. Jarak inter-klaster $d(c_i, c_j)$ dihitung menggunakan jarak Euclidean terkecil antara pasang titik objek yang berada pada dua klaster berbeda:

$$d(C_i, C_j) = \min_{x \in C_i, y \in C_j} d(x, y) \quad (18)$$

di mana x merupakan objek data anggota klaster C_i dan y merupakan objek data anggota klaster C_j . Sementara itu, diameter internal klaster $\Delta(C_k)$ didefinisikan sebagai jarak Euclidean terbesar antara dua titik objek data yang berada dalam satu klaster yang sama:

$$\Delta(C_k) = \max_{x, y \in C_k} d(x, y) \quad (19)$$

di mana x dan y keduanya merupakan objek data yang tergolong dalam klaster C_k . Sementara itu, diameter internal klaster $\Delta(C_k)$ didefinisikan sebagai jarak Euclidean terbesar antara dua titik objek data yang berada dalam satu klaster yang sama:

Sebagai contoh, diberikan hasil pengelompokan dengan tiga klaster. Jarak minimum antar klaster yang diperoleh adalah $d_{min} = 2,5$, sedangkan diameter terbesar dari seluruh klaster adalah $\Delta_{max} = 1,8$. Nilai *Dunn Index* dihitung sebagai berikut:

$$DI = \frac{2,5}{1,8} = 1,3889$$

BAB II METODE PENELITIAN

2.1. Sumber Data

Data yang digunakan dalam penelitian ini adalah data sekunder mengenai prevalensi status gizi balita di kabupaten/kota Provinsi Sulawesi Selatan pada tahun 2024. Data ini bersumber dari laporan resmi Survei Status Gizi Indonesia (SSGI) 2024 yang dipublikasikan oleh Badan Kebijakan Pembangunan Kesehatan (BKPK), Kementerian Kesehatan Republik Indonesia, dan diakses secara daring melalui situs web resmi <https://www.badankebijakan.kemkes.go.id/survei-status-gizi-indonesia-ssgi-2024/>. Data tersebut merupakan data siap pakai yang telah melalui proses pengumpulan, pengolahan, dan validasi oleh pihak Kementerian Kesehatan RI.

2.2. Deskripsi Variabel

Variabel yang digunakan dalam penelitian ini merupakan atribut analisis (X) yang diukur dalam satuan persentase (%) prevalensi status gizi sebagai berikut:


1. X_1 = Prevalensi balita *stunting*
2. X_2 = Prevalensi balita *underweight*
3. X_3 = Prevalensi balita *wasting*
4. X_4 = Prevalensi balita *severe wasting*
5. X_5 = Prevalensi balita *overweight*

2.3. Metode Analisis

Metode analisis kluster yang digunakan pada penelitian ini adalah metode non-hierarki yaitu algoritma *K-Means* dan *K-Medoids*, serta metode hierarki yaitu *Agglomerative Hierarchical Clustering*. Proses komputasi yang digunakan untuk mengolah data penelitian ini menggunakan *python* dan *google colab*. Langkah-langkah pengklusteran pada penelitian ini adalah sebagai berikut:

1. Merancang penelitian dalam analisis cluster dengan menentukan objek penelitian yang terdiri dari 24 kabupaten/kota di Provinsi Sulawesi Selatan dan 5 variabel prevalensi gizi balita.
2. Melakukan analisis statistik deskriptif untuk memahami karakteristik dasar dataset sebelum dilakukan pengelompokan.
3. Melakukan uji korelasi dengan melihat koefisien korelasi sederhana menggunakan matriks korelasi dan visualisasi *heatmap* antar-variabel gizi balita untuk mendeteksi hubungan linear.
4. Melakukan normalisasi data menggunakan metode *Min-Max* guna menyeragamkan skala seluruh variabel.
5. Melakukan pengelompokan, analisis hasil dan penamaan objek menggunakan algoritma *K-Means*, *K-Medoids*, dan *Agglomerative Hierarchical*.
6. Melakukan pemilihan metode terbaik dengan menggunakan *Silhouette Coefficient*, *Davies-Bouldin Index*, *Calinski-Harabasz Index* dan *Dunn Index*.

2.4. Diagram Alur Penelitian



BAB III HASIL DAN PEMBAHASAN

3.1. Statistik Deskriptif

Analisis statistik deskriptif diterapkan terlebih dahulu untuk memahami karakteristik dasar dataset yang akan diolah. Ringkasan statistik deskriptif disajikan pada Tabel 1.

Tabel 1. Ringkasan statistik deskriptif atribut status gizi balita


Variabel	Rata-rata	Simpangan Baku	Nilai Minimum	Nilai Maksimum
X_1 (Stunting)	25,08	4,23	17,00	37,00
X_2 (Underweight)	21,11	4,04	11,40	26,90
X_3 (Wasting)	1,28	0,69	0,10	2,80
X_4 (Severe Wasting)	7,25	2,31	2,00	11,70
X_5 (Overweight)	2,89	0,91	1,70	5,10

Berdasarkan statistik deskriptif pada Tabel 1, terdapat lima variabel utama yang dianalisis pada 24 kabupaten/kota di Provinsi Sulawesi Selatan, yang meliputi X_1 , X_2 , X_3 , X_4 dan X_5 . Indikator-indikator yang menjadi kriteria dalam *clustering* ini ditinjau terlebih dahulu karakteristiknya melalui beberapa ukuran statistik dasar, yaitu nilai minimum, nilai maksimum, rata-rata, dan standar deviasi. Nilai minimum menunjukkan batas prevalensi terendah yang ditemukan pada masing-masing indikator gizi dalam seluruh wilayah observasi. Pada variabel X_1 , nilai minimum yang tercatat adalah sebesar 17,00%, di mana angka ini merepresentasikan tingkat prevalensi terendah yang berada di Kabupaten Gowa. Untuk variabel X_2 , batas minimumnya berada di angka 11,40%, dan begitu pula seterusnya untuk variabel lainnya. Sebaliknya, nilai maksimum merepresentasikan tingkat prevalensi tertinggi yang ditemukan di dalam dataset. Pada variabel X_1 , nilai maksimum yang diperoleh adalah sebesar 37,00%, yang mana angka ekstrem ini merupakan tingkat prevalensi tertinggi yang berlokasi di Kabupaten Jeneponto. Sementara itu, pada variabel X_2 , nilai tertinggi yang tercatat di wilayah Sulawesi Selatan mencapai 26,90%, dan kondisi serupa berlaku untuk variabel lainnya. Selanjutnya, nilai *mean* menggambarkan ukuran pemusatan berupa nilai rata-rata dari masing-masing variabel di tingkat provinsi. Nilai rata-rata untuk variabel X_1 adalah sebesar 25,08%, sedangkan untuk variabel X_2 menunjukkan angka rata-rata sebesar 21,11%, dan begitu seterusnya untuk variabel lainnya. Terakhir, nilai standar deviasi digunakan sebagai parameter untuk mengukur tingkat persebaran atau variabilitas data terhadap nilai rata-ratanya. Nilai simpangan baku untuk variabel X_1 tercatat sebesar 4,23%, sedangkan untuk variabel X_2 adalah sebesar 4,04%, dan begitu seterusnya untuk variabel lainnya.

3.2. Hasil Matriks Korelasi

Analisis korelasi dilakukan terlebih dahulu untuk mengetahui hubungan linear antara atribut-atribut status gizi balita yang digunakan dalam penelitian ini. Melalui pengujian

koefisien korelasi *Pearson*, asosiasi statistik antar variabel dapat dideteksi guna memastikan ada atau tidaknya indikasi multikolinearitas yang ekstrem, serta melihat bagaimana kontribusi kedekatan antar data. Visualisasi tingkat keeratan hubungan linear antara indikator gizi tersebut dipetakan secara grafis melalui bentuk diagram heatmap matriks korelasi yang disajikan pada Gambar 5.



Gambar 5. Heatmap matriks korelasi antar variabel status gizi balita

Berdasarkan gradasi warna dan nilai koefisien korelasi pada Gambar 5, hubungan linear antar atribut status gizi balita di Provinsi Sulawesi Selatan menunjukkan pola keterkaitan yang bervariasi. Korelasi linear positif yang paling signifikan ditemukan antara variabel X_2 dan X_4 dengan nilai koefisien korelasi *pearson* mencapai 0,80. Secara statistik, nilai ini menunjukkan adanya hubungan searah yang sangat kuat, yang mengindikasikan bahwa kabupaten/kota dengan nilai X_4 yang tinggi secara linier akan mengalami tingkat kasus X_2 yang tinggi pula. Korelasi positif pada tingkat menengah searah juga ditunjukkan oleh variabel X_3 terhadap X_2 (0,56) serta X_3 terhadap X_4 (0,56), yang mencerminkan keterkaitan indikator-indikator tersebut yang saling berbanding lurus di berbagai wilayah observasi. Sementara itu, korelasi negatif terbesar ditunjukkan oleh variabel X_5 terhadap variabel X_1 dengan koefisien korelasi sebesar $-0,32$. Nilai minus ini mengindikasikan hubungan berlawanan arah yang lemah, artinya wilayah yang memiliki kecenderungan peningkatan nilai X_5 secara umum memiliki angka prevalensi X_1 yang relatif lebih rendah. Di sisi lain, variabel X_1 menunjukkan korelasi yang sangat lemah atau hampir tidak memiliki hubungan linear terhadap variabel X_3 dengan nilai koefisien sebesar $-0,05$, yang menandakan bahwa sebaran kasus X_1 bergerak secara independen dan tidak dipengaruhi oleh fluktuasi angka X_3 . Meskipun terdapat hubungan linear yang erat antara variabel X_2 dan X_4 ($r = 0,80$), nilai tersebut masih berada tepat pada ambang batas toleransi maksimal yang diizinkan dalam analisis hubungan banyak

variabel. Dengan demikian, dapat disimpulkan bahwa tidak terdapat gejala multikolinearitas serius yang dapat mempengaruhi hasil pengelompokan data, sehingga seluruh variabel X_1 hingga X_5 dinyatakan memenuhi syarat kelayakan asumsi untuk dilakukan pengelompokan.

3.3. Hasil Normalisasi Data

Sebelum tahap implementasi algoritma, seluruh data prevalensi gizi balita dinormalisasi menggunakan metode *Min-Max* berdasarkan persamaan (2), dengan tujuan menyeragamkan skala kelima variabel ke dalam interval $[0, 1]$. Melalui proses penskalaan ini, perhitungan jarak *Euclidean* antar-wilayah sehingga pada tahapan pengelompokan menggunakan algoritma akan bersifat objektif dan tidak didominasi oleh atribut yang memiliki rentang nilai asal yang sangat besar. Sebagai contoh, perhitungan normalisasi untuk variabel x_1 pada Kabupaten Kepulauan Selayar dengan nilai asli 27.5, nilai minimum $x_{\min} = 17$, dan nilai maksimum $x_{\max} = 37$ sebagai berikut:

$$x'_{1,\text{selayar}} = \frac{25,7 - 17}{37 - 17} = \frac{8,7}{20} = 0,4350$$

Dengan prosedur yang sama, diperoleh hasil normalisasi untuk seluruh variabel dan kabupaten/kota sebagaimana disajikan pada Tabel 2. Data lengkap hasil normalisasi disajikan pada Lampiran 2.

Tabel 2. Sampel hasil normalisasi data status gizi balita

Kabupaten/Kota	X_1	X_2	X_3	X_4	X_5
Kepulauan Selayar	0,435	0,7935	0,6296	1,0000	0,8529
Bulukumba	0,410	0,6968	0,5556	0,6598	0,1176
Bantaeng	0,365	0,7935	0,4074	0,7216	0,0294
...	...	...	...	...	...
Kota Palopo	0,285	0,7032	0,3333	0,6289	0,1176

3.4. Implementasi Algoritma Klusterisasi


3.4.1. Hasil Klusterisasi Algoritma *K-Means*

Sebelum pembentukan kluster menggunakan algoritma *K-Means*, tahap pertama adalah menentukan jumlah kluster (k) yang paling optimal. Penentuan nilai k terbaik menggunakan metode *Silhouette Score* menggunakan persamaan (7) dengan menguji masing-masing nilai k . Hasil simulasi komputasi dengan *Python* versi 3.14.6 disajikan pada Tabel 3 dan divisualisasikan pada Gambar 6.

Tabel 3. Nilai rata-rata *silhouette score* pada algoritma *K-Means* untuk setiap

Jumlah Klaster (k)	<i>Silhouette Score</i>
2	0,3480
3	0,3096
4	0,3498
5	0,2699
6	0,2583

Jumlah Klaster (k)	Silhouette Score
7	0,2769
8	0,2814
9	0,2651
10	0,2562



Gambar 6. Kurva Silhouette Score pada setiap skenario k untuk algoritma K-Means

Berdasarkan Tabel 3 dan Gambar 6, kurva evaluasi *Silhouette* menunjukkan puncak nilai tertinggi pada $k = 4$ dengan skor sebesar 0,3498. Hal ini menegaskan bahwa pembagian 24 kabupaten/kota ke dalam 4 kelompok menghasilkan tingkat kepadatan internal yang paling baik sekaligus pemisahan antar klaster yang paling tegas. Sebaliknya, nilai $k = 3$ atau $k \geq 5$ menghasilkan penurunan skor yang menandakan lemahnya struktur klaster. Dengan demikian, nilai $k = 4$ ditetapkan sebagai parameter optimal untuk algoritma *K-Means*.

Setelah $k = 4$ ditetapkan, algoritma *K-Means* dijalankan dengan inisialisasi *centroid* menggunakan metode *K-Means++* guna menghindari terjebaknya algoritma pada solusi minimum lokal. Posisi *centroid* awal disajikan pada Tabel 4.

Tabel 4. Koordinat centroid awal algoritma *K-Means* menggunakan metode *K-Means++*

Pusat Kelompok	X_1	X_2	X_3	X_4	X_5
Centroid 1	0.41	0.8129	0.1481	0.6907	0.0882
Centroid 2	0.53	0.2	0.3333	0	0.3235

Pusat Kelompok	X_1	X_2	X_3	X_4	X_5
Centroid 3	0.435	0.7935	0.6296	1	0.8529
Centroid 4	0.165	0.2645	0.2222	0.3093	0.6176

Selanjutnya, perhitungan jarak antara objek wilayah observasi ke masing-masing pusat kelompok c_j dihitung menggunakan persamaan jarak Euclidean berdasarkan persamaan (3). Sebagai contoh, diambil data hasil normalisasi dari objek pertama $i = 1$ yaitu Kabupaten Kepulauan Selayar dengan vektor data $x_1 = [0,4350; 0,7935; 0,6296; 1,0000; 0,8529]$. Kalkulasi jarak objek terhadap pusat kelompok pertama c_1 dijabarkan sebagai berikut:

$$d(x_1, c_1) = \sqrt{(0,435 - 0,41)^2 + \dots + (0,8429 - 0,0882)^2} = 0,84547$$

Dengan menerapkan skema perhitungan yang sama, diperoleh nilai jarak untuk pusat kelompok lainnya, yaitu $d(x_1, c_2)$, $d(x_1, c_3)$ dan $d(x_1, c_4)$. Kemudian, objek Kabupaten Kepulauan Selayar pada iterasi awal ini akan dialokasikan ke dalam kelompok yang memiliki nilai jarak *Euclidean* paling minimum. Setelah seluruh 24 kabupaten/kota berhasil ditempatkan ke dalam salah satu dari empat kluster awal, sistem melakukan pembaruan posisi titik pusat dengan menghitung nilai rata-rata koordinat dari seluruh objek yang menjadi anggota di dalam kelompok masing-masing. Proses relokasi objek dan pembaruan titik *centroid* ini dilakukan secara berulang. Berdasarkan hasil perulangan, pergeseran posisi titik pusat terus terjadi hingga algoritma dinyatakan konvergen pada iterasi ke-2. Kondisi konvergen ini tercapai karena seluruh objek data telah stabil pada kelompoknya dan tidak ada lagi perpindahan anggota wilayah antar-kluster. Integrasi hasil akhir koordinat posisi pusat kelompok yang telah stabil yaitu titik *centroid* akhir pada kondisi konvergen disajikan pada Tabel 5.

Tabel 5. Koordinat centroid akhir algoritma K-Means pada kondisi konvergen

Pusat Kelompok	X_1	X_2	X_3	X_4	X_5
Centroid 1	0.45	0.7801	0.4545	0.612	0.1684
Centroid 2	0.64	0.1957	0.1975	0.0722	0.1765
Centroid 3	0.355	0.7387	0.7284	0.7251	0.6569
Centroid 4	0.175	0.3597	0.1296	0.4253	0.5221


Koordinat akhir pada Tabel 5 merepresentasikan nilai rata-rata karakteristik sebaran gizi balita dari total anggota pada masing-masing kelompok. Berdasarkan titik pusat akhir tersebut, konfigurasi distribusi keanggotaan 24 kabupaten/kota di Provinsi Sulawesi Selatan disajikan pada Tabel 6.

Tabel 6. Distribusi keanggotaan kluster akhir algoritma K-Means ($k = 4$)

Kluster	Prioritas Intervensi	X_1	X_2	X_3	X_4	X_5	Anggota Wilayah
1	tinggi	0.45	0.7801	0.4545	0.612	0.1684	Bulukumba, Bantaeng, Jeneponto, Takalar, Sinjai, Maros,

Klaster	Prioritas Intervensi	X_1	X_2	X_3	X_4	X_5	Anggota Wilayah
							Pangkajene Dan Kepulauan, Barru, Luwu, Kota Parepare, Kota Palopo
2	sedang	0.64	0.1957	0.1975	0.0722	0.1765	Enrekang, Tana Toraja, Toraja Utara.
3	sangat tinggi	0.355	0.7387	0.7284	0.7251	0.6569	Kepulauan Selayar, Bone, Soppeng, Wajo, Pinrang, Luwu Utara.
4	rendah	0.175	0.3597	0.1296	0.4253	0.5221	Gowa, Sidenreng Rappang, Luwu Timur, Kota Makassar.

Untuk mempermudah analisis karakteristik dan perbandingan indikator gizi antar klaster, nilai rata-rata (*centroid*) hasil normalisasi dari masing-masing klaster pada Tabel 6 divisualisasikan ke dalam bentuk diagram batang profil rerata yang disajikan pada Gambar 7.




Gambar 7. Grafik Profil Rerata Indikator Gizi Per Klaster Algoritma *K-Means*

Berdasarkan Tabel 6 dan Gambar 7, hasil pengelompokan menggunakan algoritma K-Means dengan konfigurasi $k=4$ menghasilkan empat kelompok wilayah dengan tingkat prioritas intervensi yang berbeda-beda di Provinsi Sulawesi Selatan. Klaster 3 masuk kategori prioritas intervensi sangat tinggi karena memiliki nilai rata-rata normalisasi wasting (0,7284) dan severe wasting (0,7251) tertinggi di antara semua kelompok, yang berarti wilayah-wilayah dalam kelompok ini memiliki tingkat kekurangan gizi akut yang paling parah dibandingkan wilayah lainnya. Kondisi ini semakin diperburuk oleh nilai underweight (0,7387) dan overweight (0,6569) yang juga tergolong tinggi, sehingga Kepulauan Selayar, Bone, Soppeng, Wajo, Pinrang, dan Luwu Utara ditetapkan sebagai wilayah yang paling membutuhkan penanganan segera. Berbeda dengan kondisi tersebut, Klaster 1 yang mencakup 11 daerah yaitu Bulukumba, Bantaeng, Jeneponto, Takalar, Sinjai, Maros, Pangkajene dan Kepulauan, Barru, Luwu, Kota Parepare, dan Kota Palopo masuk kategori prioritas intervensi tinggi karena memiliki nilai normalisasi underweight tertinggi (0,7801) di antara seluruh klaster, bahkan lebih tinggi dibandingkan Klaster 3, serta nilai severe wasting (0,6120) dan wasting (0,4545) yang juga tergolong tinggi, sehingga kelompok ini mencerminkan beban malnutrisi akut yang cukup berat dan menyebar pada 11 wilayah tersebut. Apabila kedua klaster tersebut mencerminkan permasalahan gizi akut yang ekstrem, maka Klaster 2 yang terdiri dari Kabupaten Enrekang, Tana Toraja, dan Toraja Utara masuk kategori prioritas intervensi sedang karena meskipun memiliki nilai rata-rata normalisasi stunting tertinggi (0,6400) di seluruh provinsi yang menunjukkan tingkat gangguan pertumbuhan kronis paling tinggi, klaster ini justru memiliki nilai severe wasting (0,0722) terendah dan underweight (0,1957) terendah di antara semua kelompok, yang berarti masalah kekurangan gizi akut tidak sebanyak di daerah pada klaster lain, sehingga secara keseluruhan permasalahan gizinya bersifat kronis jangka panjang yang lebih spesifik dan tidak disertai beban malnutrisi akut yang parah. Sementara itu, Klaster 4 yang meliputi Kabupaten Gowa, Sidenreng Rappang, Luwu Timur, dan Kota Makassar masuk kategori prioritas intervensi rendah karena memiliki rata-rata nilai normalisasi stunting (0,1750) dan wasting (0,1296) terendah di antara seluruh klaster, yang berarti keempat wilayah ini memiliki kondisi gizi balita yang paling baik dan paling mendekati kondisi ideal dibandingkan wilayah lainnya di Provinsi Sulawesi Selatan.

Hasil pengelompokan wilayah menggunakan algoritma *K-Means* dapat divisualisasikan secara spasial menggunakan peta tematik. Pendekatan visual ini diterapkan untuk mempermudah identifikasi sebaran geografis dari kabupaten dan kota di Provinsi Sulawesi Selatan yang memiliki kemiripan karakteristik indikator gizi balita dalam klaster yang sama. Visualisasi spasial dari sebaran keempat kelompok tersebut disajikan pada Gambar 8.

**Peta Pemetaan Wilayah Prioritas di Provinsi Sulawesi Selatan
Berdasarkan Hasil Algoritma K-Means ($k = 4$) untuk Status Gizi Balita 2024**



Gambar 8. Peta pemetaan wilayah prioritas Intervensi hasil algoritma K-Means ($k=4$)


Berdasarkan visualisasi spasial pada Gambar 8, konfigurasi pembagian wilayah hasil *K-Means* dipetakan ke dalam empat kelompok prioritas intervensi yang direpresentasikan melalui gradasi warna yang berbeda. Daerah yang tergolong dalam Klaster 1 dikategorikan sebagai wilayah prioritas tinggi dan disimbolkan dengan warna oranye, yang merepresentasikan kawasan dengan beban malnutrisi akut yang cukup berat, ditandai oleh nilai *underweight* dan *wasting* yang tinggi. Sementara itu, Klaster 2 merepresentasikan wilayah prioritas sedang yang digambarkan dengan warna hijau muda untuk mencerminkan kelompok daerah dengan beban *stunting* kronis yang spesifik namun tidak disertai malnutrisi akut yang meluas. Untuk daerah yang masuk ke dalam klaster 3, wilayah ini disimbolkan secara kontras menggunakan warna merah sebagai penanda Prioritas Sangat Tinggi guna menegaskan wilayah yang mengalami kondisi darurat malnutrisi akut terparah secara geografis. Terakhir, daerah yang termasuk ke dalam klaster 4 diklasifikasikan sebagai wilayah prioritas rendah yang ditandai dengan warna biru, mencakup wilayah dengan tata kelola indikator gizi paling terkendali dibandingkan klaster lainnya.

3.4.2. Hasil Klasterisasi Algoritma *K-Medoids*

Serupa dengan algoritma *K-Means*, tahap pertama penerapan *K-Medoids* adalah menentukan jumlah kluster optimal menggunakan metode *Silhouette Score*. Hasil evaluasi disajikan pada Tabel 7.

Tabel 7. Nilai rata-rata *Silhouette Score* pada algoritma *K-Medoids* untuk setiap skenario k

Jumlah Klaster (k)	<i>Silhouette Score</i>
2	0,2281
3	0,3141
4	0,2377
5	0,1974
6	0,1729
7	0,0579
8	0,0825
9	0,0358
10	0,0159



Gambar 9. Kurva *Silhouette Score* pada setiap skenario k untuk algoritma *K-Medoids*

Berdasarkan Tabel 7 dan Gambar 9, nilai *Silhouette Score* mencapai puncaknya pada $k = 3$ dengan skor sebesar 0,3141. Setelah melewati titik ini, kurva mengalami penurunan drastis, terutama pada $k \geq 7$ yang mendekati angka nol. Oleh karena itu, $k = 3$ ditetapkan sebagai jumlah kluster optimal untuk algoritma *K-Medoids*.

Tahap selanjutnya yaitu menentukan 3 objek kabupaten/kota secara acak yang bertindak sebagai pusat kelompok awal. Objek wilayah yang terpilih sebagai *medoid* awal pada iterasi pertama disajikan pada tabel 8.

Tabel 8. Koordinat medoid awal algoritma K-Medoids

Pusat Kelompok	Kabupaten/Kota	X_1	X_2	X_3	X_4	X_5
Medoid 1	Kepulauan Selayar	0.435	0.7935	0.6296	1	0.8529
Medoid 2	Gowa	0	0.1806	0.037	0.4021	0.6471
Medoid 3	Sidenreng Rappang	0.165	0.2645	0.2222	0.3093	0.6176

Selanjutnya, perhitungan jarak antara objek *non-medoid* ke masing-masing pusat kelompok (m_j) dihitung menggunakan jarak *Euclidean* yang mekanismenya mengacu pada Persamaan (3). Sebagai contoh, diambil data hasil normalisasi dari Kabupaten Pinrang dengan vektor data $x_1 = [0.26; 0.6323; 0.6667; 0.5979; 0.4118]$. Kalkulasi jarak geometris objek ini terhadap objek pusat kelompok pertama (m_1) melalui substitusi pada Persamaan (3) dijabarkan sebagai berikut:

$$d(x_1, m_1) = \sqrt{(0.26 - 0.435)^2 + \dots + (0.4118 - 0.8529)^2} = 0,6436$$

Dengan menerapkan skema perhitungan yang sama, diperoleh nilai jarak untuk pusat kelompok lainnya yaitu $d(x_1, m_2)$ dan $d(x_1, m_3)$. Kemudian, objek Kabupaten Pinrang pada iterasi awal ini akan dialokasikan ke dalam kelompok yang memiliki nilai jarak *Euclidean* paling minimum.

Setelah seluruh 24 kabupaten/kota dikelompokkan, algoritma *K-Medoids* melakukan tahapan optimasi dengan menghitung total biaya konfigurasi yang merepresentasikan jumlah absolut jarak seluruh objek ke pusat kelompoknya masing-masing. Sistem kemudian menguji pergeseran pusat kelompok ke objek *non-medoid* lain secara iteratif untuk mengevaluasi apakah perubahan pusat tersebut mampu mereduksi total jarak.

Melalui algoritma iteratif yang dijalankan, proses pertukaran objek pusat ini terus dieksekusi hingga diperoleh nilai total jarak paling kecil. Kondisi konvergen ini menandakan bahwa tidak ada lagi objek *non-medoid* lain yang dapat menurunkan total jarak dalam struktur kelompok, sehingga posisi *medoid* dinyatakan telah stabil. Koordinat objek yang terpilih sebagai pusat kelompok akhir pada kondisi konvergen di sajikan pada pada Tabel 9.

Tabel 9. Koordinat medoid akhir algoritma K-Medoids pada kondisi konvergen


Pusat Kelompok	Kabupaten/Kota	X_1	X_2	X_3	X_4	X_5
Medoid 1	Bulukumba	0.41	0.6968	0.5556	0.6598	0.1176
Medoid 2	Sidenreng Rappang	0.165	0.2645	0.2222	0.3093	0.6176
Medoid 3	Soppeng	0.48	0.7226	0.555	0.6907	0.6471

Berbeda dengan *K-Means* yang pusat klasternya berupa nilai rata-rata, pusat kelompok pada Tabel 9 merupakan data asli dari kabupaten/kota yang paling merepresentasikan karakteristik sebaran gizi balita (X_1 hingga X_5) di dalam kelompoknya. Berdasarkan koordinat *medoid* akhir tersebut, konfigurasi distribusi keanggotaan dari 24 kabupaten/kota di Provinsi Sulawesi Selatan untuk algoritma *K-Medoids* disajikan pada Tabel 10.

Tabel 10. Distribusi keanggotaan klaster akhir algoritma K-Medoids (k = 3)

Klaster	Prioritas Intervensi	X_1	X_2	X_3	X_4	X_5	Anggota Wilayah
1	sedang	0.4464	0.7488	0.6001	0.4841	0.1891	Bulukumba, Bantaeng, Jeneponto, Takalar, Sinjai, Maros, Pangkajene Dan Kepulauan, Barru, Wajo, Pinrang, Enrekang, Luwu, Kota Parepare, Kota Palopo
2	rendah	0.2925	0.2731	0.2921	0.1420	0.4363	Gowa, Sidenreng Rappang, Tana Toraja, Luwu Timur, Toraja Utara, Kota Makassar
3	tinggi	0.4238	0.7290	0.7113	0.7130	0.7868	Kepulauan Selayar, Bone, Soppeng, Wajo, Pinrang, Luwu Utara.

Untuk mempermudah analisis karakteristik dan perbandingan indikator gizi antar klaster, nilai rata-rata hasil normalisasi dari masing-masing klaster pada Tabel 10 divisualisasikan ke dalam bentuk diagram batang profil rerata yang disajikan pada Gambar 10 .




Gambar 10. Grafik Profil Rerata Indikator Gizi Per Klaster Algoritma *K-Medoids*

Berdasarkan Tabel 10 dan Gambar 10, hasil pengelompokan menggunakan algoritma K-Medoids dengan konfigurasi $k=3$ menghasilkan tiga kelompok wilayah dengan tingkat prioritas intervensi yang berbeda-beda di Provinsi Sulawesi Selatan. Klaster 3 masuk kategori prioritas intervensi tinggi karena memiliki nilai normalisasi wasting (0,7113), severe wasting (0,7130), dan overweight (0,7868) tertinggi di antara semua kelompok, serta underweight (0,7290) yang tergolong tinggi (tertinggi kedua setelah Klaster 1), yang berarti keempat wilayah dalam kelompok ini yaitu Kepulauan Selayar, Bone, Soppeng, dan Luwu Utara memiliki tingkat kekurangan gizi akut yang paling parah sekaligus beban gizi lebih yang paling tinggi dibandingkan wilayah lainnya, sehingga ditetapkan sebagai kelompok yang paling membutuhkan penanganan segera. Berbeda dengan kondisi tersebut, Klaster 1 yang mencakup 14 daerah yaitu Bulukumba, Bantaeng, Jeneponto, Takalar, Sinjai, Maros, Pangkajene dan Kepulauan, Barru, Wajo, Pinrang, Enrekang, Luwu, Kota Parepare, dan Kota Palopo masuk kategori prioritas intervensi sedang karena nilai normalisasi seluruh indikatornya berada pada tingkat menengah, dengan nilai stunting (0,4464) tertinggi dan underweight (0,7488) tertinggi di antara semua klaster, yang berarti kelompok ini mencerminkan kondisi gizi yang tetap memerlukan perhatian yang berkelanjutan. Sementara itu, Klaster 2 yang meliputi Kabupaten Gowa, Sidenreng Rappang, Tana Toraja, Luwu Timur, Toraja Utara, dan Kota Makassar masuk kategori prioritas intervensi rendah karena memiliki nilai normalisasi stunting (0,2925), underweight (0,2731), wasting (0,2921), dan severe wasting (0,1420) terendah di antara seluruh klaster, yang berarti keenam wilayah ini memiliki kondisi gizi balita yang paling baik dibandingkan wilayah lainnya di Provinsi Sulawesi Selatan.

Hasil pengelompokan wilayah menggunakan algoritma *K-Medoids* dapat divisualisasikan secara spasial menggunakan peta tematik. Pendekatan visual ini

diterapkan untuk mempermudah identifikasi sebaran geografis dari kabupaten dan kota di Provinsi Sulawesi Selatan yang memiliki homogenitas karakteristik indikator gizi balita dalam klaster yang sama. Visualisasi spasial dari sebaran ketiga kelompok tersebut disajikan pada Gambar 11.

**Peta Pemetaan Wilayah Prioritas di Provinsi Sulawesi Selatan
Berdasarkan Hasil Algoritma K-Medoids ($k = 3$) untuk Status Gizi Balita 2024**



**Gambar 11. Peta pemetaan wilayah prioritas Intervensi
hasil algoritma K-Medoids ($k=3$)**

Berdasarkan visualisasi spasial pada Gambar 11, konfigurasi pembagian wilayah hasil *K-Medoids* dipetakan ke dalam tiga kelompok prioritas intervensi yang direpresentasikan melalui gradasi warna yang berbeda. Daerah yang termasuk ke dalam Klaster 2 (Prioritas Rendah) disimbolkan dengan warna biru, yang mencakup wilayah dengan tata kelola indikator gizi paling terkendali. Selanjutnya, wilayah dalam Klaster 1 (Prioritas Sedang) digambarkan dengan warna hijau, yang mencerminkan kelompok daerah dengan capaian indikator gizi yang berada di sekitar nilai rerata keseluruhan dari ketiga klaster. Terakhir, daerah yang tergolong dalam Klaster 3 (Prioritas Tinggi) disimbolkan secara kontras menggunakan warna oranye guna menegaskan wilayah yang mengalami kondisi darurat malnutrisi akut terparah secara geografis.

3.4.3. Hasil Klasterisasi Algoritma *Agglomerative Hierarchical Clustering*


Agglomerative hierarchical clustering diinisialisasi dengan memperlakukan setiap kabupaten/kota sebagai satu kluster individu mandiri. Secara iteratif, algoritma ini mencari pasangan kluster dengan jarak multivariat paling minimum untuk digabungkan, hingga seluruh objek bersatu dalam satu pohon kluster tunggal. Sebagai contoh, perhitungan jarak awal antara Kabupaten Maros dan Luwu menggunakan Persamaan (3) sebagai berikut:

$$d(\text{Maros}, \text{luwu}) = \sqrt{(0.27 - 0.33)^2 + \dots + (0.3529 - 0.3235)^2} = 0.10773$$

Setelah kluster Maros dan Luwu terbentuk, jarak ke objek tunggal lainnya diperbarui menggunakan metode *Average Linkage*. Contohnya, jarak ke Kabupaten Pinrang sebagai berikut:

$$d(\{\text{Maros}, \text{Luwu}\}, \{\text{Pinrang}\}) = \frac{d(\text{maros}, \text{pinrang}) + d(\text{luwu}, \text{pinrang})}{2} = 0.2039$$

Silsilah seluruh tahapan penggabungan divisualisasikan dalam bentuk dendrogram sebagaimana disajikan pada Gambar 12.



Gambar 12. Dendrogram hasil *Agglomerative Hierarchical Clustering*


Berdasarkan visualisasi diagram silsilah berjenjang pada Gambar 4, berikut merupakan nilai jarak pemotongan sumbu horizontal beserta analisis celah vertikal untuk menentukan jumlah partisi kelompok terbaik dirangkum pada Tabel 11.

Tabel 11. Analisis celah vertikal dendrogram untuk penentuan jumlah kluster optimal

Skenario Jumlah Kluster	Estimasi Jarak Pemotongan	Karakteristik Gap Vertikal	Keterangan Struktur Partisi
2	≈ 0,92	kecil	struktur pengelompokan terlalu makro/umum.

Skenario Jumlah Klaster	Estimasi Jarak Pemotongan	Karakteristik Gap Vertikal	Keterangan Struktur Partisi
3	$\approx 0,81$	sedang	struktur yang cukup baik.
4	$\approx 0,72$	besar	konfigurasi paling optimal dan representatif.
5	$\approx 0,44$	kecil	struktur pengelompokan terlalu mikro/rinci.

Berdasarkan Tabel 11, konfigurasi $k = 4$ dinyatakan paling optimal karena terdapat celah vertikal maksimum di sekitar nilai jarak 0,72 sebelum penggabungan besar berikutnya pada jarak 0,92. Penarikan garis pemotongan tepat di atas 0,72 memisahkan 24 kabupaten/kota ke dalam empat kelompok yang heterogen antara satu sama lain.




Gambar 13. Dendrogram hasil Agglomerative Hierarchical Clustering dengan garis pemotongan pada ambang batas $y = 0,72$

Berdasarkan gambar 13, mekanisme pemotongan pada ambang batas jarak di $y=0.72$ memotong garis konektor vertikal pohon menjadi 4 bagian terpisah yang berdiri sendiri. Setiap percabangan vertikal yang berada di bawah garis potong horizontal tersebut dikelompokkan sebagai satu kesatuan klaster yang homogen. Konfigurasi sebaran distribusi keanggotaan dari 24 kabupaten/kota di Provinsi Sulawesi Selatan disajikan pada Tabel 12.

Tabel 12. Distribusi keanggotaan klaster akhir algoritma Agglomerative Hierarchical Clustering ($k = 4$)

Klaster	Prioritas Intervensi	X_1	X_2	X_3	X_4	X_5	Anggota Wilayah
1	rendah	0,1750	0,3597	0,4253	0,1296	0,5221	Gowa, Sidenreng Rappang, Luwu Timur, Kota Makassar.
2	sedang	0,6400	0,1957	0,0722	0,1975	0,1765	Enrekang, Tana Toraja, Toraja Utara
3	tinggi	0,3800	0,7540	0,6643	0,5648	0,3474	Kepulauan Selayar, Bulukumba, Bantaeng, Takalar, Sinjai, Maros, Pangkajene Dan Kepulauan, Barru, Bone, Soppeng, Wajo, Pinrang, Luwu, Luwu Utara, Kota Parepare, Kota Palopo.
4	sangat tinggi	1,0000	0,9484	0,4536	0,3333	0,2353	Jeneponto

Untuk mempermudah analisis karakteristik dan perbandingan indikator gizi antar klaster, nilai rata-rata hasil normalisasi dari masing-masing klaster pada Tabel 12 divisualisasikan ke dalam bentuk diagram batang profil rerata yang disajikan pada Gambar 14 .




Gambar 14. Grafik Profil Rerata Indikator Gizi Per Klaster Algoritma *Agglomerative Hierarchical Clustering*

Berdasarkan Tabel 12 dan Gambar 14, hasil pengelompokan menggunakan algoritma Agglomerative Hierarchical Clustering dengan konfigurasi $k=4$ menghasilkan empat kelompok wilayah dengan tingkat prioritas intervensi yang berbeda-beda di Provinsi Sulawesi Selatan. Klaster 4 masuk kategori prioritas intervensi sangat tinggi karena Kabupaten Jeneponto sebagai satu-satunya anggota memiliki nilai normalisasi stunting sebesar 1,0000 dan underweight sebesar 0,9484, yang berarti kedua nilai tersebut merupakan yang tertinggi di antara seluruh 24 kabupaten/kota di Provinsi Sulawesi Selatan. Nilai normalisasi 1,0000 pada indikator stunting secara matematis menunjukkan bahwa Kabupaten Jeneponto berada pada posisi paling ekstrem dalam skala keseluruhan data, sehingga wilayah ini terisolasi sebagai klaster tunggal yang mencerminkan kondisi krisis gizi kronis paling parah di provinsi. Berbeda dengan kondisi tersebut, Klaster 3 yang mencakup 16 daerah yaitu Kepulauan Selayar, Bulukumba, Bantaeng, Takalar, Sinjai, Maros, Pangkajene dan Kepulauan, Barru, Bone, Soppeng, Wajo, Pinrang, Luwu, Luwu Utara, Kota Parepare, dan Kota Palopo masuk kategori prioritas intervensi tinggi karena memiliki rata-rata nilai normalisasi wasting (0,6643), severe wasting (0,5648), dan underweight (0,7540) tertinggi di antara semua klaster selain Klaster 4, yang berarti 16 wilayah dalam kelompok ini menghadapi kondisi malnutrisi akut dan membutuhkan penanganan yang segera meskipun tidak separah Kabupaten Jeneponto. Apabila Klaster 4 mencerminkan krisis gizi kronis yang paling ekstrem dan Klaster 3 mencerminkan darurat malnutrisi akut, maka Klaster 2 yang terdiri dari Kabupaten Enrekang, Tana Toraja, dan Toraja Utara masuk kategori prioritas intervensi sedang karena memiliki nilai rata-rata normalisasi stunting tertinggi kedua (0,6400) namun justru memiliki nilai wasting (0,0722) terendah di seluruh provinsi serta severe wasting (0,1975) yang juga tergolong rendah, yang berarti ketiga wilayah ini menghadapi masalah pertumbuhan kronis tanpa disertai masalah parah pada

kekurangan gizi akut sehingga tingkat urgensi penanganannya lebih rendah dibandingkan kedua klaster sebelumnya. Sementara itu, Klaster 1 yang meliputi Kabupaten Gowa, Sidenreng Rappang, Luwu Timur, dan Kota Makassar masuk kategori prioritas intervensi rendah karena memiliki rata-rata nilai normalisasi stunting (0,1750) dan severe wasting (0,1296) terendah di antara seluruh klaster, yang berarti keempat wilayah ini memiliki kondisi gizi balita yang paling baik dan paling mendekati kondisi ideal dibandingkan wilayah lainnya di Provinsi Sulawesi Selatan.

Hasil pengelompokan wilayah menggunakan algoritma *Agglomerative Hierarchical Clustering* dapat divisualisasikan secara spasial menggunakan peta tematik. Pendekatan visual ini diterapkan untuk mempermudah identifikasi sebaran geografis dari kabupaten dan kota di Provinsi Sulawesi Selatan yang memiliki kemiripan karakteristik indikator gizi balita dalam klaster yang sama. Visualisasi spasial dari sebaran ketiga kelompok tersebut disajikan pada Gambar 15.

**Peta Pemetaan Wilayah Prioritas di Provinsi Sulawesi Selatan
Berdasarkan Hasil Agglomerative Hierarchical Clustering (Status Gizi Balita 2024)**



Gambar 15. Peta pemetaan wilayah prioritas intervensi hasil algoritma Agglomerative Hierarchical Clustering ($k=4$)

Berdasarkan visualisasi spasial pada Gambar 15, konfigurasi pembagian wilayah hasil *Agglomerative Hierarchical Clustering* dipetakan ke dalam empat kelompok prioritas intervensi yang direpresentasikan melalui gradasi warna yang berbeda. Daerah yang termasuk ke dalam Klaster 1 (Prioritas Rendah) disimbolkan dengan warna biru, yang mencakup wilayah dengan tata kelola indikator gizi paling terkendali. Selanjutnya, wilayah dalam Klaster 2 (Prioritas Sedang) digambarkan dengan warna hijau muda, yang

mencerminkan kelompok daerah dengan pola malnutrisi yang bersifat spesifik. Untuk wilayah yang masuk ke dalam Klaster 3 (Prioritas Tinggi) ditandai dengan warna oranye sebagai representasi kawasan dengan beban angka *wasting* tertinggi. Terakhir, daerah yang tergolong dalam Klaster 4 (Prioritas Sangat Tinggi) disimbolkan secara eksklusif menggunakan warna merah guna menegaskan wilayah Kabupaten Jeneponto sebagai klaster tunggal yang mengalami kondisi krisis gizi kronis paling ekstrem secara geografis.

3.5. Pemilihan Algoritma Terbaik dengan Melakukan Evaluasi Metrik

Setelah seluruh tahapan pengelompokan dilakukan menggunakan ketiga algoritma, tahap berikutnya adalah evaluasi perbandingan dari ketiga algoritma tersebut guna menentukan algoritma dengan validitas tertinggi dan struktur klaster paling solid. Hasil evaluasi disajikan pada Tabel 13.

Tabel 13. Perbandingan kinerja ketiga algoritma berdasarkan empat metrik evaluasi

Algoritma Pengkasteran	Jumlah Klaster	<i>Silhouette</i> Score (↑)	<i>Davies- Bouldin</i> Index (↓)	<i>Calinski- Harabasz</i> Index (↑)	<i>Dunn</i> Index (↑)
<i>K-Means</i>	4	0,3498	0,9210	13,9704	0,2335
<i>K-Medoids</i>	3	0,3141	0,9915	11,4361	0,2739
<i>Agglomerative Hierarchical</i>	4	0.2834	0.7655	8.5610	0.3423

Keterangan: Tanda (↑) menunjukkan semakin besar nilai semakin optimal; tanda (↓) menunjukkan semakin kecil nilai semakin optimal.

Berdasarkan rincian perbandingan metrik pada Tabel 13, diperoleh analisis mengenai kualitas pengelompokan dari masing-masing algoritma yang diuji. Karena setiap metrik evaluasi memiliki bobot posisi yang setara, performa algoritma dinilai berdasarkan jumlah metrik yang berhasil diungguli. Hasil evaluasi menunjukkan bahwa algoritma *K-Means* ($k = 4$) dan *Agglomerative Hierarchical Clustering* ($k = 4$) unggul pada masing-masing dua metrik validitas, sementara algoritma *K-Medoids* ($k = 3$) berada di posisi terendah.

Pertama, algoritma *K-Means* ($k = 4$) menunjukkan performa yang kuat dengan mengungguli dua metrik, yaitu nilai *Silhouette Score* tertinggi (0,3498) dan *Calinski-Harabasz Index* tertinggi (13,9704). *K-Means* berfokus pada meminimalkan total jarak kuadrat antara objek data dengan titik pusatnya secara berkelanjutan melalui pembaruan posisi titik rata-rata (*centroid*), yang secara langsung mereduksi varians internal kelompok (W_k). Karena *Calinski-Harabasz Index* menghitung rasio antara varians antar-klaster (B_k) dan varians dalam-klaster (W_k), meminimalkan nilai W_k secara langsung oleh *K-Means* memaksimalkan pembagi rasio tersebut. Karakteristik K-Means yang berbasis pusat rata-rata terbukti efektif dalam menghasilkan kelompok dengan kerapatan internal yang tinggi serta struktur pemisahan yang optimal secara menyeluruh.

Kedua, algoritma *Agglomerative Hierarchical Clustering* ($k = 4$) dengan metode *Average Linkage* menunjukkan performa yang sama unggulnya dengan mendominasi dua metrik lainnya, yakni nilai *Davies-Bouldin Index* terendah (0,7655) dan *Dunn Index* tertinggi (0,3423). Keunggulan ini terjadi karena pendekatan hirarkis *bottom-up* berbasis

rata-rata jarak antarpasangan objek sangat sensitif terhadap nilai ekstrem. Dalam penelitian ini, algoritma AHC berhasil mengisolasi Kabupaten Jeneponto yang memiliki angka *stunting* (37%) dan *underweight* (26,1%) paling ekstrem ke dalam sebuah kluster tunggal. Pembentukan kluster tunggal ini membuat diameter internal kluster Jeneponto menjadi nol ($\Delta C_{\text{Jeneponto}} = 0$) dan mencegah pembengkakan diameter kluster lainnya, sekaligus memperlebar jarak pemisah inter-kluster terkecil. Akibatnya, nilai *Dunn Index* yang merumuskan rasio pemisahan terhadap diameter maksimum meningkat secara drastis, serta meminimalkan rasio dispersi *Davies-Bouldin Index*. Capaian ini menandakan bahwa metode hierarki memiliki kemampuan yang sangat baik dalam memisahkan batas antar-kluster secara tegas dan meminimalkan tumpang tindih data.

Sementara itu, algoritma *K-Medoids* ($k = 3$) berada pada posisi terendah karena tidak berhasil mengungguli satu pun metrik validitas yang diuji, dengan nilai *Silhouette Score* sebesar 0,3141, *Davies-Bouldin Index* sebesar 0,9915, *Calinski-Harabasz Index* sebesar 11,4361, dan *Dunn Index* sebesar 0,2739. Hal ini terjadi akibat keterbatasan penentuan pusat kluster (*medoid*) yang wajib bertumpu pada objek riil, sehingga kurang fleksibel dalam menyesuaikan varians kelompok. Selain itu, sifat ketahanan *K-Medoids* terhadap pencilaan justru menyatukan Kabupaten Jeneponto yang bernilai ekstrem ke dalam kluster heterogen berukuran besar berisi 13 wilayah lainnya, yang berdampak pada membengkaknya varians internal kelompok dan penurunan kualitas pemisahan.

Berdasarkan keseluruhan pengujian multi-metrik tersebut, algoritma *K-Means* ($k = 4$) dan *Agglomerative Hierarchical Clustering* ($k = 4$) dinyatakan memiliki kedudukan yang setara sebagai algoritma pengelompokan terbaik untuk data prevalensi gizi balita di Provinsi Sulawesi Selatan, karena masing-masing berhasil unggul pada masing-masing dua dari empat metrik yang diuji. Penggunaan kedua algoritma ini dapat disesuaikan dengan kebutuhan spesifik analisis data kesehatan, algoritma *K-Means* menjadi pilihan utama jika orientasi pemetaan berfokus pada kekompakan struktur kluster secara umum. Sebaliknya, algoritma *Agglomerative Hierarchical Clustering* menjadi pilihan terbaik jika analisis lebih mengutamakan jarak pemisahan yang tegas antar-wilayah serta sensitivitas dalam mengisolasi wilayah dengan kondisi gizi ekstrem.

BAB IV

KESIMPULAN DAN SARAN

4.1. Kesimpulan

Berdasarkan hasil analisis pengelompokan data sebaran gizi balita di Provinsi Sulawesi Selatan menggunakan tiga algoritma klusterisasi, diperoleh kesimpulan bahwa ketiga algoritma menghasilkan jumlah klaster yang berbeda satu sama lain. Algoritma *K-Means* membagi wilayah menjadi empat kelompok berdasarkan tingkat prioritas intervensi, yaitu prioritas sangat tinggi yang mencerminkan darurat malnutrisi akut terdiri dari 6 daerah (Kepulauan Selayar, Bone, Soppeng, Wajo, Pinrang, dan Luwu Utara), prioritas sedang yang berfokus pada stunting kronis dengan rata-rata indikator berada di sekitar rata-rata klaster terdiri dari 3 daerah (Enrekang, Tana Toraja, dan Toraja Utara), prioritas tinggi yang mencerminkan kondisi gizi malnutrisi akut cukup berat terdiri dari 11 daerah, serta prioritas rendah dengan indikator gizi terbaik dibandingkan dengan klaster lainnya yang terdiri dari 4 daerah (Gowa, Sidenreng Rappang, Luwu Timur, dan Kota Makassar). Algoritma *K-Medoids* membagi wilayah menjadi tiga kelompok, yaitu prioritas tinggi yang mencerminkan kondisi malnutrisi akut terdiri dari 4 daerah (Kepulauan Selayar, Bone, Soppeng, dan Luwu Utara), prioritas sedang yang mencerminkan kondisi gizi pada ambang batas rata-rata klaster terdiri dari 14 daerah, serta prioritas rendah dengan indikator gizi terbaik terdiri dari 6 daerah (Gowa, Sidenreng Rappang, Tana Toraja, Luwu Timur, Toraja Utara, dan Kota Makassar). Sementara itu, algoritma *Agglomerative Hierarchical Clustering* membagi wilayah menjadi empat kelompok, yaitu prioritas sangat tinggi untuk Kabupaten Jeneponto sebagai klaster tunggal di provinsi, prioritas tinggi untuk 16 daerah dengan angka wasting tertinggi di provinsi sebesar 8,44%, prioritas sedang yang berfokus pada stunting kronis terdiri dari 3 daerah (Enrekang, Tana Toraja, dan Toraja Utara), serta prioritas rendah dengan indikator gizi terbaik terdiri dari 4 daerah (Gowa, Sidenreng Rappang, Luwu Timur, dan Kota Makassar).

Hasil evaluasi dengan empat metrik menunjukkan bahwa performa dua dari ketiga algoritma terbagi cukup seimbang. Algoritma *K-Means* unggul pada dua metrik, yaitu *Silhouette Score* sebesar 0,3498 dan *Calinski-Harabasz Index* sebesar 13,9704. Algoritma *Agglomerative Hierarchical Clustering* unggul pada dua metrik lainnya, yaitu *Davies-Bouldin Index* sebesar 0,7655 dan *Dunn Index* sebesar 0,3423. Sementara itu, algoritma *K-Medoids* tidak unggul pada satu pun metrik yang diuji, dengan nilai *Silhouette Score* sebesar 0,3141, *Davies-Bouldin Index* sebesar 0,9915, *Calinski-Harabasz Index* sebesar 11,4361, dan *Dunn Index* sebesar 0,2739, sehingga menunjukkan performa terendah di antara ketiga metode yang diuji.

Berdasarkan hasil evaluasi tersebut, algoritma *K-Means* dan *Agglomerative Hierarchical Clustering* dengan konfigurasi $k=4$ ditetapkan bersama sebagai algoritma paling optimal, karena masing-masing berhasil unggul secara seimbang pada metrik evaluasi yang diuji. Algoritma *K-Means* terbukti paling akurat dalam menghasilkan ikatan internal kelompok yang padat berdasarkan struktur pusat data, sementara algoritma *Agglomerative Hierarchical Clustering* memiliki keunggulan utama pada sensitivitas tinggi dalam memisahkan batas antarkelompok secara tegas serta kemampuannya mengisolasi wilayah dengan profil gizi ekstrem. Melalui hasil dari kedua algoritma

tersebut, penentuan prioritas intervensi kesehatan yang dihasilkan menjadi lebih akurat, menyeluruh, dan tepat sasaran berdasarkan data prevalensi gizi balita di Provinsi Sulawesi Selatan.

4.2. Saran

Adapun saran yang dapat diberikan untuk pengembangan penelitian selanjutnya adalah sebagai berikut:

1. Bagi peneliti selanjutnya disarankan untuk mengeksplorasi penggunaan variasi metrik jarak non-Euclidean, seperti *Manhattan Distance* atau *Minkowski Distance*, serta menjajaki metode keterkaitan (*linkage*) lainnya pada algoritma *Agglomerative Hierarchical Clustering* (seperti *Complete Linkage* atau *Ward's Method*). Selain itu, peneliti selanjutnya juga dapat mencoba algoritma klasterisasi lainnya, seperti *DBSCAN* (berbasis kerapatan), *Gaussian Mixture Model* (GMM berbasis probabilitas), maupun algoritma berbasis *fuzzy* (*Fuzzy C-Means*), untuk mengevaluasi apakah batas pemisahan kelompok dan fleksibilitas pembentukan klaster dapat lebih ditingkatkan. Penambahan variabel gizi relevan lainnya seperti akses sanitasi layak, tingkat kemiskinan, atau ketahanan pangan daerah juga disarankan untuk memberikan gambaran yang lebih komprehensif.
2. Bagi Pemerintah Daerah dan Dinas Kesehatan disarankan untuk menjadikan hasil klasterisasi *K-Means* dan *Agglomerative Hierarchical Clustering* sebagai landasan berbasis data dalam perumusan kebijakan alokasi sumber daya serta perencanaan program intervensi gizi di Provinsi Sulawesi Selatan.

DAFTAR PUSTAKA

- Amiruddin dan Ishak, R., 2025. Optimalisasi seleksi atribut *K-Means* menggunakan correlation matrix pada clustering penyakit pasien. *Jambura J. Electr. Electron. Eng.* 7(2), 141–148. <https://doi.org/10.37905/jjee.v7i2.28010>. [Diakses 10 Januari 2026]
- Ananta, M.A.F. dan Sofro, A., 2025. Comparison of *K-Means* and *K-Medoids* algorithms in clustering Indonesian provinces using stunting handling index. *Numerical: J. Mat. Pendidik. Mat.* 9(2), 343–352. <https://journal.iaimnumetrolampung.ac.id/index.php/numerical/article/view/7194>. [Diakses 25 April 2026].
- Andriany, S., Kusnandar, D. dan Perdana, H., 2021. Pengelompokan provinsi di Indonesia berdasarkan permasalahan gizi balita menggunakan metode fuzzy subtractive clustering. *Bul. Ilm. Mat. Stat. Terapannya* 10(3), 351–360. <https://jurnal.untan.ac.id/index.php/jbmstr/article/download/48340/75676590061>. [Diakses 25 April 2026]
- Arthur, D. dan Vassilvitskii, S., 2007. *K-Means++*: The advantages of careful seeding. Dalam: Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA 2007); 7–9 Jan 2007, New Orleans, Louisiana, USA. Society for Industrial and Applied Mathematics, Philadelphia. pp. 1027–1035. <https://share.google/uldsZXzXQm6lv4dda>. [Diakses 1 Juni 2026]
- Han, J., Kamber, M. dan Pei, J., 2011. *Data Mining: Concepts and Techniques*. 3rd ed. Morgan Kaufmann Publishers, Burlington. <https://share.google/dKxVuRcGEC9m5kNlp>. [Diakses 20 Februari 2026]
- Hasugian, P.M., Mathelinea, D., Simamora, S. dan Simangunsong, P.B.N., 2025. Comparative evaluation of data clustering accuracy through integration of dimensionality reduction and distance metric. *MATRIK: J. Manaj. Tek. Inform. Rekayasa Komput.* 24(3), 577–588. <https://doi.org/10.30812/matrik.v24i3.5057> [Diakses 20 Mei 2026]
- Kementerian Kesehatan RI, 2025a. *Buku Saku Hasil Survei Status Gizi Indonesia (SSGI) 2024*. Badan Kebijakan Pembangunan Kesehatan, Jakarta. <https://www.badankebijakan.kemkes.go.id/survei-status-gizi-indonesia-ssgi-2024/> [Diakses 1 April 2026].
- Kementerian Kesehatan RI, 2025b. SSGI 2024: Prevalensi stunting nasional turun menjadi 19,8% [Online]. Kementerian Kesehatan Republik Indonesia, Jakarta. <https://kemkes.go.id/id/ssgi-2024-prevalensi-stunting-nasional-turun-menjadi-198> [Diakses 12 Januari 2026].
- Raihannabil, S.D., 2024. Penerapan metode hierarchical clustering untuk klasterisasi provinsi di Indonesia berdasarkan indikator status gizi anak baduta (bawah dua tahun) tahun 2023. *Emerg. Stat. Data Sci. J.* 2(3), 424–436. <https://doi.org/10.20885/esds.vol2.iss.3.art32>. [Diakses 3 Januari 2026]
- Tambunan, E., Limbeng, Y.B. dan Sipayung, S., 2026. Implementasi algoritma *K-Means* dengan normalisasi min-max pada analisis data ketidakbersekolahan anak. *J. Data Min. Inf. Syst.* 4(1). <https://journal.yp3a.org/index.php/jdmis/article/view/7064>. [Diakses 10 Februari 2026]
- UNICEF, World Health Organization dan World Bank Group, 2025. *Levels and Trends in Child Malnutrition: Key Findings of the 2025 Edition*. World Health Organization, Geneva. <https://www.who.int/publications/i/item/9789240112308> [Diakses 3 Januari 2026].

LAMPIRAN

Lampiran 1. Data prevalensi status gizi balita per kabupaten/kota di Provinsi Sulawesi Selatan tahun 2024 (Sumber: SSGI 2024)

Kota/ kabupaten	Stunting (%)	Underweight (%)	Severe Wasting (%)	Wasting (%)	Overweight (%)
Kepulauan Selayar	25.7	23.7	1.8	11.7	4.6
Bulukumba	25.2	22.2	1.6	8.4	2.1
Bantaeng	24.3	23.7	1.2	9	1.8
Jeneponto	37	26.1	1	6.4	2.5
Takalar	24	22.1	2	8	2
Gowa	17	14.2	0.2	5.9	3.9
Sinjai	28.6	23.1	1.5	6.9	2.5
Maros	22.4	21.6	1.5	6.8	2.9
Pangkajene Dan Kepulauan	25.2	24	0.5	8.7	2
Barru	26.9	26.9	1.5	8.6	2
Bone	26	23.2	1.9	7	5.1
Soppeng	26.6	22.6	1.6	8.7	3.9
Wajo	20.5	25.1	2.4	10.8	3
Sidenreng Rappang	20.3	15.5	0.7	5	3.8
Pinrang	22.2	21.2	1.9	7.8	3.1
Enrekang	34.3	17.4	0.8	3.6	1.7
Luwu	23.6	20.3	1.5	6.9	2.8
Tana Toraja	27.5	11.4	0.1	2.5	2.4
Luwu Utara	23.6	21.3	2.8	8.2	3.9
Luwu Timur	21.8	19.4	0.6	6.4	3.1
Toraja Utara	27.6	14.5	1	2	2.8
Kota Makassar	22.9	18.8	0.3	7.2	3.1
Kota Parepare	26.1	26.1	1.3	9.5	2.3
Kota Palopo	22.7	22.3	1	8.1	2.1

Lampiran 2. Hasil normalisasi data menggunakan metode Min-Max

Kota/ kabupaten	Stunting	Underweight	Severe Wasting	Wasting	Overweight
Kepulauan Selayar	0.435	0.7935	0.6296	1	0.8529
Bulukumba	0.41	0.6968	0.5556	0.6598	0.1176
Bantaeng	0.365	0.7935	0.4074	0.7216	0.0294
Jeneponto	1	0.9484	0.3333	0.4536	0.2353
Takalar	0.35	0.6903	0.7037	0.6186	0.0882
Gowa	0	0.1806	0.037	0.4021	0.6471
Sinjai	0.58	0.7548	0.5185	0.5052	0.2353
Maros	0.27	0.6581	0.5185	0.4948	0.3529
Pangkajene Dan Kepulauan	0.41	0.8129	0.1481	0.6907	0.0882

Kota/ kabupaten	Stunting	Underweight	Severe Wasting	Wasting	Overweight
Barru	0.495	1	0.5185	0.6804	0.0882
Bone	0.45	0.7613	0.6667	0.5155	1
Soppeng	0.48	0.7226	0.5556	0.6907	0.6471
Wajo	0.175	0.8839	0.8519	0.9072	0.3824
Sidenreng					
Rappang	0.165	0.2645	0.2222	0.3093	0.6176
Pinrang	0.26	0.6323	0.6667	0.5979	0.4118
Enrekang	0.865	0.3871	0.2593	0.1649	0
Luwu	0.33	0.5742	0.5185	0.5052	0.3235
Tana Toraja	0.525	0	0	0.0515	0.2059
Luwu Utara	0.33	0.6387	1	0.6392	0.6471
Luwu Timur	0.24	0.5161	0.1852	0.4536	0.4118
Toraja Utara	0.53	0.2	0.3333	0	0.3235
Kota Makassar	0.295	0.4774	0.0741	0.5361	0.4118
Kota Parepare	0.455	0.9484	0.4444	0.7732	0.1765
Kota Palopo	0.285	0.7032	0.3333	0.6289	0.1176

Lampiran 3. Hasil Iterasi pertama algoritma *K-Means*

Kota	Jarak ke <i>centroid</i> 1	Jarak ke <i>centroid</i> 2	Jarak ke <i>centroid</i> 3	Jarak ke <i>centroid</i> 4	Cluster terpilih
Kepulauan Selayar	0.9557	1.3151	0.0001	1.0253	3
Bulukumba	0.4258	0.8879	0.8196	0.8549	1
Bantaeng	0.2721	0.9961	0.8999	0.9328	1
Jeneponto	0.6918	0.9973	1.0540	1.1594	1
Takalar	0.5767	0.9209	0.8681	0.9073	1
Gowa	0.9878	0.7971	1.1471	0.2793	4
Sinjai	0.4749	0.7795	0.8131	0.8276	1
Maros	0.5378	0.7466	0.7504	0.5985	1
Pangkajene Dan Kepulauan	0.0001	0.9782	0.9556	0.8899	1
Barru	0.4237	1.0926	0.8634	1.0750	1
Bone	1.0655	1.0751	0.5090	0.8452	3
Soppeng	0.7010	0.9522	0.3880	0.7527	3
Wajo	0.8300	1.2997	0.5960	1.0923	3
Sidenreng					
Rappang	0.8900	0.5761	1.0252	0.0001	4
Pinrang	0.6613	0.8580	0.6436	0.6837	3
Enrekang	0.8276	0.5335	1.3827	0.9532	2
Luwu	0.5389	0.6852	0.7724	0.5795	1
Tana Toraja	1.0575	0.4094	1.5337	0.6963	2
Luwu Utara	1.0380	1.0910	0.5872	0.9391	3
Luwu Timur	0.5284	0.6477	0.8976	0.3654	4
Toraja Utara	0.9782	0.0000	1.3150	0.5761	2
Kota Makassar	0.5098	0.7032	0.9154	0.4219	4
Kota Parepare	0.3504	1.0943	0.7534	1.0055	1
Kota Palopo	0.2582	0.8667	0.8926	0.7558	1

Lampiran 4. Hasil centroid baru iterasi pertama algoritma *K-Means*

Pusat Kelompok	X_1	X_2	X_3	X_4	X_5
<i>Centroid 1</i>	0.45	0.7801	0.4545	0.612	0.1684
<i>Centroid 2</i>	0.64	0.1957	0.1975	0.0722	0.1765
<i>Centroid 3</i>	0.355	0.7387	0.7284	0.7251	0.6569
<i>Centroid 4</i>	0.175	0.3597	0.1296	0.4253	0.5221

Lampiran 5. Hasil konvergen pada iterasi kedua algoritma *K-Means*

Kota	Jarak ke <i>centroid 1</i>	Jarak ke <i>centroid 2</i>	Jarak ke <i>centroid 3</i>	Jarak ke <i>centroid 4</i>	Cluster terpilih
Kepulauan Selayar	0.9557	1.3151	0.0001	1.0253	3
Bulukumba	0.4258	0.8879	0.8196	0.8549	1
Bantaeng	0.2721	0.9961	0.8999	0.9328	1
Jeneponto	0.6918	0.9973	1.0540	1.1594	1
Takalar	0.5767	0.9209	0.8681	0.9073	1
Gowa	0.9878	0.7971	1.1471	0.2793	4
Sinjai	0.4749	0.7795	0.8131	0.8276	1
Maros	0.5378	0.7466	0.7504	0.5985	1
Pangkajene Dan Kepulauan	0.0001	0.9782	0.9556	0.8899	1
Barru	0.4237	1.0926	0.8634	1.0750	1
Bone	1.0655	1.0751	0.5090	0.8452	3
Soppeng	0.7010	0.9522	0.3880	0.7527	3
Wajo	0.8300	1.2997	0.5960	1.0923	3
Sidenreng Rappang	0.8900	0.5761	1.0252	0.0001	4
Pinrang	0.6613	0.8580	0.6436	0.6837	3
Enrekang	0.8276	0.5335	1.3827	0.9532	2
Luwu	0.5389	0.6852	0.7724	0.5795	1
Tana Toraja	1.0575	0.4094	1.5337	0.6963	2
Luwu Utara	1.0380	1.0910	0.5872	0.9391	3
Luwu Timur	0.5284	0.6477	0.8976	0.3654	4
Toraja Utara	0.9782	0.0000	1.3150	0.5761	2
Kota Makassar	0.5098	0.7032	0.9154	0.4219	4
Kota Parepare	0.3504	1.0943	0.7534	1.0055	1
Kota Palopo	0.2582	0.8667	0.8926	0.7558	1

Lampiran 6. Hasil Iterasi pertama algoritma *K-Medoids*

Kota	Jarak ke <i>medoid 1</i>	Jarak ke <i>medoid 2</i>	Jarak ke <i>medoid 3</i>	Cluster terpilih
Kepulauan Selayar	0.0001	1.1472	1.0253	1
Bulukumba	0.8196	1.0248	0.8549	1
Bantaeng	0.8999	1.0629	0.9328	1
Jeneponto	1.0540	1.3600	1.1594	1
Takalar	0.8681	1.0890	0.9073	1

Kota	Jarak ke <i>medoid</i> 1	Jarak ke <i>medoid</i> 2	Jarak ke <i>medoid</i> 3	Cluster terpilih
Gowa	1.1471	0.0001	0.2793	2
Sinjai	0.8131	1.0384	0.8276	1
Maros	0.7504	0.7924	0.5985	3
Pangkajene Dan Kepulauan	0.9556	0.9879	0.8899	3
Barru	0.8634	1.2402	1.0750	1
Bone	0.5090	1.0361	0.8452	1
Soppeng	0.3880	0.9361	0.7527	1
Wajo	0.5960	1.2306	1.0923	1
Sidenreng Rappang	1.0252	0.2794	0.0001	3
Pinrang	0.6436	0.8728	0.6837	1
Enrekang	1.3827	1.1468	0.9532	3
Luwu	0.7724	0.7817	0.5795	3
Tana Toraja	1.5337	0.7919	0.6963	3
Luwu Utara	0.5872	1.1412	0.9391	1
Luwu Timur	0.8976	0.5002	0.3654	3
Toraja Utara	1.3150	0.7972	0.5761	3
Kota Makassar	0.9154	0.4998	0.4219	3
Kota Parepare	0.7534	1.1497	1.0055	1
Kota Palopo	0.8926	0.8797	0.7558	3

Lampiran 7. Hasil Iterasi lengkap algoritma *K-Medoids* (proses pertukaran *medoid* hingga konvergen)

Kota	Jarak ke <i>medoid</i> 1	Jarak ke <i>medoid</i> 2	Jarak ke <i>medoid</i> 3	Cluster terpilih
Kepulauan Selayar	0.8197	1.0253	0.3882	3
Bulukumba	0.0001	0.8549	0.5356	1
Bantaeng	0.2120	0.9328	0.6500	1
Jeneponto	0.7191	1.1594	0.7722	1
Takalar	0.1677	0.9073	0.5980	1
Gowa	1.0248	0.2793	0.9358	2
Sinjai	0.2672	0.8276	0.4652	1
Maros	0.3241	0.5985	0.4177	1
Pangkajene Dan Kepulauan	0.4258	0.8899	0.7007	1
Barru	0.3191	1.0750	0.6253	1
Bone	0.9042	0.8452	0.4124	3
Soppeng	0.5356	0.7527	0.0006	3
Wajo	0.5561	1.0923	0.5693	1
Sidenreng Rappang	0.8550	0.0001	0.7524	2
Pinrang	0.3597	0.6837	0.3647	1
Enrekang	0.8059	0.9532	1.0215	1
Luwu	0.2985	0.5795	0.4301	1
Tana Toraja	1.0887	0.6963	1.1981	2
Luwu Utara	0.6986	0.9391	0.4798	3
Luwu Timur	0.5725	0.3654	0.5904	2

Kota	Jarak ke <i>medoid</i> 1	Jarak ke <i>medoid</i> 2	Jarak ke <i>medoid</i> 3	Cluster terpilih
Toraja Utara	0.8879	0.5761	0.9521	2
Kota Makassar	0.6285	0.4219	0.6363	2
Kota Parepare	0.3066	1.0055	0.5405	1
Kota Palopo	0.2570	0.7558	0.6097	1

Lampiran 8. Tahapan penggabungan lengkap algoritma *Agglomerative Hierarchical Clustering*

Tahap	Jarak 1	Jarak 2	Jarak rata- rata
Langkah 1	Maros	Luwu	0.1077
Langkah 2	Luwu Timur	Kota Makassar	0.1539
Langkah 3	Barru	Kota Parepare	0.1617
Langkah 4	Bulukumba	Takalar	0.1678
Langkah 5	Bantaeng	Kota Palopo	0.1909
Langkah 6	Maros, Luwu	Pinrang	0.2039
Langkah 7	Bantaeng, Kota Palopo	Pangkajene Dan Kepulauan	0.2651
Langkah 8	Gowa	Sidenreng Rappang	0.2793
Langkah 9	Bulukumba, Takalar Bantaeng, Kota Palopo, Pangkajene Dan	Sinjai	0.311
Langkah 10	Kepulauan	Barru, Kota Parepare	0.3431
Langkah 11	Bulukumba, Takalar, Sinjai	Maros, Luwu, Pinrang	0.3459
Langkah 12	Kepulauan Selayar	Soppeng	0.3881
Langkah 13	Tana Toraja	Toraja Utara	0.4094
Langkah 14	Bulukumba, Takalar, Sinjai, Maros, Luwu, Pinrang	Bantaeng, Kota Palopo, Pangkajene Dan Kepulauan, Barru, Kota Parepare	0.4329
Langkah 15	Gowa, Sidenreng Rappang	Luwu Timur, Kota Makassar	0.4468
Langkah 16	Kepulauan Selayar, Soppeng	Bone	0.4607
Langkah 17	Wajo	Luwu Utara	0.498
Langkah 18	Enrekang	Tana Toraja, Toraja Utara	0.5781
Langkah 19	Kepulauan Selayar, Soppeng, Bone	Wajo, Luwu Utara Bulukumba, Takalar, Sinjai, Maros, Luwu, Pinrang, Bantaeng, Kota Palopo, Pangkajene Dan Kepulauan,	0.5956
Langkah 20	Soppeng, Bone, Wajo, Luwu Utara	Barru, Kota Parepare	0.7158
Langkah 21	Gowa, Sidenreng Rappang, Luwu Timur, Kota Makassar	Enrekang, Tana Toraja, Toraja Utara	0.7888
Langkah 22	Kepulauan Selayar, Soppeng, Bone, Wajo, Luwu Utara, Bulukumba,	Jeneponto	0.8152

Tahap	Jarak 1	Jarak 2	Jarak rata-rata
	Takalar, Sinjai, Maros, Luwu, Pinrang, Bantaeng, Kota Palopo, Pangkajene Dan Kepulauan, Barru, Kota Parepare		

Lampiran 9. Kode program *python* untuk statistik deskriptif

```
import pandas as pd

# 1. TAHAP LOAD & PREPROCESSING DATA ASLI

# Membaca dataset gizi tahun 2024
df = pd.read_csv('data_gizi_2024.csv')
cols_gizi = ['Stunting(%)', 'Underweight(%)', 'Severe Wasting (%)', 'Wasting(%)',
'Overweight(%)']

# Membersihkan format angka (mengganti karakter koma menjadi titik)
for col in cols_gizi:
    if df[col].dtype == 'object':
        df[col] = df[col].str.replace(',', '.', regex=False).astype(float)

# 2. TAHAP ANALISIS STATISTIK DESKRIPTIF
# Menghitung statistik deskriptif dan melakukan transpose (.T) agar
# indikator gizi berada di baris dan metrik statistik di kolom (standar skripsi)
df_deskriptif = df[cols_gizi].describe().T

# Mengubah nama indeks menjadi kolom formal 'Indikator Gizi'
df_deskriptif.index.name = 'Indikator Gizi'
df_deskriptif = df_deskriptif.reset_index()

# Melakukan pembulatan 4 angka di belakang koma agar rapi
df_deskriptif = df_deskriptif.round(4)

# 3. EKSPOR HASIL STATISTIK DESKRIPTIF KE EXCEL
nama_file_excel = 'statistik_deskriptif_gizi.xlsx'
df_deskriptif.to_excel(nama_file_excel, index=False)

print("="*65)
print(f'{"PROSES STATISTIK DESKRIPTIF SELESAI":^65}')
print("="*65)
print(f"Hasil analisis telah berhasil disimpan dalam file:\n-> {nama_file_excel}")
```

```
print("="*65)

# Menampilkan hasil statistik deskriptif di konsol
print("\nRingkasan Statistik Deskriptif:")
print(df_deskriptif.to_string(index=False))
```

Lampiran 10. Kode program *Python* untuk algoritma *K-Means* dengan menggunakan *library python*

```
import math
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns # Import seaborn for advanced styling
from sklearn.cluster import KMeans
from sklearn.preprocessing import MinMaxScaler

# 1. TAHAP LOAD & PREPROCESSING DATA
df = pd.read_csv("data_gizi_2024.csv")
cols_gizi = [
    "Stunting(%)",
    "Underweight(%)",
    "Severe Wasting (%)",
    "Wasting(%)",
    "Overweight(%)",
]

for col in cols_gizi:
    if df[col].dtype == "object":
        df[col] = df[col].str.replace(",", ".", regex=False).astype(float)

X = df[cols_gizi].values

# 2. TAHAP NORMALISASI DATA (MIN-MAX SCALING)
scaler = MinMaxScaler()
X_normalized = scaler.fit_transform(X)
df[cols_gizi] = X_normalized

# 3. IMPLEMENTASI ALGORITMA K-MEANS CLUSTERING
kmeans = KMeans(n_clusters=4, init="k-means++", random_state=42, n_init=10)
cluster_labels = kmeans.fit_predict(X_normalized)
df["Cluster_KMeans"] = cluster_labels + 1

# 4. TAHAP PROFILING DAN IDENTIFIKASI ANGGOTA KLASSTER
print("=" * 75)
print(f'{"DAFTAR ANGGOTA WILAYAH DAN PROFIL RERATA KLASSTER":^75}')
```

```

print("=" * 75)

nama_kolom_wilayah = "Kota"

for c in sorted(df["Cluster_KMeans"].unique()):
    df_cluster = df[df["Cluster_KMeans"] == c]
    wilayah = df_cluster[nama_kolom_wilayah].tolist()

    print(f"KLAUSTER {c} (Jumlah: {len(wilayah)} Wilayah)")
    print(f"Anggota      : {' '.join(wilayah)}")

    stunting_avg = df_cluster["Stunting(%)"].mean()
    wasting_avg = df_cluster["Wasting(%)"].mean()
    severe_wasting_avg = df_cluster["Severe Wasting (%)"].mean()
    underweight_avg = df_cluster["Underweight(%)"].mean()
    overweight_avg = df_cluster["Overweight(%)"].mean()

    print(
        f"Rerata Indikator : Stunting ({stunting_avg:.4f}), "
        f"Wasting ({wasting_avg:.4f}), "
        f"Severe Wasting ({severe_wasting_avg:.4f}), "
        f"Underweight ({underweight_avg:.4f}), "
        f"Overweight ({overweight_avg:.4f})"
    )
    print("-" * 75)

print("\n" + "=" * 50)
print(f"{'CENTROID HASIL K-MEANS':^50}")
print("=" * 50)
print(kmeans.cluster_centers_.round(4))

# 5. TAHAP VISUALISASI RERATA INDIKATOR GIZI PER KLAUSTER (BAGAN
TANPA WARNA / MONOKROM)

cluster_counts = df["Cluster_KMeans"].value_counts().to_dict()
df_for_melt = df.groupby("Cluster_KMeans")[cols_gizi].mean().reset_index()
df_melted = df_for_melt.melt(
    id_vars="Cluster_KMeans",
    var_name="Indikator Gizi",
    value_name="Nilai Normalisasi",
)
df_melted["Indikator Gizi"] = (
    df_melted["Indikator Gizi"].str.replace(r"\s*(%\\)", "", regex=True).str.strip()
)

```

```
df_cluster_mean_for_x_labels = df.groupby("Cluster_KMeans")[cols_gizi].mean()
df_cluster_mean_for_x_labels.index = [
    f"Klaster {c}\n({cluster_counts.get(c, 0)} Wilayah)"
    for c in df_cluster_mean_for_x_labels.index
]
```

```
# Mengatur tema dengan gaya putih bersih
sns.set_theme(style="white")
```

```
fig, ax = plt.subplots(figsize=(14, 8), dpi=150)
```

```
# PERUBAHAN WARNA: Penggunaan gradasi abu-abu hingga hitam agar tetap
bisa membedakan 5 indikator
colors_grayscale = ["#333333", "#666666", "#999999", "#cccccc", "#e6e6e6"]
```

```
# Membuat bagan batang dengan palet abu-abu dan outline hitam tebal agar
terpisah jelas
```

```
sns.barplot(
    data=df_melted,
    x="Cluster_KMeans",
    y="Nilai Normalisasi",
    hue="Indikator Gizi",
    palette=colors_grayscale,
    ax=ax,
    width=0.8,
    edgecolor="black", # Garis tepi hitam untuk memperjelas bentuk batang
    linewidth=0.8,
)
```

```
# --- KUSTOMISASI DETAIL GRAFIK ---
```

```
# 1. Judul Utama (Hitam)
```

```
plt.title(
    "PROFIL RERATA INDIKATOR GIZI PER KLASER",
    fontsize=14,
    fontweight="bold",
    pad=25,
    color="black",
    loc="center",
)
```

```
# 2. Label Sumbu (Hitam)
```

```
plt.xlabel(
    "Kelompok Klaster K-Means",
    fontsize=11,
```

```

        fontweight="semibold",
        labelpad=12,
        color="black",
    )
    plt.ylabel(
        "Rata-rata Nilai Normalisasi",
        fontsize=11,
        fontweight="semibold",
        labelpad=12,
        color="black",
    )
    ax.set_xticklabels(df_cluster_mean_for_x_labels.index)
    plt.xticks(rotation=0, fontsize=10.5, fontweight="semibold", color="black")
    plt.yticks(fontsize=10, color="black")

```

3. Menambahkan Label Nilai di Atas Setiap Batang (Warna Hitam)

for container in ax.containers:

```

    ax.bar_label(
        container,
        fmt="%.2f",
        padding=5,
        fontsize=9,
        fontweight="bold",
        color="black",
    )

```

4. Garis Bantu (Gridlines Abu-abu Muda)

```

ax.yaxis.grid(True, linestyle="--", alpha=0.5, color="#888888")
ax.xaxis.grid(False)
sns.despine(left=False, bottom=False) # Menampilkan bingkai kiri dan bawah

```

5. Legenda Monokrom

```

plt.legend(
    title="Indikator Gizi",
    title_fontsize="11",
    fontsize="10",
    loc="upper center",
    bbox_to_anchor=(0.5, -0.15),
    ncol=5,
    frameon=True,
    facecolor="white",
    edgecolor="black",
)

```

```

plt.tight_layout()

```

```
plt.savefig("analisis_klaster_gizi_2024_monokrom.png", bbox_inches="tight",
dpi=300)
plt.show()
```

Lampiran 11. Kode program *Python* untuk algoritma *K-Medoids* dengan menggunakan *library python*

```
import sys
import subprocess

# Hapus instalasi NumPy yang ada dan instal versi 1.26.4
subprocess.check_call([sys.executable, "-m", "pip", "install", "numpy==1.26.4"])

print("NumPy versi 1.26.4 berhasil diinstal.")

import math
import subprocess
import sys
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler

# Menggunakan KMedoids dari scikit-learn-extra
try:
    from sklearn_extra.cluster import KMedoids
except ImportError:
    subprocess.check_call(
        [sys.executable, "-m", "pip", "install", "scikit-learn-extra"]
    )
    from sklearn_extra.cluster import KMedoids

# 1. TAHAP LOAD & PREPROCESSING DATA
# Membaca dataset gizi tahun 2024
df = pd.read_csv("data_gizi_2024.csv")
cols_gizi = [
    "Stunting(%)",
    "Underweight(%)",
    "Severe Wasting (%)",
    "Wasting(%)",
    "Overweight(%)",
]

# Transformasi tipe data objek ke float (mengganti koma menjadi titik)
for col in cols_gizi:
    if df[col].dtype == "object":
        df[col] = df[col].str.replace(",", ".", regex=False).astype(float)

X = df[cols_gizi].values
```

2. TAHAP NORMALISASI DATA (MIN-MAX SCALING)

```
scaler = MinMaxScaler()
X_normalized = scaler.fit_transform(X)
```

```
# Memasukkan nilai hasil normalisasi kembali ke DataFrame
df[cols_gizi] = X_normalized
```

3. IMPLEMENTASI ALGORITMA K-MEDOIDS CLUSTERING

```
kmedoids = KMedoids(
    n_clusters=3, metric="euclidean", init="k-medoids++", random_state=42
)
cluster_labels = kmedoids.fit_predict(X_normalized)
```

```
# Menyimpan hasil pelabelan klaster ke dalam DataFrame utama
df["Cluster_KMedoids"] = cluster_labels + 1
```

4. TAHAP PROFILING DAN IDENTIFIKASI ANGGOTA KLASTER

```
print("=" * 75)
print(f"{'DAFTAR ANGGOTA WILAYAH DAN PROFIL RERATA KLASTER (K-MEDOIDS):'^75}")
print("=" * 75)
```

```
nama_kolom_wilayah = "Kota"
```

```
for c in sorted(df["Cluster_KMedoids"].unique()):
    df_cluster = df[df["Cluster_KMedoids"] == c]
    wilayah = df_cluster[nama_kolom_wilayah].tolist()
```

```
print(f"KLASTER {c} (Jumlah: {len(wilayah)} Wilayah)")
print(f"Anggota      : {', '.join(wilayah)}")
```

```
stunting_avg = df_cluster["Stunting(%)"].mean()
wasting_avg = df_cluster["Wasting(%)"].mean()
severe_wasting_avg = df_cluster["Severe Wasting (%)"].mean()
underweight_avg = df_cluster["Underweight(%)"].mean()
overweight_avg = df_cluster["Overweight(%)"].mean()
```

```
print(
    f"Rerata Indikator : Stunting ({stunting_avg:.4f}), "
    f"Wasting ({wasting_avg:.4f}), "
    f"Severe Wasting ({severe_wasting_avg:.4f}), "
    f"Underweight ({underweight_avg:.4f}), "
    f"Overweight ({overweight_avg:.4f})"
)
print("-" * 75)
```

5. TAHAP MENAMPILKAN TITIK PUSAT KLASTER (MEDOID)

```
print("\n" + "=" * 50)
print(f"{'KOORDINAT MEDOID PUSAT KELOMPOK':^50}")
print("=" * 50)
print(kmedoids.cluster_centers_.round(4))
```

```

#
=====
# 6. TAHAP VISUALISASI MONOKROM / MONOCHROME (K-MEDOIDS)
#
=====

cluster_counts = df["Cluster_KMedoids"].value_counts().to_dict()

# Hitung rata-rata per kluster K-Medoids (Menggunakan nilai normalisasi)
df_cluster_mean = df.groupby("Cluster_KMedoids")[cols_gizi].mean()

# Menghilangkan teks '%' pada nama kolom untuk legenda
df_cluster_mean.columns = (
    df_cluster_mean.columns.str.replace(r"\s*(%)", "", regex=True).str.strip()
)

# Memformat label sumbu X agar menampilkan informasi jumlah wilayah secara
dinamis
df_cluster_mean.index = [
    f"Klaster {c}\n({cluster_counts.get(c, 0)} Wilayah)"
    for c in df_cluster_mean.index
]

# Mengatur tema dasar menggunakan style Seaborn bersih bertema putih
sns.set_theme(style="white")

# Membuat objek figure dan axes dengan resolusi tinggi (DPI 150)
fig, ax = plt.subplots(figsize=(14, 8), dpi=150)

# PERUBAHAN UTAMA: Gradasi abu-abu hingga hitam agar 5 indikator tetap
terpisah dengan baik
colors_grayscale = ["#333333", "#666666", "#999999", "#cccccc", "#e6e6e6"]

# Membuat bagan batang kelompok dengan garis tepi hitam tegas
df_cluster_mean.plot(
    kind="bar",
    ax=ax,
    color=colors_grayscale,
    width=0.8,
    edgecolor="black",
    linewidth=0.8,
)

# --- SENTUHAN ESTETIKA DAN DETAIL BAGAN ---

# 1. Judul dan Keterangan Sumbu (Warna Hitam)
plt.title(
    "PROFIL RERATA INDIKATOR GIZI PER KLASSTER ALGORITMA K-
MEDOIDS",
    fontsize=14,

```

```

        fontweight="bold",
        pad=25,
        color="black",
        loc="center",
    )
plt.xlabel(
    "Kelompok Klaster K-Medoids",
    fontsize=11,
    fontweight="semibold",
    labelpad=12,
    color="black",
)
plt.ylabel(
    "Rata-rata Nilai Normalisasi",
    fontsize=11,
    fontweight="semibold",
    labelpad=12,
    color="black",
)

# 2. Penataan Label Skala (Hitam)
plt.xticks(rotation=0, fontsize=10.5, fontweight="semibold", color="black")
plt.yticks(fontsize=10, color="black")

# 3. Memunculkan Nilai Akurat Tepat di Atas Batang Bagan (Teks Hitam)
for container in ax.containers:
    ax.bar_label(
        container,
        fmt="%.2f",
        padding=5,
        fontsize=9,
        fontweight="bold",
        color="black",
    )

# 4. Konfigurasi Garis Bantu (Gridlines Abu-abu) dan Frame
ax.yaxis.grid(True, linestyle="--", alpha=0.5, color="#888888")
ax.xaxis.grid(False)
sns.despine(left=False, bottom=False)

# 5. Penempatan Legenda Monokrom
plt.legend(
    title="Indikator Gizi",
    title_fontsize="11",
    fontsize="10",
    loc="upper center",
    bbox_to_anchor=(0.5, -0.15),
    ncol=5,
    frameon=True,
    facecolor="white",
    edgecolor="black",
)

```

```
plt.tight_layout()
plt.savefig(
    "analisis_klaster_kmedoids_2024_monokrom.png", bbox_inches="tight",
    dpi=300
)
plt.show()
```

Lampiran 12. Kode program *Python* untuk algoritma *Agglomerative Hierarchical Clustering* dengan menggunakan *library python*

```
import math
import subprocess
import sys
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler

# Menggunakan KMedoids dari scikit-learn-extra
try:
    from sklearn_extra.cluster import KMedoids
except ImportError:
    subprocess.check_call(
        [sys.executable, "-m", "pip", "install", "scikit-learn-extra"]
    )
    from sklearn_extra.cluster import KMedoids

# 1. TAHAP LOAD & PREPROCESSING DATA
# Membaca dataset gizi tahun 2024
df = pd.read_csv("data_gizi_2024.csv")
cols_gizi = [
    "Stunting(%)",
    "Underweight(%)",
    "Severe Wasting (%)",
    "Wasting(%)",
    "Overweight(%)",
]

# Transformasi tipe data objek ke float (mengganti koma menjadi titik)
for col in cols_gizi:
    if df[col].dtype == "object":
        df[col] = df[col].str.replace(",", ".", regex=False).astype(float)

X = df[cols_gizi].values

# 2. TAHAP NORMALISASI DATA (MIN-MAX SCALING)
scaler = MinMaxScaler()
X_normalized = scaler.fit_transform(X)
```

```

# Memasukkan nilai hasil normalisasi kembali ke DataFrame
df[cols_gizi] = X_normalized

# 3. IMPLEMENTASI ALGORITMA K-MEDOIDS CLUSTERING
kmedoids = KMedoids(
    n_clusters=3, metric="euclidean", init="k-medoids++", random_state=42
)
cluster_labels = kmedoids.fit_predict(X_normalized)

# Menyimpan hasil pelabelan kluster ke dalam DataFrame utama
df["Cluster_KMedoids"] = cluster_labels + 1

# 4. TAHAP PROFILING DAN IDENTIFIKASI ANGGOTA KLASER
print("=" * 75)
print(f'{"DAFTAR ANGGOTA WILAYAH DAN PROFIL RERATA KLASER (K-MEDOIDS)":^75}')
print("=" * 75)

nama_kolom_wilayah = "Kota"

for c in sorted(df["Cluster_KMedoids"].unique()):
    df_cluster = df[df["Cluster_KMedoids"] == c]
    wilayah = df_cluster[nama_kolom_wilayah].tolist()

    print(f'KLASTER {c} (Jumlah: {len(wilayah)} Wilayah)')
    print(f'Anggota      : {', '.join(wilayah)}')

    stunting_avg = df_cluster["Stunting(%)"].mean()
    wasting_avg = df_cluster["Wasting(%)"].mean()
    severe_wasting_avg = df_cluster["Severe Wasting (%)"].mean()
    underweight_avg = df_cluster["Underweight(%)"].mean()
    overweight_avg = df_cluster["Overweight(%)"].mean()

    print(
        f'Rerata Indikator : Stunting ({stunting_avg:.4f}), "
        f"Wasting ({wasting_avg:.4f}), "
        f"Severe Wasting ({severe_wasting_avg:.4f}), "
        f"Underweight ({underweight_avg:.4f}), "
        f"Overweight ({overweight_avg:.4f})"
    )
    print("-" * 75)

# 5. TAHAP MENAMPILKAN TITIK PUSAT KLASER (MEDOID)
print("\n" + "=" * 50)
print(f'{"KOORDINAT MEDOID PUSAT KELOMPOK":^50}')
print("=" * 50)
print(kmedoids.cluster_centers_.round(4))

#
=====
=====
# 6. TAHAP VISUALISASI MONOKROM / MONOCHROME (K-MEDOIDS)

```

```

#
=====

cluster_counts = df["Cluster_KMedoids"].value_counts().to_dict()

# Hitung rata-rata per klaster K-Medoids (Menggunakan nilai normalisasi)
df_cluster_mean = df.groupby("Cluster_KMedoids")[cols_gizi].mean()

# Menghilangkan teks '%' pada nama kolom untuk legenda
df_cluster_mean.columns = (
    df_cluster_mean.columns.str.replace(r"\s*(%)\s*", "", regex=True).str.strip()
)

# Memformat label sumbu X agar menampilkan informasi jumlah wilayah secara
dinamis
df_cluster_mean.index = [
    f"Klaster {c}\n({cluster_counts.get(c, 0)} Wilayah)"
    for c in df_cluster_mean.index
]

# Mengatur tema dasar menggunakan style Seaborn bersih bertema putih
sns.set_theme(style="white")

# Membuat objek figure dan axes dengan resolusi tinggi (DPI 150)
fig, ax = plt.subplots(figsize=(14, 8), dpi=150)

# PERUBAHAN UTAMA: Gradasi abu-abu hingga hitam agar 5 indikator tetap
terpisah dengan baik
colors_grayscale = ["#333333", "#666666", "#999999", "#cccccc", "#e6e6e6"]

# Membuat bagan batang kelompok dengan garis tepi hitam tegas
df_cluster_mean.plot(
    kind="bar",
    ax=ax,
    color=colors_grayscale,
    width=0.8,
    edgecolor="black",
    linewidth=0.8,
)

# --- SENTUHAN ESTETIKA DAN DETAIL BAGAN ---

# 1. Judul dan Keterangan Sumbu (Warna Hitam)
plt.title(
    "PROFIL RERATA INDIKATOR GIZI PER KLASER ALGORITMA K-MEDOIDS",
    fontsize=14,
    fontweight="bold",
    pad=25,
    color="black",
    loc="center",
)

```

```

plt.xlabel(
    "Kelompok Klaster K-Medoids",
    fontsize=11,
    fontweight="semibold",
    labelpad=12,
    color="black",
)
plt.ylabel(
    "Rata-rata Nilai Normalisasi",
    fontsize=11,
    fontweight="semibold",
    labelpad=12,
    color="black",
)

# 2. Penataan Label Skala (Hitam)
plt.xticks(rotation=0, fontsize=10.5, fontweight="semibold", color="black")
plt.yticks(fontsize=10, color="black")

# 3. Memunculkan Nilai Akurat Tepat di Atas Batang Bagan (Teks Hitam)
for container in ax.containers:
    ax.bar_label(
        container,
        fmt="%.2f",
        padding=5,
        fontsize=9,
        fontweight="bold",
        color="black",
    )

# 4. Konfigurasi Garis Bantu (Gridlines Abu-abu) dan Frame
ax.yaxis.grid(True, linestyle="--", alpha=0.5, color="#888888")
ax.xaxis.grid(False)
sns.despine(left=False, bottom=False)

# 5. Penempatan Legenda Monokrom
plt.legend(
    title="Indikator Gizi",
    title_fontsize="11",
    fontsize="10",
    loc="upper center",
    bbox_to_anchor=(0.5, -0.15),
    ncol=5,
    frameon=True,
    facecolor="white",
    edgecolor="black",
)

plt.tight_layout()
plt.savefig(
    "analisis_klaster_kmedoids_2024_monokrom.png", bbox_inches="tight", dpi=300
)

```

```
plt.show()
```

Lampiran 13. Kode program *Python* untuk algoritma *K-Means* dengan menggunakan perhitungan

```
#iterasi 1
import math
import pandas as pd

def hitung_euclidean(titik1, titik2):
    total_kuadrat = 0
    for i in range(len(titik1)):
        total_kuadrat += (titik1[i] - titik2[i]) ** 2
    return math.sqrt(total_kuadrat)

# 2. menggunakan centroid baru
c1_baru_1 = centroid_baru[1]
c2_baru_1 = centroid_baru[2]
c3_baru_1 = centroid_baru[3]
c4_baru_1 = centroid_baru[4]

hasil_perhitungan = []

# 3. Looping untuk menghitung jarak setiap kota ke semua centroid
for i in range(len(df)):
    # Ambil fitur kota ke-i dari scaled_df (NumPy array)
    fitur_kota = scaled_df[i]

    # Hitung jarak ke masing-masing centroid
    dist_c1 = hitung_euclidean(fitur_kota, c1)
    dist_c2 = hitung_euclidean(fitur_kota, c2)
    dist_c3 = hitung_euclidean(fitur_kota, c3)
    dist_c4 = hitung_euclidean(fitur_kota, c4)

    # Tentukan cluster (jarak minimum)
    jarak_min = min(dist_c1, dist_c2, dist_c3, dist_c4)
    if jarak_min == dist_c1:
        cluster = 1
    elif jarak_min == dist_c2:
        cluster = 2
    elif jarak_min == dist_c3:
        cluster = 3
    else:
        cluster = 4
```

```

hasil_perhitungan.append({
    'Kota': df['Kota'][i],
    'Jarak_C1': round(dist_c1, 4),
    'Jarak_C2': round(dist_c2, 4),
    'Jarak_C3': round(dist_c3, 4),
    'Jarak_C4': round(dist_c4, 4),
    'Cluster_Terpilih': cluster
})

```

4. Tampilkan dalam bentuk Tabel

```

df_hasil1 = pd.DataFrame(hasil_perhitungan)
print(df_hasil1.to_string(index=False))

```

Lampiran 14. Kode program *Python* untuk algoritma *K-Medoids* dengan menggunakan perhitungan manual

```

import math
import pandas as pd
from sklearn.preprocessing import MinMaxScaler

# 1. LOAD & PREPROCESSING DATA
df = pd.read_csv('data_gizi_2024.csv')
cols_gizi = ['Stunting(%)', 'Underweight(%)', 'Severe Wasting (%)', 'Wasting(%)',
'Overweight(%)']

for col in cols_gizi:
    if df[col].dtype == 'object':
        df[col] = df[col].str.replace(',', '.', regex=False).astype(float)

X_raw = df[cols_gizi].values

# 2. NORMALISASI
scaler = MinMaxScaler()
scaled_df = scaler.fit_transform(X_raw)

# Fungsi menghitung Jarak Euclidean
def hitung_euclidean(titik1, titik2):
    total_kuadrat = 0
    for i in range(len(titik1)):
        total_kuadrat += (titik1[i] - titik2[i]) ** 2
    return math.sqrt(total_kuadrat)

# 3. TENTUKAN MEDOID BARU (PUSAT KELOMPOK)
# M1: Bulukumba
m1 = [0.41, 0.6968, 0.5556, 0.6598, 0.1176]

```

```

# M2: Sidenreng Rappang
m2 = [0.165, 0.2645, 0.2222, 0.3093, 0.6176]
# M3: Soppeng
m3 = [0.48, 0.7226, 0.555, 0.6907, 0.6471]

hasil_perhitungan = []

# 4. LOOPING: Hitung jarak setiap kota ke semua medoid baru
for i in range(len(df)):
    # Ambil fitur kota ke-i dari data yang sudah dinormalisasi
    fitur_kota = scaled_df[i]

    # Hitung jarak ke masing-masing medoid baru
    dist_m1 = hitung_euclidean(fitur_kota, m1)
    dist_m2 = hitung_euclidean(fitur_kota, m2)
    dist_m3 = hitung_euclidean(fitur_kota, m3)

    # Tentukan cluster berdasarkan jarak minimum
    jarak_min = min(dist_m1, dist_m2, dist_m3)
    if jarak_min == dist_m1:
        cluster = 1
    elif jarak_min == dist_m2:
        cluster = 2
    else:
        cluster = 3

    hasil_perhitungan.append({
        'Kota': df['Kota'][i],
        'Jarak_M1': round(dist_m1, 4),
        'Jarak_M2': round(dist_m2, 4),
        'Jarak_M3': round(dist_m3, 4),
        'Cluster_Terpilih': cluster
    })

# 5. TAMPILKAN DAN SIMPAN HASIL
df_hasil = pd.DataFrame(hasil_perhitungan)

# Menyimpan hasil perhitungan ke file CSV baru
df_hasil.to_csv('hasil_iterasi_baru2.xlsx', index=False)

# Cetak hasil ke konsol
print(df_hasil.to_string(index=False))

```

Lampiran 15. Kode program *Python* untuk algoritma *Agglomerative Hierarchical Clustering* dengan menggunakan perhitungan manual

```
import math
import pandas as pd
from sklearn.preprocessing import MinMaxScaler

# 1. LOAD & PREPROCESSING DATA
df = pd.read_csv('data_gizi_2024.csv')
cols_gizi = ['Stunting(%)', 'Underweight(%)', 'Severe Wasting (%)', 'Wasting(%)',
'Overweight(%)']

for col in cols_gizi:
    if df[col].dtype == 'object':
        df[col] = df[col].str.replace(',', '.', regex=False).astype(float)

X_raw = df[cols_gizi].values

# 2. NORMALISASI
scaler = MinMaxScaler()
scaled_df = scaler.fit_transform(X_raw)

# ALGORITMA HIERARCHICAL CLUSTERING DENGAN EKSPOR MATRIKS LENGKAP

# 3. Fungsi Jarak Euclidean (Manual)
def hitung_euclidean(titik1, titik2):
    total_kuadrat = sum((a - b) ** 2 for a, b in zip(titik1, titik2))
    return math.sqrt(total_kuadrat)

# 4. Fungsi untuk mencari dua kluster dengan jarak terdekat
def cari_kluster_terdekat(matriks_jarak):
    min_dist = float('inf')
    pasangan = (0, 0)
    for i in range(len(matriks_jarak)):
        for j in range(i + 1, len(matriks_jarak)):
            if matriks_jarak[i][j] < min_dist:
                min_dist = matriks_jarak[i][j]
                pasangan = (i, j)
    return pasangan, min_dist

# 5. Fungsi Utama Clustering & Penyimpanan Matriks ke Excel
def hierarchical_average_simpan_matriks(data_fitur, nama_kota,
nama_file_excel):
    # Inisialisasi: Setiap kota adalah satu kluster awal
```

```
klaster = [[i] for i in range(len(nama_kota))]
tahap = 1
```

Gunakan ExcelWriter untuk menyimpan banyak sheet dalam satu file
with pd.ExcelWriter(nama_file_excel, engine='openpyxl') as writer:

```
while len(klaster) > 1:
    n = len(klaster)
    matriks_jarak = [[0.0 for _ in range(n)] for _ in range(n)]

    # Membuat label nama klaster untuk Header Kolom & Baris di Excel
    label_klaster = []
    for k in klaster:
        anggota_kota = [nama_kota[idx] for idx in k]
        label_klaster.append("; ".join(anggota_kota))

    # --- HITUNG MATRIKS JARAK (AVERAGE LINKAGE) ---
    for i in range(n):
        for j in range(n):
            if i == j:
                matriks_jarak[i][j] = 0.0
            elif i < j:
                total_jarak = 0
                jumlah_pasangan = 0
                for idx_a in klaster[i]:
                    for idx_b in klaster[j]:
                        d = hitung_euclidean(data_fitur[idx_a], data_fitur[idx_b])
                        total_jarak += d
                        jumlah_pasangan += 1

                nilai_bintang = total_jarak / jumlah_pasangan
                matriks_jarak[i][j] = round(nilai_bintang, 4)
                matriks_jarak[j][i] = round(nilai_bintang, 4) # Matriks simetris

    # --- SIMPAN MATRIKS LANGKAH INI KE EXCEL ---
    df_matriks = pd.DataFrame(matriks_jarak, columns=label_klaster,
index=label_klaster)
    df_matriks.to_excel(writer, sheet_name=f"Langkah_{tahap}")

# Cari pasangan terdekat untuk digabungkan ke langkah berikutnya
(idx1, idx2), dist = cari_klaster_terdekat(matriks_jarak)

print(f"Langkah {tahap}: Menggabungkan klaster [{label_klaster[idx1]}]
dengan [{label_klaster[idx2]}] (Jarak: {dist:.4f})")
```

```

# Gabungkan klaster
klaster[idx1].extend(klaster[idx2])
klaster.pop(idx2)
tahap += 1

# 6. EKSEKUSI DATA
fitur_normalisasi = scaled_df.tolist()
daftar_kota = df['Kota'].tolist()
file_output = 'matriks_jarak_lengkap_hierarki.xlsx'

# Jalankan fungsi
hierarchical_average_simpan_matriks(fitur_normalisasi, daftar_kota, file_output)

print(f"\n--- PROSES SELESAI ---")
print(f"Seluruh matriks jarak tiap langkah telah disimpan lengkap di file:
{file_output}")

```

Lampiran 16. Kode program Python untuk perhitungan metrik evaluasi (Silhouette Score, DBI, Calinski-Harabasz Index, dan Dunn Index)

```

import sys
import subprocess
import numpy as np
import pandas as pd
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import silhouette_score, davies_bouldin_score,
calinski_harabasz_score, pairwise_distances

# 1. INSTALASI & IMPORT K-MEDOIDS (Automated)
try:
    from sklearn_extra.cluster import KMedoids
except ImportError:
    subprocess.check_call([sys.executable, "-m", "pip", "install", "scikit-learn-extra"])
    from sklearn_extra.cluster import KMedoids

# 2. FUNGSI KUSTOM UNTUK DUNN INDEX
def dunn_index(X, labels):
    distances = pairwise_distances(X)
    unique_labels = np.unique(labels)

    if len(unique_labels) < 2:
        return 0.0

    min_inter_dist = np.inf

```

```

for i in range(len(unique_labels)):
    for j in range(i + 1, len(unique_labels)):
        cluster_i = X[labels == unique_labels[i]]
        cluster_j = X[labels == unique_labels[j]]
        inter_dist = pairwise_distances(cluster_i, cluster_j)
        min_inter_dist = min(min_inter_dist, np.min(inter_dist))

max_intra_dist = 0.0
for label in unique_labels:
    cluster_points = X[labels == label]
    if len(cluster_points) > 1:
        intra_dist = pairwise_distances(cluster_points)
        max_intra_dist = max(max_intra_dist, np.max(intra_dist))

return min_inter_dist / max_intra_dist if max_intra_dist > 0 else 0.0

# 3. LOAD & PREPROCESSING DATA
df = pd.read_csv('data_gizi_2024.csv')
cols_gizi = ['Stunting(%)', 'Underweight(%)', 'Severe Wasting (%)', 'Wasting(%)',
'Overweight(%)']

for col in cols_gizi:
    if df[col].dtype == 'object':
        df[col] = df[col].str.replace(',', '.', regex=False).astype(float)

X_raw = df[cols_gizi].values

# 4. NORMALISASI
scaler = MinMaxScaler()
scaled_df = scaler.fit_transform(X_raw)

# 5. SIAPKAN KONTEKS PENILAIAN
results = []

# 6. INISIALISASI MODEL DENGAN K BERBEDA (Sesuai K-Optimal masing-
masing)
models = {
    'K-Means': (KMeans(n_clusters=4, random_state=42, n_init=10), 4),
    'K-Medoids': (KMedoids(n_clusters=3, random_state=42), 3),
    'Agglomerative': (AgglomerativeClustering(n_clusters=4), 4, linkage='average'
) # Berdasarkan baseline k-medoids
}

# 7. PROSES EVALUASI
for name, (model, k_val) in models.items():

```

```

# Predict / Fit model
labels = model.fit_predict(scaled_df)

# Hitung 4 Metrik Evaluasi
sil = silhouette_score(scaled_df, labels)
dbi = davies_bouldin_score(scaled_df, labels)
ch = calinski_harabasz_score(scaled_df, labels)
dunn = dunn_index(scaled_df, labels)

# Simpan Hasil dengan k_val yang sesuai
results.append({
    'Algoritma': name,
    'Cluster (k)': k_val,
    'Silhouette Score ↑': sil,
    'Davies-Bouldin ↓': dbi,
    'Calinski-Harabasz ↑': ch,
    'Dunn Index ↑': dunn
})

# 8. CONVERT KE DATAFRAME & TAMPILKAN TABEL KOMPARASI
df_evaluasi = pd.DataFrame(results)

print("="*95)
print("TABEL PERBANDINGAN METRIK EVALUASI CLUSTERING K-OPTIMAL")
print("="*95)
pd.set_option('display.float_format', lambda x: '%.4f' % x)
print(df_evaluasi.to_string(index=False))
print("="*95)

```

Lampiran 17. Kode program *Python* untuk normalisasi data

```

import pandas as pd
from sklearn.preprocessing import MinMaxScaler

# 1. TAHAP LOAD & PREPROCESSING DATA ASLI
# Membaca dataset gizi tahun 2024
df = pd.read_csv('data_gizi_2024.csv')
cols_gizi = ['Stunting(%)', 'Underweight(%)', 'Severe Wasting (%)', 'Wasting(%)',
'Overweight(%)']

# Membersihkan format angka (mengganti karakter koma menjadi titik)
for col in cols_gizi:
    if df[col].dtype == 'object':

```

```

df[col] = df[col].str.replace(',', '.', regex=False).astype(float)

# 2. TAHAP NORMALISASI (MIN-MAX SCALING)
scaler = MinMaxScaler()
# Melakukan normalisasi pada kolom indikator gizi
X_normalized = scaler.fit_transform(df[cols_gizi])

# Membuat DataFrame baru khusus untuk menampung hasil normalisasi
df_normalized = pd.DataFrame(X_normalized, columns=cols_gizi)

# Menyisipkan kembali kolom identitas (Kota) di bagian awal dataframe
df_normalized.insert(0, 'Kota', df['Kota'])

# 3. EKSPOR HASIL NORMALISASI KE EXCEL
nama_file_excel = 'data_gizi_ternormalisasi.xlsx'
# Menyimpan dataframe hasil normalisasi menjadi file Excel (.xlsx)
df_normalized.to_excel(nama_file_excel, index=False)

print("="*60)
print(f'{"PROSES NORMALISASI DATA SELESAI":^60}')
print("="*60)
print(f'Hasil normalisasi telah berhasil disimpan dalam file:\n-> {nama_file_excel}')
print("="*60)

# Menampilkan 5 baris pertama data hasil normalisasi di konsol
print("\nCuplikan Data Hasil Normalisasi:")
print(df_normalized.head().to_string(index=False))

```

Lampiran 18. Kode program *Python* untuk menampilkan headmap

```

import sys
import subprocess
import pandas as pd
import matplotlib.pyplot as plt

# 1. INSTALASI & IMPORT SEABORN (Automated)
try:
    import seaborn as sns
except ImportError:
    subprocess.check_call([sys.executable, "-m", "pip", "install", "seaborn"])
    import seaborn as sns

# 2. LOAD & PREPROCESSING DATA

```

```

df = pd.read_csv('data_gizi_2024.csv')
cols_gizi = ['Stunting(%)', 'Underweight(%)', 'Severe Wasting (%)', 'Wasting(%)',
'Overweight(%)']

# Membersihkan format angka jika bertipe string/object
for col in cols_gizi:
    if df[col].dtype == 'object':
        df[col] = df[col].str.replace(',', '.', regex=False).astype(float)

# 3. MEMBUAT SUBSET DATA & RENAME MENJADI SIMBOL X
df_gizi = df[cols_gizi].copy()

# Kamus perubahan nama kolom
rename_dict = {
    'Stunting(%)': 'X1',
    'Underweight(%)': 'X2',
    'Severe Wasting (%)': 'X3',
    'Wasting(%)': 'X4',
    'Overweight(%)': 'X5'
}

df_gizi.rename(columns=rename_dict, inplace=True)

# 4. MENGHITUNG MATRIKS KORELASI (Pearson)
corr_matrix = df_gizi.corr(method='pearson')

# 5. CETAK MATRIKS KORELASI BERUPA TABEL ANGKA
print("="*85)
print("MATRIKS KORELASI VARIABEL GIZI (PEARSON)")
print("="*85)
print(corr_matrix)
print("="*85)

# 6. VISUALISASI HEATMAP MATRIKS KORELASI
plt.figure(figsize=(10, 8))

# Menggambar heatmap dengan label baru X1 - X5
sns.heatmap(corr_matrix,
            annot=True,
            cmap='coolwarm',
            fmt=".2f",
            linewidths=0.5,
            vmin=-1,
            vmax=1)

```

```
plt.title('Heatmap Matriks Korelasi Variabel Gizi', fontsize=14, pad=20)
plt.tight_layout()
plt.show()
```

Lampiran 19. Kode program untuk membuat peta hasil *clustering*

```
import geopandas as gpd
from matplotlib.patches import Patch
import matplotlib.pyplot as plt
import pandas as pd

# 1. LOAD & CLEAN DATA GEOGRAFIS (1x LOAD)
gdf_susel = gpd.read_file('gadm41_IDN_2.shp')
gdf_susel = gdf_susel[gdf_susel['NAME_1'] == 'Sulawesi Selatan'].copy()

gdf_susel['NAME_2_CLEAN'] = gdf_susel['NAME_2'].str.replace('Kabupaten|Kota',
", regex=True).str.strip()
gdf_susel['NAME_2_CLEAN'] = gdf_susel['NAME_2_CLEAN'].replace({
    'Pangkajene Kepulauan': 'Pangkajene', 'Pangkajene Dan Kepulauan':
    'Pangkajene',
    'Sidenreng Rappang / Sidrap': 'Sidenreng Rappang', 'Pare-Pare': 'Parepare'
})
gdf_susel['centroid'] =
gdf_susel.geometry.to_crs(epsg=3857).centroid.to_crs(gdf_susel.crs)

# 2. DEFINISI DATASET KLASSTER
data_all = {
    'K-Means': ({
        'Kota': ['Bulukumba', 'Bantaeng', 'Jeneponto', 'Takalar', 'Sinjai', 'Maros',
        'Pangkajene Dan Kepulauan', 'Barru', 'Luwu', 'Kota Parepare', 'Kota Palopo',
        'Enrekang', 'Tana Toraja', 'Toraja Utara', 'Kepulauan Selayar', 'Bone', 'Soppeng',
        'Wajo', 'Pinrang', 'Luwu Utara', 'Gowa', 'Sidenreng Rappang', 'Luwu Timur', 'Kota
        Makassar'],
        'Cluster': [1,1,1,1,1,1,1,1,1,1,2,2,2,3,3,3,3,3,3,4,4,4,4]
    }, {4: ('Rendah', '#2b83ba'), 2: ('Sedang', '#abdda4'), 1: ('Tinggi', '#fdae61'), 3:
    ('Sangat Tinggi', '#d7191c')}), 'k=4'),

    'K-Medoids': ({
```

```

'Kota': ['Bulukumba', 'Bantaeng', 'Jeneponto', 'Takalar', 'Sinjai', 'Maros',
'Pangkajene Dan Kepulauan', 'Barru', 'Wajo', 'Pinrang', 'Enrekang', 'Luwu', 'Kota
Parepare', 'Kota Palopo', 'Gowa', 'Sidenreng Rappang', 'Tana Toraja', 'Luwu Timur',
'Toraja Utara', 'Kota Makassar', 'Kepulauan Selayar', 'Bone', 'Soppeng', 'Luwu
Utara'],
'Cluster': [1,1,1,1,1,1,1,1,1,1,1,1,1,1,2,2,2,2,2,3,3,3,3]
}, {2: ('Rendah', '#2b83ba'), 1: ('Sedang', '#abdda4'), 3: ('Tinggi', '#fdae61')},
'k=3'),

'AHC': ({
'Kota': ['Gowa', 'Sidenreng Rappang', 'Luwu Timur', 'Kota Makassar',
'Enrekang', 'Tana Toraja', 'Toraja Utara', 'Kepulauan Selayar', 'Bulukumba',
'Bantaeng', 'Takalar', 'Sinjai', 'Maros', 'Pangkajene Dan Kepulauan', 'Barru', 'Bone',
'Soppeng', 'Wajo', 'Pinrang', 'Luwu', 'Luwu Utara', 'Kota Parepare', 'Kota Palopo',
'Jeneponto'],
'Cluster': [1,1,1,1,1,2,2,2,3,3,3,3,3,3,3,3,3,3,3,3,3,3,3,4]
}, {1: ('Rendah', '#2b83ba'), 2: ('Sedang', '#abdda4'), 3: ('Tinggi', '#fdae61'), 4:
('Sangat Tinggi', '#d7191c')}, 'AHC')
}

```

3. LOOPING GENERASI PETA

```

for algo, (data, meta, opt) in data_all.items():
    df = pd.DataFrame(data)
    df['Kota_Clean'] = df['Kota'].str.replace('Kota|Dan Kepulauan', "",
regex=True).str.strip()

    gdf_merged = gdf_susel.merge(df, left_on='NAME_2_CLEAN',
right_on='Kota_Clean', how='left')
    gdf_merged['color'] = gdf_merged['Cluster'].map(lambda c: meta[c][1])

    fig, ax = plt.subplots(figsize=(14, 12))
    gdf_merged.plot(color=gdf_merged['color'], linewidth=0.6, ax=ax,
edgecolor='black', aspect='equal')

# Label Anotasi & Legenda
for _, row in gdf_merged.iterrows():
    x, y = row['centroid'].x + (0.02 if row['NAME_2_CLEAN'] == 'Bantaeng' else -

```

```

0.08 if row['NAME_2_CLEAN'] == 'Makassar' else 0), row['centroid'].y - (0.05 if
row['NAME_2_CLEAN'] == 'Takalar' else 0)
    ax.annotate(row['NAME_2_CLEAN'], (x, y), fontsize=8, fontweight='bold',
ha='center', bbox=dict(boxstyle="round,pad=0.15", fc="white", ec="none",
alpha=0.4))

    patches = [Patch(facecolor=c_info[1], edgecolor='black', label=f'Klaster {c}:
Prioritas {c_info[0]}') for c, c_info in sorted(meta.items())]
    ax.legend(handles=patches, title=f"Prioritas ({algo})", loc="lower right",
fontsize=10)

    plt.title(f'Peta Wilayah Prioritas Sulawesi Selatan - {algo} ({opt})\nStatus Gizi
Balita 2024', fontsize=14, fontweight='bold', pad=20)
    plt.axis('off')
    plt.savefig(f'peta_clustering_{algo.lower().replace("-", "")}_sulsel.png', dpi=300,
bbox_inches='tight')
    plt.show()

```