


Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal EEG-EKG, Internet of Things, dan Support Vector Machine



AHMAD AKSA
H021221080



PROGRAM STUDI FISIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026

**Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal
EEG-EKG, *Internet of Things*, dan *Support Vector Machine***

**AHMAD AKSA
H021221080**



**PROGRAM STUDI FISIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**


SKRIPSI**Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal
EEG-EKG, *Internet of Things*, dan *Support Vector Machine*****AHMAD AKSA****H021221080****Skripsi,**

Telah dipertahankan di depan Panitia Ujian Sarjana Program Studi Fisika
Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin
Pada 29 Juli 2026 dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Fisika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:
Pembimbing Tugas Akhir




Prof. Dr. Arifin, M.T.
NIP. 196705201994031002

Mengetahui:
Ketua Program Studi



Prof. Dr. rer-nat Wira Bahari Nurdin
NIP. 196709231990031001



PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa skripsi berjudul "Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal EEG-EKG, Internet of Things, dan Support Vector Machine" adalah benar karya saya dengan arahan dari Dosen Pembimbing Prof. Dr. Arifin, M.T. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku. Dengan ini saya melimpahkan hak cipta dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 20 Juli 2026



Ahmad Aksa
NIM H021221080

UCAPAN TERIMA KASIH

Puji dan syukur penulis panjatkan ke hadirat Allah Swt. atas segala rahmat, karunia, dan ridha-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul "Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal EEG-EKG, *Internet of Things*, dan *Support Vector Machine*".

Penyusunan skripsi ini tidak terlepas dari doa, bimbingan, bantuan, dan dukungan dari berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Orang tua penulis yang telah mendampingi dan memberikan ruang bagi penulis untuk menyelesaikan tugas akhir ini.
2. Prof. Dr. Arifin, M.T. selaku Pembimbing, yang telah meluangkan waktu dengan penuh kesabaran memberikan bimbingan, arahan, serta ilmu yang sangat berharga dari awal hingga selesainya penelitian ini.
3. Program KIP Kuliah (Kartu Indonesia Pintar Kuliah) yang telah memberikan dukungan finansial dan kesempatan berharga bagi penulis untuk menempuh pendidikan tinggi hingga dapat menyelesaikan studi ini.
4. Seluruh Bapak/Ibu Dosen serta Tenaga Kependidikan Departemen Fisika, terima kasih atas ilmu pengetahuan yang telah diajarkan, arahan dan masukan dalam proses ujian, serta bantuan administrasi yang mempermudah seluruh urusan akademik penulis selama masa perkuliahan.
5. Teman-teman seperjuangan Angkatan 2022, terima kasih atas kebersamaan, solidaritas, tawa, dan cerita perjuangan yang dilewati bersama sejak awal melangkah di bangku perkuliahan.
6. Teman-teman mahasiswa Departemen Fisika, khususnya rekan-rekan di Laboratorium Elektronika dan Instrumentasi, terima kasih atas lingkungan ruang lab yang suportif, diskusi-diskusi teknis seputar hardware dan coding yang sangat membantu, serta semangat yang selalu hadir dalam pengerjaan penelitian ini.
7. Semua pihak yang tidak dapat penulis sebutkan satu per satu, yang telah memberikan bantuan, doa, dan dukungan baik langsung maupun tidak langsung demi kelancaran penyusunan skripsi ini.

ABSTRAK

Ahmad, **Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal EEG-EKG, Internet of Things, dan Support Vector Machine** (Dibimbing oleh Prof. Dr. Arifin, M.T.)

Latar Belakang. Diagnosis depresi secara klinis saat ini masih bergantung padawawancara subjektif dan peralatan medis yang mahal. **Tujuan.** Penelitian ini bertujuan merancang alat portabel untuk pemantauan gejala depresi secara objektif dan kuantitatif. **Metode.** Sistem ini mengukur sinyal Elektroensefalogram (EEG) dan Elektrokardiogram (EKG) menggunakan mikrokontroler ESP32-S3 dan penguat berbasis TL074. Sinyal EEG diproses menjadi *Power Spectral Density* (PSD) melalui kalkulasi *Fast Fourier Transform* (FFT), sedangkan sinyal EKG diproses menjadi *Heart Rate Variability* (HRV) melalui perhitungan interval R-R. Data tersebut kemudian dikirim menuju server awan (AWS EC2) berbasis *Internet of Things* (IoT) untuk diklasifikasikan oleh model *Support Vector Machine* (SVM). **Hasil.** Pengujian perangkat keras terhadap peralatan standar medis menunjukkan tingkat akurasi pengukuran EEG sebesar 82,62%, serta akurasi pengukuran EKG mencapai 98,92% untuk denyut jantung dan 99,99% untuk interval R-R. Kualitas *Signal-to-Noise Ratio* (SNR) sebesar 6,10–19,68 dB pada sinyal EEG dan 27,17–44,24 dB pada sinyal EKG, dengan daya baterai hingga 3 jam 22 menit. Pengujian IoT dengan tingkat waktu tunda dan kehilangan paket yang sesuai standar ITU-T. Pada tahap pengklasifikasian SVM, gabungan PSD dan HRV menggunakan *kernel Radial Basis Function* (RBF) pada skenario mata terbuka menghasilkan akurasi 76,00%, presisi 90,91%, spesifisitas 90%, dan *Area Under the Curve* (AUC) 0,77. **Kesimpulan.** Alat portabel yang dirancang mampu mengukur sinyal EEG dan EKG secara terintegrasi dengan sistem IoT dan AI untuk mengklasifikasikan subjek bergejala depresi secara objektif.

Kata Kunci: Depresi, Biosinyal, Heart Rate Variability, Power Spectral Density, Internet of Things, Support Vector Machine

ABSTRACT

Ahmad, **Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal EEG-EKG, Internet of Things, dan Support Vector Machine** (Supervised by Prof. Dr. Arifin, M.T.)

Background. Current clinical diagnosis of depression still relies on subjective interviews and expensive medical equipment. **Aim.** This study aims to design a portable device for objective and quantitative monitoring of depression symptoms. **Method.** This system measures Electroencephalogram (EEG) and Electrocardiogram (ECG) signals using an ESP32-S3 microcontroller and a TL074-based amplifier. The EEG signals are processed into Power Spectral Density (PSD) through Fast Fourier Transform (FFT) calculations, while the ECG signals are processed into Heart Rate Variability (HRV) through R-R interval calculations. The data is then sent to an Internet of Things (IoT)-based cloud server (AWS EC2) to be classified by a Support Vector Machine (SVM) model. **Result.** Hardware testing against standard medical equipment showed an EEG measurement accuracy of 82.62%, and ECG measurement accuracies reaching 98.92% for heart rate and 99.99% for R-R intervals. The Signal-to-Noise Ratio (SNR) quality was 6.10–19.68 dB for EEG signals and 27.17–44.24 dB for ECG signals, with a battery life of up to 3 hours and 22 minutes. IoT testing showed latency and packet loss levels that comply with ITU-T standards. In the SVM classification stage, the combination of PSD and HRV using a Radial Basis Function (RBF) kernel in the eyes-open scenario produced an accuracy of 76.00%, precision of 90.91%, specificity of 90%, and an Area Under the Curve (AUC) of 0.77. **Conclusion.** The designed portable device is capable of measuring EEG and ECG signals integrated with IoT and AI systems to objectively classify subjects with depression symptoms.

Keywords: Depression, Biosignals, Heart Rate Variability, Power Spectral Density, Internet of Things, Support Vector Machine.

DAFTAR ISI

	Halaman
PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA.....	iii
UCAPAN TERIMA KASIH.....	iv
ABSTRAK.....	v
ABSTRACT.....	vi
DAFTAR ISI.....	vii
DAFTAR GAMBAR.....	ix
DAFTAR TABEL.....	xi
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Tujuan Penelitian.....	3
1.3 Manfaat Penelitian.....	3
BAB II METODE PENELITIAN.....	4
2.1 Tempat dan Waktu Penelitian.....	4
2.2 Peralatan Penelitian.....	4
2.3 Metode Kerja.....	4
2.3.1 Perancangan Perangkat Keras.....	6
2.3.2 Penguat Biosinyal EEG dan EKG.....	9
2.3.3 Perancangan Perangkat Lunak.....	11
2.3.4 Perancangan Model <i>Artificial Intelligence</i>	12
2.3.5 Pengujian Alat.....	13
2.3.6 Bagan Alir Sistem Kerja Alat.....	14
2.3.7 Prosedur Pengambilan Data Subjek.....	15
BAB III HASIL DAN PEMBAHASAN.....	17
3.1 Hasil Perancangan Sistem.....	17
3.1.1 Hasil Perancangan Perangkat Keras.....	17
3.1.2 Hasil Perancangan Perangkat Lunak dan IoT.....	18
3.2 Hasil Pengujian Alat.....	21
3.2.1 Hasil Pengujian Alat EEG.....	21
3.2.2 Hasil Pengujian Alat EKG.....	23
3.2.3 Hasil Pengujian <i>Signal-to-Noise Ratio</i> (SNR).....	25
3.2.4 Hasil Pengujian Daya Tahan Baterai.....	26

3.3 Hasil Pengukuran Sinyal Fisiologis.....	27
3.3.1 Standar Referensi dan Penentuan Ambang Batas (Cut-Off).....	27
3.3.2 Hasil Pengukuran PSD.....	28
3.3.3 Hubungan BPM dan HRV.....	29
3.3.4 Hasil Pengukuran HRV.....	30
3.3.5 Hubungan PSD dan HRV.....	31
3.3.6 Komparasi Kondisi terhadap EEG dan EKG.....	35
3.3.7 Distribusi Data Alat terhadap Referensi.....	36
3.4 Korelasi Skor BDI-II.....	37
3.4.1 Waktu Pengisian Kuesioner.....	37
3.4.2 Korelasi BDI-II terhadap EEG dan EKG.....	38
3.5 Hasil Model AI.....	40
3.5.1 Hasil Performa Klasifikasi SVM.....	40
3.6 Hasil Pengujian Sistem Pemantauan IoT.....	44
3.6.1 Pengujian Jaringan Luar Ruangan.....	44
3.6.2 Pengujian Jaringan Dalam Ruangan.....	45
3.6.3 Stabilitas Jaringan.....	47
BAB IV PENUTUP.....	48
4.1 Kesimpulan.....	48
DAFTAR PUSTAKA.....	49

DAFTAR GAMBAR

	Halaman
Gambar 1. Diagram alur penelitian.....	5
Gambar 2. Perancangan perangkat keras.....	7
Gambar 3. Arsitektur lapisan sistem.....	8
Gambar 4. Skematik rangkaian penguat biosinyal EEG dan EKG.....	9
Gambar 5. Diagram alur perancangan perangkat lunak.....	11
Gambar 6. Hyperplane optimal SVM.....	12
Gambar 7. Diagram alir sistem kerja alat.....	14
Gambar 8. Konfigurasi posisi elektroda.....	15
Gambar 9. Hasil perancangan perangkat keras.....	17
Gambar 10. Visualisasi pemrosesan sinyal EKG dan EEG.....	19
Gambar 11. Hasil perancangan perangkat lunak.....	21
Gambar 12. PSD 8-30 Hz.....	22
Gambar 13. Pengujian frekuensi 3-30 Hz.....	22
Gambar 14. Pengujian HR alat vs pulse oximeter.....	23
Gambar 15. Pengujian interval RR alat vs pulse oximeter.....	24
Gambar 16. Pengujian HR alat vs EKG RS.....	24
Gambar 17. Pengujian interval RR alat vs EKG RS.....	25
Gambar 18. Pengujian SNR.....	26
Gambar 19. Pengujian daya tahan baterai.....	27
Gambar 20. Hasil pengukuran daya relatif.....	29
Gambar 21. Hubungan BPM terhadap HRV.....	30
Gambar 22. Hasil pengukuran HRV.....	31
Gambar 23. Hubungan PSD dan HRV kondisi buka mata.....	33
Gambar 24. Hubungan PSD dan HRV kondisi tutup mata.....	34
Gambar 25. Komparasi transisi kondisi buka mata ke tutup mata.....	36
Gambar 26. Korelasi BDI-II terhadap waktu pengisian kuesioner.....	38
Gambar 27. Korelasi BDI-II terhadap sinyal fisiologis.....	39
Gambar 28. Hasil performa klasifikasi SVM teroptimal.....	42
Gambar 29. Komparasi pengujian jangkauan jaringan luar ruangan.....	44

Gambar 30. Pengujian jangkauan jaringan luar ruangan.....	45
Gambar 31. Komparasi pengujian jangkauan jaringan dalam ruangan.....	46
Gambar 32. Pengujian jangkauan jaringan dalam ruangan.....	46
Gambar 33. Stabilitas jaringan 21 jam.....	47

DAFTAR TABEL

	Halaman
Tabel 1. Standar Referensi Klinis Parameter EEG dan HRV.....	28
Tabel 2. Rata-Rata Pengukuran Alat Terhadap Standar Referensi.....	37
Tabel 3. Hasil Komparasi Performa Skenario Klasifikasi SVM.....	41
Tabel 4. Komparasi Klasifikasi Gejala Depresi.....	43

BAB I PENDAHULUAN

1.1 Latar Belakang

Prevalensi depresi secara nasional pada penduduk usia 15 tahun ke atas mencapai 1,4%. Angka ini bahkan lebih tinggi di provinsi Sulawesi Selatan, yang menyentuh angka 1,7%. Meskipun prevalensinya signifikan, diagnosis dan pemantauan depresi bersifat subjektif, sebagaimana data prevalensi Kemenkes yang menggunakan metode *Mini International Neuropsychiatric Interview* (MINI) (Kementerian Kesehatan RI, 2023). Nejadi et al. (2020) dalam studinya bahwa metode wawancara MINI membutuhkan waktu 20-25 menit setiap pasien dan tidak direkomendasikan untuk semua kondisi seperti gangguan mental terkait stres. *Beck Depression Inventory-II* (BDI-II) merupakan asesmen laporan diri 21-item yang mudah, cepat, dan efisien, serta fokus pada gejala depresi (Boby & Veerasingam, 2025; García-Batista et al., 2018; Ginting et al., 2013).

Mitsukura et al. (2022) mendapatkan hasil pola sinyal elektroensefalogram (EEG) yang berkorelasi dengan kondisi depresi, seperti perbedaan spektrum daya terutama pada pita frekuensi alfa (α) dan beta (β). Secara spesifik, terdapat peningkatan gelombang beta di lobus frontal yang berkaitan dengan respons stres berlebih serta perubahan pada konektivitas fungsional pita alfa yang dapat berhubungan dengan tingkat keparahan depresi (Mitsukura et al., 2022). Luo et al. (2025) mengamati pengukuran menggunakan sistem EEG dapat dengan jelas membedakan pita alfa saat kondisi mata tertutup, serta dapat menangkap artefak sinyal gertakan gigi dan kedipan mata.

Penelitian oleh Luo et al. (2025) dan Mitsukura et al. (2022) dapat membuktikan bahwa EEG dapat digunakan sebagai sistem pemantauan aktivitas otak yang bersifat objektif. Perangkat EEG tingkat laboratorium dapat menghasilkan sinyal dengan kualitas tinggi, namun pemasangan alat rumit, tidak nyaman dan terbatas. Kemudian, perangkat EEG nirkabel komersial menutupi kekurangan alat tingkat laboratorium, namun harganya masih tergolong mahal (Luo et al., 2025).

Penelitian oleh Hartmann et al. (2019) bahwa depresi dikaitkan dengan disfungsi Sistem Saraf Otonom (ANS). ANS dapat diukur secara objektif melalui analisis Variabilitas Detak Jantung (HRV) dari sinyal Elektrokardiogram (EKG). Nilai *Root Mean Square of Successive Differences* (RMSSD) dan interval NN (*Standard Deviation of NN intervals* (SDNN) dan pNN50) yang merupakan parameter dari HRV pada kondisi depresi cenderung lebih rendah dibanding pada kondisi sehat (Hartmann et al., 2019; B. Li et al., 2024; S. Liu et al., 2025). HRV menunjukkan korelasi negatif terhadap depresi, dan secara spesifik SDNN menjadi penanda objektif yang dengan perbedaan paling mencolok dalam membedakan antara individu sehat dan depresi (Y. Tan et al., 2025).

Penelitian oleh Abbas et al. (2024) secara spesifik menggunakan metode klasifikasi depresi menggunakan sinyal dari EEG dan EKG. Studi

tersebut mengonfirmasi bahwa pola depresi dapat diidentifikasi dari fitur EEG dan EKG. Penelitian oleh Yang & Chen (2024) menyatakan metode SVM paling sering digunakan untuk klasifikasi; dalam penelitian tersebut digunakan SVM untuk mengklasifikasikan pasien depresi berdasarkan kondisi istirahat yang menghasilkan klasifikasi SVM dengan akurasi di atas 90% dalam membedakan antara pasien depresi dan kelompok kontrol sehat.

Metode prapemrosesan sinyal EEG umumnya menggunakan *highpass filter* (HPF), *lowpass filter* (LPF), *bandpass filter* (BPF) dan *notch filter* untuk meredam frekuensi yang tidak diperlukan dan terutama derau dari jalur listrik, serta menggunakan algoritma *Fast Fourier Transform* (FFT) untuk analisis domain frekuensinya (Boby & Veerasingam, 2025). Tran et al. (2024) mengimplementasikan FFT pada *Microcontroller* (MCU) ESP32-S3 menggunakan pustaka KissFFT untuk melakukan analisis frekuensi dan mendapatkan hasil dengan eror frekuensi yang diterima proporsional dengan frekuensi aslinya, serta variasi *sampling rate* tidak memengaruhi akurasi data yang diterima.

Penelitian oleh Ehrhardt et al. (2024) dan Faadhilah Afif et al. (2020) mengamati perbedaan antara elektroda basah dan kering, di mana elektroda basah dominan menghasilkan data EEG yang lebih baik. Elektroda basah lebih baik dalam standar deviasi *power spectral density* (PSD) dibanding elektroda kering (Faadhilah Afif et al., 2020) dan Elektroda basah memiliki *Signal to Noise Ratio* (SNR) yang lebih tinggi dibandingkan dengan elektroda kering (Ehrhardt et al., 2024). Amrinsani et al. (2022) dalam penelitiannya yang menggunakan elektroda basah (*disposable*) menunjukkan bahwa terdapat perbedaan amplitudo rata-rata sebesar 30 mV antara elektroda basah dan elektroda kering, yang menunjukkan bahwa elektroda basah menghasilkan sinyal dengan amplitudo lebih besar dibandingkan elektroda kering.

Penguat biosinyal EEG dan EKG dirancang menggunakan topologi modul BioAmp EXG Pill di mana modul tersebut digunakan pada penelitian oleh Mamee et al. (2023) dengan konfigurasi filter aktif yang disesuaikan untuk masing-masing karakteristik frekuensi biosinyal. Pemrosesan sinyal melalui mikrokontroler ESP32-S3 menggunakan analisis FFT untuk EEG dan analisis Interval R-R untuk EKG. Hasil analisis diperoleh data PSD dan *Heart Rate Variability* (HRV). Sistem diintegrasikan dengan IoT menggunakan protokol komunikasi WebSocket pada server AWS EC2 untuk pemantauan *real-time*. Data analisis EEG dan EKG digunakan untuk melatih model *Artificial Intelligence* (AI) berbasis support vector machine (SVM) untuk klasifikasi subjek bergejala atau tidak bergejala depresi.

Kebaruan penelitian ini terletak pada integrasi sistem EEG dan EKG dalam satu perangkat portabel berbasis ESP32-S3 yang terhubung dengan IoT dan model klasifikasi SVM. Sistem ini menggabungkan PSD dari sinyal EEG dan HRV dari sinyal EKG sebagai masukan kecerdasan buatan untuk skrining gejala depresi berdasarkan skor BDI-II. Dengan demikian, penelitian ini berkontribusi pada pengembangan prototipe instrumentasi medis portabel yang mampu mengukur biosinyal gabungan, pemantauan *real-time*, dan klasifikasi awal gejala depresi dalam satu sistem terpadu.

1.2 Tujuan Penelitian

1. Merancang, membangun, dan mengimplementasikan alat portabel penguat biosinyal EEG dan EKG.
2. Membangun sistem pemantauan data fisiologis secara *real-time* berbasis IoT.
3. Membangun dan menguji model *Support Vector Machine* (SVM) untuk klasifikasi gejala depresi.

1.3 Manfaat Penelitian

1. Menghasilkan alternatif perangkat pemantau aktivitas otak dan jantung yang lebih praktis dan terjangkau.
2. Memfasilitasi pemantauan kesehatan jarak jauh melalui integrasi teknologi IoT.
3. Menyediakan alat bantu skrining objektif berbasis kecerdasan buatan untuk deteksi dini gejala depresi.

BAB II METODE PENELITIAN

2.1 Tempat dan Waktu Penelitian

Penelitian ini dilaksanakan dalam rentang waktu Februari sampai dengan Juni 2026. Proses perancangan, perakitan, dan pengujian perangkat keras, pengembangan perangkat lunak dan pengambilan data dengan subjek penelitian dilakukan di:

1. Laboratorium Elektronika dan Instrumentasi Universitas Hasanuddin.
2. Rumah Sakit Pendidikan Universitas Hasanuddin (RSPUH).

2.2 Peralatan Penelitian

Peralatan dan bahan yang digunakan dalam penelitian ini diklasifikasikan ke dalam beberapa kelompok utama. Rincian fungsi beserta dokumentasi visual dari komponen fisik instrumen dapat dilihat secara lengkap pada Lampiran 1, sedangkan format instrumen kuesioner BDI-II dapat dilihat pada Lampiran 2. Adapun daftar peralatan tersebut adalah sebagai berikut:


1. Komponen perangkat keras: MCU ESP32-S3, IC Op-Amp TL074, dan modul ADC ADS1115 16-bit, serta komponen pasif elektronika (resistor dan kapasitor).
2. Komponen catu daya: Baterai ion litium 18650 (3,7 V), modul charger TP4056, modul DC-DC penaik tegangan (*step-up*), modul step-up simetris (± 12 V), dan regulator penurunan tegangan (*low dropout*) 3,3 V.
3. Sensor dan kuesioner: Elektroda basah Ag/AgCl, kabel elektroda, dan BDI-II
4. Alat ukur dan pengujian: Multimeter digital, signal generator, osiloskop digital, mesin EEG 16-channel, mesin EKG 12-lead, dan pulse oximeter.
5. Komponen mekanik dan perakitan: PCB (FR4 dan dot matrix), kabel jumper, sakelar, kotak pelindung, timah, peralatan solder, serta perlengkapan lainnya.
6. Perangkat komputasi, perangkat lunak, dan server: Komputer, koneksi jaringan internet, Arduino IDE, KiCad, Node.js, Python, dan server virtual AWS EC2.

2.3 Metode Kerja

Penelitian ini menggunakan metode eksperimental dengan pendekatan rancang bangun untuk sistem instrumentasi medis yang terintegrasi. Fokus utama penelitian adalah membangun sistem pemantauan yang menggabungkan akuisisi biosinyal aktivitas otak (EEG) dan variabilitas jantung (EKG) dalam satu platform mikrokontroler ESP32-S3 berbasis IoT.

Pelaksanaan penelitian ini dibagi menjadi beberapa tahapan terdiri dari: (1) Tahap perancangan, yang mencakup pengembangan perangkat keras instrumentasi sinyal dan perangkat lunak kecerdasan buatan; (2) Tahap Integrasi, yaitu penggabungan sistem fisik dengan arsitektur IoT dan model klasifikasi SVM; serta (3) Tahap Validasi, untuk menguji performa alat dibandingkan dengan standar

referensi. Rincian langkah-langkah sistematis dalam penelitian ini ditunjukkan melalui diagram alir pada Gambar 1.



Gambar 1. Diagram alur penelitian

Penelitian dimulai dengan studi literatur untuk memahami landasan teori dan penelitian terkini, yang dilanjutkan dengan identifikasi masalah guna merumuskan tujuan penelitian. Setelah alat dan bahan dipersiapkan, penelitian memasuki tahap utama yaitu perancangan dan pembuatan sistem. Proses ini dilaksanakan dalam dua alur kerja yang terdiri dari perancangan perangkat keras dan perancangan perangkat lunak.


Pada alur perangkat keras, proses difokuskan pada perancangan sistem EEG dan EKG, yang kemudian dilanjutkan dengan pemeriksaan konektivitas komponen. Jika koneksi baik, alur ini siap untuk diintegrasikan. Sementara itu, pada alur perangkat lunak, dilakukan perancangan pemrograman mikrokontroler dan perancangan model AI untuk klasifikasi hasil analisis. Kedua sub-sistem lunak ini diuji melalui simulasi, dan jika berhasil, dilanjutkan dengan pengaturan server IoT.

Kedua alur tersebut kemudian bertemu pada tahap integrasi perangkat lunak dan perangkat keras. Setelah sistem terintegrasi, dilakukan kalibrasi sistem untuk memastikan akurasi pembacaan biosinyal. Hasil kalibrasi kemudian divalidasi, jika sistem dinyatakan valid, maka penelitian berlanjut ke tahap pengambilan data. Namun, jika hasil validasi menunjukkan ketidakvalidan, proses akan dikembalikan ke tahap integrasi perangkat lunak dan perangkat keras untuk pemeriksaan ulang dan perbaikan menyeluruh. Data yang berhasil dikumpulkan dari sistem yang valid selanjutnya diolah dan dianalisis untuk menarik kesimpulan, menandai selesainya rangkaian penelitian ini.

2.3.1 Perancangan Perangkat Keras

Perangkat keras dirancang sebagai sistem instrumen portabel yang mampu menangani akuisisi dua jenis biosinyal (EEG dan EKG) secara simultan. Integrasi keseluruhan komponen perangkat keras, mulai dari sensor hingga manajemen daya, ditunjukkan pada Gambar 2.

Dapat dilihat pada Gambar 2, proses akuisisi dimulai dari elektroda basah Ag/AgCl yang dipilih karena stabilitas sinyal dan SNR yang lebih tinggi dibandingkan elektroda kering (Ehrhardt et al., 2024). Elektroda terhubung ke sistem melalui konektor jack audio 3,5 mm. Sinyal masukan kemudian diproses melalui dua jalur pengondisian sinyal terpisah (kanal EEG dan kanal EKG). Berbeda dengan penelitian sebelumnya, sistem ini menggunakan rangkaian penguat kustom berbasis IC Op-Amp TL074 dengan topologi seragam untuk kedua kanal, di mana prinsip pengondisian sinyal mengacu pada desain penguat instrumentasi, HPF, LPF, Notch Filter, penguat buffer dan level shifter (Clark, 2020; Malvino et al., 2021) dijelaskan lebih lanjut pada subbab 2.3.2.



Gambar 2. Perancangan perangkat keras


Keluaran analog dari kedua penguat tersebut dikonversi ke sinyal digital menggunakan dua modul ADC ADS1115 16-bit untuk setiap keluaran penguat. Tahap digitalisasi sinyal dilakukan menggunakan modul ADS1115, dioperasikan dalam mode *Single-Ended Input* dan rentang skala penuh masukan diatur pada konfigurasi $\pm 4,096$ V kanal EKG dan $\pm 2,048$ V kanal EEG untuk mencegah sinyal terpotong. Proses *sampling* dilakukan pada kecepatan maksimum 860 *Samples Per Second* (SPS) (Texas Instruments, 2024).

Data digital ditransmisikan melalui komunikasi I2C ke mikrokontroler ESP32-S3. Mikrokontroler ini dipilih karena arsitektur *Dual-Core Xtensa® LX7 240 Mhz* guna penerapan multitasking yang efisien. Satu inti dikhususkan untuk data sensor, sementara inti lainnya menangani komputasi seperti algoritma FFT dan analisis interval R-R. Fitur akselerasi vektor pada prosesor ini juga supaya pemrosesan sinyal berjalan secara *real-time* tanpa mengganggu stabilitas transmisi data ke server IoT (Espressif Systems, 2025).

Untuk mendukung portabilitas, sumber daya utama perangkat menggunakan baterai. Manajemen daya diatur melalui modul TP4056 untuk proteksi pengisian daya, yang kemudian diteruskan ke modul DC-DC step-up untuk

menaikkan tegangan menjadi 6V stabil sebagai bus daya utama. Tegangan 6V ini didistribusikan ke mikrokontroler dan dua jenis regulator lanjutan: (1) Modul *step-up* simetris yang menyuplai tegangan +12 V dan -12 V untuk Op-Amp TL074 pada penguat EEG dan EKG, serta (2) *low dropout* 3,3V untuk menyuplai tegangan ke modul ADC ADS1115.

Integrasi komponen-komponen perangkat keras tersebut membentuk sistem yang dipetakan ke dalam arsitektur IoT yang terdiri dari *sensing layer*, *connectivity layer*, dan *processing layer*. Struktur arsitektur lapisan diilustrasikan pada Gambar 3.




Gambar 3. Arsitektur lapisan sistem

Proses dimulai dari lapisan sensor untuk akuisisi dua jenis biosinyal fisiologis, yakni EEG dan EKG, menggunakan elektroda basah Ag/AgCl. Sinyal tersebut dikondisikan dengan penguat berbasis TL074 masing-masing kanal. Data yang ditangkap kemudian dikonversi ke digital menggunakan *analog-to-digital* (ADC) ADS1115, lalu diteruskan ke mikrokontroler ESP32-S3. ESP32-S3 berfungsi sebagai pusat pengumpulan data digital yang selanjutnya ditransmisikan melalui jaringan *wireless fidelity* (Wi-Fi) menuju server IoT di AWS EC2. Transmisi ini memanfaatkan protokol komunikasi Socket.IO untuk pertukaran data dua arah secara *real-time* antara perangkat keras dan *web client*. Selanjutnya, pada lapisan pemrosesan data dianalisis menggunakan skrip python untuk mengekstrak fitur PSD dari sinyal EEG dan HRV dari sinyal EKG. Fitur-fitur tersebut menjadi masukan bagi model AI berbasis SVM yang memproses klasifikasi kondisi subjek menjadi kategori bergejala depresi atau sehat.

2.3.2 Penguat Biosinyal EEG dan EKG

Implementasi perangkat keras berfokus pada perakitan penguat sinyal berbasis IC TL074 yang dirancang untuk mengakuisisi sinyal EEG dan EKG dalam menggunakan satu skema rangkaian, sebagaimana ditunjukkan pada Gambar 4, Adapun file desain tata letak PCB dapat diakses pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).



Gambar 4. Skematik rangkaian penguat biosinyal EEG dan EKG

Rangkaian ini mengadopsi prinsip desain penguat bertingkat untuk mengkondisikan biosinyal yang memiliki amplitudo rendah dan rentan terhadap noise. Sistem ini menggunakan IC TL074 yang efisien karena di dalamnya sudah terdapat empat buah penguat sekaligus. Alasan pemilihan TL074 adalah karena karakteristik inputnya yang berbasis JFET yang membuat penguat memiliki impedansi yang sangat tinggi, yang berfungsi agar sinyal listrik dari elektroda di kulit dapat diserap secara utuh tanpa mengalami penurunan tegangan. Selain itu, komponen ini memiliki tingkat derau rendah. TL074 juga memiliki respon yang cepat sehingga mampu mengikuti lonjakan sinyal detak jantung (EKG) yang tajam dengan akurat tanpa distorsi (Texas Instruments, 2021).

Rangkaian penguat dirancang berdasarkan prinsip elektronika yang dijelaskan oleh Clark (2020) dan Malvino et al. (2021). Tahap pertama berfungsi sebagai penguat instrumentasi yang dibangun menggunakan tiga buah Op-Amp (U1A, U1B, dan U1C). Total penguatan tegangan (A_{v1}) pada tahap ini ditentukan oleh rasio resistor gain (R_5) dan resistor umpan balik pada bagian diferensial, sebagaimana dinyatakan dalam Persamaan (1):

$$A_{v1} = \left(1 + \frac{R_2 R_4}{R_5} \right) \left(\frac{R_6}{R_1} \right) \quad (1)$$

Dengan menggunakan nilai komponen $R_2 = 100\text{k}\Omega$, $R_5 = 4\text{k}7\Omega$, serta rasio penguatan sekali pada tahap diferensial $R_6 = R_1 = 10\text{k}\Omega$, maka diperoleh penguatan awal sebesar 43,55 kali.

Secara paralel, untuk meredam *common-mode interference* dari jala-jala listrik, sistem ini menggunakan rangkaian umpan balik Driven Right Leg (DRL) menggunakan Op-Amp U1D. Rangkaian ini dikonfigurasi sebagai *inverting summing integrator*, yang berfungsi mengembalikan common-mode dari output *buffer* dijumlahkan dan diintegrasikan terhadap waktu sesuai Persamaan (2):

$$V_{DRL} = \frac{-1}{C_7} \int \left(\frac{V_{out,A}}{R_{12}} + \frac{V_{out,B}}{R_{13}} \right) dt \quad (2)$$

Dengan nilai resistor input $R_{12} = R_{13} = 22k\Omega$ dan kapasitor $C_7 = 10nF$, rangkaian ini memberikan umpan balik negatif yang kuat pada frekuensi rendah ke tubuh subjek, sehingga meningkatkan *Common Mode Rejection Ratio* (CMRR) sistem secara signifikan. Sinyal yang telah bersih dari interferensi kemudian diteruskan ke Op-Amp U2A yang berfungsi ganda sebagai (HPF) orde-1 dan penguat non-inverting. Frekuensi potong (f_c) filter ditentukan oleh kapasitor input (C_8) dan resistor (R_8) sesuai Persamaan (3):

$$f_{c(HPF)} = \frac{1}{2\pi R_8 C_8} \approx 3,35 \text{ Hz} \quad (3)$$

Pada tahap ini juga terjadi penguatan kedua (A_{v2}) yang ditentukan oleh rasio resistor umpan balik (R_{11}) terhadap resistor input (R_{10}) sesuai Persamaan (4):

$$A_{v2} = 1 + \frac{R_{11}}{R_{10}} \quad (4)$$

Penyesuaian nilai komponen dilakukan pada tahap ini untuk membedakan mode operasi; pada konfigurasi EEG, nilai R_{11} ditetapkan sebesar $47k\Omega$ yang menghasilkan penguatan tahap kedua 48 kali dan total penguatan sistem 2.090 kali, sedangkan pada konfigurasi EKG, nilai R_{11} diganti menjadi $22k\Omega$ yang menghasilkan penguatan tahap kedua 23 kali dan total penguatan sistem 1.002 kali.

Setelah sinyal diperkuat, pembatasan *bandwidth* dilakukan menggunakan LPF Orde-1. Rangkaian ini terdiri dari filter pasif RC (R_9 dan C_1) yang diikuti oleh Op-Amp U2C sebagai buffer impedansi dengan konfigurasi *unity gain*. Frekuensi potong (f_c) filter ini ditentukan oleh nilai resistansi dan kapasitansi input sesuai Persamaan (5):

$$f_{c(LPF)} = \frac{1}{2\pi R_9 C_1} \approx 33,5 \text{ Hz} \quad (5)$$

Rangkaian *Twin-T Notch Filter* aktif (Op-Amp U2B dan U2D) dirancang dengan frekuensi tengah (f_0) pada 50 Hz sesuai Persamaan (6):

$$f_0 = \frac{1}{2\pi RC} \approx 50 \text{ Hz} \quad (6)$$


Proses pengondisian sinyal diakhiri dengan tahap penyesuaian tegangan bias (*DC Offset*) menggunakan rangkaian pembagi tegangan R_{15} dan R_{16} pada output sebelum masuk ke ADC. Besarnya tegangan bias dihitung menggunakan Persamaan (7):

$$V_{bias} = V_{CC} \frac{R_{16}}{R_{15} + R_{16}} = 1,65 \text{ V} \quad (7)$$

Tegangan offset sebesar 1,65V ini memastikan sinyal AC berada tepat di tengah rentang dinamis input modul ADC ADS1115 (0–3,3V), sehingga mencegah terjadinya *clipping* pada fase lembah gelombang.

2.3.3 Perancangan Perangkat Lunak

Perancangan perangkat lunak pada penelitian ini diklasifikasikan ke dalam dua alur kerja utama yang saling terintegrasi, yaitu: (1) alur operasi *real-time* berbasis server, dan (2) alur pengembangan model AI yang ditunjukkan pada Gambar 5.



Gambar 5. Diagram alur perancangan perangkat lunak

Pada alur operasi *real-time*, proses diawali dengan akuisisi sinyal EEG dan EKG yang dikonversi menjadi data digital menggunakan modul ADC ADS1115. Penentuan frekuensi (*sampling rate*) pada tahap ini diatur secara presisi berdasarkan teorema sampling Nyquist-Shannon, sebagaimana dinyatakan dalam Persamaan (8):

$$f_s \geq 2f_{max} \quad (8)$$

Keterangan: f_s adalah frekuensi sampling dan f_{max} adalah komponen frekuensi tertinggi yang terdapat dalam sinyal informasi yang bertujuan untuk mencegah terjadinya aliasing sinyal. Transformasi sinyal dari domain waktu ke domain frekuensi dilakukan menggunakan kalkulasi FFT. Algoritma ini dipilih karena memiliki efisiensi komputasi yang lebih tinggi dibandingkan metode *Discrete Fourier Transform* (DFT) (L. Tan, 2008). Perhitungan parameter HRV, khususnya SDNN dan RMSSD, memanfaatkan deret waktu dari jarak antar puncak R (Interval RR) yang dihitung langsung melalui selisih waktu pembacaan sensor secara *real-time*.


Data yang telah dikondisikan selanjutnya ditransmisikan melalui protokol komunikasi WebSocket menuju server IoT yang di-hosting pada AWS EC2. Di sisi server, skrip Python menjalankan model AI yang telah dilatih untuk melakukan inferensi dan klasifikasi kondisi depresi. Hasil analisis dan prediksi diagnosis kemudian dikirimkan kembali ke *dasbor web* untuk divisualisasikan kepada pengguna.

Alur pengembangan model AI dimulai dengan pengumpulan dataset melalui fitur perekaman data pada dasbor web. Data sinyal yang tersimpan dalam format CSV diunduh untuk diolah dalam lingkungan pengembangan terpisah. Tahapan ini meliputi pra-pemrosesan sinyal untuk membuang noise dan ekstraksi fitur sebelum

digunakan untuk melatih model SVM. Setelah kinerja model divalidasi pada tahap evaluasi menggunakan metrik akurasi, presisi, dan sensitivitas, model diekspor ke dalam format berkas pickle (.pkl) dan diunggah ke server cloud (AWS EC2) untuk digunakan dalam proses klasifikasi secara *real-time*.

2.3.4 Perancangan Model *Artificial Intelligence*

Tujuan dari perancangan model kecerdasan buatan dalam penelitian ini adalah mengklasifikasikan status psikologis responden menjadi kelas normal dan indikasi depresi. Berdasarkan studi literatur G et al. (2025), algoritma SVM dipilih karena sangat efektif dalam menangani klasifikasi data kesehatan yang berdimensi tinggi dan tidak linear dengan toleransi yang baik terhadap overfitting. Algoritma ini bekerja dengan membangun sebuah batas pemisah atau hyperplane yang secara optimal mengelompokkan data ke dalam dua kelas berbeda dengan memaksimalkan jarak margin antar kelas, sebagaimana diilustrasikan pada Gambar 6.



Gambar 6. Hyperplane optimal SVM

Sebelum dimasukkan ke dalam algoritma klasifikasi, data deret waktu mentah dari instrumen harus diubah menjadi tabel fitur terstruktur melalui proses rekayasa fitur. Fitur dari sinyal otak diekstraksi ke dalam domain frekuensi menggunakan FFT Tran et al. (2024) untuk mendapatkan nilai daya relatif gelombang alfa pada rentang 8–13 Hz dan gelombang beta pada rentang 13–30 Hz. Sementara itu, sinyal jantung diekstraksi pada domain waktu untuk mendapatkan parameter variabilitas detak jantung, yaitu nilai SDNN dan RMSSD (Abbas et al., 2024; Hartmann et al., 2019). Keempat parameter ini kemudian dilebur menjadi satu kesatuan data untuk melatih model kecerdasan buatan.

Pelatihan model klasifikasi dilakukan melalui berbagai skenario, yakni pada kondisi mata terbuka dan mata tertutup, serta secara tunggal maupun gabungan. Untuk menemukan arsitektur terbaik, proses penyeteman (tuning) parameter

dilakukan menggunakan metode Grid Search yang secara otomatis menguji coba seluruh kombinasi pengaturan pada empat kernel SVM, yaitu linear, Radial Basis Function (RBF), polynomial, dan sigmoid. Sistem mencari nilai parameter dengan toleransi kesalahan (Cost) pada skala logaritmik mulai dari 0,01 hingga 1000, serta nilai radius pengaruh (γ) secara absolut maupun otomatis menyesuaikan variasi data. Mengingat terbatasnya jumlah subjek, pemodelan menerapkan metode Leave-One-Group-Out Cross-Validation (LOGO-CV) untuk mencegah model sekadar menghafal data latih (overfitting). Metode ini mengelompokkan data berdasarkan identitas subjek, sehingga algoritma dilatih dan diuji secara bergantian pada subjek yang sepenuhnya berbeda (Yang & Chen, 2024). Seluruh model yang dihasilkan dari kombinasi Grid Search tersebut divalidasi kinerjanya menggunakan metrik tingkat akurasi, presisi, sensitivitas, spesifisitas, kurva ROC, serta pemetaan pada confusion matrix. Model dengan arsitektur dan parameter terbaik kemudian diekspor menjadi berkas .pkl agar dapat digunakan pada server IoT.

2.3.5 Pengujian Alat

Pengujian perangkat keras diawali dengan memastikan komunikasi data antara ESP32-S3 dan kedua modul Analog-to-Digital Converter (ADS1115) berjalan lancar secara bersamaan. Selanjutnya, rangkaian penguat diuji menggunakan signal generator dan osiloskop untuk mengonfirmasi bahwa rentang frekuensi (bandwidth) filter berada tepat di 3,3–33,5 Hz, serta mengukur nilai penguatan (gain) yang sebenarnya. Kualitas sinyal juga dievaluasi menggunakan *Signal-to-Noise Ratio* (SNR) untuk memastikan sinyal asli lebih besar dari noise perangkat. Perhitungan SNR dirumuskan pada Persamaan (9):

$$SNR_{dB} = 20 \log_{10} \left(\frac{V_{signal}}{V_{noise}} \right) \quad (9)$$

Tahap validasi klinis dilakukan di Rumah Sakit Universitas Hasanuddin. Sinyal subjek direkam secara bersamaan menggunakan alat prototipe dan monitor medis rumah sakit. Data dari rumah sakit ini kemudian dijadikan acuan standar untuk mengkalibrasi alat prototipe. Kalibrasi dilakukan menggunakan dua metode (Chapra & Canale, 2010), metode interpolasi digunakan untuk menyesuaikan nilai amplitudo PSD gelombang otak agar pembacaannya presisi dengan alat medis. Persamaan yang digunakan ditunjukkan pada Persamaan (10):

$$f_1(x) = f(x_0) + \frac{f(x_1) - f(x_0)}{x_1 - x_0} (x - x_0) \quad (10)$$

Pada persamaan tersebut, $f_1(x)$ adalah faktor pengali frekuensi target. x adalah titik frekuensi target. Selanjutnya, x_0 dan x_1 masing-masing menunjukkan titik frekuensi terdekat di bawah dan di atas nilai x . Sementara itu, $f(x_0)$ dan $f(x_1)$ merupakan nilai faktor pengali acuan yang secara berurutan berada pada titik frekuensi x_0 dan x_1 .

Untuk melakukan kalibrasi EKG, data denyut jantung dalam satuan *Beats Per Minute* (BPM) yang diperoleh dari sinyal EKG alat dan pulseoximeter selanjutnya dikonversi menjadi nilai yang ekivalen dengan interval R-R. Jarak antar-puncak gelombang R ini dihitung dalam satuan milidetik untuk parameter HRV. Konversi dilakukan dengan membagi durasi satu menit (60.000 milidetik) dengan nilai HR yang terbaca, sebagaimana ditunjukkan pada Persamaan (11):

$$RR_{Interval} = \frac{60000}{HR_{BPM}} \quad (11)$$

Kemudian, metode regresi linear digunakan untuk mengurangi error pembacaan denyut jantung dengan mengonversi nilai ukur mentah ke nilai terkalibrasi, sesuai dengan Persamaan (12):


$$y = a + bx \quad (12)$$

Di mana y adalah hasil bacaan terkalibrasi, x adalah nilai acuan standar, a mewakili titik potong (*intercept*), dan b adalah kemiringan garis kalibrasi (*slope*). Akurasi detak jantung ini juga divalidasi dengan membandingkannya secara langsung terhadap pulseoximeter.

Tahap terakhir adalah pengujian sistem IoT. Pengujian ini memastikan ESP32-S3 berhasil mengirim data secara utuh ke server AWS EC2 melalui protokol WebSocket. Stabilitas jaringan dievaluasi berdasarkan parameter Quality of Service (QoS) standar ITU-T yang mencakup end-to-end delay, jitter, dan packet loss. Perekaman pada halaman dasbor web juga divalidasi untuk memastikan dataset tersimpan dengan benar sebagai bahan pelatihan model AI.

2.3.6 Bagan Alir Sistem Kerja Alat

Adapun bagan alir sistem kerja alat pada Gambar 7 menunjukkan urutan operasional sistem dari akuisisi data hingga visualisasi hasil.



Gambar 7. Diagram alir sistem kerja alat


Alur kerja dimulai dengan pengambilan data sinyal EEG dan EKG secara simultan dari subjek menggunakan elektroda. Sinyal analog mentah yang terekam melewati tahap pengondisian sinyal sebelum dikonversi menjadi data digital dan diolah oleh ESP32-S3. ESP32-S3 menjalankan kalkulasi FFT untuk mendapatkan nilai PSD dari sinyal EEG, serta analisis interval R-R untuk menghitung parameter HRV dari sinyal EKG.

Data tersebut kemudian ditransmisikan ke Server IoT. Di sisi server, alur data terbagi menjadi dua proses. Pertama, data analisis disimpan untuk visualisasi grafik. Kedua, data diproses oleh Model AI untuk klasifikasi. Pada tahap ini, sistem melakukan pengambilan keputusan: jika prediksi menunjukkan bergejala depresi (Ya), sistem akan mencatat hasil sebagai Bergejala Depresi, sebaliknya jika tidak (Tidak), sistem mencatat hasil Normal. Terakhir, data hasil analisis sinyal dan status klasifikasi tersebut dikirimkan secara bersamaan ke *web client* untuk divisualisasikan kepada pengguna.

2.3.7 Prosedur Pengambilan Data Subjek

Proses pengambilan data fisiologis melibatkan kelompok subjek dengan rentang usia 19 hingga 26 tahun. Subjek terdiri dari relawan mahasiswa Fisika Unhas dan pasien klinis Rumah Sakit Universitas Hasanuddin. Kriteria inklusi meliputi: responden tidak memiliki riwayat penyakit kardiovaskular bawaan, tidak memiliki riwayat cedera otak traumatis atau epilepsi.

Untuk memastikan kualitas sinyal dan meminimalisasi gangguan dari lingkungan luar, prosedur perekaman dilaksanakan di dalam ruangan yang tenang dengan pencahayaan dan suhu yang terkontrol. Subjek diinstruksikan untuk duduk bersandar secara rileks pada kursi yang telah disediakan. Setelah responden berada dalam kondisi rileks, elektroda dipasang pada posisi Fp1, A1, A2 dalam konfigurasi Internasional 10-20 untuk membaca EEG dan pada area dada posisi *standard limb leads* untuk memantau EKG seperti diilustrasikan pada Gambar 8.



Gambar 8. Konfigurasi posisi elektroda

Sebelum perekaman dimulai, seluruh subjek diberikan penjelasan mengenai prosedur dan diminta untuk menandatangani lembar Informed Consent (Lampiran 3). Selanjutnya, subjek mengisi kuesioner BDI-II untuk mengukur tingkat keparahan gejala depresi secara mandiri. Seluruh prosedur dalam penelitian ini bersifat non-invasif dan telah mendapatkan Rekomendasi Persetujuan Etik dari Komite Etik FKM Unhas (Lampiran 4).

Perekaman data kemudian dilakukan menggunakan alat yang telah dirancang dan dikalibrasi. Perekaman dilakukan selama total 10 menit dan dibagi ke dalam dua skenario, yakni kondisi mata terbuka dan mata tertutup selama masing-masing 5 menit.


BAB III HASIL DAN PEMBAHASAN

3.1 Hasil Perancangan Sistem

Subbab ini membahas hasil akhir dari realisasi perancangan perangkat keras instrumen portabel penguat biosinyal dan arsitektur perangkat lunak yang terintegrasi dengan jaringan IoT.

3.1.1 Hasil Perancangan Perangkat Keras

Sistem perangkat keras utama dibangun di atas papan PCB dot matrix berukuran 8 cm x 15 cm. Khusus untuk rangkaian penguat sinyal EEG dan EKG, desain dicetak secara terpisah pada PCB berbahan FR4 berukuran 10 cm x 5 cm yang dilapisi masking hitam. Visualisasi dari fisik arsitektur perangkat keras ini, mulai dari tampak keseluruhan hingga detail penempatan komponen, ditunjukkan pada Gambar 9.



Gambar 9. Hasil perancangan perangkat keras

(a) Keseluruhan sistem (b) Elektroda Ag/AgCl (c) Pengondisi dan pemroses sinyal (tampak atas) (d) Pemasok daya (tampak bawah)


Visualisasi keseluruhan perangkat keras ditunjukkan pada Gambar 9(a) terlihat wujud utuh sistem yang terdiri dari elektroda *disposable* Ag/AgCl beserta kabel penghubung menuju modul pengondisi dan pemroses sinyal. Rincian enam pin kabel elektroda dapat dilihat pada Gambar 9(b), yang terbagi menjadi tiga pin untuk input sinyal EEG dan tiga pin lainnya untuk input sinyal EKG yang ditandai secara khusus dengan label berwarna putih. Selanjutnya, integrasi komponen pada sisi atas papan ditunjukkan oleh Gambar 9(c). Pada bagian ini terdapat susunan ESP32-S3, modul ADS1115, serta rangkaian penguat EEG dan EKG berbasis IC TL074, yang juga dilengkapi dengan konektor *jack* 3,5 mm, susunan komponen pendukung, dan sakelar daya pada sisi samping alat. Sementara itu, sisi bawah papan yang difungsikan sebagai sistem catu daya diperlihatkan pada Gambar 9(d). Bagian tersebut terdiri dari baterai ion litium 18650 berkapasitas 1500 mAh, modul pengisi daya TP4056, modul penaik tegangan simetris $\pm 12V$, regulator tegangan LDO 3.3V, serta kapasitor filter untuk suplai daya ke seluruh sistem tetap stabil selama pengoperasian.

3.1.2 Hasil Perancangan Perangkat Lunak dan IoT

Perancangan perangkat lunak pada sistem ini dirancang secara terintegrasi, mulai dari program yang ditanamkan pada alat (firmware), sistem pengelolaan data di server, hingga *dasbor web*.

Pemrograman pada perangkat keras ditulis menggunakan bahasa C melalui *software* Arduino IDE (keseluruhan skrip *firmware* ESP32-S3 diarsipkan pada repositori penelitian, (Aksa, 2026); lihat Lampiran 9). Mengingat tingginya beban komputasi dalam memproses dua jenis biosinyal secara simultan, sistem mengimplementasikan arsitektur *dual-core* pada ESP32-S3. *Core* 1 secara khusus bertugas mengukur sinyal EEG dan EKG, menyaring derau, mendeteksi puncak interval R-R pada EKG, serta melakukan transformasi FFT pada EEG. Sementara itu, *Core* 0 bertugas mengelola konektivitas nirkabel dan mentransmisikan paket data komputasi ke *server* secara *real-time*

Ilustrasi dari tahapan pemrosesan sinyal EEG dan EKG tersebut divisualisasikan pada Gambar 10. Plot tersebut menampilkan titik puncak gelombang (R) jantung pada domain waktu dilihat pada Gambar 10(a) serta sinyal EEG dalam domain waktu seperti pada Gambar 10(b) dan menjadi parameter PSD pada domain frekuensi ditunjukkan pada Gambar 10(c).



Gambar 10. Visualisasi pemrosesan sinyal EKG dan EEG


- (a) Deteksi puncak R-R (b) Sinyal EEG dalam domain waktu
(c) Sinyal EEG dalam domain frekuensi (PSD)

Data nirkabel dari alat akan diterima oleh Virtual Private Server (VPS) dari Amazon Web Services (AWS). Sisi server dibangun menggunakan Node.js. Skrip lengkap dasbor web, server IoT, dan server AI diarsipkan pada repositori penelitian

((Aksa, 2026); lihat Lampiran 9). Agar sistem server siap menerima data *real-time*, sistem operasi dibekali pengelola proses otomatis (PM2). Seluruh data pasien yang masuk akan langsung diarsipkan ke dalam basis data terpusat (SQLite) sebagai rekam medis elektronik yang rapi dan mudah diekspor untuk keperluan analisis lanjutan. Antarmuka dirancang interaktif dan bergantung pada perangkat apa yang digunakan sebagaimana ditunjukkan pada Gambar 11.



(a)



(b)

Gambar 11. Hasil perancangan perangkat lunak

(a) Dasbor web via peramban ponsel (b) Dasbor web via peramban komputer


Berdasarkan desain antarmuka tersebut, Gambar 11(a) menampilkan antarmuka dasbor saat diakses melalui layar ponsel, sedangkan Gambar 11(b) menunjukkan tampilan saat diakses melalui layar komputer. Pada halaman *dasbor* tersebut, dapat diisi identitas dan skor BDI-II subjek sebelum memulai perekaman. Saat alat aktif, layar akan menampilkan pembaruan angka parameter fisiologis secara *real-time* lengkap dengan grafik pergerakan sinyal otak dan ritme jantung serta analisis AI untuk diamati secara langsung.

3.2 Hasil Pengujian Alat

Pengujian instrumen dilakukan untuk memvalidasi performa karakteristik komponen elektronika melalui uji laboratorium serta memastikan kesesuaian alat dalam mengakuisisi biosinyal manusia melalui uji klinis. Spesifikasi alat pembanding dan dokumentasi proses pengujian dapat dilihat pada Lampiran 5 dan Lampiran 6, serta data pembacaan standar medis tersedia pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).


3.2.1 Hasil Pengujian Alat EEG

Pengujian sinyal EEG difokuskan pada nilai PSD untuk memvalidasi kemampuan alat dalam mengekstrak fitur PSD. Pengujian pertama dilakukan dengan membandingkan pembacaan daya pada spektrum frekuensi yang dirancang,



Gambar 12. PSD 8-30 Hz

Berdasarkan Gambar 12, PSD tersebut dikalibrasi menggunakan persamaan yang ditunjukkan pada Persamaan (10). Rincian hasil pembacaan mesin EEG RS dan tabel perhitungan PSD dapat diakses pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9). Terlihat alat yang dirancang dapat mengikuti pola gelombang dari alat EEG standar RS. Pengujian pada rentang alfa-beta menghasilkan rata-rata akurasi 82.62%. Selisih ini menunjukkan bahwa alat sudah mampu mengikuti pola PSD alat standar, tetapi tingkat kesesuaiannya masih tergolong sedang sehingga belum dapat dianggap setara dengan perangkat EEG klinis. Selain pengujian PSD, juga dilakukan untuk memastikan bahwa perangkat tidak mengalami pergeseran titik frekuensi saat mengubah sinyal analog tubuh menjadi data digital. Komparasi pengujian frekuensi ini divisualisasikan pada Gambar 13.




Gambar 13. Pengujian frekuensi 3-30 Hz

Berdasarkan komparasi pembacaan antara alat dan osiloskop digital ATEN ADS1022CL+ pada rentang 3 hingga 30 Hz, sebaran titik pengukuran membentuk garis diagonal yang linear dengan akurasi sebesar 100,00%. Rincian tabel komparasi data terhadap osiloskop tersedia pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).


3.2.2 Hasil Pengujian Alat EKG

Pengujian HR pertama dilakukan dengan membandingkan pembacaan alat terhadap perangkat *pulse oximeter* komersial. Pengujian ini bertujuan untuk memvalidasi rentang HR yang dapat dideteksi, sebagaimana ditunjukkan pada Gambar 14. Tabel data hasil kalibrasi HR dan Interval R-R secara rinci dapat diakses pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).




Gambar 14. Pengujian HR alat vs pulse oximeter

Hasil pemetaan pada Gambar 14 menunjukkan bahwa titik pengukuran mengelompok mengikuti garis regresi linear. Perbandingan ini menghasilkan rata-rata akurasi sebesar 98,83%. Data denyut jantung tersebut dikalibrasi menggunakan metode regresi linear yang merujuk pada persamaan (12). Data HR yang diperoleh kemudian diubah menjadi nilai interval R-R ekivalen menggunakan Persamaan (11).



Gambar 15. Pengujian interval RR alat vs pulse oximeter


Untuk menghasilkan nilai HRV yang tepat, sistem harus mampu mengukur jarak antar-puncak gelombang R dalam hitungan milidetik. Grafik korelasi interval R-R pada gambar 15 memperlihatkan bahwa alat berhasil mencatat waktu antar-puncak dengan rata-rata akurasi mencapai 98,56% terhadap *Pulse Oximeter*. Validasi selanjutnya dilakukan dengan menyandingkan alat dengan mesin EKG standar Rumah Sakit. Komparasi pembacaan HR RS ditunjukkan pada Gambar 16.



Gambar 16. Pengujian HR alat vs EKG RS

Melalui pemetaan titik data pada Gambar 16, komparasi terhadap mesin EKG klinis tetap menghasilkan persentase rata-rata akurasi yang sangat tinggi, yakni 98,92%. Tahap validasi terakhir pada EKG adalah komparasi interval R-R dengan mesin EKG standar Rumah Sakit. Ketepatan pengukuran jarak interval

antar detak ini merupakan fondasi utama dalam ekstraksi HRV, sebagaimana diilustrasikan pada Gambar 17.





Gambar 17. Pengujian interval RR alat vs EKG RS

Berdasarkan Gambar 17, alat dapat merekam interval R-R dengan rata-rata akurasi sebesar 99,99% apabila dibandingkan dengan EKG standar medis.

3.2.3 Hasil Pengujian *Signal-to-Noise Ratio* (SNR)

Pengujian kualitas sinyal dilakukan untuk memastikan alat dapat merekam sinyal biopotensial di atas ambang batas derau kelistrikan. Diukur menggunakan metrik SNR sesuai Persamaan (10). Nilai ambang batas derau dikonfigurasi secara konstan, yaitu sebesar 9,19 μV untuk EEG dan 0,02 mV untuk EKG. Pengujian ini menggunakan data sinyal dari 25 subjek yang telah diukur sebagaimana ditunjukkan pada Gambar 18. Tabel data pengujian SNR dengan rinci dapat dilihat pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).





Gambar 18. Pengujian SNR


(a) SNR EEG (b) SNR EKG

Berdasarkan Gambar 18(a), kualitas sinyal EEG pada kondisi buka maupun tutup mata menunjukkan hasil yang stabil. Seluruh data subjek berada di atas batas 0 dB, dengan rentang SNR antara 6,10 dB hingga 19,68 dB. Sementara itu, pengukuran kualitas sinyal EKG ditunjukkan pada Gambar 18(b) menunjukkan nilai SNR yang lebih tinggi dibandingkan kanal EEG, yakni berada pada rentang 27,17 dB hingga 44,24 dB.

3.2.4 Hasil Pengujian Daya Tahan Baterai

Alat portabel ini dirancang menggunakan baterai lithium-ion 18650 dengan kapasitas 1500 mAh sebagai catu daya utama. Untuk digunakan dalam skenario tanpa terhubung ke sumber listrik, pengujian daya tahan baterai dilakukan. Pengujian ini mengukur rentang waktu penggunaan maksimal sejak baterai terisi penuh hingga alat mati secara otomatis.

Selama pengujian berlangsung, alat dikondisikan pada beban kerja komputasi maksimal. ESP32-S3 menjalankan kedua inti prosesornya secara bersamaan untuk pengambilan data biosinyal, pemrosesan filter, perhitungan FFT, dan pengiriman data secara nirkabel (Wi-Fi) ke server secara *real-time*. Hasil dari empat kali sesi pengujian durasi baterai tersebut divisualisasikan pada Gambar 19.



Gambar 19. Pengujian daya tahan baterai

Berdasarkan hasil empat kali pengujian yang divisualisasikan pada Gambar 19, alat menunjukkan durasi penggunaan alat secara konsisten berada di atas angka 3 jam, dengan waktu terpendek tercatat selama 3 jam 19 menit dan waktu terlama mencapai 3 jam 26 menit. Rata-rata daya tahan baterai adalah 3 jam 22 menit (202,5 menit) dalam satu kali pengisian daya.

3.3 Hasil Pengukuran Sinyal Fisiologis

Pengukuran sinyal fisiologis dilakukan pada 25 subjek melalui dua skenario perekaman, yakni mata terbuka dan tertutup. Parameter PSD dan HRV dipetakan ke dalam grafik sebaran untuk mengamati pola pengelompokan data. Area latar belakang grafik dibagi menjadi tiga zona berdasarkan nilai ambang batas klinis: zona hijau untuk area normal (kedua parameter berstatus normal), zona kuning untuk area peringatan (salah satu parameter berstatus bergejala depresi), dan zona merah untuk area bergejala (kedua parameter berstatus bergejala depresi).

Untuk membedakan asal usul data, identitas subjek direpresentasikan melalui bentuk geometri, di mana titik berbentuk lingkaran mewakili relawan mahasiswa dan bentuk belah ketupat mewakili pasien klinis rumah sakit. Sementara itu, tingkat keparahan gejala divisualisasikan melalui warna titik data tersebut. Spektrum warna gradasi dari hijau ke merah seiring dengan bertambahnya jumlah parameter yang bergejala depresi, sehingga pembacaan kondisi psikologis subjek dapat dilakukan secara visual. Dokumentasi pengambilan data subjek disajikan pada Lampiran 7 dan datasetnya secara rinci dapat diakses pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).

3.3.1 Standar Referensi dan Penentuan Ambang Batas (Cut-Off)

Sebelum memetakan distribusi data hasil pengukuran biosinyal ke dalam grafik observasi, diperlukan penetapan nilai ambang batas sebagai garis pemisah antara

profil fisiologis normal dan depresi. Rekapitulasi standar referensi klinis yang digunakan sebagai acuan pemetaan data ditunjukkan pada Tabel 1.


Tabel 1. Standar Referensi Klinis Parameter EEG dan HRV


Modalitas	Kondisi	Parameter	Sehat	Depresi	Ambang batas	Referensi
EKG (HRV)	Tutup Mata	SDNN (ms)	41,95	32,99	37,47	(Chang et al., 2024)
		RMSSD (ms)	31,41	25,65	28,53	
	Buka Mata	SDNN (ms)	41,6	32,2	36,9	(Chen et al., 2026)
		RMSSD (ms)	50,5	34,2	42,35	
EEG (PSD)	Tutup Mata	Alfa Relatif (%)	61,13	51,89	56,51	(L. Li et al., 2024; Mumtaz & Qayyum, 2019)
		Beta Relatif (%)	38,87	48,11	43,49	
	Buka Mata	Alfa Relatif (%)	46,29	43,5	44,89	
		Beta Relatif (%)	53,71	56,5	55,11	

Tabel 1 menyajikan rekapitulasi standar referensi klinis yang digunakan sebagai acuan pemetaan data. Berdasarkan tinjauan literatur, penentuan cut-off pada penelitian ini dikalkulasi menggunakan metode titik tengah dari rata-rata nilai kelompok sehat dan depresi.

3.3.2 Hasil Pengukuran PSD

Fitur EEG dianalisis menggunakan perbandingan persentase daya relatif antara gelombang alfa dan beta. Pemetaan titik data pada kedua gelombang ini bertujuan untuk mengobservasi pergeseran dominasi aktivitas otak antara subjek normal dan subjek bergejala depresi. Distribusi persebaran data untuk skenario buka mata dan tutup mata disajikan pada Gambar 20.







Gambar 20. Hasil pengukuran daya relatif
(a) Kondisi buka mata (b) Kondisi tutup mata

Pada kondisi buka mata dilihat pada Gambar 20a, titik data tersebar dari area kiri atas menuju kanan bawah. Pola pemisahan yang konsisten juga terlihat pada kondisi tutup mata yang dapat dilihat pada Gambar 20b, namun dengan persebaran koordinat yang bergeser secara kolektif ke arah kanan bawah. Berdasarkan data tersebut ada hubungan terbalik antara alfa relatif dengan beta relatif, dan nilai alfa yang lebih tinggi saat kondisi tutup mata.

3.3.3 Hubungan BPM dan HRV

Pengamatan sistem EKG dilakukan dengan memetakan hubungan antara rata-rata BPM dengan parameter HRV. Pemetaan regresi linear ini bertujuan untuk melihat sebaran dan arah pola hubungan kedua parameter tersebut, sebagaimana divisualisasikan pada Gambar 21.





(b)


Gambar 21. Hubungan BPM terhadap HRV

(a) SDNN (b) RMSSD


Gambar 21a memperlihatkan arah garis tren yang menurun secara konsisten pada semua skenario pengujian. Secara kuantitatif, arah tren tersebut dibuktikan oleh nilai koefisien korelasi Pearson r yang bernilai negatif. Berdasarkan hasil ekstraksi, parameter SDNN mencatatkan nilai korelasi sebesar -0,612 pada kondisi tutup mata dan -0,633 pada kondisi buka mata. Gambar 21b menunjukkan tren penurunan yang serupa pada parameter RMSSD dengan nilai r sebesar -0,707 pada kondisi tutup mata dan -0,673 pada kondisi buka mata. Pengujian ini menunjukkan adanya hubungan linear yang berbanding antara kedua variabel. Secara spesifik, sebaran data menunjukkan bahwa setiap peningkatan nilai sebaran BPM secara konsisten diikuti oleh penurunan nilai SDNN dan RMSSD.

3.3.4 Hasil Pengukuran HRV

Analisis pada sinyal jantung difokuskan pada SDNN dan RMSSD. Berdasarkan Gambar 22, persebaran data secara visual memperlihatkan pola klusterisasi linear dengan korelasi positif, yang menunjukkan nilai SDNN dan RMSSD selalu bergerak berbanding lurus, baik pada kondisi buka maupun tutup mata.



(a)



(b)


Gambar 22. Hasil pengukuran HRV

(a) Kondisi buka mata (b) Kondisi tutup mata


Pada kondisi buka mata dilihat pada Gambar 22a, titik data yang terdapat di sudut kiri bawah grafik, menandakan nilai SDNN dan RMSSD yang rendah. Kelompok normal cenderung memanjang ke arah kanan atas. Pada kondisi tutup mata ditunjukkan pada Gambar 22b, korelasi linear positif tetap terjaga. Titik data secara keseluruhan mengalami pelebaran jarak, sehingga klasternya terlihat sedikit lebih menyebar dibandingkan kondisi buka mata.

3.3.5 Hubungan PSD dan HRV


Hubungan korelasi silang antara PSD dan parameter HRV divisualisasikan pada Gambar 23 untuk kondisi buka mata dan Gambar 24 untuk kondisi tutup mata. Pemetaan dua dimensi ini dilakukan untuk mengamati pemisahan data antar kelas subjek.




(a)



(b)



(c)




(d)

Gambar 23. Hubungan PSD dan HRV kondisi buka mata




(a) SDNN vs Alfa (b) SDNN vs Beta (c) RMSSD vs Alfa (d) RMSSD vs Beta

Berdasarkan grafik korelasi pada kondisi buka mata, terlihat pola pengelompokan data yang terpisah. Pada pemetaan parameter HRV terhadap daya relatif alfa terlihat di Gambar 23a dan 23c, kelompok pasien berkumpul secara dominan di area kiri bawah (zona merah). Posisi ini menunjukkan bahwa kelompok pasien memiliki nilai HRV yang rendah, diikuti dengan nilai daya relatif alfa yang juga rendah.

Pola sebaliknya terlihat pada pemetaan HRV terhadap gelombang otak beta terlihat di Gambar 23b dan 23d. Pada grafik tersebut, kelompok pasien mengelompok di area kiri atas. Hal ini menunjukkan kombinasi antara nilai HRV yang rendah dengan nilai daya relatif beta yang tinggi.



(a)




Gambar 24. Hubungan PSD dan HRV kondisi tutup mata

(a) SDNN vs Alfa (b) SDNN vs Beta (c) RMSSD vs Alfa (d) RMSSD vs Beta


Pada kondisi tutup mata, komparasi HRV terhadap gelombang alfa, untuk SDNN terlihat pada Gambar 24a data kelompok subjek tersebar ke arah atas dan berada di tengah atau area persilangan. Data RMSSD ditunjukkan pada Gambar 24c subjek bergerak menuju arah kiri atas grafik. Demikian pula pada grafik terhadap gelombang beta, data kelompok subjek adalah cerminan dari grafik terhadap alfa. Pada parameter SDNN yang dapat dilihat pada gambar 24b kelompok subjek tersebar ke arah bawah di area persilangan tengah, sedangkan pada Gambar 24d RMSSD bergerak ke arah kiri bawah. Meskipun jarak sebaran titik data antar subjek terlihat sedikit lebih renggang pada kondisi tutup mata. Data tersebut menunjukkan bahwa seiring meningkatnya gelombang beta dan menurunnya alfa nilai RMSSD semakin menurun juga, sama halnya dengan SDNN, nilai SDNN yang rendah menunjukkan meningkatnya nilai alfa relatif dan menurunnya nilai beta relatif walaupun data cenderung tersebar di sepanjang sumbu SDNN.

3.3.6 Komparasi Kondisi terhadap EEG dan EKG

Pengamatan selanjutnya menganalisis perubahan data ketika subjek beralih dari kondisi buka mata ke kondisi tutup mata. Berdasarkan Gambar 25, pergeseran nilai parameter pada subjek yang sama divisualisasikan menggunakan garis lintasan putus-putus untuk memetakan arah transisinya.



(a)



(b)

Gambar 25. Komparasi transisi kondisi buka mata ke tutup mata

(a) Alfa vs Beta (b) SDNN vs RMSSD

Pada Gambar 25a komparasi parameter PSD, terlihat pola pergerakan arah yang seragam. Saat subjek membuka mata, seluruh titik data bergerak secara konsisten ke area dengan daya relatif alfa yang tinggi menuju area dengan daya relatif beta yang lebih dominan. Sementara itu, pada grafik komparasi parameter HRV ditunjukkan pada Gambar 25b, garis lintasan memperlihatkan pergeseran koordinat kelompok data tanpa mengubah bentuk sebarannya secara signifikan. Pada kondisi buka mata, titik data SDNN dan atau RMSSD cenderung bergerak menuju area nilai yang lebih rendah. Pola pergerakan yang sejajar ini menunjukkan bahwa transisi kondisi visual memicu penurunan HRV pada mayoritas subjek, namun tidak mengubah tingkat variasi atau jarak persebaran antar individu secara signifikan.

3.3.7 Distribusi Data Alat terhadap Referensi

Untuk memvalidasi alat yang dikembangkan, rata-rata nilai observasi dari 25 subjek yang diukur dibandingkan secara langsung dengan nilai cut-off dari literatur. Komparasi ini berfungsi sebagai referensi untuk mengetahui apakah tren perubahan fisiologis yang terekam memiliki pola yang konsisten. Rekapitulasi perbandingan rata-rata tersebut ditunjukkan pada Tabel 2.

Tabel 2. Rata-Rata Pengukuran Alat Terhadap Standar Referensi

Modalitas	Kondisi	Parameter	Rata-Rata Referensi (Normal)	Rata-Rata Alat (Normal)	Rata-Rata Referensi (Bergejala)	Rata-Rata Alat (Bergejala)
EKG (HRV)	Tutup Mata	SDNN (ms)	41,95 ± 16,26	38,26 ± 10,63	32,99 ± 15,91	41,49 ± 15,12
		RMSSD (ms)	31,41 ± 16,06	27,41 ± 13,05	25,65 ± 16,59	29,28 ± 12,93
	Buka Mata	SDNN (ms)	41,6 ± 14,90	33,57 ± 6,94	32,2 ± 12,80	40,41 ± 12,86
		RMSSD (ms)	50,5 ± 21,20	23,9 ± 8,42	34,2 ± 14,80	29,61 ± 12,90
EEG (PSD)	Tutup Mata	Alfa Rel. (%)	61,13 ± 17,35	63,24 ± 9,73	51,89 ± 17,81	57,04 ± 12,16
		Beta Rel. (%)	38,87 ± 17,35	36,76 ± 9,73	48,11 ± 17,81	42,96 ± 12,16
	Buka Mata	Alfa Rel. (%)	46,29 ± 16,59	48,93 ± 4,51	43,5 ± 18,64	46,6 ± 9,60
		Beta Rel. (%)	53,71 ± 16,59	51,07 ± 4,51	56,5 ± 18,64	53,4 ± 9,60

Berdasarkan Tabel 2, alat yang dikembangkan dapat memetakan perubahan fisiologis dengan karakteristik kepekaan yang spesifik. Pada parameter PSD, data hasil pengukuran alat menunjukkan tren yang konsisten dengan literatur. Subjek yang terindikasi bergejala mencatatkan penurunan persentase gelombang alfa yang diikuti dengan peningkatan gelombang beta pada kedua kondisi.

Sebaliknya, pada parameter HRV, terlihat adanya anomali distribusi, yakni rata-rata SDNN dan RMSSD pada kelompok bergejala justru tercatat lebih tinggi dibandingkan kelompok normal. Anomali ini terjadi akibat hadirnya beberapa nilai pencilan ekstrem (*outliers*) dari subjek yang menarik nilai rata-rata kelompok ke arah atas.


Fenomena tingginya variasi dan anomali nilai HRV pada kelompok bergejala depresi ini sejalan dengan temuan dari Van Assche & Schiweck (2026), bahwa data HRV pada perekaman naturalistik sangat rentan terdistorsi oleh faktor perancu individual. Faktor-faktor tersebut meliputi gaya hidup seperti indeks massa tubuh (BMI), kebiasaan merokok, pola aktivitas fisik, hingga riwayat paparan obat-obatan dan stimulan.

3.4 Korelasi Skor BDI-II

Tingkat keparahan gejala depresi pada subjek uji dikuantifikasi menggunakan kuesioner BDI-II. Tahapan ini bertujuan untuk memantau sejauh mana skor penilaian BDI-II berkorelasi dengan parameter observasi maupun data fisiologis lainnya.

3.4.1 Waktu Pengisian Kuesioner

Pemantauan perilaku responden secara tidak langsung dilakukan melalui durasi waktu yang dihabiskan untuk menyelesaikan kuesioner BDI-II. Pemetaan antara total skor tingkat gejala depresi dengan waktu pengisian kuesioner divisualisasikan pada Gambar 27.




Gambar 26. Korelasi BDI-II terhadap waktu pengisian kuesioner

Hasil pengukuran yang dapat dilihat pada Gambar 26 menunjukkan korelasi linear positif sebesar 0,318 antara peningkatan skor BDI-II dengan durasi pengisian kuesioner. Angka ini mengindikasikan bahwa subjek dengan tingkat gejala yang lebih tinggi cenderung membutuhkan waktu lebih lama untuk memproses dan merespons pertanyaan uji.




Secara kumulatif, kelompok subjek dengan kategori normal (< 16) mencatatkan rata-rata waktu penyelesaian selama 5,03 menit. Di sisi lain, kelompok subjek bergejala (≥ 16) mencatatkan rata-rata waktu yang lebih lama, yakni 6,25 menit. Durasi pengisian paling lambat terekam membutuhkan waktu hingga lebih dari 13 menit untuk menyelesaikan kuesioner.

3.4.2 Korelasi BDI-II terhadap EEG dan EKG

Hubungan antara skor tingkat gejala depresi berdasarkan BDI-II dengan respons fisiologis dari masing-masing subjek dianalisis menggunakan model regresi linear. Pemetaan korelasi ini menampilkan skor total BDI-II terhadap PSD serta HRV, sebagaimana ditunjukkan pada Gambar 27.



(a)



Gambar 27. Korelasi BDI-II terhadap sinyal fisiologis

(a) Alfa (b) Beta (c) SDNN (d) RMSSD

Pada pemetaan parameter daya relatif alfa dilihat pada Gambar 27a, hasil regresi menunjukkan korelasi negatif yang lemah, baik pada kondisi tutup mata ($r = -0,084$) maupun buka mata ($r = -0,005$). Garis tren yang nyaris mendatar mengindikasikan bahwa peningkatan skor BDI-II hanya diikuti oleh sedikit penurunan gelombang alfa. Pada grafik ini, garis tren kondisi tutup mata secara konsisten berada di atas garis tren kondisi buka mata.

Sebaliknya, pemetaan parameter daya relatif beta (Gambar 27b) menunjukkan korelasi positif yang lemah untuk kondisi tutup mata ($r = 0,084$) dan buka mata ($r = 0,005$). Peningkatan skor BDI-II sejalan dengan sedikit peningkatan gelombang beta. Berlawanan dengan grafik alfa, garis tren pada kondisi buka mata secara konstan berada di atas garis tren tutup mata dan sejajar tanpa persilangan.

Pemetaan pada HRV menunjukkan tren yang berbeda yang dapat dilihat pada Gambar 27c untuk SDNN dan Gambar 27d untuk RMSSD. Pada grafik RMSSD, terdapat korelasi linear negatif untuk kondisi tutup mata ($r = -0,163$) dan buka mata ($r = -0,074$), yang berarti nilai RMSSD terus menurun seiring bertambahnya skor BDI-II. Sementara itu, grafik SDNN memperlihatkan persilangan garis tren akibat perbedaan arah korelasi. SDNN pada kondisi tutup mata memiliki korelasi negatif ($r = -0,085$), sedangkan pada kondisi buka mata memiliki korelasi positif ($r = 0,123$). Pada kelompok subjek dengan skor BDI-II <16 , nilai SDNN saat tutup mata terukur lebih tinggi. Namun, seiring tingginya skor BDI-II ≥ 16 , garis tren SDNN kondisi tutup mata menurun hingga akhirnya bersilangan dengan garis tren kondisi buka mata.

3.5 Hasil Model AI

Data parameter fisiologis diproses menggunakan algoritma SVM untuk mengklasifikasikan kondisi psikologis responden ke dalam dua kelas, yaitu normal dan bergejala depresi. Pelabelan kelas merujuk secara langsung pada skor kuesioner BDI-II, dengan nilai batas ≥ 16 untuk kategori bergejala depresi (Warmenhoven et al., 2012). Pengujian performa dilakukan menggunakan metode validasi silang *Leave-One-Group-Out Cross-Validation* (LOGO-CV) untuk mencegah terjadinya *overfitting* pada dataset dengan ukuran sampel 25 responden. Evaluasi pemodelan diukur melalui parameter akurasi, presisi, sensitivitas, spesifisitas, dan *Area Under the Curve* (AUC) dari kurva *Receiver Operating Characteristic* (ROC) serta *Confusion Matrix*.

3.5.1 Hasil Performa Klasifikasi SVM

Kinerja klasifikasi dievaluasi melalui enam skenario yang membagi data berdasarkan dua perlakuan visual dan tiga jenis kombinasi fitur masukan. Optimasi arsitektur model dilakukan menggunakan metode *GridSearchCV* untuk mengevaluasi empat jenis fungsi *kernel*. Hasil komputasi performa terbaik untuk masing-masing skenario disajikan pada Tabel 3. Skrip program pelatihan, ekspor


model SVM, dan rincian hasil pelatihan diarsipkan pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).

Tabel 3. Hasil Komparasi Performa Skenario Klasifikasi SVM


Ske- nario	Kondisi	Fitur	Kernel	Konfigurasi	Akurasi (%)	Presisi (%)	Sensitivitas (%)	Spesifisitas (%)	AUC
1	Buka mata	PSD	POLY	C=1000, $\gamma=10$, Degree=4	72,00	78,57	73,33	70,00	0,75
2		HRV	SIGMOID	C=1, $\gamma=1$	64,00	80,00	53,33	80,00	0,75
3		PSD+ HRV	RBF	C=1000, $\gamma=0,01$	76,00	90,91	66,67	90,00	0,77
4	Tutup Mata	PSD	RBF	C=10, $\gamma=1$	68,00	76,92	66,67	70,00	0,58
5		HRV	SIGMOID	C=10, $\gamma=scale$	68,00	73,33	73,33	60,00	0,65
6		PSD+ HRV	POLY	C=0,1, $\gamma=10$, Degree=4	68,00	73,33	73,33	60,00	0,74

Berdasarkan Tabel 3, penggabungan fitur PSD dan HRV pada kondisi buka mata menghasilkan nilai paling optimal di antara pengujian lainnya dengan akurasi sebesar 76,00% dan tingkat presisi 90,91, sensitivitas 66.67%, Spesifisitas 90%, dan nilai AUC sebesar 0,77. Model SVM tersebut menunjukkan kemampuan klasifikasi awal yang cukup baik dengan parameter tersebut, namun performa tersebut masih memerlukan validasi lanjutan menggunakan jumlah subjek yang lebih besar dan label klinis yang lebih kuat.

Kinerja optimal pada skenario gabungan fitur buka mata dicapai melalui penggunaan fungsi kernel RBF dengan parameter Cost (C) sebesar 1000 dan parameter γ sebesar 0,01. Nilai C = 1000 bahwa model menerapkan penalti yang ketat terhadap kesalahan klasifikasi pada saat fase pelatihan. Sementara itu, nilai $\gamma = 0,01$ membentuk radius pengaruh batas keputusan yang luas, sehingga model dapat menggeneralisasi persebaran data tanpa mengalami overfitting. Rincian performa terbaik divisualisasikan melalui Confusion Matrix dan kurva ROC, sebagaimana ditunjukkan pada Gambar 28.



(a)



(b)

Gambar 28. Hasil performa klasifikasi SVM teroptimal

(a) *Confussion matrix* (b) Kurva ROC

Berdasarkan Gambar 28a, matriks tersebut mendistribusikan jumlah hasil klasifikasi model yang sesuai dengan label aslinya serta jumlah klasifikasi yang meleset (false positives dan false negatives). Selanjutnya, kemampuan pemisahan kelas oleh model direpresentasikan melalui kurva ROC pada Gambar 28b. Kurva

(oranye) yang menjauhi garis diagonal acak (baseline) mencatatkan nilai aktual AUC sebesar 0,767. Metrik ini menegaskan bahwa algoritma klasifikasi memiliki probabilitas yang tinggi dalam mendeteksi pola indikasi depresi secara tepat dengan tingkat identifikasi keliru yang minimum.

Tabel 4. Komparasi Klasifikasi Gejala Depresi

Penulis	N	Modalitas & Fitur	Metode Klasifikasi & Validasi	ACC (%)	SEN (%)	SPE (%)	PRE (%)	AUC (%)
(X. Liu et al., 2024)	169	EEG 19-kanal (Osilasi & Asimetri)	Regresi Logistik Biner 10-Fold CV	-	68,47	66,94	-	0,77
(Mumtaz et al., 2018)	64	EEG 19-kanal (Synchronization Likelihood)	SVM (Linear Kernel)10-Fold CV	98,00	99,90	95,00	-	-
(Abbas et al., 2024)	45	EEG 128-kanal & EKG (Gambar 2D Scalogram)	MobileNetV2 + AdaBoost Latih/Uji (Train/Test Split)	96,00	98,00	95,00	95,00	-
(Yang & Chen, 2024)	42	EEG 64-kanal (Entropi, Koherensi, CC, dll.)	SVM (Kernel RBF)10-Fold CV	96,66	95,93	97,55	-	-
(Byun et al., 2019)	78	EKG	SVM (Linear Kernel)LOO-CV	74,00	73,00	75,6	-	0,74
Penelitian Ini	25	Gabungan 1-Kanal EEG & 1-Kanal EKG	SVM (Kernel RBF)LOGO-CV	76,00	66,67	90,00	90,91	0,77

Keterangan singkatan: N: Jumlah subjek, CV: Cross-Validation, LOGO-CV: Leave-One-Group-Out Cross-Validation, ACC: Akurasi, SEN: Sensitivitas, SPE: Spesifisitas, PRE: Presisi, AUC: Area Under the Curve.

Tabel 4 menunjukkan komparasi antara sistem pada penelitian ini dengan studi-studi terdahulu, yang mencakup spesifikasi modalitas alat, metode pemodelan, hingga hasil metrik evaluasi klasifikasi. Secara perangkat keras, mayoritas literatur pembanding menggunakan peralatan medis klinis, mulai dari 19 kanal (X. Liu et al., 2024; Mumtaz et al., 2018), 64 kanal (Yang & Chen, 2024), hingga 128 kanal (Abbas et al., 2024). Penelitian ini menggunakan 1-kanal EEG dan 1-kanal EKG portabel yang terintegrasi sistem IoT.


Pada evaluasi metrik performa, akurasi sistem berada di angka 76,00%, sensitivitas 66,67%, spesifisitas 90,00%, presisi 90,91% serta nilai AUC sebesar 0,77. Angka tersebut mampu bersaing dengan hasil pengujian perangkat standar medis 19-kanal pada 169 subjek yang dilakukan oleh X. Liu et al. (2024) dengan perolehan AUC 0,77 dan sensitivitas 68,47%. Hasil ini menunjukkan bahwa sistem memiliki potensi sebagai alat bantu skrining gejala depresi, tetapi masih memerlukan pengujian lanjutan dengan jumlah subjek yang lebih besar dan validasi klinis yang lebih kuat.

3.6 Hasil Pengujian Sistem Pemantauan IoT

Pengujian jaringan komunikasi data dilakukan untuk menguji alat dalam mentransmisikan data rekam medis ke server secara *real-time*. Pengujian jaringan ini dibagi ke dalam tiga skenario: pengujian jangkauan luar ruangan, pengujian jangkauan dalam ruangan, dan pengujian stabilitas pengiriman selama 21 jam. Proses pengujian IoT didokumentasikan pada Lampiran 8, sementara rincian tabel log hasil pengujian jaringan secara lengkap diarsipkan pada repositori penelitian ((Aksa, 2026); lihat Lampiran 9).


3.6.1 Pengujian Jaringan Luar Ruangan

Pengujian transmisi data pada kondisi luar ruangan dilakukan tanpa adanya hambatan fisik yang menghalangi antara perangkat pengirim dan penerima. Pengujian ini bertujuan untuk mengetahui kekuatan sinyal atau Received Signal Strength Indicator (RSSI) pada berbagai jarak pancar, sebagaimana ditunjukkan pada Gambar 29.



Gambar 29. Komparasi pengujian jangkauan jaringan luar ruangan

Berdasarkan Gambar 29, pola penurunan kekuatan sinyal (RSSI) selaras dengan tren pada literatur pembandingan. Pada jarak ukur 25 meter, nilai RSSI instrumen tercatat sebesar -84 dBm, yang menunjukkan deviasi pelemahan dari penelitian referensi Kolcu & Doruk (2026) yang berada pada angka -68 dBm. Pengujian selanjutnya dilakukan untuk mengukur pengaruh RSSI tersebut terhadap nilai latensi waktu pengiriman data. Komparasi antara latensi dan RSSI di luar ruangan divisualisasikan pada Gambar 30.




Gambar 30. Pengujian jangkauan jaringan luar ruangan

Gambar 30 menunjukkan bahwa nilai latensi berada pada rentang konstan di bawah 30 ms untuk jarak transmisi 0 hingga 10 meter. Latensi meningkat seiring bertambahnya jarak transmisi, di mana pada titik terjauh 25 sampai 30 meter dengan kekuatan RSSI -84 dBm, waktu tunda transmisi mencapai 252,21 ms. Berdasarkan standar International Telecommunication Union (2011), nilai latensi maksimal tersebut berada dalam batas yang diizinkan dan diklasifikasikan ke dalam kategori kualitas layanan QoS Class 1 (≤ 400 ms).


3.6.2 Pengujian Jaringan Dalam Ruangan

Pengujian dalam ruangan dilakukan pada rentang jarak 0 hingga 8 meter untuk menguji transmisi data dengan adanya hambatan fisik seperti dinding beton, meja dan furnitur atau benda benda lainnya. Perbandingan RSSI terhadap jarak dan dinding penghalang ini ditunjukkan pada Gambar 31.



Gambar 31. Komparasi pengujian jangkauan jaringan dalam ruangan

Berdasarkan Gambar 31, RSSI alat terukur secara konsisten berada di bawah kurva literatur pembandingan Gaona Juárez et al. (2025) pada seluruh titik pengujian. Sebagai komparasi, pada titik jarak 1 meter, instrumen prototipe merekam nilai RSSI sebesar -59,35 dBm, sedangkan alat di literatur mencatatkan kekuatan sinyal sebesar -28 dBm. Meskipun terdapat perbedaan level sinyal, kedua kurva secara umum tetap memperlihatkan tren pelemahan kekuatan transmisi yang berbanding lurus dengan penambahan jarak. Selanjutnya, dilakukan pengujian untuk melihat hubungan antara RSSI akibat halangan fisik tersebut terhadap latensi. Hubungan ini direpresentasikan sebagaimana terlihat pada Gambar 32.




Gambar 32. Pengujian jangkauan jaringan dalam ruangan

Berdasarkan Gambar 32, hasil pengujian merekam pelemahan RSSI pada rentang -51 dBm hingga -72 dBm. Kendati mengalami redaman sinyal yang cukup besar, alat mampu mempertahankan rentang nilai latensi antara 4 ms hingga 24 ms secara konsisten tanpa adanya penambahan latensi.

3.6.3 Stabilitas Jaringan

Pengujian stabilitas jaringan dilakukan selama 21 jam yang dibagi menjadi 8 titik pengamatan dengan interval 3 jam. Parameter evaluasi mencakup latensi, variasi waktu tunda (jitter), dan tingkat kehilangan paket (*packet loss*) yang merujuk secara langsung pada standar International Telecommunication Union, (2011). Hasil pengujian tersebut divisualisasikan pada Gambar 33.



Gambar 33. Stabilitas jaringan 21 jam

Berdasarkan Gambar 33, parameter jitter tercatat secara konsisten di bawah angka 10 ms pada seluruh sesi pengujian. Nilai ini memenuhi kriteria QoS Class 0 yang menetapkan batas toleransi jitter sebesar ≤ 50 ms. Pada parameter latensi, waktu tunda pengiriman data dengan nilai puncak sebesar 103 ms. Berdasarkan klasifikasi standar ITU-T, nilai tersebut menempatkan performa latensi jaringan pada kategori QoS Class 1 (≤ 400 ms). Pada parameter kehilangan paket, tercatat sebesar 0% pada mayoritas durasi pengujian. Sebuah anomali terekam pada sesi pengamatan pukul 21.00 dengan tingkat kehilangan paket mencapai 2,06%. Peningkatan *packet loss* tersebut merupakan fenomena wajar yang diakibatkan oleh penumpukan antrean trafik pada router penyedia layanan internet saat periode sibuk lalu lintas jaringan (Kurose & Ross, 2017).

Secara keseluruhan, rangkaian pengujian menunjukkan bahwa alat yang dirancang telah mampu beroperasi, mulai dari tahap akuisisi sinyal, pemrosesan data, hingga transmisi dan pemantauan berbasis IoT. Penggunaan perangkat keras dengan kanal EEG dan EKG berhasil menghasilkan fitur gabungan berupa PSD dan HRV yang dapat digunakan sebagai masukan model klasifikasi. Pemrosesan data menggunakan algoritma SVM dengan kernel RBF mampu membentuk batas keputusan nonlinear untuk membedakan subjek bergejala dan tidak bergejala depresi, namun pengaruh data pencilaan dan anomali sinyal tetap perlu dianalisis melalui tahap prapemrosesan dan evaluasi model. Model AI menghasilkan presisi sebesar 90,91% dan spesifisitas sebesar 90,00%, sehingga prototipe ini berpotensi sebagai alat bantu skrining awal gejala depresi, bukan sebagai alat diagnosis klinis.

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan hasil penelitian dapat disimpulkan bahwa:

1. Sistem portabel penguat biosinyal EEG dan EKG telah berhasil dirancang, dibangun, dan diimplementasikan secara simultan. Hasil pengujian menunjukkan akurasi pengukuran denyut jantung sebesar 98,92%, interval R-R sebesar 99,99%, rentang SNR EEG sebesar 6,10–19,68 dB, rentang SNR EKG sebesar 27,17–44,24 dB, serta daya tahan baterai selama 3 jam 22 menit.
2. Sistem pemantauan data fisiologis berbasis IoT telah berhasil dibangun dan mampu mentransmisikan data EEG dan EKG ke server AWS EC2 secara *real-time*. Hasil pengujian QoS menunjukkan bahwa latensi, jitter, dan *packet loss* berada pada kategori baik sehingga sistem layak digunakan untuk pemantauan jarak jauh.
3. Model SVM telah berhasil dibangun dan diuji untuk klasifikasi gejala depresi berdasarkan skor BDI-II. Hasil terbaik diperoleh pada skenario mata terbuka dengan gabungan fitur PSD dan HRV menggunakan kernel RBF, dengan akurasi 76,00%, presisi 90,91%, sensitivitas 66,67%, spesifisitas 90,00%, dan AUC 0,77. Hasil ini menunjukkan bahwa model SVM berpotensi digunakan sebagai alat bantu skrining awal gejala depresi, tetapi masih memerlukan pengujian lanjutan.

DAFTAR PUSTAKA

- Abbas, Q., Celebi, M. E., AlBalawi, T., & Daadaa, Y. (2024). Brain and Heart Rate Variability Patterns Recognition for Depression Classification of Mental Health Disorder. *International Journal of Advanced Computer Science and Applications*, 15(7). <https://doi.org/10.14569/IJACSA.2024.0150784>
- Aksa, A. (2026). *Rancang Bangun Sistem Pemantauan Gejala Depresi Berbasis Sinyal EEG-EKG, Internet of Things, dan Support Vector Machine*. <https://doi.org/10.5281/ZENODO.21526497>
- Amrinsani, F., Wakidi, L. F., Suryanta, M. D. P., Wulandari, D. T., & Sadiq, M. T. (2022). Detection Signal Electromyography using Dry Electrode and Disposable Electrodes on the Upper Extremity when Lifting Weights. *Indonesian Journal of Electronics, Electromedical Engineering, and Medical Informatics*, 4(4), 123–130. <https://doi.org/10.35882/ijeeemi.v4i4.252>
- Boby, K., & Veerasingam, S. (2025). Depression diagnosis: EEG-based cognitive biomarkers and machine learning. *Behavioural Brain Research*, 478, 115325. <https://doi.org/10.1016/j.bbr.2024.115325>
- Byun, S., Kim, A. Y., Jang, E. H., Kim, S., Choi, K. W., Yu, H. Y., & Jeon, H. J. (2019). Detection of major depressive disorder from linear and nonlinear heart rate variability features during mental task protocol. *Computers in Biology and Medicine*, 112, 103381. <https://doi.org/10.1016/j.compbiomed.2019.103381>
- Chang, L.-H., Huang, M.-H., & Lin, I.-M. (2024). Developing a Five-Minute Normative Database of Heart Rate Variability for Diagnosing Cardiac Autonomic Dysregulation for Patients with Major Depressive Disorder. *Sensors*, 24(12), 4003. <https://doi.org/10.3390/s24124003>
- Chapra, S. C., & Canale, R. P. (2010). *Numerical methods for engineers* (6th ed., internat. ed). McGraw-Hill Higher Education.
- Chen, S., Cheng, M., Fang, X., Tang, Z., Wang, X., & Guan, N. (2026). Sleep state is superior to resting state for heart rate variability assessment in major depressive disorder. *Acta Neuropsychiatrica*, 38, e22. <https://doi.org/10.1017/neu.2026.10064>
- Clark, J. W. (2020). *Medical instrumentation: Application and design* (J. G. Webster & A. J. Nimunkar, Eds.; Fifth edition). Wiley.
- Ehrhardt, N. M., Niehoff, C., Oßwald, A.-C., Antonenko, D., Lucchese, G., & Fleischmann, R. (2024). Comparison of dry and wet electroencephalography for the assessment of cognitive evoked potentials and sensor-level connectivity. *Frontiers in Neuroscience*, 18, 1441799. <https://doi.org/10.3389/fnins.2024.1441799>

- Espressif Systems. (2025). *ESP32-S3-WROOM-1 ESP32-S3-WROOM-1U Datasheet* (V1.7). Espressif Systems. https://www.espressif.com/documentation/esp32-s3-wroom-1_wroom-1u_datasheet_en.pdf
- Faadhilah Afif, N., Harke Pratama, S., Haryanto, F., Nurul Khotimah, S., & Suprijadi. (2020). Comparison of Wet and Dry EEG Electrodes Based On Brain Signals Characterization In Temporal and Anterior Frontal Areas Using Audio Stimulation. *Journal of Physics: Conference Series*, 1505(1), 012069. <https://doi.org/10.1088/1742-6596/1505/1/012069>
- G, K., K P, I., Hasin A, J., M, L. F. J., Siluvai, S., & G, K. (2025). Support Vector Machines: A Literature Review on Their Application in Analyzing Mass Data for Public Health. *Cureus*. <https://doi.org/10.7759/cureus.77169>
- Gaona Juárez, R., García-Barrientos, A., Acosta-Elias, J., Stevens-Navarro, E., Galván, C. G., Palavicini, A., & Monroy Cruz, E. (2025). Design and Implementation of an Indoor Localization System Based on RSSI in IEEE 802.11ax. *Applied Sciences*, 15(5), 2620. <https://doi.org/10.3390/app15052620>
- García-Batista, Z. E., Guerra-Peña, K., Cano-Vindel, A., Herrera-Martínez, S. X., & Medrano, L. A. (2018). Validity and reliability of the Beck Depression Inventory (BDI-II) in general and hospital population of Dominican Republic. *PLOS ONE*, 13(6), e0199750. <https://doi.org/10.1371/journal.pone.0199750>
- Ginting, H., Näring, G., Van Der Veld, W. M., Srisayekti, W., & Becker, E. S. (2013). Validating the Beck Depression Inventory-II in Indonesia's general population and coronary heart disease patients. *International Journal of Clinical and Health Psychology*, 13(3), 235–242. [https://doi.org/10.1016/S1697-2600\(13\)70028-0](https://doi.org/10.1016/S1697-2600(13)70028-0)
- Hartmann, R., Schmidt, F. M., Sander, C., & Hegerl, U. (2019). Heart Rate Variability as Indicator of Clinical State in Depression. *Frontiers in Psychiatry*, 9, 735. <https://doi.org/10.3389/fpsy.2018.00735>
- International Telecommunication Union. (2011). *Network performance objectives for IP-based services* (Recommendation ITU-T Y.1541). ITU-T.
- Kementerian Kesehatan RI. (2023). *Laporan Survei Kesehatan Indonesia (SKI) 2023 Dalam Angka*. Kementerian Kesehatan RI.
- Kolcu, C. A., & Doruk, R. Ö. (2026). Comparison of Distance and Physical Obstacle Effects on Real-Time Data Transmission Using Esp32 and LoRa. *Journal of Scientific Technology and Engineering Research*, (1). <https://doi.org/10.53525/jster.1892489>
- Kurose, J. F., & Ross, K. W. (2017). *Computer networking: A top-down approach* (7. edition). Pearson Education.




- Li, B., Guo, S., Xu, H., Zhou, Y., Zhang, M., Wang, J., Chen, Y., Chen, H., Song, J., & Tan, S. (2024). Abnormal circadian rhythm of heart rate variability and their association with symptoms in patients with major depressive disorder. *Journal of Affective Disorders*, 362, 14–23. <https://doi.org/10.1016/j.jad.2024.06.102>
- Li, L., Wang, X., Li, J., & Zhao, Y. (2024). An EEG-based marker of functional connectivity: Detection of major depressive disorder. *Cognitive Neurodynamics*, 18(4), 1671–1687. <https://doi.org/10.1007/s11571-023-10041-5>
- Liu, S., Cui, Y., & Chen, M. (2025). Heart rate variability: A multidimensional perspective from physiological marker to brain-heart axis disorders prediction. *Frontiers in Cardiovascular Medicine*, 12, 1630668. <https://doi.org/10.3389/fcvm.2025.1630668>
- Liu, X., Zhang, H., Cui, Y., Zhao, T., Wang, B., Xie, X., Liang, S., Sha, S., Yan, Y., Zhao, X., & Zhang, L. (2024). EEG-based major depressive disorder recognition by neural oscillation and asymmetry. *Frontiers in Neuroscience*, 18, 1362111. <https://doi.org/10.3389/fnins.2024.1362111>
- Luo, H., Li, H., Tao, W., Yang, Y., leong, C.-I., & Wan, F. (2025). A Portable and Affordable Four-Channel EEG System for Emotion Recognition with Self-Supervised Feature Learning. *Mathematics*, 13(10), 1608. <https://doi.org/10.3390/math13101608>
- Malvino, A. P., Bates, D. J., & Hoppe, P. E. (2021). *Electronic principles* (Ninth edition, international student edition). McGraw-Hill.
- Mamee, T., Manorost, P., Chamroon, C., & Thunsiri, K. (2023). Comparative Analysis of AD8232 and BioAmp EXG Pill Analog Front-End Devices in ECG Signal Processing. *2023 IEEE 11th Conference on Systems, Process & Control (ICSPC)*, 252–257. <https://doi.org/10.1109/ICSPC59664.2023.10420266>
- Mitsukura, Y., Tazawa, Y., Nakamura, R., Sumali, B., Nakagawa, T., Hori, S., Mimura, M., & Kishimoto, T. (2022). Characteristics of single-channel electroencephalogram in depression during conversation with noise reduction technology. *PLOS ONE*, 17(4), e0266518. <https://doi.org/10.1371/journal.pone.0266518>
- Mumtaz, W., Ali, S. S. A., Yasin, M. A. M., & Malik, A. S. (2018). A machine learning framework involving EEG-based functional connectivity to diagnose major depressive disorder (MDD). *Medical & Biological Engineering & Computing*, 56(2), 233–246. <https://doi.org/10.1007/s11517-017-1685-z>
- Mumtaz, W., & Qayyum, A. (2019). A deep learning framework for automatic diagnosis of unipolar depression. *International Journal of Medical Informatics*, 132, 103983. <https://doi.org/10.1016/j.ijmedinf.2019.103983>

- Nejati, S., Ariai, N., Björkelund, C., Skoglund, I., Petersson, E.-L., Augustsson, P., Hange, D., & Svenningsson, I. (2020). Correspondence Between the Neuropsychiatric Interview M.I.N.I. and the BDI-II and MADRS-S Self-Rating Instruments as Diagnostic Tools in Primary Care Patients with Depression. *International Journal of General Medicine*, Volume 13, 177–183. <https://doi.org/10.2147/IJGM.S243150>
- Tan, L. (2008). *Digital signal processing: Fundamentals and applications*. Academic Press.
- Tan, Y., Zhou, M., Wang, J., Song, Y., Li, Q., Huang, Z., Li, Y., Wang, Y., Zhang, J., Quan, W., Tian, J., Yin, L., Dong, W., & Liu, B. (2025). Heart rate variability in subthreshold depression and major depressive disorder. *Journal of Affective Disorders*, 373, 306–313. <https://doi.org/10.1016/j.jad.2025.01.003>
- Texas Instruments. (2021). *TL07xx Low-Noise FET-Input Operational Amplifiers* (No. SLOS080S). Texas Instruments. <https://www.ti.com/document-viewer/tl074/datasheet>
- Texas Instruments. (2024). *ADS111x Ultra-Small, Low-Power, I2C-Compatible, 860SPS, 16-Bit ADCs with Internal Reference, Oscillator, and Programmable Comparator* (No. SBAS444E). Texas Instruments. <https://www.ti.com/document-viewer/ads1115/datasheet>
- Tran, V.-K., Thai, B.-T., Pham, H., Nguyen, V.-K., & Nguyen, V.-K. (2024). A Proposed Approach to Utilizing Esp32 Microcontroller for Data Acquisition. *Journal of Engineering and Technological Sciences*, 56(04), 474–488. <https://doi.org/10.5614/j.eng.technol.sci.2024.56.4.4>
- Van Assche, E., & Schiweck, C. (2026). Resting State Heart Rate Variability in Depression: An Introductory Narrative Review of Cross-Sectional and Longitudinal Evidence. *Journal of Personalized Medicine*, 16(2), 87. <https://doi.org/10.3390/jpm16020087>
- Warmenhoven, F., Van Rijswijk, E., Engels, Y., Kan, C., Prins, J., Van Weel, C., & Vissers, K. (2012). The Beck Depression Inventory (BDI-II) and a single screening question as screening tools for depressive disorder in Dutch advanced cancer patients. *Supportive Care in Cancer*, 20(2), 319–324. <https://doi.org/10.1007/s00520-010-1082-8>
- Yang, C.-Y., & Chen, Y.-Z. (2024). Support vector machine classification of patients with depression based on resting-state electroencephalography. *Asian Biomedicine*, 18(5), 212–223. <https://doi.org/10.2478/abm-2024-0029>

advanced cancer patients. *Supportive Care in Cancer*, 20(2), 319–324. <https://doi.org/10.1007/s00520-010-1082-8>

Yang, C.-Y., & Chen, Y.-Z. (2024). Support vector machine classification of patients with depression based on resting-state electroencephalography. *Asian Biomedicine*, 18(5), 212–223. <https://doi.org/10.2478/abm-2024-0029>

Lampiran 1. Peralatan Penelitian

No.	Peralatan & Bahan	Fungsi
1	MCU ESP32-S3 	Mengendalikan operasi sistem, menjalankan komputasi dual-core (termasuk FFT dan deteksi interval R-R), serta mentransmisikan data ke server secara real-time via Wi-Fi.
2	IC Op-Amp TL074 	Menguatkan amplitudo sinyal biopotensial dan menyaring derau frekuensi gangguan melalui konfigurasi filter analog.
3	Modul ADC ADS1115 	Mengonversi sinyal analog biopotensial dari penguat menjadi data digital beresolusi 16-bit.
4	Resistor dan Kapasitor 	Mengatur besaran nilai penguatan (gain) dan menentukan titik frekuensi cut-off pada rangkaian filter analog.

Baterai Ion Litium 18650 (3,7 V)


5



Menyuplai daya listrik utama agar instrumen dapat beroperasi dan digunakan secara portabel.

Modul Charger TP4056


6



Mengisi ulang daya baterai dan memproteksi rangkaian dari pengisian serta pengosongan daya berlebih.

Modul DC-DC Step-Up


7



Menaikkan dan menstabilkan tegangan dari baterai menjadi bus daya utama sebesar 6 V.

Modul Step-Up Simetris (± 12 V)


8



Menyuplai tegangan ganda (+12 V dan -12 V) yang dibutuhkan untuk operasional penguat IC TL074.

Regulator LDO 3,3 V

9



Menurunkan dan menstabilkan tegangan suplai khusus untuk operasional ESP32-S3 dan modul ADC.

Elektroda Basah Ag/AgCl

10



Menyadap sinyal biopotensial aktivitas kelistrikan otak (EEG) dan jantung (EKG) pada permukaan kulit subjek.

Kabel Elektroda dan Jack 3,5 mm



11

Menghubungkan sensor elektroda dari tubuh subjek secara presisi ke modul rangkaian penguat.

Kuesioner BDI-II

12

Selengkapnya pada Lampiran 2

Bertindak sebagai instrumen psikologis laporan diri untuk menentukan label tingkat keparahan gejala depresi pada subjek.

Multimeter Digital



13

Mengukur nilai tegangan, hambatan, arus, dan memastikan kontinuitas jalur kelistrikan pada PCB.

Signal Generator dan Osiloskop



14

Membangkitkan sinyal uji analog.

Mesin EEG, EKG, Osiloskop digital dan Pulse Oximeter

15

Selengkapnya pada Lampiran 8

Berfungsi sebagai instrumen standar medis untuk proses kalibrasi, memvalidasi respons frekuensi serta nilai penguatan pada tahap kalibrasi dan validasi akurasi alat.

PCB (FR4 dan Dot Matrix)

16



Menyediakan jalur kelistrikan terstruktur (layout) untuk integrasi dan pemasangan seluruh komponen elektronika.

Kabel Jumper

17



Menghubungkan jalur interkoneksi sinyal dan daya antar-modul pada papan purwarupa.

Peralatan Solder dan Timah

18



Merekatkan kaki-kaki komponen elektronika secara konduktif dan permanen ke jalur tembaga PCB.

Sakelar dan Kotak Pelindung (Casing)

19



Sakelar berfungsi sebagai pemutus arus daya, sedangkan kotak pelindung mengamankan rangkaian fisik dari gangguan luar.



Peralatan Perakitan Mekanik



20

Menunjang proses perakitan komponen fisik (terdiri atas pinset, cutter, tang potong, dan lain-lain).

Komputer




21

Menulis kode program mikrokontroler, merancang tata letak PCB, dan mengeksekusi pelatihan model kecerdasan buatan.

22 Jaringan Internet


Menyediakan jalur komunikasi nirkabel untuk transmisi data real-time dari perangkat perangkat ke server.

Arduino IDE dan KiCad




23

Arduino IDE digunakan untuk menulis firmware (C/C++), sedangkan KiCad untuk merancang desain layout PCB.




AWS EC2, Node.js, dan Python



24

AWS EC2 dan Node.js meng-hosting server IoT, sedangkan Python mengeksekusi algoritma Support Vector Machine (SVM).



Lampiran 2. BDI-II

BDI II

Nama:		Status Marital: Menikah/Belum Menikah
Usia:	Agama:	Jenis Kelamin: Laki-laki/Perempuan
Pekerjaan:		Pendidikan:

Petunjuk : Kuesioner berikut ini terdiri dari 21 kelompok pernyataan. Mohon setiap kelompok pernyataan dibaca dengan cermat, setelah itu di dalam setiap kelompok pilih satu dari pernyataan yang paling menggambarkan perasaan anda selama 2 minggu terakhir, termasuk hari ini. Lingkarilah angka di samping pernyataan yang anda pilih. Apabila di dalam satu kelompok terdapat beberapa pernyataan yang terasa sama, lingkarilah angka yang paling tinggi dari pernyataan-pernyataan yang terasa sama tersebut. Pastikan bahwa anda tidak memilih lebih dari satu pernyataan di dalam setiap kelompok, termasuk pernyataan 16 (Perubahan pola tidur) dan pernyataan 18 (Perubahan selera makan).

1	Kesedihan	2	Pesimis	3	Kegagalan masa lalu
0	Saya tidak merasa sedih.	0	Saya tidak meragukan masa depan saya.	0	Saya tidak merasa gagal.
1	Saya sering kali merasa sedih.	1	Saya merasa lebih meragukan masa depan saya dibanding biasanya.	1	Saya telah gagal lebih dari yang seharusnya.
2	Saya merasa sedih sepanjang waktu.	2	Saya merasa segala sesuatu tidak berjalan dengan baik bagi saya.	2	Saya melakukan banyak kegagalan di masa lalu.
3	Saya merasa sangat tidak bahagia atau sedih sampai tidak tertahankan.	3	Saya merasa masa depan saya tidak ada harapan dan akan semakin buruk.	3	Saya merasa gagal sama sekali (betul-betul gagal).

4	Kehilangan gairah	5	Perasaan bersalah	6	Perasaan dihukum
0	Saya mendapatkan kesenangan dari hal-hal yang saya lakukan.	0	Saya sama sekali tidak merasa bersalah.	0	Saya tidak merasa bahwa saya sedang dihukum.
1	Saya tidak menikmati sesuatu seperti biasanya.	1	Saya merasa bersalah atas banyak hal yang telah atau seharusnya saya lakukan.	1	Saya merasa bahwa mungkin saya akan dihukum.
2	Saya hanya mendapatkan sangat sedikit kesenangan dari hal-hal yang biasanya bisa saya nikmati.	2	Saya sering merasa bersalah.	2	Saya yakin bahwa saya akan dihukum.
3	Saya tidak mendapatkan kesenangan sama sekali dari hal-hal yang biasanya bisa saya nikmati.	3	Saya merasa bersalah setiap saat.	3	Saya merasa bahwa saya sedang dihukum.

7	Tidak menyukai diri sendiri	8	Mengkritik diri sendiri	9	Pikiran/keinginan bunuh diri
0	Saya tidak merasa kecewa pada diri sendiri.	0	Saya tidak mengkritik atau menyalahkan diri sendiri lebih dari biasanya.	0	Saya tidak berpikir untuk bunuh diri.
1	Saya kehilangan kepercayaan pada diri sendiri.	1	Saya mengkritik diri sendiri lebih dari biasanya.	1	Saya berpikir untuk bunuh diri, tetapi hal itu tidak akan saya lakukan.
2	Saya merasa kecewa pada diri sendiri.	2	Saya mengkritik diri sendiri atas semua kesalahan yang saya lakukan.	2	Saya ingin bunuh diri.
3	Saya benci pada diri sendiri.	3	Saya menyalahkan diri sendiri untuk semua hal-hal buruk yang terjadi.	3	Saya akan bunuh diri seandainya ada kesempatan.

10 Menangis	11 Gelisah	12 Kehilangan minat
0 Saya tidak menangis lagi seperti biasanya.	0 Saya tidak lagi merasa gelisah atau tertekan dibandingkan biasanya.	0 Saya tidak kehilangan minat untuk berelasi dengan orang lain atau melakukan aktivitas.
1 Saya lebih sering menangis dibanding biasanya.	1 Saya merasa lebih mudah gelisah atau tertekan dibanding biasanya.	1 Saya kurang berminat untuk berelasi dengan orang lain atau terhadap sesuatu dibandingkan biasanya.
2 Saya menangis bahkan untuk masalah masalah kecil.	2 Saya sangat tertekan dan gelisah sampai sulit untuk berdiam diri.	2 Saya kehilangan hampir seluruh minat saya untuk berelasi dengan orang lain atau terhadap sesuatu.
3 Rasanya saya ingin sekali menangis tetapi tidak bisa.	3 Saya sangat gelisah sehingga harus senantiasa bergerak atau melakukan sesuatu.	3 Saya tidak berminat akan apapun.

13 Sulit mengambil keputusan	14 Merasa tidak layak	15 Kehilangan tenaga (semangat)
0 Saya dapat mengambil keputusan sebagaimana yang biasanya saya lakukan.	0 Saya merasa layak.	0 Saya memiliki tenaga (semangat) seperti biasanya.
1 Saya agak sulit mengambil keputusan dibanding biasanya.	1 Saya merasa tidak layak dan tidak berguna dibandingkan biasanya.	1 Saya memiliki tenaga lebih sedikit dibanding yang seharusnya saya miliki.
2 Saya lebih banyak mengalami kesulitan dalam mengambil keputusan dibanding biasanya.	2 Saya merasa lebih tidak layak dibanding orang lain.	2 Saya tidak memiliki tenaga yang cukup untuk berbuat banyak.
3 Saya sangat mengalami kesulitan setiap kali mengambil keputusan.	3 Saya merasa sama sekali tidak layak.	3 Saya tidak memiliki tenaga yang cukup untuk melakukan apapun.

16 Perubahan pola tidur	17 Mudah marah	18 Perubahan selera makan
0 Saya tidak mengalami perubahan apapun dalam pola tidur saya.	0 Saya tidak lebih mudah marah seperti biasanya.	0 Selera makan saya tidak berubah (tidak lebih buruk) dari biasanya.
1a Saya tidur lebih dari biasanya. 1b Saya tidur kurang dari biasanya.	1 Saya lebih mudah marah dibanding biasanya.	1a Selera makan saya kurang dari biasanya. 1b Selera makan saya lebih dari biasanya.
2a Saya tidur jauh lebih lama dari biasanya. 2b Saya tidur sangat kurang dari biasanya.	2 Saya jauh lebih mudah marah dibanding biasanya.	2a Selera makan saya sangat kurang dibanding biasanya. 2b Selera makan saya sangat lebih dibanding biasanya.
3a Saya tidur hampir sepanjang hari. 3b Saya bangun 1-2 jam lebih awal dan tidak dapat tidur kembali.	3 Saya mudah marah sepanjang waktu.	3a Saya tidak punya selera makan sama sekali. 3b Saya ingin makan setiap waktu.

19 Sulit berkonsentrasi	20 Capek atau Kelelahan	21 Kehilangan gairah seksual
0 Saya mampu berkonsentrasi seperti biasanya.	0 Saya tidak lebih capek atau lelah dibanding biasanya.	0 Saya tidak melihat adanya perubahan pada gairah seksual saya.
1 Saya tidak mampu berkonsentrasi seperti biasanya.	1 Saya lebih mudah capek atau lelah dari biasanya.	1 Gairah seksual saya berkurang, tidak seperti biasanya.
2 Saya sangat sulit untuk tetap memusatkan pikiran terhadap sesuatu dalam jangka waktu yang panjang.	2 Saya merasa capek atau lelah untuk melakukan banyak hal yang biasanya saya lakukan.	2 Saya menjadi sangat kurang berminat pada aktivitas seksual saat ini.
3 Saya merasa saya tidak mampu berkonsentrasi dalam semua hal.	3 Saya terlalu capek atau lelah untuk melakukan hampir semua hal yang biasanya saya lakukan.	3 Gairah seksual saya hilang sama sekali.

Total Skor:	
-------------	--

Lampiran 3. Informed Consent

FORMULIR PERSETUJUAN SETELAH PENJELASAN (PSP) (INFORMED CONSENT)

Selamat pagi Bapak / Ibu / Saudara(i), saya Ahmad Aksa, bermaksud untuk melakukan penelitian dengan judul "Rancang Bangun Sistem

EEG dan EKG untuk Pemantauan Depresi Berbasis IoT dan AI".

Tujuan dan Manfaat Penelitian: Tujuan penelitian ini adalah untuk menguji alat prototipe yang saya rancang agar dapat memantau indikasi gejala depresi melalui sinyal aktivitas listrik otak (EEG) dan variabilitas detak jantung (EKG) secara objektif. Manfaat penelitian ini diharapkan dapat menghasilkan alat skrining awal yang murah dan mudah diakses untuk kesehatan mental masyarakat.

Prosedur Penelitian: Pada penelitian ini, partisipan akan dikelompokkan menjadi dua kategori berdasarkan hasil skrining kuesioner awal, yaitu kelompok kontrol (sehat) dan kelompok dengan indikasi gejala. Tidak ada perlakuan obat-obatan atau tindakan invasif (pembedahan/suntikan) dalam penelitian ini.

Jika Anda bersedia, prosedur yang akan dilakukan adalah: Pembersihan area kulit dahi dan dada menggunakan alkohol swab. Pemasangan sensor (elektroda tempel) pada dahi dan dada atau tangan dan kaki. Perekaman data sinyal selama ± 10 menit dalam kondisi duduk tenang/rileks.

Risiko dan Efek Samping: Penelitian ini menggunakan alat non-invasif dengan tegangan rendah (baterai) yang aman. Risiko yang mungkin timbul hanyalah ketidaknyamanan ringan seperti rasa dingin saat diusap alkohol atau rasa lengket pada kulit akibat gel elektroda. Peneliti akan menyediakan tisu basah/alkohol untuk membersihkan sisa gel setelah prosedur selesai.

Kesukarelaan: Keikutsertaan Anda dalam penelitian ini bersifat sukarela. Anda berhak menolak atau mengundurkan diri kapan saja tanpa sanksi apapun. Jika Anda setuju, diharapkan mengikuti prosedur perekaman selama 10 menit tersebut sampai selesai agar data dapat teranalisis.

Kerahasiaan dan Pembiayaan: Seluruh biaya penelitian ditanggung oleh peneliti. Identitas dan data hasil rekaman Anda akan dijaga kerahasiaannya dan hanya digunakan untuk keperluan analisis skripsi. Sebagai tanda terima kasih, peneliti akan memberikan kompensasi berupa uang transport/snack sekadarnya atas waktu yang Anda luangkan.

Jika ada hal yang ingin ditanyakan mengenai penelitian ini dapat menghubungi peneliti melalui kontak di bawah ini.

Identitas Peneliti

- Nama : Ahmad Aksa
- Alamat : BTP Blok H Jln. Kerukunan Timur 1 No. 73, Makassar
- No Hp : 085155262922

Lampiran 4. Perstujuan Etik



**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN
RISET, DAN TEKNOLOGI
UNIVERSITAS HASANUDDIN
FAKULTAS KESEHATAN MASYARAKAT**

*Jln. Perintis Kemerdekaan Km.10 Makassar 90245, Telp.(0411) 585658,
E-mail : fkm.unhas@gmail.com, website: <https://fkm.unhas.ac.id/>*

REKOMENDASI PERSETUJUAN ETIK

Nomor : 299/UN4.14.1/TP.01.02/2026

Tanggal: 22 Januari 2026

Dengan ini Menyatakan bahwa Protokol dan Dokumen yang Berhubungan dengan Protokol berikut ini telah mendapatkan Persetujuan Etik :

No. Protokol	13126091002	No. Sponsor Protokol	
Peneliti Utama	Ahmad Aksa	Sponsor	Pribadi
Judul Peneliti	Rancang Bangun Sistem EEG dan EKG untuk Pemantauan Depresi Berbasis IoT dan AI		
No.Versi Protokol	1	Tanggal Versi	22 Januari 2026
No.Versi PSP	1	Tanggal Versi	22 Januari 2026
Tempat Penelitian	1. Laboratorium Elektronika dan Instrumentasi Universitas Hasanuddin. 2. Rumah Sakit Universitas Hasanuddin (RSUH). 3. Fakultas Kesehatan Masyarakat Universitas Hasanuddin (FKM).		
Judul Review	☒ Exempted ☐ Expedited ☐ Fullboard	Masa Berlaku 22 Januari 2026 Sampai 22 Januari 2027	Frekuensi review lanjutan
Ketua Komisi Etik Penelitian	Nama : Prof.dr.Veni Hadju,M.Sc,Ph.D	Tanda tangan	Tanggal 22 Januari 2026
Sekretaris komisi Etik Penelitian	Nama : Dr. Wahiduddin, SKM.,M.Kes	Tanda tangan	Tanggal 22 Januari 2026

Kewajiban Peneliti Utama :

1. Menyerahkan Amandemen Protokol untuk persetujuan sebelum di implementasikan
2. Menyerahkan Laporan SAE ke Komisi Etik dalam 24 Jam dan dilengkapi dalam 7 hari dan Laporan SUSAR dalam 72 Jam setelah Peneliti Utama menerima laporan
3. Menyerahkan Laporan Kemajuan (progress report) setiap 6 bulan untuk penelitian resiko tinggi dan setiap setahun untuk penelitian resiko rendah
4. Menyerahkan laporan akhir setelah Penelitian berakhir
5. Melaporkan penyimpangan dari protocol yang disetujui (protocol deviation/violation)
6. Mematuhi semua peraturan yang ditentukan

Lampiran 5. Alat Pembanding

Alat Pembanding	Spesifikasi
	Nama: 16 Channel Digital Electroencephalogram EEG Machine Channel: 16 Highpass: 0.5 Hz Lowpass: 70.0 Hz Sampling freq: 250.0 Hz
	Digital Storage Oscilloscope (DSO) Nama: ATTEN ADS1022CL+ Channels: 2 Bandwidth: 25 MHz Sampling Rate: 500 MSa/s Resolusi: 8-bit
	12 lead ECG Machine Leads: Standar 12 Leads Frekuensi Respons: 0,15-100 Hz Kecepatan 25 mm/sec
	PulseOximeter Nama: Finger Clip Pulse Oximeter Parameter Pengukuran: Pulse Rate Rentang Pengukuran Pulse Rate: 25 bpm - 250 bpm Akurasi Pulse Rate: ± 1 bpm Catu Daya: 3.0V DC

Lampiran 6. Proses Pengujian Alat

a. Pengujian EKG



b. Pengujian EEG




Lampiran 7. Proses Pengujian Alat



Lampiran 8. Pengujian IoT

a. Pengujian Jaringan di dalam Ruangan



b. Pengujian Jaringan di Luar Ruangan



Lampiran 9. Tautan Repositori Data Mentah dan Kode Sumber

Seluruh data mentah, skrip pemrograman, dan dokumentasi perangkat keras pendukung penelitian ini diarsipkan secara terbuka pada repositori digital Zenodo dan dapat diakses melalui tautan DOI (Digital Object Identifier) berikut:

Tautan Repositori: <https://doi.org/10.5281/zenodo.21526497>

Adapun rincian berkas yang terdapat di dalam repositori tersebut adalah sebagai berikut:

1. Dataset.zip : Berisi data mentah (raw dataset) parameter fisiologis dari 25 subjek penelitian pada skenario mata terbuka dan mata tertutup.
2. Web.zip : Berisi keseluruhan skrip firmware ESP32-S3 (C++), skrip server berbasis Node.js, dan antarmuka dasbor web (front-end).
3. svm.zip : Berisi skrip Python untuk ekstraksi fitur dan pelatihan model Support Vector Machine (SVM) beserta file model terekspor.
4. Uji_exg.zip : Berisi tabel data pengukuran dan perhitungan kalibrasi instrumen penguat EEG dan EKG terhadap alat standar medis.
5. Uji_iot.zip : Berisi rekaman data pengujian performa jaringan IoT (latensi, jitter, dan packet loss).
6. EXG_top.png & EXG_bt.png : Dokumentasi desain tata letak PCB (Printed Circuit Board) instrumen tampak atas dan bawah.