

PEMODELAN ROBUST MODIFIED JACKKNIFE RIDGE REGRESSION DENGAN GENERALIZED-M ESTIMATOR PADA DATA TINGKAT PENGANGGURAN TERBUKA DI SULAWESI SELATAN TAHUN 2024



ISNAENI RAMADHANI

H051211015



PROGRAM STUDI STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026

**PEMODELAN *ROBUST MODIFIED JACKKNIFE RIDGE REGRESSION*
DENGAN *GENERALIZED-M ESTIMATOR* PADA DATA TINGKAT
PENGANGGURAN TERBUKA DI SULAWESI SELATAN TAHUN 2024**

**ISNAENI RAMADHANI
H051211015**



**PROGRAM STUDI STATISTIKA
DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PEMODELAN *ROBUST MODIFIED JACKKNIFE RIDGE REGRESSION*
DENGAN *GENERALIZED-M ESTIMATOR* PADA DATA TINGKAT
PENGANGGURAN TERBUKA DI SULAWESI SELATAN TAHUN 2024**

ISNAENI RAMADHANI
H051211015

Skripsi

Sebagai salah satu syarat memperoleh gelar Sarjana Statistika

Program Studi Statistika

pada

**PROGRAM STUDI STATISTIKA
DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PEMODELAN ROBUST MODIFIED JACKKNIFE RIDGE REGRESSION
DENGAN GENERALIZED-M ESTIMATOR PADA DATA TINGKAT
PENGANGGURAN TERBUKA DI SULAWESI SELATAN TAHUN 2024**

yang disusun dan diajukan oleh

ISNAENI RAMADHANI
H051211015

Skripsi

Telah dipertahankan di depan Panitia Ujian Sarjana Statistika pada 13 Juli 2026
dan dinyatakan telah memenuhi syarat kelulusan

pada


Program Studi Statistika
Departemen Statistika
Fakultas Matematika Dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan,
Pembimbing Tugas Akhir



Prof. Dr. Dr. Georgina Maria Tinungki, M.Si
NIP. 19620926 198702 2 001

Mengetahui,
Ketua Program Studi,



Dr. Anna Islamiyati, S.Si., M.Si
NIP. 19770808 200501 2 002

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "*Pemodelan Robust Modified Jackknife Ridge Regression dengan Generalized-M Estimator pada Data Tingkat Pengangguran Terbuka di Sulawesi Selatan Tahun 2024*" adalah benar karya saya dengan arahan dari pembimbing Prof. Dr. Dr. Georgina Maria Tinungki, S.Si., M.Si. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 13 Juli 2026



CC567AOX095309608

Isnaeni Ramadhani
NIM. H051211015

UCAPAN TERIMA KASIH

Puji Syukur penulis panjatkan kepada Allah Subhanahu Wa Ta'ala atas segala limpahan rahmat, karunia dan kasih sayang-Nya sehingga penulis diberikan kekuatan dan kesehatan dalam menyelesaikan skripsi ini. Shalawat serta salam senantiasa tercurah kepada junjungan Nabi Besar Muhammad Shallallahu 'Alaihi Wa Sallam beserta keluarga dan para sahabatnya.

Penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada Ibu **Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.**, selaku dosen pembimbing, atas bimbingan, arahan serta dorongan semangat yang telah diberikan sejak awal proses pengerjaan hingga penyelesaian skripsi ini. Terima kasih kepada ibu **Prof. Dr. Nurtiti Sunusi, S.Si., M.Si.** dan ibu **Sitti Sahriman, S.Si., M.Si.** selaku dosen penguji, atas segala saran serta masukan-masukan membangun yang membangun dalam penyempurnaan skripsi ini. Terima kasih pula kepada **Pimpinan Universitas Hasanuddin, Departemen Statistika, Jajaran Dosen, hingga Staf Departemen Statistika** yang telah memberikan ilmu yang bermanfaat, pengalaman, pelayanan dan berbagai fasilitas selama penulis menempuh pendidikan.

Penghargaan dan rasa terima kasih yang setulus-tulusnya penulis persembahkan kepada kedua orang tua tercinta, Bapak **Sabaruddin** dan Ibu **Sitti Salwiah**, atas segala kasih sayang, doa yang tiada henti, pengorbanan, dukungan moral maupun material, serta kepercayaan yang senantiasa diberikan kepada penulis. Keduanya selalu menjadi sumber kekuatan dan semangat yang telah menemani setiap langkah dan keputusan penulis. Semoga penulis kelak dapat membalas segala cinta, doa, dan pengorbanan yang telah diberikan dengan menjadi pribadi yang membanggakan. Ucapan terima kasih juga penulis sampaikan kepada saudara-saudara tercinta, **Nur Fadhilah, Muh. Zarqawi, dan Ilmi Fayumi**, atas segala perhatian, dukungan, bantuan, serta hiburan yang selalu diberikan kepada penulis.

Penulis juga mengucapkan terima kasih kepada teman terdekat sejak masa SMA, **IKIPI (Ila, Kesa, Ilmi dan Fitri)** yang senantiasa memberikan doa, semangat, serta tempat berbagi hiburan yang benar benar sangat berarti bagi penulis. Terima kasih juga kepada teman teman Statistika Angkatan 2021 yang telah menjadi bagian dari perjalanan akademik penulis sejak awal perkuliahan hingga akhir masa studi. Secara khusus, penulis mengucapkan terima kasih kepada **Ummu, Ummi, Zulfira, Samrina, dan Uchy** atas kebersamaan, dukungan, serta berbagai pengalaman yang telah dilalui bersama selama masa perkuliahan. Ucapan terima kasih juga penulis sampaikan kepada **Nindy, Sumita, dan Salvira** selaku teman seperbimbingan yang senantiasa berproses bersama dan saling mendukung dalam proses penyelesaian skripsi ini. Terakhir, penulis mengucapkan terima kasih kepada diri sendiri yang telah bertahan, terus berusaha, dan tidak menyerah meskipun harus menghadapi berbagai ketakutan, keraguan, dan rasa putus asa selama proses penyusunan skripsi ini.

Penulis menyadari bahwa masih banyak kekurangan dan kesalahan dalam penyusunan skripsi ini. Oleh karena itu, dengan segala kerendahan hati penulis memohon maaf. Akhir kata semoga skripsi ini dapat memberikan manfaat kepada berbagai pihak.

Makassar, 13 Juli 2026


Isnaeni Ramadhani

ABSTRAK

Isnaeni Ramadhani. **Pemodelan *Robust Modified Jackknife Ridge Regression* dengan *Generalized-M Estimator* Pada Data Tingkat Pengangguran Terbuka di Sulawesi Selatan Tahun 2024** (dibimbing oleh Prof. Dr. Dr. Georgina Maria Tinungki, M.Si)

Latar Belakang. Metode Kuadrat Terkecil merupakan metode yang umum digunakan dalam estimasi parameter regresi, namun mengharuskan terpenuhinya asumsi klasik agar menghasilkan estimasi yang andal. Dalam praktiknya, multikolinearitas dan pencilan dapat muncul secara bersamaan sehingga menyebabkan estimasi parameter menjadi tidak stabil dan kurang akurat. Salah satu metode yang mampu mengatasi kedua masalah tersebut adalah Regresi *Robust Modified Jackknife Ridge* dengan *GM-estimator* (*Robust MJRR-GM*), yang menggabungkan MJRR untuk mengatasi multikolinearitas dan *GM-estimator* untuk menangani pencilan. **Tujuan.** Penelitian ini bertujuan untuk membentuk model *Robust MJRR-GM* untuk mengidentifikasi faktor-faktor yang memengaruhi Tingkat Pengangguran Terbuka (TPT) di kabupaten/kota Sulawesi Selatan tahun 2024. **Metode.** Analisis dilakukan terhadap data TPT di kabupaten/kota Sulawesi Selatan tahun 2024. Estimasi parameter diawali menggunakan *GM-estimator* untuk menghasilkan estimasi terbobot yang mengurangi pengaruh pencilan. Hasil estimasi tersebut kemudian digunakan dalam *Modified Jackknife Ridge Regression* (MJRR) untuk mengatasi dampak multikolinearitas, sehingga diperoleh model *Robust MJRR-GM*. Sebagai pendukung evaluasi metode, digunakan pula data simulasi yang dibandingkan berdasarkan karakteristik data TPT. **Hasil.** Model *Robust MJRR-GM* pada data TPT menghasilkan nilai *Adjusted R²* sebesar 85% dan RMSE sebesar 0,129, yang lebih baik dibandingkan model MJRR. Hasil simulasi turut menunjukkan bahwa *Robust MJRR-GM* memberikan peningkatan kinerja yang lebih besar dibandingkan MJRR dalam mengatasi pengaruh pencilan yang lebih kuat. **Kesimpulan.** Hasil menunjukkan bahwa model *Robust MJRR-GM* memberikan kinerja yang lebih baik dibandingkan model MJRR berdasarkan nilai *Adjusted R²* dan RMSE. Berdasarkan hasil pemodelan, variabel yang berpengaruh signifikan terhadap TPT di kabupaten/kota Sulawesi Selatan tahun 2024 meliputi Rasio Gini, Rasio Jenis Kelamin, Umur Harapan Hidup, dan Kepadatan Penduduk.

Kata Kunci: *Robust Modified Jackknife Ridge Regression, Generalized M-Estimator, Multikolinearitas, Pencilan, Tingkat Pengangguran Terbuka.*

ABSTRACT

Isnaeni Ramadhani. **Robust Modified Jackknife Ridge Regression Modeling with Generalized M-Estimator for Open Unemployment Rate Data in South Sulawesi in 2024** (supervised by Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.)

Background. Ordinary Least Squares is the most commonly used method for estimating regression parameter. However, it requires the classical assumptions to be satisfied in order to produce reliable estimates. In practice, multicollinearity and outliers are two problems that may occur simultaneously, resulting in unstable and less accurate parameter estimates. One method capable of addressing these issues is Robust Modified Jackknife Ridge Regression with Generalized M-Estimator (Robust MJRR-GM), which combines MJRR to overcome multicollinearity and GM-estimator to handle outliers. **Objective.** This study aimed to develop a Robust MJRR-GM model to identify the factors affecting the Open Unemployment Rate (OUR) in the regencies and municipalities of South Sulawesi in 2024. **Methods.** The analysis was conducted using OUR data from the regencies and municipalities of South Sulawesi in 2024. Parameter estimation was first performed using the GM-Estimator to obtain weighted estimates that reduced the influence of outliers. These estimates were subsequently incorporated into the Modified Jackknife Ridge Regression (MJRR) to address the effects of multicollinearity, resulting in the Robust MJRR-GM model. Simulation data generated based on the characteristics of the OUR data were also employed to support the evaluation of the proposed method. **Results.** The Robust MJRR-GM model on the OUR data produced an Adjusted R^2 value of 85% and an RMSE of 0,129, which performed better than the MJRR model. Furthermore, the simulation results demonstrated that the Robust MJRR-GM model provided greater performance improvement than the MJRR model in handling data with stronger outlier effects. **Conclusion.** The results showed that the Robust MJRR-GM model outperformed the MJRR model in terms of Adjusted R^2 and RMSE. Based on the fitted model, the variables that significantly affected the OUR in the regencies and municipalities of South Sulawesi in 2024 were the Gini Ratio, Sex Ratio, Life Expectancy, and Population Density.

Keywords: *Robust Modified Jackknife Ridge Regression, Generalized M-Estimator, Multicollinearity, Outliers, Open Unemployment Rate.*

DAFTAR ISI

	Halaman
HALAMAN JUDUL.....	i
HALAMAN PENGAJUAN	ii
HALAMAN PENGESAHAN.....	iii
PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA.....	iv
UCAPAN TERIMA KASIH.....	v
ABSTRAK	vi
ABSTRACT	vii
DAFTAR ISI.....	viii
DAFTAR TABEL	x
DAFTAR LAMPIRAN	xi
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Batasan Masalah.....	3
1.3 Tujuan Penelitian.....	4
1.4 Manfaat Penelitian.....	4
1.5 Teori.....	4
1.5.1 Regresi Linier Berganda	4
1.5.2 Metode Kuadrat Terkecil	5
1.5.3 Uji Asumsi Klasik.....	6
1.5.4 Pencilan	8
1.5.5 Pemusatan dan Penskalaan	9
1.5.6 Regresi <i>Ridge</i>	10
1.5.7 <i>Generalized Ridge Regression</i>	11
1.5.8 <i>Jackknife Ridge Regression</i>	11
1.5.9 <i>Modified Jackknife Ridge Regression</i>	12
1.5.10 Regresi <i>Robust</i>	12
1.5.11 <i>Robust Generalized-M Estimator</i>	13
1.5.12 Penentuan Nilai Konstanta Bias k^*	14
1.5.13 Pengujian Signifikansi Parameter	14

1.5.14	Ukuran Kebaikan Model.....	15
1.5.15	Tingkat Pengangguran Terbuka.....	16
BAB II METODOLOGI PENELITIAN		19
2.1	Data Penelitian.....	19
2.2	Variabel Penelitian	19
2.3	Tahapan Analisis.....	19
BAB III HASIL DAN PEMBAHASAN		22
3.1	Estimasi Parameter <i>Robust Modified Jackknife Ridge Regression</i> dengan <i>Generalized M Estimator</i>	22
3.2	Statistik Deskriptif.....	29
3.3	Uji Asumsi Klasik.....	30
3.4	Identifikasi Pencilan Berpengaruh.....	31
3.5	Transformasi Menggunakan Metode Pemusatan dan Penskalaan	33
3.6	Pemodelan <i>Robust Modified Jackknife Ridge</i> dengan <i>GM-Estimator</i>	34
3.7	Uji Signifikansi Parameter	41
3.8	Hasil Analisis Data Simulasi.....	43
3.9	Evaluasi Kebaikan Model	51
BAB IV KESIMPULAN DAN SARAN.....		53
4.1.	Kesimpulan	53
4.2.	Saran.....	53
DAFTAR PUSTAKA.....		54
LAMPIRAN		58

DAFTAR TABEL

Nomor Urut	Halaman
Tabel 1. Variabel Penelitian _____	19
Tabel 2. Hasil Analisis Deskriptif _____	29
Tabel 3. Hasil Uji Shapiro Wilk _____	30
Tabel 4. Hasil Uji Multikolinearitas _____	31
Tabel 5. Hasil Identifikasi Pencilan _____	32
Tabel 6. Hasil Identifikasi Amatan Berpengaruh _____	32
Tabel 7. Hasil Identifikasi Pencilan Berpengaruh _____	33
Tabel 8. Nilai Eigen _____	34
Tabel 9. Estimasi Parameter MKT (γmkt) _____	35
Tabel 10. Hasil Iterasi Estimasi Parameter Menggunakan Robust GM-estimator _____	37
Tabel 11. Hasil Estimasi Parameter Robust GM-estimator (γGM) _____	37
Tabel 12. Hasil Estimasi Parameter Robust MJRR-GM pada Ruang Ortogonal ($\gamma RMJRR$) _____	39
Tabel 13. Hasil Estimasi Parameter Robust MJRR-GM Pada Ruang Parameter Asli ($\beta RMJRR *$) _____	39
Tabel 14. Hasil Uji Simultan Parameter Model Robust MJRR-GM _____	42
Tabel 15. Hasil Uji Parsial Parameter Model Robust MJRR-GM _____	42
Tabel 16. Karakteristik Data Simulasi _____	43
Tabel 17. Hasil Uji Shapiro Wilk Pada Data Simulasi _____	44
Tabel 18. Hasil Uji Multikolinearitas Pada Data Simulasi _____	44
Tabel 19. Identifikasi Pencilan Pada Data Simulasi _____	45
Tabel 20. Identifikasi Amatan Berpengaruh Pada Data Simulasi _____	45
Tabel 21. Identifikasi Pencilan Berpengaruh Pada Data Simulasi _____	46
Tabel 22. Hasil Iterasi Estimasi Parameter Menggunakan Robust GM-estimator Pada Data Simulasi _____	47
Tabel 23. Hasil Estimasi Parameter Robust GM-estimator (γGM) Pada Data Simulasi _____	48
Tabel 24. Hasil Estimasi Parameter Robust MJRR-GM ($\gamma RMJRR$) Pada Ruang Ortogonal (Data simulasi) _____	48
Tabel 25. Hasil Estimasi Parameter Robust MJRR-GM ($\beta RMJRR *$) Pada Ruang Parameter Asli (Data Simulasi) _____	49
Tabel 26. Hasil Uji Simultan Parameter Model Robust MJRR-GM (Data Simulasi) _____	50
Tabel 27. Hasil Uji Parsial Parameter Model Robust MJRR-GM (Data Simulasi) _____	50
Tabel 28. Perbandingan Ukuran Keباikan Model _____	51

DAFTAR LAMPIRAN

Nomor Urut	Halaman
Lampiran 1. Data Penelitian	59
Lampiran 2. Hasil Perhitungan Nilai ti , hii , dan $DFFITs$	60
Lampiran 3. Data Hasil Pemusatan dan Penskalaan.....	61
Lampiran 4. Variabel Ortogonal Z.....	62
Lampiran 5. Hasil Perhitungan Nilai Residual, Leverage, Bobot π , Skala Residual Dan Nilai Bobot untuk Iterasi Pertama	63
Lampiran 6. Hasil Iterasi Estimasi Parameter Robust GM-Estimator.....	64
Lampiran 7. Data Simulasi.....	66
Lampiran 8. Hasil Perhitungan Nilai ti , hii , dan $DFFITs$ Pada Data Simulasi	67
Lampiran 9. Data Hasil Transformasi Pemusatan dan Penskalaan Data Simulasi	68
Lampiran 10. Variabel Ortogonal Z (Untuk Data Simulasi).....	69
Lampiran 11. Hasil Perhitungan Nilai Residual, Leverage, Bobot π , Skala Residual Dan Nilai Bobot untuk Iterasi Pertama Pada Data Simulasi	70
Lampiran 12. Hasil Iterasi Estimasi Parameter Robust GM-Estimator (Pada Data Simulasi)	71

BAB I PENDAHULUAN

1.1 Latar Belakang

Analisis regresi merupakan metode statistik yang digunakan untuk menyelidiki dan memodelkan hubungan sebab akibat antara variabel respon dengan satu atau lebih variabel prediktor. Hasil analisis berupa koefisien regresi untuk masing-masing variabel prediktor, yang menunjukkan besar dan arah pengaruh setiap variabel prediktor terhadap variabel respon (Setriani & Listyani, 2017). Dalam mengestimasi parameter model regresi, metode yang paling umum digunakan yaitu metode kuadrat terkecil (MKT). MKT bekerja dengan cara meminimumkan jumlah kuadrat residual untuk menghasilkan estimasi linear yang tak bias serta ragam yang minimum (Nurbaroqah dkk., 2022). Namun, dalam penggunaan MKT harus memenuhi beberapa asumsi klasik agar menghasilkan estimasi parameter model yang bersifat *Best Linear Unbiased Estimator* (BLUE). Beberapa asumsi tersebut diantaranya residual berdistribusi normal, ragam residual homogen, tidak mengandung multikolinearitas dan tidak terjadi autokorelasi (Nurhafifah dkk., 2024). Jika salah satu asumsi tidak terpenuhi, maka kualitas estimasi akan menurun.

Dalam praktiknya, data sering kali tidak sepenuhnya memenuhi asumsi – asumsi klasik, salah satunya yaitu masalah multikolinearitas. Multikolinearitas terjadi ketika terdapat korelasi yang tinggi antar variabel prediktor yang dapat menyebabkan varians estimasi membesar, sehingga model menjadi kurang andal dan menyulitkan interpretasi kontribusi masing-masing prediktor (Jeremia dkk., 2020). Salah satu metode yang bisa digunakan untuk mengatasi multikolinearitas adalah regresi *ridge* (RR) yang merupakan modifikasi dari MKT yang menambahkan penalti terhadap besarnya koefisien regresi. Pendekatan ini mampu menstabilkan estimasi meski terdapat multikolinearitas (Waibusi, 2023). Regresi *ridge* memiliki beberapa pengembangan metode diantaranya yaitu *Generalized Ridge Regression* (GRR) dan *Jackknife Ridge Regression* (JRR). GRR dikembangkan dengan penalti yang ditambahkan berbeda beda pada tiap prediktor. Kemudian, JRR dikembangkan dengan melakukan resampling *jackknife* untuk menghindari bias (Arrasyid dkk., 2021). Selanjutnya, Batah dkk (2008) memperkenalkan metode *Modified Jackknife Ridge Regression* (MJRR) yang merupakan pengembangan dari metode JRR yang dikombinasikan dengan GRR. Ia menemukan bahwa metode MJRR lebih baik dibandingkan metode GRR dan JRR karena memiliki nilai MSE yang lebih kecil.

Selain multikolinearitas, permasalahan lain yang sering muncul adalah pencilan. Pencilan merupakan pengamatan yang memiliki nilai ekstrim dan karakteristik yang unik, berbeda dari pengamatan lainnya (Nurbaroqah dkk., 2022). Keberadaan pencilan dapat mengakibatkan estimasi parameter regresi menjadi kurang optimal akibat nilai residual yang besar. Namun, tidak dapat dibuang begitu saja, karena adakalanya justru mengandung informasi yang penting (Damayanti & Susanti, 2024). Oleh karena itu, diperlukan suatu pendekatan yang mampu meminimalkan pengaruh pencilan tanpa harus menghapus data. Salah satu metode yang dapat digunakan adalah regresi *robust*. Metode tersebut dirancang untuk tetap

menghasilkan estimasi yang andal meskipun asumsi klasik seperti normalitas residual tidak terpenuhi. Regresi *robust* menghasilkan model yang resisten terhadap pencilan dengan cara memberikan bobot lebih kecil pada pengamatan yang menyimpang (Akolo & Nadjamuddin, 2022). Salah satu estimator dalam regresi *robust* adalah *Generalized-M* (GM). Estimator ini merupakan pengembangan dari M-estimator yang memiliki keterbatasan karena hanya mampu menangani pencilan pada variabel respon. GM-estimator mengatasi kelemahan tersebut dengan membatasi pengaruh pencilan baik pada variabel prediktor maupun respon (Saputri dkk., 2024). Dalam penerapannya, GM-estimator menggunakan fungsi pembobot untuk mengurangi pengaruh data pencilan.

Multikolinearitas dan pencilan bisa muncul secara bersamaan pada data. Kombinasi keduanya akan memperbesar risiko distorsi dalam estimasi parameter regresi, sehingga diperlukan metode yang mampu mengatasi kedua masalah tersebut. Metode tersebut adalah Regresi *Robust Modified Jackknife Ridge* dengan GM-estimator. Metode ini menggabungkan MJRR untuk mengatasi multikolinearitas dan regresi *robust* GM-estimator untuk menangani pencilan. Beberapa penelitian sebelumnya telah menunjukkan efektivitas pendekatan ini. Arrasyid, Ispriyanti, dan Hoyyi (2021) menerapkan metode MJRR dan terbukti mampu mengatasi multikolinearitas dengan baik melalui nilai MSE yang kecil. Sahriman dan Upa (2024) menemukan bahwa MJRR lebih unggul dibandingkan JRR pada model *statistical downscaling*. Sementara itu, dalam konteks regresi *robust*, Nugroho dkk. (2024) dan Said dkk. (2024) membandingkan estimator GM dan MM, dan menemukan bahwa GM-estimator memberikan nilai *adj R-square* lebih tinggi serta AIC lebih rendah. Kemudian, dalam hal penerapan regresi *robust ridge*, Ruslinda (2024) memodelkan data curah hujan menggunakan *Robust* JRR dan memperoleh nilai *R-square* 68% dan nilai RMSE 192,19. Azzahra, (2024) melakukan pemodelan menggunakan *Robust* MJRR dengan MM-estimator dan terbukti mampu menangani multikolinearitas sekaligus pencilan dengan baik, ditunjukkan oleh nilai *R-square* sebesar 90,68% dan MSE 0,0223.

Berdasarkan beberapa penelitian sebelumnya, metode MJRR maupun GM-estimator menunjukkan kemampuan yang baik dalam mengatasi multikolinearitas dan pencilan. Pemilihan metode Regresi *Robust Modified Jackknife Ridge* dengan GM-estimator dalam penelitian ini juga didasarkan pada karakteristik data yang digunakan. Variabel-variabel prediktor dalam penelitian ini merupakan indikator sosial, ekonomi, dan kependudukan yang secara teoritis saling berkaitan, sehingga data berpotensi mengalami multikolinearitas antar variabel prediktor. Selain itu, perbedaan kondisi sosial dan ekonomi antar kabupaten/kota di Sulawesi Selatan juga berpotensi menimbulkan pengamatan pencilan. Oleh karena itu, metode *Robust* MJRR dengan GM-estimator dinilai sesuai karena mampu menangani permasalahan multikolinearitas dan pencilan secara simultan. Adapun studi kasus yang digunakan adalah Tingkat Pengangguran Terbuka (TPT) di Sulawesi Selatan tahun 2024. Pemilihan kasus ini didasarkan pada pentingnya memahami permasalahan pengangguran di daerah yang erat kaitannya dengan berbagai faktor sosial-ekonomi.

Pengangguran merupakan salah satu permasalahan ketenagakerjaan yang erat kaitannya dengan kondisi sosial dan ekonomi suatu daerah. Pengangguran timbul akibat ketidakseimbangan antara pertumbuhan penduduk dan ketersediaan lapangan kerja. Tingkat Pengangguran Terbuka (TPT) merupakan indikator utama pasar tenaga kerja yang menunjukkan persentase angkatan kerja yang belum bekerja tetapi aktif mencari pekerjaan, sekaligus menjadi tolok ukur efektivitas kebijakan ketenagakerjaan. Berdasarkan data BPS, TPT Sulawesi Selatan pada Agustus 2024 tercatat sebesar 4,19%, mengalami penurunan dari tahun sebelumnya sebesar 0,14%. Meski demikian, upaya pengendalian TPT tetap perlu ditingkatkan karena kondisi ini dipengaruhi oleh berbagai faktor, seperti tingkat partisipasi angkatan kerja, indeks pembangunan manusia, dan faktor sosial-ekonomi lainnya. Dengan demikian, penelitian ini diharapkan dapat memberikan pemodelan yang lebih andal dalam mengidentifikasi faktor-faktor yang berkaitan dengan TPT di Sulawesi Selatan tahun 2024.

Selain menggunakan data TPT untuk pemodelan, penelitian ini juga melibatkan data simulasi sebagai data pendukung untuk mengevaluasi kinerja metode secara metodologis pada kondisi multikolinearitas dan pencilan yang dikendalikan. Pendekatan ini dilakukan karena pada data TPT, meskipun multikolinearitas teridentifikasi cukup kuat, tingkat keberadaan pencilan yang berpengaruh relatif rendah, sehingga perbedaan kinerja antara pendekatan robust dan non-robust berpotensi tidak tampak secara jelas. Dengan demikian, penggunaan data simulasi dimaksudkan untuk mengamati stabilitas, perilaku dan keunggulan metode Robust MJRR-GM secara lebih komprehensif, sehingga hasil penelitian diharapkan mampu memberikan kontribusi baik dari sisi pemodelan data TPT maupun evaluasi kinerja metode. Berdasarkan uraian tersebut, penelitian dilakukan dengan judul “Analisis Regresi Robust Modified Jackknife Ridge dengan Generalized M-Estimator untuk Pemodelan Tingkat Pengangguran Terbuka di Sulawesi Selatan 2024”.

1.2 Batasan Masalah

Batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Data yang digunakan yaitu data Tingkat Pengangguran Terbuka di Kabupaten/Kota Provinsi Sulawesi Selatan Tahun 2024 dengan delapan variabel prediktor yang diduga memengaruhi tingkat pengangguran terbuka.
2. Penanganan pencilan dalam penelitian ini dibatasi menggunakan pembobot *Schweppe* dan fungsi pembobot Huber.
3. Perhitungan nilai konstanta bias (k_*) dilakukan menggunakan pendekatan usulan Hoerl, Kennard dan Balwin (1975) yang diperoleh berdasarkan kuadrat tengah residual dan estimasi parameter *robust*.
4. Evaluasi kebaikan model dalam penelitian ini dibatasi menggunakan nilai *Adjusted R²* dan *Root Mean Square Error* (RMSE)

1.3 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini yakni sebagai berikut:

1. Memperoleh estimasi parameter model *Robust* MJRR-GM pada kasus tingkat pengangguran terbuka di Kabupaten/Kota Sulawesi Selatan Tahun 2024.
2. Memperoleh variabel-variabel yang signifikan berpengaruh terhadap TPT di Sulawesi Selatan berdasarkan hasil estimasi model *Robust* MJRR-GM.

1.4 Manfaat Penelitian

Hasil penelitian ini diharapkan dapat memberikan kontribusi sebagai referensi ilmiah dalam penerapan metode Regresi *Robust Modified Jackknife Ridge* dengan *GM-estimator*. Selain itu, penelitian ini diharapkan dapat menjadi dasar pertimbangan dalam pemilihan model regresi yang lebih tepat pada kondisi data yang mengandung pencilan dan multikolinearitas. Penelitian ini juga diharapkan mampu menyajikan informasi empiris mengenai faktor-faktor yang memengaruhi Tingkat Pengangguran Terbuka di Provinsi Sulawesi Selatan tahun 2024 sebagai bahan pendukung analisis kebijakan ketenagakerjaan.

1.5 Teori

1.5.1 Regresi Linier Berganda

Analisis regresi merupakan metode statistik yang digunakan untuk menyelidiki dan memodelkan hubungan matematis antara satu variabel respon (terikat) dengan satu atau lebih variabel prediktor (bebas) (Hidayatulloh dkk., 2015). Tujuan utama analisis regresi adalah untuk mengidentifikasi pola hubungan, mengukur kekuatan pengaruh antar variabel, serta membuat prediksi atau estimasi nilai variabel respon berdasarkan variabel prediktor yang tersedia (Damayanti & Susanti, 2024). Dengan peranannya yang luas dalam berbagai bidang ilmu, analisis regresi menjadi alat penting dalam pengambilan keputusan dan peramalan.

Regresi linier merupakan analisis regresi yang mengasumsikan hubungan antara variabel respon dan variabel prediktor bersifat linier. Berdasarkan jumlah prediktor yang digunakan, regresi linier dibedakan menjadi dua, yaitu regresi linier sederhana dan regresi linier berganda. Regresi linier sederhana memodelkan hubungan antara satu variabel respon dengan satu variabel prediktor, sedangkan regresi linier berganda memodelkan hubungan antara satu variabel respon dengan dua atau lebih variabel prediktor (Nugroho, 2016). Bentuk dasar dari model regresi linier berganda adalah sebagai berikut:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + e_i \quad (1)$$

dengan:

- y_i : Variabel respon pada pengamatan ke- i , untuk $i = 1, 2, \dots, n$
 x_{ij} : Pengamatan ke- i dan variabel prediktor ke- j , untuk $i = 1, 2, \dots, n$
 dan $j = 1, 2, \dots, k$
 $\beta_0, \beta_1, \beta_2, \dots, \beta_k$: Parameter regresi
 e_i : Residual untuk pengamatan ke- i yang diasumsikan berdistribusi normal dengan rata – rata 0 (nol) dan variansi σ^2 atau dituliskan sebagai $e_i \sim N(0, \sigma^2)$

Persamaan (1) dapat dinyatakan dalam bentuk matriks seperti pada persamaan (2) berikut:

$$Y = X\beta + \varepsilon \quad (2)$$

dengan

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}; X = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{bmatrix}; \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}; \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Dengan Y menyatakan vektor variabel respon berukuran $n \times 1$, X menyatakan matriks variabel prediktor berukuran $n(k+1)$, β menyatakan vektor parameter model berukuran $k+1$ dan ε menyatakan vektor residual berukuran $n \times 1$ (Situmorang & Susanti, 2020).

1.5.2 Metode Kuadrat Terkecil

Metode Kuadrat Terkecil (MKT) merupakan metode yang sering digunakan untuk menghitung nilai perkiraan atau estimasi parameter dalam model regresi. Hal ini dilakukan karena dalam model regresi, nilai parameter β tidak diketahui dan perlu diestimasi terlebih dahulu. MKT menduga parameter regresi dengan meminimumkan jumlah kuadrat residual. Proses ini dilakukan dengan menghitung turunan parsial dari fungsi jumlah kuadrat residual terhadap setiap parameter $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$ dan menyamakannya dengan nol (Hidayatulloh dkk., 2015).

Bentuk umum fungsi jumlah kuadrat residual yaitu:

$$\begin{aligned} S(\beta) &= \sum_{i=1}^n \varepsilon_i^2 \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik})^2 \end{aligned} \quad (3)$$

Untuk meminimumkan fungsi jumlah kuadrat residual pada persamaan (3), dilakukan penurunan parsial terhadap β_j dan disamakan dengan nol.

$$\begin{aligned} \frac{\partial S(\beta)}{\partial \beta_j} &= \frac{\partial}{\partial \beta_j} \left[\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik})^2 \right] = 0 \\ -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_k x_{ik}) x_{ik} &= 0 \end{aligned}$$

Kemudian, disederhanakan menjadi:

$$-2 \sum_{i=1}^n (y_i - \hat{y}_i) x_{ij} = 0, \quad j = 0, 1, 2, \dots, k \quad (4)$$

Persamaan (4) dikenal sebagai persamaan normal kuadrat terkecil (*Least Square Normal Equation*) dengan koefisien regresi yang belum diketahui. Bentuk sederhana dari persamaan (4) yaitu:

$$\sum_{i=1}^n (y_i - \hat{y}_i) x_i = 0$$

Jika dalam bentuk matriks, proses meminimumkan jumlah kuadrat residual dapat dituliskan sebagai berikut :

$$\begin{aligned}
S(\beta) &= \sum_{i=1}^n \varepsilon_i^2 \\
S(\beta) &= \varepsilon' \varepsilon \\
&= (Y - X\beta)'(Y - X\beta) \\
&= Y'Y - 2\beta'X'Y + \beta'X'X\beta
\end{aligned}$$

Untuk memperoleh nilai minimum, dilakukan diferensiasi parsial terhadap β , maka:

$$\begin{aligned}
\frac{\partial(Y'Y - 2\beta'X'Y + \beta'X'X\beta)}{\partial\beta} &= 0 \\
-2X'Y + 2X'X\hat{\beta} &= 0 \\
2X'X\hat{\beta} &= 2X'Y \\
X'X\hat{\beta} &= X'Y
\end{aligned}$$

Selanjutnya, kalikan kedua sisi dengan invers dari $X'X$ akan menghasilkan :

$$(X'X)^{-1}(X'X)\hat{\beta} = (X'X)^{-1}X'Y$$

Karena $(X'X)^{-1}(X'X) = I$, I adalah matriks identitas maka diperoleh estimator kuadrat terkecil dari β adalah :

$$\hat{\beta}_{mkt} = (X'X)^{-1}(X'Y) \quad (5)$$

Penggunaan MKT memerlukan beberapa asumsi klasik yang harus dipenuhi oleh komponen sisaan atau residual (e_i) dalam model yang dihasilkan. Beberapa asumsi itu antara lain adalah bahwa komponen residual memenuhi asumsi kenormalan, kehomogenan ragam, tidak terjadi autokorelasi, dan tidak mengandung multikolinearitas. Myers (1990) dalam Cahyawati dkk (2009) menyatakan bahwa apabila asumsi klasik itu terpenuhi, maka penduga parameter yang diperoleh bersifat *Best Linear Unbiased Estimator* (BLUE). Saat asumsi ada yang tidak terpenuhi, maka penggunaan MKT akan memberikan kesimpulan yang bersifat kurang baik atau nilai penduga parameternya bersifat bias, interpretasi hasil yang diberikan juga menjadi tidak valid.

1.5.3 Uji Asumsi Klasik

Pada model regresi, perlu dilakukan uji untuk mengetahui apakah model regresi memenuhi asumsi regresi atau tidak.

1.5.3.1 Uji Normalitas

Uji normalitas digunakan untuk mengetahui apakah residual model regresi berdistribusi normal atau tidak. Pada regresi linier klasik diasumsikan bahwa tiap e_i didistribusikan normal dengan $e_i \sim N(0, \sigma^2)$. Model regresi yang baik adalah model dengan residual yang menyebar secara acak dan mendekati distribusi normal. Salah satu uji formal yang dapat digunakan untuk menguji asumsi normalitas residual adalah uji *Shapiro Wilk*. Sintia, Pasarella dan Nohe (2022) mengemukakan bahwa

Uji *Shapiro-Wilk* memiliki sensitivitas yang lebih tinggi terhadap penyimpangan dari asumsi normalitas dibandingkan uji *Kolmogorov-Smirnov* atau *Anderson-Darling*. Sejalan dengan hal tersebut, (Ahadi & Zain, 2023) menyatakan bahwa Uji *Shapiro-Wilk* lebih sesuai digunakan pada data dengan ukuran sampel kecil dibandingkan kedua uji lainnya. Hipotesis uji normalitas dapat dilihat sebagai berikut:

H_0 : residual berdistribusi normal

H_1 : residual tidak berdistribusi normal

Rumus statistik untuk uji *shapiro wilk* adalah sebagai berikut:

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (6)$$

dimana

a_i : koefisien uji *shapiro wilk*

$x_{(i)}$: data pengamatan ke- i setelah diurutkan

x_i : data pengamatan ke- i

$\bar{x}$: rata – rata data.

dengan nilai a_i dapat diperoleh dari tabel *shapiro wilk* untuk ukuran sampel hingga 50 (untuk ukuran sampel lebih besar dihitung menggunakan *software* statistik). Nilai statistik W berkisar antara 0 hingga 1. Jika nilai W mendekati 1 menunjukkan data cenderung berdistribusi normal. Sedangkan, nilai W yang jauh dari 1 (mendekati 0), maka data tidak berdistribusi normal (Das & Imon, 2016). Kriteria uji normalitas *shapiro wilk* yaitu tolak H_0 jika $W_{hitung} < W_{tabel(\alpha, n)}$ atau jika $p - value \leq \alpha$.

1.5.3.2 Uji Multikolinearitas

Multikolinearitas terjadi ketika terdapat korelasi yang cukup tinggi atau hubungan linier yang kuat di antara variabel prediktor. Dampak multikolinearitas dalam regresi linier berganda antara lain: (1) Estimasi MKT tetap bersifat BLUE, namun memiliki varians dan kovarians besar, sehingga estimasi parameter menjadi tidak tepat; (2) Interval estimasi menjadi lebih lebar dan nilai statistik uji t mengecil, sehingga variabel prediktor tampak tidak signifikan secara statistik; (3) Nilai koefisien determinasi (R^2) tetap bisa tinggi, meskipun variabel prediktor secara individual tampak tidak signifikan, sehingga menyesatkan dalam interpretasi model (Waibusi, 2023).

Salah satu metode untuk mendeteksi tingkat multikolinearitas adalah dengan menggunakan *Variance Inflation Factor* (VIF). Nilai VIF mengukur seberapa besar peningkatan ragam dari koefisien regresi akibat adanya multikolinearitas. Semakin tinggi nilai VIF, semakin tinggi tingkat multikolinearitas (Deria dkk., 2019). VIF dapat didefinisikan sebagai berikut:

$$VIF_j = \frac{1}{(1 - R_j^2)}, j = 1, 2, \dots, k \quad (7)$$

dengan R_j^2 merupakan koefisien determinasi parameter ke- j , dengan $j = 1, 2, \dots, k$. Besarnya nilai VIF bergantung pada nilai koefisien determinasi (R_j^2). Nilai $VIF > 10$ menunjukkan multikolinearitas yang kuat.

1.5.4 Pencilan

Pencilan adalah hasil observasi yang nilainya sangat berbeda jika dibandingkan dengan sebagian besar data lainnya. Menurut Sembiring (2003) pada Dewayanti dkk (2021), pencilan adalah pengamatan yang letaknya jauh dari pusat data dan berpotensi memberikan pengaruh besar terhadap koefisien regresi. Dengan demikian, pencilan dapat dipahami sebagai suatu data pengamatan yang tidak mengikuti sebagian besar pola dan terletak jauh dari pusat data atau dapat muncul dalam nilai ekstrim. Pencilan dapat menimbulkan residual yang besar, meningkatkan variansi, serta menyebabkan taksiran interval menjadi lebih lebar (Hidayatulloh dkk., 2015). Apabila dalam data amatan terdapat pencilan, maka langkah yang dapat dilakukan adalah menghapus atau membuang data pencilan terlebih dahulu. Data pencilan dapat dihapus apabila terbukti berasal dari kesalahan teknis, misalnya akibat kekeliruan pencatatan, kesalahan input data, atau kerusakan alat ukur. Namun, jika pencilan muncul karena kondisi khusus yang memuat informasi penting, maka pencilan tersebut tidak boleh dihapus, melainkan ditangani dengan metode khusus yang sesuai (Daniel, 2019).

Soemartini dalam Daniel (2019) mengemukakan bahwa keberadaan pencilan dapat dideteksi menggunakan metode grafis, seperti *scatterplot* dengan memetakan data terhadap pengamatan ke- i , serta *boxplot* yang didasarkan pada nilai kuartil dan jangkauan antarkuartil. Selain melalui visualisasi data, pencilan juga dapat diidentifikasi menggunakan pendekatan kuantitatif melalui perhitungan tertentu. Namun demikian, suatu pengamatan yang teridentifikasi sebagai pencilan belum tentu merupakan pengamatan berpengaruh. Pencilan ditandai oleh nilai sisaan yang besar, sedangkan pengamatan berpengaruh ditunjukkan oleh besarnya perubahan koefisien regresi ketika pengamatan tersebut dikeluarkan dari model. Dengan demikian, pencilan berpengaruh merupakan pengamatan yang tidak hanya memiliki sisaan besar, tetapi juga memberikan pengaruh nyata terhadap hasil estimasi model regresi (Prasetyo, 2013).

1.5.4.1. Pendeteksian pencilan

Pendeteksian pencilan dilakukan untuk mengidentifikasi pengamatan yang menyimpang dari pola umum data. Dalam penelitian ini, pendeteksian pencilan dilakukan menggunakan dua metode, yaitu *Studentized Residual* untuk mendeteksi pencilan pada variabel respon (Y) dan *Leverage Value* untuk mendeteksi pencilan pada variabel prediktor (X).

1. Leverage Value

Leverage Value atau nilai pengaruh adalah metode yang digunakan untuk mendeteksi pencilan pada variabel prediktor (X). Metode ini bekerja dengan memanfaatkan matriks *hat* (H). *Leverage value* (h_{ii}) merupakan elemen diagonal dari matriks *hat*. Matriks *hat* merupakan matriks berukuran $n \times n$ yang didefinisikan sebagai berikut:

$$H = X'(X'X)^{-1}X \quad (8)$$

Nilai h_{ii} berada pada rentang $0 \leq h_{ii} \leq 1$. Semakin besar nilai h_{ii} , semakin besar pula leverage pada pengamatan ke- i . Jika $h_{ii} > \frac{2(k+1)}{n}$, maka pengamatan ke- i dikatakan pencilan terhadap X (Nurdin & Islamiyati, 2014).

2. Studentized Deleted Residual

Studentized Deleted Residual atau TRES digunakan untuk mendeteksi pencilan pada variabel respon (Y). Hipotesis yang digunakan yaitu sebagai berikut:

H_0 : pengamatan ke- i bukan pencilan

H_1 : pengamatan ke- i merupakan pencilan

Rumus statistik untuk uji TRES adalah sebagai berikut:

$$TRES_i = e_i \sqrt{\frac{n - k - 1}{JKG(1 - h_{ii}) - e_i^2}} \quad (9)$$

dimana

n : banyaknya pengamatan,

k : banyaknya variabel prediktor,

e_i : residual ke- i ,

JKG : jumlah kuadrat residual

h_{ii} : *leverage value*.

Adapun kriteria uji yang melandasi keputusan yaitu tolak H_0 jika nilai $|t_i| > t_{(\frac{\alpha}{2}, n-k-1)}$, dengan $t_{\alpha/2}$ adalah distribusi *t-student* (Prasetyo, 2013).

1.5.4.2. Pendeteksian Amatan Berpengaruh

Pendeteksian pengamatan berpengaruh perlu dilakukan untuk mengetahui pengamatan yang berpotensi memberikan pengaruh besar terhadap pembentukan model. Salah satu Metode yang dapat digunakan untuk mengidentifikasi amatan berpengaruh adalah *Difference in Fit Standardizes* (DFFITS). DFFITS digunakan untuk menilai sejauh mana suatu titik data ke- i memengaruhi model regresi yang ditinjau dari nilai taksir, jika titik tersebut dihapus dari model. Rumus DFFITS didefinisikan sebagai berikut:

$$DFFITS_i = t_i \sqrt{\frac{h_{ii}}{1 - h_{ii}}} \quad (10)$$

Suatu data disebut pencilan jika nilai $|DFFITS_i| > 2\sqrt{\frac{p}{n}}$ dengan p adalah banyaknya parameter dan n adalah banyaknya jumlah pengamatan (Deria dkk., 2019).

1.5.5 Pemusatan dan Penskalaan

Pemusatan dan penskalaan (*centering* dan *scaling*) data merupakan bagian dari proses standarisasi variabel. Proses ini bertujuan untuk meminimalkan kesalahan pembulatan dalam perhitungan serta menyetarakan skala sehingga koefisien regresi dapat dibandingkan antar variabel (Lestari dkk., 2022). Transformasi data melalui pemusatan dan penskalaan dilakukan dengan memanfaatkan rata-rata dan simpangan baku dari masing-masing variabel. Pemusatan dilakukan dengan

mengurangkan nilai setiap observasi terhadap rata-rata keseluruhan pada variabel tersebut. Sedangkan penskalaan dilakukan dengan membagi hasil pemusatan terhadap simpangan baku, sehingga setiap pengamatan berada dalam skala simpangan baku variabelnya. Prosedur pemusatan dan penskalaan dilakukan dengan cara mentransformasikan variabel dalam bentuk berikut (Lestari dkk., 2022):

$$X_{ij}^* = \frac{1}{\sqrt{n-1}} \left(\frac{X_{ij} - \bar{X}_j}{S_{X_j}} \right) \text{ dengan } S_{X_j} = \sqrt{\frac{\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2}{n-1}} \quad (11)$$

$$Y_i^* = \frac{1}{\sqrt{n-1}} \left(\frac{Y_{ij} - \bar{Y}}{S_Y} \right) \text{ dengan } S_Y = \sqrt{\frac{\sum_{i=1}^n (Y_{ij} - \bar{Y})^2}{n-1}} \quad (12)$$

dengan

$\bar{X}_j$: Rata - rata dari pengamatan X_j

S_{X_j} : Simpangan baku dari X_j

$\bar{Y}$: Rata rata dari Y

S_Y : Simpangan baku dari Y

Berdasarkan persamaan (11) dan (12), didapatkan model regresi baku (*standardized regression model*) yaitu sebagai berikut :

$$Y_i^* = \beta_1^* X_{i1}^* + \beta_2^* X_{i2}^* + \dots + \beta_k^* X_{ik}^* + e_i^*$$

Dalam bentuk matriks dapat dituliskan sebagai berikut :

$$Y^* = X^* \beta^* + \epsilon$$

Terdapat suatu hubungan linier antara parameter dari model regresi baku ($\beta_1^*, \beta_2^*, \dots, \beta_k^*$) dengan parameter asli dari model regresi linier berganda ($\beta_1, \beta_2, \dots, \beta_k$), yang dijabarkan sebagai berikut:

$$\beta_j = \left(\frac{S_x}{S_y} \right) \beta_j^*, j = 1, 2, \dots, k \quad (13)$$

Persamaan (13) dapat digunakan untuk mendapatkan estimasi parameter yang ditransformasi kembali ke bentuk awal.

Pada prosedur pemusatan dan penskalaan, rata-rata variabel respon dan prediktor menjadi nol. Kondisi ini menyebabkan nilai intersep (β_0) hilang dari model regresi, sehingga perhitungan menjadi lebih sederhana. Untuk mengembalikan nilai intersep pada skala data semula, digunakan rumus berikut:

$$\beta_0 = \bar{Y} - \beta_1 \bar{X}_1 - \beta_2 \bar{X}_2 - \dots - \beta_k \bar{X}_k \quad (14)$$

1.5.6 Regresi Ridge

Regresi *ridge* merupakan pengembangan dari metode kuadrat terkecil (MKT) yang diperkenalkan oleh Hoerl dan Kennard pada tahun 1962. Metode ini digunakan untuk menangani masalah multikolinearitas dengan memodifikasi metode kuadrat terkecil. Dalam MKT, estimasi parameter diperoleh dengan melibatkan matriks $X'X$. Namun, pada kondisi multikolinearitas matriks $X'X$ menjadi hampir singular, sehingga *inversenya* sulit dihitung secara numerik. Hal ini menyebabkan hasil estimasi parameter menjadi tidak stabil dan kurang akurat (Wasilaine dkk., 2014). Untuk mengatasi permasalahan tersebut, regresi *ridge* menambahkan sebuah faktor koreksi berupa konstanta bias (k_*) yang dikalikan dengan matriks identitas $I_{k \times k}$,

sehingga matriks yang semula $(X'X)^{-1}$ dimodifikasi menjadi $(X'X + k_*I)^{-1}$. Penambahan konstanta ini bertujuan untuk menstabilkan perhitungan invers dengan memastikan determinan $X'X$ tetap dapat dihitung. Dengan demikian, regresi *ridge* memberikan solusi estimasi parameter yang lebih stabil dibandingkan MKT dalam kasus multikolinearitas (Waibusi, 2023). Persamaan regresi *ridge* secara umum dituliskan sebagai berikut:

$$\hat{\beta}_{Ridge} = (X'X + k_*I)^{-1}X'Y$$

Dalam penerapannya, regresi *ridge* umumnya dilakukan pada data yang telah melalui proses pemusatan dan penskalaan.

1.5.7 Generalized Ridge Regression

Menurut Hoerl dan Kennard (1962), parameter regresi *ridge* diperoleh dengan menambahkan konstanta bias yang bernilai sama untuk setiap variabel prediktor. Pada *generalized ridge regression* (GRR), yang merupakan pengembangan dari regresi *ridge*, konstanta bias yang ditambahkan merupakan konstanta bias yang berbeda untuk masing masing variabel prediktor pada matriks $X'X$ yang sudah ditransformasi (Anggraini dkk., 2019). Persamaan umum GRR diperoleh dengan mereduksi $X^{*'}X^*$ yang bersifat simetris menjadi bentuk kanonik. Bentuk kanonik yaitu bentuk khusus dari suatu matriks yang dibentuk dengan melakukan diagonalisasi pada matriks asalnya. Pembahasan mengenai GRR akan lebih sederhana apabila dilakukan transformasi terhadap data sehingga variabel prediktor menjadi variabel prediktor yang ortogonal (Utami dkk., 2013).

Estimasi parameter GRR ($\hat{\gamma}_{grr}$) didapatkan dengan menambahkan konstanta bias k_*I , yang dituliskan sebagai berikut:

$$\hat{\gamma}_{grr} = (I - A^{-1}k_*I)\hat{\gamma}_{mkt} \quad (15)$$

dengan $A = Z'Z + k_*I$

Karena diketahui bahwa $\gamma = T'\beta$, maka $\hat{\gamma}_{grr} = T'\hat{\beta}_{grr}$. Dengan demikian, estimator parameter β untuk GRR diperoleh sebagai berikut :

$$\hat{\beta}_{grr} = T\hat{\gamma}_{grr}$$

1.5.8 Jackknife Ridge Regression

Prosedur *Jackknife* awalnya diusulkan oleh Quenouille (1956) sebagai teknik untuk mengurangi bias dari suatu estimator. Kemudian, penggunaan prosedur *Jackknife* untuk mengurangi bias estimator *ridge* diteliti oleh Singh dkk (1986). Singh dkk (1986) dalam Khurana, Chaubey dan Chandra (2014) mencatat bahwa estimator GRR dapat membawa sejumlah besar bias. Untuk mengatasi masalah ini, mereka mengusulkan estimator tersebut menggunakan prosedur *Jackknife* untuk pengurangan bias dan menunjukkan bahwa estimator dengan prosedur *Jackknifed* memiliki bias yang lebih kecil serta MSE yang lebih rendah daripada estimator GRR. *Jackknife Ridge Regression* (JRR) merupakan pengembangan dari metode regresi *ridge*, yang dimana dilakukan dengan prosedur *resampling jackknife* pada parameter GRR. *Jackknife* bekerja dengan cara menghilangkan satu buah data dan

mengulangnya sebanyak jumlah sampel data yang ada (Iskandar dkk., 2013). Estimator JRR ($\hat{\gamma}_{jrr}$) dinyatakan sebagai berikut:

$$\hat{\gamma}_{jrr} = [I - ((Z'Z + k_*I)^{-1}k_*I)^2] \hat{\gamma}_{mkt} \quad (16)$$

Karena $\gamma = T'\beta$, maka $\hat{\gamma}_{jrr} = T'\hat{\beta}_{jrr}$. Dengan demikian, estimator parameter β untuk JRR diperoleh sebagai berikut :

$$\hat{\beta}_{jrr} = T\hat{\gamma}_{jrr}$$

1.5.9 Modified Jackknife Ridge Regression

Modified Jackknife Ridge Regression (MJRR) merupakan metode pengembangan dari JRR, yang merupakan gabungan ide dari metode dari GRR dengan JRR. MJRR diperkenalkan oleh Batah dkk (2008) yang dirancang untuk mengurangi bias estimator ridge serta meningkatkan performa dalam estimasi parameter, yang mana telah terbukti melalui penelitiannya bahwa MJRR memiliki MSE yang lebih kecil dibanding GRR dan JRR.

Estimator MJRR hampir sama dengan estimator JRR, tapi pada estimator MJRR pengali parameter MKT diganti dengan parameter GRR. Estimator MJRR ($\hat{\gamma}_{mjrr}$) didapatkan sebagai berikut :

$$\hat{\gamma}_{mjrr} = (I - ((A)^{-1}k_*I)^2)(I - k_*I(A)^{-1})\hat{\gamma}_{mkt} \quad (17)$$

Diketahui $\gamma = T'\beta$ dan $\beta = T\gamma$, maka estimator β metode MJRR dapat dirumuskan sebagai berikut:

$$\hat{\beta}_{mjrr} = T\hat{\gamma}_{mjrr}$$

Variansi dan MSE dapat diperoleh pada persamaan berikut (Batah dkk., 2008) :

$$\text{Var}(\hat{\gamma}_{mjrr}) = \sigma^2 W(Z'Z)^{-1}W' \quad (18)$$

$$\text{MSE}(\hat{\gamma}_{mjrr}) = \sigma^2 W(Z'Z)^{-1}W' + K\Phi A^{-1}\hat{\gamma}\hat{\gamma}'A^{-1}k_* \quad (19)$$

Dengan $W = (I - ((A)^{-1}k_*I)^2)(I - k_*I(A^{-1}))$ dan $\Phi = [I + k_*I(A^{-1}) - k_*I(A^{-1})^2]$

1.5.10 Regresi Robust

Regresi *robust* merupakan metode yang digunakan untuk mengatasi masalah dari metode kuadrat terkecil yang disebabkan oleh data mengalami pelanggaran asumsi klasik seperti residual tidak berdistribusi normal akibat terkontaminasi oleh pencilan. Metode ini merupakan alat penting untuk menganalisa data yang dipengaruhi oleh pencilan agar dihasilkan model yang *robust* atau resisten terhadap pencilan. Prosedur regresi *robust* dikembangkan untuk mengatasi keanehan dalam data, seperti keberadaan pencilan (*outlier*) atau nilai ekstrem, tanpa perlu secara eksplisit mengidentifikasi atau menghapusnya. Metode ini secara otomatis menyesuaikan estimasi model agar tetap stabil meskipun ada pencilan, sehingga menghasilkan model yang lebih tahan terhadap pelanggaran asumsi klasik, terkhusus normalitas dan heteroskedastisitas.

Dalam pendekatan Metode Kuadrat Terkecil (MKT), pencilan biasanya dideteksi dan dihapus sebelum model dibentuk, namun langkah ini berisiko menghilangkan informasi penting. Sebaliknya, regresi *robust* tetap menggunakan seluruh data dengan meminimalkan pengaruh pencilan melalui teknik pembobotan

atau metode khusus lainnya, tanpa perlu membuang observasi, sehingga mampu mempertahankan integritas data sekaligus menghasilkan estimasi parameter yang tidak terdistorsi oleh anomali (Hidayatulloh dkk., 2015). MKT memberikan bobot yang sama pada setiap pengamatan untuk mendapatkan estimasi parameter. Sedangkan regresi robust memungkinkan pengamatan dibobot secara tidak sama. Pada dasarnya, pengamatan yang menghasilkan residual besar diberikan bobot lebih kecil dengan menggunakan metode estimasi regresi *robust*. Ini menunjukkan bahwa regresi *robust* secara eksplisit memberikan bobot berbeda berdasarkan residual. Beberapa metode estimasi dalam regresi *robust* diantaranya adalah estimasi-M, *Least Trimmed Square* (LTS), *Least Median Square* (LMS), *estimasi S*, estimasi *Method of Moment* (MM) dan *Generalized M* (GM).

1.5.11 Robust Generalized-M Estimator

Salah satu metode estimasi dalam regresi robust adalah *Generalized-M* (GM) estimator. Estimator ini merupakan pengembangan dari M-Estimator yang memiliki keterbatasan karena hanya mampu menangani pencilan pada variabel respon. GM-estimator mengatasi kelemahan tersebut dengan membatasi pengaruh pencilan baik pada variabel prediktor maupun respon. Metode ini pertama kali diperkenalkan oleh Schweppe dengan menambahkan fungsi pembobot yang mempertimbangkan informasi *leverage*, sehingga pengaruh observasi dengan nilai *leverage* tinggi dapat diminimalkan (Ruslinda, 2024). Fungsi bobot tersebut umumnya didefinisikan melalui fungsi $\pi_i = \sqrt{1 - h_{ii}}$ dan $v(Z_i) = \pi_i$, dimana h_{ii} merupakan nilai *leverage* dari observasi ke- i . Nilai π_i berperan sebagai *leverage weight*, sedangkan $v(Z_i)$ digunakan sebagai faktor penskalaan residual. Dengan demikian, GM-estimator mampu menghasilkan estimasi parameter yang lebih stabil meskipun terdapat pencilan baik pada respon maupun predictor (Utomo & Fitrianto, 2022).

GM-Estimator didefinisikan sebagai berikut:

$$S(y_j) = \arg \min_Y \sum_{i=1}^n \pi_i \rho \left(\frac{e_i}{v(Z_i) \hat{\sigma}} \right) \quad (20)$$

dengan $e_i = y_i - \sum_{j=0}^k Z_{ij} \gamma_j$, π_i merupakan pembobot *leverage*, $v(Z_i)$ fungsi pembobot *leverage* dan $\hat{\sigma}$ adalah skala *robust* GM-estimator yang dirumuskan sebagai berikut:

$$\hat{\sigma}_{GM} = 1,4825 \text{ MAD} = 1,4825 \text{ median } \{|e_i - \text{median}(e_i)|\} \quad (21)$$

Pembobot yang digunakan yaitu pembobot *Schweppe* dengan $\pi_i = \sqrt{1 - h_{ii}}$ dan $v(Z_i) = \pi_i$. Pembobot tersebut akan digunakan untuk memperoleh pembobot estimasi w_i . Dalam bentuk matriks, estimator γ_{GM} dapat dituliskan sebagai berikut :

$$\hat{\gamma}_{GM} = (Z' W Z)^{-1} Z' W Y \quad (22)$$

W merupakan matriks diagonal berukuran $(n \times n)$ dengan elemen diagonalnya yaitu bobot *robust* $w_1, w_2, w_3, \dots, w_n$ dan n adalah banyaknya observasi. Nilai W dihitung dengan menggunakan $\hat{\gamma}_{GM}$, skala robust $\hat{\sigma}$, dan nilai dari pembobot *Schweppe*. Iterasi akan berjalan dengan pembaharuan W ditiap iterasi dan akan

berhenti ketika estimator memperoleh konvergen, yaitu ketika selisih γ_{GM}^{t+1} dengan γ_{GM}^t mendekati 0, dengan t adalah banyaknya iterasi.

Untuk menghitung fungsi pembobot w_i digunakan fungsi objektif. Fungsi objektif yang diturunkan terhadap u_i akan menghasilkan suatu fungsi yang disebut sebagai fungsi pengaruh ($\psi(u_i)$). Fungsi pengaruh yang dibagi dengan u_i akan menghasilkan fungsi pembobot ($w_i(u_i)$) yang akan digunakan dalam perhitungan regresi *robust* (Deria, Hoyyi dan Mustafid, 2019). Pada tahap formulasi, pembobot Schweppe digunakan untuk mengakomodasi pengaruh leverage melalui π_i . Selanjutnya, untuk membentuk bobot untuk estimasi w_i , penelitian ini menggunakan fungsi pengaruh Huber. Secara matematis, fungsi bobot *Huber* dapat dituliskan sebagai berikut:

$$w(u_i) = \begin{cases} 1, & \text{jika } |u_i| \leq c \\ \frac{c}{|u_i|}, & \text{jika } |u_i| > c \end{cases} \quad (23)$$

Dengan nilai c yang digunakan yaitu dengan rumus $c = 2\sqrt{\frac{(p+1)}{n}}$, dimana p merupakan banyaknya variabel prediktor dan n merupakan banyaknya pengamatan. Nilai c pada regresi *robust* merupakan *tuning constant* yang digunakan untuk menentukan *robustness* atau kekekaran estimator terhadap pencilan dan efisiensi estimator dalam ketidakadaan pencilan. Parameter ini berperan penting dalam menentukan seberapa besar toleransi terhadap residual yang tinggi, yaitu dengan mengatur batas perlakuan terhadap pencilan (Nugroho, 2016).

1.5.12 Penentuan Nilai Konstanta Bias k_*

Estimasi parameter regresi *ridge* dipengaruhi oleh besarnya konstanta bias k_* yang umumnya berada pada rentang $0 \leq k_* \leq 1$. Salah satu metode untuk menentukan nilai konstanta bias yang optimal diusulkan oleh Hoerl, Kennard dan Balwin (1975) menggunakan rumus berikut (Alguraibawi dkk., 2015) :

$$k_* = \frac{p\hat{\sigma}^2}{\hat{\gamma}'\hat{\gamma}} \quad (24)$$

dengan p merupakan banyaknya parameter, $\hat{\sigma}^2$ merupakan kuadrat tengah residual dari estimasi menggunakan MKT dan $\hat{\gamma}$ yaitu penduga parameter hasil estimasi menggunakan MKT.

1.5.13 Pengujian Signifikansi Parameter

Sebelum menarik kesimpulan dari suatu model regresi, terlebih dahulu dilakukan pengujian terhadap parameter regresi, baik secara simultan (bersama-sama) maupun secara (individu). Hal ini bertujuan untuk mengetahui variabel-variabel prediktor yang mempunyai pengaruh maupun tidak terhadap variabel respon.

1.5.13.1 Uji Simultan

Uji simultan atau uji statistik F digunakan untuk menguji signifikansi model regresi secara keseluruhan dengan mencari tahu apakah seluruh variabel prediktor secara

bersama sama berpengaruh signifikan terhadap variabel respon. Hipotesis untuk uji simultan dapat dinyatakan sebagai berikut:

- H_0 : $\beta_1 = \beta_2 = \dots = \beta_k = 0$ (Tidak ada variabel prediktor dalam model yang berpengaruh signifikan terhadap variabel respon secara bersama - sama)
- H_1 : Minimal ada satu $\beta_j \neq 0$ untuk $j = 1, 2, \dots, k$ (Minimal ada satu variabel prediktor dalam model yang berpengaruh signifikan terhadap variabel respon secara bersama - sama)

Uji simultan dapat dinyatakan dalam bentuk rumus sebagai berikut:

$$F_{hitung} = \frac{JKR/k}{JKG/(n - k - 1)} \quad (25)$$

dengan JKR merupakan jumlah kuadrat regresi dan JKG adalah Jumlah kuadrat residual. Adapun kriteria pengujian untuk uji simultan yaitu H_0 ditolak jika nilai $F_{hitung} > F_{\alpha, k, n-k-1}$ atau ketika $p - value < \alpha$ (Deria dkk., 2019).

1.5.13.2 Uji Parsial

Uji atau uji statistik t digunakan untuk menguji signifikansi dari masing - masing koefisien regresi dengan mencari tahu apakah setiap variabel prediktor secara individu berpengaruh signifikan terhadap variabel respon. Hipotesis uji parsial dapat dinyatakan sebagai berikut:

- H_0 : $\beta_j = 0$ (Variabel prediktor ke- i tidak berpengaruh signifikan terhadap variabel respon)
- H_1 : $\beta_j \neq 0$ untuk $j = 1, 2, \dots, k$ (Variabel prediktor ke- i berpengaruh signifikan terhadap variabel respon)

Uji parsial dapat dinyatakan dalam bentuk rumus sebagai berikut:

$$t_{hitung} = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} ; j = 1, 2, \dots, k \quad (26)$$

dengan $SE(\hat{\beta}_i) = \sqrt{var(\hat{\beta}_j)}$. $\hat{\beta}_j$ sebagai parameter penduga dari β_j dan $SE(\hat{\beta}_i)$ sebagai *standard error* dari $\hat{\beta}_j$. Adapun Kriteria pengujian untuk uji parsial yaitu H_0 ditolak jika $|t_{hitung}| > t_{(\frac{\alpha}{2}, n-k-1)}$ atau $p - value < \alpha$ (Deria dkk., 2019).

1.5.14 Ukuran Kebaikan Model

Ukuran kebaikan model digunakan untuk mengevaluasi kemampuan model regresi dalam menjelaskan variasi variabel respon serta ketepatan model dalam melakukan prediksi. Pada penelitian ini, ukuran kebaikan model dievaluasi menggunakan nilai *Adjusted R-Square* (*Adjusted R²*) dan *Root Mean Square Error* (RMSE).

1.5.14.1. Adjusted R-Square

Koefisien determinasi (R^2) digunakan untuk menilai seberapa baik model regresi menjelaskan variasi dalam variabel respon. Nilai ini mengukur proporsi varians variabel respon yang dapat diterangkan oleh model. Jika nilai R^2 semakin dekat dengan 1 maka semakin baik tingkat kecocokan data dengan model dan sebaliknya

jika nilai R^2 semakin dekat dengan 0 maka semakin rendah tingkat kecocokan model tersebut (Damayanti & Susanti, 2024). Kelemahan R^2 yaitu besarnya dipengaruhi oleh banyaknya variabel prediktor, sehingga sulit menyatakan berapa R^2 yang optimum. Salah satu cara mengatasi kelemahan R^2 adalah dengan menggunakan *adjusted R-squared* ($adj R^2$) atau R^2 yang disesuaikan. Semakin besar nilai $adj R^2$ maka semakin baik model regresinya. Untuk menghitung nilai $adj R^2$ digunakan persamaan sebagai berikut :

$$Adj R^2 = 1 - \frac{\left(\frac{JKG}{n-k}\right)}{\left(\frac{JKT}{n-1}\right)} = 1 - \frac{n-1}{n-k} \left(1 - \frac{JKG}{JKT}\right) = 1 - \frac{n-1}{n-k} (1 - R^2) \quad (27)$$

Dengan :

JKG = Jumlah kuadrat residual

JKT = Jumlah kuadrat total

k = banyaknya variabel

n = banyaknya pengamatan

1.5.14.2. Root Mean Square Error

Selain *Adjusted R²*, ukuran kebaikan model juga dapat dilakukan menggunakan *Root Mean Square Error* (RMSE). RMSE merupakan ukuran yang digunakan untuk mengukur kinerja model. RMSE memberikan gambaran tentang seberapa baik model dalam memprediksi data dengan menghitung akar dari rata rata kuadrat selisih antara nilai yang diprediksi dan nilai aktual. Semakin besar nilai RMSE yang dihasilkan maka keakuratan suatu model semakin rendah atau tidak akurat, sedangkan semakin kecil nilai RMSE maka semakin baik akurasi model tersebut (Alkautsar & Fauzi, 2024).

$$RMSE = \sqrt{MSE} = \sqrt{\frac{JKG}{df_{galat}}} \quad (28)$$

dengan JKG yaitu jumlah kuadrat residual dan df_{galat} derajat bebas residual.

1.5.15 Tingkat Pengangguran Terbuka

Pengangguran terjadi karena ketidakseimbangan laju pertumbuhan penduduk dengan lapangan kerja yang tersedia, dalam artian jumlah tenaga kerja lebih banyak dari jumlah lapangan kerja yang tersedia. Menurut Paramita (2023), pengangguran merujuk pada individu dalam angkatan kerja yang secara aktif mencari pekerjaan tetapi belum memperoleh pekerjaan. Sementara itu, Badan Pusat Statistik (BPS) mendefinisikan pengangguran sebagai penduduk berusia 15 tahun ke atas yang termasuk dalam angkatan kerja, namun tidak bekerja, sedang mencari pekerjaan, merintis usaha baru, atau memiliki pekerjaan tetapi belum mulai bekerja.

Dari berbagai sudut pandang, pengangguran dapat diartikan sebagai individu dalam angkatan kerja yang berupaya mendapatkan pekerjaan yang sesuai dengan keterampilan dan latar belakang pendidikan mereka. Namun, akibat keterbatasan lapangan kerja, mereka belum berhasil memperoleh pekerjaan yang sesuai dengan

kualifikasi dan harapan mereka. Pada umumnya, pengangguran terbagi menjadi 3, yaitu (Sari dkk., 2024):

1. Pengangguran Terbuka (*Open Unemployment*) adalah kondisi di mana seseorang tidak memiliki pekerjaan meskipun telah berusaha mencari, atau akibat kurangnya motivasi untuk bekerja.
2. Pengangguran Terselubung (*Disguised Unemployment*) terjadi ketika terlalu banyak tenaga kerja bersaing untuk satu pekerjaan atau ketika seseorang bekerja di bawah kapasitasnya karena pekerjaannya tidak sesuai dengan keterampilannya.
3. Setengah Menganggur (*Underemployment*) adalah kondisi di mana seseorang bekerja kurang dari 35 jam per minggu. Contohnya adalah pekerja harian seperti kuli bangunan yang menunggu proyek baru.

Untuk menghitung TPT dapat menggunakan rumus sebagai berikut (BPS, 2024):

$$\text{Tingkat Pengangguran Terbuka} = \frac{\text{Jumlah Pengangguran Terbuka}}{\text{Angkatan Kerja}} \times 100\%$$

Tingkat Pengangguran Terbuka (TPT) dapat dipengaruhi oleh beberapa faktor, seperti Tingkat Partisipasi Angkatan Kerja (TPAK), upah minimum, Produk Domestik Regional Bruto (PDRB) (Putra & Hidayah, 2023), pertumbuhan ekonomi, Indeks Pembangunan Manusia (IPM) dan jumlah penduduk (Wee dkk., 2024), Jumlah penduduk miskin dan Tingkat kemiskinan (Mahesa dkk., 2024)

Jumlah penduduk menggambarkan besarnya populasi yang berpengaruh terhadap peningkatan jumlah angkatan kerja. Semakin besar jumlah penduduk, semakin besar pula jumlah angkatan kerja yang masuk ke pasar kerja. Apabila peningkatan jumlah angkatan kerja tersebut tidak diimbangi dengan ketersediaan lapangan kerja yang memadai, maka TPT cenderung meningkat (Elfida dkk., 2023). Sejalan dengan itu, kepadatan penduduk yang tinggi juga dapat meningkatkan TPT karena konsentrasi penduduk yang besar dalam suatu wilayah cenderung memperketat persaingan dalam memperoleh pekerjaan.

Produk Domestik Regional Bruto (PDRB) mencerminkan total nilai barang dan jasa yang dihasilkan oleh seluruh unit usaha di suatu daerah dalam periode tertentu. PDRB dapat menggambarkan kemampuan suatu daerah dalam mengelola sumber daya alam yang dimilikinya (Rambe dkk., 2019). PDRB yang tinggi biasanya menunjukkan pertumbuhan ekonomi yang baik, yang berpotensi menciptakan lebih banyak lapangan kerja dan menurunkan TPT.

Rasio ketergantungan mencerminkan besarnya beban penduduk usia nonproduktif yang ditanggung oleh penduduk usia produktif. Rasio ketergantungan yang tinggi dapat meningkatkan tekanan ekonomi rumah tangga dan menurunkan kapasitas produktif masyarakat, sehingga berpotensi mendorong peningkatan Tingkat Pengangguran Terbuka (TPT) apabila tidak diimbangi dengan pertumbuhan ekonomi dan ketersediaan lapangan kerja. Sebaliknya, rasio ketergantungan yang rendah dapat menjadi peluang demografis karena proporsi penduduk usia produktif

lebih besar, sehingga berpotensi menurunkan TPT apabila didukung oleh peningkatan kualitas sumber daya manusia dan penciptaan kesempatan kerja.

Jumlah penduduk miskin mencerminkan rendahnya kondisi ekonomi masyarakat yang dapat membatasi akses terhadap pendidikan, keterampilan, dan peluang kerja. Semakin tinggi jumlah penduduk miskin, semakin besar risiko meningkatnya Tingkat Pengangguran Terbuka (TPT) karena rendahnya daya saing tenaga kerja dan terbatasnya akses terhadap kesempatan kerja (Mahesa dkk., 2024)

Umur Harapan Hidup (UHH) mencerminkan kualitas kesehatan masyarakat dan menunjukkan rata-rata perkiraan lama hidup penduduk dalam suatu wilayah. UHH yang lebih tinggi umumnya mencerminkan kondisi kesehatan yang lebih baik, sehingga dapat meningkatkan produktivitas, kualitas, dan daya saing tenaga kerja. Kondisi tersebut berpotensi memperluas peluang kerja dan menurunkan Tingkat Pengangguran Terbuka (TPT) (Fitri dkk., 2023) Sebaliknya, UHH yang rendah dapat mencerminkan rendahnya kualitas kesehatan masyarakat yang berpotensi menurunkan produktivitas tenaga kerja dan meningkatkan risiko pengangguran.

BAB II METODOLOGI PENELITIAN

2.1 Data Penelitian

Data yang digunakan dalam penelitian ini merupakan data sekunder yang diperoleh dari [website Badan Pusat Statistik Provinsi Sulawesi Selatan](#), yaitu data Tingkat Pengangguran Terbuka di kabupaten/kota Sulawesi Selatan pada tahun 2024. Unit observasi yang digunakan yaitu 24 kabupaten/kota di Provinsi Sulawesi Selatan.

Untuk mengevaluasi stabilitas dan ketangguhan (robustness) metode *Robust GM-estimator* dalam *Robust MJRR-GM* pada kondisi kontaminasi pencilan yang lebih ekstrem akan dilakukan simulasi dengan menambahkan pencilan sebesar 30% dari total observasi, dengan proporsi yang dibagi secara seimbang antara pencilan pada variabel prediktor dan variabel respon. Data simulasi dibangkitkan berdasarkan karakteristik statistik data TPT. Selain itu, struktur korelasi antar variabel prediktor pada data simulasi tetap mencerminkan kondisi multikolinearitas yang terdapat pada data TPT.

2.2 Variabel Penelitian

Variabel yang digunakan dalam penelitian ini terdiri atas satu variabel respon (Y) yaitu tingkat pengangguran terbuka serta delapan variabel prediktor (X) yang merepresentasikan faktor-faktor yang diduga memengaruhi tingkat pengangguran terbuka, yang dapat dilihat pada tabel 1.

Tabel 1. Variabel Penelitian

Variabel	Keterangan	Satuan
Y	Tingkat Pengangguran Terbuka (TPT)	Persen
X_1	Jumlah Penduduk	Ribu Jiwa
X_2	PDRB Atas Dasar Harga Berlaku	Miliar Rupiah
X_3	Rasio Ketergantungan	Persen
X_4	Jumlah Penduduk Miskin	Juta Jiwa
X_5	Rasio Gini	Indeks
X_6	Rasio Jenis Kelamin	Rasio
X_7	Umur Harapan Hidup	Tahun
X_8	Kepadatan Penduduk	Jiwa/km ²

2.3 Tahapan Analisis

Dalam penelitian ini, proses perhitungan dilakukan dengan bantuan *Python*. Tahapan pemodelan diterapkan pada data TPT dan data simulasi. Analisis terhadap data TPT dilakukan terlebih dahulu. Selanjutnya, data simulasi dibangkitkan berdasarkan karakteristik statistik data TPT dan kemudian dianalisis serta dimodelkan menggunakan prosedur yang sama dengan data TPT. Adapun langkah-langkah analisis yang dilakukan dalam penelitian ini adalah sebagai berikut:

1. Melakukan analisis statistik deskriptif pada data dan membuat matriks korelasi antar variabel
2. Melakukan uji normalitas dan uji multikolinearitas
3. Melakukan pendeteksian pencilan menggunakan metode *Studentized Deleted Residual* dan *Leverage Value*, serta mendeteksi pengamatan berpengaruh menggunakan metode DFFITS.
4. Melakukan standarisasi data dengan metode pemusatan dan penskalaan menggunakan persamaan (11) dan (12)
5. Menggunakan data hasil transformasi, dihitung nilai eigen dan vektor eigen dari matriks X^*X^* , kemudian dibentuk matriks T yang berisi vektor eigen tersebut. Selanjutnya, membentuk matriks $Z = X^*T$ sebagai hasil ortogonalisasi variabel pengganti X^* .
6. Melakukan estimasi parameter dengan metode regresi *robust GM-estimator*. Langkah – langkahnya adalah sebagai berikut:
 - a. Melakukan estimasi parameter MKT menggunakan persamaan $\hat{Y}_{mkt} = (Z'Z)^{-1}Z'Y^*$ dan menghitung nilai residualnya (e_i)
 - b. Menghitung nilai skala residual *robust* ($\hat{\sigma}$) menggunakan *Median Absolute Deviation* (MAD) sesuai persamaan :

$$\hat{\sigma}_{GM} = 1,4825 MAD$$
 - c. Menghitung nilai bobot berbasis leverage $\pi = \sqrt{1 - h_{ii}}$
 - d. Menghitung nilai standar residual (u_i) dengan membagi nilai residual (e_i) dengan skala *robust* residual ($\hat{\sigma}$) dan bobot π .
 - e. Menghitung pembobot w_i menggunakan fungsi pembobot *Huber* sesuai persamaan (23) dengan $c = 2\sqrt{\frac{p+1}{n}}$
 - f. Melakukan estimasi parameter $\hat{Y}_{GM}$ menggunakan persamaan (22) dengan pembobot w_i yang dihasilkan pada langkah e.
 - g. Melakukan iterasi sampai diperoleh nilai estimasi parameter $\hat{Y}_{GM}$ yang konvergen. Nilai $\hat{Y}_{GM}$ dikatakan konvergen jika nilai iterasi terakhir tidak berbeda dengan iterasi sebelumnya.
7. Melakukan estimasi parameter dengan metode *Robust Modified Jackknife Ridge* dengan *GM-Estimator* menggunakan hasil estimasi parameter *GM-estimator* yang telah konvergen pada langkah 6. Langkah-langkahnya adalah sebagai berikut:
 - a. Menghitung nilai konstanta bias k_* menggunakan persamaan :

$$k_* = \frac{p\hat{\sigma}_{GM}^2}{\hat{Y}_{GM}'\hat{Y}_{GM}}$$
 - b. Menghitung estimasi nilai $\hat{Y}_{RMJRR}$ menggunakan Persamaan :

$$\hat{Y}_{rmjrr-gm} = (I - ((A)^{-1}k_*I)^2)(I - k_*I(A)^{-1})\hat{Y}_{gm}$$
 - c. Mengubah persamaan model regresi menjadi

$$\hat{\beta}_{rmjrr-gm} = T\hat{Y}_{rmjrr-gm}$$
8. Melakukan transformasi persamaan regresi ke bentuk awal tanpa pemusatan dan penskalaan, kemudian menghitung nilai intersep persamaan regresi menggunakan persamaan berikut:

$$\beta = \left(\frac{S_y}{S_x} \right) \hat{\beta}_{rmjrr-gm}$$

$$\beta_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2 - \dots - \hat{\beta}_k \bar{X}_k$$

9. Melakukan uji signifikansi parameter model *Robust Modified Jackknife Ridge Regression* secara simultan dan parsial
10. Menghitung nilai *adjusted R-squared* ($adj R^2$) untuk mengetahui kebaikan model dalam menjelaskan pengaruh variabel respon terhadap variabel prediktor dan RMSE untuk melihat kebaikan model dalam prediksi
11. Menginterpretasi model dan menarik kesimpulan.

Adapun tahapan pembangkitan data dilakukan sebagai berikut:

1. Menghitung parameter statistik dari data TPT, meliputi rata – rata variabel prediktor (μ_X), matriks kovarians variabel prediktor (Σ_X), koefisien regresi hasil estimasi metode kuadrat terkecil, serta simpangan baku galat (σ_e).
2. Membangkitkan variabel prediktor (X) secara acak mengikuti distribusi normal multivariat dengan parameter rata – rata μ_X dan matriks kovarians Σ_X yang diperoleh pada langkah sebelumnya.
3. Membangkitkan komponen galat (ε) yang berdistribusi normal $N(0, \sigma_e^2)$, untuk merepresentasikan pengaruh faktor acak yang tidak dijelaskan oleh variabel prediktor.
4. Membentuk variabel respon (Y) menggunakan model regresi linier: $Y = \beta_0 + X\beta + \varepsilon$, sehingga diperoleh hubungan linear antara variabel respon dan variabel prediktor dengan tambahan komponen galat.
5. Menambahkan pencilan secara terkontrol sebesar 30% dari total observasi yang didistribusikan secara seimbang pada variabel respon (Y) dan pada variabel prediktor (X).
6. Membentuk dataset akhir dengan menggabungkan seluruh variabel prediktor ($X_1, X_2, \dots, X_6$) dan variabel respon (Y) ke dalam satu himpunan data yang siap digunakan untuk proses analisis regresi.

BAB III HASIL DAN PEMBAHASAN

3.1 Estimasi Parameter *Robust Modified Jackknife Ridge Regression* dengan *Generalized M Estimator*

Metode *Robust Modified Jackknife Ridge Regression* dengan *Generalized M Estimator* (Robust MJRR-GM) merupakan pengembangan dari model regresi linear berganda yang bertujuan untuk mengatasi permasalahan multikolinearitas dan pencilan secara bersamaan. Model regresi linear berganda dalam bentuk standar dapat dinyatakan sebagai berikut :

$$Y^* = X^* \beta^* + \epsilon$$

Dalam proses estimasi parameter menggunakan metode kuadrat terkecil (MKT), diperoleh estimator yang melibatkan matriks $X^{*'}X^*$. Matriks ini mencerminkan hubungan antar variabel prediktor, namun apabila terdapat korelasi yang tinggi antar variabel prediktor (multikolinearitas), maka matriks tersebut dapat menjadi tidak stabil atau mendekati singular.

Oleh karena itu, untuk mempermudah proses estimasi dan mengatasi multikolinearitas, dilakukan transformasi ortogonal melalui dekomposisi eigen terhadap matriks $X^{*'}X^*$. Proses ini menghasilkan matriks ortogonal $T_{k \times k}$ dan matriks diagonal Λ , sehingga dapat dituliskan dalam bentuk persamaan (29).

$$\begin{aligned} T'(X^{*'}X^*)T &= \Lambda \\ (T'X^{*'})X^*T &= \Lambda \\ (X^*T)'X^*T &= \Lambda \\ Z'Z &= \Lambda \end{aligned} \tag{29}$$

dengan Λ merupakan matriks yang berukuran $k \times k$ yang elemen diagonal utamanya adalah nilai eigen $(\lambda_1, \lambda_2, \dots, \lambda_k)$ dari matriks $X^{*'}X^*$, sedangkan T merupakan matriks ortogonal berukuran $k \times k$ dari vektor eigen yang bersesuaian dengan nilai eigen.

Matriks ortogonal T juga dapat ditulis menjadi $T'T = TT' = I$. Dengan mensubstitusikan matriks I pada persamaan regresi linear, maka diperoleh :

$$\begin{aligned} Y^* &= X^* \beta^* + \epsilon \\ &= X^* I \beta^* + \epsilon \\ &= (X^* T)(T' \beta^*) + \epsilon \\ &= Z \gamma + \epsilon \end{aligned} \tag{30}$$

Transformasi ini menghasilkan variabel baru yang saling ortogonal, dengan:

$$Z = X^* T, \quad \gamma = T' \beta^*$$

Dengan menggunakan persamaan MKT dan berdasarkan persamaan (29), estimator $\hat{\gamma}_{mkt}$ dapat dituliskan menjadi :

$$\begin{aligned} \hat{\gamma}_{mkt} &= (Z'Z)^{-1}Z'Y^* \\ &= \Lambda^{-1}Z'Y^* \end{aligned} \tag{31}$$

Persamaan (31) dapat dibentuk menjadi :

$$\begin{aligned} \hat{\gamma}_{mkt} &= ((X^* T)'(X^* T))^{-1}(X^* T)'Y^* \\ &= (T'X^{*'}X^*T)^{-1}T'X^{*'}Y^* \\ &= (T'X^{*'}X^*T)^{-1}T'X^{*'}\hat{\beta}_{mkt} \end{aligned}$$

$$\begin{aligned}
\hat{\gamma}_{mkt} &= T'(X^{*'}X^*)^{-1}TT'(X^{*'}X^*)\hat{\beta}_{mkt} \\
&= T'(X^{*'}X^*)^{-1}(X^{*'}X^*)\hat{\beta}_{mkt} \\
&= T'\hat{\beta}_{mkt}
\end{aligned} \tag{32}$$

Berdasarkan persamaan (32), diperoleh parameter $\hat{\beta}_{mkt}$ sebagai berikut:

$$\hat{\beta}_{mkt} = T \hat{\gamma}_{mkt}$$

Pada estimasi parameter menggunakan regresi robust, setiap pengamatan diberikan bobot yang berbeda. Dalam GM-estimator, bobot pengamatan ditentukan dengan mempertimbangkan nilai leverage. Bentuk pembobotan yang digunakan adalah $\pi_i = \sqrt{1 - h_{ii}}$, dimana h_{ii} merupakan nilai leverage pengamatan ke- i . Estimasi parameter pada *GM-estimator* dilakukan dengan meminimumkan fungsi objektif $\rho(u_i)$ objektif berbobot, yaitu kombinasi antara fungsi kerugian $\rho(\cdot)$ dan pembobot π_i , dimana residual diskalakan menggunakan $v(Z_i)$ untuk mempertimbangkan pengaruh leverage. Proses minimisasi fungsi objektif tersebut selanjutnya dirumuskan sebagai berikut:

Secara umum GM-Estimator didefinisikan sebagai berikut:

$$S(\gamma_j) = \arg \min_{\gamma} \sum_{i=1}^n \pi_i \rho \left(\frac{e_i}{v(Z_i)} \right) \tag{33}$$

Estimator γ yang diperoleh bukan merupakan skala *invariant*, sehingga digunakan residual terstandarisasi $\left(\frac{e_i}{\hat{\sigma}} \right)$ sebagai pengganti e_i , dimana $\hat{\sigma}$ merupakan faktor skala yang juga perlu diestimasi. Dengan demikian, persamaan (33) dapat ditulis menjadi:

$$S(\gamma_j) = \arg \min_{\gamma} \sum_{i=1}^n \pi_i \rho \left(\frac{e_i}{v(Z_i)\hat{\sigma}} \right)$$

karena $e_i = y_i - \sum_{j=0}^k Z_{ij}\gamma_j$, maka diperoleh:

$$S(\gamma_j) = \arg \min_{\gamma} \sum_{i=1}^n \pi_i \rho \left(\frac{y_i - \sum_{j=0}^k Z_{ij}\gamma_j}{v(Z_i)\hat{\sigma}} \right) \tag{34}$$

Untuk memperoleh estimator parameter, persamaan (34) diturunkan secara parsial terhadap parameter γ_j dengan $j = 0, 1, 2, \dots, k$ dan menyamakan hasilnya dengan 0, sehingga diperoleh:

$$\begin{aligned}
\frac{\partial (S(\gamma_j))}{\partial \gamma} &= \frac{\partial \sum_{i=1}^n \pi_i \rho \left(\frac{y_i - \sum_{j=0}^k Z_{ij}\gamma_j}{v(Z_i)\hat{\sigma}} \right)}{\partial \gamma} = 0, \quad j = 0, 1, 2, \dots, k \\
\sum_{i=1}^n \pi_i \rho' \left(\frac{y_i - \sum_{j=0}^k Z_{ij}\gamma_j}{v(Z_i)\hat{\sigma}} \right) Z_{ij} &= 0, \quad j = 0, 1, 2, \dots, k
\end{aligned} \tag{35}$$

Turunan pertama dari $\rho(\cdot)$ yaitu $\psi(\cdot)$ yang disebut sebagai fungsi pengaruh, sehingga persamaan (35) dapat dituliskan menjadi :

$$\sum_{i=1}^n Z_{ij} \pi_i \psi \left(\frac{y_i - \sum_{j=0}^k Z_{ij} \gamma_j}{v(Z_i) \hat{\sigma}} \right) = 0, \quad j = 0, 1, 2, \dots, k \quad (36)$$

dengan $\hat{\sigma}$ merupakan estimator skala *robust* pada GM-estimator menggunakan MAD sebagaimana ditunjukkan pada persamaan (21).

Setelah itu, menentukan pembobot yang digunakan yaitu pembobot *Schweppe*, dengan $\pi_i = \sqrt{1 - h_{ii}}$ dan $v(Z_i) = \pi_i$. Pembobot tersebut akan digunakan untuk memperoleh pembobot estimasi w_i , yang dinyatakan seperti persamaan berikut:

$$\begin{aligned} w_i &= \frac{\psi \left(\frac{u_i}{v(Z_i)} \right)}{u_i / \pi_i} \\ w_i &= \frac{\psi \left(\frac{y_i - \sum_{j=1}^k Z_{ij} \gamma_j}{\sigma \pi_i} \right)}{\frac{y_i - \sum_{j=1}^k Z_{ij} \gamma_j}{\sigma \pi_i}} \\ w_i \left(\frac{y_i - \sum_{j=1}^k Z_{ij} \gamma_j}{\sigma} \right) &= \pi_i \psi \left(\frac{y_i - \sum_{j=1}^k Z_{ij} \gamma_j}{\sigma \pi_i} \right) \end{aligned} \quad (37)$$

dengan $u_i = \frac{e_i}{\sigma}$.

Dengan menggunakan bobot w_i pada persamaan (37), sistem persamaan estimasi dapat dituliskan sebagai berikut:

$$\sum_{i=1}^n Z_{ij} w_i \left(y_i - \sum_{j=1}^k Z_{ij} \gamma_j \right) = 0, \quad j = 0, 1, 2, \dots, k \quad (38)$$

Persamaan (38) diselesaikan dengan menggunakan *iteratively Reweighted Least Squares* (IRLS), yaitu metode numerik untuk menyelesaikan sistem persamaan nonlinear. Nilai awal parameter diperoleh dari estimasi metode kuadrat terkecil (MKT) pada data hasil transformasi ortogonal.

Selanjutnya, persamaan (37) dapat dituliskan kembali dalam bentuk berikut:

$$\begin{aligned} \sum_{i=1}^n Z_{ij} w_i y_i - \sum_{i=1}^n Z_{ij} w_i \sum_{j=1}^k Z_{ij} \gamma_j &= 0 \\ \sum_{i=1}^n Z_{ij} w_i \sum_{j=1}^k Z_{ij} \gamma_j &= \sum_{i=1}^n Z_{ij} w_i y_i \end{aligned} \quad (39)$$

Dalam bentuk matriks, persamaan (39) dapat dituliskan sebagai berikut:

$$\mathbf{Z}'\mathbf{W}\mathbf{Z}\boldsymbol{\gamma} = \mathbf{Z}'\mathbf{W}\mathbf{Y}$$

dengan $\mathbf{W}$ merupakan matriks diagonal berukuran $n \times n$ dengan elemen diagonal $w_1, w_2, w_3, \dots, w_n$, dan n menyatakan banyaknya observasi. Untuk setiap matriks $\mathbf{W}$, estimator $\hat{\boldsymbol{\gamma}}_{GM}$ diperoleh sebagaimana ditunjukkan pada persamaan (22).

Selanjutnya, matriks pembobot $\mathbf{W}$ diperbaharui secara iteratif berdasarkan nilai residual yang diperoleh dari $\hat{\boldsymbol{\gamma}}_{GM}$, serta mempertimbangkan skala robust $\hat{\sigma}$, dan pembobot *Schweppe*. Iterasi akan berhenti ketika estimator $\hat{\boldsymbol{\gamma}}_{GM}$ telah konvergen, yaitu ketika selisih $\boldsymbol{\gamma}_{GM}^{t+1}$ dengan $\boldsymbol{\gamma}_{GM}^t$ mendekati 0, dengan t adalah banyaknya iterasi. Untuk memperoleh estimasi w_i digunakan fungsi pengaruh huber untuk membentuk pembobot estimasi yang mana dirumuskan seperti pada persamaan (23)

Setelah didapatkan estimator parameter dari GM-estimator, selanjutnya akan melakukan estimasi parameter untuk mengatasi multikolinearitas melalui pendekatan regresi ridge. Untuk menemukan estimasi parameter Modified Jackknife ridge regression, terlebih dahulu menentukan estimator parameter GRR.

Estimasi parameter GRR ($\hat{\boldsymbol{\gamma}}_{grr}$) didapatkan dengan menambahkan konstanta bias $k_*\mathbf{I}$, ke $\mathbf{Z}'\mathbf{Z}$ pada persamaan (29), yang dituliskan sebagai berikut:

$$\begin{aligned}\hat{\boldsymbol{\gamma}}_{grr} &= (\mathbf{A} + k_*\mathbf{I})^{-1}\mathbf{Z}'\mathbf{Y}^* \\ &= (\mathbf{Z}'\mathbf{Z} + k_*\mathbf{I})^{-1}\mathbf{Z}'\mathbf{Y}^* \\ &= \mathbf{A}^{-1}\mathbf{Z}'\mathbf{Y}^* \\ &= \mathbf{A}^{-1}\mathbf{Z}'\mathbf{Z}\hat{\boldsymbol{\gamma}} \\ &= \mathbf{A}^{-1}(\mathbf{A} - k_*\mathbf{I})\hat{\boldsymbol{\gamma}} \\ &= (\mathbf{A}^{-1}\mathbf{A} - \mathbf{A}^{-1}k_*\mathbf{I})\hat{\boldsymbol{\gamma}} \\ &= (\mathbf{I} - \mathbf{A}^{-1}k_*\mathbf{I})\hat{\boldsymbol{\gamma}}\end{aligned}\tag{40}$$

Setelah memperoleh estimator parameter GRR ($\hat{\boldsymbol{\gamma}}_{grr}$), langkah selanjutnya adalah membentuk estimator *Jackknife Ridge Regression* (JRR). Pembentukan estimator JRR dilakukan dengan menggunakan estimator GRR sebagai estimator awal, yang kemudian disesuaikan melalui prosedur *Jackknife*. Metode ini dilakukan dengan menghilangkan satu pengamatan secara bergantian, kemudian melakukan estimasi ulang terhadap model untuk setiap observasi. Secara matematis, estimator parameter $\hat{\boldsymbol{\gamma}}_{GRR}$ tanpa pengamatan ke- i didefinisikan sebagai berikut:

$$\hat{\boldsymbol{\gamma}}_{GRR(-i)} = (\mathbf{Z}'_{(-i)}\mathbf{Z}_{(-i)} + k_*\mathbf{I})^{-1}\mathbf{Z}'_{(-i)}\mathbf{Y}^*_{(-i)}\tag{41}$$

Jika $\mathbf{z}'_i$ adalah vektor baris ke- i dari matriks $\mathbf{Z}$, sehingga :

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}'_1 \\ \vdots \\ \mathbf{z}'_i \\ \vdots \\ \mathbf{z}'_n \end{bmatrix}, \quad \mathbf{Z}' = [\mathbf{z}_1, \dots, \mathbf{z}_i, \dots, \mathbf{z}_n]$$

maka, untuk menghilangkan observasi ke- i dari bentuk matriks $\mathbf{Z}'\mathbf{Z}$ dapat dituliskan sebagai berikut:

$$\mathbf{Z}'_{(-i)}\mathbf{Z}_{(-i)} = \mathbf{Z}'\mathbf{Z} - \mathbf{z}_i\mathbf{z}'_i$$

$$\mathbf{Z}'_{-i}\mathbf{Y}_{(-i)} = \mathbf{Z}'\mathbf{Y} - \mathbf{z}_i\mathbf{y}_i$$

dengan $\mathbf{z}_i$ dan $\mathbf{y}_i$ merupakan matriks kolom berukuran $(k \times 1)$. Maka persamaan (41) dapat dituliskan menjadi:

$$\begin{aligned}\hat{\mathbf{Y}}_{GRR(-i)} &= (\mathbf{Z}'\mathbf{Z} - \mathbf{z}_i\mathbf{z}_i' + k_*\mathbf{I})^{-1}(\mathbf{Z}'\mathbf{Y} - \mathbf{z}_i\mathbf{y}_i) \\ &= (\mathbf{Z}'\mathbf{Z} + k_*\mathbf{I} - \mathbf{z}_i\mathbf{z}_i')^{-1}(\mathbf{Z}'\mathbf{Y} - \mathbf{z}_i\mathbf{y}_i) \\ &= (\mathbf{A} - \mathbf{z}_i\mathbf{z}_i')^{-1}(\mathbf{Z}'\mathbf{Y} - \mathbf{z}_i\mathbf{y}_i)\end{aligned}\quad (42)$$

Selanjutnya, menggunakan invers penjumlahan matriks yang dipaparkan oleh Khurana, Chaubey dan Chandra (2014), dimana :

$$(\mathbf{A} - \mathbf{z}_i\mathbf{z}_i')^{-1} = \left(\mathbf{A}^{-1} + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \right)$$

Maka persamaan (42) menjadi :

$$\begin{aligned}\hat{\mathbf{Y}}_{GRR(-i)} &= (\mathbf{A} - \mathbf{z}_i\mathbf{z}_i')^{-1}(\mathbf{Z}'\mathbf{Y} - \mathbf{z}_i\mathbf{y}_i) \\ &= \left(\mathbf{A}^{-1} + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \right) (\mathbf{Z}'\mathbf{Y} - \mathbf{z}_i\mathbf{y}_i) \\ &= \mathbf{A}^{-1}\mathbf{Z}'\mathbf{Y} - \mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} (\mathbf{Z}'\mathbf{Y}) - \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} (\mathbf{z}_i\mathbf{y}_i)\end{aligned}$$

Diketahui $\mathbf{A} = \mathbf{Z}'\mathbf{Z} + k_*\mathbf{I}$ sehingga $\mathbf{A}^{-1}\mathbf{Z}'\mathbf{Y} = (\mathbf{Z}'\mathbf{Z} + k_*\mathbf{I})^{-1}\mathbf{Z}'\mathbf{Y}$ yang merupakan estimator $\hat{\mathbf{Y}}_{grr}$, oleh karena itu:

$$\begin{aligned}\hat{\mathbf{Y}}_{GRR(-i)} &= \hat{\mathbf{Y}}_{grr} - \mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} (\mathbf{Z}'\mathbf{Y}) - \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} (\mathbf{z}_i\mathbf{y}_i) \\ &= \hat{\mathbf{Y}}_{grr} - \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i(1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i)}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})(\mathbf{Z}'\mathbf{Y})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} - \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})(\mathbf{z}_i\mathbf{y}_i)}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \\ &= \hat{\mathbf{Y}}_{grr} - \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i - \mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i\mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})(\mathbf{Z}'\mathbf{Y})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} - \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})(\mathbf{z}_i\mathbf{y}_i)}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \\ &= \hat{\mathbf{Y}}_{grr} - \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} + \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1}(\mathbf{z}_i\mathbf{y}_i)}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})(\mathbf{Z}'\mathbf{Y})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} - \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})(\mathbf{z}_i\mathbf{y}_i)}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \\ &= \hat{\mathbf{Y}}_{grr} - \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} + \frac{(\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\mathbf{A}^{-1})(\mathbf{Z}'\mathbf{Y})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \\ &= \hat{\mathbf{Y}}_{grr} - \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} + \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'(\mathbf{A}^{-1}\mathbf{Z}'\mathbf{Y})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \\ &= \hat{\mathbf{Y}}_{grr} - \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} + \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\hat{\mathbf{Y}}_{grr}}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \\ &= \hat{\mathbf{Y}}_{grr} - \left(\frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{y}_i}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} - \frac{\mathbf{A}^{-1}\mathbf{z}_i\mathbf{z}_i'\hat{\mathbf{Y}}_{grr}}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \right) \\ &= \hat{\mathbf{Y}}_{grr} - \left(\frac{\mathbf{A}^{-1}\mathbf{z}_i(\mathbf{y}_i - \mathbf{z}_i'\hat{\mathbf{Y}}_{grr})}{1 - \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i} \right)\end{aligned}$$

Misalnya $\mathbf{w}_i = \mathbf{z}_i'\mathbf{A}^{-1}\mathbf{z}_i$, maka persamaan di atas dapat disederhanakan menjadi :

$$\hat{\mathbf{Y}}_{grr(-i)} = \hat{\mathbf{Y}}_{grr} - \left(\frac{\mathbf{A}^{-1}\mathbf{z}_i(\mathbf{y}_i - \mathbf{z}_i'\hat{\mathbf{Y}}_{grr})}{1 - \mathbf{w}_i} \right) \quad (43)$$

Selanjutnya Singh, Caubey dan Dwivedi (1986) dalam Fatihah (2022) mendefinisikan *pseudo-values* sebagai berikut:

$$Q_i = \hat{\gamma} + n(1 - w_i)(\gamma - \gamma_{(-i)}) \quad (44)$$

Kemudian mensubstitusi persamaan (42) ke persamaan (44), sehingga diperoleh:

$$\begin{aligned} Q_i &= \hat{\gamma} + n(1 - w_i)(\gamma - \gamma_{(-i)}) \\ &= \hat{\gamma}_{grr} + n(1 - w_i)(\gamma_{grr} - \gamma_{grr(-i)}) \\ &= \hat{\gamma}_{grr} + n(1 - w_i) \left(\gamma_{grr} - \left(\hat{\gamma}_{grr} - \left(\frac{A^{-1}z_i(\mathbf{y}_i - z_i' \hat{\gamma}_{grr})}{1 - w_i} \right) \right) \right) \\ &= \hat{\gamma}_{grr} + n(1 - w_i) \left(\frac{A^{-1}z_i(\mathbf{y}_i - z_i' \hat{\gamma}_{grr})}{1 - w_i} \right) \\ &= \hat{\gamma}_{grr} + n A^{-1}z_i(\mathbf{y}_i - z_i' \hat{\gamma}_{grr}) \end{aligned} \quad (45)$$

Dengan menggunakan rata – rata dari *pseudo-values* yang diperoleh pada persamaan (45) diperoleh estimator JRR sebagai berikut:

$$\begin{aligned} \hat{\gamma}_{jrr} &= \bar{Q}_i = \frac{1}{n} \sum Q_i \\ &= \frac{1}{n} \sum (\hat{\gamma}_{grr} + n A^{-1}z_i(\mathbf{y}_i - z_i' \hat{\gamma}_{grr})) \\ &= \frac{1}{n} \left\{ n \hat{\gamma}_{grr} + \sum n A^{-1}(z_i(\mathbf{y}_i - z_i' \hat{\gamma}_{grr})) \right\} \\ &= \hat{\gamma}_{grr} + A^{-1} \sum (z_i \mathbf{y}_i - z_i z_i' \hat{\gamma}_{grr}) \\ &= \hat{\gamma}_{grr} + A^{-1} \sum z_i \mathbf{y}_i - A^{-1} \sum z_i z_i' \hat{\gamma}_{grr} \\ &= \hat{\gamma}_{grr} + A^{-1} \mathbf{Z}' \mathbf{Y}^* - A^{-1} \mathbf{Z}' \mathbf{Z} \hat{\gamma}_{grr} \\ &= \hat{\gamma}_{grr} + A^{-1} \mathbf{Z}' (\mathbf{Y}^* - \mathbf{Z} \hat{\gamma}_{grr}) \\ &= \hat{\gamma}_{grr} + A^{-1} \mathbf{Z}' \mathbf{Y}^* - A^{-1} \mathbf{Z}' \mathbf{Z} \hat{\gamma}_{grr} \\ &= \hat{\gamma}_{grr} + \hat{\gamma}_{grr} - A^{-1} \mathbf{Z}' \mathbf{Z} \hat{\gamma}_{grr} \\ &= \hat{\gamma}_{grr} + (\mathbf{I} - A^{-1} \mathbf{Z}' \mathbf{Z}) \hat{\gamma}_{grr} \\ &= \hat{\gamma}_{grr} + (A^{-1} k_* \mathbf{I}) \hat{\gamma}_{grr} \\ &= (\mathbf{I} + (A^{-1} k_* \mathbf{I})) \hat{\gamma}_{grr} \end{aligned}$$

karena $\hat{\gamma}_{grr} = (\mathbf{I} - A^{-1} k_* \mathbf{I}) \hat{\gamma}_{mkt}$, maka diperoleh:

$$\begin{aligned} \hat{\gamma}_{jrr} &= (\mathbf{I} + (A^{-1} k_* \mathbf{I})) (\mathbf{I} - (A^{-1} k_* \mathbf{I})) \hat{\gamma}_{mkt} \\ &= \mathbf{I}^2 - (A^{-1} k_* \mathbf{I})^2 \hat{\gamma}_{mkt} \\ &= \mathbf{I} - (A^{-1} k_* \mathbf{I})^2 \hat{\gamma}_{mkt} \\ &= \mathbf{I} - ((\mathbf{Z}' \mathbf{Z} + k_* \mathbf{I})^{-1} k_* \mathbf{I})^2 \hat{\gamma}_{mkt} \end{aligned} \quad (46)$$

Setelah diperoleh estimator parameter JRR ($\hat{\gamma}_{jrr}$), selanjutnya dilakukan modifikasi terhadap estimator tersebut untuk memperoleh estimator yang lebih stabil, yaitu *Modified Jackknife Ridge Regression* (MJRR). Estimator MJRR hampir sama dengan estimator JRR, namun dalam pembentukannya digunakan parameter hasil

estimasi GRR sebagai pengganti parameter MKT. Estimator parameter MJRR ($\hat{\gamma}_{MJRR}$) dirumuskan sebagai berikut:

$$\begin{aligned}
 \hat{\gamma}_{mjrr} &= (I - ((Z'Z + k_*I)^{-1}k_*I)^2)\hat{\gamma}_{grr} \\
 &= (I - ((Z'Z + k_*I)^{-1}k_*I)^2)(Z'Z + k_*I)^{-1}Z'Y^* \\
 &= (I - ((Z'Z + k_*I)^{-1}k_*I)^2)(Z'Z + k_*I)^{-1}(Z'Z)(Z'Z)^{-1}Z'Y^* \\
 &= (I - ((Z'Z + k_*I)^{-1}k_*I)^2)(Z'Z + k_*I)^{-1}Z'Z\hat{\gamma}_{mkt} \\
 &= (I - ((Z'Z + k_*I)^{-1}k_*I)^2)(I - k_*I(Z'Z + k_*I)^{-1})\hat{\gamma}_{mkt} \\
 &= (I - ((A)^{-1}k_*I)^2)(I - k_*I(A)^{-1})\hat{\gamma}_{mkt} \tag{47}
 \end{aligned}$$

Berdasarkan persamaan (46), estimator untuk *robust modified jackknife ridge regression* dengan *GM-estimator* diperoleh dengan mengganti estimator parameter MKT ($\hat{\gamma}_{mkt}$) dengan estimator parameter GM ($\hat{\gamma}_{GM}$). Sehingga diperoleh persamaan:

$$\hat{\gamma}_{rmjrr-gm} = (I - ((A)^{-1}k_*I)^2)(I - k_*I(A)^{-1})\hat{\gamma}_{gm} \tag{48}$$

Diketahui $\gamma = T'\beta$ dan $\beta = T\gamma$, maka estimator parameter $\hat{\beta}_{rmjrr-gm}$ dapat dirumuskan sebagai berikut:

$$\hat{\beta}_{rmjrr-gm} = T\hat{\gamma}_{rmjrr-gm}$$

Dalam penerapan metode regresi *ridge*, hasil estimasi parameter dipengaruhi oleh besarnya konstanta bias k_* . Oleh karena itu, diperlukan suatu pendekatan untuk menentukan nilai k_* . Salah satu metode yang optimal diusulkan oleh Hoerl, Kennard dan Baldwin (1975) sebagaimana pada persamaan (24).

Pada regresi *robust modified jackknife ridge* dengan *GM-estimator*, nilai konstanta bias disesuaikan dengan pendekatan *robust*, yaitu dengan mengganti nilai k_* yang semula didasarkan pada estimasi MKT menjadi nilai $k_{*(GM)}$ yang berbasis pada estimator GM. Dengan demikian, diperoleh rumus berikut:

$$k_* = \frac{p\hat{\sigma}_{GM}^2}{\hat{\gamma}_{GM}'\hat{\gamma}_{GM}} \tag{49}$$

dengan

$$\hat{\sigma}_{GM}^2 = \frac{(Y - Z\hat{\gamma}_{GM})'(Y - Z\hat{\gamma}_{GM})}{n - k - 1}$$

3.2 Statistik Deskriptif


Statistik deskriptif digunakan untuk menjelaskan atau memberikan gambaran mengenai karakteristik dari suatu himpunan data. Tujuan dari statistik deskriptif adalah untuk menyajikan ringkasan informasi mengenai variabel-variabel yang digunakan dalam penelitian. Statistik deskriptif dalam penelitian ini terdiri dari nilai minimum, nilai maksimum, nilai rata-rata, dan simpangan baku yang disajikan dalam tabel 2.

Tabel 2. Hasil Analisis Deskriptif

Variabel	Rata - rata	Simpangan Baku	Minimum	Maximum
Y	3,71	1,96	1,51	9,71
X_1	394,31	284,47	142,70	1464,64
X_2	29071,64	46671,79	8340,51	243062,72
X_3	45,24	2,21	41,15	52,65
X_4	30,69	18,27	7,94	79,53
X_5	0,33	0,04	0,25	0,39
X_6	99,00	3,38	93,80	106,80
X_7	70,35	1,92	67,16	74,23
X_8	673,21	1659,44	45	8282

Tabel 2 menunjukkan bahwa beberapa variabel memiliki rentang nilai yang cukup lebar, yang terlihat dari perbedaan yang besar antara nilai minimum dan maksimum, serta didukung oleh nilai simpangan baku yang relatif tinggi. Kondisi ini terutama tampak pada variabel X_1 , X_2 , X_4 dan X_8 , dimana nilai maksimum jauh lebih besar dibandingkan nilai rata-ratanya. Simpangan baku yang besar pada variabel-variabel tersebut mengindikasikan bahwa data menyebar cukup luas dari nilai pusatnya, sehingga terdapat kemungkinan adanya pengamatan dengan nilai yang ekstrem. Sementara itu, variabel X_3 , X_5 , X_6 , dan X_7 memiliki simpangan baku yang relatif kecil, yang menunjukkan bahwa data pada variabel-variabel tersebut cenderung lebih homogen dan tidak mengalami fluktuasi yang signifikan.

Untuk memahami hubungan antar variabel prediktor yang digunakan dalam analisis, dilakukan visualisasi matriks korelasi dalam bentuk *heatmap*, seperti yang ditampilkan pada gambar 1. Visualisasi ini membantu mengidentifikasi adanya korelasi tinggi antar variabel yang dapat mengindikasikan potensi multikolinearitas dalam model regresi. Dalam *heatmap* ini, warna merah menunjukkan korelasi positif, dan warna biru menunjukkan korelasi negatif. Semakin terang atau pekat warna merahnya, semakin kuat korelasi positifnya (mendekati +1). Sebaliknya, semakin terang atau pekat warna birunya, semakin kuat korelasi negatifnya (mendekati -1). Warna mendekati putih di bagian menunjukkan korelasi yang mendekati nol.



Gambar 1 *Correlation Heatmap* variabel prediktor

Berdasarkan matriks korelasi tersebut, Kepadatan Penduduk (X_8) memiliki korelasi tertinggi terhadap Tingkat Pengangguran Terbuka (Y) sebesar 0,70, diikuti oleh PDRB (X_2) sebesar 0,62 dan Jumlah Penduduk (X_1) sebesar 0,43, yang mengindikasikan wilayah dengan kepadatan penduduk dan aktivitas ekonomi tinggi cenderung memiliki tingkat pengangguran yang lebih tinggi pula, kemungkinan akibat persaingan tenaga kerja yang lebih ketat. Sementara itu, variabel Rasio Ketergantungan (X_3), Rasio Gini (X_5), Rasio Jenis Kelamin (X_6), dan Umur Harapan Hidup (X_7) menunjukkan korelasi yang relatif lemah terhadap TPT (berkisar -0,06 hingga 0,29). Di sisi lain, matriks korelasi juga mengindikasikan multikolinearitas yang cukup serius antar variabel prediktor, terutama pada Jumlah Penduduk (X_1), PDRB (X_2), Jumlah Penduduk Miskin (X_4), dan Kepadatan Penduduk (X_8) yang saling berkorelasi tinggi. Selain itu, Rasio Jenis Kelamin (X_6) dan Umur Harapan Hidup (X_7) juga menunjukkan korelasi yang cukup tinggi sebesar 0,66. Tingginya korelasi antar variabel-variabel tersebut wajar terjadi karena secara teori saling berkaitan, di mana wilayah berpenduduk besar cenderung memiliki aktivitas ekonomi, jumlah penduduk miskin, dan kepadatan penduduk yang tinggi pula.

3.3 Uji Asumsi Klasik

Uji Asumsi klasik merupakan prasyarat dalam analisis regresi berganda. Pengujian ini harus dipenuhi agar penaksiran parameter dan koefisien regresi tidak bias. Hasil uji asumsi klasik pada data dijelaskan sebagai berikut.

3.3.1. Uji Normalitas

Pengujian normalitas residual dilakukan menggunakan uji *Shapiro-Wilk*, dengan menilai signifikansi hasil uji statistik terhadap residual model MKT. Hasil uji normalitas dari residual model disajikan pada tabel 3.

Tabel 3. Hasil Uji *Shapiro Wilk*

<i>SW Statistic</i>	<i>P – value</i>
0,903	0,026

Berdasarkan Tabel 3, diperoleh nilai p -value uji *Shapiro-Wilk* sebesar 0,026. Karena $p - value < \alpha = 0,05$, maka H_0 ditolak. Artinya, residual tidak berdistribusi normal pada taraf signifikansi 5%.

3.3.2. Uji Multikolinearitas

Uji multikolinearitas bertujuan untuk mendeteksi korelasi antar variabel prediktor. Model regresi linier yang baik mensyaratkan tidak adanya multikolinearitas yang tinggi antar variabel prediktor. Multikolinearitas diuji menggunakan nilai *Variance Inflation Factor* (VIF). Terdapat masalah multikolinearitas jika nilai VIF > 10 . Hasil uji multikolinearitas disajikan pada tabel 4.

Tabel 4. Hasil Uji Multikolinearitas

Variabel	Nilai VIF
X_1	21,995
X_2	24,346
X_3	1,597
X_4	10,910
X_5	1,485
X_6	2,673
X_7	3,321
X_8	14,749

Berdasarkan tabel 4, diperoleh nilai VIF pada variabel X_1, X_2, X_4 dan $X_8 > 10$, yang mengindikasikan adanya masalah multikolinearitas dalam model. Kondisi ini menunjukkan bahwa kedua variabel tersebut memiliki korelasi yang cukup tinggi dengan variabel prediktor lainnya.

3.4 Identifikasi Pencilan Berpengaruh

Pada uji asumsi klasik sebelumnya diperoleh kesimpulan bahwa data tidak berdistribusi normal, yang diduga disebabkan oleh adanya pencilan. Oleh karena itu, dilakukan identifikasi pencilan berpengaruh.

3.4.1. Identifikasi Pencilan

Identifikasi pencilan dilakukan untuk mendeteksi pengamatan yang menyimpang pada variabel respon maupun variabel prediktor. Pencilan pada variabel respon diidentifikasi menggunakan *Studentized Deleted Residual*, sedangkan pencilan pada variabel prediktor diidentifikasi menggunakan *leverage*. Pengamatan dikategorikan sebagai pencilan apabila nilai $|TRES_i|$ atau *leverage* melebihi titik kritis masing-masing. Hasil identifikasi pencilan disajikan pada Tabel 5. Hasil Perhitungan Nilai *Studentized residual* dan *leverage* secara lengkap disajikan pada Lampiran 2.

Tabel 5. Hasil Identifikasi Pencilan

Data Pengamatan ke- <i>i</i>	Variabel Respon		Variabel Prediktor	
	TRES	Titik Kritis	Leverage Value	Titik Kritis
10	2,6305		0,2302	
21	1,9796	2,1314	0,7142	0,6666
22	0,7973		0,9891	
24	2,7185		0,1641	

Berdasarkan Tabel 5, hasil identifikasi pencilan menunjukkan bahwa terdapat beberapa pengamatan yang terindikasi sebagai pencilan, baik pada variabel respon maupun variabel prediktor. Berdasarkan nilai *Studentized Residual*, pengamatan ke-10 dan ke-24 teridentifikasi sebagai pencilan pada variabel respon karena memiliki nilai $|TRES_i|$ yang melebihi titik kritis sebesar 2,1314. Sementara itu, berdasarkan nilai *leverage*, pengamatan ke-21 dan ke-22 teridentifikasi sebagai pencilan pada variabel prediktor karena memiliki nilai leverage yang lebih besar dari titik kritis sebesar 0,6666.

3.4.2. Identifikasi Amatan Berpengaruh

Metode yang digunakan untuk mendeteksi amatan berpengaruh yaitu DFFITS. Nilai DFFITS dihitung berdasarkan residual masing-masing observasi, kemudian dibandingkan dengan batas kritis untuk menentukan apakah suatu observasi tergolong pencilan yang berpengaruh terhadap model. Dalam penelitian ini jumlah parameter yang digunakan adalah $p = 8$ dan jumlah observasi $n = 24$. Suatu data dikatakan pencilan apabila nilai $|DFFITS|$ melebihi batas kritis, yaitu:

$$2\sqrt{\frac{p}{n}} = 2\sqrt{\frac{8}{24}} = 1,1547$$

Hasil identifikasi pencilan ditampilkan pada tabel 6. Hasil Perhitungan Nilai DFFITS secara lengkap disajikan pada Lampiran 2.

Tabel 6. Hasil Identifikasi Amatan Berpengaruh

Data Pengamatan ke- <i>i</i>	$ DFFITS_i $
6	1,2948
10	1,4385
21	3,1293
22	7,5874
24	1,2046

Berdasarkan Tabel 6, nilai $|DFFITS|$ pada data ke-6, ke-10, ke-21, ke-22 dan ke-24 melebihi batas kritis yaitu 1,1547. Dengan demikian, kelima observasi tersebut teridentifikasi sebagai pencilan berpengaruh terhadap model regresi. Kondisi ini mengindikasikan bahwa keberadaan data tersebut berpotensi memengaruhi hasil estimasi parameter secara signifikan.

3.4.3. Pencilan Berpengaruh

Pencilan berpengaruh merupakan pengamatan yang teridentifikasi sebagai pencilan sekaligus memiliki pengaruh signifikan terhadap model. Berdasarkan hasil pendeteksian pencilan dan amatan berpengaruh yang telah dilakukan sebelumnya, dapat disimpulkan bahwa pengamatan yang tergolong sebagai pencilan berpengaruh disajikan pada Tabel 7.

Tabel 7. Hasil Identifikasi Pencilan Berpengaruh

Data Pengamatan ke- <i>i</i>	Pencilan		Amatan Berpengaruh
	<i>TRES</i>	<i>Leverage</i>	<i>DFFIT</i> _{<i>i</i>}
6	Tidak	Tidak	Ya
10	Ya	Tidak	Ya
21	Tidak	Ya	Ya
22	Tidak	Ya	Ya
24	Ya	Tidak	Ya

Berdasarkan Tabel 7, diperoleh bahwa data pengamatan ke-10, ke-21, ke-22 dan ke-24 merupakan pencilan sekaligus pengamatan berpengaruh sehingga dapat disimpulkan bahwa pengamatan tersebut merupakan pencilan berpengaruh. Sedangkan data pengamatan ke-6 tidak memenuhi kriteria pencilan berpengaruh karena tidak memenuhi kriteria di kedua kategori secara bersamaan, yaitu pencilan dan amatan berpengaruh. Kondisi ini mengindikasikan bahwa keberadaan data tersebut berpotensi memengaruhi hasil estimasi parameter secara signifikan. Membuang pencilan berpengaruh akan memengaruhi model yang terbentuk, sehingga diperlukan pendugaan parameter yang tahan terhadap pencilan tersebut.

3.5 Transformasi Menggunakan Metode Pemusatan dan Penskalaan

Sebelum dilakukan pemodelan *Robust* MJRR-GM, data pada variabel *X* dan *Y* terlebih dahulu ditransformasi melalui proses pemusatan dan penskalaan sesuai dengan persamaan (11) dan (12). Perhitungan transformasi tersebut ditunjukkan sebagai berikut:

$$\begin{aligned}
 X_{ij}^* &= \frac{X_{ij} - \bar{X}_j}{\sqrt{n-1} S_X} & Y_i^* &= \frac{Y_i - \bar{Y}}{\sqrt{n-1} S_Y} \\
 X_{1,1}^* &= \frac{142,7 - 394,307}{\sqrt{24-1} (284,467)} = -0,184 & Y_1^* &= \frac{2,05 - 3,709}{\sqrt{24-1} (1,960)} = -0,176 \\
 X_{2,1}^* &= \frac{454,72 - 394,307}{\sqrt{24-1} (284,467)} = 0,044 & Y_2^* &= \frac{2,23 - 3,709}{\sqrt{24-1} (1,960)} = -0,157 \\
 &\vdots & &\vdots \\
 X_{23,8}^* &= \frac{1795 - 673,208}{\sqrt{24-1} (2,308)} = 0,140 & Y_{23}^* &= \frac{5,23 - 3,709}{\sqrt{24-1} (1,960)} = 0,162
 \end{aligned}$$

$$X_{24,8}^* = \frac{716 - 673,208}{\sqrt{24 - 1} (2,308)} = 0,005$$

$$Y_{24}^* = \frac{7,64 - 3,709}{\sqrt{24 - 1} (1,960)} = 0,419$$

Hasil transformasi data pada variabel prediktor (X^*) dan variabel respon (Y^*) secara keseluruhan terlampir pada Lampiran 3. Proses analisis selanjutnya akan menggunakan data hasil transformasi.

3.6 Pemodelan *Robust Modified Jackknife Ridge* dengan *GM-Estimator*

3.6.1 Membentuk Matriks Ortogonal Pada Variabel Prediktor

Tahap awal dalam pemodelan *Robust MJRR-GM* adalah membentuk matriks ortogonal pada variabel prediktor. Proses ini dilakukan dengan menghitung nilai eigen dan vektor eigen dari matriks $X^{*'}X^*$ berdasarkan data hasil transformasi pada tahap sebelumnya. Nilai eigen yang diperoleh disajikan pada tabel 8.

Tabel 8. Nilai Eigen

Simbol	Nilai Eigen
λ_1	3,572
λ_2	1,817
λ_3	1,250
λ_4	0,672
λ_5	0,023
λ_6	0,036
λ_7	0,210
λ_8	0,416

Berdasarkan nilai eigen tersebut diperoleh vektor-vektor eigen yang selanjutnya membentuk matriks T , yang ditunjukkan sebagai berikut:

$$T = \begin{bmatrix} -0,510 & -0,019 & 0,007 & 0,232 & 0,539 & -0,570 & 0,265 & 0,020 \\ -0,507 & 0,087 & 0,012 & -0,153 & -0,681 & -0,367 & -0,258 & 0,213 \\ 0,177 & 0,305 & -0,628 & 0,342 & 0,0567 & -0,016 & -0,118 & 0,589 \\ -0,436 & -0,082 & 0,049 & 0,647 & -0,217 & 0,540 & 0,193 & -0,076 \\ -0,188 & -0,038 & -0,744 & -0,178 & -0,039 & 0,026 & -0,012 & -0,612 \\ 0,051 & 0,638 & 0,217 & 0,315 & 0,093 & -0,098 & -0,507 & -0,410 \\ -0,050 & 0,683 & 0,038 & -0,271 & -0,118 & 0,105 & 0,656 & 0,005 \\ -0,468 & 0,130 & 0,016 & -0,427 & 0,414 & 0,477 & -0,352 & 0,241 \end{bmatrix}$$

Selanjutnya akan dibentuk matriks variabel prediktor yang ortogonal (Z) dengan $Z = X^*T$. Variabel ortogonal adalah variabel prediktor yang memiliki nilai korelasi sesama variabel prediktor sama dengan nol. Adapun nilai variabel ortogonal Z dapat dilihat pada Lampiran 4. Pada tahap selanjutnya, variabel Z inilah yang digunakan sebagai pengganti variabel X^* dalam proses estimasi, sehingga analisis dilakukan pada data hasil transformasi ortogonal.

3.6.2 Estimasi Parameter Metode Kuadrat Terkecil

Tahap selanjutnya dalam pemodelan *Robust MJRR-GM* adalah mengestimasi parameter menggunakan MKT. Estimasi MKT ini berfungsi sebagai estimator awal

(*initial estimator*) yang digunakan pada tahap selanjutnya untuk memperoleh estimasi parameter *robust GM-estimator*. Parameter MKT diestimasi menggunakan rumus :

$$\hat{\gamma}_{mkt} = (\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{Y}^*$$

Hasil estimasi parameter MKT ditunjukkan pada tabel 9.

Tabel 9. Estimasi Parameter MKT ($\hat{\gamma}_{mkt}$)

Parameter	Estimasi
γ_1	-0,289
γ_2	0,222
γ_3	-0,084
γ_4	-0,425
γ_5	0,119
γ_6	0,490
γ_7	-0,267
γ_8	0,088

3.6.3 Estimasi Parameter *GM-Estimator*

Pada tahap sebelumnya, telah diperoleh estimasi awal melalui MKT. Tahap selanjutnya adalah melakukan estimasi parameter *robust* menggunakan *GM-estimator*. Langkah pertama dalam metode ini adalah menghitung skala *robust* GM ($\hat{\sigma}_{GM}$) yang diperoleh dari residual hasil estimasi MKT. Residual e_i dihitung menggunakan persamaan $e_i = y_i^* - \hat{y}_i^*$, dengan hasil sebagai berikut:

$$e_1 = y_1^* - \hat{y}_1^* = -0,176 - (-0,038) = -0,138$$

$$e_2 = y_2^* - \hat{y}_2^* = -0,157 - (-0,071) = -0,085$$

$$e_3 = y_3^* - \hat{y}_3^* = -0,121 - (-0,044) = -0,076$$

⋮

$$e_{23} = y_{23}^* - \hat{y}_{23}^* = 0,161 - 0,201 = -0,039$$

$$e_{24} = y_{24}^* - \hat{y}_{24}^* = 0,418 - 0,057 = 0,360$$

Residual yang diperoleh selanjutnya digunakan untuk menghitung skala *robust GM-estimator*, dengan perhitungannya sebagai berikut:

$$\hat{\sigma}_{GM} = 1,4825 \text{ MAD}$$

$$\hat{\sigma}_{GM} = 1,4825 (\text{median}\{|e_i - \text{median}(e_i)|\})$$

dengan,

$$\text{median}(e_i) = \text{median}\{-0,138, -0,085, \dots, 0,360\} = -0,034$$

Sehingga:

$$\begin{aligned} \hat{\sigma}_{GM} &= 1,4825 (\text{median}\{|e_i - (-0,034)|\}) \\ &= 1,4825 (\text{median}\{|(e_1 - (-0,034))|, |(e_2 - (-0,034))|, \dots, |(e_{24} - (-0,034))|\}) \\ &= 1,4825 (\text{median}\{|-0,138 - (-0,034)|, |-0,085 - (-0,034)|, \dots, \\ &\quad |0,360 - (-0,034)|\}) \\ &= 1,4825 (0,052) = 0,078 \end{aligned}$$

Selanjutnya, menghitung nilai π_i untuk menurunkan bobot pada pengamatan yang memiliki nilai *leverage* tinggi. Nilai *leverage* (h_{ii}) diperoleh dari diagonal matriks hat, yaitu $\mathbf{H} = \mathbf{Z}'(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}$. Nilai π_i dihitung menggunakan rumus $\pi_i = \sqrt{1 - h_{ii}}$. Perhitungannya dapat dilihat sebagai berikut:

$$\pi_1 = \sqrt{1 - h_{11}} = \sqrt{1 - 0,124} = 0,935$$

$$\pi_2 = \sqrt{1 - h_{22}} = \sqrt{1 - 0,161} = 0,915$$

$$\pi_3 = \sqrt{1 - h_{33}} = \sqrt{1 - 0,459} = 0,735$$

⋮

$$\pi_{23} = \sqrt{1 - h_{2323}} = \sqrt{1 - 0,547} = 0,672$$

$$\pi_{24} = \sqrt{1 - h_{2424}} = \sqrt{1 - 0,122} = 0,936$$

Nilai $\hat{\sigma}_{GM}$ dan π_i tersebut selanjutnya digunakan untuk menghitung nilai skala residual (u_i) dengan $u_i = \frac{e_i}{\pi \hat{\sigma}_{GM}}$, perhitungannya ditunjukkan sebagai berikut:

$$u_1 = \frac{-0,138}{(0,935)(0,078)} = -1,883$$

$$u_2 = \frac{-0,085}{(0,915)(0,078)} = -1,194$$

$$u_3 = \frac{-0,076}{(0,735)(0,078)} = -1,331$$

⋮

$$u_{23} = \frac{-0,039}{(0,672)(0,078)} = -0,748$$

$$u_{24} = \frac{0,360}{(0,936)(0,078)} = 4,910$$

Hasil perhitungan nilai e_i , h_{ii} , π_i dan u_i dilampirkan pada Lampiran 5. Nilai u_i tersebut digunakan sebagai dasar untuk menghitung nilai bobot awal (w_i). Perhitungan nilai bobot akan menggunakan pembobot *Huber*, yang mana dilihat dari nilai absolut $|u_i|$. Apabila $|u_i| \leq c$ maka nilai $w_i = 1$ dan jika $|u_i| > c$ maka nilai $w_i = \frac{c}{|u_i|}$. Dimana nilai c dengan fungsi pembobot *huber* yaitu:

$$c = 2 \sqrt{\frac{p+1}{n}} = 2 \sqrt{\frac{9}{24}} = 1,224$$

Perhitungan nilai bobot awal w_i ditunjukkan sebagai berikut:

$$\text{Untuk } w_1 \rightarrow \text{karena nilai } |u_1| = 1,883 > c, \text{ maka : } w_1 = \frac{1,224}{1,883} = 0,654$$

$$\text{Untuk } w_2 \rightarrow \text{karena nilai } |u_2| = 1,194 < c, \text{ maka : } w_2 = 1$$

$$\text{Untuk } w_3 \rightarrow \text{karena nilai } |u_3| = 1,331 > c, \text{ maka : } w_3 = \frac{1,224}{1,331} = 0,920$$

⋮

$$\text{Untuk } w_{23} \rightarrow \text{karena nilai } |u_{23}| = 0,748 < c, \text{ maka : } w_{23} = 1$$

$$\text{Untuk } w_{24} \rightarrow \text{karena nilai } |u_{24}| = 4,910 > c, \text{ maka : } w_{24} = \frac{1,224}{4,910} = 0,249$$

Hasil perhitungan nilai w_i secara lengkap dilampirkan pada Lampiran 5.

Selanjutnya, dibentuk matriks bobot W berukuran 24×24 yang mana diagonal utamanya merupakan nilai w_i yang telah diperoleh. Matriks tersebut selanjutnya digunakan untuk mengestimasi parameter *robust GM-estimator* menggunakan persamaan (22), dengan W sebagai matriks bobot *robust* pada iterasi pertama. Estimasi parameter untuk iterasi pertama diperoleh sebagai berikut:

$$\hat{\gamma}_{GM}^{(1)} = \begin{bmatrix} -0,294 \\ 0,288 \\ -0,116 \\ -0,295 \\ 0,052 \\ 0,500 \\ -0,337 \\ 0,101 \end{bmatrix}$$

Iterasi dilanjutkan hingga memperoleh nilai $\hat{\gamma}_{GM}$ yang konvergen. Berdasarkan hasil perhitungan, konvergensi tercapai pada iterasi ke-46. Hasil iterasi GM-Estimasi disajikan pada tabel 10, sedangkan hasil iterasi estimasi parameter secara lengkap disajikan pada Lampiran 6.

Tabel 10. Hasil Iterasi Estimasi Parameter Menggunakan *Robust GM-estimator*

Iterasi	Parameter							
	$\hat{\gamma}_1$	$\hat{\gamma}_2$	$\hat{\gamma}_3$	$\hat{\gamma}_4$	$\hat{\gamma}_5$	$\hat{\gamma}_6$	$\hat{\gamma}_7$	$\hat{\gamma}_8$
MKT	-0,2898	0,2227	-0,0845	-0,4259	0,1195	0,4907	-0,2670	0,0888
1	-0,2946	0,2906	-0,1168	-0,2960	0,0528	0,5004	-0,3375	0,1020
2	-0,2903	0,3239	-0,1415	-0,2542	0,0658	0,5075	-0,3437	0,1528
3	-0,2884	0,3370	-0,1521	-0,2369	0,0858	0,5179	-0,3387	0,1826
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
45	-0,2889	0,3459	-0,1599	-0,2190	0,1330	0,5140	-0,3205	0,1990
46	-0,2890	0,3459	-0,1599	-0,2190	0,1330	0,5140	-0,3205	0,1990

Berdasarkan Tabel 10, terlihat bahwa nilai koefisien regresi tidak mengalami perubahan signifikan mulai dari iterasi ke-46. Oleh karena itu, hasil koefisien pada iterasi ke-46 digunakan sebagai estimasi akhir dalam regresi *robust GM-estimator*, sebagaimana ditunjukkan pada Tabel 11.

Tabel 11. Hasil Estimasi Parameter *Robust GM-estimator* ($\hat{\gamma}_{GM}$)

Parameter	Estimasi
γ_1	-0,289
γ_2	0,346
γ_3	-0,160
γ_4	-0,219
γ_5	0,133
γ_6	0,514
γ_7	-0,321
γ_8	0,199

Hasil estimasi parameter pada tabel 11 akan digunakan untuk tahap selanjutnya dalam mengestimasi parameter *Robust MJRR-GM*.

3.6.4 Estimasi Parameter *Robust MJRR GM-Estimator*

Setelah diperoleh estimasi parameter dengan pendekatan regresi *robust GM-estimator*, tahap selanjutnya adalah melakukan estimasi parameter menggunakan *Robust Modified Jackknife Ridge Regression GM-estimator* (Robust MJRR-GM). Pendekatan ini digunakan untuk menghasilkan model yang lebih stabil terhadap pengaruh pencilan sekaligus mengatasi masalah multikolinearitas pada variabel prediktor.

Sebelum melakukan estimasi parameter *Robust MJRR-GM*, terlebih dahulu ditentukan nilai konstanta bias ($k_{*(GM)}$) menggunakan Persamaan (49). Langkah awal dalam penentuan konstanta adalah menghitung kuadrat tengah residual ($\hat{\sigma}_{GM}^2$), yang diperoleh sebagai berikut :

$$\hat{\sigma}_{GM}^2 = \frac{(Y^* - Z\hat{Y}_{GM})'(Y^* - Z\hat{Y}_{GM})}{24 - 8 - 1} = 0,032$$

Maka, nilai konstanta bias ($k_{*(GM)}$) diperoleh sebagai berikut:

$$k_{*(GM)} = \frac{p\hat{\sigma}_{GM}^2}{\hat{Y}_{GM}'\hat{Y}_{GM}} = \frac{(8)(0,032)}{\hat{Y}_{GM}'\hat{Y}_{GM}} = 0,371$$

Nilai konstanta bias $k_{*(GM)}$ tersebut digunakan untuk membentuk matriks k_*I , yaitu matriks diagonal dengan nilai $k_{*(GM)}$ pada setiap elemen diagonal utamanya, yaitu sebagai berikut:

$$k_*I = \begin{bmatrix} 0,371 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0,371 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0,371 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0,371 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0,371 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0,371 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0,371 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0,371 \end{bmatrix}$$

Selanjutnya, dibentuk matriks A dengan $A = Z'Z + k_*I$, sehingga diperoleh :

$$A = \begin{bmatrix} 3,943 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2,188 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1,621 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1,044 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0,394 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0,407 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0,581 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0,787 \end{bmatrix}$$

Matriks k_*I dan matriks A yang telah diperoleh tersebut kemudian digunakan untuk estimasi parameter *Robust MJRR-GM* ($\hat{Y}_{RMJRR}$) menggunakan persamaan (48), sehingga diperoleh hasil estimasi yang dapat dilihat pada tabel 12.

Tabel 12. Hasil Estimasi Parameter *Robust* MJRR-GM pada Ruang Ortogonal ($\hat{\gamma}_{RMJRR}$)

Parameter	Estimasi
γ_1	-0,259
γ_2	0,278
γ_3	-0,116
γ_4	-0,123
γ_5	0,001
γ_6	0,008
γ_7	-0,069
γ_8	0,082

Setelah mendapatkan nilai $\hat{\gamma}_{RMJRR}$, selanjutnya menghitung estimasi parameter *Robust* MJRR-GM pada ruang parameter asli ($\hat{\beta}_{RMJRR}^*$) yaitu menggunakan persamaan $\hat{\beta}^* = T\hat{\gamma}_{RMJRR}$, sehingga hasil estimasi dapat dilihat pada tabel 13.

Tabel 13. Hasil Estimasi Parameter *Robust* MJRR-GM Pada Ruang Parameter Asli ($\hat{\beta}_{RMJRR}^*$)

Parameter	Estimasi
β_1^*	0,077
β_2^*	0,205
β_3^*	0,126
β_4^*	-0,010
β_5^*	0,098
β_6^*	0,101
β_7^*	0,188
β_8^*	0,256

Selanjutnya, nilai $\hat{\beta}_{RMJRR}^*$ yang diperoleh tersebut akan dikembalikan ke bentuk semula (sebelum standarisasi) dengan menggunakan persamaan (13), dan menghitung nilai intersep β_0 menggunakan persamaan (14). Proses pengembalian bentuk ini menggunakan rata-rata dan simpangan baku variabel yang telah diperoleh pada tahap awal. Adapun hasil pengembalian bentuk dari standarisasi ditunjukkan sebagai berikut:

$$\beta_1 = \left(\frac{S_y}{S_{x_1}} \right) \beta_1^* = \left(\frac{1,960}{284,467} \right) \times (0,077) = 5,321 \times 10^{-4}$$

$$\beta_2 = \left(\frac{S_y}{S_{x_2}} \right) \beta_2^* = \left(\frac{1,960}{46.671,791} \right) \times (0,205) = 8,619 \times 10^{-6}$$

$$\beta_3 = \left(\frac{S_y}{S_{x_3}} \right) \beta_3^* = \left(\frac{1,960}{2,211} \right) \times (0,126) = 1,121 \times 10^{-1}$$

$$\beta_4 = \left(\frac{S_Y}{S_{x_4}} \right) \beta_4^* = \left(\frac{1,960}{18,271} \right) \times (-0,010) = -1,152 \times 10^{-3}$$

$$\beta_5 = \left(\frac{S_Y}{S_{x_5}} \right) \beta_5^* = \left(\frac{1,960}{0,035} \right) \times (0,098) = 5,365$$

$$\beta_6 = \left(\frac{S_Y}{S_{x_6}} \right) \beta_6^* = \left(\frac{1,960}{3,378} \right) \times (0,101) = 5,878 \times 10^{-2}$$

$$\beta_7 = \left(\frac{S_Y}{S_{x_7}} \right) \beta_7^* = \left(\frac{1,960}{1,924} \right) \times (0,188) = 1,921 \times 10^{-1}$$

$$\beta_8 = \left(\frac{S_Y}{S_{x_8}} \right) \beta_8^* = \left(\frac{1,960}{1.659,440} \right) \times (0,256) = 3,032 \times 10^{-4}$$

$$\begin{aligned} \beta_0 &= \bar{Y} - \beta_1 \bar{X}_1 - \beta_2 \bar{X}_2 - \beta_3 \bar{X}_3 - \beta_4 \bar{X}_4 - \beta_5 \bar{X}_5 - \beta_6 \bar{X}_6 - \beta_7 \bar{X}_7 - \beta_8 \bar{X}_8 \\ &= 3,709 - (5,321 \times 10^{-4})(394,307) - (8,619 \times 10^{-6})(29.071,635) - \\ &\quad (1,494 \times 10^{-4})(45,242) - (-1,152 \times 10^{-3})(30,687) - (5,365)(0,330) - \\ &\quad (5,878 \times 10^{-2})(99,004) - (1,921 \times 10^{-1})(70,347) - (3,032 \times 10^{-4})(673,208) \\ &= -23,096 \end{aligned}$$

Dengan demikian, persamaan model *Robust* MJRR-GM adalah sebagai berikut:

$$\hat{Y} = -23,096 + 0,000532X_1 + 0,000009X_2 + 0,112105X_3 - 0,001152X_4 + 5,365206X_5 + 0,058776X_6 + 0,192053X_7 + 0,000303X_8$$

Berdasarkan model regresi yang diperoleh, konstanta sebesar -23,096 menunjukkan bahwa apabila seluruh variabel prediktor dianggap konstan bernilai nol, maka Tingkat Pengangguran Terbuka (TPT) diperkirakan sebesar -23,096 persen. Nilai konstanta ini menggambarkan tingkat dasar TPT ketika pengaruh seluruh variabel prediktor dalam model dianggap tidak ada. Koefisien regresi pada variabel jumlah penduduk (X_1) sebesar 0,000532 menunjukkan bahwa setiap kenaikan jumlah penduduk sebesar satu satuan, dengan asumsi variabel lain konstan, cenderung meningkatkan TPT sebesar 0,000532 persen. Koefisien regresi pada variabel PDRB atas dasar harga berlaku (X_2) sebesar 0,000009 menunjukkan bahwa setiap kenaikan PDRB sebesar satu satuan akan meningkatkan TPT sebesar 0,000009 persen, dengan asumsi variabel lain konstan. Koefisien regresi pada variabel rasio ketergantungan (X_3) sebesar 0,112 menunjukkan bahwa setiap kenaikan rasio ketergantungan sebesar satu satuan cenderung meningkatkan TPT sebesar 0,112 persen. Selanjutnya, koefisien regresi pada variabel jumlah penduduk miskin (X_4) sebesar -0,001152 menunjukkan bahwa setiap kenaikan jumlah penduduk miskin sebesar satu satuan, dengan asumsi variabel lain konstan, cenderung menurunkan TPT sebesar 0,001152 persen. Koefisien regresi pada variabel rasio gini (X_5) sebesar 5,365 menunjukkan bahwa setiap kenaikan rasio gini sebesar satu satuan akan meningkatkan TPT sebesar 5,365 persen. Koefisien regresi pada variabel rasio jenis kelamin (X_6) sebesar 0,059 menunjukkan bahwa setiap kenaikan rasio jenis kelamin sebesar satu satuan cenderung meningkatkan TPT sebesar 0,059 persen. Koefisien regresi pada variabel umur harapan hidup (X_7) sebesar 0,192 menunjukkan bahwa setiap kenaikan umur harapan hidup sebesar satu satuan akan meningkatkan TPT sebesar 0,192 persen. Sementara itu, koefisien regresi pada variabel kepadatan penduduk (X_8) sebesar 0,000303 menunjukkan

bahwa setiap kenaikan kepadatan penduduk sebesar satu satuan cenderung meningkatkan TPT sebesar 0,000303 persen, dengan asumsi variabel lain konstan.

Berdasarkan arah koefisien regresi yang diperoleh, sebagian besar variabel prediktor memiliki hubungan positif terhadap Tingkat Pengangguran Terbuka (TPT), sedangkan jumlah penduduk miskin memiliki hubungan negatif. Hubungan positif pada jumlah penduduk (X_1) mengindikasikan bahwa semakin banyak penduduk, semakin besar pula jumlah angkatan kerja sehingga persaingan memperoleh pekerjaan meningkat. PDRB (X_2) yang juga berhubungan positif menunjukkan bahwa peningkatan aktivitas ekonomi belum tentu diikuti oleh peningkatan penyerapan tenaga kerja secara proporsional. Rasio ketergantungan (X_3) mencerminkan meningkatnya beban penduduk usia produktif dalam menopang penduduk usia nonproduktif sehingga dapat memperbesar tekanan terhadap kesempatan kerja. Rasio Gini (X_5) yang berhubungan positif mengindikasikan bahwa ketimpangan pendapatan dapat menyebabkan kesempatan kerja yang kurang merata. Rasio jenis kelamin (X_6) menunjukkan bahwa perubahan komposisi penduduk menurut jenis kelamin dapat memengaruhi keseimbangan penawaran tenaga kerja sehingga berdampak pada dinamika pasar kerja. Umur harapan hidup (X_7) yang berhubungan positif mengindikasikan bahwa kabupaten/kota dengan kualitas hidup yang lebih baik cenderung memiliki pasar kerja yang lebih kompetitif, sehingga tingkat pengangguran terbuka relatif lebih tinggi, sedangkan kepadatan penduduk (X_8) berpotensi meningkatkan persaingan dalam memperoleh pekerjaan. Di sisi lain, jumlah penduduk miskin (X_4) memiliki hubungan negatif terhadap TPT. Hasil ini bisa terjadi karena sebagian penduduk miskin tetap bekerja pada sektor informal atau pekerjaan berpendapatan rendah sehingga tidak termasuk dalam kategori pengangguran terbuka meskipun tingkat kesejahteraannya masih rendah.

3.7 Uji Signifikansi Parameter

Setelah dilakukan pemodelan, langkah selanjutnya adalah melakukan uji signifikansi parameter. Uji signifikansi parameter dilakukan melalui uji simultan dan uji parsial untuk mengetahui apakah variabel-variabel prediktor berpengaruh secara bersama-sama maupun secara individu terhadap variabel respon pada masing-masing model regresi.

3.7.1 Uji Simultan

Uji signifikansi parameter secara simultan dilakukan untuk mengetahui pengaruh variabel prediktor terhadap tingkat pengangguran terbuka di Provinsi Sulawesi Selatan pada tahun 2024 secara bersama-sama dalam model. Uji signifikansi parameter model secara simultan dilakukan dengan uji F menggunakan statistik uji pada persamaan (25) dengan hipotesis berikut :

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_8 = 0$$

$$H_1 : \text{Minimal ada satu } \beta_j \neq 0 \text{ untuk } j = 1, 2, \dots, 8$$

Hasil statistik uji F dengan $\alpha = 0,05$ dapat dilihat pada Tabel 14.

Tabel 14. Hasil Uji Simultan Parameter Model *Robust* MJRR-GM

F_{Hit}	$p-value$
10,382	0.000

Berdasarkan tabel 14, diperoleh nilai $F_{hitung} = 10,382 > F_{(0,05, 8, 15)} = 2,64$ serta nilai $p-value = 0,000 < \alpha = 0,05$, maka H_0 ditolak, yang berarti variabel prediktor secara keseluruhan berpengaruh signifikan terhadap variabel respon dalam model regresi yang dibentuk. Dengan demikian, terdapat cukup bukti bahwa variabel $X_1, X_2, X_3, X_4, X_5, X_6, X_7$ dan X_8 secara simultan berpengaruh signifikan terhadap Tingkat Pengangguran Terbuka.

3.7.2 Uji Parsial

Setelah melakukan uji simultan, langkah selanjutnya adalah melakukan uji parsial untuk menguji signifikansi dari masing - masing koefisien regresi dengan mencari tahu apakah setiap variabel prediktor secara individu berpengaruh signifikan terhadap variabel respon. Uji signifikansi parameter model secara parsial dilakukan dengan uji t menggunakan statistik uji pada persamaan (26) dengan hipotesis berikut:

$$H_0 : \beta_j = 0, \text{ dengan } j = 1, 2, \dots, 8$$

$$H_1 : \beta_j \neq 0$$

Hasil statistik uji t dengan $\alpha = 0,05$ dapat dilihat pada Tabel 15.

Tabel 15. Hasil Uji Parsial Parameter Model *Robust* MJRR-GM

Variabel	Coefficient(β_j)	SE(β_j)	t_{hit}	P-Value
X_1	$9,121 \times 10^{-5}$	$1,012 \times 10^{-4}$	0,901	0,381
X_2	$2,424 \times 10^{-4}$	$1,274 \times 10^{-4}$	1,901	0,076
X_3	$1,494 \times 10^{-4}$	$1,392 \times 10^{-4}$	1,073	0,300
X_4	$-1,268 \times 10^{-5}$	$1,462 \times 10^{-4}$	-0,086	0,932
X_5	$1,159 \times 10^{-4}$	$9,324 \times 10^{-6}$	12,438	0,000
X_6	$1,196 \times 10^{-4}$	$1,700 \times 10^{-5}$	7,035	0,000
X_7	$2,226 \times 10^{-4}$	$9,963 \times 10^{-5}$	2,234	0,041
X_8	$3,032 \times 10^{-4}$	$1,357 \times 10^{-4}$	2,223	0,041

Berdasarkan tabel 15, diperoleh bahwa variabel X_5, X_6, X_7 dan X_8 memiliki nilai $|t_{hitung}| > t_{(\frac{0,05}{2}, 15)} = 2,1009$ serta $p-value < 0,05$, sehingga H_0 ditolak. Artinya, variabel Rasio Gini (X_5), Rasio Jenis Kelamin (X_6), Umur Harapan Hidup (X_7) dan Kepadatan Penduduk (X_8) berpengaruh signifikan terhadap Tingkat Pengangguran Terbuka.

Sementara itu, variabel X_1, X_2, X_3 dan X_4 memiliki nilai $|t_{hitung}| < t_{(\frac{0,05}{2}, 15)} = 2,1009$ dan $p-value > 0,05$, sehingga tidak cukup bukti untuk menolak H_0 . Dengan demikian, Jumlah Penduduk (X_1), PDRB (X_2), Rasio Ketergantungan (X_3) dan Jumlah Penduduk Miskin (X_4) tidak berpengaruh signifikan terhadap Tingkat Pengangguran Terbuka.

3.8 Hasil Analisis Data Simulasi

Analisis data simulasi pada penelitian ini ditujukan untuk mengevaluasi stabilitas dan ketangguhan metode Robust MJRR-GM pada kondisi multikolinearitas dan kontaminasi pencilan yang dikendalikan. Data hasil simulasi dapat dilihat pada Lampiran 7.

3.8.1 Karakteristik Data Simulasi

Pada tahap awal, dilakukan analisis statistik deskriptif terhadap data simulasi untuk menggambarkan karakteristik umum data yang dibangkitkan.

Tabel 16. Karakteristik Data Simulasi

Variabel	Rata - rata	Simpangan Baku	Minimum	Maximum
Y	3,502	3,012	-4,153	10,017
X_1	396,808	852,016	-1540,819	2379,740
X_2	24514,738	45430,039	-74324,242	99333,486
X_3	44,482	6,696	29,758	60,773
X_4	33,697	20,428	-14,553	73,147
X_5	0,328	0,117	0,064	0,609
X_6	98,673	12,084	70,835	126,678
X_7	69,861	7,455	53,157	87,412
X_8	331,047	5070,140	-11040,271	12127,637

Tabel 16 menyajikan hasil analisis statistik deskriptif data simulasi. Nilai rata-rata dan simpangan baku pada data simulasi menunjukkan pola yang relatif sebanding dengan data TPT. Hal ini mengindikasikan bahwa proses pembangkitan data simulasi telah mampu merepresentasikan karakteristik statistik data asli dengan baik. Variabel respon (Y) memiliki rata-rata sebesar 3,502 dengan simpangan baku 3,012. Rentang nilai yang cukup lebar, yaitu dari -4,153 hingga 10,117, menunjukkan bahwa data simulasi memiliki variasi yang memadai untuk keperluan analisis regresi. Pada variabel prediktor, nilai rata-rata dan simpangan baku menunjukkan pola penyebaran yang beragam. Variabel X_1 , X_2 dan X_8 memiliki simpangan baku yang relatif besar dibandingkan variabel lainnya, yang mengindikasikan adanya sebaran data yang lebih luas. Khususnya pada X_8 , simpangan baku yang tinggi menunjukkan variasi data paling besar. Sementara itu, variabel X_3 , X_4 , X_5 , X_6 , dan X_7 memiliki simpangan baku yang relatif lebih kecil, yang menunjukkan bahwa data pada variabel tersebut cenderung lebih terkonsentrasi di sekitar rata-ratanya. Secara keseluruhan, data simulasi yang dihasilkan memiliki keragaman dan pola penyebaran yang cukup beragam antarvariabel, serta mampu merepresentasikan karakteristik data dengan variasi rendah maupun tinggi. Hal ini menunjukkan bahwa data simulasi layak digunakan dalam evaluasi kinerja metode, khususnya untuk menguji kestabilan dan ketangguhan metode *Robust Modified Jackknife Ridge Regression* dengan *GM-estimator* dalam menghadapi kondisi multikolinearitas dan pencilan yang terkontrol.

3.8.2 Uji Asumsi Klasik

1. Uji Normalitas

Pengujian normalitas residual dilakukan menggunakan uji *Shapiro-Wilk*, dengan menilai signifikansi hasil uji statistik terhadap residual model regresi. Hasil uji normalitas dari residual model regresi MKT disajikan pada tabel 17.

Tabel 17. Hasil Uji *Shapiro Wilk* Pada Data Simulasi

<i>SW Statistic</i>	<i>P – value</i>
0,913	0,041

Berdasarkan Tabel 17, diperoleh nilai *p-value* uji *Shapiro-Wilk* sebesar 0,041. Karena $p - value < \alpha = 0,05$, maka H_0 ditolak. Artinya, residual tidak berdistribusi normal.

2. Uji Multikolinearitas

Uji multikolinearitas bertujuan untuk mendeteksi korelasi antar variabel prediktor. Multikolinearitas diuji menggunakan nilai *Variance Inflation Factor* (VIF). Terdapat masalah multikolinearitas jika nilai VIF > 10. Hasil uji multikolinearitas disajikan pada tabel 18.

Tabel 18. Hasil Uji Multikolinearitas Pada Data Simulasi

Variabel	Nilai VIF
X_1	71,710
X_2	7,596
X_3	18,606
X_4	10,552
X_5	16,758
X_6	31,686
X_7	47,097
X_8	75,399

Berdasarkan tabel 18, diperoleh bahwa nilai VIF pada variabel X_1 , X_3 , X_4 , X_5 , X_6 , X_7 dan X_8 lebih besar dari 10, yang mengindikasikan adanya masalah multikolinearitas dalam model. Kondisi ini menunjukkan bahwa variabel tersebut memiliki korelasi yang cukup tinggi dengan variabel prediktor lainnya.

3.8.3 Identifikasi Pencilan Berpengaruh

1. Identifikasi Pencilan

Pencilan pada variabel respon diidentifikasi menggunakan *Studentized Residual*, sedangkan pencilan pada variabel prediktor diidentifikasi menggunakan *leverage*. Hasil identifikasi pencilan disajikan pada Tabel 19. Hasil Perhitungan Nilai *Studentized residual* dan *leverage* secara lengkap disajikan pada Lampiran 8.

Tabel 19. Identifikasi Pencilan Pada Data Simulasi

Data Pengamatan ke- i	Variabel Respon		Variabel Prediktor	
	TRES	Titik Kritis	Leverage Value	Titik Kritis
4	1,7190		0,6794	
6	1,0579		0,6991	
7	0,1475	2,1314	0,7138	0,6666
10	3,0622		0,2738	
14	3,0009		0,2520	

Berdasarkan Tabel 19, nilai *Studentized Residual* pada pengamatan ke-10 dan ke-14 teridentifikasi sebagai pencilan pada variabel respon karena memiliki nilai $|TRES_i|$ yang melebihi titik kritis sebesar 2,1314. Sementara itu, berdasarkan nilai *leverage*, pengamatan ke-4, ke-6 dan ke-7 teridentifikasi sebagai pencilan pada variabel prediktor karena memiliki nilai leverage yang lebih besar dari titik kritis sebesar 0,6666.

2. Amatan Berpengaruh

Metode yang digunakan untuk mendeteksi amatan berpengaruh yaitu DFFITS. Dalam penelitian ini jumlah parameter yang digunakan adalah $p = 8$ dan jumlah observasi $n = 24$. Suatu data dikatakan pencilan apabila nilai $|DFFITS|$ melebihi batas kritis, yaitu 1,1547. Hasil identifikasi pencilan ditampilkan pada tabel 20. Hasil Perhitungan Nilai DFFITS secara lengkap disajikan pada Lampiran 8.

Tabel 20. Identifikasi Amatan Berpengaruh Pada Data Simulasi

Data Pengamatan ke- i	$ DFFITS_i $
4	1,7172
6	1,2935
7	1,2330
10	1,8805
14	1,7421

Berdasarkan Tabel 20, nilai $|DFFITS|$ pada data ke-4, ke-6, ke-7, ke-10 dan ke-14 melebihi batas kritis yaitu 1,1547. Dengan demikian, data pengamatan tersebut teridentifikasi sebagai amatan berpengaruh terhadap model regresi. Kondisi ini mengindikasikan bahwa keberadaan data tersebut berpotensi memengaruhi hasil estimasi parameter secara signifikan.

3. Pencilan Berpengaruh

Pencilan berpengaruh merupakan pengamatan yang teridentifikasi sebagai pencilan sekaligus memiliki pengaruh signifikan terhadap model. Berdasarkan hasil pendeteksian pencilan dan amatan berpengaruh yang telah dilakukan sebelumnya, dapat disimpulkan bahwa pengamatan yang tergolong sebagai pencilan berpengaruh disajikan pada Tabel 21.

Tabel 21. Identifikasi Pencilan Berpengaruh Pada Data Simulasi

Data Pengamatan ke- <i>i</i>	Pencilan		Amatan Berpengaruh
	TRES	Leverage	DFFITS _{<i>i</i>}
4	Tidak	Ya	Ya
6	Tidak	Ya	Ya
7	Tidak	Ya	Ya
10	Ya	Tidak	Ya
14	Ya	Tidak	Ya

Berdasarkan Tabel 21, diperoleh bahwa data pengamatan ke-4, ke-6, ke-7, ke-10 dan ke-14 merupakan pencilan sekaligus pengamatan berpengaruh sehingga dapat disimpulkan bahwa pengamatan tersebut merupakan pencilan berpengaruh. Kondisi ini mengindikasikan bahwa keberadaan data tersebut berpotensi memengaruhi hasil estimasi parameter secara signifikan.

3.8.4 Transformasi Menggunakan Metode Pemusatan dan Penskalaan

Sebelum dilakukan pemodelan *Robust* MJRR-GM pada data simulasi, variabel X dan Y terlebih dahulu ditransformasi melalui proses pemusatan dan penskalaan menggunakan prosedur yang sama seperti pada data TPT, sesuai dengan persamaan (10) dan (11). Hasil transformasi data pada variabel prediktor (X^*) dan variabel respon (Y^*) secara keseluruhan terlampir pada Lampiran 9. Proses analisis selanjutnya akan menggunakan data hasil transformasi.

3.8.5 Pemodelan Robust Modified Jackknife Ridge dengan GM-Estimator

1. Membentuk Matriks Ortogonal Pada Variabel Prediktor

Tahap awal dalam pemodelan *Robust* MJRR-GM adalah membentuk matriks ortogonal pada variabel prediktor. Proses ini dilakukan dengan menghitung nilai eigen dan vektor eigen dari matriks $X^{*'}X^*$. Kemudian, berdasarkan nilai eigen tersebut diperoleh vektor-vektor eigen yang selanjutnya membentuk matriks T . Selanjutnya membentuk matriks variabel prediktor yang ortogonal (Z) dengan $Z = X^*T$. Variabel ortogonal adalah variabel prediktor yang memiliki nilai korelasi sesama variabel prediktor sama dengan nol. Adapun nilai variabel ortogonal Z dapat dilihat pada Lampiran 10. Pada tahap selanjutnya, variabel Z inilah yang digunakan sebagai pengganti variabel X^* dalam proses estimasi, sehingga analisis dilakukan pada data hasil transformasi ortogonal.

2. Estimasi Parameter Metode Kuadrat Terkecil

Sebelum dilakukan pemodelan *Robust* MJRR-GM, langkah awal yang dilakukan adalah mengestimasi parameter dengan MKT. Estimasi MKT ini digunakan sebagai *initial estimator* pada tahap selanjutnya dalam memperoleh estimasi parameter *robust GM-estimator*.

3. Estimasi Parameter GM-Estimator

Pada tahap sebelumnya, telah diperoleh estimasi awal melalui MKT. Tahap selanjutnya adalah melakukan estimasi parameter menggunakan *GM-estimator*.

Prosedur estimasi dilakukan dengan menghitung skala robust GM ($\hat{\sigma}_{GM}$) dari residual hasil estimasi MKT menggunakan rumus $\hat{\sigma}_{GM} = 1,4825 MAD$, serta nilai *leverage weight* (π_i) dengan rumus $\pi_i = \sqrt{1 - h_{ii}}$ dimana nilai h_{ii} diperoleh dari elemen diagonal matriks hat, yaitu $H = Z'(Z'Z)^{-1}Z$. Selanjutnya menghitung skala residual (u_i) dengan rumus $u_i = \frac{e_i}{\pi \hat{\sigma}_{GM}}$. Hasil perhitungan nilai e_i , h_{ii} , π_i dan u_i disajikan pada Lampiran 11.

Berdasarkan komponen tersebut, bobot robust (w_i) dibentuk menggunakan fungsi pembobot uber dengan konstanta c yaitu $c = 2\sqrt{\frac{p+1}{n}} = 2\sqrt{\frac{9}{24}} = 1,224$, sebagaimana pada prosedur pembobotan *robust* pada data TPT. Hasil perhitungan nilai w_i untuk iterasi pertama secara lengkap disajikan pada Lampiran 11. Bobot tersebut kemudian digunakan untuk membentuk matriks bobot W , yang selanjutnya digunakan dalam proses iterasi estimasi parameter *GM-estimator* menggunakan persamaan (34). Pada setiap iterasi, estimasi parameter diperbarui berdasarkan matriks bobot yang terbentuk, kemudian digunakan kembali untuk menghitung residual, skala robust ($\hat{\sigma}_{GM}$), *leverage weight* (π_i), skala residual (u_i), dan bobot robust (w_i) yang baru. Proses ini dilakukan secara berulang hingga diperoleh estimasi parameter yang konvergen.

Berdasarkan hasil perhitungan, proses iterasi mencapai konvergen pada iterasi ke-29. Hasil iterasi GM-estimator ditunjukkan pada Tabel 22, sedangkan hasil iterasi estimasi parameter secara lengkap dapat dilihat pada Lampiran 12.

Tabel 22. Hasil Iterasi Estimasi Parameter Menggunakan *Robust GM-estimator* Pada Data Simulasi

Iterasi	Parameter							
	$\hat{\gamma}_1$	$\hat{\gamma}_2$	$\hat{\gamma}_3$	$\hat{\gamma}_4$	$\hat{\gamma}_5$	$\hat{\gamma}_6$	$\hat{\gamma}_7$	$\hat{\gamma}_8$
MKT	0,128	0,434	-0,694	0,653	-0,085	-0,35	0,834	1,651
1	0,12471	0,39869	-0,64703	0,48369	-0,07717	-0,27519	0,95639	1,50046
2	0,12399	0,37992	-0,64821	0,33099	-0,09836	-0,24443	0,96770	1,38367
3	0,12366	0,36744	-0,65528	0,20663	-0,09799	-0,24456	0,89968	1,29646
:	:	:	:	:	:	:	:	:
29	0,12571	0,33892	-0,67242	-0,10343	-0,10776	-0,26689	0,74772	1,03536
30	0,12571	0,33892	-0,67242	-0,10343	-0,10776	-0,26689	0,74772	1,03536

Berdasarkan Tabel 22, terlihat bahwa nilai koefisien regresi tidak mengalami perubahan signifikan mulai dari iterasi ke-29. Oleh karena itu, hasil koefisien pada iterasi ke-29 digunakan sebagai estimasi akhir dalam regresi *robust GM-estimator*, sebagaimana ditunjukkan pada Tabel 23.

Tabel 23. Hasil Estimasi Parameter *Robust GM-estimator* ($\hat{\gamma}_{GM}$) Pada Data Simulasi

Parameter	Estimasi
γ_1	0,125
γ_2	0,338
γ_3	-0,672
γ_4	-0,103
γ_5	-0,107
γ_6	-0,266
γ_7	0,747
γ_8	1,035

Hasil estimasi parameter pada tabel 23 akan digunakan untuk tahap selanjutnya dalam mengestimasi parameter *Robust MJRR-GM*

4. Estimasi Parameter *Robust MJRR GM-Estimator*

Setelah diperoleh estimasi parameter dengan pendekatan regresi *robust GM-estimator*, tahap selanjutnya adalah melakukan estimasi parameter menggunakan *Robust Modified Jackknife Ridge Regression GM-estimator*. Sebelum melakukan estimasi, terlebih dahulu menentukan nilai konstanta bias ($k_{*(GM)}$) menggunakan Persamaan (49). Penentuan konstanta bias diawali dengan menghitung nilai kuadrat tengah residual *robust* ($\hat{\sigma}_{GM}^2$), yang dirumuskan sebagai berikut :

$$\hat{\sigma}_{GM}^2 = \frac{(Y^* - Z\hat{\gamma}_{GM})'(Y^* - Z\hat{\gamma}_{GM})}{24 - 8 - 1} = 0,025$$

Berdasarkan nilai tersebut, konstanta bias (k_*) diperoleh sebagai berikut:

$$k_{*(GM)} = \frac{p\hat{\sigma}_{GM}^2}{\hat{\gamma}_{GM}'\hat{\gamma}_{GM}} = \frac{(8)(0,025)}{\hat{\gamma}_{GM}'\hat{\gamma}_{GM}} = 0,088$$

Nilai konstanta bias k_* selanjutnya digunakan untuk membentuk matriks k_*I , yaitu matriks diagonal dengan nilai $k_{*(GM)}$ pada setiap elemen diagonal utamanya. Matriks k_*I yang telah diperoleh tersebut selanjutnya digunakan dalam proses estimasi parameter *Robust MJRR-GM* ($\hat{\gamma}_{RMJRR}$) menggunakan persamaan (48). Hasil estimasi parameter tersebut disajikan pada tabel 23.

Tabel 24. Hasil Estimasi Parameter *Robust MJRR-GM* ($\hat{\gamma}_{RMJRR}$) Pada Ruang Ortogonal (Data simulasi)

Parameter	Estimasi
γ_1	0,123
γ_2	0,318
γ_3	-0,538
γ_4	-0,037
γ_5	-0,026
γ_6	-0,051
γ_7	0,007
γ_8	0,031

Setelah mendapatkan nilai $\hat{\gamma}_{RMJRR}$ pada ruang ortogonal, selanjutnya menghitung estimasi parameter *Robust* MJRR-GM pada ruang parameter asli ($\hat{\beta}_{RMJRR}^*$) yaitu menggunakan persamaan $\hat{\beta}^* = T\hat{\gamma}_{RMJRR}$, sehingga hasil estimasi dapat dilihat pada tabel 25.

Tabel 25. Hasil Estimasi Parameter *Robust* MJRR-GM ($\hat{\beta}_{RMJRR}^*$) Pada Ruang Parameter Asli (Data Simulasi)

Parameter	Estimasi
β_1^*	-0,009
β_2^*	0,580
β_3^*	-0,125
β_4^*	-0,142
β_5^*	0,033
β_6^*	-0,010
β_7^*	0,097
β_8^*	0,172

Selanjutnya, nilai $\hat{\beta}_{RMJRR}^*$ yang diperoleh tersebut akan dikembalikan ke bentuk semula (sebelum standarisasi) dengan menggunakan persamaan (13), dan menghitung nilai intersep β_0 menggunakan persamaan (14). Adapun hasil pengembalian bentuk dari standarisasi ditunjukkan sebagai berikut:

$$\beta_1 = \left(\frac{S_Y}{S_{x_1}} \right) \beta_1^* = \left(\frac{3,012}{852,016} \right) \times (-0,009) = -3,029 \times 10^{-5}$$

$$\beta_2 = \left(\frac{S_Y}{S_{x_2}} \right) \beta_2^* = \left(\frac{3,012}{45.430,039} \right) \times (0,580) = 3,846 \times 10^{-5}$$

$$\beta_3 = \left(\frac{S_Y}{S_{x_3}} \right) \beta_3^* = \left(\frac{3,012}{6,696} \right) \times (-0,125) = -5,605 \times 10^{-2}$$

$$\beta_4 = \left(\frac{S_Y}{S_{x_4}} \right) \beta_4^* = \left(\frac{3,012}{20,428} \right) \times (-0,142) = -2,096 \times 10^{-2}$$

$$\beta_5 = \left(\frac{S_Y}{S_{x_5}} \right) \beta_5^* = \left(\frac{3,012}{0,116} \right) \times (0,033) = 8,507 \times 10^{-1}$$

$$\beta_6 = \left(\frac{S_Y}{S_{x_6}} \right) \beta_6^* = \left(\frac{3,012}{12,083} \right) \times (-0,010) = -2,508 \times 10^{-3}$$

$$\beta_7 = \left(\frac{S_Y}{S_{x_7}} \right) \beta_7^* = \left(\frac{3,012}{7,455} \right) \times (-0,097) = 3,934 \times 10^{-2}$$

$$\beta_8 = \left(\frac{S_Y}{S_{x_8}} \right) \beta_8^* = \left(\frac{3,012}{5.070,140} \right) \times (0,172) = 1,021 \times 10^{-4}$$

$$\begin{aligned} \beta_0 &= \bar{Y} - \beta_1 \bar{X}_1 - \beta_2 \bar{X}_2 - \beta_3 \bar{X}_3 - \beta_4 \bar{X}_4 - \beta_5 \bar{X}_5 - \beta_6 \bar{X}_6 - \beta_7 \bar{X}_7 - \beta_8 \bar{X}_8 \\ &= 3,501 - (-3,029 \times 10^{-5})(396,807) - (3,846 \times 10^{-5})(24.514,737) - (-5,605 \times 10^{-2})(44,481) \\ &\quad - (-2,096 \times 10^{-2})(33,697) - (8,507 \times 10^{-1})(0,328) - (-2,508 \times 10^{-3})(98,672) \\ &\quad - (3,934 \times 10^{-2})(69,861) - (1,021 \times 10^{-4})(331,047) \\ &= 2,957 \end{aligned}$$

Dengan demikian, persamaan model *Robust* MJRR-GM pada data simulasi adalah sebagai berikut:

$$\hat{Y} = 3,384 - 0,00003X_1 + 0,00003X_2 - 0,05605X_3 - 0,02096X_4 + 0,8507X_5 - 0,00250X_6 - 0,03934X_7 + 0,00010X_8$$

3.8.6 Uji Signifikansi Parameter

1. Uji Simultan

Uji signifikansi parameter model secara simultan dilakukan dengan uji F menggunakan statistik uji pada persamaan (25) dengan hipotesis berikut :

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_8 = 0$$

$$H_1 : \text{Minimal ada satu } \beta_j \neq 0 \text{ untuk } j = 1, 2, \dots, 8$$

Hasil statistik uji F dengan $\alpha = 0,05$ dapat dilihat pada Tabel 26.

Tabel 26. Hasil Uji Simultan Parameter Model *Robust* MJRR-GM (Data Simulasi)

F_{Hit}	$p\text{-value}$
4,230	0,007

Berdasarkan tabel 26, diperoleh nilai $F_{hitung} = 4,230 > F_{(0,05, 8, 15)} = 2,764$ serta nilai $p\text{-value} = 0,007 < \alpha = 0,05$, maka H_0 ditolak, yang berarti variabel prediktor secara keseluruhan berpengaruh signifikan terhadap variabel respon dalam model regresi yang dibentuk.

2. Uji Parsial

Uji signifikansi parameter model secara parsial dilakukan dengan uji t menggunakan statistik uji pada persamaan (26) dengan hipotesis berikut:

$$H_0 : \beta_j = 0, \text{ dengan } j = 1, 2, \dots, 8$$

$$H_1 : \beta_j \neq 0$$

Hasil statistik uji t dengan $\alpha = 0,05$ dapat dilihat pada Tabel 27.

Tabel 27. Hasil Uji Parsial Parameter Model *Robust* MJRR-GM (Data Simulasi)

Variabel	$SE(\beta_j)$	t_{hit}	$P\text{-Value}$
X_1	$3,848 \times 10^{-5}$	-0,132	0,896
X_2	$7,382 \times 10^{-5}$	4,667	0,000
X_3	$1,173 \times 10^{-4}$	-0,631	0,537
X_4	$1,177 \times 10^{-4}$	-0,717	0,484
X_5	$9,811 \times 10^{-5}$	0,199	0,844
X_6	$8,589 \times 10^{-5}$	-0,069	0,945
X_7	$1,128 \times 10^{-5}$	5,123	0,000
X_8	$2,501 \times 10^{-5}$	4,086	0,001

Pada uji t, H_0 ditolak jika nilai $t_{hitung} > t_{(\frac{0,05}{2}, 15)} = 2,1009$ serta $p\text{-value} < \alpha = 0,05$. Berdasarkan tabel 27, Hasil pengujian menunjukkan bahwa variabel prediktor X_2 , X_7 dan X_8 memiliki nilai $|t_{hitung}|$ yang lebih besar dari 2,1009 dan $p\text{-value}$ yang lebih kecil dari 0,05, sehingga H_0 ditolak. Dengan demikian, dapat disimpulkan

bahwa variabel prediktor X_2 , X_7 dan X_8 berpengaruh signifikan secara parsial terhadap variabel respon pada tingkat signifikansi 5%.

3.9 Evaluasi Keباikan Model

Evaluasi kebaikan model dilakukan untuk menilai stabilitas dan ketangguhan metode *Robust* MJRR-GM pada kondisi data yang mengandung multikolinearitas dan kontaminasi pencilan yang dikendalikan. Kriteria kebaikan model yang digunakan adalah nilai *Adjusted R²* dan RMSE. Model yang baik adalah model yang menghasilkan nilai *Adjusted R²* yang lebih besar dan nilai RMSE yang lebih kecil. Perhitungan nilai *Adjusted R²* mengacu pada persamaan (27), sedangkan RMSE dihitung berdasarkan persamaan (28). Hasil evaluasi kebaikan model dapat dilihat pada Tabel 28.

Tabel 28. Perbandingan Ukuran Kebaikan Model

Data	Model	<i>Adjusted R²</i>	RMSE
Data TPT	MJRR	82%	0,138
	Robust MJRR-GM	85%	0,129
Data Simulasi	MJRR	16%	0,187
	Robust MJRR-GM	70%	0,113

Berdasarkan Tabel 28, terlihat bahwa model *Robust* MJRR-GM menunjukkan kinerja yang lebih baik dibandingkan model MJRR, baik pada data TPT maupun data simulasi. Pada data TPT, model MJRR menghasilkan nilai *Adjusted R²* sebesar 82% dan RMSE sebesar 0,138, sedangkan model *Robust* MJRR-GM menghasilkan nilai *Adjusted R²* yang lebih tinggi yaitu 85% serta RMSE yang lebih rendah yaitu 0,129. Hasil ini mengindikasikan bahwa model *Robust* MJRR-GM mampu menjelaskan keragaman data TPT dengan lebih baik serta menghasilkan galat prediksi yang lebih kecil dibandingkan model MJRR.

Pada data simulasi, pola yang sama juga terlihat. Model MJRR menghasilkan nilai *Adjusted R²* sebesar 16% dengan RMSE sebesar 0,187, sedangkan model *Robust* MJRR-GM memberikan peningkatan yang cukup besar dengan nilai *Adjusted R²* sebesar 70% dan RMSE sebesar 0,113. Hal tersebut memperlihatkan bahwa model *Robust* MJRR-GM memiliki kemampuan yang jauh lebih baik dalam menjelaskan variasi data simulasi sekaligus menghasilkan tingkat kesalahan prediksi yang lebih rendah dibandingkan model MJRR.

Secara keseluruhan, nilai *Adjusted R²* yang lebih tinggi dan RMSE yang lebih rendah pada kedua jenis data menunjukkan bahwa model *Robust* MJRR-GM lebih unggul dibandingkan model MJRR, baik dari sisi kemampuan penjelasan model maupun ketepatan prediksi. Meskipun demikian, peningkatan kinerja yang dihasilkan pada data TPT relatif kecil. Hal ini menunjukkan bahwa model MJRR pada data TPT masih mampu memberikan hasil yang cukup stabil, sehingga penambahan pendekatan robust melalui GM-estimator memberikan perbaikan yang terbatas. Kondisi tersebut mengindikasikan bahwa meskipun data TPT mengandung pencilan berpengaruh, pengaruhnya terhadap model cenderung masih moderat sehingga

distorsi yang ditimbulkan terhadap estimasi model belum terlalu besar. Sebaliknya, pada data simulasi peningkatan kinerja model terlihat jauh lebih besar. Kondisi ini menunjukkan bahwa pencilan yang dibangkitkan memberikan pengaruh yang lebih kuat terhadap model, sehingga model MJRR lebih mudah mengalami distorsi. Dalam kondisi tersebut, pendekatan robust melalui GM-estimator mampu menekan pengaruh pencilan secara lebih efektif, sehingga menghasilkan peningkatan kinerja model yang lebih besar dibandingkan pada data TPT. Hasil pada data simulasi menegaskan bahwa pendekatan robust dengan GM-estimator efektif dalam meningkatkan ketangguhan model terhadap pengaruh pencilan, sekaligus tetap mampu mengatasi permasalahan multikolinearitas melalui mekanisme Modified Jackknife Ridge.

Dengan demikian, pendekatan *Robust Modified Jackknife Ridge Regression* dengan *GM-estimator* terbukti mampu meningkatkan ketepatan dan kestabilan model, baik pada data aktual maupun data simulasi, sehingga layak digunakan sebagai pendekatan yang andal dalam pemodelan regresi pada data yang mengandung multikolinearitas dan pencilan berpengaruh.

BAB IV KESIMPULAN DAN SARAN

4.1. Kesimpulan

Berdasarkan hasil analisis dan pembahasan yang telah diperoleh sebelumnya, maka dapat ditarik kesimpulan sebagai berikut:

1. Model *Robust MJRR* dengan GM-estimator pada kasus tingkat pengangguran terbuka di Kabupaten/Kota Sulawesi Selatan Tahun 2024, yaitu sebagai berikut:

$$\hat{Y} = -23,096 + 0,000532X_1 + 0,000009X_2 + 0,112105X_3 - 0,001152X_4 + 5,365206X_5 + 0,058776X_6 + 0,192053X_7 + 0,000303X_8$$
2. Berdasarkan hasil pengujian parameter dengan taraf signifikansi 5%, diperoleh bahwa terdapat empat faktor yang signifikan memengaruhi tingkat pengangguran terbuka di kabupaten/kota Sulawesi Selatan tahun 2024, yaitu variabel Rasio Gini (X_5), Rasio Jenis Kelamin (X_6), Umur Harapan Hidup (X_7) dan Kepadatan Penduduk (X_8). Keempat variabel tersebut memiliki hubungan positif terhadap TPT. Hal ini menunjukkan bahwa meningkatnya ketimpangan pendapatan, perubahan komposisi penduduk menurut jenis kelamin, meningkatnya kualitas hidup yang diikuti bertambahnya penduduk usia kerja, serta tingginya kepadatan penduduk cenderung meningkatkan tekanan pada pasar kerja sehingga TPT meningkat.

4.2. Saran

Untuk penelitian selanjutnya, disarankan menggunakan pendekatan *Robust MJRR* dengan menggunakan estimator robust lain, seperti *Generalized S-estimator*. Selain itu, dapat mempertimbangkan penentuan parameter ridge yang berbeda untuk setiap variabel (k_j) melalui metode *Cross Validation* atau *Generalized Cross Validation* sebagai bentuk pengembangan pendekatan regularisasi dalam model. Di samping itu, penelitian berikutnya juga dapat memperluas variabel yang digunakan sehingga model yang dibangun lebih komprehensif dalam menjelaskan variasi tingkat pengangguran terbuka.

DAFTAR PUSTAKA

- Ahadi, G. D., & Zain, N. N. L. E. (2023). Pemeriksaan Uji Kenormalan dengan Kolmogorov-Smirnov, Anderson-Darling dan Shapiro-Wilk. *EIGEN MATHEMATICS JOURNAL*, 11–19. <https://doi.org/10.29303/emj.v6i1.131>
- Akolo, I. R., & Nadjamuddin, A. (2022). Analisis Regresi Robust Estimasi Least Trimmed Square dan Estimasi Maximum Likelihood pada Pemodelan IPM di Pulau Sulawesi. *Euler : Jurnal Ilmiah Matematika, Sains dan Teknologi*, 10(2), 211–221. <https://doi.org/10.34312/euler.v10i2.16708>
- Alguraibawi, M., Midi, H., & Rana, S. (2015). Robust Jackknife Ridge Regression To Combat Multicollinearity And High Leverage Points In Multiple Linear Regressions. *Economic Computation and Economic Cybernetics Studies and Research*, (4), 305–322.
- Alkautsar, M. A., & Fauzi, R. (2024). Estimasi Parameter pada Model Matematis Perubahan Suhu Dinding Rumah menggunakan Algoritma Genetika. *Jurnal Eureka Matika*, 12(1), 55–67.
- Anggraini, N., Kusnandar, D., & Debatara, N. N. (2019). Metode Generalized Ridge Regression Dalam Mengatasi Multikolinearitas. Dalam *Buletin Ilmiah Math. Stat. dan Terapannya (Bimaster)* (Vol. 08, Nomor 4).
- Arrasyid, A. H., Ispriyanti, D., & Hoyyi, A. (2021). Metode Modified Jackknife Ridge Regression Dalam Penanganan Multikolinearitas (Studi Kasus Indeks Pembangunan Manusia Di Jawa Tengah). *Jurnal Gaussian*, 10(1), 104–113. <https://ejournal3.undip.ac.id/index.php/gaussian/>
- Azzahra, A. S. (2024). *Penerapan Model Robust Modified Jackknife Ridge Regression dengan MM-estimator Pada Data PDRB di Indonesia*. Universitas Hasanuddin.
- Batah, F., Ramanathan, T. V., & Gore, S. D. (2008). The efficiency of modified jackknife and ridge type regression estimators: a comparison. *Surveys in Mathematics and its Application*, 3, 111–122. <http://www.utgjiu.ro/math/sma>
- Damayanti, A., & Susanti, M. (2024). Analisis Regresi Robust Estimasi-M Pembobot Huber dan Tukey Bisquare Pada Tingkat Kemiskinan Indonesia. *Jurnal Kajian dan Terapan Matematika*, 10(2), 130–141. <http://journal.student.uny.ac.id/ojs/index.php/jktm>
- Daniel, F. (2019). Mengatasi Pencilan Pada Pemodelan Regresi Linear Berganda Dengan Metode Regresi Robust Penaksir LMS. *BAREKENG: Jurnal Ilmu Matematika dan Terapan*, 13(3), 145–156. <https://doi.org/10.30598/barekengvol13iss3pp145-156ar884>

- Das, K. R., & Imon, A. H. M. R. (2016). A Brief Review of Tests for Normality. *American Journal of Theoretical and Applied Statistics*, 5(1), 5–12. <https://doi.org/10.11648/j.ajtas.20160501.12>
- Deria, A. D., Hoyyi, A., & Mustafid. (2019). Regresi Robust Estimasi-M Dengan Pembobot Andrew, Pembobot Ramsay dan Pembobot Welsch Menggunakan Software R. *Jurnal Gaussian*, 8(3).
- Elfida, C., Maimun, & Amalia, N. (2023). Cut, Maimun dan Najwa Pengaruh Jumlah Pertumbuhan Penduduk Dan Tingkat Pendidikan Terhadap Tingkat Pengangguran Terbuka Di Provinsi Aceh. *JIBES : Jurnal Ilmiah Basis Ekonomi dan Bisnis*, 2(2), 72–84.
- Fitri, Y., Arum, P. R., & Imron, A. (2023). Pengaruh Rata-Rata Lama Sekolah, Angka Harapan Hidup Dan Pengangguran Terhadap Kemiskinan Di Kabupaten Solok Selatan. *Journal of Data Insight*, 1(1), 27–33. <http://journalnew.unimus.ac.id/index.php/jodi>
- Hidayatulloh, F. P., Yuniarti, D., & Wahyuningsih, S. (2015). Regresi Robust Dengan Metode Estimasi-S. *Jurnal EKSPONENSIAL*, 6(2), 163–170.
- Iskandar, R., Mara, N., & Intisari, N. S. (2013). Perbandingan Metode Bootstrap Dan Jackknife Dalam Menaksir Parameter Regresi Untuk Mengatasi Multikolinearitas. Dalam *Buletin Ilmiah Mat. Stat. dan Terapannya (Bimaster)* (Vol. 02, Nomor 2).
- Jeremia, N. E., Nurrohmah, S., & Fithriani, I. (2020). Robust Ridge regression to solve a multicollinearity and outlier. *Journal of Physics: Conference Series*, 1442(1). <https://doi.org/10.1088/1742-6596/1442/1/012030>
- Lestari, P. S., Martha, S., & Debatara, N. N. (2022). Penerapan Metode Regresi Ridge Pada Kasus Angka Kematian Bayi Di Provinsi Jawa Timur. Dalam *Buletin Ilmiah Math. Stat. dan Terapannya (Bimaster)* (Vol. 11, Nomor 4).
- Mahesa, G. P., Khairunnisa, N., & Rohmi, M. L. (2024). Pengaruh Indeks Pembangunan Manusia (Ipm) Dan Tingkat Kemiskinan Terhadap Tingkat Pengangguran Terbuka (Tpt) Di Provinsi Dki Jakarta Tahun 2011-2020. *Kajian Ekonomi dan Akuntansi Terapan (KEAT)*, 1(4), 1–18. <https://doi.org/10.61132/keat.v1i4>
- Nugroho, S. L. (2016). *Analisis Regresi Robust Dengan Metode Penduga MM (Method of moment)*. Universitas Negeri Jakarta.
- Nurbaroqah, A., Pratikno, B., & Supriyanto. (2022). Pendekatan Regresi Robust Dengan Fungsi Pembobot Bisquare Tukey Pada Estimasi-M dan Estimasi-S. *Jurnal Ilmiah Matematika dan Pendidikan Matematika (JMP)*, 14(1), 19–30.

- Nurdin, N., & Islamiyati, A. (2014). *Penggunaan Regresi Robust Pada Data Yang Mengandung Pencilan Dengan Metode Momen* (Vol. 10, Nomor 2).
- Nurhafifah, F., Nisa, K., & Agung Wibowo, R. (2024). Sciencestatistics Journal of Statistics, Probability, and Its Application Perbandingan Pembobot Welsch dan Tukey Bisquare pada Regresi Robust S-estimator. *Journal of Statistics, Probability, and Its Application*, 2(1), 93–103. <https://scholar.ummetro.ac.id/index.php/sciencestatistics/index>
- Prasetyo, T. (2013). *Perbandingan Metode Robust Generalized-M Schweppe One Step Estimator (GM-S1S) Dan Metode Robust M-Estimator Untuk Menangani Pencilan Pada Regresi Linear Berganda*.
- Putra, G. V. H., & Hidayah, N. (2023). Analisis Pengaruh Jumlah Penduduk, Pendidikan, Tingkat Partisipasi Angkatan Kerja, Upah Minimum Kabupaten/Kota dan Produk Domestik Regional Bruto Terhadap Pengangguran di Provinsi Jawa Barat Tahun 2018-2021. *KOMITMEN: Jurnal Ilmiah Manajemen*, 4, 149–158.
- Rambe, R. C., Prihanto, P. H., & Hardiani. (2019). Analisis Faktor-Faktor Yang Mempengaruhi Pengangguran Terbuka di Provinsi Jambi. *Jurnal Ekonomi, Sumberdaya dan Lingkungan*, 8(1).
- Ruslinda. (2024). *Pemodelan Statistical Downscaling Menggunakan Robust Jackknife Ridge Regression Dengan Estimator Generalized - M Untuk Peramalan Curah Hujan di Kabupaten Pangkep*. Universitas Hasanuddin.
- Sahrman, S., & Santika Upa, D. (2024). Statistical Downscaling Model with Jackknife Ridge Regression and Modified Jackknife Ridge Regression to Forecast Rainfall. *Indonesian Journal of Statistics and Its Applications*, 8(2), 155–165. <https://doi.org/10.29244/ijsa.vxiypno>
- Saputri, G., Herawati, N., Ruby, T., & Nisa, K. (2024). Comparative Study in Controlling Outliers and Multicollinearity Using Robust Performance Jackknife Ridge Regression Estimator Based on Generalized-M and Least Trimmed Square Estimator. *Jambura Journal of Mathematics*, 6(2), 147–151. <https://doi.org/10.37905/jjom.v6i2.24828>
- Sari, T. S. P., Riskita, D., & Febiyanti, N. L. (2024). Analisis Pengaruh Angkatan Kerja Dan Pendidikan Terhadap Tingkat Pengangguran Terbuka Di Kabupaten Sidoarjo Tahun 2009-2023. *Jurnal Ekonomi, Manajemen, Akuntansi (EKOMA)*, 4(1).
- Setriani, Z., & Listyani, E. (2017). Analisis Regresi Robust Estimasi-S Menggunakan Pembobot Welsch dan Tukey Bisquare. *Jurnal Matematika*, 6(1), 48–55.

- Situmorang, M. H. S., & Susanti, Y. (2020). Pemodelan Indeks Keparahan Kemiskinan di Indonesia Menggunakan Analisis Regresi Robust. *Indonesian Journal of Applied Statistics*, 3(1), 51–63.
- Utami, N. K. T., Sukarsa, I. K. G., & Kencana, I. P. E. N. (2013). Penerapan Metode Generalized Ridge Regression Dalam Mengatasi Masalah Multikolinearitas. *e-Jurnal Matematika*, 2(1), 54–59.
- Utomo, A. T., & Fitrianto, A. (2022). Analisis Ridge Robust Penduga Generalized M (GM) Pada Pemodelan Kalibrasi Untuk Kadar Gula Darah. *VARIANSI: Journal of Statistics and Its Application on Teaching and Research*, 4(2), 59–69. <https://doi.org/10.35580/variansiunm14>
- Waibusi, H. T. M. (2023). *Estimasi Parameter Regresi Ridge Robust Pada Data Profil Kesehatan Sulawesi Selatan*. Universitas Hasanuddin.
- Wasilaine, T. L., Talakua, M. W., & Lesnussa, Y. A. (2014). Model Regresi Ridge Untuk Mengatasi Model Regresi Linier Berganda Yang Mengandung Multikolinearitas. *Jurnal Barekeng*, 8(1), 31–37.
- Wee, D. K. P., Kawung, G. M. V., & Masloman, I. (2024). Analisis Faktor – Faktor Yang Mempengaruhi Tingkat Pengangguran Terbuka Dan Kemiskinan Di Kabupaten Minahasa. *Jurnal Berkala Ilmiah Efisiensi*, 24(2), 133–145. <https://ejournal.unsrat.ac.id/v3/index.php/jbie/article/view/53859>

LAMPIRAN

Lampiran 1. Data Penelitian

No	Kabupaten / Kota	Variabel								
		Y	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8
1	Kep.Selayar	2,05	142,7	8340,51	44,22	14,94	0,329	96,7	69,26	123
2	Bulukumba	2,23	454,72	20224,4	42,77	28,6	0,329	95,5	69,00	387
3	Bantaeng	2,57	205,42	13451,4	41,15	15,8	0,249	97,7	71,30	525
4	Jeneponto	2,47	418,97	13057,1	43,47	43,9	0,304	98	67,16	526
5	Takalar	3,84	317,02	13428,1	46,79	23,51	0,385	96	68,11	571
6	Gowa	3,91	814,04	30748,7	43,92	55,13	0,326	98,4	71,06	449
7	Sinjai	1,52	270,43	15974,8	44,43	19,4	0,287	98,3	68,13	313
8	Maros	4,34	413,59	28624	45,87	34	0,349	100,9	69,68	287
9	Pangkep	3,99	359,16	34607,2	45,65	42,94	0,317	96,6	67,59	404
10	Barru	6,42	189,21	9891,13	47,46	14,64	0,31	96,1	69,73	157
11	Bone	2,28	830,12	50015,2	45,49	73,03	0,386	95,9	68,10	182
12	Soppeng	3,33	239,36	16099,2	46,55	15,9	0,381	93,8	70,79	173
13	Wajo	2,31	389,05	25954,2	44,59	26,57	0,369	94,8	68,32	149
14	Sidrap	3,02	330,74	19614,7	46,19	15,48	0,319	98,2	71,03	181
15	Pinrang	3,12	424,65	26653,4	46,14	33,04	0,299	97,9	70,65	224
16	Enrekang	1,51	238,1	10467,3	45,59	24,06	0,342	103,2	71,51	132
17	Luwu	4,14	384,28	22952,2	45,51	44,24	0,319	102	71,23	132
18	Tana Toraja	3,98	292,42	10158,5	44,25	26,3	0,32	106,8	74,23	143
19	Luwu Utara	2,39	337,66	19688,7	43,44	36,46	0,272	101,6	69,67	45
20	Luwu Timur	4,58	312,73	30391,9	46,58	20,7	0,35	105	71,42	46
21	Toraja Utara	2,44	277,79	13257,9	52,65	25,97	0,316	104	74,00	215
22	Makassar	9,71	1464,64	243063	42,52	79,53	0,372	99,1	72,78	8282
23	Pare Pare	5,23	160,92	9972,18	46,48	7,94	0,376	98,8	71,98	1795
24	Palopo	7,64	195,67	11083,9	44,12	14,43	0,333	100,8	71,60	716

Lampiran 2. Hasil Perhitungan Nilai t_i , h_{ii} , dan $DFITS$

No.	Kabupaten / Kota	t_i	h_{ii}	$DFITS$
1	Kep,Selayar	-0,8656	0,1658	-0,3859
2	Bulukumba	-0,5411	0,2036	-0,2736
3	Bantaeng	-0,6138	0,5012	-0,6153
4	Jeneponto	-0,2732	0,4383	-0,2413
5	Takalar	0,0683	0,3052	0,0453
6	Gowa	1,0144	0,6197	1,2948
7	Sinjai	-1,0166	0,3287	-0,7114
8	Maros	0,5902	0,1426	0,2407
9	Pangkep	0,7481	0,3633	0,5651
10	Barru	2,6305	0,2302	1,4386
11	Bone	-0,3533	0,5331	-0,3776
12	Soppeng	-0,4061	0,4664	-0,3797
13	Wajo	-0,5763	0,2283	-0,3134
14	Sidrap	-0,2183	0,2461	-0,1247
15	Pinrang	0,0523	0,1712	0,0238
16	Enrekang	-1,6050	0,1635	-0,7095
17	Luwu	0,5522	0,2664	0,3328
18	Tana Toraja	-0,0155	0,4227	-0,0133
19	Luwu Utara	-0,2276	0,2303	-0,1245
20	Luwu Timur	0,7420	0,5167	0,7672
21	Toraja Utara	-1,9796	0,7142	-3,1294
22	Makassar	-0,7973	0,9891	-7,5875
23	Pare Pare	-0,3450	0,5892	-0,4132
24	Palopo	2,7185	0,1641	1,2047

Lampiran 3. Data Hasil Pemusatan dan Penskalaan

Y^*	X_1^*	X_2^*	X_3^*	X_4^*	X_5^*	X_6^*	X_7^*	X_8^*
-0,1765	-0,1844	-0,0926	-0,0964	-0,1797	-0,0104	-0,1422	-0,1178	-0,0691
-0,1573	0,0443	-0,0395	-0,2331	-0,0238	-0,0104	-0,2163	-0,1460	-0,0360
-0,1212	-0,1385	-0,0698	-0,3859	-0,1699	-0,4754	-0,0805	0,1033	-0,0186
-0,1318	0,0181	-0,0715	-0,1671	0,1508	-0,1557	-0,0620	-0,3454	-0,0185
0,0139	-0,0567	-0,0699	0,1458	-0,0819	0,3151	-0,1854	-0,2424	-0,0128
0,0214	0,3077	0,0075	-0,1247	0,2789	-0,0279	-0,0373	0,0773	-0,0282
-0,2328	-0,0908	-0,0585	-0,0766	-0,1288	-0,2545	-0,0435	-0,2403	-0,0453
0,0671	0,0141	-0,0020	0,0591	0,0378	0,1058	0,1170	-0,0723	-0,0485
0,0299	-0,0258	0,0247	0,0384	0,1398	-0,0802	-0,1484	-0,2988	-0,0338
0,2883	-0,1503	-0,0857	0,2090	-0,1831	-0,1209	-0,1792	-0,0669	-0,0649
-0,1520	0,3194	0,0936	0,0233	0,4832	0,3209	-0,1916	-0,2435	-0,0617
-0,0403	-0,1136	-0,0580	0,1232	-0,1688	0,2918	-0,3212	0,0480	-0,0629
-0,1488	-0,0039	-0,0139	-0,0616	-0,0470	0,2221	-0,2595	-0,2197	-0,0659
-0,0733	-0,0466	-0,0423	0,0893	-0,1736	-0,0685	-0,0496	0,0740	-0,0618
-0,0627	0,0222	-0,0108	0,0846	0,0268	-0,1848	-0,0681	0,0328	-0,0564
-0,2339	-0,1145	-0,0831	0,0327	-0,0756	0,0651	0,2590	0,1260	-0,0680
0,0458	-0,0074	-0,0273	0,0252	0,1547	-0,0685	0,1849	0,0957	-0,0680
0,0288	-0,0747	-0,0845	-0,0936	-0,0501	-0,0627	0,4811	0,4208	-0,0666
-0,1403	-0,0415	-0,0419	-0,1700	0,0659	-0,3417	0,1602	-0,0734	-0,0789
0,0926	-0,0598	0,0059	0,1261	-0,1140	0,1117	0,3701	0,1163	-0,0788
-0,1350	-0,0854	-0,0707	0,6983	-0,0538	-0,0860	0,3083	0,3959	-0,0576
0,6383	0,7846	0,9560	-0,2567	0,5574	0,2395	0,0059	0,2637	0,9561
0,1618	-0,1711	-0,0853	0,1166	-0,2596	0,2628	-0,0126	0,1770	0,1410
0,4181	-0,1456	-0,0804	-0,1059	-0,1855	0,0128	0,1108	0,1358	0,0054

Lampiran 4. Variabel Ortogonal Z

Z_1	Z_2	Z_3	Z_4	Z_5	Z_6	Z_7	Z_8
0,2354	-0,1990	0,0207	-0,1595	-0,0304	0,0119	-0,0289	-0,0192
-0,0183	-0,3154	0,0998	-0,0902	0,0253	-0,0315	0,0715	-0,0574
0,2011	-0,0724	0,5723	-0,2245	-0,0213	0,0166	0,1147	0,0882
-0,0163	-0,3420	0,2007	0,1653	0,0497	0,0570	-0,1149	-0,0103
0,0751	-0,2513	-0,3811	-0,0487	0,0371	0,0060	-0,0941	-0,0452
-0,2919	-0,0397	0,1093	0,1924	0,0699	-0,0279	0,2278	-0,0609
0,1976	-0,2044	0,2107	-0,0057	0,0300	-0,0442	-0,1414	0,1119
0,0001	0,0294	-0,0921	0,1067	-0,0006	-0,0273	-0,0863	-0,0931
-0,0155	-0,2974	-0,0015	0,1570	-0,0482	0,0454	-0,0987	0,1170
0,2844	-0,0899	-0,0948	-0,0580	-0,0019	-0,0087	-0,0063	0,2473
-0,4466	-0,3393	-0,2783	0,3558	-0,0219	0,0160	0,1062	-0,1306
0,1385	-0,1428	-0,3733	-0,2238	-0,0510	0,0068	0,1511	0,0089
0,0053	-0,3486	-0,1949	-0,0837	-0,0199	-0,0405	0,0088	-0,0823
0,1725	0,0521	-0,0234	-0,0833	0,0101	-0,0717	0,0509	0,1036
0,0535	0,0007	0,0714	0,0797	-0,0080	-0,0172	0,0820	0,1736
0,1660	0,2512	-0,0146	0,0131	-0,0083	0,0115	-0,0527	-0,1569
0,0041	0,1698	0,0851	0,1847	-0,0370	0,0550	0,0257	-0,0526
0,1331	0,5579	0,2208	0,0080	-0,0074	0,0118	0,0597	-0,2437
0,0969	-0,0054	0,3943	0,1460	-0,0137	0,0075	-0,0651	0,0093
0,1286	0,3506	-0,0848	0,0533	-0,0206	-0,0904	-0,1391	-0,1556
0,2657	0,6756	-0,2976	0,2247	0,0151	0,0160	0,0277	0,3129
-1,6802	0,2438	0,0536	-0,2111	-0,0083	-0,0032	-0,0713	0,1089
0,1396	0,1741	-0,2775	-0,3137	0,0549	0,0806	-0,0172	-0,0541
0,1713	0,1425	0,0752	-0,1844	0,0064	0,0203	-0,0102	-0,1197

Lampiran 5. Hasil Perhitungan Nilai Residual, Leverage, Bobot π , Skala Residual Dan Nilai Bobot untuk Iterasi Pertama

No. Pengamatan	$e_i^{(0)}$	$h_{ii}^{(0)}$	$\pi_i^{(0)}$	$u_i^{(0)}$	$w_i^{(0)}$
1	-0,1383	0,1241	0,9359	-1,8830	0,6504
2	-0,0858	0,1620	0,9154	-1,1943	1
3	-0,0768	0,4595	0,7352	-1,3312	0,9201
4	-0,0367	0,3966	0,7768	-0,6015	1
5	0,0102	0,2635	0,8582	0,1519	1
6	0,1084	0,5780	0,6496	2,1264	0,5760
7	-0,1443	0,2870	0,8444	-2,1778	0,5624
8	0,0969	0,1009	0,9482	1,3024	0,9404
9	0,1051	0,3217	0,8236	1,6259	0,7533
10	0,3389	0,1886	0,9008	4,7951	0,2554
11	-0,0431	0,4915	0,7131	-0,7711	1
12	-0,0529	0,4247	0,7585	-0,8896	1
13	-0,0898	0,1866	0,9019	-1,2692	0,9650
14	-0,0340	0,2044	0,8920	-0,4855	1
15	0,0086	0,1296	0,9330	0,1168	1
16	-0,2422	0,1218	0,9371	-3,2935	0,3719
17	0,0840	0,2247	0,8805	1,2158	1
18	-0,0021	0,3811	0,7867	-0,0343	1
19	-0,0358	0,1886	0,9008	-0,5061	1
20	0,0908	0,4751	0,7245	1,5976	0,7666
21	-0,1679	0,6725	0,5723	-3,7399	0,3275
22	-0,0146	0,9474	0,2293	-0,8129	1
23	-0,0395	0,5475	0,6727	-0,7490	1
24	0,3610	0,1225	0,9368	4,9107	0,2494

Lampiran 6. Hasil Iterasi Estimasi Parameter *Robust* GM-Estimator

Iterasi	Parameter							
	$\hat{\gamma}_1$	$\hat{\gamma}_2$	$\hat{\gamma}_3$	$\hat{\gamma}_4$	$\hat{\gamma}_5$	$\hat{\gamma}_6$	$\hat{\gamma}_7$	$\hat{\gamma}_8$
MKT	-0,2898	0,2227	-0,0845	-0,4259	0,1195	0,4907	-0,2670	0,0888
1	-0,294611	0,290641	-0,116774	-0,295955	0,052766	0,500369	-0,337498	0,101958
2	-0,290258	0,323894	-0,141483	-0,254221	0,065803	0,507474	-0,343688	0,152822
3	-0,288410	0,336977	-0,152051	-0,236907	0,085787	0,517902	-0,338660	0,182560
4	-0,287740	0,342527	-0,156625	-0,228668	0,097366	0,519141	-0,336254	0,194627
5	-0,287666	0,344582	-0,158308	-0,225173	0,105596	0,519165	-0,333648	0,199330
6	-0,287796	0,345293	-0,158868	-0,223616	0,112148	0,518669	-0,331070	0,201017
7	-0,287955	0,345605	-0,159127	-0,222659	0,116906	0,517773	-0,329100	0,201355
8	-0,288113	0,345748	-0,159271	-0,221988	0,120443	0,516991	-0,327509	0,201233
9	-0,288256	0,345817	-0,159368	-0,221469	0,123136	0,516366	-0,326205	0,200973
10	-0,288380	0,345853	-0,159444	-0,221046	0,125219	0,515872	-0,325139	0,200689
11	-0,288485	0,345874	-0,159509	-0,220692	0,126844	0,515483	-0,324268	0,200422
12	-0,288574	0,345888	-0,159566	-0,220395	0,128121	0,515174	-0,323559	0,200186
13	-0,288647	0,345898	-0,159616	-0,220144	0,129126	0,514929	-0,322983	0,199982
14	-0,288707	0,345906	-0,159659	-0,219934	0,129921	0,514735	-0,322515	0,199809
15	-0,288757	0,345912	-0,159696	-0,219759	0,130549	0,514580	-0,322136	0,199665
16	-0,288798	0,345916	-0,159728	-0,219614	0,131048	0,514457	-0,321829	0,199544
17	-0,288831	0,345920	-0,159755	-0,219494	0,131443	0,514359	-0,321581	0,199444
18	-0,288859	0,345923	-0,159778	-0,219395	0,131757	0,514281	-0,321380	0,199362
19	-0,288881	0,345926	-0,159797	-0,219314	0,132007	0,514219	-0,321218	0,199294
20	-0,288899	0,345927	-0,159812	-0,219248	0,132206	0,514169	-0,321087	0,199239
21	-0,288914	0,345929	-0,159825	-0,219193	0,132365	0,514129	-0,320981	0,199193
22	-0,288925	0,345930	-0,159836	-0,219149	0,132491	0,514097	-0,320896	0,199156
23	-0,288935	0,345931	-0,159845	-0,219113	0,132592	0,514072	-0,320828	0,199126
24	-0,288943	0,345932	-0,159852	-0,219084	0,132673	0,514052	-0,320773	0,199102
25	-0,288949	0,345933	-0,159858	-0,219060	0,132737	0,514035	-0,320728	0,199082
26	-0,288954	0,345933	-0,159863	-0,219041	0,132788	0,514022	-0,320693	0,199066
27	-0,288958	0,345934	-0,159866	-0,219025	0,132829	0,514012	-0,320664	0,199053
28	-0,288962	0,345934	-0,159870	-0,219013	0,132862	0,514004	-0,320641	0,199043
29	-0,288964	0,345934	-0,159872	-0,219002	0,132888	0,513997	-0,320622	0,199034
30	-0,288966	0,345934	-0,159874	-0,218994	0,132909	0,513992	-0,320607	0,199027
31	-0,288968	0,345935	-0,159876	-0,218988	0,132926	0,513987	-0,320595	0,199022
32	-0,288969	0,345935	-0,159877	-0,218982	0,132939	0,513984	-0,320586	0,199017
33	-0,288971	0,345935	-0,159878	-0,218978	0,132950	0,513981	-0,320578	0,199014
34	-0,288972	0,345935	-0,159879	-0,218975	0,132959	0,513979	-0,320572	0,199011
35	-0,288972	0,345935	-0,159880	-0,218972	0,132966	0,513977	-0,320567	0,199008
36	-0,288973	0,345935	-0,159880	-0,218969	0,132971	0,513976	-0,320563	0,199006

37	-0,288973	0,345935	-0,159881	-0,218968	0,132976	0,513975	-0,320559	0,199005
38	-0,288974	0,345935	-0,159881	-0,218966	0,132979	0,513974	-0,320557	0,199004
39	-0,288974	0,345935	-0,159882	-0,218965	0,132982	0,513973	-0,320555	0,199003
40	-0,288974	0,345935	-0,159882	-0,218964	0,132984	0,513973	-0,320553	0,199002
41	-0,288974	0,345935	-0,159882	-0,218963	0,132986	0,513972	-0,320552	0,199001
42	-0,288975	0,345935	-0,159882	-0,218963	0,132988	0,513972	-0,320551	0,199001
43	-0,288975	0,345935	-0,159882	-0,218962	0,132989	0,513971	-0,320550	0,199000
44	-0,288975	0,345935	-0,159882	-0,218962	0,132990	0,513971	-0,320549	0,199000
45	-0,288975	0,345935	-0,159882	-0,218962	0,132990	0,513971	-0,320548	0,199000
46	-0,288975	0,345935	-0,159883	-0,218961	0,132991	0,513971	-0,320548	0,199000

Lampiran 7. Data Simulasi

Y	X₁	X₂	X₃	X₄	X₅	X₆	X₇	X₈
3,806	377,445	30102,612	43,309	23,534	0,334	98,781	71,146	254,194
7,416	561,193	89941,000	43,329	30,335	0,319	99,721	73,209	3398,495
3,596	462,732	37540,838	47,362	36,516	0,350	97,599	70,440	799,156
4,625	350,355	44105,445	46,555	34,310	0,335	106,604	72,025	516,994
5,378	530,678	34050,531	42,617	41,644	0,334	102,259	71,991	939,667
8,084	813,722	64148,208	43,417	60,880	0,365	91,783	64,522	1221,238
0,777	-307,648	-74324,242	45,164	-14,553	0,384	95,261	69,629	-1749,482
3,039	-1520,534	41529,835	30,084	33,439	0,065	70,835	53,313	-10878,025
4,469	429,703	56466,043	45,846	24,111	0,321	96,905	69,015	1599,162
10,017	157,693	32024,443	42,697	2,939	0,320	94,466	69,855	1861,514
1,531	474,757	-7721,764	41,744	41,473	0,317	95,054	65,871	-1590,799
3,380	289,745	-22306,549	45,872	17,170	0,295	96,302	70,464	-1440,787
4,146	2337,418	45920,705	60,382	49,880	0,591	125,564	87,237	12066,122
-4,153	-44,715	-31347,486	44,747	-1,624	0,290	98,232	69,987	-1132,742
1,856	389,340	36232,751	39,960	37,787	0,284	98,496	66,563	36,733
4,873	344,136	55129,083	40,316	30,387	0,334	98,219	67,948	2059,118
-2,056	-39,851	-73216,154	45,270	17,540	0,239	91,949	65,754	-3266,329
4,974	686,833	71734,661	47,838	59,491	0,369	99,980	71,656	1764,683
4,024	2379,740	33297,515	60,773	53,207	0,609	126,678	87,412	12127,637
2,509	339,581	-18874,037	44,918	40,180	0,280	101,532	70,414	-1946,140
2,890	513,424	12360,915	45,887	39,843	0,375	104,729	72,738	-836,819
5,450	810,043	99333,486	43,870	53,485	0,318	99,508	71,850	2922,095
0,298	-1540,819	-17755,683	29,758	23,608	0,064	71,333	53,157	-11040,271
3,111	728,418	49981,550	45,846	73,147	0,386	106,352	70,472	259,725

Lampiran 8. Hasil Perhitungan Nilai t_i , h_{ii} , dan $DFITS$ Pada Data Simulasi

No.	Kabupaten / Kota	t_i	h_{ii}	$DFITS$
1	Kep,Selayar	0,5592	0,2303	-0,3059
2	Bulukumba	0,0253	0,3327	-0,0179
3	Bantaeng	0,3651	0,1795	-0,1708
4	Jeneponto	1,7191	0,6795	1,7173
5	Takalar	0,6206	0,2614	0,3692
6	Gowa	1,0580	0,6992	1,2936
7	Sinjai	0,1475	0,7139	-1,2330
8	Maros	0,3189	0,4082	-0,2649
9	Pangkep	0,1779	0,3870	-0,1413
10	Barru	3,0622	0,2739	1,8806
11	Bone	0,5367	0,3599	-0,4024
12	Soppeng	0,8903	0,3293	0,6238
13	Wajo	0,4629	0,3249	-0,3211
14	Sidrap	3,0010	0,2521	-1,7421
15	Pinrang	0,6825	0,3596	-0,5114
16	Enrekang	0,1920	0,3946	-0,1550
17	Luwu	0,2269	0,5512	0,2515
18	Tana Toraja	0,3550	0,3108	-0,2384
19	Luwu Utara	0,1909	0,4026	-0,1567
20	Luwu Timur	1,5409	0,2888	0,9819
21	Toraja Utara	0,0681	0,4042	-0,0561
22	Makassar	1,0209	0,2755	-0,6296
23	Pare Pare	0,3320	0,4371	-0,2926
24	Palopo	0,0434	0,4239	0,0372

Lampiran 9. Data Hasil Transformasi Pemusatan dan Penskalaan Data Simulasi

Y^*	X_1^*	X_2^*	X_3^*	X_4^*	X_5^*	X_6^*	X_7^*	X_8^*
0,0211	-0,0047	0,0256	-0,0365	-0,1037	0,0106	0,0019	0,0359	-0,0032
0,2710	0,0402	0,3003	-0,0359	-0,0343	-0,0169	0,0181	0,0936	0,1262
0,0066	0,0161	0,0598	0,0897	0,0288	0,0386	-0,0185	0,0162	0,0193
0,0777	-0,0114	0,0899	0,0646	0,0063	0,0124	0,1369	0,0605	0,0076
0,1299	0,0328	0,0438	-0,0581	0,0811	0,0098	0,0619	0,0596	0,0250
0,3172	0,1020	0,1819	-0,0332	0,2775	0,0655	-0,1189	-0,1493	0,0366
-0,1887	-0,1724	-0,4537	0,0212	-0,4925	0,0993	-0,0589	-0,0065	-0,0856
-0,0320	-0,4692	0,0781	-0,4483	-0,0026	-0,4691	-0,4804	-0,4628	-0,4610
0,0670	0,0081	0,1466	0,0425	-0,0978	-0,0134	-0,0305	-0,0237	0,0522
0,4511	-0,0585	0,0345	-0,0556	-0,3140	-0,0153	-0,0726	-0,0002	0,0629
-0,1365	0,0191	-0,1480	-0,0852	0,0794	-0,0194	-0,0624	-0,1116	-0,0790
-0,0084	-0,0262	-0,2149	0,0433	-0,1687	-0,0585	-0,0409	0,0169	-0,0729
0,0446	0,4749	0,0982	0,4951	0,1652	0,4694	0,4640	0,4860	0,4826
-0,5300	-0,1081	-0,2564	0,0082	-0,3605	-0,0688	-0,0076	0,0035	-0,0602
-0,1139	-0,0018	0,0538	-0,1408	0,0417	-0,0797	-0,0031	-0,0922	-0,0121
0,0949	-0,0129	0,1405	-0,1297	-0,0338	0,0100	-0,0078	-0,0535	0,0711
-0,3848	-0,1069	-0,4486	0,0245	-0,1649	-0,1591	-0,1160	-0,1149	-0,1479
0,1020	0,0710	0,2167	0,1045	0,2633	0,0733	0,0226	0,0502	0,0590
0,0362	0,4853	0,0403	0,5073	0,1991	0,5003	0,4833	0,4909	0,4851
-0,0688	-0,0140	-0,1991	0,0136	0,0662	-0,0859	0,0493	0,0155	-0,0937
-0,0424	0,0285	-0,0558	0,0438	0,0627	0,0826	0,1045	0,0805	-0,0480
0,1349	0,1011	0,3434	-0,0190	0,2020	-0,0182	0,0144	0,0556	0,1066
-0,2218	-0,4742	-0,1940	-0,4585	-0,1030	-0,4708	-0,4718	-0,4672	-0,4677
-0,0270	0,0812	0,1169	0,0425	0,4027	0,1035	0,1325	0,0171	-0,0029

Lampiran 10. Variabel Ortogonal Z (Untuk Data Simulasi)

Z_1	Z_2	Z_3	Z_4	Z_5	Z_6	Z_7	Z_8
-0,0129	-0,0489	-0,0963	-0,0179	-0,0266	-0,0115	0,0273	0,0215
0,1280	0,1805	-0,2584	-0,0457	0,0045	0,0309	-0,0048	0,0272
0,0771	0,0369	-0,0110	0,0302	0,0768	-0,0303	0,0031	-0,0013
0,1211	0,0268	-0,0402	-0,1111	0,0174	-0,0463	0,0020	-0,0568
0,0738	0,0792	0,0146	-0,0536	-0,0703	0,0138	-0,0069	0,0325
0,0385	0,3470	0,0810	0,1865	0,0003	0,0014	0,0164	-0,0108
-0,2361	-0,6504	-0,0489	0,0705	-0,0348	-0,1076	-0,0113	0,0153
-1,0980	0,3070	-0,0131	-0,0208	0,0512	-0,0391	-0,0069	0,0091
0,0176	0,0387	-0,1673	0,0312	0,0658	0,0057	0,0160	-0,0441
-0,1061	-0,1608	-0,2770	0,0400	-0,0093	0,0114	-0,0057	0,0051
-0,1411	-0,0054	0,1663	0,0711	-0,0664	0,0337	0,0243	0,0033
-0,1172	-0,2604	0,0352	-0,0131	0,0471	0,0372	0,0300	0,0206
1,1845	-0,0910	0,0136	0,0083	0,0223	0,0128	-0,0125	0,0070
-0,1951	-0,4100	-0,0837	-0,0433	0,0085	0,0152	0,0043	-0,0229
-0,1142	0,1186	-0,0126	-0,0102	-0,0879	0,0555	0,0030	-0,0359
-0,0329	0,1108	-0,1457	0,0329	-0,0961	0,0033	-0,0237	-0,0216
-0,3425	-0,3794	0,2020	0,0242	0,0618	0,0852	-0,0174	-0,0155
0,2292	0,2831	0,0497	0,0126	0,0803	-0,0446	-0,0132	0,0144
1,2139	-0,1178	0,0765	0,0188	0,0047	0,0055	-0,0226	0,0099
-0,0634	-0,0969	0,1984	-0,0910	0,0003	0,0465	-0,0001	0,0046
0,1187	-0,0394	0,1022	-0,0618	-0,0295	-0,0645	0,0334	0,0158
0,1827	0,3693	-0,1039	-0,0241	0,0200	0,0459	0,0025	0,0250
-1,1631	0,0546	0,0868	0,0016	-0,0047	0,0085	-0,0287	0,0173
0,2375	0,3080	0,2319	-0,0352	-0,0352	-0,0689	-0,0085	-0,0196

Lampiran 11. Hasil Perhitungan Nilai Residual, Leverage, Bobot π , Skala Residual Dan Nilai Bobot untuk Iterasi Pertama Pada Data Simulasi

No. Pengamatan	$e_i^{(0)}$	$h_{ii}^{(0)}$	$\pi_i^{(0)}$	$u_i^{(0)}$	$w_i^{(0)}$
1	-0,0758	0,1886	0,9008	-1,4082	0,8697
2	-0,0032	0,2910	0,8420	-0,0642	1,0000
3	-0,0514	0,1378	0,9285	-0,9266	1,0000
4	0,1727	0,4578	0,7363	3,9237	0,3121
5	0,0822	0,2197	0,8833	1,5573	0,7864
6	0,1007	0,5575	0,6652	2,5331	0,4835
7	-0,0123	0,6722	0,5725	-0,3600	1,0000
8	-0,0382	0,3666	0,7959	-0,8029	1,0000
9	-0,0217	0,3453	0,8091	-0,4495	1,0000
10	0,3155	0,2322	0,8762	6,0249	0,2033
11	-0,0664	0,3182	0,8257	-1,3459	0,9100
12	0,1108	0,2876	0,8440	2,1970	0,5575
13	-0,0590	0,2833	0,8466	-1,1655	1,0000
14	-0,3163	0,2104	0,8886	-5,9566	0,2056
15	-0,0840	0,3179	0,8259	-1,7009	0,7200
16	-0,0233	0,3529	0,8044	-0,4848	1,0000
17	0,0237	0,5095	0,7003	0,5665	1,0000
18	-0,0458	0,2692	0,8549	-0,8972	1,0000
19	-0,0230	0,3609	0,7994	-0,4819	1,0000
20	0,1877	0,2471	0,8677	3,6203	0,3383
21	-0,0082	0,3625	0,7984	-0,1722	1,0000
22	-0,1310	0,2339	0,8753	-2,5039	0,4891
23	-0,0388	0,3955	0,7775	-0,8343	1,0000
24	0,0051	0,3822	0,7860	0,1096	1,0000

Lampiran 12. Hasil Iterasi Estimasi Parameter *Robust* GM-Estimator (Pada Data Simulasi)

Iterasi	Parameter							
	$\hat{\gamma}_1$	$\hat{\gamma}_2$	$\hat{\gamma}_3$	$\hat{\gamma}_4$	$\hat{\gamma}_5$	$\hat{\gamma}_6$	$\hat{\gamma}_7$	$\hat{\gamma}_8$
MKT	0,128	0,434	-0,694	0,653	-0,085	-0,35	0,834	1,651
1	0,124710	0,398690	-0,647032	0,483697	-0,077177	-0,275190	0,124710	0,398690
2	0,123996	0,379927	-0,648217	0,330997	-0,098360	-0,244433	0,123996	0,379927
3	0,123669	0,367442	-0,655289	0,206637	-0,097997	-0,244565	0,123669	0,367442
4	0,124524	0,358050	-0,664935	0,106575	-0,098357	-0,245654	0,124524	0,358050
5	0,125689	0,351295	-0,673819	0,023031	-0,114185	-0,240842	0,125689	0,351295
6	0,126219	0,346164	-0,677108	-0,036843	-0,113781	-0,249568	0,126219	0,346164
7	0,126426	0,343085	-0,676397	-0,067774	-0,113432	-0,255703	0,126426	0,343085
8	0,126561	0,341200	-0,675517	-0,085230	-0,112420	-0,260589	0,126561	0,341200
9	0,126229	0,340178	-0,673964	-0,093038	-0,109927	-0,263515	0,126229	0,340178
10	0,126001	0,339632	-0,673213	-0,097385	-0,108836	-0,265024	0,126001	0,339632
11	0,125874	0,339333	-0,672846	-0,099868	-0,108330	-0,265824	0,125874	0,339333
12	0,125804	0,339165	-0,672657	-0,101311	-0,108074	-0,266270	0,125804	0,339165
13	0,125765	0,339069	-0,672556	-0,102162	-0,107938	-0,266526	0,125765	0,339069
14	0,125743	0,339012	-0,672501	-0,102670	-0,107863	-0,266676	0,125743	0,339012
15	0,125730	0,338978	-0,672470	-0,102974	-0,107820	-0,266765	0,125730	0,338978
16	0,125723	0,338958	-0,672453	-0,103158	-0,107796	-0,266818	0,125723	0,338958
17	0,125718	0,338946	-0,672442	-0,103269	-0,107781	-0,266850	0,125718	0,338946
18	0,125716	0,338939	-0,672436	-0,103336	-0,107772	-0,266869	0,125716	0,338939
19	0,125714	0,338935	-0,672432	-0,103376	-0,107767	-0,266881	0,125714	0,338935
20	0,125713	0,338932	-0,672430	-0,103401	-0,107764	-0,266888	0,125713	0,338932
21	0,125713	0,338931	-0,672429	-0,103416	-0,107762	-0,266892	0,125713	0,338931
22	0,125712	0,338930	-0,672428	-0,103425	-0,107761	-0,266895	0,125712	0,338930
23	0,125712	0,338929	-0,672428	-0,103431	-0,107761	-0,266896	0,125712	0,338929
24	0,125712	0,338929	-0,672427	-0,103434	-0,107760	-0,266897	0,125712	0,338929
25	0,125712	0,338928	-0,672427	-0,103436	-0,107760	-0,266898	0,125712	0,338928
26	0,125712	0,338928	-0,672427	-0,103437	-0,107760	-0,266898	0,125712	0,338928
27	0,125712	0,338928	-0,672427	-0,103438	-0,107760	-0,266898	0,125712	0,338928
28	0,125712	0,338928	-0,672427	-0,103438	-0,107760	-0,266899	0,125712	0,338928
29	0,125712	0,338928	-0,672427	-0,103439	-0,107760	-0,266899	0,125712	0,338928