


**Optimasi *Markov Weighted Fuzzy Time Series* Berbasis *K-Means*
menggunakan *Particle Swarm Optimization* pada Peramalan Harga
Saham Bukalapak**



**ANDI NIA RAHMADANI
H051221041**



**PROGRAM STUDI STATISTIKA DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR**

2026

**Optimasi *Markov Weighted Fuzzy Time Series* Berbasis *K-Means*
menggunakan *Particle Swarm Optimization* pada Peramalan Harga
Saham Bukalapak**

**ANDI NIA RAHMADANI
H051221041**



**PROGRAM STUDI STATISTIKA DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**Optimasi *Markov Weighted Fuzzy Time Series* Berbasis *K-Means*
menggunakan *Particle Swarm Optimization* pada Peramalan Harga
Saham Bukalapak**

ANDI NIA RAHMADANI

H051221041

Skripsi

Diajukan sebagai salah satu syarat memperoleh gelar Sarjana Statistika

Program Studi Statistika

pada

**PROGRAM STUDI STATISTIKA DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

SKRIPSI**Optimasi *Markov Weighted Fuzzy Time Series* Berbasis *K-Means*
menggunakan *Particle Swarm Optimization* pada Peramalan Harga
Saham Bukalapak**

yang disusun dan diajukan oleh

ANDI NIA RAHMADANI

H051221041

Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana Statistika pada tanggal
22 Juli 2026 dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Statistika
Departemen Statistika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar



PENGESAHAN

Mengesahkan:
Pembimbing Tugas Akhir,



Sitti Sahriman, S.Si., M.Si.
NIP. 19881018 201504 2 002

Mengetahui:
Ketua Program Studi,



Dr. Anna Islamiyati, S.Si., M.Si.
NIP. 19770808 200501 2 002

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "*Optimasi Markov Weighted Fuzzy Time Series Berbasis K-Means menggunakan Particle Swarm Optimization pada Peramalan Harga Saham Bukalapak*" adalah benar karya saya dengan arahan dari pembimbing Sitti Sahriman, S.Si., M.Si. sebagai Pembimbing Utama. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau kutipan dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 22 Juli 2026



ANDI NIA RAHMADANI
H051221041

UCAPAN TERIMA KASIH

Segala puji bagi Allah Subhanahu Wa Ta'ala atas limpahan rahmat, hidayah, serta karunia-Nya yang telah memberikan kemudahan sehingga penulis dapat menyelesaikan tugas akhir ini. Shalawat serta salam senantiasa tercurah kepada Nabi Muhammad Shallallahu 'Alaihi Wa Sallam, beserta keluarga, para sahabatnya serta seluruh pengikutnya hingga akhir zaman.


Pada kesempatan ini, penulis menyampaikan ucapan terima kasih dan penghargaan yang setulus-tulusnya kepada Ibu **Sitti Sahrman, S.Si., M.Si.** selaku dosen pembimbing yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, arahan, masukan, serta motivasi dengan penuh kesabaran selama proses penyusunan skripsi ini. Ucapan terima kasih juga penulis sampaikan kepada Ibu **Prof. Dr. Nurtiti Sunusi, S.Si., M.Si.** dan Bapak **Siswanto, S.Si., M.Si.** selaku dosen penguji atas kritik, saran, dan masukan yang sangat berharga dalam penyempurnaan skripsi ini. Terima kasih kepada Pimpinan Universitas Hasanuddin, Departemen Statistika, Jajaran Dosen, dan Staf Departemen Statistika yang telah memfasilitasi, memberikan ilmu, dan membantu penulis selama masa perkuliahan.

Rasa terima kasih yang mendalam penulis sampaikan kepada kedua orang tua tercinta, **Andi Nodding dan Hartati**, atas kasih sayang, doa, dukungan, dan pengorbanan yang tiada henti dalam setiap langkah penulis. Ucapan terima kasih juga penulis tujukan kepada saudara-saudara tercinta, **Andi Sultan, Andi Herman** dan **Andi Aidil** atas semangat, perhatian, dan dukungan yang selalu diberikan kepada penulis. Tidak lupa, penulis juga menyampaikan terima kasih kepada keluarga besar yang senantiasa mendoakan, memberi dorongan moral, serta menjadi sumber kekuatan bagi penulis selama menempuh pendidikan hingga penyusunan skripsi ini.

Penulis juga menyampaikan terima kasih kepada seluruh **sahabat dan teman-teman** yang senantiasa kebersamai, memberi bantuan, dan dukungan selama proses perkuliahan maupun penyusunan skripsi ini.

Akhirnya, penulis menyadari bahwa skripsi ini masih memiliki keterbatasan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi penyempurnaan ke depannya. Semoga skripsi ini dapat memberikan manfaat bagi pembaca dan pihak-pihak yang berkepentingan.

Makassar, 22 Juli 2026



Andi Nia Rahmadani
H051221041

ABSTRAK

Andi Nia Rahmadani. **Optimasi *Markov Weighted Fuzzy Time Series* Berbasis *K-Means* menggunakan *Particle Swarm Optimization* pada Peramalan Harga Saham Bukalapak** (Dibimbing oleh Sitti Sahriman)

Latar Belakang. Harga saham PT Bukalapak.com Tbk memiliki karakteristik yang fluktuatif sehingga memerlukan metode peramalan yang mampu menangani ketidakpastian data. *Markov Weighted Fuzzy Time Series* (MWFTS) merupakan pengembangan dari *Fuzzy Time Series* yang memanfaatkan relasi fuzzy dan probabilitas transisi Markov untuk meningkatkan akurasi peramalan. Kinerja MWFTS dipengaruhi oleh pembentukan batas interval fuzzy. Algoritma K-Means digunakan untuk membentuk interval fuzzy yang lebih representatif terhadap distribusi data, namun batas interval yang dihasilkan masih dapat dioptimalkan. Oleh karena itu, *Particle Swarm Optimization* (PSO) diterapkan untuk mengoptimalkan batas interval fuzzy. **Tujuan.** Penelitian ini bertujuan memperoleh hasil peramalan harga saham PT Bukalapak.com Tbk menggunakan metode MWFTS berbasis interval fuzzy yang dibentuk menggunakan algoritma K-Means serta MWFTS berbasis K-Means yang dioptimalkan menggunakan PSO. **Metode.** Penelitian ini menggunakan data harga penutupan harian PT Bukalapak.com Tbk periode Oktober 2024-Desember 2025 sebanyak 298 observasi yang dibagi menjadi data latih dan data uji. Interval fuzzy dibentuk menggunakan K-Means, dilanjutkan dengan proses fuzzifikasi, pembentukan *Fuzzy Logical Relationship*, penyusunan matriks probabilitas transisi Markov, dan peramalan menggunakan MWFTS. Selanjutnya, PSO digunakan untuk mengoptimalkan batas interval fuzzy dengan meminimalkan nilai *Mean Absolute Percentage Error* (MAPE). **Hasil.** Model MWFTS berbasis K-Means menghasilkan nilai MAPE 3,1736%, MAE 5,2263, dan RMSE 5,8953. Setelah optimasi menggunakan PSO, diperoleh nilai MAPE 1,4557%, MAE 2,4331, RMSE 3,1032, serta koefisien korelasi Pearson 0,7799. **Kesimpulan.** *Particle Swarm Optimization* (PSO) berhasil mengoptimalkan batas interval fuzzy pada metode *Markov Weighted Fuzzy Time Series*, sehingga menghasilkan model peramalan harga saham PT Bukalapak.com Tbk dengan akurasi yang lebih baik.

Kata Kunci: *Markov Weighted Fuzzy Time Series*, *K-Means*, *Particle Swarm Optimization*, Harga Saham, Optimasi Interval Fuzzy.

ABSTRACT

Andi Nia Rahmadani. **Optimization of K-Means-Based Markov Weighted Fuzzy Time Series Using Particle Swarm Optimization for Forecasting Bukalapak Stock Prices** (supervised by Sitti Sahriman)

Background. The stock price of PT Bukalapak.com Tbk is characterized by fluctuations, requiring a forecasting method capable of handling data uncertainty. Markov Weighted Fuzzy Time Series (MWFTS) is an extension of Fuzzy Time Series that utilizes fuzzy relationships and Markov transition probabilities to improve forecasting accuracy. The performance of MWFTS is influenced by the construction of fuzzy interval boundaries. The K-Means algorithm is used to generate fuzzy intervals that are more representative of the data distribution; however, the resulting interval boundaries can still be optimized. Therefore, Particle Swarm Optimization (PSO) is applied to optimize the fuzzy interval boundaries. **Aim.** This study aims to obtain stock price forecasting results for PT Bukalapak.com Tbk using the MWFTS method based on fuzzy intervals generated using the K-Means algorithm and the K-Means-based MWFTS method optimized using PSO. **Methods.** This study used 298 daily closing stock price observations of PT Bukalapak.com Tbk from October 2024 to December 2025, which were divided into training and testing datasets. Fuzzy intervals were generated using K-Means, followed by the fuzzification process, the construction of Fuzzy Logical Relationships, the development of a Markov transition probability matrix, and forecasting using MWFTS. Subsequently, PSO was employed to optimize the fuzzy interval boundaries by minimizing the Mean Absolute Percentage Error (MAPE). **Results.** The K-Means-based MWFTS model produced a MAPE of 3.1736%, an MAE of 5.2263, and an RMSE of 5.8953. After optimization using PSO, the model achieved a MAPE of 1.4557%, an MAE of 2.4331, an RMSE of 3.1032, and a Pearson correlation coefficient of 0.7799. **Conclusion.** Particle Swarm Optimization (PSO) successfully optimized the fuzzy interval boundaries in the Markov Weighted Fuzzy Time Series method, resulting in a stock price forecasting model for PT Bukalapak.com Tbk with better forecasting accuracy.

Keywords: Markov Weighted Fuzzy Time Series, K-Means, Particle Swarm Optimization, Stock Price, Fuzzy Interval Optimization

DAFTAR ISTILAH

Istilah	Arti dan Penjelasan
Himpunan Fuzzy	Sekumpulan elemen yang memiliki derajat keanggotaan antara 0 sampai 1.
Interval Fuzzy	Interval yang dibentuk pada <i>universe of discourse</i> sebagai dasar pembentukan himpunan fuzzy.
Fuzzifikasi	Proses mengubah data numerik menjadi data linguistik (fuzzy).
Defuzzifikasi	Proses mengubah hasil fuzzy menjadi nilai numerik (crisp).
<i>Fuzzy Logical Relationship</i>	Hubungan logika fuzzy antara state saat ini dengan state berikutnya.
<i>Fuzzy Logical Relationship Group</i>	Kelompok FLR yang memiliki Left-Hand Side yang sama.
Klaster	Kelompok data hasil proses K-Means berdasarkan kemiripan karakteristik.
<i>Universe of Discourse</i>	Rentang nilai yang mencakup seluruh data historis sebagai dasar pembentukan interval fuzzy.
<i>Midpoint</i>	Titik tengah suatu interval fuzzy yang digunakan dalam proses peramalan.
Optimasi	Kandidat solusi pada algoritma <i>Particle Swarm Optimization</i> .
Partikel	Representasi kandidat solusi di dalam ruang pencarian algoritma <i>Particle Swarm Optimization</i> .
Probabilitas Transisi	Peluang perpindahan dari suatu state menuju state lainnya pada rantai Markov.
<i>State</i>	Representasi linguistik suatu interval fuzzy.

DAFTAR LAMBANG DAN SINGKATAN

Lambang/Singkatan	Arti dan Penjelasan
PT	Perseroan Terbatas
Tbk	Terbuka
FTS	<i>Fuzzy Time Series</i>
U	<i>Universe of Discourse</i>
$D_{\min}$	Nilai minimum data historis
$D_{\max}$	Nilai maksimum data historis
d_1	Penyesuaian batas bawah <i>Universe of Discourse</i>
d_2	Penyesuaian batas atas <i>Universe of Discourse</i>
$\mu_{A_i}(x)$	Derajat keanggotaan elemen x pada himpunan fuzzy A_i
FLR	<i>Fuzzy Logical Relationship</i>
FLRG	<i>Fuzzy Logical Relationship Group</i>
LB_i	Batas bawah interval ke- i (<i>Lower Bound</i>)
UB_i	Batas bawah interval ke- i (<i>Lower Bound</i>)
m_i	Nilai tengah (<i>Midpoint</i>) interval ke- i
k	Jumlah klaster
C_j	<i>Centroid</i> klaster ke- j
WCSS	<i>Within Cluster Sum of Squares</i>
SSE	<i>Sum of Squared Errors</i>
WFTS	<i>Weighted Fuzzy Time Series</i>
MWFTS	<i>Markov Weighted Fuzzy Time Series</i>
P_{ij}	Probabilitas transisi dari state A_i ke state A_j
PSO	<i>Particle Swarm Optimization</i>
c_1	Konstanta percepatan kognitif
c_2	Konstanta percepatan sosial
P_{best}	Posisi terbaik partikel ke- i
G_{best}	Posisi terbaik seluruh partikel
ω	Bobot inersia
MAPE	<i>Mean Absolute Percentage Error</i>
MAE	<i>Mean Absolute Error</i>
RMSE	<i>Root Mean Square Error</i>
$Y_{(t)}$	Nilai aktual pada waktu ke- t
$\hat{Y}_{(t)}$	Nilai hasil peramalan pada waktu ke- t
n	Banyaknya observasi
t	Indeks waktu

DAFTAR ISI

	Halaman
HALAMAN JUDUL	i
HALAMAN PENGANTAR	ii
HALAMAN PENGESAHAN	iii
PERNYATAAN KEASLIAN SKRIPSI	iv
UCAPAN TERIMA KASIH	v
ABSTRAK	vi
ABSTRACT	vii
DAFTAR ISTILAH	viii
DAFTAR LAMBANG DAN SINGKATAN	ix
DAFTAR ISI	x
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
DAFTAR LAMPIRAN	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Tujuan dan Manfaat	3
1.3 Batasan Masalah	4
1.4 Teori	4
1.4.1 Peramalan	4
1.4.2 Logika <i>Fuzzy</i> , Himpunan <i>Fuzzy</i> , dan Fungsi Keanggotaan	5
1.4.3 <i>Fuzzy Time Series</i>	5
1.4.4 <i>K-Means Clustering</i>	9
1.4.5 <i>Weighted Fuzzy Time Series</i>	12
1.4.6 Rantai Markov	13
1.4.7 <i>Markov Weighted Fuzzy Time Series</i>	14
1.4.8 <i>Particle Swarm Optimization</i>	16
1.4.9 Ukuran Akurasi Peramalan	18
1.4.10 Saham PT Bukalapak.com Tbk	20
BAB II METODE PENELITIAN	22
2.1 Jenis dan Sumber Data	22
2.2 Variabel Penelitian	22
2.3 Analisis Data	22
BAB III HASIL DAN PEMBAHASAN	24
3.1 Analisis Deskriptif	24
3.2 Peramalan Saham Bukalapak dengan Metode <i>Markov Weighted Fuzzy Time Series</i> Berbasis <i>K-Means</i>	26
3.2.1 Penentuan <i>Universe of Discourse</i>	26
3.2.2 Pembentukan Interval Berbasis <i>K-Means Clustering</i>	26
3.2.3 Fuzzifikasi, Pembentukan <i>Fuzzy Logical Relationship</i> dan <i>Fuzzy Logical Relationship Group</i>	28
3.2.4 Pembentukan Matriks Probabilitas Transisi Markov	30
3.2.5 Perhitungan Nilai Peramalan	31
3.2.6 Evaluasi Metode <i>Markov Weighted Fuzzy Time Series</i> Berbasis <i>K-Means</i>	33
3.3 Optimasi <i>Markov Weighted Fuzzy Time Series</i> Berbasis <i>K-Means</i> menggunakan <i>Particle Swarm Optimization</i>	33
3.3.1 Optimasi Batas Interval	33
3.3.2 Rekonstruksi Himpunan <i>Fuzzy</i> dan Matriks Probabilitas Transisi	35

3.3.3	Hasil Peramalan <i>Markov Weighted Fuzzy Time Series</i> Berbasis <i>K-Means</i> dan <i>Particle Swarm Optimization</i>	36
3.3.4	Evaluasi Metode <i>Markov Weighted Fuzzy Time Series</i> Berbasis <i>K-Means</i> dan <i>Particle Swarm Optimization</i>	38
3.4	Evaluasi dan Perbandingan Akurasi Metode Peramalan.....	39
BAB IV KESIMPULAN DAN SARAN		41
4.1	Kesimpulan.....	41
4.2	Saran.....	41
DAFTAR PUSTAKA.....		42
LAMPIRAN.....		48

DAFTAR TABEL

Nomor Urut	Halaman
1. Skala MAPE dengan Tingkat Akurasi Peramalan	19
2. Statistik Deskriptif Data Harga Penutupan Saham Bukalapak	25
3. Hasil Proses <i>K-Means Clustering</i>	27
4. Interval Fuzzy berdasarkan <i>Centroid</i> Akhir <i>K-Means</i>	27
5. Label Linguistik Interval Fuzzy	28
6. Hasil Fuzzifikasi dan FLR Data Latih	29
7. FLRG Data Latih	29
8. Frekuensi Transisi Antar <i>State</i> Data Latih	30
9. <i>Midpoint</i> Setiap <i>State</i>	31
10. Hasil Perhitungan Peramalan Data Latih	32
11. Hasil Perhitungan Peramalan Data Uji	32
12. Hasil Evaluasi Metode MWFTS Berbasis K-Means	33
13. Parameter dan Inisialisasi Komputasi PSO	34
14. Perbandingan Batas Interval Sebelum dan Setelah Optimasi PSO	35
15. Frekuensi Transisi Antar <i>State</i> Data Latih Optimasi PSO	35
16. Hasil Peramalan Data Latih MWFTS K-Means PSO	37
17. Hasil Peramalan Data Uji MWFTS K-Means PSO	38
18. Hasil Evaluasi Metode MWFTS Berbasis K-Means PSO	38
19. Perbandingan Tingkat Akurasi Metode Peramalan pada Data Uji	39

DAFTAR GAMBAR

Nomor Urut	Halaman
1. Plot Data Harga Penutupan Saham Bukalapak.....	24
2. Grafik <i>Elbow Method</i> berdasarkan Nilai WCSS.....	26
3. Plot Peramalan Data Latih menggunakan MWFTS-K-Means-PSO	37
4. Perbandingan Hasil Peramalan Data Uji dengan Data Aktual.....	40

DAFTAR LAMPIRAN

Nomor Urut	Halaman
1. Data Harga Penutupan Saham Harian PT Bukalapak.Com Tbk	49
2. Sintaks Algoritma <i>K-Means</i>	50
3. Hasil Fuzzifikasi dan FLR Data Latih	51
4. Perhitungan Matriks Probabilitas Transisi Markov MWFTS <i>K-Means</i>	52
5. Hasil Perhitungan Peramalan Data Latih MWFTS <i>K-Means</i>	53
6. Hasil Perhitungan Peramalan Data Uji MWFTS <i>K-Means</i>	54
7. Perhitungan Matriks Probabilitas Transisi Markov MWFTS <i>K-Means</i> PSO	55
8. Hasil Peramalan Data Latih MWFTS Berbasis <i>K-Means</i> -PSO	56
9. Hasil Peramalan Data Uji MWFTS Berbasis <i>K-Means</i> -PSO	57
10. Sintaks MWFTS <i>K-Means</i> dan Optimasi PSO	58

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pasar modal di Indonesia mengalami perkembangan yang signifikan dalam beberapa tahun terakhir. Perkembangan tersebut didorong oleh meningkatnya aktivitas perdagangan berbagai instrumen investasi, terutama saham sebagai bukti kepemilikan investor atas suatu perusahaan (Wang, 2021). Kondisi tersebut tercermin dari pergerakan Indeks Harga Saham Gabungan yang berhasil mencapai rekor tertinggi sepanjang masa pada level 9.032,58 pada awal tahun 2026 (Bursa Efek Indonesia, 2026). Selain itu, data Kustodian Sentral Efek Indonesia menunjukkan peningkatan jumlah investor pasar modal dari 13,70 juta pada Agustus 2024 menjadi 22,96 juta investor pada Februari 2026. Pertumbuhan tersebut menunjukkan semakin tingginya minat masyarakat terhadap investasi saham karena dinilai mampu memberikan potensi keuntungan yang besar (Kennedy dan Helena, 2024). Meskipun demikian, investasi saham tetap memiliki tingkat risiko yang tinggi karena pergerakan harganya bersifat dinamis dan fluktuatif. Hal ini dipengaruhi oleh berbagai faktor, seperti kinerja perusahaan, kondisi ekonomi makro, inflasi, suku bunga, nilai tukar, serta sentimen pasar global (Raihan et al., 2023; Wang et al., 2021). Salah satu sektor yang menunjukkan karakteristik fluktuasi tersebut adalah sektor teknologi, yang umumnya mengalami perubahan harga lebih cepat dibandingkan sektor lainnya (Ghosh, 2025).

Saham PT Bukalapak.com Tbk merupakan salah satu saham sektor teknologi yang menunjukkan dinamika harga sejak pelaksanaan *Initial Public Offering* (Frymaruwah et al., 2024). Harga saham yang ditawarkan pada level Rp850 per lembar sempat meningkat pada awal perdagangan, kemudian diikuti tren penurunan dengan volatilitas yang tinggi pada periode berikutnya (Arsha et al., 2022). Pergerakan tersebut menunjukkan karakteristik data finansial yang nonlinier. Penelitian Kim dan Won (2018) juga menyimpulkan bahwa data saham sektor teknologi cenderung memiliki pola fluktuasi yang kompleks. Kondisi ini dapat meningkatkan risiko kerugian apabila keputusan investasi dilakukan hanya berdasarkan spekulasi atau intuisi (Xie, 2024). Oleh karena itu, diperlukan metode peramalan harga saham yang mampu mendukung pengambilan keputusan investasi secara lebih terukur dan rasional.

Peramalan harga saham umumnya dilakukan menggunakan pendekatan analisis deret waktu (Rusminto et al., 2024). Namun, metode konvensional seperti *Auto Regressive Integrated Moving Average* masih memiliki keterbatasan dalam menangani karakteristik data yang bersifat nonlinier dan fluktuatif (Elmi et al., 2025). Analisis deret waktu klasik juga umumnya bergantung pada asumsi kestasioneran dan linearitas, sedangkan data finansial seperti harga saham cenderung bersifat tidak stasioner (Hansun, 2012). Kondisi tersebut mendorong pengembangan metode peramalan yang lebih adaptif dan fleksibel. Salah satu metode yang dapat digunakan adalah *Fuzzy Time Series* (FTS), yaitu metode yang merepresentasikan data numerik ke dalam bentuk linguistik sehingga mampu menangkap pola data yang

kompleks secara lebih fleksibel (Song dan Chissom, 1993). Metode ini tidak mensyaratkan asumsi klasik seperti stasioneritas, sehingga lebih sesuai untuk data yang fluktuatif (Patale dan Sharma, 2025).

Proses peramalan pada FTS dilakukan melalui pembentukan relasi *fuzzy* berdasarkan data historis yang telah difuzzifikasi. Relasi *fuzzy* tersebut merepresentasikan hubungan antar kelas (*state*) yang muncul secara berulang dalam data deret waktu, sehingga masing-masing relasi memiliki tingkat kemunculan yang berbeda (Cheng dan Chen, 2018). Namun, FTS konvensional masih memberikan bobot yang sama pada setiap relasi *fuzzy* tanpa mempertimbangkan frekuensi kemunculannya. Kondisi ini mendorong pengembangan metode *Weighted Fuzzy Time Series* (WFTS) yang memberikan bobot secara proporsional pada setiap relasi *fuzzy* (Yu, 2005). Melalui pembobotan tersebut, pola perubahan nilai yang lebih sering muncul memperoleh prioritas yang lebih tinggi. Dengan demikian, WFTS memiliki kemampuan yang lebih komprehensif dibandingkan metode konvensional karena mampu menghasilkan peramalan yang lebih representatif terhadap karakteristik data deret waktu (Ortiz-Arroyo dan Poulsen, 2018; Rubio et al., 2016).

Pengembangan terhadap WFTS dilakukan untuk meningkatkan kemampuannya dalam menangani karakteristik data yang semakin kompleks. Salah satu pengembangannya adalah *Markov Weighted Fuzzy Time Series* (MWFTS) yang mengintegrasikan konsep rantai Markov dalam proses pembobotan relasi *fuzzy* (Dewi et al., 2023). Konsep rantai Markov memiliki sifat *memoryless*, yaitu kondisi probabilitas pergerakan data pada periode berikutnya hanya ditentukan oleh *state* saat ini (Akhdan dan Fauzy, 2023). Penerapan konsep tersebut dilakukan melalui pembentukan matriks probabilitas transisi yang merepresentasikan peluang perpindahan antar *state* *fuzzy*. Probabilitas transisi tersebut digunakan dalam penyesuaian bobot relasi *fuzzy* secara dinamis sehingga pembobotan menjadi lebih adaptif terhadap pola perubahan data historis (Surono et al., 2022).

Kinerja metode MWFTS sangat dipengaruhi oleh penentuan panjang interval partisi pada *universe of discourse* (Kumar dan Susan, 2021). Pada FTS konvensional, interval umumnya dibentuk dengan panjang yang sama (Saleena et al., 2024). Namun, pendekatan tersebut belum mampu merepresentasikan distribusi data historis secara optimal, terutama pada data yang berfluktuasi tinggi sehingga dapat menyebabkan beberapa interval terlalu padat sementara interval lainnya relatif sedikit atau kosong (Surono et al., 2022). Untuk mengatasi permasalahan tersebut, algoritma *K-Means Clustering* digunakan untuk membentuk interval berdasarkan kedekatan data melalui titik pusat klaster sehingga lebih sesuai dengan pola sebaran data (Mukminin et al., 2020). Namun, *K-Means* memiliki keterbatasan karena rentan terjebak pada solusi optimum lokal, yaitu kondisi ketika proses iterasi berhenti pada solusi terbaik di suatu wilayah pencarian meskipun masih terdapat solusi lain yang lebih optimal secara keseluruhan (Umargono et al., 2019). Sehingga, diperlukan pendekatan optimasi yang mampu menyempurnakan batas interval agar hasil peramalan yang diperoleh menjadi lebih optimal. Salah satu pendekatan yang dapat digunakan adalah metode optimasi berbasis populasi, seperti *Particle Swarm Optimization*.

Particle Swarm Optimization (PSO) merupakan metode optimasi berbasis populasi yang terinspirasi dari perilaku kolektif kawanan burung atau ikan dalam menemukan posisi terbaik (Hasibuan et al., 2025). Metode ini bekerja melalui sekumpulan partikel yang bergerak dalam ruang pencarian untuk memperoleh solusi optimum (Freitas et al., 2020). Setiap partikel merepresentasikan kandidat solusi yang akan diperbarui secara iteratif berdasarkan pengalaman terbaik individu dan pengalaman terbaik seluruh populasi (Yang et al., 2022). Proses pembaruan dilakukan dengan menyesuaikan posisi dan kecepatan partikel hingga diperoleh solusi dengan nilai kesalahan yang paling minimum. Proses tersebut memungkinkan PSO melakukan pencarian solusi secara global sehingga mampu mengurangi risiko terjebak pada optimum lokal (Zhang et al., 2025). Selain itu, PSO memiliki keunggulan berupa konvergensi yang relatif cepat dan kemampuan adaptasi yang baik dalam menangani permasalahan optimasi kompleks (Deng et al., 2021). Karakteristik tersebut menjadikan PSO banyak digunakan untuk meningkatkan akurasi model peramalan pada data deret waktu.

Penelitian terkait metode MWFTS menunjukkan hasil yang baik pada berbagai kasus peramalan. Azzahra et al. (2021) melaporkan bahwa penerapan MWFTS pada peramalan harga saham PT Kimia Farma Tbk mampu menghasilkan nilai MAPE sebesar 2,63%. Wajdi (2022) juga menunjukkan performa yang baik pada peramalan harga saham BSI menggunakan kombinasi FTS dan rantai Markov dengan nilai MAPE sebesar 6,4%. Sementara itu, integrasi PSO pada metode deret waktu fuzzy juga terbukti mampu meningkatkan akurasi peramalan. Rifandi et al. (2018) melaporkan bahwa optimasi interval fuzzy menggunakan PSO menghasilkan nilai MAPE sebesar 7,50%, sedangkan Surono et al. (2022) menunjukkan bahwa MWFTS berbasis PSO memiliki performa yang lebih baik dibandingkan MWFTS berbasis *Genetic Algorithm*.

Penelitian terkait penerapan MWFTS dan PSO menunjukkan bahwa kedua metode tersebut memiliki kemampuan yang baik dalam meningkatkan akurasi peramalan pada berbagai jenis data deret waktu. Namun, penerapan kombinasi MWFTS berbasis *K-Means* dan PSO pada data harga saham sektor teknologi, khususnya saham PT Bukalapak.com Tbk masih belum banyak dilakukan. Karakteristik saham sektor teknologi yang cenderung fluktuatif dan nonlinier menyebabkan pentingnya pengembangan metode peramalan yang lebih adaptif. Berdasarkan hal tersebut, maka dilakukan penelitian berjudul “Optimasi *Markov Weighted Fuzzy Time Series* Berbasis *K-Means* menggunakan *Particle Swarm Optimization* pada Peramalan Harga Saham Bukalapak.”

1.2 Tujuan dan Manfaat

Tujuan dalam penelitian ini adalah:

1. Memperoleh hasil peramalan harga saham PT Bukalapak.com Tbk menggunakan metode *Markov Weighted Fuzzy Time Series* dengan pembentukan interval fuzzy berbasis *K-Means*.

2. Memperoleh hasil peramalan harga saham PT Bukalapak.com Tbk menggunakan metode *Markov Weighted Fuzzy Time Series* berbasis *K-Means* yang dioptimalkan dengan *Particle Swarm Optimization*.

Manfaat yang diharapkan dari penelitian ini adalah:

1. Menambah wawasan mengenai penerapan metode *Markov Weighted Fuzzy Time Series* berbasis *K-Means* yang dioptimasi menggunakan *Particle Swarm Optimization* dalam meningkatkan kinerja model deret waktu fuzzy.
2. Memberikan hasil evaluasi dan perbandingan metode peramalan yang dapat digunakan sebagai referensi untuk pengembangan algoritma optimasi pada data finansial yang fluktuatif.

1.3 Batasan Masalah

Batasan masalah pada penelitian ini adalah:

1. Data yang digunakan adalah data harga penutupan saham harian Bukalapak.com Tbk pada periode Oktober 2024 hingga Desember 2025.
2. Peramalan menggunakan metode *Markov Weighted Fuzzy Time Series* orde satu.
3. Parameter kontrol PSO meliputi nilai konstanta kognitif (c_1) dan sosial (c_2) sebesar 2, serta bobot inersia dinamis antara 0,9 hingga 0,4.
4. Evaluasi performa peramalan diukur menggunakan metrik *Mean Absolute Percentage Error*, *Mean Absolute Error*, dan *Root Mean Square Error*.

1.4 Teori

1.4.1 Peramalan

Peramalan merupakan suatu proses untuk memperkirakan nilai atau kondisi pada masa yang akan datang berdasarkan data historis dan pola yang terjadi pada periode sebelumnya (Dewi dan Listiowarni, 2020). Proses peramalan dilakukan dengan memanfaatkan berbagai metode matematika dan statistika untuk memproyeksikan pola pergerakan data masa lalu ke periode berikutnya (Ishak et al., 2020). Dalam bidang finansial, peramalan digunakan untuk mengurangi tingkat ketidakpastian terhadap pergerakan instrumen keuangan di masa depan sehingga pengambilan keputusan investasi dapat dilakukan lebih rasional dan terukur (Sulaiman, 2026).

Metode peramalan secara umum dibedakan menjadi dua kategori, yaitu peramalan kualitatif dan peramalan kuantitatif. Peramalan kualitatif didasarkan pada opini, intuisi, dan penilaian subjektif para ahli sehingga umumnya digunakan ketika data historis belum tersedia secara memadai. Sementara itu, peramalan kuantitatif menggunakan pendekatan matematis dan statistika terhadap data numerik historis untuk menghasilkan estimasi nilai di masa mendatang. Penerapan metode kuantitatif mensyaratkan tersedianya data historis yang cukup serta adanya asumsi bahwa pola pergerakan data pada masa lalu memiliki kecenderungan untuk berulang pada periode berikutnya (Prasetyo, 2024).

Peramalan dapat dibedakan berdasarkan horizon waktunya menjadi peramalan jangka pendek, jangka menengah, dan jangka panjang. Peramalan jangka pendek umumnya digunakan untuk meramalkan kondisi harian hingga

beberapa bulan ke depan. Peramalan jangka menengah digunakan untuk memperkirakan kondisi hingga sekitar dua tahun mendatang, sedangkan peramalan jangka panjang digunakan untuk proyeksi dalam periode yang lebih panjang sebagai dasar penyusunan perencanaan strategis (Ramandha et al., 2020).

1.4.2 Logika Fuzzy, Himpunan Fuzzy, dan Fungsi Keanggotaan

Logika fuzzy yang diperkenalkan oleh Lotfi A. Zadeh pada tahun 1965 merupakan suatu pendekatan matematis yang mengakomodasi adanya tingkat ketidakpastian atau kesamaran dalam penentuan nilai kebenaran (Susilo, 2006). Pada logika tegas, suatu pernyataan hanya memiliki dua kemungkinan nilai keanggotaan, yaitu 0 atau 1. Sebaliknya, logika fuzzy memungkinkan nilai keanggotaan berada pada rentang 0 hingga 1, sehingga konsep ini lebih mampu merepresentasikan kondisi nyata yang tidak sepenuhnya benar atau salah.

Himpunan fuzzy merupakan sekumpulan objek yang memiliki derajat keanggotaan bersifat kontinu dengan nilai pada rentang 0 hingga 1 (Zadeh, 1965). Secara matematis, himpunan fuzzy didefinisikan berdasarkan fungsi keanggotaan yang melekat pada setiap elemen di dalamnya. Jika U merupakan *universe of discourse* yang berisi sekumpulan objek yang dilambangkan sebagai u , maka himpunan fuzzy $\tilde{A}$ dapat dinyatakan pada Persamaan (1).

$$\tilde{A} = \{(u, \mu_{\tilde{A}}(u)) \mid u \in U\} \quad (1)$$

dengan $\mu_{\tilde{A}}(u)$ menyatakan derajat keanggotaan elemen u pada himpunan fuzzy $\tilde{A}$, sedangkan u merupakan elemen yang berada pada U . Nilai derajat keanggotaan berada pada rentang 0 hingga 1, dengan nilai yang semakin mendekati 1 menunjukkan tingkat keanggotaan yang semakin tinggi, sedangkan nilai yang semakin mendekati 0 menunjukkan tingkat keanggotaan yang semakin rendah.

Fungsi keanggotaan dapat direpresentasikan dalam berbagai bentuk kurva untuk menggambarkan hubungan antara nilai input dengan derajat keanggotaannya. Beberapa bentuk kurva yang umum digunakan antara lain kurva segitiga, trapesium, bahu, serta kurva sigmoid (Maharni, 2019). Selain menggunakan bentuk kurva kontinu, representasi fungsi keanggotaan juga dapat dilakukan melalui pendekatan partisi interval tegas (*crisp partition*).

1.4.3 Fuzzy Time Series

Fuzzy Time Series (FTS) merupakan suatu metode peramalan yang menggunakan prinsip-prinsip logika fuzzy sebagai dasar pendekatannya. Metode ini mengubah data numerik menjadi himpunan fuzzy sehingga lebih mampu menangani ketidakpastian dan fluktuasi pada data historis (Virgianti et al., 2021). Secara umum, terdapat beberapa tahapan dalam pembentukan model FTS, yaitu menentukan *universe of discourse*, pembentukan interval/kelas, melakukan proses fuzzifikasi, membentuk relasi fuzzy, melakukan defuzzifikasi, serta menentukan nilai hasil peramalan (Alyousifi et al., 2020).

1.4.3.1 Penentuan *Universe of Discourse*

Universe of Discourse (U) merupakan himpunan nilai yang mencakup seluruh rentang data yang digunakan dalam proses peramalan FTS. Penentuan *universe of discourse* dilakukan berdasarkan nilai minimum ($D_{\min}$) dan nilai maksimum ($D_{\max}$) dari data historis yang diamati. Rentang tersebut menjadi dasar dalam pembentukan interval fuzzy yang akan digunakan pada tahap fuzzifikasi. Secara matematis, *universe of discourse* dinyatakan pada Persamaan (2).

$$U = [D_{\min} - d_1 ; D_{\max} + d_2] \quad (2)$$

dengan d_1 dan d_2 merupakan bilangan positif yang digunakan untuk menyesuaikan batas bawah dan batas atas *universe of discourse* (U) (Putri et al., 2025). Penambahan kedua nilai tersebut bertujuan untuk memperluas rentang *universe of discourse* agar seluruh data historis dapat terakomodasi dengan baik, termasuk kemungkinan munculnya nilai ekstrem pada data. Penentuan *universe of discourse* mempengaruhi proses pembentukan interval fuzzy dan representasi pola data dalam model FTS. *Universe of discourse* yang terlalu sempit dapat menyebabkan beberapa data berada di luar interval yang dibentuk, sedangkan rentang yang terlalu luas dapat menghasilkan interval yang kurang representatif terhadap distribusi data historis (Rubio-Leon et al., 2023).

1.4.3.2 Pembentukan Interval

Universe of Discourse (U) dipartisi ke dalam sejumlah kelas interval yang digunakan sebagai dasar pembentukan himpunan fuzzy pada tahap fuzzifikasi. Proses partisi interval merupakan tahapan penting dalam metode FTS karena berpengaruh terhadap representasi pola data dan hasil peramalan yang dihasilkan. Pembentukan interval yang kurang sesuai dengan karakteristik data dapat menyebabkan representasi himpunan fuzzy menjadi kurang optimal.

Metode FTS konvensional umumnya menggunakan pendekatan *equal-length* interval dalam proses pembentukan interval. Pendekatan ini dilakukan dengan membagi rentang *universe of discourse* ke dalam beberapa interval dengan panjang yang sama (Jilani et al., 2008). Pembentukan interval pada metode FTS juga dapat dilakukan menggunakan pendekatan *clustering*, yaitu dengan mengelompokkan data berdasarkan tingkat kemiripan karakteristiknya. Pendekatan *clustering* memungkinkan interval terbentuk secara lebih adaptif terhadap pola distribusi data historis sehingga representasi data pada proses fuzzifikasi menjadi lebih sesuai. Beberapa algoritma *clustering* yang umum digunakan dalam pengembangan metode FTS antara lain *Fuzzy C-Means* (Chen et al., 2025), *Fuzzy K-Medoids* (Dewi et al., 2023), dan *K-Means Clustering* (Siregar dan Surono, 2022).

1.4.3.3 Fuzzifikasi

Fuzzifikasi merupakan proses transformasi data numerik tegas ke dalam bentuk variabel linguistik atau himpunan fuzzy (Song dan Chissom, 1993). Pada metode FTS, proses ini dilakukan dengan memetakan data historis ke dalam interval yang telah dibentuk pada *universe of discourse*. Setiap interval yang terbentuk selanjutnya

diasosiasikan dengan suatu himpunan fuzzy yang merepresentasikan kondisi linguistik tertentu. Proses fuzzifikasi bertujuan untuk menyederhanakan representasi data numerik sehingga pola perubahan data lebih mudah dianalisis dalam bentuk linguistik.

Universe of discourse yang dipartisi menjadi k interval, direpresentasikan sebagai $u_1, u_2, \dots, u_k$, didefinisikan sebagai sekumpulan himpunan fuzzy $A_1, A_2, \dots, A_k$ yang berkorespondensi dengan masing-masing interval tersebut (Chen, 1996). Setiap himpunan fuzzy A_i merepresentasikan *state* linguistik ke- i dari data deret waktu. Aturan fuzzifikasi dinyatakan pada Persamaan (3).

$$Y_{(t)} \rightarrow A_i, \text{ jika } LB_i \leq Y_{(t)} \leq UB_i \quad (3)$$

Suatu data historis pada periode ke- t , yang dinotasikan sebagai $Y_{(t)}$, dipetakan ke dalam *state* linguistik A_i apabila nilainya berada pada interval u_i , yaitu di antara batas bawah (LB_i) dan batas atas (UB_i), dengan $i = 1, 2, \dots, k$ (Singh, 2007). Karena menggunakan pendekatan *crisp partition*, setiap data observasi hanya dapat dipetakan ke dalam satu *state* linguistik pada setiap periode waktu. Dengan demikian, tidak terjadi keanggotaan ganda (*overlapping membership*) antarhimpunan fuzzy (Chen, 1996).

1.4.3.4 Fuzzy Logical Relationship dan Fuzzy Logical Relationship Group

Urutan *state* linguistik yang dihasilkan dari proses fuzzifikasi digunakan sebagai dasar dalam pembentukan *Fuzzy Logical Relationship* (FLR) untuk mengidentifikasi pola transisi data deret waktu (Bose dan Mali, 2019). FLR merepresentasikan hubungan perubahan *state* fuzzy dari satu periode ke periode berikutnya berdasarkan urutan data historis. Melalui pembentukan FLR, pola perpindahan antar *state* dapat dianalisis sehingga hubungan dinamis dalam data deret waktu dapat direpresentasikan dalam bentuk logika fuzzy. Menurut Song dan Chissom (1993), apabila suatu observasi pada waktu ke- t , yang dinyatakan sebagai $Y_{(t)}$, dipengaruhi oleh observasi pada periode sebelumnya $Y_{(t-1)}$, maka hubungan tersebut dapat dinyatakan sebagai relasi berikut.

$$Y_{(t-1)} \rightarrow Y_{(t)}$$

Data pada waktu ke- $t - 1$ yang dipetakan ke dalam *state* A_i dan data pada waktu ke- t yang dipetakan ke dalam *state* A_j akan membentuk suatu FLR sebagai berikut.

$$A_i \rightarrow A_j$$

Relasi tersebut menunjukkan bahwa A_i berperan sebagai *Left-Hand Side* (LHS) yang merepresentasikan keadaan saat ini (*current state*), sedangkan A_j berperan sebagai *Right-Hand Side* (RHS) yang merepresentasikan keadaan berikutnya (*next state*) (Lee et al., 2007). Pembentukan FLR dilakukan berdasarkan urutan *state* hasil fuzzifikasi sehingga pola perubahan data antarperiode dapat direpresentasikan dalam bentuk hubungan logika fuzzy.

Karakteristik data deret waktu yang dinamis menyebabkan satu *state* pada LHS dapat memiliki lebih dari satu kemungkinan transisi menuju *state* yang berbeda pada RHS. Untuk mengakomodasi variasi hubungan tersebut, seluruh FLR yang memiliki nilai LHS yang sama dikelompokkan ke dalam *Fuzzy Logical Relationship Group* (FLRG). Misalnya, apabila diperoleh beberapa relasi sebagai berikut.

$$A_i \rightarrow A_{j_1}, A_i \rightarrow A_{j_2}, \dots, A_i \rightarrow A_{j_k}$$

maka relasi tersebut digabungkan ke dalam satu kelompok FLRG yang dinyatakan sebagai berikut.

$$A_i \rightarrow A_{j_1}, A_{j_2}, \dots, A_{j_k}$$

Pembentukan FLRG memberikan representasi yang lebih ringkas terhadap pola transisi antar *state* fuzzy karena seluruh hubungan dengan LHS yang sama disajikan dalam satu kelompok relasi. Pengelompokan ini memudahkan proses identifikasi pola perubahan data historis yang memiliki kecenderungan transisi serupa. Selain itu, FLRG juga menjadi dasar dalam pembentukan aturan peramalan pada metode FTS (Chen, 1996).

1.4.3.5 Defuzzifikasi

Defuzzifikasi merupakan proses mengubah hasil peramalan yang masih berbentuk variabel linguistik atau himpunan fuzzy menjadi nilai numerik tegas (Pajriati, 2021). Tahapan ini dilakukan untuk memperoleh hasil akhir peramalan dalam bentuk numerik sehingga dapat diinterpretasikan secara kuantitatif. Proses defuzzifikasi dilakukan berdasarkan *next state* yang terdapat pada FLRG (Chen, 1996; Huarng, 2001).

Proses defuzzifikasi memanfaatkan nilai tengah (*midpoint*) dari setiap interval yang berkorespondensi dengan *state* linguistik pada sisi RHS relasi fuzzy. Nilai tengah interval dinotasikan sebagai m_i dan diperoleh dari rata-rata batas bawah (*lower bound*) serta batas atas (*upper bound*) interval yang bersangkutan. Nilai *midpoint* digunakan sebagai representasi numerik dari masing-masing *state* linguistik pada proses peramalan. Perhitungan nilai tengah interval dinyatakan pada Persamaan (4).

$$m_i = \frac{LB_i + UB_i}{2} \quad (4)$$

dengan

m_i : *Midpoint* dari interval ke- i

LB_i : *Lower Bound* dari interval ke- i

UB_i : *Upper Bound* dari interval ke- i

Aturan defuzzifikasi pada metode FTS klasik dibedakan menjadi beberapa kondisi berdasarkan bentuk relasi pada FLRG (Chen, 1996; Huarng, 2001).

1. Kondisi ketika suatu *current state* A_i hanya memiliki satu transisi relasi logika menuju *state* A_j (dinyatakan sebagai himpunan FLRG $A_i \rightarrow A_j$), maka nilai hasil

peramalan $F_{(t)}$ adalah nilai tengah dari interval u_j . Rumus matematisnya dituliskan pada Persamaan (5).

$$F_{(t)} = m_j \quad (5)$$

2. Kondisi ketika suatu *current state* A_i memiliki lebih dari satu tujuan transisi (ditulis $A_i \rightarrow A_{j_1}, A_{j_2}, \dots, A_{j_k}$), maka nilai hasil peramalan $F_{(t)}$ dihitung dari rata-rata semua nilai tengah interval milik *state* tujuan tersebut. Rumus matematisnya dituliskan pada Persamaan (6).

$$F_{(t)} = \frac{m_{j_1} + m_{j_2} + \dots + m_{j_k}}{p} \quad (6)$$

dengan $m_{j_1} + m_{j_2} + \dots + m_{j_k}$ merupakan nilai tengah dari masing-masing interval tujuan, dan p adalah jumlah total *state* tujuan yang ada di dalam FLRG tersebut.

3. Kondisi ketika *current state* A_i tidak memiliki transisi ke *state* mana pun, maka nilai hasil peramalan peramalan $F_{(t)}$ adalah nilai tengah dari interval u_i milik *state* awal A_i itu sendiri. Rumus matematisnya dituliskan pada Persamaan (7).

$$F_{(t)} = m_i \quad (7)$$

Penerapan aturan defuzzifikasi pada FTS memungkinkan setiap relasi *fuzzy* dalam FLRG dikonversi menjadi nilai numerik melalui pemanfaatan nilai tengah interval. Mekanisme ini menjaga konsistensi transformasi dari representasi linguistik menjadi bentuk kuantitatif pada setiap kondisi transisi yang terbentuk. Hasil yang diperoleh selanjutnya dapat digunakan sebagai dasar dalam analisis data deret waktu secara lebih terukur (Tsaur, 2012).

1.4.4 K-Means Clustering

K-Means merupakan salah satu metode yang digunakan untuk mengelompokkan data dengan cara mempartisi sekumpulan data ke dalam beberapa kluster (*clustering*) berdasarkan tingkat kemiripannya (Sudono et al., 2013). Algoritma ini memiliki beberapa keunggulan, antara lain kemudahan implementasi, struktur yang sederhana, skalabilitas yang baik, serta kecepatan konvergensi dalam proses pengelompokan (Oyelade et al., 2010). Setiap kluster direpresentasikan oleh sebuah titik pusat yang disebut *centroid*, yang menggambarkan nilai rata-rata dari seluruh data dalam kluster tersebut. Penentuan jumlah kluster k menjadi parameter penting karena berpengaruh langsung terhadap struktur pembagian data dalam ruang observasi (Jain, 2010).

1.4.4.1 Algoritma Perhitungan K-Means

Prinsip kerja *K-Means* didasarkan pada pengukuran jarak antara data observasi dan *centroid* untuk menentukan keanggotaan kluster. Pengukuran kedekatan ini digunakan untuk menentukan kluster yang paling sesuai bagi setiap data berdasarkan nilai jarak terkecil. Jarak tersebut dapat dinyatakan sebagai nilai mutlak selisih antara data dan pusat kluster yang ekuivalen dengan jarak *Euclidean* yang dinyatakan pada Persamaan (8) (Pribadi et al., 2022).

$$d(x, C) = \sqrt{\sum_{i=1}^n (x_i - C_{ji})^2} \quad (8)$$

dengan

$d(x, C)$: Jarak antara data dan *centroid*

x_i : Nilai data pada dimensi ke- i

C_{ji} : Nilai centroid pada dimensi ke- i

n : Jumlah dimensi data

Apabila data hanya memiliki satu dimensi, Persamaan (8) dapat disederhanakan menjadi Persamaan (9).

$$d(x, C) = |x - C| \quad (9)$$

dengan x menyatakan nilai data observasi dan C menyatakan centroid kluster.

Setiap data akan dikelompokkan ke dalam kluster dengan jarak paling kecil terhadap *centroid*. Kondisi ini menyebabkan data dalam satu kluster memiliki tingkat kemiripan yang lebih tinggi dibandingkan dengan kluster lainnya. Setelah proses pengelompokan, *centroid* diperbarui berdasarkan rata-rata seluruh anggota kluster, yang dinyatakan pada Persamaan (10) (Yuan dan Yang, 2019).

$$C_j = \frac{1}{n_j} \sum_{x_i \in S_j} x_i \quad (10)$$

dengan

n_j : Jumlah data pada kluster ke- j

S_j : Himpunan (kelompok) kluster ke- j

Proses pengelompokan pada algoritma *K-Means* berlangsung secara iteratif hingga tidak terjadi lagi perpindahan data observasi antar-kluster. Keadaan tersebut menunjukkan bahwa setiap data telah berada pada kluster yang paling dekat dengan centroid. Kondisi ini menandakan bahwa struktur kluster yang terbentuk telah mencapai keadaan stabil atau konvergen (Ahmed dkk., 2020).

1.4.4.2 Metode Elbow

Metode Elbow merupakan salah satu pendekatan yang digunakan untuk menentukan jumlah kluster (k) yang optimal pada algoritma K-Means. Prinsip dasar metode ini adalah mengevaluasi perubahan nilai variasi di dalam kluster (*within-cluster variation*) untuk setiap kandidat jumlah kluster. Seiring bertambahnya jumlah kluster, variasi dalam setiap kluster akan semakin kecil sehingga kualitas pengelompokan cenderung meningkat. Namun, setelah mencapai jumlah kluster tertentu, penurunan variasi menjadi semakin kecil sehingga penambahan kluster tidak lagi memberikan peningkatan yang signifikan. Titik perubahan laju penurunan tersebut dikenal sebagai *elbow point* dan dipilih sebagai jumlah kluster yang optimal (Maori dan Evanita, 2023).

Kualitas pengelompokan pada metode Elbow umumnya diukur menggunakan *Within Cluster Sum of Squares* (WCSS) atau sering pula disebut *Sum of Squared Errors* (SSE). WCSS menyatakan jumlah kuadrat jarak antara setiap data dengan

centroid kluster tempat data tersebut berada. Nilai WCSS yang semakin kecil menunjukkan bahwa anggota dalam setiap kluster semakin homogen atau semakin dekat dengan centroid masing-masing. Secara matematis, WCSS dinyatakan pada Persamaan (11) (Jollyta et al., 2019).

$$WCSS = \sum_{j=1}^k \sum_{x_i \in S_j} \|x_i - C_j\|^2 \quad (11)$$

dengan

WCSS : *Within Cluster Sum of Squares*

k : Jumlah kluster

S_j : Himpunan data pada kluster ke- j

x_i : Data ke- i

C_j : Centroid kluster ke- j

Semakin besar nilai k , nilai WCSS umumnya akan terus menurun karena setiap kluster mencakup data yang lebih sedikit sehingga jarak data terhadap centroid menjadi lebih kecil. Metode Elbow dilakukan dengan menghitung nilai WCSS untuk beberapa alternatif jumlah kluster, kemudian memvisualisasikannya dalam bentuk grafik yang menghubungkan nilai k pada sumbu horizontal dengan nilai WCSS pada sumbu vertikal. Grafik tersebut umumnya menunjukkan pola penurunan yang tajam pada nilai k kecil, kemudian berubah menjadi lebih landai setelah mencapai jumlah kluster tertentu. Titik perubahan kemiringan kurva yang menyerupai siku (*elbow*) dipilih sebagai jumlah kluster optimum karena setelah titik tersebut penambahan kluster hanya memberikan penurunan WCSS yang relatif kecil (Anggreani et al., 2024).

1.4.4.3 Penerapan *K-Means* pada *Fuzzy Time Series*

Pemanfaatan algoritma *K-Means* dalam metode FTS bertujuan untuk menghasilkan partisi interval yang lebih adaptif terhadap distribusi data. Interval yang terbentuk melalui proses *clustering* memungkinkan batas-batas interval menyesuaikan kepadatan dan pola penyebaran data, sehingga representasi linguistik yang dihasilkan pada tahap fuzzifikasi menjadi lebih representatif. Pendekatan ini berbeda dengan metode *equal-length interval* yang menetapkan panjang interval secara tetap tanpa mempertimbangkan karakteristik distribusi data (Alwarid dan Sihabuddin, 2021).

Centroid yang diperoleh dari algoritma *K-Means* digunakan sebagai dasar dalam membentuk interval pada *universe of discourse*. Nilai *centroid* terlebih dahulu diurutkan secara menaik sehingga diperoleh urutan $C_1, C_2, \dots, C_k$ yang digunakan untuk menentukan batas antarinterval berdasarkan nilai tengah dari dua *centroid* yang berdekatan. Batas interval di antara dua kluster berturut-turut dihitung menggunakan nilai tengah dari kedua *centroid* tersebut. Nilai tengah ini berfungsi sebagai batas atas bagi interval sebelumnya sekaligus batas bawah bagi interval berikutnya. Secara matematis, aturan tersebut dinyatakan melalui Persamaan (12) dan (13) (Zhang dan Zhu, 2012).

$$UB_j = \frac{C_j + C_{j+1}}{2} \quad (12)$$

$$LB_{j+1} = UB_j \quad (13)$$

dengan

UB_j : Batas atas interval ke- m

LB_j : Batas bawah interval ke- m

C_j : *Centroid* ke- j

C_{j+1} : *Centroid* ke- $j + 1$

Rentang interval pertama dan interval terakhir tidak dapat ditentukan menggunakan pendekatan nilai tengah karena tidak terdapat *centroid* sebelum klaster pertama maupun setelah klaster terakhir. Oleh karena itu, penentuan batas ekstrem interval ditentukan dengan mengacu pada rentang batas *universe of discourse* yang telah didefinisikan pada tahap awal (Chen dan Chen, 2015). Secara matematis, batas bawah untuk interval pertama (LB_1) ditetapkan sama dengan batas minimum dari *universe of discourse*, sedangkan batas atas untuk interval terakhir (UB_k) ditetapkan sama dengan batas maksimum dari *universe of discourse*. Aturan pemenuhan batas ekstrem ini dirumuskan pada Persamaan (14) dan Persamaan (15).

$$LB_1 = D_{\min} \quad (14)$$

$$UB_k = D_{\max} \quad (15)$$

Penetapan batas ekstrem tersebut memastikan bahwa seluruh rentang data berada dalam cakupan interval yang telah dibentuk. Batas bawah pada interval pertama dan batas atas pada interval terakhir berfungsi sebagai penutup agar tidak terdapat nilai observasi yang berada di luar *universe of discourse*. Dengan demikian, struktur interval yang dihasilkan menjadi lengkap, teratur, dan mampu merepresentasikan keseluruhan distribusi data secara konsisten (Surono et al., 2022).

1.4.5 *Weighted Fuzzy Time Series*

Pendekatan *Weighted Fuzzy Time Series* (WFTS) dikembangkan untuk menyempurnakan metode FTS klasik yang memperlakukan seluruh relasi logika fuzzy secara setara. Pada metode FTS klasik, setiap relasi dianggap memiliki kontribusi yang sama dalam proses peramalan meskipun frekuensi kemunculannya pada data historis berbeda. Oleh karena itu, WFTS menerapkan konsep pembobotan pada setiap relasi dalam FLRG. Bobot tersebut merepresentasikan tingkat dominasi suatu relasi berdasarkan frekuensi kemunculannya pada data historis. Relasi yang lebih sering muncul akan memperoleh bobot lebih besar sehingga memiliki pengaruh yang lebih kuat dalam proses peramalan. Dengan demikian, model dapat merepresentasikan pola transisi data secara lebih proporsional (Yu, 2005).

Penentuan nilai pada WFTS didasarkan pada frekuensi kemunculan relasi logika fuzzy pada data historis. Misalkan suatu *state* linguistik awal A_i memiliki beberapa relasi transisi menuju *state* tujuan yang berbeda, misalnya $A_i \rightarrow$

$A_{j_1}, A_{j_2}, \dots, A_{j_p}$. Frekuensi kemunculan masing-masing relasi tersebut dinotasikan dengan $n_1, n_2, \dots, n_p$. Total frekuensi seluruh relasi yang berasal dari *state* A_i dinyatakan pada Persamaan (16).

$$N = \sum_{m=1}^p n_m \quad (16)$$

dengan

- N : Total frekuensi relasi yang berasal dari *state* A_i
- n_m : Frekuensi kemunculan relasi ke- m
- p : Jumlah variasi *state* tujuan yang terhubung dari *state* awal

Nilai total frekuensi (N) pada Persamaan (16) digunakan sebagai penyebut dalam perhitungan proporsi bobot setiap relasi. Seluruh frekuensi transisi dalam satu kelompok relasi telah terakomodasi sebelum dilakukan proses pembobotan. Selanjutnya, nilai bobot relasi ke- m (w_m) diperoleh dengan membagi frekuensi kemunculan relasi tunggal tersebut (n_m) dengan total keseluruhan relasi dari *state* asal A_i (Yu, 2005). Persamaan matematisnya dinyatakan pada Persamaan (17).

$$w_m = \frac{n_m}{N} \quad (17)$$

dengan

- w_m : Bobot relasi ke- m
- n_m : Frekuensi kemunculan relasi ke- m
- N : Total frekuensi relasi yang berasal dari *state* A_i

Perhitungan bobot pada Persamaan (17) menunjukkan tingkat pengaruh setiap kemungkinan arah pergerakan harga saham. Relasi transisi yang memiliki frekuensi kemunculan lebih tinggi akan menghasilkan nilai bobot (w_m) yang lebih besar, sehingga memberikan pengaruh yang lebih dominan dalam proses peramalan. Dengan demikian, model dapat lebih menekankan pola pergerakan yang sering muncul pada data historis. Nilai bobot yang diperoleh juga harus memenuhi sifat proporsi, yaitu jumlah seluruh bobot dalam satu kelompok relasi harus bernilai satu. Ketentuan tersebut dinyatakan pada Persamaan (18).

$$\sum_{m=1}^p w_m = \frac{n_1}{N} + \frac{n_2}{N} + \dots + \frac{n_p}{N} = 1 \quad (18)$$

Persamaan (18) menunjukkan bahwa jumlah seluruh bobot pada satu kelompok relasi fuzzy harus bernilai sama dengan satu. Pemenuhan ketentuan tersebut diperlukan untuk menjaga konsistensi proses pembobotan pada metode WFTS. Dengan demikian, setiap relasi fuzzy dapat memberikan kontribusi yang proporsional dalam proses peramalan (Siregar dan Surono, 2022).

1.4.6 Rantai Markov

Rantai Markov merupakan suatu proses stokastik diskrit yang digunakan untuk memodelkan perpindahan suatu sistem dari satu *state* ke *state* lainnya berdasarkan

probabilitas transisi (Hariyanto et al., 2023). Secara matematis, rantai Markov direpresentasikan oleh suatu proses stokastik diskrit $\{X_n, n = 0, 1, 2, \dots\}$ yang nilai probabilitasnya dapat dihitung. Jika $X_n = i$, maka proses tersebut diasumsikan sedang berada pada *state* i saat waktu ke- n . Peluang bahwa sistem akan berpindah dari *state* i menuju *state* j pada langkah waktu berikutnya dinotasikan dengan probabilitas transisi P_{ij} . Proses ini memiliki sifat tanpa memori (*memoryless property*), yaitu probabilitas suatu keadaan pada masa depan X_{n+1} hanya dipengaruhi oleh *state* saat ini X_n dan tidak bergantung pada urutan *state* sebelumnya $(X_0, X_1, \dots, X_{n-1})$. Secara matematis, proses ini dirumuskan melalui Persamaan (19).

$$P(X_{n+1} = j | X_n = i, X_{n-1}, \dots, X_0) = P(X_{n+1} = j | X_n = i) = P_{ij} \quad (19)$$

Probabilitas transisi selalu bernilai tidak negatif dan jumlah probabilitas dari satu *state* menuju seluruh kemungkinan *state* tujuan bernilai satu. Ketentuan tersebut dinyatakan dengan $P_{ij} \geq 0$ dan $\sum_j P_{ij} = 1$. Seluruh probabilitas transisi kemudian disusun ke dalam suatu matriks probabilitas transisi P yang dinyatakan oleh Persamaan (20).

$$P = \begin{bmatrix} P_{11} & P_{12} & \dots & P_{1k} \\ P_{21} & P_{22} & \dots & P_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ P_{k1} & P_{k2} & \dots & P_{kk} \end{bmatrix} \quad (20)$$

Matriks probabilitas transisi pada Persamaan (20) merepresentasikan seluruh kemungkinan perpindahan antar *state* dalam suatu sistem secara terstruktur. Baris pada matriks mencerminkan *state* asal, sedangkan kolom menunjukkan *state* tujuan, sehingga jumlah setiap baris selalu bernilai satu sebagai bentuk distribusi probabilitas yang lengkap. Dengan demikian, matriks ini menjadi dasar utama dalam menganalisis pola pergerakan data serta digunakan pada tahap peramalan (Tsaur, 2012).

1.4.7 Markov Weighted Fuzzy Time Series

Metode *Markov Weighted Fuzzy Time Series* (MWFTS) merupakan pengembangan komprehensif dari pendekatan WFTS yang mengintegrasikan konsep matriks probabilitas transisi rantai Markov sebagai dasar pembobotan pada tahap defuzzifikasi. Integrasi ini dirancang untuk merepresentasikan kecenderungan perpindahan antar *state* linguistik secara lebih proporsional berdasarkan rekam jejak pola historis data. Dalam pendekatan ini, proses pemodelan tidak hanya mempertimbangkan keberadaan relasi antar *state*, tetapi juga memperhitungkan intensitas kemunculan relasi tersebut melalui probabilitas transisi. Matriks probabilitas transisi yang dihasilkan memetakan seluruh kemungkinan perpindahan antar *state* secara terstruktur, sehingga keluaran model menjadi lebih informatif dan adaptif dalam merespons fluktuasi data deret waktu (Alyousifi et al., 2020).

Proses peramalan pada MWFTS didasarkan pada FLRG yang telah dibentuk sebelumnya. Berdasarkan karakteristik relasi yang dimiliki setiap *state*, proses

peramalan dibedakan menjadi dua kondisi, yaitu transisi satu-ke-satu (*one-to-one case*) dan transisi satu-ke-banyak (*one-to-many case*).

1. Kasus 1: Transisi Satu-ke-Satu (*One-to-One Case*)

Kondisi ini terjadi apabila suatu *state* linguistik A_i hanya memiliki satu relasi transisi menuju *state* tujuan A_j . Karena hanya terdapat satu kemungkinan perpindahan, probabilitas transisi dari *state* A_i menuju *state* A_j bernilai satu ($P_{ij} = 1$). Oleh karena itu, nilai peramalan ditentukan sama dengan nilai *midpoint* dari interval fuzzy pada *state* tujuan. Secara matematis, nilai peramalan dirumuskan pada Persamaan (21).

$$F_{(t+1)} = m_j \times P_{ij} = m_j \quad (21)$$

dengan

- $F_{(t+1)}$: Nilai peramalan pada periode ke- ($t + 1$)
- m_j : *Midpoint* interval fuzzy pada *state* tujuan A_j
- P_{ij} : Probabilitas transisi dari *state* A_i menuju *state* A_j

2. Kasus 2: Transisi Satu-ke-Banyak (*One-to-Many Case*)

Kondisi ini terjadi apabila suatu *state* linguistik A_i memiliki lebih dari satu kemungkinan transisi menuju beberapa *state* tujuan. Pada kondisi ini, nilai peramalan dihitung menggunakan rata-rata berbobot berdasarkan probabilitas transisi Markov. Berbeda dengan pendekatan WFTS konvensional, *midpoint* pada *state* saat ini (m_i) digantikan oleh nilai aktual observasi $Y_{(t)}$. Penggantian tersebut bertujuan agar proses peramalan dapat mempertahankan informasi aktual dari data pada periode berjalan sehingga hasil peramalan lebih representatif terhadap kondisi yang sedang diamati. Secara matematis, nilai peramalan dirumuskan pada Persamaan (22).

$$F_{(t+1)} = m_1 P_{i1} + m_2 P_{i2} + \dots + Y_{(t)} P_{ii} + \dots + m_k P_{ik} \quad (22)$$

- $F_{(t+1)}$: Nilai peramalan pada periode ke- ($t + 1$)
- m_k : *Midpoint* interval fuzzy pada *state* tujuan A_j
- P_{ij} : Probabilitas transisi dari *state* A_i menuju *state* A_j
- $Y_{(t)}$: Nilai aktual pada periode ke- t
- k : Jumlah *state* linguistik

Nilai aktual $Y_{(t)}$ menggantikan *midpoint* pada *state* saat ini (m_i), sedangkan *midpoint* pada *state* lainnya tetap digunakan dalam proses pembobotan. Dengan demikian, nilai peramalan merupakan kombinasi antara probabilitas transisi Markov dan representasi numerik setiap *state* linguistik, sehingga mampu menggambarkan kecenderungan perpindahan antar *state* sekaligus mempertahankan informasi aktual dari data pada periode berjalan. Pada kondisi *one-to-one*, nilai peramalan ditentukan secara langsung oleh *midpoint state* tujuan karena hanya terdapat satu kemungkinan transisi. Sementara itu, pada kondisi *one-to-many*, nilai peramalan diperoleh melalui rata-rata berbobot seluruh kemungkinan transisi dengan menggantikan *midpoint*

state saat ini menggunakan nilai aktual observasi. Pendekatan tersebut memungkinkan model mempertahankan informasi pola historis sekaligus mengakomodasi kondisi aktual data sehingga menghasilkan nilai peramalan yang lebih representatif (Siregar & Surono, 2022).

1.4.8 Particle Swarm Optimization

Algoritma *Particle Swarm Optimization* (PSO) merupakan teknik optimasi berbasis kawanan yang diperkenalkan oleh Eberhart dan Kennedy (1995). PSO termasuk dalam metode metaheuristik yang terinspirasi dari perilaku sosial kelompok hewan seperti kawanan burung dan kelompok ikan dalam mencari sumber makanan serta menyelesaikan permasalahan optimasi non-linier (Wang et al., 2017). Dalam ruang pencarian (*search space*), PSO digunakan untuk menemukan solusi optimal secara global melalui interaksi antar partikel. PSO terdiri dari beberapa komponen utama sebagai berikut (Cholissodin dan Riyandani, 2016).

1. Kawanan

Kawanan (*swarm*) merupakan kelompok atau populasi keseluruhan di dalam ruang pencarian. Setiap individu di dalam kelompok ini memiliki pengaruh terhadap pergerakan kawannya. Jika satu partikel menemukan rute terbaik, partikel lain akan mengikuti jejak tersebut meskipun jarak mereka berjauhan.

2. Partikel

Partikel didefinisikan sebagai suatu individu unit di dalam swarm yang merepresentasikan satu kandidat solusi potensial. Partikel bergerak secara dinamis melintasi ruang pencarian. Representasi posisi partikel dinotasikan sebagai X_{id}^t .

3. Kecepatan

Kecepatan merupakan vektor yang menentukan besaran dan arah perpindahan lokasi partikel. Perubahan kecepatan dilakukan pada setiap iterasi untuk memperbaiki posisi partikel semula. Kecepatan partikel dinotasikan sebagai V_{id}^t .

4. Personal Best

Personal best (P_{best}) merupakan hasil dari pembelajaran kognitif, yaitu posisi terbaik yang pernah ditemukan dan dicapai oleh suatu partikel berdasarkan pengalaman individunya sendiri. Posisi P_{best} dievaluasi dengan membandingkan nilai fungsi objektif (*fitness*) pada posisinya saat ini dengan posisi pada iterasi-iterasi sebelumnya. Fungsi *fitness* $f(X)$ yang diminimalkan adalah tingkat galat peramalan. Secara matematis, posisi P_{best} dirumuskan pada Persamaan (23).

$$P_{best_{id}}^t = \arg \min \{ f(X_{id}^1), f(X_{id}^2), \dots, f(X_{id}^t) \} \quad (23)$$

Keterangan:

$P_{best_{id}}^t$: Posisi terbaik individu partikel ke-id hingga iterasi ke-t

$\arg \min$: Argumen posisi yang menghasilkan nilai galat paling minimum

$f(X_{id}^t)$: Nilai *fitness* dari partikel ke-id hingga iterasi ke-t

5. Global Best

Global best (G_{best}) merupakan hasil dari pembelajaran sosial yaitu posisi terbaik secara global yang berhasil dicapai oleh partikel manapun di dalam seluruh swarm. Posisi ini ditentukan dengan membandingkan memori nilai P_{best} dari masing-masing individu untuk mencari titik tunggal yang menghasilkan galat paling minimum di seluruh populasi. Secara matematis, G_{best} pada iterasi ke- t diformulasikan oleh Persamaan (24).

$$G_{best}^t = \arg \min \{ f(P_{best_1}^t), f(P_{best_2}^t), \dots, f(P_{best_N}^t) \} \quad (24)$$

Keterangan:

G_{best}^t : Posisi terbaik global dari seluruh *swarm* pada iterasi ke- t .

$f(P_{best_{id}}^t)$: Nilai *fitness* dari posisi P_{best} milik partikel ke- id

N : Jumlah total partikel di dalam *swarm*

6. Bobot Inersia

Bobot Inersia (ω^t) digunakan untuk mengontrol dampak dari kecepatan partikel pada lintasan iterasi sebelumnya terhadap kecepatan saat ini. Bobot inersia dihitung secara dinamis pada setiap iterasi agar keseimbangan antara eksplorasi global dan eksploitasi lokal tetap terjaga. Persamaan pembaruan bobot inersia dirumuskan pada Persamaan (25).

$$\omega^t = \omega_{max} - \frac{t \times (\omega_{max} - \omega_{min})}{iter_{max}} \quad (25)$$

Keterangan:

ω^t : Nilai bobot inersia dinamis pada iterasi ke- t

ω_{max} : Batas nilai bobot inersia maksimal

ω_{min} : Batas nilai bobot inersia minimal

$iter_{max}$: Jumlah iterasi maksimal yang diizinkan

t : Indeks iterasi saat ini

7. Koefisien Akselerasi

Koefisien Akselerasi merupakan faktor konstanta yang mengontrol sejauh mana lintasan partikel ditarik menuju posisi memori individu (c_1) dan memori global kelompok (c_2).

Proses pencarian solusi optimal pada algoritma PSO dilakukan melalui pergerakan partikel di dalam ruang pencarian. Pergerakan tersebut berlangsung secara iteratif dengan memperbarui kecepatan dan posisi partikel pada setiap iterasi. Pembaruan kecepatan mempertimbangkan pengaruh posisi sebelumnya, pengalaman individu, dan pengalaman global, yang dirumuskan pada Persamaan (26).

$$V_{id}^{t+1} = \omega^t \times V_{id}^t + c_1 \times \text{Rand}() \times (P_{best_{id}}^t - X_{id}^t) + c_2 \times \text{Rand}() \times (G_{best}^t - X_{id}^t) \quad (26)$$

Keterangan:

V_{id}^{t+1}	: Kecepatan partikel ke-id pada iterasi ke- (t + 1)
V_{id}^t	: kecepatan awal partikel ke-id hingga iterasi ke-t
X_{id}^t	: Posisi awal partikel ke-id hingga iterasi ke-t
c_1, c_2	: Koefisien akselerasi kognitif dan sosial
$Rand()$	: Fungsi bilangan acak yang dibangkitkan pada rentang [0,1]
$P_{best_{id}}$	: Posisi optimal individu dari partikel ke-id
G_{best}	: Posisi optimal global dari seluruh <i>swarm</i>

Posisi partikel kemudian diperbarui berdasarkan kecepatan yang diperoleh melalui Persamaan (27).

$$X_{id}^{t+1} = X_{id}^t + V_{id}^{t+1} \quad (27)$$

dengan X_{id}^{t+1} merupakan posisi partikel ke-*id* yang baru pada iterasi ke- (t + 1).

Algoritma PSO digunakan untuk mengevaluasi dan memperbaiki panjang interval yang diperoleh dari partisi *K-Means*. Posisi awal partikel (X_{id}^0) diinisialisasi dari batas interval tersebut diperbarui secara iteratif untuk menghasilkan kombinasi batas bawah dan batas atas yang lebih optimal. Setiap pembaruan posisi partikel menghasilkan partisi interval baru yang diterapkan kembali pada proses MWFTS. Proses ini berlangsung hingga diperoleh nilai galat yang stabil atau mencapai batas iterasi maksimum, dengan solusi terbaik direpresentasikan oleh nilai G_{best} (Siregar dan Surono, 2022).

1.4.9 Ukuran Akurasi Peramalan

Evaluasi kinerja peramalan dilakukan untuk mengukur tingkat kedekatan antara nilai hasil peramalan dengan nilai aktual. Semakin kecil nilai kesalahan yang dihasilkan, semakin baik kemampuan model dalam merepresentasikan pola data yang diamati. Berbagai ukuran kesalahan dapat digunakan untuk menilai performa model peramalan, di antaranya *Mean Absolute Percentage Error* (MAPE), *Mean Absolute Error* (MAE), dan *Root Mean Squared Error* (RMSE). Ketiga ukuran tersebut memiliki karakteristik yang berbeda sehingga dapat memberikan gambaran yang lebih komprehensif mengenai tingkat akurasi peramalan ((Hyndman & Koehler, 2006).

1.4.9.1 Mean Absolute Percentage Error

Mean Absolute Percentage Error (MAPE) merupakan ukuran statistik yang menghitung rata-rata penyimpangan absolut antara nilai hasil peramalan dan nilai aktual dalam bentuk persentase (Goodwin dan Lawton, 1999). Dalam konteks pemodelan rantai Markov dengan FTS, Tsaur (2012) menggunakan metode MAPE untuk mengukur dan mengevaluasi besaran penyimpangan yang terjadi pada data hasil peramalan terhadap data observasi aktual. Representasi galat dalam bentuk persentase menjadikan MAPE bersifat independen terhadap skala data, sehingga memudahkan interpretasi dan perbandingan kinerja model secara objektif. Semakin kecil nilai MAPE yang dihasilkan, maka semakin tinggi pula tingkat akurasi peramalan model tersebut. Secara matematis, nilai MAPE dirumuskan pada Persamaan (28).

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{Y_{(t)} - \hat{Y}_{(t)}}{Y_{(t)}} \right| \times 100\% \quad (28)$$

dengan

n : Jumlah data observasi

$Y_{(t)}$: Nilai aktual pada periode ke- t

$\hat{Y}_{(t)}$: Nilai hasil peramalan pada periode ke- t

Penggunaan MAPE tidak hanya berfungsi sebagai alat evaluasi, tetapi juga digunakan sebagai fungsi *fitness* dalam algoritma PSO. Seluruh proses optimasi diarahkan untuk meminimalkan nilai MAPE, sehingga diperoleh konfigurasi interval yang mampu meningkatkan akurasi peramalan secara optimal. Menurut Lewis (1982), tingkat keakuratan model peramalan berdasarkan nilai MAPE ditunjukkan pada Tabel 1.

Tabel 1. Skala MAPE dengan Tingkat Akurasi Peramalan

Tingkat Akurasi	Persentase MAPE
Sangat Baik	<10%
Baik	10%-20%
Cukup	21%-50%
Tidak Akurat	>50%

Sumber: (Lewis, 1982)

Klasifikasi nilai MAPE yang ditunjukkan pada Tabel 1 digunakan untuk mengukur tingkat akurasi model peramalan secara sistematis. Semakin kecil nilai MAPE, maka model tersebut termasuk dalam kategori yang lebih baik, bahkan dapat mencapai kategori sangat baik apabila berada di bawah 10%. Klasifikasi ini memberikan acuan yang jelas dalam menilai kualitas hasil peramalan yang diperoleh. Dengan demikian, MAPE tidak hanya berfungsi sebagai ukuran kesalahan, tetapi juga sebagai indikator utama dalam menentukan tingkat keandalan model peramalan yang digunakan.

1.4.9.2 Mean Absolute Error

Mean Absolute Error (MAE) merupakan ukuran kesalahan yang dihitung berdasarkan rata-rata nilai absolut dari selisih antara nilai aktual dan nilai hasil peramalan. MAE tidak dinyatakan dalam bentuk persentase, melainkan menggunakan satuan yang sama dengan data asli. Nilai MAE yang semakin kecil menunjukkan bahwa hasil peramalan semakin mendekati nilai aktual (Makridakis et al., 1998). Secara matematis, MAE dirumuskan pada Persamaan (29).

$$MAE = \frac{1}{n} \sum_{t=1}^n |Y_{(t)} - \hat{Y}_{(t)}| \quad (29)$$

dengan

$Y_{(t)}$: Nilai aktual pada periode ke- t

$\hat{Y}_{(t)}$: Nilai hasil peramalan pada periode ke- t

n : Jumlah data observasi

1.4.9.3 Root Mean Squared Error

Root Mean Squared Error (RMSE) merupakan ukuran kesalahan yang diperoleh dari akar kuadrat rata-rata selisih kuadrat antara nilai aktual dan nilai hasil peramalan. Penggunaan kuadrat pada proses perhitungan menyebabkan RMSE memberikan penalti yang lebih besar terhadap kesalahan peramalan yang bernilai besar dibandingkan MAE. Oleh karena itu, RMSE sering digunakan untuk mengevaluasi kemampuan model dalam mengendalikan kesalahan yang ekstrem. Nilai RMSE yang semakin kecil menunjukkan bahwa model memiliki tingkat akurasi yang semakin baik. Secara matematis, RMSE dirumuskan pada Persamaan (30) (Hyndman & Koehler, 2006).

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_{(t)} - \hat{Y}_{(t)})^2} \quad (30)$$

dengan

$Y_{(t)}$: Nilai aktual pada periode ke-t

$\hat{Y}_{(t)}$: Nilai hasil peramalan pada periode ke-t

n : Jumlah data observasi

1.4.10 Saham PT Bukalapak.com Tbk

Saham merupakan instrumen pasar modal yang merepresentasikan kepemilikan atau penyertaan modal seseorang maupun badan usaha dalam suatu perusahaan. Kepemilikan tersebut memberikan hak atas pendapatan perusahaan, klaim terhadap aset, serta hak suara dalam Rapat Umum Pemegang Saham (Ridduwan et al., 2025). Secara umum, jenis saham dibedakan berdasarkan karakteristik hak yang melekat pada pemegangnya. Saham biasa memberikan hak suara serta pembagian dividen secara proporsional, sedangkan saham preferen memiliki prioritas utama dalam pembagian dividen dan klaim aset pada saat likuidasi. Proporsi kepemilikan saham ini mencerminkan tingkat kontrol dan hak ekonomi investor terhadap perusahaan, yang ditentukan oleh jumlah saham yang dimiliki dibandingkan dengan total saham yang beredar (Wang, 2021).

Pergerakan harga saham di pasar bursa terbentuk melalui interaksi dinamis antara penawaran dan permintaan. Interaksi tersebut menghasilkan rangkaian data historis harga penutupan yang tersusun dalam bentuk data deret waktu. Karakteristik data harga saham umumnya bersifat fluktuatif, non-linier, dan mengandung tingkat ketidakpastian yang tinggi, sehingga mencerminkan kompleksitas dinamika pasar modal. Salah satu objek observasi deret waktu finansial dengan pergerakan yang sangat dinamis di Bursa Efek Indonesia adalah saham PT Bukalapak.com Tbk. Hal ini terlihat dari tingginya fluktuasi pergerakan harga saham yang kerap dipicu oleh antusiasme dan sentimen investor dalam melakukan transaksi (Mediaty et al., 2024). Selain itu, fluktuasi kinerja keuangan perusahaan turut memberikan sentimen yang bergejolak terhadap perubahan harga sahamnya di pasar modal. Sebagai entitas yang berada di sektor teknologi, saham PT Bukalapak.com Tbk. memiliki profil

pergerakan harga yang sangat non-linier dan sangat rentan terhadap perubahan tren dalam rentang waktu yang singkat (Frymaruwah et al., 2024).

BAB II METODE PENELITIAN

2.1 Jenis dan Sumber Data

Data yang digunakan dalam penelitian ini merupakan data sekunder berupa data deret waktu harga penutupan saham harian PT Bukalapak.com Tbk pada periode Oktober 2024 hingga Desember 2025. Data tersebut diperoleh dari situs penyedia data pasar keuangan Investing.com yang diakses melalui situs web resmi (<https://www.investing.com/>). Data harga penutupan mencerminkan nilai akhir transaksi saham pada setiap hari perdagangan. Dataset yang digunakan dalam penelitian ini disajikan pada Lampiran 1.

2.2 Variabel Penelitian

Variabel yang digunakan dalam penelitian ini adalah harga penutupan saham PT Bukalapak.com Tbk yang dinyatakan dalam satuan Rupiah (IDR) dan dinotasikan sebagai $Y_{(t)}$, yaitu nilai harga saham pada periode ke- t . Variabel ini merepresentasikan nilai akhir perdagangan saham pada setiap hari. Indeks waktu (t) digunakan untuk menunjukkan urutan kronologis data dalam satuan harian. Indeks waktu ini berfungsi untuk menandai posisi setiap observasi dalam deret waktu, sehingga pola pergerakan harga saham dapat dianalisis secara berurutan dari waktu ke waktu.

2.3 Analisis Data

Penelitian ini menerapkan metode MWFTS berbasis klusterisasi *K-Means* yang dioptimasi menggunakan PSO. Pengolahan data dilakukan menggunakan bahasa pemrograman R pada data harga saham PT Bukalapak.com Tbk periode Oktober 2024 – Desember 2025. Tahapan analisis disusun secara sistematis sebagai berikut:


1. Eksplorasi data
 - a. Melakukan visualisasi *time series plot* untuk mengidentifikasi pola pergerakan harga saham.
 - b. Menghitung statistik deskriptif meliputi *mean*, median, standar deviasi, serta nilai minimum $D_{\min}$ dan maksimum $D_{\max}$.
 - c. Membagi data menjadi data latih dan data uji dengan proporsi 80:20.
 - d. Menentukan *universe of discourse* (U) berdasarkan Persamaan (2).
2. Pembentukan Interval menggunakan *K-Means*
 - a. Menentukan jumlah kluster optimum menggunakan metode Elbow berdasarkan nilai *Within Cluster Sum of Square* (WCSS) menggunakan Persamaan (11).
 - b. Menentukan *centroid* awal secara acak sesuai jumlah kluster optimum yang diperoleh.
 - c. Menghitung jarak *Euclidean* setiap titik data terhadap masing-masing *centroid* menggunakan Persamaan (9).
 - d. Memperbarui *centroid* setiap kluster berdasarkan rata-rata anggota kluster sesuai Persamaan (10).

- e. Mengulangi proses pengelompokan data dan pembaruan *centroid* hingga konvergen.
 - f. Menghitung batas bawah dan batas atas interval hasil klasterisasi menggunakan Persamaan (12), Persamaan (13), Persamaan (14), dan Persamaan (15).
3. Peramalan menggunakan *Markov Weighted Fuzzy Time Series* (MWFTS)
- a. Melakukan proses fuzzifikasi data berdasarkan variabel linguistik yang merujuk pada Persamaan (3).
 - b. Menyusun *Fuzzy Logical Relationship* (FLR) berdasarkan urutan pergerakan harga saham.
 - c. Mengelompokkan FLR ke dalam *Fuzzy Logical Relationship Group* (FLRG).
 - d. Menghitung bobot relasi untuk setiap *state fuzzy* menggunakan Persamaan (16), Persamaan (17), dan Persamaan (18).
 - e. Menyusun matriks probabilitas transisi Markov menggunakan Persamaan (19) dan Persamaan (20).
 - f. Melakukan proses defuzzifikasi untuk memperoleh nilai peramalan sesuai Persamaan (21) untuk kondisi *one-to-one* atau Persamaan (22) untuk kondisi *one-to-many*.
 - g. Menghitung nilai MAPE, MAE, dan RMSE berdasarkan Persamaan (28), Persamaan (29), dan Persamaan (30) sebagai ukuran akurasi model sebelum proses optimasi.
4. Optimasi batas interval menggunakan *Particle Swarm Optimization*.
- a. Menetapkan nilai MAPE data latih sebagai *fitness value* untuk menentukan *Personal Best* (P_{best}) dan *Global Best* (G_{best}).
 - b. Menginisialisasi nilai kecepatan awal V_{id}^t secara acak dan nilai posisi X_{id}^t berdasarkan interval hasil klasterisasi K-Means.
 - c. Menentukan nilai bobot inersia ω , serta menetapkan nilai konstanta kognitif dan sosial masing-masing sebesar $c_1 = 2$ dan $c_2 = 2$.
 - d. Membangkitkan bilangan acak dalam rentang $[0,1]$ untuk menghitung kecepatan baru V_{id}^{t+1} .
 - e. Menghitung posisi baru X_{id}^{t+1} dan mengurutkan hasilnya secara *ascending* untuk membentuk batas interval baru.
 - f. Melakukan kembali proses peramalan MWFTS menggunakan batas interval hasil optimasi.
 - g. Mengulangi proses pembaruan kecepatan dan posisi partikel hingga mencapai jumlah iterasi maksimum.
 - h. Menghitung nilai MAPE, MAE, dan RMSE hasil optimasi.
 - i. Membandingkan nilai MAPE, MAE, dan RMSE sebelum dan sesudah optimasi.
5. Penarikan kesimpulan.

BAB III HASIL DAN PEMBAHASAN

3.1 Analisis Deskriptif

Analisis deskriptif dilakukan untuk melihat pola data harga penutupan saham harian PT Bukalapak.com Tbk pada periode Oktober 2024 hingga Desember 2025. Pola data tersebut dapat dilihat pada plot data yang ditunjukkan pada Gambar 1.



Gambar 1. Plot Data Harga Penutupan Saham Bukalapak

Gambar 1 menunjukkan bahwa pergerakan harga penutupan saham Bukalapak memiliki tingkat volatilitas yang tinggi dengan pola fluktuasi yang tidak stasioner sepanjang periode pengamatan. Pola historis memperlihatkan adanya konsentrasi data pada rentang harga rendah di paruh awal periode, yang kemudian diikuti oleh peningkatan tajam mulai sekitar Agustus 2025 hingga mencapai puncak pada Oktober 2025. Setelah itu, harga mengalami penurunan dan kembali menunjukkan pola fluktuasi yang tidak stabil. Pergerakan harga saham pada Oktober 2024 hingga sekitar Februari 2025 relatif stabil pada kisaran Rp115–130 per saham dengan fluktuasi yang tidak terlalu besar, sehingga menunjukkan bahwa aktivitas perdagangan saham pada awal periode masih didominasi oleh pergerakan harga yang cenderung mendatar.

Peningkatan harga saham mulai terlihat sejak pertengahan tahun 2025 dan mencapai titik tertinggi pada kisaran Agustus hingga Oktober 2025. Kondisi tersebut sejalan dengan membaiknya kinerja fundamental PT Bukalapak.com Tbk yang berhasil membukukan laba bersih sebesar Rp2,9 triliun pada kuartal III tahun 2025 setelah pada periode yang sama tahun sebelumnya mengalami rugi bersih. Peningkatan laba bersih tersebut terutama didorong oleh kenaikan nilai investasi perusahaan (Pratama et al., 2025). Program pembelian kembali (*share buyback*) yang dilanjutkan oleh PT Bukalapak.com Tbk pada Oktober 2025 juga menjadi salah

satu sentimen positif yang berpotensi meningkatkan kepercayaan investor terhadap saham BUKA dan turut mendukung penguatan harga saham pada periode tersebut (Binekasri, 2025). Harga saham kemudian mengalami koreksi pada November hingga Desember 2025, namun masih bertahan pada level yang lebih tinggi dibandingkan awal periode pengamatan.

Karakteristik sebaran data yang tidak merata pada data harga penutupan saham harian PT Bukalapak.com Tbk mengindikasikan bahwa data memiliki karakteristik yang fluktuatif dan dinamis. Kondisi tersebut mendukung penggunaan algoritma K-Means dalam pembentukan interval fuzzy karena mampu mengelompokkan data berdasarkan tingkat kemiripan sehingga menghasilkan interval yang lebih adaptif terhadap distribusi data. Perubahan harga saham dari waktu ke waktu direpresentasikan sebagai perpindahan antar *state* fuzzy, sehingga penerapan Rantai Markov dalam *Markov Weighted Fuzzy Time Series* (MWFTS) digunakan untuk membentuk matriks probabilitas transisi berdasarkan pola historis data. Selanjutnya, PSO digunakan untuk mengoptimalkan batas interval hasil klasterisasi agar diperoleh interval yang lebih optimal dalam proses peramalan. Untuk memberikan gambaran kuantitatif mengenai karakteristik data yang ditunjukkan pada Gambar 1, dilakukan analisis statistik deskriptif terhadap seluruh data. Hasil perhitungan statistik deskriptif disajikan pada Tabel 2.

Tabel 2. Statistik Deskriptif Data Harga Penutupan Saham Bukalapak

Ukuran Statistik	Nilai
Mean	144,5
Minimum	114
Maksimum	195
Standar Deviasi	19,85
Jumlah Data	298

Tabel 2 menunjukkan nilai minimum data sebesar 114 dan nilai maksimum mencapai 195. Hal ini mengindikasikan adanya rentang data yang cukup besar dan mencerminkan dinamika pergerakan harga yang aktif di pasar. Nilai standar deviasi sebesar 19,85 juga menunjukkan tingkat penyebaran data yang cukup besar terhadap nilai rata-ratanya, sehingga dapat disimpulkan bahwa volatilitas harga saham relatif tinggi. Selanjutnya, jumlah data yang digunakan dalam penelitian adalah sebanyak 298 observasi. Data tersebut dibagi menjadi dua bagian, yaitu data latih dan data uji. Data latih digunakan sebagai dasar utama dalam membangun proses peramalan. Seluruh proses perhitungan, mulai dari pembentukan interval menggunakan *K-Means* hingga optimasi menggunakan PSO dilakukan berdasarkan data latih tersebut. Sementara itu, data uji digunakan untuk mengevaluasi kinerja peramalan dengan mengukur sejauh mana hasil peramalan mampu merepresentasikan data aktual yang belum pernah digunakan dalam proses pembentukan. Dengan demikian, pembagian data ini bertujuan untuk memastikan bahwa proses peramalan tidak hanya menyesuaikan pola historis, tetapi juga memiliki kemampuan generalisasi yang baik terhadap data baru.

3.2 Peramalan Saham Bukalapak dengan Metode *Markov Weighted Fuzzy Time Series* Berbasis *K-Means*

3.2.1 Penentuan *Universe of Discourse*

Langkah awal dalam proses pembentukan interval adalah penentuan *universe of discourse*. Berdasarkan data harga penutupan saham yang digunakan, diperoleh nilai minimum ($D_{\min}$) sebesar 114 dan nilai maksimum ($D_{\max}$) sebesar 195. Selanjutnya, digunakan bilangan random positif d_1 dan d_2 yang ditentukan oleh peneliti untuk memperluas batas bawah dan batas atas *universe of discourse*. Pada penelitian ini, ditetapkan nilai $d_1 = d_2 = 0,05$. Berdasarkan nilai tersebut, *universe of discourse* yang terbentuk dengan menggunakan Persamaan (2) sebagai berikut.

$$U = [D_{\min} - d_1 ; D_{\max} + d_2]$$


$$U = [114 - 0,05 ; 195 + 0,05]$$

$$U = [113,95 ; 195,05]$$

Penentuan *universe of discourse* memastikan bahwa seluruh data harga penutupan saham PT Bukalapak.com Tbk selama periode observasi telah tercakup dengan baik. Batas yang dihasilkan menjadi sedikit lebih luas dibandingkan rentang data awal karena adanya penambahan konstanta d_1 dan d_2 pada nilai minimum dan maksimum. Hal ini bertujuan agar seluruh variasi data tetap berada dalam cakupan yang telah ditentukan.

3.2.2 Pembentukan Interval Berbasis *K-Means Clustering*

Pembentukan interval fuzzy dimulai dengan penentuan jumlah kluster menggunakan *Elbow Method* sesuai Persamaan (11). Penentuan jumlah kluster ini bertujuan untuk memperoleh pembagian data yang mampu merepresentasikan karakteristik distribusi data latih secara optimal. Hasil penerapan *Elbow Method* pada data latih disajikan pada Gambar 2.



Gambar 2. Grafik *Elbow Method* berdasarkan Nilai WCSS

Gambar 2 menunjukkan bahwa kurva *Within Cluster Sum of Squares* (WCSS) mengalami penurunan yang tajam pada penambahan jumlah kluster di awal, kemudian membentuk pola yang semakin landai setelah mencapai empat kluster.

Perubahan bentuk kurva tersebut menghasilkan titik siku (*elbow*) pada $K = 4$, yang mengindikasikan bahwa penambahan jumlah kluster setelah nilai tersebut tidak lagi memberikan peningkatan kualitas pengelompokan yang signifikan. Berdasarkan hal tersebut, jumlah kluster yang digunakan dalam penelitian ini ditetapkan sebanyak empat kluster sebagai dasar pembentukan interval fuzzy.

Proses *K-Means Clustering* diawali dengan tahap inisialisasi *centroid* sebagai titik pusat awal yang akan digunakan sebagai acuan dalam pengelompokan data latih. Nilai *centroid* awal menjadi acuan dalam menghitung jarak setiap data terhadap masing-masing kluster. Setiap data latih dialokasikan ke *centroid* terdekat menggunakan jarak Euclidean sesuai Persamaan (9). Posisi *centroid* kemudian diperbarui berdasarkan rata-rata anggota pada masing-masing kluster sesuai Persamaan (10). Proses pengalokasian data dan pembaruan *centroid* dilakukan secara iteratif hingga mencapai kondisi konvergen, yaitu ketika posisi *centroid* pada dua iterasi berturut-turut tidak lagi mengalami perubahan. Hasil akhir proses *K-Means Clustering* berupa *centroid* akhir beserta jumlah data pada masing-masing kluster disajikan pada Tabel 3.

Tabel 3. Hasil Proses *K-Means Clustering*

Kluster	Centroid Akhir	Jumlah Data
C_1	121,5802	81
C_2	134,8472	72
C_3	146,7447	47
C_4	174,5750	38
Total		238

Tabel 3 menunjukkan bahwa seluruh data latih telah terdistribusi ke dalam empat kluster sesuai dengan karakteristik kemiripan nilainya. Centroid akhir yang diperoleh selanjutnya digunakan sebagai dasar dalam pembentukan interval himpunan fuzzy. Batas antarinterval diperoleh melalui perhitungan titik tengah antara dua centroid yang berurutan sesuai Persamaan (12) dan Persamaan (13), sedangkan batas bawah interval pertama dan batas atas interval terakhir ditetapkan menggunakan nilai minimum ($U_{\min} = 113,9500$) dan nilai maksimum ($U_{\max} = 195,0500$) dari *universe of discourse* sesuai dengan Persamaan (14) dan Persamaan (15). Hasil pembentukan interval himpunan fuzzy disajikan pada Tabel 4.

Tabel 4. Interval Fuzzy berdasarkan *Centroid Akhir K-Means*

Centroid	Batas Bawah (LB_i)	Batas Atas (UB_i)
121,5802	113,9500	132,1455
134,8472	132,1455	152,6889
146,7447	152,6889	170,3553
174,5750	170,3553	195,0500

Interval yang terbentuk pada Tabel 4 menunjukkan pembagian rentang harga penutupan saham PT Bukalapak.com Tbk ke dalam empat *state* yang tersusun secara berurutan dan saling berkesinambungan. Pembagian ini merepresentasikan distribusi data hasil pengelompokan *K-Means* dengan lebar interval yang tidak seragam karena menyesuaikan tingkat kepadatan data pada masing-masing kluster.

Batas-batas tersebut memastikan bahwa setiap data dapat dipetakan secara presisi ke dalam satu himpunan *fuzzy* sesuai dengan posisi nilainya pada rentang yang telah ditentukan. Adapun sintaks program yang digunakan untuk menjalankan seluruh proses *K-Means* dalam penelitian ini disajikan pada Lampiran 2.

Pemberian label linguistik dilakukan pada setiap interval fuzzy untuk mempermudah representasi data numerik ke dalam bentuk himpunan fuzzy. Label linguistik diberikan secara berurutan sesuai peningkatan rentang nilai harga penutupan saham, yaitu Sangat Rendah, Rendah, Tinggi, dan Sangat Tinggi. Label tersebut berfungsi sebagai identitas setiap interval pada proses fuzzifikasi serta pembentukan *Fuzzy Logical Relationship* (FLR). Hasil pemberian label linguistik pada setiap interval disajikan pada Tabel 5.

Tabel 5. Label Linguistik Interval Fuzzy

State	Label Linguistik	Interval
A_1	Sangat Rendah	[113,9500 ; 132,1455)
A_2	Rendah	[132,1455 ; 152,6889)
A_3	Tinggi	[152,6889 ; 170,3553)
A_4	Sangat Tinggi	[170,3553 ; 195,0500]

Label linguistik yang telah ditetapkan pada Tabel 5 berfungsi sebagai representasi kualitatif dari setiap interval fuzzy sehingga proses transformasi data numerik ke dalam bentuk himpunan fuzzy dapat dilakukan secara sistematis. Setiap interval didefinisikan sebagai interval setengah terbuka, yaitu $[LB_i ; UB_i)$, sehingga batas bawah termasuk ke dalam interval, sedangkan batas atas tidak termasuk. Pengecualian diberikan pada interval terakhir yang ditulis agar nilai maksimum pada *Universe of Discourse* tetap terakomodasi. Dengan ketentuan tersebut, apabila suatu nilai berada tepat pada batas perpotongan dua interval, nilai tersebut dialokasikan ke interval di sebelah kanan. Ketentuan ini memastikan bahwa setiap data hanya menjadi anggota satu state fuzzy sehingga tidak terjadi ambiguitas dalam proses fuzzifikasi. Himpunan fuzzy yang terbentuk selanjutnya digunakan sebagai dasar pembentukan *Fuzzy Logical Relationship* (FLR) pada tahap berikutnya.

3.2.3 Fuzzifikasi, Pembentukan *Fuzzy Logical Relationship* dan *Fuzzy Logical Relationship Group*

Fuzzifikasi merupakan tahapan yang bertujuan untuk mentransformasikan data aktual numerik ke dalam bentuk himpunan fuzzy berdasarkan interval yang telah ditetapkan. Pada penelitian ini, data harga penutupan saham PT Bukalapak.com Tbk diklasifikasikan ke dalam empat *state*, yaitu A_1 , A_2 , A_3 , dan A_4 , sesuai dengan interval fuzzy yang dibentuk menggunakan hasil *K-Means Clustering*. Penentuan *state* dilakukan dengan membandingkan setiap nilai harga penutupan terhadap batas bawah dan batas atas interval fuzzy sesuai dengan Persamaan (3). Sebagai ilustrasi, data harga penutupan pada periode pertama bernilai 120. Nilai tersebut berada pada rentang interval 113,9500 hingga 132,1455 sehingga dipetakan ke dalam *state* A_1 . Prosedur yang sama diterapkan pada seluruh data latih hingga setiap observasi memiliki representasi dalam bentuk *state* fuzzy.

Representasi *state* yang diperoleh menjadi dasar dalam pembentukan FLR. FLR dibentuk dengan menghubungkan *state* pada periode ke- t dengan *state* pada periode ke- $t + 1$. Sebagai contoh, data pada periode pertama berada pada *state* A_1 , sedangkan data pada periode kedua juga berada pada *state* A_1 , sehingga terbentuk hubungan transisi $A_1 \rightarrow A_1$. Hubungan transisi tersebut disusun untuk seluruh data latih dan digunakan sebagai dasar pembentukan *Fuzzy Logical Relationship Group* (FLRG) pada tahap berikutnya. Hasil proses fuzzifikasi data latih disajikan pada Tabel 6, sedangkan hasil lengkapnya dapat dilihat pada Lampiran 3.

Tabel 6. Hasil Fuzzifikasi dan FLR Data Latih

t	Tanggal	$Y_{(t)}$	State	FLR
1	01/10/2024	120	A_1	
2	02/10/2024	120	A_1	$A_1 \rightarrow A_1$
3	03/10/2024	116	A_1	$A_1 \rightarrow A_1$
4	04/10/2024	115	A_1	$A_1 \rightarrow A_1$
5	07/10/2024	144	A_2	$A_1 \rightarrow A_2$
⋮	⋮	⋮	⋮	⋮
234	29/09/2025	171	A_4	$A_3 \rightarrow A_4$
235	30/09/2025	170	A_3	$A_4 \rightarrow A_3$
236	01/10/2025	180	A_4	$A_3 \rightarrow A_4$
237	02/10/2025	174	A_4	$A_4 \rightarrow A_4$
238	03/10/2025	177	A_4	$A_4 \rightarrow A_3$

Tabel 6 menunjukkan bahwa hasil fuzzifikasi merepresentasikan perubahan harga penutupan saham ke dalam urutan *state* yang menggambarkan kondisi harga pada setiap periode pengamatan. Representasi tersebut menunjukkan bahwa perpindahan *state* tidak selalu terjadi menuju *state* yang berbeda, tetapi juga dapat bertahan pada *state* yang sama selama beberapa periode berturut-turut. Kondisi ini mengindikasikan bahwa pergerakan harga saham Bukalapak memiliki kecenderungan mempertahankan kondisi harga tertentu sebelum mengalami perubahan ke rentang harga lainnya. Pola perpindahan *state* yang diperoleh selanjutnya diringkas melalui pembentukan FLRG untuk mengidentifikasi seluruh kemungkinan transisi dari setiap *state* asal. Hasil pengelompokan FLRG pada data harga saham Bukalapak dirangkum dalam Tabel 7.

Tabel 7. FLRG Data Latih

Current State (A_i)	Next State (A_j)	FLRG
A_1	A_1, A_2	$A_1 \rightarrow A_1, A_2$
A_2	A_1, A_2, A_3	$A_2 \rightarrow A_1, A_2, A_3$
A_3	A_2, A_3, A_4	$A_3 \rightarrow A_2, A_3, A_4$
A_4	A_3, A_4	$A_4 \rightarrow A_3, A_4$

Tabel 7 menunjukkan bahwa setiap *state* memiliki lebih dari satu kemungkinan perpindahan menuju *state* pada periode berikutnya. Hal tersebut menunjukkan bahwa setiap *state* memiliki lebih dari satu kemungkinan transisi

menuju *state* pada periode berikutnya, meskipun jumlah *state* tujuan pada setiap kelompok berbeda. Kondisi tersebut mengindikasikan bahwa pergerakan harga saham PT Bukalapak.com Tbk tidak bersifat tetap, melainkan memiliki beberapa kemungkinan perubahan yang dipengaruhi oleh pola historis data. Oleh karena itu, hasil pengelompokan FLRG menjadi dasar dalam penyusunan matriks frekuensi dan matriks probabilitas transisi pada metode MWFTS.

3.2.4 Pembentukan Matriks Probabilitas Transisi Markov

Pembentukan matriks probabilitas transisi Markov diawali dengan menghitung frekuensi kemunculan setiap hubungan transisi yang diperoleh dari hasil FLRG. Frekuensi tersebut menunjukkan banyaknya perpindahan harga saham dari suatu *current state* menuju *next state* pada data latih. Nilai frekuensi ini menjadi dasar dalam menghitung peluang perpindahan antar *state* pada proses Markov. Rekapitulasi frekuensi transisi antar *state* data latih disajikan pada Tabel 8.

Tabel 8. Frekuensi Transisi Antar *State* Data Latih

State	A₁	A₂	A₃	A₄	Total
A₁	94	9	0	0	103
A₂	8	82	2	0	92
A₃	0	1	6	5	12
A₄	0	0	4	26	30

Tabel 8 menunjukkan distribusi frekuensi perpindahan harga saham antar *state* selama periode pengamatan. Frekuensi yang lebih besar pada suatu relasi menunjukkan bahwa pola perpindahan tersebut lebih sering muncul pada data historis, sedangkan frekuensi yang lebih kecil menunjukkan bahwa perpindahan antar *state* terjadi relatif lebih jarang. Informasi tersebut menjadi dasar dalam menghitung probabilitas transisi dengan membandingkan frekuensi setiap relasi terhadap total kejadian pada *state* asal sesuai Persamaan (17).

Perhitungan probabilitas transisi yang berasal dari *state* A₁ dilakukan dengan membagi setiap frekuensi transisi dari A₁ terhadap total frekuensi transisi pada baris A₁, yaitu sebanyak 103 kejadian. Perhitungan tersebut diperoleh sebagai berikut.

$$P(A_1, A_1) = \frac{94}{103} = 0,9126$$

$$P(A_1, A_2) = \frac{9}{103} = 0,0874$$

$$P(A_1, A_3) = \frac{0}{103} = 0,0000$$

$$P(A_1, A_4) = \frac{0}{103} = 0,0000$$

Perhitungan probabilitas transisi yang berasal dari *state* A₂, A₃, dan A₄ dilakukan dengan prosedur yang sama. Hasil perhitungan secara lengkap disajikan pada Lampiran 4. Seluruh probabilitas transisi kemudian disusun ke dalam matriks probabilitas P sesuai Persamaan (20). Hasil perhitungan matriks probabilitas transisi Markov disajikan pada Persamaan (31).

$$P = \begin{bmatrix} 0,9126 & 0,0874 & 0,0000 & 0,0000 \\ 0,0870 & 0,8913 & 0,0217 & 0,0000 \\ 0,0000 & 0,0833 & 0,5000 & 0,4167 \\ 0,0000 & 0,0000 & 0,1333 & 0,8667 \end{bmatrix} \quad (31)$$

Persamaan (31) menunjukkan bahwa peluang transisi terbesar pada setiap *state* cenderung berada pada diagonal utama matriks. Kondisi tersebut mengindikasikan bahwa harga penutupan saham Bukalapak memiliki kecenderungan untuk mempertahankan kondisi harga pada interval yang sama dibandingkan berpindah ke interval lainnya dalam satu periode pengamatan. Di samping itu, peluang perpindahan yang muncul umumnya terjadi menuju *state* yang berdekatan, sedangkan perpindahan ke *state* yang lebih jauh memiliki peluang yang sangat kecil atau bahkan tidak terjadi. Pola tersebut menunjukkan bahwa perubahan harga saham berlangsung secara bertahap sehingga karakteristik pergerakannya dapat direpresentasikan dengan baik melalui pendekatan rantai Markov. Matriks probabilitas transisi yang diperoleh selanjutnya digunakan sebagai komponen utama dalam proses pembobotan nilai peramalan.

3.2.5 Perhitungan Nilai Peramalan

Tahap peramalan pada metode MWFTS dilakukan dengan memanfaatkan matriks probabilitas transisi Markov dan nilai *midpoint* dari setiap himpunan fuzzy. Nilai *midpoint* (m_i) dihitung menggunakan Persamaan (4) sebagai representasi numerik dari masing-masing *state*. Nilai tersebut digunakan sebagai dasar dalam memperoleh nilai peramalan melalui pembobotan berdasarkan probabilitas transisi. Hasil perhitungan *midpoint* setiap *state* disajikan pada Tabel 9.

Tabel 9. *Midpoint* Setiap *State*

State	Batas Bawah (LB_i)	Batas Atas (UB_i)	Midpoint (m_i)
A ₁	113,9500	132,1455	123,0477
A ₂	132,1455	152,6889	142,4171
A ₃	152,6889	170,3553	161,5221
A ₄	170,3553	195,0500	182,7027

Tabel 9 menyajikan nilai *midpoint* untuk setiap *state* fuzzy yang diperoleh dari interval hasil klasterisasi. Nilai *midpoint* tersebut selanjutnya digunakan sebagai nilai representatif dari setiap *state* dalam proses peramalan. Nilai peramalan dihitung menggunakan *midpoint* dan matriks probabilitas transisi Markov sesuai Persamaan (22). Setiap probabilitas transisi dikalikan dengan nilai representatif pada *state* tujuan, kemudian seluruh hasil perkalian dijumlahkan untuk memperoleh nilai peramalan pada periode berikutnya. Pada *state* yang sedang ditempati, nilai representatif digantikan oleh nilai aktual $Y_{(t)}$, sedangkan *state* lainnya direpresentasikan menggunakan nilai *midpoint*. Hasil perhitungan nilai peramalan disajikan pada Tabel 10, sedangkan hasil lengkapnya dapat dilihat pada Lampiran 5.

Tabel 10. Hasil Perhitungan Peramalan Data Latih

t	Tanggal	$Y_{(t)}$	State	$\hat{Y}_t$
1	01/10/2024	120	A_1	
2	02/10/2024	120	A_1	121,9588
3	03/10/2024	116	A_1	121,9588
4	04/10/2024	115	A_1	118,3083
5	07/10/2024	144	A_2	117,3957
⋮	⋮	⋮	⋮	⋮
234	29/09/2025	171	A_4	172,4942
235	30/09/2025	170	A_3	169,7363
236	01/10/2025	180	A_4	172,9942
237	02/10/2025	174	A_4	177,5363
238	03/10/2025	177	A_4	172,3363

Tabel 10 menyajikan hasil peramalan pada data latih. Nilai peramalan yang dihasilkan menunjukkan perubahan yang searah dengan pergerakan harga saham pada setiap periode, sehingga kecenderungan pola data dapat diikuti oleh hasil peramalan. Parameter dan interval yang telah diperoleh selanjutnya diterapkan pada data uji tanpa dilakukan pembentukan ulang. Hasil peramalan pada data uji disajikan pada Tabel 12, sedangkan hasil lengkapnya dapat dilihat pada Lampiran 6.

Tabel 11. Hasil Perhitungan Peramalan Data Uji

t	Tanggal	$Y_{(t)}$	State	$\hat{Y}_t$
239	06/10/2025	195	A_4	
240	07/10/2025	180	A_4	190,5363
241	08/10/2025	172	A_4	177,5363
242	09/10/2025	170	A_3	170,6029
243	10/10/2025	168	A_3	172,9942
⋮	⋮	⋮	⋮	⋮
294	22/12/2025	155	A_3	168,9942
295	23/12/2025	157	A_3	165,4942
296	24/12/2025	158	A_3	166,4942
297	29/12/2025	158	A_3	166,9942
298	30/12/2025	158	A_3	166,9942

Hasil peramalan pada Tabel 11 menunjukkan bahwa model mampu menghasilkan nilai peramalan untuk setiap periode pada data uji menggunakan interval fuzzy dan matriks probabilitas transisi yang diperoleh dari data latih. Secara umum, hasil peramalan masih mengikuti kecenderungan perubahan harga penutupan saham selama periode pengujian. Hasil peramalan tersebut kemudian dievaluasi menggunakan ukuran kesalahan untuk mengetahui tingkat ketepatan peramalan.

3.2.6 Evaluasi Metode *Markov Weighted Fuzzy Time Series* Berbasis *K-Means*

Evaluasi metode dilakukan menggunakan tiga metrik evaluasi, yaitu *Mean Absolute Percentage Error* (MAPE), *Mean Absolute Error* (MAE), dan *Root Mean Square Error* (RMSE). Ketiga ukuran tersebut digunakan untuk mengetahui tingkat kedekatan antara nilai aktual dan nilai hasil peramalan pada data latih maupun data uji. Hasil evaluasi menggunakan ketiga metrik tersebut disajikan pada Tabel 12.

Tabel 12. Hasil Evaluasi Metode MWFTS Berbasis *K-Means*

Data	MAPE (%)	MAE	RMSE
Data Latih	2,2575	3,1433	4,4588
Data Uji	3,1736	5,2263	5,8953

Berdasarkan Tabel 12, hasil evaluasi menunjukkan bahwa nilai MAPE, MAE, dan RMSE pada data uji lebih besar dibandingkan data latih. Pada data latih diperoleh nilai MAPE sebesar 2,2575%, MAE sebesar 3,1433, dan RMSE sebesar 4,4588, sedangkan pada data uji diperoleh nilai MAPE sebesar 3,1736%, MAE sebesar 5,2263, dan RMSE sebesar 5,8953. Nilai MAPE pada data uji masih berada di bawah 10%, sehingga berdasarkan kriteria Lewis (1982) hasil peramalan termasuk dalam kategori sangat akurat. Nilai tersebut menunjukkan bahwa interval yang dibentuk *K-Means* telah mampu merepresentasikan sebagian besar pola pergerakan harga saham sehingga menghasilkan tingkat akurasi yang baik. Namun, proses *K-Means* bertujuan meminimalkan variasi data di dalam klaster, bukan secara langsung meminimalkan kesalahan peramalan. Akibatnya, batas interval yang diperoleh belum tentu merupakan konfigurasi yang paling optimal untuk menghasilkan nilai MAPE minimum.

Nilai MAPE, MAE, dan RMSE pada data uji mengalami peningkatan dibandingkan data latih. Kondisi tersebut menunjukkan bahwa galat peramalan masih dapat diminimalkan melalui penyempurnaan pembentukan interval fuzzy. Salah satu keterbatasan metode *K-Means* adalah proses klasterisasi yang sangat dipengaruhi oleh inisialisasi centroid awal sehingga algoritma berpotensi berhenti pada solusi optimum lokal. Akibatnya, interval fuzzy yang dihasilkan belum tentu merupakan konfigurasi yang optimal untuk meminimalkan galat peramalan secara global. Oleh karena itu, optimasi menggunakan *Particle Swarm Optimization* (PSO) diterapkan untuk memperoleh interval fuzzy yang lebih optimal sehingga diharapkan mampu menurunkan nilai MAPE, MAE, dan RMSE serta meningkatkan ketepatan hasil peramalan.

3.3 Optimasi *Markov Weighted Fuzzy Time Series* Berbasis *K-Means* menggunakan *Particle Swarm Optimization*

3.3.1 Optimasi Batas Interval

Optimasi batas interval fuzzy dilakukan menggunakan algoritma PSO untuk memperoleh konfigurasi interval yang mampu meminimalkan galat peramalan pada metode MWFTS. Proses optimasi dilakukan terhadap batas interval yang dihasilkan dari metode *K-Means*. Rincian parameter kendali, skema inisialisasi, dan batasan komputasi yang digunakan dalam algoritma PSO disajikan pada Tabel 13.

Tabel 13. Parameter dan Inisialisasi Komputasi PSO

Parameter	Simbol	Nilai / Kondisi
Ukuran populasi	N	50 partikel
Maksimum iterasi	$Iter_{max}$	100
Dimensi pencarian	D	3
Bobot inersia maksimum	ω_{max}	0,9
Bobot inersia minimum	ω_{min}	0,4
Konstanta kognitif	c_1	2
Konstanta sosial	c_2	2
Posisi partikel acuan	X_{base}^0	Berdasarkan interval <i>K-Means</i>
Kecepatan awal	V_i^0	0

Berdasarkan Tabel 13, proses optimasi menggunakan 50 partikel dengan maksimum 100 iterasi. Jumlah interval fuzzy yang digunakan sebanyak empat *state*, sehingga terdapat tiga batas interval internal yang menjadi variabel pencarian pada algoritma PSO. Bobot inersia ditetapkan pada rentang 0,90 hingga 0,40 menggunakan fungsi penurunan eksponensial agar kemampuan eksplorasi lebih dominan pada iterasi awal dan secara bertahap beralih menuju eksploitasi solusi terbaik pada iterasi akhir. Nilai konstanta kognitif dan konstanta sosial masing-masing ditetapkan sebesar 2 karena memberikan pengaruh yang seimbang antara pengalaman individu partikel dan informasi yang diperoleh dari populasi, sehingga banyak digunakan sebagai parameter standar pada algoritma PSO (Kennedy & Eberhart, 1995; Kumar & Susan, 2021).

Proses inisialisasi diawali dengan menggunakan konfigurasi batas interval hasil *K-Means* sebagai solusi awal (*baseline*). Partikel pertama menggunakan konfigurasi tersebut, sedangkan partikel lainnya dibangkitkan di sekitar solusi awal sehingga menghasilkan sejumlah kandidat batas interval yang berbeda. Seluruh partikel diberikan kecepatan awal bernilai nol sehingga setiap partikel memulai proses pencarian dari kondisi awal yang sama sebelum dilakukan pembaruan posisi secara iteratif.

Setiap partikel dievaluasi menggunakan fungsi objektif yang dibangun berdasarkan nilai MAPE pada data validasi. Pada penelitian ini, data latih terlebih dahulu dibagi menjadi data *subtraining* dan data validasi sehingga proses optimasi tidak hanya menyesuaikan konfigurasi batas interval terhadap data *subtraining*, tetapi juga mengevaluasi kinerjanya pada data validasi. Selain mempertimbangkan nilai MAPE, fungsi objektif juga dilengkapi dengan mekanisme penalti untuk menghindari terbentuknya interval yang terlalu sempit, *state* yang tidak memiliki anggota, distribusi data yang tidak seimbang, serta perubahan batas interval yang terlalu jauh dari konfigurasi awal. Dengan demikian, solusi yang dipilih tidak hanya menghasilkan galat peramalan yang rendah, tetapi juga mempertahankan kualitas pembentukan interval fuzzy.

Proses optimasi dilakukan secara iteratif selama 100 iterasi. Pada setiap iterasi, kecepatan dan posisi partikel diperbarui berdasarkan komponen bobot

inersia, komponen kognitif, dan komponen sosial. Bobot inersia diperbarui menggunakan fungsi eksponensial sehingga kemampuan eksplorasi lebih dominan pada iterasi awal, kemudian secara bertahap beralih menuju eksploitasi solusi terbaik. Posisi partikel hasil pembaruan selanjutnya diperiksa melalui mekanisme *repair* untuk memastikan batas interval tetap terurut, tidak saling bertumpang tindih, serta memenuhi lebar interval minimum yang telah ditentukan. Nilai fungsi objektif kemudian dievaluasi untuk menentukan solusi terbaik yang diperoleh setiap partikel. Apabila tidak terjadi perbaikan nilai fungsi objektif dalam sejumlah iterasi tertentu, diterapkan mekanisme *random restart* dengan membangkitkan kembali beberapa partikel sehingga proses pencarian tidak terjebak pada solusi optimum lokal dan tetap mampu mengeksplorasi ruang solusi secara lebih efektif. Posisi global best (Gbest) yang diperoleh pada akhir proses optimasi merepresentasikan konfigurasi batas interval internal terbaik berdasarkan fungsi objektif yang digunakan. Perbandingan batas interval sebelum dan sesudah optimasi menggunakan PSO disajikan pada Tabel 14.

Tabel 14. Perbandingan Batas Interval Sebelum dan Setelah Optimasi PSO

State	Sebelum Optimasi		Setelah Optimasi		Midpoint (m_i)
	LB_i	UB_i	LB_i	UB_i	
A_1	113,9500	132,1455	113,9500	130,9987	122,4743
A_2	132,1455	152,6889	130,9987	146,9999	138,9993
A_3	152,6889	170,3553	146,9999	179,0006	163,0002
A_4	170,3553	195,0500	179,0006	195,0500	187,0253

Tabel 14 menunjukkan bahwa optimasi menggunakan PSO menghasilkan konfigurasi batas interval fuzzy yang berbeda dari hasil partisi awal *K-Means*. Pergeseran batas interval internal menyebabkan lebar setiap interval mengalami penyesuaian sebagai hasil proses pencarian solusi terbaik berdasarkan fungsi objektif. Konfigurasi interval hasil optimasi tersebut selanjutnya digunakan pada tahapan fuzzifikasi, pembentukan relasi logika fuzzy, penyusunan matriks probabilitas Markov, dan peramalan.

3.3.2 Rekonstruksi Himpunan *Fuzzy* dan Matriks Probabilitas Transisi

Hasil optimasi menggunakan PSO menghasilkan konfigurasi batas interval fuzzy yang berbeda dari partisi awal *K-Means*. Perubahan interval tersebut menyebabkan proses fuzzifikasi dilakukan kembali sehingga frekuensi transisi antar *state* pada data latih perlu dibentuk ulang berdasarkan interval hasil optimasi. Frekuensi transisi antar *state* hasil fuzzifikasi ulang disajikan pada Tabel 15.

Tabel 15. Frekuensi Transisi Antar *State* Data Latih Optimasi PSO

State	A_1	A_2	A_3	A_4	Total
A_1	85	7	0	0	92
A_2	6	76	7	0	89
A_3	0	6	42	3	51
A_4	0	0	3	2	5

Tabel 15 menunjukkan bahwa sebagian besar perpindahan data masih terjadi pada *state* yang sama, yang ditunjukkan oleh frekuensi terbesar pada diagonal utama matriks. Perpindahan antar *state* umumnya terjadi pada *state* yang berdekatan, sedangkan transisi menuju *state* yang berjauhan tidak ditemukan. Pola tersebut menunjukkan bahwa perubahan batas interval hasil optimasi PSO tidak mengubah karakteristik pergerakan harga saham yang cenderung berlangsung secara bertahap, tetapi menghasilkan penyesuaian pada frekuensi transisi yang menjadi dasar pembentukan kembali matriks probabilitas transisi Markov.

Perhitungan probabilitas transisi dilakukan dengan prosedur yang sama seperti pada pembentukan matriks probabilitas transisi sebelum optimasi, yaitu membagi frekuensi setiap transisi terhadap total frekuensi pada *state* asal sesuai Persamaan (17). Probabilitas transisi yang berasal dari *state* A_1 dihitung sebagai berikut.

$$\begin{aligned} P(A_1, A_1) &= \frac{85}{92} = 0,9239 \\ P(A_1, A_2) &= \frac{7}{92} = 0,0761 \\ P(A_1, A_3) &= \frac{0}{92} = 0,0000 \\ P(A_1, A_4) &= \frac{0}{92} = 0,0000 \end{aligned}$$

Perhitungan probabilitas transisi yang berasal dari *state* A_2 , A_3 , dan A_4 dilakukan menggunakan prosedur yang sama dan disajikan secara lengkap pada Lampiran 7. Matriks probabilitas transisi hasil rekonstruksi tersebut digunakan dalam proses peramalan dan disajikan pada Persamaan (32).

$$P_{\text{PSO}} = \begin{bmatrix} 0,9239 & 0,0761 & 0,0000 & 0,0000 \\ 0,0674 & 0,8539 & 0,0787 & 0,0000 \\ 0,0000 & 0,1176 & 0,8235 & 0,0588 \\ 0,0000 & 0,0000 & 0,6000 & 0,4000 \end{bmatrix} \quad (32)$$

Matriks probabilitas transisi Markov pada Persamaan (32) menunjukkan bahwa probabilitas terbesar pada setiap baris masih berada pada diagonal utama matriks. Kondisi ini mengindikasikan bahwa kecenderungan data untuk tetap berada pada *state* yang sama masih lebih besar dibandingkan berpindah ke *state* lainnya. Meskipun batas interval telah mengalami penyesuaian melalui optimasi PSO, pola probabilitas transisi yang terbentuk tetap mencerminkan karakteristik pergerakan harga saham yang relatif stabil antar *state*.


3.3.3 Hasil Peramalan *Markov Weighted Fuzzy Time Series* Berbasis *K-Means* dan *Particle Swarm Optimization*

Hasil optimasi PSO diterapkan pada proses peramalan menggunakan metode MWFTS. Peramalan dilakukan terhadap data latih dengan menggunakan interval fuzz, *midpoint*, dan matriks probabilitas transisi hasil optimasi. Hasil peramalan pada data latih disajikan pada Tabel 16, sedangkan hasil perhitungan secara lengkap dapat dilihat pada Lampiran 8.

Tabel 16. Hasil Peramalan Data Latih MWFTS *K-Means* PSO

t	Tanggal	Y_t	State	$\hat{Y}_t$
1	01/10/2024	120	A_1	
2	02/10/2024	120	A_1	121,4456
3	03/10/2024	116	A_1	121,4456
4	04/10/2024	115	A_1	117,7499
5	07/10/2024	144	A_2	116,8260
⋮	⋮	⋮	⋮	⋮
234	29/09/2025	171	A_3	166,5308
235	30/09/2025	170	A_3	168,1779
236	01/10/2025	180	A_4	167,3543
237	02/10/2025	174	A_3	169,8001
238	03/10/2025	177	A_3	170,6485

Tabel 16 menyajikan hasil peramalan pada data latih menggunakan metode MWFTS berbasis *K-Means* dan PSO. Secara umum, nilai peramalan menunjukkan kecenderungan yang searah dengan pergerakan harga saham aktual pada setiap periode. Perbandingan antara data aktual dan hasil peramalan pada data latih disajikan pada Gambar 3 untuk memberikan gambaran visual mengenai kedekatan hasil peramalan terhadap data aktual.

**Gambar 3.** Plot Peramalan Data Latih menggunakan MWFTS-*K-Means*-PSO

Gambar 3 menunjukkan perbandingan antara data aktual dan hasil peramalan pada data latih menggunakan metode MWFTS berbasis *K-Means* dan PSO. Secara umum, kurva hasil peramalan mengikuti pola pergerakan harga saham aktual, baik pada saat terjadi kenaikan maupun penurunan harga. Selain itu, puncak dan lembah pergerakan harga juga berada pada periode yang relatif sama, sehingga hasil peramalan mampu mempertahankan karakteristik pergerakan data latih.

Parameter hasil optimasi tersebut selanjutnya diterapkan pada data uji. Hasil peramalan pada data uji disajikan pada Tabel 17, sedangkan hasil perhitungan secara lengkap terdapat pada Lampiran 9.

Tabel 17. Hasil Peramalan Data Uji MWFTS *K-Means* PSO

t	Tanggal	$Y_{(t)}$	State	$\hat{Y}_t$
239	06/10/2025	195	A_4	
240	07/10/2025	180	A_3	175,8001
241	08/10/2025	172	A_3	169,8001
242	09/10/2025	170	A_3	169,0014
243	10/10/2025	168	A_3	167,3543
⋮	⋮	⋮	⋮	⋮
294	22/12/2025	155	A_3	160,7661
295	23/12/2025	157	A_3	155,0014
296	24/12/2025	158	A_3	156,6485
297	29/12/2025	158	A_3	157,4720
298	30/12/2025	158	A_3	157,4720

Tabel 17 menunjukkan bahwa hasil peramalan pada data uji mampu mengikuti pola pergerakan harga saham PT Bukalapak.com Tbk. Dibandingkan metode MWFTS berbasis *K-Means* tanpa optimasi, hasil peramalan setelah penerapan PSO menghasilkan nilai estimasi yang lebih mendekati data aktual pada sebagian besar periode pengamatan. Kondisi tersebut menunjukkan bahwa optimasi PSO memberikan penyesuaian terhadap konfigurasi interval dan probabilitas transisi sehingga representasi pola data uji menjadi lebih baik.

3.3.4 Evaluasi Metode Markov Weighted Fuzzy Time Series Berbasis *K-Means* dan Particle Swarm Optimization

Penerapan PSO menghasilkan konfigurasi interval yang berbeda sehingga diperlukan evaluasi untuk mengetahui pengaruhnya terhadap hasil peramalan metode MWFTS berbasis *K-Means*. Evaluasi dilakukan pada data latih dan data uji menggunakan nilai MAPE, MAE, dan RMSE. Hasil pengukuran ukuran kesalahan tersebut disajikan pada Tabel 18.

Tabel 18. Hasil Evaluasi Metode MWFTS Berbasis *K-Means* PSO

Data	MAPE (%)	MAE	RMSE
Data Latih	2,3561%	3,3363	4,6464
Data Uji	1,4557%	2,4331	3,1032

Tabel 18 menunjukkan bahwa metode MWFTS berbasis *K-Means* dan PSO menghasilkan nilai MAPE sebesar 2,3561% pada data latih dan 1,4557% pada data uji. Nilai MAE dan RMSE pada data uji juga lebih rendah dibandingkan data latih, masing-masing sebesar 2,4331 dan 3,1032. Hasil tersebut menunjukkan bahwa penerapan PSO mampu meningkatkan kemampuan metode dalam menghasilkan nilai peramalan yang mendekati data aktual, baik pada data latih maupun data uji.

3.4 Evaluasi dan Perbandingan Akurasi Metode Peramalan


Evaluasi dan perbandingan akurasi dilakukan untuk mengetahui pengaruh optimasi PSO terhadap kinerja MWFTS berbasis *K-Means* dalam meramalkan harga saham PT Bukalapak.com Tbk. Sebagai pembandingan, metode yang diusulkan dibandingkan dengan MWFTS konvensional, MWFTS berbasis *K-Means*, serta MWFTS yang hanya dioptimasi menggunakan PSO. Rekapitulasi hasil evaluasi disajikan pada Tabel 19.

Tabel 19. Perbandingan Tingkat Akurasi Metode Peramalan pada Data Uji

Metode	MAPE	MAE	RMSE
MWFTS Konvensional	3,3620%	5,5348	6,0950
MWFTS – <i>K-Means</i>	3,1736%	5,2263	5,8953
MWFTS – PSO	2,6698%	4,3895	4,9651
MWFTS – <i>K-Means</i> – PSO	1,4557%	2,4331	3,1032

Tabel 19 menunjukkan seluruh metode yang dibandingkan menghasilkan nilai MAPE di bawah 10%, sehingga secara umum memiliki tingkat akurasi yang sangat baik. Namun, metode MWFTS berbasis *K-Means* yang dioptimasi menggunakan PSO memberikan performa terbaik dengan nilai MAPE sebesar 1,4557%, MAE sebesar 2,4331, dan RMSE sebesar 3,1032, yang merupakan nilai terendah di antara seluruh metode yang diuji. Perbaikan tersebut terjadi karena proses optimasi menggunakan PSO tidak hanya berupaya meminimumkan nilai kesalahan peramalan, tetapi juga menghasilkan rekonstruksi batas interval fuzzy yang lebih sesuai dengan karakteristik data. Selama proses optimasi, partikel melakukan eksplorasi ruang pencarian secara global untuk menemukan berbagai kandidat solusi, kemudian mengeksploitasi solusi terbaik yang telah diperoleh sehingga batas interval dapat disesuaikan secara bertahap menuju konfigurasi yang lebih optimal. Akibatnya, terjadi pergeseran batas interval dibandingkan hasil partisi awal yang dibentuk menggunakan *K-Means*. Pergeseran tersebut menunjukkan bahwa posisi interval hasil *K-Means* masih dapat diperbaiki sehingga representasi distribusi data menjadi lebih sesuai dengan pola historis harga saham.

Perbaikan interval berdampak pada proses fuzzifikasi dan pembentukan probabilitas transisi Markov yang lebih representatif terhadap dinamika perubahan harga saham. Dampaknya, nilai MAPE menurun dari 3,1736% menjadi 1,4557%, sedangkan nilai MAE dan RMSE juga mengalami penurunan menjadi masing-masing 2,4331 dan 3,1032. Adapun perbandingan pola antara data aktual dan hasil peramalan dari seluruh metode pada data uji disajikan pada Gambar 4.



Gambar 4. Perbandingan Hasil Peramalan Data Uji dengan Data Aktual

Gambar 4 menyajikan perbandingan antara hasil peramalan seluruh metode dengan data aktual harga saham PT Bukalapak.com Tbk pada fase pengujian. Secara visual, metode MWFTS berbasis *K-Means* yang dioptimasi menggunakan PSO, yang ditunjukkan oleh garis berwarna merah, menghasilkan pola peramalan yang paling mendekati data aktual dibandingkan metode lainnya. Hal ini menunjukkan bahwa kombinasi *K-Means* dan PSO mampu menghasilkan interval fuzzy yang lebih representatif, sehingga proses peramalan dapat mengikuti perubahan harga saham dengan lebih baik. Meskipun pada beberapa periode masih terdapat selisih antara nilai aktual dan hasil peramalan, pola pergerakan yang dihasilkan tetap menunjukkan kedekatan yang lebih baik dibandingkan metode pembandingan.

Nilai koefisien korelasi Pearson sebesar 0,7799 menunjukkan adanya hubungan linier positif yang cukup kuat antara hasil peramalan dan data aktual. Kondisi tersebut mengindikasikan bahwa perubahan hasil peramalan cenderung mengikuti arah pergerakan harga saham yang sebenarnya. Konsistensi antara nilai korelasi yang cukup kuat dan kedekatan pola hasil peramalan terhadap data aktual menunjukkan bahwa penerapan PSO mampu mengoptimasi metode MWFTS berbasis *K-Means* sehingga menghasilkan kinerja peramalan yang lebih baik dibandingkan sebelum proses optimasi.

BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, didapatkan kesimpulan sebagai berikut:

1. Peramalan harga saham PT Bukalapak.com Tbk menggunakan metode *Markov Weighted Fuzzy Time Series* (MWFTS) berbasis interval yang dibentuk *K-Means* menghasilkan nilai MAPE sebesar 3,1736%, MAE sebesar 5,2263, dan RMSE sebesar 5,8953 pada data pengujian. Hasil tersebut menunjukkan bahwa metode MWFTS berbasis *K-Means* mampu memberikan hasil peramalan dengan tingkat akurasi yang baik.
2. Peramalan harga saham PT Bukalapak.com Tbk menggunakan metode MWFTS berbasis *K-Means* yang dioptimalkan dengan *Particle Swarm Optimization* (PSO) menghasilkan nilai MAPE sebesar 1,4557%, MAE sebesar 2,4331, RMSE sebesar 3,1032, dan koefisien korelasi Pearson sebesar 0,7799 pada data pengujian. Optimasi menggunakan PSO menghasilkan penurunan nilai MAPE sebesar 1,7179%, MAE sebesar 2,7932, dan RMSE sebesar 2,7921 dibandingkan model sebelum optimasi, sehingga mampu meningkatkan akurasi peramalan harga saham PT Bukalapak.com Tbk.

4.2 Saran

Penelitian selanjutnya disarankan untuk mengembangkan metode MWFTS menggunakan orde dua atau orde yang lebih tinggi agar informasi dari lebih dari satu periode sebelumnya dapat dimanfaatkan dalam proses peramalan. Selain itu, optimasi dapat diperluas tidak hanya pada pembentukan interval fuzzy, tetapi juga pada parameter lain, seperti jumlah *cluster*, banyaknya himpunan fuzzy, maupun parameter PSO. Pengembangan lebih lanjut juga dapat dilakukan pada tahap pembentukan *cluster* dengan menerapkan metode inisialisasi centroid yang lebih terstruktur, seperti *K-Means++*, atau memanfaatkan algoritma metaheuristik untuk menentukan centroid awal. Pendekatan tersebut diharapkan mampu menghasilkan proses pengelompokan yang lebih stabil dan meningkatkan kualitas interval fuzzy yang terbentuk.

DAFTAR PUSTAKA

- Ahmed, M., Seraj, R., & Islam, S. M. S., 2020. The *K-Means* algorithm: A comprehensive survey and performance evaluation. *Electronics*, 9(8): 1295. <https://doi.org/10.3390/electronics9081295>
- Akhdan, A., & Fauzy, A., 2023. Pendekatan Rantai Markov Waktu Diskrit dalam Memprediksi Penurunan dan Kenaikan Jumlah Pelanggan Air Minum Baru PDAM Kota Surakarta. *Emerging Statistics and Data Science Journal*, 1(2): 309–319.
- Alwarid, A., & Sihabuddin, A., 2022. An absolute differences *K-Means* clustering approach on determining intervals to optimize *fuzzy* time series Markov chain model. *International Journal of Intelligent Engineering and Systems*, 15(1): 33–41. <https://doi.org/10.22266/IJIES2022.0228.04>
- Alyousifi, Y., Othman, M., Faye, I., Sokkalingam, R., & Silva, P. C. L., 2020. Markov weighted *fuzzy* time-series model based on an optimum partition method for forecasting air pollution. *International Journal of Fuzzy Systems*, 22(5): 1468–1486. <https://doi.org/10.1007/s40815-020-00841-w>
- Anggreani, D., Nurmisba, Setiawan, D., & Lukman, 2024. Optimization of *K-Means* Clustering Method by Using Elbow Method in Predicting Blood Requirement of Pelamonia Hospital Makassar. *Iota*, 4(3). <https://doi.org/10.31763/iota.v4i3.755>
- Arsha, I. M. R., Rihayana, I. G., & Swara, N. N. A. A. V., 2022. Estimasi nilai harga saham wajar PT. Bukalapak.com tbk saat melakukan ipo pada tahun 2021. *Jurnal Ilmiah Mahasiswa Akuntansi*, 13(2): 671-681.
- Azzahra, R., & Gusriani, N, 2021. Markov average-based weighted *fuzzy* time series model to predict PT Kimia Farma Tbk stock price. *Desimal: Jurnal Matematika*, 4(3): 285–294. <https://doi.org/10.24042/djm>
- Binekasri, R., 2025, 23 Oktober. *Bukalapak (BUKA) mau buyback saham Rp 410,7 miliar*. CNBC Indonesia. <https://www.cnbcindonesia.com/market/20251023172201-17-678707/bukalapak--buka--mau-buyback-saham-rp-4107-miliar>
- Bose, M., & Mali, K., 2019. Designing *fuzzy* time series forecasting models: A survey. *International Journal of Approximate Reasoning*, 111: 78–99. <https://doi.org/10.1016/j.ijar.2019.05.002>
- Bursa Efek Indonesia. 2026. IHSG Tembus 9.000 Berkat Dukungan Pemerintah dan Kepercayaan Investor. Siaran Pers No: 002/BEI.SPR/1-2026. Jakarta: PT Bursa Efek Indonesia.
- Chen, H., Gao, X., & Wu, Q., 2025. An enhanced *fuzzy* time series forecasting model integrating *fuzzy* c-means clustering, the principle of justifiable granularity, and particle swarm optimization. *Symmetry*, 17(5): 753. <https://doi.org/10.3390/sym17050753>
- Chen, S. M., 1996. Forecasting enrollments based on *fuzzy* time series. *Fuzzy Sets and Systems*, 81(3): 311–319.
- Chen, S. M., & Chen, C. D., 2011. Handling forecasting problems based on high-order *fuzzy* logical relationships. *Expert Systems with Applications*, 38(4): 3857–3864. <https://doi.org/10.1016/j.eswa.2010.09.046>

- Chen, S. M., & Chen, C. D., 2015. Handling forecasting problems based on high-order *fuzzy* time series and particle swarm optimization. *Expert Systems with Applications*, 42(9): 4252–4261. <https://doi.org/10.1016/j.eswa.2014.12.029>
- Cheng, C. H., & Chen, C. H., 2018. *Fuzzy* time series model based on weighted association rule for financial market forecasting. *Expert Systems*. <https://doi.org/10.1111/exsy.12271>
- Cholissodin, I., & Riyandani, E., 2016. Swarm intelligence (teori & case study). Universitas Brawijaya.
- Deng, C., Zhang, X., Huang, Y., & Bao, Y., 2021. Equipping seasonal exponential smoothing models with particle swarm optimization algorithm for electricity consumption forecasting. *Energies*, 14(13): 4036. <https://doi.org/10.3390/en14134036>
- Dewi, N. P., & Listiowarni, I., 2020. Implementasi Holt-Winters exponential smoothing untuk peramalan harga bahan pangan di Kabupaten Pamekasan. *Digital Zone*, 11(2): 219–231. <https://doi.org/10.31849/digitalzone.v11i2.4797>
- Dewi, D. A., Surono, S., Thinakaran, R., & Nurraihan, A., 2023. Hybrid *fuzzy* K-medoids and cat and mouse-based optimizer for Markov weighted *fuzzy* time series. *Symmetry*, 15(8): 1477. <https://doi.org/10.3390/sym15081477>
- Elmi, S., Yanti, R., Mardainis, & Asnal, H., 2025. Prediksi emisi CO2 di Indonesia menggunakan pendekatan hybrid ARIMA dan LSTM. *Jurnal Ilmiah BETRIK*, 16(2): 195–208.
- Fauziah, Ningsih, Y. I., & Setiarini, E., 2019. Analisis peramalan (forecasting) penjualan jasa pada Warnet Bulian City di Muara Bulian. *Eksis: Jurnal Ilmiah Ekonomi dan Bisnis*, 10(1): 61–67.
- Freitas, D., Lopes, L. G., & Morgado-Dias, F., 2020. Particle swarm optimisation: A historical review up to the current developments. *Entropy*, 22(3): 362. <https://doi.org/10.3390/e22030362>
- Frymaruwah, E., Andrian, P., & Tecoalu, M., 2024. Analisis kinerja keuangan dan strategi manajemen PT Bukalapak.com Tbk pra & pasca Initial Public Offering (IPO). *Owner*, 8(2): 1708–1721. <https://doi.org/10.33395/owner.v8i2.2039>
- Ghosh, S., 2025. Sector wise stock market volatility estimation. *International Journal of Business and Management Invention (IJBMI)*, 14(9): 18–26. <https://doi.org/10.35629/8028-14091826>
- Goodwin, P., & Lawton, R., 1999. On the asymmetry of the symmetric MAPE. *International Journal of Forecasting*, 15(4): 405–408.
- Habbe, A. H., & Darwis, A. M., 2024. Analysis of investor motivation to buy GOTO and BUKA shares. *Journal of Management, Economic and Financial*, 2(1).
- Hansun, S., 2012. Peramalan data IHSG menggunakan *fuzzy* time series. *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, 6(2): 79–88.
- Hariyanto, S., Sumanto, Y. D., Khabibah, S., & Zaenurrohman., 2023. Average-based *fuzzy* time series Markov chain based on frequency density partitioning. *Journal of Applied Mathematics*, 2023, 9319883. <https://doi.org/10.1155/2023/9319883>

- Hasibuan, R. A., Afendi, F. M., & Wigena, A. H., 2025. Perbandingan Metode Particle Swarm Optimization dan Artificial Bee Colony pada Support Vector Machine. *JEPIN (Jurnal Edukasi dan Penelitian Informatika)*, 11(1): 158–168.
- Huarng, K., 2001. Effective lengths of intervals to improve forecasting in *fuzzy* time series. *Fuzzy Sets and Systems*, 123(3): 387–394.
- Hyndman, R. J., & Koehler, A. B., 2006. *Another look at measures of forecast accuracy*. *International Journal of Forecasting*, 22(4): 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Ishak, A., Tambunan, R. H., & Gustia, D., 2020. Peramalan inflasi di Kota Gorontalo dengan menggunakan metode time series. *TALENTA Conference Series: Energy & Engineering (EE)*, 3(2). <https://doi.org/10.32734/ee.v3i2.966>
- Jain, A. K., 2010. Data clustering: 50 years beyond *K-Means*. *Pattern Recognition Letters*, 31(8): 651–666. <https://doi.org/10.1016/j.patrec.2009.09.011>
- Jilani, T. A., Burney, S. M. A., & Ardil, C., 2008. *Fuzzy* metric approach for *fuzzy* time series forecasting based on frequency density based partitioning. *International Journal of Computational Intelligence*, 4(2): 112–117.
- Jollyta, D., Efendi, S., Zarlis, M., & Mawengkang, H., 2019. Optimasi Cluster Pada Data Stunting: Teknik Evaluasi Cluster Sum of Square Error dan Davies Bouldin Index. *Prosiding Seminar Nasional Riset Information Science (SENARIS)*, 918–926.
- Kennedy, J. & Eberhart, R., 1995. Particle swarm optimization. *Proceedings of the International Conference on Neural Networks (ICNN'95)*, 4: 1942–1948. <https://doi.org/10.1109/ICNN.1995.488968>
- Kennedy, P. S. J., & Helena., 2024. Hubungan Persepsi Risiko dan Ekspektasi Return terhadap Minat Berinvestasi Mahasiswa di Pasar Modal. *IKRAITH-EKONOMIKA*, 7(2): 295–307. <https://doi.org/10.37817/ikraith-ekonomika.v7i2>
- Kim, H. Y., & Won, C. H., 2018. Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, 103: 25–37. <https://doi.org/10.1016/j.eswa.2018.03.002>
- Kumar, N., & Susan, S., 2021. Particle swarm optimization of partitions and *fuzzy* order for *fuzzy* time series forecasting of COVID-19. *Applied Soft Computing*, 110, 107611. <https://doi.org/10.1016/j.asoc.2021.107611>
- Kustodian Sentral Efek Indonesia., 2026. Statistik Pasar Modal Indonesia - Februari 2026. Jakarta: PT Kustodian Sentral Efek Indonesia
- Lewis, C. D., 1982. *Industrial and business forecasting methods: A practical guide to exponential smoothing and curve fitting*. Butterworth Scientific.
- Maharni, E., 2019. Pemilihan *fuzzy* time series Markov chain berbasis rata-rata dan *fuzzy* time series Markov chain dengan fungsi keanggotaan Gauss pada data tingkat inflasi Indonesia [Skripsi, Universitas Brawijaya].
- Makridakis, S., Wheelwright, S. C., & Hyndman, R. J., 1998. *Forecasting: Methods and applications* (3rd ed.). John Wiley & Sons.
- Maori, N. A., & Evanita., (2023). Metode Elbow Dalam Optimasi Jumlah Cluster Pada *K-Means* Clustering. *Jurnal SIMETRIS*, 14(2): 277–287.

- Marini, F., & Walczak, B., 2015. Particle swarm optimization (PSO). A tutorial. *Chemometrics and Intelligent Laboratory Systems*, 149: 153–165. <https://doi.org/10.1016/j.chemolab.2015.08.020>
- Mediaty., Habbe, A. H., & Darwis, A. M., 2024. Analysis of investor motivation to buy GOTO and BUKA shares. *Journal of Management, Economic and Financial*, 2(1): 13–22.
- Mukminin, U. S., Irawanto, B., Surarso, B., & Farikhin., 2021. *Fuzzy time series based on frequency density-based partitioning and K-Means clustering for forecasting exchange rate*. *Journal of Physics: Conference Series*, 1943(1): 012119. <https://doi.org/10.1088/1742-6596/1943/1/012119>
- Nurlela, S., Fanani, A., & Khaulasari, H., 2023. Harga minyak mentah WTI menggunakan metode *fuzzy time series* Markov chain. *Jurnal Fourier*, 12(1): 10–19. <https://doi.org/10.14421/fourier.2023.121.10-19>
- Ortiz-Arroyo, D., & Poulsen, J. R., 2018. A weighted *fuzzy time series* forecasting model. *Indian Journal of Science and Technology*, 11(27): 1–11. <https://doi.org/10.17485/ijst/2018/v11i27/130708>
- Oyelade, O. J., Oladipupo, O. O., & Obagbuwa, I. C., 2010. Application of *K-Means* clustering algorithm for prediction of students' academic performance. *International Journal of Computer Science and Information Security*, 7(1): 292–295.
- Pajriati, N. H., Kurniati, E., & Suhaedi, D., 2021. Penerapan metode average based *fuzzy time series* Lee untuk peramalan harga emas di PT. X. *Jurnal Riset Matematika*, 1(1): 73–81. <https://doi.org/10.29313/jrm.v1i1.221>
- Patale, S., & Sharma, A., 2025. Challenges and future trends in *fuzzy logic*: A comprehensive review. *International Journal of Fuzzy Mathematical Archive*, 24(1): 13–26. <https://doi.org/10.22457/ijfma.v24n1a02254>
- Prasetyo, A., 2024. Perbandingan Kinerja Metode Triple Exponential Smoothing dan ARIMA pada Peramalan Saham. Skripsi/Repository Universitas Malikussaleh / Jurnal APTII
- Pratama, R., Hannany, Z., & Rosdiana, N., 2025, 29 Oktober. *BUKA raih laba Rp2,9 triliun dari semula merugi Rp597,3 miliar*. IDN Financials. <https://www.idnfinancials.com/id/news/58278/buka-raih-laba-rp2-9-triliun-dari-semula-merugi-rp597-3-miliar>
- Pribadi, W. W., Yunus, A., & Wiguna, A. S., 2022. Perbandingan metode *K-Means* Euclidean distance dan Manhattan distance pada penentuan zonasi COVID-19 di Kabupaten Malang. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 6(2).
- Putri Z., R. W., Hartuti, P. M., & Maududi, R. A., 2025. Penerapan algoritma *Fuzzy Time Series* Chen untuk memprediksi harga komoditas kebutuhan pokok. *Prosiding Seminar Nasional Sains (SINASIS)*, 6(1).
- Raihan, A. M., Windijarto, & Saksana, J. C., 2023. Analysis of stock price index volatility in Indonesia using macroeconomic variables and global economic uncertainty index. *Assets: Jurnal Ekonomi, Manajemen dan Akuntansi*, 13(1). <https://doi.org/10.24252/assets.v13i1.37616>
- Ramandha, D. A., Lubis, A. F., Nst, M. A., Hamdi, I., & Kelvin., 2020. Analisa pentingnya rentang waktu dalam peramalan time series. *TALENTA*

- Conference Series: Energy & Engineering (EE), 3(2).
<https://doi.org/10.32734/ee.v3i2.986>
- Rantina, M., Santoso, G., & Wilarso., 2025. Analisis pengaruh faktor eksternal terhadap perilaku investor di pasar modal. *Jurnal Manajemen Inovasi Terapan*, 1(2): 92–102. <https://doi.org/10.37373/ejm.v1i2.1704>
- Ridduwan, M., Hijawati., Yanuarsi, S., & Husnulwati, S., 2025. Saham sebagai instrumen dalam kebijakan pasar modal di Indonesia. *Solusi*, 23(1): 82–88. <https://doi.org/10.36546/solusi.v23i1.1410>
- Rifandi, A. D. A., Setiawan, B. D., & Tibyani., 2018. Optimasi interval *fuzzy* time series menggunakan particle swarm optimization pada peramalan permintaan darah: Studi kasus Unit Transfusi Darah Cabang - PMI Kota Malang. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 2(7): 2770–2779.
- Rubio, A., Bermúdez, J. D., & Vercher, E., 2016. Forecasting portfolio returns using weighted *fuzzy* time series methods. *International Journal of Approximate Reasoning*, 75: 1–12. <https://doi.org/10.1016/j.ijar.2016.03.007>
- Rubio-León, J., Rubio-Cienfuegos, J., Vidal-Silva, C., Cárdenas-Cobo, J., & Duarte, V., 2023. Applying *fuzzy* time series for developing forecasting electricity demand models. *Mathematics*, 11(17): 3667. <https://doi.org/10.3390/math11173667>
- Rusminto, M. Z., Wibowo, S. A., & Wahyuni, F. S., 2024. Peramalan harga saham menggunakan metode ARIMA (Autoregressive Integrated Moving Average) time series. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 8(2).
- Saleena, A. J., Jessy, J. C., & Lineesh, M. C., 2024. Forecasting non-stationary time series using deep learning in a *fuzzy* time series framework and its application to stock markets. *Journal of Advances in Applied & Computational Mathematics*. 11(6): 100-118. <https://doi.org/10.15377/2409-5761.2024.11.6>
- Singh, S. R., 2007. A simple time variant method for *fuzzy* time series forecasting. *Cybernetics and Systems*, 38(3): 305–321. <https://doi.org/10.1080/01969720601187354>
- Song, Q., & Chissom, B. S., 1993. Forecasting enrollments with *fuzzy* time series—Part I. *Fuzzy Sets and Systems*, 54(1): 1–9. [https://doi.org/10.1016/0165-0114\(93\)90355-L](https://doi.org/10.1016/0165-0114(93)90355-L)
- Sudono, I., Utami, W., & Lestari, S., 2013. Pengelompokan produksi padi nasional dengan pendekatan data mining konsep *K-Means* clustering. *Jurnal Irigasi*, 8(2): 86–97.
- Sulaiman, A. I. C., 2026. Analisis perbandingan metode ARIMA dan Holt untuk peramalan harga saham PT Telkom Indonesia (TLKM). *Repeater: Publikasi Teknik Informatika dan Jaringan*, 4(1): 1–7. <https://doi.org/10.62951/repeater.v4i1.762>
- Surono, S., & Siregar, N. S., 2022. The new approach optimization Markov weighted *fuzzy* time series using particle swarm algorithm. *Journal of Education and Science*, 31(2): 42–54. <https://doi.org/10.33899/edusj.2022.133052.1217>
- Surono, S., Goh, K. W., Onn, C. W., Nurraihan, A., Siregar, N. S., Saeid, A. B., & Wijaya, T. T., 2022. Optimization of Markov weighted *fuzzy* time series forecasting using genetic algorithm (GA) and particle swarm optimization

- (PSO). *Emerging Science Journal*, 6(6): 1375–1393. <https://doi.org/10.28991/ESJ-2022-06-06-010>
- Susilo, F., 2006. Himpunan dan logika kabur serta aplikasinya. Graha Ilmu.
- Tsaur, R. C., 2012. A *fuzzy* time series-Markov chain model with an application to forecast the exchange rate between the Taiwan and US dollar. *International Journal of Innovative Computing, Information and Control*, 8(7): 4931–4942.
- Umargono, E., Suseno, J. E., & Gunawan S. K., V., 2020. *K-Means* clustering optimization using the elbow method and early centroid determination based on mean and median formula. *Advances in Social Science, Education and Humanities Research*, 474: 121–129.
- Virgianti, V., Martha, S., & Imro'ah, N., 2021. Penerapan *fuzzy* time series Chen average based pada peramalan curah hujan. *Buletin Ilmiah Math. Stat. dan Terapannya (Bimaster)*, 10(4): 485–494.
- Wajdi, S., 2022. Pemodelan harga saham BSI dengan metode *fuzzy* time series Markov chain. *Jurnal Pendidikan Tambusai*, 6(1): 1715–1724.
- Wang, D., Tan, D., & Liu, L., 2017. Particle swarm optimization algorithm: An overview. *Soft Computing*, 22(2): 387–408. <https://doi.org/10.1007/s00500-016-2474-6>
- Wang, J., 2021. The analysis of the financial market in China. *Academic Journal of Business & Management*, 3(2): 58–60. <https://doi.org/10.25236/AJBM.2021.030211>
- Xie, J., 2024. The Impact of Investor Psychology on Investment Decisions. *Proceedings of ICEMGD 2024 Workshop: Innovative Strategies in Microeconomic Business Management*, 101–109. <https://doi.org/10.54254/2754-1169/114/2024BJ0168>
- Yang, Q., Bian, Y.-W., Gao, X.-D., Xu, D.-D., Lu, Z.-Y., Jeon, S.-W., & Zhang, J., 2022. Stochastic triad topology based particle swarm optimization for global numerical optimization. *Mathematics*, 10, 1032. <https://doi.org/10.3390/math10071032>
- Yu, H. K., 2005. Weighted *fuzzy* time series models for TAIEX forecasting. *Physica A: Statistical Mechanics and its Applications*, 349(3–4): 609–624. <https://doi.org/10.1016/j.physa.2004.11.006>
- Yuan, C., & Yang, H., 2019. Research on K-value selection method of *K-Means* clustering algorithm. *J*, 2(2): 226–235. <https://doi.org/10.3390/j2020016>
- Zadeh, L. A., 1965. *Fuzzy* sets. *Information and Control*, 8(3): 338–353. [https://doi.org/10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X)
- Zhang, Z., & Zhu, Q., 2012. *Fuzzy* time series forecasting based on *K-Means* clustering. *Open Journal of Applied Sciences*, (Supplement), 100–103.
- Zhang, K., Yuan, F., Jiang, Y., Mao, Z., Zuo, Z., & Peng, Y., 2025. A particle swarm optimization-guided ivy algorithm for global optimization problems. *Biomimetics*, 10(5): 342. <https://doi.org/10.3390/biomimetics10050342>

LAMPIRAN

Lampiran 1. Data Harga Penutupan Saham Harian PT Bukalapak.Com Tbk

t	Tanggal	Harga Saham (Rp)
1	01/10/2024	120
2	02/10/2024	120
3	03/10/2024	116
4	04/10/2024	115
5	07/10/2024	144
6	08/10/2024	147
7	09/10/2024	139
8	10/10/2024	129
9	11/10/2024	136
10	14/10/2024	131
11	15/10/2024	133
12	16/10/2024	135
13	17/10/2024	133
14	18/10/2024	132
15	21/10/2024	135
16	22/10/2024	134
17	23/10/2024	133
18	24/10/2024	140
19	25/10/2024	135
20	28/10/2024	131
21	29/10/2024	131
22	30/10/2024	130
23	31/10/2024	128
24	01/11/2024	125
25	04/11/2024	120
26	05/11/2024	117
27	06/11/2024	118
28	07/11/2024	118
29	08/11/2024	118
30	11/11/2024	120
31	12/11/2024	118
32	13/11/2024	119
33	14/11/2024	124
34	15/11/2024	119
⋮	⋮	⋮
296	24/12/2025	158
297	29/12/2025	158
298	30/12/2025	158

Lampiran 2. Sintaks Algoritma *K-Means*

```
# --- 1) Load & Split Data ---
df <- read_excel(path_data, sheet = sheet_name)
Y_all <- as.numeric(df[[kolom_y]])

# Membersihkan baris kosong
Y_all <- Y_all[!is.na(Y_all)]

Umin_raw <- min(Y_all) - 0.05
Umax_raw <- max(Y_all) + 0.05

# 1. Mengambil Inisiasi Awal (Titik Start Iterasi 0)
set.seed(SEED_KMEANS)
inisiasi_awal <- Y_train[sample.int(length(Y_train), FIXED_K)]
print(sort(inisiasi_awal))

# 2. Proses Konvergen K-Means
set.seed(SEED_KMEANS)
km_res <- kmeans(Y_train, centers = FIXED_K, nstart = 1,
algorithm = "Lloyd")
centers_final <- sort(km_res$centers[,1])
cat("2. Pusat Cluster Akhir setelah konvergen (Cek hasil Excel
Anda):\n")
print(centers_final)

# --- 3. MENGHITUNG BATAS LUAR TERKUNCI ---
pts_baseline <- (centers_final[1:(FIXED_K-1)] +
centers_final[FIXED_K]) / 2
lb1_base <- centers_final[1] - (pts_baseline[1] -
centers_final[1])
ubk_base <- centers_final[FIXED_K] + (centers_final[FIXED_K] -
pts_baseline[length(pts_baseline)])

LB1_FIXED <- min(Umin_raw, lb1_base)
UBK_FIXED <- max(Umax_raw, ubk_base)

tabel_baseline <- data.frame(
  State = paste0("A", 1:FIXED_K),
  LB    = round(c(LB1_FIXED, pts_baseline), 4),
  UB    = round(c(pts_baseline, UBK_FIXED), 4)
)
print(tabel_baseline)
```

Lampiran 3. Hasil Fuzzifikasi dan FLR Data Latih

t	Tanggal	Harga Saham (Rp)	State	FLR
1	01/10/2024	120	A_1	
2	02/10/2024	120	A_1	$A_1 \rightarrow A_1$
3	03/10/2024	116	A_1	$A_1 \rightarrow A_1$
4	04/10/2024	115	A_1	$A_1 \rightarrow A_1$
5	07/10/2024	144	A_2	$A_1 \rightarrow A_1$
6	08/10/2024	147	A_2	$A_2 \rightarrow A_2$
7	09/10/2024	139	A_2	$A_2 \rightarrow A_2$
8	10/10/2024	129	A_1	$A_2 \rightarrow A_1$
9	11/10/2024	136	A_2	$A_1 \rightarrow A_2$
10	14/10/2024	131	A_1	$A_2 \rightarrow A_1$
11	15/10/2024	133	A_1	$A_1 \rightarrow A_1$
12	16/10/2024	135	A_2	$A_1 \rightarrow A_2$
13	17/10/2024	133	A_1	$A_2 \rightarrow A_1$
14	18/10/2024	132	A_1	$A_1 \rightarrow A_1$
15	21/10/2024	135	A_2	$A_1 \rightarrow A_2$
16	22/10/2024	134	A_1	$A_2 \rightarrow A_1$
17	23/10/2024	133	A_1	$A_1 \rightarrow A_1$
18	24/10/2024	140	A_2	$A_1 \rightarrow A_2$
19	25/10/2024	135	A_2	$A_2 \rightarrow A_2$
20	28/10/2024	131	A_1	$A_2 \rightarrow A_1$
21	29/10/2024	131	A_1	$A_1 \rightarrow A_1$
22	30/10/2024	130	A_1	$A_1 \rightarrow A_1$
23	31/10/2024	128	A_1	$A_1 \rightarrow A_1$
24	01/11/2024	125	A_1	$A_1 \rightarrow A_1$
25	04/11/2024	120	A_1	$A_1 \rightarrow A_1$
26	05/11/2024	117	A_1	$A_1 \rightarrow A_1$
27	06/11/2024	118	A_1	$A_1 \rightarrow A_1$
28	07/11/2024	118	A_1	$A_1 \rightarrow A_1$
29	08/11/2024	118	A_1	$A_1 \rightarrow A_1$
30	11/11/2024	120	A_1	$A_1 \rightarrow A_1$
31	12/11/2024	118	A_1	$A_1 \rightarrow A_1$
32	13/11/2024	119	A_1	$A_1 \rightarrow A_1$
33	14/11/2024	124	A_1	$A_1 \rightarrow A_1$
34	15/11/2024	119	A_1	$A_1 \rightarrow A_1$
:	:	:	:	:
236	01/10/2025	177	A_4	$A_3 \rightarrow A_4$
237	02/10/2025	195	A_4	$A_4 \rightarrow A_4$
238	03/10/2025	180	A_4	$A_4 \rightarrow A_3$

Lampiran 4. Perhitungan Matriks Probabilitas Transisi Markov MWFTS *K-Means*1. State A_1

$$P(A_1, A_1) = \frac{94}{103} = 0,9126$$

$$P(A_1, A_2) = \frac{9}{103} = 0,0874$$

$$P(A_1, A_3) = \frac{0}{103} = 0,0000$$

$$P(A_1, A_4) = \frac{0}{103} = 0,0000$$

2. State A_2

$$P(A_2, A_1) = \frac{8}{92} = 0,0870$$

$$P(A_2, A_2) = \frac{82}{92} = 0,8913$$

$$P(A_2, A_3) = \frac{2}{92} = 0,0217$$

$$P(A_2, A_4) = \frac{0}{92} = 0,0000$$

3. State A_3

$$P(A_3, A_1) = \frac{0}{12} = 0,0000$$

$$P(A_3, A_2) = \frac{1}{12} = 0,0833$$

$$P(A_3, A_3) = \frac{6}{12} = 0,5000$$

$$P(A_3, A_4) = \frac{5}{12} = 0,4167$$

4. State A_4

$$P(A_4, A_1) = \frac{0}{30} = 0,0000$$

$$P(A_4, A_2) = \frac{1}{30} = 0,0333$$

$$P(A_4, A_3) = \frac{4}{30} = 0,1333$$

$$P(A_4, A_4) = \frac{26}{30} = 0,8667$$

Lampiran 5. Hasil Perhitungan Peramalan Data Latih MWFTS *K-Means*

t	Tanggal	$Y_{(t)}$	State	$\hat{Y}_{(t)}$
1	01/10/2024	120	A_1	
2	02/10/2024	120	A_1	122,5645
3	03/10/2024	116	A_1	122,5645
4	04/10/2024	115	A_1	118,9855
5	07/10/2024	144	A_2	118,0908
6	08/10/2024	147	A_2	141,8054
7	09/10/2024	139	A_2	144,3239
8	10/10/2024	129	A_1	137,6079
9	11/10/2024	136	A_2	130,6171
10	14/10/2024	131	A_1	135,0894
11	15/10/2024	133	A_1	132,4066
12	16/10/2024	135	A_2	134,1961
13	17/10/2024	133	A_1	134,2498
14	18/10/2024	132	A_1	134,1961
15	21/10/2024	135	A_2	133,3013
16	22/10/2024	134	A_1	134,2498
17	23/10/2024	133	A_1	135,0908
18	24/10/2024	140	A_2	134,1961
19	25/10/2024	135	A_2	138,4474
20	28/10/2024	131	A_1	134,2498
21	29/10/2024	131	A_1	132,4066
22	30/10/2024	130	A_1	132,4066
23	31/10/2024	128	A_1	131,5118
24	01/11/2024	125	A_1	129,7224
25	04/11/2024	120	A_1	127,0382
26	05/11/2024	117	A_1	122,5645
27	06/11/2024	118	A_1	119,8803
28	07/11/2024	118	A_1	120,775
29	08/11/2024	118	A_1	120,775
30	11/11/2024	120	A_1	120,775
31	12/11/2024	118	A_1	122,5645
32	13/11/2024	119	A_1	120,775
33	14/11/2024	124	A_1	121,6697
34	15/11/2024	119	A_1	126,1434
⋮	⋮	⋮	⋮	⋮
236	01/10/2025	180	A_4	173,9026
237	02/10/2025	174	A_3	174,0257
238	03/10/2025	177	A_4	176,4026

Lampiran 6. Hasil Perhitungan Peramalan Data Uji MWFTS *K-Means*

t	Tanggal	$Y_{(t)}$	State	$\hat{Y}_{(t)}$
239	06/10/2025	195	A_4	
240	07/10/2025	180	A_3	183,1924
241	08/10/2025	172	A_3	174,0257
242	09/10/2025	170	A_3	175,1526
243	10/10/2025	168	A_3	173,9026
244	13/10/2025	168	A_3	172,6526
245	14/10/2025	162	A_3	172,6526
246	15/10/2025	161	A_3	168,9026
247	16/10/2025	168	A_3	168,2776
248	17/10/2025	168	A_3	172,6526
249	20/10/2025	168	A_3	172,6526
250	21/10/2025	166	A_3	172,6526
251	22/10/2025	162	A_3	171,4026
252	23/10/2025	169	A_3	168,9026
253	24/10/2025	165	A_3	173,2776
254	27/10/2025	168	A_3	170,7776
255	28/10/2025	169	A_3	172,6526
256	29/10/2025	168	A_3	173,2776
257	30/10/2025	168	A_3	172,6526
258	31/10/2025	168	A_3	172,6526
259	03/11/2025	169	A_3	172,6526
260	04/11/2025	167	A_3	173,2776
261	05/11/2025	164	A_3	172,0276
262	06/11/2025	165	A_3	170,1526
263	07/11/2025	166	A_3	170,7776
264	10/11/2025	165	A_3	171,4026
265	11/11/2025	168	A_3	170,7776
266	12/11/2025	173	A_3	172,6526
267	13/11/2025	169	A_3	175,7776
268	14/11/2025	167	A_3	173,2776
269	17/11/2025	169	A_3	172,0276
270	18/11/2025	166	A_3	173,2776
271	19/11/2025	167	A_3	171,4026
272	20/11/2025	167	A_3	172,0276
⋮	⋮	⋮	⋮	⋮
296	24/12/2025	158	A_3	165,7776
297	29/12/2025	158	A_3	166,4026
298	30/12/2025	158	A_3	166,4026

Lampiran 7. Perhitungan Matriks Probabilitas Transisi Markov MWFTS *K-Means* PSO

1. State A_1

$$P(A_1, A_1) = \frac{85}{92} = 0,9239$$

$$P(A_1, A_2) = \frac{7}{92} = 0,0761$$

$$P(A_1, A_3) = \frac{0}{92} = 0,0000$$

$$P(A_1, A_4) = \frac{0}{92} = 0,0000$$

2. State A_2

$$P(A_2, A_1) = \frac{6}{89} = 0,0674$$

$$P(A_2, A_2) = \frac{76}{89} = 0,8539$$

$$P(A_2, A_3) = \frac{7}{89} = 0,0787$$

$$P(A_2, A_4) = \frac{0}{89} = 0,0000$$

3. State A_3

$$P(A_3, A_1) = \frac{0}{51} = 0,0000$$

$$P(A_3, A_2) = \frac{6}{51} = 0,1176$$

$$P(A_3, A_3) = \frac{42}{51} = 0,8235$$

$$P(A_3, A_4) = \frac{3}{51} = 0,0588$$

4. State A_4

$$P(A_4, A_1) = \frac{0}{5} = 0,0000$$

$$P(A_4, A_2) = \frac{0}{5} = 0,0000$$

$$P(A_4, A_3) = \frac{3}{5} = 0,6000$$

$$P(A_4, A_4) = \frac{2}{5} = 0,4000$$

Lampiran 8. Hasil Peramalan Data Latih MWFTS Berbasis *K-Means-PSO*

t	Tanggal	$Y_{(t)}$	State	$\hat{Y}_{(t)}$
1	01/10/2024	120	A_1	
2	02/10/2024	120	A_1	121,4458
3	03/10/2024	116	A_1	121,4458
4	04/10/2024	115	A_1	117,7502
5	07/10/2024	144	A_2	116,8263
6	08/10/2024	147	A_3	144,0445
7	09/10/2024	139	A_2	148,3979
8	10/10/2024	129	A_1	139,7750
9	11/10/2024	136	A_2	129,7609
10	14/10/2024	131	A_2	137,2133
11	15/10/2024	133	A_2	132,9438
12	16/10/2024	135	A_2	134,6516
13	17/10/2024	133	A_2	136,3594
14	18/10/2024	132	A_2	134,6516
15	21/10/2024	135	A_2	133,7977
16	22/10/2024	134	A_2	136,3594
17	23/10/2024	133	A_2	135,5055
18	24/10/2024	140	A_2	134,6516
19	25/10/2024	135	A_2	140,6289
20	28/10/2024	131	A_2	136,3594
21	29/10/2024	131	A_2	132,9438
22	30/10/2024	130	A_1	132,9438
23	31/10/2024	128	A_1	130,6848
24	01/11/2024	125	A_1	128,8370
25	04/11/2024	120	A_1	126,0653
26	05/11/2024	117	A_1	121,4458
27	06/11/2024	118	A_1	118,6741
28	07/11/2024	118	A_1	119,5980
29	08/11/2024	118	A_1	119,5980
30	11/11/2024	120	A_1	119,5980
31	12/11/2024	118	A_1	121,4458
32	13/11/2024	119	A_1	119,5980
33	14/11/2024	124	A_1	120,5219
34	15/11/2024	119	A_3	125,1414
⋮	⋮	⋮	⋮	⋮
236	01/10/2025	180	A_4	167,3384
237	02/10/2025	174	A_3	169,8001
238	03/10/2025	177	A_3	170,6324

Lampiran 9. Hasil Peramalan Data Uji MWFTS Berbasis *K-Means-PSO*

t	Tanggal	$Y_{(t)}$	State	$\hat{Y}_{(t)}$
239	06/10/2025	195	A_4	
240	07/10/2025	180	A_3	175,8001
241	08/10/2025	172	A_3	169,8001
242	09/10/2025	170	A_3	168,9854
243	10/10/2025	168	A_3	167,3384
244	13/10/2025	168	A_3	165,6914
245	14/10/2025	162	A_3	165,6914
246	15/10/2025	161	A_3	160,7504
247	16/10/2025	168	A_3	159,9269
248	17/10/2025	168	A_3	165,6914
249	20/10/2025	168	A_3	165,6914
250	21/10/2025	166	A_3	165,6914
251	22/10/2025	162	A_3	164,0444
252	23/10/2025	169	A_3	160,7504
253	24/10/2025	165	A_3	166,5149
254	27/10/2025	168	A_3	163,2209
255	28/10/2025	169	A_3	165,6914
256	29/10/2025	168	A_3	166,5149
257	30/10/2025	168	A_3	165,6914
258	31/10/2025	168	A_3	165,6914
259	03/11/2025	169	A_3	165,6914
260	04/11/2025	167	A_3	166,5149
261	05/11/2025	164	A_3	164,8679
262	06/11/2025	165	A_3	162,3974
263	07/11/2025	166	A_3	163,2209
264	10/11/2025	165	A_3	164,0444
265	11/11/2025	168	A_3	163,2209
266	12/11/2025	173	A_3	165,6914
267	13/11/2025	169	A_3	169,8089
268	14/11/2025	167	A_3	166,5149
269	17/11/2025	169	A_3	164,8679
270	18/11/2025	166	A_3	166,5149
271	19/11/2025	167	A_3	164,0444
272	20/11/2025	167	A_3	164,8679
⋮	⋮	⋮	⋮	⋮
296	24/12/2025	158	A_3	156,6329
297	29/12/2025	158	A_3	157,4564
298	30/12/2025	158	A_3	157,4564

Lampiran 10. Sintaks MWFTS *K-Means* dan Optimasi PSO

```
# --- 1. FUNGSI UTAMA PERAMALAN MWFTS ---
get_mwfts_forecast <- function(centers, internal_pts, Y_data,
n_tr, lbl_fix, ubk_fix) {
  pts <- sort(internal_pts)
  K_int <- length(centers)
  m <- (c(lbl_fix, pts) + c(pts, ubk_fix)) / 2
  # Fuzzifikasi berdasarkan batas interval (pts)
  all_s_idx <- pmax(1, pmin(K_int, findInterval(Y_data, c(-Inf,
pts, Inf))))
  # Pembentukan Matriks Probabilitas Transisi
  M_mat <- matrix(0, K_int, K_int)
  for(t in 1:(n_tr-1)) {
    M_mat[all_s_idx[t], all_s_idx[t+1]] <- M_mat[all_s_idx[t],
all_s_idx[t+1]] + 1
  }
  P_mat <- M_mat / rowSums(M_mat)
  P_mat[is.nan(P_mat)] <- 0
  for(r in 1:K_int) if(sum(M_mat[r,]) == 0) P_mat[r,] <- 1/K_int
  # Perhitungan Prediksi (Defuzzifikasi)
  forecasts <- rep(NA, length(Y_data))
  for(t in 1:(length(Y_data)-1)) {
    forecasts[t+1] <- sum(P_mat[all_s_idx[t], ] * m) + (Y_data[t]
- m[all_s_idx[t]])
  }
  return(forecasts)}
# --- 2. FUNGSI OBJEKTIF (FITNESS) EVALUASI MAPE ---
fitness_pso <- function(pts_internal) {
  # Menggunakan pusat kluster (centers_final) dari hasil iterasi
K-Means sebelumnya
  f <- get_mwfts_forecast(centers_final, pts_internal, Y_train,
n_train, LB1_FIXED, UBK_FIXED)
  mape <- mean(abs((Y_train[2:n_train] -
f[2:n_train])/Y_train[2:n_train]), na.rm=TRUE)*100
  return(mape)}
# --- 3. INISIALISASI PARTICLE SWARM OPTIMIZATION (PSO) ---
set.seed(111)
n_part <- 50
max_iter <- 100
n_dim <- FIXED_K - 1
X <- matrix(0, n_part, n_dim) # Matriks Posisi
V <- matrix(0, n_part, n_dim) # Matriks Kecepatan
X[1, ] <- pts_baseline
for(i in 2:n_part) {
  for(j in 1:n_dim) X[i, j] <- runif(1, centers_final[j],
centers_final[j+1])
  X[i, ] <- sort(X[i, ])
}
# Evaluasi Nilai Fitness Awal

Pbest_X <- X
Pbest_MAPE <- sapply(1:n_part, function(i) fitness_pso(X[i, ]))
Gbest_X <- Pbest_X[which.min(Pbest_MAPE), ]
Gbest_MAPE <- min(Pbest_MAPE)
```

Lampiran 10. (Lanjutan) Sintaks MWFTS *K-Means* dan Optimasi PSO

```
# --- 4. PROSES ITERASI OPTIMASI (PENURUNAN MAPE) ---
for(iter in 1:max_iter) {
  w <- 0.9 - (0.5 * (iter/max_iter)) # Bobot inersia dinamis
  (menurun seiring iterasi)
  for(i in 1:n_part) {
    # Pembaruan Kecepatan (Velocity) dan Posisi (Position)
    Partikel
    r1 <- runif(n_dim); r2 <- runif(n_dim)
    V[i, ] <- (w * V[i, ]) + (2 * r1 * (Pbest_X[i, ] - X[i, ])) + (2
* r2 * (Gbest_X - X[i, ]))
    X[i, ] <- sort(X[i, ] + V[i, ])
    # Penanganan Batas Ruang Pencarian (Constraint)
    for(j in 1:n_dim) {
      if(X[i, j] < centers_final[j]) X[i, j] <- centers_final[j] +
0.001
      if(X[i, j] > centers_final[j+1]) X[i, j] <-
centers_final[j+1] - 0.001
    }
    # Pembaruan Posisi Terbaik Individu (Pbest) dan Global (Gbest)
    curr_fit <- fitness_pso(X[i, ])
    if(curr_fit < Pbest_MAPE[i]) {
      Pbest_X[i, ] <- X[i, ]
      Pbest_MAPE[i] <- curr_fit
    }
  }
  if(min(Pbest_MAPE) < Gbest_MAPE) {
    Gbest_X <- Pbest_X[which.min(Pbest_MAPE), ]
    Gbest_MAPE <- min(Pbest_MAPE)
  }
}

# --- 5. PREDIKSI AKHIR MENGGUNAKAN HASIL OPTIMASI PSO ---

# Gbest_X berisi batas interval paling optimal yang menghasilkan
MAPE terendah
prediksi_optimal <- get_mwfts_forecast(centers_final, Gbest_X,
Y_all, n_train, LB1_FIXED, UBK_FIXED)
```