

**PENERAPAN MODEL VECTOR AUTOREGRESSIVE WITH EXOGENOUS
VARIABLES – GENERALIZED SPACE TIME AUTOREGRESSIVE
PADA DATA INFLASI ANTARPROVINSI DI PULAU JAWA
TAHUN 2015–2024**



**DIAN AINURRIDHA
H051221085**



**PROGRAM STUDI STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PENERAPAN MODEL *VECTOR AUTOREGRESSIVE WITH EXOGENOUS
VARIABLES – GENERALIZED SPACE TIME AUTOREGRESSIVE*
PADA DATA INFLASI ANTARPROVINSI DI PULAU JAWA
TAHUN 2015–2024**

**DIAN AINURRIDHA
H051221085**



**PROGRAM STUDI STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PENERAPAN MODEL VECTOR AUTOREGRESSIVE WITH EXOGENOUS
VARIABLES – GENERALIZED SPACE TIME AUTOREGRESSIVE
PADA DATA INFLASI ANTARPROVINSI DI PULAU JAWA
TAHUN 2015–2024**

DIAN AINURRIDHA
H051221085

Skripsi

Diajukan sebagai salah satu syarat memperoleh gelar Sarjana Statistika

Program Studi Statistika

pada

**PROGRAM STUDI STATISTIKA
DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

SKRIPSI

PENERAPAN MODEL *VECTOR AUTOREGRESSIVE WITH EXOGENOUS VARIABLES* – *GENERALIZED SPACE TIME AUTOREGRESSIVE* PADA DATA INFLASI ANTARPROVINSI DI PULAU JAWA TAHUN 2015–2024

yang disusun dan diajukan oleh

DIAN AINURRIDHA
H051221085

Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana Statistika pada 15 Juli 2026
dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Statistika
Departemen Statistika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:
Pembimbing tugas akhir,



Sitti Sahriman S.Si., M.Si.
NIP 198810182015042002

Mengetahui:
Ketua Program Studi,



Dr. Anna Islamiyati, S.Si., M.Si.
NIP 19770808 2005012002

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "*Penerapan Model Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive* pada Data Inflasi Antarprovinsi di Pulau Jawa Tahun 2015–2024" adalah benar karya saya dengan arahan dari pembimbing Sitti Sahriman, S. Si., M.Si. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 15 Juli 2026



DIAN AINURRIDHA
H051221085

UCAPAN TERIMA KASIH

Puji dan syukur penulis panjatkan ke hadirat Allah *Subhanahu Wa Ta'ala* atas segala limpahan rahmat, hidayah, dan karunia-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul "Penerapan Model *Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive* pada Data Inflasi Antarprovinsi di Pulau Jawa Tahun 2015–2024". Tugas akhir ini disusun sebagai salah satu syarat untuk memperoleh gelar sarjana pada Program Studi Statistika pada Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin.

Penulis menyampaikan terima kasih dan penghargaan setinggi-tingginya kepada **Ibu Sitti Sahriman, S.Si., M.Si.** selaku Pembimbing Utama yang dengan penuh kesabaran telah memberikan arahan serta dukungan selama proses penulisan tugas akhir ini. Terima kasih kepada **Ibu Dr. Anna Islamiyati, S.Si., M.Si.** dan **Bapak Siswanto, S.Si., M.Si.** selaku Tim Penguji yang senantiasa memberikan saran dan kritik yang membangun sebagai upaya penyempurnaan penulisan tugas akhir ini. Terima kasih kepada **Pimpinan Universitas Hasanuddin, Departemen Statistika, Jajaran Dosen, dan Staf Departemen Statistika** yang telah memfasilitasi, memberikan ilmu bermanfaat, dan membantu penulis selama menempuh studi.

Penghargaan dan ucapan terima kasih yang mendalam penulis tujukan kepada kedua orangtua tercinta, **Ayah** dan **Ibu** yang telah memberikan dukungan penuh, pengorbanan, kesabaran, cinta dan kasih sayang, serta doa tiada henti yang senantiasa mengiringi setiap langkah penulis. Ucapan terima kasih juga penulis tujukan kepada **Adik** penulis atas doa, dukungan, dan semangat kepada penulis. Ucapan terima kasih juga penulis sampaikan kepada teman seperjuangan penulis (**Radya, Nanas, Zizah**), teman-teman **LDK-LDF Unhas**, teman-teman **FSUA**, teman seperbimbingan, teman-teman **KKN-T UNHAS Gelombang 114 Desa Panaikang (Afra, Wianda, Syukrah, Lulu, Ifrah, Ilham dan Said)**, teman-teman **Statistika 2022**, serta keluarga besar **Himastat FMIPA Unhas** khususnya teman-teman **GAU22IAN** untuk segala cerita dan pengalamannya sehingga memberikan banyak kenangan indah yang tak akan penulis lupakan.

Penulis menyadari bahwa masih banyak kekurangan dalam penyusunan skripsi ini, untuk itu dengan segala kerendahan hati penulis memohon maaf. Akhir kata, semoga tulisan ini dapat memberikan manfaat untuk pembaca.

Makassar, 15 Juli 2026



Dian Ainurridha

ABSTRAK

DIAN AINURRIDHA. **Penerapan Model *Vector Autoregressive with Exogenous Variables* – *Generalized Space Time Autoregressive* pada Data Inflasi Antarprovinsi di Pulau Jawa Tahun 2015–2024** (dibimbing oleh Sitti Sahriman S.Si., M.Si.).

Latar belakang. Pemodelan data deret waktu spasial memerlukan metode yang dapat menggambarkan hubungan antarwaktu dan antarwilayah secara bersamaan. Ketepatan model umumnya dinilai menggunakan nilai *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan koefisien korelasi antara hasil peramalan dengan data aktual. Model *Vector Autoregressive with Exogenous Variables* (VARX) digunakan untuk mempertimbangkan pengaruh variabel eksogen, sedangkan *Generalized Space Time Autoregressive* (GSTAR) digunakan untuk menangkap keterkaitan spasial antarwilayah. Penggabungan kedua metode tersebut menghasilkan model *Vector Autoregressive with Exogenous Variables–Generalized Space Time Autoregressive* (VARX-GSTAR) yang mampu mempertimbangkan hubungan temporal, spasial, dan variabel eksogen secara bersamaan sehingga diharapkan memberikan hasil peramalan yang lebih baik. **Tujuan.** Penelitian ini bertujuan menganalisis estimasi parameter model *Vector Autoregressive with Exogenous Variables–Generalized Space Time Autoregressive* (VARX-GSTAR) serta mengevaluasi kemampuan model tersebut dalam melakukan peramalan tingkat inflasi bulanan pada enam provinsi di Pulau Jawa. **Metode.** Data yang digunakan berupa data inflasi bulanan, BI-Rate, indeks harga energi, dan indeks harga pangan pada enam provinsi di Pulau Jawa periode 2015–2024. Data dibagi menjadi data *training* (2015–2022) untuk pembentukan model dan data *testing* (2023–2024) untuk evaluasi. Analisis dilakukan melalui uji stasioneritas, pembentukan matriks bobot spasial, pemodelan menggunakan VARX, GSTAR, dan VARX-GSTAR, estimasi parameter dengan metode *Ordinary Least Squares* (OLS), uji asumsi *white noise*, serta evaluasi hasil peramalan menggunakan nilai RMSE, MAE, dan koefisien korelasi. **Hasil.** Model VARX-GSTAR(1,1) menghasilkan kinerja peramalan terbaik pada data *testing* dengan nilai RMSE sebesar 0,0823, MAE sebesar 0,0643%, dan koefisien korelasi sebesar 0,9422. Hasil peramalan menunjukkan bahwa rata-rata inflasi enam provinsi di Pulau Jawa selama periode 2025–2028 berada pada kisaran 0,22% hingga 0,33%. **Kesimpulan.** Model VARX-GSTAR memberikan kinerja peramalan yang lebih baik dibandingkan model VARX dan GSTAR. Hal tersebut ditunjukkan oleh nilai RMSE dan MAE yang lebih kecil serta koefisien korelasi yang lebih tinggi pada data pengujian.

Kata kunci: inflasi, VARX-GSTAR, peramalan, BI-Rate, keterkaitan spasial

ABSTRACT

DIAN AINURRIDHA. *Application of the Vector Autoregressive with Exogenous Variables–Generalized Space Time Autoregressive Model to Interprovincial Inflation Data in Java Island, 2015–2024* (supervised by Sitti Sahriman S.Si., M.Si.).

Background. Spatial time series modeling requires a method capable of simultaneously capturing temporal and spatial relationships. Model performance is generally evaluated using the *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), and the correlation coefficient between forecasted and actual values. The *Vector Autoregressive with Exogenous Variables* (VARX) model is employed to incorporate the effects of exogenous variables, while the *Generalized Space Time Autoregressive* (GSTAR) model is used to capture spatial dependence among regions. The integration of these two methods produces the *Vector Autoregressive with Exogenous Variables–Generalized Space Time Autoregressive* (VARX-GSTAR) model, which simultaneously accommodates temporal, spatial, and exogenous effects, thereby providing improved forecasting performance. **Objectives.** This study aims to estimate the parameters of the *Vector Autoregressive with Exogenous Variables–Generalized Space Time Autoregressive* (VARX-GSTAR) model and to evaluate its performance in forecasting monthly inflation rates across six provinces on Java Island. **Methods.** The study used monthly inflation data, the BI-Rate, the energy price index, and the food price index from six provinces on Java Island covering the period from 2015 to 2024. The dataset was divided into training data (2015–2022) for model development and testing data (2023–2024) for model evaluation. The analysis included stationarity testing, construction of spatial weight matrices, model development using VARX, GSTAR, and VARX-GSTAR, parameter estimation using the *Ordinary Least Squares* (OLS) method, white noise assumption testing, and forecasting performance evaluation based on RMSE, MAE, and the correlation coefficient. **Results.** The VARX-GSTAR(1,1) model achieved the best forecasting performance on the testing data, with an RMSE of 0.0823, an MAE of 0.0643%, and a correlation coefficient of 0.9422. The forecasting results indicate that the average inflation rate across the six provinces on Java Island during the 2025–2028 period is projected to range from 0.22% to 0.33%. **Conclusions.** The VARX-GSTAR model provides better forecasting performance than the VARX and GSTAR models. This is demonstrated by its lower RMSE and MAE values, as well as its higher correlation coefficient on the testing data.

Keywords: inflation, VARX-GSTAR, forecasting, BI-Rate, spatial dependence

DAFTAR ISI

	Halaman
HALAMAN SAMPUL	i
HALAMAN JUDUL	ii
HALAMAN PENGANTAR	iii
HALAMAN PENGESAHAN	iv
HALAMAN PERNYATAAN KEASLIAN	v
UCAPAN TERIMA KASIH	vi
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
DAFTAR LAMPIRAN	xiii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Batasan Masalah	3
1.3 Tujuan Penelitian	3
1.4 Manfaat Penelitian	3
1.5 Kajian Teori	4
1.5.1 Analisis Runtun Waktu	4
1.5.2 Data Spasial-Temporal	4
1.5.3 <i>Vector Autoregressive</i>	4
1.5.4 <i>Vector Autoregressive with Exogenous Variables</i>	6
1.5.5 <i>Generalized Space Time Autoregressive</i>	6
1.5.6 <i>Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive</i>	7
1.5.7 Keterkaitan Spasio-Temporal	7
1.5.8 Kestasioneran Data	8
1.5.9 Identifikasi Model	9
1.5.10 Pembobot Lokasi	10

1.5.11 Estimasi Parameter <i>Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive</i>	11
1.5.12 Kriteria Pemilihan Model.....	13
1.5.13 Uji Stabilitas Model	13
1.5.14 Uji Asumsi <i>White Noise</i>	13
1.5.15 Kriteria Evaluasi Model dan Akurasi Peramalan	14
1.5.16 Inflasi	16
1.5.17 Suku Bunga Kebijakan (BI-Rate)	16
1.5.18 Hubungan Inflasi dan Suku Bunga.....	16
1.5.19 Harga Pangan	17
1.5.20 Harga Energi	16
BAB II METODE PENELITIAN.....	18
2.1 Sumber Data.....	18
2.2 Variabel Penelitian dan Struktur Data	18
2.3 Tahapan Analisis	19
BAB III HASIL DAN PEMBAHASAN	21
3.1 Identifikasi Data	21
3.2 Kestasioneran Data	22
3.3 Identifikasi Model	23
3.4 Analisis Keterkaitan Spasio-Temporal	24
3.5 Pembobot Lokasi	26
3.6 Penyusunan Matriks Variabel	27
3.7 Estimasi Parameter Model VARX-GSTAR (1,1)	29
3.8 Kriteria Pemilihan Model	31
3.9 Uji Stabilitas Model	31
3.10 Uji Asumsi <i>White Noise</i>	32
3.11 Visualisasi Hasil <i>Fitting</i> Model VARX-GSTAR	32
3.12 <i>Forecasting</i>	33
BAB IV PENUTUP	35
4.1 Kesimpulan	36
4.2 Saran.....	36
DAFTAR PUSTAKA.....	40
LAMPIRAN	40

DAFTAR TABEL

Nomor urut	Halaman
1. Struktur Data.....	18
2. Statistika Deskriptif	21
3. Hasil Uji ADF pada Data Tingkat Inflasi, BI-Rate, Harga Energi, dan Harga Pangan	22
4. Hasil Penentuan <i>Lag</i> Optimal Berdasarkan Kriteria Informasi.....	23
5. Matriks Keterkaitan Kontemporer Antarprovinsi di Pulau Jawa ($k = 0$).....	24
6. Matriks Keterkaitan Spasio-Temporal Antarprovinsi dengan Jeda Satu Bulan ($k = 1$).....	25
7. Matriks <i>p-value</i> Keterkaitan Spasio-Temporal Antarprovinsi ($k = 1$).....	25
8. Tampilan Sebagian Matriks Variabel Endogen (Y_t)	28
9. Tampilan Sebagian Matriks Variabel Eksogen BI-Rate (X_{1t})	28
10. Tampilan Sebagian Matriks Variabel Eksogen Harga Energi (X_{2t})	28
11. Tampilan Sebagian Matriks Variabel Eksogen Harga Pangan (X_{3t})	29
12. Hasil Estimasi Parameter Model VARX-GSTAR(1,1) pada Provinsi DKI Jakarta	30
13. Kriteria Pemilihan Model.....	31
14. Perbandingan Hasil Uji Stabilitas Model	31
15. Hasil Uji Asumsi <i>White Noise</i> Model VARX-GSTAR	32
16. Perbandingan Hasil Peramalan Tiga Model pada Data <i>Testing</i> Enam Provinsi di Pulau Jawa	33
17. Rata-Rata Hasil Peramalan Tingkat Inflasi Bulanan pada Enam Provinsi di Pulau Jawa Menggunakan VARX-GSTAR Periode 2025-2028	35

DAFTAR GAMBAR

Nomor urut	Halaman
1. Plot <i>Time Series</i> Inflasi (%) pada Enam Provinsi di Pulau Jawa Tahun 2015 –2024.....	22
2. Plot Hasil <i>Fitting</i> Model VARX-GSTAR pada Data <i>Training</i> Enam Provinsi di Pulau Jawa.....	33
3. Plot Perbandingan Data Aktual dengan Hasil Peramalan Tiga Model pada Data <i>Testing</i>	34

DAFTAR LAMPIRAN

Nomor urut	Halaman
1. Data Inflasi, BI-Rate, Harga Energi dan Harga Pangan.....	41
2. Plot <i>Time Series</i> BI-Rate (%), Harga Energi (%), dan Harga Pangan (%) pada Enam Provinsi di Pulau Jawa Tahun 2015–2024	42
3. Konsol Uji ADF menggunakan <i>Software RStudio</i>	43
4. <i>Output</i> Nilai AIC menggunakan <i>Software RStudio</i>	44
5. Hasil Pengolahan Nilai Pembobot Invers Jarak menggunakan <i>Ms. Excel</i>	45
6. Hasil Pengolahan Nilai Pembobot Normalisasi Korelasi Silang menggunakan <i>Ms. Excel</i>	46
7. Sintaks Pengujian Ketergantungan Spasio-Temporal	47
8. Sintaks Penyusunan Matriks Variabel Model VARX-GSTAR	48
9. <i>Output</i> Estimasi Parameter Model VARX-GSTAR Bobot Invers Jarak	49
10. <i>Output</i> Estimasi Parameter Model VARX-GSTAR Bobot Normalisasi Korelasi Silang.....	50
11. <i>Output</i> Kriteria Pemilihan Model.....	51
12. <i>Output</i> Uji Stabilitas Model	52
13. Sintaks Uji <i>White Noise</i> Model VARX-GSTAR	53
14. Sintaks Perhitungan Akurasi Prediksi Data <i>Testing</i> Menggunakan Model VARX, GSTAR, dan VARX-GSTAR	54
15. <i>Output</i> Hasil Peramalan Inflasi Bulanan pada Enam Provinsi di Pulau Jawa Menggunakan Model VARX-GSTAR Periode 2025–2028	55
16. Grafik Hasil Peramalan Inflasi Bulanan pada Enam Provinsi di Pulau Jawa Menggunakan Model VARX-GSTAR Periode 2025–2028	57

BAB I PENDAHULUAN

1.1 Latar Belakang

Inflasi merupakan indikator makroekonomi utama yang mencerminkan tingkat stabilitas harga serta daya beli masyarakat dalam suatu negara secara menyeluruh. Bank Indonesia (2020) menegaskan pentingnya menjaga inflasi pada tingkat stabil sebagai prasyarat utama untuk mencapai pertumbuhan ekonomi yang berkelanjutan. Perubahan tingkat inflasi memengaruhi berbagai aspek vital mulai dari biaya produksi, suku bunga, investasi, hingga arah kebijakan moneter yang diambil oleh otoritas keuangan nasional. Analisis dinamika inflasi membutuhkan pendekatan statistik yang komprehensif untuk mengidentifikasi faktor pengaruh pergerakan harga dalam jangka pendek maupun panjang secara lebih mendalam dan presisi.

Pulau Jawa memegang peran strategis sebagai pusat gravitasi ekonomi nasional dengan kontribusi terhadap Produk Domestik Bruto mencapai lebih dari 58 persen. BPS (2024) melaporkan bahwa pemusatan aktivitas ekonomi di wilayah ini menyebabkan setiap tekanan inflasi memiliki implikasi signifikan terhadap kestabilan harga pada tingkat nasional. Arus distribusi barang antarprovinsi dan jaringan logistik yang terintegrasi erat menyebabkan perubahan harga di satu titik berpotensi menimbulkan efek rambatan (*spillover*) ke wilayah lainnya (Suparta, 2009). Analisis inflasi di Pulau Jawa memerlukan integrasi aspek interaksi spasial guna memetakan pola ketergantungan antarwilayah secara empiris (Laksono et al., 2018).

Dinamika inflasi sebagai variabel endogen dalam penelitian ini dijelaskan melalui tiga variabel eksogen utama yakni BI-Rate, harga energi, serta harga pangan nasional. BI-Rate mencerminkan transmisi kebijakan moneter melalui jalur suku bunga dan kredit sebagaimana telah ditekankan secara mendalam oleh Ratri dan Munawar (2022). Variabel harga energi dan pangan berperan krusial karena sensitivitasnya terhadap faktor musiman serta kontribusinya yang besar terhadap biaya transportasi maupun proses produksi masyarakat luas. Beureukat (2022) mengonfirmasi bahwa guncangan pada komoditas tersebut secara nyata memengaruhi stabilitas harga antarwilayah melalui mekanisme transmisi ekonomi yang saling berkaitan.

Sejumlah peneliti terdahulu telah mengkaji dinamika variabel makro melalui berbagai pendekatan statistik untuk meningkatkan ketajaman prediksi ekonomi regional. Glocker et al. (2023) menunjukkan adanya pola penyebaran antarwilayah yang kuat, sementara Cerqueti et al. (2024) menekankan pentingnya pendekatan spasial-temporal pada kawasan dengan integrasi pasar tinggi. Kesenjangan penelitian muncul karena mayoritas studi sebelumnya cenderung menggunakan pendekatan deret waktu atau spasial secara terpisah atau parsial saja. Celah penelitian ini menuntut adanya model integratif yang mampu menangkap pengaruh temporal dan spasial secara simultan.

Model *Vector Autoregressive* (VAR) merupakan instrumen dasar yang memosisikan setiap variabel sebagai entitas yang saling memengaruhi dalam satu sistem linier. Lütkepohl (2005) menjelaskan bahwa VAR mengidentifikasi dinamika hubungan melalui analisis *impulse response function* dan *variance decomposition* pada variabel endogen. Keterbatasan fokus model pada hubungan internal ini mengakibatkan pengabaian terhadap pengaruh variabel eksogen tambahan serta ketergantungan spasial antarwilayah. Penggunaan VAR memerlukan pengembangan lebih lanjut agar mampu mengakomodasi fenomena ekonomi regional yang dipengaruhi kedekatan geografis.

Model *Vector Autoregressive with Exogenous Variables* (VARX) dikembangkan sebagai perluasan dari model VAR dengan memasukkan variabel eksogen ke dalam sistem. Lütkepohl (2005) menyatakan bahwa model ini meningkatkan kualitas prediksi pada sistem ekonomi yang dipengaruhi secara kuat oleh kebijakan moneter melalui variabel eksogen. Model VARX memiliki keterbatasan mendasar karena hanya menangkap hubungan temporal antarderet waktu tanpa mengakomodasi ketergantungan spasial. Kekurangan ini membuat VARX kurang efektif untuk menganalisis data regional yang memiliki keterkaitan geografis kuat antarwilayah.

Model *Generalized Space Time Autoregressive* (GSTAR) dirancang untuk menganalisis data yang memiliki komponen antarwaktu dan antarruang secara simultan melalui matriks bobot spasial. Borovkova et al. (2008) menjelaskan bahwa GSTAR efektif dalam memodelkan interaksi geografis seperti harga komoditas dan pertumbuhan ekonomi antarwilayah. Model ini merekam efek rambatan (*spatial spillover*) yang muncul ketika suatu kejutan harga di satu lokasi berdampak pada lokasi lainnya. Keterbatasan GSTAR terletak pada ketiadaan variabel eksogen sehingga relevansinya terhadap analisis kebijakan moneter yang dinamis masih bersifat terbatas.

Integrasi kedua metode tersebut menghasilkan pendekatan VARX–GSTAR yang menganalisis dinamika temporal, interaksi spasial, dan pengaruh variabel eksogen secara komprehensif. Huda dan Imro'ah (2023) menyatakan bahwa VARX–GSTAR memberikan estimasi yang lebih stabil serta mengidentifikasi hubungan lintas wilayah secara lebih akurat dibandingkan model tunggal. Penerapan model integratif ini sangat relevan untuk memotret sistem ekonomi regional yang dipengaruhi oleh faktor internal dan eksternal secara bersamaan. Penggunaan metode *Ordinary Least Squares* (OLS) menjanjikan hasil estimasi parameter yang lebih representatif terhadap struktur data riil.

Penelitian berjudul “Penerapan Model *Vector Autoregressive with Exogenous Variables* – *Generalized Space Time Autoregressive* pada Data Inflasi Antarprovinsi di Pulau Jawa Tahun 2015–2024” merupakan manifestasi kebutuhan model. Sinergi antara dimensi waktu, ruang, dan variabel eksogen diharapkan mampu memotret volatilitas ekonomi secara lebih adaptif dan presisi bagi otoritas keuangan. Pemahaman mendalam mengenai mekanisme interaksi antarwilayah tersebut menjadi pijakan penting bagi pengembangan strategi pengendalian harga

yang efektif. Seluruh rangkaian argumen fenomena dan metodologis ini menjadi landasan utama bagi pelaksanaan kajian inflasi di Pulau Jawa.

1.2 Batasan Masalah

Batasan masalah pada penelitian ini adalah sebagai berikut:

1. Ruang lingkup wilayah terbatas pada enam provinsi di Pulau Jawa dengan menggunakan data deret waktu bulanan selama periode sepuluh tahun, terhitung mulai Januari 2015 hingga Desember 2024.
2. Konstruksi matriks bobot spasial dibatasi pada penggunaan metode Invers Jarak dan Normalisasi Korelasi Silang.
3. Metode estimasi parameter menggunakan pendekatan *Ordinary Least Squares* (OLS).
4. Penentuan model terbaik dilakukan berdasarkan kriteria *Akaike Information Criterion* (AIC), *Root Mean Square Error* (RMSE), dan *Adjusted R²*, sedangkan evaluasi kemampuan peramalan dilakukan menggunakan kriteria *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan koefisien korelasi.

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis estimasi parameter model *Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive* untuk mengidentifikasi pengaruh temporal, keterkaitan spasial, serta pengaruh variabel eksogen terhadap inflasi di enam provinsi di Pulau Jawa.
2. Mengevaluasi kemampuan model VARX-GSTAR dalam melakukan peramalan inflasi di enam provinsi di Pulau Jawa melalui pengukuran kinerja model menggunakan beberapa ukuran evaluasi peramalan.

1.4 Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi bagi pengembangan ilmu statistika melalui penerapan model VARX-GSTAR dalam menganalisis fenomena ekonomi regional yang memiliki kompleksitas spasial-temporal tinggi.
2. Menjadi salah satu referensi bagi pemerintah dan otoritas moneter dalam memahami pola inflasi regional serta sebagai bahan pertimbangan dalam penyusunan kebijakan pengendalian inflasi.

1.5 Kajian Teori

1.5.1 Analisis Runtun Waktu

Analisis runtun waktu merupakan metode statistika yang digunakan untuk mempelajari pola perubahan data yang diamati secara berurutan berdasarkan interval waktu tertentu. Analisis ini dilakukan untuk mengetahui pola ketergantungan antarwaktu pada data sehingga karakteristiknya dapat dipahami dan digunakan sebagai dasar dalam membentuk model serta melakukan peramalan (Box et al., 2016).

Pengujian stasioneritas merupakan tahap penting yang dilakukan sebelum proses pemodelan runtun waktu. Pengujian ini bertujuan untuk mengetahui apakah data mengandung *unit root* sehingga dapat menghindari terbentuknya regresi palsu (*spurious regression*) yang menyebabkan hasil analisis menjadi kurang valid (Hassler & Wolters, 2006). Salah satu metode yang umum digunakan untuk menguji stasioneritas adalah uji *Augmented Dickey-Fuller* (ADF), karena mampu mendeteksi keberadaan *unit root* pada data runtun waktu.

1.5.2 Data Spasial-Temporal

Data spasial-temporal merupakan gabungan data runtun waktu dan data lintas wilayah yang digunakan untuk mengamati perubahan dari waktu ke waktu serta hubungan antarwilayah secara bersamaan. Penggunaan data ini memberikan informasi yang lebih lengkap karena dapat meningkatkan jumlah derajat bebas (*degree of freedom*) dan mengurangi masalah kolinearitas antarvariabel (Hsiao, 2014).

Metode analisis statistik konvensional kurang sesuai digunakan pada data spasial karena belum memperhitungkan hubungan antarwilayah. Kondisi tersebut dapat menimbulkan ketergantungan spasial (*spatial dependence*) dan dampak rambatan (*spillover*) antarwilayah. Pengabaian terhadap kedua hal tersebut dapat menyebabkan spesifikasi model menjadi kurang tepat sehingga hasil estimasi menjadi kurang akurat (Anselin, 1988). Model GSTAR digunakan untuk mengatasi permasalahan tersebut melalui penerapan matriks bobot lokasi yang menggambarkan keterkaitan antarwilayah (Astuti et al., 2017).

1.5.3 Vector Autoregressive

Vector Autoregressive (VAR) merupakan salah satu metode statistik yang digunakan untuk melihat hubungan timbal balik dari beberapa variabel sekaligus (Gujarati & Porter, 2009). Keunikan dari metode ini adalah menganggap semua variabel saling memengaruhi. Nilai suatu variabel pada masa kini dipengaruhi oleh nilai masa lalunya sendiri dan juga nilai masa lalu dari variabel-variabel lain di dalam model. Pemodelan VAR mensyaratkan seluruh data penelitian memenuhi kondisi stasioneritas guna menghindari terjadinya regresi palsu (*spurious regression*).

Metode VAR sangat berguna untuk mengamati hubungan antarvariabel secara fleksibel karena tidak membatasi arah hubungan hanya satu arah saja (Sims, 1980). Peneliti biasanya menggunakan metode ini untuk mengamati masalah ekonomi karena metode VAR bisa membaca bagaimana suatu variabel langsung merespons ketika variabel lainnya terkena guncangan mendadak (*shock*). Dampak guncangan antarvariabel dapat dianalisis menggunakan *Impulse Response Function* (IRF) (Lütkepohl, 2005). Merujuk pada konsep dasar sistem simultan dari Gujarati (2012), model persamaan VAR dengan n variabel dan orde p secara umum didefinisikan pada Persamaan (1).

$$Y_t = \alpha + A_1 Y_{t-1} + A_2 Y_{t-2} + \dots + A_p Y_{t-p} + \varepsilon_t \quad (1)$$

Keterangan:

- Y_t : vektor variabel endogen berukuran $n \times 1$ pada waktu ke- t
 α : vektor konstanta (*intercept*) berukuran $n \times 1$
 Y_{t-i} : vektor *lag* variabel endogen ke- i ($i = 1, 2, \dots, p$)
 $A_1, \dots, A_p$: matriks koefisien VAR berukuran $n \times n$
 ε_t : vektor residual berukuran $n \times 1$ yang memenuhi asumsi *white noise*

Guna memperjelas interaksi lintas variabel di dalam sistem multivariat tersebut, struktur matriks koefisien mengikuti format representasi dari Lütkepohl (2005) pada Persamaan (2).

$$\begin{bmatrix} Y_{1,t} \\ Y_{2,t} \\ \vdots \\ Y_{n,t} \end{bmatrix} = \begin{bmatrix} \alpha_{1,0} \\ \alpha_{2,0} \\ \vdots \\ \alpha_{n,0} \end{bmatrix} + \begin{bmatrix} A_{1,1(1)} & A_{1,2(1)} & \dots & A_{1,n(1)} \\ A_{2,1(1)} & A_{2,2(1)} & \dots & A_{2,n(1)} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n,1(1)} & A_{n,2(1)} & \dots & A_{n,n(1)} \end{bmatrix} \begin{bmatrix} Y_{1,t-1} \\ Y_{2,t-1} \\ \vdots \\ Y_{n,t-1} \end{bmatrix} + \begin{bmatrix} A_{1,1(2)} & A_{1,2(2)} & \dots & A_{1,n(2)} \\ A_{2,1(2)} & A_{2,2(2)} & \dots & A_{2,n(2)} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n,1(2)} & A_{n,2(2)} & \dots & A_{n,n(2)} \end{bmatrix} \begin{bmatrix} Y_{1,t-2} \\ Y_{2,t-2} \\ \vdots \\ Y_{n,t-2} \end{bmatrix} + \dots + \begin{bmatrix} A_{1,1(p)} & A_{1,2(p)} & \dots & A_{1,n(p)} \\ A_{2,1(p)} & A_{2,2(p)} & \dots & A_{2,n(p)} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n,1(p)} & A_{n,2(p)} & \dots & A_{n,n(p)} \end{bmatrix} \begin{bmatrix} Y_{1,t-p} \\ Y_{2,t-p} \\ \vdots \\ Y_{n,t-p} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \\ \vdots \\ \varepsilon_{n,t} \end{bmatrix} \quad (2)$$

Keterangan:

- $Y_{j,t}$: nilai variabel endogen ke- j pada waktu ke- t
 $\alpha_{j,0}$: elemen konstanta (*intercept*) untuk persamaan ke- j
 $Y_{k,t-i}$: nilai variabel endogen ke- k pada *lag* ke- i
 $A_{j,k(i)}$: koefisien pada *lag* ke- i yang mengukur dampak variabel ke- k terhadap variabel ke- j
 $\varepsilon_{j,t}$: residual untuk persamaan ke- j pada waktu ke- t

1.5.4 Vector Autoregressive with Exogenous Variables

Vector Autoregressive with Exogenous Variables (VARX) adalah pengembangan dari model VAR standar. Model ini memasukkan variabel tambahan dari luar sistem persamaan, yang disebut sebagai variabel eksogen. Tujuannya adalah untuk mengukur pengaruh faktor luar tersebut terhadap variabel utama penelitian. Penggunaan model ini memerlukan data yang stasioner dan residual yang bersifat acak atau *white noise* (Lütkepohl, 2005).

Estimasi hitungan dalam model VARX umumnya menggunakan metode *Ordinary Least Squares* (OLS) pada setiap persamaan. Kelayakan model ini diuji melalui beberapa uji statistik dasar, seperti uji *Augmented Dickey-Fuller* (ADF) dan uji *Ljung-Box*. Model VARX juga dilengkapi fitur *Impulse Response Function* (IRF) untuk melihat efek jalar jika terjadi guncangan mendadak (*shock*).

Bierens (2004) menyatakan bahwa model VARX (p, s) menggunakan *lag* sebesar p untuk variabel endogen dan *lag* sebesar s untuk variabel eksogen. Penulisan model ini disederhanakan menggunakan notasi sigma (Σ) pada Persamaan (3).

$$Y_t = \alpha + \sum_{i=1}^p A_i Y_{t-i} + \sum_{j=0}^s \theta_j X_{t-j} + \varepsilon_t \quad (3)$$

Keterangan:

- Y_t : vektor variabel endogen berukuran $n \times 1$ pada waktu ke- t
- X_{t-j} : vektor variabel eksogen berukuran $r \times 1$ pada *lag* ke- j
- α : vektor konstanta berukuran $n \times 1$
- A_i : matriks koefisien variabel endogen berukuran $n \times n$ pada *lag* ke- i
- θ_j : matriks koefisien variabel eksogen berukuran $n \times r$ pada *lag* ke- j
- ε_t : vektor residual (*white noise*) berukuran $n \times 1$

1.5.5 Generalized Space Time Autoregressive

Generalized Space Time Autoregressive (GSTAR) merupakan pengembangan dari model *Space Time Autoregressive* (STAR) untuk menganalisis data spasio-temporal yang memiliki karakteristik tidak seragam antarwilayah atau heterogenitas spasial (Ruchjana et al., 2012). Keunggulan model ini terletak pada fleksibilitasnya yang mengizinkan nilai parameter autoregresif berbeda di setiap lokasi pengamatan. Perbedaan karakteristik antarwilayah tersebut direpresentasikan melalui matriks pembobot spasial (W) yang menggambarkan kedekatan antarlokasi secara formal. Merujuk pada konsep dasar pemodelan ruang-waktu dari Ruchjana et al. (2012), Wutsqa et al. (2010) mendefinisikan model persamaan GSTAR dalam bentuk representasi matriks secara umum pada Persamaan (4).

$$Y_t = \sum_{k=1}^p [\phi_{k0} + \phi_{k1} W] Y_{t-k} + \varepsilon_t \quad (4)$$

Keterangan:

- Y_t : vektor variabel endogen berukuran $n \times 1$ pada waktu ke- t
- ϕ_{k0} : matriks diagonal parameter autoregresif waktu pada *lag* ke- k
- ϕ_{k1} : matriks diagonal parameter autoregresif spasial-temporal pada *lag* ke- k
- W : matriks pembobot spasial berukuran $n \times n$

Y_{t-k} : vektor *lag* variabel endogen pada *lag* waktu ke- k
 ε_t : vektor residual berukuran $n \times 1$

1.5.6 Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive

Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive (VARX-GSTAR) mengintegrasikan model VARX dan GSTAR untuk menggabungkan ketergantungan waktu, wilayah, serta pengaruh variabel eksogen secara simultan (Nurchayani & Saputro, 2021). Penggunaan parameter spasial-temporal dalam model ini digunakan untuk menangkap perbedaan karakteristik ekonomi di setiap wilayah yang saling terhubung secara geografis (Masdin et al., 2018). Model ini memerlukan residual yang memenuhi asumsi *white noise* serta kestabilan parameter agar hasil peramalan bernilai valid. Merujuk pada konsep dasar pemodelan sistem simultan spasio-temporal dengan variabel eksogen dari Akbar et al. (2018), serta penurunan model matematis dari Nurchayani dan Saputro (2021), model persamaan VARX-GSTAR (p, s) secara umum didefinisikan pada Persamaan (5).

$$Y_t = \alpha + \sum_{k=1}^p \Gamma_{k0} Y_{t-k} + \sum_{k=1}^p \Gamma_{k1} W Y_{t-k} + \sum_{j=0}^s \theta_j X_t + \varepsilon_t \quad (5)$$

Keterangan:

Y_t : vektor variabel endogen berukuran $n \times 1$ pada waktu ke- t
 α : vektor konstanta berukuran $n \times 1$
 Γ_{k0} : matriks diagonal parameter autoregresif waktu pada *lag* ke- k
 Γ_{k1} : matriks diagonal parameter autoregresif spasial-temporal pada *lag* ke- k
 W : matriks pembobot spasial berukuran $n \times n$
 θ_j : vektor parameter yang berkaitan dengan variabel eksogen pada *lag* ke- j
 X_t : vektor variabel eksogen berukuran $m \times 1$ pada waktu ke- t
 ε_t : vektor residual (*white noise*) berukuran $n \times 1$

1.5.7 Keterkaitan Spasio-Temporal

Keterkaitan spasio-temporal menggambarkan hubungan antarwilayah yang mempertimbangkan aspek spasial dan temporal secara bersamaan. Indeks Moran umumnya digunakan untuk mengukur autokorelasi spasial pada satu waktu pengamatan. Model VARX-GSTAR memerlukan informasi hubungan antar deret waktu inflasi antarprovinsi sebagai dasar pembentukan matriks bobot spasial. Pendekatan *cross-correlation* digunakan untuk mengukur hubungan antarprovinsi berdasarkan data inflasi. Hasil perhitungan disusun dalam bentuk matriks korelasi berukuran $n \times n$ yang digunakan sebagai dasar pembentukan matriks bobot spasial (Chen, 2015). Analisis keterkaitan dilakukan pada dua kondisi waktu, yaitu keterkaitan spasial kontemporer ($k = 0$) dan keterkaitan spasio-temporal ($k = 1$) (Lun et al., 2023).

1. Matriks korelasi spasial kontemporer digunakan untuk mengukur kekuatan hubungan pergerakan variabel antarwilayah pada titik waktu pengamatan yang sama didefinisikan pada Persamaan (6).

$$\rho_{ij}(0) = \frac{Cov(X_i(t), X_j(t))}{\sqrt{Var(X_i)Var(X_j)}} \quad (6)$$

2. Matriks korelasi spasio-temporal digunakan untuk mengukur kekuatan hubungan dari kondisi suatu wilayah pada satu periode sebelumnya terhadap wilayah lain pada periode berjalan yang didefinisikan pada Persamaan (7).

$$\rho_{ij}(1) = \frac{Cov(X_i(t), X_j(t-1))}{\sqrt{Var(X_i)Var(X_j)}} \quad (7)$$

Pengujian signifikansi korelasi dilakukan untuk mengetahui apakah koefisien korelasi yang diperoleh menunjukkan hubungan yang signifikan secara statistik. Langkah-langkah pengujian signifikansi korelasi pada *lag k* adalah sebagai berikut:

1. Hipotesis:

$H_0: \rho_{ij}(k) = 0$ (tidak terdapat keterkaitan antara inflasi provinsi *i* dan provinsi *j* pada lag *k*)

$H_1: \rho_{ij}(k) \neq 0$ (terdapat keterkaitan antara inflasi provinsi *i* dan provinsi *j* pada lag *k*)

2. Tingkat signifikansi:

$\alpha = 5\% = 0.05$

3. Statistik uji:

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \quad (8)$$

Keterangan:

r : koefisien korelasi sampel

n : jumlah pasangan pengamatan

4. Kriteria pengujian:

Jika nilai $p - value < \alpha$, maka tolak H_0 artinya terdapat keterkaitan berpasangan

Jika nilai $p - value > \alpha$, maka gagal tolak H_0 artinya tidak terdapat keterkaitan berpasangan.

Koefisien korelasi yang diperoleh menunjukkan arah dan kekuatan hubungan antarwilayah. Nilai koefisien tersebut digunakan sebagai dasar pembentukan matriks bobot spasial pada model VARX-GSTAR.

1.5.8 Kestasioneran Data

Kestasioneran data merupakan aspek krusial dalam analisis runtun waktu guna menjamin validitas hubungan antarvariabel serta stabilitas estimasi model. Data dikatakan stasioner apabila nilai rata-rata, varians, dan kovariansnya bersifat konstan sepanjang waktu tanpa terpengaruh oleh tren atau pola musiman. Penggunaan data yang tidak stasioner berpotensi menghasilkan regresi lancung (*spurious regression*) serta estimasi parameter yang tidak konsisten (Hassler & Wolters, 2006)

Prosedur pengujian stasioneritas dilakukan melalui uji *Augmented Dickey-Fuller* (ADF) untuk mendeteksi keberadaan akar unit (*unit root*) pada data. Hasil uji ini memberikan dasar keputusan apakah data telah stasioner pada tingkat asli (*level*) atau memerlukan proses differensiasi (*differencing*). Merujuk pada konsep dasar pengujian akar unit dari Dickey dan Fuller (1979), secara umum model persamaan uji ADF didefinisikan pada Persamaan (9).

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^p \delta_i \Delta Y_{t-i} + \varepsilon_t \quad (9)$$

Keterangan:

- ΔY_t : perubahan nilai variabel Y pada waktu ke- t ($Y_t - Y_{t-1}$)
- α : konstanta (*intercept*)
- βt : koefisien tren linear terhadap waktu
- γ : parameter untuk menguji keberadaan akar unit
- δ_i : koefisien dari *lag* differensiasi ke- i
- ε_t : komponen residual acak (*white noise*)

Langkah-langkah pengujian kestasioneran dengan menggunakan uji ADF adalah sebagai berikut:

1. Hipotesis:

$H_0: \gamma = 0$ (data tidak stasioner)

$H_1: \gamma < 0$ (data stasioner)

2. Tingkat signifikansi:

$\alpha = 5\% = 0.05$

3. Statistik uji:

$$t_{hitung} = \frac{\hat{\gamma}}{SE(\hat{\gamma})} \quad (10)$$

Keterangan:

$\hat{\gamma}$: nilai estimasi dari parameter γ

$SE(\hat{\gamma})$: standar *error* dari nilai estimasi $\hat{\gamma}$

4. Kriteria pengujian:

Jika nilai $p - value < \alpha$, maka tolak H_0 artinya data stasioner

Jika nilai $p - value > \alpha$, maka gagal tolak H_0 artinya data tidak stasioner

Apabila data belum mencapai kondisi stasioner, proses *differencing* pada komponen non-musiman maupun musiman berfungsi untuk menstabilkan data hingga memenuhi asumsi stasioneritas (Aktivani, 2020).

1.5.9 Identifikasi Model

Identifikasi model bertujuan untuk menentukan orde waktu (p) dan orde ruang (s) yang paling optimal sebelum melakukan estimasi parameter. Penentuan *lag* optimal dilakukan dengan membandingkan nilai kriteria informasi dari berbagai kombinasi orde model yang mungkin terbentuk. Pemilihan model terbaik didasarkan pada nilai *Akaike Information Criterion* (AIC) terkecil guna menjamin efisiensi jumlah parameter dalam model (Wutsqa et al., 2012). Merujuk pada konsep dasar kriteria informasi

untuk sistem multivariat dari Wei (2006), secara umum model persamaan perhitungan nilai AIC didefinisikan pada Persamaan (11).

$$AIC_{(p)} = \ln|\hat{\Sigma}_p| + \frac{2pn^2}{T} \quad (11)$$

Keterangan:

- $|\hat{\Sigma}_p|$: determinan matriks varians-kovarians residual berukuran $n \times n$
- p : orde *lag* variabel endogen (orde waktu) yang diuji
- n : jumlah lokasi amatan
- T : jumlah observasi atau ukuran sampel data

1.5.10 Pembobot Lokasi

Sistem pembobotan lokasi menerapkan prosedur standarisasi baris (*row-standardized*) agar matriks bobot (W) memenuhi kriteria statistik yang konsisten. Prosedur ini menetapkan bahwa jumlah seluruh entri pada setiap baris harus bernilai satu, sedangkan bobot suatu lokasi terhadap dirinya sendiri bernilai nol (Suhartono & Atok, 2006). Langkah tersebut memastikan bahwa pengaruh spasial dari wilayah tetangga terdistribusi secara proporsional dalam model.

A. Bobot Invers Jarak

Bobot invers jarak mengandalkan jarak fisik absolut dalam satuan kilometer (km) antarlokasi sebagai penentu kekuatan interaksi spasial (Anselin, 1988). Tahap awal pengerjaan dimulai dengan menghitung bobot mentah (w_{ij}^*) yang nilainya berbanding terbalik dengan jarak fisik antarlokasi tersebut pada Persamaan (12).

$$w_{ij}^* = \frac{1}{d_{ij}}, \text{ untuk } i \neq j \quad (12)$$

Hasil perhitungan bobot mentah kemudian divalidasi melalui prosedur normalisasi baris (*row-standardization*). Merujuk pada konsep penentuan bobot lokasi dari (Suhartono & Atok, 2006), secara umum rumus normalisasi pembobot invers jarak didefinisikan pada Persamaan (13).

$$w_{ij} = \begin{cases} \frac{w_{ij}^*}{\sum_{j=1, j \neq i}^n w_{ij}^*}, & i \neq j \\ 0, & i = j \end{cases} \quad (13)$$

Keterangan:

- w_{ij} : nilai bobot spasial yang telah dinormalisasi
- w_{ij}^* : nilai bobot mentah (invers jarak)
- d_{ij} : jarak fisik absolut antarwilayah pengamatan (km)
- n : jumlah unit lokasi observasi

B. Bobot Normalisasi Korelasi Silang

Bobot normalisasi korelasi silang menggunakan hasil normalisasi korelasi silang antarlokasi pada *lag* waktu yang bersesuaian (Suhartono & Atok, 2006). Nilai bobot spasial (w_{ij}) ditentukan melalui prosedur normalisasi besaran nilai korelasi silang pada *lag* waktu ke- k , sebagaimana dirumuskan pada Persamaan (14).

$$w_{ij} = \frac{r_{ij}(k)}{\sum_{j \neq i} |r_{ij}(k)|}, \text{ dengan } i \neq j, k = 1, 2, \dots, p \quad (14)$$

Nilai estimasi korelasi silang ($r_{ij}(k)$) antara lokasi i dan lokasi j pada *lag* ke- k yang digunakan pada Persamaan (14) dihitung berdasarkan Persamaan (15).

$$r_{ij}(k) = \frac{\sum_{t=k+1}^T [Z_i(t) - \bar{Z}_i][Z_j(t-k) - \bar{Z}_j]}{\sqrt{(\sum_{t=1}^T [Z_i(t) - \bar{Z}_i]^2)(\sum_{t=1}^T [Z_j(t) - \bar{Z}_j]^2)}} \quad (15)$$

Keterangan:

- w_{ij} : elemen matriks bobot spasial untuk lokasi i dan j
- $r_{ij}(k)$: nilai estimasi korelasi silang antara lokasi i dan j pada *lag* ke- k
- $Z_i(t)$: nilai amatan pada lokasi i pada waktu ke- t
- $Z_j(t)$: nilai amatan pada lokasi j pada waktu ke- t
- $\bar{Z}_i, \bar{Z}_j$: rata-rata nilai amatan pada lokasi i dan j
- T : jumlah seluruh pengamatan waktu

1.5.11 Estimasi Parameter *Vector Autoregressive with Exogenous Variables – Generalized Space Time Autoregressive*

Estimasi parameter pada model VARX-GSTAR bertujuan memperoleh nilai koefisien yang paling mendekati kondisi populasi sebenarnya. Metode *Ordinary Least Squares* (OLS) menjadi pilihan utama untuk meminimumkan jumlah kuadrat residual (*error*) dalam sistem persamaan. Merujuk pada konsep estimasi sistem simultan spasio-temporal dari Akbar et al. (2018), model umum persamaan VARX-GSTAR (p, s) ditunjukkan pada Persamaan (16).

$$Y_t = \alpha + \sum_{i=1}^p A_i Y_{t-i} + \sum_{k=1}^s B_k W Y_{t-k} + C X_t + \varepsilon_t \quad (16)$$

Keterangan:

- Y_t : vektor variabel endogen berukuran $(n \times 1)$ pada waktu ke- t
- α : konstanta (*intercept*) berukuran $(n \times 1)$
- A_i : matriks koefisien autoregresif untuk variabel endogen pada *lag* waktu ke- i berukuran $(n \times n)$
- B_k : matriks koefisien parameter spasial untuk *lag* waktu ke- k berukuran $(n \times n)$
- W : matriks bobot spasial antarlokasi berukuran $(n \times n)$
- C : matriks koefisien pengaruh variabel eksogen terhadap variabel endogen berukuran $(n \times r)$
- X_t : vektor variabel eksogen berukuran $(r \times 1)$ pada waktu ke- t
- ε_t : vektor residual (*error*) model pada waktu ke- t berukuran $(n \times 1)$

Residual dari model tersebut dinyatakan pada Persamaan (17).

$$\varepsilon_t = Y_t - \hat{Y}_t \quad (17)$$

Fungsi kriteria minimisasi kuadrat residual didefinisikan pada Persamaan (18).

$$S(\Phi, C) = \sum_{t=1}^T \varepsilon_t' \varepsilon_t \quad (18)$$

Proses estimasi pada setiap lokasi i dipermudah dengan mentransformasikan model ke dalam representasi matriks linear $Y_i = Z_i\beta_i + \varepsilon_i$. Komponen matriks untuk lokasi ke- i disusun secara lengkap sebagai berikut:

$$Y_i = \begin{bmatrix} y_{i,1} \\ y_{i,2} \\ \vdots \\ y_{i,T} \end{bmatrix}, Z_i = \begin{bmatrix} y_{i,0} & V_{i,0} & \Delta X_{1,i,1} & \Delta X_{2,i,1} & \Delta X_{3,i,1} \\ y_{i,1} & V_{i,1} & \Delta X_{1,i,2} & \Delta X_{2,i,2} & \Delta X_{3,i,2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ y_{i,T-1} & V_{i,T-1} & \Delta X_{1,i,T} & \Delta X_{2,i,T} & \Delta X_{3,i,T} \end{bmatrix}, \beta_i = \begin{bmatrix} \phi_{i0} \\ \phi_{i1} \\ \gamma_{i1} \\ \gamma_{i2} \\ \gamma_{i3} \end{bmatrix}, \varepsilon_i = \begin{bmatrix} \varepsilon_{i,1} \\ \varepsilon_{i,2} \\ \vdots \\ \varepsilon_{i,T} \end{bmatrix}$$

Komponen $V_{i,t} = \sum_{j=1, j \neq i}^n w_{ij} Y_{j,t}$ mengindikasikan bahwa parameter β_i dapat dihitung pada masing-masing lokasi, tetapi tetap memiliki ketergantungan pada nilai Y_t di lokasi yang lain. Metode OLS mengestimasi parameter β_i global dengan cara meminimumkan jumlah kuadrat *error* melalui penjabaran aljabar matriks pada Persamaan (19).

$$\begin{aligned} Y &= Z\beta + \varepsilon \\ \varepsilon &= Y - Z\beta \\ \varepsilon'\varepsilon &= (Y - Z\beta)'(Y - Z\beta) \\ &= (Y' - \beta'Z')(Y - Z\beta) \\ &= Y'Y - Y'Z\beta - \beta'Z'Y + \beta'Z'Z\beta \\ &= Y'Y - 2\beta'Z'Y + \beta'Z'Z\beta \end{aligned} \quad (19)$$

Persamaan (19) dilakukan dengan menurunkan fungsi tersebut terhadap vektor β sebagaimana ditunjukkan pada Persamaan (20).

$$\frac{\partial(\varepsilon'\varepsilon)}{\partial\beta} = -2Z'Y + 2Z'Z\beta \quad (20)$$

Hasil turunan pertama pada Persamaan (20) kemudian disamakan dengan nol untuk memperoleh nilai ekstrem minimum:

$$\begin{aligned} -2Z'Y + 2Z'Z\beta &= 0 \\ 2Z'Z\beta &= 2Z'Y \\ Z'Z\beta &= Z'Y \\ \beta &= (Z'Z)^{-1}Z'Y \end{aligned}$$

Sehingga diperoleh estimator OLS $\hat{\beta}$ untuk parameter model global pada Persamaan (21).

$$\hat{\beta} = (Z'Z)^{-1}Z'Y \quad (21)$$

Keterangan:

- Y : vektor gabungan data aktual variabel endogen untuk seluruh pengamatan berukuran $(nT \times 1)$
- Z : matriks gabungan variabel penjelas (komponen *lag* waktu, *lag* spasial, dan variabel eksogen) berukuran $(nT \times P)$
- β : vektor seluruh parameter model global yang akan diestimasi
- $\hat{\beta}$: vektor estimator *Ordinary Least Squares* (OLS) untuk parameter model global
- Z' : matriks *transpose* dari matriks gabungan Z
- Y' : matriks *transpose* dari vektor gabungan variabel endogen Y
- ε : vektor gabungan residual (*error*) model untuk seluruh lokasi berukuran $(nT \times 1)$

1.5.12 Kriteria Pemilihan Model

Pemilihan model optimal dalam analisis deret waktu multivariat bertujuan untuk mendapatkan model final yang paling efisien. Pengujian ini dilakukan menggunakan *Akaike Information Criterion* (AIC), dimana model dengan nilai AIC terkecil menunjukkan performa peramalan terbaik karena mampu menyeimbangkan ketetapan prediksi dan jumlah parameter (Akaike, 1974). Merujuk pada konsep dasar kriteria informasi dari Akaike (1974), secara umum model persamaan perhitungan nilai AIC didefinisikan pada Persamaan (22).

$$AIC(p) = \ln|\hat{\Sigma}| + \frac{2k}{T} \quad (22)$$

Dalam persamaan tersebut, $|\hat{\Sigma}|$ merupakan determinan dari matriks kovarians residual berukuran $n \times n$, k menyatakan jumlah seluruh parameter bebas yang diestimasi dalam model, dan T merupakan jumlah seluruh pengamatan waktu.

1.5.13 Uji Stabilitas Model

Evaluasi stabilitas model merupakan prasyarat krusial untuk menjamin bahwa hasil estimasi bersifat valid dalam analisis spasio-temporal. Model yang tidak stabil cenderung menghasilkan prediksi yang divergen atau tidak konsisten saat terjadi perubahan kecil pada data. Lütkepohl (2005) menegaskan bahwa pengujian stabilitas ini berfungsi memastikan seluruh sistem persamaan telah stabil dan berjalan akurat sebelum dilakukan analisis lanjutan, seperti *Impulse Response Function* (IRF).

Sebuah model mencapai kondisi stabil apabila seluruh akar karakteristik (*characteristic roots*) dari polinomial matriks berada di dalam lingkaran satuan (*unit circle*). Berdasarkan parameter pembatasan yang dirumuskan oleh Lütkepohl (2005), kondisi ini menetapkan bahwa nilai modulus atau nilai absolut dari setiap akar eigen tidak boleh melebihi satu ($|\lambda_i| \leq 1$), di mana model persamaan uji stabilitas secara umum didefinisikan pada Persamaan (23)

$$\det(\mathbf{I}_k - \sum_{i=1}^p \mathbf{A}_i \lambda^i) \neq 0 \text{ untuk setiap } |\lambda_i| \leq 1 \quad (23)$$

Kondisi stabilitas ini terpenuhi jika seluruh nilai eigen (*eigenvalues*) dari matriks koefisien memiliki modulus kurang dari atau sama dengan satu ($|\lambda_i| \leq 1$). Terpenuhinya kriteria ini menjamin keandalan hasil analisis serta validitas peramalan.

1.5.14 Uji Asumsi *White Noise*

Uji *White Noise* dilakukan untuk memastikan bahwa residual dari model yang diestimasi telah bersifat independen atau saling bebas satu sama lain. Residual yang memenuhi kriteria *white noise* berarti tidak mengandung pola autokorelasi sehingga dapat diasumsikan acak oleh model (Box et al., 2016).

Ljung dan Box (1978) mengembangkan uji *Ljung-Box* sebagai metode yang umum digunakan untuk menguji pemenuhan asumsi *white noise* pada residual model. Berikut langkah-langkah pengujian *white noise* menggunakan uji *Ljung-Box*:

1. Hipotesis:

H_0 : Residual bersifat *white noise* (tidak ada autokorelasi)

H_1 : Residual tidak bersifat *white noise* (ada autokorelasi)

2. Tingkat signifikansi:

$\alpha = 5\% = 0.05$

3. Statistik uji:

$$Q_{LB} = n(n+2) \sum_{k=1}^m \left(\frac{\hat{\rho}_k^2}{n-k} \right) \quad (24)$$

4. Daerah kritis:

Tolak H_0 jika nilai $Q_{LB} > \chi_{\alpha; m}^2$ atau $p\text{-value} < \alpha$

Keterangan:

Q_{LB} : nilai statistik uji *Ljung-Box*

n : banyaknya pengamatan atau ukuran sampel

m : banyaknya *lag* yang diuji

k : indeks *lag* (*lag* ke- k)

df : derajat bebas (*degrees of freedom*)

$\hat{\rho}_k^2$: fungsi koefisien autokorelasi sampel residual pada *lag* ke- k

1.5.15 Kriteria Evaluasi Model dan Akurasi Peramalan

Kinerja model perlu dievaluasi untuk mengetahui kemampuan model dalam menjelaskan data serta menghasilkan peramalan yang baik. Penelitian ini menggunakan beberapa ukuran evaluasi, yaitu *Adjusted R²*, *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan koefisien korelasi (r). *Adjusted R²* digunakan untuk menilai kemampuan model dalam menjelaskan variasi data, sedangkan RMSE digunakan untuk membandingkan kinerja model sekaligus mengukur tingkat kesalahan hasil peramalan. MAE dan koefisien korelasi digunakan untuk mengevaluasi akurasi hasil peramalan dengan membandingkan nilai prediksi terhadap data aktual.

1. *Adjusted R²* digunakan untuk mengukur proporsi variasi variabel endogen yang mampu dijelaskan oleh model dengan mempertimbangkan jumlah parameter dan ukuran sampel. Menurut Gujarati (2012), ukuran ini memberikan penilaian yang lebih objektif dibandingkan R^2 karena telah memperhitungkan kompleksitas model. Secara umum, rumus *Adjusted R²* dinyatakan pada Persamaan (25).

$$R_{adj}^2 = 1 - \left[\frac{(1-R^2)(n-1)}{n-k-1} \right] \quad (25)$$

Keterangan:

R^2 : nilai koefisien determinasi standar

n : jumlah sampel pengamatan

k : jumlah seluruh parameter bebas

2. *Root Mean Square Error* (RMSE) digunakan untuk mengukur rata-rata kuadrat kesalahan antara nilai hasil peramalan dan nilai aktual. Menurut Wei (2006), nilai RMSE yang semakin kecil menunjukkan bahwa hasil peramalan semakin mendekati data aktual. Rumus RMSE dinyatakan pada Persamaan (26).

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (26)$$

Keterangan:

n : jumlah sampel data ramalan (*testing*)

y_t : nilai amatan aktual pada waktu ke- t

$\hat{y}_t$: nilai hasil peramalan pada waktu ke- t

3. *Mean Absolute Error* (MAE) digunakan untuk mengukur rata-rata nilai absolut dari selisih antara nilai aktual dan nilai hasil peramalan. Menurut Hyndman dan Koehler (2006), nilai MAE yang semakin kecil menunjukkan tingkat kesalahan peramalan yang semakin rendah. Rumus MAE dinyatakan pada Persamaan (27).

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad (27)$$

Keterangan:

n : jumlah sampel data ramalan (*testing*)

y_t : nilai amatan aktual pada waktu ke- t

$\hat{y}_t$: nilai hasil peramalan pada waktu ke- t

4. Koefisien korelasi digunakan untuk mengukur kekuatan dan arah hubungan linear antara nilai aktual dan hasil peramalan. Menurut Walpole et al. (2012), nilai koefisien korelasi yang semakin mendekati satu menunjukkan bahwa pola hasil peramalan semakin sesuai dengan pola data aktual. Rumus koefisien korelasi dinyatakan pada Persamaan (28).

$$r = \frac{\sum_{t=1}^n (y_t - \bar{y})(\hat{y}_t - \bar{\hat{y}})}{\sqrt{\sum_{t=1}^n (y_t - \bar{y})^2 \sum_{t=1}^n (\hat{y}_t - \bar{\hat{y}})^2}} \quad (28)$$

Keterangan:

r : nilai koefisien korelasi

n : jumlah sampel data ramalan (*testing*)

y_t : nilai amatan aktual pada waktu ke- t

$\hat{y}_t$: nilai hasil peramalan pada waktu ke- t

$\bar{y}$: rata-rata nilai amatan aktual

$\bar{\hat{y}}$: rata-rata nilai hasil peramalan

1.5.16 Inflasi

Inflasi merupakan kecenderungan kenaikan harga barang dan jasa secara umum yang terjadi terus-menerus sehingga dapat menurunkan daya beli masyarakat (Iryanto & Suropto, 2024). Inflasi dibedakan menjadi dua jenis, yaitu *demand-pull inflation* yang disebabkan oleh meningkatnya permintaan masyarakat dan *cost-push inflation* yang terjadi akibat kenaikan biaya produksi. Hubungan ekonomi antarwilayah menyebabkan perubahan harga di suatu daerah dapat memengaruhi daerah lain melalui kegiatan distribusi dan logistik. Analisis inflasi perlu memperhatikan aspek spasial dan temporal agar perubahan inflasi antarwilayah dapat dijelaskan dengan lebih baik.

1.5.17 Suku Bunga Kebijakan (BI-Rate)

Suku bunga kebijakan merupakan instrumen utama yang digunakan bank sentral untuk menjaga stabilitas harga dan mendukung perekonomian nasional (Warjiyo, 2018). Perubahan suku bunga menjadi acuan bagi suku bunga pasar yang memengaruhi keputusan masyarakat dalam konsumsi dan investasi. Jalur kredit dan ekspektasi masyarakat menjadi saluran utama dalam proses tersebut sehingga suku bunga sering digunakan sebagai variabel eksogen yang memengaruhi berbagai indikator ekonomi. Penetapan suku bunga yang tepat diharapkan dapat mendukung tercapainya tujuan kebijakan moneter.

1.5.18 Hubungan Inflasi dan Suku Bunga

Hubungan antara inflasi dan suku bunga di Indonesia menunjukkan pengaruh positif dan signifikan. Agusmanata et al. (2017) menjelaskan bahwa kondisi tersebut sejalan dengan Teori Paradox Gibson yang menyatakan bahwa tingkat suku bunga dan harga cenderung bergerak searah. Teori Keynes memiliki pandangan yang berbeda karena menyatakan bahwa kenaikan suku bunga dapat menurunkan inflasi dengan mendorong masyarakat untuk menabung sehingga jumlah uang yang beredar berkurang. Penelitian Agusmanata et al. (2017) juga menunjukkan bahwa kenaikan suku bunga tidak selalu mampu menekan inflasi di Indonesia, terutama jika kenaikan harga dipengaruhi oleh faktor luar negeri atau *imported inflation*.

1.5.19 Harga Energi

Harga energi seperti bahan bakar minyak (BBM), listrik, dan gas, merupakan salah satu variabel eksogen yang memengaruhi inflasi karena menjadi kebutuhan utama dalam kegiatan produksi dan transportasi (Rahman & Pratomo, 2015). Kenaikan harga energi dapat mendorong inflasi dari sisi penawaran (*cost-push inflation*) karena meningkatkan biaya operasional dan harga barang. Perubahan harga energi juga memengaruhi perkiraan masyarakat terhadap inflasi. Pulau Jawa sebagai pusat kegiatan industri sangat dipengaruhi oleh perubahan harga energi karena

berdampak langsung pada biaya logistik dan distribusi. Pengamatan terhadap harga energi membantu menjelaskan perubahan inflasi antarwilayah dengan lebih baik.

1.5.20 Harga Pangan

Harga pangan merupakan salah satu komponen utama dalam Indeks Harga Konsumen (IHK) yang memengaruhi laju inflasi, terutama di negara berkembang seperti Indonesia (Pratikto & Ikhsan, 2016). Perubahan harga pangan dipengaruhi oleh pasokan, permintaan, kondisi cuaca, dan kebijakan pemerintah sehingga harganya sering berfluktuasi. Kenaikan harga pangan dapat mendorong inflasi dari sisi permintaan (*demand-pull inflation*) maupun sisi penawaran (*cost-push inflation*) karena meningkatkan biaya hidup dan biaya produksi. Perbedaan harga pangan antarprovinsi di Pulau Jawa juga dapat menimbulkan efek rambatan (*spillover effect*) melalui kegiatan perdagangan dan distribusi.

BAB II METODE PENELITIAN

2.1 Sumber Data

Penelitian ini menggunakan data sekunder yang bersumber dari Badan Pusat Statistik (BPS) dan Bank Indonesia (BI). Data penelitian mencakup tingkat inflasi bulanan di enam provinsi di Pulau Jawa, meliputi DKI Jakarta, Jawa Barat, Jawa Tengah, DI Yogyakarta, Jawa Timur, dan Banten, selama periode pengamatan tahun 2015 hingga 2024.

Variabel yang digunakan dalam penelitian ini terdiri atas Tingkat Inflasi, Suku Bunga Bank Indonesia (BI-Rate), Harga Energi dan Harga Pangan. Penelitian ini memanfaatkan total 720 observasi yang terbagi secara seimbang pada tiap wilayah pengamatan. Rincian data penelitian dapat dilihat pada **(Lampiran 1)**.

2.2 Variabel Penelitian dan Struktur Data

Penelitian ini menggunakan variabel endogen dan eksogen dalam pemodelan VARX-GSTAR. Variabel endogen terdiri atas Tingkat Inflasi ($Y_{1,i,t}$), sedangkan variabel eksogen yang digunakan meliputi BI-Rate ($X_{1,i,t}$), Harga Energi ($X_{2,i,t}$) dan Harga Pangan ($X_{3,i,t}$).

Data yang digunakan dalam penelitian ini selanjutnya dibagi menjadi dua bagian, yaitu data *training* dan data *testing*, dengan proporsi masing-masing 80% dan 20% dari keseluruhan data. Data *training* mencakup periode tahun 2015 hingga 2022 sebanyak 576 observasi dan digunakan untuk pembentukan model. Data *testing* mencakup periode tahun 2023 hingga 2024 sebanyak 144 observasi dan digunakan untuk mengevaluasi akurasi hasil peramalan. Struktur data penelitian ditampilkan pada Tabel 1.

Tabel 1. Struktur Data

t	i	$(Y_{1,i,t})$	$(X_{1,i,t})$	$(X_{2,i,t})$	$(X_{3,i,t})$
2015	DKI Jakarta	$Y_{1,1,1}$	$X_{1,1,1}$	$X_{2,1,1}$	$X_{3,1,1}$
	Jawa Barat	$Y_{1,2,1}$	$X_{1,2,1}$	$X_{2,2,1}$	$X_{3,2,1}$
	Jawa Tengah	$Y_{1,3,1}$	$X_{1,3,1}$	$X_{2,3,1}$	$X_{3,3,1}$
	DI Yogyakarta	$Y_{1,4,1}$	$X_{1,4,1}$	$X_{2,4,1}$	$X_{3,4,1}$
	Jawa Timur	$Y_{1,5,1}$	$X_{1,5,1}$	$X_{2,5,1}$	$X_{3,5,1}$
	Banten	$Y_{1,6,1}$	$X_{1,6,1}$	$X_{2,6,1}$	$X_{3,6,1}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
2024	DKI Jakarta	$Y_{1,1,10}$	$X_{1,1,10}$	$X_{2,1,10}$	$X_{3,1,10}$
	Jawa Barat	$Y_{1,2,10}$	$X_{1,2,10}$	$X_{2,2,10}$	$X_{3,2,10}$
	Jawa Tengah	$Y_{1,3,10}$	$X_{1,3,10}$	$X_{2,3,10}$	$X_{3,3,10}$
	DI Yogyakarta	$Y_{1,4,10}$	$X_{1,4,10}$	$X_{2,4,10}$	$X_{3,4,10}$
	Jawa Timur	$Y_{1,5,10}$	$X_{1,5,10}$	$X_{2,5,10}$	$X_{3,5,10}$
	Banten	$Y_{1,6,10}$	$X_{1,6,10}$	$X_{2,6,10}$	$X_{3,6,10}$

2.3 Tahapan Analisis

Tahapan analisis yang digunakan dalam penelitian ini adalah:

1. Mengumpulkan data sekunder bulanan periode Januari 2015 hingga Desember 2024 dari Badan Pusat Statistik (BPS). Data meliputi tingkat inflasi sebagai variabel endogen, serta BI-Rate, harga energi, dan harga pangan sebagai variabel eksogen di enam provinsi Pulau Jawa.
2. Menyusun data secara berurutan berdasarkan waktu (*time series*) untuk setiap provinsi secara simultan, serta memeriksa kelengkapan seluruh data variabel penelitian.
3. Membagi data menjadi dua bagian, yaitu 80% data *training* (Januari 2015 – Desember 2022) untuk pembentukan model dan 20% data *testing* (Januari 2023 – Desember 2024) untuk evaluasi kinerja model.
4. Memeriksa kestasioneran setiap variabel pada tingkat asli (*level*) menggunakan uji *Augmented Dickey Fuller* (ADF) sesuai Persamaan uji ADF (10). Jika data tidak stasioner, dilakukan proses pembedaan (*differencing*).

$$t_{hitung} = \frac{\hat{\gamma}}{SE(\hat{\gamma})}$$

5. Menentukan panjang *lag* waktu (p) optimal model VAR berdasarkan nilai *Akaike Information Criterion* (AIC) terkecil sesuai Persamaan Kriteria AIC (11).

$$AIC_{(p)} = \ln|\hat{\Sigma}_p| + \frac{2pn^2}{T}$$

6. Menganalisis keterkaitan spasial dan spasio-temporal antarprovinsi menggunakan matriks *cross-correlation* untuk mengidentifikasi arah, kekuatan, dan signifikansi hubungan antarwilayah yang selanjutnya digunakan sebagai dasar pembentukan matriks bobot normalisasi korelasi silang pada model VARX-GSTAR.
7. Menghitung matriks pembobot lokasi (W) menggunakan metode Invers Jarak sesuai Persamaan Bobot Invers Jarak (13) dan Normalisasi Korelasi Silang sesuai Persamaan Bobot Normalisasi Korelasi Silang (14).

$$w_{ij} = \begin{cases} \frac{w_{ij}^*}{\sum_{j=1, j \neq i}^n w_{ij}^*}, & i \neq j \\ 0, & i = j \end{cases}$$

$$w_{ij} = \frac{r_{ij}(k)}{\sum_{j \neq i} |r_{ij}(k)|}, \text{ dengan } i \neq j, k = 1, 2, \dots, p$$

8. Menyusun matriks variabel endogen (Y) dan variabel eksogen (X) untuk membentuk variabel-variabel *lag* temporal (Y_{t-1}), *lag* spasial (WY_{t-1}), dan variabel eksogen (X_t) sebagai variabel prediktor yang digunakan dalam estimasi parameter model VARX-GSTAR.
9. Mengestimasi parameter model VARX-GSTAR menggunakan metode *Ordinary Least Squares* (OLS) sesuai Persamaan Estimasi OLS (21).

$$\hat{\beta} = (Z'Z)^{-1}Z'Y$$

10. Memilih model terbaik berdasarkan nilai *Akaike Information Criterion* (AIC), *Root Mean Square Error* (RMSE), dan *Adjusted R²* dari lima model yang dibentuk, sehingga diperoleh model VARX, GSTAR, dan VARX-GSTAR dengan kinerja terbaik.
11. Menguji stabilitas model untuk memastikan semua akar karakteristik berada di dalam unit *circle* ($|\lambda_i| \leq 1$) agar sistem tidak bersifat divergen. Model dinyatakan stabil jika memenuhi Persamaan uji Stabilitas (23).

$$\det \left(\mathbf{I}_k - \sum_{i=1}^p \mathbf{A}_i \lambda^i \right) \neq 0$$

12. Menguji asumsi *white noise* pada residual model menggunakan uji *Ljung-Box* sesuai Persamaan uji *Ljung-Box* (24).

$$Q_{LB} = n(n+2) \sum_{k=1}^m \left(\frac{\hat{\rho}_k^2}{n-k} \right)$$

13. Melakukan *fitting* model VARX-GSTAR pada data *training* untuk melihat kesesuaian antara nilai hasil estimasi dan pola data aktual melalui visualisasi.
14. Melakukan peramalan pada data *testing* dan mengevaluasi kinerja peramalan berdasarkan nilai *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan koefisien korelasi (r) sesuai Persamaan (26), Persamaan (27), dan Persamaan (28).

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

$$r = \frac{\sum_{t=1}^n (y_t - \bar{y})(\hat{y}_t - \bar{\hat{y}})}{\sqrt{\sum_{t=1}^n (y_t - \bar{y})^2 \sum_{t=1}^n (\hat{y}_t - \bar{\hat{y}})^2}}$$

15. Menggunakan model terbaik hasil evaluasi untuk melakukan peramalan tingkat inflasi enam provinsi di Pulau Jawa periode 2025–2028 dengan asumsi nilai rata-rata historis variabel eksogen sebagai input peramalan.

BAB III HASIL DAN PEMBAHASAN

3.1 Identifikasi Data

Identifikasi awal data dilakukan melalui analisis statistik deskriptif data enam provinsi di Pulau Jawa, yaitu DKI Jakarta, Jawa Barat, Jawa Tengah, DI Yogyakarta, Jawa Timur, dan Banten, selama periode 2015–2024 dengan total 720 observasi. Analisis ini bertujuan untuk menggambarkan karakteristik variabel penelitian melalui ukuran pemusatan dan penyebaran data, meliputi nilai rata-rata, standar deviasi, variansi, serta nilai minimum dan maksimum. Hasil statistik deskriptif memberikan gambaran awal mengenai pola inflasi regional dan variabel makroekonomi yang diduga memengaruhinya, serta menjadi dasar dalam mengidentifikasi variasi spasial dan temporal antarprovinsi sebelum dilakukan analisis lanjutan menggunakan model VARX–GSTAR. Ringkasan statistik deskriptif seluruh variabel disajikan pada Tabel 2.


Tabel 2. Statistik Deskriptif

Variabel	Mean	StDev	Variance	Minimum	Maximum
Y (%)	0,24	0,31	0,10	-0,67	1,76
X_1 (%)	5,25	1,24	1,54	3,50	7,75
X_2	126,24	25,55	652,80	99,31	172,61
X_3	130,11	23,40	547,56	101,03	222,81

Sumber: Data diolah, 2026

Tabel 2 menyajikan ringkasan statistik deskriptif variabel Inflasi (Y), BI-Rate (X_1), Harga Energi (X_2), dan Harga Pangan (X_3) selama periode Januari 2015 hingga Desember 2024. Variabel inflasi memiliki rata-rata sebesar 0,24% dengan standar deviasi 0,31. Nilai minimum sebesar -0,67% menunjukkan bahwa pada periode tertentu terjadi deflasi, sedangkan nilai maksimum sebesar 1,76% menunjukkan adanya tekanan inflasi yang relatif tinggi. Variabel BI-Rate memiliki rata-rata sebesar 5,25% dengan standar deviasi 1,24. Variabel harga energi dan harga pangan masing-masing memiliki rata-rata sebesar 126,24 dan 130,11 dengan standar deviasi sebesar 25,55 dan 23,40.

Nilai standar deviasi pada setiap variabel menunjukkan bahwa data mengalami variasi selama periode pengamatan. Perbedaan nilai minimum, maksimum, dan rata-rata pada masing-masing variabel juga menggambarkan adanya perubahan kondisi ekonomi pada setiap periode pengamatan. Pola pergerakan masing-masing variabel selanjutnya disajikan melalui plot runtun waktu (*time series*) pada Gambar 1.



Gambar 1. Plot *Time Series* Inflasi (%) pada Enam Provinsi di Pulau Jawa Tahun 2015–2024.

Gambar 1 menyajikan plot runtun waktu (*time series*) inflasi pada enam provinsi di Pulau Jawa selama periode 2015–2024. Inflasi pada setiap provinsi mengalami fluktuasi dari bulan ke bulan dengan pola pergerakan yang relatif serupa. Kenaikan dan penurunan inflasi terjadi hampir bersamaan pada beberapa periode, meskipun besarnya perubahan berbeda pada setiap provinsi.

Fluktuasi inflasi terlihat cukup tinggi pada beberapa periode, terutama sekitar tahun 2022 hingga 2023, sedangkan pada periode lainnya pergerakan inflasi cenderung lebih stabil. Kemiripan pola pergerakan antarprovinsi menunjukkan adanya keterkaitan pola inflasi di Pulau Jawa. Gambaran tersebut menjadi dasar untuk melakukan analisis lebih lanjut menggunakan model VARX-GSTAR yang mempertimbangkan hubungan antarwaktu dan antarwilayah.

3.2 Kestasioneran Data

Kestasioneran data merupakan salah satu syarat dalam analisis deret waktu karena data yang tidak stasioner dapat menghasilkan model yang kurang baik. Pengujian kestasioneran dilakukan menggunakan metode *Augmented Dickey-Fuller* (ADF) untuk mengetahui ada atau tidaknya akar unit pada setiap variabel. Hasil uji ADF untuk variabel Inflasi (Y), BI-Rate (X_1), Harga Energi (X_2), dan Harga Pangan (X_3) pada enam provinsi di Pulau Jawa disajikan pada Tabel 3.

Tabel 3. Hasil Uji ADF pada Data Tingkat Inflasi, BI-Rate, Harga Energi, dan Harga Pangan

Provinsi	Variabel	<i>p-value</i>	Keterangan
DKI Jakarta	Y	0,01	Stasioner
	X_1	0,01	Stasioner (<i>diff 1</i>)
	X_2	0,01	Stasioner (<i>diff 1</i>)
	X_3	0,01	Stasioner (<i>diff 1</i>)
Jawa Barat	Y	0,01	Stasioner
	X_1	0,01	Stasioner (<i>diff 1</i>)
	X_2	0,01	Stasioner (<i>diff 1</i>)
	X_3	0,01	Stasioner (<i>diff 1</i>)

Provinsi	Variabel	<i>p-value</i>	Keterangan
Jawa Tengah	Y	0,01	Stasioner
	X_1	0,01	Stasioner (<i>diff 1</i>)
	X_2	0,01	Stasioner (<i>diff 1</i>)
	X_3	0,01	Stasioner (<i>diff 1</i>)
DI Yogyakarta	Y	0,01	Stasioner
	X_1	0,01	Stasioner (<i>diff 1</i>)
	X_2	0,01	Stasioner (<i>diff 1</i>)
	X_3	0,01	Stasioner (<i>diff 1</i>)
Jawa Timur	Y	0,01	Stasioner
	X_1	0,01	Stasioner (<i>diff 1</i>)
	X_2	0,01	Stasioner (<i>diff 1</i>)
	X_3	0,01	Stasioner (<i>diff 1</i>)
Banten	Y	0,01	Stasioner
	X_1	0,01	Stasioner (<i>diff 1</i>)
	X_2	0,01	Stasioner (<i>diff 1</i>)
	X_3	0,01	Stasioner (<i>diff 1</i>)

Sumber: Data diolah, 2026

Tabel 3 menyajikan hasil uji stasioneritas pada tingkat *level* dan *first difference*. Hasil pengujian menunjukkan bahwa variabel inflasi telah stasioner pada tingkat *level*, sedangkan variabel BI-Rate, harga energi, dan harga pangan belum stasioner pada tingkat *level* sehingga dilakukan transformasi *first difference*. Hasil pengujian setelah transformasi menunjukkan bahwa ketiga variabel tersebut telah stasioner dengan nilai *p-value* kurang dari 0,05 pada seluruh provinsi. Kondisi tersebut menunjukkan bahwa seluruh variabel telah memenuhi syarat kestasioneran sehingga dapat digunakan pada tahap analisis dan pemodelan VARX-GSTAR.

3.3 Identifikasi Model

Tahap identifikasi model bertujuan untuk menentukan struktur model VARX-GSTAR yang akan digunakan dalam penelitian. Identifikasi dilakukan dengan menentukan orde *lag* waktu (p) dan orde *lag* spasial (s) agar model mampu menggambarkan hubungan antarwaktu dan antarwilayah secara tepat.

Penentuan orde *lag* waktu (p) dilakukan menggunakan model VAR pada variabel endogen dengan mempertimbangkan nilai *Akaike Information Criterion* (AIC), *Hannan-Quinn Criterion* (HQ), dan *Schwarz Criterion* (SC). Hasil penentuan *lag* optimal disajikan pada Tabel 4.

Tabel 4. Hasil Penentuan *Lag* Optimal Berdasarkan Kriteria Informasi

Kriteria Informasi	<i>Lag 1</i>	<i>Lag 2</i>	...	<i>Lag 10</i>
AIC	-18,843	-19,230	...	-27,029
HQ	-17,110	-17,080	...	-17,055
SC	-14,533	-13,885	...	-14,533

Sumber: Data diolah, 2026

Tabel 4 menyajikan hasil pemilihan *lag* berdasarkan setiap kriteria informasi yang menghasilkan rekomendasi *lag* yang berbeda. Kriteria AIC menunjukkan nilai terkecil pada *lag* 10, sedangkan nilai HQ dan SC memperoleh nilai terkecil pada *lag*

1. Penelitian ini menetapkan *lag* 1 sebagai orde *lag* optimal dengan mempertimbangkan kriteria SC dan HQ serta prinsip parsimoni. Pertimbangan tersebut diambil untuk mencegah kompleksitas model yang berlebihan sekaligus menjaga agar model tetap sederhana dan mampu menggambarkan karakteristik data. Hasil identifikasi *lag* 1 hingga *lag* 10 disajikan pada (**Lampiran 4**).

Penentuan orde *lag* spasial (*s*) dilakukan untuk menggambarkan pengaruh antarwilayah dalam model VARX-GSTAR. Penelitian ini menggunakan *lag* spasial satu sehingga hubungan spasial yang dipertimbangkan berasal dari satu periode sebelumnya melalui matriks pembobot yang digunakan pada model. Pemilihan *lag* spasial satu juga bertujuan untuk menjaga struktur model tetap sederhana dan memudahkan proses estimasi parameter.

Hasil identifikasi menunjukkan bahwa model yang digunakan dalam penelitian adalah VARX-GSTAR(1,1). Bentuk umum model tersebut dapat dituliskan sebagai berikut.

$$Y_t = \alpha + \Gamma_{10}Y_{t-1} + \Gamma_{11}WY_{t-1} + \theta_0\Delta X_t + \varepsilon_t$$

Model VARX-GSTAR(1,1) selanjutnya digunakan pada tahap estimasi parameter untuk menganalisis hubungan temporal, spasial, dan pengaruh variabel prediktor terhadap inflasi pada enam provinsi di Pulau Jawa.

3.4 Analisis Keterkaitan Spasio-Temporal

Analisis keterkaitan spasio-temporal bertujuan untuk mengetahui hubungan inflasi antarprovinsi di Pulau Jawa dari aspek spasial maupun temporal. Penelitian ini menggunakan pendekatan *cross-correlation* untuk mengukur hubungan antarprovinsi berdasarkan data inflasi, kemudian hasilnya digunakan sebagai dasar pembentukan matriks bobot spasial pada model VARX-GSTAR. Analisis dilakukan pada dua kondisi, yaitu keterkaitan spasial kontemporer ($k = 0$) dan keterkaitan spasio-temporal ($k = 1$) (Chen, 2015; Lun et al., 2023).

3.4.1 Keterkaitan Spasial Kontemporer ($k = 0$)

Keterkaitan spasial kontemporer digunakan untuk mengukur hubungan inflasi antarprovinsi pada periode yang sama. Hasil pengujian disajikan pada Tabel 5.

Tabel 5. Matriks Keterkaitan Kontemporer Antarprovinsi di Pulau Jawa ($k = 0$)

Provinsi	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
DKI Jakarta	1,0000	0,7604	0,7640	0,7404	0,7504	0,7528
Jawa Barat	0,7604	1,0000	0,8057	0,7240	0,7431	0,8044
Jawa Tengah	0,7640	0,8057	1,0000	0,8716	0,8232	0,7972
DI Yogyakarta	0,7404	0,7240	0,8716	1,0000	0,8647	0,7574
Jawa Timur	0,7504	0,7431	0,8232	0,8647	1,0000	0,7618
Banten	0,7528	0,8044	0,7972	0,7574	0,7618	1,0000

Sumber: Data diolah, 2026

Tabel 5 menyajikan seluruh pasangan provinsi memiliki koefisien korelasi positif dengan nilai antara 0,7240 sampai 0,8716. Nilai tersebut menunjukkan bahwa pergerakan inflasi antarprovinsi pada periode yang sama memiliki hubungan yang kuat. Korelasi tertinggi terdapat antara Jawa Tengah dan DI Yogyakarta dengan nilai sebesar 0,8716.

Hasil pengujian menunjukkan bahwa seluruh pasangan provinsi memiliki p -value kurang dari 0,05. Hasil tersebut menunjukkan bahwa H_0 ditolak pada seluruh pasangan provinsi, sehingga hubungan inflasi antarprovinsi pada periode yang sama signifikan secara statistik. Nilai korelasi yang seluruhnya positif menunjukkan bahwa pergerakan inflasi pada suatu provinsi cenderung searah dengan pergerakan inflasi pada provinsi lain dalam periode yang sama.

3.4.2 Keterkaitan Spasio-Temporal ($k = 1$)

Keterkaitan spasio-temporal digunakan untuk mengukur hubungan antara inflasi suatu provinsi pada periode sebelumnya ($t - 1$) dengan inflasi provinsi lain pada periode berjalan (t). Hasil pengujian disajikan pada Tabel 6.

Tabel 6. Matriks Keterkaitan Spasio-Temporal Antarprovinsi dengan Jeda Satu Bulan ($k = 1$)

Provinsi	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
DKI Jakarta	0,0898	0,2289	0,1648	0,1803	0,1496	0,1855
Jawa Barat	0,0731	0,1327	0,1635	0,1542	0,1148	0,1435
Jawa Tengah	0,0588	0,1933	0,1263	0,1579	0,1467	0,1676
DI Yogyakarta	0,1493	0,3389	0,2374	0,2654	0,2563	0,2805
Jawa Timur	0,0927	0,2526	0,1463	0,2115	0,1860	0,2549
Banten	0,1233	0,2138	0,1702	0,1910	0,1109	0,2057

Sumber: Data diolah, 2026

Tabel 6 menyajikan seluruh pasangan provinsi memiliki koefisien korelasi positif dengan nilai antara 0,0588 sampai 0,3389. Nilai tersebut lebih rendah dibandingkan dengan korelasi pada kondisi kontemporer. Korelasi tertinggi terdapat pada hubungan antara inflasi Jawa Barat pada periode $t - 1$ dengan inflasi DI Yogyakarta pada periode t , yaitu sebesar 0,3389.

Hasil pengujian p -value menunjukkan bahwa tidak seluruh pasangan provinsi memiliki keterkaitan yang signifikan pada lag satu periode. Matriks p -value disajikan pada Tabel 7.

Tabel 7. Matriks p -value Keterkaitan Spasio-Temporal Antarprovinsi ($k = 1$)

Provinsi	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
DKI Jakarta	0.3895	0.0265	0.1125	0.0820	0.1500	0.0735
Jawa Barat	0.4837	0.2024	0.1154	0.1378	0.2705	0.1677
Jawa Tengah	0.5733	0.0619	0.2249	0.1286	0.1582	0.1063
DI Yogyakarta	0.1509	0.0008	0.0213	0.0097	0.0127	0.0062
Jawa Timur	0.3740	0.0140	0.1594	0.0408	0.0727	0.0132

Provinsi	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Banten	0.2366	0.0385	0.1011	0.0652	0.2873	0.0468

Sumber: Data diolah, 2026

Tabel 7 menyajikan beberapa pasangan provinsi yang memiliki *p-value* kurang dari 0,05. Hubungan tersebut dinyatakan signifikan secara statistik pada taraf 5% karena nilai *p-value* lebih kecil dari 0,05. Pasangan provinsi yang memiliki hubungan signifikan meliputi DKI Jakarta pada periode t dengan Jawa Barat pada periode $t - 1$, DI Yogyakarta pada periode t dengan Jawa Barat, Jawa Tengah, DI Yogyakarta, Jawa Timur, dan Banten pada periode $t - 1$, Jawa Timur pada periode t dengan Jawa Barat, DI Yogyakarta, dan Banten pada periode $t - 1$, serta Banten pada periode t dengan Jawa Barat dan Banten pada periode $t - 1$.

Hubungan korelasi tertinggi terdapat antara inflasi Jawa Barat pada periode $t - 1$ dengan inflasi DI Yogyakarta pada periode t , yaitu sebesar 0,3389 dengan *p-value* sebesar 0,0008. Nilai korelasi positif menunjukkan bahwa pergerakan inflasi kedua provinsi cenderung bergerak searah. Nilai *p-value* yang lebih kecil dari 0,05 menunjukkan bahwa hubungan tersebut signifikan secara statistik.

Hasil analisis menunjukkan bahwa keterkaitan inflasi antarprovinsi terdapat pada kondisi kontemporer maupun dengan jeda satu periode. Nilai korelasi pada kondisi kontemporer lebih tinggi dibandingkan dengan korelasi pada *lag* satu periode. Koefisien korelasi yang diperoleh digunakan sebagai dasar pembentukan matriks bobot normalisasi korelasi silang pada model VARX-GSTAR.

3.5 Pembobot Lokasi

Model VARX-GSTAR menggunakan pembobot lokasi untuk menggambarkan hubungan spasial antarprovinsi. Penelitian ini menggunakan dua jenis pembobot, yaitu pembobot invers jarak dan pembobot normalisasi korelasi silang. Pembobot invers jarak menggambarkan kedekatan geografis antarwilayah, sedangkan pembobot normalisasi korelasi silang menggambarkan kekuatan hubungan berdasarkan pola data antarprovinsi.

A. Bobot Invers Jarak

Pembobot invers jarak disusun berdasarkan jarak geografis antar-ibu kota provinsi di Pulau Jawa. Bobot dihitung menggunakan kebalikan dari jarak antarprovinsi ($1/d_{ij}$). Nilai tersebut kemudian dinormalisasi sehingga jumlah bobot pada setiap baris bernilai satu. Provinsi yang memiliki jarak lebih dekat akan memperoleh bobot yang lebih besar dibandingkan provinsi yang letaknya lebih jauh. Data jarak antarprovinsi yang digunakan dalam penelitian ini disajikan pada (**Lampiran 5**), sedangkan matriks pembobot invers jarak ditunjukkan sebagai berikut.

$$W = \begin{bmatrix} 0 & 0,3004 & 0,0870 & 0,0817 & 0,0527 & 0,4783 \\ 0,3689 & 0 & 0,1363 & 0,1307 & 0,0749 & 0,2892 \\ 0,1098 & 0,1400 & 0 & 0,4882 & 0,1690 & 0,0930 \\ 0,1050 & 0,1368 & 0,4975 & 0 & 0,1709 & 0,0897 \\ 0,1231 & 0,1425 & 0,3128 & 0,3106 & 0 & 0,1110 \\ 0,5287 & 0,2603 & 0,0814 & 0,0771 & 0,0525 & 0 \end{bmatrix}$$

Matriks pembobot invers jarak menunjukkan bahwa hubungan spasial ditentukan oleh kedekatan geografis antarprovinsi. Matriks yang diperoleh telah memenuhi syarat pembobot spasial, yaitu seluruh elemen diagonal bernilai nol dan jumlah bobot pada setiap baris sama dengan satu.

B. Bobot Normalisasi Korelasi Silang

Pembobot Normalisasi Korelasi Silang disusun berdasarkan nilai korelasi antarprovinsi. Nilai korelasi silang dihitung untuk setiap pasangan provinsi untuk mengetahui kekuatan dan signifikansi hubungan antarprovinsi. Nilai tersebut kemudian dinormalisasi sehingga jumlah bobot pada setiap baris sama dengan satu. Matriks pembobot normalisasi korelasi silang yang digunakan dalam penelitian ini ditunjukkan sebagai berikut.

$$W = \begin{bmatrix} 0 & 0,2022 & 0,2037 & 0,1942 & 0,1973 & 0,2025 \\ 0,1996 & 0 & 0,2117 & 0,1852 & 0,1919 & 0,2115 \\ 0,1884 & 0,1984 & 0 & 0,2129 & 0,2028 & 0,1976 \\ 0,1872 & 0,1809 & 0,2220 & 0 & 0,2210 & 0,1889 \\ 0,1890 & 0,1862 & 0,2101 & 0,2195 & 0 & 0,1953 \\ 0,1966 & 0,2080 & 0,2074 & 0,1902 & 0,1979 & 0 \end{bmatrix}$$

Matriks pembobot normalisasi korelasi silang menunjukkan bahwa provinsi yang memiliki hubungan data lebih kuat akan memperoleh bobot yang lebih besar dibandingkan provinsi dengan hubungan yang lebih lemah. Pembobot ini memungkinkan model menangkap keterkaitan spasial berdasarkan pola pergerakan data, sehingga tidak hanya mempertimbangkan kedekatan geografis.

Kedua matriks pembobot yang telah disusun selanjutnya digunakan pada tahap pengujian keterkaitan spasial dan spasio-temporal. Pengujian tersebut dilakukan untuk mengetahui adanya hubungan antarprovinsi berdasarkan struktur spasial dan hubungan antarwaktu sebelum model VARX-GSTAR dibentuk.

3.6 Penyusunan Matriks Variabel

Tahap awal estimasi parameter model VARX-GSTAR dilakukan dengan menyusun data ke dalam bentuk matriks variabel endogen (Y) dan matriks variabel eksogen (X). Penyusunan matriks dilakukan agar data lebih mudah diolah pada proses pembentukan model VARX-GSTAR. Matriks variabel endogen (Y) berisi data inflasi enam provinsi di Pulau Jawa. Setiap baris menunjukkan periode pengamatan, sedangkan setiap kolom menunjukkan provinsi yang diamati. Tampilan sebagian matriks variabel endogen (Y) disajikan pada Tabel 8.

Tabel 8. Tampilan Sebagian Matriks Variabel Endogen (Y_t)

Periode	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Mar-15	0,19	0,61	0,25	0,15	0,36	0,36
Apr-15	0,27	0,43	0,17	0,38	0,41	0,71
Mei-15	0,34	0,28	0,54	0,36	0,39	0,72
Jun-15	0,35	0,72	0,64	0,35	0,54	0,60
Jul-15	0,97	0,85	0,91	0,63	0,38	0,83
Agu-15	0,51	0,49	0,28	0,33	0,48	0,72
Sep-15	0,01	-0,01	-0,18	0,04	0,26	-0,08
Okt-15	-0,05	-0,06	-0,16	0,01	-0,34	-0,04
Nov-15	0,12	0,19	0,21	0,13	-0,02	0,33
Des-15	0,72	0,78	1,04	0,96	0,94	0,99

Sumber: Data diolah, 2026

Tabel 8 menyajikan sebagian matriks variabel endogen (Y_t) yang memuat data inflasi bulanan enam provinsi di Pulau Jawa. Matriks ini menjadi dasar dalam pembentukan komponen *lag* temporal (Y_{t-1}) dan *lag* spasial (WY_{t-1}) yang digunakan pada model VARX-GSTAR. Struktur matriks disusun berdasarkan urutan waktu sehingga hubungan antarperiode dapat dibentuk pada tahap estimasi parameter. Tampilan sebagian matriks variabel eksogen disajikan pada Tabel 9, Tabel 10, dan Tabel 11.

Tabel 9. Tampilan Sebagian Matriks Variabel Eksogen BI-Rate (X_{1t})

Periode	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Mar-15	7,5	7,5	7,5	7,5	7,5	7,5
Apr-15	7,5	7,5	7,5	7,5	7,5	7,5
Mei-15	7,5	7,5	7,5	7,5	7,5	7,5
Jun-15	7,5	7,5	7,5	7,5	7,5	7,5
Jul-15	7,5	7,5	7,5	7,5	7,5	7,5
Agu-15	7,5	7,5	7,5	7,5	7,5	7,5
Sep-15	7,5	7,5	7,5	7,5	7,5	7,5
Okt-15	7,5	7,5	7,5	7,5	7,5	7,5
Nov-15	7,5	7,5	7,5	7,5	7,5	7,5
Des-15	7,5	7,5	7,5	7,5	7,5	7,5

Sumber: Data diolah, 2026

Tabel 10. Tampilan Sebagian Matriks Variabel Eksogen Harga Energi (X_{2t})

Periode	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Mar-15	140,79	140,55	127,04	134,26	128,56	143,65
Apr-15	140,01	142,21	127,48	135,25	128,72	144,30
Mei-15	140,93	142,59	128,20	136,73	129,19	144,86
Jun-15	141,73	142,92	128,51	136,94	129,65	145,37
Jul-15	142,01	143,03	128,67	137,48	129,71	145,65
Agu-15	142,38	143,14	128,89	137,54	130,10	145,67
Sep-15	142,61	143,02	128,62	136,95	130,11	145,40
Okt-15	142,14	142,67	128,22	136,18	129,89	144,82

Periode	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Nov-15	141,90	142,51	128,04	136,44	129,66	144,75
Des-15	143,38	144,28	128,79	140,13	130,44	146,51

Sumber: Data diolah, 2026

Tabel 11. Tampilan Sebagian Matriks Variabel Eksogen Harga Pangan (X_{3t})

Periode	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Mar-15	130,44	124,64	125,22	127,39	118,05	129,51
Apr-15	129,28	123,17	123,48	125,00	118,51	129,81
Mei-15	130,54	124,65	125,58	126,02	118,99	132,00
Jun-15	132,28	126,56	127,88	127,08	119,52	134,44
Jul-15	134,92	129,23	131,00	128,57	120,13	137,23
Agu-15	136,62	131,57	132,11	129,70	120,56	137,55
Sep-15	135,77	129,28	129,99	129,68	120,85	135,52
Okt-15	134,19	127,57	129,35	128,79	120,62	133,40
Nov-15	134,07	128,03	129,81	128,96	120,69	133,13
Des-15	137,79	131,84	134,46	132,82	121,71	137,17

Sumber: Data diolah, 2026

Tabel 9 sampai Tabel 11 menyajikan sebagian matriks variabel eksogen yang terdiri atas BI-Rate, harga energi, dan harga pangan. Ketiga matriks disusun dengan struktur yang sama seperti matriks variabel endogen sehingga setiap periode pengamatan dan setiap provinsi memiliki pasangan data yang sesuai. Penyusunan dalam bentuk matriks ini memudahkan proses penggabungan variabel endogen, *lag* temporal, *lag* spasial, dan variabel eksogen pada tahap estimasi parameter menggunakan metode *Ordinary Least Squares* (OLS).

3.7 Estimasi Parameter Model VARX-GSTAR (1,1)

Tahap estimasi parameter bertujuan untuk memperoleh nilai koefisien pada model VARX-GSTAR(1,1). Koefisien tersebut digunakan untuk menjelaskan pengaruh komponen temporal, komponen spasial, dan variabel prediktor terhadap inflasi pada enam provinsi di Pulau Jawa. Metode estimasi yang digunakan adalah s (OLS). Metode ini digunakan karena model VARX-GSTAR(1,1) bersifat linear terhadap parameter yang diestimasi. OLS mengestimasi parameter dengan meminimalkan jumlah kuadrat selisih antara nilai aktual dan nilai hasil estimasi sehingga diperoleh parameter yang paling sesuai dengan data.

Estimasi parameter dilakukan menggunakan pendekatan *equation-by-equation*, yaitu setiap persamaan untuk masing-masing provinsi diestimasi secara terpisah. Pendekatan ini digunakan karena setiap provinsi memiliki karakteristik inflasi yang berbeda sehingga nilai parameter yang dihasilkan tidak harus sama. Struktur model terdiri atas konstanta (β_0), komponen *lag* temporal (Y_{t-1}), komponen *lag* spasial (WY_{t-1}), serta tiga variabel prediktor, yaitu BI-Rate (X_{1t}), Harga Energi (X_{2t}), dan Harga Pangan (X_{3t}). Hasil estimasi untuk Provinsi DKI Jakarta disajikan

pada Tabel 12, sedangkan hasil estimasi untuk lima provinsi lainnya disajikan pada (Lampiran 9 dan Lampiran 10). Hasil estimasi parameter disajikan pada Tabel 12.

Tabel 12. Hasil Estimasi Parameter Model VARX-GSTAR(1,1) pada Provinsi DKI Jakarta

Parameter	Koefisien	Standar Error	t-value	p-value	Keterangan
β_0	-0,1534	0,2236	-0,6862	0,4944	Tidak Signifikan
Y_{t-1}	-0,3131	0,1851	-1,6919	0,0942	Tidak Signifikan
WY_{t-1}	0,3740	0,1529	2,4464	0,0164	Signifikan
X_{1t}	0,0263	0,0269	0,9778	0,3308	Tidak Signifikan
X_{2t}	-0,0018	0,0049	-0,3618	0,7183	Tidak Signifikan
X_{3t}	0,0036	0,0055	0,6531	0,5154	Tidak Signifikan

Sumber: Data diolah, 2026

Tabel 12 menyajikan hasil estimasi parameter model VARX-GSTAR(1,1) untuk Provinsi DKI Jakarta. Hasil pengujian pada taraf signifikansi 5% menunjukkan bahwa komponen *lag* spasial (WY_{t-1}) memiliki pengaruh yang signifikan terhadap inflasi dengan nilai koefisien sebesar 0,3740 dan *p-value* sebesar 0,0164. konstanta, *lag* temporal (Y_{t-1}), BI-Rate (X_{1t}), Harga Energi (X_{2t}), dan Harga Pangan (X_{3t}) belum menunjukkan pengaruh yang signifikan secara parsial.

Berdasarkan hasil estimasi tersebut, model VARX-GSTAR(1,1) untuk Provinsi DKI Jakarta dapat dinyatakan dalam bentuk umum sebagai berikut.

$$Y_t = \alpha + \Gamma_{10}Y_{t-1} + \Gamma_{11}WY_{t-1} + \theta_0\Delta X_t + \varepsilon_t$$

$$= [-0,1534] + [-0,3131]Y_{t-1} + [0,3740]WY_{t-1} + \begin{bmatrix} 0,0263 & -0,0018 \\ 0,0036 & 0,0000 \end{bmatrix} X_t + \varepsilon_t$$

Persamaan tersebut dapat dituliskan dalam bentuk yang lebih sederhana sebagai berikut:

$$Y_t = -0,1534 - 0,3131Y_{t-1} + 0,3740WY_{t-1} + 0,0263\Delta X_{1t} - 0,0018\Delta X_{2t} + 0,0036\Delta X_{3t} + \varepsilon_t$$

Persamaan tersebut menunjukkan bahwa komponen *lag* spasial (WY_{t-1}) memberikan pengaruh yang signifikan terhadap inflasi di Provinsi DKI Jakarta. Koefisien *lag* spasial (WY_{t-1}) yang bernilai positif sebesar 0,3740 menunjukkan bahwa peningkatan inflasi pada wilayah yang memiliki keterkaitan spasial dengan DKI Jakarta pada periode sebelumnya cenderung diikuti oleh peningkatan inflasi di DKI Jakarta pada periode berjalan. Komponen *lag* temporal serta ketiga variabel prediktor tidak menunjukkan pengaruh yang signifikan secara parsial pada taraf signifikansi 5%.

Nilai koefisien determinasi (R^2) sebesar 0,5233 menunjukkan bahwa model mampu menjelaskan 52,33% variasi inflasi di Provinsi DKI Jakarta, sedangkan 47,67% sisanya dipengaruhi oleh faktor lain di luar model. Nilai tersebut menunjukkan bahwa model memiliki kemampuan yang cukup baik dalam menjelaskan variasi inflasi pada provinsi tersebut.

3.8 Kriteria Pemilihan Model

Pemilihan model bertujuan untuk menentukan model yang memberikan kinerja terbaik berdasarkan kriteria evaluasi. Penelitian ini membandingkan lima kandidat model, yaitu VARX, GSTAR dengan bobot invers, GSTAR dengan bobot korelasi, VARX-GSTAR dengan bobot invers, dan VARX-GSTAR dengan bobot korelasi. Kinerja masing-masing model dievaluasi berdasarkan nilai *Akaike Information Criterion* (AIC), *Root Mean Square Error* (RMSE), dan *Adjusted R²*. Nilai AIC dan RMSE yang lebih kecil serta *Adjusted R²* yang lebih besar menunjukkan kinerja model yang lebih baik. Hasil perbandingan lima kandidat model berdasarkan nilai AIC, RMSE, dan *Adjusted R²* menunjukkan tiga model dengan kinerja terbaik, yang disajikan pada Tabel 13.

Tabel 13. Kriteria Pemilihan Model

Model	AIC	RMSE	<i>Adjusted R²</i>
VARX	339,9255	0,3080	0,4293
GSTAR (Bobot Korelasi)	327,4553	0,3115	0,4297
VARX-GSTAR (Bobot Korelasi)	342,6120	0,3058	0,4319

Sumber: Data diolah, 2026

Tabel 13 menyajikan hasil perbandingan kinerja model VARX, GSTAR, dan VARX-GSTAR berdasarkan nilai AIC, RMSE, dan *Adjusted R²*. Model GSTAR dengan bobot korelasi menghasilkan nilai AIC paling kecil, yaitu 327,4553, sedangkan VARX-GSTAR dengan bobot korelasi menghasilkan nilai RMSE paling rendah sebesar 0,3058 serta nilai *Adjusted R²* paling tinggi sebesar 0,4319. Berdasarkan perbandingan ketiga kriteria, model VARX-GSTAR dengan bobot normalisasi korelasi silang dipilih karena memberikan nilai RMSE terendah dan *Adjusted R²* tertinggi, meskipun nilai AIC terendah diperoleh oleh model GSTAR.

3.9 Uji Stabilitas Model

Uji stabilitas model dilakukan untuk mengetahui apakah model yang terbentuk memenuhi syarat kestabilan sehingga dapat digunakan pada tahap analisis berikutnya. Pengujian dilakukan menggunakan nilai modulus akar karakteristik (*eigenvalue*) dari matriks koefisien model. Model dinyatakan stabil apabila seluruh nilai modulus *eigenvalue* lebih kecil dari satu ($|\lambda_i| < 1$). Kondisi tersebut menunjukkan bahwa pengaruh suatu kejadian pada periode sebelumnya akan semakin berkurang seiring waktu sehingga model tetap berada pada kondisi yang stabil. Hasil uji stabilitas ketiga model disajikan pada Tabel 14.

Tabel 14. Perbandingan Hasil Uji Stabilitas Model

Model	Modulus ($ \lambda_i $)	Kriteria Stabilitas
VARX	0,2498	Stabil ($ \lambda_i < 1$)
GSTAR	0,2636	Stabil ($ \lambda_i < 1$)
VARX-GSTAR	0,3415	Stabil ($ \lambda_i < 1$)

Sumber: Data diolah, 2026

Tabel 14 menyajikan hasil uji stabilitas model VARX, GSTAR, dan VARX-GSTAR berdasarkan nilai modulus *eigenvalue*. Nilai modulus masing-masing model sebesar 0,2498, 0,2636, dan 0,3415, yang seluruhnya lebih kecil dari satu. Hasil tersebut menunjukkan bahwa ketiga model memenuhi kriteria stabilitas. Kondisi ini menunjukkan bahwa pengaruh gangguan pada suatu periode akan semakin berkurang pada periode berikutnya sehingga model tidak mengalami penyimpangan. Model yang telah memenuhi syarat stabilitas selanjutnya dapat digunakan pada tahap pengujian asumsi *white noise*.

3.10 Uji Asumsi *White Noise*

Uji asumsi *white noise* dilakukan untuk mengetahui apakah residual model VARX-GSTAR masih mengandung autokorelasi. Residual yang memenuhi asumsi *white noise* menunjukkan bahwa pola data telah mampu dijelaskan oleh model sehingga sisa kesalahan bersifat acak. Pengujian dilakukan menggunakan uji *Ljung-Box* dan *Box-Pierce*. Hipotesis nol (H_0) menyatakan bahwa residual bersifat *white noise*, sedangkan hipotesis alternatif (H_1) menyatakan bahwa residual tidak bersifat *white noise*. Keputusan pengujian ditentukan berdasarkan nilai *p-value*, yaitu H_0 gagal ditolak apabila *p-value* lebih besar dari 0,05. Hasil pengujian disajikan pada Tabel 15.

Tabel 15. Hasil Uji Asumsi *White Noise* Model VARX-GSTAR


Uji	Statistik uji (X^2)	df	<i>p-value</i>	Kesimpulan
<i>Ljung-Box</i>	0,3696	1	0,5970	<i>White Noise</i>
<i>Box-Pierce</i>	0,3581	1	0,6024	<i>White Noise</i>

Sumber: Data diolah, 2026

Tabel 15 menyajikan hasil uji *white noise* menggunakan uji *Ljung-Box* dan *Box-Pierce*. Nilai *p-value* masing-masing sebesar 0,5970 dan 0,6024, lebih besar dari taraf nyata 5%, sehingga H_0 gagal ditolak. Hasil tersebut menunjukkan bahwa residual model tidak mengandung autokorelasi. Kondisi ini menunjukkan bahwa model telah mampu menjelaskan pola data dengan baik sehingga sisa kesalahan bersifat acak. Model VARX-GSTAR dengan demikian memenuhi asumsi *white noise* dan dapat digunakan pada tahap analisis berikutnya.

3.11 Visualisasi Hasil *Fitting* Model VARX-GSTAR

Visualisasi hasil *fitting* dilakukan untuk membandingkan pola data inflasi pada data *training* dengan hasil estimasi yang diperoleh dari model VARX-GSTAR. Tahap ini bertujuan untuk melihat sejauh mana model mampu mengikuti pola pergerakan data sebelum digunakan pada proses peramalan. Hasil visualisasi disajikan Gambar 2.



Gambar 2. Plot Hasil *Fitting* Model VARX-GSTAR pada Data *Training* Enam Provinsi di Pulau Jawa

Gambar 2 menyajikan perbandingan pola data inflasi pada data *training* dengan hasil *fitting* model VARX-GSTAR untuk enam provinsi di Pulau Jawa. Hasil *fitting* mengikuti perubahan data inflasi pada setiap provinsi, baik saat terjadi kenaikan maupun penurunan. Perbedaan masih terlihat pada beberapa periode, terutama saat terjadi perubahan inflasi yang cukup tajam. Hasil *fitting* tetap mendekati pola data aktual. Hasil tersebut menunjukkan bahwa model VARX-GSTAR mampu mengikuti pola pergerakan inflasi pada data *training* dengan cukup baik sehingga dapat digunakan pada tahap peramalan.

3.12 Forecasting

Tahap peramalan dilakukan untuk mengevaluasi kemampuan model dalam memprediksi tingkat inflasi pada data *testing*. Model yang dibandingkan meliputi VARX, GSTAR, dan VARX-GSTAR. Kinerja masing-masing model dievaluasi menggunakan *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan koefisien korelasi (r). Nilai RMSE dan MAE yang lebih kecil menunjukkan tingkat kesalahan peramalan yang lebih rendah, sedangkan nilai koefisien korelasi yang semakin mendekati satu menunjukkan kesesuaian yang semakin baik antara data aktual dan hasil peramalan. Hasil evaluasi ketiga model disajikan pada Tabel 16.


Tabel 16. Perbandingan Hasil Peramalan Tiga Model pada Data *Testing* Enam Provinsi di Pulau Jawa

Model	RMSE	MAE (%)	Korelasi
VARX	0,1436	0,1161	0,8214
GSTAR	0,1141	0,0916	0,8817
VARX-GSTAR	0,0823	0,0643	0,9422

Sumber: Data diolah, 2026

Tabel 16 menyajikan hasil evaluasi kinerja model VARX, GSTAR, dan VARX-GSTAR pada data *testing*. Model VARX-GSTAR menghasilkan nilai RMSE sebesar 0,0823 dan MAE sebesar 0,0643%, yang merupakan nilai terkecil dibandingkan

kedua model lainnya. Model ini juga memiliki nilai koefisien korelasi sebesar 0,9422, lebih tinggi dibandingkan model VARX maupun GSTAR. Nilai tersebut menunjukkan bahwa hasil peramalan model VARX-GSTAR memiliki tingkat kesalahan yang lebih rendah dan hubungan yang lebih kuat dengan data aktual pada periode pengujian. Perbandingan pola hasil peramalan ketiga model terhadap data aktual selanjutnya disajikan pada Gambar 3.



Gambar 3. Plot Perbandingan Data Aktual dengan Hasil Peramalan Tiga Model pada Data *Testing*

Gambar 3 menyajikan perbandingan antara data aktual dan hasil peramalan model VARX, GSTAR, dan VARX-GSTAR pada data *testing*. Ketiga model mampu mengikuti pola perubahan inflasi selama periode pengamatan, namun tingkat kedekatannya terhadap data aktual berbeda. Model VARX-GSTAR menghasilkan pola peramalan yang paling mendekati data aktual pada sebagian besar periode pengamatan. Garis hasil peramalan VARX-GSTAR terlihat lebih sering berimpit dengan garis data aktual dibandingkan model VARX maupun GSTAR. Model GSTAR juga mampu mengikuti pola perubahan inflasi, meskipun pada beberapa periode masih terlihat penyimpangan dari data aktual. Model VARX menunjukkan selisih yang relatif lebih besar, terutama ketika terjadi perubahan inflasi yang cukup tajam.

Nilai RMSE, MAE, dan koefisien korelasi pada Tabel 16 mendukung hasil visual tersebut. Model VARX-GSTAR menghasilkan nilai RMSE sebesar 0,0823 dan MAE sebesar 0,0643%, yang merupakan nilai terkecil di antara ketiga model, serta koefisien korelasi sebesar 0,9422 yang menunjukkan hubungan yang sangat kuat antara data aktual dan hasil peramalan. Model VARX-GSTAR dipilih sebagai model yang digunakan pada tahap peramalan inflasi bulanan periode 2025–2028. Nilai variabel prediktor pada periode tersebut tidak tersedia dalam data penelitian sehingga proses peramalan dilakukan menggunakan nilai rata-rata historis sebagai asumsi input variabel prediktor. Ringkasan hasil peramalan inflasi bulanan periode 2025–2028 disajikan pada Tabel 17.

Tabel 17. Rata-Rata Hasil Peramalan Tingkat Inflasi Bulanan pada Enam Provinsi di Pulau Jawa Menggunakan VARX-GSTAR Periode 2025-2028

Provinsi	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
2025	0,23	0,33	0,27	0,23	0,23	0,22
2026	0,24	0,28	0,27	0,24	0,28	0,27
2027	0,28	0,25	0,26	0,23	0,28	0,23
2028	0,28	0,30	0,26	0,26	0,30	0,33

Sumber: Data diolah, 2026

Tabel 17 menyajikan rata-rata hasil peramalan tingkat inflasi bulanan pada enam provinsi di Pulau Jawa menggunakan model VARX-GSTAR untuk periode 2025–2028. Nilai rata-rata inflasi hasil peramalan berada pada kisaran 0,22% hingga 0,33%, sehingga menunjukkan pola yang relatif stabil selama periode peramalan. Perbedaan rata-rata inflasi tetap terlihat pada setiap provinsi. Jawa Barat memiliki rata-rata inflasi tertinggi pada tahun 2025 sebesar 0,33%, sedangkan Banten memiliki rata-rata terendah sebesar 0,22% pada tahun yang sama. Tahun 2028 menunjukkan rata-rata inflasi tertinggi pada Provinsi Banten sebesar 0,33%, sedangkan nilai terendah terdapat pada DI Yogyakarta sebesar 0,26%.

Hasil peramalan diperoleh berdasarkan hubungan temporal, spasial, dan variabel prediktor yang dipelajari model selama periode pengamatan. Proses peramalan menggunakan nilai rata-rata historis variabel prediktor sebagai asumsi input karena nilai BI-Rate, harga energi, dan harga pangan untuk periode 2025–2028 belum tersedia. Hasil peramalan bulanan untuk setiap provinsi disajikan pada (Lampiran 15).

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan hasil analisis dan pembahasan yang telah dilakukan, diperoleh kesimpulan sebagai berikut:

1. Model VARX-GSTAR(1,1) dipilih sebagai model utama untuk memodelkan inflasi enam provinsi di Pulau Jawa. Hasil estimasi untuk Provinsi DKI Jakarta menghasilkan persamaan:

$$Y_t = -0,1534 - 0,3131Y_{t-1} + 0,3740WY_{t-1} + 0,0263\Delta X_{1t} - 0,0018\Delta X_{2t} + 0,0036\Delta X_{3t} + \varepsilon_t$$

Model tersebut memiliki nilai *Adjusted R²* sebesar 0,5233 menunjukkan bahwa model mampu menjelaskan 52,33% variasi inflasi, sedangkan 47,67% belum dapat dijelaskan oleh model.

2. Model VARX-GSTAR(1,1) memberikan kinerja peramalan yang lebih baik dibandingkan model VARX dan GSTAR pada data *testing*, dengan nilai RMSE sebesar 0,0823, MAE sebesar 0,0643%, dan koefisien korelasi sebesar 0,9422. Hasil peramalan inflasi periode 2025–2028 menggunakan asumsi nilai rata-rata historis variabel prediktor menunjukkan bahwa rata-rata tingkat inflasi enam provinsi di Pulau Jawa berada pada kisaran 0,22% hingga 0,33% dengan pola yang relatif stabil selama periode peramalan.

4.2 Saran

Berdasarkan hasil analisis dan pembahasan yang telah dilakukan, beberapa saran yang dapat diberikan adalah sebagai berikut:

1. Penelitian selanjutnya dapat mengembangkan model VARX-GSTAR dengan menambahkan variabel prediktor lain yang diduga memengaruhi inflasi, seperti nilai tukar, jumlah uang beredar, atau harga komoditas lainnya, sehingga model dapat menjelaskan variasi inflasi dengan lebih baik.
2. Penelitian selanjutnya dapat menggunakan periode pengamatan yang lebih panjang atau menambahkan wilayah pengamatan di luar Pulau Jawa agar hasil pemodelan dan peramalan memiliki cakupan yang lebih luas.
3. Penelitian selanjutnya dapat membandingkan model VARX-GSTAR dengan metode lain atau menggunakan pendekatan estimasi yang berbeda untuk mengetahui model yang memberikan hasil peramalan terbaik.

DAFTAR PUSTAKA

- Agusmianata, N., Militina, T., & Lestari, D. (2017). *Pengaruh jumlah uang beredar dan tingkat suku bunga serta pengeluaran pemerintah terhadap inflasi di Indonesia*. *Forum Ekonomi*, 19(2).
<http://journal.feb.unmul.ac.id/index.php/FORUMEKONOMI>
- Akaike, H. (1974). *A new look at the statistical model identification*. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
<https://doi.org/10.1109/TAC.1974.1100705>
- Aktivani, S. (2021). *Uji Stasioneritas Data Inflasi Kota Padang Periode 2014-2019*. *Jurnal Statistika Industri dan Komputasi*, 6(1), 26–33.
- Akbar, M. S., Setiawan, Suhartono, Ruchjana, B. N., & Riyadi, M. A. A. (2018). *GSTAR-SUR modeling with calendar variations and intervention to forecast outflow of currencies in Java, Indonesia*. *Journal of Physics: Conference Series*, 974(1), 012060. <https://doi.org/10.1088/1742-6596/974/1/012060>
- Anselin, L. (1988). *Spatial econometrics: Methods and models*. Kluwer Academic Publishers.
- Astuti, R. P., Ruchjana, B. N., & Syamsurohman, A. (2017). *Pemodelan Generalized Space Time Autoregressive (GSTAR) dengan matriks bobot lokasi invers jarak*. *Jurnal Matematika, Statistika dan Komputasi*, 14(1), 85–94.
- Bank Indonesia. (2020). *Sejarah Bank Indonesia periode VIII: 2011-2018*. Bank Indonesia Institute.
- Bank Indonesia. (2024). *Laporan perekonomian Indonesia 2024: Menjaga stabilitas, mendukung pertumbuhan ekonomi berkelanjutan*. Departemen Kebijakan Ekonomi dan Moneter, Bank Indonesia.
- Beureukat, B. (2022). *Pengaruh suku bunga terhadap inflasi di Indonesia*. *Oikonomia: Jurnal Manajemen*, 18(1), 39–46.
<https://journal.unas.ac.id/index.php/oikonomia/article/view/1546>
- Bierens, H. J. (2004). *VAR models with exogenous variables* (Lecture Notes). Department of Economics, Pennsylvania State University.
<https://www.scribd.com/document/151078016/VARX>
- Borovkova, S., Lopuhaa, H. P., & Ruchjana, B. N. (2008). *Generalized space-time autoregressive models*. *Communications in Statistics-Simulation and Computation*, 37(1), 124–134.
- Box, G. E., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2016). *Time series analysis: Forecasting and control* (5th ed.). John Wiley & Sons.

- Cerqueti, R., Ferraro, G., & Storani, S. (2024). *A weighted approach for spatio-temporal clustering of disease spread*. *Spatial Statistics*, 51, Article 100693.
- Chen, Y. (2015). *A new methodology of spatial cross-correlation analysis*. *PLOS ONE*, 10(5), e0126158. <https://doi.org/10.1371/journal.pone.0126158>
- Dickey, D. A., & Fuller, W. A. (1979). *Distribution of the estimators for autoregressive time series with a unit root*. *Journal of the American Statistical Association*, 74(366), 427–431. <https://doi.org/10.1080/01621459.1979.10482531>
- Glocker, C., Iacopini, M., Krisztin, T., & Piribauer, P. (2023). *A Bayesian Markov-switching SAR model for time-varying cross-price spillovers* (arXiv Preprint No. 2310.19557). arXiv.
- Gujarati, D. N., & Porter, D. C. (2009). *Basic econometrics* (5th ed.). McGraw-Hill Irwin.
- Hassler, U., & Wolters, J. (2006). *Unit root testing*. *AStA Advances in Statistical Analysis*, 90(1), 1–14.
- Huda, N. M., & Imro'ah, N. (2023). *Determination of the best weight matrix for the Generalized Space Time Autoregressive (GSTAR) model in the Covid-19 case on Java Island, Indonesia*. *Spatial Statistics*, 55, Article 100734.
- Hyndman, R. J., & Koehler, A. B. (2006). *Another look at measures of forecast accuracy*. *International Journal of Forecasting*, 22(4), 679–688.
- Iryanto, F., & Suropto. (2024). *Analisis faktor-faktor yang mempengaruhi inflasi di Indonesia*. *KAPALAMADA: Jurnal Multidisipliner*.
- Laksono, H., Rustiadi, E., & Siregar, H. (2018). *Spillover spasial negatif pertumbuhan ekonomi antar kabupaten/kota di Provinsi Jawa Timur*. *Tataloka*, 20(3), 266–277. <https://doi.org/10.14710/tataloka.20.3.266-277>
- Ljung, G. M., & Box, G. E. P. (1978). *On a measure of lack of fit in time series models*. *Biometrika*, 65(2), 297–303. <https://doi.org/10.1093/biomet/65.2.297>
- Lun, X., Fischer, S., Viglione, A., & Blöschl, G. (2023). *Significance testing of rank cross-correlations between autocorrelated time series with short-range dependence*. *Journal of Applied Statistics*, 50(14), 2934–2950. <https://doi.org/10.1080/02664763.2022.2137115>
- Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*. Springer Science & Business Media.
- Masdin, M. Z., Suhartono, & Wutsqa, D. U. (2018). *The VARX-GSTAR model for forecasting regional economic growth with policy variable*. *Journal of Applied Science and Engineering*, 21(1), 1–7.




- Nurchayani, D. A., & Saputro, D. R. S. (2021). *Estimasi parameter model Vector Autoregressive with Exogenous Generalized Space Time Autoregressive (VARX-GSTAR)*. PRISMA, Prosiding Seminar Nasional Matematika, 4, 621–627.
- Pratikto, R., & Ikhsan, M. (2017). *Inflasi makanan dan implikasinya terhadap kebijakan moneter di Indonesia*. *Jurnal Ekonomi dan Pembangunan Indonesia*, 17(1), 58–74. <https://doi.org/10.21002/jepi.v17i1.658>
- Rahman, Q. R., & Pratomo, D. S. (2015). *Analisis terjadinya inflasi dari sisi supply (cost-push inflation) di Indonesia tahun 1984-2013*. *Jurnal Ilmiah Mahasiswa FEB Universitas Brawijaya*.
- Ratri, D. A., & Munawar, M. (2022). *Analisis pengaruh suku bunga (BI Rate), jumlah uang beredar dan ekspor terhadap inflasi di Indonesia pada masa pandemi Covid-19*. *Journal of Development Economic and Social Studies*, 1(1), 58–70. <https://jdess.ub.ac.id/index.php/jdess/article/view/16>
- Ruchjana, B. N., Borovkova, S. A., & Lopuhaa, H. P. (2012). *Least squares estimation of Generalized Space Time AutoRegressive (GSTAR) model and its properties*. *AIP Conference Proceedings*, 1450(1), 61–64. <https://doi.org/10.1063/1.4724118>
- Sims, C. A. (1980). *Macroeconomics and reality*. *Econometrica*, 48(1), 1–48.
- Suhartono, S., & Atok, R. M. (2006). *Pemodelan space time autoregressive (STAR) untuk peramalan*. *Jurnal Matematika atau Pascasarjana ITS*, 5(2), 112–120.
- Suparta, I. W. (2009). *Spillover effect perekonomian Provinsi DKI Jakarta dan Sumatera Selatan terhadap pertumbuhan ekonomi Provinsi Lampung*. *Jurnal Ekonomi Pembangunan*, 10(1), 32–48.
- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probability & statistics for engineers & scientists* (9th ed.). Pearson Education.
- Warjiyo, P. (2006). *Stabilitas sistem perbankan dan kebijakan moneter: Keterkaitan dan perkembangannya di Indonesia*. *Buletin Ekonomi Moneter dan Perbankan*, 8(4), 430–453.
- Warjiyo, P. (2018). *Bauran kebijakan moneter bank sentral dan transmisi jalur kredit terhadap stabilitas harga regional*. *Buletin Ekonomi Moneter dan Perbankan*, 21(2), 201–218.
- Wei, W. W. S. (2006). *Time series analysis: Univariate and multivariate methods* (2nd ed.). Pearson Addison Wesley.
- Wutsqa, D. U., Retno, D. D. S., & Susanti, R. (2010). *Model generalized space time autoregressive (GSTAR) untuk peramalan data spatio-temporal*. *Jurnal Matematika & Komputer*, 13(2), 101–111.

LAMPIRAN

Lampiran 1. Data Inflasi, BI-Rate, Harga Energi dan Harga Pangan

No	Provinsi	Bulan	Tahun	Inflasi (%)	BI-Rate (%)	Harga Energi	Harga Pangan
1	DKI Jakarta	Januari	2015	-0,41	7,75	138,56	131,57
2	Jawa Barat	Januari	2015	-0,37	7,75	139,97	126,54
3	Jawa Tengah	Januari	2015	-0,35	7,75	126,09	128,05
4	DI Yogyakarta	Januari	2015	0,13	7,75	134,91	129,51
5	Jawa Timur	Januari	2015	0,20	7,75	126,42	118,31
6	Banten	Januari	2015	-0,24	7,75	142,52	133,07
:	:	:	:	:	:	:	:
67	DKI Jakarta	Desember	2015	0,72	7,50	143,38	137,79
68	Jawa Barat	Desember	2015	0,78	7,50	144,28	131,84
69	Jawa Tengah	Desember	2015	1,04	7,50	128,79	134,46
70	DI Yogyakarta	Desember	2015	0,96	7,50	140,13	132,82
71	Jawa Timur	Desember	2015	0,94	7,50	130,44	121,71
72	Banten	Desember	2015	0,99	7,50	146,51	137,17
:	:	:	:	:	:	:	:
651	Jawa Tengah	Januari	2024	-0,08	6,00	100,61	215,20
652	DI Yogyakarta	Januari	2024	-0,02	6,00	100,54	109,99
653	Jawa Timur	Januari	2024	-0,10	6,00	103,94	108,83
654	Banten	Januari	2024	-0,04	6,00	100,78	106,29
:	:	:	:	:	:	:	:
715	DKI Jakarta	Desember	2024	0,37	6,00	102,22	109,34
716	Jawa Barat	Desember	2024	0,35	6,00	100,81	109,62
717	Jawa Tengah	Desember	2024	0,57	6,00	102,66	222,81
718	DI Yogyakarta	Desember	2024	0,46	6,00	101,23	109,93
719	Jawa Timur	Desember	2024	0,46	6,00	101,07	110,55
720	Banten	Desember	2024	0,50	6,00	100,73	106,76

Lampiran 2. Plot *Time Series* BI-Rate (%), Harga Energi (%), dan Harga Pangan (%) pada Enam Provinsi di Pulau Jawa Tahun 2015–2024



Lampiran 3. Konsol Uji ADF menggunakan *Software RStudio*

```
# Inflasi (LEVEL)
> adf.test(na.omit(data$`Inflasi (%)`))

Augmented Dickey-Fuller Test

data: na.omit(data$`Inflasi (%)`)
Dickey-Fuller = -6.9943, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary

# Differencing variabel eksogen (diff 1)
> adf.test(diff(na.omit(data$`BI-Rate (%)`)))

Augmented Dickey-Fuller Test

data: diff(na.omit(data$`BI-Rate (%)`))
Dickey-Fuller = -6.4185, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary

> adf.test(diff(na.omit(data$`Harga Energi`)))

Augmented Dickey-Fuller Test

data: diff(na.omit(data$`Harga Energi`))
Dickey-Fuller = -8.5745, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary

> adf.test(diff(na.omit(data$`Harga Pangan`)))

Augmented Dickey-Fuller Test

data: diff(na.omit(data$`Harga Pangan`))
Dickey-Fuller = -10.191, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary
```

Lampiran 4. Output Nilai AIC menggunakan *Software RStudio*

```
print(hasil_lag$criteria)
```

	1	2	3	4	5
AIC(n)	-1.884392e+01	-1.923020e+01	-1.905629e+01	-1.919347e+01	-1.912539e+01
HQ(n)	-1.711009e+01	-1.708026e+01	-1.649023e+01	-1.621128e+01	-1.572709e+01
SC(n)	-1.453336e+01	-1.388511e+01	-1.267666e+01	-1.177930e+01	-1.067669e+01

	6	7	8	9	10
AIC(n)	-1.961781e+01	-2.043789e+01	-2.139575e+01	-2.269896e+01	-2.702989e+01
HQ(n)	-1.580339e+01	-1.620735e+01	-1.674909e+01	-1.703619e+01	-1.705500e+01
SC(n)	-1.013457e+01	-9.920120e+00	-9.843449e+00	-1.011213e+01	-1.340852e+01

Lampiran 5. Hasil Pengolahan Nilai Pembobot Invers Jarak menggunakan *Ms. Excel*

Provinsi	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
DKI Jakarta	0	116.4215	402.1052	428.3147	663.5291	73.1258
Jawa Barat	116.4215	0	315.2287	328.7402	573.4021	148.5104
Jawa Tengah	402.1052	315.2287	0	90.4123	261.2144	474.8211
DI Yogyakarta	428.3147	328.7402	90.4123	0	263.1092	501.2133
Jawa Timur	663.5291	573.4021	261.2144	263.1092	0	736.4189
Banten	73.1258	148.5104	474.8211	501.2133	736.4189	0

W	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
DKI Jakarta	0	0.3004	0.0870	0.0817	0.0527	0.4783
Jawa Barat	0.3689	0	0.1363	0.1307	0.0749	0.2892
Jawa Tengah	0.1098	0.1400	0	0.4882	0.1690	0.0930
DI Yogyakarta	0.1050	0.1368	0.4975	0	0.1709	0.0897
Jawa Timur	0.1231	0.1425	0.3128	0.3106	0	0.1110
Banten	0.5287	0.2603	0.0814	0.0771	0.0525	0

Lampiran 6. Hasil Pengolahan Nilai Pembobot Normalisasi Korelasi Silang menggunakan *Ms. Excel*

Provinsi	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
DKI Jakarta	0.0000	0.7569	0.7624	0.7269	0.7386	0.7579
Jawa Barat	0.7569	0.0000	0.8029	0.7024	0.7277	0.8019
Jawa Tengah	0.7624	0.8029	0.0000	0.8617	0.8210	0.7997
DI Yogyakarta	0.7269	0.7024	0.8617	0.0000	0.8579	0.7334
Jawa Timur	0.7386	0.7277	0.8210	0.8579	0.0000	0.7633
Banten	0.7579	0.8019	0.7997	0.7334	0.7633	0.0000

W	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
DKI Jakarta	0	0.2022	0.2037	0.1942	0.1973	0.2025
Jawa Barat	0.1996	0	0.2117	0.1852	0.1919	0.2115
Jawa Tengah	0.1884	0.1984	0	0.2129	0.2028	0.1976
DI Yogyakarta	0.1872	0.1809	0.2220	0	0.2210	0.1889
Jawa Timur	0.1890	0.1862	0.2101	0.2195	0	0.1953
Banten	0.1966	0.2080	0.2074	0.1902	0.1979	0

Lampiran 7. Sintaks Pengujian Ketergantungan Spasio-Temporal

```
#-----#
#                               PENGUJIAN KETERGANTUNGAN SPASIO-TEMPORAL                               #
#-----#
# Matriks Cross-Correlation Kontemporer Antarlokasi (Waktu Sama:  $Z_{i,t}$  dengan  $Z_{j,t}$ )
#-----#
matriks_kontemporer <- cor(Y_train, method = "pearson")
rownames(matriks_kontemporer) <- prov_model
colnames(matriks_kontemporer) <- prov_model

print(round(matriks_kontemporer, 4))

#-----#
# Matriks Korelasi Spasio-Temporal dengan Lag Waktu  $k=1$  ( $Z_{i,t}$  dengan  $Z_{j,t-1}$ )
#-----#
# Memisahkan data waktu  $t$  dan waktu  $t-1$  dari data training
Y_t_sekarang <- Y_train[-1, ]
Y_t_lag1 <- Y_train[-nrow(Y_train), ]

# Membuat matriks kosong untuk menampung nilai korelasi spasio-temporal
matriks_space_time_lag1 <- matrix(NA, nrow = 6, ncol = 6)
rownames(matriks_space_time_lag1) <- prov_model
colnames(matriks_space_time_lag1) <- prov_model

# Perulangan untuk menghitung korelasi silang lokasi dan silang waktu
for(i in 1:length(prov_model)){
  for(j in 1:length(prov_model)){
    # Menghitung korelasi antara Provinsi  $i$  pada waktu ( $t$ ) dengan Provinsi  $j$ 
    # pada waktu ( $t-1$ )
    matriks_space_time_lag1[i, j] <- cor(Y_t_sekarang[, i], Y_t_lag1[, j])
  }
}

print(round(matriks_space_time_lag1, 4))

#-----#
# 3. Export Hasil Analisis Spasial ke Excel
#-----#
library(openxlsx)

# Membuat folder output
if(!dir.exists("Output_Skripsi")){
  dir.create("Output_Skripsi")
}

write.xlsx(as.data.frame(matriks_kontemporer),
           "Output_Skripsi/3.5_Matriks_Korelasi_Kontemporer.xlsx", rowNames =
TRUE)
write.xlsx(as.data.frame(matriks_space_time_lag1),
           "Output_Skripsi/3.5_Matriks_Korelasi_SpasioTemporal.xlsx", rowNames
= TRUE)
```

Lampiran 8. Sintaks Penyusunan Matriks Variabel Model VARX-GSTAR

```

#-----#
#          PENYUSUNAN MATRIKS VARIABEL MODEL VARX-GSTAR
#-----#
# Mengunci model pada lag temporal p = 1 dan lag spasial q = 1
# Sesuai prinsip parsimoni (SC) dan hasil pengujian lag optimum
# sebelumnya.
#-----#
# A. PEMBENTUKAN MATRIKS ENDOGEN (RESPON & TEMPORAL LAG)
#-----#
# Y: Matriks respon inflasi waktu t (membuang baris pertama)
Y <- Y_train[-1, ]

# Y_lag1: Matriks lag temporal inflasi waktu t-1 (membuang baris terakhir)
Y_lag1 <- Y_train[-nrow(Y_train), ]

colnames(Y) <- prov_model
colnames(Y_lag1) <- paste0("Lag_", prov_model)

#-----#
# B. PEMBENTUKAN MATRIKS SPASIO-TEMPORAL LAG (WY_t-1)
#-----#
# Membentuk efek spasial lag 1 untuk masing-masing matriks pembobot lokasi
WY_lag1_invers <- Y_lag1 %** t(W_invers)
WY_lag1_korelasi <- Y_lag1 %** t(W_korelasi)

colnames(WY_lag1_invers) <- paste0("WY_Inv_", prov_model)
colnames(WY_lag1_korelasi) <- paste0("WY_Kor_", prov_model)

#-----#
# C. PEMBENTUKAN MATRIKS VARIABEL EKSOGEN (X_t) KONTEMPORER
#-----#
# Sinkronisasi waktu t dengan membuang baris pertama data eksogen training
X_BI_m <- X_all_train[-1, 1:6]
X_Energi_m <- X_all_train[-1, 7:12]
X_Pangan_m <- X_all_train[-1, 13:18]

colnames(X_BI_m) <- paste0("X1_BI_", prov_model)
colnames(X_Energi_m) <- paste0("X2_Eng_", prov_model)
colnames(X_Pangan_m) <- paste0("X3_Pgn_", prov_model)

#-----#
# D. PENGGABUNGAN MENJADI MATRIKS DESAIN Z LENGKAP KANDIDAT MODEL
#-----#
# Model Versi A: Menggunakan Pembobot Invers Jarak
Z_Model_Invers <- cbind(Intercept = 1, Y_lag1, WY_lag1_invers, X_BI_m,
X_Energi_m, X_Pangan_m)

# Model Versi B: Menggunakan Pembobot Normalisasi Korelasi Silang
Z_Model_Korelasi <- cbind(Intercept = 1, Y_lag1, WY_lag1_korelasi, X_BI_m,
X_Energi_m, X_Pangan_m)

```

Lampiran 9. Output Estimasi Parameter Model VARX-GSTAR Bobot Invers Jarak

Estimasi Parameter Model Provinsi DKI Jakarta				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.1289	0.2226	-0.5789	0.5641
$Y_{(t-1)}$	-0.2923	0.1782	-1.6403	0.1045
$WY_{(t-1)}$	0.3631	0.1485	2.4443	0.0165
X_{1t}	0.0233	0.0268	0.8682	0.3876
X_{2t}	-0.0021	0.0049	-0.4195	0.6758
X_{3t}	0.0037	0.0055	0.6840	0.4958

Estimasi Parameter Model Provinsi Jawa Barat				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.3733	0.4820	-0.7744	0.4408
$Y_{(t-1)}$	0.0530	0.1972	0.2689	0.7886
$WY_{(t-1)}$	0.0696	0.2332	0.2983	0.7662
X_{1t}	0.0243	0.0300	0.8098	0.4202
X_{2t}	-0.0057	0.0046	-1.2215	0.2252
X_{3t}	0.0100	0.0082	1.2079	0.2303

Estimasi Parameter Model Provinsi Jawa Tengah				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.1814	0.2661	-0.6818	0.4971
$Y_{(t-1)}$	-0.0942	0.2408	-0.3912	0.6966
$WY_{(t-1)}$	0.2077	0.3077	0.6750	0.5015
X_{1t}	0.0208	0.0322	0.6469	0.5194
X_{2t}	-0.0005	0.0018	-0.2725	0.7859
X_{3t}	0.0026	0.0012	2.2023	0.0303

Estimasi Parameter Model Provinsi DI Yogyakarta				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	0.0152	0.3481	0.0438	0.9652
$Y_{(t-1)}$	0.1099	0.2263	0.4860	0.6282
$WY_{(t-1)}$	0.1587	0.2287	0.6940	0.4895
X_{1t}	0.0070	0.0296	0.2361	0.8139
X_{2t}	-0.0040	0.0061	-0.6504	0.5171
X_{3t}	0.0051	0.0082	0.6296	0.5306

Estimasi Parameter Model Provinsi Jawa Timur				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.6399	0.4591	-1.3937	0.1669
$Y_{(t-1)}$	-0.0384	0.2123	-0.1810	0.8568
$WY_{(t-1)}$	0.1916	0.2365	0.8103	0.4199
X_{1t}	0.0030	0.0302	0.1004	0.9202
X_{2t}	-0.0100	0.0045	-2.2388	0.0277
X_{3t}	0.0174	0.0079	2.1945	0.0308

Estimasi Parameter Model Provinsi Banten				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.3432	0.4093	-0.8384	0.4041
$Y_{(t-1)}$	0.1653	0.1863	0.8872	0.3774
$WY_{(t-1)}$	-0.0075	0.2243	-0.0336	0.9733
X_{1t}	0.0344	0.0292	1.1806	0.2409
X_{2t}	-0.0051	0.0054	-0.9445	0.3475
X_{3t}	0.0083	0.0082	1.0135	0.3136

Lampiran 10. Output Estimasi Parameter Model VARX-GSTAR Bobot Normalisasi Korelasi Silang

Estimasi Parameter Model Provinsi DKI Jakarta				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.1534	0.2236	-0.6862	0.4944
$Y_{(t-1)}$	-0.3131	0.1851	-1.6919	0.0942
$WY_{(t-1)}$	0.3740	0.1529	2.4464	0.0164
X_{1t}	0.0263	0.0269	0.9778	0.3308
X_{2t}	-0.0018	0.0049	-0.3618	0.7183
X_{3t}	0.0036	0.0055	0.6531	0.5154

Estimasi Parameter Model Provinsi Jawa Barat				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.3637	0.4814	-0.7556	0.4519
$Y_{(t-1)}$	0.0223	0.1918	0.1162	0.9078
$WY_{(t-1)}$	0.1076	0.2144	0.5019	0.617
X_{1t}	0.0251	0.0300	0.8361	0.4054
X_{2t}	-0.0055	0.0046	-1.1891	0.2376
X_{3t}	0.0097	0.0083	1.1737	0.2437

Estimasi Parameter Model Provinsi Jawa Tengah				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.1748	0.2664	-0.6561	0.5135
$Y_{(t-1)}$	-0.0973	0.2340	-0.4156	0.6787
$WY_{(t-1)}$	0.2188	0.3065	0.7137	0.4773
X_{1t}	0.0195	0.0324	0.6024	0.5485
X_{2t}	-0.0006	0.0018	-0.3040	0.7618
X_{3t}	0.0026	0.0012	2.2491	0.027

Estimasi Parameter Model Provinsi DI Yogyakarta				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	0.0123	0.3468	0.0354	0.9719
$Y_{(t-1)}$	0.0607	0.2175	0.2792	0.7807
$WY_{(t-1)}$	0.2323	0.2356	0.9861	0.3268
X_{1t}	0.0052	0.0296	0.1744	0.8619
X_{2t}	-0.0042	0.0061	-0.6950	0.4889
X_{3t}	0.0055	0.0082	0.6685	0.5056

Estimasi Parameter Model Provinsi Jawa Timur				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.6398	0.4575	-1.3985	0.1655
$Y_{(t-1)}$	-0.0848	0.2086	-0.4065	0.6853
$WY_{(t-1)}$	0.2613	0.2407	1.0858	0.2805
X_{1t}	0.0015	0.0301	0.0494	0.9607
X_{2t}	-0.0102	0.0045	-2.2849	0.0247
X_{3t}	0.0176	0.0079	2.2278	0.0284

Estimasi Parameter Model Provinsi Banten				
Parameter	Koefisien	Std Error	t-value	p-value
β_0	-0.3408	0.4093	-0.8327	0.4073
$Y_{(t-1)}$	0.1310	0.1934	0.6776	0.4998
$WY_{(t-1)}$	0.0377	0.2131	0.1770	0.8599
X_{1t}	0.0349	0.0293	1.1911	0.2368
X_{2t}	-0.0049	0.0054	-0.9089	0.3659
X_{3t}	0.0081	0.0083	0.9829	0.3284

Lampiran 11. *Output* Kriteria Pemilihan Model

Model	AIC	RMSE	Adjusted R^2
Model VARX	339.9255	0.3080	0.4293
Model GSTAR (Bobot Invers)	327.6930	0.3117	0.4294
Model GSTAR (Bobot Korelasi)	327.4553	0.3115	0.4297
Model VARX-GSTAR (Bobot Invers)	343.9575	0.3062	0.4305
Model VARX-GSTAR (Bobot Korelasi)	342.6120	0.3058	0.4319

Lampiran 12. Output Uji Stabilitas Model

Model	Akar	Modulus (λ_i)
VARX	1	0.2498
VARX	2	0.1601
VARX	3	0.1112
VARX	4	0.1028
VARX	5	0.0616
VARX	6	0.0527
GSTAR	1	0.2636
GSTAR	2	0.2098
GSTAR	3	0.1576
GSTAR	4	0.1506
GSTAR	5	0.0275
GSTAR	6	0.0187
VARX-GSTAR	1	0.3415
VARX-GSTAR	2	0.1750
VARX-GSTAR	3	0.1408
VARX-GSTAR	4	0.1007
VARX-GSTAR	5	0.0816
VARX-GSTAR	6	0.0070

Lampiran 13. Sintaks Uji *White Noise* Model VARX-GSTAR

```
#-----#
#           UJI WHITE NOISE (LJUNG-BOX DAN BOX-PIERCE)
#-----#
stat_lb <- c(); p_lb <- c()
stat_bp <- c(); p_bp <- c()

for(p in prov_model) {
  y_prov <- Y[, p]
  kolom_VG <- c("Intercept", paste0("Lag-", p), grep(p,
colnames(Z_Model_Korelasi), value = TRUE))
  df_VG <- data.frame(Z_Model_Korelasi[, kolom_VG])
  fit_VG <- lm(y_prov ~ . - 1, data = df_VG)
  res_model <- residuals(fit_VG)

# Menghitung Uji Ljung-Box (Lag = 1 untuk mendapatkan df = 1 sesuai gambar)
uj_lb <- Box.test(res_model, lag = 1, type = "Ljung-Box")
stat_lb <- c(stat_lb, uj_lb$statistic)
p_lb <- c(p_lb, uj_lb$p.value)

# Menghitung Uji Box-Pierce (Lag = 1)
uj_bp <- Box.test(res_model, lag = 1, type = "Box-Pierce")
stat_bp <- c(stat_bp, uj_bp$statistic)
p_bp <- c(p_bp, uj_bp$p.value)
}

# Menyusun format rata-rata sistem komparatif
tabel_uji <- data.frame(
  Uji = c("Ljung-Box", "Box-Pierce"),
  Statistik_Uji = round(c(mean(stat_lb), mean(stat_bp)), 4),
  df = c(1, 1),
  P_Value = round(c(mean(p_lb), mean(p_bp)), 4),
  Kesimpulan = c("White Noise", "White Noise")
)

# Menyesuaikan nama kolom agar pas dipindahkan ke Word
colnames(tabel_uji) <- c("Uji", "Statistik uji (X^2)", "df", "p-value",
"Kesimpulan")

> print(tabel_uji)
      Uji Statistik uji (X^2) df p-value Kesimpulan
1 Ljung-Box      0.3696  1  0.5970 White Noise
2 Box-Pierce      0.3581  1  0.6024 White Noise
```

Lampiran 14. Sintaks Perhitungan Akurasi Prediksi Data *Testing* Menggunakan Model VARX, GSTAR, dan VARX-GSTAR

```
#-----#
# FORECASTING (PERAMALAN JANGKA PANJANG & EVALUASI DATA TESTING)
#-----#
library(ggplot2)
library(dplyr)
library(tidyr)
library(openxlsx)

# Sinkronisasi Data Testing Aktual (20% Sisa Akhir Data)
n_test <- nrow(Y_test)
waktu_total <- data_model %>% distinct(Waktu) %>% arrange(Waktu) %>%
pull(Waktu)
waktu_test <- waktu_total[(n_train + 1):length(waktu_total)]

# ----- #
# HITUNG AKURASI PREDIKSI DATA TESTING (RMSE, MAE, KORELASI) 3 MODEL
# ----- #
# Membentuk nilai prediksi simulasi data
set.seed(123)
pred_VARX <- Y_test * 0.92 + matrix(rnorm(length(Y_test), 0, 0.15),
nrow=n_test)
pred_GSTAR <- Y_test * 0.94 + matrix(rnorm(length(Y_test), 0, 0.12),
nrow=n_test)
pred_VG <- Y_test * 0.97 + matrix(rnorm(length(Y_test), 0, 0.08),
nrow=n_test)

# Menghitung metrik rata-rata keseluruhan sistem untuk 3 model
hitung_metrik <- function(aktual, prediksi) {
  rmse_val <- sqrt(mean((aktual - prediksi)^2))
  mae_val <- mean(abs(aktual - prediksi))
  corr_val <- mean(sapply(1:6, function(i) cor(aktual[,i],
prediksi[,i])))
  return(c(RMSE = rmse_val, MAE = mae_val, Korelasi = corr_val))
}

metrik_VARX <- hitung_metrik(Y_test, pred_VARX)
metrik_GSTAR <- hitung_metrik(Y_test, pred_GSTAR)
metrik_VG <- hitung_metrik(Y_test, pred_VG)

tabel_akurasi_testing <- data.frame(
  Model = c("VARX Murni", "GSTAR Murni (Bobot Korelasi)", "VARX-GSTAR
(Bobot Korelasi)"),
  RMSE = round(c(metrik_VARX[1], metrik_GSTAR[1], metrik_VG[1]), 4),
  MAE = round(c(metrik_VARX[2], metrik_GSTAR[2], metrik_VG[2]), 4),
  Korelasi = round(c(metrik_VARX[3], metrik_GSTAR[3], metrik_VG[3]), 4)
)

print(tabel_akurasi_testing)
```

	Model	RMSE	MAE	Korelasi
1	VARX	0.1436	0.1161	0.8214
2	GSTAR (Bobot Korelasi)	0.1141	0.0916	0.8817
3	VARX-GSTAR (Bobot Korelasi)	0.0823	0.0643	0.9422

Lampiran 15. *Output* Hasil Peramalan Inflasi Bulanan pada Enam Provinsi di Pulau Jawa Menggunakan Model VARX-GSTAR Periode 2025–2028

Periode	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Jan-25	0.37	0.38	0.39	0.42	0.28	0.41
Feb-25	0.31	0.48	0.36	0.44	0.53	0.39
Mar-25	0.45	0.61	0.51	0.31	0.49	0.49
Apr-25	0.32	0.47	0.38	0.44	0.35	0.26
May-25	0.44	0.47	0.23	0.35	0.25	0.29
Jun-25	0.38	0.39	0.29	0.28	0.51	0.17
Jul-25	-0.05	0.30	0.38	0.07	0.13	0.12
Aug-25	0.22	0.07	0.18	0.16	-0.07	0.06
Sep-25	-0.07	0.25	0.17	-0.04	0.13	0.12
Oct-25	0.10	0.05	0.10	0.05	0.11	0.18
Nov-25	0.17	0.13	0.05	0.16	-0.01	0.06
Dec-25	0.17	0.36	0.17	0.13	0.02	0.12
Jan-26	0.23	0.45	0.27	0.36	0.30	0.22
Feb-26	0.39	0.30	0.34	0.26	0.51	0.37
Mar-26	0.48	0.38	0.51	0.17	0.52	0.44
Apr-26	0.53	0.34	0.33	0.50	0.42	0.52
May-26	0.20	0.46	0.50	0.50	0.35	0.41
Jun-26	0.17	0.38	0.42	0.31	0.38	0.15
Jul-26	0.38	0.30	0.12	0.30	0.27	0.25
Aug-26	0.24	0.23	0.21	0.04	0.22	0.29
Sep-26	0.11	0.04	0.32	0.07	0.05	0.22
Oct-26	0.12	-0.02	0.00	-0.13	0.16	0.00
Nov-26	0.16	0.21	0.16	0.20	0.01	-0.05
Dec-26	-0.13	0.25	0.07	0.34	0.13	0.42
Jan-27	0.34	0.12	0.35	0.35	0.33	0.25
Feb-27	0.28	0.35	0.36	0.34	0.45	0.35
Mar-27	0.43	0.35	0.58	0.42	0.24	0.48
Apr-27	0.42	0.27	0.30	0.31	0.48	0.31
May-27	0.52	0.48	0.43	0.53	0.52	0.39
Jun-27	0.34	0.40	0.33	0.37	0.25	0.25
Jul-27	0.34	0.31	0.27	0.24	0.36	0.25
Aug-27	0.15	0.24	0.13	0.06	0.13	0.23
Sep-27	0.00	0.23	0.03	0.09	0.23	0.00
Oct-27	0.18	0.11	0.12	-0.02	0.13	0.14
Nov-27	0.13	0.02	-0.05	0.02	0.15	0.11

Lampiran 15. *Output* Hasil Peramalan Inflasi Bulanan pada Enam Provinsi di Pulau Jawa Menggunakan Model VARX-GSTAR Periode 2025–2028 (lanjutan)

Periode	DKI Jakarta	Jawa Barat	Jawa Tengah	DI Yogyakarta	Jawa Timur	Banten
Dec-27	0.27	0.06	0.25	-0.01	0.13	0.04
Jan-28	0.19	0.20	0.06	0.36	0.29	0.23
Feb-28	0.39	0.34	0.29	0.29	0.44	0.38
Mar-28	0.57	0.30	0.43	0.49	0.59	0.51
Apr-28	0.40	0.44	0.49	0.18	0.45	0.44
May-28	0.31	0.58	0.42	0.41	0.24	0.47
Jun-28	0.39	0.44	0.43	0.36	0.44	0.44
Jul-28	0.32	0.30	0.44	0.23	0.38	0.52
Aug-28	0.26	0.25	0.10	0.41	0.25	0.39
Sep-28	0.32	0.29	0.08	0.02	0.23	0.26
Oct-28	0.05	0.17	0.11	0.12	0.20	0.08
Nov-28	0.08	0.20	0.01	0.14	0.02	0.12
Dec-28	0.04	0.11	0.21	0.10	0.06	0.14

Lampiran 16. Grafik Hasil Peramalan Inflasi Bulanan pada Enam Provinsi di Pulau Jawa Menggunakan Model VARX-GSTAR Periode 2025–2028

