


PENGEMBANGAN MODEL PREDIKSI *EL NINO*–*SOUTHERN OSCILLATION* (ENSO) MENGGUNAKAN MODEL LINEAR DAN NON-LINEAR.



ZERUYA YUDEA SIAGIAN

H061 22 1029

PROGRAM STUDI GEOFISIKA

DEPARTEMEN GEOFISIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS HASANUDDIN

MAKASSAR

2026



PENGEMBANGAN MODEL PREDIKSI *EL NINO*–*SOUTHERN OSCILLATION* (ENSO) MENGGUNAKAN MODEL LINEAR DAN NON-LINEAR.

ZERUYA YUDEA SIAGIAN

H061 22 1029



**PROGRAM STUDI GEOFISIKA
DEPARTEMEN GEOFISIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PENGEMBANGAN MODEL PREDIKSI *EL NINO–SOUTHERN
OSCILLATION* (ENSO) MENGGUNAKAN MODEL LINEAR DAN NON-
LINEAR.**

ZERUYA YUDEA SIAGIAN

H061 22 1029

Skripsi

Sebagai salah satu syarat untuk mencapai gelar sarjana

Program Studi Geofisika

Pada

**DEPARTEMEN GEOFISIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

LEMBAR PENGESAHAN

iv

LEMBAR PENGESAHAN UJIAN AKHIR

PENGEMBANGAN MODEL PREDIKSI *EL NINO-SOUTHERN
OSCILLATION* (ENSO) MENGGUNAKAN MODEL LINEAR DAN NON-
LINEAR.

ZERUYA YUDEA SIAGIAN
H061 22 1029

Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana pada tanggal 14 Juli
2026 dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Geofisika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:
Pembimbing Tugas Akhir,

Prof. Dr. Halmar Halide, M.Sc
NIP. 196303151987101001

Mengetahui:
Ketua Departemen Geofisika,



Dr. Erfan, M.Si
NIP. 196709032001121001

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

v

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul Pengembangan model prediksi *El Nino –Southern Oscillation* (ENSO) menggunakan model linear dan non-linear, adalah benar karya saya dengan arahan dari pembimbing Prof. Dr. Halmar Halide, M.Sc sebagai Pembimbing Utama. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 14 Juli 2026



Zeruya Yudea Siagian
H061221029

UCAPAN TERIMA KASIH

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat, karunia, dan penyertaan-Nya sehingga skripsi yang berjudul *“Pengembangan Model Prediksi ENSO (El Nino –Southern Oscillation) Menggunakan Model Linear dan Non-Linear”* ini dapat diselesaikan dengan baik. Dalam proses penyusunan skripsi ini, penulis menyadari bahwa banyak pihak yang telah memberikan bantuan, dukungan, dan bimbingan.

Terutama, penulis mengucapkan puji dan syukur kepada Tuhan Yesus. Terima kasih atas setiap penyertaan, kasih, kekuatan, dan pengharapan yang selalu diberikan, bahkan di saat penulis merasa lelah, ragu, dan hampir menyerah. Semua proses ini tidak akan dapat dilalui tanpa anugerah dan pertolongan Tuhan. Kiranya segala kemuliaan hanya bagi Tuhan.

Penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada Prof. Dr. Halmar Halide, M.Sc selaku dosen pembimbing yang telah meluangkan waktu serta memberikan bimbingan, arahan, dan masukan sejak tahap perencanaan hingga penyusunan akhir skripsi ini. Saran dan koreksi yang diberikan sangat membantu penulis dalam memperbaiki metodologi, analisis, serta penyajian hasil penelitian sehingga skripsi ini dapat diselesaikan dengan baik dan sesuai dengan kaidah ilmiah. Ucapan terima kasih juga penulis sampaikan kepada Prof. Dr. Eng. H. Amiruddin, S.Si., M.Si dan Bapak Dr. Muhammad Hamzah, S.S., M.T selaku dosen penguji yang telah meluangkan waktu untuk memberikan kritik, saran, serta masukan yang sangat berharga pada saat seminar maupun ujian skripsi. Berbagai masukan tersebut menjadi bahan evaluasi yang penting bagi penulis dalam menyempurnakan penelitian ini agar lebih sistematis, jelas, dan ilmiah. Penulis juga mengucapkan terima kasih kepada Bapak Dr. Muhammad Alimuddin Assegaf, M.Eng. selaku Ketua Departemen Geofisika atas dukungan dan arahan yang diberikan selama penulis menempuh pendidikan hingga penyusunan penelitian ini. Ucapan terima kasih turut disampaikan kepada Bapak Dr. Muhammad Taufik Rafie, S.Si., M.T selaku Pembimbing Akademik yang telah memberikan arahan dan bimbingan selama penulis menjalani proses perkuliahan. Penulis mengucapkan terima kasih kepada Bapak Saaduddin, M.Sc. selaku Sekretaris Departemen Geofisika atas bantuan dalam proses penetapan dosen penguji skripsi. Penulis mengucapkan terima kasih kepada Bapak Putra atas bantuan dan kesediaannya dalam proses pengumpulan serta penerimaan berkas selama penyusunan hingga penyelesaian skripsi. Penulis juga mengucapkan terima kasih kepada seluruh staf administrasi dan dosen di Departemen Geofisika Universitas Hasanuddin atas bantuan, dukungan administratif, serta ilmu pengetahuan yang telah diberikan selama masa perkuliahan hingga penyelesaian skripsi ini.

Ucapan terima kasih yang tulus juga penulis sampaikan kepada Papa, Mama, kakak, dan seluruh keluarga penulis yang senantiasa memberikan doa, dukungan, serta kepercayaan selama penulis menempuh pendidikan hingga tahap penyelesaian skripsi ini. Dukungan dan perhatian tersebut menjadi kekuatan bagi penulis dalam menjalani setiap proses serta menghadapi berbagai tantangan selama penyusunan penelitian ini. Penulis juga mengucapkan terima kasih kepada Kak Muhlis dan Kak Sri Astriyanti selaku kakak tingkat yang telah memberikan bantuan, arahan, serta berbagi pengalaman selama proses penyusunan skripsi ini.

Ucapan terima kasih juga penulis sampaikan kepada Natasya Irena Poly sebagai sahabat dan teman seperjuangan sejak masa mahasiswa baru hingga saat ini yang senantiasa bersama dalam berbagai proses perkuliahan maupun kegiatan lainnya,

serta selalu memberikan dukungan, semangat, dan kebersamaan yang berarti selama perjalanan studi ini. Penulis juga berterima kasih kepada Baso Riswanto, Muhammad Nur Bashira, Nadia Idris Riztiani, Cut Mutia, Umi Dzakira Radini, dan Nanda Lutfiah Ruslan yang telah menemani perjalanan penyusunan skripsi ini, menjadi tempat berbagi cerita, diskusi, serta memberikan motivasi hingga penelitian ini dapat terselesaikan. Penulis juga mengucapkan Terima kasih kepada teman teman sejak masa mahasiswa baru, yaitu Nurmi, Suci, Nurhidayati, Jenny, Mardiah dan Nayla, atas dukungan, kebersamaan, dan semangat yang selalu diberikan selama menjalani masa perkuliahan hingga penyusunan skripsi ini.

Selain itu, penulis juga mengucapkan terima kasih kepada rekan-rekan Geofisika angkatan 2022 Universitas Hasanuddin yang telah menjadi bagian dari perjalanan akademik penulis serta memberikan kebersamaan, dukungan, dan semangat selama masa perkuliahan.

Penulis juga mengucapkan terima kasih kepada Bapak Kepala Desa dan Ibu Kepala Desa Kanie Sidrap KKN 114 serta teman posko yang selalu di hati Cipong, Rey, Nanda, Kira dan Lika. Kehangatan yang diberikan tidak berhenti setelah program KKN selesai, tetapi tetap terjalin melalui komunikasi dan silaturahmi hingga saat ini. Penulis juga mengucapkan terima kasih kepada setiap orang yang pernah hadir dalam perjalanan penulis di Kota Makassar. Baik yang datang hanya untuk sesaat maupun yang tetap menemani hingga hari ini, terima kasih atas setiap kebaikan, pelajaran, tawa, dan kenangan yang telah diberikan. Semua itu menjadi bagian yang tidak terpisahkan dari perjalanan penulis selama menempuh pendidikan. Penulis juga mengucapkan terima kasih kepada Kota Makassar dan Provinsi Sulawesi Selatan yang telah menjadi rumah kedua selama masa perantauan. Terima kasih atas segala pengalaman, pelajaran, serta kenangan yang mengiringi perjalanan penulis sejak awal perkuliahan hingga berhasil menyelesaikan skripsi ini. Semoga setiap langkah yang pernah ditempuh di tanah rantau ini menjadi bekal berharga untuk perjalanan di masa yang akan datang. Penulis juga tidak lupa Terima kasih untuk Pondok Sakinah Yellow, tempat yang menjadi saksi banyak cerita, tawa, dan perjuangan selama masa perkuliahan. Terima kasih sudah menjadi rumah kedua dengan segala kenangannya. Semoga setiap cerita yang pernah ada di dalamnya selalu menjadi kenangan yang baik. Penulis juga mengucapkan terima kasih kepada Skage, Lazuna Lalapan Pintu 0, Mie Ayam, Nasi Kuning Tower Kanjovank, dan Tiajie yang telah menjadi bagian dari keseharian selama tinggal di kost. Terima kasih telah menemani hari-hari dengan makanan dan minuman yang sederhana, tetapi penuh kenangan.

Akhirnya, penulis mengucapkan terima kasih kepada diri sendiri yang telah bertahan hingga sejauh ini. Terima kasih karena tidak menyerah meskipun dihadapkan pada berbagai tantangan, rasa lelah, dan keraguan selama menjalani masa perkuliahan hingga penyusunan skripsi ini. Semoga setiap proses yang telah dilalui menjadi awal dari perjalanan yang lebih baik di masa depan.

Penulis,

Zeruya Yudea siagian
H061221029

ABSTRAK

ZERUYA YUDEA SIAGIAN. **Pengembangan Model Prediksi ENSO (*El Nino–Southern Oscillation*) Menggunakan Model Linear dan Non-Linear** (dibimbing oleh Prof. Dr. Halmar Halide, M.Sc).

Latar Belakang. El Nino–Southern Oscillation (ENSO) merupakan fenomena interaksi laut–atmosfer yang memengaruhi variabilitas iklim dan dapat meningkatkan risiko kekeringan serta banjir di Indonesia. Prediksi indeks Nino 3.4 diperlukan untuk mendukung upaya antisipasi terhadap dampak ENSO. **Tujuan.** Penelitian ini bertujuan menerapkan dan membandingkan kinerja Multiple Linear Regression (MLR), Long Short-Term Memory (LSTM), Random Forest, dan Extreme Gradient Boosting (XGBoost) dalam memprediksi indeks Nino 3.4 pada lead time 1–12 bulan. **Metode.** Data yang digunakan berupa indeks Nino 3.4 dan Southern Oscillation Index (SOI) bulanan periode 1873–2025 yang diperoleh dari National Oceanic and Atmospheric Administration. Data Januari 1873–Desember 2009 digunakan sebagai data pelatihan, sedangkan Januari 2010–Juli 2025 digunakan sebagai data pengujian. Variabel masukan dibentuk dari 44 lag Nino 3.4 dan 44 lag SOI. Kinerja model dievaluasi menggunakan korelasi Pearson, Root Mean Square Error (RMSE), dan Peirce Skill Score (PSS). **Hasil.** Seluruh model menunjukkan kinerja yang baik pada lead time pendek, tetapi mengalami penurunan seiring bertambahnya horizon prediksi. MLR menunjukkan kinerja paling konsisten pada sebagian besar lead time berdasarkan ketiga metrik evaluasi. LSTM memberikan hasil yang baik pada horizon pendek, tetapi mengalami penurunan lebih besar pada horizon panjang. Random Forest dan XGBoost mampu mengikuti perubahan Nino 3.4, meskipun belum menunjukkan keunggulan yang konsisten. Pada lead time 10–12 bulan, Random Forest memiliki nilai korelasi yang sedikit lebih tinggi, sedangkan MLR tetap lebih konsisten ketika RMSE dan PSS turut dipertimbangkan. **Kesimpulan.** MLR merupakan model terbaik dalam penelitian ini untuk prediksi ENSO jangka pendek hingga menengah, sedangkan kemampuan seluruh model pada lead time panjang masih terbatas.

Kata kunci: ENSO; Nino 3.4; MLR; LSTM; Random Forest; XGBoost.

ABSTRACT

ZERUYA YUDEA SIAGIAN. *Development of ENSO (El Nino –Southern Oscillation) Prediction Model Using Linear and Non-Linear Models (supervised by Prof. Dr. Halmar Halide, M.Sc).*

Background. El Nino–Southern Oscillation (ENSO) is an ocean–atmosphere phenomenon that influences climate variability and may increase the risk of droughts and floods in Indonesia. Predicting the Nino 3.4 index is therefore important for supporting early preparedness for ENSO-related impacts. **Objective.** This study aimed to implement and compare the performance of Multiple Linear Regression (MLR), Long Short-Term Memory (LSTM), Random Forest, and Extreme Gradient Boosting (XGBoost) in predicting the Nino 3.4 index at lead times of 1–12 months. **Methods.** Monthly Nino 3.4 and Southern Oscillation Index (SOI) data for 1873–2025 were obtained from the National Oceanic and Atmospheric Administration. Data from January 1873 to December 2009 were used for model training, whereas data from January 2010 to July 2025 were used for model testing. The input variables consisted of 44 historical lags of Nino 3.4 and 44 historical lags of SOI. Model performance was evaluated using Pearson correlation, Root Mean Square Error (RMSE), and Peirce Skill Score (PSS). **Results.** All models performed well at short lead times, but their performance declined as the prediction horizon increased. MLR showed the most consistent performance across most lead times based on the three evaluation metrics. LSTM also performed well at short horizons but declined more substantially at longer horizons. Random Forest and XGBoost were able to capture changes in Nino 3.4, although neither showed consistently superior performance. At lead times of 10–12 months, Random Forest produced slightly higher correlation values, while MLR remained more consistent when RMSE and PSS were also considered. **Conclusion.** MLR was the best-performing model in this study for short- to medium-range ENSO prediction, whereas the predictive ability of all models remained limited at longer lead times.

Keywords: ENSO; Nino 3.4; MLR; LSTM; Random Forest; XGBoost.

DAFTAR ISI

LEMBAR PENGESAHAN	iv
PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA	v
UCAPAN TERIMA KASIH	vi
ABSTRAK.....	viii
ABSTRACT	ix
DAFTAR ISI	x
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
DAFTAR LAMPIRAN.....	xiv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2.1 Tujuan Penelitian.....	3
1.2.2 Manfaat Penelitian	3
1.3 Landasan Teori.....	3
1.3.1 Fenomena ENSO	3
1.3.2 <i>Machine Learning</i> dan <i>Deep Learning</i> dalam Prediksi ENSO.....	5
1.3.3 <i>Multiple Linear Regression</i>	7
1.3.4 <i>Long Short Term Memory</i> (LSTM)	8
1.3.5 <i>Random Forest</i>	10
1.3.6 <i>Extreme Gradient Boosting</i> (XGBoost)	12
1.3.7 Evaluasi Model Prediksi Enso	13
BAB II METODE PENELITIAN.....	15
2.1 Data Penelitian	15
2.2 Prosedur Penelitian	15
2.2.1 Pengumpulan Data	15
2.2.2 Pra-Pemrosesan Data.....	15
2.2.4 Pemodelan Prediksi	16
2.2.5 Evaluasi dan Verifikasi Model	16
2.3 Prosedur Model Prediksi	16
2.3.1 Penerapan <i>Multiple Linear Regression</i> (MLR).....	16
2.3.2 Penerapan <i>Long Short-Term Memory</i> (LSTM)	17
2.3.3 Penerapan <i>Random Forest</i>	17

2.3.4 Penerapan <i>Extreme Gradient Boosting</i> (XGBoost)	17
2.4 Evaluasi dan Verifikasi Model	18
2.4.1 <i>Root Mean Square Error</i> (RMSE)	18
2.4.2 <i>Pearson Correlation</i> (r)	18
2.4.3 <i>Peirce Skill Score</i> (PSS)	18
2.5 Bagan Alir	19
BAB III HASIL DAN PEMBAHASAN	20
3.1 Hasil	20
3.2 Pembahasan	25
BAB IV KESIMPULAN	28
4.1 Kesimpulan	28
4.2 Saran	28
DAFTAR PUSTAKA	29
LAMPIRAN	32

DAFTAR TABEL

Tabel 1. ACC Model MLR, LSTM, RF, dan XGBoost	24
Tabel 2. RMSE Model MLR, LSTM, RF, dan XGBoost	25
Tabel 3. PSS Model MLR, LSTM, RF, dan XGBoost.....	25

DAFTAR GAMBAR

Gambar 1. Ilustrasi Perubahan Sirkulasi Atmosfer–Laut pada Fase El Nino, Netral, dan La Nina https://www.climate.gov/enso	4
Gambar 2. Diagram Hierarki <i>Artificial Intelligence</i> dan <i>Machine Learning</i> (Roihan et al., 2020).	6
Gambar 3. Bagan Alir	19
Gambar 4. Time Series dari model (a) <i>Multiple Linear Regression</i> , (b) <i>Long Short-Term Memory</i> , (c) <i>Random Forest</i> , dan (d) <i>Extreme Gradient Boosting</i>	21
Gambar 5. Evaluasi RMSE, ACC dan PSS dari model (a) <i>Multiple Linear Regression</i> , (b) <i>Long Short-Term Memory</i> , (c) <i>Random Forest</i> , dan (d) <i>Extreme Gradient Boosting</i>	23
Gambar 6. Perbandingan Kinerja Semua Model Prediksi ENSO	24

DAFTAR LAMPIRAN

Lampiran 1. Data Indeks ENSO NINO 3.4 dan SOI	32
Lampiran 2. Program matlab <i>Time Series</i>	32
Lampiran 3. Program Matlab <i>Root Mean Square Error (RMSE), Anomaly Corelation Coefisien (ACC), dan Peirce Skill Score (PSS)</i>	42
Lampiran 4. Program Matlab Perbandingan Kinerja Model	61
Lampiran 5. Hasil Penelitian	65
Lampiran 6. Riwayat Hidup.....	69

BAB I

PENDAHULUAN

1.1 Latar Belakang

El Niño–Southern Oscillation (ENSO) merupakan fenomena global yang kompleks dan memberikan pengaruh terhadap kondisi cuaca, iklim, serta berbagai sektor di Indonesia. Fenomena ini berkaitan dengan perubahan pola angin dan suhu permukaan laut di Samudra Pasifik yang selanjutnya dapat memengaruhi pola curah hujan, suhu udara, dan kejadian iklim ekstrem di berbagai wilayah dunia. Berbagai penelitian menunjukkan adanya keterkaitan antara ENSO dan perubahan pola iklim global, termasuk kejadian cuaca ekstrem seperti badai tropis, kekeringan, dan banjir. Oleh karena itu, pemahaman mengenai ENSO menjadi penting untuk meningkatkan kemampuan dalam memprediksi serta mengurangi dampak yang ditimbulkannya terhadap kehidupan dan lingkungan (Ullum et al., 2024).

ENSO memiliki dua fase utama, yaitu El Nino dan La Nina dimana El Nino merupakan fase positif yang ditandai oleh suhu permukaan laut (*Sea Surface Temperature* atau SST) di wilayah Pasifik tropis bagian tengah dan timur yang lebih tinggi dibandingkan rata-rata klimatologis. Sebaliknya, La Nina merupakan fase negatif yang terjadi ketika SST di wilayah tersebut berada lebih rendah dari kondisi normal. Di sebagian besar wilayah Indonesia, El Nino umumnya menyebabkan musim kemarau menjadi lebih kering dan awal musim hujan mengalami keterlambatan. Sementara itu, La Nina cenderung menyebabkan musim penghujan datang lebih awal dibandingkan kondisi klimatologis normal. Salah satu indeks yang digunakan untuk mengidentifikasi kondisi ENSO adalah indeks Nino 3.4 yang menunjukkan anomali suhu muka laut di wilayah tropis Samudra Pasifik (Hidayat & Prasetyo, 2021). Pemantauan dan prediksi ENSO dilakukan secara rutin oleh lembaga internasional, seperti *National Oceanic and Atmospheric Administration* (NOAA) dan *World Meteorological Organization* (WMO), dengan memanfaatkan model dinamis dan statistik yang mempertimbangkan interaksi antara laut dan atmosfer.

ENSO tidak hanya memengaruhi kondisi iklim, tetapi juga memberikan dampak terhadap sistem alam dan berbagai aktivitas manusia. Dampaknya dapat dirasakan pada sektor pertanian, kehutanan, kesehatan masyarakat, siklus hidrologi, siklus karbon global, ekosistem laut dan darat, serta perikanan. Pengaruh ENSO terhadap wilayah di luar Pasifik tropis dapat terjadi melalui mekanisme keterkaitan atmosfer (Yeh et al., 2018). Di Indonesia, sektor pertanian menjadi salah satu sektor yang cukup dipengaruhi oleh kejadian El Nino dan La Nina. El Nino umumnya berkaitan dengan penurunan curah hujan yang dapat menyebabkan kekeringan, sedangkan La Nina berhubungan dengan peningkatan curah hujan yang dapat memicu banjir. Kondisi tersebut dapat menyebabkan berkurangnya luas panen maupun penurunan produktivitas pertanian. Meskipun demikian, kejadian iklim ekstrem tidak selalu memberikan dampak negatif terhadap seluruh komoditas pertanian. Salah satu contohnya adalah kondisi musim hujan yang lebih panjang akibat La Nina yang dapat memberikan pengaruh positif

terhadap produksi padi karena adanya peningkatan luas tanam pada musim kemarau (Surmaini, 2016).

Kemampuan untuk memprediksi ENSO terus mengalami perkembangan. Dengan memanfaatkan model iklim dan data historis, ENSO dapat diprediksi hingga sekitar 14 bulan ke depan. Informasi tersebut penting dalam mendukung pengambilan keputusan, baik pada tingkat nasional maupun internasional, terutama untuk mengantisipasi dampak kejadian cuaca ekstrem yang berkaitan dengan ENSO, seperti kekeringan dan banjir. Salah satu penerapannya dilakukan oleh Peru yang memanfaatkan informasi prediksi ENSO untuk mengurangi potensi kerugian ekonomi akibat kejadian El Nino. Beberapa langkah antisipatif yang dilakukan antara lain pembangunan infrastruktur pengendali air dan penerapan skema asuransi pertanian (Nobre et al., 2019).

Indeks Nino 3.4 dan *Southern Oscillation Index* (SOI) hanya menggambarkan sebagian kondisi laut dan atmosfer yang berkaitan dengan ENSO. Oleh karena itu, metode pemodelan yang digunakan dalam prediksi menjadi salah satu hal yang perlu diperhatikan agar pola temporal pada data ENSO dapat digambarkan dengan baik. Penggunaan metode berbasis kecerdasan buatan menjadi salah satu pendekatan yang telah banyak diterapkan dalam memprediksi indeks yang berkaitan dengan ENSO. Aprilia et al. (2020) melakukan prediksi indeks ENSO menggunakan Jaringan Saraf Tiruan dengan algoritma *backpropagation*. Indeks yang digunakan dalam penelitian tersebut meliputi Nino 1.2, Nino 3, Nino 3.4, Nino 4, *Southern Oscillation Index* (SOI), dan *Multivariate ENSO Index versi 2* (MEI.v2). Proses pemodelan dilakukan dengan memvariasikan nilai *learning rate* dan momentum. Hasil penelitian menunjukkan bahwa seluruh indeks memiliki akurasi prediksi yang tinggi. Di antara indeks yang digunakan, Nino 4 memberikan hasil terbaik karena memiliki nilai *Mean Square Error* (MSE) pada tahap pelatihan dan pengujian yang lebih rendah dibandingkan indeks lainnya.

Penelitian mengenai prediksi indeks ENSO juga dilakukan oleh Zahra et al. (2024) dengan menerapkan *Artificial Neural Network* menggunakan algoritma *backpropagation* untuk memprediksi *Southern Oscillation Index* (SOI). Hasil penelitian menunjukkan bahwa arsitektur jaringan 12-7-1 merupakan model terbaik dengan nilai *Mean Squared Error* sebesar 0,0095 dan *Mean Absolute Percentage Error* sebesar 17,6851%. Model tersebut selanjutnya digunakan untuk memprediksi nilai SOI selama 12 bulan berikutnya. Penelitian terdahulu tersebut menunjukkan bahwa jaringan saraf tiruan dapat digunakan untuk memprediksi indeks yang berkaitan dengan ENSO. Aprilia et al. (2020) menerapkan *JST-backpropagation* pada beberapa indeks ENSO, sedangkan Zahra et al. (2024) secara khusus meramalkan SOI menggunakan ANN. Berbeda dengan penelitian tersebut, penelitian ini membandingkan model linear, *machine learning*, dan *deep learning*, yaitu *Multiple Linear Regression* (MLR), Random Forest, *Extreme Gradient Boosting* (XGBoost), dan *Long Short-Term Memory* (LSTM). Keempat model digunakan untuk memprediksi indeks Nino 3.4 pada *lead time* 1 hingga 12 bulan dengan memanfaatkan nilai historis Niño 3.4 dan SOI sebagai variabel prediktor. Perbandingan dilakukan untuk mengevaluasi kinerja setiap model berdasarkan ACC, RMSE, dan PSS serta menentukan model yang memberikan hasil prediksi terbaik.

Berdasarkan hal tersebut, penelitian ini dilakukan untuk mengembangkan dan membandingkan kinerja model MLR, LSTM, Random Forest, dan XGBoost dalam memprediksi indeks Niño 3.4 pada *lead time* 1 hingga 12 bulan. Hasil penelitian diharapkan dapat memberikan informasi mengenai kemampuan masing-masing model dalam memprediksi ENSO berdasarkan data historis Nino 3.4 dan SOI.

1.2 Tujuan dan Manfaat

1.2.1 Tujuan Penelitian

Adapun tujuan dari penelitian ini adalah:

1. Mengimplementasikan model *Multiple Linear Regression* (MLR), *Long Short-Term Memory* (LSTM), *Random Forest*, dan *Extreme Gradient Boosting* (XGBoost) untuk melakukan prediksi *El Nino–Southern Oscillation* (ENSO).
2. Melakukan evaluasi terhadap kinerja setiap model menggunakan *Pearson Correlation* (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS), serta menentukan model terbaik berdasarkan hasil evaluasi tersebut.

1.2.2 Manfaat Penelitian

Adapun manfaat dari penelitian ini adalah:

1. Menyediakan referensi mengenai penerapan model prediksi *El Nino–Southern Oscillation* (ENSO) menggunakan pendekatan model linear dan non-linear dalam analisis data runtun waktu.
2. Menjadi bahan referensi untuk pengembangan penelitian selanjutnya dalam pemodelan dan prediksi variabilitas iklim ENSO dengan pendekatan berbasis data.


1.3 Landasan Teori

1.3.1 Fenomena ENSO

Perubahan iklim merupakan perubahan suhu dan pola cuaca yang berlangsung dalam jangka panjang. Kondisi tersebut dapat terjadi akibat variabilitas alami maupun aktivitas manusia yang menyebabkan perubahan komposisi atmosfer (Ariska et al., 2022). Perubahan iklim dapat memengaruhi frekuensi, luas wilayah terdampak, durasi, serta waktu terjadinya cuaca ekstrem. Kondisi ini juga dapat memunculkan kejadian cuaca yang sebelumnya belum pernah terjadi dan berpotensi menimbulkan kerugian yang besar bagi manusia maupun lingkungan. Salah satu penyebab perubahan iklim adalah meningkatnya emisi CO₂ dan ozon troposfer yang memperkuat efek rumah kaca. Peningkatan tersebut berkontribusi terhadap pemanasan global yang kemudian memengaruhi suhu bumi, curah hujan, pola angin, dan evapotranspirasi. Perubahan iklim menjadi salah satu ancaman bagi kehidupan manusia dan lingkungan. Kondisi iklim dipengaruhi oleh berbagai faktor, baik abiotik maupun biotik. Faktor abiotik meliputi suhu udara, curah hujan, kondisi permukaan laut, dan unsur lingkungan fisik lainnya, sedangkan faktor biotik berkaitan dengan seluruh populasi makhluk hidup yang terdapat di bumi. Perubahan pada kondisi tersebut dapat berkaitan dengan munculnya kejadian iklim ekstrem yang menimbulkan kerugian pada berbagai sektor (Suhadi et al., 2023).

Perubahan iklim global saat ini menjadi salah satu isu penting dalam pembahasan mengenai perubahan lingkungan. Salah satu fenomena iklim yang berkaitan dengan kondisi tersebut adalah *El Nino–Southern Oscillation* (ENSO). ENSO

memiliki tiga fase, yaitu El Nino, La Nina, dan Netral. El Nino dan La Nina merupakan dua fase yang berlawanan dan ditandai oleh perubahan kondisi laut serta atmosfer karena ENSO terbentuk dari interaksi yang saling berkaitan antara kedua komponen tersebut. Fase Netral berada di antara El Nino dan La Nina. El Nino ditandai oleh peningkatan suhu permukaan laut (*Sea Surface Temperature/SST*) di atas rata-rata pada wilayah Samudra Pasifik tropis bagian tengah dan timur. Kondisi ini umumnya menyebabkan penurunan curah hujan di Indonesia, sedangkan curah hujan di wilayah Pasifik tropis mengalami peningkatan. Pada saat yang sama, angin permukaan lapisan bawah yang biasanya bergerak dari timur ke barat sepanjang ekuator atau dikenal sebagai angin timuran cenderung melemah dan pada kondisi tertentu dapat berbalik arah menjadi angin baratan. Sebaliknya, La Nina ditandai oleh suhu permukaan laut yang lebih rendah dari rata-rata pada wilayah Samudra Pasifik tropis bagian tengah dan timur. Kondisi tersebut umumnya menyebabkan peningkatan curah hujan di Indonesia dan penurunan curah hujan di wilayah Pasifik tropis bagian tengah. Pada fase ini, angin timuran di sepanjang ekuator menjadi lebih kuat dibandingkan kondisi normal. Sementara itu, fase Netral terjadi ketika kondisi El Nino maupun La Nina tidak berlangsung. Pada fase ini, SST di wilayah Pasifik tropis umumnya berada di sekitar nilai rata-rata. Meskipun demikian, dalam kondisi tertentu, keadaan laut dapat menunjukkan karakteristik yang menyerupai El Nino atau La Nina tanpa diikuti respons atmosfer yang sesuai, begitu pula sebaliknya (NOAA Climate.gov).



Gambar 1. Ilustrasi Perubahan Sirkulasi Atmosfer–Laut pada Fase El Nino, Netral, dan La Nina <https://www.climate.gov/enso>


El Nino dapat dikenali melalui peningkatan suhu permukaan laut di wilayah Pasifik serta perubahan tekanan atmosfer. Fenomena ini memberikan pengaruh yang cukup besar terhadap Indonesia, terutama berupa berkurangnya curah hujan dan berlangsungnya musim kemarau yang lebih panjang. Kondisi tersebut dapat menimbulkan berbagai permasalahan pada sektor pertanian, seperti gagal panen dan penurunan ketahanan pangan. Kekeringan yang terjadi selama El Nino juga dapat mengurangi ketersediaan air bersih, terutama di wilayah pedesaan. Selain itu, kondisi yang lebih kering dapat meningkatkan risiko kebakaran hutan, khususnya pada wilayah lahan gambut. Kebakaran tersebut tidak hanya menyebabkan kerusakan lingkungan, tetapi juga dapat meningkatkan emisi gas rumah kaca dan menimbulkan gangguan terhadap kesehatan masyarakat (Ullum et al., 2024).

Pengaruh ENSO terhadap curah hujan tahunan di Indonesia diketahui lebih besar dibandingkan pengaruh El Nino atau La Nina apabila dilihat secara terpisah. Pengaruh terhadap curah hujan musiman juga tetap terlihat, meskipun kekuatannya berbeda. El Nino memberikan pengaruh yang berada pada tingkat sedang, sedangkan pengaruh La Nina cenderung lebih lemah. Besarnya pengaruh tersebut dapat berbeda antarwilayah di Indonesia. Salah satu indikator yang banyak digunakan untuk menentukan fase ENSO adalah indeks Nino 3.4. Indeks ini menjadi salah satu indeks utama dalam mengidentifikasi kejadian El Nino dan La Nina, sedangkan indeks lainnya dapat digunakan untuk melihat karakteristik yang lebih spesifik dari masing-masing kejadian. Berdasarkan nilai anomali suhu muka laut, indeks Nino 3.4 dapat dikelompokkan menjadi beberapa kategori, yaitu lemah dengan nilai $0,5-0,9^{\circ}\text{C}$, *moderate* sebesar $1,0-1,4^{\circ}\text{C}$, kuat sebesar $1,5-1,9^{\circ}\text{C}$, dan sangat kuat dengan nilai $\geq 2,0^{\circ}\text{C}$. Sementara itu, berdasarkan klasifikasi Badan Meteorologi dan Geofisika, kategori *moderate* berada pada kisaran $1,0-2,0^{\circ}\text{C}$, sedangkan kategori kuat berada pada nilai lebih dari $2,0^{\circ}\text{C}$ (Abdullah, 2021).

1.3.2 Machine Learning dan Deep Learning dalam Prediksi ENSO

Perkembangan teknologi kecerdasan buatan (*artificial intelligence*) telah mendorong penggunaan metode komputasi dalam menyelesaikan berbagai permasalahan yang kompleks. Salah satu perkembangannya terlihat pada penggunaan *machine learning* dan *deep learning*, termasuk untuk pemodelan dan prediksi fenomena iklim seperti *El Niño–Southern Oscillation* (ENSO). Dalam kajian variabilitas iklim, *machine learning* telah digunakan untuk berbagai keperluan, seperti pemodelan iklim, prediksi cuaca ekstrem, serta analisis hubungan antara laut dan atmosfer. Dalam prediksi ENSO, algoritma *machine learning* dapat digunakan untuk mempelajari hubungan antara variabel-variabel iklim, seperti suhu muka laut dan tekanan udara, dengan perubahan indeks Niño 3.4 yang digunakan sebagai salah satu indikator kondisi El Nino, Netral, dan La Nina.

Secara umum, *machine learning* merupakan metode komputasi yang memungkinkan sistem mempelajari pola dari data untuk menghasilkan suatu prediksi. Proses pembentukan model umumnya dilakukan melalui tahap pelatihan (*training*) dan pengujian (*testing*). Tahap pelatihan digunakan untuk membangun model berdasarkan pola yang terdapat pada data, sedangkan tahap pengujian dilakukan untuk mengetahui kemampuan model dalam memberikan hasil pada data yang digunakan untuk evaluasi. Konsep utama dalam *machine learning* berkaitan dengan bagaimana suatu program komputer dapat meningkatkan kemampuannya berdasarkan pengalaman atau data yang diperoleh. Berdasarkan proses pembelajarannya, *machine learning* secara umum dikelompokkan menjadi tiga kategori, yaitu *Supervised Learning*, *Unsupervised Learning*, dan *Reinforcement Learning* (Roihan et al.). Hubungan antara *artificial intelligence* dan *machine learning* dapat dilihat pada Gambar 2.



Gambar 2. Diagram Hierarki Artificial Intelligence dan Machine Learning (Roihan et al., 2020).

Pada *Supervised Learning*, proses pembelajaran dilakukan menggunakan data yang telah memiliki label atau target sehingga model dapat digunakan untuk melakukan prediksi maupun klasifikasi. Berbeda dengan *Unsupervised Learning*, proses pembelajaran dilakukan tanpa menggunakan label sebagai acuan sehingga model berusaha menemukan pola atau struktur yang terdapat di dalam data secara mandiri. Perbedaan tersebut membuat kedua pendekatan memiliki penerapan dan hasil yang berbeda sesuai dengan karakteristik permasalahan yang dihadapi. Sementara itu, *Reinforcement Learning* merupakan pendekatan pembelajaran yang memungkinkan algoritma menentukan tindakan berdasarkan informasi berupa sinyal penguatan (*reward*) untuk mencapai hasil yang diharapkan secara optimal. Beberapa metode yang termasuk dalam *machine learning* antara lain *Multiple Linear Regression* (MLR), *Random Forest* (RF), dan *Extreme Gradient Boosting* (XGBoost). Metode-metode tersebut umumnya digunakan dalam pendekatan *supervised learning*, baik untuk permasalahan regresi maupun klasifikasi (Nurhalizah et al., 2024).

Deep learning merupakan salah satu pengembangan dari *machine learning* yang menggunakan proses pembelajaran dengan beberapa tingkatan representasi data. Pendekatan ini umumnya memanfaatkan jaringan saraf tiruan untuk mempelajari data melalui beberapa lapisan. Setiap lapisan mempelajari representasi dengan tingkat abstraksi yang berbeda, sehingga informasi pada tingkat yang lebih rendah dapat digunakan untuk membentuk representasi pada tingkat yang lebih tinggi. Menurut Khotimah dan Abdan (2025), konsep *deep learning* bukan merupakan pendekatan yang sepenuhnya baru. Istilah dan konsep *deep learning* telah berkembang sejak tahun 1976, sedangkan Marton dan Säljö (1976) memperkenalkan pendekatan pembelajaran mendalam yang menekankan pemahaman terhadap makna dan hubungan antar konsep secara menyeluruh (Santiani, 2025).

Deep learning merupakan bagian dari *machine learning* yang menggunakan Jaringan Saraf Tiruan (JST) sebagai dasar pembelajarannya. Pendekatan ini dapat dipandang sebagai pengembangan JST dengan struktur jaringan yang lebih kompleks. Biggs dan Tang (2011) menjelaskan bahwa penerapan strategi *deep learning* membutuhkan rancangan pembelajaran yang terintegrasi, mulai dari penentuan tujuan, kegiatan, hingga penilaian yang mendukung pemahaman konseptual (Fatmawati, 2024). Dalam penerapannya pada komputasi, model *deep learning* dirancang untuk mempelajari data melalui sejumlah lapisan yang saling terhubung. Struktur tersebut memungkinkan model melakukan proses pengolahan informasi secara bertahap melalui *Artificial Neural Network* (ANN). Setiap lapisan pada jaringan menghasilkan keluaran yang kemudian diteruskan ke lapisan berikutnya. Hubungan antarneuron pada lapisan

tersebut diproses menggunakan fungsi aktivasi sehingga model dapat mempelajari hubungan nonlinier dalam data. Selama proses pelatihan, parameter atau bobot pada setiap neuron diperbarui melalui proses optimasi untuk memperoleh keluaran yang mendekati nilai target. Salah satu metode *deep learning* yang banyak digunakan untuk data runtun waktu adalah *Long Short-Term Memory* (LSTM). Metode ini dirancang untuk mempelajari pola pada data sekuensial dengan mempertahankan informasi yang relevan, baik dalam hubungan jangka pendek maupun jangka panjang (Raup et al., 2022).

1.3.3 Multiple Linear Regression

Di samping metode berbasis *machine learning* dan *deep learning*, *Multiple Linear Regression* (MLR) merupakan pendekatan regresi linear yang dapat digunakan dalam pemodelan prediksi ENSO. *Multiple Linear Regression* (MLR) merupakan metode statistik yang menggunakan lebih dari satu variabel penjelas untuk memperkirakan nilai suatu variabel respon. Metode ini digunakan untuk mengetahui dan memodelkan hubungan linear antara variabel independen sebagai prediktor dengan variabel dependen sebagai respon. Regresi linear berganda dapat digunakan untuk menjelaskan perubahan pada variabel respon berdasarkan beberapa variabel prediktor yang memengaruhinya. Apabila variabel yang menjadi target memiliki nilai numerik dan variabel yang digunakan sebagai prediktor juga bersifat numerik, regresi linear dapat menjadi salah satu metode yang sesuai untuk digunakan (Samine et al., 2026).

$$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_n X_n + \epsilon \quad (1)$$

Keterangan (Wiguna, 2025):

Y= Variabel Terikat

X= Variabel Bebas

α , β_1 , β_2 , β_n = Parameter Regresi/ Koefisien Regresi

Model *Multiple Linear Regression* (MLR) variabel dependen dinyatakan sebagai kombinasi linear dari sejumlah variabel independen. Koefisien yang terdapat dalam model umumnya diperoleh menggunakan metode *least squares*, yaitu dengan meminimalkan jumlah kuadrat selisih antara nilai variabel dependen yang diamati dengan nilai yang dihasilkan oleh model. Penggunaan MLR memiliki beberapa asumsi dan keterbatasan yang perlu diperhatikan. Model mengasumsikan adanya hubungan linear antarvariabel serta independensi antarvariabel prediktor. Selain itu, ketika jumlah variabel independen cukup banyak, pemilihan jumlah variabel yang digunakan dalam model perlu diperhatikan agar kesalahan prediksi dapat diminimalkan. Apabila terdapat penyimpangan yang cukup besar dari hubungan linear yang dapat diketahui melalui analisis galat, penggunaan model regresi non-linear dapat menjadi alternatif yang lebih sesuai.

Salah satu permasalahan yang perlu diperhatikan dalam MLR adalah adanya hubungan atau korelasi antarvariabel prediktor yang dikenal sebagai *multikolinearitas*. Kondisi ini bertentangan dengan asumsi bahwa variabel prediktor bersifat independen satu sama lain. Tingkat *multikolinearitas* dapat dievaluasi menggunakan beberapa ukuran, seperti *tolerance* atau koefisien korelasi semi-parsial, yang dapat memberikan gambaran mengenai sejauh mana suatu prediktor dapat dijelaskan melalui kombinasi

linear prediktor lainnya. MLR kurang sesuai apabila terdapat tingkat *multikolinearitas* yang tinggi karena kondisi tersebut dapat menurunkan kemampuan model dalam melakukan prediksi. Apabila tersedia banyak variabel independen, variabel yang memiliki kontribusi sangat kecil terhadap prediksi dapat dipertimbangkan untuk dihilangkan dari model. Pemilihan jumlah variabel prediktor juga berkaitan dengan kemungkinan terjadinya *underfitting* dan *overfitting*. *Underfitting* terjadi ketika model menggunakan terlalu sedikit variabel independen sehingga belum mampu menjelaskan variasi pada variabel dependen dengan baik. Sebaliknya, *overfitting* dapat terjadi ketika model menggunakan terlalu banyak variabel independen sehingga model cenderung menangkap *noise* yang terdapat pada data. Kondisi tersebut dapat menyebabkan kemampuan prediksi model terhadap data baru menurun. Oleh karena itu, jumlah variabel independen yang digunakan perlu ditentukan pada tingkat yang sesuai agar model dapat memberikan kemampuan prediksi yang optimal.

MLR juga memungkinkan dilakukan pengujian terhadap tingkat signifikansi statistik dari koefisien masing-masing variabel prediktor. Variabel yang memiliki koefisien signifikan secara statistik dan nilai *tolerance* yang tinggi dapat dipertimbangkan untuk dipertahankan dalam model. Secara umum, semakin besar proporsi variabel independen yang signifikan dibandingkan dengan jumlah seluruh variabel independen yang digunakan, semakin baik kemampuan model dalam menjelaskan hubungan antara variabel prediktor dan variabel respon. Ketika jumlah variabel independen yang tersedia cukup banyak, salah satu pendekatan yang dapat digunakan untuk menentukan kombinasi variabel yang sesuai adalah *stepwise regression*. *Stepwise regression* digunakan untuk memperoleh model regresi yang memiliki kemampuan prediksi baik dengan jumlah variabel independen yang relatif minimum dan tetap memiliki signifikansi statistik. Proses pemilihan variabel dilakukan secara bertahap berdasarkan kriteria tertentu yang telah ditetapkan. Pendekatan ini dapat dilakukan melalui dua metode, yaitu *forward stepwise regression* (FSR) dan *backward stepwise regression* (BSR). Pada FSR, variabel independen dimasukkan ke dalam model secara bertahap berdasarkan kriteria yang telah ditentukan. Sebaliknya, BSR dimulai dengan model yang memuat sejumlah variabel independen, kemudian variabel yang memenuhi kriteria untuk dikeluarkan akan dihapus secara bertahap. Kriteria untuk memasukkan maupun mengeliminasi variabel ditentukan sejak awal dan dapat berupa tingkat probabilitas statistik atau ukuran kriteria tertentu. Kriteria tersebut digunakan untuk menilai besarnya kontribusi masing-masing variabel independen terhadap persamaan regresi sehingga dapat ditentukan apakah suatu variabel perlu ditambahkan atau dikeluarkan dari model (Cozmuta, 2025).

1.3.4 Long Short Term Memory (LSTM)

Salah satu metode *deep learning* yang dapat digunakan untuk mengolah data *time series*, termasuk data yang diperoleh dari pengamatan cuaca, adalah *Long Short-Term Memory* (LSTM). Metode LSTM pertama kali diperkenalkan oleh Hochreiter dan Schmidhuber pada tahun 1997 (Supriyadi, 2021). LSTM merupakan salah satu pengembangan dari arsitektur *Recurrent Neural Network* (RNN) yang dirancang untuk mengolah data secara berurutan. Keunggulan LSTM terletak pada kemampuannya dalam menentukan informasi yang perlu dipertahankan dan informasi yang tidak lagi diperlukan selama proses pembelajaran. Kemampuan tersebut diperoleh melalui mekanisme *gate* yang mengatur penyimpanan dan penggunaan informasi pada setiap bagian jaringan.

LSTM memiliki kemampuan yang lebih baik dibandingkan RNN dalam mempelajari data *time series* yang memiliki ketergantungan jangka panjang (*long-term dependency*). Informasi dari periode sebelumnya dapat dipertahankan melalui *cell state* sehingga informasi yang masih relevan dapat digunakan pada proses berikutnya. Kemampuan tersebut membuat LSTM banyak digunakan dalam pemodelan dan prediksi data yang memiliki hubungan berdasarkan urutan waktu. Pada arsitektur LSTM terdapat tiga jenis *gate* utama, yaitu *forget gate*, *input gate*, dan *output gate* yang masing-masing memiliki fungsi dalam mengatur informasi yang terdapat pada jaringan (Lattifia et al., 2022).

Forget gate berfungsi untuk menentukan informasi dari *cell state* sebelumnya yang masih perlu dipertahankan dan informasi yang dapat dihilangkan. Proses tersebut dilakukan menggunakan fungsi aktivasi *sigmoid* yang menghasilkan nilai antara 0 dan 1. Nilai yang mendekati 0 menunjukkan bahwa informasi tersebut perlu dilupakan, sedangkan nilai yang mendekati 1 menunjukkan bahwa informasi masih perlu dipertahankan. Dengan mekanisme tersebut, LSTM dapat mengurangi penyimpanan informasi yang tidak lagi diperlukan dalam proses pembelajaran. Persamaan *forget gate* dapat dituliskan sebagai berikut (Sahroni et al., 2024):

$$\sigma(x_i) = \frac{1}{1+e^{-x_i}} \quad (2)$$

Yang mana apabila bernilai benar benar mempertahankan elemen ini dan jika nilai 0 memiliki arti benar-benar menghilangkan elemen. Dilanjutkan dengan menghitung *forget gate* memakai rumus persamaan:

$$ft = \sigma(W_{fhx} \cdot X_t + W_{fhh} \cdot n_{t-1} + b_f) \quad (3)$$

Input gate berperan dalam menentukan informasi baru yang akan dimasukkan ke dalam *cell state*. Pada tahap ini, fungsi *sigmoid* digunakan untuk menentukan informasi yang akan diperbarui, sedangkan fungsi aktivasi *tanh* menghasilkan vektor kandidat informasi baru yang dapat ditambahkan ke dalam *cell state*. Kedua hasil tersebut kemudian digunakan secara bersama-sama untuk menentukan informasi yang akan disimpan pada *cell state*. Dengan demikian, *input gate* membantu LSTM dalam memilih informasi baru yang dianggap penting untuk digunakan pada proses berikutnya. Persamaan *input gate* dapat dituliskan sebagai berikut (Sahroni et al., 2024):

$$ft = \sigma(w_{ix} \cdot x_t + W_{ih} \cdot h_{t-1} + b_i) \quad (4)$$

$$\tilde{c}_t = \tanh(W_{cx} \cdot x_t + W_{ch} \cdot h_{t-1} + b_c) \quad (5)$$

Dimana Fungsi tanh:

$$\tanh(x) = 2\sigma(2x) - 1 \quad (6)$$

Cell state (ct) Di langkah ini, nilai yang ada pada sebuah mempry cell sebelumnya ($ct-1$) diperbarui dengan nilai yang ada pada *memory cell* yang baru (ct), dengan sebuah rumus persamaan:

$$ct = ft * ct - 1 + it * \tilde{c}_t \quad (7)$$

Selanjutnya, *output gate* berfungsi menentukan informasi yang akan dikeluarkan dari *cell state* sebagai *hidden state*. Pada tahap ini, fungsi sigmoid digunakan untuk menentukan bagian informasi yang akan diteruskan sebagai keluaran. Sementara itu, fungsi aktivasi tanh digunakan pada *cell state* untuk menghasilkan nilai dalam rentang -1 hingga 1. Hasil dari kedua fungsi tersebut kemudian dikalikan untuk memperoleh informasi yang dipilih sebagai *hidden state*. Informasi inilah yang selanjutnya digunakan sebagai keluaran pada tahap tersebut dan diteruskan ke proses berikutnya. Persamaan output gate dapat dituliskan sebagai berikut (Sahroni et al., 2024):

$$O_t = \sigma(W_{ox} \cdot x_t + w_{oh} \cdot h_{t-1} + b_o) \quad (8)$$

$$h_t = \tanh(c_t) * o_t \quad (9)$$

Penggunaan *Long Short-Term Memory* (LSTM) dalam prediksi *time series* memungkinkan model mempelajari pola yang terdapat pada data berdasarkan urutan waktu. Namun, parameter model LSTM yang telah diperoleh melalui proses pelatihan bersifat tetap setelah proses tersebut selesai. Kondisi ini menyebabkan model tidak dapat melakukan pembaruan parameter secara langsung berdasarkan kesalahan yang muncul setelah proses prediksi. Oleh karena itu, diperlukan proses evaluasi untuk mengetahui tingkat kesalahan dan kinerja model yang dihasilkan. Regresi merupakan salah satu pendekatan statistik dan matematis yang banyak digunakan untuk menganalisis hubungan antarvariabel. Metode ini dapat digunakan untuk melihat keterkaitan serta korelasi antarvariabel dan menggambarkan hubungan tersebut secara kuantitatif. Dalam proses peramalan, model digunakan untuk memperoleh perkiraan terhadap kondisi yang akan datang sehingga ketidakpastian dari suatu permasalahan dapat dikurangi. Hasil peramalan diharapkan memiliki tingkat kesalahan yang rendah atau *forecast error* yang minimum. Oleh karena itu, diperlukan indikator tertentu untuk mengevaluasi dan mengetahui seberapa baik kinerja model dalam menghasilkan prediksi (Ashari & Sadikin, 2020).

1.3.5 Random Forest

Salah satu metode *machine learning* yang dapat digunakan untuk menyelesaikan permasalahan regresi adalah *Random Forest* (RF). Metode ini merupakan bagian dari *ensemble learning* yang membentuk model dengan menggabungkan sejumlah *decision tree*. Setiap pohon dalam *Random Forest* dibangun menggunakan variasi data dan fitur yang berbeda. Pada proses pemisahan (*split*) setiap pohon, hanya sebagian fitur yang dipilih secara acak sebagai kandidat pemisahan. Penggunaan variasi tersebut membuat model lebih kuat dalam menghadapi data yang kompleks dan dapat mengurangi kemungkinan terjadinya *overfitting* (Sarica et al., 2025).

Random Forest termasuk dalam metode *supervised learning* dan dapat digunakan untuk permasalahan regresi dengan variabel target yang memiliki nilai kontinu. Metode ini memiliki beberapa kelebihan, antara lain kemampuan dalam mengurangi *overfitting*, menghasilkan tingkat akurasi yang baik, serta dapat digunakan pada data dengan jumlah atau dimensi fitur yang tinggi. Dalam proses prediksi, RF mempelajari pola dan hubungan antara berbagai fitur sebagai variabel independen dengan nilai target yang ingin diperkirakan. Oleh karena itu, pemahaman mengenai

hubungan antarvariabel dalam suatu dataset perlu diperhatikan sebelum model dibangun dan diterapkan (Manurung et al., 2025).

$$F(x) = \frac{1}{J} \sum_{j=1}^J h_j(x) \quad (10)$$

Keterangan (Sari & Suryono, 2024):

$F(x)$: output dari Random Forest

J : jumlah pohon dalam ensemble

$h_j(x)$: output dari pohon ke – (j)

Pembangunan model *Random Forest* dilakukan melalui beberapa tahapan. Tahap awal dilakukan dengan mengambil sejumlah sampel dari dataset menggunakan metode *bootstrap sampling*. Pengambilan sampel dilakukan secara acak dengan pengembalian sehingga diperoleh beberapa subset data yang berbeda. Setiap subset kemudian digunakan untuk membangun satu pohon regresi menggunakan algoritma *decision tree*. Pada saat pembentukan pohon, proses pemisahan *node* (*node splitting*) tidak mempertimbangkan seluruh fitur yang tersedia. Sebagian fitur dipilih secara acak dan fitur yang memberikan pemisahan terbaik dari kumpulan tersebut digunakan untuk membagi *node*. Proses pembentukan pohon dilanjutkan sampai memenuhi kriteria penghentian yang telah ditentukan, misalnya ketika kedalaman maksimum pohon telah tercapai atau jumlah sampel pada suatu *node* berada di bawah batas tertentu. Setelah seluruh pohon terbentuk, model dapat digunakan untuk melakukan prediksi terhadap data baru. Setiap *decision tree* menghasilkan nilai prediksi masing-masing, kemudian seluruh hasil tersebut digabungkan dengan menghitung nilai rata-ratanya. Nilai rata-rata dari seluruh pohon selanjutnya digunakan sebagai hasil prediksi akhir pada permasalahan regresi. Dengan cara tersebut, hasil prediksi tidak hanya bergantung pada satu pohon, tetapi merupakan gabungan dari seluruh pohon yang terdapat dalam model.

Keacakan dalam *Random Forest* berasal dari dua proses utama, yaitu pengacakan sampel dan pengacakan fitur. Pengacakan sampel dilakukan melalui *bootstrap sampling*, yaitu pengambilan sampel secara acak dengan pengembalian dari dataset awal. Hasilnya berupa beberapa subset data yang berbeda sehingga setiap pohon dapat dibangun menggunakan kombinasi sampel yang tidak sepenuhnya sama. Sementara itu, pengacakan fitur dilakukan dengan memilih sebagian fitur secara acak ketika proses *splitting* berlangsung pada setiap pohon. Pemilihan fitur secara acak tersebut membantu mengurangi korelasi antar-*decision tree* dan meningkatkan kemampuan model dalam melakukan generalisasi terhadap data baru. Kombinasi antara pengacakan sampel dan fitur memungkinkan *Random Forest* menghasilkan model yang lebih stabil dalam menghadapi dataset yang kompleks serta berbagai permasalahan regresi. Penerapan pendekatan ini juga dapat digunakan pada dataset deteksi berbasis RED yang terdiri atas tiga jenis informasi, yaitu laju pengambilan sampel (*sampling rate*), sinyal pada domain waktu (*time-domain signals*), dan muatan topologi berkas (*beam topological charge*). Karena setiap jenis data tersebut memiliki karakteristik yang berbeda, diperlukan proses identifikasi terhadap masing-masing fitur secara terpisah agar informasi yang digunakan dalam pemodelan dapat dikenali dengan baik (Song Qiu, 2025).

1.3.6 Extreme Gradient Boosting (XGBoost)

Perkembangan algoritma *boosting* dalam *machine learning* menghasilkan salah satu metode yang dikenal sebagai *Extreme Gradient Boosting* (XGBoost). XGBoost merupakan algoritma *machine learning* berbasis *ensemble* yang menggunakan kerangka kerja *gradient boosting*. Pada metode *gradient boosting*, model dibentuk secara bertahap dengan menggabungkan beberapa pohon keputusan. Setiap pohon yang dibangun berikutnya berfungsi untuk memperbaiki kesalahan atau residual yang dihasilkan oleh model sebelumnya. Proses tersebut dilakukan secara berulang dengan tujuan memperoleh model yang mampu meminimalkan nilai *loss function* sesuai dengan fungsi tujuan (*objective*) yang digunakan.

XGBoost dikembangkan dengan sejumlah optimasi yang membuat proses pemodelan menjadi lebih cepat dan efisien dibandingkan penerapan *gradient boosting* konvensional. Salah satu keunggulannya adalah penggunaan regularisasi L1 dan L2 yang dapat membantu mengurangi risiko *overfitting*. Selain itu, XGBoost mendukung proses *training* secara paralel sehingga waktu komputasi dapat dikurangi dan memiliki kemampuan untuk menangani nilai yang hilang secara otomatis. Karakteristik tersebut membuat XGBoost dapat digunakan untuk berbagai permasalahan prediksi, baik regresi maupun klasifikasi. Penggabungan sejumlah pohon keputusan secara bertahap memungkinkan model memperbaiki kesalahan dari proses sebelumnya sehingga hasil prediksi menjadi lebih stabil. Meskipun memiliki kemampuan prediksi yang baik, kinerja XGBoost masih dapat ditingkatkan melalui pengaturan parameter model. Beberapa parameter yang dapat disesuaikan antara lain jumlah pohon (*n_estimators*), kedalaman maksimum pohon (*max_depth*), *learning rate*, dan tingkat regularisasi (Arunika & Dewi, 2025).

$$\hat{y}_i = \phi(x_i) = \sum_{k=1}^K f_k(x_i), \quad f_k \in F \quad (11)$$

Keterangan (Chen & Guestrin, 2016):

$\hat{y}_i$ = hasil prediksi untuk data ke- i

$\phi(x_i)$ = fungsi prediksi model terhadap input x_i

x_i = data input/prediktor ke- i

$\sum_{k=1}^K$ = penjumlahan dari pohon ke-1 sampai pohon ke- K

$f_k(x_i)$ = fungsi pohon regresi ke- k

$f_k \in F$ = setiap pohon f_k termasuk dalam ruang fungsi pohon regresi.

XGBoost diperkenalkan oleh Chen dan Guestrin (2016) melalui sebuah proyek *open-source* yang dirancang untuk menghasilkan sistem *machine learning* yang efisien, cepat, dan dapat diterapkan pada data dalam skala besar. Metode ini merupakan pengembangan dari *Gradient Boosting Decision Tree* (GBDT) dengan menambahkan fungsi regularisasi dalam proses pembentukan model. Regularisasi tersebut digunakan untuk mengendalikan kompleksitas model sehingga risiko *overfitting* dapat dikurangi sekaligus meningkatkan efisiensi komputasi (Rizky et al., 2022). Selain regularisasi, XGBoost menggunakan beberapa teknik lain untuk meningkatkan kinerja model, seperti pengaturan *subsampling* dan berbagai optimasi pada proses komputasi. Algoritma ini juga menyediakan informasi *feature importance* yang dapat digunakan untuk melihat

tingkat kontribusi masing-masing variabel terhadap hasil prediksi. Kemampuan tersebut memberikan tambahan informasi dalam memahami variabel yang memiliki pengaruh lebih besar terhadap model. Sebagai metode *ensemble* yang dikembangkan dari pendekatan *gradient tree boosting*, XGBoost mampu menangani dataset dalam skala besar serta memodelkan hubungan non-linear antarvariabel dengan tingkat akurasi yang baik (Rahman et al., 2025).

1.3.7 Evaluasi Model Prediksi Enso

Evaluasi model pada data runtun waktu dilakukan untuk mengetahui tingkat kesesuaian antara nilai yang dihasilkan oleh model dengan nilai observasi. Dalam penelitian prediksi ENSO, beberapa metrik yang dapat digunakan untuk menilai kinerja model adalah *Root Mean Square Error* (RMSE), *Pearson Correlation* atau *Anomaly Correlation Coefficient* (ACC), dan *Peirce Skill Score* (PSS). Penggunaan beberapa metrik tersebut dapat memberikan penilaian dari aspek yang berbeda, sehingga kemampuan model dalam menghasilkan prediksi dapat diketahui secara lebih menyeluruh.

Root Mean Square Error (RMSE) merupakan salah satu metrik yang banyak digunakan untuk mengevaluasi kesalahan pada model regresi dan membandingkan kinerja beberapa model. RMSE menunjukkan besarnya rata-rata kesalahan prediksi dengan menghitung akar dari rata-rata kuadrat selisih antara nilai prediksi dan nilai observasi. Karena memiliki satuan yang sama dengan variabel yang diprediksi, nilai RMSE dapat memberikan gambaran langsung mengenai besarnya penyimpangan hasil prediksi terhadap nilai aktual (Suarna & Prihartono, 2025). Dalam evaluasi peramalan, RMSE juga digunakan untuk mengukur perbedaan antara nilai yang dihasilkan oleh suatu model atau *estimator* dengan nilai yang diamati. Perbedaan tersebut disebut sebagai residual apabila dihitung berdasarkan data yang digunakan dalam proses estimasi, sedangkan pada data di luar sampel (*out-of-sample*) perbedaan tersebut disebut sebagai kesalahan prediksi (Kuswanto, 2024). Rumus RMSE sebagai berikut :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (12)$$

di mana (y_i) adalah nilai observasi pada waktu ke-(i), ($\hat{y}_i$) adalah nilai prediksi pada waktu ke-(i), dan (n) adalah jumlah data dalam periode verifikasi.

RMSE dapat digunakan untuk menunjukkan seberapa besar kesalahan yang dihasilkan oleh suatu model prediksi. Nilai RMSE selalu berada pada nilai nol atau lebih dan tidak memiliki batas atas tertentu. Semakin kecil nilai RMSE, semakin rendah kesalahan yang dihasilkan oleh model sehingga kinerja prediksi dapat dikatakan semakin baik (Nurani et al., 2023).

Selain mengukur besarnya kesalahan, evaluasi model juga dapat dilakukan dengan melihat tingkat hubungan linear antara nilai prediksi dan nilai observasi. Korelasi Pearson atau *product moment correlation* merupakan metode statistik yang digunakan untuk mengukur tingkat keeratan hubungan linear antara dua variabel. Analisis ini umumnya digunakan pada data yang memenuhi asumsi distribusi normal (Duwi Priyanto, 2014).

Dalam evaluasi hasil prediksi, nilai korelasi Pearson dapat digunakan untuk mengetahui sejauh mana perubahan pada kedua data memiliki pola hubungan linear yang serupa. Rumus korelasi *product moment* dapat dituliskan sebagai berikut (Sari et al., 2023):

$$r_{xy} = \frac{n \cdot \sum XY - (\sum X) \cdot (\sum Y)}{\sqrt{\{n \cdot \sum X^2 - (\sum X)^2\} \cdot \{n \cdot \sum Y^2 - (\sum Y)^2\}}} \quad (13)$$

dimana r_{xy} adalah nilai koefisien korelasi antara variabel (X) dan variabel (Y), (n) adalah jumlah sampel, $\sum X$ adalah jumlah nilai variabel (X), $\sum Y$ adalah jumlah nilai variabel (Y), $\sum X^2$ adalah jumlah kuadrat nilai variabel (X), $\sum Y^2$ adalah jumlah kuadrat nilai variabel (Y), dan $\sum XY$ adalah jumlah hasil perkalian antara nilai variabel (X) dan variabel (Y).

Nilai koefisien korelasi Pearson, yang dinyatakan dengan r , berada pada rentang -1 hingga 1 . Nilai yang mendekati 1 menunjukkan adanya hubungan linear positif yang kuat antara kedua variabel. Sebaliknya, nilai yang mendekati -1 menunjukkan hubungan linear negatif yang kuat. Apabila nilai mendekati 0 , hubungan linear antara kedua variabel tergolong lemah atau tidak menunjukkan hubungan linear yang berarti (Sari et al., 2023). Dalam konteks evaluasi prediksi ENSO, nilai korelasi yang semakin mendekati 1 menunjukkan bahwa pola perubahan nilai yang diprediksi semakin sesuai dengan pola data observasi.

Peirce Skill Score (PSS), yang juga dikenal sebagai Hanssen–Kuipers discriminant, sebagai ukuran yang memenuhi kebutuhan evaluasi ini. Statistik ini membandingkan jumlah prakiraan yang benar, dikurangi dengan jumlah yang dihasilkan dari tebakan acak, dengan jumlah prakiraan sempurna hipotetis. PSS dapat dihitung sebagai berikut:

$$PSS = \frac{ad - bc}{(b + d)(a + c)} \quad (14)$$

di mana (a) adalah jumlah kejadian *hit* (prediksi ya dan observasi ya), (b) adalah jumlah *false alarm* (prediksi ya tetapi observasi tidak), (c) adalah jumlah *miss* (prediksi tidak tetapi observasi ya), dan (d) adalah jumlah *correct rejection* (prediksi tidak dan observasi tidak).

PSS memperhitungkan dua jenis kesalahan dalam prediksi, yaitu *omission error* dan *commission error*, serta memperhitungkan keberhasilan yang mungkin diperoleh akibat tebakan acak. Nilai PSS berada pada rentang -1 hingga 1 . Nilai 1 menunjukkan kesesuaian atau keterampilan prediksi yang sempurna, sedangkan nilai 0 menunjukkan bahwa kemampuan prediksi tidak lebih baik dibandingkan tebakan acak. Nilai negatif menunjukkan bahwa kinerja model lebih buruk dibandingkan acuan tersebut. Salah satu karakteristik PSS adalah nilainya tidak dipengaruhi oleh prevalensi kejadian. Selain itu, ukuran *validation set* tidak secara langsung memengaruhi nilai PSS, sehingga dua metode dengan tingkat kinerja yang sama dapat menghasilkan nilai PSS yang sama. PSS merupakan kasus khusus ketika proporsi kejadian (*presence*) dan ketidakterjadian (*absence*) dalam *validation set* berada pada kondisi yang sama (Allouche et al., 2006).

BAB II METODE PENELITIAN

2.1 Data Penelitian

Penelitian ini menggunakan data indeks ENSO bulanan yang direpresentasikan oleh indeks Nino 3.4 dan Southern Oscillation Index (SOI). Data Nino 3.4 dan SOI diperoleh dari *National Oceanic and Atmospheric Administration* (NOAA) melalui NOAA *Physical Sciences Laboratory*. Indeks Nino 3.4 merupakan anomali suhu permukaan laut (*Sea Surface Temperature/SST*) pada wilayah 5°LU–5°LS dan 170°BB–120°BB di Samudra Pasifik ekuatorial yang digunakan untuk mengidentifikasi kejadian El Nino dan La Nina. Sementara itu, SOI merupakan indeks atmosfer yang dihitung berdasarkan perbedaan tekanan udara yang telah dinormalisasi antara Tahiti dan Darwin.

Data yang digunakan merupakan data runtun waktu dengan resolusi temporal bulanan pada periode 1870–2025. Struktur data terdiri atas kolom waktu, nilai indeks Nino 3.4, dan nilai SOI. Dalam penelitian ini, nilai Nino 3.4 pada periode yang akan diprediksi ditetapkan sebagai variabel target, sedangkan nilai historis Nino 3.4 dan SOI digunakan sebagai variabel prediktor. Penggunaan nilai historis Nino 3.4 sebagai prediktor didasarkan pada karakteristik data ENSO sebagai data runtun waktu, di mana kondisi pada periode sebelumnya memiliki keterkaitan dengan kondisi pada periode berikutnya. Selanjutnya, data disusun dalam format runtun waktu untuk membangun model prediksi ENSO pada lead time 1 hingga 12 bulan.

2.2 Prosedur Penelitian

Prosedur penelitian disusun secara sistematis agar setiap tahapan dapat direplikasi dan diverifikasi secara ilmiah. Secara umum, penelitian ini meliputi tahapan pengumpulan data, pra-pemrosesan data, pembagian data, pemodelan prediksi, evaluasi model, serta analisis perbandingan kinerja model.

2.2.1 Pengumpulan Data

Data yang digunakan dalam penelitian ini terdiri atas indeks Niño 3.4 dan *Southern Oscillation Index* (SOI) yang diperoleh dari sumber data iklim resmi. Data tersebut disusun dalam bentuk runtun waktu (*time series*) dengan resolusi temporal bulanan, sehingga setiap observasi merepresentasikan kondisi iklim pada satu periode bulan tertentu. Struktur data memuat informasi waktu, nilai indeks Nino 3.4, dan nilai SOI. Pemilihan indeks Nino 3.4 dan SOI didasarkan pada peran keduanya dalam merepresentasikan dinamika ENSO. Indeks Nino 3.4 menggambarkan kondisi laut melalui anomali suhu permukaan laut di wilayah Pasifik ekuatorial, sedangkan SOI menggambarkan kondisi atmosfer melalui variasi tekanan udara yang berkaitan dengan sirkulasi atmosfer tropis. Dengan demikian, penggunaan kedua variabel tersebut diharapkan dapat merepresentasikan interaksi laut-atmosfer yang menjadi karakteristik utama fenomena ENSO.

2.2.2 Pra-Pemrosesan Data

Tahap ini mencakup pemeriksaan konsistensi data, penanganan data yang hilang (*missing value*), penerapan metode *3-month running mean*, standardisasi data, serta pembentukan variabel *lag* untuk pemodelan prediksi runtun waktu. Penelitian ini

menggunakan *lag* sepanjang 44 bulan, sehingga setiap sampel prediksi dibentuk berdasarkan data historis indeks Nino 3.4 dan SOI selama 44 bulan sebelumnya sebagai variabel masukan. Adapun nilai indeks Nino 3.4 pada *lead time* 1–12 bulan ditetapkan sebagai variabel target yang akan diprediksi.

2.2.3 Pembagian Data

Pembagian dataset dilakukan secara kronologis tanpa pengacakan untuk mempertahankan struktur temporal data runtun waktu. Data periode Januari 1873 hingga Desember 2009 digunakan sebagai data pelatihan (*training set*), sedangkan data periode Januari 2010 hingga Juli 2025 digunakan sebagai data pengujian (*testing set*). Pendekatan ini diterapkan untuk mensimulasikan kondisi prediksi ke depan atau out-of-sample *forecasting*, sehingga model diuji menggunakan data yang benar-benar berada di luar periode pelatihan. Pemisahan data secara kronologis juga bertujuan untuk mengevaluasi kemampuan generalisasi model terhadap data baru dan meminimalkan potensi *overfitting*. Dengan menggunakan pembagian tersebut, model dilatih berdasarkan pola historis sebelum tahun 2010, kemudian diuji pada periode setelahnya untuk menilai kinerja prediksi pada data yang belum pernah digunakan dalam proses pelatihan.

2.2.4 Pemodelan Prediksi

Pemodelan dilakukan menggunakan beberapa pendekatan, yaitu *Multiple Linear Regression* (MLR) sebagai model statistik linear, *Random Forest* dan XGBoost sebagai model *ensemble machine learning*, serta *Long Short-Term Memory* (LSTM) sebagai model deep learning untuk data *time series*. Dalam penelitian ini, indeks Niño 3.4 merupakan data *time series* bulanan yang tersusun berurutan dan saling berkaitan antar waktu, sehingga digunakan variabel lag dan penyusunan sekuens data agar model dapat menangkap pola perubahan ENSO dan melakukan prediksi untuk *lead time* 1–12 bulan ke depan.

2.2.5 Evaluasi dan Verifikasi Model

Kinerja model dievaluasi dengan membandingkan hasil prediksi terhadap data observasi menggunakan indikator statistik, yaitu *Root Mean Square Error* (RMSE), *Pearson Correlation* (r), dan *Peirce Skill Score* (PSS).

2.3 Prosedur Model Prediksi

Prediksi ENSO dilakukan menggunakan model MLR, LSTM, *Random Forest*, dan XGBoost. Seluruh model menggunakan Nino 3.4 dan SOI sebagai prediktor, sedangkan Niño 3.4 pada periode berikutnya sebagai target. Data masukan dibentuk dari 44 lag Niño 3.4 dan 44 lag SOI, dengan *lead time* 1 hingga 12 bulan.

2.3.1 Penerapan *Multiple Linear Regression* (MLR)

Multiple Linear Regression (MLR) merupakan pendekatan statistik yang digunakan untuk menggambarkan hubungan linear antarvariabel dalam proses prediksi. Pelatihan model dilakukan dengan menentukan koefisien regresi melalui metode *Ordinary Least Squares* (OLS). Metode tersebut digunakan untuk membentuk persamaan regresi dengan meminimalkan jumlah kuadrat perbedaan antara nilai hasil prediksi dan nilai observasi. Proses pelatihan dilaksanakan secara terpisah pada setiap *lead time*, sehingga masing-

masing periode prediksi menghasilkan persamaan regresi yang berbeda. Model yang telah dilatih kemudian diterapkan pada data pengujian, dan hasil prediksinya digunakan untuk mengevaluasi kinerja model.

2.3.2 Penerapan *Long Short-Term Memory* (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari *Recurrent Neural Network* (RNN) yang dirancang untuk mempelajari pola temporal dan keterkaitan jangka panjang pada data runtun waktu. Arsitektur jaringan terdiri atas satu *sequence input layer* dengan dua fitur masukan, satu lapisan LSTM dengan 10 unit tersembunyi (*hidden units*) dan pengaturan *OutputMode* = 'last', satu lapisan *fully connected* dengan satu neuron keluaran, serta satu lapisan regresi. Proses pelatihan dilakukan menggunakan algoritma optimasi Adam dengan *MaxEpochs* = 30, *MiniBatchSize* = 16, *InitialLearnRate* = 0,001, dan *GradientThreshold* = 1. Data pelatihan diacak pada setiap *epoch* melalui pengaturan *Shuffle* = 'every-epoch', sedangkan tampilan proses pelatihan dinonaktifkan melalui *Verbose* = false dan *Plots* = 'none'. Pelatihan dilakukan secara terpisah untuk setiap *lead time* 1–12 bulan sehingga diperoleh model yang berbeda untuk masing-masing periode prediksi. Pada tahap pengujian, prediksi dilakukan menggunakan *MiniBatchSize* = 1. Model yang telah dilatih kemudian diterapkan pada data pengujian, dan hasil prediksinya digunakan untuk mengevaluasi kinerja model.

2.3.3 Penerapan *Random Forest*

Random Forest merupakan metode pembelajaran mesin berbasis *ensemble learning* yang menggabungkan sejumlah pohon regresi untuk meningkatkan kestabilan dan kemampuan prediksi model. *Hyperparameter* yang digunakan meliputi *numTrees* = 300, *minLeafSize* = 3, dan *bagFraction* = 0,8. Jumlah prediktor yang dipertimbangkan pada setiap pemisahan ditetapkan sebesar sepertiga dari jumlah seluruh prediktor melalui pengaturan *NumPredictorsToSample*. Proses pelatihan dilakukan dengan membangun 300 pohon regresi menggunakan sekitar 80% sampel data pelatihan yang dipilih secara acak untuk setiap pohon. Setiap daun pada pohon sekurang-kurangnya memuat tiga observasi. Hasil prediksi akhir diperoleh dengan menghitung rata-rata keluaran seluruh pohon yang terbentuk. Selain itu, fitur *out-of-bag prediction* diaktifkan untuk mengamati kesalahan model pada data yang tidak digunakan dalam pembentukan setiap pohon. Pelatihan dilakukan secara terpisah untuk setiap *lead time*, sehingga diperoleh model yang berbeda untuk masing-masing periode prediksi. Model yang telah dilatih kemudian diterapkan pada data pengujian, dan hasil prediksinya digunakan untuk mengevaluasi kinerja model.

2.3.4 Penerapan *Extreme Gradient Boosting* (XGBoost)

Extreme Gradient Boosting (XGBoost) merupakan salah satu metode pembelajaran mesin berbasis *gradient boosting* yang menggunakan sekumpulan pohon keputusan untuk meningkatkan ketepatan hasil prediksi. *Hyperparameter* yang diterapkan dalam model ini terdiri atas *nTrees* = 300, *learnRate* = 0,03, *minLeafSize* = 5, dan *maxNumSplits* = 20. Proses pelatihan model dilakukan secara bertahap dengan membangun pohon keputusan berdasarkan data pelatihan. Pada setiap tahap, model berupaya mengoreksi kesalahan prediksi yang masih dihasilkan oleh tahap sebelumnya, sehingga kinerja prediksi dapat meningkat secara bertahap. Pelatihan dilakukan secara terpisah untuk

setiap *lead time*, sehingga diperoleh model yang berbeda untuk masing-masing periode prediksi. Model yang telah dilatih kemudian diterapkan pada data pengujian, dan hasil prediksinya digunakan untuk mengevaluasi kinerja model.

2.4 Evaluasi dan Verifikasi Model

Evaluasi model dilakukan untuk mengukur tingkat kesalahan prediksi, hubungan statistik, serta kesesuaian pola temporal antara hasil prediksi dan data observasi. Proses evaluasi tidak hanya menilai tingkat akurasi secara numerik, tetapi juga memperhatikan kesesuaian pola runtun waktu (*time series*) yang dihasilkan oleh masing-masing model. Indikator evaluasi yang digunakan dalam penelitian ini meliputi sebagai berikut.

2.4.1 Root Mean Square Error (RMSE)

Root Mean Square Error (RMSE) digunakan untuk mengukur rata-rata besarnya kesalahan antara nilai prediksi dan nilai observasi. RMSE dihitung berdasarkan akar dari rata-rata kuadrat selisih antara nilai prediksi dan observasi. Nilai RMSE yang lebih kecil menunjukkan bahwa model memiliki kemampuan yang lebih baik dalam meminimalkan kesalahan prediksi.


2.4.2 Pearson Correlation (r)

Pearson Correlation (r) digunakan untuk mengukur kekuatan dan arah hubungan antara hasil prediksi dan data observasi. Nilai (r) berada pada rentang -1 hingga 1 . Nilai yang mendekati 1 menunjukkan hubungan positif yang sangat kuat, nilai yang mendekati 0 menunjukkan hubungan yang lemah, sedangkan nilai yang mendekati -1 menunjukkan hubungan negatif yang sangat kuat. Dalam evaluasi model prediksi, nilai (r) yang semakin mendekati 1 menunjukkan bahwa pola perubahan hasil prediksi semakin sesuai dengan pola perubahan data observasi.

2.4.3 Peirce Skill Score (PSS)

Peirce Skill Score (PSS) digunakan untuk menilai kemampuan model dalam membedakan kejadian yang sesuai dan tidak sesuai berdasarkan kategori nilai yang telah ditentukan. Nilai PSS berada pada rentang -1 hingga 1 . Nilai yang mendekati 1 menunjukkan kemampuan prediksi yang sangat baik, nilai mendekati 0 menunjukkan kemampuan prediksi yang rendah, sedangkan nilai negatif menunjukkan bahwa hasil prediksi tidak sesuai dengan data observasi.

2.5 Bagan Alir




Gambar 3. Bagan Alir


BAB III HASIL DAN PEMBAHASAN

3.1 Hasil


Hasil ini menampilkan perbandingan antara data observasi dan hasil prediksi model indeks Nino 3.4 dalam bentuk deret waktu (*time series*) pada periode pengujian. Visualisasi ini digunakan untuk melihat kesesuaian pola antara nilai prediksi dan data observasi serta kemampuan model dalam mengikuti dinamika perubahan indeks ENSO dari waktu ke waktu.




(a)



(b)




(c)




(d)

Gambar 4. Time Series dari model (a) *Multiple Linear Regression*, (b) *Long Short-Term Memory*, (c) *Random Forest*, dan (d) *Extreme Gradient Boosting*


Untuk menilai kinerja model prediksi ENSO secara kuantitatif, digunakan beberapa metrik evaluasi yaitu *Pearson Correlation*, *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS). Hasil evaluasi kinerja model pada berbagai *lead time* ditampilkan pada Gambar sebagai berikut.




(a)



(b)




(c)



(d)

Gambar 5. Evaluasi RMSE, *Pearson Correlation* dan PSS dari model (a) *Multiple Linear Regression*, (b) *Long Short-Term Memory*, (c) *Random Forest*, dan (d) *Extreme Gradient Boosting*

Perbandingan kinerja model prediksi ENSO dilakukan menggunakan tiga indikator evaluasi, yaitu *Pearson Correlation*, *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS). Ketiga indikator tersebut digunakan untuk melihat tingkat kesesuaian pola prediksi, besarnya kesalahan, serta kemampuan model dalam mengidentifikasi kejadian ENSO pada *lead time* 1–12 bulan. Hasil perbandingan kinerja model MLR, LSTM, *Random Forest*, dan XGBoost disajikan pada Gambar berikut.



Gambar 6. Perbandingan Kinerja Semua Model Prediksi ENSO

Untuk mengevaluasi kinerja model prediksi ENSO, digunakan beberapa metrik evaluasi yaitu *Pearson Correlation* (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS). Nilai dari masing-masing metrik pada berbagai *lead time* ditampilkan pada Tabel 1 hingga Tabel 3.

Tabel 1. *Pearson Correlation* model MLR, LSTM, RF, dan XGBoost

Lead	MLR (r)	LSTM (r)	RF (r)	XGB (r)
1	0.99563	0.99198	0.97016	0.98469
2	0.97533	0.96374	0.91141	0.93686
3	0.92358	0.89027	0.81716	0.83678
4	0.85691	0.73696	0.70508	0.73656
5	0.77903	0.54395	0.59264	0.62949
6	0.68898	0.55272	0.49647	0.52594
7	0.59776	0.24854	0.42398	0.43482
8	0.50916	0.14090	0.40352	0.33910
9	0.43236	0.052269	0.36937	0.30197
10	0.36951	0.24304	0.38822	0.26665
11	0.32993	0.11547	0.38473	0.26975
12	0.32058	0.10982	0.36183	0.27046

Tabel 2. RMSE Model MLR, LSTM, RF, dan XGBoost

<i>Lead</i>	MLR (RMSE)	LSTM (RMSE)	RF (RMSE)	XGB (RMSE)
1	0.079855	0.11474	0.22481	0.15458
2	0.18808	0.24346	0.37161	0.30573
3	0.32582	0.41199	0.50840	0.48251
4	0.43726	0.58864	0.61316	0.58653
5	0.53251	0.71387	0.69025	0.67061
6	0.61689	0.71428	0.74297	0.73185
7	0.68324	0.86939	0.77603	0.77346
8	0.73277	0.96609	0.78411	0.80842
9	0.76488	0.94957	0.79553	0.81852
10	0.78331	0.94894	0.78805	0.82581
11	0.78996	1.00080	0.78726	0.81907
12	0.78678	1.00380	0.78898	0.81467

Tabel 3. PSS Model MLR, LSTM, RF, dan XGBoost

<i>Lead</i>	MLR (PSS)	LSTM (PSS)	RF (PSS)	XGB (PSS)
1	0.95911	0.94706	0.92296	0.93501
2	0.90314	0.84217	0.84733	0.86398
3	0.80781	0.77493	0.74881	0.69943
4	0.71538	0.66923	0.63365	0.60865
5	0.64009	0.49635	0.53530	0.38900
6	0.61005	0.48089	0.46319	0.41932
7	0.52135	0.30814	0.38086	0.34698
8	0.49655	0.11793	0.35293	0.25605
9	0.37354	0.031013	0.34962	0.20633
10	0.36798	0.31748	0.18796	0.16520
11	0.28597	0.18884	0.24141	0.12219
12	0.31097	0.23881	0.16090	0.14824

3.2 Pembahasan

Hasil pengujian menunjukkan bahwa kemampuan MLR, LSTM, Random Forest, dan XGBoost dalam memprediksi indeks Nino 3.4 menurun seiring bertambahnya *lead time*. Penurunan tersebut ditunjukkan oleh nilai *Pearson Correlation* (r) dan PSS yang cenderung menurun, disertai peningkatan RMSE. Hal ini menunjukkan bahwa kondisi ENSO pada horizon pendek masih memiliki keterkaitan kuat dengan keadaan laut dan atmosfer sebelumnya, sedangkan ketidakpastian prediksi meningkat pada horizon yang lebih panjang. Pola penurunan yang terjadi pada keempat model menunjukkan bahwa bertambahnya horizon prediksi menjadi faktor yang membatasi kemampuan model, terlepas dari perbedaan pendekatan yang digunakan.

Pada *lead time* satu bulan, seluruh model menunjukkan kinerja yang baik. MLR menghasilkan nilai (r) sebesar 0,99563, PSS sebesar 0,95911, dan RMSE sebesar 0,079855. LSTM memperoleh nilai (r) sebesar 0,99198, PSS sebesar 0,94706, dan RMSE sebesar 0,11474. XGBoost menghasilkan nilai (r) sebesar 0,98469, PSS sebesar 0,93501, dan RMSE sebesar 0,15458, sedangkan *Random Forest* memperoleh nilai (r) sebesar 0,97016, PSS sebesar 0,92296, dan RMSE sebesar 0,22481. Hasil tersebut menunjukkan bahwa keempat model mampu mengikuti perubahan Nino 3.4 pada horizon pendek, meskipun tingkat ketepatannya berbeda. Nilai PSS yang tinggi menunjukkan bahwa seluruh model mampu membedakan nilai Nino 3.4 positif dan negatif dengan baik pada periode prediksi satu bulan.

Hasil prediksi yang baik pada *lead time* pendek terjadi karena kondisi ENSO cenderung bertahan selama beberapa bulan. Pada fase El Nino, peningkatan suhu permukaan laut di Pasifik tengah dan timur diikuti oleh pelemahan angin pasat dan berkurangnya *upwelling* air dingin. Pada fase La Nina, angin pasat menguat, *upwelling* meningkat, dan suhu permukaan laut menurun. Hubungan antara suhu permukaan laut, tekanan udara, dan angin tersebut menyebabkan nilai historis Nino 3.4 dan SOI masih memiliki informasi prediktif yang kuat pada beberapa bulan pertama.

Pada *lead time* pendek hingga menengah, MLR menunjukkan hasil yang paling konsisten berdasarkan nilai (r), RMSE, dan PSS. Hasil ini menunjukkan bahwa hubungan antara Nino 3.4 dan SOI masih dapat dipelajari dengan baik ketika pengaruh kondisi awal masih kuat. Penerapan rata-rata bergerak tiga bulan juga membantu mengurangi fluktuasi bulanan, sehingga pola ENSO yang lebih persisten menjadi lebih jelas. LSTM juga memberikan hasil yang baik pada *lead time* pendek, tetapi kinerjanya menurun lebih cepat pada horizon panjang. Pada *lead time* tujuh hingga sembilan bulan, nilai (r) LSTM turun menjadi 0,24854, 0,14090, dan 0,052269. Pada *lead time* dua belas bulan, RMSE LSTM mencapai 1,00380 dan menjadi yang terbesar dibandingkan model lain. Hasil ini menunjukkan bahwa kemampuan LSTM dalam mempelajari keterkaitan temporal belum cukup untuk mempertahankan ketepatan prediksi ketika pengaruh kondisi awal semakin melemah. Penurunan nilai (r) yang disertai peningkatan RMSE menunjukkan bahwa hasil prediksi LSTM semakin berbeda, baik dari arah perubahan maupun besarnya nilai observasi.

Random Forest dan XGBoost mampu mempelajari hubungan non-linear dari nilai historis Nino 3.4 dan SOI. Pada *lead time* satu bulan, XGBoost menunjukkan kinerja yang lebih baik daripada *Random Forest* karena menghasilkan nilai (r) dan PSS yang lebih tinggi serta RMSE yang lebih rendah. Pada *lead time* 10–12 bulan, *Random Forest* memiliki nilai (r) yang sedikit lebih tinggi, tetapi nilai RMSE dan PSS tidak menunjukkan keunggulan yang sama secara konsisten. Hal ini menunjukkan bahwa *Random Forest* dan XGBoost masih mampu mengikuti sebagian pola perubahan Nino 3.4, tetapi keduanya belum cukup baik dalam mempertahankan ketepatan prediksi pada horizon panjang. Keterbatasan tersebut dapat terjadi karena model hanya menggunakan Niño 3.4 dan SOI, sedangkan perkembangan ENSO juga dipengaruhi oleh kondisi laut bawah permukaan, perubahan termoklin, dan gangguan angin.

Penurunan kinerja seluruh model pada *lead time* panjang berkaitan dengan semakin kompleksnya dinamika ENSO. Selain suhu permukaan laut dan tekanan atmosfer, perkembangan ENSO juga dipengaruhi oleh kandungan panas laut bawah permukaan, kedalaman termoklin, perambatan gelombang ekuatorial, dan gangguan angin. Variabel-variabel tersebut tidak dimasukkan secara langsung ke dalam model, sehingga Niño 3.4 dan SOI belum mampu mewakili seluruh proses pertumbuhan, fase matang, dan pelemahan ENSO.

Hasil penelitian menunjukkan bahwa setiap model memiliki kemampuan yang berbeda. MLR lebih konsisten pada sebagian besar *lead time*, LSTM cukup baik pada horizon pendek tetapi menurun pada horizon panjang, sedangkan *Random Forest* dan XGBoost mampu mengenali pola non-linear namun belum memberikan hasil terbaik secara menyeluruh. Oleh karena itu, penentuan model terbaik perlu mempertimbangkan nilai (r), RMSE, dan PSS secara bersama. Untuk meningkatkan prediksi jangka panjang, diperlukan penambahan variabel fisik yang dapat menggambarkan dinamika laut-atmosfer ENSO secara lebih lengkap.

BAB IV KESIMPULAN

4.1 Kesimpulan

Adapun kesimpulan dari penelitian ini adalah:

1. Model *Multiple Linear Regression* (MLR), *Long Short-Term Memory* (LSTM), *Random Forest*, dan *Extreme Gradient Boosting* (XGBoost) telah diterapkan untuk memprediksi indeks Nino 3.4 pada *lead time* 1 hingga 12 bulan dengan menggunakan nilai historis Nino 3.4 dan *Southern Oscillation Index* (SOI) sebagai prediktor. Keempat model mampu mengikuti perubahan indeks Niño 3.4 dengan baik pada *lead time* pendek. Kemampuan prediksi seluruh model menurun ketika *lead time* bertambah, yang ditunjukkan oleh kecenderungan penurunan nilai korelasi Pearson dan PSS serta peningkatan nilai RMSE.
2. Hasil evaluasi menunjukkan bahwa MLR memiliki kinerja paling konsisten pada sebagian besar *lead time* berdasarkan nilai *Pearson Correlation*, RMSE, dan PSS. LSTM memberikan hasil yang baik pada *lead time* pendek, tetapi mengalami penurunan yang lebih besar pada horizon panjang. XGBoost menunjukkan kinerja yang lebih baik daripada Random Forest pada *lead time* satu bulan, sedangkan *Random Forest* memiliki nilai korelasi yang sedikit lebih tinggi pada *lead time* 10 hingga 12 bulan. Namun, keunggulan *Random Forest* pada nilai korelasi tidak diikuti secara konsisten oleh nilai RMSE dan PSS. Berdasarkan ketiga metrik evaluasi secara bersama, MLR merupakan model dengan kinerja terbaik dalam penelitian ini.

Secara umum, hasil penelitian menunjukkan bahwa nilai historis Nino 3.4 dan SOI masih memberikan informasi yang kuat untuk prediksi ENSO jangka pendek hingga menengah. Pada *lead time* panjang, kemampuan seluruh model masih terbatas karena kedua prediktor tersebut belum mewakili seluruh proses laut-atmosfer yang memengaruhi perkembangan ENSO.

4.2 Saran

Penelitian selanjutnya disarankan menggunakan beberapa periode data pengujian yang berbeda untuk menilai konsistensi dan kemampuan generalisasi model MLR, LSTM, *Random Forest*, dan XGBoost dalam memprediksi ENSO. Pengujian pada periode yang mencakup kejadian El Nino dan La Nina dengan intensitas yang berbeda diperlukan untuk mengetahui apakah kinerja model tetap stabil pada berbagai kondisi ENSO.

DAFTAR PUSTAKA

- Abdullah, S. E. A. N. A. (2021). Analisis hubungan indeks nino 3.4 dengan curah hujan di Jawa Tengah. *Buletin Meteorologi, Klimatologi dan Geofisika*, 2(1), 24-30.
- Allouche, O., Tsoar, A., & Kadmon, R. (2006). Assessing the accuracy of species distribution models: prevalence, kappa and the true skill statistic (TSS). *Journal of applied ecology*, 43(6), 1223-1232.
- Aprilia, B., Marzuki, M., & Taufiq, I. (2020). Prediksi El Nino Southern Oscillation (ENSO) Menggunakan Jaringan Saraf Tiruan (JST)-Backpropagation. *Jurnal Fisika Unand*, 9(4), 421-427.
- Ariska, M., Akhsan, H., Muslim, M., Romadoni, M., & Putriyani, F. S. (2022). Prediksi perubahan iklim ekstrem di kota Palembang dan kaitannya dengan fenomena el niño-southern oscillation (enso) berbasis machine learning. *JIPFRI (Jurnal Inovasi Pendidikan Fisika dan Riset Ilmiah)*, 6(2), 79-86.
- Ashari, M. L., & Sadikin, M. (2020). Prediksi data transaksi penjualan time series menggunakan regresi lstm. *Jurnal Nasional Pendidikan Teknik Informatika: JANAPATI*, 9(1), 1-10.
- Cozmuta, L. M. (2025). The application of multiple linear regression methods to FTIR spectra of fingernails for predicting gender and age of human subjects. *Heliyon*, 11(4).
- Chen, T., & Guestrin, C. (2016, August). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (pp. 785-794).
- Duwi priyatno (2014). Analisis Korelasi, Regresi dan Multivariate dengan SPSS, Jakarta, Andi Publishe
- Fatmawaty, F. (2024). Deep learning: Sebuah pendekatan untuk pembelajaran bermakna. *Harmoni Pendidikan: Jurnal Ilmu Pendidikan*, 1(1), 71-85.
- Hidayat, U., Prasetyo, S., Haryanto, Y. D., & Riama, N. F. (2021). Pengaruh ENSO terhadap curah hujan dan kelembapan relatif serta suhu permukaan laut di Sulawesi. *Buletin GAW Bariri (BGB)*, 2(2), 88-96.
- Kuswanto, A. D., Amanda, A. P., Priscilla, Y., Magdalena, M., Safira, A. P., & Maulida, I. (2024). Penerapan Algoritma Linear Regression Dalam Memprediksi Harga Saham Bank BRI. *Switch: Jurnal Sains dan Teknologi Informasi*, 2(4), 88-102.
- Manurung, D., Zealtiel, B., & Lubis, A. H. (2025). Prediksi Produksi Tanaman Padi di Indonesia dengan Menggunakan Algoritma Random Forest Regressor. *Journal of Computing and Informatics Research*, 4(3), 337-345.
- National Oceanic and Atmospheric Administration. (2025). *El Niño & La Niña (El Niño-Southern Oscillation)*. Climate.gov. <https://www.climate.gov/enso>
- Nobre, G. G., Muis, S., Veldkamp, T. I., & Ward, P. J. (2019). Achieving the reduction of disaster risk by better predicting impacts of El Niño and La Niña. *Progress in Disaster Science*, 2, 100022.
- Nurani, A. T., Setiawan, A., & Susanto, B. (2023). Perbandingan kinerja regresi decision tree dan regresi linear berganda untuk prediksi BMI pada dataset asthma. *Jurnal Sains dan Edukasi Sains*, 6(1), 34-43.

- Nurhalizah, R. S., Ardianto, R., & Purwono, P. (2024). Analisis supervised dan unsupervised learning pada machine learning: Systematic literature review. *Jurnal Ilmu Komputer dan Informatika*, 4(1), 61-72.
- Rahman, A., Yusnita, A., & Ekawati, H. (2025). Penerapan Algoritma XGBoost Dalam Prediksi Harga Sewa Kos Di Kota Samarinda. *Bulletin of Information Technology (BIT)*, 6(4), 379-390.
- Raup, A., Ridwan, W., Khoeriyah, Y., Supiana, S., & Zaqiah, Q. Y. (2022). Deep learning dan penerapannya dalam pembelajaran. *JlIP-Jurnal Ilmiah Ilmu Pendidikan*, 5(9), 3258-3267.
- Rizky, P. S., Hirzi, R. H., & Hidayaturohman, U. (2022). Perbandingan metode LightGBM dan XGBoost dalam menangani data dengan kelas tidak seimbang. *J Statistika: Jurnal Ilmiah Teori dan Aplikasi Statistika*, 15(2), 228-236.
- Roihan, A., Sunarya, P. A., & Rafika, A. S. (2020). Pemanfaatan machine learning dalam berbagai bidang. *Jurnal Khatulistiwa Informatika*, 5(1), 490845.
- Samine, S., Karouchi, M., Zemzami, M., Hmina, N., Lagache, M., & Belhouideg, S. (2026). Deep Learning and Multiple Linear Regression for Predicting Mechanical Properties from Elastic Constants: Application to Aluminum-Based Alloys Used in 3D Printing. *Results in Engineering*, 109602.
- Santiani, S. (2025). Analisis literatur: Pendekatan pembelajaran deep learning dalam pendidikan. *Jurnal Ilmiah Nusantara*, 2(3), 50-57.
- Sahroni, M., Arif, M. F., & Misdram, M. (2024). Stock Price Prediction Using The Long Short-Term Memory Method. *Jurnal Teknik Informatika (Jutif)*, 5(6), 1769-1777.
- Suarna, N., & Prihartono, W. (2025). Algoritma regresi linier sederhana untuk prediksi penggunaan volume air berdasarkan jenis pelanggan pdam. *Jurnal Kecerdasan Buatan dan Teknologi Informasi*, 4(1), 43-52.
- Suhadi, S., Mabruroh, F., Wiyanto, A., & Ikra, I. (2023). Analisis fenomena perubahan iklim terhadap curah hujan ekstrim. *OPTIKA: Jurnal Pendidikan Fisika*, 7(1), 94-100.
- Supriyadi, E. (2021). Prediksi Parameter Cuaca Menggunakan Deep Learning Long-Short Term Memory (Lstm). *Jurnal Meteorologi dan Geofisika*, 21(2), 55-67.
- Surmaini, E., & Faqih, A. (2016). Kejadian iklim ekstrem dan dampaknya terhadap pertanian tanaman pangan di Indonesia. *Jurnal Sumberdaya Lahan*, 10(2).
- Sarica, A., Camastra, C., Pelagi, A., Arcuri, F., Novellino, F., Quattrone, A., & Quattrone, A. (2025). The ICeX framework: Brain age estimation from thalamic nuclei with conformalized and eXplainable random forest regression. *Computer Methods and Programs in Biomedicine*, 109140.
- Sari, F. M., Hadiati, R. N., & Sihotang, W. (2023). Analisis korelasi pearson jumlah penduduk dengan jumlah kendaraan bermotor di provinsi Jambi. *Multi Proximity: Jurnal Statistika*, 2(1), 39-44.
- Sari, P. K., & Suryono, R. R. (2024). Komparasi algoritma Support Vector Machine dan Random Forest untuk analisis sentimen metaverse. *Jurnal Mnemonic*, 7(1), 31-39.
- Ullum, I. T. N. H., Fitria, A., & Widodo, W. (2024). Variasi Hasil Analisis Data Hasil El Nino-Southern Oscillation (ENSO) terhadap Iklim Global. *Jurnal Sains Natural*, 2(2), 40-47.

- Wiguna, D. P. (2025). Pemodelan Prediksi Mahasiswa Berprestasi Akademik Dengan Multi-Linear Regression (Studi Kasus: Prodi Sistem Informasi). *Complex: Jurnal Multidisiplin Ilmu Nasional*, 2(1), 53-58.
- Yeh, S. W., Cai, W., Min, S. K., McPhaden, M. J., Dommenges, D., Dewitte, B., ... & Kug, J. S. (2018). ENSO atmospheric teleconnections and their response to greenhouse gas forcing. *Reviews of Geophysics*, 56(1), 185-206.
- Zahra, F. S. A., Sumargo, B., Siregar, D., & Fathya, A. Y. (2024). The application of the artificial neural network (ANN) method for forecasting the Southern Oscillation Index (SOI). *Jurnal Statistika dan Aplikasinya*, 8(2), 179–192.

LAMPIRAN

Lampiran 1. Data Indeks ENSO NINO 3.4 dan SOI

Date	NINO 3.4	SOI
1873-01-0	-0.78	2.47
1873-02-0	-1.01	1.12
1873-03-0	-1.31	1.63
1873-04-0	-0.67	2.29
1873-05-0	-0.53	1.19
1873-06-0	-0.48	-3.09
1873-07-0	-0.58	-1.14
1873-08-0	-0.39	-0.59
1873-09-0	-0.34	-2.13
1873-10-0	-0.78	-1.78
1873-11-0	-0.77	-0.36
1873-12-0	-0.7	1.33
1874-01-0	-0.93	0.9
1874-02-0	-1.06	-0.28
1874-03-0	-1.4	-0.52
1874-04-0	-0.94	0.98
1874-05-0	-0.86	1.29
1874-06-0	-0.72	-1.92
1874-07-0	-1	-0.14
1874-08-0	-1.05	0.75
1874-09-0	-1.13	2.03

Lampiran 2. Program matlab *Time Series*

Program Matlab *Time Series Multiple Linear Regression*

```
%% =====
% ENSO PREDICTION
% MULTIPLE LINEAR REGRESSION MODEL
% Predictor : NINO 3.4 + SOI
% Target   : NINO 3.4
% Lead     : 1, 4, 7, 11 Months
% Lag      : 44 Months
% =====

clear; close all; clc;

%% ----- PARAMETERS -----
filename = 'DataKeseluruhan.csv';
p       = 44;
splitYr = 2010;
leads   = [1 4 7 11];

%% ----- READ DATA -----
T = readtable(filename);
time_d = datetime(T{:,1},'InputFormat','yyyy-MM-dd');
nino   = T{:,2};
soi    = T{:,3};
TT = timetable(time_d,nino,soi);
TTm = retime(TT,'monthly','mean');
time = TTm.time_d;
nino = TTm.nino;
soi = TTm.soi;

%% ----- 3-MONTH RUNNING MEAN -----
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);
```

```

%% ----- STANDARDIZATION -----
mu_nino = mean(nino,'omitnan');
sd_nino = std(nino,'omitnan');
mu_soi = mean(soi,'omitnan');
sd_soi = std(soi,'omitnan');
ninoZ = (nino - mu_nino) ./ sd_nino;
soiZ = (soi - mu_soi) ./ sd_soi;

%% ----- BUILD LAG DATA -----
numSamples = N - p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lag_nino = ninoZ(i:i+p-1);
    lag_soi = soiZ(i:i+p-1);
    X(i,:) = [lag_nino' lag_soi'];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end

%% ----- TRAIN / TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);

Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
time_test = time(testIdx);
obs_test = nino(testIdx);

%% ----- MLR MODEL -----
Pred = NaN(length(leads),length(Xts));
for k = 1:length(leads)
    L = leads(k);
    validTrain = ~isnan(Ytr(:,L));
    % Tambahkan intercept
    Xtr_valid = [ones(sum(validTrain),1) Xtr(validTrain,:)];
    % Training MLR
    beta = Xtr_valid \ Ytr(validTrain,L);
    % Testing
    Xts_bias = [ones(size(Xts,1),1) Xts];
    Pred(k,:) = (Xts_bias * beta);
end

%% ----- KEMBALI KE SKALA ASLI -----
Pred = Pred * sd_nino + mu_nino;

%% ----- PLOT OBS VS PRED -----
figure('Color','w','Position',[150 100 900 550])
hold on
box on
plot(time_test,obs_test, ...
    'k-', ...
    'LineWidth',2.2, ...

```

```

'DisplayName','Observed Niño 3.4')

plot(time_test,Pred(1,:), ...
     '--', ...
     'Color',[0 0 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-1')

plot(time_test,Pred(2,:), ...
     '--', ...
     'Color',[1 0 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-4')

plot(time_test,Pred(3,:), ...
     '--', ...
     'Color',[0 0.7 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-7')

plot(time_test,Pred(4,:), ...
     '--', ...
     'Color',[0.7 0 0.7], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-11')

xlabel('Year')
ylabel('Niño 3.4 (°C)')
title('ENSO Prediction using MLR')
legend('Location','northwest')
legend boxoff
grid on
set(gca,'FontSize',11)
ylim([-2 3])

%% ----- FINISH -----

disp(' ')
disp('Selesai.')
disp('Grafik observasi dan prediksi MLR berhasil ditampilkan.')

Program Matlab Time Series Long Short Term Memory
%% =====
% ENSO PREDICTION (LSTM: NINO 3.4 + SOI)
% Lead: 1, 4, 7, 11
% =====

clear; close all; clc;

%% ----- PARAMETERS -----
filename = 'DataKeseluruhan.csv';
p       = 44;
splitYr = 2010;
leads   = [1 4 7 11];
numHiddenUnits = 100;
maxEpochs   = 150;

```



```

miniBatchSize = 32;

%% ----- READ DATA -----
T = readtable(filename);
time_d = datetime(T{:,1},'InputFormat','yyyy-MM-dd');
nino = T{:,2};
soi = T{:,3};
TT = timetable(time_d,nino,soi);
TTm = retime(TT,'monthly','mean');
time = TTm.time_d;
nino = TTm.nino;
soi = TTm.soi;

%% ----- 3-MONTH RUNNING MEAN -----
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);

%% ----- STANDARDIZATION -----
mu_nino = mean(nino,'omitnan');
sd_nino = std(nino,'omitnan');
mu_soi = mean(soi,'omitnan');
sd_soi = std(soi,'omitnan');
ninoZ = (nino - mu_nino) ./ sd_nino;
soiZ = (soi - mu_soi) ./ sd_soi;

%% ----- BUILD SEQUENCE DATA -----
numSamples = N - p;
X = cell(numSamples,1);
Y = NaN(numSamples, max(leads));
for i = 1:numSamples
    seq_nino = ninoZ(i:i+p-1);
    seq_soi = soiZ(i:i+p-1);
    % 2 fitur ? [2 x timeStep]
    X{i} = [seq_nino; seq_soi];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end
end

%% ----- TRAIN / TEST SPLIT -----
allIdx = (p+1):N;
testIdx = allIdx(year(time(allIdx)) >= splitYr);
trainIdx = allIdx(year(time(allIdx)) < splitYr);
Xtr = X(trainIdx-p);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p);
Yts = Y(testIdx-p,:);

```

```

time_test = time(testIdx);
obs_test = nino(testIdx);

%% ===== LSTM MODEL =====
Pred = NaN(length(leads), length(Xts));
for k = 1:length(leads)
    L = leads(k);
    valid = ~isnan(Ytr(:,L));
    Xtrain = Xtr(valid);
    Ytrain = Ytr(valid,L);

    %% ----- LSTM Architecture -----
    layers = [
        sequenceInputLayer(2)
        lstmLayer(numHiddenUnits,'OutputMode','last')
        fullyConnectedLayer(1)
        regressionLayer];
    options = trainingOptions('adam', ...
        'MaxEpochs', maxEpochs, ...
        'MiniBatchSize', miniBatchSize, ...
        'InitialLearnRate', 0.005, ...
        'GradientThreshold',1, ...
        'Shuffle','every-epoch', ...
        'Verbose',0);

    %% ----- TRAIN -----
    net = trainNetwork(Xtrain, Ytrain, layers, options);

    %% ----- PREDICT -----
    pred = predict(net, Xts, 'MiniBatchSize',1);
    Pred(k,:) = pred';
end

%% ----- KEMBALI KE SKALA ASLI -----
Pred = Pred * sd_nino + mu_nino;

%% ===== PLOT =====
figure('Color','w','Position',[150 100 900 550])
hold on; box on
plot(time_test, obs_test, ...
    'k-','LineWidth',2, ...
    'DisplayName','Observed Niño 3.4')

plot(time_test, Pred(1,:), '--k','LineWidth',1,'DisplayName','Lead-1')
plot(time_test, Pred(2,:), '--r','LineWidth',1,'DisplayName','Lead-4')
plot(time_test, Pred(3,:), '--g','LineWidth',1,'DisplayName','Lead-7')
plot(time_test, Pred(4,:), '--m','LineWidth',1,'DisplayName','Lead-11')
xlabel('Year')
ylabel('Niño 3.4 (°C)')
title('ENSO Prediction using LSTM')

```

```

legend('Location','northwest')
legend boxoff
grid on
set(gca,'FontSize',11)
ylim([-2 3])
%% ===== METRIK =====
for k = 1:length(leads)
    pred_k = Pred(k,:);
    valid = ~isnan(pred_k);
    RMSE = sqrt(mean((obs_test(valid) - pred_k(valid)).^2));
    ACC = corr(obs_test(valid), pred_k(valid));
    fprintf('LSTM Lead-%d -> RMSE: %.3f | ACC: %.3f\n', ...
        leads(k), RMSE, ACC);
end

```

Program Matlab *Time Series Random Forest*

```

%% =====
% ENSO PREDICTION
% RANDOM FOREST MODEL
% Predictor : NINO 3.4 + SOI
% Target   : NINO 3.4
% Lead     : 1, 4, 7, 11 Months
% Lag      : 44 Months
% =====

clear; close all; clc;

%% ----- PARAMETERS -----
filename = 'DataKeseluruhan.csv';
p       = 44;
splitYr = 2010;
leads   = [1 4 7 11];
nTrees  = 100;

%% ----- READ DATA -----
T = readtable(filename);
time_d = datetime(T{:,1},'InputFormat','yyyy-MM-dd');
nino    = T{:,2};
soi     = T{:,3};
TT = timetable(time_d,nino,soi);
TTm = retime(TT,'monthly','mean');

time = TTm.time_d;
nino = TTm.nino;
soi = TTm.soi;

%% ----- 3-MONTH RUNNING MEAN -----
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);

%% ----- STANDARDIZATION -----
mu_nino = mean(nino,'omitnan');
sd_nino = std(nino,'omitnan');
mu_soi = mean(soi,'omitnan');

```

```

sd_soi = std(soi,'omitnan');
ninoZ = (nino - mu_nino) ./ sd_nino;
soiZ = (soi - mu_soi) ./ sd_soi;

%% ----- BUILD LAG DATA -----
numSamples = N - p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lag_nino = ninoZ(i:i+p-1);
    lag_soi = soiZ(i:i+p-1);
    X(i,:) = [lag_nino' lag_soi'];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end
end

%% ----- TRAIN / TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
time_test = time(testIdx);
obs_test = nino(testIdx);

%% ----- RANDOM FOREST MODEL -----
Pred = NaN(length(leads),length(Xts));
for k = 1:length(leads)
    L = leads(k);
    validTrain = ~isnan(Ytr(:,L));
    RFmodel = fitrensemble( ...
        Xtr(validTrain,:), Ytr(validTrain,L), ...
        'Method','Bag', ...
        'NumLearningCycles',nTrees, ...
        'Learners','tree');
    Pred(k,:) = predict(RFmodel,Xts);
end

%% ----- KEMBALI KE SKALA ASLI -----
Pred = Pred * sd_nino + mu_nino;

%% ----- PLOT OBS VS PRED -----
figure('Color','w','Position',[150 100 900 550])
hold on
box on

plot(time_test,obs_test, ...
    'k-', ...
    'LineWidth',2.2, ...
    'DisplayName','Observed Niño 3.4')

plot(time_test,Pred(1,:), ...
    'r-', ...
    'Color',[0 0 0], ...
    'LineWidth',1.2, ...
    'DisplayName','Lead-1')

```

```

plot(time_test,Pred(2,:), ...
     '--', ...
     'Color',[1 0 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-4')

plot(time_test,Pred(3,:), ...
     '--', ...
     'Color',[0 0.7 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-7')

plot(time_test,Pred(4,:), ...
     '--', ...
     'Color',[0.7 0 0.7], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-11')

xlabel('Year')
ylabel('Niño 3.4 (°C)')
title('ENSO Prediction using Random Forest')

legend('Location','northwest')
legend boxoff
grid on
set(gca,'FontSize',11)
ylim([-2 3])

%% ----- FINISH -----

disp(' ')
disp('Selesai.')
disp('Grafik observasi dan prediksi Random Forest berhasil ditampilkan.')

```

Program Matlab Time Series Extreme Gradient Boosting

```

%% =====
% ENSO PREDICTION
% EXTREME GRADIENT BOOSTING / XGBOOST-STYLE
% Predictor : NINO 3.4 + SOI
% Target    : NINO 3.4
% Lead      : 1, 4, 7, 11 Months
% Lag       : 44 Months
% =====

clear; close all; clc;

%% ----- PARAMETERS -----
filename = 'DataKeseluruhan.csv';
p        = 44;
splitYr  = 2010;
leads    = [1 4 7 11];
nTrees   = 300; % jumlah boosting iteration
learnRate = 0.05; % learning rate
maxDepth = 4; % kedalaman tree

%% ----- READ DATA -----

```

```

T = readtable(filename);
time_d = datetime(T{:,1},'InputFormat','yyyy-MM-dd');
nino = T{:,2};
soi = T{:,3};
TT = timetable(time_d,nino,soi);
TTm = retime(TT,'monthly','mean');
time = TTm.time_d;
nino = TTm.nino;
soi = TTm.soi;

%% ----- 3-MONTH RUNNING MEAN -----
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);

%% ----- STANDARDIZATION -----
mu_nino = mean(nino,'omitnan');
sd_nino = std(nino,'omitnan');
mu_soi = mean(soi,'omitnan');
sd_soi = std(soi,'omitnan');
ninoZ = (nino - mu_nino) ./ sd_nino;
soiZ = (soi - mu_soi) ./ sd_soi;

%% ----- BUILD LAG DATA -----
numSamples = N - p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lag_nino = ninoZ(i:i+p-1);
    lag_soi = soiZ(i:i+p-1);
    X(i,:) = [lag_nino' lag_soi'];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end

%% ----- TRAIN / TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);

Xts = X(testIdx-p,:);
Yts = Y(testIdx-p,:);
time_test = time(testIdx);
obs_test = nino(testIdx);

%% ----- XGBOOST-STYLE MODEL -----
Pred = NaN(length(leads),length(Xts));
treeTemplate = templateTree('MaxNumSplits',2^maxDepth);
for k = 1:length(leads)
    L = leads(k);
    validTrain = ~isnan(Ytr(:,L));
    model = fitrensemble( ...
        Xtr(validTrain,:), Ytr(validTrain,L), ...

```

```

        'Method','LSBoost', ...
        'NumLearningCycles',nTrees, ...
        'LearnRate',learnRate, ...
        'Learners',treeTemplate);
    Pred(k,:) = predict(model,Xts);
End

%% ----- KEMBALI KE SKALA ASLI -----
Pred = Pred * sd_nino + mu_nino;

%% ----- PLOT OBS VS PRED -----
figure('Color','w','Position',[150 100 900 550])
hold on
box on

plot(time_test,obs_test, ...
     'k-', ...
     'LineWidth',2.2, ...
     'DisplayName','Observed Niño 3.4')

plot(time_test,Pred(1,:), ...
     '--', ...
     'Color',[0 0 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-1')

plot(time_test,Pred(2,:), ...
     '--', ...
     'Color',[1 0 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-4')

plot(time_test,Pred(3,:), ...
     '--', ...
     'Color',[0 0.7 0], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-7')

plot(time_test,Pred(4,:), ...
     '--', ...
     'Color',[0.7 0 0.7], ...
     'LineWidth',1.2, ...
     'DisplayName','Lead-11')

xlabel('Year')
ylabel('Niño 3.4 (°C)')
title( ENSO 'Prediction using XGBoost')
legend('Location','northwest')
legend boxoff
grid on
set(gca,'FontSize',11)

ylim([-2 3])

```

Lampiran 3. Program Matlab *Root Mean Square Error (RMSE)*, *Anomaly Corelation Coefisien (ACC)*, dan *Peirce Skill Score (PSS)*

Program Matlab RMSE, ACC, dan PSS Multiple Linear Regression

```
%% =====
% MULTIPLE LINEAR REGRESSION MLR ENSO PREDICTION
% Predictor : NINO3.4 + SOI
% Target : NINO3.4
% ACC, RMSE, PSS
% SAVE RESULT
%% =====
clear;
close all;
clc;
rng(42,'twister');
%% PARAMETERS
filename = 'DataKeseluruhan.csv';
p = 44;
splitYr = 2010;
leads = 1:12;
%% READ DATA
T = readtable(filename,'VariableNamingRule','preserve');
time = datetime(T{:,1},'InputFormat','yyyy-MM-dd');
nino = T{:,2};
soi = T{:,3};
nino = fillmissing(nino,'linear');
soi = fillmissing(soi,'linear');
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);
%% STANDARDIZATION
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
muSOI = mean(soi,'omitnan');
sdSOI = std(soi,'omitnan');
ninoZ = (nino-muNINO)./sdNINO;
soiZ = (soi-muSOI)./sdSOI;
%% BUILD LAGGED DATA
numSamples = N-p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lagNINO = ninoZ(i:i+p-1);
    lagSOI = soiZ(i:i+p-1);
    X(i,:) = [lagNINO' lagSOI'];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end
end
%% TRAIN TEST SPLIT
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
```



```

testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
Yts = Y(testIdx-p,:);
%% INFO DATA SPLIT
fprintf('\n===== INFO DATA SPLIT =====\n');
fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train    : %d\n',length(trainIdx));
fprintf('Jumlah Test     : %d\n',length(testIdx));
fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));
fprintf('Periode Test  : %s sampai %s\n', ...
    datestr(time(testIdx(1))), ...
    datestr(time(testIdx(end))));
%% MLR TRAINING
MLR = cell(length(leads),1);
Pred = NaN(length(leads),size(Xts,1));
for k = 1:length(leads)
    L = leads(k);
    valid = ~isnan(Ytr(:,L));
    MLR{k} = fitlm(Xtr(valid,:),Ytr(valid,L));
    Pred(k,:) = predict(MLR{k},Xts);
end
%% BACK TO ORIGINAL SCALE
Pred = Pred.*sdNINO + muNINO;
%% METRICS
ACC = NaN(length(leads),1);
ACC_err = NaN(length(leads),1);
RMSE = NaN(length(leads),1);
RMSE_err = NaN(length(leads),1);
PSS = NaN(length(leads),1);
PSS_err = NaN(length(leads),1);

for k = 1:length(leads)
    L = leads(k);

    obs = Yts(:,L).*sdNINO + muNINO;
    pred = Pred(k,:);

    idx = ~isnan(obs) & ~isnan(pred);
    obs = obs(idx);
    pred = pred(idx);

    %% =====
    % PEARSON CORRELATION (ACC)
    %% =====
    n = length(obs);
    sumX = sum(obs);
    sumY = sum(pred);
    sumXY = sum(obs.*pred);
    sumX2 = sum(obs.^2);

```

```

sumY2 = sum(pred.^2);

ACC(k) = (n*sumXY - sumX*sumY) / ...
    sqrt((n*sumX2 - sumX^2) * (n*sumY2 - sumY^2));

%% =====
% RMSE (sesuai rumus gambar)
%% =====
RMSE(k) = sqrt(mean((obs - pred).^2));

%% =====
% PSS (ad-bc)/(b+d)(a+c)
% threshold = 0 (ENSO phase)
%% =====
obs_bin = obs > 0;
pred_bin = pred > 0;

a = sum((obs_bin==1) & (pred_bin==1)); % hit
b = sum((obs_bin==0) & (pred_bin==1)); % false alarm
c = sum((obs_bin==1) & (pred_bin==0)); % miss
d = sum((obs_bin==0) & (pred_bin==0)); % correct rejection

PSS(k) = (a*d - b*c) / ((b + d) * (a + c));

%% error estimate (tetap seperti sebelumnya)
ACC_err(k) = sqrt((1 - ACC(k)^2) / n);
RMSE_err(k) = sqrt(2/n);
PSS_err(k) = sqrt(2/n);
end
%% RESULT TABLE
ResultTable = table( ...
    leads', ...
    ACC, ...
    ACC_err, ...
    RMSE, ...
    RMSE_err, ...
    PSS, ...
    PSS_err, ...
    'VariableNames', ...
    {'Lead','ACC','ACC_err','RMSE','RMSE_err','PSS','PSS_err'});
disp(ResultTable)
%% SAVE RESULT
ACC_MLR = ACC;
RMSE_MLR = RMSE;
PSS_MLR = PSS;
save('ENSO_MLR_Result.mat', ...
    'ACC_MLR', ...
    'RMSE_MLR', ...
    'PSS_MLR', ...
    'leads');
writetable(ResultTable,'ENSO_MLR_Result.csv');
fprintf("\nENSO_MLR_Result.mat berhasil disimpan\n");
fprintf('ENSO_MLR_Result.csv berhasil disimpan\n');

```

```

%% PLOT
figure('Position',[200 100 1000 450])
subplot(1,2,1)
yyaxis left
errorbar(leads,ACC,ACC_err, ...
    '-ob', ...
    'LineWidth',1.8, ...
    'MarkerFaceColor','b')
ylabel('ACC')
hold on
yline(0.5,'--k','LineWidth',1.2)
yyaxis right
errorbar(leads,RMSE,RMSE_err, ...
    '--sg', ...
    'LineWidth',1.8, ...
    'MarkerFaceColor','g')
ylabel('RMSE')
xlabel('Lead month')
title('ACC and RMSE')
grid on
legend('ACC','ACC = 0.5','RMSE', ...
    'Location','southwest')
subplot(1,2,2)
errorbar(leads,PSS,PSS_err, ...
    '-ok', ...
    'LineWidth',1.8, ...
    'MarkerFaceColor','k')
xlabel('Lead month')
ylabel('PSS')
title('Peirce Skill Score')
grid on
ylim([-0.4 1])
sgtitle('Monthly ENSO Prediction Verification MLR')

```

Program Matlab RMSE, ACC, dan PSS Long Short Term Memory

```

%% =====
% LSTM ENSO PREDICTION
% Predictor : NINO3.4 + SOI
% Target    : NINO3.4
% + PSS error bar
% + INFO SPLIT TRAIN TEST
%% =====
clear; close all; clc;
rng(42,'twister');
%% ----- PARAMETERS -----
filename = 'DataKeseluruhan.csv';
p = 44;
splitYr = 2010;
leads = 1:12;
hiddenUnits = 10;
maxEpochs = 30;
miniBatchSize = 16;
%% ----- READ DATA -----

```

```

T = readtable(filename,'VariableNamingRule','preserve');
time = datetime(T{:,1},'InputFormat','yyyy-MM-dd');
nino = T{:,2};
soi = T{:,3};
nino = fillmissing(nino,'linear');
soi = fillmissing(soi,'linear');
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);
%% ----- STANDARDIZATION -----
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
muSOI = mean(soi,'omitnan');
sdSOI = std(soi,'omitnan');
ninoZ = (nino-muNINO)./sdNINO;
soiZ = (soi-muSOI)./sdSOI;

%% ----- BUILD SEQUENCE DATA -----
numSamples = N-p;
X = cell(numSamples,1);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lagNINO = ninoZ(i:i+p-1);
    lagSOI = soiZ(i:i+p-1);
    X{i} = [lagNINO; lagSOI];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end
end
%% ----- TRAIN TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p);
Yts = Y(testIdx-p,:);

%% ----- INFO SPLIT DATA -----
fprintf('\n===== INFO DATA SPLIT =====\n');
fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train : %d\n',length(trainIdx));
fprintf('Jumlah Test : %d\n',length(testIdx));
fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));
fprintf('Periode Test : %s sampai %s\n', ...
    datestr(time(testIdx(1))), ...
    datestr(time(testIdx(end))));
%% ----- LSTM ARCHITECTURE -----

```

```

layers = [
    sequenceInputLayer(2)
    lstmLayer(hiddenUnits,'OutputMode','last')
    fullyConnectedLayer(1)
    regressionLayer
];
options = trainingOptions('adam', ...
    'MaxEpochs',maxEpochs, ...
    'MiniBatchSize',miniBatchSize, ...
    'InitialLearnRate',0.001, ...
    'GradientThreshold',1, ...
    'Shuffle','every-epoch', ...
    'Verbose',false, ...
    'Plots','none');

%% ----- TRAINING -----
Pred = NaN(length(leads),length(Xts));
for k = 1:length(leads)
    fprintf("Training Lead %d bulan...\n",leads(k));
    valid = ~isnan(Ytr(:,k));
    XTrain = Xtr(valid);
    YTrain = Ytr(valid,k);
    net = trainNetwork( ...
        XTrain, ...
        YTrain, ...
        layers, ...
        options);
    YPred = predict( ...
        net, ...
        Xts, ...
        'MiniBatchSize',1);
    Pred(k,:) = YPred(:);
end
%% ----- BACK TO ORIGINAL SCALE -----
Pred = Pred.*sdNINO + muNINO;

%% ----- METRICS -----

r      = NaN(length(leads),1);
r_err  = NaN(length(leads),1);
PSS    = NaN(length(leads),1);
PSS_err = NaN(length(leads),1);
RMSE   = NaN(length(leads),1);
RMSE_err = NaN(length(leads),1);

for k = 1:length(leads)

    obs = Yts(:,k).*sdNINO + muNINO;
    pred = Pred(k,:);

    idx = ~isnan(obs) & ~isnan(pred);

    obs = obs(idx);

```

```

pred = pred(idx);

n = length(obs);

%% ----- PEARSON CORRELATION r -----
%  $r = \frac{[n \cdot \sum(XY) - \sum(X) \cdot \sum(Y)]}{\sqrt{\{n \cdot \sum(X^2) - [\sum(X)]^2\} \cdot \{n \cdot \sum(Y^2) - [\sum(Y)]^2\}}}$ 
%
pembilang_r = n*sum(obs.*pred) ...
    - sum(obs)*sum(pred);

penyebut_r = sqrt( ...
    (n*sum(obs.^2) - (sum(obs))^2) * ...
    (n*sum(pred.^2) - (sum(pred))^2));

if penyebut_r ~= 0
    r(k) = pembilang_r/penyebut_r;
else
    r(k) = NaN;
end

%% ----- r ERROR -----

if n > 3 && isfinite(r(k)) && abs(r(k)) < 1

    z = atanh(r(k));
    z_err = 1/sqrt(n-3);

    r_upper = tanh(z+z_err);
    r_err(k) = abs(r_upper-r(k));

else

    r_err(k) = NaN;

end

%% ----- PEIRCE SKILL SCORE -----
%  $PSS = \frac{(a \cdot d - b \cdot c)}{((b+d) \cdot (a+c))}$ 

obs_event = obs >= 0;
pred_event = pred >= 0;

a = sum(obs_event == 1 & pred_event == 1);
b = sum(obs_event == 0 & pred_event == 1);
c = sum(obs_event == 1 & pred_event == 0);
d = sum(obs_event == 0 & pred_event == 0);

penyebut_pss = (b+d)*(a+c);

if penyebut_pss ~= 0
    PSS(k) = (a*d-b*c)/penyebut_pss;

```

```

else
    PSS(k) = NaN;
end

%% ----- PSS ERROR -----
if n > 0
    PSS_err(k) = sqrt(2/n);
else
    PSS_err(k) = NaN;
end

%% ----- RMSE -----
% RMSE = sqrt((1/n)*sum((yi-yhat_i)^2))

if n > 0
    RMSE(k) = sqrt((1/n)*sum((obs-pred).^2));
else
    RMSE(k) = NaN;
end

%% ----- RMSE ERROR -----

if n > 0
    RMSE_err(k) = RMSE(k)/sqrt(2*n);
else
    RMSE_err(k) = NaN;
end

end

%% ----- RESULT TABLE -----

ResultTable = table( ...
    leads', ...
    r,r_err, ...
    RMSE,RMSE_err, ...
    PSS,PSS_err, ...
    'VariableNames', ...
    {'Lead','r','r_err','RMSE','RMSE_err','PSS','PSS_err'});

disp(ResultTable)

%% ----- SAVE RESULT -----

r_LSTM      = r;
r_err_LSTM  = r_err;
RMSE_LSTM   = RMSE;
RMSE_err_LSTM = RMSE_err;
PSS_LSTM    = PSS;
PSS_err_LSTM = PSS_err;

save('ENSO_LSTM_Result.mat', ...
    'r_LSTM', ...

```

```

'r_err_LSTM', ...
'RMSE_LSTM', ...
'RMSE_err_LSTM', ...
'PSS_LSTM', ...
'PSS_err_LSTM', ...
'leads');

writetable(ResultTable,'ENSO_LSTM_Result.csv');

fprintf("\nENSO_LSTM_Result.mat berhasil disimpan\n");
fprintf('ENSO_LSTM_Result.csv berhasil disimpan\n');

%% ----- PLOT -----

figure('Position',[200 100 1000 450])

subplot(1,2,1)

yyaxis left

errorbar(leads,r,r_err, ...
    '-ob','LineWidth',1.8, ...
    'MarkerFaceColor','b')

ylabel('Pearson Correlation (r)')

hold on

yline(0.5,'--k','LineWidth',1.2)
yyaxis right
errorbar(leads,RMSE,RMSE_err, ...
    '--sg','LineWidth',1.8, ...
    'MarkerFaceColor','g')
ylabel('RMSE')
xlabel('Lead month')
title('Pearson Correlation and RMSE')

grid on
legend('r','r = 0.5','RMSE', ...
    'Location','southwest')
subplot(1,2,2)
errorbar(leads,PSS,PSS_err, ...
    '-ok','LineWidth',1.8, ...
    'MarkerFaceColor','k')
xlabel('Lead month')
ylabel('PSS')
title('Peirce Skill Score')
grid on
ylim([-1 1])

sgtitle('Monthly ENSO Prediction Verification LSTM')

```

Program Matlab RMSE, ACC, dan PSS Random Forest


```

%% =====
% RANDOM FOREST ENSO PREDICTION
% Predictor : NINO 3.4 + SOI
% Target   : NINO 3.4
% + ACC and RMSE error
% + PSS error bar
% + INFO SPLIT TRAIN TEST
% + SAVE RESULT
%% =====

clear; close all; clc;
rng(42,'twister');

%% ----- PARAMETERS -----
filename = 'DataKeseluruhan.csv';
p = 44;
splitYr = 2010;
leads = 1:12;
numTrees = 300;
minLeafSize = 3;
bagFraction = 0.8;

%% ----- READ DATA -----
T = readtable(filename,'VariableNamingRule','preserve');
time = datetime(T{:,1});
nino = T{:,2};
soi = T{:,3};
nino = fillmissing(nino,'linear');
soi = fillmissing(soi,'linear');
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);

%% ----- STANDARDIZATION -----
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
muSOI = mean(soi,'omitnan');
sdSOI = std(soi,'omitnan');
ninoZ = (nino-muNINO)./sdNINO;
soiZ = (soi-muSOI)./sdSOI
%% ----- BUILD LAGGED DATA -----
numSamples = N-p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lagNINO = ninoZ(i:i+p-1);
    lagSOI = soiZ(i:i+p-1);
    X(i,:) = [lagNINO' lagSOI'];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end

```

```

end
%% ----- TRAIN TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
Yts = Y(testIdx-p,:);
%% ----- INFO SPLIT DATA -----
fprintf('\n===== INFO DATA SPLIT =====\n');
fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train      : %d\n',length(trainIdx));
fprintf('Jumlah Test       : %d\n\n',length(testIdx));
fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));
fprintf('Periode Test : %s sampai %s\n\n', ...
    datestr(time(testIdx(1))), ...
    datestr(time(testIdx(end))));
%% ----- RANDOM FOREST TRAINING -----
Model = cell(length(leads),1);
Pred = NaN(length(leads),size(Xts,1));
for k = 1:length(leads)
    L = leads(k);
    valid = ~isnan(Ytr(:,L));
    numPredictors = size(Xtr,2);
    Model{k} = TreeBagger( ...
        numTrees, ...
        Xtr(valid,:), ...
        Ytr(valid,L), ...
        'Method','regression', ...
        'MinLeafSize',minLeafSize, ...
        'NumPredictorsToSample',max(1,round(numPredictors/3)), ...
        'InBagFraction',bagFraction, ...
        'OOBPrediction','on');
    Pred(k,:) = predict(Model{k},Xts);
end
%% ----- BACK TO ORIGINAL SCALE -----
Pred = Pred .* sdNINO + muNINO;

%% ----- METRICS -----
r = NaN(length(leads),1);
r_err = NaN(length(leads),1);
PSS = NaN(length(leads),1);
PSS_err = NaN(length(leads),1);
RMSE = NaN(length(leads),1);
RMSE_err = NaN(length(leads),1);

for k = 1:length(leads)
    L = leads(k);
    obs = Yts(:,L).*sdNINO + muNINO;

```

```

pred = Pred(k,:);
idx = ~isnan(obs) & ~isnan(pred);
obs = obs(idx);
pred = pred(idx);
n = length(obs);

%% Pearson correlation (r)
numerator = n*sum(obs.*pred) - sum(obs)*sum(pred);

denominator_r = sqrt( ...
    (n*sum(obs.^2) - (sum(obs))^2) * ...
    (n*sum(pred.^2) - (sum(pred))^2));

if denominator_r ~= 0
    r(k) = numerator/denominator_r;
else
    r(k) = NaN;
end

%% r error
if n > 3 && isfinite(r(k)) && abs(r(k)) < 1

    z = atanh(r(k));
    z_err = 1/sqrt(n-3);

    r_upper = tanh(z+z_err);
    r_err(k) = abs(r_upper-r(k));

else

    r_err(k) = NaN;

end

%% Peirce Skill Score (PSS)
obs_event = obs >= 0;
pred_event = pred >= 0;

a = sum(obs_event == 1 & pred_event == 1);
b = sum(obs_event == 0 & pred_event == 1);
c = sum(obs_event == 1 & pred_event == 0);
d = sum(obs_event == 0 & pred_event == 0);

denominator_pss = (b+d)*(a+c);

if denominator_pss ~= 0
    PSS(k) = (a*d-b*c)/denominator_pss;
else
    PSS(k) = NaN;
end

%% PSS error
if n > 0

```

```

        PSS_err(k) = sqrt(2/n);
    else
        PSS_err(k) = NaN;
    end

    %% RMSE
    if n > 0
        RMSE(k) = sqrt((1/n)*sum((obs-pred).^2));
    else
        RMSE(k) = NaN;
    end

    %% RMSE error
    if n > 0
        RMSE_err(k) = RMSE(k)/sqrt(2*n);
    else
        RMSE_err(k) = NaN;
    end

end

%% ----- RESULT TABLE -----
ResultTable = table( ...
    leads', ...
    r, ...
    r_err, ...
    PSS, ...
    PSS_err, ...
    RMSE, ...
    RMSE_err, ...
    'VariableNames', ...
    {'Lead','r','r_error','PSS','PSS_error', ...
    'RMSE','RMSE_error'});

disp(' ')
disp('==== HASIL EVALUASI RANDOM FOREST =====')
disp(ResultTable)

%% ----- SAVE RESULT -----
r_RF = r;
r_error_RF = r_err;
PSS_RF = PSS;
PSS_error_RF = PSS_err;
RMSE_RF = RMSE;
RMSE_error_RF = RMSE_err;

save('ENSO_RF_Result.mat', ...
    'r_RF', ...
    'r_error_RF', ...
    'PSS_RF', ...
    'PSS_error_RF', ...
    'RMSE_RF', ...
    'RMSE_error_RF', ...

```

```

    'leads');

writetable(ResultTable,'ENSO_RF_Result.csv');

fprintf("\nENSO_RF_Result.mat berhasil disimpan\n");
fprintf('ENSO_RF_Result.csv berhasil disimpan\n');

%% ----- PLOT -----
figure('Position',[200 100 1000 450])

subplot(1,2,1)

yyaxis left

errorbar(leads,r,r_err, ...
    '-ob','LineWidth',1.8, ...
    'MarkerFaceColor','b')

ylabel('Pearson Correlation (r)')
hold on
yline(0.5,'--k','LineWidth',1.2)

yyaxis right

errorbar(leads,RMSE,RMSE_err, ...
    '--sg','LineWidth',1.8, ...
    'MarkerFaceColor','g')

ylabel('RMSE')
xlabel('Lead month')
title('Pearson Correlation and RMSE')
grid on

legend('r','r = 0.5','RMSE', ...
    'Location','southwest')

subplot(1,2,2)

errorbar(leads,PSS,PSS_err, ...
    '-ok','LineWidth',1.8, ...
    'MarkerFaceColor','k')

xlabel('Lead month')
ylabel('PSS')
title('Peirce Skill Score')
grid on
ylim([-1 1])

sgtitle('Monthly ENSO Prediction Verification Random Forest')

Program Matlab RMSE, ACC, dan PSS Extreme Gradient Boosting

%% =====

```

```

% XGBOOST ENSO PREDICTION
% Predictor : NINO3.4 + SOI
% Target   : NINO3.4
% + ACC & RMSE error
% + PSS error bar
% + INFO SPLIT TRAIN TEST
% + SAVE RESULT
%% =====

clear; close all; clc;
rng(42,'twister');
%% ----- PARAMETERS -----
filename = 'DataKeseluruhan.csv';
p = 44;
splitYr = 2010;
leads = 1:12;

nTrees    = 300;
learnRate = 0.03;
minLeafSize = 5;
maxNumSplits = 20;
%% ----- READ DATA -----
T = readtable(filename,'VariableNamingRule','preserve');
time = datetime(T{:,1});
nino = T{:,2};
soi = T{:,3};
nino = fillmissing(nino,'linear');
soi = fillmissing(soi,'linear');
nino = movmean(nino,3,'omitnan');
soi = movmean(soi,3,'omitnan');
N = length(nino);
%% ----- STANDARDIZATION -----
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
muSOI = mean(soi,'omitnan');
sdSOI = std(soi,'omitnan');
ninoZ = (nino-muNINO)./sdNINO;
soiZ = (soi-muSOI)./sdSOI;
%% ----- BUILD LAGGED DATA -----

numSamples = N-p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lagNINO = ninoZ(i:i+p-1);
    lagSOI = soiZ(i:i+p-1);
    X(i,:) = [lagNINO' lagSOI'];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = ninoZ(i+p-1+L);
        end
    end
end

```

```

        end
    end
end
%% ----- TRAIN TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
Yts = Y(testIdx-p,:);
%% ----- INFO SPLIT DATA -----
fprintf('\n===== INFO DATA SPLIT =====\n');
fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train    : %d\n',length(trainIdx));
fprintf('Jumlah Test     : %d\n',length(testIdx));
fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));
fprintf('Periode Test : %s sampai %s\n', ...
    datestr(time(testIdx(1))), ...
    datestr(time(testIdx(end))));
%% ----- XGBOOST TRAINING -----
Model = cell(length(leads),1);
Pred = NaN(length(leads),size(Xts,1));
t = templateTree( ...
    'MinLeafSize',minLeafSize, ...
    'MaxNumSplits',maxNumSplits);
for k = 1:length(leads)
    L = leads(k);
    valid = ~isnan(Ytr(:,L));
    Model{k} = fitrensemble( ...
        Xtr(valid,:), ...
        Ytr(valid,L), ...
        'Method','LSBoost', ...
        'NumLearningCycles',nTrees, ...
        'LearnRate',learnRate, ...
        'Learners',t);
    Pred(k,:) = predict(Model{k},Xts);
end
%% ----- BACK TO ORIGINAL SCALE -----
Pred = Pred .* sdNINO + muNINO;

%% ----- METRICS -----
r = NaN(length(leads),1);
r_err = NaN(length(leads),1);
RMSE = NaN(length(leads),1);
RMSE_err = NaN(length(leads),1);
PSS = NaN(length(leads),1);
PSS_err = NaN(length(leads),1);

```

```

for k = 1:length(leads)

    L = leads(k);

    obs = Yts(:,L).*sdNINO + muNINO;
    pred = Pred(k,:);

    idx = ~isnan(obs) & ~isnan(pred);

    obs = obs(idx);
    pred = pred(idx);

    n = length(obs);

    %% ----- PEARSON CORRELATION r -----
    %  $r = \frac{[n \cdot \sum(XY) - \sum(X) \cdot \sum(Y)]}{\sqrt{\{n \cdot \sum(X^2) - [\sum(X)]^2\} \cdot \{n \cdot \sum(Y^2) - [\sum(Y)]^2\}}}$ 
    %
    numerator_r = n*sum(obs.*pred) ...
        - sum(obs)*sum(pred);

    denominator_r = sqrt( ...
        (n*sum(obs.^2) - (sum(obs))^2) * ...
        (n*sum(pred.^2) - (sum(pred))^2));

    if denominator_r ~= 0
        r(k) = numerator_r/denominator_r;
    else
        r(k) = NaN;
    end

    %% ----- r ERROR -----

    if n > 3 && isfinite(r(k)) && abs(r(k)) < 1

        z = atanh(r(k));
        z_err = 1/sqrt(n-3);

        r_upper = tanh(z+z_err);
        r_err(k) = abs(r_upper-r(k));

    else

        r_err(k) = NaN;

    end

    %% ----- PEIRCE SKILL SCORE -----

```



```

% PSS = (a*d-b*c)/((b+d)*(a+c))

obs_event = obs >= 0;
pred_event = pred >= 0;

a = sum(obs_event == 1 & pred_event == 1); % Hit
b = sum(obs_event == 0 & pred_event == 1); % False alarm
c = sum(obs_event == 1 & pred_event == 0); % Miss
d = sum(obs_event == 0 & pred_event == 0); % Correct negative

denominator_pss = (b+d)*(a+c);

if denominator_pss ~= 0
    PSS(k) = (a*d-b*c)/denominator_pss;
else
    PSS(k) = NaN;
end

%% ----- PSS ERROR -----

if n > 0
    PSS_err(k) = sqrt(2/n);
else
    PSS_err(k) = NaN;
end

%% ----- RMSE -----
% RMSE = sqrt((1/n)*sum((yi-yhat_i)^2))

if n > 0
    RMSE(k) = sqrt((1/n)*sum((obs-pred).^2));
else
    RMSE(k) = NaN;
end

%% ----- RMSE ERROR -----

if n > 0
    RMSE_err(k) = RMSE(k)/sqrt(2*n);
else
    RMSE_err(k) = NaN;
end

end

%% ----- RESULT TABLE -----
ResultTable = table( ...
    leads',r,r_err, ...
    RMSE,RMSE_err, ...
    PSS,PSS_err, ...

```

```

'VariableNames',{'Lead','r','r_err', ...
'RMSE','RMSE_err','PSS','PSS_err'});

disp(ResultTable)

%% ----- SAVE RESULT -----
r_XGB = r;
r_err_XGB = r_err;
RMSE_XGB = RMSE;
RMSE_err_XGB = RMSE_err;
PSS_XGB = PSS;
PSS_err_XGB = PSS_err;

save('ENSO_XGB_Result.mat', ...
'r_XGB', ...
'r_err_XGB', ...
'RMSE_XGB', ...
'RMSE_err_XGB', ...
'PSS_XGB', ...
'PSS_err_XGB', ...
'leads');

writetable(ResultTable,'ENSO_XGB_Result.csv');

fprintf("\nENSO_XGB_Result.mat berhasil disimpan\n");
fprintf('ENSO_XGB_Result.csv berhasil disimpan\n');

%% ----- PLOT -----
figure('Position',[200 100 1000 450])

subplot(1,2,1)

yyaxis left

errorbar(leads,r,r_err, ...
'-ob','LineWidth',1.8, ...
'MarkerFaceColor','b')

ylabel('Pearson Correlation (r)')

hold on

yline(0.5,'--k','LineWidth',1.2)

yyaxis right

errorbar(leads,RMSE,RMSE_err, ...
'--sg','LineWidth',1.8, ...
'MarkerFaceColor','g')

```

```

ylabel('RMSE')
xlabel('Lead (month)')
title('Pearson Correlation and RMSE (NINO3.4 + SOI)')

grid on

legend('r','r = 0.5','RMSE', ...
       'Location','southwest')

subplot(1,2,2)

errorbar(leads,PSS,PSS_err, ...
        '-ok','LineWidth',1.8, ...
        'MarkerFaceColor','k')

xlabel('Lead (month)')
ylabel('PSS')

title('Peirce Skill Score (NINO3.4 + SOI)')

grid on
ylim([-1 1])

sgtitle('Monthly ENSO Prediction Verification (XGBoost)')

```

Lampiran 4. Program Matlab Perbandingan Kinerja Model

```

%% =====
% PERBANDINGAN KINERJA MODEL PREDIKSI ENSO
% Model : MLR, LSTM, Random Forest, XGBoost
% Evaluasi: Pearson Correlation (r), RMSE, PSS
%% =====
clear;
close all;
clc;

%% ----- LOAD RESULT -----

MLR = load('ENSO_MLR_Result.mat');
LSTM = load('ENSO_LSTM_Result.mat');
RF = load('ENSO_RF_Result.mat');
XGB = load('ENSO_XGB_Result.mat');

%% ----- LEAD TIME -----

leads = MLR.leads(:);

%% ----- MLR RESULT -----

if isfield(MLR,'r_MLR')
    r_MLR = MLR.r_MLR;
elseif isfield(MLR,'ACC_MLR')
    r_MLR = MLR.ACC_MLR;
else

```

```

    error('Variabel r_MLR atau ACC_MLR tidak ditemukan.');
```

end

```

RMSE_MLR = MLR.RMSE_MLR;
PSS_MLR = MLR.PSS_MLR;

%% ----- LSTM RESULT -----

if isfield(LSTM,'r_LSTM')
    r_LSTM = LSTM.r_LSTM;
elseif isfield(LSTM,'ACC_LSTM')
    r_LSTM = LSTM.ACC_LSTM;
else
    error('Variabel r_LSTM atau ACC_LSTM tidak ditemukan.');
```

end

```

RMSE_LSTM = LSTM.RMSE_LSTM;
PSS_LSTM = LSTM.PSS_LSTM;

%% ----- RANDOM FOREST RESULT -----

if isfield(RF,'r_RF')
    r_RF = RF.r_RF;
elseif isfield(RF,'ACC_RF')
    r_RF = RF.ACC_RF;
else
    error('Variabel r_RF atau ACC_RF tidak ditemukan.');
```

end

```

RMSE_RF = RF.RMSE_RF;
PSS_RF = RF.PSS_RF;

%% ----- XGBOOST RESULT -----

if isfield(XGB,'r_XGB')

    r_XGB = XGB.r_XGB;
elseif isfield(XGB,'ACC_XGB')
    r_XGB = XGB.ACC_XGB;
else
    error('Variabel r_XGB atau ACC_XGB tidak ditemukan.');
```

end

```

RMSE_XGB = XGB.RMSE_XGB;
PSS_XGB = XGB.PSS_XGB;

%% ----- COLUMN VECTOR -----

r_MLR = r_MLR(:);
r_LSTM = r_LSTM(:);
r_RF = r_RF(:);
r_XGB = r_XGB(:);

RMSE_MLR = RMSE_MLR(:);
RMSE_LSTM = RMSE_LSTM(:);
RMSE_RF = RMSE_RF(:);
RMSE_XGB = RMSE_XGB(:);

PSS_MLR = PSS_MLR(:);
PSS_LSTM = PSS_LSTM(:);
PSS_RF = PSS_RF(:);
PSS_XGB = PSS_XGB(:);
```

```

%% ----- CREATE FIGURE -----

figure( ...
    'Position',[100 50 1100 750], ...
    'Color','w');

%% =====
% PEARSON CORRELATION
%% =====

subplot(3,1,1)

plot(leads,r_MLR, ...
    '-o', ...
    'LineWidth',1.5, ...
    'MarkerSize',5, ...
    'MarkerFaceColor','auto');

hold on

plot(leads,r_LSTM, ...
    '-s', ...
    'LineWidth',1.5, ...
    'MarkerSize',5, ...
    'MarkerFaceColor','auto');

plot(leads,r_RF, ...
    '-d', ...
    'LineWidth',1.5, ...
    'MarkerSize',5, ...
    'MarkerFaceColor','auto');

plot(leads,r_XGB, ...
    '-p', ...
    'LineWidth',1.5, ...
    'MarkerSize',6, ...
    'MarkerFaceColor','auto');
ylabel('r')
title('Pearson Correlation Coefficient')
xlim([1 12])
ylim([-1 1])
xticks(1:12)
grid on
box on
legend( ...
    'MLR', ...
    'LSTM', ...
    'Random Forest', ...
    'XGBoost', ...
    'Location','southwest');

%% =====
% ROOT MEAN SQUARE ERROR
%% =====

subplot(3,1,2)
plot(leads,RMSE_MLR, ...
    '-o', ...

```

```

'LineWidth',1.5, ...
'MarkerSize',5, ...
'MarkerFaceColor','auto');
hold on
plot(leads,RMSE_LSTM, ...
'-s', ...
'LineWidth',1.5, ...
'MarkerSize',5, ...
'MarkerFaceColor','auto');
plot(leads,RMSE_RF, ...
'-d', ...
'LineWidth',1.5, ...
'MarkerSize',5, ...
'MarkerFaceColor','auto');
plot(leads,RMSE_XGB, ...
'-p', ...
'LineWidth',1.5, ...
'MarkerSize',6, ...
'MarkerFaceColor','auto');
ylabel('RMSE')
title('Root Mean Square Error')
xlim([1 12])
xticks(1:12)
grid on
box on
legend( ...
'MLR', ...
'LSTM', ...
'Random Forest', ...
'XGBoost', ...
'Location','northwest');

```

```

%% =====
% PEIRCE SKILL SCORE
%% =====
subplot(3,1,3)
plot(leads,PSS_MLR, ...
'-o', ...
'LineWidth',1.5, ...
'MarkerSize',5, ...
'MarkerFaceColor','auto');
hold on
plot(leads,PSS_LSTM, ...
'-s', ...
'LineWidth',1.5, ...
'MarkerSize',5, ...
'MarkerFaceColor','auto');

plot(leads,PSS_RF, ...
'-d', ...
'LineWidth',1.5, ...
'MarkerSize',5, ...
'MarkerFaceColor','auto');

plot(leads,PSS_XGB, ...
'-p', ...
'LineWidth',1.5, ...
'MarkerSize',6, ...

```

```

'MarkerFaceColor','auto');


xlabel('Lead Time (Month)')
ylabel('PSS')
title('Peirce Skill Score')
xlim([1 12])
ylim([-1 1])
xticks(1:12)
grid on
box on
legend( ...
    'MLR', ...
    'LSTM', ...
    'Random Forest', ...
    'XGBoost', ...
    'Location','southwest');




%% ----- MAIN TITLE -----
sgtitle( ...
    'Perbandingan Kinerja Model Prediksi ENSO', ...
    'FontWeight','bold');

%% ----- SAVE FIGURE -----
saveas(gcf,'Perbandingan_Model_ENSO.png');
savefig(gcf,'Perbandingan_Model_ENSO.fig');
fprintf('\nGrafik perbandingan berhasil dibuat.\n');
fprintf('Perbandingan_Model_ENSO.png berhasil disimpan.\n');
fprintf('Perbandingan_Model_ENSO.fig berhasil disimpan.\n');


```

Lampiran 5. Hasil Penelitian







Monthly ENSO Prediction Verification MLR




Monthly ENSO Prediction Verification LSTM




Monthly ENSO Prediction Verification Random Forest



Monthly ENSO Prediction Verification (XGBoost)



Perbandingan Kinerja Model Prediksi ENSO



Lampiran 6. Riwayat Hidup**A. Data Pribadi**

- 1. Nama : Zeruya Yudea Siagian
- 2. Tempat, Tanggal Lahir : Jakarta, 15 Agustus 2004
- 3. Alamat : Jakarta Timur
- 4. Kewarganegaraan : Indonesia

B. Riwayat Pendidikan

Tamat SMA tahun 2022 di SMA Negeri 115 Jakarta

C. Pekerjaan dan Riwayat Pekerjaan

-

D. Karya Ilmiah yang telah di publikasikan

-

E. Makalah pada Seminar/ Konferensi Ilmiah Nasional dan Internasional

-