


PENGEMBANGAN MODEL PREDIKSI *INDIAN OCEAN DIPOLE (IOD)* MENGUNAKAN MODEL LINEAR DAN NON-LINEAR



NATASYA IRENE POLY

H061 22 1073

PROGRAM STUDI GEOFISIKA

DEPARTEMEN GEOFISIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS HASANUDDIN

MAKASSAR

2026



**PENGEMBANGAN MODEL PREDIKSI *INDIAN OCEAN DIPOLE* (IOD)
MENGUNAKAN MODEL LINEAR DAN NON-LINEAR**

NATASYA IRENE POLY

H061 22 1073



**PROGRAM STUDI GEOFISIKA
DEPARTEMEN GEOFISIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PENGEMBANGAN MODEL PREDIKSI *INDIAN OCEAN DIPOLE* (IOD)
MENGUNAKAN MODEL LINEAR DAN NON-LINEAR**

NATASYA IRENE POLY

H061 22 1073

Skripsi

Sebagai salah satu syarat untuk mencapai gelar sarjana

Program Studi Geofisika

Pada

**DEPARTEMEN GEOFISIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

LEMBAR PENGESAHAN UJIAN AKHIR

iv

LEMBAR PENGESAHAN UJIAN AKHIR

PENGEMBANGAN MODEL PREDIKSI *INDIAN OCEAN DIPOLE* (IOD)
MENGUNAKAN MODEL LINEAR DAN NON-LINEAR

NATASYA IRENE POLY
H061 22 1073


Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana pada tanggal 14 Juli
2026 dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Geofisika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:
Pembimbing Tugas Akhir,



Prof. Dr. Halmar Halide, M.Sc.
NIP. 196303151987101001

Mengetahui:
Ketua Departemen Geofisika,



Dr. Erian, M.Si.
NIP. 196709032001121001

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

v

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "Pengembangan model prediksi *Indian Ocean Dipole* (IOD) menggunakan model linear dan non-linear" adalah benar karya saya dengan arahan dari pembimbing Prof. Dr. Halmar Halide, M.Sc sebagai pembimbing utama. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 14 Juli 2026



Natasya Irene Poly
H061221073

UCAPAN TERIMA KASIH

Penulis menyampaikan penghargaan dan ucapan terima kasih yang sebesar-besarnya kepada berbagai pihak yang telah memberikan dukungan, bimbingan, dan bantuan selama proses perkuliahan hingga penyusunan skripsi ini.

1. Ucapan terima kasih ditujukan kepada **Prof. Dr. Halmar Halide, M.Sc.**, selaku pembimbing utama, yang telah memberikan arahan dan bimbingan selama pelaksanaan penelitian dan penyusunan skripsi
2. Ucapan terima kasih **Prof. Dr. Eng. H. Amiruddin, S.Si., M.Si, dan Dr. Muhammad Hamzah, S.Si., M.T.**, selaku penguji, yang telah memberikan saran dan koreksi terhadap skripsi ini serta **Dr. Muhammad Alimuddin Hamzah Assegaf, M.Eng**, selaku Kepala Departemen Geofisika, atas dukungan yang diberikan selama penulis menempuh pendidikan.
3. **Prof. Dr. Samsu Arif, M.Si.**, selaku Pembimbing Akademik, terima kasih atas arahan dan bimbingan yang telah diberikan selama penulis menjalani masa perkuliahan hingga menyelesaikan pendidikan.
4. Ucapan terima kasih juga ditujukan kepada **seluruh dosen dan staf Departemen Geofisika** atas ilmu, bimbingan, dan bantuan administrasi yang telah diberikan selama masa perkuliahan.
5. Untuk diri sendiri, **Natasya Irene Poly**, yang telah berusaha untuk tetap bertahan dan menyelesaikan setiap proses selama masa perkuliahan hingga penyusunan skripsi ini. Terima kasih telah tetap melangkah meskipun perjalanan ini tidak selalu mudah. Terima kasih telah bertahan di tengah rasa lelah, keraguan, tekanan, dan berbagai keadaan yang sempat membuat penulis ingin menyerah. Terima kasih karena tetap mencoba setiap kali merasa tidak mampu dan terus menyelesaikan apa yang telah dimulai hingga akhirnya sampai pada tahap ini. Berbagai tantangan, rasa lelah, dan proses yang telah dilalui menjadi bagian dari perjalanan yang memberikan banyak pelajaran dan pengalaman. Terima kasih telah bertahan sejauh ini dan tidak benar-benar menyerah. Semoga pencapaian ini menjadi pengingat bahwa setiap usaha yang telah dilakukan memiliki arti dan bahwa diri ini mampu melewati berbagai hal yang sebelumnya dianggap tidak mungkin untuk dilalui.
6. **Mama, Bapak, dan Adik**, terima kasih atas doa, kasih sayang, perhatian, dan dukungan yang selalu diberikan selama penulis menjalani perkuliahan hingga menyelesaikan skripsi ini. Terima kasih karena selalu ada dan terus memberikan semangat ketika penulis menghadapi berbagai kesulitan selama proses perkuliahan dan penyusunan skripsi. Kesabaran, pengorbanan, dan dukungan yang diberikan selama ini menjadi kekuatan bagi penulis untuk terus berusaha dan menyelesaikan pendidikan hingga tahap akhir. Penulis menyadari bahwa sampai pada titik ini bukanlah hasil dari usaha penulis sendiri, melainkan juga berkat

doa, dukungan, dan pengorbanan keluarga yang selalu menyertai setiap proses yang dijalani.

7. **Zeruya Yudea Siagian**, yang telah menjadi teman seperjuangan penulis sejak awal menjadi mahasiswa hingga akhirnya sampai pada tahap penyusunan skripsi. Terima kasih sudah menemani perjalanan perkuliahan sejak masa-masa menjadi mahasiswa baru, menjalani berbagai tugas dan kesibukan, hingga sama-sama berusaha menyelesaikan skripsi. Hampir semua hal selama masa kuliah kita lalui bersama, mulai dari mengikuti perkuliahan, mengerjakan tugas, menghadapi berbagai kesibukan, hingga melewati proses penyusunan skripsi. Banyak suka dan duka yang telah kita lewati bersama, mulai dari hal-hal sederhana yang bisa ditertawakan hingga masa-masa sulit yang harus dilewati dengan saling menguatkan. Terima kasih untuk semua cerita, kebersamaan, bantuan, dukungan, dan semangat yang selama ini diberikan. Kehadiranmu sebagai teman seperjuangan membuat perjalanan kuliah ini terasa lebih ringan dan tentunya menjadi bagian yang tidak terlupakan dari perjalanan penulis. Teman-teman penulis, **Afrildieztha Bandaso, Elma Paembonan, Gabrella Anjelina, Tiara Saputri, Musdalipa, Baso Riswanto, Cut Mutia, Muhammad Nur Bashira, dan Nadia Idris Riztiani**, terima kasih atas kebersamaan, bantuan, dan dukungan yang telah diberikan selama masa perkuliahan hingga proses penyusunan skripsi. **Kak Muhlis dan Kak Sri**, terima kasih atas bantuan dan dukungan yang telah diberikan selama proses penyusunan skripsi.
8. Rekan-rekan **Geofisika Angkatan 2022**, yang telah menjadi teman seperjuangan selama menjalani perkuliahan. Terima kasih atas kebersamaan, kerja sama, dukungan, dan semangat yang telah diberikan selama masa studi. Berbagai pengalaman, cerita, tantangan, dan proses yang telah kita lalui bersama menjadi bagian yang berarti dalam perjalanan penulis selama menempuh pendidikan di Geofisika Universitas Hasanuddin. Terima kasih telah menjadi bagian dari perjalanan ini dan telah menciptakan begitu banyak kenangan selama masa perkuliahan.
9. **EVOS Esports**, terima kasih telah menjadi salah satu hiburan yang menemani penulis di tengah kesibukan perkuliahan dan proses penyusunan skripsi. Terima kasih untuk setiap pertandingan, kemenangan, kekalahan, dan berbagai momen yang menjadi hiburan ketika penulis merasa lelah atau membutuhkan waktu untuk beristirahat sejenak. Menonton pertandingan EVOS menjadi salah satu hal sederhana yang membuat masa perkuliahan terasa lebih menyenangkan. **EVOS ROARRR 🐾**

10. **Cerita-cerita AU (*Alternate Universe*)**, terima kasih telah menjadi salah satu hiburan di sela-sela kesibukan perkuliahan dan proses penyusunan skripsi. Terima kasih untuk cerita-cerita yang sering kali membuat penulis tersenyum sendiri, ikut terbawa suasana, dan sejenak melupakan berbagai kesibukan yang sedang dihadapi. Bahkan, ada kalanya cerita yang dibaca terasa begitu nyata sampai penulis lupa bahwa semuanya hanyalah cerita fiksi. Membaca AU menjadi salah satu hal sederhana yang dapat membuat penulis merasa senang dan beristirahat sejenak dari berbagai hal yang melelahkan selama masa perkuliahan. Terima kasih telah menjadi bagian kecil yang ikut menemani penulis sampai pada tahap ini.

Penulis menyadari bahwa karya ini masih memiliki kekurangan, sehingga setiap kritik dan saran akan sangat berharga bagi perbaikan karya ini.

Penulis,

Natasya Irene Poly
H061221073

ABSTRAK

NATASYA IRENE POLY. **Pengembangan model prediksi *Indian Ocean Dipole* (IOD) menggunakan model linear dan non-linear** (dibimbing oleh Prof. Dr. Halmar Halide, M.Sc).

Latar Belakang. *Indian Ocean Dipole* (IOD) merupakan fenomena variabilitas iklim antar-tahunan di Samudera Hindia yang berpengaruh terhadap pola curah hujan dan kondisi iklim di Indonesia, sehingga kemampuan prediksi yang akurat menjadi penting dalam mendukung upaya mitigasi risiko hidrometeorologi.

Tujuan. Penelitian ini bertujuan mengimplementasikan dan membandingkan kinerja model linear dan non-linear dalam memprediksi indeks *Indian Ocean Dipole* (IOD) pada *lead time* 1-12 bulan. **Metode.** Penelitian ini menggunakan data bulanan *Dipole Mode Index* (DMI) dan *Niño 3.4* periode 1870-2025. Pemodelan dilakukan menggunakan *Multiple Linear Regression* (MLR), *Random Forest*, *Extreme Gradient Boosting* (XGBoost), dan *Long Short-Term Memory* (LSTM). Kinerja model dievaluasi menggunakan Korelasi Pearson (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS) pada *lead time* 1-12 bulan.

Hasil. Hasil penelitian menunjukkan bahwa seluruh model memiliki keterampilan prediksi yang sangat baik pada *lead time* 1 bulan. Model MLR memberikan performa terbaik dengan nilai Korelasi Pearson (r) sebesar 0,97398, RMSE sebesar 0,070657, dan PSS sebesar 0,88194. Seiring bertambahnya *lead time*, keterampilan prediksi seluruh model cenderung menurun, ditunjukkan oleh penurunan nilai Korelasi Pearson (r) dan PSS serta peningkatan nilai RMSE. Meskipun demikian, MLR tetap menunjukkan performa yang paling konsisten pada sebagian besar *lead time*. **Kesimpulan.** Model *Multiple Linear Regression* (MLR) merupakan model terbaik dalam penelitian ini karena menghasilkan nilai Korelasi Pearson (r) yang relatif lebih tinggi, nilai RMSE yang paling rendah, serta nilai PSS yang lebih baik dibandingkan model lainnya. Hasil penelitian menunjukkan bahwa prediksi indeks IOD memiliki tingkat akurasi yang lebih baik pada *lead time* jangka pendek, terutama hingga sekitar 3-4 bulan ke depan.

Kata kunci: *Indian Ocean Dipole* (IOD), *Dipole Mode Index* (DMI), *Niño 3.4*, *Multiple Linear Regression* (MLR), *Extreme Gradient Boosting* (XGBoost), *Random Forest*, dan *Long Short-Term Memory* (LSTM).

ABSTRACT

NATASYA IRENE POLY. **Development of an Indian Ocean Dipole (IOD) prediction model using linear and non-linear models** (supervised by Prof. Dr. Halmar Halide, M.Sc.).

Background. The Indian Ocean Dipole (IOD) is an interannual climate variability phenomenon in the Indian Ocean that significantly influences rainfall patterns and climatic conditions across Indonesia. Therefore, accurate prediction of the IOD is essential for supporting hydrometeorological risk mitigation efforts. **Objective.** This study aims to implement and compare the performance of linear and non-linear models in predicting the Indian Ocean Dipole (IOD) index at lead times ranging from 1 to 12 months. **Methods.** Monthly Dipole Mode Index (DMI) and Niño 3.4 data spanning the period from 1870 to 2025 were used in this study. Prediction models were developed using Multiple Linear Regression (MLR), Random Forest, Extreme Gradient Boosting (XGBoost), and Long Short-Term Memory (LSTM). Model performance was evaluated using the Pearson correlation (r), Root Mean Square Error (RMSE), and Peirce Skill Score (PSS) for lead times of 1 to 12 months. **Results.** The results indicate that all models achieved excellent predictive performance at the 1-month lead time. The MLR model demonstrated the best overall performance, with a Pearson correlation (r) of 0.97398, an RMSE of 0.070657, and a PSS of 0.88194. As the lead time increased, the predictive skill of all models gradually declined, as reflected by decreasing Pearson correlation (r) and PSS values, along with increasing RMSE values. Nevertheless, the MLR model showed the most consistent performance across most lead times. **Conclusion.** Multiple Linear Regression (MLR) was identified as the best-performing model in this study, as it generally produced higher Pearson correlation (r), lower RMSE values, and relatively better PSS values than the other models. The findings indicate that IOD index predictions are more accurate at short lead times, particularly up to approximately 3-4 months ahead.

Keywords: Indian Ocean Dipole (IOD), Dipole Mode Index (DMI), Niño 3.4, Multiple Linear Regression (MLR), Extreme Gradient Boosting (XGBoost), Random Forest, and Long Short-Term Memory (LSTM).

DAFTAR ISI

LEMBAR PENGESAHAN	iv
PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA	v
UCAPAN TERIMA KASIH	vi
ABSTRAK.....	ix
ABSTRACT.....	x
DAFTAR ISI	xi
DAFTAR TABEL	xiii
DAFTAR GAMBAR	xiv
DAFTAR LAMPIRAN.....	xv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Tujuan dan Manfaat.....	3
1.2.1 Tujuan	3
1.2.2 Manfaat	3
1.3 Landasan Teori	3
1.3.1 Fenomena <i>Indian Ocean Dipole</i> (IOD)	3
1.3.2 <i>Multiple Linear Regression</i> (MLR)	5
1.3.3 <i>Extreme Gradient Boosting</i> (XGBoost).....	6
1.3.4 <i>Random Forest</i>	7
1.3.5 <i>Long Short-Term Memory</i> (LSTM).....	9
1.3.6 Evaluasi Model.....	10
BAB II METODE PENELITIAN.....	13
2.1 Data Penelitian	13
2.2 Prosedur Penelitian	13
2.3 Prosedur Model Prediksi	14
2.3.1 Penerapan <i>Multiple Linear Regression</i> (MLR)	14
2.3.2 Penerapan <i>Extreme Gradient Boosting</i> (XGBoost).....	14
2.3.3 Penerapan <i>Random Forest</i>	14
2.3.4 Penerapan <i>Long Short-Term Memory</i> (LSTM)	15
2.4 Evaluasi dan Verifikasi Model.....	15
2.5 Bagan Alir	16
BAB III HASIL DAN PEMBAHASAN	17

3.1 Hasil.....	17
3.2 Pembahasan	22
BAB IV KESIMPULAN	25
4.1 Kesimpulan.....	25
4.2 Saran	25
DAFTAR PUSTAKA.....	26
LAMPIRAN	30

DAFTAR TABEL

Tabel 1. Korelasi Pearson (r) dari MLR, XGBoost, <i>Random Forest</i> , dan LSTM	21
Tabel 2. RMSE dari MLR, XGBoost, <i>Random Forest</i> , dan LSTM	22
Tabel 3. PSS dari MLR, XGBoost, <i>Random Forest</i> , dan LSTM	22

DAFTAR GAMBAR

Gambar 1. Fase Positif <i>Indian Ocean Dipole</i> (IOD)	5
Gambar 2. Bagan Alir	16
Gambar 3. <i>Time Series</i> , (a) <i>Multiple Linear Regression</i> , (b) <i>Extreme Gradient Boosting</i> , (c) <i>Random Forest</i> , (d) <i>Long Short-Term Memory</i>	18
Gambar 4. Evaluasi Korelasi Pearson (r), RMSE, & PSS, (a) <i>Multiple Linear Regression</i> , (b) <i>Extreme Gradient Boosting</i> , (c) <i>Random Forest</i> , (d) <i>Long Short-Term Memory</i>	20
Gambar 5. Perbandingan Kinerja Model	21

DAFTAR LAMPIRAN

Lampiran 1. Data Penelitian.....	30
Lampiran 2. Program Matlab <i>Time Series</i>	30
Lampiran 3. Program Matlab Korelasi Pearson (r), <i>Root Mean Square Error</i> (RMSE), dan <i>Peirce Skill Score</i> (PSS).....	38
Lampiran 4. Program Matlab Perbandingan Kinerja Model.....	57
Lampiran 5. Hasil Penelitian	59
Lampiran 6. Daftar Riwayat Hidup	62

BAB I PENDAHULUAN

1.1 Latar Belakang

Samudera Hindia merupakan salah satu wilayah perairan terbesar yang berperan penting terhadap karakteristik perairan Indonesia, terutama di bagian barat Sumatera. Kondisi tersebut menyebabkan perairan barat Sumatera memiliki karakteristik yang kompleks dan beragam. Kompleksitas ini berkaitan dengan adanya pengaruh massa air yang berasal dari berbagai wilayah perairan di sekitarnya, seperti Laut Arab, Laut Persia, Laut Andaman, dan Teluk Bengal. Selain itu, masukan air dari sejumlah sungai besar turut memberikan kontribusi terhadap variasi karakteristik oseanografi, terutama suhu dan salinitas. Variabilitas kondisi tersebut juga dipengaruhi oleh fenomena iklim antar-tahunan *Indian Ocean Dipole* (IOD) yang dapat menyebabkan perubahan pola curah hujan, baik berupa peningkatan maupun penurunan intensitasnya, sehingga berpengaruh terhadap kondisi suhu dan salinitas perairan (Ramadhanty et al., 2021).

Indian Ocean Dipole (IOD) merupakan salah satu mode variabilitas iklim utama di wilayah tropis Samudera Hindia. Fenomena ini umumnya mulai berkembang pada akhir musim semi, mencapai intensitas maksimum pada musim gugur, khususnya pada periode September-November (SON), kemudian mengalami pelemahan. Kejadian IOD dicirikan oleh adanya perbedaan anomali suhu permukaan laut antara wilayah barat dan timur Samudera Hindia tropis. Identifikasi fenomena IOD dilakukan menggunakan indeks yang merepresentasikan gradien timur-barat anomali suhu permukaan laut antara wilayah Samudera Hindia bagian barat di sekitar ekuator dan wilayah Samudera Hindia bagian tenggara. IOD positif ditandai oleh kondisi suhu permukaan laut yang lebih hangat dari normal di bagian barat Samudera Hindia dan lebih dingin di bagian timur, khususnya di sekitar perairan lepas pantai Sumatera. Sebaliknya, IOD negatif ditandai oleh anomali suhu permukaan laut yang lebih rendah di bagian barat dan anomali suhu permukaan laut yang lebih tinggi di bagian timur Samudera Hindia.

Fenomena IOD memiliki pengaruh terhadap kondisi iklim di berbagai wilayah melalui interaksi antara proses atmosfer dan laut. Variabilitas IOD diketahui berkaitan dengan perubahan pola monsun musim panas di India serta memengaruhi pola curah hujan di Sri Lanka, Australia, Amerika Selatan, dan Afrika Timur. Selain itu, fenomena ini turut memberikan pengaruh terhadap kondisi iklim di Asia Timur dan Eropa. Dampak IOD tidak terbatas pada aspek lingkungan, tetapi juga dapat memengaruhi kondisi sosial dan ekonomi masyarakat, baik di negara-negara yang berada di sekitar Samudera Hindia maupun di wilayah lainnya yang terdampak oleh variabilitas iklim tersebut. Oleh karena itu, kemampuan dalam memprediksi indeks IOD secara akurat menjadi

penting untuk mendukung upaya antisipasi terhadap berbagai dampak yang ditimbulkannya. Namun, prediksi IOD dalam jangka waktu yang panjang masih menjadi tantangan. Model dinamis yang berkembang saat ini masih memiliki keterbatasan dalam memprediksi IOD dengan waktu prakiraan lebih dari tiga bulan. Meskipun sejumlah penelitian menunjukkan bahwa prediksi IOD hingga tujuh bulan sebelumnya secara teoritis memungkinkan, diperlukan identifikasi indikator awal yang lebih representatif untuk meningkatkan kemampuan prediksi perkembangan IOD. Sejalan dengan perkembangan teknologi komputasi, penerapan metode *machine learning* dan *deep learning* dengan struktur model yang lebih kompleks semakin banyak digunakan dalam upaya meningkatkan kemampuan prediksi indeks IOD (Dipo et al., 2011; Liu et al., 2021; Ratnam et al., 2025).

Penelitian oleh Ratnam et al. (2020) mengembangkan model *Artificial Neural Network* (ANN) untuk memprediksi *Indian Ocean Dipole* (IOD) menggunakan variabel *sea surface temperature* (SST) serta anomali *geopotential height* pada lapisan 850 hPa dan 200 hPa. Hasil penelitian menunjukkan bahwa model ANN memiliki kemampuan prediksi yang lebih baik dibandingkan model *North American Multi-Model Ensemble* (NMME), yang ditunjukkan oleh nilai ACC yang lebih tinggi dan *Root Mean Square Error* (RMSE) yang lebih rendah. Selain itu, model ANN juga mampu memprediksi fase kejadian IOD ekstrem dengan tingkat keberhasilan yang tinggi. Temuan tersebut menunjukkan bahwa pendekatan *machine learning* memiliki potensi yang baik dalam pengembangan sistem prediksi fenomena iklim, khususnya *Indian Ocean Dipole* (IOD).

Selain itu, Liu et al. (2021) menerapkan metode *Deep Learning* berbasis *Convolutional Neural Network* (CNN) untuk memprediksi *Indian Ocean Dipole* (IOD) menggunakan data anomali suhu permukaan laut (*Sea Surface Temperature Anomalies/SSTA*) di Samudera Hindia. Hasil penelitian menunjukkan bahwa model CNN memiliki kemampuan prediksi yang baik serta mampu meningkatkan keterampilan prediksi IOD dibandingkan metode prediksi konvensional. Selain menghasilkan tingkat akurasi prediksi yang tinggi, model CNN juga mampu mengidentifikasi wilayah-wilayah prekursor yang berperan dalam pembentukan kejadian IOD. Penelitian tersebut menyimpulkan bahwa CNN merupakan metode yang efektif untuk prediksi IOD dan berpotensi meningkatkan pemahaman terhadap mekanisme fisik yang memengaruhi perkembangan fenomena IOD. Berdasarkan uraian tersebut, penelitian ini dilakukan untuk membandingkan dan mengevaluasi model *Multiple Linear Regression* (MLR), *Random Forest*, *Extreme Gradient Boosting* (XGBoost), dan *Long Short-Term Memory* (LSTM) dalam memprediksi *Indian Ocean Dipole* (IOD). Evaluasi kinerja model dilakukan menggunakan Korelasi Pearson (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS).

1.2 Tujuan dan Manfaat

1.2.1 Tujuan

Tujuan dari penelitian ini adalah:

1. Mengimplementasikan model *Multiple Linear Regression* (MLR), *Long Short-Term Memory* (LSTM), *Random Forest*, dan *Extreme Gradient Boosting* (XGBoost) untuk memprediksi *Indian Ocean Dipole* (IOD).
2. Mengevaluasi kinerja masing-masing model menggunakan Korelasi Pearson (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS), serta melakukan pemilihan model terbaik berdasarkan hasil evaluasi tersebut.

1.2.2 Manfaat

Manfaat dari penelitian ini adalah:

1. Memberikan informasi mengenai kemampuan prediksi *fenomena Indian Ocean Dipole* (IOD) pada berbagai *lead time*.
2. Menjadi referensi bagi penelitian selanjutnya dalam pengembangan model prediksi *Indian Ocean Dipole* (IOD) menggunakan pendekatan model linear dan non-linear.

1.3 Landasan Teori

1.3.1 Fenomena *Indian Ocean Dipole* (IOD)

Fenomena *Indian Ocean Dipole* (IOD) merupakan salah satu bentuk variabilitas iklim yang terjadi di Samudera Hindia dan ditandai oleh adanya perbedaan suhu permukaan laut antara wilayah bagian barat dan timur Samudera Hindia (Krisnanto et al., 2024). IOD merupakan mode variabilitas iklim antar-tahunan yang terbentuk melalui interaksi antara atmosfer dan laut serta memiliki pengaruh yang besar terhadap perubahan curah hujan dan kejadian ekstrem di negara-negara yang berada di sekitar Samudera Hindia. Oleh karena itu, peningkatan kemampuan dalam memprediksi variabilitas IOD, terutama dalam kondisi pemanasan global, menjadi salah satu aspek penting dalam kajian ilmu iklim. Fenomena IOD pertama kali diperkenalkan oleh Saji et al. (1999) sebagai pola perubahan suhu permukaan laut antara wilayah tropis Samudera Hindia bagian barat dan timur. Karakteristik IOD dapat diketahui melalui perbedaan suhu permukaan laut antara wilayah timur yang berada pada 90°BT-110°BT dan 10°LS-ekuator dengan wilayah barat pada 50°BT-70°BT dan 10°LS-10°LU. Perbedaan tersebut dinyatakan melalui *Dipole Mode Index* (DMI) yang digunakan sebagai indikator untuk menggambarkan intensitas fenomena IOD (Kämpf, 2024).


Dipole Mode Index (DMI) merupakan indeks yang digunakan untuk mengidentifikasi keberadaan dan fase fenomena IOD. Indeks ini dihitung berdasarkan perbedaan rata-rata anomali suhu permukaan laut antara wilayah tropis bagian barat dan wilayah tropis bagian tenggara Samudera Hindia. Wilayah

barat berada pada 50°BT – 70°BT dan 10°LS – 10°LU , sedangkan wilayah tenggara berada pada 90°BT – 110°BT dan 10°LS –ekuator. Data yang digunakan dalam perhitungan DMI memiliki resolusi temporal bulanan. Nilai DMI selanjutnya dapat digunakan untuk menentukan fase IOD, yaitu fase positif, fase negatif, atau kondisi netral (Gifari, 2020).

Fenomena IOD terdiri atas tiga fase, yaitu fase netral, fase positif, dan fase negatif. Pada fase netral, aliran massa air hangat dari wilayah kolam hangat Samudera Pasifik bagian barat menuju Samudera Hindia melalui wilayah perairan Indonesia berperan dalam mempertahankan kondisi perairan yang relatif hangat pada lapisan atas laut. Kondisi tersebut menyebabkan suhu permukaan laut di wilayah khatulistiwa bagian timur Samudera Hindia tetap relatif tinggi. Pemanasan di wilayah tersebut menyebabkan udara bergerak naik, kemudian mengalami penurunan di bagian barat cekungan Samudera Hindia. Pada lapisan permukaan, angin timuran bertiup relatif lemah di sepanjang wilayah khatulistiwa. Kondisi angin yang relatif lemah tersebut berkaitan dengan perbedaan suhu permukaan laut dan kedalaman termoklin antara bagian barat dan timur Samudera Hindia yang relatif kecil. Kondisi tersebut menunjukkan keadaan yang mendekati normal sehingga tidak menimbulkan anomali iklim yang signifikan.

Pada fase IOD negatif, angin di sepanjang wilayah khatulistiwa menguat dan mendorong perpindahan massa air hangat menuju bagian timur Samudera Hindia, khususnya di sekitar perairan Indonesia dan Australia. Kondisi tersebut menyebabkan akumulasi massa air hangat di wilayah timur sehingga kedalaman termoklin mengalami peningkatan. Sebaliknya, termoklin di bagian barat Samudera Hindia menjadi lebih dangkal. Perubahan kondisi tersebut menyebabkan perbedaan suhu permukaan laut antara bagian timur dan barat Samudera Hindia semakin besar. Akibatnya, wilayah timur Samudera Hindia memiliki suhu permukaan laut yang lebih tinggi dibandingkan kondisi normal, sedangkan wilayah barat mengalami suhu permukaan laut yang relatif lebih rendah dibandingkan kondisi pada fase netral.

Sebaliknya, fase IOD positif ditandai oleh terjadinya pendinginan suhu permukaan laut secara tidak normal di wilayah tenggara Samudera Hindia tropis dan pemanasan di bagian barat serta wilayah tengah Samudera Hindia tropis. Pada fase ini, angin di sepanjang wilayah khatulistiwa mengalami perubahan sehingga massa air hangat terdorong bergerak ke arah barat menuju wilayah sekitar Afrika. Perubahan pola angin tersebut menyebabkan terjadinya perubahan kedalaman termoklin. Di bagian timur Samudera Hindia, termoklin mengalami kenaikan secara tidak normal, sedangkan di bagian tengah wilayah khatulistiwa termoklin mengalami pendalaman. Kondisi tersebut selanjutnya berkontribusi terhadap terbentuknya perbedaan suhu permukaan laut antara wilayah barat dan timur Samudera Hindia (Polonsky & Torbinsky, 2021).



Gambar 1. Fase Positif *Indian Ocean Dipole* (IOD)

IOD merupakan fenomena yang melibatkan interaksi antara laut dan atmosfer dalam skala cekungan Samudera Hindia serta dapat memberikan pengaruh terhadap kondisi atmosfer, daratan, dan laut di berbagai wilayah dunia. Variabilitas IOD, misalnya, memiliki keterkaitan dengan perubahan pola monsun musim panas di India. Selain itu, anomali curah hujan yang berkaitan dengan fenomena IOD telah dilaporkan terjadi di berbagai wilayah di beberapa benua. Variabilitas IOD juga berkaitan dengan perubahan tinggi gelombang signifikan di wilayah utara Samudera Hindia khatulistiwa. Pada kondisi tertentu, IOD dapat berkontribusi terhadap terjadinya kekeringan yang parah di Australia serta peningkatan kejadian kebakaran hutan di Australia dan Indonesia. Fenomena ini juga memberikan kontribusi terhadap variabilitas suhu permukaan laut di Samudera Hindia, dengan IOD menyumbang sekitar 12% terhadap variabilitas tersebut. Berbagai dampak lingkungan dan sosial ekonomi yang berkaitan dengan IOD menunjukkan bahwa pengaruh fenomena ini dapat dirasakan pada wilayah yang luas. Sejumlah kejadian lingkungan dan kesehatan, seperti pemutihan terumbu karang, peningkatan populasi belalang, dan wabah malaria di Afrika, juga dikaitkan dengan kondisi iklim yang tidak normal selama kejadian IOD (Shi & Wang, 2022).

1.3.2 *Multiple Linear Regression* (MLR)

Multiple Linear Regression (MLR) atau regresi linear berganda merupakan salah satu metode statistik yang digunakan untuk menganalisis dan memperkirakan hubungan antara satu variabel dependen dengan dua atau lebih variabel independen. Metode ini digunakan untuk membentuk hubungan linear antara variabel prediktor sebagai variabel independen dan variabel respons sebagai variabel dependen (Abdelhafez et al., 2025). MLR dapat diterapkan pada permasalahan prediksi ketika variabel yang menjadi hasil atau target berbentuk numerik dan variabel prediktornya juga berupa data numerik. Dengan demikian, metode ini dapat digunakan untuk mengetahui hubungan antara variabel dependen dengan beberapa variabel independen yang diduga memengaruhinya (Manurung, 2021). Secara matematis *Multiple Linear Regression* ditunjukkan pada persamaan berikut:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon \quad 1.1$$

Pada persamaan regresi linear berganda, Y merupakan variabel dependen atau variabel yang menjadi target prediksi, sedangkan $X_1, X_2, \dots, X_n$ merupakan variabel independen yang digunakan sebagai prediktor dalam menjelaskan perubahan nilai Y . Parameter β_0 merupakan intersep atau konstanta yang menunjukkan nilai Y ketika seluruh variabel independen bernilai nol. Sementara itu, $\beta_1, \beta_2, \dots, \beta_n$ merupakan koefisien regresi yang menunjukkan besarnya perubahan pada variabel dependen akibat perubahan masing-masing variabel independen dengan variabel independen lainnya dianggap tetap. Adapun ε (*error term*) merupakan komponen kesalahan yang menggambarkan selisih antara nilai aktual dan nilai yang diperkirakan oleh model. Komponen tersebut juga merepresentasikan variasi pada variabel dependen yang tidak dapat dijelaskan oleh variabel independen yang digunakan dalam model (Santoso & Nursiaga, 2026).

MLR memiliki beberapa keunggulan dalam penerapannya sebagai metode prediksi. Salah satunya adalah kemampuan menghasilkan proses peramalan dengan waktu komputasi yang relatif singkat serta hasil yang baik. Oleh karena itu, MLR telah banyak diterapkan dalam berbagai penelitian yang berkaitan dengan peramalan dan prediksi (Nurdin et al., 2022). Selain itu, MLR mampu mengidentifikasi dan mengekstraksi pola tertentu yang terdapat dalam data sehingga dapat digunakan untuk melakukan generalisasi terhadap data. Metode ini juga dapat digunakan untuk memperoleh informasi dari data yang memiliki tingkat ketidakpastian serta mendukung proses perhitungan secara paralel sehingga waktu pemrosesan dapat menjadi lebih efisien (Amrin, 2016).

1.3.3 *Extreme Gradient Boosting (XGBoost)*

XGBoost merupakan singkatan dari *Extreme Gradient Boosting*, yaitu salah satu algoritma *machine learning* yang dikembangkan dari metode *Gradient Boosting*. Metode *Gradient Boosting* pertama kali diperkenalkan oleh Friedman (2001), sedangkan Chen dan Guestrin (2016) mengembangkan XGBoost sebagai proyek *open source* yang dirancang untuk menghasilkan sistem *machine learning* yang efisien, cepat, dan mampu menangani data dalam skala besar (Rizky et al., 2022). XGBoost dapat digunakan untuk menyelesaikan permasalahan prediksi maupun klasifikasi dengan memanfaatkan struktur *decision tree*. Algoritma ini dirancang menggunakan teknik optimasi yang memungkinkan proses komputasi berlangsung secara efisien, bahkan dapat mencapai kecepatan pemrosesan yang lebih tinggi dibandingkan metode *Gradient Boosting Machine* (GBM) konvensional. Meskipun demikian, kinerja dan akurasi model XGBoost sangat dipengaruhi oleh pemilihan serta pengaturan parameter yang digunakan selama proses pelatihan (Givari et al., 2022).

XGBoost merupakan pengembangan dari metode *Gradient Boosting* yang menggunakan pendekatan *ensemble* dengan menggabungkan sejumlah

decision tree secara bertahap untuk membentuk model prediksi yang lebih kuat. Setiap *tree* dibangun secara berurutan dengan memanfaatkan kesalahan prediksi atau *residual* yang dihasilkan oleh model sebelumnya. Dengan pendekatan tersebut, model secara bertahap memperbaiki kesalahan prediksi pada tahap sebelumnya sehingga menghasilkan model akhir dengan kemampuan prediksi yang lebih baik. Selain itu, XGBoost dirancang untuk menghasilkan waktu komputasi yang relatif efisien sehingga dapat diterapkan pada pengolahan data dalam jumlah besar (Nugraha & Irawan, 2023). Secara matematis *Extreme Gradient Boosting* (XGBoost) ditunjukkan pada persamaan berikut:

$$\hat{y}_i = \sum_{m=1}^M f_m(x_i) \quad 1.2$$

Di mana, m menunjukkan jumlah pohon, x_i menunjukkan fitur input ke- i , f_m adalah pohon independen ke- m , dan $\hat{y}_i$ menunjukkan *output* yang sesuai dari input ke- i (Amiri et al., 2025).

Dalam proses pembentukan pohon regresi, XGBoost menerapkan pengendalian kompleksitas model melalui struktur pohon yang lebih teratur. Pengendalian tersebut bertujuan untuk memperoleh model dengan kinerja yang baik sekaligus mengurangi risiko *overfitting* (Yulianti et al., 2022). Selain itu, XGBoost menerapkan teknik regularisasi L1 dan L2 yang berfungsi mengendalikan kompleksitas model dengan memberikan penalti terhadap parameter model yang terlalu kompleks. Penerapan regularisasi tersebut membantu membatasi kompleksitas pohon yang terbentuk sehingga model tidak terlalu menyesuaikan diri terhadap data pelatihan dan memiliki kemampuan generalisasi yang lebih baik terhadap data yang belum pernah digunakan dalam proses pelatihan (Ru et al., 2023).

1.3.4 Random Forest

Random Forest merupakan salah satu metode *machine learning* yang diperkenalkan oleh Leo Breiman pada tahun 2001. Metode ini terdiri atas sejumlah *decision tree* yang dibentuk dengan tingkat korelasi yang rendah melalui pemilihan fitur secara acak dan penerapan metode *bagging* (*Bootstrap Aggregating*). *Random Forest* banyak digunakan dalam proses klasifikasi maupun regresi karena mampu memberikan hasil prediksi yang baik. Selain memiliki mekanisme yang relatif sederhana, metode ini juga mampu mengolah data dengan dimensi yang tinggi dan jumlah data yang besar. Kemampuan tersebut menjadi salah satu keunggulan *Random Forest* dibandingkan dengan metode *machine learning* lainnya. Oleh karena itu, *Random Forest* banyak diterapkan sebagai salah satu metode yang efektif dalam berbagai permasalahan prediksi dan analisis data (Rizky & Andarsyah, 2023). Secara matematis *Random Forest* ditunjukkan pada persamaan berikut:

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M T_m(x) \quad 1.3$$

Dalam hal ini, T_m mewakili nilai yang diprediksi dari pohon ke- m untuk input x , dan hasil prediksi akhirnya adalah rata-rata dari nilai *output* semua pohon (Jiang et al., 2026).

Penerapan algoritma *Random Forest* dilakukan melalui beberapa tahapan. Tahap awal dilakukan dengan mengambil sejumlah sampel secara acak dari data asli menggunakan *bootstrap sampling* sehingga terbentuk beberapa subset data. Setiap subset tersebut kemudian digunakan untuk membangun sebuah pohon regresi dengan algoritma pohon keputusan. Pada setiap proses pemisahan simpul (*node splitting*), tidak seluruh fitur digunakan sebagai kandidat pemisahan. Sebagian fitur dipilih secara acak, kemudian fitur terbaik dari kumpulan tersebut digunakan untuk menentukan pemisahan simpul. Pembentukan pohon dilanjutkan hingga kriteria penghentian terpenuhi, seperti tercapainya kedalaman maksimum pohon atau jumlah sampel pada suatu simpul berada di bawah batas yang telah ditentukan. Setelah seluruh pohon terbentuk, data masukan baru diproses oleh masing-masing pohon keputusan untuk menghasilkan prediksi. Pada permasalahan regresi, hasil prediksi akhir diperoleh dari nilai rata-rata seluruh prediksi yang dihasilkan oleh pohon keputusan.

Keacakan yang menjadi karakteristik utama *Random Forest* diterapkan melalui dua mekanisme, yaitu keacakan sampel (*sample randomness*) dan keacakan fitur (*feature randomness*). Keacakan sampel diperoleh melalui *bootstrap sampling*, yaitu pengambilan sampel secara acak dengan pengembalian (*sampling with replacement*) dari data asli untuk membentuk beberapa subset. Dengan demikian, setiap pohon keputusan dibangun menggunakan kombinasi sampel yang berbeda. Sementara itu, keacakan fitur dilakukan dengan memilih sebagian fitur secara acak pada setiap proses pemisahan dalam pembentukan pohon keputusan. Penerapan kedua mekanisme tersebut dapat mengurangi korelasi antarpohon sehingga setiap pohon memberikan informasi yang relatif berbeda dalam membentuk prediksi. Selain itu, mekanisme tersebut dapat meningkatkan kemampuan generalisasi model terhadap data yang belum digunakan dalam proses pelatihan. Dengan menggabungkan keacakan sampel dan keacakan fitur, *Random Forest* mampu membentuk model prediksi yang kuat dan dapat diterapkan pada data dengan karakteristik kompleks, termasuk berbagai permasalahan regresi (Qiu et al., 2025).

Random Forest memiliki beberapa keunggulan, salah satunya adalah kemampuan dalam menangkap hubungan dan interaksi yang kompleks antarkomponen dalam data. Metode ini juga memiliki kemampuan untuk mengurangi risiko *overfitting* melalui penggabungan hasil prediksi dari sejumlah pohon keputusan. Selain itu, *Random Forest* mampu menghasilkan tingkat kesalahan yang relatif rendah dan memberikan kinerja yang baik dalam

permasalahan klasifikasi. Metode ini juga dapat mengolah data pelatihan dalam jumlah besar secara efisien serta dapat digunakan untuk memperkirakan nilai data yang hilang (Tantyoko et al., 2023).

1.3.5 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari *Recurrent Neural Network* (RNN) yang diperkenalkan oleh Hochreiter dan Schmidhuber untuk mengatasi keterbatasan RNN dalam mempelajari hubungan jangka panjang pada data berurutan. Pengembangan tersebut dilakukan dengan menambahkan mekanisme interaksi pada setiap unit LSTM sehingga informasi yang relevan dapat dipertahankan dalam proses pembelajaran (Hilmawan, 2022). RNN merupakan salah satu jenis *Artificial Neural Network* (ANN) yang dikembangkan dari konsep *feedforward neural network*. Berbeda dengan jaringan saraf *feedforward* yang memproses data secara satu arah, RNN melakukan pemrosesan secara berulang dengan mempertimbangkan informasi dari data sebelumnya. Mekanisme tersebut memungkinkan RNN digunakan untuk mengolah data sekuensial, termasuk data *time series*. Meskipun memiliki kemampuan yang lebih baik dalam mengolah data berurutan dibandingkan ANN konvensional, RNN memiliki keterbatasan dalam mempelajari ketergantungan jangka panjang akibat permasalahan *vanishing gradient*. LSTM dikembangkan untuk mengatasi permasalahan tersebut melalui penggunaan *cell state* yang berfungsi sebagai media penyimpanan informasi dalam jangka panjang. Arsitektur LSTM terdiri atas *input layer*, *hidden layer*, *cell state*, dan *output layer*. Selain itu, LSTM memiliki mekanisme gerbang yang mengatur proses penyimpanan, penghapusan, dan pembaruan informasi pada *cell state* (Budiprasetyo et al., 2023).

LSTM memiliki kemampuan dalam mempelajari pola yang kompleks pada data *time series* yang sulit direpresentasikan menggunakan metode regresi linear. Keunggulan utama LSTM dibandingkan RNN terletak pada kemampuannya dalam mempertahankan informasi dari data sebelumnya sehingga dapat mempelajari hubungan atau ketergantungan jangka panjang (*long-term dependency*). Kemampuan tersebut diperoleh melalui penggunaan *cell state* yang memungkinkan informasi penting diteruskan ke tahapan berikutnya. Dalam proses tersebut, LSTM memiliki tiga jenis gerbang utama, yaitu *forget gate*, *input gate*, dan *output gate*. *Forget gate* berfungsi menentukan informasi yang perlu dipertahankan atau dihapus dari *cell state*. *Input gate* berfungsi menentukan informasi baru yang akan dimasukkan dan digunakan untuk memperbarui *cell state*. Sementara itu, *output gate* menentukan informasi dari *cell state* yang akan diteruskan sebagai keluaran (*output*) pada tahap berikutnya (Lattifia et al., 2022). Dengan demikian, *input gate* dan *output gate* mengatur aliran informasi yang masuk dan keluar dari jaringan, sedangkan *forget gate* berperan dalam menghilangkan informasi yang dianggap kurang relevan. Kinerja model LSTM juga dipengaruhi oleh konfigurasi *hyperparameter* yang digunakan selama proses pelatihan. Pemilihan kombinasi *hyperparameter* yang kurang tepat dapat menyebabkan penurunan kemampuan model dalam

mempelajari pola data dan berdampak terhadap kinerja prediksi yang dihasilkan (Hawali & Walid, 2025). Secara matematis *Long Short-Term Memory* (LSTM) ditunjukkan pada persamaan berikut:

$$f_t = \sigma(W_f X_t + U_f h_{t-1} + b_f) \quad 1.4$$

$$i_t = \sigma(W_i X_t + U_i h_{t-1} + b_i) \quad 1.5$$

$$\tilde{c}_t = \tanh(W_c X_t + U_c h_{t-1} + b_c) \quad 1.6$$

$$O_t = \sigma(W_o X_t + U_o h_{t-1} + b_o) \quad 1.7$$

$$C_t = f_t \circ c_{t-1} + i_t \circ \tilde{c}_t \quad 1.8$$

$$h_t = O_t \circ \tanh(C_t) \quad 1.9$$

σ dan $\tanh$ masing-masing merupakan fungsi aktivasi sigmoid dan tangen hiperbolik. Simbol it , ot , ft , dan Ct secara berturut-turut menunjukkan gerbang masukan (*input gate*), gerbang keluaran (*output gate*), gerbang lupa (*forget gate*), dan status sel (*cell state*). Pada langkah waktu t , X_t menyatakan data masukan yang diteruskan ke lapisan tersembunyi, sedangkan h_{t-1} merupakan keluaran dari blok pada langkah waktu sebelumnya dan C_{t-1} menunjukkan memori sel dari blok sebelumnya. Matriks W dan U berfungsi sebagai matriks bobot, sementara b menyatakan vektor bias. Adapun operator ($\circ$) menunjukkan perkalian Hadamard, yaitu perkalian yang dilakukan secara elemen per elemen (Avoussou et al., 2026).

1.3.6 Evaluasi Model

Root Mean Square Error (RMSE) merupakan salah satu metrik yang digunakan untuk mengevaluasi tingkat kesalahan antara nilai yang dihasilkan oleh model dan nilai observasi. Metrik ini dapat digunakan untuk mengetahui tingkat kedekatan hasil prediksi terhadap data aktual serta mengukur besarnya kesalahan yang dihasilkan oleh model (Sulistiyono et al., 2023). RMSE banyak digunakan dalam evaluasi model statistik dan model prediksi karena mampu menunjukkan besarnya perbedaan antara nilai prediksi dan nilai observasi. Nilai RMSE yang semakin kecil menunjukkan bahwa kesalahan prediksi yang dihasilkan model semakin rendah sehingga kinerja model dalam menghasilkan prediksi semakin baik (Nurholipah et al., 2024).

RMSE juga telah banyak digunakan sebagai salah satu metrik standar dalam mengevaluasi kinerja model pada berbagai bidang, seperti meteorologi, kualitas udara, dan ilmu iklim. Dalam bidang geosains, RMSE sering digunakan untuk menggambarkan tingkat kesalahan suatu model terhadap data observasi. Penggunaan RMSE memungkinkan perbedaan antara nilai aktual dan nilai prediksi dinyatakan dalam satuan yang sama dengan variabel yang dianalisis. Namun, RMSE memiliki kelemahan karena sensitif terhadap keberadaan *outlier*. Nilai ekstrem dalam data dapat memberikan pengaruh yang cukup besar

terhadap hasil perhitungan sehingga nilai RMSE dapat meningkat dan kurang merepresentasikan tingkat kesalahan secara keseluruhan apabila data mengandung *outlier* (Piotrowski et al., 2022). Secara matematis *Root Mean Square Error* (RMSE) ditunjukkan pada persamaan berikut:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad 1.10$$

Keterangan:

y_i = nilai aktual

$\hat{y}_i$ = nilai prediksi

i = urutan data pada *database*

n = jumlah data evaluasi

Korelasi Pearson (r) merupakan salah satu metode statistik yang digunakan untuk mengukur tingkat keeratan hubungan linear antara dua variabel. Metode ini dapat diterapkan pada variabel yang berskala interval atau rasio dan memenuhi asumsi distribusi normal. Koefisien korelasi Pearson memiliki rentang nilai antara -1 dan 1. Nilai koefisien yang mendekati 1 menunjukkan adanya hubungan positif yang kuat antara kedua variabel, sedangkan nilai yang mendekati -1 menunjukkan hubungan negatif yang kuat. Sementara itu, nilai koefisien yang mendekati 0 menunjukkan bahwa hubungan linear antara kedua variabel sangat lemah atau tidak terdapat hubungan linear yang berarti (Windarto, 2020). Rumus Korelasi Pearson (r) ditunjukkan sebagai berikut (Wang et al., 2025).

$$r = \frac{N \sum XY - (\sum X \sum Y)}{\sqrt{[N \sum x^2 - (\sum x)^2][N \sum y^2 - (\sum y)^2]}} \quad 1.11$$

Di mana r adalah koefisien korelasi Pearson, N adalah jumlah data (sampel), $\sum X$ adalah jumlah seluruh nilai X , $\sum Y$ adalah jumlah seluruh nilai Y , $\sum XY$ adalah jumlah hasil perkalian antara nilai X dan nilai Y , $\sum X^2$ adalah jumlah kuadrat nilai X , dan $\sum Y^2$ adalah jumlah kuadrat nilai Y .

Peirce Skill Score (PSS) merupakan salah satu metrik yang digunakan untuk menilai keterampilan atau kemampuan suatu model dalam menghasilkan prediksi. PSS juga dikenal sebagai *True Skill Statistic* (TSS) atau *Hanssen-Kuipers Skill Score*. Metrik ini digunakan untuk mengevaluasi kemampuan prediksi dengan mempertimbangkan keberhasilan model dalam mengidentifikasi kejadian dan ketidakjadian. Pembilang dalam PSS memiliki bentuk yang sama dengan *Odds Ratio Skill Score* (ORSS), sedangkan penyebutnya lebih sederhana dibandingkan *Heidke Skill Score* (HSS), yaitu melibatkan perkalian

antara jumlah kejadian dan jumlah ketidakjadian dalam data (Liemohn et al., 2021). Nilai PSS berada pada rentang -1 hingga 1. Nilai yang mendekati 1 menunjukkan bahwa model memiliki keterampilan prediksi yang baik, nilai yang mendekati 0 menunjukkan bahwa kemampuan prediksi model tidak lebih baik daripada prediksi acak, sedangkan nilai yang mendekati -1 menunjukkan bahwa kemampuan prediksi model sangat rendah (Pérez-Alarcón et al., 2025). Rumus dalam menentukan *Peirce Skill Score* (PSS) ditunjukkan sebagai berikut.

$$PSS = \frac{ad-bc}{(b+d)(a+c)} \quad 1.12$$

BAB II METODE PENELITIAN

2.1 Data Penelitian

Penelitian ini menggunakan data sekunder berupa indeks *Indian Ocean Dipole* (IOD) dan *El Niño-Southern Oscillation* (ENSO) bulanan dengan periode pengamatan dari tahun 1870 hingga 2025 dalam bentuk deret waktu (*time series*). Indeks IOD direpresentasikan oleh *Dipole Mode Index* (DMI), sedangkan ENSO direpresentasikan oleh indeks Niño 3.4. Data *Dipole Mode Index* (DMI) dan Niño 3.4 diperoleh dari *NOAA Physical Sciences Laboratory* (PSL).

2.2 Prosedur Penelitian

Prosedur penelitian disusun secara sistematis agar setiap tahapan dapat direplikasi dan dievaluasi. Secara umum tahapan penelitian meliputi:

1. Pengumpulan Data

Data indeks *Indian Ocean Dipole* (IOD) dan Niño 3.4 bulanan diperoleh dari sumber data iklim yang telah terverifikasi, kemudian disusun dalam format tabel runtun waktu (*time series*) yang konsisten untuk keperluan analisis dan pemodelan.

2. Pra-Pemrosesan Data

Tahapan ini meliputi pengecekan konsistensi data, penanganan nilai kosong (*missing value*), perataan data menggunakan metode *3-month running mean*, standarisasi data, serta pembentukan variabel *lag* untuk kebutuhan pemodelan prediksi runtun waktu. Pada penelitian ini digunakan *lag* sepanjang 44 bulan, sehingga setiap sampel prediksi memanfaatkan data indeks IOD dan Niño 3.4 selama 44 bulan sebelumnya sebagai variabel masukan. Selanjutnya, nilai indeks IOD pada *lead time* 1-12 bulan digunakan sebagai variabel target yang akan diprediksi.

3. Pembagian Data

Dataset dibagi menjadi data pelatihan (*training set*) dan data pengujian (*testing set*) secara kronologis (tanpa pengacakan) untuk menjaga struktur temporal. Data periode 1873 sampai 2009 digunakan sebagai data pelatihan (*training set*), sedangkan data periode 2010 sampai 2025 digunakan sebagai data pengujian (*testing set*). Pemisahan ini bertujuan menguji kemampuan generalisasi model serta menghindari *overfitting*.

4. Pemodelan Prediksi

Pemodelan dilakukan menggunakan beberapa pendekatan, yaitu *Multiple Linear Regression* (MLR) sebagai model statistik linear, *Random Forest* dan *XGBoost* sebagai model *ensemble machine learning*, serta *Long Short-Term Memory* (LSTM) sebagai model *deep learning* runtun waktu.

5. Evaluasi dan Verifikasi Model

Kinerja model dievaluasi dengan membandingkan hasil prediksi terhadap data observasi menggunakan indikator statistik seperti *Root Mean Square Error* (RMSE), Korelasi Pearson (r), *Peirce Skill Score* (PSS) serta analisis kesesuaian pola runtun waktu.

2.3 Prosedur Model Prediksi

2.3.1 Penerapan *Multiple Linear Regression* (MLR)

Multiple Linear Regression (MLR) digunakan sebagai pendekatan statistik untuk memodelkan hubungan linear antara variabel dalam prediksi. Proses pelatihan dilakukan dengan mengestimasi koefisien regresi menggunakan metode *Ordinary Least Squares* (OLS). Metode ini bertujuan memperoleh persamaan regresi yang meminimalkan jumlah kuadrat selisih antara nilai prediksi dan nilai observasi. Pelatihan dilakukan secara terpisah untuk setiap *lead time* sehingga diperoleh persamaan regresi yang berbeda untuk masing-masing periode prediksi. Persamaan regresi yang dihasilkan selanjutnya digunakan untuk menghasilkan prediksi pada data pengujian. Hasil prediksi yang diperoleh kemudian digunakan untuk mengevaluasi kinerja model.

2.3.2 Penerapan *Extreme Gradient Boosting* (XGBoost)

Extreme Gradient Boosting (XGBoost) merupakan metode pembelajaran mesin berbasis gradient boosting yang memanfaatkan sejumlah pohon keputusan untuk meningkatkan kemampuan prediksi model. *Hyperparameter* model yang digunakan meliputi $nTrees = 300$, $learnRate = 0,03$, $minLeafSize = 5$, dan $maxNumSplits = 20$. Proses pelatihan dilakukan dengan membangun pohon keputusan secara bertahap menggunakan data pelatihan. Pada setiap iterasi, model memperbaiki kesalahan prediksi yang dihasilkan pada tahap sebelumnya sehingga kemampuan prediksi meningkat secara bertahap. Pelatihan dilakukan secara terpisah untuk setiap *lead time* sehingga diperoleh model yang berbeda untuk masing-masing periode prediksi. Model yang telah dilatih selanjutnya digunakan untuk menghasilkan prediksi pada data pengujian. Hasil prediksi yang diperoleh kemudian digunakan untuk mengevaluasi kinerja model.

2.3.3 Penerapan *Random Forest*

Random Forest merupakan metode pembelajaran mesin berbasis *ensemble learning* yang menggabungkan sejumlah pohon keputusan untuk meningkatkan stabilitas dan akurasi prediksi. *Hyperparameter* model yang digunakan meliputi $nTrees = 300$, $MinLeafSize = 5$, dan $NumPredictorsToSample = 'all'$. Proses pelatihan dilakukan dengan membangun sejumlah pohon keputusan menggunakan sampel data yang dipilih secara acak dari data pelatihan. Setiap pohon keputusan dibangun secara independen sehingga menghasilkan variasi model yang dapat meningkatkan kemampuan generalisasi. Hasil prediksi akhir diperoleh melalui rata-rata keluaran seluruh pohon keputusan yang terbentuk. Pelatihan dilakukan secara terpisah untuk setiap *lead time* sehingga diperoleh model yang berbeda untuk masing-masing periode prediksi. Model yang telah dilatih selanjutnya digunakan untuk menghasilkan prediksi pada data pengujian.

Hasil prediksi yang diperoleh kemudian digunakan untuk mengevaluasi kinerja model.

2.3.4 Penerapan *Long Short-Term Memory* (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari *Recurrent Neural Network* (RNN) yang dirancang untuk mempelajari hubungan jangka panjang pada data runtun waktu. Kemampuan tersebut diperoleh melalui mekanisme *memory cell* yang memungkinkan informasi penting dipertahankan selama proses pembelajaran. Arsitektur model terdiri atas satu lapisan LSTM dengan 10 unit tersembunyi (*hidden units*), satu lapisan *fully connected*, dan satu lapisan keluaran untuk menghasilkan nilai prediksi. Proses pelatihan dilakukan menggunakan $\text{maxEpochs} = 30$, $\text{miniBatchSize} = 16$, $\text{InitialLearnRate} = 0,001$, dan $\text{GradientThreshold} = 1$. Selama proses pelatihan, bobot jaringan diperbarui secara berulang berdasarkan galat prediksi yang dihasilkan hingga diperoleh model yang mampu merepresentasikan pola temporal pada data. Pelatihan dilakukan secara terpisah untuk setiap *lead time* sehingga diperoleh model yang berbeda untuk masing-masing periode prediksi. Model yang telah dilatih selanjutnya digunakan untuk menghasilkan prediksi pada data pengujian. Hasil prediksi yang diperoleh kemudian digunakan untuk mengevaluasi kinerja model.

2.4 Evaluasi dan Verifikasi Model

Evaluasi model dilakukan untuk mengukur tingkat kesalahan, hubungan statistik, serta kesesuaian pola temporal antara hasil prediksi dan data observasi. Proses evaluasi tidak hanya menilai akurasi numerik, tetapi juga memperhatikan kesesuaian pola runtun waktu dari masing-masing model. Indikator evaluasi yang digunakan meliputi:

1. *Root Mean Square Error* (RMSE)

Digunakan untuk mengukur rata-rata besar kesalahan antara nilai prediksi dan nilai observasi. Nilai RMSE yang lebih kecil menunjukkan performa model yang lebih baik dalam meminimalkan kesalahan prediksi.

2. Korelasi Pearson (r)


Korelasi Pearson (r) digunakan untuk mengetahui keeratan hubungan antara hasil prediksi dan data observasi. Nilai korelasi Pearson (r) berada pada rentang -1 hingga 1 . Nilai yang mendekati 1 menunjukkan hubungan positif yang kuat, nilai yang mendekati -1 menunjukkan hubungan negatif yang kuat, sedangkan nilai yang mendekati 0 menunjukkan hubungan yang lemah atau tidak terdapat hubungan linear antara kedua data.

3. *Peirce Skill Score* (PSS)

Digunakan untuk menilai kemampuan model dalam membedakan kejadian yang sesuai dan tidak sesuai berdasarkan kategori nilai yang telah ditentukan. Nilai PSS berada pada rentang -1 sampai 1 . Nilai yang mendekati 1 menunjukkan kemampuan prediksi yang sangat baik, nilai mendekati 0 menunjukkan

kemampuan prediksi yang rendah, sedangkan nilai negatif menunjukkan bahwa hasil prediksi tidak sesuai dengan data observasi.

2.5 Bagan Alir




Gambar 2. Bagan Alir


BAB III HASIL DAN PEMBAHASAN

3.1 Hasil


Hasil prediksi model pada penelitian ini ditampilkan dalam bentuk grafik *time series*. *Time series* bertujuan untuk menggambarkan pola hasil prediksi yang dihasilkan oleh model selama periode penelitian.




(a)



(b)




(c)




(d)

Gambar 3. Time Series, (a) Multiple Linear Regression, (b) Extreme Gradient Boosting, (c) Random Forest, (d) Long Short-Term Memory


Untuk mengetahui kinerja model, dilakukan evaluasi model menggunakan beberapa metrik evaluasi, yaitu *Root Mean Square Error* (RMSE), Korelasi Pearson (r), dan *Peirce Skill Score* (PSS). Hasil evaluasi model tersebut ditampilkan sebagai berikut.




(a)



(b)




(c)



(d)

Gambar 4. Evaluasi Korelasi Pearson (r), RMSE, & PSS, (a) *Multiple Linear Regression*, (b) *Extreme Gradient Boosting*, (c) *Random Forest*, (d) *Long Short-Term Memory*

Berikut perbandingan kinerja model *Multiple Linear Regression*, *Extreme Gradient Boosting*, *Random Forest*, dan *Long Short-Term Memory* dalam memprediksi *Indian Ocean Dipole* (IOD) pada berbagai *lead time*.



Gambar 5. Perbandingan Kinerja Model

Evaluasi kinerja model dalam penelitian ini dilakukan menggunakan beberapa metrik, yaitu Korelasi Pearson (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS). Nilai dari masing-masing metrik evaluasi tersebut ditampilkan pada tabel berikut.

Tabel 1. Korelasi Pearson (r) dari MLR, XGBoost, *Random Forest*, dan LSTM

Lead	MLR (Korelasi)	XGBoost (Korelasi)	<i>Random Forest</i> (Korelasi)	LSTM (Korelasi)
1	0.97398	0.90884	0.9023	0.9541
2	0.88107	0.67789	0.6963	0.8452
3	0.69063	0.37946	0.44836	0.67667
4	0.54848	0.099761	0.21769	0.40444
5	0.43782	-0.050239	0.036244	0.32947
6	0.3249	-0.060399	0.0019514	0.27767
7	0.22143	-0.16782	-0.015041	0.19777
8	0.14556	-0.17016	-0.061557	0.19365
9	0.10614	-0.18246	-0.066031	0.097994
10	0.094878	-0.18438	-0.042548	0.19691
11	0.10254	-0.043724	-0.0085763	0.23161
12	0.10798	-0.096887	0.040483	0.34863

Tabel 2. RMSE dari MLR, XGBoost, *Random Forest*, dan LSTM

<i>Lead</i>	MLR (RMSE)	XGBoost (RMSE)	<i>Random Forest</i> (RMSE)	LSTM (RMSE)
1	0.070657	0.14224	0.14053	0.10574
2	0.15061	0.25021	0.24035	0.19459
3	0.23365	0.30556	0.3032	0.26854
4	0.27439	0.34075	0.33481	0.35892
5	0.29851	0.37018	0.3576	0.36217
6	0.31728	0.37093	0.36132	0.40083
7	0.33198	0.38431	0.36189	0.38367
8	0.34274	0.39251	0.36641	0.42426
9	0.34996	0.39018	0.36766	0.40106
10	0.35414	0.38709	0.36758	0.41785
11	0.3555	0.36677	0.36788	0.42996
12	0.35632	0.38363	0.36469	0.39902

Tabel 3. PSS dari MLR, XGBoost, *Random Forest*, dan LSTM

<i>Lead</i>	MLR (PSS)	XGBoost (PSS)	<i>Random Forest</i> (PSS)	LSTM (PSS)
1	0.88194	0.75595	0.76786	0.80159
2	0.70383	0.53191	0.46171	0.65616
3	0.43131	0.20884	0.27828	0.46212
4	0.25408	0.051478	0.14475	0.22885
5	0.23148	-0.0046296	-0.013889	0.34722
6	0.20794	-0.024403	0.0020768	0.056075
7	0.1623	-0.090694	-0.029222	0.0089509
8	0.1255	-0.095995	-0.014686	0.10174
9	0.13165	-0.077746	0.0017608	0.087363
10	0.098406	-0.079302	-0.07779	0.069269
11	0.073371	-0.023574	-0.091087	0.13656
12	0.047295	-0.14387	-0.080006	0.099547

3.2 Pembahasan

Berdasarkan grafik *time series*, terlihat perbandingan antara nilai observasi indeks *Indian Ocean Dipole* (IOD) dengan hasil prediksi yang dihasilkan oleh model *Multiple Linear Regression* (MLR), *Extreme Gradient Boosting* (XGBoost), *Random Forest*, dan *Long Short-Term Memory* (LSTM). Secara umum, keempat model mampu merepresentasikan pola fluktuasi indeks IOD selama periode penelitian. Pada *lead time* 1 bulan, hasil prediksi dari seluruh model masih menunjukkan kesesuaian yang sangat baik dengan data observasi sehingga pola variasi indeks IOD masih dapat diikuti dengan baik. Memasuki *lead time* 4 bulan, mulai terlihat adanya penyimpangan antara nilai prediksi dan nilai observasi, yang menunjukkan bahwa kemampuan model dalam mengikuti perubahan amplitudo dan fase fluktuasi IOD mulai berkurang. Perbedaan tersebut semakin

jelas pada *lead time* 7 bulan, ketika hasil prediksi mulai sulit mengikuti pola observasi secara konsisten. Selanjutnya, pada *lead time* 11 bulan, penyimpangan antara hasil prediksi dan observasi menjadi semakin besar sehingga kemampuan model dalam merepresentasikan variabilitas indeks IOD semakin menurun seiring bertambahnya *lead time*.

Penurunan kemampuan prediksi tersebut berkaitan dengan karakteristik fisik fenomena IOD yang dipengaruhi oleh interaksi laut dan atmosfer di Samudera Hindia. Pada periode prediksi yang pendek, kondisi suhu permukaan laut, kedalaman termoklin, dan pola angin permukaan masih memiliki keterkaitan yang kuat dengan kondisi sebelumnya sehingga informasi kondisi awal yang digunakan model masih mampu menggambarkan perkembangan IOD beberapa bulan ke depan. Namun, seiring bertambahnya *lead time*, pengaruh kondisi awal semakin berkurang akibat berkembangnya berbagai proses laut-atmosfer yang bersifat dinamis, seperti perubahan gradien suhu permukaan laut antara bagian barat dan timur Samudera Hindia, variasi angin zonal di sepanjang ekuator, serta perubahan struktur termoklin yang berperan dalam proses pertumbuhan dan peluruhan IOD. Akibatnya, ketidakpastian prakiraan meningkat sehingga pola prediksi menjadi semakin sulit mengikuti perkembangan indeks IOD.

Hasil evaluasi menggunakan Korelasi Pearson (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS) menunjukkan bahwa seluruh model memiliki keterampilan prediksi yang sangat baik pada *lead time* 1 bulan. Model MLR memberikan kinerja terbaik dengan nilai korelasi sebesar 0,97398, RMSE sebesar 0,070657, dan PSS sebesar 0,88194. Model LSTM berada pada urutan kedua dengan nilai korelasi sebesar 0,9541, RMSE sebesar 0,10574, dan PSS sebesar 0,80159. Sementara itu, model XGBoost dan *Random Forest* juga menunjukkan kemampuan prediksi yang baik dengan nilai korelasi masing-masing sebesar 0,90884 dan 0,9023, meskipun menghasilkan nilai RMSE yang lebih besar dibandingkan MLR dan LSTM. Tingginya nilai korelasi dan PSS serta rendahnya nilai RMSE menunjukkan bahwa pola variabilitas indeks IOD masih dapat direpresentasikan dengan baik pada periode prakiraan yang pendek.

Pada *lead time* 2-3 bulan, nilai Korelasi Pearson (r) dan PSS pada seluruh model mulai menurun, sedangkan nilai RMSE meningkat dibandingkan *lead time* 1. Meskipun demikian, seluruh model masih mampu mempertahankan keterampilan prediksi yang cukup baik. Model MLR tetap menunjukkan performa terbaik, diikuti oleh LSTM, sedangkan XGBoost dan *Random Forest* mengalami penurunan yang lebih besar. Kondisi ini menunjukkan bahwa informasi kondisi awal masih memiliki pengaruh yang kuat hingga sekitar tiga bulan ke depan, meskipun mulai berkurang akibat berkembangnya dinamika laut-atmosfer.

Pada *lead time* 4 bulan, penurunan keterampilan prediksi seluruh model mulai terlihat secara jelas. Model MLR masih menunjukkan nilai korelasi sebesar 0,54848, RMSE sebesar 0,27439, dan PSS sebesar 0,25408, yang merupakan kinerja terbaik dibandingkan model lainnya. Pada *lead time* yang sama, LSTM

menghasilkan korelasi sebesar 0,40444, RMSE sebesar 0,35892, dan PSS sebesar 0,22885, sedangkan XGBoost dan *Random Forest* memiliki korelasi yang lebih rendah, masing-masing sebesar 0,099761 dan 0,21769. Kondisi ini menunjukkan bahwa variasi laut-atmosfer yang berkembang setelah beberapa bulan mulai mengurangi kemampuan model dalam mempertahankan akurasi prediksi.

Pada *lead time* 5-12 bulan, kinerja seluruh model semakin menurun. MLR tetap menunjukkan performa yang paling konsisten dalam mempertahankan keterampilan prediksi pada periode prakiraan yang lebih panjang. LSTM juga masih memiliki kemampuan yang lebih baik dibandingkan XGBoost dan *Random Forest* pada sebagian besar *lead time* menengah hingga panjang, yang menunjukkan bahwa model ini lebih mampu memanfaatkan informasi temporal dari data historis. Sebaliknya, XGBoost dan *Random Forest* mengalami penurunan keterampilan yang lebih cepat sehingga kemampuan kedua model dalam merepresentasikan pola variabilitas indeks IOD menjadi semakin terbatas. Penurunan kinerja seluruh model pada *lead time* yang lebih panjang menunjukkan bahwa perkembangan IOD semakin dipengaruhi oleh dinamika laut-atmosfer yang kompleks dan tidak sepenuhnya dapat direpresentasikan oleh informasi kondisi awal yang digunakan dalam pemodelan.

Secara keseluruhan, model *Multiple Linear Regression* (MLR) menunjukkan performa terbaik dan paling konsisten dibandingkan model lainnya. Keunggulan tersebut ditunjukkan oleh nilai Korelasi Pearson (r) yang relatif lebih tinggi, nilai RMSE yang paling rendah pada seluruh *lead time*, serta nilai PSS yang tetap positif hingga *lead time* 12 bulan. Model LSTM menunjukkan performa yang sangat baik pada *lead time* pendek dan secara umum memiliki keterampilan yang lebih baik dibandingkan XGBoost dan *Random Forest* pada sebagian besar *lead time* menengah hingga panjang, terutama berdasarkan nilai korelasi dan PSS. Sebaliknya, model XGBoost dan *Random Forest* mengalami penurunan keterampilan yang lebih cepat, ditandai dengan menurunnya nilai korelasi serta nilai PSS yang menjadi negatif pada beberapa *lead time*, sehingga kemampuan keduanya dalam merepresentasikan perkembangan IOD jangka panjang menjadi lebih terbatas. Hasil ini menunjukkan bahwa prediksi IOD memiliki tingkat akurasi yang lebih baik pada *lead time* jangka pendek, khususnya hingga sekitar 3-4 bulan ke depan. Setelah melewati periode tersebut, kemampuan seluruh model cenderung menurun akibat berkurangnya persistensi anomali laut-atmosfer serta meningkatnya kompleksitas interaksi antara suhu permukaan laut, pola angin, dan dinamika termoklin di Samudera Hindia.

BAB IV KESIMPULAN

4.1 Kesimpulan

Adapun kesimpulan dari penelitian ini adalah sebagai berikut:

1. Penelitian ini berhasil mengimplementasikan model *Multiple Linear Regression* (MLR), *Long Short-Term Memory* (LSTM), *Random Forest*, dan *Extreme Gradient Boosting* (XGBoost) untuk memprediksi indeks *Indian Ocean Dipole* (IOD). Implementasi dilakukan melalui tahapan pengolahan data, pembentukan model, pelatihan, dan pengujian sehingga diperoleh hasil prediksi indeks IOD pada *lead time* 1 hingga 12 bulan.
2. Hasil evaluasi menggunakan Korelasi Pearson (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS) menunjukkan bahwa keempat model memiliki kemampuan yang berbeda dalam memprediksi IOD. Pada *lead time* 1 bulan, model MLR menghasilkan nilai korelasi sebesar 0,97398, RMSE sebesar 0,070657, dan PSS sebesar 0,88194. Model LSTM menghasilkan nilai korelasi sebesar 0,9541, RMSE sebesar 0,10574, dan PSS sebesar 0,80159. Sementara itu, model XGBoost dan *Random Forest* menghasilkan nilai korelasi masing-masing sebesar 0,90884 dan 0,9023, dengan nilai RMSE yang lebih tinggi dibandingkan MLR dan LSTM. Pada *lead time* 2 hingga 4 bulan, model MLR masih menunjukkan kinerja yang relatif lebih baik dibandingkan model lainnya. Pada *lead time* 5 hingga 12 bulan, seluruh model masih mampu menghasilkan prediksi IOD, namun keterampilan prediksinya mengalami penurunan yang ditunjukkan oleh menurunnya nilai korelasi dan PSS serta meningkatnya nilai RMSE seiring bertambahnya *lead time*.
3. Berdasarkan hasil evaluasi menggunakan metrik Korelasi Pearson (r), RMSE, dan PSS, model *Multiple Linear Regression* (MLR) merupakan model terbaik dalam penelitian ini. Hal ini ditunjukkan oleh nilai Korelasi Pearson (r) yang lebih tinggi, nilai RMSE yang lebih rendah, serta nilai PSS yang lebih tinggi pada sebagian besar *lead time*. Oleh karena itu, model MLR dipilih sebagai model terbaik untuk prediksi *Indian Ocean Dipole* (IOD) pada penelitian ini.

4.2 Saran

Penelitian selanjutnya disarankan untuk mengembangkan model prediksi *Indian Ocean Dipole* (IOD) melalui penerapan algoritma *machine learning* dan *deep learning* yang lebih kompleks, serta pengembangan model *hybrid*. Pendekatan tersebut diharapkan dapat meningkatkan kemampuan model dalam menangkap dinamika fenomena IOD, sehingga dapat meningkatkan akurasi prediksi, terutama pada *lead time* menengah hingga panjang.

DAFTAR PUSTAKA

- Abdelhafez, E., Shaban, N. A., Hamdan, M., & Magasleh, M. A. (2025). Comparative Data-Driven Modeling of Thermal Energy Storage Using Artificial Neural Networks and Multiple Linear Regression. *International Journal of Thermofluids*, 101539.
- Amiri-Ramsheh, B., Larestani, A., Atashrouz, S., Nasirzadeh, E., Essakhraoui, M., Abedi, A., ... & Hemmati-Sarapardeh, A. (2025). *Toward accurate prediction of carbon dioxide (CO₂) compressibility factor using tree-based intelligent schemes (XGBoost and LightGBM) and equations of state. Results Eng Volume 25 104035, ISSN 2590–1230.*
- Amrin, A. (2016). Data Mining Dengan Regresi Linier Berganda Untuk Peramalan Tingkat Inflasi. *Jurnal Techno Nusa Mandiri*, 13(1), 74-79.
- Arifuddin, D., Kusriani, K., & Kusnawi, K. (2025). Perbandingan Performansi Algoritma Multiple Linear Regression dan Multi Layer Perceptron Neural Network dalam Memprediksi Penjualan Obat: Comparison of the Performance of Multiple Linear Regression Algorithms and Multi Layer Perceptron Neural Networks in Predicting Drug Sales. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 5(2), 722-737.
- Avoussou, D. K., Salami, A. A., & Barchiesi, D. (2026). Interval forecasting of solar irradiation using LSTM, XGBoost and bandwidth optimization of KDE by differential evolution. *Solar Compass*, 100171.
- Budiprasetyo, G., Hani'ah, M., & Aflah, D. Z. (2023). Prediksi Harga Saham Syariah Menggunakan Algoritma Long Short-Term Memory (LSTM). *Jurnal Nasional Teknologi dan Sistem Informasi*, 8(3), 164-172.
- Dipo, P., Nurjaya, I. W., & Syamsudin, F. (2011). Karakteristik oseanografi fisik di perairan samudera hindia timur pada saat fenomena indian ocean dipole (iod) fase positif tahun 1994/1995, 1997/1998 dan 2006/2007. *Jurnal Ilmu dan Teknologi Kelautan Tropis*, 3(2), 71-84.
- Gifari, F. (2020). PENGARUH FENOMENA INDIAN OCEAN DIPOLE TERHADAP PROPAGASI MADDEN JULIAN OSCILLATION DI BENUA MARITIM. *The Influence of Indian Ocean Dipole on Madden Julian Oscillation Propagation in Maritime Continent*.
- Givari, M. R., Sulaeman, M. R., & Umaidah, Y. (2022). Perbandingan Algoritma SVM, Random Forest Dan XGBoost Untuk Penentuan Persetujuan Pengajuan Kredit. *Nuansa Informatika*, 16(1), 141-149.
- Hawali, M. L., & Walid, W. (2025). Pemilihan Neuron LSTM dan LSTM Bayesian Optimization Untuk Prediksi Curah Hujan Bulanan Berbasis Iklim. *Jurnal Fasilkom*, 15(2), 376-382.
- Hilmawan, M. D. (2022). Deteksi Sarkasme Pada Judul Berita Berbahasa Inggris Menggunakan Algoritma Bidirectional LSTM. *Journal of Dinda: Data Science, Information Technology, and Data Analytics*, 2(1), 46-51.

- Jiang, Y., Zhang, Z., Wen, J., Gao, P., & Tan, J. (2026). Toothed nozzle optimization for enhancement of interlayer tensile strength of 3D-printed concrete with CTGAN and XGBoost model. *Case Studies in Construction Materials*, e06007.
- Kämpf, J. (2024). Do coastal or equatorial wind anomalies drive the Indian Ocean Dipole?. *Journal of Marine Systems*, 246, 104016.
- Krisnanto, W. F., Sartimbul, A., Pranowo, W. S., Sari, S. H. J., & Setyawan, F. O. (2024). Studi Eksperimen Indeks El Niño Southern Oscillation & Indian Ocean Dipole di Indonesia dengan Memanfaatkan Oceanic Niño Index dan Dipole Mode Index (Studi Kasus: Tahun 2009–2020): Experimental Study Of The Coupling Between The El Niño Southern Oscillation Index and The Indian Ocean Dipole in Indonesia Utilizing The Oceanic Niño Index and Dipole Mode Index (Case Study: 2009–2020). *Jurnal Chart Datum*, 10(1), 23-38.
- Lattifia, T., Buana, P. W., & Rusjyanthi, N. K. D. (2022). Model Prediksi Cuaca Menggunakan Metode LSTM. *JITTER J. Ilm. Teknol. dan Komput*, 3(1), 994-1000.
- Liemohn, M. W., Shane, A. D., Azari, A. R., Petersen, A. K., Swiger, B. M., & Mukhopadhyay, A. (2021). RMSE is not enough: Guidelines to robust data-model comparisons for magnetospheric physics. *Journal of Atmospheric and Solar-Terrestrial Physics*, 218, 105624.
- Maulana, M. D., Hadiana, A. I., & Umbara, F. R. (2023). Algoritma Xgboost Untuk Klasifikasi Kualitas Air Minum. *Jati (Jurnal Mahasiswa Teknik Informatika)*, 7(5), 3251-3256.
- Liu, J., Tang, Y., Wu, Y., Li, T., Wang, Q., & Chen, D. (2021). Forecasting the Indian Ocean Dipole with deep learning techniques. *Geophysical Research Letters*, 48(20), e2021GL094407.
- Manurung, D. (2021). Perbandingan Metode Algoritma Support Vector Regression dan Multiple Linear Regression Untuk Memprediksi Stok Obat. *Journal of Applied Technology and Informatics Indonesia*.
- Nugraha, A. C., & Irawan, M. I. (2023). Komparasi Deteksi Kecurangan pada Data Klaim Asuransi Pelayanan Kesehatan Menggunakan Metode Support Vector Machine (SVM) dan Extreme Gradient Boosting (XGBoost). *Jurnal Sains dan Seni ITS*, 12(1), A40-A46.
- Nurdin, N., Fajriana, F., Maryana, M., & Zanati, A. (2022). Information system for predicting fisheries outcomes using regression algorithm multiple linear. *Journal Of Informatics And Telecommunication Engineering*, 5(2), 247-258.
- Nurholipah, T., Kurniawan, R., & Wijaya, Y. A. (2024). EVALUASI PERFORMA MODEL REGRESI LINEAR DENGAN RMSE PADA JUMLAH PENUMPANG BUS TRANSJAKARTA. *JIKA (Jurnal Informatika)*, 8(2), 180-186.
- Pérez-Alarcón, A., Vázquez, M., Trigo, R. M., Nieto, R., & Gimeno, L. (2025). Towards an understanding of uncertainties in the Lagrangian analysis of

moisture sources for tropical cyclone precipitation through a study case. *Atmospheric Research*, 314, 107822.

- Piotrowski, P., Rutyna, I., Baczyński, D., & Kopyt, M. (2022). Evaluation metrics for wind power forecasts: A comprehensive review and statistical analysis of errors. *Energies*, 15(24), 9657.
- Polonsky, A., & Torbinsky, A. (2021). The IOD–ENSO interaction: The role of the Indian Ocean current's system. *Atmosphere*, 12(12), 1662.
- Qiu, S., Wang, Q., Xiong, M., Zheng, J., & Wang, X. (2025). Adaptive extraction of rotating Doppler shift based on random forest regression. *Physics Open*, 100347.
- Ramadhanty, F. W., Muslim, M., Kunarso, K., Rochaddi, B., & Ismunarti, D. H. (2021). Pengaruh fenomena IOD (Indian Ocean Dipole) terhadap sebaran temperatur dan salinitas di Perairan barat Sumatera. *Indonesian Journal of Oceanography*, 3(1), 89-99.
- Ratnam, J. V., Dijkstra, H. A., & Behera, S. K. (2020). A machine learning based prediction system for the Indian Ocean Dipole. *Scientific reports*, 10(1), 284.
- Ratnam, J. V., Behera, S. K., Nonaka, M., & Patil, K. R. (2025). Skillful prediction of Indian Ocean Dipole index using machine learning models. *Applied Computing and Geosciences*, 25, 100228.
- Rizky, M., & Andarsyah, R. (2023). Klasifikasi MIT-BIH Arrhythmia Database Metode Random Forest dan CNN dengan Model ResNet-50: A Systematic Literature Review. *Jurnal Teknologi Dan Sistem Informasi Bisnis*, 5(3), 190-196.
- Rizky, P. S., Hirzi, R. H., & Hidayaturohman, U. (2022). Perbandingan metode LightGBM dan XGBoost dalam menangani data dengan kelas tidak seimbang. *J Statistika: Jurnal Ilmiah Teori dan Aplikasi Statistika*, 15(2), 228-236.
- Ru, X., Zou, Q., & Lin, C. (2023). Optimization of drug–target affinity prediction methods through feature processing schemes. *Bioinformatics*, 39(11), btad615.
- Santoso, I., & Nursiaga, R. (2026). PREDICTION OF CUMULATIVE ACHIEVEMENT INDEX (IPK) USING THE LINEAR REGRESSION METHOD. *Journal of Information System, Applied, Management, Accounting and Research*, 10(1), 297-303.
- Shi, W., & Wang, M. (2022). Biological dipole mode indices: New parameters to characterize the physical and biological processes of the Indian Ocean Dipole event. *Progress in Oceanography*, 206, 102847.
- Sulistiyono, W., Adianova, H., & Haryanto, Y. D. (2023). Verifikasi Data Suhu Udara Luaran Model Iklim CMIP5 Terhadap Data Observasi Pada Wilayah Palembang (Periode 1975-2005). *OPTIKA: Jurnal Pendidikan Fisika*, 7(1), 146-154.

- Tantyoko, H., Sari, D. K., & Wijaya, A. R. (2023). Prediksi Potensial Gempa Bumi Indonesia Menggunakan Metode Random Forest Dan Feature Selection. *IDEALIS: Indonesia Journal Information System*, 6(2), 83-89.
- Yulianti, S. E. H., Soesanto, O., & Sukmawaty, Y. (2022). Penerapan Metode Extreme Gradient Boosting (XGBOOST) pada Klasifikasi Nasabah Kartu Kredit. *Journal of Mathematics: Theory and Applications*, 21-26.
- Wang, Y. C., Song, H. M., Wang, J. S., Ma, X. R., Song, Y. W., & Qi, Y. L. (2025). Multi-strategy fusion binary SHO guided by Pearson correlation coefficient for feature selection with cancer gene expression data. *Egyptian Informatics Journal*, 29, 100639.
- Windarto, Y. E. (2020). Analisis penyakit kardiovaskular menggunakan metode korelasi pearson, spearman dan kendall. *Jurnal Saintekom: Sains, Teknologi, Komputer dan Manajemen*, 10(2), 119-127.

LAMPIRAN

Lampiran 1. Data Penelitian

Tanggal	IOD	NINO 3.4
1870-01-0	-0.438	-1
1870-02-0	-0.336	-1.2
1870-03-0	0.177	-0.83
1870-04-0	-0.048	-0.81
1870-05-0	-0.48	-1.27
1870-06-0	-0.548	-1.08
1870-07-0	-0.65	-1.04
1870-08-0	-0.522	-0.88
1870-09-0	-0.728	-0.53
1870-10-0	-0.636	-0.92
1870-11-0	-0.401	-0.79
1870-12-0	-0.375	-0.79
1871-01-0	-0.273	-0.25
1871-02-0	-0.17	-0.58
1871-03-0	-0.212	-0.43

Lampiran 2. Program Matlab *Time Series*

Program Matlab *Time Series Multiple Linear Regression (MLR)*

```
%% =====
% IOD PREDICTION USING MULTIPLE LINEAR REGRESSION (MLR)
% Predictor : IOD + NINO 3.4
% Target   : IOD
% Leads    : 1, 4, 7, 11 months
%% =====
clear;
close all;
clc;
rng(42,'twister');
%% ----- PARAMETERS -----
filename = 'DATAIOD1.csv';
p = 44;
splitYr = 2010;
leads = [1 4 7 11];
%% ----- READ DATA -----
T = readtable(filename,'VariableNamingRule','preserve');

time = datetime(T.Tanggal,'InputFormat','yyyy-MM-dd');
iod = T.IOD;
nino = T("NINO 3.4");
iod = movmean(iod,3,'Endpoints','shrink');
N = length(iod);
%% ----- STANDARDIZATION -----
muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;
%% ----- BUILD DATASET -----
numSamples = N-p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
```

```

lagIOD = iodZ(i:i+p-1);
lagNINO = ninoZ(i:i+p-1);
X(i,:) = [lagIOD' lagNINO'];
for L = leads
    if (i+p-1+L) <= N
        Y(i,L) = iodZ(i+p-1+L);
    end
end
end
%% ----- TRAIN TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
time_test = time(testIdx);
obs_test = iod(testIdx);
%% ----- TRAIN MLR -----
MLR = cell(length(leads),1);
Pred = NaN(length(leads),size(Xts,1));
for k = 1:length(leads)
    L = leads(k);
    valid = ~isnan(Ytr(:,L));
    MLR{k} = fitlm( ...
        Xtr(valid,:), ...
        Ytr(valid,L));
    Pred(k,:) = predict( ...
        MLR{k}, ...
        Xts );
end
%% ----- DENORMALIZATION -----
Pred = Pred .* sdIOD + muIOD;
%% ----- PLOT -----
figure('Color','w',...
    'Position',[150 100 950 550])
hold on
box on
plot(time_test,...
    obs_test,...
    'k-',...
    'LineWidth',1.8,...
    'DisplayName','Observed')
plot(time_test,...
    Pred(1,:),...
    '--',...
    'Color',[0 0 1],...
    'LineWidth',1.1,...
    'DisplayName','Lead-1')
plot(time_test,...
    Pred(2,:),...
    '--',...
    'Color',[1 0 0],...
    'LineWidth',1.1,...
    'DisplayName','Lead-4')
plot(time_test,...
    Pred(3,:),...
    '--',...
    'Color',[0 0.6 0],...
    'LineWidth',1.1,...
    'DisplayName','Lead-7')

```

```

plot(time_test,...
     Pred(4,:),...
     '--',...
     'Color',[0.6 0 0.6],...
     'LineWidth',1.1,...
     'DisplayName','Lead-11')
xlabel('Year','FontSize',12)
ylabel('IOD Index','FontSize',12)

title('IOD Prediction Using MLR',...
     'FontSize',13)
legend('Location','northwest')
grid on
set(gca,...
     'FontSize',11,...
     'LineWidth',1)
xlim([time_test(1) time_test(end)])

```

Program Matlab Time Series Extreme Gradient Boosting (XGBoost)

```

%% =====
% IOD PREDICTION USING XGBOOST
% Predictor : IOD + NINO 3.4
% Target   : IOD
% Leads    : 1, 4, 7, 11 months
%% =====

clear;
close all;
clc;
rng(42,'twister');
%% ----- PARAMETERS -----
filename = 'DATAIOD1.csv';
p = 44;
splitYr = 2010;
leads = [1 4 7 11];
%% ----- READ DATA -----
T = readtable(filename,'VariableNamingRule','preserve');
time = datetime(T("Tanggal'),'InputFormat','yyyy-MM-dd');
iod = T("IOD");
nino = T("NINO 3.4");

iod = movmean(iod,3,'Endpoints','shrink');
N = length(iod);
%% ----- STANDARDIZATION -----
muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;
%% ----- BUILD DATASET -----
numSamples = N-p;
X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lagIOD = iodZ(i:i+p-1);
    lagNINO = ninoZ(i:i+p-1);
    X(i,:) = [lagIOD lagNINO];
    for L = leads
        if (i+p-1+L) <= N
            Y(i,L) = iodZ(i+p-1+L);
        end
    end
end

```

```

end
end
%% ----- TRAIN TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);

Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
time_test = time(testIdx);
obs_test = iod(testIdx);
%% ----- XGBOOST MODEL -----
models = cell(length(leads),1);
PredZ = NaN(length(leads),size(Xts,1));
t = templateTree( ...
    'MaxNumSplits',20,...
    'MinLeafSize',5);
for k = 1:length(leads)
    L = leads(k);
    valid = ~isnan(Ytr(:,L));
    models{k} = fitensemble( ...
        Xtr(valid,:), ...
        Ytr(valid,L), ...
        'Method','LSBoost', ...
        'Learners',t, ...
        'NumLearningCycles',300, ...
        'LearnRate',0.05);
    PredZ(k,:) = predict( ...
        models{k}, ...
        Xts);
end
%% ----- DENORMALIZATION -----
Pred = PredZ .* sdIOD + mulIOD;
%% ----- PLOT -----
figure('Color','w',...
    'Position',[150 100 950 550])
hold on
box on
plot(time_test,...
    obs_test,...
    'k',...
    'LineWidth',1.8,...
    'DisplayName','Observed')
plot(time_test,...
    Pred(1,:),...
    '--',...
    'Color',[0 0 1],...
    'LineWidth',1.1,...
    'DisplayName','Lead-1')
plot(time_test,...
    Pred(2,:),...
    '--',...
    'Color',[1 0 0],...
    'LineWidth',1.1,...
    'DisplayName','Lead-4')
plot(time_test,...
    Pred(3,:),...
    '--',...
    'Color',[0 0.6 0],...
    'LineWidth',1.1,...

```

```

'DisplayName','Lead-7')
plot(time_test,...
     Pred(4,:),...
     '--',...
     'Color',[0.6 0 0.6],...
     'LineWidth',1.1,...
     'DisplayName','Lead-11')
xlabel('Year')
ylabel('IOD Index')
title('IOD Prediction Using XGBoost',...
     'FontSize',13)
legend('Location','northwest')
grid on
set(gca,...
     'FontSize',11,...
     'LineWidth',1)
xlim([time_test(1) time_test(end)])

```

Program Matlab Time Series Random Forest

```

%% =====
% IOD PREDICTION USING RANDOM FOREST (RF)
% Predictor : IOD + NINO 3.4
% Target    : IOD
% Leads     : 1, 4, 7, 11 months
%% =====

clear;
close all;
clc;
rng(42,'twister');
%% ----- PARAMETERS -----
filename = 'DATAIOD1.csv';
p = 44;
splitYr = 2010;
leads = [1 4 7 11];
%% ----- READ DATA -----
T = readtable(filename);
time = datetime(T.Tanggal,'InputFormat','yyyy-MM-dd');
iod = T.IOD;
nino = T.NINO3_4;
iod = movmean(iod,3,'Endpoints','shrink');
N = length(iod);
%% ----- STANDARDIZATION -----
muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;
%% ----- BUILD DATASET -----
numSamples = N-p;

X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lagIOD = iodZ(i:i+p-1);
    lagNINO = ninoZ(i:i+p-1);
    X(i,:) = [lagIOD' lagNINO'];
    for L = leads
        if (i+p-1+L) <= N
            Y(i,L) = iodZ(i+p-1+L);
        end
    end
end

```

```

end
end
%% ----- TRAIN TEST SPLIT -----
allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p,:);
time_test = time(testIdx);
obs_test = iOD(testIdx);
%% ----- TRAIN RANDOM FOREST -----
numTrees = 300;
RF = cell(length(leads),1);
Pred = NaN(length(leads),size(Xts,1));
for k = 1:length(leads)
    L = leads(k);
    valid = ~isnan(Ytr(:,L));
    RF{k} = TreeBagger( ...
        numTrees,...
        Xtr(valid,:),...
        Ytr(valid,L),...
        'Method','regression',...
        'OOBPrediction','on');
    Pred(k,:) = predict( ...
        RF{k},...
        Xts);
end
%% ----- DENORMALIZATION -----
Pred = Pred .* sdiOD + mulOD;

%% ----- PLOT -----
figure('Color','w',...
    'Position',[150 100 950 550])
hold on
box on
plot(time_test,...
    obs_test,...
    'k',...
    'LineWidth',1.8,...
    'DisplayName','Observed')
plot(time_test,...
    Pred(1,:),...
    '--',...
    'Color',[0 0 1],...
    'LineWidth',1.1,...
    'DisplayName','Lead-1')
plot(time_test,...
    Pred(2,:),...
    '--',...
    'Color',[1 0 0],...
    'LineWidth',1.1,...
    'DisplayName','Lead-4')
plot(time_test,...
    Pred(3,:),...
    '--',...
    'Color',[0 0.6 0],...
    'LineWidth',1.1,...
    'DisplayName','Lead-7')
plot(time_test,...
    Pred(4,:),...

```

```

'--',...
'Color',[0.6 0 0.6],...
'LineWidth',1.1,...
'DisplayName','Lead-11')
xlabel('Year','FontSize',12)
ylabel('IOD Index','FontSize',12)
title('IOD Prediction Using Random Forest',...
'FontSize',13)
legend('Location','northwest')
grid on
set(gca,...
'FontSize',11,...
'LineWidth',1)
xlim([time_test(1) time_test(end)])

```

Program *Time Series Long Short-Term Memory (LSTM)*

```

%% =====
% IOD PREDICTION USING LSTM
% Predictor : IOD + NINO 3.4
% Target   : IOD
% Leads    : 1, 4, 7, 11 months
%% =====

clear;
close all;
clc;
rng(42,'twister');
%% ----- PARAMETERS -----
filename = 'DATAIOD1.csv';
p = 44;
splitYr = 2010;
leads = [1 4 7 11];
%% ----- READ DATA -----
T = readtable(filename);
time = datetime(T{:,1},'InputFormat','yyyy-MM-dd');
iod = T{:,2};
nino = T{:,3};
iod = movmean(iod,3,'Endpoints','shrink');
N = length(iod);
%% ----- STANDARDIZATION -----
muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');
muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');
iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;
%% ----- BUILD DATASET -----
numSamples = N-p;
X = cell(numSamples,1);
Y = NaN(numSamples,max(leads));
for i = 1:numSamples
    lagIOD = iodZ(i:i+p-1);
    lagNINO = ninoZ(i:i+p-1);
    X{i} = [lagIOD'; lagNINO'];
    for L = leads
        if i+p-1+L <= N
            Y(i,L) = iodZ(i+p-1+L);
        end
    end
end
end
%% ----- TRAIN TEST SPLIT -----

```

```

allIdx = (p+1):N;
trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);
Xtr = X(trainIdx-p);
Ytr = Y(trainIdx-p,:);
Xts = X(testIdx-p);
time_test = time(testIdx);
obs_test = iod(testIdx);
%% ----- LSTM STRUCTURE -----
numFeatures = 2;
numHiddenUnits = 20;
layers = [
    sequenceInputLayer(numFeatures)
    lstmLayer(numHiddenUnits,'OutputMode','last')
    dropoutLayer(0.2)
    fullyConnectedLayer(1)
    regressionLayer
];
%% ----- TRAINING OPTIONS -----
options = trainingOptions('adam',...
    'MaxEpochs',50,...
    'MiniBatchSize',64,...
    'InitialLearnRate',0.001,...
    'GradientThreshold',1,...
    'Shuffle','every-epoch',...
    'Verbose',false);
%% ----- TRAIN LSTM -----
LSTM = cell(length(leads),1);
Pred = NaN(length(leads),length(Xts));
for k = 1:length(leads)
    fprintf('Training Lead-%d ...\n',leads(k));
    L = leads(k);

    valid = ~isnan(Ytr(:,L));
    XTrain = Xtr(valid);
    YTrain = Ytr(valid,L);
    LSTM{k} = trainNetwork(...
        XTrain,...
        YTrain,...
        layers,...
        options);
    Pred(k,:) = predict(...
        LSTM{k},...
        Xts,...
        'MiniBatchSize',1);
end
%% ----- DENORMALIZATION -----
Pred = Pred.*sdIOD + muIOD;
%% ----- PLOT -----
figure('Color','w',...
    'Position',[150 100 950 550])
hold on
box on
plot(time_test,...
    obs_test,...
    'k-',...
    'LineWidth',1.8,...
    'DisplayName','Observed')
plot(time_test,...
    Pred(1,:),...
    'r-',...

```

```

'Color',[0 0 1],...
'LineWidth',1.1,...
'DisplayName','Lead-1')
plot(time_test,...
    Pred(2,:),...
    'r',...
    'Color',[1 0 0],...
    'LineWidth',1.1,...
    'DisplayName','Lead-4')
plot(time_test,...
    Pred(3,:),...
    'r',...
    'Color',[0 0.6 0],...
    'LineWidth',1.1,...
    'DisplayName','Lead-7')
plot(time_test,...
    Pred(4,:),...
    'r',...
    'Color',[0.6 0 0.6],...
    'LineWidth',1.1,...
    'DisplayName','Lead-11')
xlabel('Year','FontSize',12)
ylabel('IOD Index','FontSize',12)
title('IOD Prediction Using LSTM','FontSize',13)
legend('Location','northwest')
grid on
set(gca,...
    'FontSize',11,...
    'LineWidth',1)
xlim([time_test(1) time_test(end)])

```

Lampiran 3. Program Matlab Korelasi Pearson (r), *Root Mean Square Error* (RMSE), dan *Peirce Skill Score* (PSS)

Program Matlab Korelasi Pearson (r), RMSE, dan PSS *Multiple Linear Regression* (MLR)

```

%% =====
% MULTIPLE LINEAR REGRESSION (MLR) IOD PREDICTION
% Predictor : IOD + NINO3.4
% Target   : IOD
% + r, RMSE & PSS
% + SAVE RESULT
%% =====

clear; close all; clc;
rng(42,'twister');

%% ----- PARAMETERS -----

filename = 'DATAIOD1.csv';

p = 44;
splitYr = 2010;
leads = 1:12;

%% ----- READ DATA -----

T = readtable(filename,'VariableNamingRule','preserve');

```

```

time = datetime(T{:,1});

iod = T{:,2};
nino = T{:,3};

iod = fillmissing(iod,'linear');
nino = fillmissing(nino,'linear');

iod = movmean(iod,3,'omitnan');
nino = movmean(nino,3,'omitnan');

N = length(iod);

%% ----- STANDARDIZATION -----

muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');

muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');

iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;

%% ----- BUILD LAGGED DATA -----

numSamples = N-p;

X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));

for i = 1:numSamples

    lagIOD = iodZ(i:i+p-1);
    lagNINO = ninoZ(i:i+p-1);

    X(i,:) = [lagIOD' lagNINO'];

    for L = leads

        if i+p-1+L <= N
            Y(i,L) = iodZ(i+p-1+L);
        end

    end

end

end

%% ----- TRAIN / TEST SPLIT -----

allIdx = (p+1):N;

trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);

Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);

Xts = X(testIdx-p,:);
Yts = Y(testIdx-p,:);

```

```

%% ----- INFO SPLIT DATA -----

fprintf('\n===== INFO DATA SPLIT =====\n');

fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train    : %d\n',length(trainIdx));
fprintf('Jumlah Test     : %d\n',length(testIdx));

fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));

fprintf('Periode Test  : %s sampai %s\n', ...
    datestr(time(testIdx(1))), ...
    datestr(time(testIdx(end))));

%% ----- MLR TRAINING -----

MLR = cell(length(leads),1);

Pred = NaN(length(leads),size(Xts,1));

for k = 1:length(leads)

    L = leads(k);

    valid = ~isnan(Ytr(:,L));

    MLR{k} = fitlm(Xtr(valid,:),Ytr(valid,L));

    Pred(k,:) = predict(MLR{k},Xts);

end

%% ----- BACK TO ORIGINAL SCALE -----

Pred = Pred .* sdIOD + mulIOD;

%% ----- METRICS -----

r      = NaN(length(leads),1);
r_err  = NaN(length(leads),1);

RMSE   = NaN(length(leads),1);
RMSE_err = NaN(length(leads),1);

PSS    = NaN(length(leads),1);
PSS_err = NaN(length(leads),1);

for k = 1:length(leads)

    L = leads(k);

    obs = Yts(:,L).*sdIOD + mulIOD;
    pred = Pred(k,:);

    idx = ~isnan(obs) & ~isnan(pred);

    obs = obs(idx);
    pred = pred(idx);

```

```

n = length(obs);

%% ----- r -----

sumX = sum(obs);
sumY = sum(pred);

sumXY = sum(obs.*pred);

sumX2 = sum(obs.^2);
sumY2 = sum(pred.^2);

r(k) = ...
    (n*sumXY - sumX*sumY) / ...
    sqrt((n*sumX2 - sumX^2) * ...
          (n*sumY2 - sumY^2));

r_err(k) = sqrt((1-r(k)^2)/(n-2));

%% ----- RMSE -----

RMSE(k) = sqrt(sum((obs-pred).^2)/n);

RMSE_err(k) = ...
    std((obs-pred).^2) / ...
    (2*RMSE(k)*sqrt(n));

%% ----- PSS -----

a = sum((obs > 0) & (pred > 0));
b = sum((obs <= 0) & (pred > 0));
c = sum((obs > 0) & (pred <= 0));
d = sum((obs <= 0) & (pred <= 0));

denom = (b+d)*(a+c);

if denom == 0
    PSS(k) = NaN;
else
    PSS(k) = (a*d - b*c) / denom;
end

PSS_err(k) = sqrt(2/n);

end

%% ----- RESULT TABLE -----

ResultTable = table( ...
    leads', ...
    r,r_err,...
    RMSE,RMSE_err,...
    PSS,PSS_err,...
    'VariableNames',{'Lead','r','r_err',...
    'RMSE','RMSE_err','PSS','PSS_err'});

disp(ResultTable)

%% ----- SAVE RESULT -----

r_MLR = r;

```

```

RMSE_MLR = RMSE;
PSS_MLR = PSS;

save('MLR_Result.mat', ...
    'r_MLR', ...
    'RMSE_MLR', ...
    'PSS_MLR', ...
    'leads');

fprintf('\nMLR_Result.mat berhasil disimpan\n');

%% ----- PLOT -----

figure('Position',[200 100 1000 450])

subplot(1,2,1)

yyaxis left
errorbar(leads,r,r_err,...
    '-ob','LineWidth',1.8,...
    'MarkerFaceColor','b')

ylabel('Pearson Correlation (r)')

hold on
yline(0.5,'--k','LineWidth',1.2)

yyaxis right
errorbar(leads,RMSE,RMSE_err,...
    '--sg','LineWidth',1.8,...
    'MarkerFaceColor','g')

ylabel('RMSE')

xlabel('Lead (month)')
title('Pearson Correlation & RMSE')
grid on

legend('r','r = 0.5','RMSE',...
    'Location','southwest')

subplot(1,2,2)

errorbar(leads,PSS,PSS_err,...
    '-ok','LineWidth',1.8,...
    'MarkerFaceColor','k')

xlabel('Lead (month)')
ylabel('PSS')
title('Peirce Skill Score')
grid on
ylim([-0.4 1])

sgtitle('Monthly IOD Prediction Verification (MLR)')

Program Matlab Korelasi Pearson (r), RMSE, dan PSS Extreme Gradient Boosting (XGBoost)
%% =====
% XGBOOST IOD PREDICTION
% Predictor : IOD + NINO 3.4

```

```

% Target : IOD
% + r, RMSE & PSS
% + SAVE RESULT
%% =====

clear; close all; clc;
rng(42,'twister');

%% ----- PARAMETERS -----

filename = 'DATAIOD1.csv';

p = 44;
splitYr = 2010;
leads = 1:12;

nTrees = 300;
learnRate = 0.03;
minLeafSize = 5;
maxNumSplits = 20;

%% ----- READ DATA -----

T = readtable(filename,'VariableNamingRule','preserve');

time = datetime(T{:,1});

iod = T{:,2};
nino = T{:,3};

iod = fillmissing(iod,'linear');
nino = fillmissing(nino,'linear');

iod = movmean(iod,3,'omitnan');
nino = movmean(nino,3,'omitnan');

N = length(iod);

%% ----- STANDARDIZATION -----

muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');

muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');

iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;

%% ----- BUILD LAGGED DATA -----

numSamples = N-p;

X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));

for i = 1:numSamples
    lagIOD = iodZ(i:i+p-1);
    lagNINO = ninoZ(i:i+p-1);

```

```

X(i,:) = [lagIOD' lagNINO'];

for L = leads

    if i+p-1+L <= N
        Y(i,L) = iodZ(i+p-1+L);
    end

end

end

%% ----- TRAIN TEST SPLIT -----

allIdx = (p+1):N;

trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);

Xtr = X(trainIdx-p,:);
Ytr = Y(trainIdx-p,:);

Xts = X(testIdx-p,:);
Yts = Y(testIdx-p,:);

%% ----- INFO SPLIT DATA -----

fprintf('\n===== INFO DATA SPLIT =====\n');

fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train      : %d\n',length(trainIdx));
fprintf('Jumlah Test       : %d\n',length(testIdx));

fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));

fprintf('Periode Test : %s sampai %s\n\n', ...
    datestr(time(testIdx(1))), ...
    datestr(time(testIdx(end))));

%% ----- XGBOOST TRAINING -----

Model = cell(length(leads),1);
Pred = NaN(length(leads),size(Xts,1));

t = templateTree( ...
    'MinLeafSize',minLeafSize, ...
    'MaxNumSplits',maxNumSplits);

for k = 1:length(leads)

    L = leads(k);

    valid = ~isnan(Ytr(:,L));

    Model{k} = fitrensemble( ...
        Xtr(valid,:), ...
        Ytr(valid,L), ...
        'Method','LSBoost', ...
        'NumLearningCycles',nTrees, ...

```

```

    'LearnRate',learnRate, ...
    'Learners',t);

    Pred(k,:) = predict(Model{k},Xts);

end

%% ----- BACK TO ORIGINAL SCALE -----

Pred = Pred .* sdiOD + mulOD;

%% ----- METRICS -----

r      = NaN(length(leads),1);
r_err  = NaN(length(leads),1);

RMSE    = NaN(length(leads),1);
RMSE_err = NaN(length(leads),1);

PSS     = NaN(length(leads),1);
PSS_err = NaN(length(leads),1);

for k = 1:length(leads)

    L = leads(k);

    obs = Yts(:,L).*sdiOD + mulOD;
    pred = Pred(k,:);

    idx = ~isnan(obs) & ~isnan(pred);

    obs = obs(idx);
    pred = pred(idx);

    n = length(obs);

    %% Pearson Correlation

    SX = sum(obs);
    SY = sum(pred);

    SXY = sum(obs.*pred);

    SX2 = sum(obs.^2);
    SY2 = sum(pred.^2);

    r(k) = ...
        (n*SXY - SX*SY) ./ ...
        sqrt((n*SX2 - SX^2) .* ...
        (n*SY2 - SY^2));

    if n > 2
        r_err(k) = sqrt((1-r(k)^2)/(n-2));
    else
        r_err(k) = NaN;
    end

    %% RMSE

    err = obs - pred;

```

```

RMSE(k) = sqrt(mean(err.^2));

if RMSE(k) > 0
    RMSE_err(k) = std(err.^2)/(2*RMSE(k)*sqrt(n));
else
    RMSE_err(k) = 0;
end

%% PSS

a = sum(obs > 0 & pred > 0);
b = sum(obs <= 0 & pred > 0);
c = sum(obs > 0 & pred <= 0);
d = sum(obs <= 0 & pred <= 0);

denom = (b+d)*(a+c);

if denom ~= 0
    PSS(k) = (a*d - b*c)/denom;
else
    PSS(k) = NaN;
end

PSS_err(k) = sqrt(2/n);

end

%% ----- RESULT TABLE -----

ResultTable = table( ...
    leads', ...
    r,r_err, ...
    RMSE,RMSE_err, ...
    PSS,PSS_err, ...
    'VariableNames', ...
    {'Lead','r','r_err', ...
    'RMSE','RMSE_err', ...
    'PSS','PSS_err'});

disp(ResultTable)

%% ----- SAVE RESULT -----

r_XGB = r;
RMSE_XGB = RMSE;
PSS_XGB = PSS;

save('XGB_Result.mat', ...
    'r_XGB', ...
    'RMSE_XGB', ...
    'PSS_XGB', ...
    'leads');

fprintf('\nXGB_Result.mat berhasil disimpan\n');

%% ----- PLOT -----

figure('Position',[200 100 1000 450])

subplot(1,2,1)

```

```

yyaxis left
errorbar(leads,r,r_err,...
    '-ob','LineWidth',1.8,...
    'MarkerFaceColor','b')

ylabel('Pearson Correlation (r)')

hold on
yline(0.5,'--k','LineWidth',1.2)

yyaxis right
errorbar(leads,RMSE,RMSE_err,...
    '--sg','LineWidth',1.8,...
    'MarkerFaceColor','g')

ylabel('RMSE')

xlabel('Lead (month)')
title('Pearson Correlation & RMSE')

grid on

legend('r','r = 0.5','RMSE', ...
    'Location','southwest')

subplot(1,2,2)

errorbar(leads,PSS,PSS_err,...
    '-ok','LineWidth',1.8,...
    'MarkerFaceColor','k')

xlabel('Lead (month)')
ylabel('PSS')
title('Peirce Skill Score')
grid on
ylim([-0.4 1])

sgtitle('Monthly IOD Prediction Verification (XGBoost)')

```

Program Matlab Korelasi Pearson (r), RMSE, dan PSS *Random Forest*

```

%% =====
% RANDOM FOREST (RF) IOD PREDICTION
% Predictor : IOD + NINO 3.4
% Target   : IOD
% r, RMSE & PSS
% SAVE RESULT
%% =====

clear; close all; clc;
rng(42,'twister');

%% ----- PARAMETERS -----

filename = 'DATAIOD1.csv';

p = 44;
splitYr = 2010;
leads = 1:12;

nTrees = 300;

```

```

%% ----- READ DATA -----

T = readtable(filename,'VariableNamingRule','preserve');

time = datetime(T{:,1});

iod = T{:,2};
nino = T{:,3};

iod = fillmissing(iod,'linear');
nino = fillmissing(nino,'linear');

iod = movmean(iod,3,'omitnan');
nino = movmean(nino,3,'omitnan');

N = length(iod);

%% ----- STANDARDIZATION -----

muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');

muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');

iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;

%% ----- BUILD LAGGED DATA -----

numSamples = N-p;

X = zeros(numSamples,2*p);
Y = NaN(numSamples,max(leads));

for i = 1:numSamples

    lagIOD = iodZ(i:i+p-1);
    lagNINO = ninoZ(i:i+p-1);

    X(i,:) = [lagIOD' lagNINO'];

    for L = leads

        if i+p-1+L <= N
            Y(i,L) = iodZ(i+p-1+L);
        end

    end

end

%% ----- TRAIN / TEST SPLIT -----

allIdx = (p+1):N;

trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);

Xtr = X(trainIdx-p,:);

```

```

Ytr = Y(trainIdx-p,:);

Xts = X(testIdx-p,:);
Yts = Y(testIdx-p,:);

%% ----- INFO SPLIT DATA -----

fprintf("\n===== INFO DATA SPLIT =====\n");

fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train      : %d\n',length(trainIdx));
fprintf('Jumlah Test       : %d\n',length(testIdx));

fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));

fprintf('Periode Test  : %s sampai %s\n\n', ...
    datestr(time(testIdx(1))), ...
    datestr(time(testIdx(end))));

%% ----- RANDOM FOREST TRAINING -----

RF = cell(length(leads),1);

Pred = NaN(length(leads),size(Xts,1));

for k = 1:length(leads)

    L = leads(k);

    valid = ~isnan(Ytr(:,L));

    RF{k} = TreeBagger( ...
        nTrees,...
        Xtr(valid,:),...
        Ytr(valid,L),...
        'Method','regression',...
        'OOBPrediction','on',...
        'MinLeafSize',5,...
        'NumPredictorsToSample','all');

    Pred(k,:) = predict(RF{k},Xts);

end

%% ----- BACK TO ORIGINAL SCALE -----

Pred = Pred .* sdIOD + muIOD;

%% ----- METRICS -----

r      = NaN(length(leads),1);
r_err  = NaN(length(leads),1);

RMSE   = NaN(length(leads),1);
RMSE_err = NaN(length(leads),1);

PSS    = NaN(length(leads),1);
PSS_err = NaN(length(leads),1);

```

```

for k = 1:length(leads)

    L = leads(k);

    obs = Yts(:,L).*sdIOD + mulIOD;
    pred = Pred(k,:);

    idx = ~isnan(obs) & ~isnan(pred);

    obs = obs(idx);
    pred = pred(idx);

    n = length(obs);

    %% ----- Pearson Correlation (r) ----

    sumX = sum(obs);
    sumY = sum(pred);

    sumXY = sum(obs.*pred);

    sumX2 = sum(obs.^2);
    sumY2 = sum(pred.^2);

    denom_r = sqrt( ...
        (n*sumX2 - sumX^2) * ...
        (n*sumY2 - sumY^2));

    if denom_r == 0
        r(k) = NaN;
    else
        r(k) = ...
            (n*sumXY - sumX*sumY) / denom_r;
    end

    r_err(k) = sqrt((1-r(k)^2)/(n-2));

    %% ----- RMSE -----

    RMSE(k) = sqrt(sum((obs-pred).^2)/n);

    RMSE_err(k) = ...
        std((obs-pred).^2) / ...
        (2*RMSE(k)*sqrt(n));

    %% ----- PSS -----

    a = sum((obs > 0) & (pred > 0));
    b = sum((obs <= 0) & (pred > 0));
    c = sum((obs > 0) & (pred <= 0));
    d = sum((obs <= 0) & (pred <= 0));

    denom_pss = (b+d)*(a+c);

    if denom_pss == 0
        PSS(k) = NaN;
    else
        PSS(k) = (a*d - b*c)/denom_pss;
    end

    PSS_err(k) = sqrt(2/n);

```

```

end

%% ----- RESULT TABLE -----

ResultTable = table( ...
    leads', ...
    r,r_err,...
    RMSE,RMSE_err,...
    PSS,PSS_err,...
    'VariableNames',{'Lead','r','r_err',...
    'RMSE','RMSE_err','PSS','PSS_err'});

disp(ResultTable)

%% ----- SAVE RESULT -----

r_RF = r;
RMSE_RF = RMSE;
PSS_RF = PSS;

save('RF_Result.mat', ...
    'r_RF', ...
    'RMSE_RF', ...
    'PSS_RF', ...
    'leads');

fprintf('\nRF_Result.mat berhasil disimpan\n');

%% ----- PLOT -----

figure('Position',[200 100 1000 450])

subplot(1,2,1)

yyaxis left
errorbar(leads,r,r_err,...
    '-ob','LineWidth',1.8,...
    'MarkerFaceColor','b')

ylabel('Pearson Correlation (r)')

hold on
yline(0.5,'--k','LineWidth',1.2)

yyaxis right
errorbar(leads,RMSE,RMSE_err,...
    '--sg','LineWidth',1.8,...
    'MarkerFaceColor','g')

ylabel('RMSE')

xlabel('Lead (month)')
title('Pearson Correlation & RMSE')

grid on

legend('r','r = 0.5','RMSE',...
    'Location','southwest')

subplot(1,2,2)

```

```

errorbar(leads,PSS,PSS_err,...
        '-ok','LineWidth',1.8,...
        'MarkerFaceColor','k')

```

```

xlabel('Lead (month)')
ylabel('PSS')

```

```

title('Peirce Skill Score')
grid on
ylim([-0.4 1])

```

```

sgtitle('Monthly IOD Prediction Verification (Random Forest)')

```

Program Matlab Korelasi Pearson (r), RMSE, dan PSS Long Short-Term Memory (LSTM)

```

%% =====
% LSTM IOD PREDICTION
% Predictor : IOD + NINO 3.4
% Target   : IOD
% + r, RMSE & PSS
% Save Result
%% =====

```

```

clear;
close all;
clc;

```

```

rng(42,'twister');

```

```

%% ----- PARAMETERS -----

```

```

filename = 'DATAIOD1.csv';

```

```

p = 44;
splitYr = 2010;
leads = 1:12;

```

```

hiddenUnits = 10;
maxEpochs = 30;
miniBatchSize = 16;

```

```

%% ----- READ DATA -----

```

```

T = readtable(filename,'VariableNamingRule','preserve');

```

```

time = datetime(T{:,1});

```

```

iod = T{:,2};
nino = T{:,3};

```

```

iod = fillmissing(iod,'linear');
nino = fillmissing(nino,'linear');

```

```

iod = movmean(iod,3,'omitnan');
nino = movmean(nino,3,'omitnan');

```

```

N = length(iod);

```

```

%% ----- STANDARDIZATION -----

```

```

muIOD = mean(iod,'omitnan');
sdIOD = std(iod,'omitnan');

muNINO = mean(nino,'omitnan');
sdNINO = std(nino,'omitnan');

iodZ = (iod-muIOD)./sdIOD;
ninoZ = (nino-muNINO)./sdNINO;

%% ----- BUILD SEQUENCE DATA -----

numSamples = N-p;

X = cell(numSamples,1);
Y = NaN(numSamples,max(leads));

for i = 1:numSamples

    lagIOD = iodZ(i:i+p-1);
    lagNINO = ninoZ(i:i+p-1);

    X{i} = [lagIOD'; lagNINO'];

    for L = leads

        if (i+p-1+L) <= N
            Y(i,L) = iodZ(i+p-1+L);
        end

    end

end

%% ----- TRAIN / TEST SPLIT -----

allIdx = (p+1):N;

trainIdx = allIdx(year(time(allIdx)) < splitYr);
testIdx = allIdx(year(time(allIdx)) >= splitYr);

Xtr = X(trainIdx-p);
Ytr = Y(trainIdx-p,:);

Xts = X(testIdx-p);
Yts = Y(testIdx-p,:);

%% ----- INFO SPLIT DATA -----

fprintf("\n===== INFO DATA SPLIT =====\n");

fprintf('Jumlah Data Total : %d\n',N);
fprintf('Jumlah Train      : %d\n',length(trainIdx));
fprintf('Jumlah Test       : %d\n',length(testIdx));

fprintf('Periode Train : %s sampai %s\n', ...
    datestr(time(trainIdx(1))), ...
    datestr(time(trainIdx(end))));

fprintf('Periode Test  : %s sampai %s\n', ...
    datestr(time(testIdx(1))), ...

```

```

    datestr(time(testIdx(end))));

%% ----- LSTM ARCHITECTURE -----

layers = [
    sequenceInputLayer(2)

    lstmLayer(hiddenUnits,'OutputMode','last')

    fullyConnectedLayer(1)

    regressionLayer];

options = trainingOptions('adam', ...
    'MaxEpochs',maxEpochs,...
    'MiniBatchSize',miniBatchSize,...
    'InitialLearnRate',0.001,...
    'GradientThreshold',1,...
    'Shuffle','every-epoch',...
    'Verbose',false,...
    'Plots','none');

%% ----- TRAINING -----

Pred = NaN(length(leads),length(Xts));

for k = 1:length(leads)

    fprintf('Training Lead %d bulan...\n',leads(k));

    valid = ~isnan(Ytr(:,k));

    XTrain = Xtr(valid);
    YTrain = Ytr(valid,k);

    net = trainNetwork( ...
        XTrain,...
        YTrain,...
        layers,...
        options);

    YPred = predict(net,...
        Xts,...
        'MiniBatchSize',1);

    Pred(k,:) = YPred(:);

end

%% ----- BACK TO ORIGINAL SCALE -----

Pred = Pred .* sdIOD + muIOD;

%% ----- METRICS -----

Pearson    = NaN(length(leads),1);
Pearson_err = NaN(length(leads),1);

RMSE      = NaN(length(leads),1);
RMSE_err  = NaN(length(leads),1);

```

```

PSS      = NaN(length(leads),1);
PSS_err  = NaN(length(leads),1);

for k = 1:length(leads)

    obs = Yts(:,k).*sdlOD + mulOD;
    pred = Pred(k,:);

    idx = ~isnan(obs) & ~isnan(pred);

    obs = obs(idx);
    pred = pred(idx);

    n = length(obs);

    %% =====
    % PEARSON CORRELATION
    %% =====

    sumX = sum(obs);
    sumY = sum(pred);

    sumXY = sum(obs .* pred);

    sumX2 = sum(obs.^2);
    sumY2 = sum(pred.^2);

    Pearson(k) = ...
        (n*sumXY - sumX*sumY) / ...
        sqrt((n*sumX2 - sumX^2) * ...
            (n*sumY2 - sumY^2));

    Pearson_err(k) = sqrt((1-Pearson(k)^2)/(n-2));

    %% =====
    % RMSE
    %% =====

    RMSE(k) = sqrt(mean((obs-pred).^2));

    RMSE_err(k) = RMSE(k)/sqrt(2*n);

    %% =====
    % PSS
    %% =====

    threshold = 0;

    obs_event = obs >= threshold;
    pred_event = pred >= threshold;

    a = sum(obs_event & pred_event);
    b = sum(~obs_event & pred_event);
    c = sum(obs_event & ~pred_event);
    d = sum(~obs_event & ~pred_event);

    denom = (b+d)*(a+c);

    if denom == 0
        PSS(k) = NaN;
    else

```

```

        PSS(k) = (a*d - b*c)/denom;
    end

    PSS_err(k) = sqrt(2/n);

end

%% ----- RESULT TABLE -----

ResultTable = table( ...
    leads', ...
    Pearson,...
    Pearson_err,...
    RMSE,...
    RMSE_err,...
    PSS,...
    PSS_err,...
    'VariableNames', ...
    {'Lead',...
    'PearsonCorrelation',...
    'Pearson_err',...
    'RMSE',...
    'RMSE_err',...
    'PSS',...
    'PSS_err'});

disp(ResultTable)

%% ----- SAVE RESULT -----

Pearson_LSTM = Pearson;
RMSE_LSTM    = RMSE;
PSS_LSTM     = PSS;

save('LSTM_Result.mat', ...
    'Pearson_LSTM', ...
    'RMSE_LSTM', ...
    'PSS_LSTM', ...
    'leads');

fprintf("\nLSTM_Result.mat berhasil disimpan\n");

%% ----- PLOT -----

figure('Position',[200 100 1000 450])

subplot(1,2,1)

yyaxis left

errorbar(leads,...
    Pearson,...
    Pearson_err,...
    '-ob',...
    'LineWidth',1.8,...
    'MarkerFaceColor','b')

ylabel('Pearson Correlation (r)')

hold on

```

```

yline(0.5,'--k','LineWidth',1.2)

yyaxis right

errorbar(leads,...
         RMSE,...
         RMSE_err,...
         '--sg',...
         'LineWidth',1.8,...
         'MarkerFaceColor','g')

ylabel('RMSE')

xlabel('Lead (month)')

title('Pearson Correlation & RMSE')

grid on

legend('r',...
       'r = 0.5',...
       'RMSE',...
       'Location','southwest')

subplot(1,2,2)

errorbar(leads,...
         PSS,...
         PSS_err,...
         '-ok',...
         'LineWidth',1.8,...
         'MarkerFaceColor','k')

xlabel('Lead (month)')
ylabel('PSS')
title('Peirce Skill Score')
grid on
ylim([-0.4 1])
sgtitle('Monthly IOD Prediction Verification (LSTM)')

```

Lampiran 4. Program Matlab Perbandingan Kinerja Model

```

%% =====
% PERBANDINGAN MLR vs RF vs XGBOOST vs LSTM
% Pearson Correlation
% RMSE
% PSS
%% =====
clear
close all
clc
%% ===== LOAD RESULT =====
load MLR_Result.mat
load RF_Result.mat
load XGB_Result.mat
load LSTM_Result.mat
%% ===== TABEL HASIL =====

```

```

Hasil = table( ...
    leads', ...
    r_MLR, ...
    r_RF, ...
    r_XGB, ...
    Pearson_LSTM, ...
    RMSE_MLR, ...
    RMSE_RF, ...
    RMSE_XGB, ...
    RMSE_LSTM, ...
    PSS_MLR, ...
    PSS_RF, ...
    PSS_XGB, ...
    PSS_LSTM, ...
    'VariableNames',{ ...
    'Lead', ...
    'MLR_r','RF_r','XGB_r','LSTM_r', ...
    'MLR_RMSE','RF_RMSE','XGB_RMSE','LSTM_RMSE', ...
    'MLR_PSS','RF_PSS','XGB_PSS','LSTM_PSS'});

disp('=====')
disp('      TABEL PERBANDINGAN KINERJA MODEL')
disp('=====')
disp(Hasil)

%% ===== FIGURE =====
figure('Position',[100 50 1200 850])
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
%% Pearson Correlation
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
subplot(3,1,1)
plot(leads,r_MLR,'-ob','LineWidth',2,'MarkerFaceColor','b')
hold on
plot(leads,r_RF,'-sr','LineWidth',2,'MarkerFaceColor','r')
plot(leads,r_XGB,'-^g','LineWidth',2,'MarkerFaceColor','g')
plot(leads,Pearson_LSTM,'-dk','LineWidth',2,'MarkerFaceColor','k')
grid on
xlabel('Lead (Month)')
ylabel('Pearson Correlation (r)')
title('Perbandingan Pearson Correlation (r)')
legend('MLR','RF','XGBoost','LSTM',...
    'Location','southwest')
ylim([0 1])
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
%% RMSE
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
subplot(3,1,2)
plot(leads,RMSE_MLR,'-ob','LineWidth',2,'MarkerFaceColor','b')
hold on
plot(leads,RMSE_RF,'-sr','LineWidth',2,'MarkerFaceColor','r')
plot(leads,RMSE_XGB,'-^g','LineWidth',2,'MarkerFaceColor','g')


```




```

plot(leads, RMSE_LSTM, '-dk', 'LineWidth', 2, 'MarkerFaceColor', 'k')
grid on
xlabel('Lead (Month)')
ylabel('RMSE')
title('Perbandingan RMSE')
legend('MLR', 'RF', 'XGBoost', 'LSTM', ...
       'Location', 'northwest')
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
%% PSS
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
subplot(3, 1, 3)
plot(leads, PSS_MLR, '-ob', 'LineWidth', 2, 'MarkerFaceColor', 'b')
hold on
plot(leads, PSS_RF, '-sr', 'LineWidth', 2, 'MarkerFaceColor', 'r')
plot(leads, PSS_XGB, '-^g', 'LineWidth', 2, 'MarkerFaceColor', 'g')
plot(leads, PSS_LSTM, '-dk', 'LineWidth', 2, 'MarkerFaceColor', 'k')
grid on
xlabel('Lead (Month)')
ylabel('PSS')
title('Perbandingan PSS')
legend('MLR', 'RF', 'XGBoost', 'LSTM', ...
       'Location', 'southwest')
ylim([-0.2 1])
sgtitle('Grafik Perbandingan Kinerja Model Prediksi IOD')


```

Lampiran 5. Hasil Penelitian







Monthly IOD Prediction Verification (XGBoost)



Monthly IOD Prediction Verification (Random Forest)



Monthly IOD Prediction Verification (LSTM)



Lampiran 6. Daftar Riwayat Hidup**A. Data Pribadi**

1. Nama : Natasya Irene Poly
2. Tempat, Tanggal Lahir : Luwu Timur, 24 Desember 2003
3. Alamat : Luwu Timur
4. Kewarganegaraan : Indonesia

B. Riwayat Pendidikan

Tamat SMA tahun 2022 di SMA Negeri 4 Luwu Timur

C. Pekerjaan dan Riwayat Pekerjaan

-

D. Karya Ilmiah yang telah di publikasikan

-

E. Makalah pada Seminar/ Konferensi Ilmiah Nasional dan Internasional

-