


PENGEMBANGAN PETA KENDALI FUZZY DEMERIT BERBASIS *MOVING CENTERLINE* (MC) UNTUK DATA BERAUTOKORELASI



Nurmasyita Nasruddin

H062232005

Dosen Pembimbing : 1. Prof. Dr. Erna Tri Herdianti, S. Si., M. Si.
2. Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.
Dosen Penguji : 1. Prof. Dr. Nurtiti Sunusi, S.Si., M.Si.
2. Dr. Nirwan, M.Si.
3. Dr. Anna Islamiyati, S.Si., M.Si.



PROGRAM STUDI MAGISTER STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026

PENGEMBANGAN PETA KENDALI FUZZY DEMERIT BERBASIS *MOVING CENTERLINE* (MC) UNTUK DATA BERAUTOKORELASI

NURMASYITA NASRUDDIN

H062232005



**PROGRAM STUDI MAGISTER STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

PENGEMBANGAN PETA KENDALI FUZZY DEMERIT BERBASIS *MOVING CENTERLINE* (MC) UNTUK DATA BERAUTOKORELASI

Tesis

Sebagai salah satu syarat untuk mencapai gelar magister

Program Studi Magister Statistika

Disusun dan diajukan oleh

NURMASYITA NASRUDDIN

H062232005

Kepada

**PROGRAM STUDI MAGISTER STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

TESIS**PENGEMBANGAN PETA KENDALI FUZZY DEMERIT BERBASIS
MOVING CENTERLINE (MC) UNTUK DATA BERAUTOKORELASI****NURMASYITA NASRUDDIN****H062232005**


Telah dipertahankan di hadapan Panitia Ujian Magister pada
13 Mei 2026 dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Magister Statistika
Departemen Statistika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:

Pembimbing Utama



Prof. Dr. Erna Tri Herdiani, S.Si., M.Si.
NIP. 19750429 200003 2 001

Pembimbing Pendamping



Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.
NIP. 19620926 198702 2 001

Ketua Program Studi
Magister Statistika



Prof. Dr. Erna Tri Herdiani, S.Si., M.Si.
NIP. 19750429 200003 2 001

Dekan Fakultas Matematika dan
Ilmu Pengetahuan Alam
Universitas Hasanuddin



Dr. Sri. Muhammad Zakir, S.Si., M.Si.
NIP. 19701103 199903 1 001

**PERNYATAAN KEASLIAN TESIS
DAN PELIMPAHAN HAK CIPTA**

Dengan ini saya menyatakan bahwa, tesis berjudul "Pengembangan Peta Kendali Fuzzy Demerit Berbasis Moving Centerline (MC) Untuk Data Berautokorelasi" adalah benar karya saya dengan arahan dari tim pembimbing (Dr. Erna Tri Herdiani, S.Si., M.Si. dan Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.). Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apapun kepada perguruan tinggi manapun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka tesis ini. Sebagian dari tesis ini akan dipublikasikan di *Communications in Mathematical Biology and Neuroscience* sebagai artikel dengan judul "Enhancing Attribute Control Charts: A Fuzzy Demerit EWMA Approach for Autocorrelated Quality Data".

Dengan ini saya melimpahkan hak cipta dari karya tulis saya berupa tesis ini kepada Universitas Hasanuddin.

Makassar, 5 Juni 2026



Nurmasyita Nasruddin
H062232005

UCAPAN TERIMA KASIH

Puji syukur kepada Allah Subhana Wa Ta'ala atas segala limpahan rahmat, nikmat, dan hidayah-Nya, serta shalawat dan salam semoga selalu dilimpahkan kepada Nabiyang paling dimuliakan, pemimpin orang-orang bertakwa, Muhammad Sallahu Aalaihi Wassallam dan kepada para keluarga serta sahabat yang berjuang bersamabeliau. Alhamdulillah, berkat pertolongan Allah akhirnya tesis dengan judul "Pengembangan Peta Kendali Fuzzy Demerit Berbasis Moving Centerline (MC) Untuk Data Berautokorelasi" yang disusun sebagai salah satu syarat akademik untuk meraih gelar Magister pada Program Studi Magister Statistika Departemen Statistika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin.

Penulis menyadari bahwa penyelesaian tesis ini tidak lepas dari bantuan dandorongan dari berbagai pihak. Oleh karena itu, penulis menyampaikan terimakasih yang sebesar-besarnya kepada Dr. Erna Tri Herdiani, S.Si., selaku pembimbing utama dan Prof. Dr. Dr. Georgina Maria Tinungki, M. Si., selaku pembimbing pertama yang dengan sabar telah menyisihkan waktu dan pikirannya di tengah berbagai kesibukan dan prioritasnya, selalu memberikan panduan, dorongan, motivasi, dan kemudahan kepada penulis dalam menyelesaikan tesis ini. Serta ucapan terima kasih penulis kepada Prof. Dr. Nurtiti Tsunusi S.Si., M.Si., Dr. Nirwan, M.Si., dan Dr. Anna Islamiyati, S.Si., M.Si selaku tim penguji yang telah memberikan saran membangun, arahan dalam penyempurnaan penyusunantesis ini, serta waktu yang telah diluangkan untuk penulis.

Penulisan tugas akhir ini tentunya tidak lepas dari bantuan berbagai pihak baik moral maupun materi. Oleh karena itu, penulis menyampaikan ucapan terima kasih yang tak terhingga untuk Bapak saya tersayang Nasruddin, mama saya tercinta Nurtati, yang tak kenal lelah mendoakan, memberikan dukungan, dan selalu melimpahkan cinta dan kasih sayangnnya kepada penulis sehingga mereka menjadi motivasi terbesar penulis dalam menyelesaikan tugas akhir ini. Kemudian teman-teman seperjuangan di Program Studi Magister Statistika Angkatan 9, terima kasih atas bantuan dan dukungan selama perkuliahan dan penyusunan tesis ini. Serta kepada semua pihak yang penulis tidak dapat tuliskan satu persatu, terimakasih atasbantuannya.

Penulis menyadari bahwa masih banyak kekurangan dalam tesis ini, untuk itu dengan segala kerendahan hati, penulis memohon maaf

Makassar, 5 Juni 2026



Nurmaryita Nasruddin

ABSTRAK

NURMASYITA NASRUDDIN. **Pengembangan Peta Kendali Fuzzy Demerit Berbasis Moving Centerline (MC) Untuk Data Berautokorelasi** (dibimbing oleh Prof. Dr. Erna Tri Herdiani, S.Si., dan Prof. Dr. Dr. Georgina Maria Tinungki, M. Si.)

Latar Belakang: Data atribut yang memiliki tingkat keparahan cacat berbeda umumnya dimonitor menggunakan peta kendali demerit. Namun, pada data kerentanan siber, selain mengandung ketidakpastian dalam penentuan tingkat keparahan, data juga sering menunjukkan autokorelasi. Kondisi tersebut menyebabkan peta kendali demerit konvensional kurang efektif karena meningkatkan kemungkinan terjadinya false alarm dan menurunkan kemampuan deteksi pergeseran proses. **Tujuan:** Penelitian ini bertujuan mengembangkan peta kendali Fuzzy Demerit berbasis Moving Centerline (MC) untuk data berautokorelasi serta mengevaluasi performanya dalam mendeteksi kondisi out of control. **Hasil:** Hasil penelitian menunjukkan bahwa peta kendali Fuzzy Demerit berhasil mengakomodasi ketidakpastian bobot cacat dan menghasilkan seluruh titik pengamatan berada dalam batas kendali. Pendekatan Moving Centerline mampu menyesuaikan garis pusat secara dinamis mengikuti pola data sehingga lebih adaptif terhadap autokorelasi. Berdasarkan evaluasi ARL, metode Moving Centerline berbasis AR(1) memberikan performa yang lebih baik dibandingkan pendekatan EWMA, ditunjukkan oleh penurunan nilai ARL_1 yang lebih cepat seiring meningkatnya nilai pergeseran (shift). Hal ini menunjukkan kemampuan deteksi yang lebih sensitif terhadap perubahan proses tanpa meningkatkan alarm palsu secara berlebihan. **Kesimpulan:** Dapat disimpulkan bahwa peta kendali Fuzzy Demerit berbasis Moving Centerline efektif digunakan untuk memonitor data berautokorelasi yang mengandung ketidakpastian, khususnya pada data kerentanan siber. Metode ini mampu meningkatkan sensitivitas deteksi pergeseran proses sekaligus mempertahankan stabilitas pemantauan dibandingkan pendekatan konvensional.

Kata kunci: Peta Kendali Fuzzy Demerit, *Moving Centerline*, *Autokorelasi*, EWMA, *Average Run Length*, Kerentanan Siber.

ABSTRACT

NURMASYITA NASRUDDIN. **Development of a Moving Centerline (MC)-Based Fuzzy Demerit Control Chart for Autocorrelated Data** (supervised by Prof. Dr. Erna Tri Herdiani, S.Si. and Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.).

Background: Attribute data with different levels of defect severity are commonly monitored using demerit control charts. However, cybersecurity vulnerability data are often characterized by uncertainty in severity classification and the presence of autocorrelation. These conditions reduce the effectiveness of conventional demerit control charts by increasing the likelihood of false alarms and decreasing the ability to detect process shifts. **Objective:** This study aims to develop a Moving Centerline (MC)-based Fuzzy Demerit Control Chart for autocorrelated data and evaluate its performance in detecting out-of-control conditions. **Methods:** Cybersecurity vulnerability data consisting of four severity levels—low, medium, high, and critical—were used as a case study. Uncertainty in defect severity weights was modeled using Triangular Fuzzy Numbers (TFNs) with an α -cut approach. To address autocorrelation, a Moving Centerline framework was implemented using both Exponentially Weighted Moving Average (EWMA) and Autoregressive Order One [AR(1)] models. The performance of the proposed control chart was evaluated using Average Run Length (ARL) measures under both in-control and out-of-control conditions. **Results:** The results indicate that the proposed Fuzzy Demerit Control Chart successfully accommodates uncertainty in defect severity weights while maintaining all observations within the control limits. The Moving Centerline approach dynamically adjusts the center line according to the data pattern, making it more adaptive to autocorrelated processes. Based on ARL evaluation, the AR(1)-based Moving Centerline method outperformed the EWMA-based approach, as demonstrated by a faster decrease in ARL_1 values as the magnitude of process shifts increased. This finding suggests a higher sensitivity in detecting process changes without generating excessive false alarms. **Conclusion:** The Moving Centerline-based Fuzzy Demerit Control Chart is effective for monitoring autocorrelated data containing uncertainty, particularly cybersecurity vulnerability data. The proposed method improves the sensitivity of shift detection while maintaining monitoring stability compared with conventional approaches.

Keywords: Fuzzy Demerit Control Chart, Moving Centerline, Autocorrelation, EWMA, Average Run Length, Cybersecurity Vulnerability.

DAFTAR ISI

HALAMAN JUDUL	ii
PERNYATAAN PENGAJUAN	iii
HALAMAN PENGESAHAN	iv
PERNYATAAN KEASLIAN TESIS	v
UCAPAN TERIMA KASIH	vi
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
DAFTAR LAMPIRAN	xiii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	3
1.4 Manfaat Penelitian	3
1.5 Batasan Masalah	3
1.6 Teori	4
1.6.1 SPC	4
1.6.2 Peta Kendali Demerit	4
1.6.3 Logika Fuzzy	6
1.6.4 Peta kendali Fuzzy Demerit	9
1.6.5 Data Berautokorelasi	11
1.6.6 <i>Moving Centerline</i> (MC)	13
1.6.7 <i>Avarage Run Length</i>	15
1.6.8 Data Siber	16
1.6.9 Kerangka Konseptual	17
BAB II METODE PENELITIAN	18

2.1 Sumber Data	18
2.2 Identifikasi Variabel.....	18
2.3 Metode Analisis Data	18
BAB III HASIL DAN PEMBAHASAN	20
3.1 Peta Kendali Fuzzy Demerit.....	20
3.2 Data Berautokorelasi.....	27
3.3 Fuzzy Demerit berbasis <i>Moving Centerline</i>	29
3.3.1 Penentuan batas kendali Fuzzy Demerit berbasis Moving Centerline dengan EWMA	29
3.3.2 Pemilihan lamda (λ)	31
3.3.3 Studi kasus Data Cyber	33
3.3.4 Penentuan batas kendali Fuzzy Demerit berbasis Moving Centerline dengan Runtun Waktu	36
3.3.5 Studi Kasus untuk Moving Centerline dengan AR(1)	37
BAB IV KESIMPULAN DAN SARAN	43
4.1 Kesimpulan	43
4.2 Saran	43
DAFTAR PUSTAKA	43

DAFTAR TABEL

Nomor urut	Halaman
1. Struktur Data Peta Kendali Demerit	5
2. Ciri-ciri teoritis ACF dan PACF untuk proses stasioner	13
3. Data Lengkap Fuzzy Demerit.....	20
4. ARL Fuzzy Demerit	23
5. Pemilihan Lamda	32
6. Uji ARL dengan uji coba 2000	32
7. ARL Fuzzy Demerit berbasis Moving Centerline AR(1).....	38
8. Perbandingan ARL EWMA dan ARL AR(1)	41

DAFTAR GAMBAR

Nomor urut	Halaman
1. Derajat Keanggotaan Fuzzy	8
2. Tingkat (derajat) keanggotaan	20
3. Peta kendali Fuzzy Demerit	27
4. ACF Fuzzy Demerit Left Poin	28
5. ACF Fuzzy Demerit Right Poin	28
6. PACF Fuzzy Demerit Left Poin	28
7. PACF Fuzzy Demerit Right Poin	28
8. Fuzzy Demerit berbasis Moving Centerline EWMA	35
9. ACF Residual AR(1) Left Point	36
10. PACF Residual AR(1) Left Point	36
11. ACF Residual AR(1) Right Point	36
12. PACF Residual AR(1) Right Point	36
13. Fuzzy Demerit berbasis Moving Centerline AR(1)	39

DAFTAR LAMPIRAN

Nomor urut	Halaman
1. Data Fuzzy Demerit	46
2. Uji Ljung-Box pada data demerit.....	47
3. Uji Box-Ljung test Left Poin untuk $\lambda = 0.1$ hingga $\lambda = 0.7$	48
4. Uji Box-Ljung test Right Poin untuk $\lambda = 0.1$ hingga $\lambda = 0.7$	49
5. Uji ARL Left Poin untuk $\lambda = 0.7$ dan $L = 2, 2.81$ dan 3	50
6. Uji ARL Right Poin untuk $\lambda = 0.6$ dan $L = 2, 2.81$ dan 3	51
7. Fuzzy Demerit Berbasis <i>Moving Centerline</i> EWMA untuk Left Poin	52
8. Fuzzy Demerit Berbasis <i>Moving Centerline</i> EWMA untuk <i>Right Poin</i>	53
9. Estimasi Parameter <i>Moving Centerline</i> AR(1) dan uji L-jung Box untuk Left Poin.....	54
10. Estimasi Parameter <i>Moving Centerline</i> AR(1) dan uji L-jung Box untuk Right Poin.....	55
11. Uji ARL <i>Moving Centerline</i> AR(1) Left Poin	56
12. Uji ARL <i>Moving Centerline</i> AR(1) Right Poin.....	58
13. Data Lengkap <i>Moving Centerline</i> AR(1) Left Poin.....	60
14. Data Lengkap <i>Moving Centerline</i> AR(1) Right Poin	61

BAB I PENDAHULUAN

1.1 Latar Belakang

Kualitas merupakan kemampuan suatu produk atau layanan untuk memenuhi kebutuhan klien sehingga menjadi kebutuhan yang sangat penting dalam dunia industry maupun manufaktur. Perbedaan kualitas produk atau layanan cenderung karena adanya variabilitas dalam produk (Montgomeri., 2012). Metode statistik yang digunakan dalam pengendalian kualitas produksi adalah *Statistical Process Control* (SPC). SPC merupakan Teknik penyelesaian masalah yang digunakan untuk memantau, mengontrol, dan menganalisis proses produksi dari waktu ke waktu untuk mendeteksi perubahan dalam kinerja proses, salah satu alat bantu yang dapat digubakan untuk mendukung analisis dan pengambilan Keputusan adalah peta kendali (Jamadar, 2020).

Peta kendali adalah alat yang digunakan untuk mengidentifikasi keberadaan variasi proses yang abnormal. Selain peta kendali untuk data variabel, terdapat pula peta kendali atribut yang digunakan untuk mengendalikan kualitas berdasarkan data kategorikal, seperti jumlah produk cacat atau proporsi cacat dalam suatu *batch*. Peta kendali atribut ini mencakup berbagai jenis seperti peta kendali p, np, c, dan u, yang berguna untuk produk dengan data diskrit dan sifat mutu yang tidak diukur secara langsung. Lebih lanjut, dalam upaya meningkatkan sensitivitas dan detail pemantauan kualitas, digunakan juga peta kendali demerit yang tidak hanya mencatat adanya cacat, tetapi juga memberikan bobot berdasarkan tingkat keparahan cacat tersebut. Namun, dalam prakteknya tidak semua asumsi dapat terpenuhi salah satunya ketika data bersifat autokorelasi. Jika data produksi adalah autokorelasi, maka akan meningkatkan waktu deteksi pergeseran dan frekuensi *false alarm* (kesalahan tanda bahaya). Autokorelasi data menyebabkan meningkatnya *rate type I error* (Silpakob, *et. al.*, 2022).

Penerapan peta kendali tradisional kurang optimal untuk diterapkan pada data yang memiliki sifat autokorelasi. Modifikasi Peta Kendali pada data Autokorelasi sebelumnya pernah dilakukan oleh Herdiani, *et. al.*, (2018) pada statistika Exponential Weighted Moving Avarage (EWMA), hasil penelitian yang diperoleh yaitu modifikasi ewma lebih stabil dibandingkan ewma klasik. Pada penelitian Nasruddin, dkk (2023), juga menuliskan tentang peta kendali demerit untuk data autokorelasi dengan menggunakan residual dan Moving Centerline pada peta kendali demerit, hasil dari penelitian ini, peta kendali MCD berhasil mengurangi false alarm begitupula dengan Peta kendali Residual Demerit. Penelitian lainnya juga dilakukan oleh Nembhard dan Nembhard (2000), untuk mengatasi data autokorelasi pada demerit dengan memodifikasi Peta kendali Demerit dengan meng*hybrid* dan *memodifikasi Adjusted Demerit* dan *Moving Centerline* hasil dari penelitian ini peta kendali ini mendapatkan ARL yang diinginkan dan lebih baik dari Peta kendali Demerit Klasik. Pada penellitian Yao (2023) menunjukkan bahwa kita tidak perlu menghilangkan autokorelasi secara paksa sebelum membuat peta kendali, tetapi justru bisa memasukkan struktur autokorelasi itu langsung ke dalam desain peta kendali melalui

model AR(1). Dengan cara ini, pengendalian difokuskan pada residual yang telah terbebas dari dependensi waktu, sehingga kinerja peta kendali menjadi lebih valid secara statistik.

Peta kendali demerit merupakan peta kendali dengan jenis cacat yang dikategorikan menjadi beberapa kelas menurut tingkat keseriusan cacatnya terdiri dari empat kelas yaitu cacat sangat serius, cacat serius, cacat cukup serius dan cacat minor (Montgomery, 2015). Apabila dalam perusahaan terdapat berbagai macam tingkat kesalahan, maka perusahaan disarankan menggunakan peta kendali jenis kesalahan atau peta kendali demerit dengan menggunakan peta kendali demerit, perusahaan dapat memperkirakan tingkat keparahan masalah kualitas dan menentukan apakah perbaikan diperlukan (Sagnak, 2020). Bobot untuk setiap kategori cacat ditentukan secara independen dan terbatas, yang dapat memberikan informasi terbatas dan menyebabkan bias. Oleh karena itu, situasinya agak mirip dengan manufaktur dengan jumlah ketidaksesuaian dengan tingkat keparahan yang berbeda.

Keamanan siber telah menjadi salah satu aspek paling krusial dalam perkembangan teknologi informasi di era digital. Kerugian ekonomi akibat kejahatan siber sangat besar dan terus meningkat dari waktu ke waktu karena kerentanan lokal dipengaruhi oleh penyebab eksternal, hal ini menjadikan data cyber sering menjadi data berautokorelasi. Menurut laporan *Cybersecurity Ventures*, pada tahun 2021 saja diperkirakan kerugian ekonomi global akibat kejahatan siber mencapai lebih dari 6 triliun USD. Hal ini disebabkan oleh biaya pemulihan sistem yang terkena serangan. Selain itu, kejahatan siber juga dapat menyebabkan kerugian operasional, pengurangan produktivitas, dan penurunan pendapatan. Kerugian tersebut tidak hanya dialami oleh perusahaan, tetapi juga oleh individu dan pemerintah.

Data kerentanan siber sering kali disediakan setiap bulan dengan mengacu pada Penilaian Kerentanan Umum System atau *Common Vulnerability Scoring System* (CVSS), namun interpretasi terhadap dampak nyatanya tidak selalu tegas dan dapat berbeda tergantung konteks sistem atau lingkungan organisasi. Pada data siber, tidak jarang sebuah host atau sistem memiliki lebih dari satu jenis kerentanan pada saat yang sama, misalnya dua kerentanan sedang dan satu kerentanan kritis. (Palma & Boonomi, 2025). Fenomena ini sangat mirip dengan dunia manufaktur, di mana suatu produk bisa memiliki beberapa cacat dengan tingkat keparahan berbeda, membuat klasifikasi kerentanan sering kali bersifat kabur atau tidak pasti, terlebih ketika satu kejadian tidak dapat diklasifikasikan secara mutlak ke dalam satu tingkat keparahan saja. Penggunaan pembobot crisp pada situasi di mana terdapat beberapa jenis cacat dalam satu kategori dapat menyebabkan penurunan performa yang signifikan pada peta kendali demerit biasa

Oleh karena itu, untuk memperbaiki permasalahan ini, pembobot linguistik dapat digunakan dalam mengatasi pembobot di setiap kategori cacat, pendekatan Fuzzy Demerit menjadi lebih tepat digunakan karena tidak hanya mempertimbangkan jumlah dan bobot keparahan, tetapi juga mengakomodasi ketidakpastian dan ambiguitas dalam klasifikasi tingkat risiko melalui derajat keanggotaan fuzzy. Dengan demikian, Fuzzy Demerit mampu memberikan ukuran risiko sistem yang lebih

realistik, fleksibel, dan adaptif terhadap dinamika ancaman dunia maya yang kompleks.

Matdoan, M.Y. *et. al.*, (2024) telah menunjukkan keunggulan pendekatan fuzzy pada data demerit dalam menangani ketidakpastian yang muncul dari penilaian cacat. Selain itu, penelitian Ahsan, M. *et. al.*, (2024) yang memodifikasi pendekatan fuzzy dan demerit menunjukkan sensitivitas yang lebih tinggi dalam mendeteksi titik di luar kendali. Penelitian lain oleh Shu, M.H. *et. al.*, (2014) juga mendukung bahwa metode fuzzy demerit memberikan pendekatan yang lebih realistis dan adaptif terhadap kondisi proses modern yang mengandung unsur acak dan kabur, serta memungkinkan pengambilan keputusan yang lebih fleksibel.

Berdasarkan latar belakang, metode Fuzzy demerit ini sangat bagus untuk data cacat yang bersifat kabur atau tidak pasti, namun data siber rentang mengalami autokorelasi. Pengabaian autokorelasi ini menyebabkan batas kendali tradisional menghasilkan alarm palsu yang tinggi. Salah satu metode yang dikembangkan untuk mengatasi autokorelasi adalah dengan menerapkan konsep Moving Centerline (MC). Moving Centerline adalah pendekatan di mana garis tengah pada peta kendali tidak bersifat statis, melainkan dihitung secara dinamis mengikuti pola data terbaru, sehingga saya mengusulkan penelitian **“Pengembangan Peta kendali Fuzzy Demerit berbasis *Moving Centerline* (MC) untuk data Berautokorelasi”**

1.2 Rumusan Masalah

Berikut rumusan masalah berdasarkan latar belakang yang telah diuraikan:

1. Bagaimana membangun peta kendali Fuzzy Demerit pada data berautokorelasi?
2. Bagaimana performa peta kendali Fuzzy Demerit ketika diterapkan pada data berautokorelasi?

1.3 Tujuan Penelitian

Berikut tujuan penelitian berdasarkan rumusan masalah yang telah dijelaskan:

1. Membangun peta kendali Fuzzy Demerit pada data yang berautokorelasi.
2. Melihat performa peta kendali Fuzzy Demerit untuk data berautokorelasi.

1.4 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Penulis memperoleh pemahaman yang lebih baik mengenai peta kendali fuzzy demerit, khususnya untuk data berautokorelasi.
2. Meningkatkan akurasi dalam monitoring keamanan siber, dalam mengatasi keraguan.

1.5 Batasan Masalah

Batasan masalah pada penelitian ini mencakup:

1. Penggunaan Data yang digunakan merupakan data yang berautokorelasi yaitu data kerentanan siber.
2. Data yang digunakan adalah data kerentanan siber dengan empat tingkat keparahan (kelas).

1.6 Teori

Sub-bab teori ini membahas mengenai beberapa teori yang digunakan untuk membahas pokok pembahasan terkait Peta kendali demerit, Peta kendali *Fuzzy demerit* dan Peta kendali *Fuzzy demerit* pada data berautokorelasi.

1.6.1 SPC

Statistical process control (SPC) merupakan salah satu *tools* berupa metode pengendalian proses menggunakan data dan alat-alat statistik untuk menjaga kestabilan proses agar memenuhi spesifikasi yang diberikan konsumen atau dapat dikatakan metode yang sistematis.

Tujuan utama SPC adalah memastikan proses tetap stabil dan menghasilkan produk atau layanan yang konsisten dengan standar kualitas yang diinginkan. Diagram kontrol statistik adalah alat penting dalam SPC yang digunakan untuk memvisualisasikan data proses dan membantu dalam pengambilan keputusan berdasarkan analisis statistik (Qiu. *et. al.*, 2020). Komponen utama dari peta kendali adalah sebagai berikut:

- a) Garis Tengah (*Central Line*)
Garis tengah pada diagram kontrol mewakili rata-rata atau nilai yang diharapkan dari data proses. *Central line* berfungsi sebagai referensi untuk mengevaluasi kinerja proses dan menentukan apakah proses dalam keadaan terkendali.
- b) Batas Kontrol Atas dan Bawah (*Upper and Lower Control Limits*)
Batas kontrol atas dan bawah adalah garis yang berada di atas dan di bawah garis tengah, biasanya berada pada ± 3 standar deviasi dari rata-rata. LCL dan UCL digunakan untuk menentukan apakah variasi dalam proses adalah karena variasi alami (*common cause variation*) atau variasi khusus (*special cause variation*).

1.6.2 Peta Kendali Demerit

Peta kendali demerit merupakan peta kendali yang digunakan untuk menganalisis sambungan yang terdapat kerusakan dalam setiap unit, namun terkadang pada beberapa proses ditemukan bermacam-macam jenis cacat yang tidak semua sambungan cacat mempengaruhi produk dengan akibat yang sama, dengan kata lain jenis cacat yang terjadi tidak boleh disamakan atau memiliki bobot kerusakan yang berbeda.

Menurut Mountgomery (2012), prosedur yang modern seringkali membagi berbagai kemungkinan kecacatan (dalam pengertian ketaksesuaiannya terhadap spesifikasi) ke dalam empat kelas, tergantung pada keseriusan dari kecacatan yang berlainan seperti berikut ini:

- a) Ciri cacat kelas 1 (minor) adalah yaitu unit memiliki ketidaksempurnaan kecil dalam bentuk akhir, penampilan atau kualitas pekerjaan sehingga tidak menyebabkan kegagalan dalam pelayanan.

- b) Ciri cacat kelas 2 (Cukup Serius) Unit tersebut mungkin akan gagal berfungsi, atau menyebabkan masalah yang tidak separah kegagalan pengoperasian, atau mungkin mengurangi masa pakai atau meningkatkan biaya perawatan, atau memiliki cacat besar pada hasil akhir, tampilan, atau kualitas pekerjaan
- c) Ciri cacat kelas 3 (serius) adalah unit akan meningkatkan biaya perawatan dan bisa mengalami cacat operasional kelas A sehingga mengurangi daya hidup produk.
- d) Ciri cacat kelas 4 (sangat serius) adalah unit akan menyebabkan kecelakaan yang tidak mudah untuk diperbaiki sehingga sama sekali tidak cocok untuk ditawarkan.

Berikut struktur data peta kendali Demerit ditunjukkan pada Tabel 1

Tabel 1. Struktur Data Peta Kendali Demerit

<i>Subgrup(i)</i>	<i>n</i>	<i>Karakteristik Kualitas (j)</i>				<i>Demerit (d_i)</i>	<i>U_i</i>
		<i>Kelas</i>	<i>Kelas</i>	<i>Kelas</i>	<i>Kelas</i>		
		1	2	3	4		
Obs ke-1	<i>n</i> ₁	<i>c</i> _{1,1}	<i>c</i> _{1,2}	<i>c</i> _{1,3}	<i>c</i> _{1,4}	<i>d</i> ₁	<i>U</i> ₁
Obs ke-2	<i>n</i> ₂	<i>c</i> _{2,1}	<i>c</i> _{2,2}	<i>c</i> _{2,3}	<i>c</i> _{2,4}	<i>d</i> ₂	<i>U</i> ₂
Obs ke-3	<i>n</i> ₃	<i>c</i> _{3,1}	<i>c</i> _{3,3}	<i>c</i> _{3,3}	<i>c</i> _{3,4}	<i>d</i> ₃	<i>U</i> ₃
...	...	...	...	...	...	...	...
Obs ke- <i>m</i>	<i>n</i> _{<i>m</i>}	<i>c</i> _{<i>m</i>,1}	<i>c</i> _{<i>m</i>,2}	<i>c</i> _{<i>m</i>,3}	<i>c</i> _{<i>m</i>,4}	<i>d</i> _{<i>m</i>}	<i>U</i> _{<i>m</i>}
Jumlah		$\sum_{j=1}^m c_{ij}$	$\sum_{j=1}^m c_{ij}$	$\sum_{j=1}^m c_{ij}$	$\sum_{j=1}^m c_{ij}$		

dengan:

c_{i,j} : jumlah unit cacat pada observasi ke-*i* dan di kelas *j*

i : jumlah subgroup dimana *i*; 1,2,3, ..., *m*

j : jumlah kelas dimana *j*: 1,2, 3 dan 4

n_i : banyaknya sampel pada observasi ke-*i*

Jumlah cacat terboboti (*d_i*), pada masing-masing subgroup (*i*) ditentukan dengan mengalikan jumlah unit cacat pada obeservasi ke-*i* dan di kelas *j* (*c_{i,j}*) dengan bobot sistem (*w_i*), pembobotan akan meningkat sesuai dengan tingkatan cacat demerit, jumlah cacat terboboti dapat dirumuskan seperti pada persamaan berikut (Montgomery, 2012):

$$d_i = w_1 c_{i,1} + w_2 c_{i,2} + w_3 c_{i,3} + w_4 c_{i,4} \quad (1)$$

Nilai rata-rata cacat per unit (*U_i*) untuk masing-masing subgroup pengamatan yang berjumlah *i* subgroup diperoleh menggunakan persamaan berikut:

$$U_i = \frac{d_i}{n_i} \quad (2)$$

dengan n_i : banyaknya sampel pada observasi ke- i

Garis tengah peta kendali demerit diperoleh menggunakan persamaan sebagai berikut:

$$\bar{U} = w_1 \bar{u}_1 + w_2 \bar{u}_2 + w_3 \bar{u}_3 + w_4 \bar{u}_4 \quad (3)$$

dengan $\bar{u}_1, \bar{u}_2, \bar{u}_3$, dan $\bar{u}_4$ yang menunjukkan rata-rata cacat per unit untuk kategori 1, 2, 3 dan 4 yang dapat diperoleh dengan cara membagi jumlah cacat pada masing-masing kategori tersebut dengan jumlah keseluruhan sampel yang terdapat pada subgroup pengamatan atau dapat didefinisikan sebagai berikut:

$$\bar{u}_j = \frac{\sum_{i=1}^m c_{i,j}}{\sum_{i=1}^m n_i} \quad (4)$$

dimana:

$c_{i,j}$: jumlah unit cacat pada obeservasi ke- i dan di kelas j

j : jumlah kelas dimana j : 1,2, 3 dan 4

n_i : banyaknya sampel pada obeservasi ke- i

i : 1,2,3, ..., m

Nilai dari batas kontrol dapat digambarkan sebagai UCL (*Upper Control Limit*) dan LCL (*Lower Control Limit*) sebagai berikut:

$$UCL = \bar{U} + 3\hat{\sigma}_{U_i} \quad (5)$$

$$LCL = \bar{U} - 3\hat{\sigma}_{U_i}$$

selanjutnya untuk menghitung nilai standar deviasi $\hat{\sigma}_{U_i}$ adalah:

$$\hat{\sigma}_{U_i} = \sqrt{\frac{(w_1^2 \bar{u}_1 + w_2^2 \bar{u}_2 + w_3^2 \bar{u}_3 + w_4^2 \bar{u}_4)}{n_i}} \quad (6)$$

dengan i : 1,2,3 ..., m

1.6.3 Logika Fuzzy

Himpunan fuzzy merupakan himpunan yang tidak dapat didefinisikan secara tegas, berbeda dengan teori himpunan klasik (crisp set) yang menetapkan keanggotaan suatu elemen secara pasti, yaitu hanya bernilai 0 atau 1. Dalam himpunan fuzzy, suatu elemen dapat memiliki derajat keanggotaan pada lebih dari satu himpunan sekaligus. Sebagai contoh, seseorang dapat termasuk dalam kategori “muda” dan “paruh baya” secara bersamaan, dengan tingkat keanggotaan tertentu yang dinyatakan dalam interval $[0,1]$. Hal ini menunjukkan bahwa logika fuzzy mampu

merepresentasikan ketidakpastian dan ambiguitas yang sering muncul dalam penilaian nyata.

Dalam konteks peta kendali demerit, penilaian terhadap tingkat keparahan cacat sering kali tidak bersifat tegas dan cenderung subjektif. Suatu cacat tidak selalu dapat diklasifikasikan secara pasti ke dalam kategori tertentu (misalnya minor, mayor, atau kritis), karena terdapat kemungkinan berada di antara dua kategori. Oleh karena itu, penggunaan bilangan fuzzy menjadi penting untuk merepresentasikan ketidakpastian tersebut secara lebih fleksibel dan realistis.

Himpunan fuzzy direpresentasikan melalui fungsi keanggotaan (membership function), yaitu kurva yang memetakan nilai input ke derajat keanggotaannya (Sagna, 2007). Salah satu pendekatan yang umum digunakan adalah triangular fuzzy number (TFN), karena bentuknya sederhana dan mampu merepresentasikan data linguistik secara efektif. Dalam peta kendali fuzzy demerit, data demerit yang bersifat bertingkat dan tidak memiliki batas yang tegas antar kategori membuat TFN menjadi pilihan yang sesuai, karena dapat menggambarkan rentang nilai yang dianggap setara sekaligus mengakomodasi ketidakpastian dalam penilaian cacat. Dengan demikian, penggunaan bilangan fuzzy, khususnya TFN, memungkinkan proses pengendalian kualitas menjadi lebih adaptif dan akurat dibandingkan pendekatan konvensional. TFN menyatakan angka sebagai tiga nilai (a, b, c):

a = nilai minimum (batas bawah)

b = nilai paling representatif atau mewakili (nilai tengah)


c = nilai maksimum (batas atas)

Sehingga nilai tidak lagi satu angka pasti, tetapi rentang dengan tingkat kepercayaan. Hubungan *Triangular Fuzzy Number* (TFN) dengan bobot demerit adalah terletak pada cara merepresentasikan bobot tingkat keparahan cacat yang tidak pasti menjadi bentuk numerik yang lebih fleksibel. Dalam peta kendali demerit klasik, setiap jenis cacat diberi bobot pasti, misalnya:

- Rendah = 2
- sedang = 5.5
- Tinggi = 8.5
- Kritis = 10

Masalahnya, penentuan bobot ini sering terlalu kaku, padahal dalam kenyataan suatu cacat bisa “hampir tinggi” atau “antara tinggi dan kritis”. Sehingga, di sinilah TFN digunakan. Oleh karena itu dalam fuzzy demerit peran TFN-nya menyatakan bobot demerit dalam tiga nilai. Sehingga nilai rentang bobot fuzzy demerit untuk kategori ke- j dilambangkan dengan:

$$\tilde{w}_j = (w_j^a, w_j^b, w_j^c) \quad (7)$$



Gambar 1. Derajat Keanggotaan Fuzzy

Fungsi Keanggotaan:

$$\mu(x) = \begin{cases} \frac{x - w_j^a}{w_j^b - w_j^a} & ; \quad w^a \leq x \leq w^b \\ \frac{w_j^c - x}{w_j^c - w_j^b} & ; \quad w^b \leq x \leq w^c \\ 0 & ; \quad \text{lainnya} \end{cases} \quad (8)$$

Dimana:

$\mu(x)$: Adalah fungsi keanggotaan

w_j^a : nilai bobot terendah yang masih mungkin,

w_j^b : nilai bobot yang paling mewakili,


w_j^c : nilai bobot tertinggi yang masih mungkin

dengan $0 < w_j^a \leq w_j^b \leq w_j^c$ untuk semua j , dimana j adalah kategori cacat.

Contoh penggunaan TFN pada bobot demerit: Misalnya kita punya empat kategori cacat yaitu rendah, sedang, tinggi dengan kritis dengan bobot awal yang telah ditentukan masing-masing sebesar 2, 5.5, 8.5, dan 10. Selanjutnya empat kategori cacat ini dimisalkan dengan menggunakan TFN dinyatakan dalam bentuk selang kepercayaan sebagai berikut:

- Rendah = 2 dengan menggunakan TFN akan menjadi (0, 2, 5.5). Artinya: bobot cacat paling kecil dapat mendekati 0, umumnya 2, dan maksimum 5.5
- Sedang = 5.5 dengan menggunakan TFN akan menjadi (2, 5.5, 8.5). Artinya: biasanya 5.5, tapi bisa serendah 2 atau setinggi 8.5
- Tinggi = 8.5 dengan menggunakan TFN akan menjadi (5.5, 8.5, 10). Artinya: biasanya 8.5, tapi bisa serendah 5.5 atau setinggi 10

- Kritis = 10 dengan menggunakan TFN akan menjadi (8.5, 10, 11.5). Artinya: sekitar 10, dengan variasi kemungkinan
Adapun penentuan nilai TFN ini dapat dilihat pada Gambar 2.



Gambar 2. Tingkat (derajat) keanggotaan

Setelah menghitung TFN pada peta kendali fuzzy demerit, langkah berikutnya menentukan α – cut yang tujuannya untuk mengubah data fuzzy menjadi bentuk yang bisa dihitung secara numerik. α – cut merepresentasikan tingkat keyakinan (confidence level) terhadap bilangan fuzzy. jika $\alpha = 0$ maka seluruh seluruh rentang TFN (paling lebar, paling tidak pasti). Sedangkan jika $\alpha = 1$ maka hanya titik tengah (paling sempit, paling pasti). Dengan demikian, semakin besar nilai dari α maka semakin ketat intervalnya. Sehingga akan diperoleh performa control chart dan model stabil terhadap perubahan α .

1.6.4 Peta kendali Fuzzy Demerit

Peta kendali Fuzzy berperan dalam pengendalian kualitas yang mengandung kesamaran (*vagueness*) seperti pada kecacatan produk. Penggunaan pembobot Fuzzy dapat lebih menggambarkan klasifikasi kecacatan suatu produk. Salah satu peta kendali yang menggunakan konsep Fuzzy adalah Fuzzy Demerit. Setiap bobot linguistik dapat digambarkan sebagai bilangan Fuzzy atau *fuzzy number* (FN), dengan demikian peta kendali Fuzzy Demerit dapat dibangun dari *fuzzy set theory* (FST). Bobot linguistik pada suatu kategori ke- j dinyatakan sebagai FN, $\tilde{w}_j$, dengan fungsi keanggotaan kontinyu positif $\mu_{\tilde{w}_k}$ (Shu, M. H. *et. al.*, 2015). Jumlah demerit pada unit inspeksi ke- i dapat didefinisikan sebagai berikut:

$$\tilde{D}_i = \sum_{k=1}^m \tilde{w}_j c_{ij} \quad (9)$$

Dengan menggunakan operasi aritmatik pada FN, maka akan diperoleh bahwa statistik fuzzy demerit $\tilde{D}_i$ merupakan FN. α – cut merupakan konsep dalam teori

himpunan fuzzy yang digunakan untuk mengubah himpunan atau bilangan fuzzy menjadi himpunan tegas (Ross, 2010). Dengan kata lain, α – cut menyaring bagian himpunan fuzzy yang dianggap cukup mewakili tingkat keyakinan tertentu, sehingga hasilnya dapat dianalisis menggunakan metode statistik atau matematis konvensional. Menurut Adamo (1980), untuk membandingkan dua bilangan FN , yaitu $\tilde{A}$ dan $\tilde{B}$, terlebih dahulu dipilih suatu nilai α dengan $0 \leq \alpha \leq 1$, yang dalam praktiknya biasanya digunakan nilai $\alpha > 0,5$.

Selanjutnya akan diformulasikan α – cut atau dituliskan dengan α_c pada fuzzy demerit dan demerit berbasis TFN. Konsep α_c pada TFN digunakan untuk mengatasi ketidakpastian dengan cara mengubah bilangan fuzzy menjadi interval tegas sehingga bisa dianalisis secara matematis. Untuk mempertimbangkan ketidakpastian digunakan α_c dari TFN:

$${}^{\alpha_c}\tilde{w}_j = [w_j^a + \alpha_c(w_j^b - w_j^a); w_j^c - \alpha_c(w_j^c - w_j^b)] \quad (10)$$

Setelah nilai ${}^{\alpha_c}\tilde{w}_j$ dihitung, maka untuk nilai fuzzy demerit untuk unit ke- i dihitung sebagai berikut:

$${}^{\alpha_c}\tilde{D}_i = \left[\sum_{k=1}^m c_{ij} (w_j^a + \alpha_c(w_j^b - w_j^a)); \sum_{k=1}^m c_{ij} (w_j^c - \alpha_c(w_j^c - w_j^b)) \right] \quad (11)$$

Untuk *Control Limit* dapat dilihat sebagai berikut:

$$\begin{aligned} {}^{\alpha_c}\tilde{C}L &= {}^{\alpha_c} \left(\frac{1}{m} \sum_{i=1}^m \tilde{D}_i \right) = \frac{1}{m} {}^{\alpha_c}\tilde{D}_i \\ {}^{\alpha_c}\tilde{C}L &= \left[\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^m c_{ij} (w_j^a + \alpha_c(w_j^b - w_j^a)); \right. \\ &\quad \left. \frac{1}{m} \sum_{i=1}^m \sum_{j=1}^m c_{ij} (w_j^c - \alpha_c(w_j^c - w_j^b)) \right] \end{aligned}$$

Maka diperoleh:

$${}^{\alpha_c}\tilde{C}L = \left[\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)); \sum_{j=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) \right] \quad (12)$$

Langkah selanjutnya adalah mengevaluasi sistem dalam keadaan *out of control* atau *in control*, sebelum itu melihat α – cut dari standar deviasi, jika $\bar{c}_i$ adalah bilangan ril lebih besar sama dengan 0 untuk semua i sebagai berikut:

$$\begin{aligned}
\tilde{S}^2 &= Var(\tilde{D}) = \sum_{k=1}^m \tilde{w}_j^2 \bar{c}_i \\
^{ac} \left(\sqrt{\sum_{j=1}^m \tilde{w}_j^2 \bar{c}_i} \right) &= \sqrt{\sum_{j=1}^m (^{ac} \tilde{w}_j)^2 \bar{c}_i} \\
&= \left[\sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2}; \sqrt{\sum_{k=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2} \right] \quad (13)
\end{aligned}$$

Maka α -cut dari *Upper Control Limit* dan *Lowe Control Chart* dapat diperoleh sebagai berikut:

$$\begin{aligned}
^{ac}U\tilde{C}L &= \left[\sum_{k=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) + L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2}; \right. \\
&\quad \left. ; \sum_{k=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) + L \sqrt{\sum_{k=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2} \right] \quad (14)
\end{aligned}$$

Lowe Control Limit

$$\begin{aligned}
^{ac}L\tilde{C}L &= \left[\max \sum_{k=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) - L \sqrt{\sum_{k=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2}, 0; \right. \\
&\quad \left. \max \sum_{k=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) - L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2}, 0 \right] \quad (15)
\end{aligned}$$

Jika:

$^{ac}\tilde{D}_i > ^{ac}U\tilde{C}L$ atau $^{ac}\tilde{D}_i < ^{ac}L\tilde{C}L$ maka peta kendali akan memberikan sinyal *Out of Control* atau berada di luar batas (kendali).

1.6.5 Data Berautokorelasi

Peta kendali pada umumnya dibentuk berdasarkan asumsi kebebasan atau berdistribusi normal pada data observasi. Namun, dalam kenyataannya data tidak selalu berdistribusi normal dan terjadi proses autokorelasi, sehingga keadaan ini akan berpengaruh terhadap pembuatan peta kendali. Ljung-Box merupakan uji statistik yang dikembangkan oleh Greta M. Ljung dan George E. P. Box digunakan dalam analisis deret waktu untuk menguji apakah residual model bersifat white noise (Fisher *et. al.*, 2018). Hipotesis yang digunakan dalam uji Ljung-Box sebagai berikut:

$$H_0: \rho_1 = \rho_2 = \dots = \rho_h = 0$$

$$H_1: \exists \rho_k \neq 0 \text{ (Ada Autokorelasi pada minimal satu lag)}$$

Statistik uji Ljung-Box yang dirumuskan sebagai berikut:

$$Q = n(n+2) \sum_{k=1}^h \frac{\rho_k^2}{n-k} \quad (16)$$

dengan:

Q : Statistik uji Ljung-Box

n : jumlah observasi

h : jumlah lag yang diuji

ρ_k : autokorelasi pada lag k

Dimana Q mengikuti distribusi chi-square sehingga kriteria keputusan pengujian apabila $p - value > 0.05$, maka gagal menolak H_0 , atau tidak terdapat autokorelasi residual, sebaliknya apabila $p - value \leq 0.05$, maka tolak H_0 , atau terdapat autokorelasi residual.

Untuk mengidentifikasi adanya ketergantungan antar pengamatan, salah satu alat yang umum digunakan adalah koefisien autokorelasi. Menurut Montgomery *et. al.*, (2015), untuk suatu data deret waktu $X_1, X_2, \dots, X_t$ koefisien autokorelasi pada lag ke- k didefinisikan sebagai perbandingan antara autokovariansi pada lag ke- k dan variansi data, yang dirumuskan sebagai berikut:

$$\rho_k = \frac{cov(X_t, X_{t+k})}{\sqrt{Var(X_t)}\sqrt{Var(X_{t+k})}} = \frac{E(X_t - \mu)(X_{t+k} - \mu)}{\sqrt{E(X_t - \mu)^2}\sqrt{E(X_{t+k} - \mu)^2}} = \frac{\gamma_k}{\gamma_0} \quad (17)$$

Dengan:

μ : rata-rata

γ_k : autokovariansi pada lag k

ρ_k : autokorelasi pada lag k

t : waktu pengamatan

X_t : nilai pengamatan dari suatu variabel pada waktu- t

Nilai *partial autocorrelation function* pada lag k adalah

$$\phi_{kk} = \frac{\rho_k - \sum_{j=1}^{k-1} \phi_{k-1,j} \rho_{k-j}}{1 - \sum_{j=1}^{k-1} \phi_{k-1,j} \rho_j} \quad (18)$$

dengan ϕ_{kk} adalah autokorelasi parsial antara X_t dan X_{t-k}

Berikut Ciri-ciri teoritis ACF dan PACF untuk proses stasioner ditunjukkan pada Tabel 2 sebagai berikut:

Tabel 2. Ciri-ciri teoritis ACF dan PACF untuk proses stasioner

Model	ACF	PACF
MA (q)	Terpotong setelah $lag\ q$	Turun secara eksponensial atau membentuk gelombang sinus
AR (p)	Turun secara eksponensial atau membentuk gelombang sinus	Terpotong setelah $lag\ p$
ARMA (p, q)	Turun cepat setelah $lag\ (q - p)$	Turun cepat setelah $lag\ (p - q)$

Sumber: Montgomery *et. al.*, 2015

1.6.6 Moving Centerline (MC)

Peta kendali ideal adalah peta kendali yang sederhana untuk diimplementasikan dan memiliki kemampuan tinggi dalam mengidentifikasi pergeseran proses pada berbagai tingkat sesuai standar teknis (Patel & Divecha, 2022). Alternatif untuk pendekatan di atas adalah dengan menggunakan model EWMA (*Exponentially Weighted Moving Everage*) sebagai perkiraan model deret waktu umum yang mempertahankan peta kendali tunggal yang ekuivalen, ini pertama kali disarankan oleh Roberts (1959) selain itu juga disankan Rey, pendekatan moving centerline dirancang untuk mengurangi dampak ketergantungan tersebut dalam pengendalian proses. *Moving Centerline* adalah pendekatan di mana garis tengah pada peta kendali tidak bersifat statis, melainkan dihitung secara dinamis mengikuti pola data terbaru. Dengan MC, peta kendali menjadi lebih adaptif terhadap perubahan proses yang bersifat temporal atau berkorelasi waktu, sehingga meningkatkan kemampuan deteksi pergeseran proses dan mengurangi false alarm. Persamaan EWMA umum adalah:

$$Z_i = \lambda X_i + (1 - \lambda)Z_{i-1} \quad (19)$$

dengan:

i : 1,2,3 ..., m

λ : nilai pembobot dengan $0 < \lambda \leq 1$ perkiraan satu langkah kedepan

X_i : nilai pengamatan pada waktu ke- i

Z_0 : ($\bar{X}$) rata-rata data awal nilai pengamatan

Jika Z_i diramalkan untuk pengamatan pada periode $i + 1$, maka prediksi masa depan ini dilambangkan dengan

$$\hat{Z}_{i+1}(i) = Z_i \quad (20)$$

Kesalahan prediksi residual satu langkah kedepan mengikuti metode dari Mastrangelo dan Montgomery (1995) yaitu $e_i = X_i - \hat{Z}_i(i - 1)$, didistribusikan secara independen dan tidak berkorelasi dengan rata-rata nol dan standar deviasi.

Peta kendali EWMA dapat diterapkan pada data autokorelasi karena EWMA adalah prediktor satu langkah maju yang optimal untuk kelas tertentu dari model deret waktu yang melibatkan autokorelasi dan prediktor yang masuk akal untuk model yang lebih umum. Peta MCD kemudian dirancang dengan menggunakan prediktor satu langkah ke depan sebagai garis tengah untuk periode $i + 1$ dengan batas kendali atas dan batas kendali bawah sebagai berikut:

$$\begin{aligned} UCL_{i+1} &= Z_i + L\sigma_p \\ LCL_{i+1} &= Z_i - L\sigma_p \end{aligned} \quad (21)$$

Untuk memperkirakan σ_p dengan menggunakan standar deviasi tetap dari satu langkah ke depan dengan mengakar kuadrat dari jumlah kesalahan prediksi dibagi dengan jumlah pengamatan:

$$\sigma_p = \sqrt{\frac{\sum_{i=1}^N (X_i - \hat{Z}_i(i-1))^2}{N}} \quad (22)$$

dengan:

N : Jumlah data

U_i : Nilai rata-rata cacat per unit

$\hat{Z}_i$: Predeksi EWMA

i : 1,2,3 ..., m

Batas kendali dihitung, kemudian diplot ke depan untuk perbandingan pada periode berikutnya.

Pendekatan Moving Centerline berbasis EWMA memanfaatkan prediktor satu langkah ke depan yang diperoleh melalui mekanisme penghalusan eksponensial. Struktur peta kendali ini bersifat umum, sehingga dapat diperluas dengan menggunakan prediktor satu langkah ke depan yang berasal dari model deret waktu yang lebih fleksibel, seperti model runtun waktu. Banyak peneliti menekankan pentingnya penggunaan model deret waktu sebelum menerapkan control chart, terutama karena residual model cenderung bersifat white noise dan lebih sesuai untuk monitoring (Lirio *et. al.*, 2022). Peta kendali yang dibangun berdasarkan pemodelan autoregressive moving average (ARMA/ARIMA) memiliki keunggulan dalam mengatasi pengaruh autokorelasi dan kecenderungan tren pada data. Hal ini disebabkan karena residual yang dihasilkan oleh model umumnya bersifat tidak berkorelasi dan telah terbebas dari pola tren (Montgomery *et. al.*, 1991). Di antara berbagai pendekatan berbasis model deret waktu, skema yang paling sederhana adalah yang didasarkan pada model autoregressive orde satu atau AR(1). Beberapa peneliti telah menunjukkan bahwa pendekatan berbasis AR(1) efektif dalam menangani permasalahan autokorelasi sekaligus kecenderungan tren yang mendasari data proses (Runger dan Willemain, 1995). Selain itu, Yao et all (2023) dalam studi desain *Shewhart-type control chart* untuk data autokorelasi

mengilustrasikan bahwa struktur AR(1) dapat dipakai secara eksplisit dalam konteks chart individu untuk menangani dependensi waktu. Dimana persamaan AR(1) sebagai berikut:

$$\hat{X}_t = c + \phi X_{t-1} + \varepsilon_t \quad (23)$$

Dimana:

c : konstanta

ϕ : parameter autogregresif orde satu

ε_t : Error acak yang berdistribusi white noise dengan rata-rata nol dan varians konstan

X_i : nilai pengamatan pada waktu ke- i

Dengan persamaan residualnya sebagai berikut:

$$e_i = X_i - \hat{X}_i \quad (24)$$

1.6.7 Average Run Length

Salah satu kriteria utama dalam mengevaluasi kinerja sebuah peta kendali adalah kemampuannya dalam mendeteksi kondisi proses yang berada di luar kendali (*out-of-control*) secara cepat dan tepat. Selain itu salah satu metode ukuran yang paling umum digunakan untuk mengukur kinerja peta kendali dalam hal ini adalah *Average Run Length* (ARL). ARL didefinisikan sebagai rata-rata jumlah observasi yang diperlukan hingga peta kendali menghasilkan sinyal. ARL yang umum digunakan untuk mengukur kinerja peta kendali terbagi dua yaitu (sunthornwat, *et. al.*, 2023):

- a. ARL_0 (*in control*): rata-rata *run length* saat proses stabil ada tidak ada pergeseran. Semakin tinggi nilai ARL_0 , semakin kecil kemungkinan alarm palsu. Dinyatakan dengan rumus sebagai berikut:

$$ARL = \frac{1}{P(\text{suatu titik di luar kendali})} \quad (25)$$

Atau

$$ARL_0 = \frac{1}{\alpha} \quad (26)$$

Apabila proses dalam keadaan terkendali (*in control*). Parameter α menyatakan probabilitas kesalahan (*error*) tipe I (menyatakan keadaan tidak terkendali padahal keadaan terkendali) atau probabilitas suatu titik rata-rata sampel jatuh di luar batas pengendali pada saat proses terkendali.

- b. ARL_1 (*out-of-control*): rata-rata *run length* saat terjadi pergeseran. Semakin kecil nilai ARL_1 , semakin cepat peta kendali memberikan sinyal peringatan saat proses mengalami masalah. Sedangkan perumusan untuk proses dalam keadaan tidak terkendali (*out of control*) adalah:

$$ARL_1 = \frac{1}{1 - \beta} \quad (27)$$

dimana β = probabilitas kesalahan (*error*) tipe II (menyatakan keadaan terkendali padahal keadaan tidak terkendali) atau probabilitas suatu titik rata-

rata sampel jatuh di dalam batas pengendali pada saat proses tidak terkendali.

Pada peta kendali konvensional, probabilitas kesalahan tipe I (α) dan tipe II (β) bersifat konstan karena batas kendali tidak berubah terhadap waktu, hal ini menyebabkan peluang sinyal juga konstan, sehingga nilai ARL dapat dihitung secara langsung. Namun, pada peta kendali dengan *Moving Centerline*, batas kendali berubah pada setiap waktu ke- i . Akibatnya, probabilitas suatu titik berada di dalam atau di luar batas kendali tidak lagi konstan, melainkan bergantung pada waktu. Oleh karena itu, probabilitas yang sebelumnya dinyatakan dengan satu nilai tetap α atau β , kini menjadi peluang yang berubah-ubah terhadap waktu, yaitu:

$$p_t = P(LCL_i \leq D_i^U \leq UCL_i) \quad (28)$$

Seperti pada penelitian Raza, *et. al.*, (2023), maka simulasi Monte Carlo dipilih karena lebih fleksibel dan efisien dalam mengestimasi karakteristik *run length* untuk peta kendali yang memiliki struktur ketergantungan waktu, seperti EWMA dengan *moving centerline*. Nilai ARL diperoleh sebagai rata-rata dari seluruh p_t yang dihasilkan, sebagai berikut:

$$ARL = \frac{1}{N} \sum_{t=1}^N p_t \quad (29)$$

dimana:

N = jumlah simulasi

t = indeks simulasi

p_t = panjang deret pengamatan sampai muncul sinyal pertama

1.6.8 Data Siber


Keamanan siber telah menjadi isu prioritas seluruh negara di dunia semenjak teknologi informasi dan komunikasi dimanfaatkan dalam berbagai aspek kehidupan, baik dalam aspek sosial, ekonomi, hukum, organisasi, kesehatan, pendidikan, budaya, pemerintahan, keamanan, pertahanan, dan lain sebagainya. Berbanding lurus dengan tingginya tingkat pemanfaatan teknologi informasi dan komunikasi tersebut, tingkat risiko dan ancaman penyalahgunaan teknologi informasi dan komunikasi juga semakin tinggi dan semakin kompleks (Mvula, *et. al.*, 2023).

Data kerentanan siber sering kali disediakan setiap bulan dengan mengacu pada Penilaian Kerentanan Umum System atau *Common Vulnerability Scoring System* (CVSS). Skor CVSS berkisar dari (0,0), yang berarti tidak ada kerentanan, hingga (10,0), yang mengindikasikan bahwa program yang mengevaluasi sistem (pemindai) berada dalam posisi untuk mengambil alih sistem host. Teknologi pemindaian yang umum membagi kerentanan ke dalam beberapa kategori berdasarkan skor CVSS: rendah (0,0-3,9), sedang (4,0-6,9), tinggi (7,0-9,9), dan kritis (10,0). Inang yang diberikan dapat memiliki beberapa tingkat kerentanan, misalnya, 2 tingkat sedang dan 1 tingkat kritis.

Dua kerentanan yang diberi nilai numerik yang sama belum tentu memiliki konsekuensi risiko yang identik. Misalnya, kerentanan pada sistem kritis dan sistem non-kritis dapat memiliki dampak yang sangat berbeda meskipun tingkat keparahannya dinilai sama. Dalam satu periode, satu sistem dapat memiliki beberapa kerentanan dengan tingkat keparahan yang berbeda. Penggabungan nilai numerik tegas sering kali tidak mencerminkan kontribusi relatif masing-masing kerentanan secara adil, CVSS hanya mengklasifikasikan kerentanan

Serangan siber semakin meningkat dan banyak organisasi kehilangan sejumlah besar uang akibatnya. Kerentanan siber adalah cara-cara di mana host seperti komputer pribadi, server, dan printer dapat dieksploitasi (Ibrahim, *et. al.*, 2021). Contoh kerentanan termasuk: kata sandi yang lemah, proses otentikasi yang lemah, sistem operasi yang tidak didukung, pengungkapan informasi, dan penggunaan perangkat lunak dengan bug yang diketahui dapat dieksploitasi. Dilaporkan, lebih dari 90% serangan yang berhasil mengeksploitasi kerentanan yang diketahui di mana tambalan (patch) sudah ada tetapi belum diterapkan oleh administrator system. Oleh karena itu, sementara teknologi baru untuk mengidentifikasi dan menambal kerentanan penting, mengamankan dan memfokuskan sumber daya manusia untuk menghilangkan kerentanan yang diketahui juga penting.

1.6.9 Kerangka Konseptual



BAB II METODE PENELITIAN

2.1 Sumber Data

Data yang digunakan dalam penelitian ini merupakan data sekunder dari kerentanan siber dengan pemindaian Nessus bulanan. Pada setiap kerentanan terdapat 4 kerentanan yaitu Tingkat rendah, sedang, tinggi dan krisis. Data ini diperoleh dari publikasi jurnal yang berjudul *Control charting methods for autocorrelated cyber vulnerability Data* dengan Organisasi yang diteliti memiliki (seluruhnya) 498 host selama periode 28 bulan, Dadzie dan T.Allen (2016). Organisasi yang diteliti memiliki (seluruhnya) 498 host selama periode 28 bulan menggunakan data dari pemindaian Nessus bulanan. Nessus adalah perangkat lunak pemindaian kerentanan yang dikembangkan oleh Tenable Network Security, yang secara luas dianggap sebagai pemimpin dunia dalam pemindaian kerentanan.

2.2 Identifikasi Variabel

Variabel yang digunakan dalam penelitian ini terdapat 4 tingkatan keseriusan serangan siber terhadap dampak yang ditimbulkan yaitu 1, 2, 3 dan 4. Untuk penyelidikan, mengelompokkan tingkat keparahan suatu kerentanan keamanan siber ke dalam empat kelas sebagai berikut:

- a. Kelas 1 (rendah) adalah Kerentanan dengan dampak minimal atau sulit dieksploitasi secara praktis, seperti Informasi sistem bocor tetapi tidak langsung dapat digunakan untuk serangan.
- b. Kelas 2 (Sedang) adalah Kerentanan yang dapat digunakan untuk mendapatkan akses terbatas atau menyebabkan gangguan, tetapi tidak memungkinkan pengambilan sistem sepenuhnya seperti Kelemahan dalam autentikasi yang memungkinkan penyerang mendapatkan hak akses terbatas.
- c. Kelas 3 (Tinggi) adalah Kerentanan yang berpotensi menyebabkan dampak serius, tetapi eksploitasi biasanya memerlukan kondisi tambahan, seperti memerlukan akses jaringan tertentu atau interaksi pengguna untuk dieksploitasi.
- d. Kelas 4 (Krisis) adalah Kerentanan yang sangat berbahaya dan memungkinkan eksploitasi penuh oleh penyerang.

Bobot demerit pada data ini telah diputuskan oleh organisasi. Dengan bobot adalah $w_1 = 2$, $w_2 = 5.5$, $w_3 = 8.5$, dan $w_4 = 10$ untuk tingkat rendah, sedang, tinggi dan krisis.

2.3 Metode Analisis Data

Pada penelitian ini menggunakan *software* statistik (*Minitab*, *Excel* dan *Rstudio*) untuk dapat menyelesaikan proses perhitungan dalam penelitian ini. Adapun langkah-langkah yang dilakukan yaitu sebagai berikut:

1. Membuat peta kendali fuzzy demerit dengan langkah-langkah sebagai berikut:

- a. Pemberian bobot Tingkat keparahan cacat setiap jenis kategori syber.
 - b. Menghitung *alpha – cut* dari TFN dengan menggunakan persamaan (10).
 - c. Menghitung statistik fuzzy demerit ${}^{ac}\tilde{D}_i$ dengan Persamaan
 - d. Menghitung batas kendali fuzzy ${}^{ac}\tilde{C}L$, ${}^{ac}\tilde{U}CL$ dan ${}^{ac}\tilde{L}CL$ menggunakan Persamaan (12), (13), dan (14) dengan menggunakan right endpoint.
 - e. Memplot statistic fuzzy demerit (${}^{ac}\tilde{D}_i$) dengan batas-batas kendali yang telah diperoleh.
2. Membuat dan menyesuaikan peta kendali Fuzzy Demerit pada data berautokorelasi dengan berbasis *Moving Centerline* (MC).
 3. Melihat Performa peta kendali Fuzzy Demerit pada data berautokorelasi dan Fuzzy Demerit biasa dengan *Out Of Control*.
 4. Melihat dan membandingkan performa peta kendali Fuzzy Demerit pada data berautokorelasi dan Fuzzy Demerit biasa.

BAB III HASIL DAN PEMBAHASAN

3.1 Peta Kendali Fuzzy Demerit


Peta kendali fuzzy digunakan dalam pengendalian kualitas untuk menangani ketidakpastian (vagueness), salah satu metode yang menerapkan konsep ini adalah peta kendali fuzzy demerit, di mana bobot cacat dinyatakan secara linguistik, seperti kritis, tinggi, sedang, dan rendah. Untuk merepresentasikan ketidakpastian serta transisi bertahap antar tingkat cacat tersebut, setiap bobot dimodelkan sebagai bilangan fuzzy berbentuk triangular fuzzy number (TFN).

- a. Pemilihan bobot tingkat keparahan cacat. Misalkan fungsi keanggotaan untuk pembobot setiap cacat didefinisikan sebagai bilangan fuzzy dalam koordinat seperti pada persamaan (7) dengan puncak TFN atau w_j^b diambil berdasarkan bobot awal sebagai berikut:

Tabel 3. Bobot Puncak (w_j^b)

j	Jenis Cacat	Bobot Awal
1	Rendah	2
2	Sedang	5.5
3	Tinggi	8.5
4	Kritis	10

Penggunaan TFN yang asimetris dipilih karena memberikan transisi yang halus antar Tingkat cacat (Baldwin & karale, 2003). Pendekatan ini sejalan dengan konsep fuzzy partition, di mana himpunan fuzzy dibentuk sedemikian rupa sehingga setiap nilai dapat memiliki derajat keanggotaan pada lebih dari satu himpunan fuzzy secara bersamaan, sehingga representasi ketidakpastian menjadi lebih realistis dan stabil ini disebut *overlap* (Klir *et. al.*, 1996). Pembentukan ini menghasilkan overlap antar kategori, sehingga satu nilai dapat memiliki derajat keanggotaan pada lebih dari satu kategori fuzzy atau dapat digambarkan TFN sebagai berikut:



Gambar 2. Tingkat (derajat) keanggotaan

Berdasarkan Gambar 2, fungsi keanggotaan bobot untuk setiap tingkat keparahan cacat didefinisikan sebagai bilangan fuzzy segitiga (TFN) pada persamaan (7) sebagai berikut:

$$\tilde{w}_j = (w_j^a, w_j^b, w_j^c)$$

dengan:

w_j^a : nilai bobot terendah yang masih mungkin,

w_j^b : nilai bobot yang paling mewakili,

w_j^c : nilai bobot tertinggi yang masih mungkin

Fungsi keanggotaan bobot fuzzy untuk masing-masing kategori tersebut didefinisikan sebagai bilangan fuzzy segitiga (*Triangular Fuzzy Number* atau TFN) dengan menggunakan indeks $j = 1, 2, 3, 4$, yang secara berurutan merepresentasikan tingkat keparahan rendah, sedang, tinggi, dan kritis. Sesuai dengan persamaan (7) sebagai berikut:

$$\tilde{w}_{Rendah} = (0, 2, 5.5)$$

$$\tilde{w}_{Sedang} = (2, 5.5, 8.5)$$

$$\tilde{w}_{Tinggi} = (5.5, 8.5, 10)$$

$$\tilde{w}_{Kritis} = (8.5, 10, 11.5)$$

Setelah menghitung TFN pada peta kendali fuzzy demerit, langkah berikutnya menentukan α – *cut* yang tujuannya untuk mengubah data fuzzy menjadi bentuk yang bisa dihitung secara numerik. α – *cut* merepresentasikan tingkat keyakinan (confidence level) terhadap bilangan fuzzy. Nilai α – *cut* yang terlalu kecil menghasilkan interval yang terlalu lebar sehingga sulit diinterpretasikan, sedangkan nilai yang terlalu besar cenderung menghilangkan ketidakpastian fuzzy. Oleh karena itu, dalam penelitian ini digunakan α – *cut* sebesar 0.8, yang merepresentasikan tingkat keanggotaan tinggi dan menghasilkan interval yang cukup sempit namun tetap mempertahankan sifat fuzzy. Pemilihan nilai ini juga konsisten dengan praktik umum dalam literatur peta kendali fuzzy. Oleh karena itu ${}^{ac}\tilde{w}_j$ dapat diperoleh dalam bentuk interval tertutup dengan menggunakan persamaan (10) sebagai berikut:

$${}^{ac}\tilde{w}_j = [w_j^a + \alpha_c(w_j^b - w_j^a); w_j^c - \alpha_c(w_j^c - w_j^b)]$$

$${}^{ac}\tilde{w}_1 = [w_1^a + \alpha_c(w_1^b - w_1^a); w_1^c - \alpha_c(w_1^c - w_1^b)]$$

$${}^{ac}\tilde{w}_1 = [0 + 0.8(2 - 0); 5.5 - 0.8(5.5 - 2)]$$

$${}^{ac}\tilde{w}_1 = [1.6; 2.7]$$

$${}^{ac}\tilde{w}_2 = [w_2^a + \alpha_c(w_2^b - w_2^a); w_2^c - \alpha_c(w_2^c - w_2^b)]$$

$${}^{ac}\tilde{w}_2 = [2 + 0.8(5.5 - 2); 8.5 - 0.8(8.5 - 5.5)]$$

$${}^{ac}\tilde{w}_2 = [4.8; 6.1]$$

$${}^{ac}\tilde{w}_3 = [w_3^a + \alpha_c(w_3^b - w_3^a); w_3^c - \alpha_c(w_3^c - w_3^b)]$$

$${}^{ac}\tilde{w}_3 = [5.5 + 0.8(8.5 - 5.5); 10 - 0.8(10 - 8.5)]$$

$${}^{ac}\tilde{w}_3 = [7.9; 8.8]$$

$${}^{ac}\tilde{w}_4 = [w_4^a + \alpha_c(w_4^b - w_4^a); w_4^c - \alpha_c(w_4^c - w_4^b)]$$

$${}^{ac}\tilde{w}_4 = [8.5 + 0.8(10 - 8.5); 11.5 - 0.8(11.5 - 10)]$$

$${}^{ac}\tilde{w}_4 = [9.7; 10.3]$$

- b. Selanjutnya dengan menggunakan operasi aritmetika pada interval tertutup. Nilai fuzzy demerit untuk unit ke- $i = 1$ dan 2 dihitung dengan persamaan (11) sebagai berikut:

$$\tilde{D}_i = \sum_{k=1}^m \tilde{w}_j c_{ij}$$

untuk $i = 1$

$${}^{ac}\tilde{D}_i = \left[\sum_{k=1}^m c_{ij} (w_j^a + \alpha_c(w_j^b - w_j^a)); \sum_{k=1}^m c_{ij} (w_j^c - \alpha_c(w_j^c - w_j^b)) \right]$$

$${}^{ac}\tilde{D}_1 = \left[\sum_{k=1}^4 c_{1,1} (w_1^a + \alpha_c(w_1^b - w_1^a)) + c_{1,2} (w_2^a + \alpha_c(w_2^b - w_2^a)) + c_{1,3} (w_3^a + \alpha_c(w_3^b - w_3^a)) + c_{1,4} (w_4^a + \alpha_c(w_4^b - w_4^a)); \left(w_1^a + \alpha_c(w_1^b - w_1^a) \right) + c_{1,2} (w_2^a + \alpha_c(w_2^b - w_2^a)) + c_{1,3} (w_3^a + \alpha_c(w_3^b - w_3^a)) + c_{1,4} (w_4^a + \alpha_c(w_4^b - w_4^a)) \right]$$

$${}^{ac}\tilde{D}_1 = [12(1.6) + 33(4.8) + 8(7.9) + 0(9.7); 12(2.7) + 33(6.1) + 8(8.8) + (0)10.3]$$

$${}^{ac}\tilde{D}_1 = [240.8; 304.1]$$

Untuk $i = 2$

$${}^{ac}\tilde{D}_2 = [\sum_{k=1}^4 c_{2,1} (w_{2,1} + \alpha_c(w_{2,2} - w_{2,1})) + c_{2,2} (w_{3,1} + \alpha_c(w_{3,2} - w_{3,1})) + c_{2,3} (w_{3,1} + \alpha_c(w_{3,2} - w_{3,1})) + c_{2,4} (w_{4,1} + \alpha_c(w_{4,2} - w_{4,1}))]; \sum_{k=1}^4 c_{2,1} (w_{1,1} + \alpha_c(w_{1,2} - w_{1,1})) + c_{2,2} (w_{2,1} + \alpha_c(w_{2,2} - w_{2,1})) + c_{2,3} (w_{3,1} + \alpha_c(w_{3,2} - w_{3,1})) + c_{2,4} (w_{4,1} + \alpha_c(w_{4,2} - w_{4,1}))]$$

$${}^{ac}\tilde{D}_2 = [12(1.6) + 30(4.8) + 8(7.9) + 0(9.7); 12(2.7) + 30(6.1) + 8(8.8) + 0(10.3)]$$

$${}^{ac}\tilde{D}_2 = [226.4; 285.8]$$

Dengan cara yang sama untuk obeservasi ke— $i = 3, 4, \dots, 28$ hasilnya dilambangkan dengan ${}^{ac}\tilde{D}_3, {}^{ac}\tilde{D}_4, \dots, {}^{ac}\tilde{D}_{28}$, maka hasilnya dituliskan dalam Tabel 4.

Tabel 4. Data Lengkap Fuzzy Demerit

Bulan	Rendah	Sedang	Tinggi	Kritis	${}^{ac}_L\tilde{D}_i$	${}^{ac}_R\tilde{D}_i$
1	12	33	8	0	240.8	304.1
2	12	30	8	0	226.4	285.8
3	10	30	7	0	215.3	271.6
4	10	33	9	0	245.5	307.5
5	13	33	9	0	250.3	315.6
6	19	41	8	0	290.4	371.8
7	24	45	7	0	309.7	400.9
8	21	46	9	0	325.5	416.5
9	16	42	9	0	298.3	378.6
10	15	46	7	0	300.1	382.7
11	15	41	9	0	291.9	369.8
12	14	47	9	0	319.1	403.7
13	19	54	9	0	360.7	459.9
14	18	71	12	1	474.1	597.6
15	13	47	12	1	350.9	437.7
16	18	63	16	1	467.3	584
17	19	80	21	8	657.9	806.5
18	18	84	25	8	707.1	863.4
19	22	93	26	8	764.6	937.9
20	26	118	26	7	881.3	1090.9
21	14	99	25	8	772.7	944.1
22	20	123	27	8	913.3	1124.3
23	19	130	29	8	961.1	1181.9
24	23	99	21	6	736.1	912.6

25	23	103	21	6	755.3	937
26	21	91	17	3	633.8	792.3
27	22	88	15	2	595.5	748.8
28	18	48	7	0	314.5	403
Jumlah	494	1858	408	75	17030.5	13659.5
Rata-rata	17.643	66.357	14.571	2.678	608.232	487.84

Sumber: dioleh 2026

Sehingga diperoleh CL berdasarkan data dalam Tabel 4 dengan menggunakan persamaan (12) sebagai berikut:

$${}^{ac}\tilde{CL} = [\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)); \sum_{j=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))]$$

$${}^{ac}\tilde{CL} = [17.64(1.6) + 66.36(4.8) + 14.57(7.9) + 2.68(9.7); 17.64(2.7) + 66.36(6.1) + 14.57(8.8) + 2.68(10.3)]$$

$${}^{ac}\tilde{CL} = [107.62 + 318.51 + 115.10 + 26; 47.63 + 404.8 + 128.22 + 27.60]$$

$${}^{ac}\tilde{CL} = [567.23; 608.25]$$

Untuk Standar Deviasi Fuzzy Demerit menggunakan persamaan (13) sebagai berikut:

$${}^{ac}\sigma_{FD} = \left[\sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2}; \sqrt{\sum_{k=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2} \right]$$

$${}^{ac}\sigma_{FD} = [\sqrt{17,64(1.6)^2 + 66,36(4.8)^2 + 14,57(7.9)^2 + 2,68(9.7)^2}; \sqrt{17,64(2.7)^2 + 66,36(6.1)^2 + 14,57(8.8)^2 + 2,68(10.3)^2}]$$

$${}^{ac}\sigma_{FD} = [\sqrt{45.16 + 1528.93 + 909.31 + 252.16}; \sqrt{128.59 + 2469.25 + 1128.3 + 284.32}]$$

$${}^{ac}\sigma_{FD} = [52.59; 63.33]$$

Dengan menggunakan $L = 3$, maka nilai UCL dapat diperoleh dengan persamaan (14) sebagai berikut:

$${}^{ac}U\tilde{CL} = [\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) + L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2};$$

$$\sum_{j=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) + L \sqrt{\sum_{k=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2}$$

Selanjutnya, rumus dari

$${}^{a_c}U\tilde{C}L = \sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) + L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2}$$

disebut sebagai UCL *Left Poin*. Kemudian akan dihitung nilai dari UCL left Poin berdasarkan data yang ada:

$$\begin{aligned} {}^{a_c}U\tilde{C}L &= \sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) + L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2} \\ &= \sum_{j=1}^{28} \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) + L \sqrt{\sum_{j=1}^{28} \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2} \\ &= 17.64(1.6) + 66.36(4.8) + 14.57(7.9) + 2.68(9.7) + 3(52.59) \\ &= 725 \end{aligned}$$

Dan untuk rumus UCL *Right Point* sebagai berikut:

$$\begin{aligned} {}^{a_c}U_R\tilde{C}L &= \sum_{j=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) + L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2} \\ &= \sum_{j=1}^{28} \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) + L \sqrt{\sum_{j=1}^{28} \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2} \\ &= 17.64(2.7) + 66.36(6.1) + 14.57(8.8) + 2.68(10.3) + 3(63.33) \\ &= 798.24 \end{aligned}$$

Sehingga diperoleh nilai dari UCL sebagai berikut:

$$\begin{aligned} {}^{a_c}U\tilde{C}L &= [{}^{a_c}U_L\tilde{C}L; {}^{a_c}U_R\tilde{C}L] \\ &= [725; 798.24] \end{aligned}$$

Nilai LCL ditentukan menggunakan rumus sebagai berikut:

$${}^{a_c}L\tilde{C}L = [\max \sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) - L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2}, 0; \\ \max \sum_{j=1}^m \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) - L \sqrt{\sum_{j=1}^m \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2}, 0]$$

Penulisan ${}^{a_c}L\tilde{C}L = [{}^{a_c}L\tilde{C}L; {}^{a_c}L\tilde{C}L]$, dimana ${}^{a_c}L\tilde{C}L$ adalah nilai LCL Left Point.

$${}^{a_c}L\tilde{C}L = \max \sum_{j=1}^{28} \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a)) - L \sqrt{\sum_{j=1}^{28} \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b))^2}, 0 \\ = \max(17.64(1.6) + 66.36(4.8) + 14.57(7.9) + 2.68(9.7) - 3(63.33)), 0 \\ = \max(567.23 - 189.99), 0 \\ = 377.24$$


Sedangkan ${}^{a_c}L\tilde{C}L$ adalah nilai untuk LCL Right Point.

$${}^{a_c}L\tilde{C}L = \max \sum_{j=1}^{28} \bar{c}_j (w_j^c - \alpha_c(w_j^c - w_j^b)) - L \sqrt{\sum_{j=1}^{28} \bar{c}_j (w_j^a + \alpha_c(w_j^b - w_j^a))^2}, 0 \\ = \max(17.64(2.7) + 66.36(6.1) + 14.57(8.8) + 2.68(10.3) - 3(52.59)), 0 \\ = 608.25 - 157.77 \\ = 450.48$$

Sehingga diperoleh nilai dari LCL sebagai berikut:

$${}^{a_c}L\tilde{C}L = [{}^{a_c}L\tilde{C}L; {}^{a_c}L\tilde{C}L] \\ = [377.24; 450.48]$$

Maka penentuan kaidah keputusan sesuai dengan nilai ${}^{ac}\tilde{D}_i$, dengan batas kendali yaitu ${}^{a_c}\tilde{C}L$, ${}^{a_c}U\tilde{C}L$ dan ${}^{a_c}L\tilde{C}L$ untuk data kerentanan siber dapat diamati melalui peta kendali Fuzzy Demerit. Fuzzy Demerit *right point* digunakan sebagai dasar atau perwakilan dari peta kendali Fuzzy Demerit, namun penampilan peta kendali Left Point sebagai pendukung atas peta kendali *right point* (Shu & Wu, 2011). Maka peta kendali Fuzzy Demerit sebagai berikut:



Gambar 3. Peta kendali Fuzzy Demerit

Gambar 3 menunjukkan peta kendali fuzzy demerit dengan pendekatan *left point* (LP) dan *right point* (RP). Berdasarkan grafik, proses pengelolaan kerentanan siber 78,57% berada dalam kondisi tidak terkendali (*out of control*) karena beberapa titik pengamatan melampaui batas kendali atas (UCL), terutama pada periode pertengahan hingga akhir pengamatan.

Pada pendekatan *left point*, meskipun menggunakan estimasi risiko minimum, terlihat adanya peningkatan nilai fuzzy demerit yang cukup tajam hingga melewati UCL. Hal ini menunjukkan bahwa bahkan pada kondisi optimis, proses masih mengalami ketidakstabilan. Setelah periode tersebut, nilai kembali turun ke dalam batas kendali, namun pelanggaran sebelumnya tetap menandakan proses tidak stabil secara statistik.

Sementara itu, pendekatan *right point* menunjukkan kondisi yang lebih ekstrem. Nilai fuzzy demerit meningkat lebih tinggi dan lebih banyak melampaui UCL karena RP merepresentasikan risiko maksimum atau skenario pesimis. Pola ini mengindikasikan adanya faktor penyebab khusus yang kuat dan berpotensi bersifat struktural terhadap peningkatan kerentanan siber.

Perbedaan pola antara LP dan RP terjadi karena sifat bilangan fuzzy segitiga, di mana LP menggambarkan kondisi optimis dan RP menggambarkan kondisi pesimis. Secara keseluruhan, kedua grafik menunjukkan bahwa proses pengendalian kerentanan siber belum stabil dan memerlukan tindakan perbaikan yang lebih menyeluruh.


3.2 Data Berautokorelasi

Uji Autokorelasi yang dilakukan pada penelitian dengan menggunakan metode Ljung-Box. Hipotesis yang digunakan dalam uji Ljung-Box adalah sebagai berikut:


$$H_0: \rho_1 = \rho_2 = \dots = \rho_h = 0$$

$$H_1: \exists \rho_k \neq 0 \text{ (Ada Autokorelasi pada minimal satu lag)}$$

Berdasarkan hasil pengujian uji Ljung-Box, diperoleh nilai p – $value$ yaitu 9.455×10^{-07} untuk RP dan 8.851×10^{-07} untuk LP ini lebih kecil dari 0.05, maka tolak H_0 terima H_1 . Sehingga, dapat disimpulkan bahwa autokorelasi yang terjadi pada data adalah autokorelasi positif. Selain itu ACF dapat dilihat sebagai berikut:




Gambar 4. ACF Fuzzy Demerit Left Poin




Gambar 5. ACF Fuzzy Demerit Right Poin

Pada lag 1 hingga 2, nilai ACF bersifat positif dan menurun secara bertahap. Beberapa lag awal melewati batas signifikansi pada tingkat kepercayaan 5%, serta tidak terlihat adanya *cut-off* yang tajam. Pola ini menunjukkan bahwa data tidak bersifat *white noise* dan mengindikasikan adanya ketergantungan serial yang konsisten dengan karakteristik proses *random walk*.



Gambar 6. PACF Fuzzy Demerit Left Poin



Gambar 7. PACF Fuzzy Demerit Right Poin

Pada PACF melewati batas taraf kepercayaan pada lag 1 yang menyarankan model deret waktu adalah AR(1) untuk proses tersebut.

3.3 Fuzzy Demerit berbasis *Moving Centerline*

3.3.1 Penentuan batas kendali Fuzzy Demerit berbasis *Moving Centerline* dengan EWMA

Sebagai alternatif untuk pendekatan di atas adalah dengan menggunakan model model EWMA (*Exponentially Weighted Moving Everage*) pada persamaan (16), dengan parameter pembobot $0 < \lambda \leq 1$ dan untuk $Z_0 = \bar{X}_i$ dengan X_i adalah data awal. Nilai Z_i pada persamaan (17) sebagai berikut:

$$Z_i = \lambda X_i + (1 - \lambda)Z_{i-1}$$

dimana X_i adalah ${}^{ac}\tilde{D}_i$ pada persamaan (11) sebagai nilai awal sebagai berikut:

$$X_i = {}^{ac}\tilde{D}_i = \left[\sum_{k=1}^m c_{ik} (w_{k,1} + \alpha_c (w_{k,2} - w_{k,1})) ; \sum_{k=1}^m c_{ik} (w_{k,3} - \alpha_c (w_{k,3} - w_{k,2})) \right]$$

dimisalkan:

$$\sum_{k=1}^m c_{ik} (w_{k,1} + \alpha_c (w_{k,2} - w_{k,1})) = {}^{ac}_L \tilde{D}_i$$

dan untuk

$$\sum_{k=1}^m c_{ik} (w_{k,3} - \alpha_c (w_{k,3} - w_{k,2})) = {}^{ac}_R \tilde{D}_i$$

Maka:

$${}^{ac}X_i = [{}^{ac}_L \tilde{D}_{i-1}; {}^{ac}_R \tilde{D}_{i-1}] \quad (30)$$

Jika Z_i diramalkan untuk pengamatan pada periode $i + 1$, maka prediksi masa depan ini dilambangkan dengan:

$${}^{ac}\hat{Z}_{i+1}(i) = {}^{ac}\tilde{Z}_i \quad (31)$$

Kesalahan prediksi residual satu langkah kedepan mengikuti metode dari Mastrangelo dan Montgomery (1995) yaitu $e_i = {}^{ac}\tilde{D}_i - {}^{ac}\tilde{Z}_i(i-1)$ didistribusikan secara independen dan tidak berkorelasi dengan rata-rata nol dan standar deviasi maka untuk ${}^{ac}\tilde{e}_i$ dapat dilihat sebagai berikut:

$${}^{ac}\tilde{e}_i = [{}^{ac}_L \tilde{D}_i - {}^{ac}_L \tilde{Z}_i(i-1); {}^{ac}_R \tilde{D}_i - {}^{ac}_R \tilde{Z}_i(i-1)] \quad (32)$$

Kemudian substitusi error kepersamaan ewma sebagai berikut:

$$\begin{aligned} Z_i &= \lambda X_i + (1 - \lambda)Z_{i-1} \\ {}^{ac}\tilde{Z}_i &= \lambda {}^{ac}\tilde{D}_i + (1 - \lambda) {}^{ac}\tilde{Z}_{i-1} \\ {}^{ac}\tilde{Z}_i &= \lambda {}^{ac}\tilde{D}_i + {}^{ac}\tilde{Z}_{i-1} + \lambda {}^{ac}\tilde{Z}_{i-1} \end{aligned}$$

$${}^{a_c}\tilde{Z}_i = {}^{a_c}\tilde{Z}_{i-1} + \lambda \left({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1) \right)$$

$${}^{a_c}\tilde{Z}_i = {}^{a_c}\tilde{Z}_{i-1} + \lambda {}^{a_c}\tilde{e}_i$$

sehingga menghasilkan persamaan sebagai berikut:

$${}^{a_c}\tilde{Z}_i = [{}^{a_c}\tilde{Z}_{i-1} + \lambda {}^{a_c}\tilde{e}_i; {}^{a_c}\tilde{Z}_{i-1} + \lambda {}^{a_c}\tilde{e}_i] \quad (33)$$

Pada pendekatan random walk atau residual prediksi, error diasumsikan memiliki rata-rata nol, sehingga:

$$\mu_e = E(e_i) = 0 \quad (34)$$

Akibatnya, standar deviasi error menjadi:

$$\sigma_p = \sqrt{E(e_i^2)} \quad (35)$$

Sehingga standar deviasi dari error, dapat dilihat sebagai berikut:

$${}^{a_c}\sigma_p = \left[\sqrt{\frac{\sum_{i=1}^N \left({}^{a_c}\tilde{D}_i - \frac{{}^{a_c}\tilde{Z}_i(i-1)}{N} \right)^2}{N}}; \sqrt{\frac{\sum_{i=1}^N \left({}^{a_c}\tilde{D}_i - \frac{{}^{a_c}\tilde{Z}_i(i-1)}{N} \right)^2}{N}} \right] \quad (36)$$

Selanjutnya, standar deviasi ini digunakan dalam pembentukan batas kendali probabilistik:

$$\Pr[-U_{\alpha/2}\sigma_p \leq e_i \leq U_{\alpha/2}\sigma_p] = 1 - \alpha$$

$$\Pr[-U_{\alpha/2}\sigma_p \leq {}^{a_c}\tilde{D}_i - \frac{{}^{a_c}\tilde{Z}_i(i-1)}{N} \leq U_{\alpha/2}\sigma_p] = 1 - \alpha$$

$$\Pr \left[\frac{{}^{a_c}\tilde{Z}_i(i-1)}{N} - U_{\alpha/2}\sigma_p \leq {}^{a_c}\tilde{D}_i \leq \frac{{}^{a_c}\tilde{Z}_i(i-1)}{N} + U_{\alpha/2}\sigma_p \right] = 1 - \alpha$$

dimana $U_{\alpha/2}$ adalah kuantil distribusi normal, dalam literatur SPC, kuantil $U_{\alpha/2}$ sering diganti dengan konstanta batas kendali L .

Dengan demikian, batas kendali disesuaikan secara untuk mencapai kinerja pengendalian yang diinginkan. Sehingga UCL dan LCL peta kendali Fuzzy Demerit berbasis *Moving Centerline* sebagai berikut:

$${}^{a_c}UCL_i = \left[\frac{{}^{a_c}\tilde{Z}_i(i-1)}{N} + L \sqrt{\frac{\sum_{i=1}^N \left({}^{a_c}\tilde{D}_i - \frac{{}^{a_c}\tilde{Z}_i(i-1)}{N} \right)^2}{N}}; \right. \quad (37)$$

$$\begin{aligned}
& {}^a_c\tilde{Z}_i(i-1) + L \sqrt{\frac{\sum_{i=1}^N ({}^a_c\tilde{D}_i - {}^a_c\tilde{Z}_i(i-1))^2}{N}} \\
& {}^a_cLCL_i = [\max({}^a_c\tilde{Z}_i(i-1) - L \sqrt{\frac{\sum_{i=1}^N ({}^a_c\tilde{D}_i - {}^a_c\tilde{Z}_i(i-1))^2}{N}}, 0); \\
& \max({}^a_c\tilde{Z}_i(i-1) + L \sqrt{\frac{\sum_{i=1}^N ({}^a_c\tilde{D}_i - {}^a_c\tilde{Z}_i(i-1))^2}{N}}, 0)]
\end{aligned} \tag{38}$$

3.3.2 Pemilihan lamda (λ)

Average Run Length (ARL) adalah jumlah rata-rata atau sampel yang harus digambarkan sebelum sebuah titik atau sampel menunjukkan suatu keadaan tidak terkendali (Montgomery, 2009). Pada penelitian suriyakat *et. al.*, (2012) menentukan parameter lamda berdasarkan evaluasi performa ARL untuk nilai-nilai lamda yang direkomendasikan dalam literatur EWMA. Berbeda dengan pendekatan Montgomery dan Mastrangelo nilai λ pada penelitiannya yaitu parameter dipilih berdasarkan SSE, begitu pula pada nembard dan nembard namun desain tidak mempertimbangkan autokorelasi. Literatur EWMA klasik menentukan parameter λ melalui pendekatan desain berbasis ARL. Namun, pendekatan ini mengasumsikan observasi bersifat independen.

Dalam data yang berautokorelasi, nilai L tidak boleh diperlakukan sebagai konstanta tetap seperti $L = 3$ pada peta kendali klasik. Nilai ini harus dikalibrasi agar *Average Run Length (ARL) in-control* tetap sesuai dengan target yang diinginkan. Prinsip ini sangat jelas didukung (Afful-Dadzie & Allen, 2016). Sehingga pada penelitian ini, nilai λ dan L ditentukan secara bersamaan sehingga diperoleh kombinasi parameter yang mampu menghasilkan residual bersifat *white noise* serta memenuhi nilai ARL yang diinginkan.

Parameter pemulusan λ ditentukan secara *data-driven* meminimalkan galat prediksi satu langkah ke depan. Penentuan nilai λ dilakukan secara empiris dengan mempertimbangkan kriteria utama, yaitu penghilangan autokorelasi residual. Pengujian autokorelasi residual dilakukan menggunakan uji Ljung–Box. Hipotesis yang digunakan dalam uji Ljung–Box sebagai berikut:

$$H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$$

$$H_1: \rho_k \neq 0 \text{ (Ada Autokorelasi pada minimal satu lag)}$$

dengan bantuan R studio dapat dilihat hasilnya pada tabel 5 sebagai berikut:

Tabel 5. Pemilihan Lamda

λ	$P - Value$ (<i>Left Poin</i>)	$P - Value$ (<i>Right Poin</i>)
0.1	2.834×10^{-7}	8.809×10^{-9}
0.2	2.760×10^{-5}	5.755×10^{-5}
0.3	2.047×10^{-4}	1.783×10^{-3}
0.4	2.248×10^{-3}	9.847×10^{-3}
0.5	7.866×10^{-3}	3.342×10^{-2}
0.6	0.039	0.081
0.7	0.139	0.133

Sumber: data dioleh 2026

Berdasarkan hasil uji Ljung–Box pada residual fuzzy demerit *Left Poin* dan *Right Poin*, diperoleh bahwa karakteristik autokorelasi pada kedua sisi tidak identik, sehingga parameter pemulusan λ ditentukan secara terpisah. Untuk fuzzy demerit *Left Poin* nilai $\lambda = 0.7$ dan untuk *Right Poin* nilai $\lambda = 0.6$ dipilih karena $p - value > 0.05$ yang artinya H_0 diterima. Hal ini menunjukkan bahwa tidak terdapat autokorelasi yang signifikan pada residual.

Selanjutnya, berdasarkan hasil simulasi ARL, nilai L ditentukan sedemikian sehingga ARL *in-control* mendekati nilai target, yaitu sekitar 200, dengan simulasi data 2000, maka hasil ARL didapatkan sebagai berikut:

Tabel 6. Uji ARL dengan uji coba 2000

<i>Shift/L</i>	<i>Left poin</i> dengan $\lambda = 0.7$			<i>Right Poin</i> dengan $\lambda = 0.6$		
	2	2.81	3	2	2.81	3
0	25.67	210.32	373.08	24.40	213.21	377.929
0.5	24.90	205.66	392.56	22.80	205.59	382.53
1	22.83	211.08	365.55	20.83	201.76	384.87
2	12.84	178.38	365.02	10.97	176.77	330.10
3	2.97	89.40	230.22	2.25	80.87	182.88

Sumber: data dioleh 2026

Pada Tabel 6 dapat dilihat nilai yang mendekati nilai 200 adalah $L = 2.81$ untuk untuk *Right and Left Poin*. Dengan demikian, pemilihan parameter λ dan L pada penelitian ini tidak hanya didasarkan pada kemampuan EWMA dalam menghilangkan pengaruh autokorelasi, tetapi juga pada kemampuan peta kendali dalam mencapai kinerja deteksi yang diharapkan, yang direpresentasikan oleh nilai ARL. Sehingga dapat dilanjutkan ke pembuatan peta kendali.

3.3.3 Studi kasus Data Cyber

Mencari residual pertama menggunakan persamaan (32) sebagai berikut:

$${}^{ac}\tilde{e}_i = [{}^L_{ac}\tilde{D}_i - {}^L_{ac}\tilde{Z}_i(i-1); {}^R_{ac}\tilde{D}_i - {}^R_{ac}\tilde{Z}_i(i-1)]$$

$${}^{ac}\tilde{e}_1 = [{}^L_{ac}\tilde{D}_1 - {}^L_{ac}\tilde{Z}_0; {}^R_{ac}\tilde{D}_1 - {}^R_{ac}\tilde{Z}_0]$$

$${}^{ac}\tilde{e}_1 = [240.8 - 487.84; 304.1 - 611.45]$$

$${}^{ac}\tilde{e}_1 = [-247.04; -307.35]$$

Maka perhitungan nilai ${}^{ac}\tilde{Z}_i$ yang didapat menggunakan persamaan (33) sebagai berikut:

$${}^{ac}\tilde{Z}_i = [{}^L_{ac}\tilde{Z}_{i-1} + \lambda {}^L_{ac}\tilde{e}_i; {}^R_{ac}\tilde{Z}_{i-1} + \lambda {}^R_{ac}\tilde{e}_i]$$

$${}^{ac}\tilde{Z}_1 = [487.84 + (0.7)(-247.04); 611.45 + (0.6)(-307.35)]$$

$${}^{ac}\tilde{Z}_1 = [487.84 - 172.93; 611.45 - 184.41]$$

$${}^{ac}\tilde{Z}_1 = [314.91; 427.04]$$

$${}^{ac}\tilde{Z}_2 = [314.91 + (0.7)(-88.51); 427.04 + (0.6)(-141.24)]$$

$${}^{ac}\tilde{Z}_2 = [314.91 - 61.96; 427.04 - 84.744]$$

$${}^{ac}\tilde{Z}_2 = [252.95; 342.29]$$

⋮

$${}^{ac}\tilde{Z}_{28} = [619.02 + (0.7)(-304.52); 796.98 + (0.6)(-393.98)]$$

$${}^{ac}\tilde{Z}_{28} = [619.02 - 213.16; 796.98 - 236.39]$$

$${}^{ac}\tilde{Z}_{28} = [405.86; 560.59]$$

Hasil lebih lengkapnya dapat dilihat pada Lampiran 7 dan Lampiran 8.

Sehingga Standar Deviasi yang diperoleh dengan menggunakan persamaan (36) sebagai berikut:

$${}^{ac}\sigma_p = \left[\sqrt{\frac{\sum_{i=1}^N ({}^L_{ac}\tilde{D}_i - {}^L_{ac}\tilde{Z}_i(i-1))^2}{N}}; \sqrt{\frac{\sum_{i=1}^N ({}^R_{ac}\tilde{D}_i - {}^R_{ac}\tilde{Z}_i(i-1))^2}{N}} \right]$$

$${}^{ac}\sigma_p = \sqrt{\frac{\sum_{i=1}^{28} (-247.04)^2 + (-88.51)^2 + \dots + (-304.52)^2}{28}};$$

$$\sqrt{\frac{\sum_{i=1}^{28} (-307.35)^2 + (-141.24)^2 + \dots + (-393.38)^2}{28}}$$

$${}^{ac}\sigma_p = [117.08; 151.596]$$

Maka untuk UCL dan LCL pada peta kendali Fuzzy Demerit berbasis *Moving centerline* menggunakan persamaan (37) dengan nilai $L = 2.81$ untuk kiri dan kanan sebagai berikut:

$${}^{a_c}UCL_i = \left[{}^{a_c}\tilde{Z}_{i-1} + L\sqrt{\frac{\sum_{i=1}^N \left({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1) \right)^2}{N}}; {}^{a_c}\tilde{Z}_{i-1} + L\sqrt{\frac{\sum_{i=1}^N \left({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1) \right)^2}{N}} \right]$$

$${}^{a_c}UCL_1 = [487.84 + 2.81 (117.08); 611.45 + 2.81 (151.596)]$$

$${}^{a_c}UCL_1 = [417.94; 1037.43]$$

$${}^{a_c}UCL_2 = [314.91 + 2.81 (117.08); 427.04 + 2.81(151.596)]$$

$${}^{a_c}UCL_2 = [816.83; 853.02]$$

⋮

$${}^{a_c}UCL_{28} = [619.02 + 2.81(117.08); 796.98 + 2.81(151.596)]$$

$${}^{a_c}UCL_{28} = [948.02; 1222.96]$$

Untuk LCL sebagai berikut:

$${}^{a_c}LCL_i = \left[\max \left({}^{a_c}\tilde{Z}_{i-1} - L\sqrt{\frac{\sum_{i=1}^N \left({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1) \right)^2}{N}}, 0 \right); \max \left({}^{a_c}\tilde{Z}_{i-1} - L\sqrt{\frac{\sum_{i=1}^N \left({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1) \right)^2}{N}}, 0 \right) \right]$$

$${}^{a_c}LCL_1 = [487.84 - 2.81 (117.08); 611.45 - 2.81 (151.596)]$$

$$= [158.85;]$$

$${}^{a_c}LCL_2 = [314.91 - 2.81 (117.08); 427.04 - 2.81(151.596)]$$


$${}^{a_c}LCL_2 = [0; 1.05]$$

⋮

$${}^{a_c}LCL_{28} = [619.02 + 2.81(117.08); 796.98 + 2.81(151.596)]$$

$${}^{a_c}UCL_{28} = [290.03; 370.99]$$

Hasil lebih lengkap untuk UCL dan LCL dapat dilihat pada Lampiran 7 dan Lampiran 8. Maka peta kendali fuzzy demerit berbasis *Moving Centerline* didapatkan sebagai berikut:



Gambar 8. Fuzzy Demerit berbasis *Moving Centerline*

Gambar 8 menunjukkan peta kendali fuzzy demerit berbasis *moving centerline* menggunakan pendekatan *right point* (RP) dan *left point* (LP). Garis pusat serta batas kendali bergerak mengikuti perubahan data sehingga lebih adaptif terhadap dinamika tingkat kerentanan siber. Oleh karena itu, peta kendali ini lebih sesuai untuk mendeteksi kondisi ekstrem atau lonjakan tingkat kerentanan siber yang berpotensi berdampak besar.

Berdasarkan grafik, seluruh nilai fuzzy demerit masih berada di dalam batas kendali atas (UCL) dan batas kendali bawah (LCL), sehingga proses dinyatakan terkendali secara statistik (*in control*). Meskipun terjadi peningkatan nilai demerit pada periode sekitar bulan ke-18 hingga ke-23, kondisi tersebut masih berada dalam batas kendali yang diizinkan.

Pendekatan *right point* menghasilkan batas kendali yang lebih konservatif karena berfokus pada nilai maksimum bilangan fuzzy, sehingga lebih cocok untuk mendeteksi lonjakan ekstrem kerentanan siber. Sementara itu, pendekatan *left point* lebih sensitif terhadap perubahan kecil karena menggunakan nilai minimum bilangan fuzzy.


Secara keseluruhan, kedua pendekatan saling melengkapi dalam memantau dinamika kerentanan siber, baik untuk mendeteksi perubahan kecil maupun lonjakan ekstrem.

3.3.4 Penentuan batas kendali Fuzzy Demerit berbasis Moving Centerline dengan Runtun Waktu


Berdasarkan Gambar 6 dan 7 diperoleh bahwa data mengikuti model AR(1), sehingga peta kendali Moving Centerline dibangun dengan menggunakan nilai prediksi satu langkah ke depan dari model AR(1) sebagai garis tengah yang bersifat dinamis. Dengan demikian, centerline secara langsung merepresentasikan struktur autokorelasi proses, sedangkan batas kendali dibentuk berdasarkan simpangan baku residual model AR(1). Berdasarkan persamaan (23) model AR(1) yang diperoleh dengan dibantu oleh minitab sesuai sebagai berikut:

$${}^a_c\hat{X}_i = [26.9 + 0.9303 {}^a_c\tilde{D}_{i-1}; 35 + 0.9282 {}^a_c\tilde{D}_{i-1}] \quad (39)$$


Kemudian untuk menunjukkan bahwa model memberikan kecocokan model dapat dilihat dari gambar sebagai berikut:




Gambar 9. ACF Residual AR(1) Left Point



Gambar 10. PACF Residual AR(1) Left Point



Gambar 11. ACF Residual AR(1) Right Point



Gambar 12. PACF Residual AR(1) Right Point

Dapat dilihat gambar diatas menunjukkan bahwa model memberikan kecocokan yang memuaskan karena tidak ada yang keluar dari garis putus-putus ACF dan PACF untuk itu model dapat digunakan.

Maka kesalahan prediksi residual didistribusikan secara independent dan tidak berautokorelasi dengan rata-rata nol dan standar deviasi maka untuk ${}^{ac}\tilde{e}_i$ sebagai berikut:

$${}^{ac}\tilde{e}_i = [{}^{ac}_L\tilde{D}_i - {}^{ac}_L\hat{X}_i; {}^{ac}_R\tilde{D}_i - {}^{ac}_R\hat{X}_i] \quad (40)$$

Sehingga standar deviasi dari error, dapat dilihat sebagai berikut:

$${}^{ac}\sigma_p = \left[\sqrt{\frac{\sum_{i=1}^N ({}^{ac}_L\tilde{D}_i - {}^{ac}_L\hat{X}_i)^2}{N}}; \sqrt{\frac{\sum_{i=1}^N ({}^{ac}_R\tilde{D}_i - {}^{ac}_R\hat{X}_i)^2}{N}} \right] \quad (41)$$

dengan demikian, batas kendali disesuaikan secara untuk mencapai kinerja pengendalian yang diinginkan. Sehingga UCL dan LCL peta kendali Fuzzy Demerit berbasis *Moving Centerline* sebagai berikut:

$${}^{ac}UCL_i = [{}^{ac}_L\hat{X}_i + L \sqrt{\frac{\sum_{i=1}^N ({}^{ac}_L\tilde{D}_i - {}^{ac}_L\hat{X}_i)^2}{N}}; {}^{ac}_R\hat{X}_i + \sqrt{\frac{\sum_{i=1}^N ({}^{ac}_R\tilde{D}_i - {}^{ac}_R\hat{X}_i)^2}{N}}] \quad (42)$$

$${}^{ac}LCL_i = [\max({}^{ac}_L\hat{X}_i - L \sqrt{\frac{\sum_{i=1}^N ({}^{ac}_L\tilde{D}_i - {}^{ac}_L\hat{X}_i)^2}{N}}, 0); \max({}^{ac}_R\hat{X}_i - \sqrt{\frac{\sum_{i=1}^N ({}^{ac}_R\tilde{D}_i - {}^{ac}_R\hat{X}_i)^2}{N}}, 0)] \quad (43)$$

3.3.5 Studi Kasus untuk Moving Centerline dengan AR(1)

Setelah model deret waktu memberikan kecocokan yang baik, maka akan menghilangkan autokorelasi, sehingga dihasilkan residual independen. Untuk pembuatan peta kendali Residual untuk garis tengah dan standar deviasi. Pada ACF dan PACF untuk residual perlu mencari ${}^{ac}\hat{X}_i$ dengan Persamaan (40) sebagai berikut:

$${}^{ac}\hat{X}_i = [26.9 + 0.9303 {}^{ac}_L\tilde{D}_{i-1}; 35 + 0.9282 {}^{ac}_R\tilde{D}_{i-1}]$$

$${}^{ac}\hat{X}_1 = [26.9 + 0.9303(487.84); 35 + 0.9282(611.45)]$$

$${}^{ac}\hat{X}_1 = [480.74; 602.55]$$

$${}^{ac}\hat{X}_2 = [26.9 + 0.9303(240.8); 35 + 0.9282(304.1)]$$

$${}^{ac}\hat{X}_2 = [250.92; 317.27]$$

$${}^{ac}\hat{X}_3 = [26.9 + 0.9303(226.4); 35 + 0.9282(285.8)]$$

$${}^a_c\hat{X}_3 = [237.52; 300.28]$$

⋮

$${}^a_c\hat{X}_{28} = [26.9 + 0.9303(595.5); 35 + 0.9282(751.2)]$$

$${}^a_c\hat{X}_{28} = [580.89; 732.26]$$

Dapat dilihat lebih lengkap untuk nilai right poin dan left point pada lampiran 13 dan lampiran 14. Mencari standar deviasi menggunakan persamaan (41) sebagai berikut:

$${}^a_c\sigma_p = \left[\sqrt{\frac{\sum_{i=1}^N (240.8 - 480.74)^2 + (226.4 - 250.92)^2 + \dots + (314.5 - 580.89)^2}{28}}; \right. \\ \left. \sqrt{\frac{\sum_{i=1}^N (304.1 - 602.55)^2 + (285.8 - 317.27)^2 + \dots + (403 - 732.26)^2}{28}} \right]$$

$${}^a_c\sigma_p = [144.10; 177.94]$$

Menentukan nilai L sedemikian sehingga ARL *in-control* mendekati nilai target yaitu sekitar 200, dengan simulasi data 2000, maka hasil ARL didapatkan sebagai berikut:

Tabel 7. ARL Fuzzy Demerit berbasis Moving Centerline AR(1)

	<i>Left poin</i>			<i>Right Poin</i>		
<i>Shift/L</i>	2	2.82	3	2	2.82	3
0	23.55	200.78	351.41	23.40	211.61	346.90
0.5	14.59	92.82	161.07	14.43	96.53	157.80
1	7.45	29.68	44.46	7.29	30.06	45.62
2	4.19	11.45	16.31	4.29	11.70	16.19
3	3.02	5.82	7.39	2.99	5.79	7.20

Sumber: diolah 2026

Maka untuk UCL dan LCL pada peta kendali Fuzzy Demerit berbasis *Moving centerline* AR(1) menggunakan persamaan (42) dan persamaan (43) dengan nilai $L = 2.82$ untuk *left* dan *right* sebagai berikut:

$${}^a_cUCL_i = \left[{}^a_c\hat{X}_i + L \sqrt{\frac{\sum_{i=1}^N ({}_L^a_c\tilde{D}_i - {}_L^a_c\hat{X}_i)^2}{N}}; {}^a_c\hat{X}_i + \sqrt{\frac{\sum_{i=1}^N ({}_R^a_c\tilde{D}_i - {}_R^a_c\hat{X}_i)^2}{N}} \right]$$

$${}^a_cUCL_1 = [480.59 + 2.82(144.10); 584.69 + 2.82(177.94)]$$

$${}^a_cUCL_1 = [887.10; 1104.33]$$

$${}^a_c UCL_2 = [250.84 + 2.82(144.10); 308.39 + 2.82(177.94)]$$

$${}^a_c UCL_2 = [657.28; 819.06]$$

⋮

$${}^a_c UCL_{28} = [580.71 + 2.82(144.10); 710.33 + 2.82(177.94)]$$

$${}^a_c UCL_{28} = [987.26; 1234.05]$$

Dan untuk LCL sebagai berikut:

$${}^a_c LCL_i = [\max({}_L^a_c \hat{X}_i - L \sqrt{\frac{\sum_{i=1}^N ({}_L^a_c \tilde{D}_i - {}_L^a_c \hat{X}_i)^2}{N}}, 0); \max({}_R^a_c \hat{X}_i - \sqrt{\frac{\sum_{i=1}^N ({}_R^a_c \tilde{D}_i - {}_R^a_c \hat{X}_i)^2}{N}}, 0)]$$

$${}^a_c LCL_1 = [480.59 - 2.82(144.10); 584.69 - 2.82(177.94)]$$

$${}^a_c LCL_1 = [73.37; 100.75]$$

$${}^a_c LCL_2 = [250.84 - 2.82(144.10); 308.39 - 2.82(177.94)]$$


$${}^a_c LCL_2 = [0; 0]$$

⋮

$${}^a_c LCL_{28} = [580.71 - 2.82(144.10); 710.33 - 2.82(177.94)]$$

$${}^a_c LCL_{28} = [174.53; 230.47]$$

Hasil lebih lengkap untuk UCL dan LCL untuk *left poin* dan *right poin* dapat dilihat pada Lampiran 13 dan Lampiran 14. Maka peta kendali fuzzy demerit berbasis *Moving Centerline AR(1)* didapatkan sebagai berikut:



Gambar 13. *Moving Centerline Fuzzy Demerit AR(1)*

Gambar menunjukkan peta kendali fuzzy demerit berbasis *moving centerline* untuk pendekatan *left point* (LP) dan *right point* (RP). Pada periode awal (bulan 1–13), nilai fuzzy demerit relatif stabil dan berada di dalam batas kendali, sehingga proses masih terkendali secara statistik.

Mulai sekitar bulan 14–20, terjadi peningkatan nilai demerit yang cukup tajam. Garis tengah (CL) serta batas kendali (UCL dan LCL) ikut bergerak naik mengikuti pola data. Hal ini menunjukkan sifat adaptif dari metode *moving centerline*, di mana batas kendali menyesuaikan perubahan proses sehingga kenaikan tren tidak langsung dianggap sebagai kondisi *out of control*. Pada grafik terlihat bahwa seluruh nilai D_i berada di antara batas kendali, sehingga tidak terjadi sinyal *out-of-control* yang tegas. Ini mengindikasikan bahwa fluktuasi yang muncul masih dapat dijelaskan oleh variasi alami proses sesuai model fuzzy demerit yang digunakan.

Pada periode sekitar bulan 22–23, nilai demerit mencapai titik tertinggi, terutama pada pendekatan *right point* yang merepresentasikan kondisi risiko maksimum. Namun, hampir seluruh titik pengamatan masih berada di antara batas kendali, sehingga fluktuasi yang terjadi masih dianggap sebagai variasi alami proses.

Secara keseluruhan, grafik LP dan RP menunjukkan pola yang hampir sama karena batas kendali dibentuk secara simetris berdasarkan varians residual. Oleh karena itu, kedua pendekatan memberikan kesimpulan bahwa proses masih terkendali, meskipun terdapat peningkatan tingkat kerentanan siber pada pertengahan hingga akhir periode pengamatan.

3.3.6 Perbandingan ARL dari MC EWMA dan MC AR(1)

Hasil perbandingan nilai ARL pada peta kendali berbasis Moving Centerline dan Moving Centerline AR(1) menunjukkan bahwa pendekatan Moving Centerline AR(1) memiliki kinerja yang lebih baik dalam memonitor data kerentanan siber. Hal ini terlihat dari nilai ARL_1 yang cenderung lebih kecil dibandingkan metode EWMA pada berbagai tingkat pergeseran (*shift*), sehingga peta kendali lebih cepat mendeteksi perubahan proses. Selain itu, meskipun pada beberapa periode terjadi peningkatan nilai demerit yang cukup signifikan, seluruh titik pengamatan masih berada di dalam batas kendali, sehingga proses masih dapat dikategorikan terkendali secara statistik.

Berdasarkan hasil pengujian, semakin besar nilai *shift* atau ARL_0 , maka nilai ARL_1 cenderung semakin menurun. Kondisi ini menunjukkan bahwa kemampuan peta kendali dalam mendeteksi perubahan proses menjadi semakin baik. Dengan kata lain, peta kendali berbasis Moving Centerline AR(1) memiliki sensitivitas yang tinggi terhadap pergeseran proses tanpa menghasilkan alarm palsu (*false alarm*) yang berlebihan. Hal tersebut mengindikasikan bahwa variasi yang muncul masih termasuk variasi alami proses dan bukan disebabkan oleh faktor khusus yang memerlukan tindakan korektif segera.

Sebaliknya, pada peta kendali Moving Centerline berbasis EWMA, meskipun nilai ARL pada kondisi *in-control* (ARL_0) tergolong baik, nilai ARL pada kondisi *out-of-control* (ARL_1) masih relatif besar, terutama ketika nilai *shift* meningkat. Penurunan nilai ARL_1 pada metode EWMA juga berlangsung lebih lambat dibandingkan

pendekatan $AR(1)$. Kondisi ini menunjukkan bahwa sensitivitas EWMA dalam mendeteksi pergeseran proses yang lebih besar masih lebih rendah dibandingkan metode Moving Centerline berbasis $AR(1)$.

Tabel 8. Perbandingan ARL EWMA dan ARL AR(1)

	<i>Left poin</i>						<i>Right Poin</i>					
<i>L</i>	2		2.82		3		2		2.82		3	
<i>shift</i>	EWMA	AR(1)	EWMA	AR(1)	EWMA	AR(1)	EWMA	AR(1)	EWMA	AR(1)	EWMA	AR(1)
0	25.67	23.55	210.32	200.78	373.08	351.41	24.40	23.40	213.21	211.61	377.929	346.90
0.5	24.90	14.59	205.66	92.82	392.56	161.07	22.80	14.43	205.59	96.53	382.53	157.80
1	22.83	7.45	211.08	29.68	365.55	44.46	20.83	7.29	201.76	30.06	384.87	45.62
2	12.84	4.19	178.38	11.45	365.02	16.31	10.97	4.29	176.77	11.70	330.10	16.19
3	2.97	3.02	89.40	5.82	230.22	7.39	2.25	2.99	80.87	5.79	182.88	7.20

Sumber: diolah 2026

BAB IV KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan hasil yang diperoleh dan diuraikan pada pembahasan sebelumnya, dapat diperoleh beberapa kesimpulan sebagai berikut:

1. Pada peta kendali fuzzy demerit berbasis moving centerline pada data berautokorelasi adalah:

$$\begin{aligned}
 {}^{a_c}UCL_i &= [{}^{a_c}\tilde{Z}_{i-1} + L \sqrt{\frac{\sum_{i=1}^N ({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1))^2}{N}}; \\
 &\quad {}^{a_c}\tilde{Z}_{i-1} + L \sqrt{\frac{\sum_{i=1}^N ({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1))^2}{N}}] \\
 {}^{a_c}LCL_i &= [\max({}^{a_c}\tilde{Z}_{i-1} - L \sqrt{\frac{\sum_{i=1}^N ({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1))^2}{N}}, 0); \\
 &\quad \max({}^{a_c}\tilde{Z}_{i-1} - L \sqrt{\frac{\sum_{i=1}^N ({}^{a_c}\tilde{D}_i - {}^{a_c}\tilde{Z}_i(i-1))^2}{N}}, 0)]
 \end{aligned}$$

2. Performa dari peta kendali fuzzy demerit berbasis moving centerline pada data berautokorelasi menunjukkan bahwa semakin besar nilai perubahan meannya maka nilai ARL nya semakin kecil. Hal ini menunjukkan bahwa peta kendali ini efektif dalam mendeteksi adanya data out of control pada saat perubahan besar.

4.2 Saran

Berdasarkan hasil penelitian ini, saran yang dapat diberikan untuk penelitian selanjutnya adalah sebagai berikut:

1. Penelitian berikutnya disarankan untuk membandingkan peta kendali fuzzy demerit berbasis moving centerline dengan metode pengendalian lain, seperti peta kendali residual ARIMA, EWMAST, atau CUSUM berbasis fuzzy.
2. Studi lanjutan dapat menerapkan metode yang diusulkan pada berbagai jenis data kerentanan siber, seperti data dari beberapa host, jaringan, atau periode waktu yang lebih panjang.

DAFTAR PUSTAKA

- Afful-Dadzie, A., & Allen, T. T. (2016). Control charting methods for autocorrelated cyber vulnerability data. *Quality Engineering*, 28(3), 313-328.
- Ahsan, M., Arinda, B. T., & Prasetya, I. K. (2024). Monitoring Welding Process on Ship Construction Using Demerit Control Chart and Fuzzy Analytics Hierarchy Process Integrated Statistical Process Control. *IAENG International Journal of Applied Mathematics*, 54(7), 1251-1258.
- Al Mohamed, A. A., Al Mohamed, S., & Zino, M. (2023). Application of fuzzy multicriteria decision-making model in selecting pandemic hospital site. *Future business journal*, 9(1), 14.
- Baldwin, J. F., & Karale, S. B. (2003, September). Asymmetric triangular fuzzy sets for classification models. In *International Conference on Knowledge-Based and Intelligent Information and Engineering Systems* (pp. 364-370). Berlin, Heidelberg: Springer Berlin Heidelberg.
- Durbin, J., & Watson, G. S. (1951). *Testing for serial correlation in least squares regression II*. *Biometrika*, 38(1-2), 159-178
- Fisher, T. J., & Robbins, M. W. (2018). An improved measure for lack of fit in time series models. *Statistica Sinica*, 28(3), 1285-1305.
- Herdiani, E.T., Fandrilla, G., and Sunusi, N. (2018) Modified exponential weighted moving average (EWMA) control chart on autocorrelation data. *Journal of Physics: Conference Series*. Vol. 979. IOP Publishing.
- Ibrahim, M., Faily, S., & Newman, M. E. (2021). Software security patch management: A systematic literature review of challenges, approaches, tools and practices. *Journal of Systems and Software*, 174.
- Islam, T., & Toor, E. (2019). Power comparison of autocorrelation tests in dynamic models. *International Econometric Review*, 11(2), 58-69.
- Jamadar, S. (2020). Statistical process control. *International Journal of Engineering Research & Technology*, 8(15).
- Karoon, K., Areepong, Y., & Sukparungsee, S. (2024). On the performance of the extended EWMA control chart for monitoring process mean based on autocorrelated data. *Applied Science and Engineering Progress*, 17(2), 6599-6599.
- Klir, G. J., & Yuan, B. (1996). Fuzzy sets and fuzzy logic: theory and applications. *Possibility Theory versus Probab. Theory*, 32(2), 207-208.

- Lirio, V. W., Martins, T., Reichert, B., Lirio, G. S. W., Souza, A. M., & da Silva, W. V. (2022). Literature review on control charts for autocorrelated processes. *Ciência e Natura*, 44, e2-e2.
- Matdoan, M. Y., Talakua, A. H., Marsono, M., Safira, D. A., Suriaslan, A. S., Zulfadhli, M., & Rukua, A. W. (2024). Application of Demerit Chart and Fuzzy Demerit Chart for Monitoring Paper Production. *Pattimura International Journal of Mathematics (PIJMath)*, 3(2), 77-86.
- Montgomery, D. C., & Mastrangelo, C. M. (1991). Some statistical process control methods for autocorrelated data. *Journal of quality technology*, 23(3), 179-193.
- Montgomery, D.C., Jennings, C.L. & Kulahci, M. (2015). *Introduction to time series analysis and forecasting (Second Edition)*. New York: John Wiley & Sons.
- Mvula, P. K., Branco, P., Jourdan, G. V., & Viktor, H. L. (2023). A systematic literature review of cyber-security data repositories and performance assessment metrics for semi-supervised learning. *Discover Data*, 1(1), 4.
- Nasruddin, N., Herdiani, E. T., & Sirajang, N. (2024). Peta Kendali Demerit Untuk Data Autokorelasi (Moving Centerline Demerit dan Moving Range). *Statistika*, 24(2), 123-134.
- Nembhard, D. A., & Nembhard, H. B. (2000). A Demerits Control Chart For Autocorrelated Data. *Quality Engineering*, 13(2), 179-190.
- Palma, A., & Bonomi, S. (2025). Behind the scenes of attack graphs: Vulnerable network generator for in-depth experimental evaluation of attack graph scalability. *Computers & Security*, 104576.
- Patel, A. K., & Divecha, J. (2022). Modified exponentially weighted moving average (EWMA) control chart for an analytical process data. *International Journal of Quality & Reliability Engineering*, 38(4), 345–359. (ini cari lamda yang beda)
- Putri, R., Nanda, E., & Aksioma, D. F. (2018). Pengendalian kualitas kantong semen di PT. Industri Kemasan Semen Gresik menggunakan peta kendali demerit dan fuzzy demerit. *Jurnal Sains dan Seni ITS*, 7(2), 156–161.
- Qiu, P., Li, W., & Li, J. (2020). A new process control chart for monitoring short-range serially correlated data. *Technometrics*, 62(1), 71-83.

- Rahayu, S. (2009). *Penggunaan Metode Durbin Watson dalam Menyelesaikan Model Regresi yang Mengandung Autokorelasi*. Skripsi. FMIPA, Universitas Sumatera Utara, Medan.
- Raza, M. A., Iqbal, K., Aslam, M., Nawaz, T., Bhatti, S. H., & Engmann, G. M. (2023). Mixed exponentially weighted moving average—moving average control chart with application to combined cycle power plant. *Sustainability*, 15(4), 3239.
- Reynolds Jr, M. R., & Lu, C. W. (1997). Control charts for monitoring processes with autocorrelated data. *Nonlinear Analysis: Theory, Methods & Applications*, 30(7), 4059-4067.
- Roberts, S. W. (1959). Control chart tests based on geometric moving averages. *Technometrics*, 1(3), 239–251.
- Ross, T. J. (2010). *Fuzzy logic with engineering applications*. John Wiley & Sons.
- Runger, G. C., & Willemain, T. R. (1995). Model-based and model-free control of autocorrelated processes. *Journal of Quality Technology*, 27(4), 283-292.
- Sagnak, M. (2020). Fuzzy analytic hierarchy process-integrated statistical process control: An application of demerit chart at furniture manufacturing company. *Journal of Multi-Criteria Decision Analysis*, 27(1–2), 96–103.
- Shu, M. H., Kung, J. Y., & Hsu, B. M. (2015). Demerit-fuzzy rating mechanism and monitoring chart. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 23(03), 399-420.
- Silpakob, K., Areepong, Y., Sukparungsee, S., & Sunthornwat, R. (2022). A new modified EWMA control chart for monitoring processes involving autocorrelated data. *Intelligent Automation & Soft Computing*, 36(1), 281–298.
- Sunthornwat, R., Sukparungsee, S., & Areepong, Y. (2023). Analytical explicit formulas of average run length of homogenously weighted moving average control chart based on a MAX process. *Symmetry*, 15(12), 2112.
- Yao, Y., Chakraborti, S., Yang, X., Parton, J., Lewis Jr, D., & Hudnall, M. (2023). Phase I control chart for individual autocorrelated data: application to prescription opioid monitoring. *Journal of Quality Technology*, 55(3), 302-317.
- Yilmaz, H., & Yanik, S. (2020). Design of demerit control charts with fuzzy c-means clustering and an application in textile sector. *Textile and Apparel*, 30(2), 117-125.

Lampiran 1. Data Fuzzy Demerit

Bulan	n_i	Rendah	Sedang	Tinggi	Kritis	${}^{a_c}_L \tilde{D}_i$	${}^{a_c}_R \tilde{D}_i$
1	199	12	33	8	0	240.8	304.1
2	201	12	30	8	0	226.4	285.8
3	207	10	30	7	0	215.3	271.6
4	241	10	33	9	0	245.5	307.5
5	246	13	33	9	0	250.3	315.6
6	219	19	41	8	0	290.4	371.8
7	235	24	45	7	0	309.7	400.9
8	244	21	46	9	0	325.5	416.5
9	247	16	42	9	0	298.3	378.6
10	237	15	46	7	0	300.1	382.7
11	231	15	41	9	0	291.9	369.8
12	205	14	47	9	0	319.1	403.7
13	228	19	54	9	0	360.7	459.9
14	247	18	71	12	1	474.1	597.6
15	244	13	47	12	1	350.9	437.7
16	243	18	63	16	1	467.3	584
17	241	19	80	21	8	657.9	806.5
18	217	18	84	25	8	707.1	863.4
19	222	22	93	26	8	764.6	937.9
20	129	26	118	26	7	881.3	1090.9
21	130	14	99	25	8	772.7	944.1
22	130	20	123	27	8	913.3	1124.3
23	128	19	130	29	8	961.1	1181.9
24	136	23	99	21	6	736.1	912.6
25	114	23	103	21	6	755.3	937
26	92	21	91	17	3	633.8	792.3
27	110	22	88	15	2	595.5	748.8
28	85	18	48	7	0	314.5	403
Jumlah		494	1858	408	75	17030.5	13659.5
Rata-rata		17.643	66.357	14.571	2.678	608.232	487.84

Lampiran 2. Uji Ljung-Box pada data demerit

```

DIa <- c(
  304.1, 285.8, 271.6, 307.5, 315.6, 371.8, 400.9, 416.5,
  378.6, 382.7, 369.8, 403.7, 459.9, 598.8, 438.9, 585.2,
  816.1, 873.0, 947.5, 1099.3, 953.7, 1133.9, 1191.5,
  919.8, 944.2, 795.9, 751.2, 403.0)

DIb <- c(
  240.8, 226.4, 215.3, 245.5, 250.3, 290.4, 309.7, 325.5,
  298.3, 300.1, 291.9, 319.1, 360.7, 474.1, 350.9, 467.3,
  657.9, 707.1, 764.6, 881.3, 772.7, 913.3, 961.1,
  736.1, 755.3, 633.8, 595.5, 314.5)
ts_DIa <- ts(DIa)
ts_DIb <- ts(DIb)

Box.test(ts_DIa, lag = 1, type = "Ljung-Box")

##
## Box-Ljung test
##
## data: ts_DIa
## X-squared = 24.036, df = 1, p-value = 9.455e-07

Box.test(ts_DIb, lag = 1, type = "Ljung-Box")

##
## Box-Ljung test
##
## data: ts_DIb
## X-squared = 24.163, df = 1, p-value = 8.851e-07

```

Lampiran 3. Uji Box-Ljung test *Left Poin* untuk $\lambda = 0.1$ hingga $\lambda = 0.7$

```
X <- c( 240.8, 226.4, 215.3, 245.5, 250.3, 290.4, 309.7, 325.5,
       298.3, 300.1, 291.9, 319.1, 360.7, 474.1, 350.9, 467.3,
       657.9, 707.1, 764.6, 881.3, 772.7, 913.3, 961.1,
       736.1, 755.3, 633.8, 595.5, 314.5)
Z0 <- 487.84
n <- length(X)
lambda_set <- c(0.05, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7)
ewma_residual <- function(X, lambda, Z0){
  n <- length(X)
  Z <- numeric(n)
  Z[1] <- lambda*X[1] + (1 - lambda)*Z0
  for(i in 2:n){
    Z[i] <- lambda*X[i] + (1 - lambda)*Z[i-1] }

  # residual sesuai rumus: e_i = X_i - Z_{i-1}
  e <- c(NA, X[-1] - Z[-n])
  return(list(Z = Z, e = e))}
hasil <- list()
for(lam in lambda_set){
  tmp <- ewma_residual(X, lam, Z0)
  e <- ts(na.omit(tmp$e))
  lb <- Box.test(e, lag = 10, type = "Ljung-Box")

  hasil[[paste0("lambda_", lam)]] <- list(
    lambda = lam,
    p_value = lb$p.value,
    statistic = lb$statistic)}

data.frame(
  lambda = sapply(hasil, function(x) x$lambda),
  LjungBox_stat = sapply(hasil, function(x) as.numeric(x$statistic))
,
  p_value = sapply(hasil, function(x) x$p_value))

##          lambda LjungBox_stat      p_value
## lambda_0.05    0.05      62.07166 1.466505e-09
## lambda_0.1     0.10      49.85788 2.834597e-07
## lambda_0.2     0.20      38.79231 2.760472e-05
## lambda_0.3     0.30      33.73500 2.047871e-04
## lambda_0.4     0.40      28.91314 1.287031e-03
## lambda_0.5     0.50      23.90151 7.866149e-03
## lambda_0.6     0.60      19.06927 3.939164e-02
## lambda_0.7     0.70      14.81916 1.387954e-01
```

Lampiran 4. Uji Box-Ljung test *Right Poin* untuk $\lambda = 0.1$ hingga $\lambda = 0.7$

```
X <- c( 308.3859, 291.9342, 279.1684, 311.4425, 318.7244,
       369.2482, 395.4091, 409.4335, 375.3614, 379.0473,
       367.4502, 397.9263, 448.4501, 573.3212, 429.5711,
       561.0948, 768.6739, 819.8270, 886.8025, 1023.2707,
       892.3763, 1054.3761, 1106.1585, 861.9002, 883.8358,
       750.5141, 710.3288)
Z0 <- 611.45
n <- length(X)
lambda_set <- c( 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7)
ewma_residual <- function(X, lambda, Z0){
  n <- length(X)
  Z <- numeric(n)
  Z[1] <- lambda*X[1] + (1 - lambda)*Z0
  for(i in 2:n){
    Z[i] <- lambda*X[i] + (1 - lambda)*Z[i-1]}
  # residual sesuai rumus: e_i = X_i - Z_{i-1}
  e <- c(NA, X[-1] - Z[-n])

  return(list(Z = Z, e = e))}
hasil <- list()
for(lam in lambda_set){
  tmp <- ewma_residual(X, lam, Z0)
  e <- ts(na.omit(tmp$e))

  lb <- Box.test(e, lag = 10, type = "Ljung-Box")

  hasil[[paste0("lambda_", lam)]] <- list(
    lambda = lam,
    p_value = lb$p.value,
    statistic = lb$statistic)}
data.frame(lambda = sapply(hasil, function(x) x$lambda),
  LjungBox_stat = sapply(hasil, function(x) as.numeric(x$statistic)),
  p_value = sapply(hasil, function(x) x$p_value))

##          lambda LjungBox_stat      p_value
## lambda_0.1      0.1         57.95651 8.809284e-09
## lambda_0.2      0.2         36.95809 5.754595e-05
## lambda_0.3      0.3         28.03360 1.783023e-03
## lambda_0.4      0.4         23.25406 9.846651e-03
## lambda_0.5      0.5         19.58611 3.341956e-02
## lambda_0.6      0.6         16.73391 8.046311e-02
## lambda_0.7      0.7         14.97996 1.327941e-01
```

Lampiran 5. Uji ARL *Left Poin* untuk $\lambda = 0.7$ dan $L = 2, 2.81$ dan 3

```
# =====
shift_values <- c(0, 0.5, 1, 2, 3)
ARL_values <- sapply(shift_values, function(s){
  simulate_ARL_sigma_berjalan(
    lambda = 0.7,
    shift = s,
    L = 2,
    nsim = 2000,
    Xi = Xi
  )
})
ARL_values
[1] 25.6740 24.8890 22.8335 12.8450  2.9745

. # =====
. shift_values <- c(0, 0.5, 1, 2, 3)
. ARL_values <- sapply(shift_values, function(s){
.   simulate_ARL_sigma_berjalan(
.     lambda = 0.7,
.     shift = s,
.     L = 2.81,
.     nsim = 2000,
.     Xi = Xi
.   )
. })
. ARL_values
[1] 210.3245 205.6600 211.0795 178.3795  89.4045

> shift_values <- c(0, 0.5, 1, 2, 3)
> ARL_values <- sapply(shift_values, function(s){
+   simulate_ARL_sigma_berjalan(
+     lambda = 0.7,
+     shift = s,
+     L = 3,
+     nsim = 2000,
+     Xi = Xi
+   )
+ })
> ARL_values
[1] 373.0815 392.5635 365.5475 365.0195 230.2220
```

Lampiran 6. Uji ARL *Right Poin* untuk $\lambda = 0.6$ dan $L = 2, 2.81$ dan 3

```
> shift_values <- c(0, 0.5, 1, 2, 3)
> ARL_values <- sapply(shift_values, function(s){
+   simulate_ARL_sigma_berjalan(
+     lambda = 0.6,
+     shift = s,
+     L = 2,
+     nsim = 2000,
+     Xi = Xi
+   )
+ })
> ARL_values
[1] 24.4010 22.7960 20.8300 10.9685 2.2495
```

```
> # =====
> shift_values <- c(0, 0.5, 1, 2, 3)
> ARL_values <- sapply(shift_values, function(s){
+   simulate_ARL_sigma_berjalan(
+     lambda = 0.6,
+     shift = s,
+     L = 2.81,
+     nsim = 2000,
+     Xi = Xi
+   )
+ })
> ARL_values
[1] 213.2085 205.5880 201.7615 176.7720 80.8765
```

```
> ARL_values <- sapply(shift_values, function(s){
+   simulate_ARL_sigma_berjalan(
+     lambda = 0.6,
+     shift = s,
+     L = 3,
+     nsim = 2000,
+     Xi = Xi
+   )
+ })
> ARL_values
[1] 377.9290 382.5270 384.8720 330.1045 182.8835
```

Lampiran 7. Fuzzy Demerit Berbasis Moving Centerline untuk *Left Poin*

i	$D_i(\text{Left Poin})$	Z_i	UCL	LCL
1	240.8	314.91	816.83	158.85
2	226.4	252.95	643.91	0.00
3	215.3	226.60	581.95	0.00
4	245.5	239.83	555.59	0.00
5	250.3	247.16	568.82	0.00
6	290.4	277.43	576.15	0.00
7	309.7	300.02	606.42	0.00
8	325.5	317.86	629.01	0.00
9	298.3	304.17	646.85	0.00
10	300.1	301.32	633.16	0.00
11	291.9	294.73	630.31	0.00
12	319.1	311.79	623.72	0.00
13	360.7	346.03	640.78	0.00
14	474.1	435.68	675.02	17.03
15	350.9	376.33	764.67	106.68
16	467.3	440.01	705.33	47.34
17	657.9	592.53	769.00	111.02
18	707.1	672.73	921.53	263.54
19	764.6	737.04	1001.72	343.74
20	881.3	838.02	1066.03	408.05
21	772.7	792.30	1167.02	509.03
22	913.3	877.00	1121.29	463.30
23	961.1	935.87	1205.99	548.01
24	736.1	796.03	1264.86	606.88
25	755.3	767.52	1125.02	467.04
26	633.8	673.92	1096.51	438.53
27	595.5	619.02	1002.91	344.92
28	314.5	405.86	948.02	290.03

Lampiran 8. Fuzzy Demerit berbasis *Moving Centerline* untuk *Right Poin*

i	$D_i(\text{Right Poin})$	Z_i	UCL	LCL
1	304.1	427.04	1037.43	185.46
2	285.8	342.30	853.02	1.05
3	271.6	299.88	768.28	0.00
4	307.5	304.45	725.86	0.00
5	315.6	311.14	730.44	0.00
6	371.8	347.54	737.13	0.00
7	400.9	379.55	773.52	0.00
8	416.5	401.72	805.54	0.00
9	378.6	387.85	827.71	0.00
10	382.7	384.76	813.83	0.00
11	369.8	375.78	810.74	0.00
12	403.7	392.53	801.77	0.00
13	459.9	432.95	818.52	0.00
14	598.8	532.46	858.94	6.97
15	438.9	476.32	958.45	106.48
16	585.2	541.65	902.31	50.34
17	816.1	706.32	967.63	115.66
18	873.0	806.33	1132.31	280.33
19	947.5	891.03	1232.31	380.34
20	1099.3	1015.99	1317.02	465.05
21	953.7	978.62	1441.98	590.01
22	1133.9	1071.79	1404.60	552.63
23	1191.5	1143.61	1497.77	645.80
24	919.8	1009.33	1569.60	717.63
25	944.2	970.25	1435.31	583.34
26	795.9	865.64	1396.24	544.27
27	751.2	796.98	1291.63	439.65
28	403.0	560.59	1222.96	370.99

Lampiran 9. Estimasi Parameter Moving Centerline AR(1) dan Uji L-jung Box untuk *Left Poin*

Final Estimates of Parameters

Type	Coef	SE Coef	T-Value	P-Value
AR 1	0,9303	0,0808	11,51	0,000
Constant	26,9	21,0	1,28	0,212
Mean	385	301		

Modified Box-Pierce (Ljung-Box) Chi-Square Statistic

Lag	12	24	36	48
Chi-Square	11,04	13,35	*	*
DF	10	22	*	*
P-Value	0,355	0,923	*	*

Lampiran 10. Estimasi Parameter Moving Centerline AR(1) dan Uji L-jung Box untuk *Right Poin*

Final Estimates of Parameters

Type	Coef	SE Coef	T-Value	P-Value
AR 1	0,9282	0,0817	11,36	0,000
Constant	35,0	26,0	1,35	0,190
Mean	488	362		

Modified Box-Pierce (Ljung-Box) Chi-Square Statistic

Lag	12	24	36	48
Chi-Square	10,46	12,86	*	*
DF	10	22	*	*
P-Value	0,401	0,937	*	*

Lampiran 11. Uji ARL Moving Centerline AR(1) Left Poin

```
# Data asli
X <- c(
  240.8, 226.4, 215.3, 245.5, 250.3, 290.4, 309.7, 325.5,
  298.3, 300.1, 291.9, 319.1, 360.7, 474.1, 350.9, 467.3,
  657.9, 707.1, 764.6, 881.3, 772.7, 913.3, 961.1,
  736.1, 755.3, 633.8, 595.5, 314.5)

# Estimasi AR(1)
model <- arima(X, order = c(1,0,0))
phi <- coef(model)["ar1"]
mu <- coef(model)["intercept"]
c0 <- (1 - phi) * mu

# Residual dari data asli
n <- length(X)
e_data <- numeric(n)
e_data[1] <- 0
for(t in 2:n){
  e_data[t] <- X[t] - (c0 + phi * X[t-1])}

# Sigma dari SSE (bisa berubah kalau datanya berubah)
sigma_hat <- sqrt( sum(e_data[2:n]^2) / (n-1) )

sigma <- sigma_hat # dikunci sebagai parameter proses
simulate_ARL_MC_AR1 <- function(c0, phi, sigma, L, delta, X0,
                                nsim = 2000, max_steps = 1000){

  RL <- numeric(nsim)
  for(sim in 1:nsim){
    X <- numeric(max_steps)
    CL <- numeric(max_steps)
    UCL <- numeric(max_steps)
    LCL <- numeric(max_steps)
    # nilai awal
    X[1] <- X0
    CL[1] <- c0 + phi * X0
    UCL[1] <- CL[1] + L * sigma
    LCL[1] <- CL[1] - L * sigma
    out <- FALSE
    for(t in 2:max_steps){
      # residual jalan, sigma tetap
      e <- rnorm(1, mean = delta * sigma, sd = sigma)
      # proses AR(1)
      X[t] <- c0 + phi * X[t-1] + e
      # moving CL
      CL[t] <- c0 + phi * X[t-1]
      # batas kendali pakai sigma konstan
      UCL[t] <- CL[t] + L * sigma
      LCL[t] <- CL[t] - L * sigma
      # cek out of control
      if(X[t] > UCL[t] || X[t] < LCL[t]){
```

```

        RL[sim] <- t
        out <- TRUE
        break }}
    if(!out){
        RL[sim] <- max_steps } }
    mean(RL)}
X0 <- mean(X)
#dengan L=3
shift_values <- c(0, 0.5, 1, 1.5, 2)
ARL_values <- sapply(shift_values, function(d){
    simulate_ARL_MC_AR1(c0 = c0, phi = phi, sigma = sigma, L = 3,
        delta = d, X0 = X0, nsim = 2000, max_steps = 1000)})
data.frame(Shift = shift_values, ARL = ARL_values)

##      Shift      ARL
## 1    0.0 351.4100
## 2    0.5 161.0715
## 3    1.0  44.4575
## 4    1.5  16.3115
## 5    2.0   7.3865

shift_values <- c(0, 0.5, 1, 1.5, 2)
#dengan L=2.82
ARL_values <- sapply(shift_values, function(d){
    simulate_ARL_MC_AR1(c0 = c0, phi = phi, sigma = sigma, L = 2.82,
        delta = d, X0 = X0, nsim = 2000, max_steps = 1000)})
data.frame(Shift = shift_values, ARL = ARL_values)

##      Shift      ARL
## 1    0.0 200.7790
## 2    0.5  92.8275
## 3    1.0  29.6810
## 4    1.5  11.4455
## 5    2.0   5.8205

#dengan L =2
ARL_values <- sapply(shift_values, function(d){
    simulate_ARL_MC_AR1(c0 = c0, phi = phi, sigma = sigma, L = 2,
        delta = d, X0 = X0, nsim = 2000, max_steps = 1000)})
data.frame(Shift = shift_values, ARL = ARL_values)

##      Shift      ARL
## 1    0.0 23.5595
## 2    0.5 14.5875
## 3    1.0  7.4480
## 4    1.5  4.1870
## 5    2.0  3.0115

```

Lampiran 12. Uji ARL Moving Centerline AR(1) Right Poin

```
# Data asli
X <- c(
  304.1, 285.8, 271.6, 307.5, 315.6, 371.8, 400.9, 416.5,
  378.6, 382.7, 369.8, 403.7, 459.9, 598.8, 438.9, 585.2,
  816.1, 873.0, 947.5, 1099.3, 953.7, 1133.9, 1191.5,
  919.8, 944.2, 795.9, 751.2, 403.0)

# Estimasi AR(1)
model <- arima(X, order = c(1,0,0))
phi <- coef(model)["ar1"]
mu <- coef(model)["intercept"]
c0 <- (1 - phi) * mu

# Residual dari data asli
n <- length(X)
e_data <- numeric(n)
e_data[1] <- 0
for(t in 2:n){
  e_data[t] <- X[t] - (c0 + phi * X[t-1])}

# Sigma dari SSE (bisa berubah kalau datanya berubah)
sigma_hat <- sqrt( sum(e_data[2:n]^2) / (n-1) )

sigma <- sigma_hat # dikunci sebagai parameter proses
simulate_ARL_MC_AR1 <- function(c0, phi, sigma, L, delta, X0,
                                nsim = 2000, max_steps = 1000){
  RL <- numeric(nsim)
  for(sim in 1:nsim){
    X <- numeric(max_steps)
    CL <- numeric(max_steps)
    UCL <- numeric(max_steps)
    LCL <- numeric(max_steps)
    # nilai awal
    X[1] <- X0
    CL[1] <- c0 + phi * X0
    UCL[1] <- CL[1] + L * sigma
    LCL[1] <- CL[1] - L * sigma
    out <- FALSE
    for(t in 2:max_steps){
      # residual jalan, sigma tetap
      e <- rnorm(1, mean = delta * sigma, sd = sigma)
      # proses AR(1)
      X[t] <- c0 + phi * X[t-1] + e
      # moving CL
      CL[t] <- c0 + phi * X[t-1]
      # batas kendali pakai sigma konstan
      UCL[t] <- CL[t] + L * sigma
      LCL[t] <- CL[t] - L * sigma
      # cek out of control
      if(X[t] > UCL[t] || X[t] < LCL[t]){
```

```

        RL[sim] <- t
        out <- TRUE
        break }}
    if(!out){
        RL[sim] <- max_steps} }
    mean(RL)}
X0 <- mean(X)
#dengan L=3
shift_values <- c(0, 0.5, 1, 1.5, 2)
ARL_values <- sapply(shift_values, function(d){
    simulate_ARL_MC_AR1(c0 = c0, phi = phi, sigma = sigma, L = 3,
        delta = d, X0 = X0, nsim = 2000, max_steps = 1000)})
data.frame(Shift = shift_values, ARL = ARL_values)

##      Shift      ARL
## 1    0.0 346.9010
## 2    0.5 157.8040
## 3    1.0  45.6220
## 4    1.5  16.1860
## 5    2.0   7.2085

shift_values <- c(0, 0.5, 1, 1.5, 2)
#dengan L=2.82
ARL_values <- sapply(shift_values, function(d){
    simulate_ARL_MC_AR1(c0 = c0, phi = phi, sigma = sigma, L = 2.82,
        delta = d, X0 = X0, nsim = 2000, max_steps = 1000)})
data.frame(Shift = shift_values, ARL = ARL_values)

##      Shift      ARL
## 1    0.0 211.6110
## 2    0.5  96.5345
## 3    1.0  30.0625
## 4    1.5  11.6985
## 5    2.0   5.7945

#dengan L =2
ARL_values <- sapply(shift_values, function(d){
    simulate_ARL_MC_AR1(c0 = c0, phi = phi, sigma = sigma, L = 2,
        delta = d, X0 = X0, nsim = 2000, max_steps = 1000)})
data.frame(Shift = shift_values, ARL = ARL_values)

##      Shift      ARL
## 1    0.0 23.4020
## 2    0.5 14.4300
## 3    1.0  7.2915
## 4    1.5  4.2860
## 5    2.0  2.9930

```

Lampiran 13. Data Lengkap Moving Centerline AR(1) Left Poin

i	$D_i(\text{Left Poin})$	$\hat{X}_i$	UCL	LCL
1	240.8	480.74	887.10	74.37
2	226.4	250.92	657.28	0.00
3	215.3	237.52	643.89	0.00
4	245.5	227.19	633.56	0.00
5	250.3	255.29	661.66	0.00
6	290.4	259.75	666.12	0.00
7	309.7	297.06	703.43	0.00
8	325.5	315.01	721.38	0.00
9	298.3	329.71	736.08	0.00
10	300.1	304.41	710.78	0.00
11	291.9	306.08	712.45	0.00
12	319.1	298.45	704.82	0.00
13	360.7	323.76	730.13	0.00
14	474.1	362.46	768.83	0.00
15	350.9	467.96	874.32	61.59
16	467.3	353.34	759.71	0.00
17	657.9	461.63	868.00	55.26
18	707.1	638.94	1045.31	232.58
19	764.6	684.72	1091.08	278.35
20	881.3	738.21	1144.58	331.84
21	772.7	846.77	1253.14	440.41
22	913.3	745.74	1152.11	339.37
23	961.1	876.54	1282.91	470.18
24	736.1	921.01	1327.38	514.64
25	755.3	711.69	1118.06	305.33
26	633.8	729.56	1135.92	323.19
27	595.5	616.52	1022.89	210.16
28	314.5	580.89	987.26	174.53

Lampiran 14. Data Lengkap Moving Centerline AR(1) Right Poin

i	$D_i(\text{Right Poin})$	Z_i	UCL	LCL
1	304.1	602.54	1104.33	100.75
2	285.8	317.27	819.06	0.00
3	271.6	300.28	802.07	0.00
4	307.5	287.10	788.89	0.00
5	315.6	320.42	822.21	0.00
6	371.8	327.94	829.73	0.00
7	400.9	380.10	881.89	0.00
8	416.5	407.12	908.91	0.00
9	378.6	421.60	923.39	0.00
10	382.7	386.42	888.21	0.00
11	369.8	390.22	892.01	0.00
12	403.7	378.25	880.04	0.00
13	459.9	409.71	911.50	0.00
14	598.8	461.88	963.67	0.00
15	438.9	590.81	1092.60	89.02
16	585.2	442.39	944.18	0.00
17	816.1	578.18	1079.97	76.39
18	873.0	792.50	1294.29	290.71
19	947.5	845.32	1347.11	343.53
20	1099.3	914.47	1416.26	412.68
21	953.7	1055.37	1557.16	553.58
22	1133.9	920.22	1422.01	418.43
23	1191.5	1087.49	1589.28	585.70
24	919.8	1140.95	1642.74	639.16
25	944.2	888.76	1390.55	386.97
26	795.9	911.41	1413.20	409.62
27	751.2	773.75	1275.54	271.96
28	403.0	732.26	1234.05	230.47