

**PEMODELAN GEOGRAPHICALLY WEIGHTED NEGATIVE BINOMIAL
REGRESSION FLEXIBLY SHAPED SPATIAL SCAN STATISTIC PADA JUMLAH
KASUS STUNTING DI PROVINSI SULAWESI SELATAN**



A. Juanda B. Syahputra

H062232006

Dosen Pembimbing : 1. Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.

2. Dr. Anna Islamiyati, S. Si., M. Si.

Dosen Penguji : 1. Prof. Dr. Nurtiti Sunusi, S. Si., M. Si.

2. Prof. Sri Astuti Thamrin, M. Stat., Ph.D.

3. Prof. Dr. Erna Tri Herdianti, S. Si., M. Si.



**PROGRAM STUDI MAGISTER STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PEMODELAN *GEOGRAPHICALLY WEIGHTED NEGATIVE BINOMIAL
REGRESSION FLEXIBLY SHAPED SPATIAL SCAN STATISTIC* PADA JUMLAH
KASUS STUNTING DI PROVINSI SULAWESI SELATAN**

A. JUANDA B. SYAHPUTRA

H062232006



**PROGRAM STUDI MAGISTER STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PEMODELAN *GEOGRAPHICALLY WEIGHTED NEGATIVE BINOMIAL
REGRESSION FLEXIBLY SHAPED SPATIAL SCAN STATISTIC* PADA JUMLAH
KASUS STUNTING DI PROVINSI SULAWESI SELATAN**

Tesis

Sebagai salah satu syarat untuk mencapai gelar magister

Program Studi Magister Statistika

Disusun dan diajukan oleh

A. JUANDA B. SYAHPUTRA

H062232006

Kepada

**PROGRAM STUDI MAGISTER STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

TESIS

PEMODELAN GEOGRAPHICALLY WEIGHTED NEGATIVE BINOMIAL
REGRESSION FLEXIBLY SHAPED SPATIAL SCAN STATISTIC PADA
JUMLAH KASUS STUNTING DI PROVINSI SULAWESI SELATAN

A. Junda B. Syahputra

H062232006

Telah dipertahankan di hadapan Panitia Ujian Magister pada
22 Juli 2026 dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Magister Statistika
Departemen Statistika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:

Pembimbing Utama

Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.

NIP. 19620926 198702 2 001

Pembimbing Pendamping

Dr. Anna Islamiyati, S.Si., M.Si.

NIP. 19770808 200501 2 002

Ketua Program Studi
Magister Statistika

Prof. Dr. Erna Tri Herdiani, S.Si., M.Si.

NIP. 19750429 200003 2 001

Dekan Fakultas Matematika dan
Ilmu Pengetahuan Alam
Universitas Hasanuddin

Dr. Sci. Muhammad Zakir, S.Si., M.Si.

NIP. 19701103 199903 1 001

**PERNYATAAN KEASLIAN TESIS
DAN PELIMPAHAN HAK CIPTA**

Dengan ini saya menyatakan bahwa, tesis berjudul "*Pemodelan Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic*" pada jumlah kasus stunting di Provinsi Sulawesi Selatan" adalah benar karya saya dengan arahan dari tim pembimbing (Prof. Dr. Dr. Georgina Maria Tinungki, M.Si dan Dr. Anna Islamiyati, S.Si., M.Si). Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apapun kepada perguruan tinggi manapun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka tesis ini. Sebagian dari tesis ini akan dipublikasikan di *Communications in Mathematical Biology and Neuroscience* sebagai artikel dengan judul "*Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic Modeling on the Number of Stunting Case*".

Dengan ini saya melimpahkan hak cipta dari karya tulis saya berupa tesis ini kepada Universitas Hasanuddin.

Makassar, 11 Agustus 2026



B. Syahputra
H062232006

UCAPAN TERIMA KASIH


Puji syukur kepada Allah Subhana Wa Ta'ala atas segala limpahan rahmat, nikmat, dan hidayah-Nya, serta shalawat dan salam semoga selalu dilimpahkan kepada Nabiyang paling dimuliakan, pemimpin orang-orang bertakwa, Muhammad Sallahu Aalaih Wassallam dan kepada para keluarga serta sahabat yang berjuang bersamabeliau. Alhamdulillah, berkat pertolongan Allah akhirnya tesis dengan judul "*Pemodelan Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic*" pada jumlah kasus stunting di Provinsi Sulawesi Selatan" yang disusun sebagai salah satu syarat akademik untuk meraih gelar Magister pada Program Studi Magister Statistika Departemen Statistika Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin.

Penulis menyadari bahwa penyelesaian tesis ini tidak lepas dari bantuan dandorongan dari berbagai pihak. Oleh karena itu, penulis menyampaikan terimakasih yang sebesar-besarnya kepada Prof. Dr. Dr. Georgina Maria Tinungki, M. Si., selaku pembimbing utama dan Dr. Anna Islamiyati, S.Si., M.Si., selaku pembimbing pertama yang dengan sabar telah menyisihkan waktu dan pikirannya di tengah berbagai kesibukan dan prioritasnya, selalu memberikan panduan, dorongan, motivasi, dan kemudahan kepada penulis dalam menyelesaikan tesis ini. Serta ucapan terima kasih penulis kepada Prof. Dr. Nurtiti Sunusi S.Si., M.Si., Prof. Dr. Erna Tri Herdiani, S.Si., M.Si., dan Prof. Sri Astuti Thamrin S.Si., M. Stat., Ph.D selaku tim penguji yang telah memberikan saran membangun, arahan dalam penyempurnaan penyusunantesis ini, serta waktu yang telah diluangkan untuk penulis.

Penulisan tugas akhir ini tentunya tidak lepas dari bantuan berbagai pihak baik moral maupun materi. Oleh karena itu, penulis menyampaikan ucapan terima kasih yang tak terhingga untuk kakek, nenek, Bapak saya tersayang, Ibu saya tercinta, yang tak kenal lelah mendoakan, memberikan dukungan, dan selalu melimpahkan cinta dan kasih sayangnnya kepada penulis sehingga mereka menjadi motivasi terbesar penulis dalam menyelesaikan tugas akhir ini. Kemudian teman-teman seperjuangan di Program Studi Magister Statistika Angkatan 9, terima kasih atas bantuan dan dukungan selama perkuliahan dan penyusunan tesis ini. Serta kepada semua pihak yang penulis tidak dapat tuliskan satu persatu, terimakasih atas bantuannya.

Penulis menyadari bahwa masih banyak kekurangan dalam tesis ini, untuk itudengan segala kerendahan hati, penulis memohon maaf

Makassar, 11 Agustus 2026



A. Juanda/B. Syahputra

ABSTRAK

A. JUANDA. B. SYAHPUTRA. **Pemodelan *Geographically Weighted Negative Binomial Regression Flexibly Shaped Statal Scan Statistic* pada jumlah kasus stunting di Provinsi Sulawesi Selatan** (dibimbing oleh Prof. Dr. Dr. Georgina Maria Tinungki, M. Si., dan Dr. Anna Islamiyati, S.Si., M.Si.).

Latar Belakang: Jumlah kasus stunting merupakan data jumlah (*count data*) yang umumnya dipengaruhi oleh faktor lingkungan, kesehatan, dan geografis. Namun, data sering kali mengalami overdispersi serta heterogenitas spasial antar wilayah. Kondisi tersebut menyebabkan penggunaan regresi Poisson konvensional kurang tepat karena berpotensi menghasilkan estimasi parameter yang kurang akurat.. **Tujuan:** Penelitian ini bertujuan untuk mengestimasi parameter, memodelkan faktor-faktor yang berpengaruh terhadap jumlah kasus stunting, serta mendeteksi lokasi *hotspot* stunting di Provinsi Sulawesi Selatan menggunakan kombinasi metode *Geographically Weighted Negative Binomial Regression* (GWNBR) dan *Flexibly Shaped Spatial Scan Statistic* (FSSS). **Hasil:** Hasil penelitian menunjukkan bahwa penggunaan model Regresi Binomial Negatif berhasil mengatasi masalah overdispersi. Model GWNBR dengan pembobot *Adaptive Bisquare Kernel* terbukti sangat efektif dengan nilai AIC sebesar 216,98, jauh lebih unggul dibandingkan model Binomial Negatif global (AIC = 414,80). Hasil analisis parsial lokal mengelompokkan 24 kabupaten/kota menjadi tiga kelompok berdasarkan variabel signifikan. Penerapan FSSS berhasil mengidentifikasi tiga klaster kantong stunting yang signifikan. Klaster utama mencakup enam wilayah (Gowa, Takalar, Jeneponto, Bantaeng, Bulukumba, dan Kepulauan Selayar) dengan tingkat risiko relatif stunting sebesar 2,6 kali lebih tinggi dibandingkan wilayah lainnya. **Kesimpulan:** Kombinasi metode GWNBR dan FSSS sangat efektif untuk memodelkan data stunting yang mengalami overdispersi dan heterogenitas spasial. Metode ini mampu memetakan determinan lokal secara presisi serta menentukan wilayah prioritas utama dalam penanganan stunting.

Kata kunci: Stunting, GWNBR, Flexibly Shaped Spatial Scan Statistic, Overdispersi, Heterogenitas Spasial.

ABSTRACT

A. JUANDA B. SYAHPUTRA. Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic Modeling on the Number of Stunting Cases in South Sulawesi Province (supervised by Georgina Maria Tinungki and Anna Islamiyati)

Background: The number of stunting cases is count data generally influenced by environmental, health, and geographic factors. However, the data frequently exhibits overdispersion and spatial heterogeneity across regions. These conditions render conventional Poisson regression inappropriate as it potentially yields inaccurate parameter estimates. **Objective:** This study aims to estimate parameters, model the factors influencing stunting cases, and detect stunting hotspot locations in South Sulawesi Province using a combination of Geographically Weighted Negative Binomial Regression (GWNBR) and Flexibly Shaped Spatial Scan Statistic (FSSS). **Results:** The results show that the Negative Binomial Regression model successfully addresses the overdispersion issue. The GWNBR model with Adaptive Bisquare Kernel weighting proves highly effective with an AIC value of 216.98, significantly outperforming the global Negative Binomial model (AIC = 414.80). Local partial analysis categorizes the 24 regencies/cities into three groups based on significant variables. Furthermore, the application of FSSS successfully identifies three significant stunting cluster hotspots. The primary cluster encompasses six regions (Gowa, Takalar, Jeneponto, Bantaeng, Bulukumba, and Kepulauan Selayar) with a relative risk of stunting 2.6 times higher than other regions. **Conclusion:** The combination of GWNBR and FSSS methods is highly effective for modeling stunting data characterized by overdispersion and spatial heterogeneity. This approach precisely maps local determinants and identifies primary priority regions for stunting intervention.

Keywords: Stunting, GWNBR, Flexibly Shaped Spatial Scan Statistic, Overdispersion, Spatial Heterogeneity.

DAFTAR ISI

PERNYATAAN KEASLIAN TESIS	Error! Bookmark not defined.
DAN PELIMPAHAN HAK CIPTA	Error! Bookmark not defined.
UCAPAN TERIMA KASIH	Error! Bookmark not defined.
ABSTRAK	vi
DAFTAR ISI	viii
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
DAFTAR LAMPIRAN	xiii
BAB I	1
PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	5
1.3 Batasan Masalah	5
1.4 Tujuan Penelitian	5
1.5 Manfaat Penelitian	6
1.6 Teori	6
1.6.1 Regresi Poisson	6
1.6.2 Multikolinearitas	7
1.6.3 Overdispersi	8
1.6.4 Regresi Binomial Negatif	9
1.6.5 Estimasi Parameter Model Regresi Binomial Negatif	10
1.6.6 Efek Spasial	13
1.6.7 Heterogenitas Spasial	13
1.6.8 Matriks Pembobot Spasial	13
1.6.8.1 Adaptive Gaussian Kernel	14
1.6.8.2 Adaptive Bisquare Kernel	14
1.6.9 Penentuan <i>Bandwidth Optimum</i>	15
1.6.10 Geographically Weighted Negative Binomial Regression	16
1.6.10.1 Pengujian Parameter GWNBR	17

1.6.11 Flexibly Shaped Spatial Scan Statistic	18
1.6.11.1 Likelihood Ratio Test dan Pengujian Hipotesis Monte Carlo	19
1.6.11.2 Hotspot atau Kantong-kantong	20
1.6.12 Stunting	21
1.6.13 Kerangka Konseptual	23
METODOLOGI PENELITIAN	24
2.1 Sumber Data	24
2.2 Identifikasi Variabel	24
2.3 Analisis Data	25
BAB III	28
HASIL DAN PEMBAHASAN	28
3.1 Estimasi Parameter Model Geographically Weighted Negative Binomial Regression (GWNBR)	28
3.2 Karakteristik Data dan Peta Persebaran Jumlah Kasus Stunting dan Faktor-faktor yang diduga Mempengaruhi	31
3.2.1 karakteristik jumlah kasus stunting dan faktor-faktor yang diduga mempengaruhi	31
3.2.2 Peta Persebaran Jumlah kasus Stunting dan Faktor yang mempengaruhinya	32
3.2.2.1 Jumlah Kasus Stunting	32
3.2.2.2 Cakupan Pemberian ASI Eksklusif menurut Kabupaten/Kota di Sulawesi Selatan	33
3.2.2.3 Cakupan Pemberian Makanan Pendamping ASI (MP-ASI) menurut Kabupaten/Kota di Sulawesi Selatan	34
3.2.2.4 Cakupan Imunisasi Dasar Lengkap menurut Kabupaten/Kota di Sulawesi Selatan	35
3.2.2.5 Angka Melek Baca menurut Kabupaten/Kota di Sulawesi Selatan ..	37
3.2.2.6 Cakupan Sanitasi Air Bersih menurut Kabupaten/Kota di Sulawesi Selatan	38
3.2.2.7 Jumlah Sarana Kesehatan menurut Kabupaten/Kota di Sulawesi Selatan	39

3.3 Pemodelan Jumlah Kasus Stunting menurut Kabupaten/Kota di Sulawesi Selatan	40
3.3.1 Pendeteksian Multikolinieritas	40
3.3.2 Pemeriksaan dan penanganan kasus overdispersi	40
3.3.3 Pemodelan Regresi Binomial Negatif	41
3.3.3.1 Pengujian Signifikasi Parameter Secara Serentak	41
3.3.3.2 Pengujian Signifikasi Parameter Parsial	42
3.3.4 Heteroginitas Spasial	42
3.4 Pemodelan Geographically Weighted Negative Binomial Regression	43
3.4.1 Penentuan bandwidth dan Pembobot Optimum	43
3.4.2 pengujian parsial GWNBR secara serentak	43
3.4.3 Pengujian Signifikansi Parameter GWNBR Secara Parsial	44
3.4.4 Pemilihan Model Terbaik	47
3.5 Pendeteksian Jumlah Kasus Stunting di Provinsi Sulawesi Selatan menggunakan Flexibly Shaped Spatial Scan Statistic	47
BAB IV	50
4.1 Kesimpulan	50
4.2 Saran	50
DAFTAR PUSTAKA	52

DAFTAR TABEL

Nomor Urut	Halaman
1. Variabel Penelitian	24
2. Analisis Deskriptif.....	24
3. Nilai VIF dari Variabel Prediktor	24
4. Estimasi Parameter Regresi Binomial Negatif	39
5. Uji Breusch-Pagan (BP).....	40
6. Nilai AIC dari masing-masing Fungsi Kernal.....	24
7. Estimasi Parameter GWNBR.....	42
8. Pengelompokan Kabupaten/kota berdasarkan Variabel Signifikan.....	43
9. Pemilihan Model Terbaik.....	45
10. Hasil Deteksi Kantong Stunting di Provinsi Sulawesi Selatan.....	45

DAFTAR GAMBAR

Nomor Urut	Halaman
1. Kerangka Konseptual	23
2. Peta Sebaran Jumlah Kasus Stunting	30
3. Peta Sebaran Pemberian ASI Eksklusif	31
4. Cakupan Pemberian MP-ASI	32
5. Cakupan Imunisasi Dasar Lengkap	33
6. Angka Melek Baca	34
7. Cakupan Sanitasi Air Bersih	35
8. Jumlah Sarana Kesehatan	36
9. Peta Sebaran Pengelompokan Kabupaten/kota	44
10. Pemetaan Hasil Pendeteksian Kantong Stunting	46

DAFTAR LAMPIRAN

Nomor Urut	Halaman
1. Variabel Penelitian	53
2. Hasil Korelasi Variabel	53
3. Hasil Analisis Overdispersi Regresi Poisson.....	54
4. Hasil Analisis Regresi Binomial Negatif	54
5. Hasil Pengujin Spasial	55
6. Cross Validation	55
7. Bandwidth Optimum tiap Kabupaten/Kota	56
8. Syntax Program R	56

BAB I

PENDAHULUAN

1.1 Latar Belakang

Arah kebijakan Badan Perencanaan dan Pembangunan tahun anggaran 2026 menyebutkan prioritas utama pemerintah dengan beberapa program yang akan dilakukan diantaranya makan bergizi gratis yang merupakan program andalan. Program ini ditargetkan anak dan ibu hamil dengan harapan nutrisi dan gizi anak dan ibu bisa terpenuhi dan mengurangi angka stunting yang ada di Indonesia.

Stunting merupakan kondisi gagal tumbuh pada anak akibat kekurangan gizi kronis, yang berdampak pada perkembangan fisik dan kognitif anak. Di Indonesia, prevalensi stunting telah mengalami penurunan signifikan dalam beberapa tahun terakhir. Berdasarkan data Riset Kesehatan Dasar (Riskesdas, 2024), prevalensi stunting turun dari 30,8% pada tahun 2018 menjadi 21,5% pada tahun 2023, menunjukkan penurunan sebesar 9,3% dalam lima tahun (kemkes, 2023).

Meskipun demikian, angka tersebut masih berada di atas standar yang ditetapkan oleh Organisasi Kesehatan Dunia (WHO), yaitu di bawah 20% (kemkes, 2023). Selain itu, Indonesia menargetkan penurunan prevalensi stunting hingga 14% pada tahun 2024, sesuai dengan Rencana Pembangunan Jangka Menengah Nasional (RPJMN) 2020-2024 (kemkes, 2023). Akan tetapi target tersebut belum terpenuhi. Akhirnya, Untuk mencapai target tersebut, pemerintah Indonesia telah mengimplementasikan berbagai program, termasuk Program Makan Bergizi Gratis (MBG) yang diluncurkan pada tahun 2025. Program ini bertujuan untuk menyediakan makanan bergizi bagi anak-anak sekolah dan ibu hamil, dengan harapan dapat meningkatkan status gizi dan menurunkan angka stunting. Program ini juga diharapkan dapat mendorong pertumbuhan ekonomi lokal melalui pemberdayaan petani dan produsen makanan lokal.

Upaya percepatan penurunan stunting memerlukan kolaborasi lintas sektor dan partisipasi aktif dari seluruh lapisan masyarakat. Dengan komitmen yang kuat dan implementasi program yang efektif, diharapkan Indonesia dapat mencapai target prevalensi stunting 15% pada tahun 2030, sehingga generasi mendatang dapat tumbuh dan mendukung program Indonesia emas 2045.

Terkait dengan tujuan ini yaitu menurunkan angka stunting anak hingga 15% dalam kurung waktu 5 tahun, maka diperlukan upaya penanganan yang serius, salah

satunya adalah dengan penanggulangan ataupun pencegahan kasus stunting dengan menganalisis dan memahami faktor-faktor yang memicu angka kenaikan resiko tersebut. Jika dilihat dari data persentase stunting Provinsi di Indonesia, adanya kecenderungan persentase yang tinggi di pulau Kalimantan, Sulawesi, dan Papua. Sedangkan pada pulau Sumatera dan Jawa, angka persentase balita stunting lebih rendah. Ini menunjukkan adanya ketimpangan provinsi di Indonesia dalam pemenuhan kebutuhan gizi balita, oleh karena itu diperlukan penelitian untuk melihat faktor-faktor yang memengaruhi tingginya persentase stunting dengan mempertimbangkan wilayah atau aspek spasial.

Jumlah kasus stunting merupakan data *count* yang mengikuti distribusi poisson. Regresi Poisson merupakan metode yang sering digunakan untuk menganalisis data *count* (Cameron & Trivedi, 1998). Data *count* adalah data yang menyatakan banyaknya kejadian dalam interval waktu, ruang, atau volume tertentu. Regresi Poisson merupakan model regresi nonlinear yang digunakan untuk menganalisis data diskrit (*count*). Dalam regresi Poisson terdapat asumsi yang harus dipenuhi yaitu variabel respon (Y) berupa data diskrit dan *equidispersi*. *Equidispersi* yaitu nilai rata-rata sama dengan nilai varian. Seringkali hitungan data memiliki variansi yang lebih besar dari meannya atau biasa disebut istilah *overdispersi* (Yasin et al., 2021). Pelanggaran dari asumsi ini menyebabkan parameter yang dihasilkan dari regresi Poisson menjadi kurang akurat, sedangkan jika nilai variansi lebih kecil dari nilai mean disebut *underdispersi* (McCullagh & Nelder, 1989). Sehingga muncul suatu pengembangan model yang disebut Model Negatif Binomial merupakan model yang dapat mengatasi *overdispersi* dan lebih fleksibel daripada model regresi Poisson karena asumsi mean dan variansinya tidak harus sama. (Yasin et al., 2021).

Distribusi Binomial Negatif tidak mengharuskan nilai variansi sama dengan meannya serta memiliki parameter dispersi yang membuat variansi dapat bervariasi menjadi lebih besar dari rata-rata. Apabila nilai parameter dispersi pada regresi Binomial Negatif sama dengan nol, maka akan menghasilkan nilai variansi sama dengan nilai rata-rata sesuai dengan asumsi pada regresi Poisson (Yuli & Indriani, 2015). Penelitian ini tidak hanya sampai pada penanganan *overdispersi*, namun model regresi ini memperhatikan faktor heterogenitas spasial karena pada kenyataannya kondisi geografis, sosial budaya dan ekonomi pada suatu wilayah tentunya akan berbeda-beda atau disebut heterogenitas spasial antar wilayah.

Pengembangan model regresi yang memperhatikan faktor heterogenitas spasial dengan pembobotan geografi yaitu *Geographically Weighted Regression* (GWR) (Fotheringham, 2002). Sebelumnya penelitian dilakukan oleh Brunsdon (1996) yang menunjukkan bahwa model regresi Poisson tidak dapat menjelaskan hubungan antara beberapa set peubah jika terdapat faktor geografis, akan tetapi GWR dapat menjelaskan hubungan yang berbeda pada setiap titik lokasi pengamatan, namun GWR hanya digunakan ketika data atau variabel respon yang kontinu. Sehingga untuk mengatasi variabel respon yang tidak kontinu atau diskrit, Nakaya et al. (2005) telah mengembangkan model *Geographically Weighted Poisson Regression* (GWPR). Model GWPR cukup baik digunakan apabila asumsi ekuidispersi terpenuhi, namun bila terjadi overdispersi, terdapat model *Geographically Weighted Negative Binomial Regression* (GWNBR) yang diperkenalkan pertama kali oleh Ricardo & Carvalho (2014) dalam penelitiannya menyatakan bahwa metode GWNBR baik digunakan untuk memodelkan data diskrit, khususnya ketika data tersebut terjadi overdispersi dan menyatakan metode GWNBR ini lebih baik dibandingkan dengan regresi Poisson, GWPR, dan regresi Binomial Negatif berdasarkan nilai AIC.

Penelitian sebelumnya menggunakan model GWNBR telah dilakukan oleh peneliti, Juniardi & Salamah (2015) dengan melakukan analisis faktor-faktor yang mempengaruhi jumlah kasus Kusta di Jawa Timur menggunakan *Geographically Weighted Negative Binomial Regression* (GWNBR). Fitriyah (2017) tentang estimasi parameter model GWNBR dengan pembobot Adaptive Gaussian Kernel yang diaplikasikan terhadap pemetaan kemiskinan dan menghasilkan 15 kelompok wilayah berdasarkan variabel yang signifikan. Yasin et al. (2021) Grafik model GWNBR menggunakan R-Shiny yang menghasilkan model GWNBR dengan pembobot Adaptive Boxcar model terbaik berdasarkan nilai AIC. Putera et al. (2021) tentang Pemodelan Spasial Kasus Terkonfirmasi Covid-19 di Kalimantan, Indonesia menggunakan GWNBR lebih baik dari model lainnya dalam hal AIC.

Selain mengetahui faktor-faktor yang berpengaruh terhadap kasus stunting pada anak, maka perlu untuk mengetahui hotspot atau kantong kasus stunting, dikarenakan dengan adanya informasi tersebut dapat diketahui wilayah mana saja yang memerlukan perhatian khusus dan prioritas utama dalam upaya menangani masalah kasus stunting. Hotspot atau kantong kasus adalah wilayah tertentu yang memiliki jumlah atau prevalensi kasus stunting yang secara signifikan lebih tinggi

dibandingkan dengan daerah sekitarnya. Dalam analisis spasial, istilah ini digunakan untuk menggambarkan daerah yang menunjukkan klusterisasi (pengelompokan) kasus dalam jumlah besar, sehingga menjadi fokus utama dalam intervensi kesehatan Masyarakat. Beberapa metode yang digunakan untuk mendeteksi hotspot antara lain *Circular Spatial Scan Statistic*, *Upper Level Set Scan Statistic* dan *Flexibly Shaped Spatial Scan Statistic*. Kelebihan metode *Flexibly Shaped Spatial Scan Statistic* dibanding metode *Circular Spatial Scan Statistic* adalah keakuratan dan kekuatan yang cukup baik dalam mendeteksi hotspot yang tidak berbentuk lingkaran (Tango dan Takahashi, 2005). Penelitian sebelumnya tentang mendeteksi hotspot atau kantong pernah dilakukan oleh Hasibuan (2008) Dimana dengan metode *Flexibly Shaped Spatial Scan* diperoleh tujuh kantong kemiskinan dari beberapa kecamatan di Indramayu Jawa Barat, pemodelan kasus pneumonia balita di kota Surabaya dengan *Flexibly shaped spatial scan statistic* oleh Purhadi (2015) menjelaskan bahwa terdapat empat kantong yang sangat beresiko terhadap pneumonia di kota Surabaya, dan penelitian Niswatul (2016) tentang Analisis Pola Persebaran ISPA (Infeksi Saluran Pernafasan Akut) Sebagai Dampak Industri Migas di Kabupaten Bojonegoro Menggunakan *Spatial Pattern Analysis* dan *Flexibly Shaped Spatial Scan Statistic* yang menghasilkan dua belas kantong untuk provinsi sangat rawan, empat belas kantong dengan provinsi rawan dan delapan kantong untung provinsi tidak rawan.

Berdasarkan uraian di atas menunjukkan masih tingginya kasus stunting di Indonesia, sehingga diperlukan suatu penelitian untuk mengidentifikasi faktor-faktor yang mempengaruhi jumlah kasus stunting di wilayah Kota Makassar dengan metode *Generalized Weighted Negative Binomial Regression*. Serta diperlukan identifikasi keberadaan kantong-kantong jumlah kasus stunting di Kota Makassar dengan pendekatan *Flexibly Shaped Spatial Scan Statistic* agar upaya penanggulangan jumlah kasus stunting lebih efektif dan tepat sasaran. Adapun penelitian sebelumnya yang menggabungkan kedua metode ini dilakukan oleh Hidayanti (2015) pemodelan kasus DBD di kota Surabaya dengan *Geographically Weighted Regression* dan *Flexibly Shaped Spatial Scan* menyatakan bahwa dengan mengelolah faktor berpengaruh terlebih dahulu membuat deteksi kasus lebih baik. Luhung (2021) pemodelan dan pemetaan jumlah penderita kusta di Jawa Barat dengan regresi binomial negative dan *Flexibly Shaped Spatial Scan* menghasilkan

3 faktor berpengaruh signifikan dalam mendeteksi kasus kantong yang lebih rawan menghasilkan keakuratan dalam pemetaan dan lebih efektif dalam mendeteksi *cluster* dalam suatu wilayah yang memiliki potensi penyakit kusta tinggi dengan menggunakan gabungan dari kedua metode. Maka, penelitian ini mengambil judul **“Pemodelan *Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic* Pada Jumlah Kasus Stunting di Provinsi Sulawesi Selatan”**

1.2 Rumusan Masalah

Berdasarkan dari latar belakang yang telah di uraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana estimasi parameter model *Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic*?
2. Bagaimana pemodelan kasus Stunting di Provinsi Sulawesi Selatan dengan menggunakan metode *Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic*?
3. Bagaimana mendeteksi *hotspot* atau kantong Stunting di Provinsi Sulawesi Selatan dengan menggunakan metode *Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic*?

1.3 Batasan Masalah

Adapun Batasan masalah pada penelitian ini adalah sebagai berikut:

1. Data yang digunakan adalah banyaknya kasus Stunting tiap Kabupaten/kota di Provinsi Sulawesi Selatan tahun 2024.
2. Metode estimasi parameter yang digunakan adalah Maximum Likelihood Estimation (MLE).
3. Pembobot yang di gunakan adalah Adaptive Bisquare Kernel.

1.4 Tujuan Penelitian

Berdasarkan latar belakang dan rumusan masalah diatas maka tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut.

1. Memperoleh estimasi parameter *Geographically Weighted Binomial Regression Flexibly Shaped Spatial Scan Statistic*.
2. Memperoleh hasil pemodelan *Geographically Weighted Binomial Regression Flexibly Shaped Spatial Scan Statistic*.

3. Mengetahui faktor yang berpengaruh terhadap kasus stunting, dan kecamatan mana saja yang terdeteksi sebagai hotspot atau kantong Stunting di Provinsi Sulawesi Selatan dengan *Geographically Weighted Binomial Regression Flexibly Shaped Spatial Scan Statistic*.

1.5 Manfaat Penelitian

Hasil penelitian ini diharapkan mampu memberi manfaat bagi berbagai pihak. Seperti dinas Kesehatan kota makassar dapat memberikan faktor-faktor yang mempengaruhi keberadaan hotspot atau kantong kasus stunting, pemerintah setempat sebagai landasan dalam pengambilan kebijakan, tambahan ilmu tentang penerapan ilmu statistika dalam kehidupan sehari-hari, memberi pemahaman tentang model *Geographically Weighted Negative Binomial Regression Flexibly Shaped Spatial Scan Statistic*, memberikan informasi efektivitas mengenai Stunting, memberi informasi tambahan pada pemerintah mengenai penanganan Stunting pada masing masing wilayah karna memiliki pengaruh kondisi lokal sehingga setiap wilayah dapat di tangani dengan cara yang berbeda-beda.

1.6 Teori

Sub-bab teori ini membahas mengenai beberapa teori yang digunakan untuk pokok pembahasan terkait metode *Geographically Weighted Binomial Regression Flexibly Shaped Spatial Scan Statistic*.

1.6.1 Regresi Poisson

Regresi Poisson Regresi poisson merupakan model regresi nonlinear yang sering digunakan untuk data count, dimana variabel respon mengikuti distribusi poisson Agresti (2002). Distribusi poisson adalah suatu distribusi dimana kejadian tergantung pada interval waktu tertentu atau di suatu daerah tertentu dengan hasil pengamatan berupa variabel diskrit. Interval waktu tersebut dapat berupa semenit, sehari, seminggu, sebulan atau setahun (Walpole, 1995).

Ciri-ciri percobaan yang mengikuti sebaran distribusi poisson, adalah sebagai berikut (Cameron dan Trivedi, 1998).

- a. Kejadian dengan probabilitas kecil yang terjadi pada populasi dengan jumlah anggota besar.
- b. Bergantung pada interval waktu tertentu.
- c. Kejadian termasuk dalam proses stokastik (*counting process*).

- d. Perulangan dari kejadian yang mengikuti sebaran binomial. Menurut (Myers, 1990), probabilitas distribusi poisson adalah sebagai berikut:

$$P(Y; \mu) = \frac{e^{-\mu} \mu^y}{y!}; y = 0, 1, 2, \dots \quad (1)$$

dengan μ adalah rata-rata variabel random Y yang berdistribusi poisson dimana nilai rata-rata dan varians dari variabel random Y mempunyai nilai lebih dari nol. Distribusi poisson digunakan untuk memodelkan peristiwa yang jarang terjadi dalam periode waktu tertentu. Misalkan terdapat sekumpulan data dengan struktur berikut:

$$\begin{bmatrix} y_1 & x_{11} & x_{12} & \dots & x_{1k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ y_i & x_{i1} & x_{i2} & \dots & x_{ik} \end{bmatrix} \quad (2)$$

dimana:

y_i = Nilai variabel respon (Y) dari observasi ke- i

x_{ik} = Nilai variabel prediktor (x_k) dari observasi ke- i

Model regresi poisson ditulis dengan persamaan berikut:

$$\mu_i = \exp(\mathbf{x}_i^T \boldsymbol{\beta}) \quad (3)$$

dimana:

$$\mathbf{x}_i = [1 \quad x_{1i} \quad x_{2i} \quad \dots \quad x_{ki}]^T$$

$$\boldsymbol{\beta} = [\beta_0 \quad \beta_{1i} \quad \beta_{2i} \quad \dots \quad \beta_k]^T$$

1.6.2 Multikolinearitas

Salah satu asumsi yang harus dipenuhi pada analisis regresi dengan beberapa peubah prediktor adalah tidak adanya korelasi antara satu peubah prediktor dengan peubah prediktor yang lain. Sembiring (1995) menyatakan bahwa jika dalam suatu model regresi terdapat kolinieritas maka akan mempengaruhi hubungan antara peubah prediktor dengan peubah respon. Penduga koefisien dari peubah prediktor menjadi tidak tunggal, melainkan tak terhingga banyaknya sehingga sulit untuk melakukan pendugaan. Selain itu, multikolinieritas dalam regresi dapat mengakibatkan besarnya simpangan baku dari penduga koefisien regresi. Kejadian multikolinieritas akan menyebabkan kesalahan yang besar pada penduga parameter regresi. Sehingga menyebabkan hasil penduga parameter bias dan tidak baik untuk dianalisis lebih lanjut. Oleh sebab itu, perlu dilakukan pemeriksaan multikolinieritas agar hasil penduga parameter tersebut bisa dianalisis lebih lanjut. Pemeriksaan multikolinieritas dapat dilakukan melalui perhitungan nilai koefisien korelasi Pearson

(ril) antar variabel prediktor. Jika nilai-nilai koefisien korelasi Pearson (ril) antar variabel prediktor lebih besar dari 0,95 maka terjadi multikolinieritas dalam model tersebut. Selain dengan nilai koefisien korelasi Pearson (ril), pemeriksaan multikolinieritas dapat dilakukan melalui nilai *Variance Inflation Factors* (VIF).

Pendeteksian kasus multikolinearitas menurut Hocking (1996) dapat dilihat dengan beberapa cara berikut:

- Jika koefisien korelasi pearson (r_{ij}) antar variable prediktor lebih besar dari 0,95 ($r_{ij} > 0,95$) maka terdapat korelasi antar variable tersebut.
- Nilai VIF lebih besar dari 10 ($VIF > 10$) menunjukkan bahwa adanya multikolinearitas antar variable predictor atau terdapat pelanggaran asumsi multikolinearitas. Nilai VIF dinyatakan sebagai berikut:

$$VIF_j = \frac{1}{1 - R_j^2} \quad ; j = 1, 2, \dots, p \quad (4)$$

dengan j adalah jumlah variable predictor dan R_j^2 adalah koefisien determinasi antara satu variable dengan variabel prediktor lainnya. Solusi untuk mengatasi adanya kasus multikolinieritas yaitu dengan mengeluarkan variabel prediktor satu per satu mulai dari yang memiliki nilai VIF paling besar, melakukan transformasi variabel, penambahan variabel ataupun melakukan metode *Principal Component Analysis* (PCA). Pelanggaran asumsi non-multikolinieritas dapat menyebabkan nilai taksiran parameter regresi yang didapatkan memiliki standar error besar sehingga asumsi non-multikolinieritas menjadi salah satu syarat utama yang harus dipenuhi dalam pemodelan regresi.

1.6.3 Overdispersi

Regresi Poisson dikatakan overdispersi apabila nilai variansinya lebih besar dari nilai rata-ratanya ($Var(Y) > E(Y)$). Jika pada data diskrit terjadi *overdispersi* dan tetap menggunakan regresi Poisson sebagai metode penyelesaiannya, maka nilai *standard error* menjadi *underestimate* sehingga kesimpulan yang akan ditarik menjadi tidak valid. *Overdispersi* merupakan nilai *dispersi pearson chisquare* dan *deviance* yang dibagi dengan derajat bebasnya, diperoleh nilai lebih besar dari 1. Untuk melihat adanya indikasi overdispersi, digunakan nilai devians (ϕ) dibagi dengan derajat bebas (df) (Famoye, et al, 2004):

$$\hat{\phi} = \frac{\text{nilai deviance}}{df} \quad (5)$$

Dimana df didapatkan dari $n - p - 1$ dengan n adalah jumlah data dan k merupakan jumlah parameter. Sedangkan, nilai *deviance* (D) didefinisikan sebagai:

$$D = 2 \sum_{i=1}^n \left\{ y_i \ln \left(\frac{y_i}{\mu_i} \right) - (y_i - \mu_i) \right\} \quad (6)$$

Keterangan:

D : Nilai *deviance*

y_i : Nilai observasi

μ_i : Nilai yang diharapkan dari model

n : Jumlah data

Jika nilai $\phi > 1$ artinya terjadi *overdispersi* pada regresi poisson, sedangkan jika $\phi < 1$ artinya terjadi *underdispersi*, dan jika $\phi \approx 1$ artinya tidak terjadi kasus *over* maupun *under* biasa disebut *equidispersi*.

1.6.4 Regresi Binomial Negatif

Regresi Binomial Negatif, variabel responnya diasumsikan memiliki distribusi Binomial Negatif yang dihasilkan dari distribusi campuran Poisson-Gamma (Yasin dkk, 2021). Model binomial negatif dinyatakan pada:

$$y_i \sim NB \left[\exp \left(\left(\sum_{j=0}^k \beta_j x_{ij} \right), \theta \right) \right], \quad i = 1, 2, \dots, n \quad (7)$$

Binomial Negatif merupakan salah satu solusi untuk mengatasi adanya kasus *overdispersi*. Model Binomial Negatif didasarkan pada distribusi *mixture Poisson-Gamma* (Hardin dan Hilbe 2018). Sebaran binomial negatif memiliki rata-rata dan varian (Hilbe 2011).

$$E(y_i | x_i) = \mu_i = \exp(x_i^T \beta) \quad (8)$$

$$\text{var}(y_i | x_i) = \mu_i \theta \mu_i^2 \quad (6)$$

Sehingga menghasilkan fungsi peluang distribusi binomial negatif adalah (Greene 2007):

$$f(y_i | \mu_i, \theta) = \frac{\Gamma(y_i + \frac{1}{\theta})}{\Gamma(\frac{1}{\theta}) \Gamma(y_i + 1)} \left(\frac{1}{1 + \theta \mu_i} \right)^{\frac{1}{\theta}} \left(\frac{\theta \mu_i}{1 + \theta \mu_i} \right)^{y_i}, \quad y_i = 0, 1, 2, \dots, n \quad (10)$$

Keterangan:

- $f(y, \mu, \theta)$ = peluang sebaran binomial negatif
 μ = nilai harapan peubah respon Y
 y = nilai dari peubah respon Y
 θ = parameter *disperse*

Binomial Negatif memiliki bentuk model regresi yang sama seperti model regresi Poisson pada persamaan (5) karena memiliki fungsi penghubung yang sama, yaitu fungsi penghubung *log*. Model regresi binomial negatif dituliskan sebagai berikut:

$$E(Y) = \mu \text{ dan } Var(Y) = \mu + a\mu^2 \quad (11)$$

dengan θ adalah parameter disperse. Kemudian fungsi probabilitas Binomial Negatif dinyatakan sebagai berikut:

$$\ln(\hat{\mu}_i) = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \dots + \hat{\beta}_k x_{ki} \quad (12)$$

Hilbe (2011) menyatakan bahwa model binomial negative pada umumnya menggunakan bentuk eksponensial untuk mencari nilai $\hat{\mu}_i$ yaitu:

$$\hat{\mu}_i = \exp(\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \dots + \hat{\beta}_k x_{ki}) \quad (13)$$

1.6.5 Estimasi Parameter Model Regresi Binomial Negatif

Estimasi parameter dari regresi binomial negative digunakan metode *Maximum Likelihood Estimation* (MLE) dan menggunakan metode iterasi *Newton Raphson* untuk memaksimalkan fungsi likelihood (Hilbe, 2011). Metode ini membutuhkan turunan pertama dan turunan kedua dari fungsi *likelihood* y_i mempunyai fungsi kepadatan probabilitas dinyatakan pada:

$$L(\boldsymbol{\beta}, \theta) = \ln\{L(\boldsymbol{\beta}, \theta)\}$$

$$= \sum_{i=1}^n \left[\sum_{r=1}^{y_i-1} \ln(r + \theta^{-1}) - \ln(y_i!) + \ln(\theta \mu_i) - (\theta^{-1} + y_i) \ln(1 + \theta \mu_i) \right] \quad (14)$$

Turunan pertama dari fungsi log-likelihood terhadap koefisien β dinyatakan pada persamaan:

Untuk β_0

$$\frac{\partial L(\boldsymbol{\beta}, \theta)}{\partial \beta_0} = \sum_{i=1}^n \left[\frac{y_i - \mu_i}{1 + \theta \mu_i} \right] \quad (15)$$

Untuk β_j

$$\frac{\partial L(\boldsymbol{\beta}, \theta)}{\partial \beta_j} = \sum_{i=1}^n \left[\frac{(y_i - \mu_i) x_{ij}}{1 + \theta \mu_i} \right] \quad (16)$$

Turunan pertama dari fungsi *log-likelihood* dari parameter disperse θ dinyatakan pada:

$$\begin{aligned} f'(\theta) &= \frac{\partial L(\boldsymbol{\beta}, \theta)}{\partial \theta} \\ &= \sum_{i=1}^n \left[-\theta^{-2} \sum_{r=0}^{y_i-1} \frac{1}{(r + \theta^{-1})} + \theta^{-2} \ln(1 + \theta \mu_i) - \left(\frac{(y_i - \mu_i)}{\theta(1 + \theta \mu_i)} \right) \right] \end{aligned} \quad (16)$$

Turunan parsial kedua fungsi *log-likelihood* terhadap parameter koefisien regresi (β_0, β_j) elemen diagonal pada matriks Hessian ditunjukkan pada persamaan:

$$\begin{aligned} \frac{\partial^2 L(\boldsymbol{\beta}, \theta)}{\partial \beta_0^2} &= - \sum_{i=1}^n \left[\frac{(1 + \theta \mu_i) \mu_i}{(1 + \theta \mu_i)^2} \right] \\ \frac{\partial^2 L(\boldsymbol{\beta}, \theta)}{\partial \beta_j^2} &= - \sum_{i=1}^n \left[\frac{-\mu_i x_{ij} (1 + \theta \mu_i) - (y_i - x_{ij})(x_{ij} \theta \mu_i)}{(1 + \theta \mu_i)^2} \right] \end{aligned}$$

$$\frac{\partial^2 L(\boldsymbol{\beta}, \theta)}{\partial \beta_j^2} = - \sum_{i=1}^n \left[\frac{(1 + \theta \mu_i) x_{ij} \mu_i}{(1 + \theta \mu_i)^2} \right] \quad (17)$$

Turunan parsial kedua terhadapat (β_0, β_j) elemen *off* diagonal pada matriks Hessian ditunjukkan pada persamaan:

$$\begin{aligned} \frac{\partial^2 L(\boldsymbol{\beta}, \theta)}{\partial \beta_j \partial \beta_k} &= \sum_{i=1}^n \left[\frac{-\mu_i x_{ij} x_{ik} (1 + \theta \mu_i) - (y_i - x_i) (x_j x_{ik} \theta \mu_i)}{(1 + \theta \mu_i)^2} \right] \\ \frac{\partial^2 L(\boldsymbol{\beta}, \theta)}{\partial \beta_j \partial \beta_k} &= - \sum_{i=1}^n \left[\frac{\mu_i x_{ij} x_{ik} (1 + \theta \mu_i)}{(1 + \theta \mu_i)^2} \right] \end{aligned} \quad (18)$$

Ekspektasi dari turunan kedua *log-likelihood* adalah dinyatakan pada persamaan berikut:

$$E \left(- \frac{\partial^2 L(\boldsymbol{\beta}, \theta)}{\partial \beta_j \partial \beta_k} \right) = \sum_{i=1}^n \left[\frac{\mu_i x_{ij} x_{ik} (1 + \theta \mu_i)}{(1 + \theta \mu_i)} \right] \quad (19)$$

Turunan kedua fungsi *log-likelihood* terhadap parameter disperse θ dinyatakan pada:

$$\begin{aligned} f''(\theta) &= \frac{\partial^2 L(\boldsymbol{\beta}, \theta)}{\partial \theta^2} \\ &= \sum_{i=1}^n \left[\theta^{-3} \sum_{r=0}^{y_i-1} \frac{(2r + \theta^{-1})}{(r + \theta^2 \mu_i)^2} - 2\theta^{-3} \ln(1 + \theta \mu_i) + \frac{-\theta^2 \mu_i}{(1 + \theta \mu_i)} + \frac{(y_i - \mu_i (1 + 2\theta \mu_i))}{(\theta + \theta^2 \mu_i)^2} \right] \end{aligned} \quad (20)$$

Langkah-langkah dalam estimasi parameter dengan metode *Newton Raphson* pada model regresi binomial negatif adalah sebagai berikut:

Pembentukan vektor gradien $\mathbf{g}$

$$\mathbf{g}^T(\boldsymbol{\beta}_{(m)})_{(k+1)} = \left[\frac{\partial \ln L(\boldsymbol{\beta})}{\partial \theta}, \frac{\partial \ln L(\boldsymbol{\beta})}{\partial \beta_0}, \frac{\partial \ln L(\boldsymbol{\beta})}{\partial \beta_1}, \dots, \frac{\partial \ln L(\boldsymbol{\beta})}{\partial \beta_k} \right]$$

Pembentukan matriks Hessian $\mathbf{H}$

$$\mathbf{H}(\boldsymbol{\beta}_{(m)})_{(k+1)(k+1)} = \begin{bmatrix} \frac{\partial^2 \ln L(\boldsymbol{\beta})}{\partial \theta^2} & \frac{\partial^2 \ln L(\boldsymbol{\beta})}{\partial \theta \partial \beta_0} & \dots & \frac{\partial^2 \ln L(\boldsymbol{\beta})}{\partial \theta \partial \beta_k} \\ \frac{\partial^2 \ln L(\boldsymbol{\beta})}{\partial \beta_0^2} & \dots & \dots & \frac{\partial^2 \ln L(\boldsymbol{\beta})}{\partial \beta_0 \partial \beta_k} \\ & & \ddots & \vdots \\ & & & \frac{\partial^2 \ln L(\boldsymbol{\beta})}{\partial \beta_k^2} \end{bmatrix}$$

Melakukan iterasi yang dimulai pada $m = 0$ dengan persamaan yang ditujukan pada:

$$\hat{\beta}_{(m+1)} = \hat{\beta}_{(m)} - \mathbf{H}^{-1}(\hat{\beta}_{(m)})\mathbf{g}(\hat{\beta}_{(m)}) \quad (21)$$

Dengan $\beta_{(m)}$ adalah estimator parameter yang dikonvergen pada iterasi ke- m . jika belum mencapai penaksir parameter yang konvergen. Maka dilakukan ulang pada iterasi ke $m = m + 1$. Penaksir parameter yang konvergen diperbolehkan jika $\|\hat{\beta}_{(m+1)} - \hat{\beta}_{(m)}\| \leq \varepsilon$. Dimana ε merupakan bilangan sangat kecil.

1.6.6 Efek Spasial

Efek spasial ditunjukkan adanya dependensi/autokorelasi spasial dan heterogenitas spasial. Autokorelasi spasial adalah penilaian korelasi antar pengamatan yang berdekatan pada suatu variabel. Jika pengamatan $X_1, X_1, \dots, X_n$ menunjukkan saling ketergantungan terhadap ruang, maka data tersebut dikatakan terdapat autokorelasi spasial. Metode pengujian untuk mengetahui apakah terdeteksi autokorelasi spasial adalah dapat menggunakan indikator *Moran's I*, *Rasio Geary's*, dan *Local Indicator of Spatial Autocorrelation* (LISA).

1.6.7 Heterogenitas Spasial

Heterogenitas spasial dapat terjadi apabila satu variabel prediktor yang sama memberikan respon yang berbeda pada lokasi lain dalam satu wilayah penelitian. Menurut Anselin (1988) pengujian heterogenitas spasial dilakukan untuk melihat perbedaan karakteristik antara satu titik pengamatan dengan titik pengamatan lainnya, sehingga parameter regresi yang dihasilkan berbeda-beda secara spasial. Pengujian *heterogenitas* spasial dilakukan menggunakan statistik uji *Breusch-Pagan* (BP) dengan hipotesis sebagai berikut:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_p^2 = \sigma \text{ (varians antar Lokasi sama)}$$

$$H_1 : \text{minimal ada satu } \sigma_i^2 \neq \sigma^2 \text{ (varians antar Lokasi berbeda)}$$

Dimana p adalah banyaknya variable prediktor, σ^2 adalah varians e_i , dan σ_i^2 adalah varians dari variable predictor ke i . statistik uji sebagai berikut:

$$BP = \left(\frac{1}{2}\right) f^T Z (Z^T Z)^{-1} Z^T f \sim X_{(p)}^2 \quad (22)$$

1.6.8 Matriks Pembobot Spasial

Matriks pembobot spasial menggunakan kedekatan antar wilayah atau jarak antar wilayah satu sama lain. Beberapa fungsi yang digunakan dalam pembentukan matriks pembobot spasial adalah sebagai berikut (Fotheringham et al., 2002):

1.6.8.1 Adaptive Gaussian Kernel

Menurut Leung, Mei dan Zhang (2000) dalam analisis spasial, suatu pengamatan yang berdekatan dengan lokasi i diasumsikan lebih berpengaruh dalam pendugaan parameter daripada pengamatan yang lebih jauh. Oleh karena itu ketika parameter di lokasi ke- i diduga, harus ditempatkan pada pengamatan yang dekat dengan lokasi ke- i . Berdasarkan pokok, salah satu fungsi pembobot yang paling umum digunakan adalah fungsi Gaussian seperti berikut:

$$w_{ij} = \exp \left[-\frac{1}{2} \left(\frac{d_{ij}}{b_i} \right)^2 \right] \quad (23)$$

$i, j = 1, 2, \dots, n; i \neq j$

d_{ij} = jarak *euclidean* antara lokasi amatan i dengan lokasi amatan j

b_i = lebar bandwidth pada lokasi pengamatan ke- i

Jika i dan j sama, pembobot dari titik akan tunggal sedangkan pembobotan dari data lain akan menurun berdasarkan pada kurva Gaussian seiring dengan meningkatnya jarak diantara i dan j .

1.6.8.2 Adaptive Bisquare Kernel

Menurut Leung, dkk (2000) fungsi pembobotan yang lain adalah untuk mengatur bobot bernilai nol jika berada di luar bandwidth dan menurun secara monoton ke nol jika berada dalam bandwidth seiring dengan peningkatan jarak dari kedua lokasi pengamatan.

$$w_{ij} = \left\{ \left[-\frac{1}{2} \left(\frac{d_{ij}}{b_i} \right)^2 \right], \text{ jika } d_{ij} < b, \text{ dan } 0 \text{ untuk lainnya} \right\} \quad (24)$$

Keterangan:

$i, j = 1, 2, \dots, n; i \neq j$

d_{ij} = jarak *Euclidean* antara Lokasi amatan i dengan Lokasi amatan j

b_i = lebar *bandwidth* pada lokasi pengamatan ke- i

dengan $d_{ij} = \sqrt{(\mu_i - \mu_j)^2 + (v_i - v_j)^2}$ adalah jarak *Euclidean* antara titik Lokasi pengamatan ke- i dan titik lokasi pengamatan ke- j .

1.6.9 Penentuan *Bandwidth Optimum*

Secara teoritis *bandwidth* merupakan luasan dengan radius b dari titik pusat lokasi yang digunakan sebagai dasar menentukan bobot setiap pengamatan terhadap model regresi pada lokasi tersebut. Pengamatan-pengamatan yang terletak di dalam radius b masih dianggap berpengaruh terhadap model pada lokasi tersebut sehingga akan diberi bobot tergantung pada fungsi yang digunakan. Nilai *bandwidth* yang sangat kecil menyebabkan varians semakin besar. Hal ini dikarenakan jika nilai *bandwidth* sangat kecil maka akan semakin sedikit pengamatan yang berada dalam radius b , sehingga model yang diperoleh akan sangat kasar (*under smoothing*). Sebaliknya nilai *bandwidth* yang besar akan menimbulkan bias yang semakin besar karena semakin banyak pengamatan yang berada dalam radius b , sehingga model yang diperoleh akan terlampau halus (*over smoothing*).

Pemilihan *bandwidth* optimum menjadi sangat penting karena akan mempengaruhi ketepatan model terhadap data, yaitu mengatur varians dan bias dari model. Penentuan *bandwidth optimum* dilakukan menggunakan metode *Cross Validation* (CV) sebagai berikut:

$$CV(b) = \sum_{i=1}^n (y_i - \hat{y}_{-i}(b))^2 \quad (25)$$

$\hat{y}_{-i}(b)$ merupakan nilai penaksiran untuk pengamatan ke- i yang Dimana saat pemodelannya pengamatan ke- i dihilangkan dari proses penaksiran. *Bandwidth optimum* tercapai apabila diperoleh nilai cv paling minimum.

Pemilihan *bandwidth optimum* salah satunya adalah *Akaike Information Criterion* (AIC). Menurut Akaike (1974) fungsi AIC yaitu:

$$AIC = 2_n \log e(\delta) + n \log e(2\pi) + n + tr(S) \quad (26)$$

Proses pemilihan lebar *bandwidth optimum* menggunakan teknik *Golden Section Search*. Teknik ini dilakukan secara iterasi dengan mengevaluasi nilai AIC terkecil pada *interval* jarak *minimum* dan *maksimum* lokasi pengamatan sehingga diperoleh nilai AIC *minimum*.

1.6.10 Geographically Weighted Negative Binomial Regression

Model Geographically Weighted Negative Binomial Regression (GWNBR) adalah salah satu metode yang cukup efektif untuk menduga data yang memiliki heterogenitas spasial untuk data count yang memiliki *overdispersi*. GWNBR merupakan salah satu metode yang cukup efektif untuk menduga parameter lokal dengan unit amatan berupa wilayah pada data *count* yang memiliki *heterogenitas* spasial dan mengalami kasus *overdispersi*. GWNBR juga merupakan metode hasil pengembangan dari model regresi Binomial Negatif. Model GWNBR akan menghasilkan parameter lokal yang masing-masing memiliki parameter berbeda-beda. Model GWNBR dirumuskan sebagai berikut (Ricardo dan Carvalho 2014):

$$y_i \sim NB \left[\exp \left(\sum_k \beta_k(\mu_i, v_i) \chi_{ki} \right), \theta(\mu_i, v_i) \right] \quad i = 1, 2, \dots, n \quad (27)$$

$$y_i \sim NB[\exp(\chi_i' \beta(\mu_i, v_i), \theta(\mu_i, v_i))]$$

dimana:

$i = 1, 2, \dots, n$

y_i = nilai observasi respon pada Lokasi ke- i

χ_{ki} = variabel preditor Lokasi (μ_i, v_i)

$\beta_k(\mu_i, v_i)$ = koefesiensi regresi di lokasi (μ_i, v_i)

$\theta(\mu_i, v_i)$ = parameter disperse pada Lokasi (μ_i, v_i)

Fungsi sebaran binomial negatif untuk setiap Lokasi dapat ditulis sebagai berikut (Yasin et al., 2021):

$$\begin{aligned} f(y_i | x_i^T, \beta(u_i, v_i), \theta(u_i, v_i)) \\ = \frac{\Gamma(y_i + \frac{1}{\theta_i})}{\Gamma(\frac{1}{\theta_i}) \Gamma(y_i + 1)} \left(\frac{1}{1 + \theta_i \mu_i} \right)^{\frac{1}{\theta_i}} \left(\frac{\theta_i \mu_i}{1 + \theta_i \mu_i} \right)^{y_i} \end{aligned} \quad (28)$$

model GWNBR dapat ditulis sebagai berikut:

$$\hat{\mu}_i = \exp(\hat{\beta}_0(u_i, v_i) + \hat{\beta}_1(u_i, v_i)x_{i1} + \hat{\beta}_2(u_i, v_i)x_{i2} + \dots + \hat{\beta}_k(u_i, v_i)x_{ik}) \quad (29)$$

1.6.10.1 Pengujian Parameter GWNBR

Pengujian signifikansi parameter model GWNBR terdiri dari uji serentak dan uji parsial. Menentukan nilai statistik uji, terlebih dahulu ditentukan dua buah fungsi *likelihood* yang berhubungan dengan model regresi yang diperoleh. Fungsi-fungsi *likelihood* yang dimaksud adalah $L(\hat{\Omega})$ yaitu nilai *maximum likelihood* untuk model yang lebih lengkap dengan melibatkan variabel prediktor dan $L(\hat{\omega})$ yaitu nilai *maximum likelihood* untuk model sederhana tanpa melibatkan prediktor. Uji signifikansi secara serentak dapat menggunakan *Maximum Likelihood Ratio Test* (MLRT). Dengan hipotesis sebagai berikut:

$$H_0 : \beta_1(\mu_i, v_i) = \beta_2(\mu_i, v_i) = \dots = \beta_p(\mu_i, v_i) = 0$$

$$H_0 : \beta_j(\mu_i, v_i) \neq 0 ; j = 1, 2, \dots, p$$

Statistik uji:

$$D(\hat{\beta}) = -2 \ln \left(\frac{L(\hat{\omega})}{L(\hat{\Omega})} \right) = 2 (\ln L(\hat{\Omega}) - L(\hat{\omega})) \quad (30)$$

Kriteria penolakan adalah tolak H_0 jika nilai $D(\hat{\beta})$ lebih besar dari $\chi^2_{(p,a)}$ yang artinya minimal terdapat satu parameter dalam model GWNBR yang berpengaruh signifikan terhadap variabel respon. Setelah dilakukan pengujian serentak, dilakukan pengujian secara parsial untuk mengetahui parameter mana saja yang memberikan pengaruh signifikan terhadap variabel respon pada tiap – tiap lokasi dengan hipotesis sebagai berikut:

$$H_0 : \beta_j(\mu_i, v_i) = 0$$

$$H_1 : \beta_j(\mu_i, v_i) \neq 0 ; j = 1, 2, \dots, p$$

Statistik uji:

$$Z_{hit} = \frac{\hat{\beta}_j(\mu_i, v_i)}{se(\hat{\beta}_j(\mu_i, v_i))} \quad (31)$$

Dimana $\hat{\beta}_j$ adalah koefisien model variable prediktor ke-j, $se(\hat{\beta}_j)$ adalah *standart error* dan estimasi *maximum likelihood*. Daerah penolakan adalah tolak H_0 jika nilai dari $|Z_{hit}|$ lebih besar dari $z_{\alpha/2}$ yang artinya parameter tersebut berpengaruh signifikan terhadap variabel respon pada tiap – tiap lokasi dalam model GWNBR.

1.6.11 Flexibly Shaped Spatial Scan Statistic

Menurut Luhung (2021), *spatial scan statistic* merupakan sebuah metode untuk mengidentifikasi keberadaan kluster (*hotspot*) yang signifikan secara statistik terkait risiko kasus tertentu di suatu wilayah. Metode ini berkembang ke dalam beberapa variasi, seperti *Circular Spatial Scan Statistic*, *Upper Level Set Scan Statistic*, dan *Flexibly Shaped Spatial Scan Statistic*. Di antara variasi tersebut, *Flexibly Shaped Spatial Scan Statistic* dinilai sebagai salah satu pendekatan terbaik dalam mendeteksi kluster yang polanya tidak beraturan (Otani & Takahashi, 2021). Prinsip dasar dari metode ini adalah mengenali wilayah dengan tingkat insiden yang berada di atas atau di bawah estimasi normal, tanpa terpaku pada asumsi bahwa bentuk geometris kluster harus selalu simetris seperti lingkaran.

Pada metode *Flexibly Shaped Spatial Scan Statistic*, pembentukan himpunan wilayah Z yang berbentuk tidak beraturan (*irregularly shape*) dilakukan dengan cara mengintegrasikan wilayah-wilayah yang saling bertetangga atau berdekatan. Himpunan Z ini memiliki ukuran panjang k pada setiap lokasi pengamatan. Komponen di dalamnya terdiri atas k wilayah (yang mencakup wilayah indeks i itu sendiri) dengan rentang panjang nilai yang bergerak dari 1 hingga K . Wilayah yang berbatasan dibatasi sebagai himpunan bagian dari wilayah i dan $(K - 1)$ wilayah sekitar yang terdekat dengan wilayah i untuk menghindari pendeteksian *cluster* yang bentuknya aneh (*unlikely peculiar shape*). Selanjutnya akan terbentuk Z yang berbeda-beda dan saling *overlapping* (tumpang tindih). Z tersebut dinotasikan dengan $Z_{ik(j)}$, $j = 1, \dots, j_{ik}$, dimana j_{ik} merupakan adalah jumlah j yang memenuhi $Z_{ik(j)} \subseteq Z_{ik}$ untuk $k = 1, 2, \dots, K$. Algoritma yang digunakan untuk mendapatkan Z dengan *pre-specified maximum length* L adalah sebagai berikut:

1. Membentuk himpunan wilayah Z dinyatakan pada Persamaan (20).

$$Z = \{Z_{ik(j)} \mid 1 \leq i \leq n, 1 \leq k \leq K, 1 \leq j \leq j_{ik}\} \quad (32)$$

dimana:

n : banyaknya data pengamatan

K : banyaknya wilayah maksimum dalam satu *cluster*

j : banyaknya data bangkitan simulasi Monte-Carlo

2. Membagi himpunan wilayah Z menjadi dua himpunan wilayah baru, yaitu Z_0 dan Z_1 . Z_0 merupakan himpunan wilayah acak dari Z . Sedangkan Z_1 merupakan himpunan wilayah acak dari Z selain Z_0 .

3. Membuat dua himpunan baru Z'_0 dan Z'_1 . Z'_0 terdiri dari wilayah Z_1 yang berbatasan dengan wilayah Z_0 . Di sisi lain, Z'_1 terdiri dari wilayah Z_1 yang tidak berbatasan dengan wilayah Z_0 . Kemudian, ganti Z_0 dan Z_1 dengan Z'_0 dan Z'_1 .
4. Mengulangi langkah 3 hingga Z_0 atau Z_1 menjadi himpunan kosong.
5. Buat kesimpulan dimana Z dikatakan berhubungan (*connected*) ketika Z_1 menjadi himpunan kosong dan tidak berhubungan ketika Z_0 menjadi himpunan kosong.
6. Mengulangi langkah 2-5 hingga terbentuk maksimum s wilayah. Nilai s ditentukan berdasarkan jumlah iterasi yang dilakukan pada langkah 2-5.

1.6.11.1 Likelihood Ratio Test dan Pengujian Hipotesis Monte Carlo

Untuk setiap wilayah i dan Panjang dari scanning hotspot, hipotesis alternatifnya Adalah minimal ada satu hotspot Z yang mempunyai peluang resiko lebih tinggi daripada di luar hotspot. Dengan kata lain, hipotesis yang digunakan Adalah sebagai berikut:

$$H_0: E(Y(Z)) = \mu(Z) \text{ untuk semua } Z$$

$$H_1: E(Y(Z)) > \mu(Z) \text{ untuk beberapa } Z$$

Keterangan:

$Y(.)$: jumlah kasus *random*

$\mu(.)$: nilai harapan dari kasus *hotspot* tertentu

Pada setiap hotspot, dapat dihitung likelihood untuk mengetahui jumlah kasis di dalam dan diluar hotspot. Persamaan likelihood untuk setiap hotspot dengan mengikuti distribusi Binomial Negatif, uji statistic yang disusun dengan likelihood ratio test (Kulldorff, 1977) dinyatakan pada persamaan (21) sebagai berikut:

$$\lambda = \sup_{Z \in Z} \left\{ \left(\frac{y(Z)}{\mu(Z)} \right)^{y(Z)} \left(\frac{y(Z^c)}{\mu(Z^c)} \right)^{y(Z^c)} I \left(\frac{y(Z)}{\mu(Z)} > \frac{y(Z^c)}{\mu(Z^c)} \right) \right\} \quad (33)$$

Dimana

Z^c : semua wilayah di luar hotspot Z

$I(.)$: fungsi indikator

Ketika memeriksa kantong dengan high rates, maka $I(.)$ Memiliki nilai 1 jika Z memiliki peluang lebih besar dari 0 jika lainnya. Prosedur untuk mendapatkan P – *value* dengan pendekatan Monte Carlo Adalah sebagai berikut:

1. Menghitung penjumlahan nilai *log likelihood ratio* tertinggi t_0 untuk data riil.
2. Membangun data acak yang ukurannya sama dengan data riil yang dibangun di bawah kondisi H_0 .
3. Melakukan proses pembentukan *scanning hotspot* Z dari data acak yang dibangun berdasarkan kondisi H_0 .
4. Mencari nilai *log likelihood ratio* dari setiap *scanning hotspot*, dan dicatat apakah jumlah kasus yang diamati lebih besar atau lebih kecil dari yang diestimasi, kemudian menjumlahkan nilai *log likelihood ratio* yang jumlah kasusnya lebih besar dari jumlah yang diestimasi, untuk setiap *scanning hotspot*. Selanjutnya, mendapatkan penjumlahan nilai *log likelihood ratio* yang tertinggi dari simulasi pertama pembangunan data acak tersebut.
5. Mengulang langkah 2, 3, dan 4 sebanyak m kali pengulangan / simulasi, sehingga memperoleh m penjumlahan nilai *log likelihood ratio* tertinggi dari data acak dan data riil.
6. Hitung *P-value*, dengan persamaan berikut:

$$p = \frac{\text{banyaknya } (T(x) \geq \lambda)}{m + 1} \quad (34)$$

Keterangan:

$T(x)$: penjumlahan nilai *log likelihood ratio* dari data acak yang dibangun di bawah kondisi H_0 .

λ : penjumlahan nilai *log likelihood ratio* tertinggi.

m : banyaknya simulasi untuk membangun data di bawah kondisi H_0 .

dengan tingkat signifikansi α , H_0 ditolak jika $P - value < \alpha$ yang artinya bahwa *window* Z merupakan wilayah *cluster* rawan yang signifikan.

1.6.11.2 Hotspot atau Kantong-kantong

Hotspot atau kantong-kantong didefinisikan sebagai lokasi atau wilayah terjadinya suatu kejadian yang tidak biasa atau kejadian luar biasa atau disebut juga wilayah kritis (Patil dan Taillie, 2003). Sedangkan menurut Haran (2006) didefinisikan sebagai lokasi atau wilayah yang konsisten memiliki karakteristik berbeda dengan daerah sekelilingnya. Dalam penelitian ini, wilayah yang terdeteksi sebagai hotspot disebut sebagai daerah Stunting, sehingga kantong dapat diartikan sebagai kumpulan daerah-daerah yang memiliki tingkat kasus Stunting lebih besar dari pada daerah-daerah di luar kantong. Wilayah hotspot atau kantong Stunting sangat penting diketahui karena dengan adanya informasi tersebut dapat diketahui wilayah yang memerlukan perhatian khusus dalam upaya menangani masalah yang berkaitan

dengan kasus Stunting dan jika hotspot atau kantong Stunting suatu wilayah sudah terdeteksi maka informasi tersebut dapat dibuat menjadi peta kerawanan wilayah terjadinya kasus Stunting.

1.6.12 Stunting

Menurut WHO (2021), stunting merupakan bentuk gangguan perkembangan dan pertumbuhan pada anak yang diakibatkan oleh kekurangan gizi kronis dan infeksi berulang, gangguan ini ditandai dengan panjang atau tinggi badan balita di bawah standar. Kekurangan gizi ini dapat terjadi sejak bayi masih berada dalam kandungan dan pada masa awal setelah kelahiran, tetapi akan baru nampak setelah anak menginjak usia 2 tahun, di mana kesehatan ibu dan anak sangat penting bagi pertumbuhan anak. Usia bayi antara 0 dan 24 adalah periode yang penting karena menentukan kualitas kehidupan, dan disebut sebagai periode emas. Akibatnya, dampak yang ditimbulkan pada bayi selama periode ini akan menjadi permanen dan tidak bisa diperbaiki. Pada usia ini, diperlukan nutrisi yang cukup, mengingat masalah gizi termasuk penurunan perkembangan otak, kecerdasan, pertumbuhan fisik, dan gangguan metabolisme tubuh yang merupakan efek jangka pendek dari stunting (Rahayu, dkk, 2018).

Sebagai negara yang memiliki populasi penduduk besar, Indonesia memiliki tantangan khusus dalam menangani masalah stunting. Hasil Studi Status Gizi Indonesia (SSGI) yang dirilis oleh Kementerian Kesehatan (Kemenkes) menunjukkan bahwa prevalensi balita yang stunting di Indonesia mencapai 24,4 persen pada tahun 2021. Hal ini mengartikan hampir seperempat dari semua balita di Indonesia mengalami stunting pada tahun tersebut (Kemenkes, 2022).

Permasalahan stunting di Indonesia ini perlu mendapatkan penanganan yang serius, salah satunya adalah dengan penanggulangan ataupun pencegahan kasus stunting dengan menganalisis dan memahami faktor-faktor yang memicu angka kenaikan resiko tersebut. Jika dilihat dari data persentase stunting Provinsi di Indonesia, adanya kecenderungan persentase yang tinggi di pulau Kalimantan, Sulawesi, dan Papua. Sedangkan pada pulau Sumatera dan Jawa, angka persentase balita stunting lebih rendah. Ini menunjukkan adanya ketimpangan provinsi di Indonesia dalam pemenuhan kebutuhan gizi balita, oleh karena itu diperlukan penelitian untuk melihat faktor-faktor yang memengaruhi tingginya persentase balita stunting dengan mempertimbangkan wilayah atau aspek spasial.

Maka metode yang tepat dalam memodelkannya adalah GWNBR dengan harapan dapat memberikan model yang tepat bagi setiap wilayah dan FSSS untuk melihat wilayah dengan Tingkat stunting tinggi.

Stunting, atau gangguan pertumbuhan akibat kekurangan gizi kronis, disebabkan oleh berbagai faktor, termasuk asupan gizi yang tidak memadai, infeksi berulang, sanitasi buruk, dan kurangnya akses ke layanan Kesehatan. Faktor-faktor penyebab stunting diantaranya (Riskedas 2024):

1. Malnutrisi pada Ibu Hamil dan Anak

Kekurangan gizi pada ibu hamil dapat menyebabkan pertumbuhan janin terhambat, dan kurangnya asupan gizi pada anak selama masa pertumbuhan juga dapat menyebabkan stunting.

2. Sanitasi yang buruk dan akses air bersih yang terbatas

Kondisi sanitasi yang buruk dan kurangnya akses ke air bersih dapat meningkatkan risiko infeksi dan penyakit yang dapat menyebabkan stunting.

3. Pendidikan ibu

Ibu dengan pendidikan rendah cenderung kurang memahami pentingnya gizi dan perawatan anak yang baik, sehingga anak-anak mereka berisiko mengalami stunting.


4. Sarana Kesehatan

Dengan jauhnya jarak dan juga kurangnya program pada sarana Kesehatan seperti puskesmas atau posyandu, membuat kurangnya pengetahuan Masyarakat akan gejala penyakit ini sehingga dapat menyebabkan stunting.

5. Riwayat penyakit

Infeksi seperti diare, batuk, dan demam dapat menghambat penyerapan nutrisi dan menyebabkan stunting.

1.6.13 Kerangka Konseptual



Gambar 1. Kerangka Konseptual

BAB II

METODOLOGI PENELITIAN

2.1 Sumber Data

Data yang digunakan dalam penelitian ini berupa data sekunder yang diperoleh dari Dinas Kesehatan Provinsi Sulawesi Selatan tahun 2024 yang dapat di akses pada <https://dinkes.sulselprov.go.id> dan Badan Pusat Statistik (BPS) tahun 2024 yang dapat di akses pada <https://www.bps.go.id/>. Satuan spasial yang digunakan dalam penelitian ini adalah Kabupaten/kota di Provinsi Sulawesi Selatan yang terdiri dari 24 lokasi amatan tak lain yakni Kabupaten/kota yang ada di Provinsi Sulawesi Selatan itu sendiri.

2.2 Identifikasi Variabel

Variabel yang digunakan dalam penelitian ini terdapat dua variabel yaitu variabel respon dan variabel prediktor. Berikut adalah variabel-variabel yang digunakan dalam penelitian.

Tabel 1. Variabel Penelitian

Variabel	Keterangan	Tipe Variabel	Satuan
Y	Jumlah kasus Stunting	Diskrit	Jiwa
X_1	ASI Eksklusif	Kontinu	Persen
X_2	MP-ASI	Kontinu	Persen
X_3	Imunisasi Dasar Lengkap	Kontinu	Persen
X_4	Melek Baca	Kontinu	Persen
X_5	Sanitasi dan akses air bersih	Kontinu	Persen
X_6	Sarana Kesehatan	Diskrit	Unit

Berikut merupakan definisi operasional variabel yang digunakan dalam penelitian (Pusat data dan Informasi Kemenkes RI, 2021).

1. Kasus Stunting Anak (Y)
Jumlah kasus stunting anak di setiap Kabupaten/kota di Provinsi Sulawesi Selatan tahun 2024.
2. Persentase pemberian ASI Eksklusif (X_1)

Variabel ini menggambarkan persentase bayi usia 0–6 bulan yang hanya diberi ASI tanpa tambahan makanan atau minuman lain. ASI eksklusif berperan penting dalam pertumbuhan dan perkembangan bayi, serta melindungi dari risiko gizi buruk dan stunting.

3. Persentase Bayi yang Mendapat MP-ASI (X_2)

Variabel ini menunjukkan cakupan pemberian makanan pendamping ASI pada bayi usia 6–23 bulan. MP-ASI yang tepat waktu, bergizi, dan sesuai kebutuhan akan membantu memenuhi kebutuhan energi dan zat gizi yang tidak lagi cukup hanya dari ASI.

4. Persentase Imunisasi Dasar Lengkap (X_3)

Variabel ini mencerminkan cakupan anak balita yang telah menerima imunisasi dasar lengkap (misalnya BCG, DPT, Polio, Campak). Imunisasi berfungsi melindungi anak dari penyakit infeksi yang dapat menghambat pertumbuhan dan meningkatkan risiko stunting.

5. Persentase Angka Melek Baca (X_4)

Variabel ini menggambarkan tingkat literasi masyarakat (angka melek huruf). Melek baca sering digunakan sebagai indikator pendidikan dan pengetahuan orang tua, yang berpengaruh pada pola asuh, pemahaman gizi, serta praktik kesehatan anak.

6. Persentase Sanitasi dan akses air bersih (X_5)

Variabel ini menunjukkan cakupan rumah tangga yang memiliki akses terhadap sanitasi dan air bersih. Sanitasi yang baik mencegah penyakit infeksi seperti diare, yang dapat mengganggu penyerapan gizi dan meningkatkan risiko stunting.

7. Jumlah Sarana Kesehatan (X_6)

Variabel ini mengukur jumlah fasilitas kesehatan (puskesmas, rumah sakit, klinik) yang tersedia di suatu wilayah. Ketersediaan sarana kesehatan memudahkan akses masyarakat terhadap layanan kesehatan, imunisasi, dan pemantauan tumbuh kembang anak.

2.3 Analisis Data

Langkah-langkah analisis untuk menyelesaikan setiap permasalahan penelitian adalah sebagai berikut.

- A. Langkah-langkah mendapatkan faktor-faktor yang berpengaruh terhadap jumlah kasus stunting di Provinsi Sulawesi Selatan adalah sebagai berikut.
1. Mengambil data terkait kasus Stunting sebagai variabel respon dan 6 variabel prediktor serta data spasial yang berupa titik koordinat masing-masing Kabupaten/kota di Provinsi Sulawesi selatan.
 2. Mendeskripsikan variabel respon dan variabel prediktor, meliputi rata-rata, varians, nilai minimum, nilai maksimum dan peta tematik.
 3. Pemeriksaan multikolinearitas antar variabel prediktor menggunakan *Variance Inflation Factor* (VIF) dan menganalisis korelasi antar variabel prediktor dengan matriks korelasi.
 4. Memodelkan GWNBR dengan langkah-langkah sebagai berikut:
 - a. Menentukan u_i dan v_i berdasarkan garis lintang selatan dan garis bujur timur untuk setiap Kabupaten di Provinsi Sulawesi Selatan.
 - b. Menentukan bandwidth optimum untuk setiap lokasi pengamatan dengan menggunakan *Cross Validation* (CV).
 - c. Menghitung jarak *Euclidean* antar lokasi pengamatan berdasarkan posisi geografis.
 - d. Menghitung matriks pembobot dengan menggunakan fungsi *Adaptive Bisquare Kernel*.
 - e. Mengestimasi parameter model GWNBR.
 5. Menghitung nilai AIC pada model GWNBR.
 6. Menginterpretasikan Hasil membentuk peta pengelompokkan.
- B. Langkah-langkah untuk mendeteksi kantong-kantong kasus Stunting pada tingkat kabupaten di Provinsi Sulawesi Selatan dengan pendekatan *Flexibly Shaped Spatial Scan Statistic* sebagai berikut:
1. Mengambil data jumlah kasus stunting per kabupaten sebagai kasus dan jumlah balita per kabupaten sebagai populasi. Selain itu mengambil data spasial yang berupa titik koordinat masing-masing Kabupaten.
 2. Membuat prediksi jumlah kasus Stunting per kabupaten ($\hat{y}_i$) berdasarkan model terpilih pada langkah (A6).
 3. Mengidentifikasi kandidat cluster/hotspot dengan algoritma yang ada di metode *Flexibly Shaped Spatial Scan Statistic*. Penentuan *pre-set maximum number*

mengacu pada *pre-set maximum number* yang digunakan pada metode *Flexibly Shaped Spatial Scan Statistic*.

4. Menghitung jumlah populasi dan jumlah kasus untuk setiap cluster.
5. Menghitung *log likelihood function* dari setiap cluster kemudian menguji signifikansi cluster dengan simulasi *Monte Carlo* untuk mendapatkan *p – value*.
6. Menghitung resiko relatif untuk setiap *cluster*.
7. Membuat peta kantong kasus Stunting berdasarkan cluster yang signifikan pada α sebesar 0,10.
8. Menginterpretasikan hasil dengan membuat deskripsi kantong kasus Stunting sehingga diperoleh prioritas lokasi pengendalian penyakit dan faktor-faktor yang signifikan mempengaruhi kasus di wilayah kantong kantong.

BAB III

HASIL DAN PEMBAHASAN

3.1 Estimasi Parameter Model Geographically Weighted Negative Binomial Regression (GWNBR)

Fungsi sebaran Binomial Negative untuk setiap Lokasi dapat dinyatakan secara matematis melalui persamaan sebagai berikut (Yasin et al., 2021):

$$f(y_i | x_i^T, \beta(u_i, v_i), \theta(u_i, v_i)) = \frac{\Gamma(y_i + \frac{1}{\theta_i})}{\Gamma(\frac{1}{\theta_i}) \Gamma(y_i + 1)} \left(\frac{1}{1 + \theta_i \mu_i} \right)^{\frac{1}{\theta_i}} \left(\frac{\theta_i \mu_i}{1 + \theta_i \mu_i} \right)^{y_i} \quad (35)$$

keterangan:

$$\mu_i = \exp(x_i^T, \beta(u_i, v_i))$$

$$\theta_i = \theta(u_i, v_i)$$

Dimana:

$$\hat{\mu}_i = \exp(\hat{\beta}_0(u_i, v_i) + \hat{\beta}_1(u_i, v_i)x_{i1} + \hat{\beta}_2(u_i, v_i)x_{i2} + \dots + \hat{\beta}_k(u_i, v_i)x_{ik})$$

Estimasi parameter model GWNBR dilakukan dengan menggunakan metode Maximum Likelihood Estimation (MLE). Sebagai berikut (Ricardo & Carvalho, 2014):

$$L(\beta(u_i, v_i), \theta_i | y_i, x_i) = \prod_{i=1}^n \left[\frac{\Gamma(y_i + \theta(u_i, v_i)^{-1})}{\Gamma(\theta(u_i, v_i)^{-1}) y_i!} \times \left(\frac{1}{1 + \theta(u_i, v_i) \exp(x_i^T \beta_{(u_i, v_i)})} \right)^{\frac{1}{\theta_i}} \times \left(\frac{\theta(u_i, v_i) \exp(x_i^T \beta_{(u_i, v_i)})}{1 + \theta(u_i, v_i) \exp(x_i^T \beta_{(u_i, v_i)})} \right)^{y_i} \right] \quad (36)$$

Kemudian fungsi likelihood pada persamaan (36) diubah dalam bentuk logaritma natural, sebagai berikut:

$$\begin{aligned} \ln\{L(\beta(u_i, v_i), \theta_i | y_i, x_i)\} &= \sum_{i=1}^n \left[\left(\sum_{r=1}^{y_i-1} \ln((r + \theta(u_i, v_i)^{-1}) - \ln(y_i!)) \right. \right. \\ &\quad \left. \left. + y_i \ln(\theta(u_i, v_i) \exp(x_i^T \beta_{(u_i, v_i)})) - \right. \right. \\ &\quad \left. \left. (y_i + (\theta(u_i, v_i)^{-1}) \ln(1 + \theta(u_i, v_i) \exp(x_i^T \beta_{u_i v_i}))) \right] \quad (37) \end{aligned}$$

Faktor letak geografis merupakan faktor pembobot pada model GWNBR. Faktor ini memiliki nilai yang berbeda untuk setiap wilayah yang diamati. Oleh karena itu, pembobot diberikan pada bentuk persamaan log likelihood, diperoleh bentuk persamaan sebagai berikut:

$$\begin{aligned} \ln\{L(\beta(u_i, v_i), \theta_i | y_i, x_i)\} &= \sum_{i=1}^n w_j(u_i, v_i) \left[\sum_{i=1}^n \left(\sum_{r=1}^{y_i-1} \ln((r + \theta(u_i, v_i))^{-1}) \right. \right. \\ &\quad \left. \left. - \ln(y_i!) + y_i \ln(\theta(u_i, v_i) \exp(x_i^T \beta_{(u_i, v_i)})) - \right. \right. \\ &\quad \left. \left. (y_i + (\theta(u_i, v_i))^{-1}) \ln(1 + \theta(u_i, v_i) \exp(x_i^T \beta_{(u_i, v_i)})) \right] \end{aligned} \quad (38)$$

Misal:

$$a = \sum_{r=0}^{y_i} \ln(r + \theta_i^{-1}) - \ln(y_i!)$$

$$b = y_i \ln(\theta_i \exp(x_i^T \beta_{(u_i, v_i)}))$$

$$c = (y_i + \theta_i^{-1}) \ln(1 + \theta_i \exp(x_i^T \beta_{(u_i, v_i)}))$$

maka diperoleh persamaan sebagai berikut:

$$\ln\{L(\beta(u_i, v_i), \theta_i | y_i, x_i)\} = \sum_{i=1}^n w_i(u_i, v_i) [a + b - c] \quad (39)$$

Turunan dari logaritma fungsi likelihood $\ln\{L(\beta(u_i, v_i), \theta_i | y_i, x_i)\}$ terhadap parameter dispersi (θ) adalah:

$$\begin{aligned} \frac{\partial \ln L(.)}{\partial \theta_i} &= \sum_{i=1}^n w_j(u_i, v_i) \left[\frac{\partial a}{\partial \theta_i} + \frac{\partial b}{\partial \theta_i} - \frac{\partial c}{\partial \theta_i} \right] \\ \frac{\partial \ln L(.)}{\partial \theta_i} &= \sum_{i=1}^n w_j(u_i, v_i) \left[\frac{\partial \sum_{r=0}^{y_i} \ln(r + \theta_i^{-1}) - \ln(y_i!)}{\partial \theta_i} + \frac{\partial y_i \ln(\theta_i \exp(x_i^T \beta_{(u_i, v_i)}))}{\partial \theta_i} - \frac{\partial (y_i + \theta_i^{-1}) \ln(1 + \theta_i \exp(x_i^T \beta_{(u_i, v_i)}))}{\partial \theta_i} \right] \end{aligned}$$

Sehingga,

$$\frac{\partial a}{\partial \theta_i} = -\theta_i^{-2} \sum_{r=0}^{y_i-1} \frac{1}{r + \theta_i^{-1}}$$

$$\frac{\partial b}{\partial \theta_i} = y_i \frac{\mu_i}{\theta_i \mu_i} = \frac{y_i}{\theta_i}$$

$$\frac{\partial c}{\partial \theta_i} = (-\theta_i^{-2} \ln(1 + \theta_i \mu_i) + y_i + \theta_i^{-1}) \frac{\mu_i}{1 + \theta_i \mu_i}$$

$$\begin{aligned}
&= \left(\frac{\ln(1 + \theta_i \mu_i)}{\theta_i^{-2}} + \frac{y_i + \theta_i^{-1} \mu_i}{1 + \theta_i \mu_i} \right) \\
&= -d + e
\end{aligned} \tag{40}$$

Dimana,

$$d = \frac{\ln(1 + \theta_i \exp(x_i^T \beta(u_i, v_i)))}{\theta_i^2} \text{ dan } e = \frac{(y_i + \theta_i^{-1}) \exp(x_i^T \beta(u_i, v_i))}{1 + \theta_i \exp(x_i^T \beta(u_i, v_i))} \tag{41}$$

Sehingga disederhanakan menjadi,

$$\frac{\partial \ln L(.)}{\partial \theta_i} = \sum_{i=1}^n w_j(u_i, v_i) \left[\frac{\partial a}{\partial \theta_i} + \frac{\partial b}{\partial \theta_i} + d - e \right] \tag{42}$$

Untuk mendapatkan estimasi parameter $\beta(u_i, v_i)$ maka persamaan $\ln L(.)$ terhadap $\beta^T(u_i, v_i)$ adalah:

$$\begin{aligned}
\frac{\partial \ln L(\beta(u_i, v_i), \theta_i | (y_i, x_i))}{\partial \beta^T(u_i, v_i)} &= \sum_{i=1}^n w_j(u_i, v_i) \left[\frac{\partial a}{\partial \beta^T(u_i, v_i)} + \frac{\partial b}{\partial \beta^T(u_i, v_i)} - \frac{\partial c}{\partial \beta^T(u_i, v_i)} \right] \\
&= \sum_{i=1}^n w_j(u_i, v_i) \left[\frac{\partial \sum_{r=0}^{y_i} \ln(r + \theta_i^{-1}) - \ln(y_i!)}{\partial \beta^T(u_i, v_i)} + \frac{\partial y_i \ln(\theta_i \exp(x_i^T \beta(u_i, v_i)))}{\partial \beta^T(u_i, v_i)} - \right. \\
&\quad \left. \frac{\partial (y_i + \theta_i^{-1}) \ln(1 + \theta_i \exp(x_i^T \beta(u_i, v_i)))}{\partial \beta^T(u_i, v_i)} \right] \\
\frac{\partial a}{\partial \beta^T(u_i, v_i)} &= 0 \\
\frac{\partial b}{\partial \beta^T(u_i, v_i)} &= \frac{y_i}{(\mu_i) x_i} (\theta_i \mu_i) x_i \\
\frac{\partial c}{\partial \beta^T(u_i, v_i)} &= (y_i + \theta_i^{-1}) \frac{(\theta_i \mu_i) x_i}{(1 + \theta_i \mu_i) x_i}
\end{aligned} \tag{43}$$

Persamaan (43) disubstitusikan disederhanakan sebagai berikut,

$$\frac{\partial \ln L(\beta(u_i, v_i), \theta_i | (y_i, x_i))}{\partial \beta^T(u_i, v_i)} = \sum_{i=1}^n w_j(u_i, v_i) \left[\frac{(y_i - \mu_i) x_i}{(1 + \theta_i \mu_i)} \right] \tag{44}$$

Lalu kemudian membentuk Vektor gradient $\mathbf{g}$:

$$\mathbf{g}^T(\beta_{(m)}(u_i, v_i))_{(k+1)} = \left[\frac{\partial \ln L(\beta(u_i, v_i))}{\partial \theta}, \frac{\partial \ln L(\beta(u_i, v_i))}{\partial \beta_0(u_i, v_i)}, \dots, \frac{\partial \ln L(\beta(u_i, v_i))}{\partial \beta(u_i, v_i)} \right]$$

Pembentukan matriks Hessian H

$$H(\beta_{(m)}(u_i, v_i))_{(k+1) \times (k+1)} = \begin{bmatrix} \frac{\partial^2 \ln L(\beta_j(u_i, v_i))}{\partial \theta^2} & \frac{\partial^2 \ln L(\beta_j(u_i, v_i))}{\partial \theta \partial \beta_0(u_i, v_i)} & \cdots & \frac{\partial^2 \ln L(\beta_j(u_i, v_i))}{\partial \theta \partial \beta_k(u_i, v_i)} \\ \frac{\partial^2 \ln L(\beta_j(u_i, v_i))}{\partial \beta_0(u_i, v_i)^2} & \frac{\partial^2 \ln L(\beta_j(u_i, v_i))}{\partial \beta_0(u_i, v_i) \partial \beta_k(u_i, v_i)} & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 \ln L(\beta_j(u_i, v_i))}{\partial \beta_k(u_i, v_i)^2} & \vdots & \vdots & \vdots \end{bmatrix}$$

Melakukan iterasi yang dimulai pada $m = 0$ dengan persamaan yang ditunjukkan:

$$\hat{\beta}_{(m+1)} = \hat{\beta}_{(m)} - H^{-1}(\hat{\beta}_{(m)})g(\hat{\beta}_{(m)}) \quad (45)$$

Proses iterasi dihentikan Ketika nilai estimasi yang diperoleh sudah konvergen ke suatu nilai atau $\hat{\beta}_{(m+1)} \approx \hat{\beta}_{(m)}$.

Jika belum mencapai penaksir parameter yang konvergen, maka mengulang persamaan hingga konvergen. Penaksir parameter yang konvergen diperoleh jika $\|\hat{\beta}_{(m+1)} - \hat{\beta}_{(m)}\| \leq \varepsilon$.

3.2 Karakteristik Data dan Peta Persebaran Jumlah Kasus Stunting dan Faktor-faktor yang diduga Mempengaruhi

Karakteristik data dan peta persebaran variabel penelitian ini memuat hasil analisis statistika deskriptif dari jumlah kasus stunting di Provinsi Sulawesi Selatan pada tahun 2024 serta variabel-variabel yang mempengaruhinya. Selain itu, peta sebaran disajikan dalam bentuk peta tematik.

3.2.1 karakteristik jumlah kasus stunting dan faktor-faktor yang diduga mempengaruhi

Hasil laporan TPPS Provinsi Sulawesi Selatan dari total 24 kabupaten/kota ada 12 kabupaten yang mengalami kenaikan stunting dengan kenaikan angka rata-rata 1,1% - 10,3%. Sebagai gambaran awal mengenai jumlah kasus stunting pada setiap kabupaten/kota di provinsi Sulawesi Selatan pada tahun 2024, akan disajikan sebagai berikut:

Tabel 2. Statistik Deskriptif

Variabel	Satuan	Mean	Standar Deviasi	Maksimum	Minimum
Y	Kasus	3622,458	2100,675	9472	908
X_1	%	58,446	7,337	70,1	38,5
X_2	%	59,433	5,483	66,8	45,6

X_3	%	51,604	9,026	68,9	35,8
X_4	%	3,547	2,223	9,07	0,59
X_5	%	92,267	5,705	99,09	78,07
X_6	Unit	123,125	63,107	314	45

Tabel 2 menunjukkan gambaran umum data penelitian mengenai kasus stunting dan variabel-variabel penjelas di 24 kabupaten/kota di Sulawesi Selatan. Variabel Y (jumlah kasus stunting) memiliki rata-rata sebesar 3.622 kasus per kabupaten/kota, dengan variasi yang cukup besar (minimum 908 kasus dan maksimum 9.472 kasus). Hal ini mengindikasikan adanya ketimpangan jumlah kasus stunting antar wilayah. Variabel X_1 (ASI Eksklusif) memiliki rata-rata 58,45% dengan rentang antara 38,50% hingga 70,10%. Variabel X_2 (MP-ASI) rata-rata 59,43% dengan kisaran 45,60%–66,80%. Variabel X_3 (Imunisasi Dasar Lengkap) rata-rata 51,60% dengan kisaran 35,80%–68,90%. Ketiga variabel ini relatif homogen antar kabupaten, meskipun tetap terdapat variasi antar wilayah.

Variabel X_4 (Melek Baca) memiliki rata-rata 3,547% dengan variasi yang cukup besar (minimum 0,590% dan maksimum 9,070%). Hal ini menunjukkan adanya kabupaten dengan Melek Baca yang sangat rendah dibandingkan kabupaten lain. Variabel X_5 (sanitasi Air Bersih) relatif tinggi dan homogen, dengan rata-rata 92,67% dan kisaran 78,07%–99,09%. Variabel X_6 (Sarana Kesehatan) menunjukkan variasi yang paling besar, dengan rata-rata 123 Sarana kesehatan per kabupaten/kota, minimum 45, dan maksimum 314. Besarnya standar deviasi pada variabel ini menandakan adanya ketimpangan distribusi Sarana kesehatan antar kabupaten/kota. Secara keseluruhan, tabel deskriptif ini memperlihatkan bahwa beberapa variabel (X_1, X_3, X_5) relatif homogen antar kabupaten/kota, sementara variabel lain (Y, X_4, X_6) menunjukkan variasi yang cukup besar. Temuan ini penting karena ketimpangan antar wilayah dapat memengaruhi hasil analisis spasial dan menegaskan perlunya pendekatan berbasis lokasi dalam penanganan stunting.


3.2.2 Peta Persebaran Jumlah kasus Stunting dan Faktor yang mempengaruhinya

Persebaran data untuk setiap Variabel penelitian disajikan dalam bentuk peta tematik, dengan tujuan memudahkan pemahaman mengenai pola persebaran data dari masing-masing variabel. Berikut hasil pemetaan persebaran variabel-variabel yang dianalisis dalam penelitian ini.

3.2.2.1 Jumlah Kasus Stunting

Stunting adalah kondisi gagal tumbuh pada anak balita akibat kekurangan gizi kronis dan infeksi berulang, terutama pada masa 1.000 hari pertama kehidupan (sejak janin hingga usia dua tahun). Anak yang mengalami stunting memiliki tinggi badan lebih rendah dari standar usianya karena pertumbuhan tubuh dan otaknya terhambat. Kondisi ini tidak hanya berdampak pada aspek fisik, tetapi juga pada perkembangan kognitif, produktivitas, dan kesehatan jangka panjang. Stunting menjadi salah satu indikator penting dalam menilai status gizi dan kesejahteraan masyarakat, serta mencerminkan kualitas sumber daya manusia di suatu wilayah. Di Indonesia, termasuk di Provinsi Sulawesi Selatan, stunting masih menjadi masalah kesehatan masyarakat yang serius. Oleh karena itu, analisis spasial terhadap sebaran jumlah

kasus stunting diperlukan untuk mengidentifikasi wilayah dengan prevalensi tinggi dan merumuskan kebijakan intervensi yang lebih tepat sasaran.



Gambar 2. Peta Sebaran Jumlah Kasus Stunting


Gambar 2 memperlihatkan sebaran jumlah kasus stunting di 24 kabupaten/kota di Provinsi Sulawesi Selatan. Warna pada peta menunjukkan intensitas jumlah kasus, dengan gradasi dari ungu tua (jumlah kasus rendah) hingga kuning terang (jumlah kasus tinggi). Secara umum, terlihat bahwa kabupaten/kota di bagian selatan seperti Gowa, Takalar, Jeneponto, Bulukumba, dan Kota Makassar memiliki jumlah kasus stunting yang relatif tinggi, ditunjukkan oleh warna oranye hingga kuning. Sementara itu, wilayah tengah dan utara seperti Luwu Utara, Luwu Timur, Toraja Utara, dan Tana Toraja didominasi warna ungu, menandakan jumlah kasus yang lebih rendah.

Distribusi ini menunjukkan adanya pola spasial di mana daerah pesisir selatan cenderung memiliki prevalensi stunting lebih tinggi dibandingkan daerah pegunungan di bagian utara. Faktor-faktor seperti kepadatan penduduk, akses terhadap layanan kesehatan, dan kondisi sosial ekonomi kemungkinan berperan dalam perbedaan ini. Secara visual, peta ini memberikan gambaran yang jelas mengenai ketimpangan jumlah kasus stunting antar wilayah, yang dapat menjadi dasar untuk penentuan prioritas intervensi dan perencanaan kebijakan kesehatan berbasis wilayah di Sulawesi Selatan.

3.2.2.2 Cakupan Pemberian ASI Eksklusif menurut Kabupaten/Kota di Sulawesi Selatan

Pemberian ASI eksklusif adalah pemenuhan gizi bayi yang hanya bersumber dari air susu ibu tanpa adanya tambahan makanan atau minuman lain. Cakupan pemberian ASI eksklusif merupakan persentase dari jumlah bayi yang mendapatkan ASI eksklusif terhadap jumlah seluruh populasi bayi yang didata pada tiap

Kabupaten/Kota di Sulawesi Selatan. Angka cakupan ini dihitung untuk mengevaluasi tingkat keberhasilan program pemenuhan gizi masyarakat serta melihat pemerataan capaian target indikator kesehatan keluarga di setiap wilayah. Berikut peta persebaran cakupan pemberian ASI eksklusif menurut Kabupaten/Kota di Sulawesi Selatan.



Gambar 3. persebaran cakupan pemberian ASI eksklusif menurut Kabupaten/Kota di Sulawesi Selatan


Berdasarkan visualisasi peta di atas, persebaran cakupan pemberian ASI Eksklusif (X_1) di Provinsi SulSel dikelompokkan menggunakan gradasi warna dengan rentang persentase berkisar dari 40% hingga 70%. Kabupaten Luwu Utara serta Kabupaten Pangkajene dan Kepulauan menjadi daerah dengan capaian tertinggi mendekati angka 70% yang ditandai dengan warna kuning cerah, disusul oleh klaster wilayah bagian selatan dan tengah seperti Enrekang, Luwu, Gowa, Takalar, dan Jeneponto yang berada pada kategori sedang menuju tinggi dengan visualisasi warna jingga.

Sebaliknya, penurunan capaian yang cukup signifikan terlihat pada wilayah dengan indikasi warna ungu gelap seperti Toraja Utara, Tana Toraja, Sidenreng Rappang, Barru, dan Bone yang berada di kisaran 45% hingga 50%. Sementara itu, wilayah dengan cakupan terendah berada di Kabupaten Kepulauan Selayar yang ditunjukkan oleh warna biru tua pekat dengan nilai berada di sekitar 40% atau bahkan di bawahnya.

3.2.2.3 Cakupan Pemberian Makanan Pendamping ASI (MP-ASI) menurut Kabupaten/Kota di Sulawesi Selatan

Pemberian Makanan Pendamping ASI (MP-ASI) adalah proses pemberian makanan dan minuman khusus yang memenuhi kecukupan gizi bayi di samping pemberian air susu ibu, guna mendukung transisi pemenuhan kebutuhan tumbuh kembangnya. Cakupan pemberian MP-ASI merupakan persentase dari jumlah bayi yang mendapatkan MP-ASI sesuai standar kesehatan terhadap jumlah seluruh populasi

bayi yang didata pada tiap Kabupaten/Kota di Sulawesi Selatan. Ini dihitung untuk mengevaluasi efektivitas program intervensi gizi anak serta memetakan tingkat keberhasilan pola asuh nutrisi keluarga di setiap wilayah. Berikut peta persebaran cakupan pemberian MP-ASI menurut Kabupaten/Kota di SulSel.




Gambar 4. Cakupan pemberian MP-ASI menurut Kabupaten/Kota di Sulawesi Selatan

Berdasarkan visualisasi peta di atas, persebaran cakupan pemberian MP-ASI (X_2) di Provinsi Sulawesi Selatan dikelompokkan menggunakan gradasi warna dengan rentang persentase berkisar dari di bawah 50% hingga 65%. Kabupaten Luwu Utara, Tana Toraja, Pinrang, Pangkajene dan Kepulauan, serta Bantaeng menjadi daerah dengan capaian tertinggi mendekati angka 65% yang ditandai dengan warna kuning cerah, disusul oleh klaster wilayah sekitarnya seperti Enrekang, Sidenreng Rappang, Parepare, Barru, Maros, Makassar, Gowa, dan Sinjai yang berada pada kategori sedang dengan visualisasi warna jingga. Sebaliknya, wilayah dengan indikasi warna ungu kemerahan hingga ungu gelap seperti Toraja Utara, Luwu, Palopo, Wajo, Soppeng, Bone, Takalar, Jeneponto, dan Kepulauan Selayar menunjukkan capaian yang cenderung rendah di kisaran 50%- 55%. Sementara itu, penurunan capaian paling signifikan terlihat di Kabupaten Luwu Timur dan Kabupaten Bulukumba yang ditunjukkan oleh warna biru tua pekat, menandakan kedua daerah tersebut memiliki nilai cakupan terendah yang berada di sekitar 50% atau di bawahnya.

3.2.2.4 Cakupan Imunisasi Dasar Lengkap menurut Kabupaten/Kota di Sulawesi Selatan

Imunisasi dasar lengkap adalah pemberian rangkaian vaksinasi awal secara menyeluruh kepada bayi untuk memberikan perlindungan optimal terhadap berbagai penyakit yang dapat dicegah dengan imunisasi (PD3I). Cakupan imunisasi dasar lengkap merupakan persentase dari jumlah bayi yang telah mendapatkan seluruh

jenis vaksinasi dasar yang diwajibkan terhadap jumlah seluruh populasi bayi yang didata pada tiap Kabupaten/Kota di SulSel. Angka cakupan ini untuk mengevaluasi tingkat ketahanan dan kekebalan kelompok (*herd immunity*) masyarakat terhadap ancaman wabah penyakit serta mengukur efektivitas jangkauan pelayanan posyandu dan fasilitas kesehatan di setiap wilayah. Berikut peta persebaran cakupan imunisasi dasar lengkap menurut Kabupaten/Kota di Sulawesi Selatan.




Gambar 5. Cakupan Imunisasi Dasar Lengkap menurut Kabupaten/Kota di Sulawesi Selatan

Berdasarkan visualisasi peta di atas, persebaran cakupan Imunisasi Dasar Lengkap (X_3) di Provinsi Sulawesi Selatan dikelompokkan menggunakan gradasi warna dengan rentang persentase berkisar dari 40% hingga di atas 60%. Kota Makassar dan Kota Palopo menjadi daerah dengan capaian tertinggi mendekati atau berada di atas angka 60% yang ditandai dengan warna kuning cerah, disusul oleh klaster wilayah sekitarnya seperti Barru, Kota Parepare, Gowa, dan Bantaeng yang berada pada kategori sedang menuju tinggi dengan visualisasi warna jingga. Sebaliknya, wilayah dengan indikasi warna ungu kemerahan hingga ungu gelap seperti Luwu Utara, Luwu, Toraja Utara, Tana Toraja, Enrekang, Pinrang, Sidenreng Rappang, Wajo, Soppeng, Bone, Bulukumba, Takalar, Jeneponto, dan Selayar menunjukkan capaian yang cenderung rendah di kisaran 45%-50%. Sementara itu, penurunan capaian paling signifikan terlihat di Pangkajene dan Kepulauan, Maros, Sinjai, serta Luwu Timur yang ditunjukkan oleh warna biru tua, menandakan wilayah tersebut memiliki nilai cakupan terendah yang berada di kisaran 40% atau di bawahnya.

3.2.2.5 Angka Melek Baca menurut Kabupaten/Kota di Sulawesi Selatan

Angka melek baca adalah indikator yang menunjukkan kemampuan seseorang untuk membaca dan menulis kalimat sederhana dalam kehidupan sehari-hari. Angka melek baca merupakan persentase dari jumlah penduduk yang memiliki kemampuan membaca dan menulis terhadap jumlah seluruh populasi penduduk yang disurvei pada tiap Kabupaten/Kota di SulSel. Angka indikator ini dihitung untuk mengevaluasi kemampuan literasi dasar masyarakat dalam menyerap informasi kesehatan dan gizi, serta melihat kesiapan kualitas sumber daya manusia dalam mendukung program penurunan kasus *stunting* di setiap wilayah. Berikut peta persebaran angka melek Baca menurut Kabupaten/Kota di Sulawesi Selatan.




Gambar 6. Angka Melek Baca menurut Kabupaten/Kota di Sulawesi Selatan

Berdasarkan peta di atas, persebaran Angka Melek Aksara (X_4) di Provinsi Sulawesi Selatan dikelompokkan menggunakan gradasi warna dengan rentang skala indeks berkisar dari di bawah 2,5 hingga diatas 7,5. Kabupaten Jeneponto dan Bantaeng menjadi daerah dengan capaian tertinggi mendekati atau berada pada angka 7,5 yang ditandai dengan warna kuning cerah, disusul oleh klaster wilayah sekitarnya seperti Takalar, Gowa, Kota Makassar, Maros, Bone, Soppeng, dan Wajo yang berada pada kategori sedang menuju tinggi dengan visualisasi warna jingga ke merah. Sebaliknya, wilayah dengan indikasi warna ungu kemerahan hingga ungu tua seperti Bulukumba, Sinjai, Barru, Kota Parepare, Sidenreng Rappang, Pinrang, Enrekang, Luwu, Kota Palopo, Tana Toraja, dan Toraja Utara menunjukkan capaian indeks yang cenderung rendah di kisaran 2,5-5,0. Sementara itu, nilai capaian paling rendah terlihat di Pangkajene dan Kepulauan, Luwu Utara, serta Luwu Timur yang didominasi oleh warna biru tua pekat, menandakan wilayah-wilayah tersebut memiliki indeks capaian terendah yang berada di sekitar nilai $\leq 2,5$.

3.2.2.6 Cakupan Sanitasi Air Bersih menurut Kabupaten/Kota di Sulawesi Selatan

Sanitasi air bersih mencakup ketersediaan sarana air sehat demi memenuhi kebutuhan domestik dan mencegah penyakit berbasis lingkungan. Di Sulawesi Selatan, indikator ini diukur dari persentase rumah tangga dengan akses sanitasi layak di setiap Kabupaten/Kota. Angka cakupan ini penting untuk mengevaluasi kualitas pemukiman, mengukur pemerataan infrastruktur, serta menganalisis dampaknya terhadap penurunan risiko stunting. Peta persebarannya disajikan sebagai berikut:




Gambar 7. Cakupan Sanitasi Air Bersih menurut Kabupaten/Kota di Sulawesi Selatan

Berdasarkan peta di atas, persebaran cakupan Sanitasi Air Bersih di Provinsi Sulawesi Selatan dikelompokkan menggunakan gradasi warna dengan rentang persentase yang relatif tinggi, berkisar dari 80% hingga di atas 95%. Kota Parepare, Kabupaten Barru, Wajo, Soppeng, Bone, Sinjai, dan Maros menjadi daerah dengan capaian tertinggi mendekati atau berada di atas angka 95% yang ditandai dengan warna kuning cerah, disusul oleh klaster wilayah sekitarnya seperti Luwu Utara, Luwu, Palopo, Enrekang, Sidenreng Rappang, Pinrang, Pangkajene dan Kepulauan, Makassar, Gowa, Takalar, dan Luwu Timur yang berada pada kategori sedang menuju tinggi dengan visualisasi warna jingga. Sebaliknya, wilayah dengan indikasi warna ungu kemerahan hingga ungu gelap seperti Toraja Utara, Tana Toraja, Bulukumba, Jeneponto, dan Kepulauan Selayar menunjukkan capaian yang cenderung lebih rendah di kisaran 85%-90%. Sementara itu, penurunan capaian paling signifikan terlihat di Kabupaten Bantaeng yang ditunjukkan oleh warna biru tua pekat, menandakan daerah tersebut memiliki nilai cakupan terendah yang berada di kisaran 80% atau di bawahnya.

3.2.2.7 Jumlah Sarana Kesehatan menurut Kabupaten/Kota di Sulawesi Selatan

Jumlah sarana kesehatan adalah total fasilitas fisik yang beroperasi untuk menyelenggarakan pelayanan promotif, preventif, kuratif, dan rehabilitatif. Dalam penelitian ini, sarana kesehatan mencakup rumah sakit, puskesmas, puskesmas pembantu, dan klinik. Indikator ini dihitung untuk mengevaluasi kapasitas medis, menilai pemerataan infrastruktur, serta memetakan kecukupan fasilitas penunjang intervensi stunting di Sulawesi Selatan. Berikut peta persebaran jumlah sarana kesehatan menurut Kabupaten/Kota di Sulawesi Selatan.



Gambar 8. Jumlah Sarana Kesehatan menurut Kabupaten/Kota di Sulawesi Selatan

Berdasarkan visualisasi peta di atas, persebaran jumlah sarana kesehatan (X_6) di Provinsi Sulawesi Selatan dikelompokkan menggunakan gradasi warna dengan rentang nilai mutlak berkisar dari di bawah 100 unit hingga mencapai lebih dari 300 unit. Kota Makassar menjadi daerah tunggal dengan jumlah sarana kesehatan tertinggi yang berada di atas angka 300 unit yang ditandai dengan visualisasi warna kuning cerah, disusul oleh Kabupaten Gowa yang berada pada kategori tinggi dengan visualisasi warna jingga di kisaran angka 250 unit. Klaster wilayah dengan kapasitas menengah yang ditunjukkan oleh warna merah muda hingga ungu kemerahan diduduki oleh daerah seperti Luwu Timur, Luwu, Bone, Soppeng, dan Pinrang dengan kisaran nilai mendekati 150 hingga 200 unit. Sebaliknya, penurunan jumlah sarana yang cukup merata dengan indikasi warna ungu tua mendominasi sebagian besar wilayah Sulawesi Selatan, seperti Luwu Utara, Toraja Utara, Tana Toraja, Kota Palopo, Enrekang, Sidenreng Rappang, Wajo, Maros, Pangkajene Dan Kepulauan, Barru, Kota Parepare, Takalar, Jeneponto, Bulukumba, Sinjai, dan Kepulauan Selayar yang berada di kisaran 100 unit. Sementara itu, nilai sarana kesehatan paling minimum atau terendah terlihat di Kabupaten Bantaeng yang

ditunjukkan oleh warna biru tua pekat, menandakan wilayah tersebut memiliki jumlah fasilitas pelayanan yang paling sedikit atau berada di bawah kisaran 100 unit.

3.3 Pemodelan Jumlah Kasus Stunting menurut Kabupaten/Kota di Sulawesi Selatan

Jumlah kasus stunting adalah variabel respon berupa data *count* sehingga pembentukan modelnya menggunakan Regresi Poisson. Namun, pada umumnya data *count* mempunyai varians yang lebih besar dari rata-rata, atau biasa disebut dengan kondisi overdispersi. Salah satu pendekatan untuk mengatasi overdispersi adalah dengan menggunakan Regresi Binomial Negatif. Dengan memperhatikan aspek spasial wilayah, maka metode yang digunakan adalah *Geographically Weighted Negative Binomial Regression* (GWNBR).

3.3.1 Pendeteksian Multikolinieritas

Sebelum melakukan analisis menggunakan metode *Regresi Binomial Negatif*, dan *Geographically Weighted Negative Binomial Regression* (GWNBR) maka dilakukan pengujian multikolinieritas terhadap data yang digunakan untuk mengetahui apakah diantara variabel prediktor tidak memiliki korelasi yang tinggi, karena jika terjadi multikolinearitas bisa mengakibatkan taksiran parameter regresi yang didapatkan akan mempunyai standard error yang besar sehingga akan mempengaruhi kesimpulan yang didapatkan. Ada beberapa cara untuk mendeteksi adanya kasus multikolinieritas, yaitu dengan melihat koefisien korelasi Pearson (r_{ij}) dan nilai VIF (Variance Inflation Factor). Berikut ini merupakan koefisien korelasi antara variabel prediktor yang diperoleh dari hasil pengolahan dengan bantuan syntax pada software R pada Lampiran 2.

Tabel 3. Nilai VIF dari Variabel Prediktor

Variabel	VIF
X1	1,160
X2	1,199
X3	1,248
X4	1,609
X5	1,889
X6	1,146

Berdasarkan Tabel 3 menunjukkan hasil perhitungan VIF menunjukkan bahwa seluruh variabel independen memiliki nilai VIF di bawah 2. Hal ini menandakan tidak terdapat masalah multikolinearitas dalam model, sehingga seluruh variabel dapat digunakan secara bersamaan tanpa menimbulkan bias estimasi.

3.3.2 Pemeriksaan dan penanganan kasus overdispersi

Overdispersi dalam regresi count data merupakan kondisi ketika varians data jauh lebih besar dibandingkan dengan nilai rata-ratanya. Pada model Poisson, asumsi dasar yang digunakan adalah bahwa rata-rata sama dengan varians, sehingga ketika data menunjukkan varians yang lebih besar, model Poisson tidak lagi sesuai. Pemeriksaan terhadap *overdispersi* biasanya dilakukan dengan melihat rasio deviance terhadap derajat bebas atau rasio Pearson Chi-Square terhadap derajat bebas. Jika nilai rasio tersebut jauh lebih besar dari satu, maka dapat dipastikan

terjadi overdispersi. Dalam kasus stunting, misalnya model Poisson menghasilkan deviance yang sangat tinggi dibandingkan dengan derajat bebas, sehingga jelas menunjukkan adanya overdispersi. Setelah memeriksa multikolineritas di antara variabel prediktor hasil pemeriksaan menunjukkan nilai Deviance sebesar 7950,5 dengan derajat bebas 17. Hasil bagi deviance dari model regresi poisson dengan derajat bebas tersebut adalah 467,676. Nilai ini lebih besar dari 1, yang artinya menandakan adanya overdispersi, dimana varians lebih besar dari rata-rata.

Untuk menangani masalah ini, pendekatan yang paling umum adalah menggunakan *Negative Binomial regresi* (NBR). Model ini menambahkan parameter dispersi sehingga mampu mengakomodasi varians yang lebih besar daripada rata-rata. Dengan demikian, estimasi menjadi lebih stabil dan hasil model lebih sesuai dengan data. Selain NBR, terdapat juga pendekatan *Quasi-Poisson* yang memperbolehkan varians proporsional terhadap *mean*, meskipun kelemahannya adalah tidak berbasis likelihood sehingga tidak dapat digunakan untuk perbandingan model dengan AIC. Model lain seperti *Generalized Poisson* atau *COM-Poisson* juga dapat digunakan untuk kasus dispersi yang lebih kompleks. Namun, jika overdispersi muncul akibat heterogenitas spasial antar wilayah, maka model spasial seperti *Geographically Weighted Negative Binomial Regression* (GWNBR) lebih tepat digunakan karena memungkinkan parameter berbeda di setiap lokasi, sehingga variasi spasial dapat ditangkap dengan lebih baik.

3.3.3 Pemodelan Regresi Binomial Negatif

Hasil pemodelan regresi binomial negative ditunjukkan sebagai berikut:

Tabel 4. Estimasi Parameter Regresi Binomial Negatif

Variabel	Estimasi	Z-hitung	P-Value
Intersep	13,485	8,648	2×10^{-16} ***
X1	-0,007	-0,774	0,439
X2	0,001	0,087	0,931
X3	-0,012	-1,511	0,131
X4	-0,024	-0,641	0,522
X5	-0,056	-3,568	$3,59 \times 10^{-4}$ ***
X6	0,007	6,029	$1,65 \times 10^{-9}$ ***

Keterangan: **Bold Fount** menunjukkan variabel yang berpengaruh signifikan pada $\alpha = 0,05$

Berdasarkan Tabel 4 didapatkan hasil pemodelan jumlah kasus stunting di Kabupaten/Kota di Sulawesi Selatan menggunakan Regresi Binomial Negatif sebagai berikut.

$$\hat{\mu}_i = \exp(13,485 - 0,056X_5 + 0,007X_6)$$

3.3.3.1 Pengujian Signifikasi Parameter Secara Serentak

Penguji signifikansi parameter secara serentak dalam model Regresi Binomial Negatif dilakukan untuk mengevaluasi apakah seluruh variabel prediktor secara bersama-sama memberikan pengaruh yang nyata terhadap variabel respons. Hipotesis yang digunakan pada uji serentak Adalah sebagai berikut:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_6 = 0 \text{ (semua variabel predictor tidak berpengaruh terhadap)}$$

jumlah kasus stunting)
 $H_1: \beta_j \neq 0; j = 1, 2, \dots, 6$ (minimal terdapat satu variabel prediktor yang berpengaruh terhadap jumlah kasus stunting)

Dengan Tingkat signifikansi (α) sebesar 0,005 ditetapkan daerah penolakan yaitu H_0 ditolak jika nilai $Deviance > X^2_{0,005;6}$. Berdasarkan hasil perhitungan yang didapatkan nilai $Deviance$ sebesar 51,326 yang nilainya lebih besar dari $X^2_{0,005;6}$ sebesar 12,592 sehingga diperoleh Keputusan tolak H_0 yang artinya minimal ada salah satu variabel predictor yang berpengaruh terhadap variabel respon.

3.3.3.2 Pengujian Signifikansi Parameter Parsial

Pengujian signifikan parameter Binomial Negatif secara parsial dilakukan untuk mengetahui variabel mana saja yang berpengaruh terhadap variabel respon dengan hipotesis sebagai berikut:

$H_0: \beta_j = 0$ (variabel ke- j tidak berpengaruh terhadap jumlah kasus Stunting)

$H_1: \beta_j \neq 0$ (Variabel ke- j berpengaruh terhadap jumlah kasus Stunting)

Dimana:

$j = 1, 2, \dots, 6$

Berdasarkan hasil pengujian signifikansi parameter secara parsial pada Tabel 4 dengan tingkat signifikansi (α) sebesar 0,05, ditetapkan daerah penolakan hipotesis yaitu H_0 ditolak jika nilai $|Z_{hitung}| > Z_{(0,025)}$ (sebesar 1,96) atau jika nilai $p\text{-value} < 0,05$. Hasil pengujian menunjukkan bahwa variabel X_5 dan X_6 memiliki pengaruh yang signifikan terhadap variabel respons. Hal ini dibuktikan oleh nilai mutlak $|Z_{hitung}|$ untuk X_5 sebesar 3,568 dan X_6 sebesar 6,029, di mana kedua nilai tersebut lebih besar dari Z_{tabel} (1,96), serta diperkuat oleh nilai $p\text{-value}$ masing-masing sebesar $3,59 \times 10^{-4}$ dan $1,65 \times 10^{-9}$ yang jauh lebih kecil dari taraf 0,05 (Tolak H_0). Sebaliknya, untuk variabel X_1, X_2, X_3 , dan X_4 , masing-masing memiliki nilai $|Z_{hitung}|$ yang lebih kecil dari 1,96 (berturut-turut sebesar 0,774; 0,087; 1,511; dan 0,641) serta nilai $p\text{-value}$ yang lebih besar dari 0,05 (masing-masing sebesar 0,439; 0,931; 0,131; dan 0,522). Oleh karena itu, diputuskan Gagal Tolak H_0 untuk variabel X_1, X_2, X_3 , dan X_4 , yang artinya keempat variabel tersebut secara parsial tidak memiliki pengaruh yang signifikan terhadap variabel respons dalam model.

3.3.4 Heterogenitas Spasial

Pengujian heterogenitas spasial dilakukan untuk mengetahui apakah terdapat perbedaan karakteristik antar Kabupaten/Kota setelah adanya indikasi keterkaitan spasial. Perbedaan tersebut membuat parameter regresi yang diperoleh dapat berbeda-beda antar Kabupaten/Kota. Pengujian ini dilakukan dengan uji Breusch Pagan. Berikut adalah hasil pengujian heterogenitas spasial.

Tabel 5. Uji Breusch-Pagan (BP)

BP	DF	P-Value
----	----	---------

12,603	17	0,0497
--------	----	--------

Dengan Tingkat signifikansi (α) sebesar 0,05, ditetapkan daerah pengujian yaitu H_0 ditolak jika nilai $BP > \chi^2_{0,05;17}$ serta $P - Value < (\alpha)$, yang artinya variasi antar lokasi berbeda. Pada Tabel 5, didapatkan nilai BP sebesar 12,603 yang nilainya lebih besar dari χ^2 yakni sebesar 12,59 serta diperkuat oleh $P - Value$ sebesar 0,0497 yang lebih kecil dari (α) sebesar 0,05. Sehingga diperoleh keputusan H_0 ditolak yang artinya varians antar lokasi pengamatan tidak sama atau terdapat keragaman antar lokasi pengamatan.

3.4 Pemodelan Geographically Weighted Negative Binomial Regression

Geographically Weighted Negative Binomial Regression (GWNBR) merupakan pengembangan dari regresi binomial negatif. Model GWNBR menggunakan pembobot geografis pada penaksiran parameternya. Matriks pembobot didapatkan dengan menggunakan pembobot fungsi Adaptive Bisquare Kernel. Sehingga akan diperoleh parameter yang berbeda-beda untuk setiap kabupaten/kota di Sulawesi Selatan.

3.4.1 Penentuan bandwidth dan Pembobot Optimum

Tahap pertama dalam membangun model *Geographically Weighted Negative Binomial Regression* (GWNBR) adalah menetapkan titik pengamatan berdasarkan koordinat geografis (lintang dan bujur) untuk setiap kabupaten/kota di Jawa Timur. Setelah itu, ditentukan *bandwidth* optimal menggunakan kriteria *Cross Validation* (CV) yang memiliki nilai paling rendah. Untuk memilih *bandwidth* optimum, digunakan salah satu dari empat fungsi kernel yaitu fungsi kernel *Fixed Gaussian*, *Fixed Bisquare*, *Adaptive Gaussian*, dan *Adaptive Bisquare*. Selanjutnya, untuk menentukan matriks pembobot dari fungsi kernel, digunakan kriteria *Akaike Information Criterion* (AIC) dengan nilai terendah. Nilai AIC untuk setiap fungsi kernel ditunjukkan dalam Tabel 6, sebagai berikut:

Tabel 6. Nilai AIC dari masing-masing fungsi Karna

Fungsi Karna	AIC
Fixed Gaussien	445,929
Fixed Bisquare	447,778
Adaptive Gaussian	447,113
Adaptive Bisquare	422,699

Tabel 6 menunjukkan bahwa pembobot karna yang akan digunakan untuk mengestimasi parameter model GWNBR Adalah fungsi kerner Adaptive Bisquare karena memiliki nilai AIC yang terkecil yaitu sebesar 422,699. Nilai CV minimum yang diperoleh yaitu sebesar 100023553 dengan bandwidth optimum sebesar 3,531857.

3.4.2 pengujian parsial GWNBR secara serentak

Penguji signifikansi parameter GWNBR secara serentak dilakukan untuk mengevaluasi apakah seluruh variabel prediktor secara serentak memberikan

pengaruh yang nyata terhadap variabel respons. Hipotesis yang digunakan pada uji serentak adalah sebagai berikut:

$$H_0: \beta_1(u_i, v_i) = \beta_2(u_i, v_i) = \dots = \beta_k(u_i, v_i) = 0; i = 1, 2, \dots, 24$$

$$H_1: \beta_j(u_i, v_i) \neq 0; j = 1, 2, \dots, 6$$

Dengan Tingkat signifikansi (α) sebesar 0,005 ditetapkan daerah penolakan yaitu H_0 ditolak jika nilai *Deviance* $> X^2_{0,005;6}$. Berdasarkan hasil perhitungan yang didapatkan nilai *Deviance* sebesar 48,874 yang nilainya lebih besar dari $X^2_{0,005;6}$ sebesar 12,592 sehingga diperoleh Keputusan tolak H_0 yang artinya minimal ada salah satu variabel prediktor yang berpengaruh terhadap variabel respon.

3.4.3 Pengujian Signifikansi Parameter GWNBR Secara Parsial

Pengujian secara parsial bertujuan untuk mengetahui variabel respon mana yang berpengaruh signifikan terhadap variabel prediktor pada setiap wilayah. Pengujian secara parsial menghasilkan parameter yang berbeda untuk setiap Kabupaten/Kota, untuk mengetahui variabel yang signifikan tiap Kabupaten/Kota dilakukan perbandingan nilai *Zhitung* dengan *Ztabel* menggunakan $\alpha = 5\%$. Hipotesis yang digunakan untuk uji parsial sebagai berikut:

$$H_0: \beta_j(u_i, v_i) = 0 \text{ (variabel prediktor } j \text{ tidak berpengaruh signifikan terhadap variabel respon di wilayah } i)$$

$$H_1: \beta_j(u_i, v_i) \neq 0; i = 1, 2, \dots, n; j = 1, 2, \dots, k \text{ (variabel prediktor } j \text{ berpengaruh signifikan terhadap variabel respon di wilayah } i)$$

dengan $i = 1, 2, \dots, 6$ dan $j = 1, 2, \dots, 6$.

Untuk nilai Z_{tabel} diperoleh $Z_{0,05/2} = 1,96$. Sehingga apabila nilai $Z - hitung$ lebih besar dari nilai Z_{tabel} maka tolak H_0 yang artinya bahwa variabel tersebut secara parsial berpengaruh signifikan terhadap jumlah kasus stunting. Berdasarkan pengujian parameter secara parsial dengan menggunakan bantuan syntax pada software R, sebagai contoh pembentukan model GWNBR untuk lokasi pengamatan pada Kabupaten/Kota ke-23 (u_{23}, v_{23}) yaitu Kota Makassar dengan estimasi parameter seperti pada:

Tabel 7. Estimasi Parameter

Parameter	Koefisien	Z-hitung
$\hat{\beta}_0$	19253,73	5,234
$\hat{\beta}_1$	16,40	1,318
$\hat{\beta}_2$	89,25	0,228
$\hat{\beta}_3$	-26,69	0,731
$\hat{\beta}_4$	-26,45	0,428
$\hat{\beta}_5$	-284,53	-0,083
$\hat{\beta}_6$	25,61	-2,394

Berdasarkan tabel 7 diperoleh bahwa untuk Kota Makassar model GWNBR yang terbentuk adalah persamaan berikut:

$$\mu_i = \exp(\beta_0 + \beta_1(u_i, v_i)x_1 + \beta_2(u_i, v_i)x_2 + \dots + \beta_k(u_i, v_i)x_k)$$

Contoh hasil estimasi pada lokasi ke-22 adalah:

$$\mu_{22} = \exp(19253,73 + 16,40x_1 + 89,25x_2 - 26,69x_3 - 26,45x_4 - 284,53x_5 + 25,61x_6)$$

Pada lokasi pengamatan ke-22 yakni Kota Makassar, model GWNBR menunjukkan bahwa intercept bernilai besar dan signifikan, menandakan adanya *baseline* kasus stunting yang tinggi meskipun tanpa pengaruh variabel independen. Variabel Asi Eksklusif, MP-ASI, dan Imunisasi Dasar Lengkap memiliki koefisien positif, yang berarti secara arah cenderung meningkatkan kasus stunting, namun nilai Z-hitungnya rendah sehingga tidak signifikan secara statistik. Hal ini mengindikasikan bahwa faktor-faktor tersebut belum cukup kuat menjelaskan variasi stunting di wilayah ini.

Sebaliknya, variabel Angka Melek Baca dan Sanitasi dan Akses Air Bersih memiliki koefisien negatif, yang secara arah menunjukkan potensi menurunkan kasus stunting, tetapi keduanya juga tidak signifikan. Artinya, meskipun ada indikasi pengaruh, bukti statistiknya masih lemah.

Yang paling menonjol adalah variabel Sarana Kesehatan, dengan koefisien positif sebesar 25.61 namun Z-hitung -2.394 . Nilai Z yang relatif besar secara negatif menunjukkan bahwa variabel ini berperan signifikan dalam menurunkan kasus stunting di Kota Makassar. Dengan kata lain, faktor yang direpresentasikan oleh Sarana Kesehatan memiliki kontribusi nyata dalam mengurangi prevalensi stunting.

Secara keseluruhan, model di Kota Makassar menegaskan bahwa meskipun sebagian besar variabel tidak signifikan, Sarana Kesehatan menjadi faktor kunci yang berpengaruh nyata terhadap penurunan stunting. Hal ini dapat menjadi dasar rekomendasi kebijakan, misalnya memperkuat intervensi pada aspek yang diwakili oleh Sarana Kesehatan untuk menekan angka stunting di wilayah tersebut.

Tabel 8. Pengelompokan Kabupaten/kota berdasarkan variabel yang signifikan pada model GWNBR

Kelompok	Signifikan	Kabupaten/Kota
1	X_5	Luwu Timur
2	X_5 dan X_6	Kepulauan Selayar, Bulukumba, Bantaeng, Sinjai, Maros, Pangkajene dan kepulauan, Barru, Bone, Soppeng, Wajo, Sidenreng Rappang, Pinrang, Enrekang, Luwu, Tana Toraja, Luwu Utara, Toraja Utara, Kota Parepare, Kota Palopo
3	X_3, X_5 dan X_6	Jeneponto, Takalar, Gowa, Kota Makassar

tingkat stunting. Secara keseluruhan, peta ini menegaskan bahwa faktor lingkungan dan kesehatan merupakan determinan utama stunting di Sulawesi Selatan, dengan variasi lokal yang mencerminkan kondisi infrastruktur dan pelayanan kesehatan di masing-masing kabupaten/kota.

3.4.4 Pemilihan Model Terbaik

Pemilihan model terbaik berdasarkan pada nilai AIC. Model yang baik akan memiliki nilai AIC yang kecil. Nilai AIC di setiap model regresi ditunjukkan pada Tabel 9.

Tabel 9. Pemilihan Model Terbaik

Metode	AIC
Regresi Binomial Negatif	414.8023
GWNBR	216.9794

Tabel 9 menunjukkan bahwa nilai AIC yang dihasilkan oleh model GWNBR lebih kecil dari model Regresi Binomial Negatif. Sehingga model GWNBR sesuai untuk memodelkan faktor-faktor yang mempengaruhi jumlah kasus stunting di setiap kabupaten/kota di provinsi Sulawesi Selatan.

3.5 Pendeteksian Jumlah Kasus Stunting di Provinsi Sulawesi Selatan menggunakan Flexibly Shaped Spatial Scan Statistic

Pendeteksian kantong hotspot merupakan langkah pencegahan untuk mengurangi angka stunting dan dapat membantumenentukan wilayah mana saja yang memerlukan perhatian khusus dan prioritas utama dalam Upaya penanganan kasus stunting. Dengan demikian, diharapkan Tindakan pencegahan dan perlakuan ataupun program dapat dilakukan seawall mungkin. Salah satu metode yang dapat digunakan untuk mendeteksi hotspot tersebut adalah dengan menggunakan *flexibly shaped spatial scan statistic*. Metode ini merupakan statistik yang mampu mendeteksi daerah hotspot. Dalam penelitian ini, daerah yang dianggap sebagai hotspot adalah kabupaten atau kota.

Hasil pendeteksian hotspot jumlah stunting di provinsi Sulawesi Selatan dengan data prediksi selengkapnya dapat dilihat pada tabel 9 dan gambar 9. Pengujian Tingkat signifikansi dilakukan dengan Teknik simulasi monte carlo dengan rumus pada persamaan 22, dimana sebanyak 99, 999, 9999 menghasilkan kesimpulan yang sama baik dari sisi jumlah hotspot stunting yang dideteksi maupun resiko relatifnya. Perbedaan hasil hanya pada keakuratan nilai $p - value$. Oleh karena itu, hasil yang disajikan pada Tabel 9 merupakan pengujian Tingkat signifikansi dengan pengulangan sebanyak 9999.

Tabel 10. Hasil Deteksi Kantong Stunting di Provinsi Sulawesi Selatan

Cluster Stunting	Jumlah Kabupaten/Kota	Kasus Stunting	Harapan	Resiko Relatif	P-Value
1	4	40372	21734	2,6	0,001
2	1	4542	3622	1,3	0,001
3	1	3861	3622	1,1	0,010

Keterangan:

Cluster Stunting: Kumpulan satu atau beberapa Kabupaten/kota yang membentuk hotspot atau kantong stunting


Jumlah

Kabupaten/kota: jumlah kabupaten/kota yang termaksud dalam satu kantong

Harapan : jumlah kasus stunting dalam satu hotspot yang diharapkan, diperoleh dari hasil estimasi gwnbr.

Resiko relative : perbandingan nilai resiko relative di dalam kantong stunting dengan nilai resiko relative diluar hotspot.

Secara keseluruhan, hasil FSSS menegaskan adanya konsentrasi stunting yang tidak merata, dengan satu klaster besar yang sangat signifikan dan dua klaster kecil yang tetap menunjukkan kelebihan kasus. Temuan ini penting untuk mengarahkan intervensi kebijakan, di mana wilayah dalam klaster pertama harus menjadi prioritas utama penanganan, sementara klaster kedua dan ketiga tetap perlu mendapat perhatian karena menunjukkan pola hotspot lokal.



Gambar 10. Pemetaan Hasil Pendeteksian Kantong Stunting

Berdasarkan Tabel 10 dan Gambar 10 terdapat informasi mengenai tiga kantong stunting di provinsi Sulawesi Selatan, dengan rincian sebagai berikut:

1. Cluster 1

Observed kasus 40,372, jauh lebih tinggi dari expected 21,734.8. Relative Risk (RR) 2.6 risiko stunting 2,6 kali lebih tinggi dibanding wilayah lain. LLR

9,323.3 dengan p 0.001 sangat signifikan. Artinya, ini adalah kantong utama stunting dengan bentuk fleksibel gabungan 4 kabupaten/kota diantara yakni Bulukumba, Jeneponto, Takalar dan Gowa.

2. Cluster 2

Observed 4,542, expected 3,622.5. RR 1.3 risiko stunting 30% lebih tinggi dari ekspektasi. LLR 113.0, p 0.001 signifikan. Kabupaten Kepulauan Selayar menunjukkan hotspot tunggal dengan kasus lebih tinggi dari harapan.

3. Cluster 3

Observed 3,861, expected 3,622.5. RR 1.1 risiko 10% lebih tinggi dari ekspektasi. LLR 8.0, p 0.010 signifikan, tetapi relatif kecil dibanding cluster lain. Kabupaten Bantaeng adalah kantong kecil dengan kelebihan kasus ringan namun tetap signifikan.

BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan hasil analisis pemodelan Geographically Weighted Negative Binomial Regression (GWNBR) dan Flexibly Shaped Spatial Scan Statistic (FSSS) terhadap jumlah kasus stunting di Provinsi Sulawesi Selatan, dapat ditarik beberapa kesimpulan utama sebagai berikut.

1. Hasil uji overdispersi menunjukkan bahwa data kasus stunting tidak sesuai dengan asumsi ekuidispersi pada regresi Poisson, sehingga model Negative Binomial lebih tepat digunakan. Model NB memberikan hasil yang lebih baik dengan nilai AIC yang lebih rendah dibandingkan model Poisson, serta mampu mengatasi masalah overdispersi.
2. Hasil uji signifikansi parsial pada model NB menunjukkan bahwa dari enam variabel prediktor yang digunakan, hanya variabel X5 (cakupan sanitasi air bersih) dan X6 (jumlah sarana kesehatan) yang berpengaruh signifikan terhadap jumlah kasus stunting. Variabel lainnya (X1, X2, X3, X4) tidak signifikan secara statistik. Hal ini menegaskan bahwa faktor lingkungan dan akses kesehatan merupakan determinan utama stunting di Sulawesi Selatan.
3. Hasil pemodelan GWNBR memperlihatkan adanya heterogenitas spasial, di mana pengaruh variabel berbeda antar kabupaten/kota. Dari matriks signifikansi lokal, terbentuk tiga kelompok wilayah: 1. Kelompok 1: hanya X5 signifikan (contoh: Luwu Timur). 2. Kelompok 2: X5 dan X6 signifikan bersama (mayoritas kabupaten/kota di Sulawesi Selatan). 3. Kelompok 3: X3, X5, dan X6 signifikan (wilayah selatan seperti Jeneponto, Takalar, Gowa, dan Kota Makassar). Pengelompokan ini menunjukkan bahwa intervensi kebijakan harus disesuaikan dengan kondisi lokal masing-masing wilayah.
4. Hasil FSSS mendeteksi adanya tiga klaster stunting. Klaster pertama terdiri dari enam kabupaten/kota dengan jumlah kasus 40.372, jauh lebih tinggi dari harapan 21.734, dengan risiko relatif 2,6 kali lipat dan p-value 0,001. Klaster ini merupakan kantong utama stunting yang harus menjadi prioritas penanganan. Klaster kedua dan ketiga masing-masing terdiri dari satu kabupaten/kota dengan risiko relatif 1,3 dan 1,1, keduanya signifikan, meskipun lebih kecil dibanding klaster pertama.

4.2 Saran

Berdasarkan kesimpulan penelitian, terdapat beberapa saran yang dapat diajukan untuk mendukung upaya penanggulangan stunting di Provinsi Sulawesi Selatan.

1. Pemerintah daerah perlu memprioritaskan peningkatan akses sanitasi air bersih dan penguatan sarana kesehatan, karena kedua faktor ini terbukti signifikan memengaruhi jumlah kasus stunting. Program pembangunan infrastruktur sanitasi dan pemerataan fasilitas kesehatan harus diarahkan ke wilayah yang termasuk dalam klaster utama stunting.

2. wilayah dengan kombinasi variabel signifikan (X3, X5, dan X6), seperti Jeneponto, Takalar, Gowa, dan Kota Makassar, memerlukan intervensi yang lebih komprehensif. Selain sanitasi dan sarana kesehatan, cakupan imunisasi dasar lengkap harus ditingkatkan melalui kampanye kesehatan masyarakat, penyediaan vaksin yang memadai, serta penguatan sistem monitoring imunisasi.
3. Hasil FSSS menunjukkan adanya kantong stunting yang signifikan. Oleh karena itu, intervensi berbasis wilayah (spatial targeting) perlu diterapkan. Wilayah dalam klaster pertama harus menjadi prioritas utama, sementara klaster kedua dan ketiga tetap mendapat perhatian sebagai hotspot lokal. Pendekatan ini akan membuat kebijakan lebih efektif dan tepat sasaran.
4. penelitian lanjutan disarankan untuk memasukkan variabel sosial ekonomi dan pola asuh keluarga, karena faktor-faktor tersebut kemungkinan besar berperan di wilayah yang tidak menunjukkan signifikansi pada variabel yang diteliti. Dengan demikian, model yang lebih komprehensif dapat memberikan gambaran yang lebih utuh mengenai determinan stunting.

DAFTAR PUSTAKA

- Akaike, H. (1974). A New Look at The Statistical Model Identification. *Automatic Control, IEEE Transactions on*, 19(6), pp 716-723.
- Anselin, L. (1988). *Spatial econometrics: methods and models* (Vol. 4). Springer Science & Business Media.
- Brunsdon, C., Fotheringham, A. S., & Charlton, M. E. (1996). Geographically weighted regression: a method for nonstationarity. *Geographical analysis*, 28(4), 281-298.
- Cameron, A. C., & Trivedi, P. K. (1998). *Regression Analysis of Count Data*. Cambridge: Cambridge University Press.
- Casella, G., & Berger, R. L. (1990). *Statistical Inference*, Belmont, California, Wadsworth.
- Famoye, F., Wulu, J. T., & Singh, K. P. (2004). On the generalized Poisson regression model with an application to accident data. *Journal of Data Science*, 2(3), 287-295.
- Fitriyah, I. I. (2017). Estimasi Parameter Model Geographically Weighted Negative Binomial Regression (GWNBR) dengan Pembobot Adaptive Gaussian Kernel.
- Fotheringham, A.S., Brundson, C., dan Charlton, M. (2002). *Geographically Weighted Regression. The Analysis Of Spatially Varying Relationship*. England : John Wiley & Sons Ltd.
- Greene, W. (2008). Functional forms for the negative binomial model for count data. *Economics Letters*, 99(3), 585–590.
- Haran. M., Molineros J., & Patil, G.P. (2006). Large Scale Plant Disease Forecasting. Technical Report Number 2006-0530. Presented at the 7th Annual International Conference on Digital Government Research.
- Hardin, J. W., Hardin, J. W., Hilbe, J. M., & Hilbe, J. (2007). *Generalized linear models and extensions*. Stata press.
- Hasibuan, L.S. (2008). *Pola Spasial Kemiskinan di Indramayu*, Tesis Jurusan Statistika IPB. Bogor : IPB.
- Hilbe, J. M. (2011). *Negative binomial regression*. Cambridge University Press.
- Hocking, R. (1996). *Method and Applications of Linier Models*. New York: Cambridge University Press.
- Juniardi, L. C., & Salamah, M. (2015). Analisis Faktor-Faktor yang Mempengaruhi Jumlah Kasus Kusta di Jawa Timur pada Tahun 2013 Menggunakan Geographically Weighted Negative Binomial Regression (GWNBR). *Jurnal Sains dan Seni ITS*, 4(1), D55-D60.

- Kemenkes. (2023). Kementrian Kesehatan Republik Indonesia. <https://kemenkes.go.id>
- Kuldorff, M. (1997). A Spatial Scan Statistic. *Communication In Statistics Theory And Method*, 26(6), 1481-1496.
- Leung, Y., Mei, C. L., & Zhang, W. X. (2000). Statistical tests for spatial nonstationarity based on the geographically weighted regression model. *Environment and Planning A*, 32(1), 9-32.
- Luhung M. B. (2021). pemodelan dan pemetaan jumlah penderita kusta di Jawa Barat dengan regresi binomial negative dan *Flexibly Shaped Spatial Scan*. *Jurnal Riset Statistika*, 1(2), H99-106.
- McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* 2nd ed. Chapman and Hall, New York.
- Nakaya, T., Fotheringham, A. S., Brunsdon, C., & Charlton, M. (2005). Geographically weighted Poisson regression for disease association mapping. *Statistics in medicine*, 24(17), 2695-2717.
- Niswatul Q, Sutikno. (2016). Analisis Pola Persebaran ISPA (Infeksi Saluran Pernafasan Akut) Sebagai Dampak Industri Migas di Kabupaten Bojonegoro Menggunakan Spatial Pattern Analysis dan *Flexibly Shaped Spatial Scan* Statistic. *Jurnal sains dan seni ITS*, 5(2), D462.
- Patil, G.P. & Taillie C. (2003). Upper Level Set Scan Statistic For Detecting Arbitarily Shaped Hotspots. *Enviromental and Ecological Statistics*, Volume : 11 : 183-197.
- Purhadi, Latra I. N., Hidayanti U. (2015). pemodelan kasus DBD di kota Surabaya dengan *Geographically Weighted Regression* dan *Flexibly Shaped Spatial Scan*. *Jurnal sains dan seni ITS*, 4(2), D272.
- Purhadi, Latra I. N., Magfiroh F. (2015). pemodelan kasus pneumonia balita di kota Surabaya dengan *Flexibly shaped spatial scan statistic*. *Jurnal sains dan seni ITS*, 4(2), D205.
- Putera, M. L. S., Wahyunita, L., & Yusup, F. (2021). Spatial Modelling of Covid-19 Confirmed Cases in Kalimantan, Indonesia: How Neighborhood Matters? *Walailak Journal of Science and Technology (WJST)*, 18(15), 22120-17.
- Ricardo, A., & Carvalho, T. (2014). *Geographically Weighted Negative Binomial Regression-Incorporating Overdispersion*. Business Media New York: Springer Science.
- Sembiring, R. K. (1995). *Analisis Regresi Edisi Kedua*. Penerbit ITB. Bandung.
- Tango, T. dan Takahashi, K. (2005) A *Flexibly Shaped Spatial Scan* Statistic For Detecting Clusters. *International Journal of Health Geographics*, Volume: 4 :11.

- Yasin, H., Suryani, I., & Kartikasari, P. (2021, July). Graphical interface of geographically weighted negative binomial regression (GWNBR) model using R-Shiny. In *Journal of Physics: Conference Series* (Vol. 1943, No. 1, p. 012155). IOP Publishing.
- Yuli, D., & Indriani, D. (2015). Pemodelan Binomial Negatif Untuk Mengatasi Overdispersi Data Diskrit Pada Kasus Baru Tb Di Provinsi Jawa Timur. *Jurnal Biometrika Dan Kependudukan*, 4(2), 134-142.

Lampiran 1 Variabel Penelitian

No	Kabupaten/ Kota	Y	X1	X2	X3	X4	X5	X6	U (longitude)	V (Latitude)
1	Kepulauan Selayar	3861	38.5	59.1	46.8	3.91	85.65	93	-6.12	120.46
2	Bulukumba	6505	55.5	45.6	56.8	3.73	86.8	144	-5.56	120.18
3	Bantaeng	2059	60.4	61.2	61.7	9.07	78.07	60	-5.55	119.95
4	Jeneponto	6406	63.7	58.6	41.7	8.8	83.19	119	-5.68	119.75
5	Takalar	2793	65	55.3	51.7	6.51	95.59	117	-5.43	119.44
6	Gowa	6306	61.1	64.4	58.2	4.45	96.16	251	-5.23	119.44
7	Sinjai	2278	67	61	40.5	3.5	86.54	101	-5.13	120.25
8	Maros	5696	58.3	61.7	37.5	4.46	86.09	87	-4.95	119.59
9	Pangkajene Dan Kepulauan	5987	69.7	63.9	35.8	2.2	88	122	-4.83	119.77
10	Barru	1961	54.6	61.3	60.8	1.79	99.09	61	-4.41	119.62
11	Bone	2479	50.4	55.9	43.9	4.48	97.2	199	-4.53	120.32
12	Soppeng	1559	62.3	60.9	52	4.39	95.67	86	-4.35	119.3
13	Wajo	3162	59.2	58.7	49.6	5.39	97.03	124	-4.11	120.02
14	Sidenreng Rappang	2323	48.9	63.7	52.6	2.09	94.77	112	-3.92	119.76
15	Pinrang	2638	60.9	64.4	48.9	2.85	94.64	106	-3.8	119.64
16	Enrekang	1485	65.6	60.5	52.1	2.3	97.29	105	-3.56	119.77
17	Luwu	3531	58.5	53.4	53.9	3.41	94.72	192	-3.06	120.24
18	Tana Toraja	4542	57.3	65.1	46.3	3.36	86.03	75	-3.09	119.87
19	Luwu Utara	2368	70.1	64.4	53.5	1.36	95.94	111	-2.55	120.37
20	Luwu Timur	2895	56.3	46.9	42.4	2.07	92.5	174	-2.6	120.81
21	Toraja Utara	3834	46.4	52.6	50.4	2.71	91.83	76	-2.55	120.37
22	Kota Makassar	9472	54.9	62.8	66.4	0.59	97.56	314	-5.15	119.43
23	Kota Parepare	908	60.9	66.8	68.9	0.71	97.86	45	-3.98	119.64
24	Kota Palopo	1891	57.2	58.2	66.1	1.01	96.18	81	-2.99	120.2

Lampiran 2. Hasil Korelasi Variabel

##	X1	X2	X3	X4	X5	X6
## X1	1.000	0.291	-0.102	0.103	0.023	-0.049
## X2	0.291	1.000	0.136	-0.147	0.099	-0.174
## X3	-0.102	0.136	1.000	-0.276	0.410	0.074
## X4	0.103	-0.147	-0.276	1.000	-0.589	-0.110
## X5	0.023	0.099	0.410	-0.589	1.000	0.288
## X6	-0.049	-0.174	0.074	-0.110	0.288	1.000

Lampiran 3. Hasil Analisis Overdispersi Regresi Poisson

```
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept) 13.5413251  0.0856474 158.106 < 2e-16 ***
## X1          -0.0032006  0.0005035  -6.357 2.06e-10 ***
## X2           0.0064650  0.0006356  10.172 < 2e-16 ***
## X3          -0.0085077  0.0004257 -19.985 < 2e-16 ***
## X4          -0.0335885  0.0019413 -17.302 < 2e-16 ***
## X5          -0.0644968  0.0008675 -74.345 < 2e-16 ***
## X6           0.0069716  0.0000557 125.164 < 2e-16 ***
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Dispersion parameter for poisson family taken to be 1)
##      Null deviance: 25758.1  on 23  degrees of freedom
## Residual deviance: 7950.5   on 17  degrees of freedom
## AIC: 8201.6
## Number of Fisher Scoring iterations: 4
```

Lampiran 4. Hasil Analisis Regresi Binomial Negatif

```
## Coefficients:
##           Estimate Std. Error z value Pr(>|z|)
## (Intercept) 13.484483  1.559256  8.648 < 2e-16 ***
## X1          -0.007355  0.009504  -0.774 0.438992
## X2           0.001120  0.012928  0.087 0.930950
## X3          -0.012109  0.008015  -1.511 0.130869
## X4          -0.023663  0.036942  -0.641 0.521818
## X5          -0.055664  0.015599  -3.568 0.000359 ***
## X6           0.006622  0.001098  6.029 1.65e-09 ***
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## (Dispersion parameter for Negative Binomial(10.4054) family taken to be 1)
##      Null deviance: 75.701  on 23  degrees of freedom
## Residual deviance: 24.375  on 17  degrees of freedom
## AIC: 414.8
## Number of Fisher Scoring iterations: 1
##           Theta: 10.41
##           Std. Err.: 2.97
## 2 x log-likelihood: -398.802
```

Lampiran 5. Hasil Pengujian Spasial

```
## studentized Breusch-Pagan test
##   Statistik df   p.value
## BP  12.60329  6 0.0497865

## Moran I test under randomisation
## sample estimates:
## Moran I statistic      Expectation      Variance
##      0.01856550      -0.04347826      0.01617905
```

Lampiran 6. Cross Validation

```
## Adaptive q: 0.381966 CV score: 1237780485
## Adaptive q: 0.618034 CV score: 125630161
## Adaptive q: 0.763932 CV score: 121658463
## Adaptive q: 0.692093 CV score: 133019940
## Adaptive q: 0.854102 CV score: 113105474
## Adaptive q: 0.9098301 CV score: 108664542
## Adaptive q: 0.9442719 CV score: 108435639
## Adaptive q: 0.9311532 CV score: 108335231
## Adaptive q: 0.9320061 CV score: 108344260
## Adaptive q: 0.9230085 CV score: 108226667
## Adaptive q: 0.9179748 CV score: 108138591
## Adaptive q: 0.9148638 CV score: 108250162
## Adaptive q: 0.9191563 CV score: 108160642
## Adaptive q: 0.9167865 CV score: 108115629
## Adaptive q: 0.9160521 CV score: 108159277
## Adaptive q: 0.9171447 CV score: 108122632
## Adaptive q: 0.916506 CV score: 108125237
## Adaptive q: 0.9168496 CV score: 108116867
## Adaptive q: 0.9166793 CV score: 108113522
## Adaptive q: 0.9166131 CV score: 108117256
## Adaptive q: 0.9167202 CV score: 108114328
## Adaptive q: 0.9166793 CV score: 108113522
```

Lampiran 7. Bandwidth Optimum tiap Kabupaten/kota

Kepulauan Selayar	11.44039	Wajo	9.244435
Bulukumba	13.62136	Sidenreng Rappang	9.863172
Bantaeng	14.11793	Pinrang	10.27625
Jeneponto	13.93892	Enrekang	11.08866
Takalar	14.29437	Luwu	10.95937
Gowa	14.58787	Tana Toraja	11.28794
Sinjai	13.8158	Luwu Utara	9.943369
Maros	14.90308	Luwu Timur	9.325603
Pangkajene Dan Kepulauan	14.80861	Toraja Utara	9.943369
Baru	12.99072	Kota Makassar	14.63216
Bone	11.12104	Kota Parepare	9.88873
Soppeng	11.9524	Kota Palopo	10.94594

Lampiran 8. Syntax Program R

```
#####
## REGRESI BINOMIAL NEGATIF
#####

library(MASS)

model_nb <- glm.nb( Y ~ X1 + X2 + X3 + X4 + X5 + X6, data = DATA)
summary(model_nb)

#####
## TABEL ESTIMASI PARAMETER
#####

hasil_nb <- summary(model_nb)

coef_nb <- as.data.frame(hasil_nb$coefficients)

colnames(coef_nb) <- c("Estimasi", "Std.Error", "Z", "P.Value")

coef_nb$Estimasi <- round(coef_nb$Estimasi,4)
coef_nb$Std.Error <- round(coef_nb$Std.Error,4)
coef_nb$Z <- round(coef_nb$Z,4)
coef_nb$P.Value <- round(coef_nb$P.Value,4)

#####
## MODEL NULL
#####

model_null <- glm.nb(Y ~ 1,data = DATA)
```

```
#####
## LOG LIKELIHOOD
#####

LL_null <- as.numeric(logLik(model_null))

LL_nb <- as.numeric(logLik(model_nb))

#####
## LIKELIHOOD RATIO TEST
#####

G2 <- 2*(LL_nb-LL_null)

G2

df_chi <- 6

alpha <- 0.05

chisq_tabel <- qchisq( 0.95, df_chi )

chisq_tabel

p_value <- 1-pchisq( G2, df_chi)

p_value

#####
## TABEL LRT
#####

tabel_LRT <- data.frame(

  Statistik=c( "Log Likelihood Null",

    "Log Likelihood NB",

    "G^2",

    "Chi-square(0.05)",

    "P-value"),

  Nilai=c(LL_null, LL_nb, G2, chisq_tabel, p_value))

tabel_LRT$Nilai <- round(tabel_LRT$Nilai, 4)
```

```

tabel_LRT

if(G2 > chisq_tabel){ cat("Tolak H0")}else{cat("Gagal Tolak H0")}

#####
## UJI WALD
#####

hasil_wald <- data.frame(

  Variabel = rownames(coef_nb),

  Estimasi = coef_nb[,1],

  Std_Error = coef_nb[,2],

  Z_Hitung = coef_nb[,3],

  P_Value = coef_nb[,4])

hasil_wald$Estimasi <-
  round(hasil_wald$Estimasi,4)

hasil_wald$Std_Error <-
  round(hasil_wald$Std_Error,4)

hasil_wald$Z_Hitung <-
  round(hasil_wald$Z_Hitung,4)

hasil_wald$P_Value <-
  round(hasil_wald$P_Value,4)

hasil_wald

alpha <- 0.05

z_tabel <- qnorm(1-alpha/2)

z_tabel

## [1] 1.959964

hasil_wald$Keputusan <-

  ifelse(hasil_wald$P_Value<0.05,"Signifikan", "Tidak Signifikan"
)

#####
## UJI SIGNIFIKANSI SERENTAK

```

```
#####

model_null <- glm.nb(Y ~ 1, data = DATA)

LL0 <- as.numeric(logLik(model_null))
LL1 <- as.numeric(logLik(model_nb))

G2 <- -2*(LL0-LL1)

derajat_bebas <- length(coef(model_nb))-1

pvalue <- 1-pchisq(G2,derajat_bebas)

hasil_serentak <- data.frame(
  LogLik_Null = LL0,
  LogLik_Full = LL1,
  G2 = G2,
  derajat_bebas = derajat_bebas,
  p_value = pvalue)

if(pvalue<0.05){
  cat("Tolak H0\n")}else{
  cat("Gagal Tolak H0\n")}

#####
## Uji SIGNIFIKANSI PARSIAL
#####

hasil_parsial <- data.frame(
  Variabel = rownames(koef_nb),
  Estimasi = coef_nb[,1],
  Std_Error = coef_nb[,2],
  Z_hitung = coef_nb[,3],
  p_value = coef_nb[,4])

hasil_parsial
hasil_parsial$Keputusan <-
  ifelse(hasil_parsial$p_value < 0.05,
    "Signifikan",
```

```

    "Tidak Signifikan")

hasil_parsial
hasil_parsial[,2:5] <-
    round( hasil_parsial[,2:5], 4)

#####
## RESIDUAL MODEL NB
#####

res_nb <- residuals(
    model_nb,
    type = "pearson")

head(res_nb)

##           1           2           3           4           5
6
## -0.5784590  1.1581087 -1.3971651  0.8708189  0.6840570  0.4937
286

#####
## NEIGHBOR
#####

library(spdep)
coord <- as.matrix(
    DATA[, c("U", "V")])

head(coord)

##           U           V
## [1,] -6.12 120.46
## [2,] -5.56 120.18
## [3,] -5.55 119.95
## [4,] -5.68 119.75
## [5,] -5.43 119.44
## [6,] -5.23 119.44

dim(coord)

#####
## MATRIKS JARAK
#####

jarak <- as.matrix(

```

```

dist(coord))

dim(jarak)

round(jarak[1:5,1:5],3)

##          1          2          3          4          5
## 1 0.000 0.626 0.765 0.835 1.231
## 2 0.626 0.000 0.230 0.446 0.751
## 3 0.765 0.230 0.000 0.239 0.524
## 4 0.835 0.446 0.239 0.000 0.398
## 5 1.231 0.751 0.524 0.398 0.000

#####
## K-NEAREST NEIGHBOR
#####

library(spdep)

knn <- knearneigh(
  coord,
  k = 4)

nb <- knn2nb(knn)

#####
## BOBOT SPASIAL
#####

lw <- nb2listw( nb,style = "W")
lw

library(lmtest)

bp <- bptest(model_nb)

bp

hasil_bp <- data.frame(
  Statistik = as.numeric(bp$statistic),
  df = as.numeric(bp$parameter),
  p.value = bp$p.value)

```

```

hasil_bp

#####
## RESIDUAL PEARSON
#####

res_nb <- residuals(
  model_nb,
  type = "pearson")

#####
## MORAN'S I
#####

moran_nb <- moran.test(res_nb, lw)

moran_nb
## Moran I statistic standard deviate = 0.48778, p-value = 0.3129
## alternative hypothesis: greater

hasil_moran <- data.frame(
  Moran_I = as.numeric(moran_nb$estimate[1]),
  Expectation = as.numeric(moran_nb$estimate[2]),
  Variance = as.numeric(moran_nb$estimate[3]),
  p.value = moran_nb$p.value)

#####
## BANDWIDTH ADAPTIVE GAUSSIAN
#####

bw_AG <- gwr.sel(
  Y ~ X1 + X2 + X3 + X4 + X5 + X6,
  data = DATA,
  coords = coord,
  adapt = TRUE,
  gweight = gwr.Gauss)

```

```

bw_AG

## [1] 0.5856135

#####
## BANDWIDTH ADAPTIVE BISQUARE
#####

bw_AB <- gwr.sel(

  Y ~ X1 + X2 + X3 + X4 + X5 + X6,

  data = DATA,

  coords = coord,

  adapt = TRUE,

  gweight = gwr.bisquare)

bw_AB

## [1] 0.9166793

#####
## BANDWIDTH FIXED GAUSSIAN
#####

bw_FG <- gwr.sel(

  Y ~ X1 + X2 + X3 + X4 + X5 + X6,

  data = DATA,

  coords = coord,

  adapt = FALSE,

  gweight = gwr.Gauss)

bw_FG

## [1] 1.423654

#####
## BANDWIDTH FIXED BISQUARE
#####

bw_FB <- gwr.sel(

```

```

Y ~ X1 + X2 + X3 + X4 + X5 + X6,

data = DATA,

coords = coord,

adapt = FALSE,

gweight = gwr.bisquare)
bw_FB
## [1] 3.220229
gwr_AG <- gwr(
  Y ~ X1 + X2 + X3 + X4 + X5 + X6,
  data = DATA,
  coords = coord,
  adapt = bw_AG,
  gweight = gwr.Gauss,
  hatmatrix = TRUE)
gwr_AB <- gwr(
  Y ~ X1 + X2 + X3 + X4 + X5 + X6,
  data = DATA,
  coords = coord,
  adapt = bw_AB,
  gweight = gwr.bisquare,
  hatmatrix = TRUE)
gwr_FG <- gwr(
  Y ~ X1 + X2 + X3 + X4 + X5 + X6,
  data = DATA,
  coords = coord,

```

```

bandwidth = bw_FG,
gweight = gwr.Gauss,
hatmatrix = TRUE)
gwr_FB <- gwr(
  Y ~ X1 + X2 + X3 + X4 + X5 + X6,
  data = DATA,
  coords = coord,
  bandwidth = bw_FB,
  gweight = gwr.bisquare,
  hatmatrix = TRUE)
str(gwr_AG, max.level = 2)
names(gwr_AB)
str(gwr_AB, max.level = 2)
gwr_AG$results
hasil_bandwidth <- data.frame(
  Kernel = c(
    "Adaptive Gaussian",
    "Adaptive Bisquare",
    "Fixed Gaussian",
    "Fixed Bisquare"),
  Bandwidth = c(bw_AG,bw_AB, bw_FG, bw_FB ),
  AIC = c(
    gwr_AG$results$AICc,
    gwr_AB$results$AICc,
    gwr_FG$results$AICc,

```

```

gwr_FB$results$AICc))
w_opt <- bw_AB

#####
## FUNGSI PEMBENTUK MATRIKS BOBOT
#####

weight_bisquare <- function(coord, bw){

  n <- nrow(coord)

  ## matriks jarak
  D <- as.matrix(dist(coord))

  ## matriks bobot
  W <- matrix(0, n, n)

  for(i in 1:n){

    ## bandwidth Lokal
    hi <- sort(D[i,])[ceiling(bw*n)]

    for(j in 1:n){

      if(D[i,j] <= hi){

        W[i,j] <- (1-(D[i,j]/hi)^2)^2 }else{

          W[i,j] <- 0}} return(W)}

W <- weight_bisquare(coord,bw_opt)

dim(W)

round(W[1:5,1:5],4)

rowSums(W)

Y <- DATA$Y
X <- as.matrix(
  cbind(
    Intercept = 1,
    DATA[, c("X1", "X2", "X3", "X4", "X5", "X6")]))
dim(X)

head(X)

```

```
#####
## FUNGSI MU
#####

mu_nb <- function(X, beta){

  beta <- matrix(beta, ncol = 1)

  eta <- X %*% beta

  mu <- exp(eta)

  return(mu)}

#####
## PARAMETER AWAL
#####

beta0 <- coef(model_nb)

phi0 <- 1/model_nb$theta

theta0 <- c(phi0,beta0)

theta0

ll_nb_obs <- function(Y,mu,phi){

  lgamma(Y+1/phi)-
  lgamma(1/phi)-
  lgamma(Y+1)+
  Y*log(phi*mu)-
  (Y+1/phi)*log(1+phi*mu)}

ll_nb_local <- function(X,Y,W,beta,phi){

  mu <- mu_nb(X,beta)

  ll <- ll_nb_obs(Y,mu,phi)

  sum(diag(W)*ll)}

ll_gwnbr <- function(X,Y,W,beta,phi){

  n <- nrow(W)

  LL <- numeric(n)

  for(i in 1:n){
```

```

Wi <- diag(W[i,])

LL[i] <- ll_nb_local(
  X, Y, Wi, beta,
  phi)} sum(LL)}

LL0 <- ll_gwnbr(
  X, Y, W, beta0,
  phi0)

LL0
## [1] -2439.399

#####
## NUMERICAL GRADIENT
#####
grad_num <- function(theta,
                      X, Y, W, h = 1e-6){

  p <- length(theta)

  g <- numeric(p)

  for(j in 1:p){

    theta.plus <- theta
    theta.minus <- theta

    theta.plus[j] <- theta.plus[j] + h
    theta.minus[j] <- theta.minus[j] - h

    f.plus <- ll_gwnbr(
      X,Y,W,
      theta.plus[-1],
      theta.plus[1])

    f.minus <- ll_gwnbr(
      X,Y,W,
      theta.minus[-1],
      theta.minus[1] )

    g[j] <- (f.plus-f.minus)/(2*h)}g}

g <- grad_num(

```

```

theta0, X, Y, W)

round(g,6)

#####
## NUMERICAL HESSIAN
hessian_num <- function(theta, X, Y, W, h = 1e-5){

  p <- length(theta)

  H <- matrix(0,p,p)

  for(i in 1:p){

    for(j in i:p){

      th1 <- theta
      th2 <- theta
      th3 <- theta
      th4 <- theta

      th1[i] <- th1[i] + h
      th1[j] <- th1[j] + h

      th2[i] <- th2[i] + h
      th2[j] <- th2[j] - h

      th3[i] <- th3[i] - h
      th3[j] <- th3[j] + h

      th4[i] <- th4[i] - h
      th4[j] <- th4[j] - h

      f1 <- ll_gwnbr(
        X,Y,W,
        th1[-1],
        th1[1])

      f2 <- ll_gwnbr(
        X,Y,W,
        th2[-1],
        th2[1])

      f3 <- ll_gwnbr(
        X,Y,W,
        th3[-1],
        th3[1])

      f4 <- ll_gwnbr(

```

```

      X,Y,W,
      th4[-1],
      th4[1])

H[i,j] <- (f1-f2-f3+f4)/(4*h^2)

H[j,i] <- H[i,j] } } H}

H <- hessian_num(
  theta0, X,Y,W)

round(H,4)

eigen(H)$values

beta_awal <- coef(model_nb)

phi_awal <- 1/model_nb$theta

theta0 <- c(phi_awal, beta_awal)

#####
## ESTIMASI PARAMETER GWNBR
library(MASS)
library(geosphere)

library(dplyr)

library(tidyr)

# Data koordinat (Lon = V, Lat = U)
coords <- as.matrix(DATA[, c("V","U")])

# Fungsi bobot adaptif bisquare
bisquare_weights_adaptive <- function(dist_vec, q){
  # q = prop adaptif (misalnya 0.917 dari hasilmu)
  k <- ceiling(length(dist_vec) * q)
  b_i <- sort(dist_vec, partial = k)[k]
  w <- ifelse(dist_vec <= b_i, (1 - (dist_vec / b_i)^2)^2, 0) ret
  urn(w)}

# Fungsi fit Lokal GWNBR
fit_gwnbr_local <- function(DATA, coords, q, formula_str){
  n <- nrow(DATA)
  jarak <- geosphere::distm(coords, fun = distHaversine) # meter
  results <- vector("list", n)
  for(i in seq_len(n)){
    w <- bisquare_weights_adaptive(jarak[i, ], q = q)
    DATA$w_local <- w
  }
}

```

```

fit <- try(glm.nb(as.formula(formula_str), data = DATA, weights = w), silent = TRUE)
if(inherits(fit, "try-error")){
  results[[i]] <- list(success = FALSE)} else {
  results[[i]] <- list(success = TRUE,
                      fit = fit,
                      coef = coef(fit),
                      aic = AIC(fit),
                      theta = fit$theta,
                      summary = summary(fit))} }

return(results)}

# Jalankan GWNBR dengan q = 0.917 (hasil adaptif bisquare dari kamu)
res_best <- fit_gwnbr_local(DATA, coords, q = 0.917,
                           formula_str = "Y ~ X1 + X2 + X3 + X4
+ X5 + X6")

# Ekstrak koefisien lokal dan p-value
coef_names <- unique(unlist(lapply(res_best, function(x) if(x$success) names(x$coef)))))
local_coefs <- matrix(NA, nrow = nrow(DATA), ncol = length(coef_names))
colnames(local_coefs) <- coef_names
local_aic <- rep(NA, nrow(DATA))
local_pvals <- matrix(NA, nrow = nrow(DATA), ncol = length(coef_names))
colnames(local_pvals) <- coef_names

for(i in seq_len(nrow(DATA))){
  if(res_best[[i]]$success){
    cf <- res_best[[i]]$coef
    local_coefs[i, names(cf)] <- cf
    local_aic[i] <- res_best[[i]]$aic
    s <- res_best[[i]]$summary
    if(!is.null(s$coefficients)){
      for(nm in rownames(s$coefficients)){
        if(nm %in% coef_names) local_pvals[i, nm] <- s$coefficients[nm, "Pr(>|z|)"]}}}

# Tabel koefisien lokal per kabupaten/kota
local_coefs_df <- as.data.frame(local_coefs) %>%
  mutate(Kabupaten.Kota = DATA$`Kabupaten/Kota`,
         AIC_local = local_aic)
print(head(local_coefs_df))

# Tabel variabel signifikan per kabupaten/kota
local_pvals_df <- as.data.frame(local_pvals) %>%
  mutate(Kabupaten.Kota = DATA$`Kabupaten/Kota`)

```

```

sig_table <- local_pvals_df %>%
  pivot_longer(cols = all_of(coef_names), names_to = "Variable",
    values_to = "pval") %>%
  filter(!is.na(pval) & pval < 0.05) %>%
  arrange(Variable, pval)
print(head(sig_table))

library(dplyr)

# local_pvals_df sudah ada dari hasil GWNBR
# Buat indikator signifikan (TRUE/FALSE)
sig_matrix <- local_pvals_df %>%
  mutate(across(c("(Intercept)", X1:X6), ~ ifelse(!is.na(.) & . <
0.05, "√", ""))) %>%
  select(Kabupaten.Kota, X1, X2, X3, X4, X5, X6)

# Cetak tabel ringkasan
print(sig_matrix)

write.csv(local_coefs_df, "local_coefs_df.csv", row.names = FALSE
)
local_coefs_df <- read.csv("local_coefs_df.csv")
getwd()

## [1] "C:/Users/M S I/OneDrive/Documents"

# Simpan ke CSV
write.csv(sig_matrix, "sig_matrix_per_kabupaten.csv", row.names =
FALSE)

AIC_global <- AIC(model_nb) # NB global
AIC_sum_local <- sum(local_coefs_df$AIC_local, na.rm = TRUE)

data.frame(Model = c("Global NB", "GWNBR sum local"),
  AIC = c(AIC_global, AIC_sum_local))

```