


**PEMODELAN SPATIAL AUTOREGRESSIVE ERROR DENGAN PENALTI
LEAST ABSOLUTE SHRINKAGE AND SELECTION OPERATOR
MENGUNAKAN ALGORITMA COORDINATE DESCENT**

**SPATIAL AUTOREGRESSIVE ERROR MODELING WITH LEAST
ABSOLUTE SHRINKAGE AND SELECTION OPERATOR PENALTY USING
THE COORDINATE DESCENT ALGORITHM**



FADLAN AMIN

H062242004

- Dosen Pembimbing** : 1. Dr. Anna Islamiyati, S.Si., M.Si.
2. Dr. Nirwan, M.Si.
- Dosen Penguji** : 1. Prof. Dr. Dr. Georgina Maria Tinungki, M.Si.
2. Prof. Dr. Nurtiti Sunusi, S.Si., M.Si.
3. Prof. Dr. Erna Tri Herdiani, S.Si., M.Si.



**PROGRAM STUDI MAGISTER STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PEMODELAN SPATIAL AUTOREGRESSIVE ERROR DENGAN PENALTI
LEAST ABSOLUTE SHRINKAGE AND SELECTION OPERATOR
MENGUNAKAN ALGORITMA COORDINATE DESCENT**

FADLAN AMIN

H062242004



**PROGRAM STUDI MAGISTER STATISTIKA DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR**

2026

**PEMODELAN SPATIAL AUTOREGRESSIVE ERROR DENGAN PENALTI
LEAST ABSOLUTE SHRINKAGE AND SELECTION OPERATOR
MENGUNAKAN ALGORITMA COORDINATE DESCENT**

Tesis

Sebagai salah satu syarat untuk mencapai gelar magister

Program Studi Magister Statistika

Disusun dan diajukan oleh

FADLAN AMIN

H062242004

Kepada

**PROGRAM STUDI MAGISTER STATISTIKA DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

TESIS

PEMODELAN SPATIAL AUTOREGRESSIVE ERROR DENGAN PENALTI LEAST ABSOLUTE SHRINKAGE AND SELECTION OPERATOR MENGGUNAKAN ALGORITMA COORDINATE DESCENT

FADLAN AMIN
H062242004

Telah dipertahankan dihadapan Panitia Ujian Magister pada 18 Agustus 2026 dan
dinyatakan telah memenuhi syarat kelulusan

Pada

Program Studi Magister Statistika
Departemen Statistika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:

Pembimbing Utama,



Dr. Anna Islamiyati, S.Si., M.Si.
NIP. 19770808 200501 2 002

Pembimbing Pendamping,





Dr. Nirwan, M.Si.
NIP. 19630306 198702 1 002

Ketua Program Studi Magister Statistika,



Prof. Dr. Erna Tri Herdiani, S.Si., M.Si.
NIP. 19750429 200003 2 001

Dekan Fakultas Matematika dan Ilmu
Pengetahuan Alam
Universitas Hasanuddin,



Dr. Sci. Muhammad Zakir, M.Si.
NIP. 19701103 199903 1 001

PERNYATAAN KEASLIAN TESIS DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, tesis berjudul "Pemodelan Spatial Autoregressive Error dengan Penalti Least Absolute Shrinkage and Selection Operator Menggunakan Algoritma Coordinate Descent" adalah benar karya saya dengan arahan dari tim pembimbing Dr. Anna Islamiyati, S.Si., M.Si. dan Dr. Nirwan, M.Si.. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka tesis ini. Sebagian dari isi tesis ini telah dipublikasikan di Jurnal MethodsX sebagai artikel dengan judul "Spatial Regression on Literacy Rate in South Sulawesi with Least Absolute Shrinkage and Selection Operator using Coordinate Descent Algorithm". Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan tesis ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa tesis ini kepada Universitas Hasanuddin.

Makassar, 18 Agustus 2026



FADLAN AMIN
NIM H062242004

Ucapan Terima Kasih

Puji syukur penulis panjatkan kepada Allah *Subhanahu Wa Ta'ala* atas segala limpahan rahmat, hidayah, dan karunia-Nya sehingga penulis dapat menyelesaikan Tesis ini yang berjudul "Pemodelan Spatial Autoregressive Error dengan Penalti Least Absolute Shrinkage and Selection Operator Menggunakan Algoritma Coordinate Descent". Shalawat dan salam senantiasa tercurahkan kepada baginda Rasulullah *Shallallahu 'Alaihi Wa Sallam* beserta keluarga dan para sahabatnya.

Penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada Dr. Anna Islamiyati, S.Si., M.Si. dan Dr. Nirwan, M.Si. selaku Pembimbing yang dengan penuh kesabaran telah meluangkan waktu dan pemikirannya, memberikan motivasi, dorongan semangat, dan bimbingan kepada penulis selama proses penulisan tugas akhir ini. Terima kasih kepada Prof. Dr. Dr. Georgina Maria Tinungki, M.Si., Prof. Dr. Nurtiti Sunusi, S.Si., M.Si., dan Prof. Dr. Erna Tri Herdiani, S.Si., M.Si., selaku Tim Penguji yang senantiasa memberikan saran dan kritikan yang membangun dalam penyempurnaan penulisan tugas akhir ini. Terima kasih kepada Pimpinan Universitas Hasanuddin, Fakultas MIPA, Departemen Statistika, Jajaran Dosen, dan Staf Departemen Statistika yang telah memfasilitasi, memberikan ilmu bermanfaat, dan membantu penulis selama menempuh studi.

Penghargaan dan ucapan terima kasih yang tulus juga penulis ucapkan kepada kedua orang tua penulis yang tercinta, Ibunda Hj. A. Haryati Yusuf, S.P. dan Ayahanda Dr. H. Muhammad Amin, S.Si., M.Eng. yang telah memberikan kasih sayang, dukungan, semangat, dan doa yang senantiasa mengiringi langkah penulis. Terima kasih juga kepada Nahdiah Amin, Fakhri Amin, dan Faqih Amin sebagai saudara saya yang senantiasa menjadi tempat berdiskusi, bersunda-gurau, dan bercanda-tawa. Terima kasih kepada keluarga besar teman-teman seperjuangan Magister Statistika yang senantiasa diskusi dan komunikasi dimanapun dan kapanpun.

Penulis menyadari bahwa masih banyak kekurangan dalam penyusunan tugas akhir ini, untuk itu dengan segala kerendahan hati penulis memohon maaf. Akhir kata, semoga tulisan ini dapat memberikan manfaat untuk berbagai pihak.

Penulis,

Fadlan Amin

ABSTRAK

FADLAN AMIN. Pemodelan Spatial Autoregressive Error dengan Penalti Least Absolute Shrinkage and Selection Operator Menggunakan Algoritma Coordinate Descent (dibimbing oleh Dr. Anna Islamiyati, S.Si., M.Si., dan Dr. Nirwan Ilyas, M.Si.).

Latar belakang. Angka Melek Huruf (AMH) merupakan salah satu indikator penting dalam menggambarkan kualitas sumber daya manusia dan keberhasilan pembangunan sektor pendidikan. Perbedaan kondisi sosial ekonomi antarwilayah dapat menyebabkan variasi nilai AMH serta membentuk pola keterkaitan antarwilayah. Dalam analisis data spasial, ketergantungan geografis dan hubungan antarvariabel prediktor yang kompleks dapat menyebabkan ketidakstabilan estimasi model regresi. Model Spatial Autoregressive Error (SAE) mampu mengakomodasi pengaruh spasial pada residual, sedangkan penalti LASSO dapat mengatasi multikolinearitas melalui seleksi variabel. **Tujuan.** Penelitian ini bertujuan memperoleh estimasi parameter model SAE dengan penalti LASSO menggunakan algoritma Coordinate Descent serta menentukan faktor yang memengaruhi angka melek huruf di Provinsi Sulawesi Selatan. **Metode.** Estimasi parameter spasial SAE dilakukan menggunakan Maximum Likelihood Estimation. Parameter spasial yang diperoleh digunakan untuk melakukan transformasi spasial terhadap variabel respon dan prediktor. Selanjutnya, estimasi koefisien regresi dilakukan menggunakan penalti LASSO dengan algoritma Coordinate Descent melalui fungsi *cv.glmnet*. **Hasil.** Estimasi model dengan algoritma Coordinate Descent mampu melakukan seleksi variabel yang kuat dibandingkan dengan model lain seperti LARS, namun tetap mampu memberikan performa yang paling baik dengan perolehan nilai AIC dan BIC yang diperoleh berturut-turut 28,654 dan 40,435. **Kesimpulan.** Pendekatan SAE dengan penalti LASSO menggunakan algoritma Coordinate Descent mampu melakukan seleksi variabel pada pemodelan angka melek huruf di Sulawesi Selatan, sehingga diperoleh faktor yang berpengaruh adalah Produk Domestik Regional Bruto (PDRB), Kepadatan Penduduk, Tingkat Pengangguran Terbuka (TPT), Rata-rata Lama Sekolah (RLS), dan Harapan Lama Sekolah (HLS).

Kata kunci: Spatial Autoregressive Error, LASSO, Coordinate Descent, Maximum Likelihood, Angka Melek Huruf.

ABSTRACT

FADLAN AMIN. Spatial Autoregressive Error Modeling with Least Absolute Shrinkage and Selection Operator Penalty Using the Coordinate Descent Algorithm (supervised by Dr. Anna Islamiyati, S.Si., M.Si., and Dr. Nirwan Ilyas, M.Si.).

Background. Literacy Rate (LR) is one of the important indicators reflecting human resource quality and the success of educational development. Differences in socioeconomic conditions between regions can lead to variations in LR values and create spatial relationships among regions. In spatial data analysis, geographical dependence and complex relationships among predictor variables can cause instability in regression model estimation. The Spatial Autoregressive Error (SAE) model can accommodate spatial effects in residuals, while the LASSO penalty can overcome multicollinearity through variable selection. **Objective.** This study aims to estimate the parameters of the SAE model with LASSO penalty using the Coordinate Descent algorithm and to identify factors influencing the literacy rate in South Sulawesi Province. **Methods.** The spatial parameter estimation of the SAE model was performed using Maximum Likelihood Estimation. The obtained spatial parameter was then used to conduct spatial transformation on the response and predictor variables. Subsequently, regression coefficient estimation was carried out using the LASSO penalty with the Coordinate Descent algorithm implemented through the *cv.glmnet* function. **Results.** The estimation using the Coordinate Descent algorithm was able to perform effective variable selection compared with other models, such as LARS, while still providing the best performance with AIC and BIC values of 28.654 and 40.435, respectively. **Conclusion.** The SAE model with LASSO penalty using the Coordinate Descent algorithm is capable of performing variable selection in modeling literacy rates in South Sulawesi Province. The influential factors identified were Gross Regional Domestic Product (GRDP), Population Density, Open Unemployment Rate (OUR), Mean Years of Schooling (MYS), and Expected Years of Schooling (EYS).

Keywords: Spatial Autoregressive Error, LASSO, Coordinate Descent, Maximum Likelihood, Literacy Rate.

DAFTAR ISI

HALAMAN JUDUL	i
PERNYATAAN PENGAJUAN	ii
HALAMAN PENGESAHAN	iii
PENYATAAN KEASLIAN TESIS	iv
UCAPAN TERIMA KASIH	v
ABSTRAK	vi
DAFTAR ISI	viii
DAFTAR TABEL	x
DAFTAR GAMBAR	xi
DAFTAR LAMPIRAN	xii
BAB I PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	3
1.3. Batasan Masalah	3
1.4. Tujuan Penelitian	3
1.5. Manfaat Penelitian	3
1.6. Tinjauan Pustaka	4
1.6.1. Multikolinearitas	4
1.6.2. Autokorelasi Spasial	4
1.6.3. Lagrange Multiplier Test	5
1.6.4. Spatial Autoregressive Error Model	5
1.6.5. Estimasi Parameter Spatial Autoregressive Error Model	6
1.6.6. <i>Least Absolute Shrinkage and Selection Operator</i>	8
1.6.7. Spatial Autoregressive Error Model dengan Penalti LASSO	9
1.6.8. Algoritma <i>Coordinate Descent</i>	9
1.6.9. Uji Kelayakan Model	10
1.6.10. Angka Melek Huruf	10
1.7. Kerangka Konseptual	11
BAB II METODOLOGI PENELITIAN	12

2.1. Sumber Data.....	12
2.2. Variabel Penelitian	12
2.3. Analisis Data	12
2.4. Diagram Alir	13
BAB III Hasil dan Pembahasan	14
3.1. Estimasi Parameter Spatial Autoregressive Error dengan Penalti LASSO Menggunakan Algoritma Coordinate Descent.....	14
3.2. Penerapan Model SAE-LASSO dengan Coordinate Descent pada Angka Melek Huruf di Sulawesi Selatan tahun 2022.....	16
3.2.1. Eksplorasi Data	16
3.2.2. Pembentukan Matriks Pembobot.....	18
3.2.3. Analisis Kluster LISA	20
3.2.4. Uji Autokorelasi Spasial	21
3.2.5. Uji Multikolineritas	22
3.2.6. Pemodelan Angka Melek Huruf	23
BAB IV KESIMPULAN DAN SARAN	26
4.1. Kesimpulan	26
4.2. Saran	26
DAFTAR PUSTAKA.....	28
LAMPIRAN.....	32

DAFTAR TABEL

Nomor Urut	Halaman
Tabel 1. Variabel Penelitian.....	12
Tabel 2. Statistik Deskriptif dari Data	16
Tabel 3. Pengujian Indeks Moran.....	21
Tabel 4. Pengujian Lagrange Multiplier	21
Tabel 5. Pengujian Multikolineritas.....	23
Tabel 6. Estimasi Parameter OLS, SAE, dan SAE-LASSO dengan Algoritma LARS dan CD.....	24
Tabel 7. Kebaikan Model.....	25

DAFTAR GAMBAR

Nomor Urut	Halaman
Gambar 1. Kerangka Konseptual.....	11
Gambar 2. Diagram Alir Penelitian.....	13
Gambar 3. Pola Sebaran Angka Melek Huruf di Sulawesi Selatan	17
Gambar 4. Pemetaan Akses Jalan Pinrang – Enrekang – Tana Toraja	18
Gambar 5. Visualisasi Matriks Pembobot Antarwilayah di Sulawesi Selatan: (a) Akses Langsung, (b) Akses Step 1-city	19
Gambar 6. Pemetaan LISA Cluster Antarwilayah di Sulawesi Selatan.....	20
Gambar 7. Heatmap Korelasi dari Data	22

DAFTAR LAMPIRAN

Nomor Urut	Halaman
Lampiran 1. Data Penelitian	33
Lampiran 2. Matriks Pembobot Spasial	35

BAB I PENDAHULUAN

1.1. Latar Belakang

Regresi spasial merupakan teknik analisis pemodelan yang dilakukan terhadap data yang memiliki dimensi geografis, karena kepekaan model terhadap pola ketergantungan spasial pada unit observasi. Ketergantungan ini muncul akibat kedekatan geografis, kemiripan demografis, atau hubungan sistemik antardaerah. Dalam data spasial, respon di suatu area kerap kali dipengaruhi oleh kondisi di wilayah sekitarnya, sehingga asumsi independensi antarobservasi menjadi tidak valid. Untuk mengakomodasi isu ini, model regresi spasial seperti *Spatial Autoregressive Error* (SAE) menciptakan sebuah parameter autokorelasi spasial pada error, sehingga residual model lebih realistis merepresentasikan pola geografis yang tidak dijelaskan variabel prediktor (Anselin, 1988).

Pemodelan SAE memberikan interpretasi yang akurat dibandingkan dengan regresi klasik, karena ikut memperhitungkan efek spasial dalam pemodelan. Namun, data-data yang tersedia saat ini biasanya termasuk data dengan dimensi tinggi. Hal ini menjadi tantangan tersendiri dalam pemodelan SAE, karena SAE sangat rentan mengalami overfitting ketika prediktor sangat banyak atau terjadi multikolinearitas. Multikolinearitas dapat menyebabkan koefisien regresi menjadi tidak stabil dan interpretasi model menjadi bias. Dalam mengatasi ini, biasanya model regresi akan dikenakan regularisasi untuk mengatasi efek pada koefisien (Al-Momani dkk., 2017).

Metode *Least Absolute Shrinkage and Selection Operator* (LASSO) menjadi solusi bagi metode regularisasi modern. LASSO melakukan dua fungsi secara bersamaan, yaitu menyusutkan (*shrinkage*) nilai koefisien melalui penalti L1 serta melakukan seleksi variabel dengan mengarahkan sebagian koefisien ke nol (Song dkk., 2021). Sehingga, LASSO tidak hanya mengurangi risiko overfitting pada data berdimensi tinggi, tetapi juga membantu mengidentifikasi variabel paling penting yang benar-benar berkontribusi pada variasi variabel respon (Wen dkk., 2018). Integrasi LASSO ke dalam model SAE melahirkan model SAE-LASSO atau *penalized spatial autoregressive error model*. Model ini mengadaptasi keunggulan regularisasi LASSO ke dalam regresi spasial, memungkinkan estimasi parameter tetap efisien meski jumlah prediktor sangat besar atau hubungan antarprediktor kompleks (Huang dkk., 2010). SAE-LASSO tidak hanya menangani masalah seleksi variabel secara otomatis, tetapi juga mempertahankan keunggulan SAE dalam mengoreksi autokorelasi spasial pada residual, sehingga tetap valid secara statistik untuk data yang memiliki pola spasial kuat (Cai dkk., 2019). Dalam implementasinya, proses estimasi parameter penalti dapat dilakukan dengan berbagai algoritma optimisasi seperti *Least Angle Regression* (LARS) (Efron dkk., 2004) maupun *Coordinate Descent* (CD) (Friedman dkk., 2010).

Namun, pada data spasial yang berukuran besar dan bersifat multikolinearitas, algoritma LARS seringkali menghadapi keterbatasan komputasi karena setiap langkahnya memerlukan operasi matriks berskala penuh dan perhitungan yang kompleks (Sherina & Sagala, 2025). Sebaliknya, *Coordinate Descent* menawarkan pendekatan iteratif yang lebih sederhana dan efisien, dengan memperbarui satu

koefisien pada satu waktu sambil menahan yang lain tetap konstan. Pendekatan ini mampu mengakomodasi regularisasi L1 secara lebih stabil, bahkan untuk model yang melibatkan penalti tambahan atau komponen spasial yang kompleks (Ohishi dkk., 2025). Selain itu, *Coordinate Descent* memiliki keunggulan dalam hal konvergensi numerik dan skalabilitas ketika diterapkan pada model spasial berdimensi tinggi, karena tidak memerlukan dekomposisi matriks besar di setiap iterasi (Ma dkk., 2023).

Dalam analisis data spasial yang melibatkan banyak variabel sosial ekonomi dan lingkungan, tantangan utama yang sering dihadapi adalah masalah multikolinearitas serta autokorelasi spasial yang kompleks (Hou dkk., 2024). Kondisi ini menuntut penggunaan model yang tidak hanya mampu mengoreksi ketergantungan spasial, tetapi juga dapat melakukan seleksi variabel secara efisien agar estimasi menjadi stabil dan interpretasi model lebih tepat (Gonella dkk., 2022). Pendekatan ini sangat relevan apabila diterapkan dalam konteks kajian sosial-ekonomi (Ketut dkk., 2023), khususnya dalam memahami faktor-faktor yang memengaruhi angka melek huruf. Angka melek huruf (AMH) merupakan indikator yang menggambarkan kemampuan dasar penduduk dalam membaca dan menulis, yang menjadi salah satu ukuran penting kualitas sumber daya manusia. Secara umum, angka melek huruf didefinisikan sebagai persentase penduduk berusia 15 tahun ke atas yang mampu membaca dan menulis huruf Latin atau huruf lainnya dengan pemahaman terhadap teks sederhana dalam kehidupan sehari-hari (Bekti dkk., 2014). Menurut Badan Pusat Statistik (BPS), indikator ini dihitung dengan membandingkan jumlah penduduk melek huruf terhadap total penduduk dalam kelompok usia yang sama, kemudian dikalikan seratus untuk memperoleh nilai dalam bentuk persentase. Semakin tinggi nilai AMH, semakin besar proporsi masyarakat yang memiliki kemampuan literasi dasar, yang pada gilirannya mencerminkan keberhasilan pembangunan sektor pendidikan dan peningkatan akses terhadap informasi. Sebaliknya, rendahnya angka melek huruf menunjukkan masih adanya hambatan dalam pemerataan pendidikan, keterbatasan fasilitas pembelajaran, maupun kesenjangan sosial ekonomi antarwilayah. Oleh karena itu, AMH sering digunakan sebagai variabel utama dalam kajian pembangunan manusia, sosial, dan ekonomi, serta menjadi indikator penting dalam pengukuran kemajuan suatu daerah.

Penelitian terkait isu ini sudah kerap dilakukan oleh peneliti-peneliti nasional maupun mancanegara. Jimsan melakukan pemodelan terhadap angka melek huruf antarprovinsi di pulau Sulawesi. Hasil penelitiannya menunjukkan performa dari model yang dibangunnya mampu menangkap variabel regresi dengan MAPE 0.59% (Jimsan dkk., 2024). Jogani juga melakukan analisis secara spasial terhadap program edukasi dan literasi di Indonesia. Jogani menggunakan pemodelan SAE dan Spatial Durbin Error Model (SDEM) dan menunjukkan performa yang baik dalam prediksi (Jogani, 2021). Zhang juga memodelkan 10 indikator performa matematika siswa dengan 19 variabel prediktor. Pemodelan yang dilakukan oleh Zhang menunjukkan hasil yang baik dalam prediksi angka literasi. Penelitian Zhang juga menunjukkan adanya perbedaan literasi di tiap daerah diakibatkan adanya perbedaan secara kultur dan asumsi sosial terhadap pendidikan, sehingga mengisyaratkan agar penelitian serupa dilanjutkan dengan mempertimbangkan aspek tersebut (Y. Zhang & Cutumisu, 2024).

Meskipun beberapa penelitian telah menggunakan SAE atau model spasial lain untuk memodelkan angka melek huruf, belum ada penelitian yang mengintegrasikan

SAE dengan penalti LASSO menggunakan algoritma Coordinate Descent untuk menangani multikolinearitas dan seleksi variabel pada data spasial berdimensi tinggi (Yun, 2014). Oleh karena itu, diperlukan pendekatan baru pada regresi spasial, khususnya Spatial Autoregressive Error Model (SAE), untuk menangkap pengaruh ketetanggaan geografis tersebut. Namun, karena banyaknya variabel sosial-ekonomi yang saling berkorelasi, estimasi model spasial memerlukan teknik regularisasi seperti LASSO untuk menghindari overfitting dan memastikan seleksi variabel yang efisien. Dengan demikian, pengembangan SAE-LASSO menggunakan algoritma Coordinate Descent diharapkan dapat memberikan estimasi yang lebih stabil dan akurat dalam memetakan faktor-faktor yang memengaruhi angka melek huruf di Sulawesi Selatan. Oleh sebab itu, peneliti ingin melakukan penelitian dengan judul “Pemodelan Spatial Autoregressive Error dengan Penalti Least Absolute Shrinkage and Selection Operator Menggunakan Algoritma Coordinate Descent” untuk mengkaji faktor-faktor yang mempengaruhi angka melek huruf di kabupaten/kota di Sulawesi Selatan.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dari penelitian ini adalah:

1. Bagaimana estimasi parameter dari spatial autoregressive error dengan penalti LASSO menggunakan algoritma Coordinate Descent?
2. Apa-apa faktor yang mempengaruhi angka melek huruf di Sulawesi Selatan?

1.3. Batasan Masalah

Berdasarkan permasalahan yang telah diuraikan, batasan masalah dari penelitian ini adalah:

1. Data yang digunakan adalah data faktor sosio-ekonomi 1 tahun (2022) sehingga tidak melihat adanya faktor antarwaktu.
2. Matriks pembobot yang digunakan didasarkan pada ketetanggaan.
3. Algoritma *Coordinate Descent* bekerja secara siklis.

1.4. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, tujuan dari penelitian ini adalah:

1. Menentukan estimasi parameter dari spatial autoregressive error dengan penalti LASSO menggunakan algoritma Coordinate Descent.
2. Menentukan faktor yang mempengaruhi angka melek huruf di Sulawesi Selatan menggunakan model spatial autoregressive error dengan penalti LASSO yang diestimasi menggunakan algoritma Coordinate Descent.

1.5. Manfaat Penelitian

Manfaat yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Memberikan pengetahuan dan wawasan dalam bidang statistika khususnya yang berhubungan dengan metode spatial autoregressive error model dengan penalti LASSO.

2. Memberikan informasi bagi Pemerintah di Indonesia serta dinas terkait sehingga dapat dijadikan sebagai bahan acuan dalam pengambilan setiap kebijakan.

1.6. Tinjauan Pustaka

1.6.1. Multikolinearitas

Multikolinieritas menunjukkan adanya hubungan linier yang sangat kuat antara variabel prediktor dalam suatu model regresi. Keberadaan multikolinieritas dapat mengakibatkan ketidakstabilan koefisien regresi, sehingga tidak lagi mencerminkan secara akurat pengaruh dari variabel independen (Lee dkk., 2015). Selain itu, keberadaan multikolinieritas juga cenderung meningkatkan besarnya nilai error dalam estimasi, yang dapat mengganggu validitas hasil analisis. Pendekatan kuadrat terkecil menjadi kurang tepat karena adanya multikolinieritas. Salah satu cara untuk mengidentifikasi multikolinearitas adalah dengan menghitung nilai *Variance Inflation Factor* (VIF). Kolinieritas dianggap tinggi jika VIF memiliki nilai lebih dari 10. Nilai VIF dapat didefinisikan sebagai berikut:

$$VIF = \frac{1}{(1 - R_j^2)} \quad (1)$$

dengan R_j^2 merupakan koefisien determinasi antara variabel prediktor ke- j dengan variabel prediktor yang lainnya dengan $j = 1, 2, \dots, k$.

1.6.2. Autokorelasi Spasial

Autokorelasi spasial menunjukkan adanya korelasi dari suatu wilayah terhadap wilayah lainnya. Untuk melihat nilai autokorelasi spasial secara global, digunakan Indeks Moran dengan hipotesis:

H_0 : tidak terjadi autokorelasi

H_1 : terjadi autokorelasi

Memperoleh nilai indeks Moran dapat dilakukan dengan menggunakan Persamaan (2):

$$I = \frac{n \sum_{i \neq j}^n w_{ij} (y_i - \bar{y})(y_j - \bar{y})}{S_0 \sum_{i=1}^n (y_i - \bar{y})^2} \quad (2)$$

dengan:

$$S_0 = \sum_{i=1}^n \sum_{j=1}^n w_{ij}; S_1 = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (w_{ij} + w_{ji})^2;$$

$$S_2 = \sum_{i=1}^n \left(\sum_{j=1}^n w_{ij} + \sum_{j=1}^n w_{ji} \right)^2$$

Statistik Uji dari indeks moran adalah:

$$|Z_{hitung}| = \frac{I - E(I)}{\sqrt{Var(I)}} \sim N(0,1) \quad (3)$$

dengan:

$$E(I) = -\frac{1}{n-1} \quad Var(I) = \frac{n^2 S_1 - n S_2 + 3 S_0}{(n^2 - 1) S_0^2} - [E(I)]^2$$

Apabila $Z_{hitung} > Z_{tabel}$, maka H_0 ditolak. Maka data diasumsikan mengalami autokorelasi spasial (Rochana dkk., 2015).

Nilai indeks moran bernilai kisaran -1 sampai 1. Nilai 0 menandakan data tidak mengalami autokorelasi spasial, berarti daerah tersebut tidak bersifat kelompok dalam wilayahnya. Indeks moran bernilai positif menandakan daerah-daerah pada wilayah tersebut saling berpengaruh secara positif. Suatu daerah yang mengalami kenaikan nilai, akan meningkatkan nilai pada daerah tetangganya. Indeks moran yang bernilai negatif, menandakan daerah-daerah pada wilayah tersebut saling berpengaruh negatif, yang berarti meningkatnya nilai suatu wilayah akan menurunkan nilai pada wilayah lainnya (Barde dkk., 2025).

1.6.3. Lagrange Multiplier Test

Autokorelasi atau efek ketergantungan dapat terjadi pada residual dalam data. Untuk menguji efek ketergantungan pada variabel respon, digunakan Uji *Lagrange Multiplier* (LM) sebagai dasar untuk memilih model regresi spasial yang sesuai dengan kondisi ketergantungannya (LeSage & Pace, 2009). Pengujian LM pada error dilakukan dengan hipotesis:

$H_0: \lambda = 0$ (tidak ada autokorelasi dalam residual)

$H_1: \lambda \neq 0$ (terdapat autokorelasi dalam residual)

Statistik Uji:

$$LM_{error} = \frac{[(e^T W e)/(e^T e/N)]^2}{[tr(W^T W + W^2)]} \sim \chi^2_{(1-\alpha);1} \quad (4)$$

Untuk pengujian LM pada lag dilakukan dengan hipotesis:

$H_0: \rho = 0$ (tidak ada autokorelasi dalam lag)

$H_1: \rho \neq 0$ (terdapat autokorelasi dalam lag)

Statistik Uji:

$$LM_{lag} = \frac{[(e^T W y)/(e^T e/N)]^2}{\left[\frac{(W X \hat{\beta})^2 M(W X \hat{\beta})}{(e^T e/N)} \right] + [tr(W^T W + W^2)]} \sim \chi^2_{(1-\alpha);1} \quad (5)$$

dengan $M = I - X(X^T X)^{-1} X^T$, Kriteria uji untuk kedua uji adalah menolak H_0 ketika nilai LM_{lag} lebih besar dari $\chi^2_{(1-\alpha);1}$. Apabila LM_{lag} signifikan, maka model yang terbentuk adalah model *Spatial Autoregressive* (Azizah, 2023). Kriteria uji pada error adalah menolak H_0 ketika nilai LM_{error} lebih besar dari $\chi^2_{(1-\alpha);1}$. Apabila LM_{error} signifikan, maka model yang terbentuk adalah *spatial autoregressive error model*.

1.6.4. Spatial Autoregressive Error Model

Spatial autoregressive error model (SAE) adalah model yang menggabungkan model regresi linear dengan spasial residual dengan menggunakan data yang bertipe *cross section*. Model SAE memberikan interpretasi pada data yang mengalami autokorelasi pada residual (Su & Yang, 2015). Persaman model SAE dapat dituliskan sebagai berikut:

$$y = X\beta + u \quad (6)$$

$$u = \lambda W u + \varepsilon \quad (7)$$

dengan $\varepsilon \sim NM(0, \sigma^2 \Omega(\lambda))$ dan λ adalah koefisien spatial error.

W adalah matriks pembobot spasial yang digunakan dalam memodelkan regresi spasial seperti model SAE (C. Zhang, 2012). Matriks pembobot dari model SAE menggunakan pembobotan dengan rumus:

$$w_{ij}^* = \begin{cases} 2, & \text{ketika } j \text{ memiliki akses langsung dari } i \\ 1, & \text{ketika } j \text{ memiliki akses yang melewati satu wilayah dari } i \\ 0, & \text{lainnya} \end{cases} \quad (8)$$

Pembobot matriks spasial perlu distandarisasi dengan rumus:

$$w_{ij} = \begin{cases} \frac{w_{ij}^*}{\sum_{j=1}^n w_{ij}^*}, & i \neq j \\ 0, & i = j \end{cases} \quad (9)$$

Matriks pembobot yang terstandarisasi akan memiliki nilai dari rentang 0 hingga 1 sehingga tiap baris dalam pembobotnya menghasilkan jumlah nilai sama dengan 1.

1.6.5. Estimasi Parameter Spatial Autoregressive Error Model

Estimasi model SAE dimulai dengan menyusun model regresi linear dasar, dengan residual (*error*) yang dimodelkan memiliki korelasi spasial. Biasanya korelasi tersebut merepresentasikan interaksi antar lokasi yang berdekatan dalam ruang. Model dasar menggunakan Persamaan (6), dengan model residual mengikuti struktur dependensi spasial sesuai Persamaan (7) (Anselin & Bera, 1998). Model tersebut kemudian dapat dituliskan dalam bentuk error yang sudah memperhitungkan bobot spasial:

$$u = (I - \lambda W)^{-1} \varepsilon \quad (10)$$

Agar $(I - \lambda W)$ dapat diinvers, determinannya harus tidak sama dengan nol:

$$|I - \lambda W| \neq 0$$

Determinannya dapat dinyatakan dalam bentuk nilai eigen (ω_i) dari W :

$$|I - \lambda W| = \prod_{i=1}^n (1 - \lambda \omega_i)$$

Dari persamaan ini terlihat bahwa matriks $(I - \lambda W)$ akan singular (tidak dapat diinvers) jika terdapat nilai eigen ω_i sehingga $1 - \lambda \omega_i = 0$, atau:

$$\lambda = \frac{1}{\omega_i}$$

Dengan demikian, agar model stabil, λ harus berada di luar nilai-nilai tersebut, yaitu:

$$\lambda \in \left(\frac{1}{\omega_{\min}}, \frac{1}{\omega_{\max}} \right)$$

dengan $\omega_{\min}$ dan $\omega_{\max}$ adalah nilai eigen minimum dan maksimum dari matriks W .

Nilai eigen atau λ ini menggambarkan “kekuatan konektivitas spasial” dalam sistem. Terdapat 2 kondisi terkait dengan nilai λ ini, jika $|\lambda|$ mendekati batas, maka korelasi spasialnya sangat kuat dan model bisa tidak stabil. Jika $|\lambda|$ terlalu kecil (mendekati 0), maka model mendekati OLS biasa, atau dikatakan efek spasial hampir tidak ada.

Hubungan ini menunjukkan bahwa nilai eigen berperan sebagai batas teoretis bagi λ untuk memastikan stabilitas dan validitas model spasial. Selanjutnya, estimasi awal parameter regresi dilakukan dengan *Ordinary Least Squares* (OLS). Proses ini menghasilkan dugaan awal parameter β . Namun, ketika terdapat autokorelasi spasial pada error, hasil estimasi OLS tidak lagi efisien. Menanggapi masalah dependensi

spasial pada error, pendekatan *Generalized Least Square* (GLS) memberikan gambaran teoritis mengenai transformasi model ketika error memiliki struktur kovarian tertentu. Pada model SAE, transformasi tersebut dilakukan melalui struktur spasial $(I - \lambda W)$ untuk mengakomodasi adanya korelasi spasial pada residual (Kelejian & Prucha, 1998). Sehingga model dapat diubah bentuknya dengan mentransformasi model menjadi:

$$\begin{aligned} y &= X\beta + (I - \lambda W)^{-1}\varepsilon \\ y - X\beta &= (I - \lambda W)^{-1}\varepsilon \\ (I - \lambda W)(y - X\beta) &= \varepsilon \\ (I - \lambda W)y - (I - \lambda W)X\beta &= \varepsilon \\ (I - \lambda W)y &= (I - \lambda W)X\beta + \varepsilon \\ y^* &= X^*\beta + \varepsilon \end{aligned} \quad (11)$$

dengan

$$X^* = (I - \lambda W)X \text{ dan } y^* = (I - \lambda W)y$$

Persamaan (12) dapat diselesaikan dengan memperoleh penduga parameter $\hat{\beta}$ yang meminimalkan jumlah kuadrat galat, yang dinyatakan sebagai:

$$S(\beta) = \varepsilon'\varepsilon = (y^* - X^*\beta)'(y^* - X^*\beta) \quad (13)$$

Untuk memperoleh nilai β yang meminimalkan fungsi tersebut, dilakukan turunan pertama terhadap β dan disetarakan dengan nol:

$$\frac{\partial S(\beta)}{\partial \beta} = -2X^{*'}y^* + 2X^{*'}X^*\beta = 0$$

Sehingga diperoleh sistem persamaan yang dikenal sebagai persamaan normal (*normal equations*):

$$X^{*'}X^*\beta = X^{*'}y^* \quad (14)$$

Dengan mengalikan kedua ruas dengan $[X'X]^{-1}$, maka diperoleh persamaan koefisien regresi:

$$\hat{\beta} = [X^{*'}X^*]^{-1}X^{*'}y^* \quad (15)$$

Namun, parameter λ yang mengukur kekuatan dependensi spasial antar residual tidak dapat diperoleh secara langsung melalui GLS. Oleh karena itu, dalam model SAE parameter spasial λ tidak diestimasi menggunakan GLS, melainkan melalui *Maximum Likelihood Estimation* (MLE), karena parameter tersebut memengaruhi struktur kovarian error dan determinan matriks spasial yang didasarkan pada asumsi bahwa error ε berdistribusi normal multivariat $\varepsilon \sim NM(0, \sigma^2\Omega(\lambda))$.

Fungsi densitas dari y ketika $y \sim N(\mu, \Sigma)$ adalah

$$f(y) = \frac{1}{(2\pi)^{\frac{n}{2}}|\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(y^* - X^*\beta)'(y^* - X^*\beta)\right) \quad (16)$$

Substitusi $\Sigma = \sigma^2\Omega(\lambda)$ sehingga

$$f(y) = \frac{1}{(2\pi)^{\frac{n}{2}}|\sigma^2\Omega(\lambda)|^{\frac{1}{2}}} \exp\left(-\frac{(y^* - X^*\beta)'(y^* - X^*\beta)}{2\sigma^2}\right) \quad (17)$$

Ambil log untuk mendapatkan log-likelihood $\ell(\theta)$ (dengan $\theta = (\beta, \sigma^2, \lambda)$):

$$\ell(\theta) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2}\log|\Omega(\lambda)| - \frac{(y^* - X^*\beta)'(y^* - X^*\beta)}{2\sigma^2} \quad (18)$$

dengan

$$\Omega(\lambda) = [(I - \lambda W)'(I - \lambda W)]^{-1} \quad (19)$$

Estimasi nilai λ dilakukan secara simultan bersamaan dengan estimasi nilai β_{SAE} dengan langkah iterasi sampai diperoleh hasil yang konvergen, sebagai berikut:

1. Mencari nilai y^* dan X^* dengan nilai $\lambda(0) = 0$ sebagai inisiasi awal
2. Memperoleh nilai β_{SAE}
3. Mencari nilai $\epsilon_{SAE} = y^* - X^* \beta_{SAE}$
4. Dengan nilai ϵ_{SAE} , mencari nilai λ optimal yang memaksimumkan likelihood pada Persamaan (18).
5. Ulangi langkah 1-4 tersebut hingga diperoleh nilai λ yang konvergen, dengan syarat konvergensi $(|\lambda^{(n+1)} - \lambda^{(n)}| < 0.0001)$. Jika tidak, maka
6. Dengan λ optimal, estimasi β menggunakan Persamaan (15).

1.6.6. Least Absolute Shrinkage and Selection Operator

Least Absolute Shrinkage and Selection Operator (LASSO) merupakan metode regresi hasil dari pengembangan regresi ridge yang mampu untuk mengatasi masalah multikolinearitas. Metode ini pertama kali diperkenalkan oleh Robert Tibshirani (1996). Regresi LASSO digunakan untuk *shrinkage* yaitu menyusutkan koefisien regresi mendekati angka nol atau menjadi tepat nol. *Selection operator*, yaitu menyeleksi variabel-variabel prediktor sehingga menghasilkan model dengan variabel optimal (Friedman dkk., 2007).

Estimasi koefisien regresi LASSO ($\hat{\beta}_{LASSO}$) diperoleh dengan cara meminimumkan jumlah kuadrat galat dengan fungsi kendala $\sum_{k=1}^p |\beta_k| \leq t$. Persamaannya sebagai berikut (Tibshirani, 1996):

$$\beta_{LASSO} = \operatorname{argmin} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{k=1}^p x_{ik} \beta_k \right)^2 + \lambda_{LASSO} \sum_{k=1}^p |\beta_k| \right\} \quad (20)$$

y_i menyatakan variabel respon pengamatan ke- i , β_0 merupakan konstanta, β_k merupakan koefisien dari variabel prediktor ke- k , x_{ik} merupakan variabel prediktor, n menyatakan banyaknya observasi dan p merupakan banyaknya variabel prediktor dalam model.

Nilai t merupakan suatu besaran yang mengontrol besarnya penyusutan pada koefisien regresi LASSO. Nilai t dinamakan parameter tuning dengan nilai $t \geq 0$. Misalkan diketahui β_k merupakan estimasi OLS dengan nilai t_0 di denifisikan $t_0 = \sum_{k=1}^p |\beta_k|$, maka jika nilai $t < t_0$ akan menyebabkan koefisien OLS akan menyusut ke arah nol, dan memungkinkan beberapa koefisien tepat nol. Jika nilai $t \geq t_0$, maka koefisien regresi LASSO memberikan hasil yang sama dengan koefisien OLS (Zou, 2006).

Estimasi koefisien LASSO diperoleh dengan menentukan batas yang dibakukan yaitu $s = \frac{t}{\sum_{k=1}^p |\beta_k|}$ dengan $t = \sum_{k=1}^p |\beta_k|$ dan β_k adalah estimasi parameter untuk model penuh. Kemudian λ pada Persamaan (19) disebut sebagai parameter tuning yang berkorespondensi satu-satu dengan s artinya untuk setiap β_j^{LASSO} terdapat $\lambda \geq 0$ sedemikian sehingga nilai $t \geq t_0$ yang menghasilkan solusi β_j menghasilkan solusi β_j^{LASSO} juga.

1.6.7. Spatial Autoregressive Error Model dengan Penalti LASSO

Estimasi model SAE dengan penalti LASSO dilakukan melalui pendekatan transformasi spasial. Parameter spasial terlebih dahulu diestimasi menggunakan Maximum Likelihood pada model SAE, kemudian hasil transformasi digunakan dalam proses estimasi koefisien regresi menggunakan penalti LASSO. Persamaan (6) dan (7) serta (20) dapat dituliskan dalam bentuk likelihood dari model SAE-LASSO, sehingga dapat ditulis sebagai berikut:

$$L(\boldsymbol{\beta}, \lambda) = \frac{1}{n} \sum_{i=1}^n (Y_i - X\boldsymbol{\beta} - \lambda \mathbf{W}\mathbf{u})^2 + \lambda_{LASSO} \sum_{k=1}^p |\beta_k| \quad (21)$$

dengan $\lambda_{LASSO} > 0$ sebagai parameter regularisasi.

Solusi regresi LASSO tidak memiliki solusi eksplisit karena pada fungsi kendala regresi LASSO berbentuk fungsi mutlak yang tidak dapat diturunkan pada titik beloknya, sehingga prosedur yang dapat digunakan untuk mengatasi hal tersebut dengan menggunakan pemrograman kuadratik (Qi, 2016), salah satu metodenya adalah Coordinate Descent (Wright, 2015).

1.6.8. Algoritma *Coordinate Descent*

Algoritma *Coordinate Descent* (CD) merupakan algoritma yang digunakan untuk memecahkan masalah optimasi dengan meminimumkan nilai fungsi yang dapat diperoleh dari meminimalkan likelihood secara berurutan (Wu & Lange, 2008). Algoritma ini mudah untuk diterapkan dalam pemodelan karena melakukan estimasi untuk tiap satu koefisien dalam satu waktu (Shi dkk., 2017). Algoritma *Coordinate Descent* dapat digambarkan sebagai berikut:

1. Menentukan nilai awal koefisien $\beta^{(0)}$
2. Untuk setiap variabel $j = 1, 2, \dots, p$, menghitung residual parsial:

$$\mathbf{r}_j = \mathbf{y} - \sum_{k \neq j} \mathbf{X}_k \beta_k$$

3. Memperbarui koefisien menggunakan soft-thresholding:

$$\hat{\beta}_j = \frac{S(\mathbf{X}_j^T \mathbf{r}_j, \lambda_{LASSO})}{\mathbf{X}_j^T \mathbf{X}_j}$$

4. Proses iterasi dilakukan hingga koefisien konvergen.
5. Menentukan parameter penalti LASSO optimal menggunakan cross-validation melalui fungsi `cv.glmnet()`
6. Memilih variabel dengan:

$$\hat{\beta}_j \neq 0$$

7. Variabel terpilih yang memiliki nilai koefisien akan dimasukkan ke dalam model regresi.

Koefisien $\hat{\boldsymbol{\beta}}$ yang diperoleh merupakan solusi optimal LASSO, sebagian koefisien dapat bernilai nol merupakan variabel tidak terpilih, dan sisanya bernilai selain nol merupakan variabel terpilih (Saha & Tewari, 2010).

1.6.9. Uji Kelayakan Model

Metode yang digunakan dalam uji kelayakan model menggunakan nilai *Akaike Information Criterion* (AIC) yang dapat mengukur kebaikan dan kesesuaian model dalam menduga parameter sekaligus mencegah *overfitting*. Suatu model yang baik menunjukkan nilai AIC yang lebih kecil. Nilai AIC dapat dihitung melalui:

$$AIC = 2k - 2 \ln L(\beta) \quad (24)$$

dengan k adalah jumlah parameter yang digunakan dalam model dan $L(\beta)$ adalah maksimum logaritma likelihood.

Selain nilai AIC, metrik yang digunakan dalam pengujian kelayakan model adalah nilai *Bayesian Information Criterion* (BIC) yang memberikan akurasi berdasarkan sudut pandang bayesian. Nilai BIC dihitung melalui:


$$BIC = k \ln(n) - 2 \ln L(\beta) \quad (25)$$

kedua nilai ini memberikan gambaran terkait performa model sebagai landasan dalam pemilihan model terbaik (James dkk., 2021).

1.6.10. Angka Melek Huruf

Angka melek huruf (AMH) merupakan indikator yang menggambarkan kemampuan dasar penduduk dalam membaca dan menulis, yang menjadi salah satu ukuran penting kualitas sumber daya manusia. Secara umum, angka melek huruf didefinisikan sebagai persentase penduduk berusia 15 tahun ke atas yang mampu membaca dan menulis huruf Latin atau huruf lainnya dengan pemahaman terhadap teks sederhana dalam kehidupan sehari-hari (Badan Pusat Statistik Indonesia, 2025). Indikator ini dihitung dengan membandingkan jumlah penduduk melek huruf terhadap total penduduk dalam kelompok usia yang sama, kemudian dikalikan seratus untuk memperoleh nilai dalam bentuk persentase. Semakin tinggi nilai AMH, semakin besar proporsi masyarakat yang memiliki kemampuan literasi dasar, yang pada gilirannya mencerminkan keberhasilan pembangunan sektor pendidikan dan peningkatan akses terhadap informasi. Sebaliknya, rendahnya angka melek huruf menunjukkan masih adanya hambatan dalam pemerataan pendidikan, keterbatasan fasilitas pembelajaran, maupun kesenjangan sosial ekonomi antarwilayah. Oleh karena itu, AMH sering digunakan sebagai variabel utama dalam kajian pembangunan manusia, sosial, dan ekonomi, serta menjadi indikator penting dalam pengukuran kemajuan suatu daerah.

1.7. Kerangka Konseptual



Gambar 1. Kerangka Konseptual

BAB II METODOLOGI PENELITIAN

2.1. Sumber Data

Data yang digunakan dalam penelitian ini adalah data sosial-ekonomi di Sulawesi Selatan, diambil dari Badan Pusat Statistik (BPS) Provinsi Sulawesi Selatan tahun 2022.

2.2. Variabel Penelitian

Variabel yang digunakan terdiri dari 1 variabel respon dan 12 variabel prediktor yang disajikan melalui Tabel 1. Keseluruhan data telah disajikan pada Lampiran 1.

Tabel 1. Variabel Penelitian


Variabel	Nama	Satuan
Y	Angka Melek Huruf	%
X_1	Produk Domestik Regional Bruto	Juta Rupiah
X_2	Pengeluaran per Kapita	Juta Rupiah
X_3	Kepadatan Penduduk	Jiwa/km ²
X_4	Tingkat Pengangguran Terbuka	%
X_5	Rata-Rata Lama Sekolah	Tahun
X_6	Garis Kemiskinan	Juta Rupiah
X_7	Gini Ratio	-
X_8	Harapan Lama Sekolah	-
X_9	Jumlah Perpustakaan	-
X_{10}	Tingkat Kegemaran Membaca	%
X_{11}	Tingkat Partisipasi Angkatan Kerja	%
X_{12}	Persentase Penduduk Miskin	%

2.3. Analisis Data

Langkah-langkah yang dilakukan untuk menganalisis data dalam penelitian ini meliputi:

- 1) Estimasi Parameter Model SAE dengan penalti LASSO
Langkah-langkah estimasi parameter model sebagai berikut:
 1. Menentukan fungsi kepadatan peluang parameter.
 2. Membentuk fungsi likelihood dari fungsi kepadatan peluang dari parameter.
 3. Memaksimumkan fungsi likelihood dari model SAE dengan Maximum Likelihood untuk memperoleh nilai λ .
 4. Dengan nilai λ , melakukan transformasi pada variabel X dan y .
 5. Mengestimasi koefisien β yang terbentuk dari variabel hasil transformasi menggunakan algoritma Coordinate Descent.
- 2) Penerapan pada data angka melek huruf di Sulawesi Selatan tahun 2022
Langkah-langkah penerapannya sebagai berikut:
 1. Eksplorasi Data.
 2. Menguji autokorelasi spasial dan Lagrange Multiplier.
 3. Mendeteksi multikolinearitas dari model regresi dengan nilai VIF.
 4. Mengestimasi parameter model SAE dengan penalti LASSO dengan metode Maksimum Likelihood.
 5. Menguji signifikansi parameter dan menginterpretasikan model yang diperoleh.

2.4. Diagram Alir



Gambar 2. Diagram Alir Penelitian

BAB III

Hasil dan Pembahasan

3.1. Estimasi Parameter Spatial Autoregressive Error dengan Penalti LASSO Menggunakan Algoritma Coordinate Descent

Estimasi parameter model SAE-LASSO diawali dengan pembentukan likelihood dari model SAE yang berpenalti. Bentuk model dari Spatial Autoregressive Error dijabarkan di Persamaan (12), yakni:

$$\mathbf{y}^* = \mathbf{X}^* \boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

dengan $\mathbf{y}^*$ adalah variabel respon yang sudah ditransformasi, $\mathbf{X}^*$ adalah matriks variabel prediktor yang sudah ditransformasi berukuran $n \times (p + 1)$ dan $\boldsymbol{\beta}$ adalah koefisien regresi.

Parameter λ mengukur kekuatan dependensi spasial antar residual. Untuk memperoleh estimasi λ yang efisien dan konsisten, digunakan pendekatan *Maximum Likelihood Estimation* (MLE), yang didasarkan pada asumsi bahwa error $\boldsymbol{\varepsilon}$ berdistribusi normal multivariat $\boldsymbol{\varepsilon} \sim NM(0, \sigma^2 \Omega(\lambda))$. Berikut fungsi log-likelihood dari model SAE:

$$L(\boldsymbol{\beta}, \lambda, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2} \log|\Omega(\lambda)| - \frac{(\mathbf{y}^* - \mathbf{X}^* \boldsymbol{\beta})'(\mathbf{y}^* - \mathbf{X}^* \boldsymbol{\beta})}{2\sigma^2} \quad (26)$$

Setelah diperoleh nilai $\hat{\lambda}$ sebagai parameter spasial, maka transformasi pada variabel $\mathbf{X}$ dan $\mathbf{y}$ dapat dilakukan. Setelah transformasi spasial dilakukan menggunakan nilai $\hat{\lambda}$, maka estimasi parameter regresi dilakukan dengan meminimumkan fungsi objektif yang hanya bergantung pada parameter $\boldsymbol{\beta}$. Oleh karena itu, bagian fungsi objektif yang bergantung pada $\boldsymbol{\beta}$ ekuivalen dengan fungsi penalized least squares sehingga dapat dituliskan sebagai:

$$Q(\boldsymbol{\beta}) = \frac{1}{2} \|\mathbf{y}^* - \mathbf{X}^* \boldsymbol{\beta}\|^2 + \lambda_{LASSO} \sum_{j=1}^p |\boldsymbol{\beta}_j| \quad (27)$$

Parameter $\boldsymbol{\beta}$ pada model multivariate memiliki jumlah lebih dari satu tergantung jumlah variabel yang digunakan, sehingga estimasi parameter $\boldsymbol{\beta}$ turut dilakukan satu persatu, sehingga Persamaan (27) perlu dijabarkan khusus untuk $\boldsymbol{\beta}_j$, dengan membagi $\mathbf{X}^* \boldsymbol{\beta}$ menjadi:

$$\mathbf{X}^* \boldsymbol{\beta} = \mathbf{X}_j^* \boldsymbol{\beta}_j + \sum_{k \neq j} \mathbf{X}_k^* \boldsymbol{\beta}_k \quad (28)$$

Sehingga Persamaan (27) menjadi:

$$Q(\boldsymbol{\beta}_j) = \frac{1}{2} \left\| \mathbf{y}^* - \sum_{k \neq j} \mathbf{X}_k^* \boldsymbol{\beta}_k - \mathbf{X}_j^* \boldsymbol{\beta}_j \right\|^2 + \lambda_{LASSO} |\boldsymbol{\beta}_j| \quad (29)$$

Untuk menyederhanakan fungsi objektif tersebut, didefinisikan residual parsial sebagai:

$$\mathbf{r}_j = \mathbf{y}^* - \sum_{k \neq j} \mathbf{X}_k^* \boldsymbol{\beta}_k \quad (30)$$

Residual parsial adalah nilai yang dihasilkan dari selisih respon dan kontribusi variabel selain j . Substitusi residual parsial tersebut ke dalam Persamaan (29) menghasilkan:

$$Q(\beta_j) = \frac{1}{2} \|r_j - X_j^* \beta_j\|^2 + \lambda_{LASSO} |\beta_j| \quad (31)$$

Proses ini dilakukan karena algoritma CD hanya melakukan perbaruan pada satu koefisien β_j dalam satu waktu, sehingga variabel lain dianggap tetap. Setelah memperoleh Persamaan (31), dilakukan proses estimasi terhadap β_j .

Setelah fungsi objektif dinyatakan terhadap satu koordinat, langkah berikutnya adalah menentukan nilai β_j yang meminimumkan fungsi tersebut. Friedman dkk. (2010) menunjukkan bahwa solusi minimisasi dapat diperoleh melalui operator soft-thresholding sehingga setiap koefisien diperbarui secara bergantian hingga konvergen. Persamaan (31) diekspansi menjadi:

$$\begin{aligned} Q(\beta_j) &= \frac{1}{2} (r_j - X_j^* \beta_j)^T (r_j - X_j^* \beta_j) + \lambda_{LASSO} |\beta_j| \\ &= \frac{1}{2} (r_j^T r_j - 2X_j^{*T} \beta_j^T r_j + \beta_j^2 X_j^{*T} X_j^*) + \lambda_{LASSO} |\beta_j| \end{aligned}$$

Karena $r_j^T r_j$ konstan terhadap β_j , maka dapat dihilangkan dari estimasi, sehingga fungsi yang telah diminimumkan menjadi:

$$Q(\beta_j) = \frac{1}{2} \beta_j^2 X_j^{*T} X_j^* - X_j^{*T} \beta_j^T r_j^* + \lambda_{LASSO} |\beta_j| \quad (32)$$

Solusi dari fungsi objektif tersebut diperoleh menggunakan fungsi soft-thresholding:

$$\hat{\beta}_j = \frac{S(X_j^{*T} r_j^*, \lambda_{LASSO})}{X_j^{*T} X_j^*} \quad (33)$$

dengan $S(x, \lambda)$ adalah fungsi soft-thresholding yang didefinisikan sebagai:

$$S(x, \lambda) = \begin{cases} x - \lambda, & x > \lambda \\ 0, & |x| \leq \lambda \\ x + \lambda, & x < -\lambda \end{cases}$$

Operator soft-thresholding mengecilkan nilai koefisien menuju nol sesuai besar penalti LASSO. Apabila nilai absolut $X_j^{*T} r_j^*$ lebih kecil dibandingkan parameter λ_{LASSO} , maka koefisien akan menjadi nol sehingga variabel tersebut dieliminasi dari model. Oleh karena itu, proses estimasi tidak hanya menghasilkan penyusutan koefisien, tetapi juga melakukan seleksi variabel secara simultan.

Pada penelitian ini, algoritma Coordinate Descent tidak diimplementasikan secara manual, tetapi menggunakan fungsi `cv.glmnet()` yang mengimplementasikan algoritma cyclic Coordinate Descent (Friedman et al., 2010). Fungsi tersebut digunakan untuk memperoleh estimasi parameter regresi sekaligus melakukan seleksi variabel melalui operator *soft-thresholding*. Variabel yang memiliki koefisien sama dengan nol dieliminasi dari model, sedangkan variabel dengan koefisien tidak nol digunakan dalam pembentukan model SAE akhir.

Berdasarkan penjabaran matematis tersebut, langkah-langkah estimasi model SAE-LASSO dengan algoritma Coordinate Descent dapat diringkas dalam algoritma berikut:

Langkah-langkah:

1. Membentuk model SAE awal dan mengestimasi parameter spasial menggunakan Maximum Likelihood.
2. Melakukan transformasi spasial terhadap variabel respon dan prediktor:

$$y^* = (I - \lambda W)y$$

$$X^* = (I - \lambda W)X$$

Langkah-langkah:

3. Menentukan nilai awal koefisien $\beta^{(0)}$
4. Untuk setiap variabel $j = 1, 2, \dots, p$, menghitung residual parsial:

$$r_j = y^* - \sum_{k \neq j} X_k^* \beta_k$$

5. Memperbarui koefisien menggunakan soft-thresholding:

$$\hat{\beta}_j = \frac{S(X_j^{*T} r_j^*, \lambda_{LASSO})}{X_j^{*T} X_j^*}$$

6. Proses iterasi dilakukan hingga koefisien konvergen.
7. Menentukan parameter penalti LASSO optimal menggunakan cross-validation melalui fungsi `cv.glmnet()`
8. Memilih variabel dengan:

$$\hat{\beta}_j \neq 0$$

9. Membentuk kembali model SAE menggunakan variabel terpilih dan melakukan evaluasi menggunakan AIC dan BIC.
-

Algoritma Coordinate Descent menghasilkan estimasi koefisien regresi untuk setiap nilai parameter penalti LASSO. Variasi nilai menghasilkan tingkat penyusutan koefisien yang berbeda sehingga memengaruhi jumlah variabel yang terpilih dalam model. Nilai parameter penalti LASSO optimal ditentukan menggunakan metode cross-validation melalui fungsi `cv.glmnet()`.

Nilai AIC dan BIC digunakan sebagai dasar pemilihan model terbaik, dimana model dengan nilai AIC dan BIC terkecil menunjukkan model yang memiliki tingkat kesesuaian terbaik dengan mempertimbangkan jumlah parameter yang digunakan. Model SAE terbaik selanjutnya diterapkan pada data Angka Melek Huruf di Provinsi Sulawesi Selatan.

3.2. Penerapan Model SAE-LASSO dengan Coordinate Descent pada Angka Melek Huruf di Sulawesi Selatan tahun 2022

3.2.1. Eksplorasi Data

Model SAE dengan Penalti LASSO dengan perbaruan algoritma diterapkan pada data Angka Melek Huruf (AMH) dari Sulawesi Selatan tahun 2022, yang mencakup 24 kabupaten/kota. AMH mengukur persentase penduduk berusia 15 tahun ke atas yang mampu membaca dan menulis. Analisa deskriptif dari data tersebut dinyatakan dalam statistik deskriptif yang dapat dilihat pada Tabel 2.


Tabel 2. Statistik Deskriptif dari Data

Variabel	Mean	Standard Deviasi	Minimum	Maksimum
Angka Melek Huruf (Y)	92,559	0,828	80,810	99,170
PDRB (X_1)	56,016	4,979	28,690	145,890
Pengeluaran per Kapita (X_2)	11,272	0,423	7,584	17,406
Kepadatan Penduduk (X_3)	608,208	293,405	44	7188
Tingkat Pengangguran Terbuka (X_4)	3,632	0,496	0,580	11,820

Variabel	Mean	Standard Deviasi	Minimum	Maksimum
Rata-rata Lama Sekolah (X_5)	8,360	0,244	6,750	11,550
Garis Kemiskinan (X_6)	0,394	0,007	0,364	0,511
Gini Ratio (X_7)	0,362	0,004	0,320	0,395
Harapan Lama Sekolah (X_8)	13,361	0,167	12,110	15,590
Jumlah Perpustakaan (X_9)	24,625	6,146	2	137
Tingkat Kegemaran Membaca (X_{10})	74,111	1,667	58,620	90,940
Tingkat Partisipasi Angkatan Kerja (X_{11})	67,294	1,372	57,630	85,110
Persentase Penduduk Miskin (X_{12})	9,318	0,578	4,580	13,920

Tabel 2 menunjukkan statistik deskriptif dari variabel prediktor yang digunakan dalam penelitian ini. Standar deviasi menunjukkan keberagaman dari nilai-nilai yang terdapat pada setiap variabel. Standar deviasi secara keseluruhan data tergolong kecil, kecuali untuk variabel Kepadatan Penduduk yang menunjukkan angka 293,405. Hal ini menunjukkan bahwa Kepadatan Penduduk dari antarwilayah di Sulawesi Selatan mengalami keberagaman, terdapat daerah yang padat penduduknya, dan sebaliknya terdapat juga daerah yang minim penduduk. Variasi ini mengindikasikan bahwa variabel tersebut berpotensi memberikan kontribusi besar dalam menjelaskan variasi Angka Melek Huruf pada model regresi..

Angka Melek Huruf sebagai variabel respon juga tak luput untuk menjadi target eksplorasi sebelum dilakukan tahap analisis. Adapun visualisasi sebaran variabel respon ditunjukkan melalui Gambar 3.



Gambar 3. Pola Sebaran Angka Melek Huruf di Sulawesi Selatan


Gambar 3 menunjukkan peta Provinsi Sulawesi Selatan, yang terbagi menjadi 21 Kabupaten, yakni Bantaeng, Barru, Bone, Bulukumba, Enrekang, Gowa, Jeneponto, Kepulauan Selayar, Luwu, Luwu Timur, Luwu Utara, Maros, Pangkajene dan Kepulauan, Pinrang, Sidenreng Rappang, Sinjai, Soppeng, Takalar, Tana Toraja, Toraja Utara, dan Wajo, serta 3 Kota, yakni Makassar, Palopo, dan Pare-Pare. Warna pada setiap wilayah merepresentasikan nilai Angka Melek Huruf yang tercatat pada masing-masing daerah pada tahun 2022.

Distribusi nilai dari Angka Melek Huruf di Sulawesi Selatan, seperti yang terlihat pada Gambar 3, menunjukkan adanya klusterisasi pada wilayah tertentu. Daerah sekitaran Palopo (sebelah atas Sulawesi Selatan) menunjukkan nilai-nilai yang tinggi kisaran 92 – 98%. Daerah sekitaran Jeneponto (bawah Sulawesi Selatan) menunjukkan nilai-nilai yang cukup rendah pada kisaran 81 – 88 %. Sekilas terlihat adanya klusterisasi secara geografis dari angka melek huruf di Sulawesi Selatan, yang mengakibatkan munculnya efek spasial. Untuk mengidentifikasi keberadaan efek spasial antarwilayah di Sulawesi Selatan, dilakukan uji Breusch-Pagan, Indeks Moran, dan *Lagrange Multiplier* (LM). Sebelum itu, dibentuk terlebih dahulu matriks pembobot spasial.

3.2.2. Pembentukan Matriks Pembobot

Pembentukan matriks pembobot merupakan tahap yang krusial dalam pemodelan spasial. Kekuatan ketetanggaan suatu daerah dengan daerah lain menjadi kunci dalam menentukan pengaruh antardaerah yang terdapat dalam data. Pembentukan matriks ini biasanya dilakukan dengan *rook*, *bishop*, atau *queen continuity* (Janatabadi & Ermagun, 2024).


Penggunaan pendekatan *continuity* mampu memberikan bobot yang sesuai dengan kondisi geografis, karena memberikan interpretasi bahwa terdapat pengaruh dari daerah yang tepat bersinggungan dengan daerah lainnya. Namun dalam kasus di Sulawesi Selatan, kondisi tetangga sebagai daerah yang bersinggungan secara geografis dapat memberikan interpretasi yang keliru, karena tidak semua daerah yang bersentuhan memiliki akses jalan diantara keduanya. Beberapa daerah perlu ditempuh melalui daerah lain agar bisa sampai ke daerah yang bersinggungan dengannya.



Gambar 4. Pemetaan Akses Jalan Pinrang – Enrekang – Tana Toraja

Gambar 4 menunjukkan pemetaan akses jalan oleh di Sulawesi Selatan, dalam hal ini diwakili oleh hubungan 3 daerah, Pinrang, Enrekang, dan Tana Toraja yang ditampilkan oleh pemetaan ESRI (*Environmental Systems Research Institute*) menggunakan aplikasi QGIS 3.44.9. Pinrang dan Tana Toraja akan diberikan bobot 1 (bertetangga) apabila menggunakan prinsip matriks pembobot pada umumnya, karena secara geografis keduanya bersinggungan. Namun apabila dilihat kembali secara aksesibilitas jalan sebagaimana yang ditunjukkan melalui garis coklat dalam peta di Gambar 4, keduanya tidak bisa dikatakan sebagai tetangga karena akses jalan utama tidak terbentuk diantara keduanya. Akibatnya, pemerataan ekonomi ataupun migrasi sosial-budaya tidak bisa dilakukan secara langsung antara Pinrang dan Tana Toraja. Oleh sebab itu, dalam pembentukan matriks pembobot, akses Pinrang – Enrekang dan akses Enrekang – Tana Toraja diberi bobot 2 (akses langsung) dan akses Pinrang – Tana Toraja diberi bobot 1 (akses *step 1-city*).

Pendekatan ini berbeda dengan queen maupun rook contiguity yang hanya mempertimbangkan kedekatan geometris. Matriks pembobot yang digunakan dalam penelitian ini mempertimbangkan aksesibilitas antarwilayah sehingga hubungan spasial yang terbentuk diharapkan lebih merepresentasikan interaksi nyata antar kabupaten/kota. Penerapan pendekatan akses langsung dan *step 1-city* diharapkan mampu memberikan hubungan yang lebih realistis pada kondisi aksesibilitas di Sulawesi Selatan. Dengan menerapkan pendekatan ini terhadap semua wilayah di Sulawesi Selatan, maka diperoleh matriks pembobot yang terlampir di Lampiran 2. Adapun visualisasi dari matriks pembobot ditunjukkan melalui Gambar 5.




Gambar 5. Visualisasi Matriks Pembobot Antarwilayah di Sulawesi Selatan: (a) Akses Langsung, (b) Akses *Step 1-city*

Gambar 5 menunjukkan visualisasi matriks pembobot spasial di Sulawesi Selatan, yang direpresentasikan dengan 2 jenis garis, yakni garis berwarna merah dan biru muda. Gambar 5(a) merepresentasikan hubungan 2 daerah yang memiliki akses langsung diantara keduanya, sedangkan Gambar 5(b) merepresentasikan hubungan 2 daerah yang aksesnya perlu melewati 1 daerah lain. Matriks pembobot yang sudah terbentuk akan digunakan untuk analisis statistik lanjutan, seperti klasterisasi LISA untuk melihat klasterisasi daerah-daerah yang memiliki AMH tinggi dan rendah, analisis indeks Moran untuk melihat kekuatan pengaruh spasial dari suatu daerah, serta pemodelan AMH di Sulawesi Selatan pada tahun 2022.

3.2.3. Analisis Klaster LISA

Analisis LISA dilakukan sebagai eksplorasi lokal untuk mengidentifikasi lokasi-lokasi yang membentuk klaster spasial sebelum dilakukan pengujian formal menggunakan Indeks Moran. Analisis dilanjutkan dengan mengamati sebaran Angka Melek Huruf melalui peta *LISA Cluster* pada Gambar 6.



Gambar 6. Pemetaan LISA Cluster Antarwilayah di Sulawesi Selatan

Gambar 6 menunjukkan hasil klasterisasi LISA di Sulawesi Selatan. Melalui analisis ini, ditemukan klasterisasi daerah-daerah yang memiliki AMH yang tinggi yang ditandai dengan daerah berwarna biru, daerah-daerah tersebut mencakup Luwu Timur, Luwu Utara, Toraja Utara, Tana Toraja, Luwu, Kota Palopo, Pinrang, Sidrap, dan Enrekang. Daerah berwarna merah menunjukkan klaster daerah-daerah dengan AMH yang kurang, yakni Bone, Sinjai, Gowa, Takalar, Jeneponto, dan Bantaeng.

Klasterisasi LISA yang terlihat pada kabupaten/kota di Sulawesi Selatan menunjukkan terdapat faktor yang terklaster, artinya terdapat faktor signifikan yang membuat daerah2 Utara memiliki AMH yang tinggi dan sebaliknya. Hal ini turut menunjukkan adanya efek spasial yang mengakibatkan daerah-daerah yang berdekatan memiliki suatu pola yang sama (Bivand & Wong, 2018). Untuk itu, perlu dilakukan pengujian lebih lanjut secara statistik.

3.2.4. Uji Autokorelasi Spasial

Uji autokorelasi spasial bertujuan untuk mendeteksi keberadaan ketergantungan spasial pada Angka Melek Huruf di Provinsi Sulawesi Selatan secara menyeluruh. Analisis dilakukan menggunakan Indeks Moran Global dengan matriks pembobot spasial yang sudah dibangun Berdasarkan pengujian yang dilakukan menggunakan perangkat lunak R, diperoleh ringkasan hasil yang ditunjukkan melalui Tabel 3.

Tabel 3. Pengujian Indeks Moran

Pembobot	Moran's I	P-Value	Keputusan
Spasial	0.227	0.007	Signifikan

Berdasarkan Tabel 3, diperoleh nilai $p - value$ sebesar 0,007 lebih kecil dari $\alpha = 5\%$ sehingga diputuskan untuk menolak H_0 . Hal ini menunjukkan bahwa secara statistik terdapat autokorelasi spasial positif yang signifikan pada Angka Melek Huruf di Sulawesi Selatan. Dengan kata lain, kabupaten/kota dengan angka melek huruf tertentu cenderung dikelilingi oleh wilayah dengan karakteristik yang serupa (pola mengelompok).

Setelah terbukti terdapat autokorelasi spasial melalui Indeks Moran, dilakukan uji *Lagrange Multiplier* atau *Rao's Score Test* untuk menentukan tipe model spasial yang paling representatif bagi data. Uji ini membandingkan apakah ketergantungan spasial terletak pada variabel dependen (*spatial lag*) atau pada sisaan (*spatial error*).


Tabel 4. Pengujian Lagrange Multiplier

Pengujian	Nilai	$p - value$
RSerr	5.701	0.017
RSlag	0.084	0.772

Berdasarkan Tabel 4, pengujian pada taraf nyata 5% menunjukkan bahwa statistik RSerr (LM-Error) bersifat signifikan dengan $p-value$ 0.017, sedangkan RSlag (LM-Lag) tidak signifikan dengan $p-value$ 0.772. Sesuai dengan kaidah pemilihan model, jika nilai *LM-Error* signifikan dan *LM-Lag* tidak signifikan, maka model yang paling tepat untuk digunakan adalah Spatial Autoregressive Error (SAE). Hal ini mengindikasikan bahwa ketergantungan spasial pada Angka Melek Huruf di Sulawesi Selatan terjadi pada sisaan model, yang berarti terdapat variabel-variabel penjelas lain yang tidak masuk dalam model namun memiliki pola spasial antarwilayah.

3.2.5. Uji Multikolineritas

Uji multikolineritas dilakukan untuk menilai tingkat korelasi antarvariabel. Sebelum menguji multikolineritas dengan menggunakan nilai Variance Inflation Factor (VIF), terlebih dahulu dilakukan analisis korelasi. Hasil uji korelasi divisualisasikan dalam bentuk *heatmap* sebagaimana ditunjukkan pada Gambar 6.



Gambar 7. Heatmap Korelasi dari Data

Matriks korelasi atau *heatmap* pada Gambar 7 memberikan gambaran menyeluruh mengenai kekuatan dan arah hubungan antar variabel, dengan gradasi warna biru menunjukkan korelasi positif dan warna merah menunjukkan korelasi negatif. Secara umum, variabel dependen Angka Melek Huruf (Y) memiliki hubungan positif yang paling kuat dengan variabel pendidikan, yaitu Rata-rata Lama Sekolah (X_5) dan Harapan Lama Sekolah (X_8), yang divisualisasikan dengan kotak berwarna biru tua. Hal ini mengindikasikan bahwa peningkatan kualitas dan durasi pendidikan secara konsisten diikuti oleh peningkatan angka literasi di wilayah tersebut. Di sisi lain, Y menunjukkan hubungan negatif dengan Tingkat Partisipasi Angkatan Kerja (X_{11}) dan Persentase Penduduk Miskin (X_{12}), meskipun kekuatannya tidak sedominan variabel pendidikan.

Dilihat dari hubungan antar variabel independen, terdapat indikasi kuat adanya multikolineritas pada beberapa kelompok variabel. Blok berwarna biru pekat terlihat pada interaksi antara PDRB (X_1), Pengeluaran per Kapita (X_2), Kepadatan Penduduk (X_3), dan Tingkat Pengangguran Terbuka (X_4), yang menandakan bahwa variabel-variabel ekonomi dan demografi ini saling berkaitan erat satu sama lain. Selain itu, Persentase Penduduk Miskin (X_{12}) menunjukkan korelasi negatif yang sangat kontras dengan variabel ekonomi seperti Pengeluaran per Kapita (X_2), yang secara statistik

sangat logis karena wilayah dengan pengeluaran tinggi cenderung memiliki tingkat kemiskinan yang lebih rendah. Berdasarkan asumsi tersebut, dilakukan uji Multikolineritas dengan melihat nilai VIF pada setiap variabel. Hasil pengujian multikolineritas ditunjukkan oleh Tabel 5.

Tabel 5. Pengujian Multikolineritas

Variabel	VIF	Hasil
PDRB (X_1)	4,850	Tidak Ada Multikolineritas
Pengeluaran per Kapita (X_2)	5,818	Tidak Ada Multikolineritas
Kepadatan Penduduk (X_3)	10,107	Multikolineritas
Tingkat Pengangguran Terbuka (X_4)	5,667	Tidak Ada Multikolineritas
Rata-rata Lama Sekolah (X_5)	10,137	Multikolineritas
Garis Kemiskinan (X_6)	9,300	Tidak Ada Multikolineritas
Gini Ratio (X_7)	3,294	Tidak Ada Multikolineritas
Harapan Lama Sekolah (X_8)	13,187	Multikolineritas
Jumlah Perpustakaan (X_9)	4,324	Tidak Ada Multikolineritas
Tingkat Kegemaran Membaca (X_{10})	4,957	Tidak Ada Multikolineritas
Tingkat Partisipasi Angkatan Kerja (X_{11})	2,275	Tidak Ada Multikolineritas
Persentase Penduduk Miskin (X_{12})	4,624	Tidak Ada Multikolineritas

Adanya multikolineritas antara variabel independen dalam model regresi ditunjukkan dengan nilai VIF yang lebih besar dari 10 (Montgomery dkk., 2012). Tabel 5 menunjukkan terdapat 3 variabel yang mengalami multikolineritas, yakni Kepadatan Penduduk, Rata-rata Lama Sekolah, dan Harapan Lama Sekolah. Keberadaan multikolineritas dalam model regresi akan berakibat pada penurunan keakuratan model dalam melakukan prediksi. Temuan ini mendukung penggunaan penalti LASSO, karena regularisasi L_1 mampu menstabilkan estimasi koefisien sekaligus melakukan seleksi variabel ketika multikolinearitas terjadi. Sebabnya, dalam penelitian ini, model regresi spasial akan dimodifikasi dengan penambahan penalti LASSO untuk menangani multikolineritas dalam data.

3.2.6. Pemodelan Angka Melek Huruf

Pemodelan AMH di Sulawesi Selatan dilakukan dengan model *Spatial Autoregressive Error* dengan Penalti LASSO menggunakan algoritma *Coordinate Descent*. Metode regularisasi LASSO ini akan mengeliminasi variabel-variabel yang bersifat redundan sehingga akan menghasilkan susunan variabel signifikan yang lebih sederhana. Estimasi parameter LASSO dengan algoritma LARS dan CD ditunjukkan melalui Tabel 6.

Tabel 6. Estimasi Parameter OLS, SAE, dan SAE dengan Penalti LASSO menggunakan Algoritma LARS dan CD

Variabel	β	OLS	SAE	SAE dengan Penalti LASSO	
				LARS	CD
Intercept	β_0	-9,83E-13	0.026	0.035	0.033
PDRB	β_1	0.602	0.836*	0.909*	0.879*
Pengeluaran per Kapita	β_2	0.208	0.003	-0.052	—
Kepadatan Penduduk	β_3	-0.961*	-0.986*	-0.823*	-0.831*
Tingkat Pengangguran Terbuka	β_4	-0.671	-0.589*	-0.504*	-0.509*
Rata-rata Lama Sekolah	β_5	0.683	1.069*	1.115*	1.084*
Garis Kemiskinan	β_6	0.511	0.261	-0.024	-0.013
Gini Ratio	β_7	-0.082	0.059	0.086	0.081
Harapan Lama Sekolah	β_8	0.904	0.495*	0.271*	0.298*
Jumlah Perpustakaan	β_9	0.224	0.061	—	—
Tingkat Kegemaran Membaca	β_{10}	-0.514	-0.246	—	—
Tingkat Partisipasi Angkatan Kerja	β_{11}	-0.246	-0.098	—	—
Persentase Penduduk Miskin	β_{12}	0.569	0.162	—	—
	λ	-	-1.246	-1.259	-1.257

Ket:

*) = Signifikan

—) = Tereliminasi oleh regularisasi LASSO

Dibandingkan model SAE tanpa penalti, SAE-LASSO mengeliminasi variabel Pengeluaran per Kapita, Garis Kemiskinan, Gini Ratio, Jumlah Perpustakaan, Tingkat Kegemaran Membaca, Tingkat Partisipasi Angkatan Kerja, dan Persentase Penduduk Miskin. Hal ini menunjukkan bahwa kontribusi variabel-variabel tersebut terhadap model relatif kecil setelah mempertimbangkan korelasi dengan variabel lain.

Dalam pengembangan model regresi dengan regularisasi LASSO, pemilihan algoritma estimasi parameter menjadi sangat penting untuk memastikan akurasi prediksi dan stabilitas model. Penelitian ini menggunakan algoritma *Coordinate Descent* (CD) terhadap Angka Melek Huruf di Sulawesi Selatan pada data tahun 2022, menunjukkan performa yang paling baik diantara model-model yang diuji. Hasil yang ditunjukkan melalui Tabel 6, faktor-faktor yang mempengaruhi angka melek huruf adalah PDRB, Kepadatan Penduduk, Tingkat Pengangguran Terbuka, Rata-rata Lama Sekolah, dan Harapan Lama Sekolah.

Produk Domestik Regional Bruto (PDRB) merupakan jumlah nilai barang dan jasa akhir yang dihasilkan oleh seluruh unit ekonomi dalam suatu wilayah (Badan Pusat Statistik Indonesia, 2024). Berdasarkan analisis regresi pada Tabel 6, ditunjukkan bahwa

peningkatan PDRB berpengaruh secara positif terhadap peningkatan nilai AMH di Sulawesi Selatan. PDRB menjadi indikator penting dalam menunjukkan tingkat ekonomi suatu wilayah. Ekonomi wilayah yang baik mampu menjadi penopang sarana dan prasarana pendidikan, secara langsung mampu memberikan ruang bagi masyarakat untuk meningkatkan literasi.

Kepadatan Penduduk dan Tingkat Pengangguran Terbuka merupakan dua faktor yang berkaitan dengan sosial dan ekonomi. Kepadatan penduduk dihitung dengan membagi jumlah penduduk dengan luas dari wilayah tersebut. Hasil regresi menyatakan bahwa semakin meningkat kepadatan penduduk dari suatu wilayah, dapat menyebabkan turunnya angka melek huruf di wilayah tersebut. Tingkat Pengangguran Terbuka (TPT) adalah nilai yang menunjukkan persentase jumlah pengangguran terbuka terhadap jumlah angkatan kerja. Faktor ini juga secara regresi berpengaruh terbalik terhadap nilai AMH. Semakin tinggi nilai TPT, maka nilai AMH akan semakin menurun. Hal ini jelas bersesuaian dengan pengaruh dari PDRB terhadap AMH. Penurunan TPT menunjukkan peningkatan ekonomi dari suatu wilayah, mengakibatkan akses serta pemerataan literasi yang lebih ekspansif.

Terakhir, Rata-rata Lama Sekolah (RLS) dan Harapan Lama Sekolah (HLS) menjadi faktor pendidikan yang sekiranya wajar untuk berpengaruh secara signifikan terhadap Angka Melek Huruf. RLS merupakan nilai yang menunjukkan rata-rata jumlah tahun sekolah yang diselesaikan oleh penduduk usia 25 tahun ke atas. Nilai HLS menunjukkan jumlah tahun sekolah yang diharapkan akan ditempuh oleh anak-anak usia 7 tahun ke atas (Pratiwi dkk., 2025). Kedua faktor ini menunjukkan pengaruh yang positif terhadap nilai AMH. Hal ini dapat ditanggapi positif, bahwa faktor pendidikan terutama persekolahan menjadi poin kunci dalam peningkatan literasi dalam suatu wilayah.

Model-model yang terbentuk perlu diuji kelayakan dalam melakukan prediksi untuk melihat model dengan metrik yang lebih baik dalam memodelkan Angka Melek Huruf di Sulawesi Selatan. Metrik yang digunakan adalah nilai AIC dan BIC sesuai dengan Persamaan (31) dan (32). Hasil perbandingan ditunjukkan melalui Tabel 7.

Tabel 7. Kebaikan Model

Metrik	OLS	SAE	SAE-LASSO	
			LARS	CD
AIC	56.795	35.347	30.328	28.654
BIC	73.288	53.018	43.287	40.434

Hasil pengujian sesuai dengan yang telah ditunjukkan melalui Tabel 7, menunjukkan performa SAE-LASSO dengan algoritma *Coordinate Descent* memiliki akurasi yang mengungguli semua model, baik melalui metrik AIC maupun BIC. Hal ini menunjukkan performa model tersebut mampu menghasilkan model yang terbaik dalam memodelkan Angka Melek Huruf di Sulawesi Selatan. Berdasarkan seluruh hasil pengujian, model SAE-LASSO menggunakan algoritma *Coordinate Descent* mampu mengatasi autokorelasi spasial sekaligus multikolinearitas (Breheny & Huang, 2011). Model ini menghasilkan jumlah variabel yang lebih ringkas dibandingkan SAE biasa serta memberikan nilai AIC dan BIC terkecil sehingga dipilih sebagai model terbaik.

BAB IV KESIMPULAN DAN SARAN

4.1. Kesimpulan

Melalui penelitian ini, diperoleh kesimpulan sebagai berikut:

1. Penelitian ini menerapkan model Spatial Autoregressive Error (SAE) dengan penalti LASSO menggunakan algoritma Coordinate Descent untuk melakukan seleksi variabel dan estimasi parameter regresi. Tahapan estimasi dilakukan melalui pendekatan Spatial LASSO, yaitu dengan mengestimasi parameter spasial terlebih dahulu menggunakan metode Maximum Likelihood pada model SAE. Bentuk likelihoodnya adalah:

$$L(\beta, \lambda) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2} \log|\Omega(\lambda)| - \frac{(\mathbf{y}^* - \mathbf{X}^* \beta)'(\mathbf{y}^* - \mathbf{X}^* \beta)}{2\sigma^2}$$

Nilai parameter spasial yang diperoleh kemudian digunakan untuk melakukan transformasi spasial terhadap variabel respon dan prediktor. Hasil transformasi tersebut selanjutnya digunakan dalam proses estimasi koefisien regresi menggunakan penalti LASSO berbasis algoritma Coordinate Descent, melalui:

$$\hat{\beta}_j = \frac{S(\mathbf{X}_j^{*T} \mathbf{r}_j^*, \lambda_{LASSO})}{\mathbf{X}_j^{*T} \mathbf{X}_j^*}$$

Variabel dengan koefisien tidak nol dipilih untuk membentuk model SAE akhir yang mampu mempertimbangkan adanya dependensi spasial sekaligus mengurangi kompleksitas model melalui proses seleksi variabel.

2. Melalui pemodelan SAE-LASSO yang sudah dibentuk pada Angka Melek Huruf (AMH) di Sulawesi Selatan pada tahun 2022, diperoleh faktor-faktor yang mempengaruhi Angka Melek Huruf adalah Produk Domestik Regional Bruto (PDRB), Kepadatan Penduduk, Tingkat Pengangguran Terbuka (TPT), Rata-rata Lama Sekolah (RLS), dan Harapan Lama Sekolah (HLS).

Peningkatan PDRB menunjukkan kenaikan taraf ekonomi dari suatu wilayah, hal ini meningkatkan kesejahteraan masyarakat untuk dapat menempuh pendidikan sehingga nilai AMH turut meningkat. Kenaikan kepadatan penduduk mengakibatkan perlunya peningkatan kualitas pendidikan agar semua masyarakat menjadi melek huruf. Sejalan dengan itu, peningkatan TPT juga menurunkan kualitas AMH dari suatu wilayah. Pengangguran menunjukkan ketidakmerataan kesejahteraan ekonomi dari masyarakat, sehingga akses terhadap literasi dan pendidikan juga turut terganggu. Peningkatan RLS dan HLS juga turut memberikan pengaruh positif terhadap AMH. faktor inilah yang memiliki pengaruh yang signifikan terhadap AMH di Sulawesi Selatan pada tahun 2022.

4.2. Saran

Melalui penelitian ini, terdapat saran serta rekomendasi yang dapat diberikan untuk penelitian selanjutnya:

1. Algoritma Coordinate Descent sangat efektif apabila diterapkan kepada data yang high-dimensional, artinya jumlah parameter lebih banyak dibandingkan jumlah data. Struktur data di penelitian ini masih tergolong kecil untuk diterapkan dalam algoritma tersebut, walau hasilnya tetap memiliki keakuratan yang lebih

baik dibandingkan dengan algoritma LARS. Apabila terdapat data dengan dimensi yang tinggi, seperti data-data yang biasanya dianalisis dalam ranah remote-sensing, seperti data polusi udara ($PM_{2.5}$, NO_2 , SO_2 , AOD), topologi, karakteristik biota laut melalui drone UAV, dan sebagainya. Penggunaan data tersebut yang berukuran sangat besar tentu akan menonjolkan performa dari algoritma Coordinate Descent ini.

2. Terdapat beberapa teknik pendekatan dalam algoritma Coordinate Descent selain pendekatan siklis yang dilakukan di penelitian ini, ada pendekatan block, pendekatan random, dan pendekatan greedy yang tentu akan memberikan hasil yang berbeda pada setiap kasus. Silakan merujuk pada penelitian Saha dan Tewari (2010) dan Shi dkk. (2017).
3. Analisis data spasial, terkhusus pada konteks pemodelan sangat bergantung pada pembobotan antarwilayah yang disebut sebagai tetangga dari suatu daerah. Setiap penelitian memiliki landasan tersendiri dalam pendekatan pembobotan daerah. Terdapat beberapa pendekatan lain yang sedang berkembang yang dapat dicoba oleh penelitian selanjutnya, seperti distance-weight, generalized-weight, k-order neighbors weight, dan access weight matrix. Silakan merujuk pada penelitian Zhang, C. (2012) dan Janatabadi – Ermagun (2024).

DAFTAR PUSTAKA

- Al-Momani, M., Hussein, A. A., & Ahmed, S. E. (2017). Penalty and related estimation strategies in the spatial error model. *Statistica Neerlandica*, 71(1), 4–30. <https://doi.org/10.1111/stan.12098>
- Anselin, L. (1988). *Spatial Econometrics: Methods and Models* (Vol. 4). Springer Netherlands. <https://doi.org/10.1007/978-94-015-7799-1>
- Anselin, L., & Bera, A. K. (1998). *Spatial Dependence in Linear Regression Models with an Introduction to Spatial Econometrics*. https://dces.wisc.edu/wp-content/uploads/sites/128/2013/08/W7_AnselinBera1998.pdf
- Azizah, N. (2023). Pemodelan Spatial Autoregressive (SAR-X) pada Perkawinan Usia Anak di Indonesia. *Jurnal Riset Statistika*, 1–10. <https://doi.org/10.29313/jrs.v3i1.1643>
- Badan Pusat Statistik Indonesia. (2024). *Gross Regional Domestic Product of North Penajam Paser 2019-2023* (Vol. 12). <https://ppukab.bps.go.id/id/publication/2024/04/04/e2c7274e31cf33399967a4ad/pr oduk-domestik-regional-bruto-kabupaten-penajam-paser-utara-menurut-lapangan-usaha-2019--2023.html>
- Badan Pusat Statistik Indonesia. (2025). *Statistical Yearbook of Indonesia 2025* (Vol. 53). <https://www.bps.go.id/id/publication/2025/02/28/8cfe1a589ad3693396d3db9f/stati stik-indonesia-2025.html>
- Barde, S., Cherodian, R., & Tchuente, G. (2025). Moran's I lasso for models with spatially correlated data. *Econometrics Journal*, 28(3), 423–441. <https://doi.org/10.1093/ectj/utaf008>
- Bekti, R. D., Andiyono, & Irwansyah, E. (2014). Mapping of illiteracy and information and communication technology indicators using geographically weighted regression. *Journal of Mathematics and Statistics*, 10(2), 130–138. <https://doi.org/10.3844/jmssp.2014.130.138>
- Bivand, R. S., & Wong, D. W. S. (2018). Comparing implementations of global and local indicators of spatial association. *Test*, 27(3), 716–748. <https://doi.org/10.1007/s11749-018-0599-x>
- Breheny, P., & Huang, J. (2011). Coordinate descent algorithms for nonconvex penalized regression, with applications to biological feature selection. *Annals of Applied Statistics*, 5(1), 232–253. <https://doi.org/10.1214/10-AOAS388>
- Cai, L., Maiti, T., Bhattacharjee, A., & Calantone, R. (2019). Variable selection with spatially autoregressive errors: A generalized moments LASSO estimator. *Sankhya: The Indian Journal of Statistics*, 81B, S146–S200. <https://doi.org/10.1007/s13571-018-0176-z>
- Efron, B., Hastie, T., Johnstone, I., & Tibshirani, R. (2004). Least Angle Regression. *Annals of Statistics*, 32(2), 407–451. <https://doi.org/10.1214/0090536040000000067>

- Friedman, J., Hastie, T., Höfling, H., & Tibshirani, R. (2007). Pathwise coordinate optimization. *The Annals of Applied Statistics*, 1(2). <https://doi.org/10.1214/07-aos131>
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33. <https://doi.org/10.18637/jss.v033.i01>
- Gonella, R., Bourel, M., & Bel, L. (2022). Facing spatial massive data in science and society: Variable selection for spatial models. *Spatial Statistics*, 50. <https://doi.org/10.1016/j.spasta.2022.100627>
- Greene, W. H. (2002). *Econometric Analysis* (5 ed.). Prentice Hall.
- Hou, L., Jin, B., & Wu, Y. (2024). Estimation and variable selection for high-dimensional spatial dynamic panel data models. *Journal of Econometrics*, 238(2). <https://doi.org/10.1016/j.jeconom.2023.105605>
- Huang, H. C., Hsu, N. J., Theobald, D. M., & Breidt, F. J. (2010). Spatial lasso with applications to GIS model selection. *Journal of Computational and Graphical Statistics*, 19(4), 963–983. <https://doi.org/10.1198/jcgs.2010.07102>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (Second Edition). <https://link.springer.com/book/10.1007/978-1-0716-1418-1>
- Janatabadi, F., & Ermagun, A. (2024). Access Weight Matrix: A Place and Mobility Infused Spatial Weight Matrix. *Geographical Analysis*, 56(4), 746–767. <https://doi.org/10.1111/gean.12395>
- Jimsan, J., Iin, J. N., & Ayuningsih, E. (2024). Implementation of the KNN Method to Predict the Literacy Rate of Residents Aged Over 15 Years on Sulawesi Island. *Instal: Jurnal Komputer*, 16(02), 88–98. <https://doi.org/10.54209/jurnalinstall.v16i02.209>
- Jogani, C. (2021). Spatial Analysis of an Education Program and Literacy in India. *Review of Regional Studies*, 51, 41–63. <https://doi.org/10.52324/001c.19516>
- Kelejian, H. H., & Prucha, I. R. (1998). A Generalized Spatial Two-Stage Least Squares Procedure for Estimating a Spatial Autoregressive Model with Autoregressive Disturbances. Dalam *Journal of Real Estate Finance and Economics* (Vol. 17). Kluwer Academic Publishers.
- Ketut, I., Wiguna, A. C., Komang, N., Bali, N., Government, P., Shri, K., Savitri, Y., & Government, B. P. (2023). Spatial Regression and Spatial Autocorrelation Analysis of The Determinants of Poverty in Indonesia in 2022. *Artha Info Journal*.
- Lee, S., Seo, M. H., & Shin, Y. (2015). The lasso for high dimensional regression with a possible change point. *Journal of the Royal Statistical Society: Series B (Methodological)*, 78, 193–210. <https://doi.org/10.1111/rssb.12108>
- LeSage, J., & Pace, R. K. (2009). *Introduction to Spatial Econometrics*. <https://www.researchgate.net/publication/339938974>

- Ma, S., Hou, Y., Song, Y., & Zhou, F. (2023). Robust Variable Selection with Exponential Squared Loss for the Spatial Error Model. *Axioms*, 13(1), 4. <https://doi.org/10.3390/axioms13010004>
- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis* (Fifth Edition). John Wiley & Sons, Inc. https://doi.org/10.1111/insr.12020_10
- Ohishi, M., Okamura, K., Itoh, Y., Wakaki, H., & Yanagihara, H. (2025). Coordinate descent algorithm for generalized group fused Lasso. *Behaviormetrika*, 52(1), 105–137. <https://doi.org/10.1007/s41237-024-00233-6>
- Pratiwi, I., Triono, W., Panjaitan, R. R., Rambe, R. R., Dalimunthe, S. F., Statistika, P., Matematika, F., Ilmu, D., & Alam, P. (2025). Analysis of Factors Affecting Literacy Rates in Indonesia Using Robust Regression. *Jurnal Ilmiah Multidisiplin*, 3(2), 519–528. <https://doi.org/10.5281/zenodo.15073386>
- Qi, W. (2016). *A Study on Adaptive Lasso and Its Weight Selection*.
- Rochana, S. H., Kombaitan, B., Purwanda, E., & Stambi Bandung, S. (2015). Road Infrastructure and Spatial Economic Dependence in The Western Region of Java. Dalam *Journal of Indonesian Economy and Business* (Vol. 30, Nomor 3).
- Saha, A., & Tewari, A. (2010). *On the Finite Time Convergence of Cyclic Coordinate Descent Methods*. <https://doi.org/10.48550/arXiv.1005.2146>
- Sherina, R., & Sagala, Y. (2025). Parameter Estimation of the Least Absolute Shrinkage and Selection Operator (LASSO) Using the Cyclic Coordinate Descent Algorithm. *Jurnal Pendidikan Inklusif*, 9(6). <https://oaj.jurnalhst.com/index.php/jpi/article/view/12633>
- Shi, H.-J. M., Tu, S., Xu, Y., & Yin, W. (2017). *A Primer on Coordinate Descent Algorithms*. <https://ww3.math.ucla.edu/camreport/cam16-67.pdf>
- Song, Y., Liang, X., Zhu, Y., & Lin, L. (2021). Robust variable selection with exponential squared loss for the spatial autoregressive model. *Computational Statistics and Data Analysis*, 155. <https://doi.org/10.1016/j.csda.2020.107094>
- Su, L., & Yang, Z. (2015). QML estimation of dynamic panel data models with spatial errors. *Journal of Econometrics*, 185(1), 230–258. <https://doi.org/10.1016/j.jeconom.2014.11.002>
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267–288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- Wen, Y., Shen, X., & Lu, Q. (2018). Genetic risk prediction using a spatial autoregressive model with adaptive lasso. *Statistics in Medicine*, 37(26), 3764–3775. <https://doi.org/10.1002/sim.7832>
- Wright, S. J. (2015). Coordinate descent algorithms. *Mathematical Programming*, 151(1), 3–34. <https://doi.org/10.1007/s10107-015-0892-3>

- Wu, T. T., & Lange, K. (2008). Coordinate descent algorithms for lasso penalized regression. *Annals of Applied Statistics*, 2(1), 224–244. <https://doi.org/10.1214/07-AOAS147>
- Yun, S. (2014). On the iteration complexity of cyclic coordinate gradient descent methods. *SIAM Journal on Optimization*, 24(3), 1567–1580. <https://doi.org/10.1137/130937755>
- Zhang, C. (2012). Spatial Weights Matrix and its Application. *Journal of Regional Development Studies*.
- Zhang, Y., & Cutumisu, M. (2024). Predicting the Mathematics Literacy of Resilient Students from High-performing Economies: A Machine Learning Approach. *Studies in Educational Evaluation*, 83. <https://doi.org/10.1016/j.stueduc.2024.101412>
- Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429. <https://doi.org/10.1198/016214506000000735>

LAMPIRAN

Lampiran 1. Data Penelitian

Kabupaten/Kota	Y	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11	X12
Kepulauan Selayar	93,080	53,760	9,446	103	1,490	8,090	0,431	0,350	12,670	4	82,990	69,930	12,240
Bulukumba	93,310	38,880	10,941	345	1,260	8,010	0,390	0,361	13,420	49	69,620	65,270	7,390
Bantaeng	86,340	61,000	12,133	504	2,720	6,810	0,394	0,320	12,300	8	69,160	75,360	9,070
Jeneponto	80,810	28,690	9,425	581	2,210	6,750	0,384	0,338	12,110	11	70,030	75,260	13,730
Takalar	88,200	40,180	10,746	538	2,630	7,640	0,399	0,375	12,480	6	62,730	64,460	8,250
Gowa	91,020	32,700	9,812	416	3,260	8,400	0,429	0,364	13,660	31	90,790	73,160	7,360
Sinjai	89,620	51,290	9,726	330	1,800	7,790	0,374	0,357	13,250	22	77,700	63,340	8,800
Maros	89,650	58,310	11,403	249	5,040	8,020	0,450	0,362	13,300	35	90,940	61,370	9,430
Pangkajene Dan Kepulauan	95,790	86,740	11,817	310	5,230	8,050	0,390	0,334	12,780	21	72,380	74,660	13,920
Barru	89,170	47,500	11,275	159	5,320	8,250	0,368	0,366	13,610	19	71,920	62,360	8,400
Bone	92,320	53,670	9,277	178	2,270	7,360	0,381	0,376	12,990	27	69,450	67,480	10,580
Soppeng	91,990	58,220	9,756	152	3,400	7,960	0,366	0,386	13,200	19	58,620	61,900	7,490
Wajo	91,880	64,140	12,729	152	2,540	7,160	0,375	0,375	13,300	3	68,090	61,130	6,570
Sidenreng Rappang	92,820	51,000	12,379	174	3,560	8,040	0,383	0,354	13,010	75	68,480	57,630	5,110
Pinrang	94,820	57,710	12,102	210	2,790	8,040	0,367	0,363	13,250	8	71,340	57,720	8,790
Enrekang	93,990	39,130	11,183	129	0,580	8,930	0,372	0,346	13,860	17	84,140	72,050	12,390
Luwu	96,290	54,030	10,308	111	3,850	8,480	0,381	0,364	13,400	2	78,690	67,740	12,490
Tana Toraja	93,000	30,090	7,584	146	2,320	8,520	0,367	0,355	13,870	4	68,160	85,110	12,180
Luwu Utara	96,390	48,960	12,105	44	2,810	7,870	0,382	0,349	12,580	7	67,950	72,230	13,220
Luwu Timur	92,710	92,980	13,058	44	4,480	8,920	0,394	0,394	13,000	34	71,350	71,510	6,810
Toraja Utara	93,050	42,180	8,494	221	1,990	8,260	0,364	0,356	13,410	3	73,480	68,840	11,650

Lampiran 1. (Lanjutan). Data Penelitian

Kabupaten/Kota	Y	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11	X12
Kota Makassar	99,170	145,890	17,406	7188	11,820	11,550	0,511	0,395	15,590	137	84,520	59,270	4,580
Kota Parepare	98,420	56,160	14,027	1559	5,600	10,660	0,402	0,379	14,520	47	76,870	63,620	5,410
Kota Palopo	97,570	51,180	13,404	754	8,200	11,090	0,403	0,371	15,100	2	79,260	63,650	7,780

Lampiran 2. Matriks Pembobot Spasial

Kabupaten/Kota	Kepulauan Selayar	Bulukumba	Bantaeng	Jeneponto	Takalar	Gowa	Sinjai	Maros	Pangkep	Barru	Bone	Soppeng	Wajo	Sidenreng Rappang	Pinrang	Enrekang	Luwu	Tana Toraja	Luwu Utara	Luwu Timur	Toraja Utara	Kota Makassar	Kota Parepare	Kota Palopo
Kepulauan Selayar	0	2	1	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	2	0	0
Bulukumba	2	0	2	1	0	1	2	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
Bantaeng	1	2	0	2	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Jeneponto	1	1	2	0	2	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Takalar	1	0	1	2	0	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
Gowa	0	1	0	1	2	0	2	1	0	0	1	0	0	0	0	0	0	0	0	0	0	2	0	0
Sinjai	0	2	1	0	0	2	0	1	0	0	2	1	1	0	0	0	0	0	0	0	0	1	0	0
Maros	0	0	0	0	0	1	1	0	2	1	2	1	1	0	0	0	0	0	0	0	0	2	0	0
Pangkajene Dan Kepulauan	0	0	0	0	0	0	0	2	0	2	1	1	0	0	0	0	0	0	0	0	0	1	1	0
Barru	0	0	0	0	0	0	0	1	2	0	1	2	1	1	1	0	0	0	0	0	0	0	2	0
Bone	0	1	0	0	0	1	2	2	1	1	0	2	2	1	0	0	1	0	0	0	0	1	0	0
Soppeng	0	0	0	0	0	0	1	1	1	2	2	0	2	2	1	1	1	0	0	0	0	0	1	0
Wajo	0	0	0	0	0	0	1	1	0	1	2	2	0	2	1	1	2	0	0	0	0	0	1	1
Sidenreng Rappang	0	0	0	0	0	0	0	0	0	1	1	2	2	0	2	2	1	1	0	0	0	0	2	0
Pinrang	0	0	0	0	0	0	0	0	0	1	0	1	1	2	0	2	0	1	0	0	0	0	2	0
Enrekang	0	0	0	0	0	0	0	0	0	0	0	1	1	2	2	0	0	2	0	0	1	0	1	0
Luwu	0	0	0	0	0	0	0	0	0	0	1	1	2	1	0	0	0	0	0	0	1	0	0	2
Tana Toraja	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	2	0	0	0	0	2	0	0	1
Luwu Utara	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	2	1	0	0	2

Lampiran 2. (Lanjutan). Matriks Pembobot Spasial

Kabupaten/Kota	Kepulauan Selavar	Bulukumba	Bantaeng	Jeneponto	Takalar	Gowa	Sinjai	Maros	Pangkep	Barro	Bone	Soppeng	Wajo	Sidenreng Rappang	Pinrang	Enrekang	Luwu	Tana Toraja	Luwu Utara	Luwu Timur	Toraja Utara	Kota Makassar	Kota Parepare	Kota Palopo
Luwu Timur	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	2	0	0	0	0	1
Toraja Utara	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	2	1	0	0	0	0	2
Kota Makassar	2	0	0	0	1	2	1	2	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
Kota Parepare	0	0	0	0	0	0	0	0	1	2	0	1	1	2	2	1	0	0	0	0	0	0	0	0
Kota Palopo	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	2	1	2	1	2	0	0	0

