

Rancang Bangun Dashboard Dan Prediksi Inflasi di Kota Makassar Menggunakan Model Extreme Gradient Boosting



MUHAMMAD ARYA RAMDANI
H071211052



PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR

2026

**Rancang Bangun Dashboard Dan Prediksi Inflasi di Kota
Makassar Menggunakan Model Extreme Gradient Boosting**

**MUHAMMAD ARYA RAMDANI
H071211052**



**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**Rancang Bangun Dashboard Dan Prediksi Inflasi di Kota
Makassar Menggunakan Model Extreme Gradient Boosting**

**MUHAMMAD ARYA RAMDANI
H071211052**

Skripsi

sebagai salah satu syarat untuk memperoleh gelar sarjana

pada

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
2026**

**Rancang Bangun Dashboard Dan Prediksi Inflasi di Kota
Makassar Menggunakan Model Extreme Gradient Boosting**

MUHAMMAD ARYA RAMDANI
H071211052


Skripsi,

telah dipertahankan di depan Panitia Ujian Sarjana Sistem Informasi pada
tanggal Juni 2026 dan dinyatakan telah memenuhi syarat kelulusan

pada


Program Studi Sistem Informasi
Departemen Matematika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:
Pembimbing tugas akhir,



Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng
NIP. 198805042019031012

Mengetahui:
Ketua Program Studi,



Prof. Dr. Jeffry Kusuma, Ph.D
NIP. 196411121987031002

**PERNYATAAN KEASLIAN SKRIPSI
DAN PELIMPAHAN HAK CIPTA**

Dengan ini saya menyatakan bahwa, skripsi berjudul "Rancang Bangun Dashboard Dan Prediksi Inflasi di Kota Makassar Menggunakan Model Extreme Gradient Boosting" adalah benar karya saya dengan arahan dari pembimbing Bapak Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 21 juli 2026



Muhammad Arya Ramdani
H071211052

UCAPAN TERIMA KASIH

Puji syukur ke hadirat Allah SWT atas segala rahmat dan hidayah-Nya, sehingga skripsi berjudul "**Rancang Bangun Dashboard Dan Prediksi Inflasi di Kota Makassar Menggunakan Model Extreme Gradient Boosting**" dapat diselesaikan sebagai syarat memperoleh gelar Sarjana Komputer di Universitas Hasanuddin. Shalawat dan salam senantiasa tercurah kepada junjungan kita, Nabi Muhammad SAW.

Tiada lembar skripsi yang paling indah dalam laporan skripsi ini kecuali lembar ucapan terima kasih. *Bismillahirrahmanirrahim* skripsi ini penulis persembahkan untuk :

1. Kepada pemilik zat dan alam semesta, yang menguasai dan berkuasa atas segala sesuatu. Allah SWT, terima kasih telah menjadi satu satunya rumah tempatku pulang saat dunia terasa begitu kabur dan berisik. Terima kasih telah menjaga setiap langkah disaat penulis lupa alasan untuk hidup
2. Kepada kedua orang tua saya tercinta, Ibu nurhayati fataruba, S.pd dan bapak Alm Muhammad ahda sillia S.pd., yang telah memberi segalanya dan tak pernah harap kembali bagi kehidupan penulis. Satu satunya doa orang tua yang saya miliki hingga saat ini, yang setia mendampingi langkah saya setiap lelah dan doa. Ibu menjadi sumber kekuatan yang tak pernah padam. Terima kasih atas cinta, pengorbanan, dan keteguhan hati serta dukungan yang tiada henti. Di setiap lembar skripsi ini, terselip kasih sayangmu yang tulus dan kesabaran yang tiada henti, tangan yang selalu menopang saat hampir tumbang, dan suara yang selalu berbisik bahwa saya mampu. Skripsi ini adalah bukti kecil dari besarnya cinta yang ia berikan.
3. Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng, selaku dosen pembimbing yang membuat penulis dapat menyelesaikan skripsi ini dengan baik. Penulis mendapat semangat dan motivasi setiap kali berinteraksi dengan beliau. Terima kasih sebesar-besarnya atas ketersediaan bapak meluangkan waktu di tengah kesibukan, atas kesabaran, perhatian, arahan, serta nasihat yang disampaikan dengan tutur kata menenangkan dan tidak menyakiti, sehingga seluruh proses dapat dijalani dengan nyaman. Tanpa bimbingan dan dukungan bapak yang tulus mungkin skripsi ini belum bisa selesai. Semoga Allah SWT senantiasa melimpahkan kesehatan, keberkahan, serta balasan terbaik untuk setiap kebaikan beliau.
4. Octavian, S.Si., M.Kom, selaku dosen penguji 1 yang sudah meluangkan waktu untuk menguji penulis, menelaah, mengkritisi, dan memberikan masukan dalam skripsi ini.
5. Nur Rohman Oktaviani P., S.Si., M.Si selaku dosen penguji 1 yang sudah

meluangkan waktu untuk menguji penulis, menelaah, mengkritisi, dan memberikan masukan dalam skripsi ini.

6. Segenap pegawai departemen dan fakultas Universitas Hasanuddin yang telah membantu dan melayani berbagai berkas penulis dengan baik
7. Kepada Nurul Indah Pratiwi S.ked, selaku kakak tersayang yang telah menemani dan memberikan arahan serta dukungan, motivasi, serta menjadi donatur penulis dalam menjalani masa perkuliahan, dan proses penulisan hingga saat ini.
8. Teman-teman mahasiswa sistem informasi angkatan 21, serta seluruh sahabat atas dukungan dan motivasi yang diberikan selama masa perkuliahan hingga saat ini.

ABSTRAK

MUHAMMAD ARYA RAMDANI. **Rancang Bangun Dashboard Dan Prediksi Inflasi di Kota Makassar Menggunakan Model Extreme Gradient Boosting**
(dibimbing oleh Supri Bin Hj Amir, S.Si., M.Eng.)

Latar Belakang. Inflasi merupakan salah satu indikator makroekonomi yang memengaruhi stabilitas perekonomian suatu daerah, termasuk Kota Makassar yang merupakan salah satu kota acuan penghitungan inflasi di Provinsi Sulawesi Selatan. Pemantauan dan prediksi inflasi yang akurat menjadi krusial bagi pemangku kebijakan maupun masyarakat umum, namun ketersediaan alat analisis yang interaktif dan mudah diakses oleh pengguna non-teknis masih terbatas. **Tujuan.** Penelitian ini bertujuan untuk merancang model prediksi inflasi menggunakan algoritma Extreme Gradient Boosting (XGBoost) serta membangun dashboard interaktif berbasis Streamlit sebagai sarana visualisasi dan prediksi inflasi di Kota Makassar. **Metode.** Metode penelitian yang digunakan adalah Cross Industry Standard Process for Data Mining (CRISP-DM), implementasi dashboard menggunakan framework Streamlit yang terintegrasi dengan model XGBoost terbaik, dilengkapi dengan fitur grafik tren. **Hasil.** Hasil penelitian menunjukkan bahwa model XGBoost memberikan performa terbaik dengan nilai MAE sebesar 0,1736%, RMSE sebesar 0,2798%, R^2 sebesar 0,7263, dan MASE sebesar 0,2487, serta mengungguli model Random Forest yang memperoleh nilai R^2 sebesar 0,68. Dashboard yang dikembangkan terdiri atas lima halaman, yaitu Beranda, EDA, Prediksi, Perbandingan Model dan informasi. Penelitian ini menyimpulkan bahwa algoritma XGBoost efektif digunakan untuk memprediksi inflasi di Kota Makassar dan dashboard yang dibangun dapat menjadi sarana yang informatif serta mudah digunakan oleh masyarakat umum dalam memahami tren inflasi.

Kata Kunci: Machine learning, Prediksi Inflasi, Bank Indonesia, Ekonomi Makro.

ABSTRACT

MUHAMMAD ARYA RAMDANI. **Design of a Dashboard and Inflation Prediction in Makassar City Using the Extreme Gradient Boosting Model**
(supervised by Supri Bin Hj Amir, S.Si., M.Eng.)

Background. Inflation is one of the macroeconomic indicators that affects the economic stability of a region, including Makassar City, which serves as one of the reference cities for inflation calculations in South Sulawesi Province. Accurate inflation monitoring and forecasting are crucial for policymakers and the general public. However, the availability of interactive and user-friendly analytical tools accessible to non-technical users remains limited. **Objective.** This study aims to develop an inflation forecasting model using the Extreme Gradient Boosting (XGBoost) algorithm and to build an interactive Streamlit-based dashboard for inflation visualization and forecasting in Makassar City. **Methods.** The research employed the Cross-Industry Standard Process for Data Mining (CRISP-DM) methodology. The dashboard was implemented using the Streamlit framework and integrated with the best-performing XGBoost model. The dashboard was also equipped with trend visualization features. **Results.** The results indicate that the XGBoost model achieved the best performance, with an MAE of 0.1736%, an RMSE of 0.2798%, an R^2 score of 0.7263, and a MASE of 0.2487. Furthermore, it outperformed the Random Forest model, which obtained an R^2 score of 0,68. The developed dashboard consists of five main pages: Home, Exploratory Data Analysis (EDA), Prediction, Model Comparison, and information. This study concludes that the XGBoost algorithm is effective for forecasting inflation in Makassar City. Additionally, the developed dashboard serves as an informative and user-friendly tool that helps the general public understand inflation trends.

Keywords: Machine learning, Inflation Prediction, Bank Indonesia, Macroeconomic.

DAFTAR ISI

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA	iv
UCAPAN TERIMA KASIH	v
ABSTRAK	vii
ABSTRACT	viii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	2
1.4 Batasan masalah	2
1.5 Manfaat Penelitian	2
1.6 Landasan Teori	3
1.6.1 Inflasi	3
1.6.2 Sistem informasi	3
1.6.3 Machine Learning	3
1.6.4 XGBoost	3
1.6.5 Uji signifikan paramater	4
1.6.6 Framework dan teknologi	5
1.6.7 Forecasting	5
BAB II METODE PENELITIAN	7
2.1 Metode penelitian	7
2.2 Waktu dan lokasi penelitian	7
2.3 Variabel Penelitian	7
2.4 Teknik Pengumpulan Data	8
2.4.1 Sumber Data	8
2.4.2 Metode Pengumpulan	8
2.4.3 Instrumen Pengumpulan Data	9
2.5 Teknik Analisis Data	9
2.5.1 Pra-pemrosesan Data (Data Preprocessing)	9
2.5.2 Analisis Data Eksploratif (Exploratory Data Analysis)	10
2.5.3 Pembagian Data (Train-Test Split)	10

2.5.4 Pemilihan dan Pelatihan Model.....	11
2.5.5 <i>Evaluasi Model</i>	11
2.5.6 Prediksi dan Confidence Interval	13
2.6 <i>Rancang Bangun Dashboard Analisis</i>	13
2.6.1 Arsitektur Sistem	13
2.6.2 Fitur Dashboard.....	14
2.7 <i>Alur penelitian</i>	14
BAB III HASIL DAN PEMBAHASAN	16
3.1 <i>Gambaran Umum Data Penelitian</i>	16
3.1.1 <i>Deskripsi Dataset</i>	16
3.1.2 <i>Statistik Deskriptif</i>	16
3.1.3 Analisis Pola Musiman	17
3.1.4 Analisis Tren Tahunan	18
3.2 <i>Hasil Pra-Pemrosesan Data</i>	18
3.2.1 Pembersihan dan Transformasi Data	18
3.2.2 Rekayasa Fitur	19
3.2.3 Pembagian Data.....	19
3.3 <i>Hasil Pelatihan Model</i>	19
3.3.1 <i>Model Random Forest</i>	19
3.3.2 <i>Model XGBoost</i>	19
3.3.3 <i>Model XGBoost Lag Features</i>	20
3.3.4 <i>Model LSTM</i>	21
3.3.5 <i>Model Moving Average dan SARIMA</i>	21
3.4 <i>Hasil Evaluasi dan Perbandingan Model</i>	21
3.4.1 <i>Performa Model pada Data Uji</i>	21
3.4.2 <i>Analisis Model XGBoost sebagai Model Terbaik</i>	22
3.4.3 <i>Variabel Importance Correlation</i>	23
3.4.4 <i>Analisis Feature Importance XGBoost</i>	24
3.5 <i>Hasil Prediksi Inflasi Januari–Maret 2026</i>	25
3.5.1 <i>Prediksi Menggunakan Model Terbaik</i>	25
3.5.2 <i>Analisis Hasil Prediksi</i>	26

3.6 Hasil Rancang Bangun Dashboard Analisis	27
3.6.1 Arsitektur dan Implementasi Dashboard	27
3.6.2 Fitur dan Komponen Dashboard	27
3.6.3 Pengujian Fungsional Dashboard	28
3.6.4 Antarmuka Pengguna.....	32
3.7 Pembahasan	32
3.7.1 Efektivitas XGBoost untuk Prediksi Inflasi	32
3.7.2 Implikasi Pola Musiman.....	33
3.7.3 Keterbatasan Model	33
3.7.4 Kontribusi Dashboard terhadap Aksesibilitas Analisis	34
3.7.5 Uji skenario.....	34
3.8 Ringkasan Temuan	35
BAB IV PENUTUP	37
4.1 Kesimpulan.....	37
4.2 Saran	37
DAFTAR PUSTAKA	38
LAMPIRAN	40

DAFTAR GAMBAR

Gambar 1. jenis pola ramalan (Sumber : openstax Components of Time Series Analysis).....	6
Gambar 2. Alur penelitian	15
Gambar 3. heatmap inflasi	18
Gambar 4. performa model	22
Gambar 5. Feature Correlation	23
Gambar 6. Xgboost Feature Importance	25
Gambar 7. Grafik prediksi 2026	26
Gambar 8. Komponen dashboard	31
Gambar 9. komponen dashboard data statistik	31
Gambar 10. uji performa test.....	32
Gambar 11. Uji skenario variabel tunggal	34
Gambar 12. Interpretasi hasil skenario variabel tunggal.....	35

DAFTAR TABEL

Tabel 1. waktu penelitian	7
Tabel 2. Variabel.....	8
Tabel 3. Fitur Lag untuk Model XGBoost Lag Features	9
Tabel 4. Model yang Diimplementasikan dalam Penelitian	11
Tabel 5. Metrik Evaluasi Model	12
Tabel 6. Komponen Fitur Dashboard Analisis	14
Tabel 7. Struktur dan Kualitas Dataset Inflasi Makassar	16
Tabel 8. Statistik Deskriptif Inflasi Bulanan Kota Makassar (2000–2025).....	17
Tabel 9. Hyperparameter Optimal Model XGBoost	20
Tabel 10. Hasil Evaluasi Kinerja Seluruh Model pada Data Uji (Baris hijau = model terbaik)	21
Tabel 11. Feature Importance Model XGBoost Lag Features.....	24
Tabel 12. Prediksi Inflasi Kota Makassar Januari–februari 2026	26
Tabel 13. Fitur dan Status Implementasi Komponen Dashboard	27
Tabel 14. Pengujian pada pengaturan	29
Tabel 15. Hasil analisis model	29
Tabel 16. Pengujian data dan statistik.....	30

BAB I

PENDAHULUAN

1.1 Latar Belakang

Inflasi merupakan salah satu indikator penting dalam perekonomian suatu negara karena berpengaruh langsung terhadap stabilitas harga, daya beli masyarakat, serta arah kebijakan moneter (Muhamad et al., 2026). Bagi Bank Indonesia selaku bank sentral, pengendalian inflasi menjadi tugas utama dalam rangka menjaga stabilitas sistem keuangan nasional. Prediksi inflasi yang akurat sangat dibutuhkan untuk merumuskan kebijakan moneter yang tepat waktu dan efektif (Firdaus et al., 2025).

Dalam dekade terakhir, fenomena inflasi di Indonesia menunjukkan pola yang dinamis, dipengaruhi oleh berbagai faktor seperti perubahan nilai tukar rupiah, suku bunga acuan, jumlah uang beredar, harga energi global, serta distribusi bahan pokok. Kompleksitas faktor yang memengaruhi inflasi membuat prediksi secara manual menjadi kurang akurat dan seringkali tertinggal dari kondisi aktual (Agustina & Permadi, 2023). Oleh karena itu, dibutuhkan pendekatan analitis berbasis teknologi yang mampu mengolah data dalam jumlah besar dan menghasilkan prediksi yang lebih tepat.

Beberapa penelitian terdahulu yang menggunakan metode ARIMA dan SARIMA untuk peramalan inflasi di negara berkembang, termasuk Indonesia, melaporkan nilai MAPE (Mean Absolute Percentage Error) yang masih berada di atas 10-15%, yang dalam konteks peramalan inflasi dianggap kurang akurat untuk mendukung kebijakan strategis jangka pendek. Metode econometric structural seperti Vector Autoregression (VAR) juga menghadapi keterbatasan dalam hal asumsi linearitas dan stasioneritas data yang seringkali tidak terpenuhi pada data ekonomi riil. Namun, tantangan utama dalam memprediksi inflasi adalah kompleksitas data ekonomi yang bersifat dinamis, multivariat, serta dipengaruhi oleh faktor eksternal maupun internal. Metode konvensional seperti analisis regresi dan time series memiliki keterbatasan dalam mengolah data dalam jumlah besar dan pola yang non-linear. Oleh karena itu, dibutuhkan pendekatan yang lebih adaptif dan cerdas dalam memproses data, salah satunya dengan teknologi data mining.

Machine learning memungkinkan peneliti untuk menggali pola tersembunyi dari data historis ekonomi, termasuk data makroekonomi yang dimiliki Bank Indonesia seperti indeks harga konsumen, nilai tukar, suku bunga, dan variabel moneter lainnya. Melalui penerapan algoritma tertentu, seperti Decision Tree, Random Forest, atau Artificial Neural Network, sistem informasi prediksi inflasi dapat dikembangkan untuk mendukung proses analisis dan pengambilan keputusan.

Penelitian ini hadir untuk mengisi kesenjangan tersebut melalui penerapan

kerangka CRISP-DM sebagai panduan metodologis yang terstruktur, disertai evaluasi komparatif yang menyeluruh antara algoritma machine learning mutakhir (XGBoost dan Random Forest), metode statistik klasik (SARIMA), serta pendekatan deep learning (LSTM). Dengan menggunakan data ekonomi yang bersumber dari Bank Indonesia, penelitian ini diharapkan mampu memberikan sumbangsih baik secara akademis maupun praktis dalam bidang pemodelan prediksi inflasi, khususnya dalam menghasilkan model dengan tingkat akurasi yang tinggi serta sistem visualisasi interaktif yang dapat dimanfaatkan secara langsung untuk mendukung pengelolaan inflasi di Kota Makassar.

1.2 Rumusan Masalah

Berdasarkan uraian di atas, dapat dirumuskan beberapa masalah yaitu sebagai berikut:

1. Seberapa baik performa model XGBoost dalam memprediksi inflasi di Kota Makassar dibandingkan dengan model *baseline* lainnya seperti SARIMA, LSTM, *Random Forest*, dan *Moving Average*?
2. Bagaimana merancang dan membangun dashboard interaktif yang dapat menyajikan data historis, hasil prediksi inflasi, dan analisis visualisasi secara informatif?

1.3 Tujuan Penelitian

Berdasarkan permasalahan yang telah dirumuskan, tujuan penelitian adalah sebagai berikut:

1. Merancang dan mengimplementasikan dashboard interaktif sebagai antarmuka visualisasi data historis dan hasil prediksi inflasi di Kota Makassar.
2. Menerapkan algoritma machine learning untuk membangun model prediksi inflasi.

1.4 Batasan masalah

Adapun batasan masalah pada pembuatan tugas akhir ini adalah sebagai berikut:

1. Prediksi yang dihasilkan bersifat jangka pendek (hingga beberapa bulan ke depan) dan hanya berlaku untuk wilayah Kota Makassar, tidak digeneralisasi ke kota atau wilayah lain.
2. Sistem informasi yang dikembangkan berupa prototype, belum diimplementasikan secara penuh dalam infrastruktur Bank Indonesia.

1.5 Manfaat Penelitian

Manfaat dari penelitian dapat dilihat sebagai berikut :

1. Menggambarkan integrasi data dengan sistem informasi untuk pemrosesan data ekonomi.
2. Menjadi model awal pengembangan aplikasi analitik prediktif dalam sektor keuangan nasional.

1.6 Landasan Teori

1.6.1 Inflasi

Inflasi merupakan kenaikan tingkat umum harga barang dan jasa dalam suatu ekonomi selama periode tertentu yang menyebabkan daya beli uang menurun. Teori klasik menyebut faktor uang (money supply) sebagai penyebab utama (monetarist), sedangkan teori lainnya menekankan biaya produksi atau cost-push dan permintaan agregat (demand-pull). Menemukan bahwa dalam jangka pendek, penawaran uang dan suku bunga berdampak signifikan terhadap inflasi di Indonesia (Pisganidy & Awaluddin, 2025). Selain itu memperlihatkan bagaimana pandemi COVID-19 mempengaruhi konvergensi inflasi regional di Indonesia, menunjukkan faktor eksternal dan spasial juga relevan.

1.6.2 Sistem informasi

Sistem informasi adalah suatu kombinasi dari teknologi informasi dan aktivitas orang yang menggunakan teknologi tersebut untuk mendukung operasi, manajemen, dan pengambilan keputusan (Putra et al., 2021). Sistem informasi modern tidak hanya menyajikan data, tetapi juga menyediakan analisis, visualisasi, dan rekomendasi untuk mendukung proses strategis. Sistem informasi tidak hanya dipandang sebagai kombinasi perangkat keras dan perangkat lunak, tetapi juga sebagai suatu entitas sosio-teknis yang melibatkan perubahan pada aspek pekerjaan, kompetensi sumber daya manusia, manajemen, serta struktur organisasi ketika sistem baru diterapkan (Neni Sahara Noerdin, 2011).

1.6.3 Machine Learning

Machine Learning (ML) merupakan salah satu cabang dari Artificial Intelligence (AI) yang berfokus pada pengembangan algoritma dan model yang memungkinkan sistem komputer belajar dari data tanpa diprogram secara eksplisit untuk setiap tugas tertentu. Machine learning didefinisikan sebagai cabang ilmu yang berfokus pada perancangan dan analisis algoritma yang memungkinkan komputer untuk belajar secara mandiri. ML berisi algoritma bersifat umum (generik) yang mampu menghasilkan informasi menarik atau bermanfaat dari sekumpulan data tanpa memerlukan penulisan kode secara spesifik. Ketika algoritma generik tersebut diberi sejumlah data, ia dapat membangun aturan, model, atau inferensi berdasarkan data yang diberikan (Burzykowski et al., 2023). Sebagai ilustrasi, sebuah algoritma yang dirancang untuk mengenali tulisan tangan dapat digunakan kembali untuk mendeteksi email spam versus non-spam tanpa perlu mengubah kode programnya. Algoritma yang sama, ketika dilatih dengan data pelatihan yang berbeda, akan menghasilkan logika klasifikasi yang berbeda pula.

1.6.4 XGBoost

XGBoost adalah teknik pembelajaran yang diawasi yang menawarkan efisiensi, adaptabilitas, dan portabilitas luar biasa. Menggunakan algoritma pembelajaran otomatis dalam kerangka kerja Gradient Boosting, XGBoost memberikan

peningkatan pohon paralel yang cepat dan efektif untuk menangani berbagai tantangan dalam ilmu data. Keunggulan utamanya meliputi skalabilitas yang tinggi, eksekusi yang cepat, dan kinerja superior dibandingkan dengan algoritma lain. Hiperparameter memegang peranan penting dalam mengoptimalkan kinerja model XGBoost (Deng & Lumley, 2024).

Dengan mengatur parameter ini, pengguna dapat memperbaiki cara algoritma beroperasi untuk mencapai hasil yang lebih baik dalam pengolahan data dan prediksi yang mereka lakukan. Integrasi machine learning dalam sistem informasi memungkinkan dilakukannya analisis data yang lebih mendalam serta menghasilkan prediksi yang lebih akurat, terutama untuk mendukung proses pengambilan keputusan (Priharsari, 2022). Algoritma ini dirancang untuk meningkatkan kecepatan dan performa prediksi dengan penggunaan sumber daya yang lebih efisien. Dengan menggunakan optimasi Bayesian, dimungkinkan untuk menyetel *hyperparameter* secara tepat dan meningkatkan performa klasifikasi pada berbagai jenis dataset. Hal ini menunjukkan bahwa teknik yang sesuai dengan karakteristik dataset sangat penting, dan optimasi *hyperparameter* memainkan peran penting dalam membangun model dengan akurasi tinggi (Sutarman et al., 2025).

1.6.5 Uji signifikan paramater

Uji signifikansi parameter merupakan prosedur statistik yang digunakan untuk menentukan apakah suatu parameter atau fitur dalam model memiliki pengaruh yang signifikan secara statistik terhadap variabel target. Dalam konteks pemodelan prediksi berbasis machine learning, uji ini berperan penting untuk memvalidasi bahwa fitur-fitur yang digunakan dalam model benar-benar memberikan kontribusi nyata terhadap akurasi prediksi, bukan sekadar noise atau korelasi semu.

Uji Permutasi (Permutation Importance Test). Dalam konteks model machine learning seperti XGBoost, uji signifikansi parameter konvensional berbasis distribusi parametrik tidak selalu dapat diterapkan secara langsung karena model tidak menghasilkan koefisien linier yang eksplisit. Sebagai alternatif, Permutation Importance digunakan untuk mengukur seberapa besar penurunan performa model ketika nilai suatu fitur diacak secara acak (permuted), sehingga hubungan antara fitur tersebut dengan variabel target dihilangkan (Fisher et al., 2019).

Secara formal, Permutation Importance untuk fitur j dihitung sebagai:

$$PI_j = (1/K) \sum [L(y, \hat{f}(X\pi_j)) - L(y, \hat{f}(X))]]$$

Pertama, kita hitung kesalahan model menggunakan data asli X . Hasilnya adalah $L(y, \hat{f}(X))$. Kita hitung ulang kesalahan model, tetapi sekarang menggunakan data yang sudah diacak $X\pi$, jika hasilnya positif besar artinya kesalahan model meningkat drastis setelah fitur j diacak. karena pengacakan bisa berbeda-beda setiap kali, kita ulangi langkah 2-4 sebanyak K kali dan ambil rata-ratanya untuk

mendapatkan nilai P_{ij} yang stabil. Fitur dengan nilai Permutation Importance yang tinggi dianggap signifikan karena penghapusan informasinya menyebabkan penurunan akurasi model yang substansial (Breiman, 2001; Fisher et al., 2019).

1.6.6 Framework dan teknologi

Dalam membangun dasbor interaktif untuk prediksi inflasi di Kota Makassar Dalam penelitian ini, berbagai framework dan teknologi digunakan untuk memastikan efisiensi dalam pemrosesan data, pengembangan model, dan visualisasi prediksi (Hao et al., n.d.). Pemilihan teknologi ini mempertimbangkan kompatibilitas dengan model serta kemudahan integrasinya. Framework dashboard yang digunakan yaitu streamlit, merupakan framework open-source yang digunakan untuk membangun aplikasi web berbasis Python secara cepat dan interaktif (*Website Streamlit*, 2018). Dalam penelitian ini, Streamlit digunakan untuk mengembangkan dasbor yang menampilkan hasil prediksi cuaca secara real-time, memungkinkan pengguna untuk mengeksplorasi data secara dinamis. Streamlit adalah kerangka kerja (framework) open-source yang berfungsi untuk membangun antarmuka pengguna (User Interface/UI) interaktif untuk aplikasi data science menggunakan bahasa pemrograman Python (Mochamad Ilham, 2024.). Kelebihan paling cepat develop, pure Python. Matplotlib, khususnya modul PyPlot, digunakan untuk membuat grafik statis seperti line chart dan scatter plot (*Website Matplotlib*, 2003).

Dalam penelitian ini, dasbor interaktif dikembangkan untuk visualisasikan hasil prediksi inflasi Kota Makassar yang dihasilkan oleh model xgboost. Dengan dasbor ini, pengguna dapat memantau prediksi, menganalisis pola historis, dan mengeksplorasi tren secara interaktif (Cohen et al., 2021). Sistem ini dirancang untuk menjadi alat yang mudah diakses, baik oleh pengguna teknis maupun non-teknis, untuk mendukung pengambilan keputusan berbasis data. Pada tahap akhir, pemanfaatan visualisasi interaktif terbukti efektif dalam meningkatkan partisipasi pengguna, khususnya di kalangan awam non-teknis. Metode ini memungkinkan mereka untuk menyelami data melalui pendekatan yang lebih alami, yang pada akhirnya memperdalam wawasan serta memperkuat keterlibatan mereka terhadap materi yang dipaparkan (Leffrang & Muller, 2021).

1.6.7 Forecasting


Peramalan (forecasting) adalah suatu estimasi mengenai kondisi di masa mendatang yang dapat dilakukan melalui berbagai pendekatan sesuai dengan karakteristik pola data yang tersedia. Proses ini dapat dilaksanakan dengan cara memanfaatkan data historis lalu memproyeksikannya ke periode depan menggunakan model matematis tertentu (pendekatan kuantitatif), atau dapat pula berupa prediksi berbasis intuisi yang bersifat subjektif (pendekatan kualitatif). Peramalan kuantitatif menerapkan metode statistik maupun beragam model matematis yang memanfaatkan data masa lalu serta hubungan antar variabel untuk memperkirakan permintaan. Sementara itu, peramalan subjektif atau kualitatif

memadukan faktor-faktor seperti intuisi, emosi, pengalaman pribadi, serta sistem nilai dari pengambil keputusan dalam melakukan prediksi. Peramalan memiliki manfaat yang sangat berarti, antara lain membantu pemerintah dan perusahaan dalam menyusun perencanaan serta mengambil keputusan yang lebih baik (Lusiana & Yuliarty, n.d.).

Secara umum, terdapat tiga jenis peramalan (forecasting), yakni: peramalan ekonomi yang berkaitan dengan indikator-indikator ekonomi makro (misalnya inflasi, pertumbuhan PDB, atau tingkat pengangguran); peramalan teknologi yang berhubungan dengan laju perkembangan teknologi; serta peramalan permintaan yang terkait dengan prediksi volume permintaan terhadap produk atau layanan suatu perusahaan. Selain ketiga jenis tersebut, Seto (2016) mengemukakan beberapa komponen pola data dalam peramalan, yaitu:

1. Tren (Trend/T), yaitu kondisi ketika terjadi kenaikan atau penurunan data secara bertahap dalam periode waktu yang panjang.
2. Musiman (Seasonality/S), yaitu pola yang berulang setelah rentang waktu tertentu, seperti harian, mingguan, bulanan, triwulan, atau tahunan.
3. Siklus (Cycles/C), yaitu pola data yang muncul setiap beberapa tahun sekali, umumnya dipengaruhi oleh fluktuasi ekonomi jangka panjang yang berkaitan dengan siklus bisnis.
4. Horizontal (Horizontal/H) atau Stasioner, yaitu kondisi ketika nilai data berfluktuasi di sekitar nilai rata-rata yang tetap dan stabil, atau dengan kata lain stasioner terhadap nilai rata-ratanya.

Time Series Components



Gambar 1. jenis pola ramalan (Sumber : *openstax Components of Time Series Analysis*)

BAB II METODE PENELITIAN

Tabel 1. waktu penelitian

No	Kegiatan	November	Desember	Januari	Februari	Maret	April
1	Observasi	✓					
2	Studi Literatur	✓					
3	Pengumpulan Data		✓				
4	Pra-pemrosesan Data			✓			
5	Implementasi Model			✓	✓	✓	✓

2.1 Metode penelitian

Penelitian ini menggunakan metodologi CRISP-DM (Cross-Industry Standard Process for Data Mining) sebagai kerangka kerja utama. CRISP-DM dipilih karena menyediakan pendekatan sistematis dan terstruktur yang mencakup seluruh siklus proyek data, mulai dari pemahaman bisnis hingga implementasi mode(Nogueira Costa, 2020).

2.2 Waktu dan lokasi penelitian

Penelitian ini dilaksanakan mulai dari oktober 2025 sampai dengan mei 2026, dilaksanakan di Bank Indonesia, divisi kelompok perumusan kebijakan provinsi.

2.3 Variabel Penelitian

Penelitian ini menggunakan tiga variabel utama sebagaimana disajikan pada Tabel 2 berikut.

Tabel 2. Variabel

Variabel	Tipe Data	Peran	Periode
Tahun	Numerik (Integer)	Independen	2000–2025
Bulan	Numerik (Integer 1–12)	Independen	Januari–Desember
Inflasi YoY (%)	Numerik (Float)	Dependen / Target	Bulanan

Variabel Tahun dan Bulan berfungsi sebagai fitur input (feature) yang merepresentasikan dimensi waktu. Pada model XGBoost Lag Features, variabel input diperluas dengan menambahkan fitur turunan berupa nilai inflasi pada lag waktu tertentu dan komponen siklik musiman.

2.4 Teknik Pengumpulan Data

2.4.1 Sumber Data

Data yang digunakan dalam penelitian ini adalah data sekunder resmi yang bersumber dari Badan Pusat Statistik (BPS), yaitu lembaga pemerintah yang bertanggung jawab atas penghitungan dan publikasi data statistik nasional termasuk Indeks Harga Konsumen (IHK) dan inflasi. Sumber data meliputi:

- Portal BPS Kota Makassar (makassar.bps.go.id): Data indeks dan inflasi bulanan spesifik Kota Makassar.
- Portal BPS Provinsi Sulawesi Selatan (sulsel.bps.go.id): Data pendukung dan seri historis inflasi regional.
- Portal BPS Nasional (bps.go.id): Tabel dinamis inflasi kota-kota IHK nasional.

2.4.2 Metode Pengumpulan

Pengumpulan data dilakukan melalui metode dokumentasi, yaitu mengunduh dan mencatat data inflasi bulanan dari publikasi resmi BPS. Langkah-langkah pengumpulan data adalah sebagai berikut:

1. Mengakses portal BPS Kota Makassar dan mengunduh tabel inflasi bulanan YoY dalam format Excel (.xlsx) atau CSV.
2. Memverifikasi kelengkapan data untuk setiap bulan pada periode 2000–2025.
3. Menyelaraskan format tanggal dan nama kolom agar konsisten untuk proses analisis.
4. Menyimpan data mentah ke file CSV dengan kolom: Tanggal, Tahun, Bulan, Bulan_Angka, dan Inflasi.

2.4.3 Instrumen Pengumpulan Data

Instrumen pengumpulan data yang digunakan adalah lembar pengamatan dokumentasi yang berisi daftar periksa (checklist) kelengkapan data untuk memastikan tidak ada bulan yang terlewat pada periode sampel. Validasi awal dilakukan dengan membandingkan data yang diperoleh dari dua sumber BPS yang berbeda untuk memastikan konsistensi angka inflasi.

2.5 Teknik Analisis Data

Analisis data dalam penelitian ini mengikuti alur standar pipeline machine learning untuk data time series. Tahapan analisis data diuraikan sebagai berikut.

2.5.1 Pra-pemrosesan Data (Data Preprocessing)

Pra-pemrosesan data bertujuan memastikan kualitas dan konsistensi data sebelum masuk ke tahap pemodelan. Langkah-langkah yang dilakukan meliputi:

1. Pemeriksaan nilai hilang (missing values): Data dicek untuk mendeteksi nilai kosong pada setiap kolom. Apabila ditemukan nilai hilang pada data inflasi, dilakukan imputasi menggunakan interpolasi linear.
2. Konversi tipe data: Kolom Tahun dan Bulan_Angka dipastikan bertipe integer, sedangkan kolom Inflasi bertipe float.
3. Pembuatan kolom datetime: Kolom Tanggal_dt dibuat dari kombinasi Tahun dan Bulan_Angka (hari default = 1) menggunakan fungsi `pd.to_datetime()` untuk keperluan visualisasi time series.
4. Pengurutan data: Data diurutkan berdasarkan Tanggal_dt secara ascending untuk memastikan urutan kronologis.
5. Normalisasi fitur Tahun: Fitur tahun dinormalisasi menggunakan `StandardScaler` untuk mencegah dominansi nilai besar pada model LSTM dan XGBoost.
6. Rekayasa fitur (feature engineering) untuk model lag: Dibuat fitur lag inflasi (t-1, t-2, t-3, t-6, t-12) serta komponen musiman siklik (sin dan cos bulan) sebagaimana ditampilkan pada Tabel 3.

Tabel 3. Fitur Lag untuk Model XGBoost Lag Features

No	Nama Fitur	Deskripsi	Kategori
1	Inflasi_Lag1	Nilai inflasi 1 bulan sebelumnya	Lag / Autoregresif
2	Inflasi_Lag2	Nilai inflasi 2 bulan sebelumnya	Lag / Autoregresif
3	Inflasi_Lag3	Nilai inflasi 3 bulan sebelumnya	Lag / Autoregresif

No	Nama Fitur	Deskripsi	Kategori
4	Rolling_Mean_3	Rata-rata bergerak 3 bulan terakhir	Rolling Statistics
5	Rolling_Std_3	Standar deviasi bergerak 3 bulan	Rolling Statistics
6	Rolling_Mean_6	Rata-rata bergerak 6 bulan terakhir	Rolling Statistics
7	Rolling_Mean_12	Rata-rata bergerak 12 bulan terakhir	Rolling Statistics
8	Rolling_Min_3	Nilai minimum dari 3 bulan terakhir	Rolling Statistics
9	Rolling_Max_3	Nilai maksimum dari 3 bulan terakhir	Rolling Statistics
10	sin_Month	$\sin(2\pi \times \text{bulan} / 12)$	Fitur Musiman Siklik
11	cos_Month	$\cos(2\pi \times \text{bulan} / 12)$	Fitur Musiman Siklik
12	Tahun_Continu	Tahun dikurangi 2000 (0–25)	Fitur Tren

2.5.2 Analisis Data Eksploratif (Exploratory Data Analysis)

Sebelum pemodelan, dilakukan EDA untuk memahami karakteristik data inflasi Kota Makassar, meliputi:

1. Visualisasi time series inflasi untuk mengidentifikasi tren jangka panjang, siklus, dan anomali.
2. Analisis statistik deskriptif: mean, median, standar deviasi, nilai minimum, maksimum, skewness, dan kurtosis.
3. Analisis pola musiman: rata-rata inflasi per bulan dan per tahun untuk mendeteksi efek musiman (seasonality).
4. Distribusi data: histogram dan boxplot untuk memahami sebaran inflasi dan mendeteksi outlier.

2.5.3 Pembagian Data (Train-Test Split)

Data dibagi menjadi data latih (training set) dan data uji (test set) menggunakan strategi pembagian berbasis waktu (time-based split) untuk menghindari data leakage. Proporsi yang digunakan adalah 80% data latih dan 20% data uji. Dengan total 309 observasi, data latih mencakup 247 observasi (april 2000 – Desember 2025) dan data uji mencakup 62 observasi (november 2000 – Desember 2025).

Pembagian berbasis waktu dilakukan agar evaluasi model mencerminkan kondisi prediksi nyata, di mana model hanya boleh menggunakan data historis dan tidak boleh melihat data masa depan.

2.5.4 Pemilihan dan Pelatihan Model

Penelitian ini melatih dan membandingkan enam model prediksi sebagaimana disajikan pada Tabel 4. Model utama yang menjadi fokus penelitian adalah XGBoost dan XGBoost Lag Features, sementara model lainnya berfungsi sebagai baseline pembanding.

Tabel 4. Model yang Diimplementasikan dalam Penelitian

Model	Deskripsi Singkat	Peran
Random Forest	Ensemble pohon keputusan dengan bagging	Baseline ensemble
XGBoost	Gradient boosting dengan regularisasi L1/L2	Model utama
XGBoost Lag Features	XGBoost dengan fitur lag 1,2,3,6,12 bulan	Model (autoregressive)
LSTM	Deep learning untuk temporal dependencies	Deep learning baseline
Moving Average (12)	Rata-rata bergerak 12 bulan	Naive baseline
SARIMA	Model statistik musiman klasik	Statistical baseline

Proses pelatihan XGBoost dilakukan dengan optimasi hyperparameter menggunakan teknik grid search atau random search pada parameter utama: jumlah estimator (`n_estimators`), kedalaman pohon maksimum (`max_depth`), learning rate (`eta`), subsample ratio, dan regularisasi (`alpha`, `lambda`). Model LSTM menggunakan arsitektur dengan dua lapisan LSTM diikuti oleh lapisan Dense, dengan urutan waktu (timesteps) sebesar 12 bulan.

2.5.5 Evaluasi Model

Evaluasi model dilakukan pada data uji menggunakan enam metrik sebagaimana disajikan pada Tabel 5. Penggunaan beberapa metrik evaluasi bertujuan memberikan penilaian yang komprehensif terhadap performa model dari sudut pandang yang berbeda.

Tabel 5. Metrik Evaluasi Model

Simbol	Nama Lengkap	Penjelasan	Kriteria Terbaik
MAE	Mean Absolute Error	Rata-rata error absolut (unit asli %)	Lebih kecil lebih baik
RMSE	Root Mean Squared Error	Penalti lebih besar pada outliers	Lebih kecil lebih baik
R ²	Coefficient of Determination	Proporsi varians yang dijelaskan model	Mendekati 1
MAPE	Mean Absolute Percentage Error	Error dalam persen, sensitif pada nilai kecil	Lebih kecil lebih baik
sMAPE	Symmetric MAPE	Lebih stabil pada nilai mendekati nol/negatif	Lebih kecil lebih baik
MASE	Mean Absolute Scaled Error	Dibandingkan naive seasonal forecast	< 1 berarti lebih baik dari naive

Selain evaluasi metrik numerik, dilakukan juga perbandingan visual antara nilai aktual dan prediksi pada data uji untuk menilai kemampuan model menangkap pola tren dan musiman. Model terbaik ditentukan berdasarkan nilai MAE terkecil sebagai metrik primer, dengan konfirmasi dari metrik lainnya menggunakan sistem ranking rata-rata (average rank) dari seluruh metrik.

MAE mengukur rata-rata selisih absolut antara prediksi dan aktual. Karena menggunakan nilai absolut, MAE tidak memperhatikan arah error (tidak peduli overestimate atau underestimate). MAE mudah diinterpretasikan karena satuannya sama dengan unit variabel target

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

MSE mengukur rata-rata kuadrat selisih antara prediksi dan aktual. Karena dikuadratkan, error besar mendapat penalti yang jauh lebih besar dibandingkan error kecil.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

RMSE adalah akar kuadrat dari MSE. Dengan mengambil akar, satuannya kembali sama dengan unit variabel target, sehingga lebih mudah diinterpretasikan dibandingkan MSE.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

MAPE mengukur rata-rata persentase absolut error antara prediksi dan aktual. Hasilnya dalam bentuk persentase, sehingga sangat intuitif dan mudah dipahami oleh non-teknis.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$$

sMAPE adalah versi simetris dari MAPE. Dirancang untuk mengatasi kelemahan MAPE yang tidak simetris (underestimate lebih dihukum). sMAPE menghitung persentase error dengan membagi selisih absolut terhadap rata-rata dari aktual dan prediksi.

$$sMAPE = \frac{1}{n} \sum_{i=1}^n \frac{2|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \times 100\%$$

R^2 mengukur seberapa baik model regresi menjelaskan variabilitas data. Nilainya berkisar antara 0 hingga 1 (atau 0% hingga 100%).

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

2.5.6 Prediksi dan Confidence Interval

Model terbaik digunakan untuk menghasilkan prediksi inflasi pada periode Januari dan Maret 2026 sebagai output resmi penelitian. Untuk memberikan ukuran ketidakpastian prediksi, dihitung confidence interval 95% dengan rumus:

$$CI\ 95\% = \text{Prediksi} \pm (1,96 \times RMSE)$$

Pendekatan ini mengasumsikan distribusi error mendekati normal dan menggunakan MAE sebagai estimasi standar deviasi error. Untuk model rekursif (LSTM, Moving Average, XGBoost Lag, SARIMA), prediksi dilakukan secara iteratif (recursive forecasting) dari observasi terakhir hingga horizon yang ditargetkan.

2.6 Rancang Bangun Dashboard Analisis

2.6.1 Arsitektur Sistem

Dashboard analisis dibangun menggunakan framework Streamlit berbasis Python yang memungkinkan pembangunan aplikasi web interaktif secara cepat tanpa memerlukan penulisan kode HTML/CSS/JavaScript secara eksplisit. Arsitektur sistem terdiri dari tiga lapisan utama:

1. Lapisan Data: File CSV data historis inflasi dan file model terlatih (.pkl untuk scikit-learn/XGBoost/SARIMA dan .keras/.h5 untuk LSTM) disimpan di server lokal.
2. Lapisan Logika (Backend): Skrip Python menangani pemuatan model, pra-pemrosesan input, inferensi prediksi, dan perhitungan metrik evaluasi.
3. Lapisan Presentasi (Frontend): Antarmuka Streamlit menampilkan visualisasi interaktif menggunakan library Plotly dan Matplotlib.

2.6.2 Fitur Dashboard


Dashboard dirancang dengan lima tab utama sebagaimana ditampilkan pada Tabel 6.

Tabel 6. Komponen Fitur Dashboard Analisis

Tab / Fitur	Konten Utama
Dashboard Utama	Time series interaktif, distribusi, tren tahunan, statistik ringkasan
Prediksi Kustom	Input tahun dan bulan, pilih model, tampilkan hasil beserta 95% CI
Analisis Model	Tabel metrik, bar chart perbandingan, heatmap ranking antar model
Data & Statistik	Preview data, statistik deskriptif, breakdown per tahun dan per bulan
Tentang	Dokumentasi metodologi, penjelasan model, referensi data BPS

2.7 Alur penelitian

Ringkasan alur pembuatan dasbor yang akan dilakukan dapat dilihat pada gambar 2 di bawah.



Gambar 2. Alur penelitian

BAB III HASIL DAN PEMBAHASAN

3.1 Gambaran Umum Data Penelitian

Pada bagian ini disajikan hasil eksplorasi dan analisis awal terhadap dataset inflasi bulanan Kota Makassar yang digunakan sebagai basis pelatihan seluruh model prediksi. Pemahaman yang mendalam terhadap karakteristik data merupakan langkah fundamental sebelum proses pemodelan dilaksanakan.

3.1.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah data inflasi bulanan Year-on-Year (YoY) Kota Makassar yang diperoleh dari Badan Pusat Statistik (BPS). Data mencakup periode Januari 2000 hingga Desember 2025 dengan total 309 observasi. Struktur dataset ditampilkan pada Tabel 7 berikut.

Tabel 7. Struktur dan Kualitas Dataset Inflasi Makassar

Kolom	Tipe Data	Jumlah Baris	Missing	Rentang Nilai
Tahun	Integer	312	0	2000 – 2025
Bulan_Angka	Integer	312	0	1 – 12
Bulan	String	312	0	Januari – Desember
Inflasi	Float	312	0	-1,7400– 9,4400

Berdasarkan Tabel 3.1, dataset memiliki kualitas yang sangat baik dengan tidak ditemukan nilai hilang (missing values) pada seluruh kolom. Rentang nilai inflasi berkisar antara -1.7400 hingga 9.4400, mengindikasikan adanya variasi kondisi deflasi (inflasi negatif) hingga inflasi yang cukup tinggi selama periode pengamatan.

Kondisi deflasi yang tercatat pada nilai minimum -1,0830% terjadi akibat pencabutan subsidi BBM pemerintah yang menyebabkan tekanan terhadap permintaan agregat di Kota Makassar. Sebaliknya, inflasi tertinggi 9.4400 terjadi pada periode pasca-pandemi seiring dengan normalisasi aktivitas ekonomi dan kenaikan harga komoditas global.

3.1.2 Statistik Deskriptif

Analisis statistik deskriptif dilakukan untuk memahami sebaran, tendensi sentral, dan bentuk distribusi data inflasi Kota Makassar. Hasil analisis disajikan pada Tabel 8.

Tabel 8. Statistik Deskriptif Inflasi Bulanan Kota Makassar (2000–2025)

Statistik	Nilai (%)	Statistik	Nilai	Statistik	Nilai
Mean	0,464167	Minimum	-1,740000	Skewness	3,676379
Median	0,350000	Maksimum	9,440000	Kurtosis	32,027540
Std. Deviasi	0,896611	Q1 (25%)	-0,600000	Shapiro-Wilk p	0,0432
Variance	0,803911	Q3 (75%)	0,770000	ADF Test p	0,0011
Coeff. Variation	54,47%	IQR	0,830000	Stasioneritas	YA (H0 tolak)


Berdasarkan hasil analisis statistik deskriptif, data memiliki nilai rata-rata (mean) sebesar 0,464% dengan median 0,350%, yang mengindikasikan distribusi data condong ke kanan (right-skewed). Hal ini dikonfirmasi oleh nilai skewness sebesar 3,68 (>2). Standar deviasi sebesar 0,897 dengan koefisien variasi 54,47% menunjukkan bahwa data memiliki tingkat variabilitas yang tinggi. Nilai minimum tercatat -1,74% dan maksimum 9,44%, yang mengindikasikan adanya outlier positif ekstrem.. Sementara itu, uji stasioneritas ADF menunjukkan p-value 0,0011 ($<0,05$), yang berarti data telah stasioner dan layak digunakan untuk analisis deret waktu lebih lanjut.

Koefisien variasi sebesar 54,47% menunjukkan tingkat fluktuasi yang cukup besar, mengindikasikan bahwa inflasi Kota Makassar rentan terhadap guncangan ekonomi eksternal. ADF Test ($p = 0,0011$): Data stasioner pada tingkat signifikansi 5%. Ini berarti data tidak memiliki akar unit (unit root) dan cocok untuk analisis deret waktu (time series).

3.1.3 Analisis Pola Musiman

Hasil analisis seasonal decomposition dengan model aditif dan periode 12 bulan berhasil memisahkan komponen tren jangka panjang, pola musiman, dan komponen residual. Komponen musiman menunjukkan adanya pola yang berulang setiap tahun, di mana inflasi cenderung meningkat pada bulan-bulan menjelang Lebaran (biasanya April–Juni) akibat lonjakan permintaan pangan, serta pada bulan Desember–Januari akibat musim liburan akhir tahun.

Heatmap inflasi per bulan per tahun mengonfirmasi pola ini, di mana sel-sel dengan warna lebih hangat (inflasi tinggi) terkonsentrasi pada bulan-bulan tersebut di hampir setiap tahun pengamatan. Bulan-bulan dengan rata-rata inflasi terendah umumnya terjadi pada Februari–Maret, bertepatan dengan periode pasca liburan dan awal tahun anggaran pemerintah.



Gambar 3. Heatmap inflasi

3.1.4 Analisis Tren Tahunan

Analisis tren tahunan dilakukan dengan menghitung rata-rata inflasi per tahun untuk mengidentifikasi pola jangka panjang. Rata-rata inflasi tertinggi terjadi pada tahun 2022 sebesar 4,8700% akibat kenaikan harga energi dan pangan global pasca pandemi. Rata-rata inflasi terendah terjadi pada tahun 2020 sebesar 0,9300% yang mencerminkan dampak resesi ekonomi akibat pandemi COVID-19. Secara keseluruhan, terdapat tren penurunan inflasi dari 2015 menuju 2020, diikuti kenaikan tajam pada 2022, dan normalisasi pada 2023–2024. Pola tren non-linear ini menjadi alasan digunakannya model machine learning yang mampu menangkap hubungan non-linier dibandingkan metode regresi linear biasa.

3.2 Hasil Pra-Pemrosesan Data

3.2.1 Pembersihan dan Transformasi Data

Proses pra-pemrosesan data dilaksanakan untuk memastikan kualitas input yang diberikan ke setiap model. Tahapan yang dilakukan adalah sebagai berikut. Pertama, pemeriksaan nilai hilang dilakukan menggunakan fungsi `isnull().sum()` pada seluruh kolom dataset. Hasilnya menunjukkan tidak terdapat nilai hilang sehingga tidak diperlukan imputasi data.

Kedua, konversi kolom tanggal dilaksanakan dengan membuat kolom `Tanggal_dt` bertipe `datetime` dari kombinasi kolom `Tahun` dan `Bulan_Angka` menggunakan `pd.to_datetime(dict(year=df['Tahun'], month=df['Bulan_Angka'], day=1))`. Kolom `datetime` ini digunakan untuk pengurutan data dan visualisasi time series.

Ketiga, normalisasi fitur tahun dilakukan menggunakan `StandardScaler` dari `scikit-learn`. Fitur `Tahun` dinormalisasi agar berada dalam rentang yang setara

dengan fitur Bulan sehingga tidak terjadi dominansi nilai skala besar pada model tree-based dan LSTM. Scaler disimpan ke file `year_scaler.pkl` untuk digunakan pada tahap prediksi.

3.2.2 Rekayasa Fitur

Rekayasa fitur (feature engineering) dilakukan khusus untuk model XGBoost Lag Features dengan menambahkan tujuh fitur turunan dari data inflasi historis. Fitur `lag_1`, `lag_2`, `lag_3`, `lag_6`, dan `lag_12` masing-masing merepresentasikan nilai inflasi pada 1, 2, 3, 6, dan 12 bulan sebelumnya. Penambahan fitur `lag_12` sangat penting karena menangkap pola musiman tahunan yang teridentifikasi pada analisis EDA.

Selain fitur lag, ditambahkan pula dua fitur siklik musiman yaitu `month_sin` = $\sin(2\pi \times \text{Bulan} / 12)$ dan `month_cos` = $\cos(2\pi \times \text{Bulan} / 12)$. Kedua fitur ini merepresentasikan posisi bulan dalam siklus tahunan secara kontinyu, sehingga model mampu memahami bahwa Desember (bulan 12) bertetangga dengan Januari (bulan 1) dalam siklus musiman, berbeda dengan representasi linear biasa yang menganggap keduanya berjauhan.

3.2.3 Pembagian Data

Data dibagi menggunakan strategi time-based split dengan proporsi 80:20. Data latih mencakup 247 observasi dari Januari 2000 hingga oktober 2020, sedangkan data uji mencakup 62 observasi dari november 2020 hingga Desember 2025. Pembagian berbasis waktu ini memastikan tidak terjadi kebocoran data (data leakage), di mana model tidak dapat melihat data masa depan selama proses pelatihan.

3.3 Hasil Pelatihan Model

3.3.1 Model Random Forest

Model Random Forest dilatih menggunakan fitur input Tahun (setelah normalisasi) dan Bulan_Angka. Algoritma ini membangun 100 pohon keputusan (default) secara paralel menggunakan teknik bagging, di mana setiap pohon dilatih pada subset acak dari data latih. Prediksi akhir merupakan rata-rata output seluruh pohon.

Hasil pelatihan menunjukkan bahwa Random Forest mampu menangkap hubungan non-linear antara waktu dan inflasi dengan baik. Namun, karena model ini hanya menggunakan fitur waktu (tahun dan bulan) tanpa informasi lag historis, kemampuan prediksinya dibatasi oleh informasi yang tersedia dalam dimensi waktu saja.

3.3.2 Model XGBoost

Model XGBoost (Extreme Gradient Boosting) merupakan model utama dalam penelitian ini. XGBoost dilatih dengan teknik gradient boosting, di mana setiap pohon baru dilatih untuk memprediksi residual (selisih antara nilai aktual dan prediksi saat ini) dari iterasi sebelumnya. Proses ini diulang secara iteratif hingga

sejumlah T pohon terbentuk atau kriteria berhenti terpenuhi.

Optimasi hyperparameter dilakukan menggunakan 5-fold cross-validation pada data latih. Parameter terbaik yang diperoleh disajikan pada Tabel 9.

Tabel 9. Hyperparameter Optimal Model XGBoost

Parameter	Nilai Optimal	Keterangan
n_estimators	500	Jumlah pohon keputusan dalam ensemble
max_depth	4	Kedalaman maksimum tiap pohon
learning_rate (eta)	0,05	Laju pembelajaran; nilai kecil mencegah overfitting
subsample	0,8	Proporsi sampel yang digunakan tiap pohon
colsample_bytree	0,8	Proporsi fitur yang digunakan tiap pohon
min_child_weight	3	Bobot minimum untuk split node
gamma	0,1	Regulasi penambahan pohon baru (pruning)
reg_alpha (L1)	0,01	Regularisasi Lasso pada bobot daun
reg_lambda (L2)	1,0	Regularisasi Ridge pada bobot daun
objective	reg:squarederror	Fungsi loss regresi MSE

Learning rate yang rendah (0,05) dikombinasikan dengan jumlah pohon yang besar (500) merupakan strategi umum yang efektif pada XGBoost untuk mencapai generalisasi yang baik. Nilai subsample dan colsample_bytree sebesar 0,8 memberikan efek regularisasi stochastic yang mencegah overfitting. Regularisasi L2 (reg_lambda = 1,0) dan L1 (reg_alpha = 0,01) menambahkan penalti pada kompleksitas model, menjaga agar model tidak terlalu bergantung pada fitur atau nilai leaf tertentu.

3.3.3 Model XGBoost Lag Features

Model XGBoost Lag Features menggunakan fitur yang diperluas dengan menambahkan nilai inflasi historis pada lag 1, 2, 3, 6, dan 12 bulan, serta komponen siklik musiman (sin dan cos bulan). Penambahan fitur lag memungkinkan model menangkap pola autoregresif pada data inflasi, yakni hubungan antara nilai inflasi saat ini dengan nilai inflasi di masa lalu.

Karena model ini menggunakan nilai inflasi aktual sebagai fitur, prediksi untuk horizon lebih dari satu bulan ke depan harus dilakukan secara rekursif:

prediksi bulan $t+1$ digunakan sebagai input untuk prediksi bulan $t+2$, dan seterusnya. Pendekatan ini memiliki keterbatasan berupa akumulasi error seiring dengan bertambahnya horizon prediksi.

3.3.4 Model LSTM

Model Long Short-Term Memory (LSTM) dibangun menggunakan TensorFlow/Keras dengan arsitektur dua lapisan LSTM masing-masing berukuran 64 unit, diikuti oleh dropout rate 0,2 untuk regulasi, dan lapisan Dense dengan 1 unit sebagai output. Model dilatih menggunakan urutan temporal (sequence) berupa 12 timestep terakhir dari fitur Tahun (yang dinormalisasi) dan Bulan.

LSTM secara khusus dirancang untuk menangkap dependensi jangka panjang dalam data sekuensial melalui mekanisme gerbang (forget gate, input gate, output gate) yang mengontrol aliran informasi antar timestep. Pelatihan dilaksanakan selama 100 epoch dengan batch size 16 dan learning rate 0,001 menggunakan optimizer Adam.

3.3.5 Model Moving Average dan SARIMA

Model Moving Average (MA-12) digunakan sebagai baseline naif dengan memprediksi nilai inflasi sebagai rata-rata 12 bulan terakhir. Model ini merupakan representasi dari pengetahuan minimal yang dapat dicapai tanpa pembelajaran dari pola kompleks data.

Model SARIMA (Seasonal AutoRegressive Integrated Moving Average) diestimasi menggunakan library statsmodels dengan order $(p,d,q)(P,D,Q,12)$ yang ditentukan berdasarkan analisis ACF dan PACF. Model SARIMA berfungsi sebagai baseline statistik klasik untuk dibandingkan dengan model machine learning.

3.4 Hasil Evaluasi dan Perbandingan Model


3.4.1 Performa Model pada Data Uji

Evaluasi dilakukan pada data uji (Januari 2020 – Desember 2025) menggunakan enam metrik. Hasil evaluasi seluruh model disajikan pada Tabel 10 dan gambar 2

Tabel 10. Hasil Evaluasi Kinerja Seluruh Model pada Data Uji (Baris hijau = model terbaik)

Model	MAE (%)	RMSE (%)	R^2	MAPE (%)	sMAPE (%)	MASE	Rank
XGBoost	0.1736 39	0.279 770	0.726 348	93.645 1%	70.867 0%	0.248 722	1

Model	MAE (%)	RMSE (%)	R ²	MAPE (%)	sMAPE (%)	MASE	Rank
Random Forest	0.215086	0.301406	0.682386	111.2672%	91.3405%	0.308089	2
LSTM	0.376213	0.558717	0.091392	149.5027%	114.1829%	0.538888	3
SARIMA	0.380128	0.568644	0.130520	101.9228%	154.4344%	0.544497	4
Moving Average (Baseline)	0.389213	0.568658	0.130574	99.8658%	155.7434%	0.557510	5



Gambar 4. performa model

3.4.2 Analisis Model XGBoost sebagai Model Terbaik


Berdasarkan Tabel 10, model XGBoost menempati peringkat pertama dengan nilai MAE terkecil sebesar 0.173639 poin persentase.

3.4.4 Analisis Feature Importance XGBoost

Salah satu keunggulan XGBoost adalah kemampuannya menghasilkan ukuran kepentingan fitur (feature importance) yang menjelaskan kontribusi relatif setiap fitur terhadap prediksi. Hasil analisis feature importance disajikan pada Tabel 11 dan gambar 4.

Tabel 11. Feature Importance Model XGBoost Lag Features

Rank	Nama Fitur	Importance Score	Kategori
1	Rolling_Mean_3	0.289914	Rolling Statistics
2	Rolling_Mean_12	0.173827	Rolling Statistics
3	Inflasi lag 2	0.150424	lag
4	Rolling min 3	0.147347	Rolling Statistics
5	Rolling max 3	0.102519	Rolling Statistics
6	Inflasi lag 1	0.046347	lag
7	Rolling std 3	0.044999	Rolling Statistics
8	Cos month	0.013395	musiman
9	Sin_month	0.011686	musiman
10	Tahun continue	0.0123	Tren
11	Rolling mean 6	0.006786	Rolling Statistics
12	Inflasi lag 3	0.0038	lag



Gambar 6. Xgboost Feature Importance


Hasil analisis feature importance memberikan beberapa temuan yang menarik secara teoritis maupun praktis. Rolling_Mean_3 menduduki posisi teratas dengan kontribusi besar, menunjukkan bahwa tren rata-rata inflasi satu tahun ke belakang merupakan prediktor terkuat. Hal ini sejalan dengan fakta bahwa inflasi YoY memiliki persistensi tinggi—nilai inflasi saat ini sangat bergantung pada kondisi inflasi dalam periode 12 bulan terakhir. Berdasarkan hasil analisis feature importance pada model XGBoost, diketahui bahwa lima fitur dengan kontribusi terbesar adalah Rolling_Mean_3 (29,0%), Rolling_Mean_12 (17,4%), Inflasi_Lag2 (15,0%), Rolling_Min_3 (14,7%), dan Rolling_Max_3 (10,3%). Kelima fitur ini secara kumulatif menyumbang 86,4% terhadap keseluruhan prediksi model. Hal ini mengindikasikan bahwa pergerakan inflasi sangat ditentukan oleh nilai-nilai masa lalu, khususnya rata-rata bergerak 3 dan 12 bulan serta nilai inflasi dua bulan sebelumnya. Sebaliknya, fitur IHK memiliki nilai importance hanya 0,2%, yang mengindikasikan bahwa informasi dalam IHK telah terwakili oleh fitur-fitur rolling statistics lainnya. Temuan ini menegaskan bahwa model XGBoost lebih mengandalkan fitur turunan (lag dan rolling) dibandingkan fitur mentah IHK untuk memprediksi inflasi.

3.5 Hasil Prediksi Inflasi Januari–Maret 2026

3.5.1 Prediksi Menggunakan Model Terbaik

Berdasarkan hasil evaluasi pada Bagian 3.4, model XGBoost ditetapkan sebagai model terbaik dan digunakan untuk menghasilkan prediksi resmi inflasi Kota

Makassar untuk periode Januari dan februari 2026. Prediksi dilakukan secara langsung (direct forecasting) karena XGBoost hanya menggunakan fitur Tahun dan Bulan sebagai input, sehingga tidak memerlukan nilai inflasi aktual periode sebelumnya. Hasil prediksi disajikan pada Tabel 12 dan gambar 5.



Gambar 7. Grafik prediksi 2026

Tabel 12. Prediksi Inflasi Kota Makassar Januari–februari 2026

Periode	Model	Prediksi	Keterangan
Januari 2026	XGBoost	0.2563%	Model terbaik (MAE 0.173639%)
Februari 2026	XGBoost	0.1956%	Model terbaik (MAE 0.173639%)

3.5.2 Analisis Hasil Prediksi

Berdasarkan hasil forecasting menggunakan model XGBoost, inflasi Januari 2026 diprediksi sebesar 0,2563% dengan Confidence Interval 95% berkisar antara -0,2920% hingga 0,8046%. Sementara itu, inflasi Februari 2026 diprediksi sebesar 0,1956% dengan CI 95% antara -0,3527% hingga 0,7439%. Lebar interval kepercayaan sebesar $\pm 0,55\%$ mencerminkan tingkat ketidakpastian yang masih cukup tinggi, yang disebabkan oleh RMSE model sebesar 0,2798% pada data uji.

Dengan tingkat kepercayaan 95%, terdapat kemungkinan sekitar 18% terjadinya deflasi pada Januari 2026 dan 24% pada Februari 2026 (ditandai dengan batas bawah interval yang negatif). Meskipun demikian, titik estimasi (point estimate) menunjukkan bahwa perekonomian diprediksi masih berada dalam zona inflasi rendah, konsisten dengan tren inflasi Indonesia pasca-2023 yang cenderung terkendali di kisaran 0,2-0,3% per bulan.

$$\text{CI 95\%: Prediksi} \pm (z \times \text{RMSE}) = 0,2563\% \pm (1,96 \times 0,279770\%) = 0,8046\%$$

Perlu dicatat bahwa confidence interval dihitung menggunakan pendekatan $95 \times \text{MAE}$ sebagai estimasi standar deviasi error, dengan asumsi distribusi error yang mendekati normal. Meskipun pendekatan ini bersifat aproksimasi, nilai CI yang dihasilkan memberikan gambaran yang praktis tentang rentang ketidakpastian prediksi.

3.6 Hasil Rancang Bangun Dashboard Analisis

3.6.1 Arsitektur dan Implementasi Dashboard

Dashboard analisis inflasi Kota Makassar berhasil diimplementasikan menggunakan framework Streamlit versi 1.28 dengan Python 3.11. Dashboard dibangun dengan arsitektur tiga lapisan: lapisan data (file CSV dan model terlatih), lapisan logika (skrip Python untuk pemrosesan dan inferensi), dan lapisan presentasi (antarmuka Streamlit dengan visualisasi Plotly).

Seluruh model yang telah dilatih disimpan menggunakan joblib (untuk model scikit-learn, XGBoost, dan SARIMA) dan TensorFlow SavedModel (untuk LSTM). Mekanisme caching menggunakan dekorator `@st.cache_resource` diterapkan pada fungsi pemuatan model sehingga model hanya dimuat satu kali ke memori dan dapat digunakan kembali tanpa overhead loading ulang pada setiap interaksi pengguna.

3.6.2 Fitur dan Komponen Dashboard

Dashboard dirancang dengan antarmuka multi-tab yang memisahkan fungsi analisis eksploratif, prediksi, dan perbandingan model. Rincian fitur setiap tab disajikan pada Tabel 13.

Tabel 13. Fitur dan Status Implementasi Komponen Dashboard

Tab	Konten & Fitur	Status Implementasi
Dashboard Utama	Time series inflasi 2000–2025 (Plotly interaktif), histogram distribusi, bar chart rata-rata per bulan, tren tahunan	Berhasil ditampilkan dengan hover tooltip dan zoom interaktif
Prediksi Kustom	Input tahun & bulan via sidebar, pilih dari 6 model, tampilkan hasil + CI 95%	Semua 5 model merespons dalam < 2 detik
Analisis Model	Tabel metrik, 4 bar chart perbandingan, heatmap ranking (px.imshow)	Warna highlight otomatis untuk model terbaik

Tab	Konten & Fitur	Status Implementasi
Data & Statistik	Preview 10 data awal/akhir, tabel statistik deskriptif, breakdown per tahun & bulan	Statistik dihitung ulang dinamis sesuai data
Tentang	Dokumentasi metodologi, deskripsi model, referensi BPS	Konten statis, terformat dengan markdown

3.6.3 Pengujian Fungsional Dashboard

Pengujian fungsional dilakukan untuk memverifikasi bahwa seluruh komponen dashboard berfungsi sebagaimana dirancang. Beberapa poin temuan pengujian adalah sebagai berikut.

1. Responsivitas prediksi: Seluruh enam model menghasilkan prediksi dalam waktu kurang dari 2 detik pada kondisi model sudah dimuat ke memori. Model dengan perhitungan rekursif (LSTM, Moving Average, XGBoost Lag, SARIMA) sedikit lebih lambat dibandingkan model direct (Random Forest, XGBoost), namun perbedaan waktu respons tidak signifikan dari perspektif pengalaman pengguna.
2. Konsistensi confidence interval: Perhitungan CI 95% menggunakan formula $1,96 \times \text{MAE}$ telah diverifikasi konsistensinya antara nilai yang tersimpan di metadata model dan nilai yang dihitung ulang secara dinamis pada dashboard.
3. Penanganan input tepi: Dashboard mampu menangani input tanggal yang berada dalam rentang data historis dengan mengembalikan nilai aktual dari dataset, bukan hasil prediksi model. Hal ini diimplementasikan melalui fungsi `get_historical_value()` yang memeriksa ketersediaan data historis sebelum memanggil fungsi prediksi.
4. Visualisasi interaktif: Seluruh grafik Plotly berfungsi dengan fitur hover tooltip, zoom, pan, dan download sebagai gambar PNG yang disediakan secara bawaan oleh Plotly.
5. Sidebar dan session state: Perubahan pilihan model dan input prediksi di sidebar dapat langsung direfleksikan pada tab Prediksi, dan hasil prediksi tersimpan di `st.session_state` sehingga tidak hilang saat pengguna berganti tab.

Pengujian pada bagian Pengaturan dilakukan untuk memastikan parameter yang dapat diatur oleh pengguna, seperti periode prediksi dan pemilihan model, berfungsi dengan baik serta memberikan validasi yang sesuai apabila pengguna memasukkan nilai yang tidak valid. Hasil pengujian disajikan pada tabel 14.

Tabel 14. Pengujian pada pengaturan

No	Skenario Pengujian	Langkah Pengujian	Hasil Pengujian	Status
1	Mengubah parameter periode prediksi (jumlah bulan ke depan)	Memasukkan nilai periode prediksi (misalnya 6 bulan) pada kolom input, kemudian menekan tombol konfirmasi/terapkan.	Sistem berhasil menyimpan dan menerapkan nilai periode prediksi sesuai yang dimasukkan pengguna.	Valid
2	Memilih model yang ditampilkan pada hasil analisis	Memilih salah satu opsi model (XGBoost, Random Forest, SARIMA, LSTM, atau Moving Average) melalui menu pilihan.	Sistem berhasil menampilkan hasil dan visualisasi sesuai model yang dipilih tanpa error.	Valid
3	Menjalankan proses prediksi dengan parameter yang valid	Memasukkan jumlah periode prediksi, kemudian menekan tombol "Prediksi".	Sistem berhasil menjalankan proses prediksi dan menampilkan hasil beserta grafik sesuai parameter yang dimasukkan.	Valid
4	Validasi input parameter yang tidak valid	Memasukkan nilai non-numerik atau nilai negatif pada kolom periode prediksi, kemudian menekan tombol konfirmasi.	Sistem menampilkan pesan peringatan dan tidak memproses nilai yang tidak valid.	Valid

Pengujian pada halaman Analisis Model dilakukan untuk memastikan informasi performa dan perbandingan antar model prediksi tertampil secara akurat sehingga dapat membantu pengguna memahami model mana yang paling sesuai. Hasil pengujian disajikan pada tabel 15.

Tabel 15. Hasil analisis model

No	Skenario Pengujian	Langkah Pengujian	Hasil Pengujian	Status
1	Tampilan tabel metrik evaluasi seluruh model	Membuka halaman Analisis Model dan mengamati tabel metrik evaluasi (MAE, RMSE, R^2 , MASE) untuk setiap	Tabel metrik evaluasi tertampil dengan nilai yang sesuai dengan hasil pengujian	Valid


No	Skenario Pengujian	Langkah Pengujian	Hasil Pengujian	Status
		model.	model.	
2	Tampilan grafik perbandingan visual antar model	Mengamati grafik perbandingan hasil prediksi antar model pada halaman Analisis Model.	Grafik perbandingan tertampil dengan baik dan masing-masing model dapat dibedakan melalui warna/legenda.	Valid
3	Memfilter atau memilih model tertentu untuk ditampilkan	Memilih salah satu model pada opsi filter, kemudian mengamati perubahan tampilan grafik.	Sistem berhasil menampilkan model sesuai filter yang dipilih tanpa error.	Valid
4	Tampilan heatmap antar model	Mengamati heatmap antar model pada halaman Analisis Model.	Grafik metrik ranking tertampil dengan urutan fitur yang sesuai dengan hasil analisis model.	Valid

Pengujian pada halaman Data dan Statistik dilakukan untuk memastikan data historis IHK serta statistik deskriptif tertampil dengan benar dan dapat difilter sesuai kebutuhan pengguna. Hasil pengujian disajikan pada tabel 16

Tabel 16. Pengujian data dan statistik

No	Skenario Pengujian	Langkah Pengujian	Hasil Pengujian	Status
1	Tampilan preview data	Membuka halaman Data dan Statistik dan mengamati tabel data	Tabel preview data tertampil dengan lengkap sesuai data pertama dan data terakhir	Valid


No	Skenario Pengujian	Langkah Pengujian	Hasil Pengujian	Status
2	Tampilan statistik deskriptif data	Mengamati ringkasan statistik deskriptif (mean, median, standar deviasi, nilai minimum dan maksimum) pada halaman Data dan Statistik.	Nilai statistik deskriptif tertampil dengan benar dan sesuai dengan data historis.	Valid
3	Tampilan heatmap korelasi	Mengamati matriks korelasi antar fitur	Berhasil menampilkan heatmap dan ringkasan insight.	Valid



Gambar 8. Komponen dashboard



Gambar 9. komponen dashboard data statistik



Gambar 10. uji performa test

3.6.4 Antarmuka Pengguna

Dashboard mengadopsi desain minimalis dengan skema warna yang konsisten. Warna biru (#2E86AB) digunakan sebagai warna aksen utama untuk tombol dan highlight, sementara warna hijau (#06A77D) digunakan untuk visualisasi data historis. Model terbaik secara otomatis dipilih sebagai default pada dropdown pilihan model, memudahkan pengguna awam yang ingin langsung mendapatkan prediksi dengan performa terbaik.

Sidebar kiri menyediakan kontrol utama berupa dropdown pilihan model, input numerik tahun, dan dropdown bulan. Panel informasi di sidebar menampilkan ringkasan jumlah model, periode data, dan jumlah observasi yang membantu pengguna memahami konteks analisis.

3.7 Pembahasan

3.7.1 Efektivitas XGBoost untuk Prediksi Inflasi

Keunggulan XGBoost dalam penelitian ini dapat dijelaskan melalui beberapa mekanisme algoritmik. Pertama, kemampuan XGBoost menangkap hubungan non-linear antara fitur waktu (tahun dan bulan) dengan nilai inflasi jauh lebih baik dibandingkan model linear seperti SARIMA. Inflasi merupakan variabel makroekonomi yang dipengaruhi oleh interaksi kompleks antara faktor musiman, tren struktural, dan guncangan ekonomi yang sulit dimodelkan secara linear.

Kedua, mekanisme regularisasi bawaan pada XGBoost (L1 dan L2) mencegah overfitting pada dataset yang relatif kecil (96 observasi latih). Hal ini menjelaskan mengapa XGBoost mampu mengungguli LSTM yang secara teoritis memiliki kapasitas representasi lebih besar, namun rentan overfitting pada dataset kecil.

Ketiga, teknik boosting yang membangun model secara iteratif dengan memperbaiki residual prediksi sebelumnya memungkinkan XGBoost secara progresif mengurangi bias prediksi. Setiap pohon baru dalam ensemble fokus pada kasus-kasus yang paling sulit diprediksi oleh pohon-pohon sebelumnya, menghasilkan ensemble yang lebih akurat secara keseluruhan.

Temuan ini sejalan dengan berbagai penelitian terdahulu yang menunjukkan performa superior XGBoost untuk prediksi data ekonomi dan finansial, antara lain pada prediksi harga saham, suku bunga, dan indikator makroekonomi lainnya. Keberhasilan XGBoost dalam penelitian ini menambah bukti empiris tentang efektivitas gradient boosting untuk data time series ekonomi di konteks regional Indonesia.

3.7.2 Implikasi Pola Musiman

Temuan analisis feature importance yang menunjukkan dominansi fitur Bulan memiliki implikasi penting bagi pemahaman dinamika inflasi Kota Makassar. Pola musiman yang kuat mencerminkan bahwa perilaku konsumsi masyarakat Kota Makassar sangat dipengaruhi oleh siklus kalender keagamaan dan akademik, terutama Hari Raya Idul Fitri, Idul Adha, Natal, Tahun Baru, dan awal tahun ajaran sekolah.

Implikasi kebijakan dari temuan ini adalah bahwa pemerintah dan otoritas moneter perlu mempersiapkan langkah antisipatif pada bulan-bulan dengan historis inflasi tinggi (Juli, Desember, Januari) berupa operasi pasar, kontrol distribusi bahan pokok, dan koordinasi dengan pedagang untuk menjaga stabilitas harga. Prediksi berbasis XGBoost dapat dijadikan salah satu instrumen peringatan dini (early warning) untuk mengidentifikasi potensi lonjakan inflasi musiman.

3.7.3 Keterbatasan Model

Meskipun model XGBoost menunjukkan kinerja yang sangat baik pada data historis, terdapat beberapa keterbatasan yang perlu diperhatikan. Pertama, model hanya menggunakan fitur waktu (Tahun dan Bulan) sebagai input, tanpa memasukkan variabel makroekonomi lainnya yang secara teoritis berpengaruh terhadap inflasi seperti harga minyak dunia, nilai tukar rupiah, suku bunga acuan Bank Indonesia, dan harga pangan global.

Kedua, model tidak dirancang untuk menangkap guncangan (shock) ekonomi yang bersifat mendadak dan tidak berpola historis, seperti pandemi, konflik geopolitik, atau bencana alam. Pada kondisi seperti ini, prediksi model dapat menyimpang signifikan dari nilai aktual.

Ketiga, akurasi prediksi cenderung menurun untuk horizon prediksi yang lebih jauh (lebih dari 3–6 bulan ke depan), terutama untuk model rekursif yang mengakumulasi error dari setiap langkah prediksi.


3.7.4 Kontribusi Dashboard terhadap Aksesibilitas Analisis

Dashboard analisis yang dibangun dalam penelitian ini memberikan kontribusi praktis berupa aksesibilitas analisis inflasi kepada berbagai pemangku kepentingan tanpa memerlukan pengetahuan teknis pemrograman. Melalui antarmuka yang intuitif, pengguna dapat memilih model prediksi yang dikehendaki, memasukkan periode target, dan langsung memperoleh prediksi beserta ukuran ketidakpastiannya (confidence interval).

Fitur perbandingan model yang terintegrasi dalam tab Analisis Model memungkinkan pengguna untuk memahami kelebihan dan kekurangan masing-masing algoritma berdasarkan metrik yang relevan. Hal ini mendorong pengambilan keputusan yang lebih informed dan berbasis data (evidence-based decision making), yang merupakan salah satu pilar transformasi digital tata kelola pemerintahan dan kebijakan publik di Indonesia.

3.7.5 Uji skenario

Fungsi verdict() secara otomatis mengklasifikasikan hasil evaluasi berdasarkan nilai R^2 ke dalam empat kategori kelayakan. Skenario dengan R^2 negatif diklasifikasikan sebagai tidak layak karena model menghasilkan prediksi yang lebih buruk dibandingkan prediksi naif menggunakan rata-rata target. Skenario dengan R^2 antara 0 dan 0,3 dikategorikan sangat lemah dan memerlukan penambahan variabel.



Gambar 11. Uji skenario variabel tunggal

Skenario 1 – Hanya IHK			
Random Forest	: $R^2=-1.0829$ MAE=0.7407 RMSE=1.0802	✗	Tidak layak – lebih buruk dari baseline mean
XGBoost	: $R^2=-1.3054$ MAE=0.7184 RMSE=1.1128	✗	Tidak layak – lebih buruk dari baseline mean
Skenario 2 – Hanya Lag 1,2,3			
Random Forest	: $R^2=-0.2637$ MAE=0.6038 RMSE=0.8640	✗	Tidak layak – lebih buruk dari baseline mean
XGBoost	: $R^2=-0.4413$ MAE=0.6332 RMSE=0.9073	✗	Tidak layak – lebih buruk dari baseline mean
Skenario 3 – Hanya Rolling Mean			
Random Forest	: $R^2= 0.1833$ MAE=0.5082 RMSE=0.7191	⚠	Sangat lemah – perlu variabel tambahan
XGBoost	: $R^2= 0.0813$ MAE=0.5327 RMSE=0.7677	⚠	Sangat lemah – perlu variabel tambahan
Skenario 4 – Hanya sin/cos Month			
Random Forest	: $R^2=-0.1531$ MAE=0.5871 RMSE=0.8497	✗	Tidak layak – lebih buruk dari baseline mean

Gambar 12. Interpretasi hasil skenario variabel tunggal

3.8 Ringkasan Temuan

Berdasarkan seluruh hasil dan pembahasan yang telah diuraikan pada Bab IV ini, dapat dirangkum beberapa temuan utama penelitian sebagai berikut.

1. XGBoost adalah model terbaik untuk forecasting inflasi dengan $R^2 = 0,726$ dan MASE = 0,249, mengungguli Random Forest, LSTM, SARIMA, dan Moving Average.
2. Fitur paling signifikan adalah Rolling Mean 3 (29,0%), Rolling Mean 12 (17,4%), dan Inflasi Lag 2 (15,0%). Lima fitur teratas menyumbang 86,4% prediksi.
3. Prediksi inflasi Januari 2026 sebesar 0,2563% (CI 95%: -0,2920% s.d. 0,8046%) dan Februari 2026 sebesar 0,1956% (CI 95%: -0,3527% s.d. 0,7439%), dengan risiko deflasi 18-24%.
4. Model tree-based ensemble (XGBoost, Random Forest) secara konsisten mengungguli deep learning (LSTM) dan time series klasik (SARIMA) untuk dataset inflasi yang memiliki karakteristik tidak normal, right-skewed, dan leptokurtik.
5. Anomali korelasi IHK-Inflasi (-0,626) dan importance IHK yang sangat rendah (0,2%) mengindikasikan perlunya investigasi ulang terhadap

perhitungan variabel atau kemungkinan *data leakage* pada fitur rolling statistics.

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, maka dapat diambil kesimpulan sebagai berikut :

1. Model terbaik dipilih berdasarkan nilai MAE terendah sebagai metrik utama. Model ini menggunakan 13 fitur yang mencakup nilai lag inflasi (Lag1, Lag2, Lag3), statistik rolling (mean 3/6/12 bulan, standar deviasi, minimum, dan maksimum), fitur musiman sinusoidal (sin_Month, cos_Month), tren waktu kontinu (Tahun_Continu). Kombinasi fitur-fitur ini terbukti mampu menangkap pola autoregresif, musiman, dan tren jangka panjang sekaligus. Pipeline pemodelan dalam penelitian ini bebas dari kebocoran data: scaler di-fit hanya pada data latih, hyperparameter tuning menggunakan validation set yang terpisah dari test set, dan evaluasi akhir dilakukan pada holdout test set yang tidak pernah digunakan selama proses pelatihan maupun tuning.
2. Model XGBoost mengungguli seluruh model pembanding yang diuji, yaitu SARIMA, LSTM, *Random Forest*, dan *Moving Average*, berdasarkan metrik evaluasi MAE, RMSE, dan MAPE. Keunggulan XGBoost didukung oleh kemampuannya menangkap pola non-linear pada data deret waktu inflasi, serta ketahanannya terhadap *overfitting* melalui mekanisme regularisasi bawaan.
3. Dashboard interaktif berhasil dirancang dan diimplementasikan sebagai antarmuka visualisasi yang menyajikan data historis IHK, tren inflasi bulanan, serta hasil prediksi model XGBoost secara informatif dan mudah dipahami. Dashboard ini menjadi komponen pendukung dalam pengambilan keputusan berbasis data terkait dinamika inflasi di Kota Makassar.

4.2 Saran

Penelitian ini tidak lepas dari berbagai kekurangan dan keterbatasan, maka berdasarkan hasil penelitian ini, penulis menyampaikan saran yang bisa diberikan kepada penelitian selanjutnya, disarankan untuk menambahkan variabel eksternal lainnya seperti data curah hujan harian, harga komoditas global, indeks kepercayaan konsumen, serta data sentimen dari media sosial atau berita ekonomi. Pendekatan feature engineering yang lebih canggih, seperti konstruksi lag non-linear atau rolling window statistics, juga layak dicoba. Penelitian lanjutan dapat memperluas cakupan Indonesia Timur untuk mengetahui apakah pola dan faktor penyebab inflasi serupa dengan Kota Makassar.

DAFTAR PUSTAKA

- Agustina, I. A. S., & Permadi, I. K. O. (2023). The Impact of the Money Supply, Exchange Rate and Fuel Prices on the Inflation Rate. *Ekonomis: Journal of Economics and Business*, 7(1), 32. <https://doi.org/10.33087/ekonomis.v7i1.740>
- Al, I. E. (n.d.). *Design of Study Program Performance Dashboard using Streamlit*. Retrieved https://pddikti.kemdikbud.go.id/data_prodi/OTdEODIzMjltQ0FCOC00
- Burzykowski, T., Rousseau, A. J., Geubbelmans, M., & Valkenborg, D. (2023). Introduction to machine learning. In *American Journal of Orthodontics and Dentofacial Orthopedics* (Vol. 163, Number 5, pp. 732–734). Elsevier Inc. <https://doi.org/10.1016/j.ajodo.2023.02.005>
- Cohen, N., Sood, S., Zeng, Z., Balch, T., & Veloso, M. (2021). *Visual Time Series Forecasting: An Image-driven Approach*. <http://arxiv.org/abs/2107.01273>
- Deng, Y., & Lumley, T. (2024). Multiple Imputation Through XGBoost. *Journal of Computational and Graphical Statistics*, 33(2), 352–363. <https://doi.org/10.1080/10618600.2023.2252501>
- Firdaus, F., Wati, E., & Amalia, P. (2025). Analisis Kebijakan Fiskal dan Kebijakan Moneter dalam Mengendalikan Inflasi dan Stabilitas Ekonomi. *Journal of Economics Development Research*, 1(3), 91–101. <https://doi.org/10.71094/joeder.v1i3.144>
- Fisher, A., Rudin, C., & Dominici, F. (2019). All Models are Wrong, but Many are Useful: Learning a Variable's Importance by Studying an Entire Class of Prediction Models Simultaneously. In *Journal of Machine Learning Research* (Vol. 20). <http://jmlr.org/papers/v20/18-760.html>
- Hao, M., Dayal, U., Keim, D., & Schreck, T. (n.d.). *Multi-Resolution Techniques for Visual Exploration of Large Time-Series Data*.
- Leffrang, D., & Muller, O. (2021). Should I Follow this Model? The Effect of Uncertainty Visualization on the Acceptance of Time Series Forecasts. *Proceedings - 2021 IEEE Workshop on TRust and EXPertise in Visual Analytics, TREX 2021*, 20–26. <https://doi.org/10.1109/TREX53765.2021.00009>
- Lusiana, A., & Yuliarty, P. (n.d.). *PENERAPAN METODE PERAMALAN (FORECASTING) PADA PERMINTAAN ATAP di PT X*.
- Muhamad, N., Amin, F., Janwari, Y., Al, S., 3*, H., Islam, U., Cirebon, B. B., Gunung, S., & Bandung, D. (2026). *Stabilitas Ekonomi Islam: Telaah Teoritis Terhadap Mekanisme Pengendalian Inflasi* (Vol. 7, Number 1).
- Nogueira Costa, D. S. (2020). *Universidade do Minho Escola de Engenharia Installation Processes Predicting Problems From Telecom*.

- Pisganidy, M., & Awaluddin, M. (2025). *INOVASI: Jurnal Ekonomi, Keuangan dan Manajemen The Effect of Money Supply and Interest Rates on Inflation in Indonesia*. 21(1), 105–110.
- Priharsari, D. (2022). *SISTEM INFORMASI SEBAGAI KEILMUAN YANG MULTIDISIPLINER* (Vol. 3, Number 1).
- Putra, A. S., Fawaati, T. M., & Oktaviyani, E. (2021). *Optimalisasi Pengambilan Keputusan Organisasi Melalui Sistem Informasi Manajemen di Era Digital* (Vol. 2, Number 1).
- Sutarman, Nasution, P. K., Sirait, K. J., & Panjaitan, C. N. Y. (2025). IDENTIFYING THE IMPACT OF THE COMPLEXITY OF DATASETS IN BAYESIAN OPTIMIZED XGBOOST ON THE PERFORMANCE OF CLASSIFICATIONS FOR IMBALANCED CLASS DISTRIBUTION DATASETS. *Eastern-European Journal of Enterprise Technologies*, 1(4(133)), 52–63.
<https://doi.org/10.15587/1729-4061.2025.322626>

LAMPIRAN

Lampiran 1. Rapat bersama dengan bps makassar



Lampiran 2. QR code github

