


PENGEMBANGAN DASHBOARD DETEKSI PESAN SPAM BERBAHASA INDONESIA BERBASIS INDOBERT DENGAN METODE LOCAL INTERPRETABLE MODEL-AGNOSTIC EXPLANATIONS (LIME) SEBAGAI INTERPRETABILITAS KEPUTUSAN MODEL



DEWA AYU EKA NATALIA PRATIWI
H071221021

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026



**PENGEMBANGAN DASHBOARD DETEKSI PESAN SPAM BERBAHASA
INDONESIA BERBASIS INDOBERT DENGAN METODE LOCAL
INTERPRETABLE MODEL-AGNOSTIC EXPLANATIONS (LIME) SEBAGAI
INTERPRETABILITAS KEPUTUSAN MODEL**


**DEWA AYU EKA NATALIA PRATIWI
H071221021**



**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

**PENGEMBANGAN DASHBOARD DETEKSI PESAN SPAM BERBAHASA
INDONESIA BERBASIS INDOBERT DENGAN METODE LOCAL
INTERPRETABLE MODEL-AGNOSTIC EXPLANATIONS (LIME) SEBAGAI
INTERPRETABILITAS KEPUTUSAN MODEL**

DEWA AYU EKA NATALIA PRATIWI
H071221021



**PROGRAM STUDI SISTEM INFORMASI
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
2026**

SKRIPSI**PENGEMBANGAN DASHBOARD DETEKSI PESAN SPAM BERBAHASA
INDONESIA BERBASIS INDOBERT DENGAN METODE LOCAL
INTERPRETABLE MODEL-AGNOSTIC EXPLANATIONS (LIME) SEBAGAI
INTERPRETABILITAS KEPUTUSAN MODEL****DEWA AYU EKA NATALIA PRATIWI****H071221021**

Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana Sistem Informasi

Pada tanggal 17 Juli 2026

Dan dinyatakan telah memenuhi syarat kelulusan
pada

Program Studi Sistem Informasi

Departemen Matematika

Fakultas Matematika dan Ilmu Pengetahuan Alam

Universitas Hasanuddin

Makassar

Mengetahui:

Pembimbing Tugas Akhir,


Octavian, S.Si., M.Kom

NIP 199210142024123001



Mengetahui:

Ketua Program Studi,

Prof. Dr. Jeffry Kusuma, Ph.D.

NIP 196411121987031002

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa skripsi yang berjudul "Pengembangan Dashboard Deteksi Pesan Spam Berbahasa Indonesia Berbasis IndoBERT dengan Metode Local Interpretable Model-Agnostic Explanations (LIME) sebagai Interpretabilitas Keputusan Model" adalah benar karya saya dengan arahan dari pembimbing (Octavian, S.Si., M.Kom). Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.



makassar, 17 Juli 2026

Dewa Ayu Eka Natalia Pratiwi
NIM H071221021

UCAPAN TERIMA KASIH

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas anugerah dan karunia-nya, penulis dapat menyelesaikan skripsi yang berjudul “Pengembangan Dashboard Deteksi Pesan Spam Berbahasa Indonesia Berbasis IndoBERT dengan Metode Local Interpretable Model-Agnostic Explanations (LIME) sebagai Interpretabilitas Keputusan Model” sebagai salah satu syarat untuk memperoleh gelar sarjana pada Program Studi Sistem Informasi, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Hasanuddin. Dalam proses penyusunan tugas akhir ini, penulis menyadari bahwa keberhasilan ini tidak akan terwujud tanpa adanya doa, dukungan, bimbingan, serta bantuan yang sangat berarti dari berbagai pihak.

Rasa terima kasih yang paling utama, tulus, dan terdalam penulis persembahkan kepada kedua orang tua tercinta, Bapak I Dewa Ketut Sudiana dan Ibu Agustina Tattu, yang senantiasa menjadi sumber kekuatan terbesar penulis. Terima kasih atas segala pengorbanan, kasih sayang tak terhingga, serta untaian doa yang tiada putusnya dipanjatkan demi kelancaran studi dan kebahagiaan penulis. Segala dukungan moral maupun finansial yang diberikan adalah fondasi utama hingga penulis berhasil menyelesaikan pendidikan ini. Semoga pencapaian ini dapat menjadi persembahan yang membanggakan, dan semoga Tuhan Yang Maha Esa senantiasa melimpahkan kesehatan, kebahagiaan, serta umur yang panjang bagi kedua orang tua. Ucapan terima kasih juga penulis sampaikan kepada seluruh keluarga besar atas perhatian dan dukungan yang selalu mengiringi setiap langkah penulis selama ini.

Penulis mengucapkan terima kasih kepada Pemerintah Provinsi Kalimantan Timur, melalui Dinas Pendidikan dan Kebudayaan Provinsi Kalimantan Timur atas beasiswa pendidikan yang diberikan selama menempuh program sarjana. Penulis juga menyampaikan terima kasih kepada pimpinan Universitas Hasanuddin, pimpinan Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Hasanuddin, Ketua Departemen Matematika, Ketua Prodi Sistem Informasi, Jajaran Dosen, dan Staf Departemen Matematika yang telah membekali ilmu dan memberikan fasilitas yang melancarkan penulis dalam menempuh masa studi.

Penulis juga menyampaikan rasa terima kasih dan penghormatan kepada Bapak Octavian, S.Si., M.Kom., selaku dosen pembimbing, atas bimbingan, arahan, kesabaran, serta dedikasi yang diberikan selama proses penyusunan tugas akhir ini. Terima kasih pula kepada Ibu Siti Rabiatus Adawiyah, S.Si., M.Kom. dan Bapak Dr. Eng. Supri Bin Hj. Amir, S.Si., M.Eng., atas saran dan masukan yang sangat berarti bagi penyempurnaan penelitian ini.

Penulis juga berterima kasih kepada teman-teman Sistem Informasi Angkatan 2022, teman-teman seperjuangan, khususnya H071221034, H071221025, H071221013, H071221049, H071221041, H071221010 dan H071221009, teman-teman KKN 114 Desa Bira, sahabat dari SMP Negeri 5 Samarinda, sahabat dari SMA Negeri 5 Samarinda, terima kasih atas semangat, motivasi, doa, dan dukungan yang telah diberikan selama ini. Akhir kata, terima kasih kepada seluruh pihak yang tidak dapat disebutkan satu per satu atas segala doa dan bantuannya. Semoga segala kebaikan dan ketulusan tersebut dibalas dengan pahala yang berlipat ganda oleh Tuhan YME.

ABSTRAK

Latar Belakang. Penyebaran pesan spam berbasis penipuan siber (*phishing*) terus meningkat seiring dengan tingginya penetrasi internet di Indonesia. Metode klasifikasi tradisional berbasis kata kunci sering kali gagal memahami konteks semantik teks informal, sementara model deep learning modern yang akurat umumnya bersifat *blackbox* sehingga tidak transparan bagi pengguna. **Tujuan.** Penelitian ini bertujuan mengembangkan dashboard interaktif deteksi pesan spam berbahasa Indonesia dengan mengintegrasikan model bahasa berbasis *Transformer* IndoBERT varian *indobert-base-p2* dan metode *Local Interpretable Model-Agnostic Explanations* (LIME) sebagai pendekatan *Explainable Artificial Intelligence* (XAI). **Metode.** Penelitian menggunakan metode *Research and Development* (R&D) dan eksperimental komputasional, di mana model dilatih menggunakan skema *5-Fold Stratified Cross-Validation* pada 2.096 sampel data pelatihan dan evaluasi bersih hasil pra-pemrosesan. **Hasil.** Penerapan mekanisme *Early Stopping* dengan nilai *patience* sebesar 2 menghasilkan rata-rata *F1-Score* sebesar 0,9904 dan *Validation Loss* 0,0714, terbukti lebih optimal dalam mencegah *overfitting* dibandingkan pelatihan penuh 10 epoch. Model terbaik diperoleh dari Fold 3 checkpoint-420 pada epoch kedua dengan *F1-Score* 0,9955 dan *Recall* sempurna 1,0000. Pada pengujian menggunakan 524 sampel data uji yang sepenuhnya terpisah, model *Best Single Fold* mencatatkan *Accuracy* 0,9866, *F1-Score* 0,9872, dan AUC 0,9975, mengungguli pendekatan *Soft Voting Ensemble* yang menghasilkan 10 kesalahan prediksi. Metode LIME berhasil memberikan interpretabilitas tingkat lokal dengan memvisualisasikan kontribusi kata per kata melalui sorotan warna pada teks input. **Kesimpulan.** Dashboard interaktif berbasis *Streamlit* berhasil dikembangkan dan di-*deploy* secara public melalui *Streamlit Cloud* dan terbukti fungsional dalam mendeteksi pesan spam secara *real-time* sekaligus memberikan transparansi keputusan model kepada pengguna.

Kata Kunci: Deteksi Spam, IndoBERT, LIME, *Explainable Artificial Intelligence*, *Streamlit*.

ABSTRACT

Background. The dissemination of digital spam message based on cyber phishing continues to increase alongside the high internet penetration rate in Indonesia. Traditional keyword-based classification methods frequently fail to capture the semantic context of informal texts, while highly accurate modern deep learning models generally operate as a black box, offering little transparency to end users. **Objective.** This study aims to develop an interactive dashboard for Indonesian spam message detection by integrating the IndoBERT Transformer-based language model (indobert-base-p2 variant) with the Local Interpretable Model-Agnostic Explanations (LIME) method as an Explainable Artificial Intelligence (XAI) approach. **Method.** The study employs a Research and Development (R&D) and computational experimental method, in which the model was trained using a 5-Fold Stratified Cross-Validation scheme on 2,096 pre-processed clean training and evaluation data samples. **Results.** The implementation of an Early Stopping mechanism with a patience value of 2 yields an average F1-Score of 0.9904 and a Validation Loss of 0.0714, proving mode effective in preventing overfitting compared to full 10-epoch training. The best model was obtained from Fold 3 checkpoint-420 at the second epoch, achieving an F1-Score of 0.9955 and a perfect Recall of 1.0000. When evaluated against 524 independent test samples, the Best Single Fold model achieved an Accuracy of 0.9866, an F1-Score of 0.9872, and AUC of 0.9975, outperforming the Soft Voting Ensemble approach which registered 10 prediction errors. The LIME method successfully provided instance-level interpretability by visualizing word-by-word contributions through text highlighting. **Conclusion.** An interactive Streamlit-based dashboard was successfully developed and publicly deployed on Streamlit Cloud and has been proven functional for real-time spam detection while providing model decision transparency to users.

Keywords: Spam Detection, IndoBERT, LIME, Explainable Artificial Intelligence, Streamlit.

DAFTAR ISI

	Halaman
HALAMAN JUDUL	ii
HALAMAN PENGANTAR	iii
HALAMAN PENGESAHAN	iv
PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA	v
UCAPAN TERIMA KASIH	vi
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
DAFTAR LAMPIRAN	xiii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah	3
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Landasan Teori	4
1.6.1 Pesan Spam	4
1.6.2 Natural Language Processing (NLP)	5
1.6.3 Deep Learning	5
1.6.3.1 Transformer	5
1.6.3.2 Bidirectional Encoder Representation from Transformers (BERT)	6
1.6.3.3 IndoBERT	7
1.6.4 Cross Validation	8
1.6.4.1 K-Fold Cross Validation	9
1.6.5 Explainable Artificial Intelligence	9
1.6.5.1 Local Interpretable Model-Agnostic Explanations (LIME)	10
1.6.6 Streamlit	11
1.7 Penelitian Terdahulu	12
BAB II METODE PENELITIAN	18

2.1 Pendekatan Penelitian	18
2.2 Waktu dan Tempat Penelitian	18
2.3 Instrumen Penelitian	18
2.3.1 Perangkat Keras (Hardware)	19
2.3.2 Perangkat Lunak (Software)	19
2.4 Deskripsi Data	20
2.5 Teknik Analisis Data dan Pemodelan	21
2.5.1 Analisis Data Eksplorasi (EDA)	21
2.5.2 Pre-processing Data	25
2.5.3 Pembagian Data (Splitting Data)	26
2.5.4 Pemodelan IndoBERT	27
2.5.4.1 Arsitektur Model	27
2.5.4.2 Tokenisasi.....	28
2.5.4.3 Hyperparameter	29
2.5.4.4 K-Fold Cross Validation.....	30
2.5.5 Metrik Evaluasi Kinerja Model	30
2.5.6 Implementasi Explainable Artificial Intelligence (XAI).....	32
2.6 Rancangan Dashboard Streamlit	33
BAB III HASIL DAN PEMBAHASAN	34
3.1 Hasil Pelatihan Model.....	34
3.2 Hasil Evaluasi Model	36
3.2.1 Evaluasi Best Single Fold	37
3.2.2 Evaluasi Soft Voting Ensemble	40
3.3 Implementasi LIME pada Model.....	43
3.4 Implementasi Model pada Dashboard.....	45
BAB IV PENUTUP	50
4.1 Kesimpulan	50
4.2 Saran	51
DAFTAR PUSTAKA.....	53
LAMPIRAN	55

DAFTAR TABEL

Halaman

Tabel 1. Ringkasan penelitian terdahulu	12
Tabel 2. Waktu penelitian.....	18
Tabel 3. Perangkat Keras (Hardware).....	19
Tabel 4. Perangkat Lunak (Software).....	19
Tabel 5. Distribusi Kelas Dataset.....	21
Tabel 6. Pembagian Dataset	26
Tabel 7. Pembagian Data pada K-Fold Cross Validation	27
Tabel 8. Distribusi Kelas pada Setiap Subset Data	27
Tabel 9. Arsitektur Model IndoBERT.....	28
Tabel 10. Konfigurasi Hyperparameter	29
Tabel 11. Kinerja Hasil Pelatihan Model dengan Early Stopping	34
Tabel 12. Kinerja Hasil Pelatihan Tanpa Early Stopping	35
Tabel 13. Perbandingan Rata-rata Kinerja Early Stopping dan Full 10 Epoch	35
Tabel 14. Hasil Evaluasi Model Best Single Fold pada Data Uji	37
Tabel 15. Kesalahan Prediksi Model Best Single Fold	39
Tabel 16. Hasil Evaluasi Model Soft Voting Ensemble pada Data Uji	40
Tabel 17. Kesalahan Prediksi Model Soft Voting Ensemble.....	42

DAFTAR GAMBAR

Halaman

Gambar 1. Arsitektur Model Transformer (Vaswani et al., 2017)	6
Gambar 2. Prosedur Pre-Training dan Fine Tuning BERT (Devlin et al., 2019)	7
Gambar 3. Proses Embedding IndoBERT (Nabiilah et al., 2024)	8
Gambar 4. Ilustrasi Pembagian Data pada K-Fold Stratified Cross Validation (GeeksforGeeks, 2025).....	9
Gambar 5. Konsep Explainable Artificial Intelligence (GeeksforGeeks, 2026)	10
Gambar 6. Hasil Visualisasi Kontribusi Kata oleh Metode LIME (Ribeiro, 2016).....	11
Gambar 7. Pipeline penelitian	21
Gambar 8. Distribusi Kelas pada Dataset	22
Gambar 9. Distribusi Panjang Teks per Kelas	23
Gambar 10. Sebaran Panjang Teks per Kelas	24
Gambar 11. Pipeline Alur Pra-pemrosesan Data	25
Gambar 12. Wireframe Halaman Beranda	33
Gambar 13. Perbandingan Rata-rata Kinerja Early Stopping dan Full 10 Epoch	36
Gambar 14. Riwayat Pelatihan Fold 3.....	37
Gambar 15. Confusion Matrix Best Single Fold	38
Gambar 16. Kurva ROC Best Single Fold	39
Gambar 17. Confusion Matrix Soft Voting Ensemble	41
Gambar 18. Kurva ROC Soft Voting Ensemble	42
Gambar 19. Hasil Interpretasi LIME untuk Pesan Spam	44
Gambar 20. Hasil Interpretasi LIME untuk Pesan Non-Spam.....	44
Gambar 21. Pipeline Deployment Model ke Streamlit	46
Gambar 22. Tampilan Halaman Beranda	47
Gambar 23. Tampilan Halaman Beranda untuk Hasil Prediksi Spam.....	48
Gambar 24. Tampilan Halaman Beranda untuk Hasil Prediksi Non-Spam	49

DAFTAR LAMPIRAN

Halaman

Lampiran 1. Source Code Dashboard Streamlit	55
Lampiran 2. Source Code Fine-tuning Model IndoBERT	55
Lampiran 3. Source Code Evaluasi Model IndoBERT	56
Lampiran 4. Data Kesalahan Prediksi Model IndoBERT	56

BAB I PENDAHULUAN

1.1 Latar Belakang

Penyebaran pesan Spam di Indonesia terus mengalami peningkatan seiring dengan pesatnya penggunaan layanan internet. Menurut Asosiasi Penyelenggara Jasa Internet Indonesia (APJII) tahun 2025 jumlah pengguna internet di Indonesia mencapai 229,4 juta jiwa dengan tingkat penetrasi mencapai 80,66% dari total populasi, dan akan terus mengalami peningkatan di tahun 2026 sejalan dengan pemerataan akses di wilayah pelosok (APJII, 2025). Dengan adanya peningkatan pengguna layanan internet, dapat berdampak pada peningkatan potensi penyebaran pesan Spam di berbagai platform. Spam bukan hanya mengganggu kenyamanan pengguna yang menerimanya, tetapi juga dapat berisi konten berbahaya atau menyesatkan yang akan berdampak pada aspek privasi dan keamanan pengguna tersebut.

Spam dapat menjadi titik tolak bagi tindakan *phishing* atau penipuan siber. Tindakan *phishing* atau penipuan siber merupakan tindakan yang menggunakan email, pesan teks, telepon, atau situs web palsu untuk menjebak pengguna agar dapat menyerahkan data-data sensitif atau pribadi, mengunduh sebuah *malware*, dan atau melakukan aktivitas merugikan lainnya (IBM, 2025). Banyak pengguna yang tidak menyadari bahwa sebuah pesan yang tampak biasa saja dapat menjadi ancaman nyata, karena pesan tersebut sering disajikan dalam bentuk pesan promosi, pemberitahuan resmi, atau hadiah palsu. Berdasarkan hal tersebut, deteksi otomatis terhadap pesan *spam* menjadi kebutuhan penting guna melindungi pengguna dari risiko keamanan digital.

Metode konvensional untuk mendeteksi *spam*, seperti *rule-based filtering*, klasifikasi sederhana berbasis TF-IDF, *Naive Bayes*, atau SVM, memiliki keterbatasan dalam menangani pesan modern yang beragam dan kompleks, khususnya dalam bahasa sehari-hari atau bahasa campuran informal seperti yang banyak digunakan dalam bahasa Indonesia. Hal tersebut menjadikan teknik berbasis *deep learning* dan *Natural Language Processing* (NLP) sebagai opsi yang lebih relevan dikarenakan mampu memahami konteks, variasi bahasa, dan makna semantik dalam sebuah teks. Salah satu kemajuan signifikan dalam bidang NLP yakni berkembangnya model berbasis arsitektur transformer, seperti *Bidirectional Encoder Representations from Transformers* (BERT) yang dapat menangkap hubungan antar kata dalam suatu kalimat secara lebih komprehensif, sehingga mampu mengurangi ambiguitas makna. Terdapat beberapa variasi model BERT salah satunya adalah IndoBERT yang telah dipra-latih dengan menggunakan korpus bahasa Indonesia. Penggunaan model IndoBERT untuk mendeteksi pesan spam berbahasa Indonesia dinilai lebih unggul dibandingkan dengan model lainnya, hal tersebut telah diuji pada penelitian yang dilakukan oleh (Amin et al., 2024), penggunaan model IndoBERT untuk mendeteksi pesan spam berbahasa Indonesia mampu mencapai akurasi hingga 98%, yang mana lebih unggul dibandingkan dengan Multilingual BERT yang hanya mencapai akurasi 95%. Penelitian lain yang dilakukan oleh (AbdulNabi & Yaseen, 2021) dan (Guo et al., 2022) dapat mengkonfirmasi efektivitas dari *deep learning* dan model *transformer* dalam mendeteksi spam, meskipun penelitian-penelitian tersebut masih terbatas pada dataset berbahasa Inggris. Hal

tersebut menunjukkan bahwa model berbasis *transformer*, terkhususnya IndoBERT, memiliki potensi besar untuk dikembangkan lebih lanjut dalam konteks deteksi spam berbahasa Indonesia.

Meskipun model modern seperti IndoBERT menawarkan performa yang tinggi, model ini sering dianggap sebagai *blackbox*, yaitu sulit untuk menjelaskan bagaimana keputusan prediksi tersebut dibuat. Berkaitan dengan deteksi spam dan *phishing*, transparansi dan kepercayaan merupakan bagian yang sangat penting, oleh karena itu interpretabilitas prediksi menjadi aspek yang krusial. Sehingga pendekatan *Explainable Artificial Intelligence* (XAI) seperti LIME (*Local Interpretable Model-Agnostic Explanations*) dapat diterapkan agar pengguna dapat mengetahui kata atau bagian mana dari teks yang menyebabkan model mengklasifikasikan suatu pesan sebagai spam. Penelitian yang dilakukan oleh (Uddin et al., 2025) telah membuktikan bahwa kombinasi model *transformer* dengan teknik *explainability* pada deteksi SMS spam mampu meningkatkan kepercayaan dan transparansi sistem, sekaligus menghasilkan interpretasi kontribusi kata terhadap prediksi yang dapat dipahami oleh pengguna.

Merujuk pada penelitian-penelitian sebelumnya, terdapat celah penelitian yang dapat ditingkatkan pada penelitian ini. Penelitian-penelitian berbasis BERT untuk bahasa Indonesia yang dilakukan oleh (Amin et al., 2024) dan (Arum & Pradana, 2025) masih berfokus pada performa model dan belum mengintegrasikan teknik XAI untuk memberikan penjelasan terhadap setiap prediksi. Sementara itu, penelitian yang dilakukan oleh (Alzahrani, 2024) dan (Uddin et al., 2025) telah menggabungkan XAI dengan deteksi spam, namun masih berfokus pada dataset berbahasa Inggris dan belum mengeksplorasi penggunaan model lokal seperti IndoBERT. Akan tetapi, penelitian yang dilakukan oleh (Supono & Imani, 2026) telah mengimplementasikan IndoBERT dengan antarmuka *Streamlit* untuk mendeteksi email spam berbahasa Indonesia dan mencapai akurasi 97%, namun penelitian tersebut belum menyertakan teknik XAI seperti LIME untuk menjelaskan kontribusi kata per kata terhadap keputusan model, sehingga sistem yang dihasilkan belum sepenuhnya transparan bagi pengguna.

Berlandaskan celah penelitian tersebut, kebaruan (*novelty*) dalam penelitian ini berada pada pengintegrasian IndoBERT sebagai model klasifikasi dengan LIME sebagai teknik XAI secara khusus untuk mendeteksi pesan spam berbahasa Indonesia, yang kemudian disajikan dalam sebuah dashboard interaktif berbasis *Streamlit*. Dashboard tersebut tidak hanya menampilkan hasil klasifikasi, tetapi juga memberikan visualisasi kontribusi kata per kata yang menjelaskan alasan suatu pesan diklasifikasikan sebagai spam, sehingga sistem yang dibangun tidak hanya akurat secara teknik tetapi juga transparan dan dapat dipertanggungjawabkan.

Berdasarkan uraian yang telah dijabarkan sebelumnya, peneliti memutuskan untuk melakukan penelitian dengan mengembangkan dashboard interaktif deteksi pesan spam berbahasa Indonesia berbasis *Streamlit* dengan mengintegrasikan model *transformer* IndoBERT sebagai pendeteksi pesan spam berbahasa Indonesia dan metode *Local Interpretable Model-Agnostic Explanation* (LIME) sebagai interpretabilitas keputusan model. Penelitian ini diharapkan dapat memberikan kontribusi nyata dalam upaya melindungi pengguna dari ancaman pesan spam dan penipuan siber di Indonesia, sekaligus mendorong pengembangan sistem kecerdasan buatan yang lebih transparan dan dapat dipercaya.

1.2 Rumusan Masalah

Sebagaimana yang telah dipaparkan pada latar belakang sebelumnya, adapun rumusan masalah yang akan dibahas pada penelitian ini adalah:

1. Bagaimana performa model IndoBERT dalam mengklasifikasikan pesan spam berbahasa Indonesia pada dataset penelitian yang seimbang?
2. Bagaimana penerapan metode *Local Interpretable Model-Agnostic Explanations* (LIME) dalam memberikan penjelasan visual kontribusi setiap kata terhadap keputusan prediksi model IndoBERT?
3. Bagaimana perancangan dan pengembangan dashboard interaktif berbasis *Streamlit* yang mengintegrasikan model IndoBERT dan metode LIME secara terpadu?

1.3 Batasan Masalah

Adapun batasan masalah pada penelitian ini adalah:

1. Penelitian ini berfokus pada pendeteksian pesan spam berbahasa Indonesia dengan menggunakan model IndoBERT.
2. Dataset pada penelitian ini menggunakan Spam Dataset Indonesia yang bersumber dari Kaggle.com yang telah diklasifikasikan menjadi dua kelas, yakni spam dan non-spam.
3. Interpretabilitas keputusan model dibatasi pada penggunaan metode LIME yang menghasilkan kontribusi fitur berupa kata per kata terhadap hasil klasifikasi dalam bentuk nilai persentase yang divisualkan secara interaktif pada dashboard.
4. Evaluasi kinerja model klasifikasi diukur berdasarkan metrik *accuracy*, *precision*, *recall* dan *F1-score* menggunakan skema pengujian *5-Fold Stratified Cross Validation* pada data latih serta pengujian akhir pada data uji.
5. Pengembangan sistem dibatasi pada pembuatan dashboard berbasis *Streamlit* yang berjalan secara lokal untuk analisis berbasis input teks manual (on-demand), tanpa terintegrasi langsung ke API platform perpesanan pihak ketiga.

1.4 Tujuan Penelitian

Adapun tujuan dari penelitian ini adalah sebagai berikut:

1. Menerapkan model IndoBERT untuk melakukan klasifikasi biner pesan spam berbahasa Indonesia serta mengukur akurasi kinerjanya.
2. Mengintegrasikan metode LIME sebagai pendekatan *Explainable Artificial Intelligence* (XAI) untuk menghasilkan transparansi keputusan model melalui visualisasi bobot kata demi kata.
3. Membangun sebuah dashboard interaktif berbasis *Streamlit* yang menyajikan hasil prediksi model IndoBERT beserta penjelasan visual LIME dalam satu antarmuka pengguna yang fungsional.

1.5 Manfaat Penelitian

Manfaat pada penelitian adalah sebagai berikut:

1. Memberikan kontribusi pada pengembangan ilmu di bidang *Natural Language Processing* (NLP) khususnya dalam deteksi spam berbahasa Indonesia

menggunakan model berbasis transformer seperti IndoBERT.

2. Memperkaya kajian terkait penerapan *Explainable Artificial Intelligence* (XAI), khususnya metode LIME dalam ruang lingkup deteksi teks berbahasa Indonesia.
3. Memberikan edukasi literasi digital bagi pengguna akhir dalam mengenali ciri-ciri kata mencurigakan yang berpotensi penipuan siber melalui visualisasi kontribusi LIME.
4. Menjadi acuan taktis bagi pengembang sistem informasi dalam membangun aplikasi cerdas yang mengutamakan aspek tata Kelola dan kepercayaan pengguna

1.6 Landasan Teori

1.6.1 Pesan Spam

Spam merupakan singkatan dari *Sending and Posting Advertisement in Mass*, yang merujuk pada tindakan pengiriman pesan elektronik secara massal kepada sejumlah besar penerima tanpa persetujuan atau permintaan sebelumnya (AbdulNabi & Yaseen, 2021). Dalam konteks yang lebih luas, *spam* tidak hanya mencakup pesan iklan atau promosi, tetapi juga mencakup berbagai jenis konten berbahaya seperti *phishing*, *malware*, dan penipuan siber yang dikirimkan melalui berbagai media komunikasi digital. Menurut Amin et al. (2024), spam secara umum merupakan tindakan mengirim pesan yang tidak diinginkan atau tidak diminta kepada sejumlah besar orang, dan saat ini dapat ditemui dalam berbagai bentuk seperti web maupun multimedia.

Karakteristik utama pesan spam meliputi tiga aspek utama, yaitu pengiriman pesan dalam jumlah besar, konten yang bersifat komersial atau mengandung unsur penipuan, serta tidak adanya persetujuan dari penerima pesan. Pesan spam modern telah berkembang jauh lebih canggih dibandingkan pesan iklan sederhana. Alzahrani (2024) menjelaskan bahwa spam saat ini hadir dalam berbagai platform digital, termasuk email, *Short Message Service* (SMS), pesan instan, dan media sosial, dengan teknik penyamaran yang semakin kompleks sehingga semakin sulit dibedakan dari pesan yang sah.

Berdasarkan jenisnya, spam dapat dikategorikan menjadi beberapa kelompok utama. Pertama, email spam merupakan bentuk yang paling umum, melibatkan pengiriman email tidak diminta secara massal, mulai dari promosi produk hingga upaya *phishing* yang mencoba mencuri informasi sensitif pengguna. Kedua, SMS spam atau *smishing*, melibatkan pengiriman pesan teks yang tidak diminta melalui telepon seluler. Ketiga, spam pesan instan yang memanfaatkan platform seperti Whatsapp, Telegram, dan Line untuk menyebarkan pesan berbahaya atau konten penipuan melalui berbagai platform.

Dampak pesan spam tidak hanya sebatas gangguan kenyamanan pengguna. Alaoui et al. (2024) menekankan bahwa pesan spam dapat menjadi pintu masuk bagi serangan siber yang lebih serius, termasuk pencurian identitas, penipuan finansial, dan penyebaran *malware*. Dalam konteks bahasa Indonesia, karakteristik spam menjadi lebih kompleks karena penggunaan bahasa campuran (*code-switching*), slang lokal, dan variasi dialek yang membuat metode deteksi tradisional menjadi kurang efektif.

1.6.2 Natural Language Processing (NLP)

Natural Language Processing (NLP) merupakan cabang dari kecerdasan buatan yang berfokus pada interaksi antara komputer dan bahasa manusia, dengan tujuan memungkinkan komputer untuk memahami, menginterpretasikan, dan menghasilkan bahasa alami secara bermakna (Guo et al., 2022). NLP menggabungkan berbagai disiplin ilmu termasuk linguistik komputasional, ilmu komputer, dan kecerdasan buatan, untuk mengembangkan algoritma dan model yang mampu memproses teks atau ucapan manusia secara otomatis.

Dalam sistem deteksi pesan spam, NLP memainkan peran yang sangat krusial karena kemampuannya untuk memahami konteks, makna semantik, dan pola linguistik dalam teks. Uddin et al. (2025) menjelaskan bahwa pendekatan NLP modern mampu menangkap hubungan kompleks antar kata dalam sebuah kalimat, tidak hanya berdasarkan kemunculan kata secara statistik seperti pada pendekatan tradisional, tetapi juga mempertimbangkan konteks dan makna kata dalam kalimat secara keseluruhan.

Sebelum teks diproses oleh model NLP, tahapan pra-pemrosesan teks merupakan langkah yang sangat penting untuk membersihkan dan menstandarkan data teks mentah. Tahapan umum dalam pra-pemrosesan teks meliputi *case folding* yang mengubah seluruh teks menjadi huruf kecil, tokenisasi yang memecah teks menjadi unit-unit token, *stopword removal* yang menghapus kata-kata tidak bermakna, serta *stemming* atau lematisasi yang menyederhanakan kata ke bentuk dasarnya. Amin et al. (2024) menekankan bahwa tahapan pra-pemrosesan yang tepat sangat berpengaruh terhadap kualitas representasi teks, terlebih untuk teks berbahasa Indonesia yang memiliki karakteristik morfologis yang kaya dan penggunaan bahasa informal yang beragam.

1.6.3 Deep Learning

Deep Learning merupakan subbidang dari *machine learning* yang menggunakan jaringan syaraf tiruan berlapis banyak untuk mempelajari representasi data secara hierarki dari data mentah. Berbeda dengan metode *machine learning* tradisional yang memerlukan rekayasa fitur secara manual, deep learning mampu mengekstrak fitur secara otomatis melalui proses optimasi yang iteratif (AbdulNabi & Yaseen, 2021). Kemampuan ini memungkinkan model untuk mempelajari representasi yang semakin abstrak dan kompleks seiring bertambahnya kedalaman lapisan jaringan.


Dalam domain NLP, *deep learning* telah merevolusi cara komputer memahami bahasa manusia. Nabiilah et al. (2024) menjelaskan bahwa model berbasis *deep learning* secara signifikan mengungguli metode tradisional seperti *Naïve Bayes* dan *Support Vector Machine* (SVM) dalam tugas klasifikasi teks, termasuk deteksi spam, karena kemampuannya untuk menangkap pola linguistik yang kompleks dan konteks semantik dalam teks secara lebih mendalam dan akurat.

1.6.3.1 Transformer

Transformer merupakan arsitektur *deep learning* yang diperkenalkan oleh Vaswani et al. (2017) melalui paper yang berjudul "*Attention is All You Need*". Arsitektur ini merevolusi bidang NLP dengan memperkenalkan mekanisme *self-attention* yang memungkinkan model untuk mempertimbangkan seluruh konteks kalimat secara paralel, berbeda

dengan pendekatan sebelumnya seperti *Recurrent Neural Network* (RNN) dan *Long Short-Term Memory* (LSTM) yang memproses teks secara sekuensial sehingga kurang efisien untuk teks panjang.

Komponen utama arsitektur *Transformer* terdiri dari bagian *encoder* dan *decoder*. *Encoder* bertanggung jawab untuk mengubah urutan input menjadi representasi kontekstual, sementara *decoder* menghasilkan urutan output berdasarkan representasi tersebut. Setiap lapisan pada *encoder Transformer* terdiri dari dua sub-lapisan utama, yaitu *multi-head self-attention* dan *feed-forward neural network*. Mekanisme *self-attention* memungkinkan setiap token dalam urutan untuk memperhatikan semua token lainnya secara bersamaan, sehingga model dapat menangkap hubungan jangka panjang antar kata dalam kalimat dengan lebih efektif (Guo et al., 2022). Arsitektur model *Transformer* dapat dilihat pada Gambar 1.



Gambar 1. Arsitektur Model Transformer (Vaswani et al., 2017)


Keunggulan utama *Transformer* dibandingkan arsitektur sebelumnya adalah kemampuan untuk dilatih secara paralel yang secara signifikan mengurangi waktu pelatihan, serta kemampuan untuk menangkap dependensi jangka panjang dalam teks tanpa masalah *vanishing gradient* yang umum terjadi pada RNN. Keunggulan inilah yang menjadikan *Transformer* sebagai fondasi dari berbagai model bahasa modern termasuk BERT dan IndoBERT yang digunakan dalam penelitian ini (Uddin et al., 2025).

1.6.3.2 Bidirectional Encoder Representation from Transformers (BERT)

BERT (*Bidirectional Encoder Representation from Transformers*) merupakan model bahasa berbasis *Transformer* yang dikembangkan oleh Google AI dan diperkenalkan

oleh Devlin et al. (2019). BERT dirancang untuk menghasilkan representasi kata yang kaya konteks dengan memanfaatkan informasi dari kedua arah secara bersamaan, yaitu dari kiri ke kanan dan dari kanan ke kiri, berbeda dengan model bahasa sebelumnya yang hanya memproses teks dari satu arah.

Secara arsitektur, BERT menggunakan hanya Sebagian *encoder* dari *Transformer*. Versi BERT-base terdiri dari 12 lapisan *Transformer*, 768 unit tersembunyi, dan sekitar 110 juta parameter, sedangkan versi BERT-large memiliki 24 lapisan dan 340 juta parameter (Devlin et al., 2019). BERT menggunakan pendekatan tokenisasi *WordPiece* yang memecah kata menjadi sub-kata, serta menggunakan token khusus [CLS] untuk representasi kalimat secara keseluruhan yang digunakan dalam tugas klasifikasi, dan [SEP] sebagai pemisah antar segmen kalimat.



Gambar 2. Prosedur *Pre-Training* dan *Fine Tuning* BERT (Devlin et al., 2019)


Pada Gambar 2 diperlihatkan secara keseluruhan prosedur *pre-training* dan *fine-tuning* BERT. Proses pelatihan BERT dilakukan dalam dua fase. Fase pertama adalah *pre-training* yang terdiri dari dua tugas utama, yaitu *Masked Language Modeling* (MLM) di mana sebagian token pada input disembunyikan dan model dilatih untuk memprediksinya, serta *Next Sentence Prediction* (NSP) di mana model dilatih untuk memprediksi apakah dua kalimat merupakan pasangan yang berurutan. Fase kedua adalah *fine-tuning*, di mana model yang telah di-*pre-train* disesuaikan dengan tugas-tugas spesifik seperti klasifikasi teks dengan menambahkan lapisan klasifikasi di atas lapisan [CLS] dan melatih ulang seluruh model dengan data berlabel (Arum & Pradana, 2025).

1.6.3.3 IndoBERT

IndoBERT merupakan varian BERT yang dikembangkan secara khusus untuk memahami teks berbahasa Indonesia. Model ini dikembangkan dalam kerangka proyek IndoNLU (*Indonesian Natural Language Understanding*) dan tersedia secara publik melalui platform Hugging Face. IndoBERT dilatih menggunakan korpus teks berbahasa Indonesia yang sangat besar, mencapai 5,5 Miliar kata, yang mencakup berbagai sumber seperti, Wikipedia Indonesia, artikel berita daring, dan korpus web berbahasa Indonesia (Amin et al., 2024).

Secara teknis, Indo BERT menggunakan arsitektur BERT standar dengan 12 lapisan *Transformer* dan 768 unit pemrosesan. Model ini dilatih menggunakan kosataka

WordPiece berbahasa Indonesia yang terdiri dari 31.923 token, jauh lebih spesifik dibandingkan kosakata Multilingual BERT yang harus berbagi ruang kosakata dengan lebih 100 bahasa lainnya. proses pelatihan IndoBERT dilakukan selama 2,4 juta Langkah menggunakan tugas *Masked Language Modeling* dan *Next Sentence Prediction*. Terdapat beberapa varian IndoBERT yang tersedia, di antaranya IndoBERT-base-p1, IndoBERT-base-p2, IndoBERT-large, dan IndoBERT-lite, dimana varian base memiliki sekitar 124,5 juta parameter (Nabiilah et al., 2024). Proses embedding pada model IndoBERT yang digunakan dalam penelitian ini digambarkan pada Gambar 3 berikut.



Gambar 3. Proses *Embedding* IndoBERT (Nabiilah et al., 2024)


Keunggulan IndoBERT dibandingkan model multibahasa terletak pada kemampuannya memahami nuansa linguistik bahasa Indonesia secara lebih mendalam, termasuk karakteristik morfologis bahasa Indonesia, penggunaan kata informal, dan variasi bahasa yang sering ditemukan dalam pesan sehari-hari. Amin et al. (2024) membuktikan bahwa IndoBERT mampu mencapai akurasi 98% dalam mendeteksi pesan spam berbahasa Indonesia, lebih unggul dibandingkan Multilingual BERT yang hanya mampu mencapai 95%, mengkonfirmasi bahwa penggunaan model yang dilatih khusus untuk bahasa tertentu memberikan hasil yang lebih optimal.

1.6.4 Cross Validation

Cross Validation merupakan teknik evaluasi model *machine learning* yang digunakan untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya. Teknik ini bekerja dengan membagi dataset menjadi beberapa bagian, kemudian secara bergantian menggunakan sebagian data sebagai data pelatihan dan bagian lainnya sebagai data validasi. Tujuan utama penggunaan *cross validation* adalah untuk menghasilkan estimasi kinerja model yang lebih objektif dan tidak bergantung pada satu pembagian data tertentu, sehingga mengurangi risiko *overfitting* maupun *underfitting* (Nugroho & Amrullah, 2023).

1.6.4.1 K-Fold Cross Validation

K-Fold Stratified Cross Validation merupakan salah satu metode *cross validation* yang paling umum digunakan, dimana dataset dibagi menjadi k kelompok (fold) yang sama besar. Pada setiap iterasi, satu fold secara bergantian digunakan sebagai data validasi sementara k-1 fold sisanya digunakan sebagai data pelatihan, sehingga setelah k iterasi selesai seluruh data telah digunakan sebagai data validasi tepat satu kali. Hasil evaluasi akhir diperoleh dari rata-rata metrik kinerja model pada seluruh iterasi, sehingga menghasilkan estimasi yang lebih stabil dan representative dibandingkan pembagian data tunggal (Hafid et al., 2023).




Gambar 4. Ilustrasi Pembagian Data pada K-Fold Stratified Cross Validation (GeeksforGeeks, 2025)

Pemilihan nilai k sangat berpengaruh terhadap kualitas evaluasi model. Nilai k yang terlalu kecil dapat menghasilkan estimasi yang kurang stabil karena setiap fold memiliki sedikit data validasi, sementara nilai k yang terlalu besar meningkatkan waktu komputasi secara signifikan. Nilai $k = 5$ dan $k = 10$ merupakan nilai yang paling umum digunakan dalam penelitian karena memberikan keseimbangan yang baik antara bias dan variansi estimasi kinerja model (Nugroho & Amrullah, 2023). Ilustrasi proses pembagian data pada metode *K-Fold Stratified Cross Validation* dengan nilai $k = 5$ dapat dilihat pada Gambar 4. Dalam penelitian ini, *K-Fold Stratified Cross Validation* dengan nilai $k = 5$ diterapkan pada data pelatihan dan validasi yang berjumlah 80% dari total dataset, sehingga pada setiap iterasinya data tersebut dibagi menjadi 4 fold sebagai data pelatihan dan 1 fold sebagai data validasi secara bergantian.

1.6.5 Explainable Artificial Intelligence

Explainable Artificial Intelligence (XAI) merupakan serangkaian metode dan teknik yang dirancang untuk membantu manusia memahami, menginterpretasikan, dan mempercayai proses pengambilan keputusan yang dilakukan oleh model kecerdasan buatan, khususnya model yang bersifat *blackbox* atau kotak hitam (Agrawal & Agrawal, 2025). Model *blackbox* seperti jaringan saraf dalam model *Transformer* memiliki jutaan

parameter yang sulit dipahami secara intuitif oleh manusia, sehingga sulit untuk mengetahui alasan di balik setiap prediksi yang dihasilkan. Secara umum, konsep *Explainable Artificial Intelligence* dalam sistem kecerdasan buatan dapat digambarkan seperti pada Gambar 5 berikut.



Gambar 5. Konsep Explainable Artificial Intelligence (GeeksforGeeks, 2026)

Kebutuhan akan XAI muncul seiring dengan semakin luasnya penerapan model AI dalam pengambilan keputusan yang berdampak besar. Alaoui et al. (2024) menekankan bahwa dalam konteks keamanan siber seperti deteksi spam, transparansi dan kepercayaan terhadap keputusan model merupakan aspek yang sangat penting. Pengguna perlu mengetahui tidak hanya hasil klasifikasi, tetapi juga alasan mengapa suatu pesan diklasifikasikan sebagai spam, agar dapat memvalidasi keputusan model dan meningkatkan kepercayaan terhadap sistem.


Secara umum, metode XAI dapat diklasifikasikan berdasarkan beberapa dimensi. Berdasarkan cakupannya, terdapat penjelasan global yang menjelaskan perilaku model secara keseluruhan, dan penjelasan lokal yang menjelaskan prediksi untuk satu *instance* tertentu. Berdasarkan ketergantungannya pada model, terdapat metode *model-specific* yang hanya bekerja untuk jenis model tertentu, dan metode *model-agnostic* yang dapat diterapkan pada model apapun tanpa perlu mengetahui arsitektur internalnya. Alzahrani (2024) menjelaskan bahwa pendekatan XAI model Agnostik menawarkan fleksibilitas tinggi karena dapat diintegrasikan dengan berbagai jenis model tanpa mengubah arsitektur model itu sendiri.

1.6.5.1 Local Interpretable Model-Agnostic Explanations (LIME)

LIME (*Local Interpretable Model-Agnostic Explanations*) merupakan metode XAI yang diperkenalkan oleh Ribeiro et al. (2016) melalui paper berjudul “*Why Should I Trust You?*” *Explaining the Predictions of Any Classifier*. Sesuai dengan Namanya, LIME memiliki tiga karakteristik utama. *Local* berarti penjelasan bersifat lokal dan spesifik untuk satu prediksi tertentu. *Interpretable* berarti penjelasan yang dihasilkan dapat dipahami oleh manusia dalam bentuk kontribusi fitur yang intuitif. *Model-Agnostic* berarti LIME dapat

diterapkan pada model apapun tanpa perlu mengetahui arsitektur internalnya, sehingga berlaku untuk model *Transformer* seperti IndoBERT (Uddin et al., 2025).

Cara kerja LIME untuk data teks dapat dijelaskan dalam beberapa tahapan. Pertama, LIME menerima sebuah *instance* teks yang akan dijelaskan beserta prediksi model. Kedua, Lime melakukan pertubasi terhadap teks input dengan cara menghapus atau mengganti sebagian kata secara acak untuk memastikan sejumlah besar variasi teks. Ketiga, setiap variasi teks dimasukkan ke dalam model *blackbox* untuk mendapatkan prediksi. Keempat, LIME melatih sebuah *surrogate* model lokal yang sederhana berupa regresi linier menggunakan variasi teks tersebut sebagai data pelatihan, di mana setiap sampel diberi bobot berdasarkan kedekatannya dengan *instance* asli. Kelima, bobot fitur dari *surrogate* model digunakan sebagai skor kontribusi setiap kata terhadap prediksi model (Alzahrani, 2024). Contoh hasil visualisasi kontribusi kata yang dihasilkan oleh metode LIME dapat dilihat pada Gambar 6 berikut.



Gambar 6. Hasil Visualisasi Kontribusi Kata oleh Metode LIME (Ribeiro, 2016)

Output LIME berupa skor kontribusi per kata yang dapat bernilai positif atau negatif. Skor positif menunjukkan bahwa kata tersebut berkontribusi terhadap prediksi kelas spam, sementara skor negatif menunjukkan sebaliknya. Besarnya nilai skor mencerminkan kekuatan pengaruh kata tersebut terhadap prediksi yang dapat divisualisasikan dalam bentuk persentase kontribusi per kata. Uddin et al. (2025) membuktikan bahwa penerapan LIME pada model *Transformer* untuk deteksi SMS spam menghasilkan pengguna memahami alasan di balik setiap keputusan model.

1.6.6 Streamlit

Streamlit merupakan *framework Python open-source* yang dirancang untuk memudahkan para ilmuwan data dan Insinyur *machine learning* dalam membangun dan berbagi aplikasi web interaktif berbasis data tanpa memerlukan pengetahuan pengembangan front-end seperti HTML, CSS, maupun JavaScript (Streamlit Documentation, 2024). *Streamlit* menjadi salah satu *framework* paling populer untuk pengembangan aplikasi berbasis *data science* dan *machine learning*.

Keunggulan utama *Streamlit* terletak pada kesederhanaan penggunaannya. Dengan hanya beberapa baris kode *Python*, pengembangan dapat menciptakan antarmuka web yang interaktif dan menarik, termasuk widget input, visualisasi data, dan

komponen interaktif lainnya. *Streamlit* menggunakan pendekatan *scripting* murni berbasis *Python*, di mana setiap perubahan pada skrip secara otomatis memperbarui tampilan aplikasi secara real-time tanpa perlu melakukan refresh halaman secara manual.

Dalam konteks pengembangan sistem berbasis NLP dan *machine learning*, *Streamlit* menjadi pilihan yang sangat relevan karena kemampuannya mengintegrasikan model NLP langsung kedalam antarmuka pengguna tanpa lapisan pengembangan yang kompleks. Penelitian yang dilakukan oleh Supono & Imani (2026) telah membuktikan keberhasilan penggunaan *Streamlit* dalam mengimplementasikan model IndoBERT untuk klasifikasi email spam berbahasa Indonesia, di mana sistem yang dikembangkan mampu memberikan hasil klasifikasi secara *real-time* melalui antarmuka yang intuitif dan mudah digunakan. Dalam penelitian ini, *Streamlit* dipilih sebagai platform pengembangan dashboard dikarenakan kemampuannya dalam menampilkan hasil klasifikasi model IndoBERT sekaligus visualisasi interpretabilitas LIME secara terintegrasi dalam satu antarmuka yang dapat diakses langsung oleh pengguna.

1.7 Penelitian Terdahulu

Dalam penyusunan penelitian ini, penulis menggunakan acuan dari berbagai hasil penelitian terdahulu sebagai referensi. Berikut disajikan tabel ringkasan penelitian terdahulu yang relevan dengan topik penelitian ini pada Tabel 1.

Tabel 1. Ringkasan penelitian terdahulu

No	Tahun	Penulis	Judul	Identifikasi Masalah	Teknik/ Metode	Hasil
1	2025	(Agrawal & Agrawal, 2025)	<i>Explainable AI in Early Autism Detection: A Literature Review of Interpretable Machine Learning Approaches</i>	Model prediksi ASD berbasis ML sering bersifat <i>blackbox</i> sehingga sulit untuk dipahami oleh klinisi	<i>Literature review</i> terhadap penggunaa n XAI pada berbagai pendekatan ML untuk deteksi dini ASD	XAI terbukti meningkatkan transparansi dan kepercayaan model prediksi pada domain kesehatan, khususnya deteksi ASD
2	2021	(AbdulNabi & Yaseen, 2021)	<i>Spam Email Detection Using Deep Learning</i>	Email spam sulit dideteksi secara akurat menggunakan	<i>Fine-tuning BERT (bert-base-cased)</i> dan perbandingan dengan	BERT dapat mencapai akurasi 98,67% dan F1-score 98,66% pada dua dataset

No	Tahun	Penulis	Judul	Identifikasi Masalah	Teknik/ Metode	Hasil
			<i>Techniques</i>	an metode klasik yang tidak memahami konteks teks	BiLSTM, KNN, dan Multinomial NB	publik, metode tersebut melampaui metode tradisional lainnya.
3	2022	(Guo et al., 2022)	<i>Spam Detection Using Bidirectional Transformer and Machine Learning Classifier Algorithms</i>	Keterbatasan metode deteksi spam konvensional dalam memahami representasi semantik teks email	BERT digunakan sebagai <i>feature extractor</i> yang dikombinasikan dengan empat algoritma ML yaitu <i>Logistic Regression</i> , SVM, KNN, dan <i>Random Forest</i>	<i>Logistic Regression</i> mencapai performa terbaik pada dua dataset public, yang membuktikan efektivitas kombinasi BERT dan ML
4	2024	(Amin et al., 2024)	Deteksi Spam Berbahasa Indonesia Berbasis Teks Menggunakan Model BERT	Kurangnya model deteksi spam yang dirancang khusus untuk memahami karakteristik linguistic bahasa Indonesia	<i>Fine-tuning</i> IndoBERT dan Multilingual BERT pada dataset SMS dan email spam berbahasa Indonesia	IndoBERT mencapai akurasi 98% dan MultilingualBERT 95%, hal tersebut membuktikan keunggulan model spesifik bahasa untuk deteksi spam berbahasa Indonesia
5	2024	(Alzaharani, 2024)	<i>Explainable AI-based Framework for Efficient</i>	Model deteksi spam berbasis ML atau DL bersifat	<i>Ensemble stacking</i> dua lapis dengan empat <i>base classifier</i>	<i>Recall</i> 98%, <i>Precision</i> 96%, <i>F1-score</i> 97%, lalu SHAP berhasil menjelaskan

No	Tahun	Penulis	Judul	Identifikasi Masalah	Teknik/ Metode	Hasil
			<i>Detection of Spam from Text using Enhanced Ensemble Technique</i>	<i>blackbox</i> sehingga sulit di percaya pengguna	dan <i>meta-classifier Random Forest</i> , yang juga dilengkapi XAI berbasis SHAP	kontribusi fitur terhadap prediksi spam
6	2025	(Arum & Pradana, 2025)	Implementasi <i>Bidirectional Encoder Representation from Transformer (BERT)</i> untuk Klasifikasi Spam pada Email	Metode deteksi spam tradisional seperti <i>Naïve Bayes</i> dan SVM memiliki keterbatasan dalam memahami konteks teks	<i>Fine-tuning BERT pre-trained</i> pada dataset email spam	Akurasi mencapai 97%, lebih tinggi dibandingkan metode tradisional seperti <i>Naïve Bayes</i> dan SVM
7	2025	(Uddin et al., 2025)	<i>Explainable Detector: Exploring Transformer-based Language Modeling Approach for SMS Spam Detection with Explainability Analysis</i>	SMS Spam sulit dideteksi dan model <i>Transformer</i> yang digunakan bersifat <i>blackbox</i> tanpa penjelasan prediksi	<i>Fine-tuning RoBERTa</i> untuk klasifikasi SMS spam, dilengkapi XAI dengan LIME untuk menghasilkan skor koefisien per token	RoBERTa mencapai akurasi 99,84%, dan LIME berhasil menghasilkan interpretasi kontribusi kata terhadap prediksi spam secara transparan
8	2024	(Alaoui et al., 2024)	<i>Towards Transparent Cybersec</i>	Sistem deteksi SMS spam berbasis MI	Kombinasi BERT, ANN, dan <i>Random</i>	Model <i>hybrid</i> berhasil meningkatkan akurasi deteksi

No	Tahun	Penulis	Judul	Identifikasi Masalah	Teknik/ Metode	Hasil
			<i>urity: The Role of Explainable AI in Mitigating Spam Threats</i>	dan DL tidak transparan sehingga sulit dipercaya dan divalidasi	<i>Forest</i> untuk mendeteksi spam SMS, dengan SHAP untuk interpretabilitas keputusan model	spam sekaligus memberikan penjelasan transparan melalui SHAP values
9	2026	(Supono & Imani, 2026)	Implementasi <i>Machine Learning</i> untuk Klasifikasi Email Spam Menggunakan IndoBERT, Hugging Face <i>Transformers</i> dan <i>Streamlit</i>	Metode deteksi spam konvensional berbasis kata kunci tidak mampu memahami makna semantik teks email berbahasa Indonesia secara kontekstual	<i>Fine-tuning</i> IndoBERT dengan <i>tokenizer</i> Hugging Face pada dataset email berbahasa Indonesia, diimplementasikan ke dalam antarmuka berbasis <i>Streamlit</i>	Akurasi 97%, presisi 98%, dan <i>recall</i> 95% pada data uji, serta pengujian <i>end-to-end</i> membuktikan keberhasilan implementasi model dalam skenario penggunaan nyata

Berdasarkan **Error! Reference source not found.**, berikut uraian singkat dari masing-masing penelitian terdahulu yang relevan dengan topik penelitian ini.

Penelitian berjudul “*Explainable AI in Early Autism Detection: A Literature Review of Interpretable Machine Learning Approaches*” yang dilakukan oleh Agrawal & Agrawal (2025) mengkaji berbagai pendekatan *machine learning* yang dapat diinterpretasikan untuk membantu diagnosis ASD secara transparan. Hasil tinjauan menunjukkan bahwa XAI sangat penting dalam meningkatkan transparansi dan kepercayaan model prediksi di domain kesehatan. Penelitian ini relevan karena menguatkan kebutuhan penggunaan XAI, khususnya LIME, untuk menjelaskan keputusan model pada klasifikasi teks seperti deteksi spam.

Penelitian berjudul “*Spam Email Detection Using Deep Learning Techniques*” yang dilakukan oleh AbdulNabi & Yaseen (2021) membahas efektivitas *word embedding* dalam mengklasifikasikan email spam menggunakan model BERT (*bert-base-cased*) yang di-*fine-tune* dan dibandingkan dengan BiLSTM serta klasifier tradisional. Hasil penelitian menunjukkan bahwa BERT mencapai akurasi 98,67% dan F1-Score 98,66%,

membuktikan bahwa *deep learning* berbasis *Transformer* memiliki potensi kuat untuk mendeteksi spam dibandingkan metode tradisional.

Penelitian berjudul “*Spam Detection Using Bidirectional Transformers and Machine Learning Classifier Algorithms*” yang dilakukan oleh Guo et al. (2022) mengusulkan pendekatan deteksi spam yang menggabungkan BERT sebagai *feature extractor* dengan empat algoritma machine learning. Hasil evaluasi menunjukkan bahwa *Logistic Regression* mencapai performa terbaik pada kedua dataset public yang digunakan, mendukung penggunaan model berbasis BERT untuk deteksi spam berbasis teks.

Penelitian berjudul “Deteksi Spam Berbahasa Indonesia Berbasis Teks Menggunakan Model BERT” yang dilakukan oleh Amin et al. (2024) mengevaluasi model IndoBERT dan MultilingualBERT dalam mengklasifikasikan pesan spam berbahasa Indonesia. IndoBERT mencapai akurasi 98% dibandingkan MultilingualBERT yang hanya 95%, membuktikan keunggulan model spesifik bahasa untuk deteksi spam berbahasa Indonesia. Namun, penelitian ini belum mengintegrasikan teknik interpretabilitas untuk menjelaskan keputusan prediksi model.

Penelitian berjudul “*Explainable AI-based Framework for Efficient Detection of Spam from Text using an Enhanced Ensemble Technique*” yang dilakukan oleh Alzahrani (2024) mengembangkan sistem deteksi spam menggunakan *ensemble stacking* dua lapis yang dilengkapi XAI berbasis SHAP. Hasil penelitian menunjukkan performa tinggi dengan Recall 98%, Precision 96%, dan F1-Score 97%, mendukung pentingnya menggabungkan model modern dengan XAI untuk menghasilkan sistem deteksi spam yang akurat sekaligus dapat dijelaskan.

Penelitian berjudul “Implementasi *Bidirectional Encoder Representations from Transformers* (BERT) untuk Klasifikasi Spam pada Email” yang dilakukan oleh Arum & Pradana (2025) menerapkan model BERT *pre-trained* untuk mengklasifikasikan email spam dengan akurasi mencapai 97%, jauh lebih tinggi dibandingkan metode tradisional. Namun, penelitian ini masih berfokus pada performa model dan belum menyertakan teknik interpretabilitas untuk menjelaskan keputusan prediksi.

Penelitian berjudul “*ExplainableDetector: Exploring Transformer-based Language Modeling Approach for SMS Spam Detection with Explainability Analysis*” yang dilakukan oleh Uddin et al. (2025) mengembangkan model deteksi SMS Spam berbasis RoBERTa yang dilengkapi dengan analisis interpretabilitas menggunakan LIME. Hasil penelitian menunjukkan akurasi 99,84% sekaligus menghasilkan interpretabilitas yang transparan melalui LIME, namun masih terbatas pada dataset berbahasa Inggris.

Penelitian berjudul “*Towards Transparent Cybersecurity: The Role of Explainable AI in Mitigating Spam Threats*” yang dilakukan oleh Alaoui et al. (2024) menginvestigasi peran XAI dalam sistem deteksi spam SMS menggunakan model *hybrid* yang dilengkapi SHAP untuk interpretabilitas. Hasil penelitian menunjukkan bahwa pendekatan XAI tidak hanya meningkatkan akurasi deteksi spam, tetapi juga meningkatkan transparansi dan kepercayaan prediksi.

Penelitian berjudul “Implementasi *Machine Learning* untuk Klasifikasi Email Spam Menggunakan IndoBERT, Hugging Face *Transformers* dan *Streamlit*” yang dilakukan oleh Supono & Imani (2026) mengimplementasikan IndoBERT dengan antarmuka *Streamlit* untuk deteksi email spam berbahasa Indonesia dan mencapai

akurasi 97%. Namun, penelitian tersebut belum menyertakan teknik XAI seperti LIME untuk menjelaskan kontribusi kata per kata terhadap keputusan model, sehingga sistem yang dihasilkan belum sepenuhnya transparan bagi pengguna.

BAB II METODE PENELITIAN

2.1 Pendekatan Penelitian

Penelitian ini menggunakan pendekatan kuantitatif dengan metode *Research and Development* (R&D) yang dikombinasikan dengan pendekatan eksperimental komputasional. Pendekatan R&D dipilih karena penelitian ini tidak hanya bertujuan untuk menganalisis kinerja model secara teoritis, tetapi juga menghasilkan sebuah produk berupa dashboard interaktif deteksi pesan Spam yang dapat digunakan langsung oleh pengguna. Sementara itu, pendekatan eksperimental komputasional digunakan untuk mengevaluasi kinerja model IndoBERT secara terukur melalui serangkaian eksperimen pelatihan dan pengujian yang sistematis.

Secara operasional, model IndoBERT varian indobert-base-p2 di-*fine-tune* menggunakan skema *5-Fold Stratified Cross-Validation* dengan mekanisme *Early Stopping* untuk mengevaluasi kinerja klasifikasi model yang diukur menggunakan metrik *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *AUC*. Untuk meningkatkan transparansi keputusan model yang bersifat *blackbox*, metode LIME diterapkan sebagai pendekatan *Explainable Artificial Intelligence* (XAI) untuk memvisualisasikan kontribusi setiap kata terhadap keputusan prediksi model. Seluruh komponen tersebut kemudian diintegrasikan ke dalam dashboard interaktif berbasis *Streamlit* yang menampilkan hasil prediksi, visualisasi *highlight* warna, dan tabel skor kontribusi kata secara *real-time*.

2.2 Waktu dan Tempat Penelitian

Penelitian ini dilaksanakan di Kota Makassar, Sulawesi Selatan, dengan waktu penelitian dua bulan sejak Oktober 2025 hingga November 2025. Adapun detail waktu penelitian dapat dilihat pada Tabel 2.

Tabel 2. Waktu penelitian

Kegiatan	Oktober				November			
	1	2	3	4	1	2	3	4
Pengumpulan Data								
Studi Literatur								
Perancangan Sistem								
Preprocessing Data & Persiapan Dataset								
Fine-Tuning Model IndoBERT								
Evaluasi Model								
Penerapan LIME XAI								
Implementasi Aplikasi Streamlit								

2.3 Instrumen Penelitian

Pelaksanaan penelitian ini didukung oleh beberapa instrumen yang digunakan selama proses penelitian berlangsung. Instrumen tersebut terbagi menjadi dua kategori, yaitu perangkat keras (*hardware*) dan perangkat lunak (*software*).

2.3.1 Perangkat Keras (Hardware)

Adapun perangkat keras yang digunakan dalam penelitian ini dapat dilihat pada Tabel 3.

Tabel 3. Perangkat Keras (Hardware)

Jenis	Spesifikasi
Sistem Operasi	Windows 11
Prosesor	AMD Ryzen 5 5600H
Memori (RAM)	16GB DDR4
GPU	AMD Radeon ^(TM) Graphics

2.3.2 Perangkat Lunak (Software)

Adapun perangkat lunak yang digunakan selama penelitian ini dengan tujuan untuk mempermudah proses pengerjaan dapat dilihat pada Tabel 4.

Tabel 4. Perangkat Lunak (Software)

Perangkat Lunak	Fungsi Utama
<i>Python</i>	Bahasa pemrograman utama yang digunakan dalam penelitian ini untuk mengembangkan, melatih, serta mengevaluasi model deteksi pesan spam berbasis IndoBERT
<i>Pandas</i>	<i>Library Python</i> untuk mengolah dan menganalisis dataset pesan spam dalam bentuk struktur <i>DataFrame</i> , termasuk proses pembersihan dan persiapan data
<i>SciPy</i>	<i>Library</i> komputasi ilmiah <i>Python</i> yang digunakan untuk operasi matematika dan statistik tingkat lanjut, termasuk perhitungan jarak dan distribusi probabilitas yang dibutuhkan dalam proses interpretasi LIME
<i>Accelerate</i>	<i>Library</i> dari Hugging Face yang digunakan untuk mengoptimalkan dan mempercepat proses pelatihan model IndoBERT pada perangkat keras yang tersedia, termasuk pengelolaan komputasi GPU secara efisien
<i>SentencePiece</i>	<i>Library</i> tokenisasi yang digunakan sebagai dependensi pendukung <i>tokenizer</i> IndoBERT dalam memproses dan memecah teks berbahasa Indonesia menjadi unit sub-kata (<i>subword</i>)
<i>TorchVision</i>	<i>Library</i> dari ekosistem <i>PyTorch</i> yang digunakan sebagai dependensi pendukung dalam operasi pemrosesan data berbasis tensor
<i>re</i> (<i>Regular Expression</i>)	modul <i>Python</i> yang digunakan untuk melakukan pembersihan teks secara otomatis melalui pencocokan pola (<i>pattern matching</i>), mencakup penghapusan tautan URL, karakter khusus, serta normalisasi spasi berlebih
<i>NumPy</i>	<i>Library</i> komputasi numerik <i>Python</i> yang digunakan untuk operasi <i>array</i> dan matriks dalam proses pengolahan data dan perhitungan metrik evaluasi model
<i>Hugging Face Hub</i>	<i>Platform</i> repositori model yang digunakan untuk menyimpan dan mengelola artefak model IndoBERT hasil pelatihan, serta menjembatani transfer model dari Google Colab ke aplikasi <i>Streamlit</i>

Perangkat Lunak	Fungsi Utama
<i>LIME</i>	<i>Library Python</i> untuk mengimplementasikan metode <i>Local Interpretable Model-Agnostic Explanation</i> (LIME) sebagai teknik XAI yang menghasilkan interpretasi kontribusi kata per kata terhadap keputusan prediksi model
<i>Matplotlib & Seaborn</i>	<i>Library</i> visualisasi data yang digunakan untuk menghasilkan grafik dan diagram evaluasi model seperti <i>confusion matrix</i> , kurva akurasi, dan kurva loss selama proses pelatihan
<i>PyTorch</i>	<i>Framework deep learning</i> yang digunakan sebagai fondasi pelatihan dan fine-tuning model IndoBERT, termasuk pengelolaan tensor, propagasi balik, dan optimasi parameter model
<i>Scikit Learn</i>	<i>Library machine learning</i> yang digunakan untuk proses pembagian dataset, serta menghitung metrik evaluasi kinerja model yang meliputi <i>accuracy</i> , <i>precision</i> , <i>recall</i> , dan <i>F1-score</i>
<i>Transformers</i>	<i>Library</i> dari Hugging face yang digunakan untuk mengkonfigurasi, dan melakukan <i>fine-tuning</i> model IndoBERT beserta <i>tokenizer</i> -nya dalam tugas klasifikasi pesan spam
<i>Visual Studio Code</i>	<i>Integrated Development Environment</i> yang digunakan sebagai editor kode utama dalam pengembangan aplikasi dashboard berbasis <i>Streamlit</i>
<i>Google Colab</i>	<i>Platform</i> komputasi berbasis <i>cloud</i> yang digunakan untuk menjalankan proses pelatihan dan <i>fine-tuning</i> model IndoBERT dengan memanfaatkan GPU yang tersedia
<i>Google Drive</i>	Layanan penyimpanan <i>cloud</i> yang digunakan untuk menyimpan dataset, menyimpan <i>checkpoint</i> model hasil pelatihan, serta mengintegrasikan data dengan Google Colab
<i>Streamlit</i>	<i>Framework Python</i> yang digunakan untuk membangun dan mengembangkan dashboard interaktif berbasis web yang mengintegrasikan model IndoBERT dan visualisasi LIME secara <i>real-time</i>
<i>Microsoft Edge</i>	Peramban web yang digunakan untuk mengakses dan menguji tampilan serta fungsionalitas dashboard Streamlit selama proses pengembangan dan pengujian sistem

2.4 Deskripsi Data


Penelitian ini menggunakan dataset Spam Dataset Indonesia yang merupakan kumpulan pesan spam berbahasa Indonesia. Kumpulan data tersebut bersumber dari situs Kaggle (<https://www.kaggle.com/datasets/rafiyahmadzainur/spam-dataset-indonesia>), yang merupakan sebuah platform yang menyajikan berbagai dataset publik dan telah digunakan oleh peneliti dan praktisi dalam ruang lingkup *machine learning*. Dataset ini berisi 2.636 pesan berbahasa Indonesia yang telah terbagi menjadi dua kelas, yakni spam dan non-spam. Setiap kelas memiliki jumlah data yang berbeda, pada kelas spam terdapat 1.368 pesan (51,90%) dan 1.268 (48,10%) pesan pada kelas non-spam. Distribusi lengkap jumlah pesan dapat dilihat pada Tabel 5.

Tabel 5. Distribusi Kelas Dataset

Label	Proporsi	Jumlah
Spam	51,90%	1.368
Non-spam	48,10%	1.268

2.5 Teknik Analisis Data dan Pemodelan

Teknik analisis data dan pemodelan dalam penelitian ini dilakukan melalui serangkaian tahapan yang bertujuan untuk mengembangkan model klasifikasi pesan Spam berbahasa Indonesia yang akurat dan dapat diinterpretasikan berbasis IndoBERT. Tahapan analisis mencakup analisis data eksplorasi (EDA), pra-pemrosesan data, pembagian dataset, *fine-tuning* model IndoBERT menggunakan *skema 5-Fold Stratified Cross-Validation*, evaluasi model menggunakan pendekatan *Best Single Fold* dan *Soft Voting Ensemble*, hingga implementasi hasil pada dashboard interaktif berbasis *Streamlit* yang dilengkapi dengan interpretabilitas berbasis LIME. Adapun alur tahapan penelitian ini secara keseluruhan dapat dilihat pada Gambar 7.

**Gambar 7.** Pipeline penelitian


2.5.1 Analisis Data Eksplorasi (EDA)

Tahapan analisis data dan pemodelan dalam penelitian ini diawali dengan melakukan prosedur Analisis Data Eksplorasi atau *Exploratory Data Analysis* (EDA) terhadap

dataset mentah. Eksekusi tahap EDA ini bertujuan untuk mengidentifikasi karakteristik fisik dataset, mendeteksi keberadaan anomaly data, memeriksa Tingkat keseimbangan kelas target (*data imbalance checking*), serta memetakan variansi dimensi panjang karakter teks. Implementasi tahapan EDA ini menjadi landasan teknis yang krusial sebelum data dialirkan menuju tahap pra-pemrosesan (*pre-processing*) teks dan pemodelan IndoBERT.

Overview Dataset. Tahapan awal dalam EDA adalah melakukan *overview* dataset untuk memahami struktur dan kualitas data secara umum. Pada tahap ini dilakukan pemeriksaan jumlah data, jumlah fitur, serta tipe data pada setiap kolom. Selain itu, dilakukan identifikasi terhadap nilai yang hilang (*missing values*) untuk mengetahui kelengkapan data, serta deteksi data duplikat guna memastikan tidak terdapat data berulang yang dapat menyebabkan bias pada model. Berdasarkan hasil pemeriksaan, dataset terdiri dari 2.636 sampel dengan dua kolom, yakni kolom label bertipe *integer* dan kolom *text* bertipe *object*. Hasil pemeriksaan integritas data menunjukkan bahwa dataset tidak mengandung *missing values* pada kedua kolom. Namun, ditemukan 16 data duplikat yang selanjutnya dihapus pada tahap *pre-processing*, sehingga dataset bersih yang digunakan dalam proses pelatihan berjumlah 2.620 sampel.

Distribusi Kelas pada Dataset. Analisis distribusi kelas dilakukan untuk mengetahui sebaran jumlah data pada setiap kelas target. Tahap ini bertujuan untuk mengidentifikasi apakah dataset memiliki distribusi yang seimbang (*balanced*) atau terdapat ketimpangan (*imbalanced*) antar kelas yang dapat mempengaruhi proses pelatihan model.




Gambar 8. Distribusi Kelas pada Dataset


Berdasarkan Gambar 8, terlihat bahwa distribusi kelas pada dataset menunjukkan komposisi yang relatif seimbang antara kelas Spam dan Non-Spam. Kelas Spam (1) memiliki jumlah sampel sebanyak 1.368 sampel (51,90%), sementara kelas Non-Spam (0) memiliki jumlah sampel sebanyak 1.268 sampel (48,10%), dengan selisih

proporsi antar kelas sebesar 3,80%. Kondisi ini mengindikasikan bahwa dataset tidak mengalami ketimpangan kelas yang ekstrem, sehingga model memiliki kesempatan yang cukup seimbang untuk mempelajari karakteristik linguistik dari kedua kelas secara proporsional. Meskipun demikian, selisih proporsi yang ada tetap ditangani melalui mekanisme pembobotan kelas dinamis (*dynamic class weights*) pada fungsi kerugian *Cross-Entropy* guna memastikan sensitivitas model terhadap kelas minoritas tetap terjaga secara optimal selama proses pelatihan.

Analisis Panjang Teks Pesan. Analisis panjang teks pesan dilakukan untuk memahami karakteristik konten teks yang terdapat dalam dataset. Panjang teks dihitung berdasarkan jumlah karakter pada setiap pesan, kemudian dianalisis menggunakan statistik deskriptif seperti nilai minimum, maksimum, rata-rata, dan median. Selain itu, distribusi panjang teks divisualisasikan menggunakan histogram per kelas untuk melihat pola sebaran data, serta *boxplot* per kelas untuk mengidentifikasi keberadaan nilai ekstrem (*outlier*) pada masing-masing kelas



Gambar 9. Distribusi Panjang Teks per Kelas



Gambar 10. Sebaran Panjang Teks per Kelas


Berdasarkan Gambar 9, histogram distribusi panjang teks per kelas menunjukkan bahwa baik kelas Spam maupun Non-Spam didominasi oleh pesan-pesan dengan panjang teks yang pendek, yakni berada pada rentang 0 hingga 1.000 karakter. Kedua kelas memperlihatkan pola distribusi yang sangat condong ke kanan (*right-skewed*), yang ditandai dengan frekuensi tertinggi pada rentang panjang teks terpendek dan menurun tajam seiring bertambahnya panjang teks. Kurva distribusi kelas Non-Spam memperlihatkan puncak yang lebih tinggi dibandingkan kelas Spam pada rentang teks pendek, namun kelas Spam memiliki ekor distribusi yang lebih panjang, mengindikasikan bahwa pesan Spam cenderung memiliki variasi panjang teks yang lebih beragam dibandingkan pesan Non-Spam.

Hal tersebut diperkuat oleh visualisasi *boxplot* pada Gambar 10, yang menunjukkan adanya banyak nilai ekstrem (*outlier*) pada bagian atas untuk kedua kelas. Pada kelas Non-Spam, nilai *outlier* tertinggi mencapai lebih dari 33.000 karakter, sementara pada kelas Spam nilai *outlier* tertinggi mencapai sekitar 30.000 karakter. Kotak pada kedua kelas terlihat sangat tipis dan berada di rentang bawah, mengkonfirmasi bahwa 50% data tengah pada kedua kelas memiliki panjang teks yang relatif pendek. Nilai median panjang teks secara keseluruhan berada di angka 860 karakter, dengan rata-rata 1.481,52 karakter yang jauh lebih tinggi akibat tarikan nilai-nilai ekstrem tersebut. Kondisi distribusi panjang teks yang *right-skewed* dengan banyak *outlier* ini memiliki implikasi langsung terhadap konfigurasi pemodelan IndoBERT, khususnya dalam penentuan parameter *max_length* pada proses tokenisasi. Mengingat model IndoBERT memiliki batasan panjang token maksimum sebesar 512 token dan sebagian besar pesan berkarakter pendek, maka ditetapkan nilai *max_length* sebesar 128 token sebagai kompromi antara cakupan informasi teks yang representatif dan efisiensi komputasi selama proses pelatihan. Pesan-pesan yang panjangnya melebihi

batas tersebut akan dipotong secara otomatis, sementara pesan yang lebih pendek akan dilengkapi dengan token *padding* hingga mencapai panjang yang seragam.

2.5.2 Pre-processing Data

Tahap pra-pemrosesan data dilakukan untuk membersihkan dan menyiapkan dataset sebelum digunakan dalam proses pelatihan model. Dataset dimuat dalam format CSV yang memiliki dua kolom utama, yaitu kolom text yang berisi isi pesan dan kolom label yang berisi kategori kelas pesan. Tahapan pra-pemrosesan data dalam penelitian ini mencakup tiga proses utama, yakni pembersihan teks (*text cleaning*), dan label *encoding*. Alur tahapan pra-pemrosesan data dalam penelitian ini secara keseluruhan divisualisasikan pada Gambar 11.



Gambar 11. Pipeline Alur Pra-pemrosesan Data

Penghapusan Data Duplikat. Sebelum proses pembersihan teks dilakukan, tahap pertama dalam pra-pemrosesan data adalah penghapusan data duplikat. Berdasarkan hasil identifikasi pada tahap EDA, ditemukan sebanyak 16 sampel duplikat dalam dataset mentah, yakni baris data yang memiliki isi teks dan label kelas yang identik secara keseluruhan. Data duplikat tersebut dihapus seluruhnya dari dataset untuk menghindari bias pada proses pelatihan model, di mana keberadaan data berulang dapat menyebabkan model mempelajari pola yang sama secara berlebihan sehingga

mengurangi kemampuan generalisasi model terhadap data baru. Setelah penghapusan data duplikat, dataset yang semula berjumlah 2.636 sampel berkurang menjadi 2.620 sampel yang selanjutnya digunakan dalam seluruh tahapan pemrosesan dan pelatihan model.

Text Cleaning. Proses pembersihan teks dilakukan untuk menghilangkan *noise* dan karakter yang tidak relevan dari data mentah sebelum diproses lebih lanjut. Pada tahap ini, teks pesan dibersihkan melalui dua langkah utama secara berurutan, yakni menghapus tautan URL yang tidak berkontribusi terhadap makna semantik pesan, serta menghapus karakter khusus dan tanda baca yang tidak relevan seperti simbol, angka, dan karakter non-alfanumerik. Tahapan *text cleaning* ini bertujuan untuk menghilangkan elemen-elemen yang berpotensi mengganggu proses ekstraksi fitur linguistik oleh model IndoBERT.

Normalisasi Teks. Setelah proses *text cleaning* selesai tahapan selanjutnya adalah normalisasi teks yang bertujuan untuk menstandarisasi format penulisan teks agar konsisten di seluruh dataset. Normalisasi teks dilakukan melalui dua Langkah, yakni *case folding* yang mengubah seluruh karakter teks menjadi huruf kecil (*lowercase*) untuk memastikan keseragaman representasi kata tanpa memandang perbedaan kapitalisasi, serta normalisasi spasi yang bertujuan untuk membersihkan spasi berlebih sehingga antar kata hanya dipisahkan oleh satu spasi tunggal. Kombinasi kedua Langkah ini menghasilkan teks yang bersih, konsisten, dan terstandarisasi sebagai masukan bagi tahap label *encoding* dan tokenisasi selanjutnya.

Label Encoding. Setelah proses pembersihan teks selesai dilakukan, tahapan selanjutnya adalah label *encoding* yang bertujuan untuk mengkonversi label kelas dari format teks menjadi format numerik yang dapat diproses oleh model. Pada tahap ini, label pada dataset dikonversi secara biner, dimana label Spam dikonversi menjadi nilai 1 dan label Ham atau Non-Spam dikonversi menjadi nilai 0, sehingga tugas klasifikasi menjadi klasifikasi biner (*binary classification*). Konversi ini diperlukan karena model IndoBERT hanya dapat memproses input dalam bentuk numerik, sehingga representasi label dalam bentuk angka menjadi prasyarat sebelum data dapat dialirkan ke dalam proses pelatihan model.

2.5.3 Pembagian Data (Splitting Data)

Tahap pembagian data dilakukan untuk memisahkan dataset menjadi dua bagian yang digunakan pada taha berbeda dalam proses penelitian. Pada penelitian ini dataset dibagi dengan proporsi 80% untuk data pelatihan dan validasi serta 20% untuk data pengujian. Pembagian ini dilakukan secara proporsional, artinya perbandingan jumlah pesan spam dan non-spam pada setiap bagian data tetap dijaga agar seimbang sesuai dengan komposisi pada dataset asli, sehingga tidak terjadi ketimpangan kelas yang dapat mempengaruhi proses pelatihan maupun evaluasi model. Distribusi lengkap pembagian dataset dapat dilihat pada Tabel 6.

Tabel 6. Pembagian Dataset

Subset Data	Proporsi	Jumlah Data
Train & Validasi	80%	2.096
Test	20%	524

Total	100%	2.620
--------------	-------------	--------------

Tabel 7. Pembagian Data pada K-Fold Cross Validation

Subset Data	Proporsi	Jumlah Data
Train	52,20%	1.677
Validasi	47,80%	419
Total	100%	2.096

Pada Tabel 7, data pelatihan dan validasi yang berjumlah 80% dari total dataset selanjutnya digunakan dalam proses *K-Fold Stratified Cross Validation* dengan nilai $k = 5$, dimana data tersebut dibagi menjadi 5 kelompok (fold) yang sama besar. Pada setiap iterasi, satu fold dengan proporsi 52,20% dari total dataset secara bergantian digunakan sebagai data validasi sementara empat fold sisanya dengan proporsi 47,80% dari total dataset digunakan sebagai data pelatihan. Sementara itu, data pengujian yang berjumlah 20% dipisahkan sejak awal dan hanya digunakan pada tahap akhir untuk mengukur kinerja model secara independen dan objektif. Hasil evaluasi akhir kemudian diperoleh dari rata-rata metrik kinerja model pada kelima iterasi yang telah dilakukan. Untuk memastikan distribusi kelas pada setiap subset data tetap proporsional, rincian jumlah data berdasarkan kelas spam dan non-spam pada masing masing subset data dapat dilihat pada Tabel 8.

Tabel 8. Distribusi Kelas pada Setiap Subset Data

Subset Data	Spam (1)	Non-Spam (0)	Total
Train & Validasi	1.094	1.002	2.096
Test	274	250	524
Total	1.368	1.252	2.620

2.5.4 Pemodelan IndoBERT

Pemodelan dalam penelitian ini menggunakan IndoBERT, yaitu model berbasis arsitektur *Transformer* yang dirancang khusus untuk memahami teks dalam bahasa Indonesia secara kontekstual. IndoBERT digunakan dengan pendekatan *fine-tuning*, yaitu proses penyesuaian bobot model terhadap dataset yang digunakan. Teks yang menjadi *input* terlebih dahulu melalui tahap tokenisasi, kemudian diubah menjadi representasi numerik melalui *embedding layer*. Selanjutnya, representasi tersebut diproses oleh *encoder transformer* yang terdiri dari beberapa lapisan dengan mekanisme *self-attention* untuk memahami keterkaitan antar kata dalam kalimat. *Output* dari encoder direpresentasikan melalui token [CLS] yang digunakan sebagai representasi keseluruhan kalimat. Representasi ini kemudian diteruskan ke lapisan klasifikasi untuk menghasilkan prediksi akhir.

2.5.4.1 Arsitektur Model

Arsitektur IndoBERT yang digunakan pada penelitian ini mengacu pada model BERT-base yang terdiri dari beberapa komponen utama, yaitu *embedding layer*, *encoder transformer*, serta lapisan klasifikasi. Model ini memiliki 12 *encoder layer*, *hidden size* sebesar 768, dan 12 *attention head*, dengan total parameter sekitar 124 juta.

Tabel 9. Arsitektur Model IndoBERT

Komponen	Layer	Fungsi	Aktivasi	Output Shape
Embedding	Word, Position, Token type	Mengubah token menjadi representasi vektor numerik	-	(None, 128, 768)
Encoder	Self-Attention	Menangkap hubungan antar kata dalam kalimat	-	(None, 128, 768)
	Feed Forward Network	Transformasi fitur	GELU	(None, 128, 768)
	LayerNorm + Residual	Menstabilkan proses pelatihan	-	(None, 128, 768)
Pooler	Dense ([CLS])	Representasi keseluruhan kalimat	Tanh	(None, 768)
Classifier	Dense	Proses klasifikasi	Softmax	(None, 2)

Berdasarkan Tabel 9, proses diawali dari *embedding layer* yang mengubah teks menjadi vektor numerik. Selanjutnya, data diproses melalui *encoder transformer* sebanyak 12 lapisan yang menggunakan mekanisme *self-attention* untuk memahami konteks kalimat. Setiap *encoder layer* juga dilengkapi dengan *feed forward network* serta *layer normalization* untuk meningkatkan stabilitas pelatihan model. Hasil dari proses *encoder* kemudian direpresentasikan melalui token [CLS] yang berfungsi sebagai representasi keseluruhan kalimat. Representasi ini selanjutnya diproses oleh lapisan klasifikasi untuk menghasilkan prediksi akhir. Dalam penelitian ini, panjang maksimum input yang digunakan adalah 128 token. Teks yang melebihi batas tersebut akan dipotong, sedangkan teks yang lebih pendek akan ditambahkan padding agar memiliki panjang yang sama.

2.5.4.2 Tokenisasi

Sebelum teks masukan diproses oleh model IndoBERT, dilakukan tahap tokenisasi yang bertujuan untuk mengubah teks bersih menjadi format numerik yang dapat diterima oleh arsitektur model. Dalam implementasinya, proses tokenisasi dieksekusi secara terintegrasi di dalam setiap iterasi *K-Fold Stratified Cross Validation* untuk memastikan tidak terjadi kebocoran data antar lipatan sehingga setiap subset data di proses secara independent dan konsisten. Tokenisasi dilakukan menggunakan *BertTokenizer* yang dimuat dari model *pre-trained* IndoBERT varian *indobert-base-p2* melalui platform Hugging Face. Tokenizer ini menggunakan pendekatan *WordPiece* sebagian metode tokenisasi bawaan BERT, di mana setiap kata dalam teks akan dipecah menjadi sub-kata (*subword*) sesuai dengan kosakata IndoBERT yang terdiri dari 31.923 token khusus bahasa.

Dalam proses tokenisasi, terdapat beberapa konfigurasi yang diterapkan. Panjang maksimum token ditetapkan sebesar 128 token untuk setiap teks masukan, yang ditentukan berdasarkan hasil analisis distribusi panjang teks pada tahap EDA.

Untuk teks yang panjangnya kurang dari 128 token, token [PAD] ditambahkan secara otomatis hingga mencapai panjang maksimum yang telah ditetapkan (*padding*). Sebaliknya, untuk teks yang panjangnya melebihi 128 token, teks akan dipotong secara otomatis (*truncation*) sehingga panjangnya tidak melebihi batas yang ditentukan. Output yang dihasilkan dari proses tokenisasi ini terdiri dari tiga komponen utama yang dibutuhkan oleh model IndoBERT, yaitu *input_ids* yang merupakan representasi numerik dari setiap token, *attention_mask* yang bernilai 1 untuk token asli dan 0 untuk token padding sehingga model hanya memproses token yang relevan, serta *token_type_ids* yang membedakan segmen kalimat input. Selain itu, tokenizer secara otomatis menambahkan token khusus [CLS] di awal setiap teks sebagai representasi keseluruhan kalimat yang digunakan untuk proses klasifikasi, serta token [SEP] di akhir teks sebagai penanda batas kalimat.

2.5.4.3 Hyperparameter

Hyperparameter merupakan parameter yang ditentukan sebelum proses pelatihan model dimulai dan berperan penting dalam menentukan performa model yang dihasilkan. Konfigurasi *hyperparameter* yang digunakan dalam penelitian ini ditentukan berdasarkan praktik umum yang direkomendasikan untuk *fine-tuning* model berbasis BERT dan disajikan pada Tabel 10 berikut.

Tabel 10. Konfigurasi Hyperparameter

Hyperparameter	Konfigurasi
Batch Size	8
Epoch	10
Early Stopping Patience	2
Learning Rate	2e-5
Optimizer	AdamW
Weight Decay	0.01
Scheduler	Linear
Loss Function	CrossEntropyLoss

Berdasarkan Tabel 10, *batch size* sebesar 8 digunakan untuk menyesuaikan kapasitas memori GPU yang tersedia selama proses pelatihan sekaligus membantu model belajar secara lebih stabil pada setiap iterasi. Maksimum *epoch* ditetapkan sebesar 10 dengan menerapkan mekanisme *Early Stopping* dengan nilai *patience* sebesar 2, yang berarti pelatihan nilai *F1-Score* pada data validasi selama 2 *epoch* berturut-turut. Pendekatan ini memastikan model berhenti pada titik generalisasi optimal tanpa harus menunggu seluruh 10 *epoch* selesai, sehingga mencegah terjadinya *overfitting* sekaligus menghemat waktu komputasi.

Learning rate ditetapkan sebesar 2e-5 yang merupakan nilai yang direkomendasikan untuk *fine-tuning* model berbasis BERT agar pembaruan bobot berlangsung secara stabil tanpa merusak pengetahuan linguistik yang telah dipelajari selama fase *pre-training*. *Optimizer AdamW* digunakan karena merupakan pengembangan dari Adam yang lebih efektif dalam menangani *weight decay* secara terpisah dari momentum gradien, dikombinasikan dengan *weight decay* sebesar 0,01

yang memberikan penalti terhadap bobot yang terlalu besar untuk mencegah *overfitting*. *Scheduler linear* diterapkan untuk menurunkan *learning rate* secara bertahap seiring bertambahnya iterasi pelatihan sehingga model dapat melakukan penyesuaian bobot yang lebih presisi pada tahap akhir pelatihan. Adapun fungsi kerugian yang digunakan adalah *CrossEntropyLoss* standar tanpa pembobotan kelas karena distribusi kelas pada dataset relatif seimbang dengan rasio 51,90% Spam dan 48,10% Non-Spam, sehingga tidak diperlukan penanganan ketidakseimbangan kelas secara khusus.

2.5.4.4 K-Fold Cross Validation

Pada penelitian ini, evaluasi model dilakukan dengan menggunakan metode *K-Fold Stratified Cross Validation* dengan nilai $k = 5$ yang diterapkan pada data pelatihan dan validasi yang berjumlah 2.096 sampel. Data dibagi menjadi 5 kelompok yang sama besar, di mana pada setiap iterasinya satu fold secara bergantian digunakan sebagai data validasi sementara empat fold lainnya digunakan sebagai data pelatihan, sehingga setelah 5 iterasi selesai seluruh data telah digunakan sebagai data validasi tepat satu kali. Model IndoBERT diinisialisasi ulang dari bobot *pre-trained* yang sama pada setiap iterasi dengan konfigurasi *hyperparameter* yang sama, maksimum 10 *epoch*, dan mekanisme *Early Stopping* dengan nilai *patience* sebesar 2. Model terbaik pada setiap fold ditentukan berdasarkan nilai *F1-Score* tertinggi pada data validasi dan disimpan sebagai *best checkpoint*. Nilai kinerja akhir diperoleh dari rata-rata dan standar deviasi metrik evaluasi pada seluruh iterasi sehingga hasil yang diperoleh lebih *robust* dan representatif terhadap kemampuan generalisasi model.

2.5.5 Metrik Evaluasi Kinerja Model

Evaluasi kinerja model pada penelitian ini dilakukan menggunakan empat metrik utama yang umum digunakan dalam tugas klasifikasi teks, yaitu *accuracy*, *precision*, *recall*, dan *F1-score*. Keempat metrik tersebut dihitung berdasarkan nilai yang diperoleh dari *confusion matrix*, yang terdiri dari *True Positif* (TP), *True Negatif* (TN), *False Positif* (FP), dan *False Negatif* (FN). Berdasarkan nilai *confusion matrix* tersebut, masing-masing metrik evaluasi dihitung menggunakan persamaan-persamaan berikut.

Metrik pertama adalah *accuracy*, yang digunakan untuk mengukur proporsi keseluruhan prediksi yang benar terhadap total data. Nilai *accuracy* dihitung menggunakan persamaan berikut:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

Keterangan:

- TP (*True Positif*) merupakan jumlah pesan Spam yang diprediksi benar sebagai Spam
- TN (*True Negatif*) merupakan jumlah pesan Non-Spam yang diprediksi benar sebagai Non-Spam
- FP (*False Positif*) merupakan jumlah pesan Non-Spam yang salah diprediksi sebagai Spam

- FN (*False Negatif*) merupakan jumlah pesan Spam yang salah diprediksi sebagai Non-Spam

Selanjutnya, *precision* digunakan untuk mengukur tingkat ketepatan model dalam memprediksi kelas spam, yaitu proporsi prediksi spam yang benar-benar merupakan spam dari seluruh data yang diprediksi sebagai spam. Persamaan *precision* ditunjukkan sebagai berikut:

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

Keterangan:

- TP (*True Positif*) merupakan jumlah pesan Spam yang diprediksi benar sebagai Spam
- FP (*False Positif*) merupakan jumlah pesan Non-Spam yang salah diprediksi sebagai Spam

Metrik berikutnya adalah *recall*, yang digunakan untuk mengukur kemampuan model dalam mendeteksi seluruh data spam yang ada. Nilai *recall* menunjukkan seberapa banyak data spam yang berhasil diidentifikasi dengan benar oleh model. Persamaannya adalah sebagai berikut:

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

Keterangan:

- TP (*True Positif*) merupakan jumlah pesan Spam yang diprediksi benar sebagai Spam
- FN (*False Negatif*) merupakan jumlah pesan Spam yang salah diprediksi sebagai Non-Spam

Terakhir, *F1-score* digunakan sebagai metrik utama dalam penelitian karena mampu memberikan keseimbangan antara ketepatan (*precision*) dan kelengkapan deteksi (*recall*), terutama pada kasus klasifikasi dengan potensi ketidakseimbangan data. Persamaan *F1-score* adalah sebagai berikut:

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (4)$$

Keterangan:

- *Precision* merupakan tingkat ketepatan model memprediksi kelas Spam
- *Recall* merupakan Tingkat kemampuan model mendeteksi seluruh data Spam yang ada

2.5.6 Implementasi Explainable Artificial Intelligence (XAI)

Pada penelitian ini, implementasi *Explainable Artificial Intelligence* (XAI) dilakukan untuk meningkatkan transparansi dan interpretabilitas hasil prediksi model klasifikasi Spam berbasis IndoBERT. Meskipun model berbasis *deep learning* memiliki performa yang lebih tinggi, proses pengambilan keputusannya cenderung bersifat *blackbox*, sehingga sulit dipahami oleh pengguna akhir. Oleh karena itu, pendekatan XAI diperlukan untuk memberikan penjelasan logis, terukur, dan mudah dipahami terhadap setiap keputusan prediksi yang dihasilkan oleh model.

Metode XAI yang dipilih dalam penelitian ini adalah *Local Interpretable Model-Agnostic Explanations* (LIME). Pemilihan LIME sebagai metode XAI didasarkan pada beberapa pertimbangan. Pertama, LIME menyediakan komponen *LimeTextExplainer* yang dioptimalkan khusus untuk data teks dengan menggunakan perturbasi pada level kata, sehingga lebih sesuai dengan karakteristik dataset pesan Spam berbahasa Indonesia yang digunakan dalam penelitian ini. Kedua, LIME memiliki efisiensi komputasi yang lebih rendah dibandingkan SHAP yang harus menghitung kontribusi seluruh kombinasi fitur berdasarkan teori permainan kooperatif (*Shapley values*), menjadikannya lebih praktis untuk diintegrasikan secara real-time dalam dashboard *Streamlit*. Ketiga, Ahmed et al. (2024) dalam penelitiannya yang membandingkan LIME dan SHAP secara komprehensif pada berbagai model machine learning membuktikan bahwa LIME menunjukkan performa yang lebih baik dibandingkan SHAP pada hampir seluruh skenario pengujian yang dilakukan. Keempat, Uddin et al. (2025) telah membuktikan secara empiris bahwa LIME efektif menghasilkan interpretasi kontribusi kata yang transparan pada model *Transformer* untuk deteksi pesan Spam teks, yang relevan langsung dengan konteks penelitian ini.

Secara teknis, LIME bekerja dengan membangun *surrogate model* lokal berupa regresi linear di sekitar instance yang ingin dijelaskan. Penggunaan regresi linear sebagai *surrogate model* didasarkan pada sifatnya yang *inherently interpretable*, di mana setiap koefisien regresi secara langsung mempresentasikan besar dan arah kontribusi setiap kata terhadap keputusan prediksi. Proses pembangunan *surrogate model* dilakukan melalui perturbasi teks *input* dengan cara menghapus atau mengganti sebagian kata secara acak untuk menghasilkan sejumlah besar variasi teks, kemudian setiap variasi dimasukkan ke dalam model IndoBERT untuk mendapatkan hasil prediksi. Variansi teks beserta prediksinya digunakan sebagai data pelatihan regresi linier lokal, dimana setiap sampel diberikan bobot berdasarkan kedekatannya dengan teks asli. Koefisien dari regresi linier yang terbentuk inilah yang menjadi skor kontribusi setiap kata terhadap prediksi model.


Dalam implementasinya, setiap teks yang dimasukkan ke dalam sistem akan diproses oleh model IndoBERT untuk menghasilkan probabilitas kelas Spam dan Non-Spam. Selanjutnya, LIME mengidentifikasi kata-kata yang memiliki pengaruh besar terhadap keputusan model dan memberikan nilai kontribusi, baik positif maupun negatif. Skor positif menunjukkan bahwa kata tersebut mendorong prediksi ke arah kelas Spam, sementara skor negatif menunjukkan sebaliknya. Hasil interpretasi LIME kemudian divisualisasikan dalam bentuk *highlight* warna pada teks dan grafik batang kontribusi (Skor kata), sehingga pengguna dapat secara intuitif memahami alasan di balik keputusan model. Dengan adanya implementasi XAI berbasis LIME ini, sistem tidak

hanya mampu memberikan prediksi yang akurat, tetapi juga mampu menjelaskan dasar pengambilan keputusan model secara transparan, sehingga meningkatkan kepercayaan pengguna terhadap sistem sekaligus mendukung proses analisis kesalahan model (*error analysis*).

2.6 Rancangan Dashboard Streamlit

Penelitian ini mengembangkan sebuah Dashboard dengan menggunakan *Streamlit* yang merupakan *Framework Python open-source* yang memungkinkan pengembangan aplikasi website berbasis *data science* secara tepat dan efisien. Dashboard ini dikembangkan dengan hanya memiliki satu halaman utama, yakni halaman beranda. Halaman beranda merupakan halaman utama yang menjadi antarmuka pertama yang akan ditemui oleh pengguna saat mengakses sistem. Pada bagian atas halaman ditampilkan judul sistem yang berfungsi sebagai identitas aplikasi sekaligus memberikan gambaran umum mengenai fungsi utama sistem kepada pengguna. Di bawah judul sistem, terdapat kolom input yang memungkinkan pengguna untuk memasukkan teks pesan yang ingin dianalisis. Kemudian setelah teks pesan dimasukkan, pengguna dapat menekan tombol analisis yang akan memicu proses klasifikasi oleh model IndoBERT secara otomatis. Hasil analisis tersebut akan ditampilkan secara langsung di sisi kanan halaman, dengan menyajikan informasi mengenai hasil klasifikasi pesan beserta visualisasi interpretabilitas LIME yang menunjukkan kontribusi setiap kata terhadap keputusan prediksi model. Tata letak halaman yang membagi area input di sisi kiri dan area hasil di sisi kanan dirancang agar pengguna dapat melihat proses klasifikasi dan penjelasannya secara bersamaan dalam satu tampilan yang terintegrasi dan mudah dipahami.

Sebelum Dashboard diimplementasikan, seluruh rancangan antarmuka divisualisasikan terlebih dahulu dalam bentuk *Wireframe*. Pembuatan *Wireframe* tersebut bertujuan untuk memberikan gambaran awal mengenai penyusunan elemen tampilan, alur interaksi pengguna, serta tata letak fitur yang akan dikembangkan. Dengan visualisasi tersebut, proses perancangan dapat dilakukan secara lebih terarah dan sistematis sehingga meminimalkan perubahan besar pada tahap implementasi. *Wireframe* halaman beranda dapat dilihat pada Gambar 12.



Gambar 12. Wireframe Halaman Beranda

BAB III HASIL DAN PEMBAHASAN

3.1 Hasil Pelatihan Model

Proses pelatihan model dilakukan dalam dua eksperimen untuk mengevaluasi pengaruh mekanisme penghentian dini (*Early Stopping*) terhadap kinerja model. Pendekatan pertama menggunakan mekanisme *Early Stopping* dengan nilai *patience* sebesar 2, sedangkan pendekatan kedua melatih model secara penuh selama 10 epoch tanpa mekanisme penghentian dini. Kedua eksperimen tersebut menggunakan konfigurasi *hyperparameter* yang sama dan di evaluasi menggunakan *5-Fold Stratified Cross-Validation* pada data pelatihan dan validasi yang berjumlah 2.096 sampel.

Pada pendekatan pertama, model IndoBERT dilatih menggunakan mekanisme *Early Stopping* yang secara otomatis menghentikan proses pelatihan apabila tidak terjadi peningkatan nilai *F1-Score* pada data validasi selama 2 epoch berturut-turut. Rangkuman metrik kinerja model pada titik-titik henti terbaik (*best checkpoint*) untuk masing-masing lipatan disajikan pada Tabel 11 berikut.

Tabel 11. Kinerja Hasil Pelatihan Model dengan Early Stopping

Fold	Epoch	Val Loss	Accuracy	Precision	Recall	F1-Score	AUC
Fold 1	4	0.0911	0.9833	0.9907	0.9772	0.9839	0.9991
Fold 2	5	0.0582	0.9928	0.9864	1.0000	0.9932	0.9992
Fold 3	4	0.0220	0.9952	0.9910	1.0000	0.9955	0.9994
Fold 4	6	0.0883	0.9905	0.9954	0.9863	0.9908	0.9992
Fold 5	6	0.0973	0.9881	0.9864	0.9909	0.9886	0.9991
Rata-rata	5	0.0714	0.9900	0.9900	0.9909	0.9904	0.9992
Std Dev	1	0.0315	0.0046	0.0038	0.0097	0.0044	0.0001

Berdasarkan Tabel 11, model IndoBERT menunjukkan kinerja yang sangat baik dan konsisten pada seluruh lipatan dengan rata-rata *F1-Score* sebesar 0.9904 dan rata-rata AUC sebesar 0.9992. Nilai standar deviasi *F1-Score* yang rendah sebesar 0.0044 mengindikasikan bahwa kinerja model stabil dan tidak bergantung pada pembagian data tertentu. Dari seluruh lipatan yang diuji, Fold 3 menghasilkan kinerja klasifikasi terbaik dengan *F1-Score* tertinggi sebesar 0.9955, *Accuracy* 0.9952, *Recall* sempurna 1.0000, serta *Validation Loss* terendah sebesar 0.0220 yang jauh lebih kecil dibandingkan Fold lainnya. Pencapaian *Recall* sempurna pada Fold 3 menunjukkan bahwa model berhasil mendeteksi seluruh pesan spam tanpa ada yang terlewatkan, yang merupakan aspek krusial dalam sistem deteksi spam. Atas dasar keunggulan tersebut, representasi bobot jaringan dari Fold 3 secara resmi ditetapkan sebagai *Best Single Fold* dan digunakan sebagai acuan pada tahapan pengujian selanjutnya.

Pada pendekatan kedua, model IndoBERT dilatih secara penuh selama 10 epoch tanpa mekanisme penghentian dini sebagai eksperimen perbandingan.

Rangkuman metrik kinerja model terbaik pada masing-masing lipatan disajikan pada Tabel 12 berikut.

Tabel 12. Kinerja Hasil Pelatihan Tanpa Early Stopping

Fold	Epoch	Val Loss	Accuracy	Precision	Recall	F1-Score	AUC
Fold 1	10	0.0763	0.9881	0.9908	0.9863	0.9886	0.9995
Fold 2	10	0.1386	0.9785	0.9729	0.9862	0.9795	0.9990
Fold 3	10	0.0244	0.9976	0.9955	1.0000	0.9977	0.9993
Fold 4	10	0.0882	0.9857	0.9908	0.9817	0.9862	0.9985
Fold 5	10	0.1031	0.9761	0.9729	0.9817	0.9773	0.9988
Rata-rata	10	0.0861	0.9852	0.9846	0.9872	0.9859	0.9990
Std Dev	0	0.0417	0.0085	0.0109	0.0075	0.0081	0.0004


Berdasarkan Tabel 12, eksperimen pelatihan *Full 10 Epoch* menunjukkan kinerja rata-rata *F1-Score* sebesar 0.9859 dengan standar deviasi sebesar 0.0081. Meskipun Fold 3 kembali menghasilkan kinerja terbaik dengan *F1-Score* 0.9977 dan *Recall* sempurna 1.0000, terdapat variasi kinerja yang lebih besar antar fold dibandingkan pendekatan *Early Stopping*. Hal ini terlihat dari Fold 2 dan Fold 5 yang menunjukkan penurunan performa signifikan dengan *F1-Score* masing-masing hanya 0.9795 dan 0.9772, mengindikasikan adanya gejala *overfitting* pada beberapa fold akibat pelatihan yang terlalu panjang tanpa mekanisme penghentian dini.

Untuk memberikan Gambaran yang lebih jelas mengenai perbedaan kinerja kedua eksperimen pelatihan, disajikan tabel perbandingan rata-rata metrik evaluasi pada **Tabel 13** dan visualisasi perbandingan pada Gambar 13 berikut.

Metrik	Early Stopping	Full 10 Epoch	Selisih
Accuracy	0.9900	0.9852	+0.0048
Precision	0.9900	0.9846	+0.0054
Recall	0.9909	0.9872	+0.0037
F1-Score	0.9904	0.9859	+0.0045
AUC	0.9992	0.9990	+0.0002
Std Dev F1	0.0044	0.0081	-0.0037
Rata-rata Val Loss	0.0714	0.0861	-0.0147

Tabel 13. Perbandingan Rata-rata Kinerja Early Stopping dan Full 10 Epoch

Metrik	Early Stopping	Full 10 Epoch	Selisih
Accuracy	0.9900	0.9852	+0.0048
Precision	0.9900	0.9846	+0.0054
Recall	0.9909	0.9872	+0.0037
F1-Score	0.9904	0.9859	+0.0045
AUC	0.9992	0.9990	+0.0002
Std Dev F1	0.0044	0.0081	-0.0037
Rata-rata Val Loss	0.0714	0.0861	-0.0147



Gambar 13. Perbandingan Rata-rata Kinerja Early Stopping dan Full 10 Epoch

Berdasarkan

Tabel 13 dan Gambar 13, eksperimen pelatihan dengan *Early Stopping* secara

Metrik	Early Stopping	Full 10 Epoch	Selisih
Accuracy	0.9900	0.9852	+0.0048
Precision	0.9900	0.9846	+0.0054
Recall	0.9909	0.9872	+0.0037
F1-Score	0.9904	0.9859	+0.0045
AUC	0.9992	0.9990	+0.0002
Std Dev F1	0.0044	0.0081	-0.0037
Rata-rata Val Loss	0.0714	0.0861	-0.0147

konsisten menghasilkan kinerja yang lebih baik dibandingkan *Full 10 Epoch* pada seluruh metrik evaluasi. Rata-rata *F1-Score* dengan *Early Stopping* mencapai 0.9904, lebih tinggi dibandingkan *Full 10 Epoch* sebesar 0.9859 dengan selisih 0.0045. Perbedaan yang paling signifikan terlihat pada nilai standar deviasi *F1-Score*, dimana *Early Stopping* menghasilkan standar deviasi 0.0044 yang jauh lebih rendah dibandingkan *Full 10 Epoch* sebesar 0.0081, menunjukkan bahwa *Early Stopping* menghasilkan kinerja yang lebih stabil dan konsisten antar fold.

Selain itu, rata-rata *Validation Loss* pada eksperimen *Early Stopping* sebesar 0.0714 juga lebih rendah dibandingkan *Full 10 Epoch* sebesar 0.0861, mengindikasikan bahwa model dengan *Early Stopping* memiliki kemampuan generalisasi yang lebih baik terhadap data yang belum pernah dilihat sebelumnya. Kondisi ini terjadi karena mekanisme *Early Stopping* menghentikan pelatihan pada titik optimal sebelum model mulai mengalami *overfitting*, sehingga model tidak terlalu menyesuaikan diri secara berlebihan terhadap data pelatihan.

Berdasarkan analisis perbandingan tersebut, dapat disimpulkan bahwa penggunaan mekanisme *Early Stopping* terbukti secara empiris lebih efektif dan efisien dibandingkan pelatihan penuh tanpa penghentian dini, baik dari segi kinerja klasifikasi,


stabilitas hasil antar fold, maupun kemampuan generalisasi model. Oleh karena itu, model yang dilatih dengan pendekatan *Early Stopping* dipilih dan digunakan pada tahap pengujian serta implementasi dashboard *Streamlit* selanjutnya.

3.2 Hasil Evaluasi Model

Setelah melalui tahapan pelatihan dan validasi menggunakan skema *5-Fold Stratified Cross-Validation*, model IndoBERT pada Fold 3 ditetapkan sebagai representasi bobot terbaik (*Best Single Fold*), Langkah krusial selanjutnya adalah menguji sejauh mana kemampuan generalisasi model tersebut. Pengujian dilakukan menggunakan dua pendekatan berbeda, yaitu pengujian mandiri menggunakan model *Best Single Fold* dan pengujian agregat menggunakan mekanisme *Soft Voting Ensemble*. Kedua pendekatan ini dievaluasi secara objektif menggunakan 524 sampel data uji (*Test Set*) yang telah diisolasi dan bersih dari data duplikat sejak awal tahapan pra-pemrosesan.

3.2.1 Evaluasi Best Single Fold

Bagian ini menyajikan hasil evaluasi model IndoBERT pada pendekatan *Best Single Fold*, yakni model dengan representasi bobot terbaik yang diperoleh dari Fold 3. Evaluasi dilakukan terhadap 524 sampel data uji (*test set*) yang sepenuhnya terpisah dari proses pelatihan. Metrik evaluasi yang digunakan meliputi *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan AUC, yang dihitung berdasarkan hasil prediksi model pada data uji tersebut. Selain evaluasi kuantitatif, analisis kualitatif terhadap sampel yang salah diklasifikasikan turut dilakukan guna memahami pola dan faktor penyebab kesalahan prediksi secara mendalam.



Gambar 14. Riwayat Pelatihan Fold 3


Berdasarkan grafik Riwayat pelatihan (*Training History*) pada Gambar 14, kurva fungsi *Loss* memperlihatkan bahwa nilai kesalahan validasi mengalami penurunan dari *epoch* pertama (0.0316) hingga mencapai titik terendahnya sebesar 0.0220 pada *epoch* kedua, kemudian meningkat secara konsisten pada *epoch* ketiga (0.0316) dan keempat (0.0919). Pola ini mengindikasikan bahwa titik generalisasi optimal model ditemukan pada *epoch* kedua, sehingga mekanisme *Early Stopping* mengekstraksi bobot terbaik pada *epoch* tersebut sebelum pelatihan dihentikan setelah 4 *epoch* berjalan. Sejalan dengan itu, kurva *Validation F1-Score* mencapai puncaknya pada *epoch* ke dua sebesar 0.9955, didukung oleh nilai *Recall* yang sempurna (1.0000), kemudian menurun pada

epoch ketiga (0.9932) dan keempat (0.9838). Tren kedua kurva yang bergerak secara sinkron ini membuktikan bahwa bobot pada *epoch* kedua merupakan titik keseimbangan optimal antara minimalisasi error dan kemampuan generalisasi model. Hasil evaluasi kuantitatif model pada data uji disajikan pada Tabel 14 berikut.

Tabel 14. Hasil Evaluasi Model Best Single Fold pada Data Uji

Kelas	Precision	Recall	F1-Score	Support
Non-Spam (0)	0,9800	0,9920	0,9860	250
Spam (1)	0,9926	0,9818	0,9872	274
Rata-rata (Macro)	0,9863	0,9869	0,9866	524
Rata-rata (Weighted)	0,9866	0,9866	0,9866	524
Accuracy			0,9866	524
AUC			0,9975	


Model *Best Single Fold* mencatatkan *Accuracy* sebesar 0.9866 dengan *F1-Score* agregat 0.9872 dan AUC 0.9975 pada data uji. Nilai AUC yang mendekati 1.0 mengindikasikan bahwa model memiliki kemampuan diskriminasi yang sangat tinggi dalam memisahkan kelas Spam dan Non-Spam. Secara per kelas, model menunjukkan *Precision* yang lebih tinggi pada kelas Spam (0.9926) dibandingkan Non-Spam (0.9800), sementara *Recall* kelas Non-Spam (0.9920) sedikit lebih tinggi dibandingkan Spam (0.9818), yang mencerminkan kecenderungan model lebih konservatif dalam memprediksi kelas Spam.



Gambar 15. Confusion Matrix Best Single Fold

Berdasarkan *confusion matrix* pada Gambar 15, dari 250 sampel Non-Spam pada data uji, model berhasil mengklasifikasikan 248 sampel secara benar sebagai Non-Spam (*True Negatif*) dan hanya salah mengklasifikasikan 2 sampel sebagai Spam (*False Positif*). Sementara itu, dari 274 sampel Spam, model berhasil mengklasifikasikan 269 sampel secara benar sebagai Spam (*True Positif*) dan salah mengklasifikasikan 5 sampel

sebagai Non-Spam (*False Negatif*). Secara keseluruhan, model berhasil mengklasifikasikan 517 dari 524 sampel uji secara benar, dengan total kesalahan 7 sampel sekitar 1,34% dari keseluruhan data uji. Dominasi nilai TP dan TN yang tinggi pada diagonal utama *confusion matrix* secara visual mengkonfirmasi bahwa model memiliki kemampuan klasifikasi yang sangat baik pada kedua kelas secara seimbang.



Gambar 16. Kurva ROC Best Single Fold

Selain *confusion matrix*, evaluasi model juga divisualisasikan melalui kurva ROC (*Receiver Operating Characteristic*) pada Gambar 16. Kurva ROC menggambarkan hubungan antara *True Positif Rate* (TPR) dan *False Positif Rate* (FPR) pada berbagai nilai ambang batas (*Threshold*) keputusan. Model *Best Single Fold* menghasilkan nilai AUC sebesar 0,9975, yang mengindikasikan bahwa model memiliki kemampuan diskriminasi yang sangat tinggi dalam memisahkan kelas Spam dan Non-Spam. Kurva ROC yang terbentuk mendekati sudut kiri atas grafik dengan kenaikan yang sangat tajam sejak nilai FPR mendekati nol, menunjukkan bahwa model mampu mencapai TPR yang sangat tinggi bahkan pada Tingkat FPR yang sangat rendah. Nilai AUC sebesar 0,9975 juga mengkonfirmasi bahwa kemampuan klasifikasi model tidak bergantung pada pemilihan nilai *threshold* tertentu, melainkan secara konsisten unggul di seluruh rentang *threshold* yang mungkin.

Meskipun demikian, model tidak terlepas dari kesalahan prediksi, berdasarkan *confusion matrix*, model menghasilkan total 7 kesalahan prediksi yang terdiri dari 2 *False Positif* dan 5 *False Negatif*. Ringkasan kesalahan prediksi disajikan pada Tabel 15. Contoh teks pesan pada masing-masing sampel yang salah diklasifikasikan dapat dilihat secara lengkap pada Lampiran 4.

Tabel 15. Kesalahan Prediksi Model Best Single Fold

Indeks	Label Aktual	Hasil Prediksi	Jenis Kesalahan	Karakteristik Penyebab
28	Non-Spam (0)	Spam (1)	False Positif	Newsletter teknis dengan kepadatan URL tinggi dan frasa promosi berlangganan
105	Non-Spam (0)	Spam (1)	False Positif	Buletin Industri keuangan dengan promosi konferensi dan tautan berulang
150	Spam (1)	Non-Spam (0)	False Negatif	Notifikasi teknis bounce message yang sangat singkat dan minim fitur promosi
236	Spam (1)	Non-Spam (0)	False Negatif	Undangan pelatihan profesional dengan bahasa formal dan terminologi keuangan
255	Spam (1)	Non-Spam (0)	False Negatif	Call for papers konferensi akademik dengan format ilmiah formal
275	Spam (1)	Non-Spam (0)	False Negatif	Pesan sangat pendek dengan karakter acak dan URL terobfuskasi
352	Spam (1)	Non-Spam (0)	False Negatif	Promosi saham pump-and-dump berformat laporan bisnis formal

Analisis terhadap pola kesalahan menunjukkan bahwa kedua kasus *False Positif* terjadi akibat kemiripan struktural antara *newsletter legitim* dengan Spam, di mana kepadatan tautan URL, frasa promosi, dan format email massal secara konsisten diasosiasikan model sebagai sinyal Spam. Sementara itu, kelima kasus *False Negatif* mencerminkan strategi penyamaran Spam yang beragam, mulai dari pesan teknis yang sangat singkat dan minim fitur semantik, undangan formal bernuansa edukatif, professional. Secara keseluruhan, kesalahan-kesalahan ini bukan merupakan indikasi kelemahan mendasar model, melainkan mencerminkan ambiguitas linguistik yang inheren pada sampel-sampel tepi (*edge cases*) yang batas semantiknya tidak dapat dipisahkan secara tegas oleh model berbasis representasi teks.

3.2.2 Evaluasi Soft Voting Ensemble


Bagian ini menyajikan hasil evaluasi model IndoBERT pada pendekatan *Soft Voting Ensemble*, yakni mekanisme agregasi prediksi probabilitas dari kelima lipatan secara bersamaan. Evaluasi dilakukan pada data uji yang sama dengan pendekatan sebelumnya sehingga hasil kedua pendekatan dapat dibandingkan secara langsung. Pada mekanisme ini, probabilitas prediksi dari masing-masing fold diagregasi dengan cara dirata-ratakan, kemudian keputusan akhir ditentukan berdasarkan nilai probabilitas agregat tertinggi. Hasil evaluasi kuantitatif model pada data uji disajikan pada Tabel 16 berikut.

Tabel 16. Hasil Evaluasi Model Soft Voting Ensemble pada Data Uji

Kelas	Precision	Recall	F1-Score	Support
Non-Spam (0)	0,9720	0,9880	0,9800	250
Spam (1)	0,9889	0,9745	0,9816	274
Rata-rata (Macro)	0,9805	0,9813	0,9808	524
Rata-rata (Weighted)	0,9810	0,9809	0,9809	524


Accuracy	0,9809	524
AUC	0,9979	

Model *Soft Voting Ensemble* mencatatkan *Accuracy* sebesar 0,9809 dengan *F1-Score* agregat 0,9816 dan AUC 0,9979 pada data uji. Menariknya, meskipun *Accuracy* dan *F1-Score* *Soft Voting* lebih rendah dibandingkan *Best Single Fold*, nilai AUC-nya justru sedikit lebih tinggi. Secara per kelas, *Precision* kelas Spam (0,9889) tetap lebih tinggi dibandingkan Non-Spam (0,9720), sementara *Recall* kelas Non-Spam (0,9880) lebih tinggi dibandingkan Spam (0,9745), pola yang konsisten dengan pendekatan *Best Single Fold*.



Gambar 17. Confusion Matrix Soft Voting Ensemble

Berdasarkan *confusion matrix* pada Gambar 17, dari 250 sampel Non-Spam pada data uji, model berhasil mengklasifikasikan 247 sampel secara benar sebagai Non-Spam (*True negatif*) dan salah mengklasifikasikan 3 sampel sebagai Spam (*False Positif*). Sementara itu, dari 274 sampel Spam, model berhasil mengklasifikasikan 267 sampel secara benar sebagai Spam (*True Positif*) dan salah mengklasifikasikan 7 sampel sebagai Non-Spam (*False Negatif*). Secara keseluruhan, model berhasil mengklasifikasikan 514 dari 524 sampel uji secara benar, dengan total kesalahan 10 sampel sekitar 1,91% dari keseluruhan data uji. Meskipun jumlah kesalahan sedikit lebih tinggi dibandingkan *Best Single Fold*, diagonal utama *confusion matrix* tetap didominasi oleh nilai TP dan TN yang tinggi, mengindikasikan bahwa model *Soft Voting Ensemble* masih mempertahankan kemampuan klasifikasi yang sangat baik pada kedua kelas.



Gambar 18. Kurva ROC Soft Voting Ensemble

Selain *confusion matrix*, evaluasi model juga divisualisasikan melalui kurva ROC pada Gambar 18. Model *Soft Voting Ensemble* menghasilkan nilai AUC sebesar 0,9979, yang sedikit lebih tinggi dibandingkan *Best Single Fold* (0,9975). Kurva ROC yang terbentuk memiliki karakteristik serupa, yakni mendekati sudut kiri atas grafik dengan kenaikan yang sangat tajam, mengindikasikan kemampuan diskriminasi yang sangat baik pada seluruh rentang *threshold*. Peningkatan AUC pada *Soft Voting* ini menunjukkan bahwa agregasi probabilitas dari kelima lipatan menghasilkan estimasi probabilitas yang lebih terkalibrasi secara keseluruhan, meskipun pada titik keputusan biner dengan *threshold* default 0,5 justru menghasilkan lebih banyak kesalahan klasifikasi dibandingkan *Best Single Fold*. Fenomena ini mengindikasikan bahwa *Soft Voting Ensemble* berpotensi menghasilkan performa klasifikasi yang lebih optimal apabila nilai *threshold* dioptimasi lebih lanjut, misalnya melalui analisis kurva *Precision-Recall* atau metode kalibrasi probabilitas.

Meskipun demikian, model tidak terlepas dari kesalahan prediksi, berdasarkan *confusion matrix*, model menghasilkan total 10 kesalahan prediksi yang terdiri dari 3 *False Positif* dan 7 *False Negatif*. Ringkasan kesalahan prediksi disajikan pada Tabel 17. Contoh teks pesan pada masing-masing sampel yang salah diklasifikasikan dapat dilihat secara lengkap pada Lampiran 4.

Tabel 17. Kesalahan Prediksi Model Soft Voting Ensemble

Indeks	Label Aktual	Hasil Prediksi	Jenis Kesalahan	Karakteristik Penyebab
28	Non-Spam (0)	Spam (1)	False Positif	Newsletter teknis dengan kepadatan URL tinggi dan frasa promosi berlangganan
105	Non-Spam (0)	Spam (1)	False Positif	Buletin Industri keuangan dengan promosi konferensi dan tautan berulang
388	Non-Spam (0)	Spam (1)	False Positif	Newsletter ulasan produk teknologi dengan sponsor iklan dan tautan eksternal
150	Spam (1)	Non-Spam (0)	False Negatif	Notifikasi teknis bounce message yang sangat singkat dan minim fitur promosi
236	Spam (1)	Non-Spam (0)	False Negatif	Undangan pelatihan profesional dengan bahasa formal dan terminologi keuangan
255	Spam (1)	Non-Spam (0)	False Negatif	Call for papers konferensi akademik dengan format ilmiah formal
275	Spam (1)	Non-Spam (0)	False Negatif	Pesan sangat pendek dengan karakter acak dan URL terobfuskasi
299	Spam (1)	Non-Spam (0)	False Negatif	Pesan sangat pendek dan tidak koheren dengan fitur semantik yang sangat minim
352	Spam (1)	Non-Spam (0)	False Negatif	Promosi saham pump-and-dump berformat laporan bisnis formal
91	Spam (1)	Non-Spam (0)	False Negatif	Promosi saham dengan terminology mager dan akuisisi yang menyerupai komunikasi bisnis legitim


Analisis terhadap pola kesalahan menunjukkan bahwa tujuh dari sepuluh kesalahan merupakan kesalahan yang juga terjadi pada pendekatan *Best Single Fold*, mengindikasikan bahwa sampel-sampel tersebut memang merupakan *edge cases* yang secara inheren sulit diklasifikasikan. Tiga kesalahan tambahan yang bersifat eksklusif pada *Soft Voting*, yakni Indeks 388 (FP), 91 (FN), dan 299 (FN), mengindikasikan bahwa mekanisme agregasi probabilitas lintas lipatan pada kasus tertentu justru mengakumulasi bias prediksi yang serupa di antara lipatan-lipatan penyusunnya, sehingga keyakinan kolektif model mengarah pada keputusan yang keliru. Fenomena ini menjelaskan mengapa *Soft Voting Ensemble* pada penelitian ini tidak menghasilkan performa yang lebih unggul dibandingkan *Best Single Fold*, khususnya pada sampel-sampel dengan karakteristik linguistik yang ambigu dan berada di wilayah batas keputusan semantik kedua kelas.

3.3 Implementasi LIME pada Model

Pencapaian metrik kuantitatif yang tinggi serta identifikasi sampel kesalahan baru mampu membuktikan akurasi model secara statistik, namun belum bisa menjelaskan dasar penalaran internal model IndoBERT saat membedakan teks. Mengingat arsitektur *deep learning* berbasis jaringan saraf *Transformer* ini memiliki jutaan parameter

tersembunyi yang bersifat *blackbox*, maka diperlukan evaluasi tingkat lokal untuk memberikan transparansi ilmiah. Oleh karena itu, bagian ini mengimplementasikan teknik *Explainable Artificial Intelligence* (XAI) melalui metode *Local Interpretable Model-Agnostic Explanations* (LIME) guna membedah dan memvalidasi kontribusi fitur kata demi kata dari hasil prediksi model secara visual (*Instance-level interpretability*).


Metode LIME bekerja dengan melakukan perturbasi (pengacakan) terhadap token input teks, mengamati perubahan nilai probabilitas output model IndoBERT, lalu melatih sebuah *surrogate* model lokal berupa regresi linier sederhana untuk menghitung skor koefisien kontribusi dari masing-masing kata terhadap hasil keputusan final.



Gambar 19. Hasil Interpretasi LIME untuk Pesan Spam

Berdasarkan Gambar 19, ditampilkan hasil interpretasi visual LIME untuk sampel teks pesan yang berhasil diklasifikasikan secara mutlak oleh model IndoBERT sebagai kategori Spam. Model memberikan nilai probabilitas sebesar 1,00 terhadap kelas Spam dan 0,00 terhadap kelas Non-Spam. Melalui grafik bar kontribusi fitur, terlihat bahwa kata-kata seperti “gratis” (0,10), “pulsa” (0,07), “Anda” (0,07), “Juta” (0,06), “Mendapatkan” (0,06), “rupiah” (0,06), dan “hadiah” (0,05) memiliki skor koefisien positif dominan yang mengarah kuat ke sisi kanan.

Secara teoritis, pola kata-kata ini merepresentasikan teknik rekayasa sosial yang dirancang untuk menarik perhatian target melalui iming-iming finansial atau hadiah instan. Kemampuan model IndoBERT dalam menangkap sinyal-sinyal semantik ini membuktikan bahwa model tidak sekadar menghafal teks secara literal, melainkan berhasil mengenali karakteristik teks penipuan digital dalam korpus bahasa Indonesia secara kontekstual.



Gambar 20. Hasil Interpretasi LIME untuk Pesan Non-Spam

Sementara itu, Gambar 20 menampilkan hasil pengujian interpretasi LIME untuk sampel teks pesan normal yang diklasifikasikan kedalam kategori Non-Spam (Ham) dengan tingkat probabilitas sebesar 0,82. Berdasarkan visualisasi tersebut, kata “Minggu” (0,29), “kami” (0,12), “bisa” (0,10), “update” (0,08), dan “produktivitas” (0,07) mencatatkan skor kontribusi negatif yang menarik keputusan model ke arah zona kiri. Karakteristik kata-kata tersebut mencerminkan konteks pesan informatif atau pemberitahuan pembaruan sistem yang lazim dikirimkan oleh instansi resmi.


Menariknya, di dalam pesan ini terdapat beberapa kata seperti “memiliki” (0,15), “Anda” (0,15), “aplikasi” (0,14), “terbaru” (0,08), dan “yang” (0,05) yang memberikan nilai koefisien positif ke arah kelas spam karena sering muncul dalam korpus pesan pemasaran otomatis. Namun, karena akumulasi bobot negatif dari kata “Minggu” dan kata pendukung lainnya jauh lebih dominan, batas keputusan (*decision boundary*) model tetap terjaga secara konsisten untuk menetapkan pesan tersebut sebagai Non-Spam.

Berdasarkan kedua hasil pengujian tersebut, dapat disimpulkan bahwa model IndoBERT tidak hanya mampu memberikan hasil prediksi dengan tingkat akurasi tinggi, tetapi juga memiliki kepekaan kontekstual untuk mengidentifikasi kata-kata kunci yang menjadi dasar dalam proses pengambilan keputusan. Integrasi teknik *Explainable Artificial Intelligence* (XAI) melalui metode LIME ini telah berhasil memberikan transparansi, akuntabilitas, serta validasi linguistik yang logis terhadap model klasifikasi yang digunakan.

Hubungan antara hasil eksplanasi lokal LIME dengan perancangan sistem informasi ini terletak pada penyajian transparansi informasi bagi pengguna akhir (*end-user*). Skor kontribusi kata yang dihasilkan oleh model regresi linier lokal LIME tidak hanya berfungsi sebagai alat evaluasi internal bagi pengembang sistem, melainkan diintegrasikan ke dalam Interface dashboard *Streamlit* untuk memberikan edukasi literasi digital secara langsung. Dengan menampilkan *highlight* warna visual pada kata-kata yang memicu keputusan Spam, pengguna dapat secara mandiri mengidentifikasi karakteristik pesan penipuan siber. Rekonsiliasi antara keandalan matematis model IndoBERT dan transparansi visual LIME inilah yang menjadi pondasi utama dalam membangun sistem informasi deteksi spam yang tidak hanya memiliki tingkat akurasi tinggi, tetapi juga aman, interaktif, dan dapat dipercaya oleh masyarakat pengguna layanan digital.

3.4 Implementasi Model pada Dashboard

Model IndoBERT yang telah dilatih dan dievaluasi selanjutnya diimplementasikan ke dalam sebuah dashboard interaktif berbasis *Streamlit* yang mengintegrasikan model IndoBERT dan metode LIME secara terpadu. Dashboard ini bertujuan untuk memudahkan pengguna dalam mendeteksi pesan spam secara langsung melalui antarmuka yang sederhana dan mudah digunakan tanpa memerlukan pemahaman teknis mengenai cara kerja model. Secara keseluruhan, alur implementasi sistem terbagi menjadi tiga tahapan utama sebagaimana ditunjukkan pada Gambar 21, yaitu tahap pelatihan model di Google Colab, tahap penyimpanan *artifacts* model ke Hugging Face Hub, dan tahap implementasi pada aplikasi *Streamlit*.




Gambar 21. Pipeline Deployment Model ke Streamlit

Pada tahap pertama, seluruh proses pelatihan model dilakukan di Google Colab menggunakan akselerasi GPU. Proses dimulai dari pemuatan dataset CSV yang berisi 2.636 sampel, kemudian setelah tahap pra-pemrosesan termasuk penghapusan 16 data duplikat, jumlah data bersih yang digunakan adalah 2.620 sampel. Data tersebut diproses melalui tahapan *fine-tuning* model IndoBERT menggunakan skema *5-Fold Stratified Cross-Validation* dengan mekanisme *Early Stopping*, serta evaluasi dan pemilihan model terbaik berdasarkan hasil perbandingan antar fold. Fold 3 ditetapkan sebagai model terbaik dengan *F1-Score* 0,9955, *Accuracy* 0,9952, *Recall* sempurna 1,0000, dan *Validation Loss* terendah sebesar 0,0220. *Artifacts* yang dihasilkan dari *checkpoint Fold 3* terdiri dari empat file utama yaitu *model.safetensors* yang menyimpan

bobot model, *config.json* yang menyimpan konfigurasi arsitektur model, *tokenizer.json* yang menyimpan konfigurasi tokenizer beserta kosakata, serta *tokenizer_config.json* yang menyimpan parameter konfigurasi tambahan tokenizer.

Pada tahap selanjutnya, keempat *artifacts* tersebut diunggah ke repositori publik di Hugging Face Hub menggunakan fungsi *push_to_hub()*. Hugging Face Hub berfungsi sebagai platform penyimpanan model terpusat yang memungkinkan model diakses dari lingkungan manapun melalui koneksi internet. Pendekatan ini dipilih karena file *model.safetensors* berukuran 498 MB yang melebihi batas maksimum ukuran file pada platform GitHub sebesar 100 MB, sehingga penyimpanan di Hugging Face Hub menjadi solusi yang tepat untuk keperluan deployment.

Pada tahap terakhir, aplikasi *Streamlit* dijalankan melalui *entry point App.py* yang memuat model IndoBERT dan tokenizer secara otomatis dari Hugging Face Hub menggunakan fungsi *pipeline* dengan konfigurasi *text-classification* dan parameter *top_k=None*. Model dimuat menggunakan dekorator *@st.cache_resource* sehingga model hanya dimuat satu kali dan tetap tersimpan di memori selama sesi berlangsung. Ketika pengguna memasukkan teks pesan dan menekan tombol analisis, sistem memproses input melalui tokenisasi, inferensi model IndoBERT untuk menghasilkan probabilitas prediksi melalui fungsi *Softmax*, serta interpretasi LIME menggunakan *LimeTextExplainer* untuk menghasilkan skor kontribusi kata yang berpengaruh terhadap keputusan prediksi. Hasil prediksi beserta visualisasi LIME kemudian ditampilkan secara real-time pada dashboard.




Gambar 22. Tampilan Halaman Beranda

Tampilan antarmuka aplikasi pada kondisi awal disajikan pada Gambar 22. Antarmuka dirancang dengan tata letak tiga kolom yang terdiri dari kolom Input Pesan di sisi kiri yang menyediakan kolom teks untuk memasukkan pesan beserta tombol Analisis, kolom Hasil Prediksi di tengah yang menampilkan label prediksi, nilai *confidence*, dan visualisasi highlight LIME beserta legenda warna, serta kolom Skor Kata di sisi kanan yang menampilkan tabel kontribusi kata secara terurut. Pengguna cukup mengetikkan atau menempelkan teks pesan pada kolom yang tersedia, kemudian menekan tombol


Analisis untuk memperoleh seluruh hasil secara langsung dalam satu tampilan yang terintegrasi.

Pengujian fungsionalitas dashboard dilakukan menggunakan dua contoh pesan yang berbeda untuk memverifikasi bahwa seluruh komponen sistem berjalan dengan benar pada kedua kelas prediksi sebagaimana ditunjukkan pada Gambar 23 dan Gambar 24.



Gambar 23. Tampilan Halaman Beranda untuk Hasil Prediksi Spam

Pada skenario pertama, pesan “Selamat! Anda mendapatkan hadiah pulsa gratis 1 juta rupiah!” dimasukkan sebagai contoh pesan Spam. Sebagaimana ditunjukkan pada Gambar 23, dashboard menampilkan label prediksi Spam dengan nilai *confidence* 0,9995 yang ditandai dengan garis merah di sisi kiri kartu prediksi. Di bawah hasil prediksi, visualisasi LIME menampilkan teks input dengan sorotan warna pada setiap kata, di mana kata-kata seperti “gratis”, “pulsa”, dan “Anda” disorot dengan warna hijau yang menunjukkan kontribusi ke arah kelas Spam menurut model *surrogate* LIME, sementara kata “Selamat” disorot dengan warna merah menunjukkan kontribusi ke arah kelas Non-Spam. Di kolom kanan, tabel Skor Kata menampilkan nilai kontribusi setiap kata secara terurut dari yang tertinggi hingga terendah dengan pewarnaan yang konsisten dengan *highlight* teks.



Gambar 24. Tampilan Halaman Beranda untuk Hasil Prediksi Non-Spam

Pada skenario kedua, pesan “Halo! Minggu ini kami memiliki update terbaru mengenai fitur aplikasi yang bisa membantu produktivitas Anda.” Dimasukkan sebagai contoh pesan Non-Spam. Sebagaimana ditunjukkan pada Gambar 24, dashboard menampilkan label prediksi Non-Spam dengan nilai *confidence* 0,8216 yang ditandai dengan garis hijau di sisi kiri kartu prediksi. Visualisasi LIME menunjukkan kata-kata seperti “Anda”, “aplikasi”, “memiliki”, dan “terbaru” disorot dengan warna hijau sebagai kontributor ke arah kelas Spam, sementara kata kata seperti “Minggu”, “kami”, “Update”, dan “bisa” disorot dengan warna merah yang menunjukkan kontribusi ke arah kelas Non-Spam. Nilai *confidence* yang lebih rendah dibandingkan skenario pertama mencerminkan adanya ambiguitas linguistik pada pesan tersebut, namun kontribusi kata-kata Non-Spam tetap lebih dominan sehingga model menghasilkan prediksi yang sesuai.

Secara keseluruhan, implementasi antarmuka pada aplikasi *Streamlit* ini berhasil menyajikan sistem deteksi Spam yang fungsional, interaktif, dan mudah dioperasikan oleh pengguna akhir. Melalui integrasi pembagian tiga panel kerja yang dinamis serta konsisten komponen legenda warna dalam merespon hasil prediksi, aplikasi ini terbukti mampu mengubah luaran model *deep learning* yang rumit menjadi sajian visual yang sangat komunikatif melalui tautan <https://spamdetectorindobert.streamlit.app/>. Tata letak panel yang terstruktur serta fungsionalitas pemetaan warna ini tidak hanya memberikan hasil prediksi yang instan, tetapi juga memberikan edukasi literasi digital yang interaktif bagi pengguna dalam mengenali karakteristik kata kunci pendorong Spam maupun Non-Spam dari setiap pesan yang dianalisis.

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan hasil penelitian, eksperimen, analisis, serta implementasi sistem informasi deteksi Spam berbahasa Indonesia berbasis IndoBERT dengan metode LIME sebagai interpretabilitas keputusan model yang telah dipaparkan pada bab sebelumnya, maka dapat ditarik beberapa Kesimpulan sebagai berikut:

1. Model IndoBERT yang dilatih menggunakan skema *5-Fold Stratified Cross-Validation* dengan mekanisme *Early Stopping* berhasil menghasilkan kinerja klasifikasi yang sangat baik dan konsisten. Model terbaik diperoleh dari Fold 3 dengan *checkpoint* pada *epoch* kedua, mencatatkan *F1-Score* sebesar 0,9955, *Accuracy* 0,9952, *Validation Loss* terendah sebesar 0,0220, serta *Recall* sempurna sebesar 1,0000 pada fase validasi. Pada tahap evaluasi menggunakan 524 sampel data uji yang sepenuhnya terpisah dari proses pelatihan, model *Best Single Fold* mempertahankan kinerjanya dengan *Accuracy* sebesar 0,9866, *F1-Score* agregat 0,9872, dan AUC 0,9975, dengan total kesalahan prediksi hanya 7 sampel (1,34% dari data uji). Perbandingan dengan pendekatan *Soft Voting Ensemble* menunjukkan bahwa *Best Single Fold* menghasilkan kinerja yang lebih unggul secara keseluruhan, sehingga bobot jaringan dari fold 3 secara resmi ditetapkan sebagai model final.
2. Penerapan metode LIME (*Local Interpretable Model-Agnostic Explanations*) sebagai pendekatan *Explainable Artificial Intelligence* (XAI) berhasil memberikan penjelasan visual kontribusi kata demi kata terhadap keputusan prediksi model IndoBERT secara transparan dan mudah dipahami. Hasil interpretasi LIME membuktikan bahwa model memiliki kepekaan kontekstual yang tinggi dalam mengenali pola linguistik pesan Spam berbahasa Indonesia, di mana kata-kata seperti “gratis”, “pulsa”, dan “hadiah” teridentifikasi sebagai kontributor utama keputusan prediksi Spam. Melalui visualisasi grafik batang kontribusi dan pemetaan warna (*text highlighting*) pada tabel Skor Kata, LIME berhasil memberikan dasar penalaran linguistik yang logis, terukur, serta dapat divalidasi oleh pengguna, sehingga model IndoBERT yang bersifat *blackbox* menjadi lebih transparan dan dapat dipercaya.
3. Dashboard interaktif berbasis *Streamlit* yang mengintegrasikan model IndoBERT dan metode LIME secara terpadu berhasil dirancang, dikembangkan, dan di-*deploy* secara operasional pada platform *cloud public* yang dapat diakses melalui tautan resmi <https://spamdetectorindobert.streamlit.app/>. Integrasi sistem dari lingkungan pengembangan Google Colab menuju lingkungan produksi *Streamlit* berhasil dijemput secara efisien menggunakan repositori terpusat Hugging Face Hub melalui fungsi *push_to_hub()* dan *from_pretrained()*. Antarmuka satu halaman yang terbagi ke dalam tiga kolom terbukti fungsional dalam menyajikan label klasifikasi, nilai *confidence*, dan visualisasi kontribusi kata berbasis LIME secara *real-time*, sehingga

menghasilkan sistem yang tidak hanya memiliki akurasi matematis tinggi, tetapi juga interaktif, transparan, dan dapat dipercaya oleh pengguna layanan digital.

4.2 Saran

Berdasarkan hasil penelitian, eksperimen, serta keterbatasan teknis yang ditemukan selama proses pengembangan sistem dijalankan, terdapat beberapa saran strategis yang dapat diajukan untuk penelitian selanjutnya:

1. Pemanfaatan dataset yang lebih representative secara lokal. Dataset yang digunakan dalam penelitian ini sebagian besar merupakan hasil translasi linguistik dari korpus spam eksternal ke dalam bahasa Indonesia, sehingga karakteristik sosiologisnya belum sepenuhnya mencerminkan pola pesan penipuan siber yang sesungguhnya terjadi di Indonesia. Penelitian selanjutnya sangat disarankan untuk menghimpun data dari korpus pesan spam bahasa Indonesia asli yang dikoleksi langsung secara on-demand dari saluran SMS, aplikasi pesan instan, maupun medial social, agar model dapat mengidentifikasi struktur bahasa prokem, dialek lokal, dan modus operandi penipuan siber Indonesia secara lebih akurat.
2. Eksplorasi arsitektur model bahasa yang lebih baru dan besar. Penelitian ini terbatas pada penggunaan varian model indobert-base-p2 sebagai arsitektur dasar. Penelitian lanjutan dapat mengeksplorasi dan membandingkan performa model bahasa Indonesia yang memiliki kapasitas parameter lebih besar, seperti IndoBERT-large, atau memanfaatkan arsitektur rumpun *Transformer* modern lainnya guna menguji apakah penambahan parameter jaringan mampu menghasilkan batas keputusan semantik yang lebih kokoh dalam menangani klasifikasi teks.
3. Optimasi nilai ambang batas (*Threshold Tuning*). Hasil analisis pengujian membuktikan bahwa pendekatan *Soft Voting Ensemble* menghasilkan nilai AUC yang sedikit lebih tinggi (0,9979) dibandingkan *Best Single Fold* (0,9975), namun mencatatkan lebih banyak kesalahan pada parameter *threshold default* sebesar 0,5. Oleh karena itu, penelitian selanjutnya disarankan untuk menerapkan eksperimen optimasi nilai ambang batas keputusan melalui analisis kurva *Precision-Recall* atau metode kalibrasi probabilitas guna menemukan titik ekuilibrium yang lebih seimbang antara nilai *Precision* dan *Recall*.
4. Peningkatan aspek konsisten interpretabilitas model. Hasil interpretasi visual metode LIME secara inheren memiliki sifat non-deterministik karena mengandalkan proses perturbasi berbasis sampling acak, sehingga berpotensi memunculkan fluktuasi skor kontribusi kata antar eksekusi runtime meskipun telah diatasi lewat pembatasan parameter *random_state=42*. Penelitian berikutnya diharapkan dapat mengeksplorasi metode XAI lain yang memiliki landasan teori permainan yang lebih deterministic dan konsisten secara aksiomatis seperti SHAP (*Shapley Additive Explanations*), atau menggabungkan kedua metode tersebut untuk melahirkan interpretasi fitur yang lebih komprehensif.
5. Pengembangan fitur antarmuka dan skalabilitas dashboard. Desain aplikasi dashboard Streamlit yang dikembangkan saat ini masih terbatas pada skenario

analisis berbasis input teks manual per satu pesan. Penelitian selanjutnya disarankan untuk memperluas fungsionalitas rekayasa perangkat lunak aplikasi dengan menambahkan fitur pemrosesan data massal, sistem penyimpanan riwayat analisis, hingga integrasi *Application Programming Interface* (API) secara langsung ke platform aplikasi pengirim pesan agar produk sistem informasi yang dibuat memiliki skalabilitas pemanfaatan yang lebih luas.

6. Penanganan sampel kesalahan pada kasus tepi (*edge cases*). Melalui analisis kualitatif *error analysis*, model terbukti masih mengalami ambiguitas keputusan ketika dihadapkan pada sampel data uji yang memiliki struktur kemiripan tinggi antarkelas, seperti pesan spam promosi saham massal yang dikemas dalam format laporan bisnis formal atau undangan akademik massal legitim. Penelitian di masa depan disarankan untuk mengintegrasikan teknik augmentasi data khusus pada sampel-sampel tepi tersebut atau menerapkan metode *few-shot learning* guna memperkaya pemahaman model terhadap variasi pola penipuan non-konvensional.

DAFTAR PUSTAKA

- AbdulNabi, I., & Yaseen, Q. (2021). Spam Email Detection Using Deep Learning Techniques. *Procedia Computer Science*, 184, 853–858. <https://doi.org/10.1016/J.PROCS.2021.03.107>
- Agrawal, R., & Agrawal, R. (2025). Explainable AI in early autism detection: a literature review of interpretable machine learning approaches. *Discover Mental Health*, 5(1). <https://doi.org/10.1007/S44192-025-00232-3>
- Ahmed, S., Kaiser, M. S., Shahadat Hossain, M., & Andersson, K. (2025). A Comparative Analysis of LIME and SHAP Interpreters With Explainable ML-Based Diabetes Predictions. *IEEE Access*, 13, 37370–37388. <https://doi.org/10.1109/ACCESS.2024.3422319>
- Alzahrani, A. (2024). Explainable AI-based Framework for Efficient Detection of Spam from Text using an Enhanced Ensemble Technique. *Engineering, Technology & Applied Science Research*, 14(4), 15596–15601. <https://doi.org/10.48084/ETASR.7901>
- Apa itu Phishing? | IBM*. (n.d.). Retrieved April 19, 2026, from <https://www.ibm.com/id-id/think/topics/phishing>
- Arum, D. T., Nurchim, N., & Pradana, A. I. (2025). IMPLEMENTASI BIDIRECTIONAL ENCODER REPRESENTATIONS FROM TRANSFORMERS (BERT) UNTUK KLASIFIKASI SPAM PADA EMAIL. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 9(2), 2491–2496. <https://doi.org/10.36040/JATI.V9I2.13114>
- Asosiasi Penyelenggara Jasa Internet Indonesia - Survei*. (n.d.). Retrieved April 19, 2026, from <https://survei.apjii.or.id/>
- Basil Musyaffa Amin, M., Hakim, G., Taufik Maulana, M., Fajrul Alwan, M., Shafira Anggraheni, H., Jilan Naufal, M., Yudistira, N., Brawijaya, U., & Korespondensi, P. (2024). Deteksi Spam Berbahasa Indonesia Berbasis Teks Menggunakan Model Bert. *Jurnal Teknologi Informasi Dan Ilmu Komputer*, 11(6), 1291–1302. <https://doi.org/10.25126/JTIK.2024118121>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North*, 4171–4186. <https://doi.org/10.18653/V1/N19-1423>
- El Abdellaoui Alaoui, E. A., Filali, A., Sallah, A., Hajhouj, M., Hessane, A., & Merras, M. (2024). Towards Transparent Cybersecurity: The Role of Explainable AI in Mitigating Spam Threats. *Procedia Computer Science*, 236, 394–401. <https://doi.org/10.1016/J.PROCS.2024.05.046>
- Explainable Artificial Intelligence(XAI) - GeeksforGeeks*. (n.d.). Retrieved April 25, 2026, from <https://www.geeksforgeeks.org/artificial-intelligence/explainable-artificial-intelligencexai/>
- Guo, Y., Mustafaoglu, Z., & Koundal, D. (2023). Spam Detection Using Bidirectional Transformers and Machine Learning Classifier Algorithms. *Journal of Computational and Cognitive Engineering*, 2(1), 5–9. <https://doi.org/10.47852/BONVIEWJCCE2202192>
- Hafid, H. (2023). Penerapan K-Fold Cross Validation untuk Menganalisis Kinerja Algoritma K-Nearest Neighbor Pada Data Kasus Covid-19 di Indonesia. *Journal of*

- Mathematics Computations and Statistics*, 6(2), 161–168.
<https://doi.org/10.35580/JMATHCOS.V6I2.53043>
- K- Fold Cross Validation in Machine Learning - GeeksforGeeks. (n.d.). Retrieved April 25, 2026, from <https://www.geeksforgeeks.org/machine-learning/k-fold-cross-validation-in-machine-learning/>
- Nabiilah, G. Z., Alam, I. N., Purwanto, E. S., & Hidayat, M. F. (2024). Indonesian multilabel classification using IndoBERT embedding and MBERT classification. *International Journal of Electrical and Computer Engineering (IJECE)*, 14(1), 1071–1078.
<https://doi.org/10.11591/ijece.v14i1.pp1071-1078>
- Nugroho, A., & Amrullah, A. (2023). EVALUASI KINERJA ALGORITMA K-NN MENGGUNAKAN K-FOLD CROSS VALIDATION PADA DATA DEBITUR KSP GALIH MANUNGGAL. *Jurnal Informatika Teknologi Dan Sains (Jinteks)*, 5(2), 294–300. <https://doi.org/10.51401/JINTEKS.V5I2.2506>
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). “Why should i trust you?” Explaining the predictions of any classifier. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 13-17-August-2016*, 1135–1144. <https://doi.org/10.1145/2939672.2939778>
- Streamlit documentation*. (n.d.). Retrieved April 24, 2026, from <https://docs.streamlit.io/>
- Supono, R. A., & Imani, M. I. (2026). Implementasi Machine Learning untuk Klasifikasi Email Spam Menggunakan Indobert, Hugging Face Transformers dan Streamlit. *Jurnal Sosial Teknologi*, 6(1), 420–440.
<https://doi.org/10.59188/JURNALSOSTECH.V6I1.32659>
- Uddin, M. A., Islam, M. N., Maglaras, L., Janicke, H., & Sarker, I. H. (2025). ExplainableDetector: Exploring transformer-based language modeling approach for SMS spam detection with explainability analysis. *Digital Communications and Networks*, 11(5), 1504–1518. <https://doi.org/10.1016/J.DCAN.2025.07.008>
- Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*. 1. <https://arxiv.org/pdf/1706.03762>

LAMPIRAN

Lampiran 1. Source Code Dashboard Streamlit



https://github.com/nataliatw/SpamChat_BERTXAI.git

Lampiran 2. Source Code Fine-tuning Model IndoBERT



<https://colab.research.google.com/drive/1kU56rq2p-UACYu--lkOAwt4hPStrSg3?usp=sharing>

Lampiran 3. Source Code Evaluasi Model IndoBERT

https://colab.research.google.com/drive/1bdqDAsL_YmdgF1f4byFSNRo5Aogc3Wo4?usp=sharing

Lampiran 4. Data Kesalahan Prediksi Model IndoBERT

<https://colab.research.google.com/drive/1pwfJaTc5w4sUmgwde1VR7Ht0PaDalA9E?usp=sharing>