

PERBANDINGAN KINERJA *SENTENCE-BERT* DAN *UNIVERSAL SENTENCE ENCODER* UNTUK PENILAIAN KESESUAIAN CV DAN *JOB PROFILE* PADA SISTEM PENDUKUNG KEPUTUSAN HRD (STUDI KASUS: KALLA ASPAL)



**AL QADRI
H071221052**



**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN**

MAKASSAR

2026

PERBANDINGAN KINERJA *SENTENCE-BERT* DAN *UNIVERSAL SENTENCE ENCODER* UNTUK PENILAIAN KESESUAIAN CV DAN *JOB PROFILE* PADA SISTEM PENDUKUNG KEPUTUSAN HRD (STUDI KASUS: KALLA ASPAL)

**AL QADRI
H071221052**



**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

PERBANDINGAN KINERJA *SENTENCE-BERT* DAN *UNIVERSAL SENTENCE ENCODER* UNTUK PENILAIAN KESESUAIAN CV DAN *JOB PROFILE* PADA SISTEM PENDUKUNG KEPUTUSAN HRD (STUDI KASUS: KALLA ASPAL)

AL QADRI
H071221052

Skripsi

sebagai salah satu syarat untuk mencapai gelar sarjana
Program Studi Sistem Informasi

pada

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

SKRIPSI
**PERBANDINGAN KINERJA SENTENCE-BERT DAN UNIVERSAL
SENTENCE ENCODER UNTUK PENILAIAN KESESUAIAN CV DAN JOB
PROFILE PADA SISTEM PENDUKUNG KEPUTUSAN HRD (STUDI
KASUS: KALLA ASPAL)**


AL QADRI
H071221052

Skripsi,

Telah dipertahankan di depan Panitia Ujian Sarjana Sistem Informasi pada tanggal
27 Juli 2026 dan dinyatakan telah memenuhi syarat kelulusan pada


PROGRAM STUDI SISTEM INFORMASI
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR

Mengesahkan:
Pembimbing Tugas Akhir,


Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng.
NIP. 198805042019031012



Mengetahui:
Ketua Program Studi,


Prof. Drs. Jeffry Kusuma, Ph.D.
NIP. 196411121987031002

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi yang berjudul "*Perbandingan Kinerja Sentence-BERT Dan Universal Sentence Encoder Untuk Penilaian Kesesuaian CV Dan Job Profile Pada Sistem Pendukung Keputusan HRD (Studi Kasus: Kalla Aspal)*" adalah benar karya saya dengan arahan dari dosen pembimbing (Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng.). Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar, 27 Juli 2026



AL QADRI
H071221052

UCAPAN TERIMA KASIH

Puji dan syukur penulis ucapkan kepada Allah Subhanahu wata'ala atas segala rahmat dan pertolongan-Nya, sehingga skripsi yang berjudul "**Perbandingan Kinerja *Sentence-BERT* dan *Universal Sentence Encoder* untuk Penilaian Kesesuaian CV dan *Job Profile* pada Sistem Pendukung Keputusan HRD (Studi Kasus: Kalla Aspal)**" ini dapat diselesaikan dengan baik. Skripsi ini merupakan hasil perjuangan penulis selama menempuh pendidikan pada Program Studi Sistem Informasi, Departemen Matematika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Hasanuddin.

Penyelesaian skripsi ini tidak terlepas dari dukungan, doa, dan kasih sayang kedua orang tua, bapak **Ramli** dan ibu **Midya**, yang menjadi alasan penulis untuk terus berjuang dan tidak pernah menyerah. Kepada kakak-kakak tersayang, **Ardiansya** dan **Asraruddin**, serta keponakan-keponakan penulis, **Arsy** dan **Assya**, terima kasih telah menjadi penghibur di tengah lelahnya proses penyusunan skripsi ini.

Penulis juga menyadari bahwa keberhasilan penyusunan skripsi ini tidak terlepas dari bantuan dan dukungan berbagai pihak. Maka dari itu, dengan ketulusan hati, penulis mengucapkan terima kasih kepada:

1. Bapak **Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng.**, selaku Dosen Pembimbing, atas waktu, tenaga, dan pikiran yang telah diberikan dalam membimbing penulis menyelesaikan skripsi ini.
2. Bapak **Octavian, S.Si., M.Kom.**, dan Bapak **Jeriko Gormantara, S.Si., M.Si.**, selaku Dosen Penguji, atas kritik dan saran yang sangat membantu penulis memperbaiki kekurangan skripsi ini.
3. Bapak **Dr. Hendra, S.Si., M.Kom.**, selaku Dosen Penasehat Akademik (PA), atas bimbingan dan arahan selama penulis menjalani masa perkuliahan di Universitas Hasanuddin.
4. Seluruh **Dosen Program Studi Sistem Informasi** serta seluruh **Staf dan Pegawai Departemen Matematika**, atas ilmu, wawasan, dan bantuan administrasi selama masa perkuliahan.
5. Keluarga besar **Kalla Aspal** dan **KPPN Majene**, atas kesempatan magang serta pengalaman yang diperoleh penulis, khususnya Kalla Aspal yang juga menjadi penyedia data dalam penelitian skripsi ini.
6. **Yayasan Hadji Kalla**, atas beasiswa Kalla yang diberikan kepada penulis selama semester 1 hingga semester 8, yang sangat membantu penulis menyelesaikan pendidikan hingga jenjang sarjana ini.
7. Teman-teman **Rukont, Sekte Wacana, Desa Suruang, Rill2022, KKN113 Maritengngae**, dan **teman-teman seangkatan Sisfo 22**, atas kebersamaan, dukungan, dan tawa yang menjadi pelepas penat penulis selama menempuh perkuliahan hingga penyelesaian skripsi ini.

ABSTRAK

AL QADRI. **Perbandingan Kinerja *Sentence-BERT* dan *Universal Sentence Encoder* untuk Penilaian Kesesuaian CV dan *Job Profile* pada Sistem Pendukung Keputusan HRD (Studi Kasus: Kalla Aspal)** (dibimbing oleh Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng.).

Latar belakang. Proses *screening* CV secara manual pada perusahaan dengan volume pelamar tinggi cenderung memakan waktu dan rentan terhadap subjektivitas penilaian. Pendekatan *semantic similarity* berbasis *sentence embedding* menawarkan solusi otomatis yang mampu memahami makna kontekstual dokumen rekrutmen, tetapi dua model utama, yaitu *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE), belum pernah dibandingkan secara langsung pada domain pencocokan CV dan *Job Profile* dalam konteks perusahaan Indonesia. **Tujuan.** Penelitian ini bertujuan membandingkan kinerja SBERT dan USE berdasarkan nilai *Cosine similarity*, waktu komputasi, dan enam metrik *Information Retrieval* (MRR, ARHR@5, nDCG@5, *Precision@5*, *Recall@5*, *F1@5*), serta mengimplementasikan model terbaik ke dalam Sistem Pendukung Keputusan rekrutmen berbasis *website*. **Metode.** *Dataset* terdiri atas 851 dokumen CV dan 26 *Job Profile* dari Kalla Aspal. Teks CV diekstraksi menggunakan *PyMuPDF*, kemudian dikelompokkan ke dalam tiga komponen penilaian, yaitu pendidikan (10%), pengalaman (40%), dan kemampuan (50%). Evaluasi dilakukan terhadap 95 dokumen *Ground truth* yang ditetapkan tim HRD. **Hasil.** SBERT mengungguli USE pada seluruh enam metrik, dengan nilai MRR 62.25%, nDCG@5 69.48%, dan *Recall@5* 93.68%, serta unggul pula dalam kecepatan komputasi. Model SBERT varian *all-MiniLM-L6-v2* diimplementasikan ke dalam SPK berbasis *Streamlit*, dan pengujian *Black-Box* terhadap 17 skenario fungsional menunjukkan seluruh fitur berjalan tanpa kegagalan. **Kesimpulan.** SBERT memberikan kinerja terbaik pada seluruh aspek yang diukur dan mampu mendukung proses *screening* CV secara lebih cepat, objektif, dan efisien dibandingkan metode manual.

Kata kunci: *Cosine similarity*, *sentence embedding*, *siamese network*, pencocokan semantik, seleksi kandidat, pengambilan informasi

ABSTRACT

AL QADRI. **Performance Comparison of Sentence-BERT and Universal Sentence Encoder for Assessing CV and Job Profile Suitability in an HRD Decision Support System (Case Study: Kalla Aspal)** (supervised by Dr. Eng Supri Bin Hj Amir, S.Si., M.Eng.).

Background. Manual CV screening in companies with a high volume of applicants tends to be time-consuming and prone to subjective judgment. A semantic similarity approach based on sentence embedding offers an automated solution capable of capturing the contextual meaning of recruitment documents, yet the two leading models, Sentence-BERT (SBERT) and Universal Sentence Encoder (USE), have never been directly compared in the domain of CV and Job Profile matching within an Indonesian corporate context. **Objective.** This study aims to compare the performance of SBERT and USE based on Cosine similarity scores, computation time, and six Information Retrieval metrics (MRR, ARHR@5, nDCG@5, Precision@5, Recall@5, F1@5), and to implement the best-performing model into a website-based recruitment Decision Support System. **Methods.** The Dataset consisted of 851 CV documents and 26 Job Profiles from Kalla Aspal. CV text was extracted using PyMuPDF and then grouped into three assessment components: education (10%), experience (40%), and skills (50%). Evaluation was conducted on 95 Ground truth documents determined by the HR team. **Results.** SBERT outperformed USE across all six metrics, achieving an MRR of 62.25%, nDCG@5 of 69.48%, and Recall@5 of 93.68%, and was also faster in computation time. The SBERT variant all-MiniLM-L6-v2 was implemented into a Streamlit-based Decision Support System, and Black-Box testing on 17 functional scenarios showed that all features ran without failure. **Conclusion.** SBERT delivered the best performance across all evaluated aspects and is able to support the CV screening process in a faster, more objective, and more efficient manner than manual methods.

Keywords: Cosine similarity, sentence embedding, siamese network, semantic matching, candidate selection, Information Retrieval

DAFTAR ISI

	Halaman
HALAMAN JUDUL	i
HALAMAN PENGANTAR	ii
HALAMAN PENGESAHAN	iii
PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA	iv
UCAPAN TERIMA KASIH	v
ABSTRAK	vi
ABSTRACT	vii
DAFTAR ISI	viii
DAFTAR TABEL	x
DAFTAR GAMBAR	xi
DAFTAR LAMPIRAN	xii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah	3
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	4
1.6 Landasan Teori	4
1.6.1 Rekrutmen dan <i>Screening Curriculum Vitae</i> (CV)	4
1.6.2 Sistem Pendukung Keputusan (SPK)	5
1.6.3 PyMuPDF untuk Ekstraksi Dokumen PDF	5
1.6.4 <i>Transformer</i> dan <i>Sentence embedding</i>	6
1.6.5 <i>Sentence-BERT</i> (SBERT)	8
1.6.6 <i>Universal Sentence Encoder</i> (USE)	9
1.6.7 <i>Cosine similarity</i>	11
1.6.8 Evaluasi Kinerja Model	12
1.6.9 Rancangan Sistem Penilaian Multi-Kriteria	15
1.6.10 Pengembangan Sistem Berbasis <i>Website</i> (Streamlit)	15
1.7 Tinjauan Penelitian Terkait	16
BAB II METODE PENELITIAN	20
2.1 Waktu dan Tempat Penelitian	20
2.2 Instrumen Penelitian	20
2.2.1 Perangkat Keras (<i>Hardware</i>)	20
2.2.2 Perangkat Lunak (<i>Software</i>)	21
2.3 Alur Penelitian	22
2.4 Sumber dan Data Penelitian	22
2.5 Tahapan Pra-pemrosesan Data	25
2.5.1 Ekstraksi Informasi <i>Curriculum Vitae</i> (CV)	26
2.5.2 Pengolahan Data <i>Job Profile</i>	27
2.5.3 Pembentukan Representasi Teks	28

2.6	Tahap Perbandingan dan Evaluasi Model.....	30
2.7	Tahap Implementasi Model dan Perancangan Sistem	32
2.7.1	Implementasi Model Terbaik	33
2.7.2	Tampilan Halaman Awal <i>Dashboard</i>	34
2.7.3	Tampilan Halaman <i>Single CV</i>	34
2.7.4	Tampilan Halaman <i>Leaderboard</i> Mode <i>Single CV</i>	35
2.7.5	Tampilan Halaman <i>Leaderboard</i> Mode <i>Bulk CV</i>	36
2.7.6	Tampilan Halaman <i>Bulk CV</i> Mode Otomatis	36
2.7.7	Tampilan Halaman <i>Bulk CV</i> Mode Manual	37
2.8	Tahap Pengujian Sistem	38
2.8.1	Skenario Pengujian Halaman Beranda.....	39
2.8.2	Skenario Pengujian Halaman <i>Single CV</i>	39
2.8.3	Skenario Pengujian Halaman <i>Leaderboard</i>	39
2.8.4	Skenario Pengujian Halaman <i>Bulk CV</i>	39
BAB III	HASIL DAN PEMBAHASAN	40
3.1	Hasil Pra-pemrosesan Data	40
3.1.1	Hasil Ekstraksi Informasi <i>Curriculum Vitae</i> (CV)	40
3.1.2	Hasil Pengolahan Data <i>Job Profile</i>	42
3.1.3	Hasil Pembentukan Representasi Teks	44
3.2	Hasil Perbandingan dan Evaluasi Model	45
3.2.1	Hasil Perhitungan <i>Cosine similarity</i> dan Skor Kecocokan	46
3.2.2	Hasil Pengukuran Waktu Proses Komputasi	47
3.2.3	Hasil Evaluasi Metrik <i>Information Retrieval</i>	48
3.2.4	Evaluasi pada <i>Dataset</i> Penuh (851 CV)	51
3.2.5	Pembahasan Evaluasi dan Penentuan Model Terbaik	54
3.3	Hasil Implementasi Model dan Pengujian Sistem	55
3.3.1	Hasil Implementasi Sistem	55
3.3.2	Hasil Pengujian Sistem (<i>Black-Box Testing</i>)	59
BAB IV	PENUTUP	62
4.1	Kesimpulan	62
4.2	Saran	62
DAFTAR PUSTAKA		64
LAMPIRAN		67

DAFTAR TABEL

Nomor Urut	Halaman
Tabel 1. Perbandingan Karakteristik Teknis SBERT dan USE	10
Tabel 2. Ringkasan Penelitian Terkait.....	17
Tabel 3. Waktu Penelitian	20
Tabel 4. Perangkat Keras (<i>Hardware</i>)	20
Tabel 5. Perangkat Lunak (<i>Software</i>)	21
Tabel 6. Distribusi Dokumen CV Berdasarkan Posisi Jabatan	23
Tabel 7. Pemetaan Informasi CV ke Komponen Penilaian	26
Tabel 8. Struktur Atribut Dataset <i>Job Profile</i>	28
Tabel 9. Pemetaan Informasi <i>Job Profile</i> ke Komponen Penilaian	28
Tabel 10. Contoh Hasil Pembentukan Komponen Kombinasi Teks	29
Tabel 11. Hasil Ekstraksi Informasi CV Kandidat.....	41
Tabel 12. Hasil Pengolahan Data <i>Job Profile</i>	42
Tabel 13. Hasil Pasangan Komponen Teks Hasil Pra-pemrosesan Akhir	44
Tabel 14. Perbandingan Rata-Rata Skor Kecocokan (<i>Avg True Score</i>)	47
Tabel 15. Perbandingan Waktu Proses Komputasi SBERT dan USE.....	47
Tabel 16. Hasil Evaluasi Metrik <i>Information Retrieval</i> pada Dataset Penuh	51
Tabel 17. Perbandingan SBERT dan USE untuk <i>Ground truth</i> dan Seluruh CV.....	52
Tabel 18. Rangkuman Perbandingan Kinerja SBERT dan USE	54
Tabel 19. Hasil Pengujian Halaman Beranda	59
Tabel 20. Hasil Pengujian Halaman <i>Single CV</i>	60
Tabel 21. Hasil Pengujian Halaman <i>Leaderboard</i>	60
Tabel 22. Hasil Pengujian Halaman <i>Bulk CV</i>	61

DAFTAR GAMBAR

Nomor Urut	Halaman
Gambar 1. Arsitektur <i>Transformer</i>	7
Gambar 2. Arsitektur <i>Sentence-BERT</i>	9
Gambar 3. Arsitektur <i>Universal Sentence Encoder</i>	10
Gambar 4. Diagram Alur Tahapan Metode Penelitian.....	22
Gambar 5. Contoh Sampel Dokumen <i>Curriculum Vitae</i> (CV).....	24
Gambar 6. Contoh Sampel Dokumen <i>Job Profile</i> Resmi Kalla Aspal.....	25
Gambar 7. Alur Sistem Penilaian Kesesuaian CV dan <i>Job Profile</i>	32
Gambar 8. Alur Pemilihan Model Terbaik Berdasarkan Hasil Evaluasi.....	33
Gambar 9. Rancangan Halaman Beranda <i>Dashboard</i> SPK.....	34
Gambar 10. Rancangan Halaman <i>Single CV</i>	34
Gambar 11. Rancangan Halaman Peringkat (<i>Leaderboard</i>) Mode <i>Single CV</i>	35
Gambar 12. Rancangan Halaman Peringkat (<i>Leaderboard</i>) Mode <i>Bulk CV</i>	36
Gambar 13. Rancangan Halaman <i>Bulk CV</i> (Mode Otomatis)	37
Gambar 14. Rancangan Halaman <i>Bulk CV</i> (Mode Manual).....	38
Gambar 15. Proses Perhitungan Skor Kecocokan Akhir	46
Gambar 16. Perbandingan Metrik <i>Information Retrieval</i> pada Data <i>Ground truth</i> ..	48
Gambar 17. Sebaran Peringkat Kandidat <i>Ground truth</i>	50
Gambar 18. Distribusi Kandidat <i>Ground truth</i> dalam <i>Top-5</i> Rekomendasi.....	50
Gambar 19. Tampilan Halaman Beranda	55
Gambar 20. Tampilan Halaman <i>Single CV</i>	56
Gambar 21. Tampilan Halaman <i>Leaderboard</i> Mode <i>Single CV</i>	57
Gambar 22. Tampilan Halaman <i>Leaderboard</i> Mode <i>Bulk CV</i>	57
Gambar 23. Tampilan Halaman <i>Bulk CV</i> Mode Otomatis.....	58
Gambar 24. Tampilan Halaman <i>Bulk CV</i> Mode Manual	59

DAFTAR LAMPIRAN

Nomor Urut	Halaman
Lampiran 1. Dokumentasi.....	67
Lampiran 2. <i>Dashboard</i> Streamlit	67
Lampiran 3. <i>Source Code</i> Perbandingan Model	67

BAB I PENDAHULUAN

1.1 Latar Belakang

Proses rekrutmen karyawan merupakan tahapan krusial dalam manajemen sumber daya manusia untuk memperoleh kandidat yang sesuai dengan kebutuhan perusahaan. Umumnya, *Curriculum Vitae* (CV) menjadi dokumen utama bagi *Human Resource Department* (HRD) dalam menilai kualifikasi pelamar kerja, karena berperan sebagai penilaian awal terhadap potensi dan kemampuan pelamar (Anggraini et al., 2021). Perkembangan platform pencarian kerja digital telah mengubah proses rekrutmen secara signifikan, sehingga perusahaan mampu menjangkau pelamar dalam skala yang lebih luas (Hidayah et al., 2026). Penggunaan teknologi seperti sistem pelacakan pelamar, kecerdasan buatan, dan platform digital juga terbukti mampu menghemat waktu dan mengurangi biaya proses rekrutmen secara keseluruhan (Susanto & Hamzali, 2024). Namun, peningkatan volume pelamar yang dihasilkan dari perluasan jangkauan ini tetap membebani tahap *screening* CV, terutama apabila proses penilaian masih dilakukan secara manual, sehingga menjadi kurang efisien dan rentan subjektivitas, bahkan berisiko mengabaikan kandidat potensial atau meloloskan kandidat yang kurang sesuai (Firmansyah, 2025). Oleh karena itu, diperlukan sistem otomatis berbasis teknologi yang mampu menganalisis dokumen kandidat secara lebih cepat dan konsisten.

Untuk mengatasi permasalahan tersebut, berbagai penelitian telah mengembangkan Sistem Pendukung Keputusan (SPK) pada proses rekrutmen. (Kusumo & Rakasiwi, 2020) membuktikan bahwa SPK dapat membantu perusahaan menentukan kandidat terbaik secara lebih efektif, sementara (Satrio & Suryadi, 2020) menunjukkan bahwa otomatisasi pencocokan profil mampu meningkatkan objektivitas penilaian. Meskipun demikian, sebagian besar sistem yang ada masih berbasis *rule-based* atau *keyword matching* konvensional, sehingga belum mampu memahami konteks dan makna semantik dari CV maupun *Job Profile* secara mendalam.

Perkembangan *Natural Language Processing* (NLP) memungkinkan pemahaman teks secara kontekstual melalui pendekatan *semantic similarity* berbasis *sentence embedding*, yaitu representasi teks dalam bentuk vektor numerik yang kemiripan maknanya diukur menggunakan *Cosine similarity* dan terbukti lebih baik menangkap kesamaan makna dibandingkan pencocokan kata secara harfiah. Dua model *sentence embedding* yang banyak digunakan adalah *Sentence-BERT* (SBERT) yang efisien untuk *semantic similarity* (Reimers & Gurevych, 2019), dan *Universal Sentence Encoder* (USE) yang stabil menangkap hubungan semantik lintas tugas NLP (Cer et al., 2018). Perbedaan karakteristik ini menimbulkan kebutuhan untuk mengetahui model yang lebih sesuai untuk pencocokan CV dan *Job Profile*.

Beberapa penelitian terdahulu menunjukkan bahwa *sentence embedding* juga terbukti memiliki performa lebih baik dibandingkan metode tradisional seperti TF-IDF: SBERT dan USE mengungguli teknik *embedding* lain seperti InferSent, ELMo, XLNet, dan Doc2Vec pada tugas *document ranking* berdasarkan MAP dan nDCG (Gupta et al., 2022), sementara di ranah rekrutmen, *semantic similarity* berbasis kecerdasan buatan terbukti mengatasi keterbatasan *keyword matching* dengan memahami konteks makna antar dokumen, menghasilkan pencocokan kandidat lebih akurat (Ajjam & Al-Raweshidy, 2025). Namun, penelitian terdahulu masih memiliki *gap*, umumnya hanya menggunakan satu model tunggal, belum fokus pada pencocokan CV dan *Job Profile*, serta minim evaluasi metrik *Information Retrieval* (IR) komprehensif, khususnya di konteks perusahaan Indonesia.

Dalam sistem rekomendasi kandidat, kualitas hasil pemeringkatan ditentukan oleh kemampuan sistem dalam menempatkan kandidat relevan pada urutan teratas. Oleh karena itu, penelitian ini mengevaluasi performa model menggunakan enam metrik *Information Retrieval*, yaitu *Mean Reciprocal Rank* (MRR), *Average Reciprocal Hit Rank* (ARHR@5), *Normalized Discounted Cumulative Gain* (nDCG@5), *Precision@5*, *Recall@5*, dan *F1@5*. Metrik ARHR, nDCG, *Precision*, *Recall*, dan *F1* dihitung pada batas *Top-5* untuk merepresentasikan kondisi nyata di perusahaan, di mana pada tahap *screening* awal administrasi tim HRD umumnya memprioritaskan sejumlah kecil kandidat dengan peringkat tertinggi sebelum melanjutkan ke tahapan berikutnya. Sejalan dengan pandangan (Jadon & Patil, 2024), penggunaan beberapa metrik evaluasi secara bersamaan diperlukan untuk memperoleh penilaian sistem yang lebih komprehensif.

Kebutuhan otomatisasi proses rekrutmen ini sangat relevan bagi Kalla Aspal, sebuah perusahaan distribusi aspal curah bagian dari Kalla Group dengan jaringan distribusi yang luas berdasarkan informasi pada *website* resmi Kalla Group. Berdasarkan observasi dan wawancara dengan tim HRD Kalla Aspal, proses *screening* awal pelamar masih dilakukan secara manual melalui peninjauan dokumen CV. Proses ini membutuhkan waktu relatif lama ketika jumlah pelamar meningkat serta berpotensi menimbulkan subjektivitas dalam penilaian.

Berdasarkan kesenjangan tersebut, penelitian ini mengusulkan perbandingan kinerja *Sentence-BERT* dan *Universal Sentence Encoder* untuk penilaian kesesuaian *Curriculum Vitae* (CV) dan *Job Profile* pada Sistem Pendukung Keputusan HRD dengan studi kasus di Kalla Aspal. Kebaruan penelitian ini diarahkan pada komparasi langsung arsitektur SBERT dan USE khusus untuk domain rekrutmen di Indonesia, yang kemudian dievaluasi menggunakan kombinasi enam metrik *Information Retrieval*, yaitu *Mean Reciprocal Rank* (MRR), *Average Reciprocal Hit Rank* (ARHR@5), *Normalized Discounted Cumulative Gain* (nDCG@5), *Precision@5*, *Recall@5*, dan *F1@5*, hingga akhirnya model terbaik diimplementasikan ke dalam prototipe SPK berbasis *website* menggunakan *framework* Streamlit untuk membantu tim HRD melakukan proses *screening* secara lebih efektif, efisien, dan objektif.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana perbandingan kinerja *Sentence-BERT* dan *Universal Sentence Encoder* berdasarkan nilai *Cosine similarity*, waktu proses komputasi, serta efektivitas pemeringkatan rekomendasi menggunakan metrik *Information Retrieval* (MRR, ARHR@5, nDCG@5, *Precision@5*, *Recall@5*, dan *F1@5*)?
2. Bagaimana implementasi model dengan performa terbaik ke dalam Sistem Pendukung Keputusan (SPK) berbasis *website* untuk proses penilaian kesesuaian CV dan *Job Profile* pada studi kasus Kalla Aspal?

1.3 Batasan Masalah

Agar penelitian tetap terfokus pada tujuan yang ingin dicapai, maka ditetapkan batasan masalah sebagai berikut:

1. Penelitian ini hanya menggunakan dua model *sentence embedding*, yaitu *Sentence-BERT* (all-MiniLM-L6-v2) dan *Universal Sentence Encoder* (v4 berbasis *Transformer*), tanpa dilakukan proses *fine-tuning* maupun pelatihan ulang (*retraining*) model.
2. Penilaian kesesuaian dilakukan menggunakan metode *Cosine similarity* untuk mengukur tingkat kemiripan teks berdasarkan representasi *embedding* dari masing-masing model.
3. Data yang digunakan berupa dokumen CV pelamar dalam format PDF dan data *Job Profile* resmi Kalla Aspal. Dokumen CV yang diproses merupakan CV berbahasa Indonesia maupun bahasa Inggris yang bersifat digital (berbasis teks, bukan hasil pemindaian/*scan*).
4. Aspek yang dianalisis dalam penilaian kesesuaian meliputi pendidikan, pengalaman, dan kemampuan kandidat. Proses penilaian menggunakan skema pembobotan tetap (*fixed weight*) berdasarkan tinjauan literatur dan hasil wawancara dengan tim HRD Kalla Aspal, dengan rincian 10% untuk pendidikan, 40% untuk pengalaman, dan 50% untuk kemampuan. Bobot ini bersifat tetap dan bukan hasil optimasi otomatis.
5. Evaluasi model difokuskan pada analisis nilai *Cosine similarity*, waktu proses komputasi, serta kualitas pemeringkatan rekomendasi menggunakan metrik *Information Retrieval*, yaitu *Mean Reciprocal Rank* (MRR), *Average Reciprocal Hit Rank* (ARHR@5), *Normalized Discounted Cumulative Gain* (nDCG@5), *Precision@5*, *Recall@5*, dan *F1@5*. Pada penelitian ini, metrik ARHR, nDCG, *Precision*, *Recall*, dan *F1* dievaluasi pada batas *Top-5* untuk menilai kualitas rekomendasi kandidat pada peringkat teratas.
6. Sistem diimplementasikan sebagai Sistem Pendukung Keputusan (SPK) berbasis *website* menggunakan *framework* Streamlit untuk membantu proses *screening* CV kandidat.

1.4 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dipaparkan, maka tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis perbandingan kinerja SBERT dan USE berdasarkan nilai *Cosine similarity*, waktu proses komputasi, dan kualitas pemeringkatan kandidat menggunakan metrik *Information Retrieval* (MRR, ARHR@5, nDCG@5, *Precision@5*, *Recall@5*, dan *F1@5*) guna menentukan model terbaik untuk diterapkan pada sistem rekrutmen.
2. Mengimplementasikan model dengan performa terbaik ke dalam Sistem Pendukung Keputusan (SPK) berbasis *website* untuk proses penilaian kesesuaian CV dan *Job Profile* pada studi kasus di Kalla Aspal.

1.5 Manfaat Penelitian

Hasil penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Memberikan kontribusi pada pengembangan penerapan *Natural Language Processing* (NLP), khususnya penggunaan *Sentence-BERT*, *Universal Sentence Encoder*, dan *Cosine similarity* dalam proses pencocokan dokumen CV dan *Job Profile*.
2. Mendukung proses rekrutmen yang lebih cepat, efisien, dan objektif melalui implementasi Sistem Pendukung Keputusan berbasis *website* untuk membantu proses *screening* kandidat.
3. Menjadi referensi dalam pengembangan dan evaluasi sistem rekrutmen berbasis kecerdasan buatan, khususnya dalam pemilihan model *sentence embedding* yang sesuai untuk pencocokan dokumen berbahasa Indonesia.

1.6 Landasan Teori

1.6.1 Rekrutmen dan *Screening Curriculum Vitae* (CV)

Rekrutmen merupakan salah satu proses penting dalam manajemen sumber daya manusia yang bertujuan untuk memperoleh kandidat yang sesuai dengan kebutuhan perusahaan. Menurut (Kartodikromo et al., 2017), rekrutmen adalah proses pencarian dan penarikan calon tenaga kerja yang memiliki kemampuan dan kualifikasi sesuai dengan kebutuhan organisasi. Proses rekrutmen yang baik dapat membantu perusahaan memperoleh karyawan yang kompeten serta meningkatkan efektivitas dan produktivitas kerja organisasi.

Dalam proses rekrutmen, *Curriculum Vitae* (CV) menjadi salah satu dokumen utama yang digunakan oleh tim HRD untuk melakukan penilaian awal terhadap pelamar kerja. CV memuat berbagai informasi penting seperti identitas, riwayat pendidikan, pengalaman, keterampilan, sertifikasi, dan kompetensi yang dimiliki kandidat. Menurut (Rikardo et al., 2026), CV merupakan sumber informasi utama dalam proses *screening* kandidat karena digunakan untuk mengevaluasi kesesuaian profil pelamar dengan kriteria pekerjaan yang dibutuhkan perusahaan.

Seiring meningkatnya jumlah pelamar kerja, proses *screening* CV secara manual menjadi kurang efisien karena membutuhkan waktu yang lama serta berpotensi menimbulkan subjektivitas dalam pengambilan keputusan. (Firmansyah, 2025) menjelaskan bahwa proses pemeriksaan CV secara manual memiliki keterbatasan dari sisi efisiensi dan akurasi, terutama ketika perusahaan harus menyeleksi banyak dokumen pelamar dalam waktu singkat. Oleh karena itu, diperlukan sistem otomatis yang mampu membantu tim HRD dalam melakukan proses *screening* secara lebih cepat, objektif, dan akurat melalui pemanfaatan teknologi NLP dan model *sentence embedding* untuk mengukur tingkat kesesuaian antara CV kandidat dan *Job Profile*.

1.6.2 Sistem Pendukung Keputusan (SPK)

Sistem Pendukung Keputusan (SPK) merupakan sistem berbasis komputer yang dirancang untuk membantu proses pengambilan keputusan dalam menyelesaikan permasalahan tidak terstruktur. Menurut (Setiaji, 2012), SPK didefinisikan sebagai sistem informasi berbasis komputer yang adaptif, interaktif, dan fleksibel yang secara khusus dikembangkan untuk mendukung solusi permasalahan manajemen yang tidak terstruktur guna meningkatkan kualitas pengambilan keputusan. SPK berfungsi sebagai alat bantu yang mampu meningkatkan efektivitas dan efisiensi proses pengambilan keputusan melalui pengolahan data secara sistematis sehingga keputusan yang dihasilkan dapat lebih objektif dan akurat.

Dalam bidang HRD, SPK dapat diterapkan pada proses rekrutmen dan seleksi kandidat karyawan. (Kusumo & Rakasiwi, 2020) menyatakan bahwa penerapan SPK pada proses rekrutmen dapat membantu perusahaan dalam melakukan seleksi kandidat secara lebih cepat dan efektif berdasarkan kriteria yang telah ditentukan. Dengan adanya SPK, proses penilaian kandidat tidak lagi bergantung sepenuhnya pada subjektivitas tim HRD, melainkan juga didukung oleh sistem yang mampu mengelola dan menganalisis data pelamar secara lebih sistematis.

Pada penelitian ini, SPK digunakan untuk membantu tim HRD dalam melakukan penilaian kesesuaian antara CV kandidat dan *Job Profile* perusahaan. Sistem memanfaatkan teknologi NLP dan model *sentence embedding* untuk mengukur tingkat kemiripan semantik antara isi CV dan kebutuhan pekerjaan, sehingga dapat memberikan rekomendasi kandidat yang memiliki tingkat kesesuaian tertinggi terhadap posisi pekerjaan yang tersedia.

1.6.3 PyMuPDF untuk Ekstraksi Dokumen PDF

PyMuPDF merupakan *library* Python yang digunakan untuk mengekstrak informasi teks dari dokumen PDF, termasuk konten teks dan posisinya pada setiap halaman dokumen (Raharjo et al., 2026). *Library* ini menyediakan akses terhadap konten tekstual yang tersimpan pada struktur internal dokumen sehingga proses ekstraksi dapat dilakukan secara cepat dengan tetap mempertahankan informasi yang terdapat pada dokumen asli. Selain itu, PyMuPDF mendukung pemrosesan

dokumen dalam jumlah besar sehingga sesuai digunakan pada penelitian yang melibatkan ratusan dokumen CV dan *Job Profile*.

(Adhikari & Agarwal, 2025) melakukan perbandingan terhadap sepuluh *library* ekstraksi PDF menggunakan *Dataset* DocLayNet yang mencakup enam kategori dokumen. Hasil penelitian menunjukkan bahwa PyMuPDF dan pypdfium2 secara umum mengungguli *library* lainnya dalam tugas ekstraksi teks, termasuk dibandingkan PyPDF, pdfminer.six, dan pdfplumber, meskipun seluruh *library* masih mengalami kesulitan pada dokumen bertipe ilmiah dan paten.

Temuan tersebut sejalan dengan studi *benchmark* yang dilakukan oleh (Subramanian, 2026), yang mengevaluasi tujuh *library* ekstraksi PDF pada *pipeline Retrieval-Augmented Generation* (RAG) menggunakan empat metrik komplementer. Hasil penelitian menunjukkan bahwa PyMuPDF termasuk dalam kelompok *library* berbasis aturan (*rule-based*) yang memiliki performa terbaik dalam hal kualitas hasil ekstraksi (*fidelity*) sekaligus kecepatan pemrosesan (*speed*), dan secara signifikan mengungguli *library* berbasis AI seperti Docling dan pymupdf4llm yang justru terbukti lebih lambat dengan hasil fidelitas lebih rendah. Berdasarkan hasil kedua penelitian tersebut, PyMuPDF dipilih sebagai metode ekstraksi teks pada penelitian ini karena mampu menghasilkan teks yang berkualitas dan efisien untuk diproses pada tahap berikutnya.

1.6.4 Transformer dan Sentence embedding

Transformer merupakan arsitektur *deep learning* yang diperkenalkan oleh (Vaswani et al., 2017) untuk meningkatkan kemampuan pemrosesan bahasa alami dalam memahami hubungan antar kata pada suatu teks. Berbeda dengan *Recurrent Neural Network* (RNN) dan *Long Short-Term Memory* (LSTM) yang memproses data secara berurutan, *Transformer* menggunakan mekanisme *self-attention* yang memungkinkan model memahami hubungan antar kata secara paralel. Kemampuan tersebut menjadikan *Transformer* sebagai arsitektur utama dalam perkembangan NLP modern dan menjadi dasar berbagai model seperti BERT, GPT, *Sentence-BERT*, dan *Universal Sentence Encoder*.


Mekanisme utama *Transformer* adalah *self-attention*, yang memungkinkan model menentukan tingkat hubungan antar kata berdasarkan konteks kalimat secara keseluruhan. Selain itu, *Transformer* menerapkan *multi-head attention* yang memungkinkan model mempelajari berbagai hubungan semantik secara bersamaan dari berbagai sudut pandang konteks. *Transformer* juga menggunakan *positional encoding* untuk memberikan informasi urutan kata pada teks, sehingga model tetap dapat memahami struktur kalimat meskipun proses dilakukan secara paralel (Vaswani et al., 2017).

Perkembangan *Transformer* mendorong lahirnya berbagai teknik representasi teks modern yang dikenal sebagai *embedding*. *Embedding* merupakan teknik yang digunakan untuk merepresentasikan teks ke dalam bentuk vektor numerik agar dapat diproses oleh komputer. Secara mendasar, (Mikolov et al., 2013) menunjukkan bahwa representasi ini memungkinkan model memahami hubungan makna antar kata berdasarkan posisi vektornya pada ruang semantik, di

mana kata yang bermakna serupa akan berada dalam posisi yang saling berdekatan. Konsep ruang semantik ini kemudian diadopsi dalam skala yang lebih luas pada *sentence embedding*, di mana representasi seluruh kalimat juga dipetakan ke dalam vektor-vektor yang saling berdekatan jika memiliki kedekatan makna.

Seiring perkembangan *Natural Language Processing* (NLP), teknik *embedding* tidak hanya diterapkan pada level kata, tetapi juga pada level kalimat melalui konsep *sentence embedding*. *Sentence embedding* merupakan teknik representasi kalimat menjadi vektor berdimensi tertentu yang mampu menangkap makna serta konteks suatu kalimat secara utuh. Teknik ini memungkinkan komputer memahami hubungan makna antar teks secara lebih kontekstual dibandingkan pendekatan tradisional berbasis *keyword matching*. Meskipun demikian, (Li et al., 2020) menemukan bahwa representasi *sentence embedding* yang diperoleh langsung dari model bahasa pra-latih seperti BERT tanpa penyesuaian lanjutan justru menghasilkan ruang vektor yang kurang optimal (*anisotropic*) untuk tugas *semantic similarity*, sehingga diperlukan model *sentence embedding* yang dirancang secara khusus agar representasi kalimat dapat dibandingkan secara efektif menggunakan *Cosine similarity*.

Perkembangan *Transformer* juga melahirkan BERT (*Bidirectional Encoder Representations from Transformers*), yaitu model yang menggunakan pendekatan *bidirectional encoder* untuk memahami konteks kata dari arah kiri dan kanan secara bersamaan. (Devlin et al., 2019) menunjukkan bahwa BERT mencapai *state-of-the-art* pada 11 tugas NLP dengan *GLUE score* mencapai 80.5%. Kemampuan memahami konteks dua arah tersebut menjadikan BERT sebagai dasar lahirnya model *sentence embedding* modern seperti SBERT dan USE. Adapun struktur dasar arsitektur *Transformer* dapat dilihat pada Gambar 1.



Gambar 1. Arsitektur *Transformer* (Vaswani et al., 2017)

1.6.5 Sentence-BERT (SBERT)


Sentence-BERT (SBERT) merupakan pengembangan dari arsitektur BERT yang dirancang untuk menghasilkan representasi kalimat dalam bentuk *sentence embedding* yang lebih efisien dan sesuai untuk tugas pengukuran kemiripan semantik. Model ini diperkenalkan untuk mengatasi keterbatasan BERT konvensional yang tidak efisien ketika digunakan untuk membandingkan pasangan kalimat dalam jumlah besar. (Reimers & Gurevych, 2019) menunjukkan bahwa SBERT mampu menghasilkan representasi kalimat berkualitas tinggi secara signifikan lebih efisien dibandingkan BERT konvensional, di mana setiap kalimat dipetakan ke dalam bentuk vektor berdimensi tetap (*fixed-size embedding*) yang dapat dibandingkan secara langsung menggunakan *Cosine similarity*.

SBERT menggunakan arsitektur *siamese network* dan *triplet network* yang memungkinkan dua atau lebih kalimat diproses secara paralel untuk menghasilkan representasi vektor. Hal ini membuat SBERT jauh lebih cepat dibandingkan pendekatan BERT *cross-encoder*, terutama ketika digunakan pada *Dataset* besar seperti kumpulan CV pelamar dan deskripsi pekerjaan. (Gupta et al., 2022) menunjukkan bahwa SBERT dan USE mengungguli teknik *sentence embedding* lainnya (*InferSent*, *ELMo*, *XLNet*, *Doc2Vec*) pada tugas *document ranking* berdasarkan metrik MAP dan nDCG, yang menunjukkan keunggulan model berbasis *Transformer* dalam menangkap makna semantik dokumen.

Dalam penelitian ini digunakan model *all-MiniLM-L6-v2* yang merupakan varian SBERT berbasis *MiniLM Transformer*. Model ini menghasilkan representasi teks dengan 384 dimensi *embedding*, sehingga lebih ringan namun tetap memiliki performa yang kompetitif dalam tugas *semantic similarity*. Arsitektur dasar dengan dimensi 384 ini berasal dari metode *deep self-attention distillation* yang dikembangkan oleh (Wang et al., 2020) di mana model BERT-base berukuran besar (12-layer, 768 hidden size) didistilasi menjadi *student model* yang lebih kecil. Pada eksperimen tersebut, *student model* 6-layer dengan 384 hidden size ini terbukti memperoleh *speedup* sebesar 5.3 kali dibandingkan BERT-base dengan tetap menghasilkan performa yang kompetitif. Arsitektur 6-layer/384-hidden inilah yang menjadi basis konfigurasi model *all-MiniLM-L6-v2* yang digunakan dalam penelitian ini. Pemilihan model ini didasarkan pada keseimbangan antara efisiensi komputasi dan kualitas representasi makna teks, yang sangat penting pada sistem SPK rekrutmen yang memproses banyak dokumen secara berulang.

Model *all-MiniLM-L6-v2* yang digunakan dalam penelitian ini dilatih menggunakan korpus berbahasa Inggris. Meskipun demikian, model-model berbasis arsitektur MiniLM yang sama telah berhasil dikembangkan menjadi versi multibahasa melalui teknik *knowledge distillation*, di mana representasi dari model monolingual berbahasa Inggris ditransfer ke berbagai bahasa lain tanpa memerlukan pelatihan ulang penuh pada data multibahasa (Reimers & Gurevych, 2020). Pendekatan ini menunjukkan bahwa arsitektur berbasis *Transformer* seperti SBERT memiliki kapabilitas transfer semantik lintas bahasa yang kuat, sehingga representasi yang dihasilkan oleh model *all-MiniLM-L6-v2* berpotensi tetap mampu menangkap kemiripan makna pada teks berbahasa Indonesia, meskipun model ini

tidak dilatih secara eksplisit pada data multibahasa. Hal ini menjadi salah satu pertimbangan dalam pemilihan model, dengan tetap memperhatikan bahwa potensi penurunan akurasi pada teks non-Inggris merupakan salah satu keterbatasan. Arsitektur *Sentence-BERT* yang digunakan dalam penelitian ini ditunjukkan pada Gambar 2.



Gambar 2. Arsitektur *Sentence-BERT* (Reimers & Gurevych, 2019)


1.6.6 Universal Sentence Encoder (USE)

Universal Sentence Encoder (USE) merupakan model *sentence embedding* yang dikembangkan oleh Google untuk menghasilkan representasi kalimat dalam bentuk vektor numerik yang dapat digunakan untuk mengukur kemiripan semantik antar teks. (Cer et al., 2018) menjelaskan bahwa USE dirancang untuk mendukung *transfer learning* pada berbagai tugas NLP, termasuk *semantic similarity* dan *text classification*.

USE memiliki dua arsitektur utama, yaitu *Deep Averaging Network* (DAN) dan *Transformer encoder*. Dalam penelitian ini digunakan USE berbasis *Transformer* karena lebih mampu menangkap hubungan kontekstual antar kata dibandingkan pendekatan *averaging* sederhana. Model ini menghasilkan representasi kalimat dengan 512 dimensi *embedding*, yang memberikan ruang representasi lebih luas dalam menangkap variasi makna teks dibandingkan pendekatan berbasis kata individual.

Pemilihan USE berbasis *Transformer* didasarkan pada keseimbangan antara akurasi representasi semantik dan efisiensi komputasi. Meskipun dimensi *embedding*-nya lebih besar dari SBERT (512 vs 384), USE tetap mampu memberikan hasil yang stabil pada berbagai jenis teks, termasuk dokumen formal seperti CV dan deskripsi pekerjaan, sehingga cocok digunakan pada sistem yang membutuhkan proses perbandingan dokumen dalam jumlah besar. USE v4 yang digunakan dalam penelitian ini pada dasarnya dilatih menggunakan korpus

berbahasa Inggris. Meskipun demikian, tim pengembang USE sendiri telah mengembangkan varian multilingual dari arsitektur USE yang mendukung pemrosesan lintas bahasa secara lebih luas. (Yang et al., 2020) menunjukkan bahwa pendekatan *Multilingual Universal Sentence Encoder* berbasis *Transformer* mampu menghasilkan representasi semantik yang kompetitif pada berbagai tugas *cross-lingual*, termasuk *semantic retrieval* dan *question answering* lintas bahasa, yang menunjukkan bahwa arsitektur *Transformer* pada keluarga model USE secara umum memiliki kapabilitas transfer semantik lintas bahasa yang baik. Kemampuan arsitektural ini menjadi salah satu pertimbangan bahwa representasi yang dihasilkan oleh USE v4 berpotensi tetap dapat menangkap kemiripan makna pada teks berbahasa Indonesia, meskipun model spesifik ini tidak dilatih secara eksplisit pada data multibahasa. Potensi penurunan akurasi pada teks non-Inggris ini menjadi salah satu keterbatasan penelitian. Arsitektur *Universal Sentence Encoder* yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.



Gambar 3. Arsitektur *Universal Sentence Encoder* (Cer et al., 2018)

Perbandingan karakteristik antara SBERT dan USE secara ringkas disajikan pada Tabel 1.

Tabel 1. Perbandingan Karakteristik Teknis SBERT dan USE

Aspek Karakteristik	<i>Sentence-BERT</i> (SBERT)	<i>Universal Sentence Encoder</i> (USE)
Arsitektur Utama	<i>Siamese/Triplet BERT Network</i>	<i>Transformer Encoder</i> / DAN
Dimensi <i>Embedding</i>	384 (all-MiniLM-L6-v2)	512 (v4, berbasis <i>Transformer</i>)

Aspek Karakteristik	Sentence-BERT (SBERT)	Universal Sentence Encoder (USE)
Kecepatan Inferensi	Sangat cepat, <i>batch processing</i> sangat efisien	Cepat, lebih ringan dari arsitektur BERT penuh
Keunggulan Utama	<i>Document ranking</i> , CV-to-job <i>matching</i> , <i>semantic search</i>	Stabilitas komputasi, <i>multi-tasking</i> , <i>real-time inference</i>
Model Spesifik Penelitian	all-MiniLM-L6-v2	universal-sentence-encoder v4

1.6.7 Cosine similarity

Cosine similarity merupakan metode pengukuran tingkat kemiripan antara dua dokumen teks berdasarkan sudut antar dua vektor dalam ruang multidimensi. Dalam representasi teks berbasis *vector space model*, setiap dokumen atau kalimat direpresentasikan dalam bentuk vektor numerik, sehingga tingkat kemiripan tidak dihitung berdasarkan kuantitas kata yang sama secara harfiah, melainkan berdasarkan arah dari vektor tersebut. Semakin kecil sudut antar dua vektor, maka semakin tinggi tingkat kemiripan semantik antara kedua teks tersebut (Ariantini et al., 2016).

Secara matematis, *Cosine similarity* dihitung menggunakan perbandingan antara perkalian titik (*dot product*) dari dua vektor dengan hasil perkalian magnitudo/panjang kedua vektor. Nilai *Cosine similarity* berada pada rentang 0 hingga 1 dalam konteks pemrosesan teks karena nilai representasi fitur teks tidak bernilai negatif. Nilai mendekati 1 menunjukkan tingkat kemiripan semantik yang tinggi, sedangkan nilai mendekati 0 menunjukkan bahwa kedua dokumen tidak memiliki hubungan makna yang signifikan (Supiyanto & Sriyono, 2023). Adapun rumus matematikanya sebagai berikut:

Rumus *Cosine similarity*

$$\cos(A, B) = \frac{A \cdot B}{|A| \times |B|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \times \sqrt{\sum_{i=1}^n B_i^2}} \quad (1)$$

Keterangan:

- A = vektor *embedding* dokumen CV
- B = vektor *embedding* dokumen *Job Profile*
- A_i = nilai elemen ke- i pada vektor A
- B_i = nilai elemen ke- i pada vektor B
- n = jumlah dimensi vektor *embedding*
- $|A|$ = magnitudo atau panjang vektor A
- $|B|$ = magnitudo atau panjang vektor B

Penggunaan *Cosine similarity* bersama model *sentence embedding* berbasis *Transformer* menjadi pendekatan yang umum diterapkan pada sistem

Natural Language Processing (NLP) karena *embedding* yang dihasilkan mampu merepresentasikan makna dan konteks suatu teks secara lebih baik. Melalui pendekatan ini, *Cosine similarity* dapat digunakan untuk mengukur tingkat kemiripan semantik antar dokumen berdasarkan kedekatan arah vektor yang dihasilkan (Reimers & Gurevych, 2019). Dalam penelitian ini, metode tersebut digunakan sebagai instrumen utama untuk menghitung skor kesesuaian antara dokumen CV dan *Job Profile* serta sebagai dasar evaluasi perbandingan performa model yang diusulkan.

1.6.8 Evaluasi Kinerja Model

Evaluasi kinerja model merupakan proses untuk mengukur kemampuan sistem dalam menghasilkan rekomendasi yang relevan dan sesuai dengan kebutuhan pengguna. (Jadon & Patil, 2024) menjelaskan bahwa evaluasi sistem rekomendasi dapat dilakukan menggunakan beberapa metrik berbasis relevansi dan peringkat (*ranking*). Tidak ada metrik tunggal yang mampu merepresentasikan seluruh aspek performa secara mutlak, sehingga penggunaan beberapa metrik secara bersamaan diperlukan untuk memperoleh penilaian yang lebih komprehensif. Dalam penelitian ini, evaluasi dilakukan menggunakan enam metrik berbasis *Top-k* dengan menetapkan batasan nilai $k = 5$ yang diimplementasikan secara konsisten pada tahap pengujian:

1. Mean Reciprocal Rank (MRR)

Mean Reciprocal Rank (MRR) merupakan metrik evaluasi yang digunakan untuk mengukur kemampuan sistem dalam menempatkan kandidat relevan pada posisi teratas hasil rekomendasi. MRR dihitung berdasarkan kebalikan dari posisi kemunculan pertama kandidat relevan (*reciprocal rank*) pada setiap data uji, kemudian dirata-ratakan untuk seluruh data uji. Semakin tinggi nilai *MRR*, semakin baik kemampuan sistem dalam menempatkan kandidat yang relevan pada peringkat awal.

Rumus MRR

$$MRR = \frac{1}{|U|} \sum_{i=1}^{|U|} \frac{1}{rank_i} \quad (2)$$

Keterangan:

U = himpunan data uji (*query set*)

$rank_i$ = posisi kandidat relevan pertama pada data uji ke- i

2. Average Reciprocal Hit Rank (ARHR@k)

Average Reciprocal Hit Rank (ARHR@k) merupakan metrik evaluasi yang mengukur kualitas hasil rekomendasi berdasarkan posisi seluruh kandidat relevan dalam daftar rekomendasi teratas. Berbeda dari *MRR* yang hanya mempertimbangkan objek relevan pertama, *ARHR@k* memberikan bobot resiprokal pada setiap kandidat relevan yang berhasil muncul pada peringkat teratas.

Rumus ARHR@k

$$ARHR@k = \frac{1}{|U|} \sum_{u \in U} \sum_{i=1}^k \frac{\delta(i, u)}{i} \quad (3)$$

Keterangan:

- U = himpunan data uji (*query set*)
- k = jumlah rekomendasi teratas yang dievaluasi
- i = posisi atau peringkat kandidat pada daftar rekomendasi
- δ = fungsi indikator relevansi, bernilai 1 jika kandidat pada posisi ke- i relevan dengan data uji u , dan 0 jika sebaliknya.

3. Normalized Discounted Cumulative Gain (nDCG@k)

Normalized Discounted Cumulative Gain (nDCG@k) merupakan metrik evaluasi yang digunakan untuk mengukur kualitas urutan (*ranking quality*) pada sistem rekomendasi dengan membandingkan urutan hasil rekomendasi yang dihasilkan sistem terhadap urutan ideal. Metrik ini memperhitungkan tingkat relevansi kandidat serta posisinya dalam daftar rekomendasi melalui mekanisme *discounting* berbasis logaritma, sehingga kandidat yang relevan pada posisi lebih atas akan memberikan kontribusi nilai yang lebih besar.

Rumus DCG@k

$$DCG@k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i + 1)} \quad (4)$$

Keterangan:

- k = jumlah rekomendasi teratas yang dievaluasi.
- i = posisi atau peringkat kandidat pada daftar rekomendasi
- rel_i = nilai relevansi kandidat pada posisi ke- i (1 jika relevan, 0 jika tidak relevan)

Setelah nilai DCG diperoleh, dilakukan normalisasi menggunakan *Ideal Discounted Cumulative Gain* (IDCG), yaitu nilai DCG pada kondisi ideal ketika seluruh kandidat relevan berada pada urutan teratas.

Rumus nDCG@k

$$nDCG@k = \frac{DCG@k}{IDCG@k} \quad (5)$$

Keterangan:

- DCG@k = nilai *Discounted Cumulative Gain* hasil rekomendasi sistem
- IDCG@k = nilai *Ideal Discounted Cumulative Gain* atau nilai maksimum dari urutan rekomendasi terbaik.

Nilai nDCG yang semakin mendekati 1 menunjukkan bahwa sistem mampu mengurutkan kandidat relevan pada posisi yang semakin optimal sesuai dengan urutan ideal rekomendasi.

4. *Precision@k*

Precision@k merupakan metrik evaluasi yang digunakan untuk mengukur proporsi kandidat relevan yang berhasil ditemukan sistem di dalam k rekomendasi teratas. Metrik ini menunjukkan tingkat ketepatan hasil rekomendasi dengan membandingkan jumlah kandidat relevan yang muncul pada *top-k* rekomendasi terhadap jumlah keseluruhan rekomendasi yang diberikan sistem. Semakin tinggi nilai *Precision@k*, semakin besar proporsi kandidat relevan yang berhasil direkomendasikan oleh sistem pada posisi teratas.

Rumus *Precision@k*

$$Precision@k = \frac{\text{Number of relevant in top-}k}{k} \quad (6)$$

Keterangan:

Number of relevant in top-k = jumlah kandidat relevan pada top-k rekomendasi.
k = jumlah rekomendasi teratas yang dievaluasi.

5. *Recall@k*

Recall@k merupakan metrik evaluasi yang digunakan untuk mengukur kemampuan sistem dalam menemukan kembali seluruh kandidat relevan yang tersedia pada data acuan melalui k rekomendasi teratas yang dihasilkan. Metrik ini menunjukkan seberapa besar proporsi kandidat relevan yang berhasil ditemukan oleh sistem dibandingkan dengan seluruh kandidat yang seharusnya relevan.

Rumus *Recall@k*:

$$Recall@k = \frac{\text{Relevant} \cap \text{Top-}k}{\text{Relevant items}} \quad (7)$$

Keterangan:

Relevant $\cap$ *Top-k* = jumlah kandidat relevan yang berhasil ditemukan pada rekomendasi k
Relevant items = jumlah total Kandidat relevan yang tersedia.

6. *F1@k*

F1@k merupakan metrik evaluasi yang merepresentasikan rata-rata harmonik (*harmonic mean*) antara nilai *Precision@k* dan *Recall@k*. Metrik ini digunakan untuk menyeimbangkan kedua ukuran tersebut sehingga mampu memberikan gambaran yang lebih komprehensif mengenai performa sistem rekomendasi. Nilai *F1@k* akan tinggi apabila sistem memiliki nilai *Precision@k* dan *Recall@k* yang sama-sama tinggi.

Rumus *F1@k*

$$F1@k = 2 \times \frac{Precision@k \times Recall@k}{Precision@k + Recall@k} \quad (8)$$

Keterangan:

Recall@k = kemampuan menemukan kandidat relevan pada top-*k*

Precision@k = proporsi kandidat relevan pada top-*k* rekomendasi

1.6.9 Rancangan Sistem Penilaian Multi-Kriteria

Dalam sistem pendukung keputusan rekrutmen, penilaian kandidat umumnya menggunakan pendekatan *multi-criteria* yang melibatkan berbagai kriteria seperti usia, pendidikan, pengalaman, dan keterampilan, dengan bobot yang ditentukan melalui metode seperti *Analytic Hierarchy Process* (AHP) agar prioritas antar kriteria dapat ditetapkan secara lebih objektif dan terstruktur (Ikah & Fitriani, 2022). Berdasarkan hal tersebut, penelitian ini menggunakan tiga kriteria penilaian, yaitu pendidikan, pengalaman, dan kemampuan, yang dipilih karena masing-masing memiliki fungsi berbeda dalam menggambarkan kualitas kandidat: pendidikan menunjukkan dasar pengetahuan akademik dan latar belakang formal pelamar, pengalaman mencerminkan tingkat keterbiasaan kandidat terhadap lingkungan kerja, sementara kemampuan menggambarkan kompetensi aktual kandidat dalam melaksanakan pekerjaan sesuai kebutuhan perusahaan.

Dalam penelitian ini, aspek kemampuan diberikan bobot lebih tinggi dibandingkan pendidikan dan pengalaman, dilandasi dua sumber justifikasi yang saling memperkuat. Dari sisi literatur, (Alsaif et al., 2022) membangun sistem rekomendasi pekerjaan berbasis konten yang memberikan bobot lebih besar pada aspek keterampilan dibandingkan atribut lain dalam mengukur kesesuaian pelamar dengan lowongan, sementara (Firmansyah, 2025) menunjukkan bahwa *screening* CV tradisional sering tidak meloloskan kandidat berkemampuan sesuai hanya karena nilai akhirnya rendah, menandakan kemampuan lebih mencerminkan kesiapan praktis dibandingkan latar belakang pendidikan semata. Dari sisi praktis, hasil wawancara dengan tim HRD Kalla Aspal mengonfirmasi bahwa kemampuan dan kompetensi teknis menjadi pertimbangan utama, diikuti pengalaman, sementara pendidikan formal hanya dipandang sebagai syarat dasar.

Berdasarkan kesesuaian antara kajian literatur dan masukan tim HRD tersebut, penelitian ini menerapkan skema pembobotan tetap (*fixed weight*) sebesar 10% untuk pendidikan, 40% untuk pengalaman, dan 50% untuk kemampuan. Bobot kemampuan ditetapkan paling tinggi karena dianggap paling menentukan kesesuaian kandidat dengan kebutuhan operasional, pengalaman diberi bobot cukup besar karena mencerminkan kesiapan menghadapi lingkungan kerja nyata, sementara pendidikan diberi bobot paling rendah karena praktik rekrutmen modern di Kalla Aspal tidak lagi berfokus pada latar belakang akademik semata. Skema ini bersifat tetap berdasarkan kebijakan pakar (*expert judgment*) HRD internal yang diperkuat landasan empiris literatur, bukan hasil optimasi algoritma otomatis, dan diterapkan secara konsisten pada seluruh perhitungan skor akhir penelitian.

1.6.10 Pengembangan Sistem Berbasis Website (Streamlit)

Pengembangan sistem informasi merupakan kegiatan yang dilakukan oleh pengembang untuk menerjemahkan kebutuhan pengguna ke dalam bahasa teknis sistem, sehingga dihasilkan sistem yang sesuai dengan kebutuhan pengguna serta

sejalan dengan perencanaan dan penjadwalan yang telah disepakati (Purnomo, 2017). Dalam penelitian ini, sistem dikembangkan menggunakan *framework* Streamlit, yaitu *framework open-source* berbasis Python yang dirancang untuk membangun, menyebarkan (*deploy*), dan memvisualisasikan aplikasi web interaktif secara cepat, minimalis, namun tetap menyajikan antarmuka yang ramah pengguna (*user-friendly*) (Hastomo et al., 2022). Streamlit menyediakan berbagai komponen antarmuka (*widget* bawaan) seperti penggeser (*slider*), kolom teks, pengunggah berkas, hingga elemen HTML seperti *checkboxes* dan *radio buttons*. Keberadaan komponen ini memungkinkan pengembang membangun aplikasi data dan *machine learning* secara instan tanpa memerlukan penguasaan mendalam terhadap teknologi *front-end* konvensional seperti HTML, CSS, dan JavaScript (Hastomo et al., 2022).

Beberapa penelitian telah memanfaatkan Streamlit sebagai platform visualisasi data dan implementasi aplikasi berbasis *machine learning*. (Sowmiya et al., 2024) menunjukkan bahwa Streamlit dapat dimanfaatkan untuk memvisualisasikan data dan hasil analisis secara langsung dalam antarmuka berbasis web yang interaktif, mencakup tampilan grafik, peta topografi, dan pemrosesan data kepada pengguna. Lebih lanjut, (Hastomo et al., 2022) menjelaskan bahwa Streamlit bekerja dengan konsep mengeksekusi ulang seluruh skrip Python dari atas ke bawah setiap kali terjadi interaksi pengguna pada antarmuka. *Framework* gratis ini berjalan pada Python atau Visual Studio Code, dengan struktur tampilan beranda yang secara umum dapat dipisahkan menjadi panel menu kontrol (*buttons*) dan panel tampilan visual grafik (*chart*). Karakteristik tersebut membuktikan bahwa Streamlit sangat mendukung pengembangan aplikasi yang menggabungkan proses pengolahan data, visualisasi hasil, dan manajemen status aplikasi dalam satu platform yang terintegrasi secara efisien.

Pada penelitian ini, Streamlit digunakan sebagai platform untuk mengimplementasikan model terbaik hasil proses perbandingan dan evaluasi. Melalui aplikasi berbasis web yang dikembangkan, pengguna dapat mengunggah dokumen *Curriculum Vitae* (CV), memperoleh hasil perhitungan skor kecocokan (*matching score*) kandidat terhadap *Job Profile*, serta melihat hasil pemeringkatan kandidat secara interaktif. Dukungan integrasi dengan berbagai pustaka Python juga memungkinkan pengembangan sistem yang menggabungkan proses pengolahan data, perhitungan kemiripan semantik, dan penyajian hasil analisis dalam satu antarmuka yang mudah digunakan.

1.7 Tinjauan Penelitian Terkait

Sebagai landasan dalam pengembangan penelitian ini, penulis menelaah berbagai penelitian terdahulu yang relevan dengan penggunaan *sentence embedding*, *semantic similarity*, serta sistem rekrutmen berbasis kecerdasan buatan. Ringkasan penelitian terkait yang digunakan sebagai acuan disajikan pada Tabel 2.

Tabel 2. Ringkasan Penelitian Terkait

Nama Peneliti (Tahun)	Judul	Metode/ Model	Hasil Utama	Relevansi dan Gap Penelitian
(Mikolov et al., 2013)	<i>Efficient Estimation of Word Representations in Vector Space</i>	Word2Vec	Menghasilkan representasi vektor kata yang efisien dan mampu menangkap regularitas semantik antar kata.	Fondasi konsep <i>word embedding</i> , namun belum menangani representasi kalimat untuk <i>semantic similarity</i> .
(Vaswani et al., 2017)	<i>Attention Is All You Need</i>	Transformer	Mekanisme <i>self-attention</i> mengungguli RNN dan LSTM dalam pemrosesan bahasa alami.	Dasar arsitektur <i>Transformer</i> pada SBERT dan USE, namun belum membahas pencocokan dokumen rekrutmen.
(Devlin et al., 2019)	<i>BERT: Pre-training of Deep Bidirectional Transformers</i>	BERT (Transformer Encoder)	Mencapai <i>state-of-the-art</i> pada berbagai tugas NLP dengan <i>GLUE Score</i> 80.5%.	Dasar pengembangan SBERT, namun belum dirancang untuk <i>sentence embedding</i> yang efisien.
(Cer et al., 2018)	<i>Universal Sentence Encoder</i>	USE (DAN & Transformer)	Menghasilkan representasi kalimat untuk <i>semantic similarity</i> , dan <i>text classification</i> , varian <i>Transformer (v4)</i> menghasilkan <i>embedding</i> 512 dimensi.	Dasar penggunaan USE, namun belum dibandingkan dengan SBERT pada pencocokan CV dan <i>Job Profile</i> .
(Reimers & Gurevych, 2019)	<i>Sentence-BERT: Sentence embeddings</i>	SBERT + Cosine similarity	Mereduksi waktu pencarian pasangan kalimat	Dasar penggunaan SBERT, namun belum

Nama Peneliti (Tahun)	Judul	Metode/ Model	Hasil Utama	Relevansi dan Gap Penelitian
	<i>using Siamese BERT-Networks</i>		paling mirip dari 65 jam (BERT) menjadi 5 detik pada 10000 (sepuluh ribu) kalimat, dengan akurasi setara.	diimplementasikan pada SPK rekrutmen berbasis <i>website</i> .
(Gupta et al., 2022)	<i>A Comparative Analysis of Sentence embedding Techniques for Document Ranking</i>	SBERT vs USE vs TF-IDF, dll.	SBERT dan USE mengungguli teknik <i>embedding</i> lain (InferSent, ELMo, XLNet, Doc2Vec) pada metrik MAP dan nDCG.	Mendukung perlunya perbandingan SBERT-USE, namun tidak pada domain rekrutmen dan tidak memakai metrik MRR /ARHR /Precision@5 /Recall@5 /F1@5.
(Ajjam & Al-Raweshidy, 2025)	<i>AI-driven semantic similarity-based Job Matching Framework for Recruitment Systems</i>	<i>Semantic Similarity+AI</i>	Pendekatan <i>semantic similarity</i> berbasis AI mengatasi keterbatasan <i>keyword matching</i> dan menghasilkan pencocokan kandidat lebih akurat.	Acuan implementasi pencocokan rekrutmen berbasis AI, namun tidak membandingkan beberapa model <i>sentence embedding</i> .
(Jadon & Patil, 2024)	<i>A Comprehensive Survey of Evaluation Techniques for Recommendation Systems</i>	MRR, nDCG, Precision, Recall	Kombinasi beberapa metrik IR menghasilkan evaluasi yang lebih komprehensif.	Dasar pemilihan metrik evaluasi, namun belum diterapkan pada kasus CV dan <i>Job Profile</i> .

Berdasarkan tinjauan penelitian terdahulu, berbagai penelitian telah membuktikan efektivitas model *sentence embedding* dalam memahami makna semantik teks serta mendukung tugas *Information Retrieval* dan pencocokan

dokumen, namun masih terbatas penelitian yang secara khusus membandingkan kinerja *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE) pada pencocokan *Curriculum Vitae* (CV) dan *Job Profile* dalam konteks rekrutmen, serta mengintegrasikan hasilnya ke dalam Sistem Pendukung Keputusan (SPK) yang dapat digunakan secara operasional. Oleh karena itu, penelitian ini membandingkan kinerja SBERT dan USE menggunakan metrik *Information Retrieval* yang komprehensif *Mean Reciprocal Rank* (MRR), *Average Reciprocal Hit Rank* (ARHR@5), *Normalized Discounted Cumulative Gain* (nDCG@5), *Precision@5*, *Recall@5*, dan *F1@5* serta mengimplementasikan model dengan performa terbaik ke dalam SPK rekrutmen berbasis *website* pada studi kasus Kalla Aspal, sehingga diharapkan dapat berkontribusi baik dari sisi evaluasi model *sentence embedding* maupun penerapannya dalam mendukung proses rekrutmen yang lebih efektif dan objektif.

BAB II METODE PENELITIAN

2.1 Waktu dan Tempat Penelitian

Penelitian ini dilaksanakan dari bulan Januari 2026 hingga April 2026. Penelitian bertempat di Wisma Kalla Lantai 10, *Head Office* Kalla Aspal, Makassar, sebagai lokasi pengambilan data *Curriculum Vitae* (CV) dan *Job Profile*. Rincian waktu dan tahapan pelaksanaan penelitian dapat dilihat pada Tabel 3.

Tabel 3. Waktu Penelitian

Tahapan	Januari				Februari				Maret				April			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Pengumpulan Data																
Pra-pemrosesan Data																
Perbandingan dan evaluasi model																
Implementasi Model dan Perancangan Sistem																
Pengujian Sistem																

2.2 Instrumen Penelitian

Instrumen penelitian merupakan sarana yang digunakan untuk mendukung pelaksanaan penelitian agar berjalan sesuai dengan tujuan yang telah ditetapkan. Pada penelitian ini, instrumen yang digunakan terdiri atas perangkat keras (*Hardware*) dan perangkat lunak (*Software*) yang berperan dalam proses pengolahan data, implementasi model, serta evaluasi hasil penelitian.

2.2.1 Perangkat Keras (*Hardware*)

Perangkat keras yang digunakan dalam penelitian ini mencakup beberapa komponen beserta spesifikasi yang mendukung pelaksanaan komputasi model *deep learning*. Rincian spesifikasi perangkat keras yang digunakan disajikan pada Tabel 4.

Tabel 4. Perangkat Keras (*Hardware*)

<i>Hardware</i>	Spesifikasi
Operating System (OS)	Windows 11 Home

Hardware	Spesifikasi
Processor	AMD Ryzen 5 7520U with Radeon Graphics
RAM	8 GB
Storage	477 GB SSD
GPU	AMD Radeon Graphics (Integrated)

2.2.2 Perangkat Lunak (Software)


Perangkat lunak yang digunakan dalam penelitian ini berperan sebagai pendukung utama dalam proses ekstraksi data, pengolahan teks, implementasi model SBERT dan USE, perhitungan tingkat kesesuaian dokumen, serta analisis hasil penelitian. Daftar perangkat lunak beserta fungsinya disajikan pada Tabel 5.

Tabel 5. Perangkat Lunak (Software)

Software	Keterangan
Python	Bahasa pemrograman utama untuk implementasi sistem secara menyeluruh.
Visual Studio Code	<i>Integrated Development Environment</i> (IDE) untuk penyusunan kode program.
Google Colab / Jupyter	Lingkungan eksperimen pemodelan SBERT, USE, dan analisis metrik evaluasi.
PyMuPDF (fitz)	Ekstraksi teks dari dokumen <i>Portable Document Format</i> (PDF) dari <i>Curriculum Vitae</i> (CV).
<i>Transformers</i> (Hugging Face)	Pemuatan model translasi MarianMT (<i>Helsinki-NLP/opus-mt-id-en</i>) untuk menerjemahkan komponen teks CV dari Bahasa Indonesia ke Bahasa Inggris.
PyTorch (Torch)	<i>Framework</i> komputasi tensor yang mendasari eksekusi model translasi MarianMT.
Pandas & NumPy	Manipulasi data tabular (CSV) dan komputasi numerik matriks <i>embedding</i> .
Scikit-learn	Komputasi matriks <i>similarity</i> menggunakan fungsi <i>Cosine similarity</i> .
Sentence-Transformers	Generator <i>sentence embedding</i> berbasis arsitektur <i>Sentence-BERT</i> (SBERT).
TensorFlow & TF Hub	<i>Framework</i> pendukung eksekusi model <i>Universal Sentence Encoder</i> (USE).
Openpyxl	Pembacaan dan penyusunan laporan data hasil evaluasi ke format Excel.
Streamlit	<i>Framework</i> pengembangan antarmuka Sistem Pendukung Keputusan (SPK) berbasis <i>website</i> .
Re (Regular Expression)	Operasi pembersihan (<i>cleaning</i>) dan standardisasi teks mentah.
OS & Zipfile	Manajemen direktori, pembacaan berkas, dan ekstraksi paket <i>Dataset</i> ZIP.

2.3 Alur Penelitian

Alur atau tahapan komparasi model dan perancangan sistem yang dilakukan pada penelitian ini digambarkan secara sistematis melalui diagram alur pada Gambar 4.



Gambar 4. Diagram Alur Tahapan Metode Penelitian

2.4 Sumber dan Data Penelitian

Data penelitian ini diperoleh dari Kalla Aspal sebagai mitra penelitian, terdiri atas dokumen *Curriculum Vitae* (CV) kandidat dan dokumen *Job Profile* dalam format *Portable Document Format* (PDF) untuk menjaga struktur dan keaslian informasi teks sebagaimana kondisi nyata proses rekrutmen.

Pada tahap awal akuisisi data, tim *Human Resource Department* (HRD) Kalla Aspal menetapkan 95 dokumen CV sebagai data acuan (*Ground truth*) untuk mengukur performa sistem rekomendasi yang dikembangkan. Penetapan ini dilakukan berdasarkan hasil seleksi administrasi internal yang telah berjalan sebagai bagian dari proses rekrutmen resmi perusahaan, sehingga kandidat yang ditetapkan sebagai *Ground truth* merupakan pelamar yang telah dinyatakan lolos seleksi administrasi dan dinilai paling sesuai dengan kebutuhan posisi berdasarkan penilaian profesional tim HRD. Validitas *Ground truth* ini bersandar pada kompetensi domain (*domain expertise*) tim HRD sebagai *subject matter expert* yang memahami kebutuhan jabatan, budaya perusahaan, dan kriteria seleksi internal. Meskipun penetapannya tidak melalui mekanisme anotasi multi-penilai (*multi-rater*), keputusan tersebut tetap memiliki legitimasi kuat karena didasarkan pada prosedur seleksi resmi yang dapat dipertanggungjawabkan secara institusional.

Setelah *Ground truth* ditetapkan, peneliti menerima seluruh berkas CV mentah dari tim HRD mencakup semua folder formasi jabatan, dengan total 893 dokumen. Tingginya jumlah berkas ini disebabkan oleh kebijakan rekrutmen Kalla Aspal yang memperbolehkan satu pelamar mendaftar pada lebih dari satu posisi jabatan sekaligus, sehingga CV kandidat yang sama termasuk sebagian kandidat *Ground truth* dapat muncul di lebih dari satu folder formasi. Sebelum diproses ke lingkungan eksperimen, peneliti melakukan pembersihan dan validasi data secara manual dengan menelusuri seluruh folder formasi jabatan untuk mengidentifikasi salinan duplikat. Dari proses ini ditemukan 42 berkas duplikat lintas formasi jabatan yang kemudian dieliminasi, sehingga diperoleh total *Dataset* sebanyak 851 dokumen CV unik yang tersebar ke dalam 26 posisi jabatan aktif, termasuk 95 dokumen *Ground truth* yang telah bersih dari duplikasi. Rincian distribusi 851 dokumen CV berdasarkan posisi jabatan disajikan pada Tabel 6.

Tabel 6. Distribusi Dokumen CV Berdasarkan Posisi Jabatan

No.	Posisi Jabatan	Total Dokumen CV
1	Sales Administration Staff	47
2	General Affair Staff	43
3	Marketing Region Analyst	43
4	Sales Staff	43
5	Equipment & Maintenance Staff	41
6	HCBP Staff	41
7	Account Receivable Staff	39
8	Non Aspal Purchasing Staff	36
9	Training & Development Junior Analyst	35
10	Accounting Staff	34
11	Aspal Emulsi Operator	34
12	Finance Staff	33
13	Cashier Branch Office	33
14	Business Development Staff	31
15	Aspal Procurement Staff	31
16	Driver	31
17	Mechanical Electrical Engineer	30
18	Tax Staff	30
19	Tanker Truck Driver	30
20	Cashflow Management Staff	29
21	Balance & Boiler Operator	25
22	Legal Staff	24
23	Budget Control Analyst	23
24	HSE Associates	22
25	Security TAC	22
26	Office Boy	21
Total	Keseluruhan Dokumen CV	851

Dokumen CV memuat berbagai informasi yang berkaitan dengan profil kandidat, seperti riwayat pendidikan, pengalaman kerja, pengalaman organisasi, penguasaan bahasa, serta pekerjaan yang disukai oleh kandidat. Contoh tampilan dokumen CV yang digunakan dalam penelitian ini ditunjukkan pada Gambar 5.

 AL QADRI Gender : Laki - Laki Email : [redacted]	No. Identitas [redacted]	Social Media Facebook : [redacted] Instagram : [redacted] Twitter : [redacted] LinkedIn : [redacted]
	Kota Asal [redacted]	
	Alamat [redacted]	
	Kode Pos [redacted]	
	Tempat & Tanggal Lahir [redacted]	
	Status Pernikahan Belum Menikah	
	Aqama ISLAM	

Riwayat Pendidikan Sekolah Menengah Atas (SMA) Universitas Bumi Persada Jurusan : Sains Informatika Masuk : Juli 2019 - Tamat Mei 2022 IPK/ Nilai : 88.74	Pengalaman Pekerjaan Internship / OJT KANTOR PELAYANAN PERBENDAHARAAN NEGARA MAJENE - IT SUPPORT Masuk : Maret 2025 - Selesai Juli 2025 Deskripsi : MELAKUKAN MAGANG MANDIRI DI KANTOR PELAYANAN PERBENDAHARAAN NEGARA MAJENE
---	---

Pengalaman organisasi HIMPUNAN MAHASISWA MATEMATIK FMIPA UNHAS - ANGGOTA BIDANG AKADEMIK Mulai : Juli 2024 - Selesai Juli 2025 Tanggung Jawab : MENJADI ANGGOTA BIDANG AKADEMIK HIMPUNAN MAHASISWA MATEMATIK FMIPA UNHAS	TPA & TOEFL/IETLS English Proficiency Test (EPT) - Score : 490.00 Universitas Hasanuddin : 2023-12-11
--	---

Penguasaan Bahasa Bahasa Manda Tingkat : Intermediate Bahasa Inggris Tingkat : Basic Bahasa Indonesia Tingkat : Basic	Pekerjaan Yang disukai Microsoft Office Deskripsi : Saya menyukai Microsoft Office karena mudah digunakan dan sangat membantu dalam mengerjakan tugas, seperti membuat dokumen, laporan, dan presentasi. Aplikasinya juga lengkap dan sering saya gunakan dalam kegiatan sehari-hari. IT Support Deskripsi : Saya menyukai pekerjaan sebagai IT Support karena saya senang membantu orang lain menyelesaikan masalah teknis. Saya merasa puas ketika bisa memperbaiki error, menyelesaikan kendala jaringan, atau membantu pengguna yang kesulitan dengan perangkat atau sistem. Pekerjaan ini juga membuat saya terus belajar hal baru seputar teknologi dan sistem informasi.
---	---

Gambar 5. Contoh Sampel Dokumen *Curriculum Vitae* (CV)

Selain data CV, tim HRD juga menyediakan dokumen *Job Profile* resmi perusahaan. Dari total data *Job Profile* yang tersedia, dipilih 26 *Job Profile* yang digunakan dalam penelitian berdasarkan arahan tim HRD. Pemilihan tersebut difokuskan pada posisi tingkat staf (*staff level*) yang tidak memiliki bawahan langsung (*non-supervisory position*) serta memiliki frekuensi pembukaan lowongan kerja yang relatif tinggi dalam proses rekrutmen perusahaan. Posisi-posisi tersebut berasal dari berbagai unit kerja yang tersebar di *Head Office* maupun kantor cabang Kalla Aspal sehingga dianggap representatif untuk digunakan sebagai basis pengujian performa sistem rekomendasi.

Dokumen *Job Profile* tersebut berfungsi sebagai acuan dalam proses pencocokan dengan CV kandidat untuk mengetahui tingkat kesesuaian terhadap posisi pekerjaan yang tersedia. Contoh tampilan dokumen *Job Profile* yang digunakan dalam penelitian ini dapat dilihat pada Gambar 6.

Kode Dokumen: 026/JOB-PROFILE/HQ/HCBP/IX/2025



JOB PROFILE

Identitas Jabatan	
Nama Jabatan	: Equipment & Maintenance Staff
Divisi	: Bussiness Supporting
Departemen	: Equipment & Maintenance
Bagian	: -
Atasan Langsung	: Equipment & Maintenance Assistant Manager
Bawahan Langsung	: -

Tujuan Utama	
Memastikan pengelolaan material dan sparepart di gudang dilakukan secara tepat sesuai dengan aturan perusahaan.	

Kewenangan	
Kewenangan	- Jumlah Atasan Langsung : 1 orang - Jumlah Bawahan Langsung : -

Peran & Tanggung Jawab	
- Membuat data jumlah dan kondisi armada, serta biaya perawatan/perbaikan untuk armada. - Menyajikan data ketersediaan dan kondisi perlatan (equipment tools), serta membuat rekapitulasi kebutuhan pengadaan peralatan. - Memproses pengajuan perbaikan dari cabang/TAC. - Memproses kebutuhan untuk pengadaan stok inventory yang di ajukan oleh cabang/TAC - Memastikan bantuan kebutuhan suplai sparepart atau material lainnya (pembelian makassar) diterima oleh user. - Mengkoordinir cabang, agar seluruh laporan (laporan armada, tools, stok bahan bakar, biaya perbaikan, dll) yang diterima dengan akurat dan tepat waktu. - Melakukan tindak lanjut terhadap pengajuan cabang yang masuk. - Menerima dan memverifikasi pengajuan cabang terkait rencana revitalisasi asset teknis/fasilitas pendukung yang ada di TAC. - Menyusun dokumen besok dan Membuat perhitungan estimasi kebutuhan pekerjaan revitalisasi yang diajukan oleh cabang. - Memonitoring progres pengerjaan perbaikan agar dapat terselesaikan sesuai dengan jadwal. - Melakukan koordinasi dengan konsultan dan pengawas lapangan, agar pembangunan yang dilakukan sesuai dengan perencanaan. - Mencocokkan peraturan perusahaan terkait konsep, kebijakan, pedoman dan SOP dalam menunjang operasional - Mengimplementasikan prosedur, sistem dan SOP dalam kegiatan operasi - Menerap hasil usulan perbaikan kebijakan, system, pedoman dan SOP dalam kegiatan operasional	
Umum - Mempelajari identifikasi bahaya yang mungkin terjadi pada lingkup pekerjaan - Melakukan tindakan pencegahan yang dibutuhkan untuk menghindari bahaya di lingkungan kerja yang telah diidentifikasi.	

Persyaratan Jabatan			
Pendidikan	: Min. S1 Jurusan Teknik Sipil/Mesin		
Pengalaman	- Memiliki pengalaman kerja di bagian Equipment & Maintenance - Freshgraduate are welcome		
Persyaratan Bahasa	: Bahasa Inggris	Lisan & Tulisan	Baik
Pengetahuan / Keterampilan			
- IT Skill - Kemampuan Bahasa Inggris lisan dan tulisan atau setara skor TOEFL ITP Min 450 / IELTS 5.0 - Pengetahuan produk perusahaan - Mengetahui proses bisnis Perusahaan - Memiliki pengetahuan tentang jenis sparepart/material dan peruntukannya - Memiliki kemampuan komunikasi dan interpersonal yang baik			

Persyaratan Fisik:

- Tidak diperlukan usaha atau kemampuan fisik khusus untuk melakukan pekerjaan ini.

Gambar 6. Contoh Sampel Dokumen Job Profile Resmi Kalla Aspal

2.5 Tahapan Pra-pemrosesan Data

Tahap pra-pemrosesan data (*data preprocessing*) dilakukan untuk mempersiapkan data sebelum digunakan dalam proses perhitungan *semantic similarity* menggunakan model *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE). Pada tahap ini, data *Curriculum Vitae* (CV) kandidat dan *Job Profile* diolah menjadi bentuk yang lebih terstruktur agar dapat digunakan sebagai masukan (*input*) bagi model.

Tujuan dari tahap pra-pemrosesan adalah mengekstraksi informasi yang relevan dari dokumen sumber, menyusun informasi berdasarkan komponen penilaian yang digunakan dalam penelitian, serta menghasilkan representasi teks yang dapat dibandingkan antara CV kandidat dan *Job Profile*. Tahap pra-pemrosesan ini terdiri atas proses ekstraksi informasi CV, pengolahan data *Job Profile*, pembentukan komponen penilaian, dan pembentukan representasi teks.

2.5.1 Ekstraksi Informasi *Curriculum Vitae* (CV)

Dokumen CV yang digunakan dalam penelitian ini memiliki format awal berupa *Portable Document Format* (PDF). Oleh karena itu, sebelum memasuki tahap pemodelan, dilakukan proses ekstraksi informasi menggunakan pustaka Python PyMuPDF untuk memperoleh teks yang relevan dengan kebutuhan penilaian kesesuaian kandidat terhadap *Job Profile*.

Proses ekstraksi hanya diterapkan pada dokumen PDF berbasis teks (*text-based* PDF), sehingga dokumen hasil pemindaian (*scanned* PDF) tidak termasuk dalam cakupan penelitian. Setelah teks berhasil diekstraksi, dilakukan tahapan *text cleaning* yang mencakup konversi seluruh teks menjadi huruf kecil (*lowercasing*), penghapusan karakter *newline*, serta normalisasi tanda baca seperti titik koma, titik dua, tanda kurung, garis vertikal, dan simbol lain yang tidak relevan. Selain itu, sistem juga menghapus informasi periode kerja berbasis bulan dan tahun menggunakan pendekatan *regular expression* (seperti pola “januari 2020 sampai desember 2022”). Kata-kata struktural seperti “masuk”, “mulai”, “deskripsi”, “tanggung jawab”, “selesai”, dan “sekarang” juga dihilangkan agar tidak memengaruhi bobot informasi pada proses ekstraksi pengalaman.

Selanjutnya, pemisahan informasi dilakukan melalui pendekatan *keyword-based section extraction* dengan kata kunci spesifik seperti “pengalaman pekerjaan”, “pengalaman organisasi”, “penguasaan bahasa”, dan “pekerjaan yang disukai”. Hasil ekstraksi tersebut kemudian diproses menggunakan fungsi pemisahan terstruktur guna menghasilkan tiga komponen utama penilaian, yaitu pendidikan, pengalaman, dan kemampuan.

1. Komponen Pendidikan: Merepresentasikan jenjang pendidikan dan jurusan berdasarkan deteksi kata kunci seperti S1, D3, D4, SMA, SMK, SMP, serta nama jurusan seperti hukum, psikologi, teknik, dan sejenisnya.
2. Komponen Pengalaman: Merupakan gabungan dari informasi pengalaman pekerjaan dan pengalaman organisasi yang telah dibersihkan dari label struktural.
3. Komponen Kemampuan: Merupakan gabungan dari penguasaan bahasa dan pekerjaan yang disukai. Apabila komponen kemampuan bernilai kosong, sistem menggunakan teks komponen pengalaman sebagai fallback untuk menjaga kelengkapan informasi penilaian.

Hasil akhir dari tahapan ini berupa representasi data terstruktur yang akan digunakan sebagai *input* pada tahap perhitungan kemiripan (*similarity computation*). Pemetaan informasi ini disajikan secara ringkas pada Tabel 7.

Tabel 7. Pemetaan Informasi CV ke Komponen Penilaian

Komponen Penilaian	Informasi CV
Pendidikan	Riwayat Pendidikan (Jenjang dan Jurusan)
Pengalaman	Pengalaman Kerja, Pengalaman Organisasi
Kemampuan	Penguasaan Bahasa, Pekerjaan yang Disukai

Di dalam dokumen CV yang digunakan, kolom pekerjaan yang disukai tidak hanya berisi preferensi karier, tetapi juga sering kali memuat keterampilan teknis (*hard skills*) kandidat. Oleh karena itu, seluruh informasi pada kolom tersebut digabungkan dengan penguasaan bahasa ke dalam komponen kemampuan agar representasi kompetensi kandidat menjadi lebih komprehensif.

Selain itu, terdapat penanganan khusus pada komponen pendidikan untuk kondisi lowongan jabatan dengan kualifikasi "Semua Jurusan". Kondisi ini berpotensi menimbulkan bias jika dihitung langsung menggunakan pendekatan *semantic similarity*, karena jurusan yang bersifat umum akan memiliki tingkat kemiripan semantik yang rendah terhadap jurusan spesifik pada CV kandidat. Guna mengatasi kendala tersebut, digunakan pendekatan berbasis aturan (*rule-based logic*) untuk mengevaluasi kesesuaian berdasarkan jenjang pendidikan minimum.

Kandidat yang memenuhi jenjang pendidikan yang dipersyaratkan (misalnya S1 atau D4 untuk level sarjana, serta SMA/SMK/SMP untuk level menengah) diberikan nilai kesesuaian sebesar 0.8. Sementara itu, kandidat yang belum sepenuhnya memenuhi kualifikasi diberikan nilai 0.4. Bobot nilai ini ditetapkan berdasarkan hasil diskusi dengan tim HRD Kalla Aspal sebagai bentuk penyesuaian terhadap fleksibilitas kebijakan "Semua Jurusan" perusahaan. Di sisi lain, untuk posisi yang mensyaratkan jurusan spesifik, penilaian komponen pendidikan tetap menggunakan metode *Cosine similarity* terhadap representasi *embedding* semantik. Melalui kombinasi tersebut, pendekatan yang diterapkan pada penelitian ini bersifat *hybrid*, yaitu kombinasi antara *rule-based scoring* dan *semantic similarity*.

2.5.2 Pengolahan Data *Job Profile*

Data *Job Profile* yang diperoleh dari tim HRD Kalla Aspal memuat informasi mengenai persyaratan dan kebutuhan yang harus dipenuhi oleh kandidat untuk suatu posisi pekerjaan tertentu. Data tersebut masih berbentuk dokumen *Portable Document Format* (PDF). Untuk memudahkan proses pengolahan dan analisis data, informasi yang terdapat pada setiap *Job Profile* diidentifikasi dan disusun secara manual ke dalam format *Comma-Separated Values* (CSV).

Pada proses ini, beberapa informasi yang semula dituliskan dalam satu bagian pada dokumen *Job Profile* dipisahkan menjadi atribut yang lebih terstruktur. Sebagai contoh, informasi pendidikan yang dituliskan sebagai "Min. S1 Jurusan Akuntansi/Ekonomi" dipisahkan menjadi atribut *degree* yang berisi "S1" dan atribut *major* yang berisi "Akuntansi/Ekonomi". Proses ini dilakukan agar setiap atribut dapat diolah dan dibandingkan secara lebih efektif pada tahap pencocokan kandidat.

Hasil penyusunan data menghasilkan beberapa atribut, seperti *job_title*, tujuan, peran/tanggung_jawab, *degree*, *major*, pengalaman, bahasa, dan kemampuan. Atribut *job_title* digunakan sebagai identitas jabatan yang akan direkomendasikan oleh sistem. Struktur lengkap dari *Dataset Job Profile* disajikan pada Tabel 8.

Tabel 8. Struktur Atribut *Dataset Job Profile*

Atribut	Deskripsi
job_title	Nama jabatan
tujuan	Tujuan jabatan
peran/tanggung_jawab	Uraian tugas dan tanggung jawab jabatan
degree	Persyaratan jenjang pendidikan
major	Persyaratan jurusan pendidikan
pengalaman	Persyaratan pengalaman kerja
bahasa	Persyaratan kemampuan bahasa
kemampuan	Persyaratan kemampuan kerja

Selanjutnya, atribut-atribut pada *Job Profile* tersebut dikelompokkan ke dalam tiga komponen penilaian yang sesuai dengan struktur data CV berdasarkan hasil diskusi dengan tim HRD Kalla Aspal. Pengelompokan atribut ini dilakukan untuk menyesuaikan struktur informasi pada *Job Profile* dengan komponen penilaian yang digunakan dalam proses pencocokan kandidat.

1. Komponen Pendidikan: dibentuk dari penggabungan atribut *degree* dan *major* yang merepresentasikan persyaratan latar belakang pendidikan suatu jabatan.
2. Komponen Pengalaman: dibentuk dari penggabungan atribut pengalaman dan tujuan yang merepresentasikan kebutuhan pengalaman kerja suatu jabatan.
3. Komponen Kemampuan: dibentuk dari penggabungan atribut kemampuan, bahasa, serta *peran/tanggung_jawab* yang digunakan untuk merepresentasikan kompetensi dan keterampilan yang dibutuhkan dalam pelaksanaan pekerjaan.

Pemetaan seluruh atribut *Job Profile* ke dalam komponen penilaian dirangkum pada Tabel 9.

Tabel 9. Pemetaan Informasi *Job Profile* ke Komponen Penilaian

Komponen Penilaian	Informasi <i>Job Profile</i>
Pendidikan	<i>degree, major</i>
Pengalaman	pengalaman, tujuan
Kemampuan	kemampuan, bahasa, <i>peran/tanggung_jawab</i>

2.5.3 Pembentukan Representasi Teks

Setelah data dari *Curriculum Vitae* (CV) dan *Job Profile* berhasil diambil dan dikelompokkan, langkah berikutnya adalah membentuk representasi teks untuk setiap komponen penilaian. Tujuannya adalah menghasilkan pasangan data teks yang siap direpresentasikan dan dihitung tingkat kemiripannya menggunakan model SBERT dan USE.

Proses pembentukan representasi teks dilakukan dengan menggabungkan setiap informasi atau nilai atribut dalam satu komponen menjadi satu kesatuan teks

menggunakan pemisah koma (*string concatenation*). Karena seluruh data telah melalui proses normalisasi pada tahap sebelumnya, representasi teks yang dihasilkan berada dalam kondisi bersih dan siap digunakan pada tahap pemodelan. Proses pembentukan teks untuk setiap komponen adalah sebagai berikut:

1. Komponen Pendidikan: Teks dibentuk dari gabungan informasi jenjang pendidikan dan jurusan. Pada dokumen CV, data diperoleh dari hasil ekstraksi informasi pendidikan pelamar, sedangkan pada *Job Profile* data diperoleh dari atribut *degree* dan *major*. Untuk posisi yang menetapkan kualifikasi "Semua Jurusan", penilaian komponen pendidikan mengikuti aturan khusus yang telah dijelaskan pada tahap ekstraksi informasi CV.
2. Komponen Pengalaman: Teks dibentuk dari gabungan informasi pengalaman kerja dan pengalaman organisasi milik pelamar pada CV. Teks ini kemudian dipasangkan dengan gabungan isi atribut pengalaman dan tujuan pada *Job Profile*.
3. Komponen Kemampuan: Teks dibentuk dari gabungan informasi penguasaan bahasa dan pekerjaan yang disukai oleh pelamar pada CV. Teks ini kemudian dipasangkan dengan gabungan isi atribut kemampuan, bahasa, dan peran/tanggung_jawab pada *Job Profile*.

Hasil akhir dari tahap ini adalah tiga pasang data teks terstruktur untuk setiap pelamar dan setiap posisi jabatan, yaitu teks komponen pendidikan, pengalaman, dan kemampuan. Contoh hasil pembentukan representasi teks ditunjukkan pada Tabel 10.

Tabel 10. Contoh Hasil Pembentukan Komponen Kombinasi Teks

Komponen	CV Kandidat	Job Profile
Pendidikan	S1, Akuntansi	S1, Semua Jurusan
Pengalaman	Staff Administrasi Penjualan PT XYZ, Bendahara Himpunan Mahasiswa, pengalaman mengelola dokumen penjualan dan berkoordinasi dengan pelanggan	<i>Freshgraduate</i> / pengalaman di bidang penjualan (<i>sales</i>), memastikan tersedianya data yang akurat dan kelengkapan dokumen penjualan untuk menunjang kelancaran proses penjualan aspal curah
Kemampuan	Bahasa Inggris, <i>Microsoft Excel</i> , administrasi penjualan, komunikasi pelanggan, pengolahan data	<i>IT Skill</i> , pengetahuan produk perusahaan, mengetahui proses bisnis perusahaan, pengetahuan pemasaran, kemampuan komunikasi dan interpersonal, Bahasa Inggris aktif

Output dari seluruh tahap pra-pemrosesan ini berupa data teks terstruktur yang telah dikelompokkan ke dalam tiga komponen, yaitu pendidikan, pengalaman,

dan kemampuan, baik pada sisi CV kandidat maupun *Job Profile*. Sebelum masuk ke tahap representasi vektor, data teks tersebut terlebih dahulu diterjemahkan ke dalam Bahasa Inggris menggunakan model penerjemahan *Helsinki-NLP/opus-mt-id-en*, mengingat model *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE) yang digunakan pada penelitian ini dilatih dan bekerja optimal pada teks berbahasa Inggris. Data teks yang telah diterjemahkan kemudian direpresentasikan ke dalam bentuk *embedding* menggunakan model *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE). Representasi vektor yang dihasilkan selanjutnya digunakan untuk menghitung tingkat kemiripan antara CV kandidat dan *Job Profile*, menghasilkan skor kecocokan, serta melakukan pemeringkatan kandidat berdasarkan kesesuaiannya dengan *Job Profile*.

2.6 Tahap Perbandingan dan Evaluasi Model

Setelah data CV kandidat dan *Job Profile* selesai diproses menjadi teks terstruktur, tahap selanjutnya adalah melakukan eksperimen utama penelitian, yaitu membandingkan dan mengevaluasi kinerja model kecerdasan buatan. Pada tahap ini, dua model *Natural Language Processing* (NLP), yaitu SBERT dan USE, diuji menggunakan *Dataset* yang sama dari Kalla Aspal.

Secara umum, proses pada tahap ini dibagi menjadi tiga langkah utama sebagai berikut.

1. Proses Penyandian Teks (*Text Encoding*)

Masing-masing komponen teks yang telah dibentuk, yaitu pendidikan, pengalaman, dan kemampuan, baik dari dokumen CV kandidat maupun *Job Profile*, terlebih dahulu diterjemahkan ke dalam Bahasa Inggris untuk menyesuaikan dengan bahasa yang digunakan pada proses pelatihan model SBERT dan USE. Teks hasil terjemahan tersebut kemudian dimasukkan ke dalam model SBERT dan USE. Pada tahap ini, teks diubah menjadi representasi vektor numerik (*embedding vector*) yang merepresentasikan makna dan konteks dari teks tersebut.

2. Perhitungan Kemiripan Makna (*Similarity Computation*)

Setelah seluruh teks direpresentasikan dalam bentuk vektor, sistem menghitung tingkat kemiripan semantik antara informasi pada CV kandidat dan kriteria pada *Job Profile* menggunakan metode *Cosine similarity*. Nilai kemiripan yang diperoleh dari ketiga komponen penilaian, yaitu pendidikan, pengalaman, dan kemampuan, kemudian digabungkan menggunakan metode penjumlahan berbobot (*weighted sum*) untuk menghasilkan skor kecocokan akhir (*final matching score*).

Skema pembobotan dalam penelitian ini menerapkan porsi 10% untuk kriteria pendidikan, 40% untuk pengalaman, dan 50% untuk kemampuan. Pembobotan tersebut mengacu pada hasil diskusi dengan tim HRD Kalla Aspal serta didukung oleh kajian literatur yang menempatkan aspek kemampuan sebagai kriteria dengan kontribusi terbesar dalam proses seleksi kandidat. Perhitungan skor kecocokan akhir dilakukan menggunakan persamaan berikut.

$$\begin{aligned} \text{Final Score} = & (0.10 \times \text{Skor Pendidikan}) + (0.40 \times \text{Skor Pengalaman}) \\ & + (0.50 \times \text{Skor Kemampuan}) \end{aligned} \quad (9)$$

Khusus pada komponen pendidikan, pasangan CV dan *Job Profile* yang memiliki kualifikasi "Semua Jurusan" menggunakan nilai kesesuaian pendidikan berdasarkan aturan khusus yang telah dijelaskan pada tahap ekstraksi informasi CV. Untuk kondisi lainnya, nilai kemiripan komponen pendidikan dihitung menggunakan metode *Cosine similarity*.

3. Evaluasi Akurasi Berbasis Data Acuan (*Ground truth Evaluation*)

Untuk mengetahui model yang menghasilkan rekomendasi paling sesuai, hasil pemeringkatan (*ranking*) yang dihasilkan oleh SBERT dan USE dibandingkan dengan data acuan (*Ground truth*) yang telah dilabeli secara manual oleh tim HRD Kalla Aspal. Evaluasi dilakukan menggunakan metrik *Information Retrieval* dengan batasan nilai $k = 5$, yaitu:

- Mean Reciprocal Rank* (MRR), untuk mengukur ketepatan posisi kandidat relevan pertama pada daftar rekomendasi.
- Average Reciprocal Hit Rank* (ARHR@5), untuk mengukur kualitas pemeringkatan berdasarkan posisi seluruh kandidat relevan yang muncul pada lima rekomendasi teratas.
- Normalized Discounted Cumulative Gain* (nDCG@5), untuk mengukur kualitas urutan rekomendasi yang dihasilkan sistem dibandingkan dengan urutan ideal.
- Precision@5*, *Recall@5*, dan *F1@5*, untuk mengukur tingkat ketepatan, cakupan, dan keseimbangan performa rekomendasi dalam lima hasil teratas.

Nilai k ditetapkan sebesar 5 karena proses *screening* rekrutmen pada praktiknya umumnya berfokus pada sejumlah kecil kandidat dengan peringkat tertinggi yang akan ditinjau lebih lanjut oleh tim HRD. Selain itu, berdasarkan hasil diskusi dan wawancara dengan tim HRD Kalla Aspal, proses seleksi administrasi biasanya dilakukan dengan memprioritaskan beberapa kandidat terbaik yang dianggap paling sesuai dengan kebutuhan posisi sebelum dilanjutkan ke tahapan seleksi berikutnya. Oleh karena itu, penggunaan lima rekomendasi teratas (*Top-5*) dipilih untuk merepresentasikan kondisi penggunaan sistem secara nyata sekaligus mengevaluasi kemampuan model dalam menempatkan kandidat yang relevan pada posisi peringkat teratas.


Selain evaluasi berbasis data acuan (*Ground truth*) menggunakan 95 dokumen CV yang telah diverifikasi oleh tim HRD, penelitian ini juga melakukan evaluasi tambahan terhadap *Dataset* penuh yang mencakup seluruh 851 dokumen CV unik dari 26 posisi jabatan aktif di Kalla Aspal. Evaluasi tambahan ini dilakukan menggunakan metrik *Information Retrieval* yang sama, yaitu MRR, ARHR@5, nDCG@5, *Precision@5*, *Recall@5*, dan *F1@5*, dengan tetap menggunakan data acuan 95 kandidat *Ground truth* sebagai referensi relevansi. Tujuan dari evaluasi ini adalah untuk menguji *robustness* dan kemampuan generalisasi kedua model pada kondisi yang lebih mendekati skenario rekrutmen nyata, di mana sistem harus membedakan kandidat yang relevan dari seluruh pelamar aktif secara bersamaan. Kondisi ini secara signifikan meningkatkan tingkat persaingan antar kandidat dalam

proses pemeringkatan, sehingga memberikan gambaran yang lebih realistis mengenai kemampuan masing-masing model dalam menghadapi volume data rekrutmen sesungguhnya. Waktu proses komputasi pada kedua skenario evaluasi juga diukur dan dibandingkan sebagai aspek tambahan dalam penilaian kinerja model secara menyeluruh.

2.7 Tahap Implementasi Model dan Perancangan Sistem

Setelah melakukan pengujian antara model *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE), alur penelitian dilanjutkan ke tahap implementasi model dan perancangan sistem. Pada tahap ini, model *embedding* NLP dengan performa terbaik berdasarkan hasil evaluasi pada enam metrik *Information Retrieval* (IR) diintegrasikan ke dalam sebuah Sistem Pendukung Keputusan (SPK) rekrutmen berbasis *website* guna melakukan otomatisasi *screening* dokumen *Curriculum Vitae* (CV) terhadap *Job Profile* secara *real-time*.

Alur proses implementasi sistem yang dikembangkan dalam penelitian ini ditunjukkan pada Gambar 7. Diagram tersebut menggambarkan keseluruhan tahapan pemrosesan, mulai dari unggah dokumen CV dan *Job Profile*, ekstraksi dan *preprocessing* teks, pembentukan komponen (pendidikan, pengalaman, kemampuan), pembentukan *embedding vector* menggunakan model terbaik, perhitungan *Cosine similarity* per komponen, perhitungan skor akhir berbasis pembobotan (*weighted sum score*), hingga pemeringkatan kandidat yang ditampilkan melalui *Dashboard* Streamlit dengan tiga mode tampilan: *Single CV*, *Leaderboard*, dan *Bulk CV*.




Gambar 7. Alur Sistem Penilaian Kesesuaian CV dan *Job Profile*

Proses pengembangan ini bertujuan untuk menjembatani kompleksitas arsitektur model NLP dengan pengguna akhir, sehingga proses seleksi administrasi rekrutmen pada Kalla Aspal dapat dilakukan secara praktis dan mudah. Pengembangan antarmuka pengguna (*user interface*) dibangun menggunakan bahasa pemrograman Python dengan memanfaatkan *framework* Streamlit. Rincian implementasi model dan arsitektur perancangan setiap komponen halaman *Dashboard* dijabarkan sebagai berikut.

2.7.1 Implementasi Model Terbaik

Penentuan model yang ditanamkan ke dalam sistem didasarkan pada hasil perbandingan kinerja *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE) yang telah dilakukan pada tahap sebelumnya. Perbandingan dilakukan berdasarkan kemampuan masing-masing model dalam menghasilkan skor kemiripan semantik (*Cosine similarity*), waktu proses komputasi, serta efektivitas pemeringkatan rekomendasi menggunakan metrik *Information Retrieval* yang meliputi *Mean Reciprocal Rank* (MRR), *Average Reciprocal Hit Rank* (ARHR@5), *Normalized Discounted Cumulative Gain* (nDCG@5), *Precision@5*, *Recall@5*, dan *F1@5*. Nilai metrik tersebut diperoleh melalui proses evaluasi terhadap data acuan (*Ground truth*) yang telah dilabeli oleh tim HRD Kalla Aspal.

Model yang memperoleh performa terbaik pada mayoritas metrik evaluasi kemudian dipilih sebagai model terbaik (*selected model*) dan diintegrasikan ke dalam Sistem Pendukung Keputusan (SPK) rekrutmen. Alur pemilihan model terbaik ditunjukkan pada Gambar 8.




Gambar 8. Alur Pemilihan Model Terbaik Berdasarkan Hasil Evaluasi

Gambar 8 menunjukkan tahapan pemilihan model yang digunakan dalam sistem. Proses diawali dengan penyandian teks CV dan *Job Profile* menggunakan model SBERT dan USE untuk menghasilkan representasi vektor (*embedding*). Representasi vektor tersebut kemudian digunakan dalam perhitungan *Cosine similarity* untuk memperoleh skor kesesuaian antara CV dan *Job Profile*. Skor kesesuaian yang dihasilkan selanjutnya digunakan untuk menyusun pemeringkatan rekomendasi pekerjaan.

Hasil pemeringkatan kemudian dievaluasi menggunakan data acuan (*Ground truth*) yang telah dilabeli oleh tim HRD Kalla Aspal melalui metrik *MRR*, *ARHR@5*, *nDCG@5*, *Precision@5*, *Recall@5*, dan *F1@5*. Selain itu, waktu proses komputasi masing-masing model juga diukur sebagai salah satu aspek perbandingan kinerja. Hasil evaluasi kedua model kemudian dibandingkan untuk menentukan model yang memperoleh performa terbaik pada mayoritas metrik evaluasi. Model tersebut selanjutnya dipilih sebagai model terbaik (*selected model*) dan digunakan pada tahap implementasi sistem.

2.7.2 Tampilan Halaman Awal *Dashboard*

Tampilan awal aplikasi saat pertama kali diakses oleh pengguna dirancang sebagai beranda panduan interaktif bagi tim HRD Kalla Aspal. Rancangan tata letak visual untuk komponen halaman beranda awal ini ditunjukkan pada Gambar 9.




Gambar 9. Rancangan Halaman Beranda *Dashboard* SPK

Halaman ini menyajikan deskripsi umum mengenai fungsionalitas sistem, tujuan pengembangan kecerdasan buatan dalam mempermudah pencocokan dokumen, serta rangkuman panduan operasional dari tiga menu utama aplikasi.

2.7.3 Tampilan Halaman *Single CV*

Struktur rancangan antarmuka untuk halaman ini dapat dilihat pada Gambar 10.




Gambar 10. Rancangan Halaman *Single CV*

Halaman *Single CV* dirancang khusus untuk memfasilitasi kebutuhan pengguna dalam melakukan analisis mendalam terhadap satu berkas kandidat secara lebih fokus dan terperinci. Antarmuka pada halaman ini menyediakan beberapa komponen visual utama, antara lain kartu metrik skor kecocokan (*matching score*) global, visualisasi grafik batang untuk rincian skor parsial per komponen penilaian (pendidikan, pengalaman, dan kemampuan), informasi detail kualifikasi akademik pelamar, identifikasi posisi jabatan terbaik pelamar (*Best Job Match*), tombol integrasi pesan WhatsApp untuk keperluan pemanggilan kandidat secara langsung, tabel interaktif yang menyajikan daftar 5 besar rekomendasi jabatan teratas (*Top-5 Job*), serta kolom teks narasi yang memuat analisis dan saran pengembangan kompetensi kandidat.

2.7.4 Tampilan Halaman *Leaderboard Mode Single CV*

Detail rancangan antarmuka untuk halaman peringkat ini dapat dilihat pada Gambar 11.




Gambar 11. Rancangan Halaman Peringkat (*Leaderboard*) Mode *Single CV*

Halaman ini menyajikan laporan peringkat kumulatif seluruh kandidat berdasarkan riwayat pemrosesan dokumen pada mode *Single CV*. Menu ini dilengkapi dengan grafik batang dinamis yang menampilkan persentase skor kecocokan, serta tabel detail peringkat yang dapat disaring berdasarkan kriteria

tertentu. Tersedia juga tombol WhatsApp langsung di setiap baris kandidat untuk mempermudah komunikasi. Halaman ini dirancang untuk membantu tim HRD membandingkan kompetensi antarpelamar secara cepat dan efisien.

2.7.5 Tampilan Halaman *Leaderboard* Mode *Bulk CV*

Rancangan visual komponen halaman peringkat berkas massal ini ditunjukkan secara eksplisit pada Gambar 12.




Gambar 12. Rancangan Halaman Peringkat (*Leaderboard*) Mode *Bulk CV*

Memiliki struktur fungsional yang serupa dengan menu peringkat sebelumnya, halaman *Leaderboard* Mode *Bulk CV* dirancang khusus untuk menyajikan hasil analisis berkas pelamar yang diproses secara massal. Antarmuka halaman ini menampilkan visualisasi grafik batang performa kelompok serta tabel detail peringkat dari seluruh dokumen PDF pelamar yang diekstraksi langsung dari folder posisi jabatan terkait. Halaman ini mempermudah tim HRD dalam meninjau dan membandingkan kompetensi kandidat dalam skala besar secara efisien.

2.7.6 Tampilan Halaman *Bulk CV* Mode Otomatis

Desain visual untuk halaman mode otomatis ini tertera pada Gambar 13.




Gambar 13. Rancangan Halaman *Bulk CV* (Mode Otomatis)

Halaman ini merepresentasikan implementasi mode analisis otomatis dalam menangani pemrosesan banyak berkas CV sekaligus secara massal. Pada mode otomatis ini, sistem secara mandiri memproses seluruh berkas PDF pelamar yang diunggah secara bersamaan, kemudian algoritma model NLP secara otomatis akan mendeteksi dan mengelompokkan posisi jabatan staf yang paling relevan bagi masing-masing pelamar. Antarmuka halaman ini dikonstruksikan dengan memuat kartu informasi ringkasan berkas CV terbaik, indikator skor tertinggi, total file terunggah, grafik distribusi skor, tabel rekapitulasi penilaian keseluruhan, serta visualisasi kartu pengelompokan sebaran deteksi posisi pelamar.

2.7.7 Tampilan Halaman *Bulk CV* Mode Manual

Struktur antarmuka fungsional pada mode manual ini disajikan secara jelas pada Gambar 14.



Gambar 14. Rancangan Halaman *Bulk CV* (Mode Manual)

Sebagai alternatif pemrosesan massal, halaman ini menyediakan mode analisis manual yang memfasilitasi pengguna untuk menetapkan satu posisi jabatan target secara spesifik terlebih dahulu melalui komponen bilah samping (*sidebar*). Setelah posisi dikunci, pengguna dapat mengunggah tumpukan berkas PDF kandidat untuk diseleksi secara massal khusus pada formasi jabatan tersebut. Halaman ini menyajikan kartu ringkasan hasil skrining massal, grafik distribusi skor kelompok, dan tabel detail penilaian keseluruhan pelamar.

2.8 Tahap Pengujian Sistem

Tahap pengujian sistem merupakan fase krusial guna memastikan bahwa Sistem Pendukung Keputusan (SPK) *screening Curriculum Vitae* (CV) yang telah dibangun dapat berfungsi dengan baik sebelum diimplementasikan secara penuh. Pada penelitian ini, pengujian sistem dilakukan menggunakan metode *Black-Box Testing*. Metode ini berfokus pada pengujian fungsionalitas sistem berdasarkan kesesuaian antara masukan (*input*) dan keluaran (*output*) yang dihasilkan tanpa memperhatikan struktur kode program maupun proses komputasi internal model.

Tujuan utama dari pengujian ini adalah memvalidasi bahwa seluruh fitur pada *Dashboard* Streamlit dapat beroperasi sesuai dengan kebutuhan pengguna serta bebas dari kesalahan teknis (*bug*). Untuk mencapai tujuan tersebut, pengujian

dilakukan terhadap 17 skenario fungsional yang mencakup seluruh fitur utama sistem, yaitu halaman Beranda, *Single CV*, *Leaderboard*, dan *Bulk CV*. Rincian skenario pengujian pada masing-masing halaman dijelaskan sebagai berikut.

2.8.1 Skenario Pengujian Halaman Beranda

Pengujian pada halaman Beranda dilakukan untuk memastikan bahwa sistem dapat menampilkan halaman awal aplikasi dengan baik ketika diakses oleh pengguna. Fokus pengujian mencakup validasi tampilan deskripsi sistem, informasi penggunaan aplikasi, serta navigasi menuju halaman-halaman utama yang tersedia pada *Dashboard*.

2.8.2 Skenario Pengujian Halaman *Single CV*

Pengujian pada halaman ini dilakukan untuk memastikan sistem mampu menerima masukan berupa satu berkas dokumen CV dalam format PDF, melakukan ekstraksi teks secara *real-time*, dan menghasilkan *output* analisis individu secara tepat. Skenario pengujian meliputi validasi keberhasilan komponen pengunggah berkas (*file uploader*) dalam membaca dokumen PDF kandidat, pengujian ketepatan sistem dalam menampilkan grafik batang skor kecocokan parsial yang mencakup aspek pendidikan, pengalaman, dan kemampuan, validasi kartu metrik skor global, pengujian tombol integrasi WhatsApp, verifikasi ketepatan tabel rekomendasi *Top-5* Job, serta validasi tampilan kolom narasi analisis dan saran pengembangan kompetensi kandidat.

2.8.3 Skenario Pengujian Halaman *Leaderboard*

Pengujian pada halaman *Leaderboard* dilakukan untuk memvalidasi fungsi manajemen data dan visualisasi peringkat kumulatif pelamar, mencakup validasi fitur penyaringan (*filter*) berdasarkan posisi jabatan, pengujian tombol penyegaran (*refresh*) data, verifikasi ketepatan pengurutan tabel peringkat berdasarkan skor kecocokan, serta pengujian fungsi tombol integrasi WhatsApp pada mode *Single CV*.

2.8.4 Skenario Pengujian Halaman *Bulk CV*

Halaman pemrosesan massal memerlukan pengujian yang lebih intensif karena menangani banyak dokumen PDF secara bersamaan. Pengujian pada halaman ini dibagi menjadi dua mode, yaitu mode otomatis dan mode manual.

Pada mode otomatis, pengujian dilakukan untuk memastikan sistem dapat menerima unggahan massal dokumen PDF, melakukan ekstraksi teks secara bersamaan, mendeteksi posisi jabatan yang paling relevan untuk setiap kandidat, serta menampilkan grafik distribusi skor dengan benar.

Sementara itu, pada mode manual, pengujian dilakukan untuk memastikan sistem dapat mengunci satu posisi jabatan tertentu yang dipilih pengguna melalui *sidebar*, menghitung skor kesesuaian seluruh kandidat terhadap posisi tersebut, dan menampilkan hasil penilaian dalam bentuk tabel peringkat secara akurat.

BAB III

HASIL DAN PEMBAHASAN

3.1 Hasil Pra-pemrosesan Data

Tahap pra-pemrosesan data merupakan langkah awal yang krusial dalam penelitian ini sebelum dilakukan proses perhitungan kemiripan semantik dan evaluasi model. Tujuan utama dari tahap ini adalah memastikan bahwa dokumen *Curriculum Vitae* (CV) kandidat pelamar kerja dan dokumen *Job Profile* pada Kalla Aspal dapat ditransformasikan dan direpresentasikan ke dalam format teks terstruktur yang bersih, konsisten, dan siap digunakan sebagai masukan (*input*) bagi model *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE).

Sebagaimana telah diuraikan pada proses pembersihan dan validasi data, *Dataset* bersih yang dihasilkan berjumlah 851 dokumen CV unik yang tersebar ke dalam 26 posisi jabatan aktif, termasuk di dalamnya 95 dokumen *Ground truth* yang telah bebas dari duplikasi. *Dataset* inilah yang selanjutnya digunakan sebagai masukan dalam seluruh tahapan pra-pemrosesan berikut. Proses penataan ini mengikuti tiga tahapan utama, yaitu: (1) ekstraksi informasi CV, (2) pengolahan data *Job Profile*, dan (3) pembentukan representasi teks.

3.1.1 Hasil Ekstraksi Informasi *Curriculum Vitae* (CV)

Proses ekstraksi informasi dari berkas dokumen CV dilakukan menggunakan pustaka Python PyMuPDF. Tahapan ini berhasil mencapai tingkat keberhasilan 100% pada seluruh sampel yang berjumlah 851 dokumen CV. Tingkat keberhasilan yang mutlak ini disebabkan oleh seluruh dokumen yang digunakan telah memenuhi batas operasional penelitian yang ditentukan, yaitu berupa dokumen PDF berbasis teks (*text-based PDF*) dan bukan merupakan dokumen hasil pemindaian (*scanned PDF*).

Teks hasil ekstraksi kasar tersebut kemudian diproses melalui tahapan pembersihan teks (*text cleaning*) sesuai dengan arsitektur sistem yang dibangun. Tahapan ini mencakup konversi huruf menjadi kecil keseluruhan (*lowercasing*), penghapusan karakter baris baru (*newline*), serta normalisasi tanda baca seperti titik koma, titik dua, tanda kurung, garis vertikal, dan karakter khusus lainnya. Sistem juga menghapus informasi periode kerja berbasis bulan dan tahun menggunakan pendekatan *regular expression* (Regex), serta menghilangkan kata-kata struktural (seperti “masuk”, “mulai”, “deskripsi”, “tanggung jawab”, “selesai”, dan “sekarang”) agar teks hasil ekstraksi lebih padat dan fokus pada substansi isi pengalaman kandidat. Selanjutnya, teks dipisah menggunakan pendekatan *keyword-based section extraction* melalui fungsi *parse_cv_structured* menjadi tiga komponen yaitu *edu*, *exp*, dan *skill*.

Karena masih berbahasa Indonesia, ketiga komponen ini kemudian diterjemahkan ke bahasa Inggris menggunakan model *pre-trained Helsinki-NLP/opus-mt-id-en* (*Hugging Face Transformers*). Penerjemahan otomatis ini diperlukan agar teks CV berada pada domain bahasa yang sama dengan model representasi teks (SBERT dan USE) yang dilatih pada korpus berbahasa Inggris,

sehingga menghasilkan representasi vektor semantik yang lebih akurat. Hasil akhirnya berupa data terstruktur berbahasa Inggris yang siap digunakan pada tahap perhitungan kemiripan. Ringkasan sampelnya disajikan pada Tabel 11.

Tabel 11. Hasil Ekstraksi Informasi CV Kandidat

Nama CV	Pendidikan (edu)	Pengalaman (exp)	Kemampuan (skill)
a7271043110030002.pdf	senior high school	Internship / ojt pt. Earth's main means the current fleet driver is still working as an internship/ojtp. earth's major system driver dismissed due to the reduction of employee entry level/ staff, our pt anist.was our work driver	Drivers really like driving jobs.
a7326016010980002.pdf	bachelor's degree, Law	Associate/ supervisory, section head pt wings solar supervisor sales becomes leader teams that carry 8 salesmen, 2 spgs, and 4 merchandise, breakdown team targets to per sales, support sales and spg in reaching targets, select potential applicants spg each event, establish good communication with customeres and help sales to deal with the customer, oversee the merchandising display. Entical/ staff, anesst pst bank marches like a loan, insurance against loans, and do collections against mortgages. Atmakhiare community	Indonesia is an expensive level of advertising, finance / banking because I currently work in finance. marketing because according to my experience working as marketing in the people's banks legal, hrd because it corresponds to my major as a law major.

Nama CV	Pendidikan (edu)	Pengalaman (exp)	Kemampuan (skill)
		students. Spiritual services, making appointments, meetings, rites, rituals, practices for university performances, college studies.	

Data pada Tabel 11 menunjukkan sampel hasil ekstraksi dan terjemahan CV kandidat setelah melalui tahapan *text cleaning*, penataan berbasis kata kunci ke dalam tiga komponen utama (*edu*, *exp*, dan *skill*), serta penerjemahan ke bahasa Inggris menggunakan model *Helsinki-NLP/opus-mt-id-en*. Proses ini mengubah data teks tidak terstruktur dan berbahasa Indonesia menjadi format yang lebih konsisten dan selaras dengan bahasa yang dibutuhkan model SBERT dan USE, yang bekerja optimal pada teks berbahasa Inggris. Hasil terjemahan inilah yang digunakan sebagai *input* pada tahap komputasi nilai kemiripan semantik.

3.1.2 Hasil Pengolahan Data *Job Profile*

Dokumen *Job Profile* dari tim HRD Kalla Aspal diolah menjadi data terstruktur berisi komponen pendidikan, pengalaman, dan kemampuan. Berbeda dengan CV yang diterjemahkan secara otomatis di dalam sistem menggunakan model *Helsinki-NLP/opus-mt-id-en*, data *Job Profile* sejak awal disusun langsung dalam bahasa Inggris ke berkas CSV pada tahap penyiapan data, tanpa melalui model penerjemahan, guna menghemat waktu komputasi karena proses ini cukup dilakukan sekali di awal. Hasil pengolahan tersebut disajikan pada Tabel 12, yang menampilkan dua dari 26 *Job Profile* yang digunakan dalam penelitian ini, yaitu *Tanker Truck Driver* dan *Sales Staff*, sebagai representasi hasil akhir pengolahan data.

Tabel 12. Hasil Pengolahan Data *Job Profile*

Komponen	<i>Tanker Truck Driver</i>	<i>Sales Staff</i>
Pendidikan	junior high school / senior high school / vocational school, all majors	bachelor's degree, all majors
Pengalaman	experience as a driver, ensure that asphalt order delivery activities to customers are fulfilled on time.	fresh graduate / experience in the sales field, ensure the availability of accurate data and complete sales documents to facilitate smooth operations in bulk asphalt sales.

Komponen	<i>Tanker Truck Driver</i>	<i>Sales Staff</i>
Kemampuan	ability to drive trucks, possess a valid heavy vehicle license sim b2 umum, ability to understand traffic signs, understanding of geographical coverage, tyre changer skills, active indonesia, ensure asphalt order delivery activities to customers are carried out punctually according to schedule, check vehicle engine conditions, and coordinate with the bitumen delivery supervisor or balance & boiler operator before delivery, inspect storage tanks to ensure asphalt quantities match customer orders, perform asphalt delivery using the prepared vehicle, and ensure the distribution process is executed within the specified time limits, monitor asphalt conditions inside the tank during delivery, perform heating if necessary so asphalt temperature remains up to standard, and ensure asphalt cargo is unloaded according to customer orders, execute asphalt loading and unloading processes according to safety standards using full ppe, ensure customers sign dos or baps upon asphalt reception, and ensure delivery administration runs properly, return the vehicle to the bulk asphalt terminal after delivery processes are completed, ensure fleet cleanliness is maintained, study hazard identification within the work scope, and take	it skills, company product knowledge, understanding company business processes, knowledge of using asphalt for hotmix, marketing knowledge, strong communication and interpersonal skills, active english, ensure asphalt sales processes run according to company procedures, send bidding proposals to contractors, and ensure the completeness of sales data and documents to support smooth bulk asphalt sales, convey information to the tac for tank truck loading followup and distribution to customers, execute asphalt sales, and coordinate with the finance department to prepare customer payment billing documents, provide customers with info regarding asphalt price updates, ensure customer payment processes run smoothly and on time, and remind customers of applicable payment deadlines, conduct collection of receivables and guarantees from customers, coordinate with the finance department regarding unpaid receivables, and compile competitor activities regarding asphalt sales for company evaluation, ensure work execution complies with qhse/k3 standards, study hazard identification within the work scope, and take preventative

Komponen	<i>Tanker Truck Driver</i>	<i>Sales Staff</i>
	preventative measures against workplace risks.	measures against workplace risks according to company procedures.

Melalui visualisasi data pada Tabel 12 dapat dilihat bahwa informasi pada dokumen *Job Profile* telah terstruktur ke dalam komponen pendidikan, pengalaman, dan kemampuan yang selaras dengan struktur data CV pelamar. Keselarasan struktur ini penting agar proses perhitungan kemiripan antara CV kandidat dan *Job Profile* dilakukan pada dimensi informasi yang sebanding saat direpresentasikan menggunakan model *embedding*.

3.1.3 Hasil Pembentukan Representasi Teks

Tahap ini menghasilkan pasangan data terstruktur antara CV kandidat (hasil ekstraksi, *cleaning*, dan penerjemahan otomatis) dan *Job Profile* (hasil ekstraksi, dengan teks yang sudah berbahasa Inggris sejak penyiapan CSV). Setiap komponen CV dipasangkan dengan komponen bersesuaian pada *Job Profile*, dengan kedua sisi pasangan sama-sama berbahasa Inggris, sehingga siap digunakan pada perhitungan kemiripan. Contoh hasil pasangan disajikan pada Tabel 13.

Tabel 13. Hasil Pasangan Komponen Teks Hasil Pra-pemrosesan Akhir

Komponen	CV Kandidat (a7271043110030002.pdf)	<i>Job Profile</i> (<i>tanker truck driver</i>)
Pendidikan	senior high school	junior high school / senior high school / vocational school, all majors
Pengalaman	Internship / ojt pt. Earth's main means the current fleet driver is still working as an internship/ojtp. earth's major system driver dismissed due to the reduction of employee entry level/ staff, our pt anist.was our work driver.	experience as a driver, ensure that asphalt order delivery activities to customers are fulfilled on time.
Kemampuan	Drivers really like driving jobs.	ability to drive trucks, possess a valid heavy vehicle license sim b2 umum, ability to understand traffic signs, understanding of geographical coverage, tyre changer skills, active indonesia, ensure asphalt order delivery activities to customers are carried out punctually according to schedule, check vehicle engine

Komponen	CV Kandidat (a7271043110030002.pdf)	<i>Job Profile</i> (<i>tanker truck driver</i>)
		conditions, and coordinate with the bitumen delivery supervisor or balance & boiler operator before delivery, inspect storage tanks to ensure asphalt quantities match customer orders, perform asphalt delivery using the prepared vehicle, and ensure the distribution process is executed within the specified time limits, monitor asphalt conditions inside the tank during delivery, perform heating if necessary so asphalt temperature remains up to standard, and ensure asphalt cargo is unloaded according to customer orders, execute asphalt loading and unloading processes according to safety standards using full ppe, ensure customers sign dos or baps upon asphalt reception, and ensure delivery administration runs properly, return the vehicle to the bulk asphalt terminal after delivery processes are completed, ensure fleet cleanliness is maintained, study hazard identification within the work scope, and take preventative measures against workplace risks.

Berdasarkan Tabel 13 informasi pendidikan, pengalaman, dan kemampuan pada CV kandidat telah dipasangkan dengan komponen yang sesuai pada *Job Profile*. Hasil pasangan data tersebut menjadi masukan bagi model *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE) untuk menghasilkan representasi vektor (*embedding*). Representasi vektor yang dihasilkan selanjutnya digunakan dalam proses perhitungan tingkat kemiripan, pembentukan skor kecocokan berdasarkan pembobotan komponen, serta pemeringkatan kandidat berdasarkan tingkat kesesuaiannya terhadap *Job Profile* yang dievaluasi.

3.2 Hasil Perbandingan dan Evaluasi Model


Tahap ini merupakan inti eksperimen penelitian, yaitu membandingkan kinerja model *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE) dalam menilai kesesuaian CV kandidat terhadap *Job Profile* menggunakan *Dataset* dari Kalla Aspal. Evaluasi dilakukan berdasarkan tiga aspek utama, yaitu nilai *Cosine*

similarity yang dihasilkan, waktu proses komputasi, serta kualitas pemeringkatan rekomendasi menggunakan enam metrik *Information Retrieval*, yaitu *Mean Reciprocal Rank* (MRR), *Average Reciprocal Hit Rank* (ARHR@5), *Normalized Discounted Cumulative Gain* (nDCG@5), *Precision@5*, *Recall@5*, dan *F1@5*.

3.2.1 Hasil Perhitungan *Cosine similarity* dan Skor Kecocokan

Pada tahap ini, seluruh komponen teks CV kandidat dan *Job Profile* yang telah melalui proses pra-pemrosesan diubah menjadi representasi vektor (*embedding*) menggunakan masing-masing model. Model *Sentence-BERT* (SBERT) menghasilkan representasi vektor berdimensi 384 menggunakan model *all-MiniLM-L6-v2*, sedangkan *Universal Sentence Encoder* (USE) menghasilkan representasi vektor berdimensi 512 menggunakan model *Universal Sentence Encoder v4* berbasis *Transformer*.

Selanjutnya, nilai *Cosine similarity* dihitung antara vektor CV dan vektor *Job Profile* untuk setiap komponen penilaian, yaitu pendidikan, pengalaman, dan kemampuan. Ketiga nilai kemiripan tersebut kemudian digabungkan menggunakan skema pembobotan yang telah ditetapkan, yaitu 10% untuk pendidikan, 40% untuk pengalaman, dan 50% untuk kemampuan. Proses penggabungan skor ini menghasilkan nilai kecocokan akhir (*final matching score*) yang digunakan sebagai dasar pemeringkatan kandidat terhadap setiap posisi jabatan. Proses pembentukan skor kecocokan akhir ditunjukkan pada Gambar 15.



Gambar 15. Proses Perhitungan Skor Kecocokan Akhir

Khusus komponen pendidikan, 14 dari 26 posisi berkualifikasi "Semua Jurusan" dinilai dengan *rule-based scoring* (0.8 jika memenuhi jenjang minimum, 0.4 jika tidak), sedangkan 12 posisi sisanya yang mensyaratkan jurusan spesifik tetap dinilai menggunakan *Cosine similarity* seperti biasa. Pendekatan *hybrid* ini diterapkan untuk menghindari bias semantik antara jurusan umum dan spesifik. *Final matching score* dari kedua pendekatan tersebut dipakai untuk pemeringkatan kandidat, dan rata-rata skor terhadap *Ground truth* disajikan pada Tabel 14.

Tabel 14. Perbandingan Rata-Rata Skor Kecocokan (*Avg True Score*)

Model	<i>Avg True Score (%)</i>
<i>Sentence-BERT (SBERT)</i>	44.16%
<i>Universal Sentence Encoder (USE)</i>	35.33%
Selisih	8.83%

Tabel 14 menunjukkan bahwa model SBERT memperoleh rata-rata skor kecocokan sebesar 44.16%, sedangkan USE memperoleh 35.33% dengan selisih 8.83% yang menunjukkan SBERT menghasilkan tingkat kecocokan lebih tinggi pada data rekrutmen yang digunakan dalam penelitian ini. Namun, rata-rata skor kecocokan belum cukup menggambarkan kualitas pemeringkatan kandidat secara menyeluruh, sehingga evaluasi lanjutan menggunakan metrik *Information Retrieval* dilakukan untuk menilai kemampuan kedua model dalam menempatkan kandidat relevan pada posisi peringkat teratas.

3.2.2 Hasil Pengukuran Waktu Proses Komputasi

Selain kualitas hasil pemeringkatan, waktu proses komputasi juga diukur sebagai salah satu aspek perbandingan kinerja antara kedua model. Pengukuran dilakukan terhadap total waktu yang dibutuhkan oleh masing-masing model untuk memproses 95 dokumen CV *Ground truth* terhadap 26 *Job Profile* yang tersedia pada lingkungan lokal (*CPU-bound*). Perbandingan waktu komputasi kedua model disajikan pada Tabel 15.

Tabel 15. Perbandingan Waktu Proses Komputasi SBERT dan USE


Model	Total Process Time (detik)	<i>Avg Process Time per Dokumen (detik)</i>
<i>Sentence-BERT (SBERT)</i>	5.8235	0.0613
<i>Universal Sentence Encoder (USE)</i>	6.0395	0.0636

Tabel 15 menunjukkan bahwa SBERT memproses seluruh *Dataset Ground truth* dalam total waktu 5.8235 detik (rata-rata 0.0613 detik per dokumen), sedangkan USE membutuhkan 6.0395 detik (rata-rata 0.0636 detik per dokumen). SBERT justru tercatat sedikit lebih cepat, dengan selisih sekitar 0.216 detik, selisih yang relatif tipis dan dapat bervariasi tergantung kondisi lingkungan eksekusi seperti spesifikasi perangkat keras dan konektivitas jaringan.

Perbedaan ini perlu dikontekstualisasikan dengan beban pemrosesan yang ditangani. Dalam konteks rekrutmen nyata di Kalla Aspal yang memproses ratusan dokumen CV, baik SBERT maupun USE sama-sama mampu menyelesaikan *screening* seluruh *Dataset* dalam hitungan detik, menunjukkan efisiensi komputasi yang secara praktis memadai untuk kebutuhan operasional sistem, dengan SBERT unggul tipis pada pengujian ini.

3.2.3 Hasil Evaluasi Metrik *Information Retrieval*

Evaluasi utama kinerja model dilakukan menggunakan enam metrik *Information Retrieval* yang dibandingkan terhadap data acuan (*Ground truth*) yang telah ditetapkan oleh tim HRD Kalla Aspal. Metrik yang digunakan meliputi *Mean Reciprocal Rank* (MRR), *Average Reciprocal Hit Rank* (ARHR@5), *Normalized Discounted Cumulative Gain* (nDCG@5), *Precision@5*, *Recall@5*, dan *F1@5*. Hasil evaluasi lengkap kedua model disajikan pada Gambar 16.



Gambar 16. Perbandingan Metrik *Information Retrieval* pada Data *Ground truth*

Berdasarkan Gambar 16, SBERT secara konsisten mengungguli USE pada seluruh enam metrik evaluasi. Pembahasan hasil masing-masing metrik diuraikan sebagai berikut.

1. *Mean Reciprocal Rank* (MRR)

SBERT memperoleh nilai MRR sebesar 0.6225, melampaui USE yang mencapai 0.5756. Nilai MRR SBERT yang mendekati 0.63 menunjukkan bahwa secara rata-rata, sistem berhasil menempatkan kandidat relevan pertama pada posisi peringkat yang cukup tinggi dalam daftar rekomendasi. Hal ini berarti dalam sebagian besar kasus, kandidat yang ditetapkan sebagai *Ground truth* oleh tim HRD berhasil muncul pada peringkat awal dari daftar kandidat yang direkomendasikan oleh SBERT. Sementara itu, nilai MRR USE yang sedikit lebih rendah menunjukkan bahwa kandidat relevan pertama rata-rata muncul pada posisi peringkat yang sedikit lebih rendah dibandingkan SBERT.

2. *Average Reciprocal Hit Rank* (ARHR@5)

SBERT memperoleh nilai ARHR@5 sebesar 0.6153, dibandingkan USE yang mencapai 0.5516. Nilai ARHR@5 SBERT yang lebih tinggi menunjukkan bahwa model ini lebih mampu menempatkan seluruh kandidat relevan, bukan hanya yang pertama, pada posisi peringkat yang lebih tinggi dalam lima rekomendasi teratas. Perbedaan ini mengindikasikan bahwa SBERT relatif lebih efektif dalam mempertahankan kualitas pemeringkatan secara menyeluruh untuk semua kandidat relevan yang tersedia dalam *Dataset*.

3. *Normalized Discounted Cumulative Gain (nDCG@5)*

SBERT memperoleh nilai $nDCG@5$ sebesar 0.6948, sedangkan USE memperoleh 0.6088. Nilai $nDCG@5$ SBERT yang mendekati 0.70 mengindikasikan bahwa urutan pemeringkatan yang dihasilkan oleh SBERT cukup mendekati urutan ideal (*ideal ranking*), yaitu kondisi ketika seluruh kandidat relevan ditempatkan pada posisi paling atas. Dengan kata lain, SBERT tidak hanya berhasil menemukan kandidat yang relevan, tetapi juga cenderung mengurutkannya lebih sesuai dengan tingkat relevansinya dibandingkan USE.

4. *Precision@5*

SBERT memperoleh nilai $Precision@5$ sebesar 0.1874, sedangkan USE memperoleh 0.1558. Nilai ini muncul karena setiap data uji *Ground truth* hanya memiliki satu kandidat relevan, sehingga $Precision@5$ untuk masing-masing data uji hanya dapat bernilai 0.2 (apabila kandidat relevan tersebut berhasil masuk ke dalam *Top-5* rekomendasi) atau 0 (apabila tidak). Nilai agregat kemudian diperoleh dengan merata-ratakan hasil dari seluruh 95 data uji *Ground truth*. Dengan demikian, nilai 0.1874 pada SBERT setara dengan keberhasilan menemukan sekitar 93.68% kandidat *Ground truth* dalam *Top-5* rekomendasi. Hal ini karena pada skema evaluasi dengan satu kandidat relevan per data uji, $Precision@5$ pada dasarnya merupakan $Recall@5$ dibagi lima. SBERT unggul sekitar 20.3% dibandingkan USE pada metrik ini, menandakan proporsi kandidat relevan yang berhasil direkomendasikan pada lima posisi teratas relatif lebih besar pada SBERT.


5. *Recall@5*

SBERT memperoleh nilai $Recall@5$ sebesar 0.9368, melampaui USE yang hanya memperoleh 0.7789, selisih yang cukup signifikan di antara keduanya. Nilai *recall* yang diperoleh mencerminkan kemampuan sistem dalam menemukan kembali kandidat relevan dari seluruh *Ground truth* yang tersedia. Nilai $Recall@5$ SBERT yang lebih tinggi menunjukkan bahwa model ini lebih mampu menjangkau kandidat-kandidat relevan yang tersebar dalam *Dataset* dan memasukkan mereka ke dalam lima rekomendasi teratas, sehingga risiko melewatkan kandidat potensial yang sebenarnya sesuai dengan kebutuhan jabatan menjadi lebih kecil.

6. *F1@5*

SBERT memperoleh nilai $F1@5$ sebesar 0.3122, sedangkan USE memperoleh 0.2596, atau SBERT unggul sekitar 20.3% dibandingkan USE. Sebagai rata-rata harmonik antara $Precision@5$ dan $Recall@5$, nilai $F1@5$ SBERT yang lebih tinggi mengonfirmasi bahwa SBERT tidak hanya unggul pada salah satu aspek saja, melainkan secara seimbang unggul pada ketepatan (*precision*) maupun cakupan (*recall*) hasil rekomendasi yang dihasilkan.


Untuk memperdalam pemahaman mengenai distribusi kualitas pemeringkatan, Gambar 17 menyajikan sebaran peringkat kandidat *Ground truth* dalam daftar rekomendasi yang dihasilkan oleh masing-masing model.



Gambar 17. Sebaran Peringkat Kandidat *Ground truth*

Berdasarkan Gambar 17, performa kedua model dapat dianalisis melalui distribusi posisi peringkat (*ranking*) kandidat *Ground truth* pada hasil rekomendasi. Pada *Rank 1*, SBERT berhasil menempatkan 42 dari 95 kandidat (44.21%) secara langsung sebagai rekomendasi terbaik, sedangkan USE hanya 38 dari 95 kandidat (40.00%), menunjukkan SBERT lebih efektif menemukan dan mengamankan posisi kandidat relevan sejak peringkat pertama.

Namun, dalam skenario rekrutmen nyata, pembuat keputusan tidak hanya terpaku pada peringkat pertama, melainkan juga mempertimbangkan lima besar sebagai batas toleransi penyaringan awal yang ideal. Oleh karena itu, diperlukan analisis akumulatif untuk melihat seberapa banyak kandidat *Ground truth* yang berhasil dijangkau ke dalam zona aman tersebut, sebagaimana disajikan pada Gambar 18.



Gambar 18. Distribusi Kandidat *Ground truth* dalam *Top-5* Rekomendasi

Merujuk pada Gambar 18, SBERT semakin mempertegas keunggulannya dengan berhasil mencakup 89 dari 95 kandidat (93.68%) ke dalam batas *Top-5* rekomendasi. Sebaliknya, pada rentang kelompok yang sama, USE hanya mampu mencakup 74 dari 95 kandidat (77.89%). Selisih performa ini membuktikan bahwa SBERT memiliki konsistensi yang lebih tinggi dalam mendeteksi kedekatan makna kompetensi pelamar.

Selain itu, jika ditinjau pada sisa distribusi peringkat yang lebih rendah, terutama pada rentang *Rank* 6-26, SBERT hanya menyisakan 6 kasus (6.32%) kandidat *Ground truth* yang berada di luar *Top-5*. Hal ini berbeda dengan USE yang memiliki hingga 21 kasus (22.11%) kandidat relevan yang tercecer di peringkat bawah. Temuan tersebut menunjukkan bahwa USE lebih sering gagal menempatkan kandidat relevan pada posisi yang mudah dijangkau oleh perekrut, sementara SBERT lebih konsisten mempertahankan kandidat yang relevan pada peringkat yang lebih tinggi. Secara keseluruhan, hasil ini menegaskan bahwa SBERT memiliki kemampuan yang lebih baik dibandingkan USE dalam memahami kesesuaian semantik antara profil kandidat dan kebutuhan jabatan pada proses *screening* rekrutmen di Kalla Aspal.

3.2.4 Evaluasi pada *Dataset* Penuh (851 CV)

Untuk menguji *robustness* dan kemampuan generalisasi kedua model pada kondisi yang lebih mendekati skenario rekrutmen nyata, evaluasi tambahan dilakukan terhadap seluruh *Dataset* yang tersedia, yaitu 851 dokumen CV yang mencakup seluruh pelamar aktif dari 26 posisi jabatan di Kalla Aspal. Berbeda dengan evaluasi sebelumnya yang hanya melibatkan 95 dokumen CV *Ground truth* yang telah diverifikasi oleh tim HRD, evaluasi pada *Dataset* penuh ini mengikutsertakan seluruh dokumen CV yang ada dalam sistem, termasuk CV dari kandidat yang tidak termasuk dalam data acuan (*noise*). Kondisi ini secara signifikan meningkatkan tingkat persaingan antar kandidat dalam proses pemeringkatan, sehingga memberikan gambaran yang lebih realistis mengenai kemampuan kedua model dalam menghadapi volume data rekrutmen sesungguhnya. Hasil evaluasi kedua model pada *Dataset* penuh 851 CV disajikan pada Tabel 16.

Tabel 16. Hasil Evaluasi Metrik *Information Retrieval* pada *Dataset* Penuh

Metode Evaluasi	Sentence-BERT (SBERT)	Universal Sentence Encoder (USE)
MRR	0.3323	0.3237
ARHR@5	0.2822	0.2714
nDCG@5	0.3292	0.3178
Precision@5	0.0943	0.0920
Recall@5	0.4716	0.4598
F1@5	0.1572	0.1532
Avg True Score (%)	31.52%	21.87%
Total Process Time (detik)	53.6637	59.4915
Avg Process Time (detik)	0.0631	0.0698

Berdasarkan Tabel 16 terdapat beberapa temuan penting yang perlu diuraikan sebagai berikut.

1. Penurunan Performa Kedua Model

Dibandingkan dengan hasil evaluasi pada 95 CV *Ground truth*, kedua model mengalami penurunan nilai pada seluruh metrik *Information Retrieval* ketika diuji pada *Dataset* penuh 851 CV. SBERT mengalami penurunan nilai MRR dari 0.6225 menjadi 0.3323, sementara USE mengalami penurunan dari 0.5756 menjadi 0.3237. Penurunan serupa juga terjadi pada metrik nDCG@5, di mana SBERT turun dari 0.6948 menjadi 0.3292 dan USE turun dari 0.6088 menjadi 0.3178.

Penurunan performa ini merupakan fenomena yang wajar dan dapat dijelaskan secara teknis. Pada *Dataset* 95 CV *Ground truth*, seluruh dokumen yang dievaluasi merupakan kandidat yang telah diverifikasi relevansinya oleh tim HRD, sehingga tingkat persaingan antar kandidat relatif lebih terstruktur. Sebaliknya, pada *Dataset* penuh 851 CV, sistem harus membedakan kandidat *Ground truth* dari ratusan CV lain yang tidak relevan secara bersamaan. Kepadatan kandidat non-relevan yang jauh lebih tinggi ini menyebabkan proses pemerinkatan menjadi lebih sulit, karena model harus memilah sinyal kesesuaian semantik yang lebih lemah di antara *noise* yang lebih besar.

2. SBERT Tetap Unggul pada Seluruh Metrik IR

Meskipun kedua model mengalami penurunan performa, SBERT secara konsisten tetap mengungguli USE pada seluruh metrik *Information Retrieval* dalam pengujian *Dataset* penuh. Nilai MRR SBERT (0.3323) masih lebih tinggi dibandingkan USE (0.3237), begitu pula pada nDCG@5 (0.3292 vs 0.3178), Recall@5 (0.4716 vs 0.4598), dan F1@5 (0.1572 vs 0.1532). Konsistensi keunggulan SBERT pada kedua skenario pengujian ini memperkuat kesimpulan bahwa SBERT memiliki kemampuan diskriminasi semantik yang lebih andal dibandingkan USE, baik pada kondisi data terkontrol maupun pada kondisi data skala penuh.

Perbandingan performa kedua model antara evaluasi 95 CV *Ground truth* dan evaluasi *Dataset* penuh 851 CV disajikan secara berdampingan pada Tabel 17 untuk memudahkan analisis perubahan performa.

Tabel 17. Perbandingan SBERT dan USE untuk *Ground truth* dan Seluruh CV

Metrik	SBERT 95 GT	SBERT 851 CV	USE 95 GT	USE 851 CV
MRR	0.6225	0.3323	0.5756	0.3237
ARHR@5	0.6153	0.2822	0.5516	0.2714
nDCG@5	0.6948	0.3292	0.6088	0.3178
Precision@5	0.1874	0.0943	0.1558	0.0920
Recall@5	0.9368	0.4716	0.7789	0.4598
F1@5	0.3122	0.1572	0.2596	0.1532
Avg True Score (%)	44.16%	31.52%	35.33%	21.87%
Total Process Time (detik)	5.8235	53.6637	6.0395	59.4915

3. Fenomena Avg True Score pada Dataset Penuh

Temuan lain yang menarik perhatian pada evaluasi *Dataset* penuh adalah penurunan *Avg True Score* yang cukup besar pada kedua model. SBERT turun dari 44.16% menjadi 31.52% (selisih 12.64%, atau sekitar 28.6% secara relatif), sementara USE turun dari 35.33% menjadi 21.87% (selisih 13.46%, atau sekitar 38.1% secara relatif). Menariknya, selisih antara kedua model relatif tidak berubah banyak 8.83% pada 95 *Ground truth* berbanding 9.65% pada 851 CV menunjukkan bahwa kedua model terdampak kondisi evaluasi yang lebih menantang secara serupa, bukan salah satu model yang "menyusul" model lainnya.

Penurunan ini dapat dijelaskan dari perbedaan komposisi data yang dievaluasi. Pada evaluasi 95 *Ground truth*, *Avg True Score* dihitung hanya dari kandidat yang telah diverifikasi kesesuaiannya secara manual oleh tim HRD, sehingga skor kecocokannya cenderung tinggi dan konsisten. Sebaliknya, pada evaluasi 851 CV, sebagian besar kandidat yang dimasukkan ke dalam perhitungan bukan hasil verifikasi HRD, melainkan diasumsikan sesuai dengan posisi jabatan berdasarkan folder penempatan berkasnya. Kandidat semacam ini berpotensi memiliki tingkat kesesuaian semantik yang lebih rendah terhadap posisi yang "diasumsikan" sebagai jabatan yang tepat, sehingga menurunkan rata-rata skor kecocokan secara keseluruhan bagi kedua model.

Meskipun *Avg True Score* menurun pada kedua model, hal ini tidak mengubah kesimpulan bahwa SBERT tetap unggul dalam kualitas pemeringkatan, sebagaimana tercermin dari nilai MRR, nDCG@5, Recall@5, dan F1@5 yang secara konsisten lebih tinggi dibandingkan USE pada *Dataset* penuh, sebagaimana telah diuraikan sebelumnya. Penurunan *Avg True Score* ini lebih mencerminkan tantangan tambahan akibat volume dan variasi data yang lebih besar, bukan indikasi berkurangnya keunggulan SBERT atas USE.

4. Peningkatan Waktu Komputasi

Pada *Dataset* penuh 851 CV, total waktu komputasi SBERT meningkat menjadi 53.6637 detik dengan rata-rata 0.0631 detik per dokumen, sementara USE membutuhkan 59.4915 detik dengan rata-rata 0.0698 detik per dokumen. Pada pengujian ini, SBERT justru tercatat sedikit lebih cepat dibandingkan USE, dengan selisih waktu proses sekitar 5.8278 detik. Perlu dicatat bahwa selisih kecepatan ini relatif tipis dan dapat bervariasi pada percobaan berikutnya bergantung pada kondisi lingkungan eksekusi seperti spesifikasi perangkat keras dan konektivitas jaringan. Peningkatan waktu total kedua model dibandingkan evaluasi 95 GT sejalan dengan naiknya volume data yang diproses dari 95 menjadi 851 dokumen, sehingga skalabilitas kedua model tetap terjaga secara proporsional. Dalam konteks operasional sistem rekrutmen Kalla Aspal, proses ini berjalan sebagai komputasi di latar belakang (*background*) sistem dan tidak memengaruhi pengalaman pengguna (*user experience*) secara langsung, sehingga durasi komputasi tersebut masih dinilai dapat diterima untuk kebutuhan operasional nyata.

3.2.5 Pembahasan Evaluasi dan Penentuan Model Terbaik

Berdasarkan hasil evaluasi menyeluruh yang telah dipaparkan, SBERT secara konsisten mengungguli USE pada seluruh enam metrik *Information Retrieval* (IR), menghasilkan rata-rata skor kecocokan (*Avg True Score*) yang lebih tinggi terhadap kandidat *Ground truth* baik pada 95 dokumen *Ground truth* (44.16% berbanding 35.33%) maupun pada keseluruhan 851 dokumen CV (31.52% berbanding 21.87%), serta unggul pula dalam efisiensi waktu komputasi pada kedua skala data. Pada 95 dokumen *Ground truth*, SBERT membutuhkan total waktu pemrosesan 5.8235 detik (rata-rata 0.0613 detik per dokumen), sedikit lebih cepat dibandingkan USE yang membutuhkan 6.0395 detik (rata-rata 0.0636 detik per dokumen). Pola serupa terlihat pada keseluruhan 851 dokumen CV, di mana SBERT memerlukan 53.6637 detik (rata-rata 0.0631 detik per dokumen) dibandingkan USE yang membutuhkan 59.4915 detik (rata-rata 0.0698 detik per dokumen). Dengan demikian, SBERT unggul di seluruh sembilan aspek yang dievaluasi pada kedua skala data. Rangkuman perbandingan kinerja kedua model secara menyeluruh pada kedua skala data tersebut disajikan pada Tabel 18.

Tabel 18. Rangkuman Perbandingan Kinerja SBERT dan USE

Aspek Evaluasi	SBERT 95 GT	USE 95 GT	SBERT 851 CV	USE 851 CV	Model Unggul
MRR	0.6225	0.5756	0.3323	0.3237	SBERT
ARHR@5	0.6153	0.5516	0.2822	0.2714	SBERT
nDCG@5	0.6948	0.6088	0.3292	0.3178	SBERT
Precision@5	0.1874	0.1558	0.0943	0.0920	SBERT
Recall@5	0.9368	0.7789	0.4716	0.4598	SBERT
F1@5	0.3122	0.2596	0.1572	0.1532	SBERT
<i>Avg True Score</i> (%)	44.16%	35.33%	31.52%	21.87%	SBERT
Total Process Time (detik)	5.8235	6.0395	53.6637	59.4915	SBERT
Avg Process Time/Dokumen (detik)	0.0613	0.0636	0.0631	0.0698	SBERT

Berdasarkan Tabel 18 SBERT unggul secara mutlak pada seluruh sembilan aspek evaluasi yang diukur, termasuk efisiensi waktu komputasi. Mengacu pada kriteria pemilihan model yang digunakan dalam penelitian ini, yaitu model yang memperoleh performa terbaik pada mayoritas metrik evaluasi ditetapkan sebagai model terbaik, maka *Sentence-BERT* (SBERT) varian *all-MiniLM-L6-v2* secara resmi dipilih untuk diintegrasikan ke dalam Sistem Pendukung Keputusan (SPK) rekrutmen berbasis *website*.

Keunggulan SBERT yang konsisten di seluruh aspek, baik kualitas pemeringkatan rekomendasi maupun efisiensi komputasi, semakin memperkuat keputusan ini. Kualitas pemeringkatan rekomendasi yang dihasilkan SBERT juga terbukti jauh lebih mendekati pola keputusan nyata (*Ground truth*) yang ditetapkan

oleh tim HRD Kalla Aspal. Atas dasar pertimbangan tersebut, integrasi SBERT dinilai sebagai keputusan arsitektural sistem yang terbaik untuk menjamin akurasi dan relevansi rekomendasi, sekaligus mengurangi beban kerja operasional *screening* manual.

3.3 Hasil Implementasi Model dan Pengujian Sistem


Berdasarkan hasil perbandingan dan evaluasi model yang telah dilakukan pada tahap sebelumnya, model SBERT dengan varian all-MiniLM-L6-v2 diintegrasikan ke dalam Sistem Pendukung Keputusan (SPK) rekrutmen berbasis *website* yang dikembangkan menggunakan *framework* Streamlit. Sistem ini dirancang untuk membantu tim HRD Kalla Aspal dalam melakukan proses *screening* dokumen CV kandidat secara lebih cepat, objektif, dan efisien dibandingkan metode manual yang selama ini digunakan.

3.3.1 Hasil Implementasi Sistem

Sistem yang dikembangkan terdiri atas empat komponen halaman utama yang dapat diakses melalui antarmuka *Dashboard* berbasis *website*, yaitu halaman Beranda, halaman *Single CV*, halaman *Leaderboard*, dan halaman *Bulk CV*. Seluruh halaman tersebut dibangun menggunakan *framework* Streamlit dengan mengintegrasikan model SBERT untuk mengukur tingkat kesesuaian antara CV kandidat dan *Job Profile*.

1. Halaman Beranda


Halaman beranda merupakan tampilan pertama yang diakses pengguna saat membuka sistem, menyajikan deskripsi umum fungsionalitas sistem, tujuan pengembangan kecerdasan buatan dalam mempermudah pencocokan dokumen, serta rangkuman panduan operasional dari tiga menu utama aplikasi, sebagaimana ditunjukkan pada Gambar 19.



Gambar 19. Tampilan Halaman Beranda

2. Halaman *Single CV*

Halaman *Single CV* memfasilitasi analisis mendalam terhadap satu berkas kandidat. Pengguna mengunggah CV berformat PDF, dan sistem secara *real-time* mengekstraksi informasinya, menghitung skor kesesuaian terhadap 26 posisi jabatan, serta menyajikan hasilnya lewat kartu skor kecocokan (*matching score*) global, grafik skor parsial per komponen (pendidikan, pengalaman, kemampuan), detail kualifikasi akademik, identifikasi jabatan terbaik (*Best Job Match*), tombol WhatsApp, tabel *Top-5 Job*, dan narasi saran pengembangan kompetensi, sebagaimana ditunjukkan pada Gambar 20.




Gambar 20. Tampilan Halaman *Single CV*


3. Halaman *Leaderboard*

Sistem menyediakan dua varian halaman *Leaderboard* yang bersumber dari metode pemrosesan data berbeda. *Leaderboard Mode Single CV* menyajikan peringkat kumulatif seluruh kandidat dari riwayat pemrosesan dokumen tunggal, dilengkapi grafik batang dinamis persentase skor kecocokan, tabel detail peringkat yang dapat disaring berdasarkan posisi jabatan, serta tombol WhatsApp per baris data untuk menghubungi kandidat langsung. *Leaderboard Mode Bulk CV* memiliki

struktur serupa, namun khusus menyajikan hasil analisis berkas yang diproses secara massal tanpa fitur komunikasi langsung. Visualisasi kedua varian ini ditunjukkan berturut-turut pada Gambar 21 dan Gambar 22.



Gambar 21. Tampilan Halaman *Leaderboard* Mode *Single CV*




Gambar 22. Tampilan Halaman *Leaderboard* Mode *Bulk CV*


4. Halaman *Bulk CV*

Halaman *Bulk CV* menyediakan dua mode pemrosesan massal. Pada mode otomatis, sistem secara mandiri memproses seluruh berkas PDF pelamar yang diunggah secara bersamaan, kemudian model SBERT secara otomatis mendeteksi dan mengelompokkan posisi jabatan yang paling relevan bagi masing-masing pelamar. Antarmuka halaman ini memuat kartu informasi ringkasan CV terbaik, indikator skor tertinggi, total berkas terunggah, grafik distribusi skor, tabel rekapitulasi penilaian keseluruhan, serta visualisasi kartu pengelompokan sebaran deteksi posisi pelamar.

Pada mode manual, pengguna menetapkan satu posisi jabatan target secara spesifik melalui komponen bilah samping (*sidebar*) sebelum mengunggah berkas CV. Setelah posisi jabatan dikunci, sistem melakukan kalkulasi skor kesesuaian massal hanya terhadap formasi jabatan yang dipilih dan menyajikan hasilnya dalam bentuk kartu ringkasan, grafik distribusi skor kelompok, dan tabel detail penilaian keseluruhan pelamar. Tampilan halaman *Bulk CV* mode otomatis dan mode manual masing-masing ditunjukkan pada Gambar 23 dan Gambar 24.



Gambar 23. Tampilan Halaman *Bulk CV* Mode Otomatis



Gambar 24. Tampilan Halaman *Bulk CV Mode Manual*

3.3.2 Hasil Pengujian Sistem (*Black-Box Testing*)

Pengujian sistem dilakukan menggunakan metode *Black-Box Testing* untuk memvalidasi bahwa seluruh fitur pada *Dashboard Streamlit* dapat beroperasi sesuai dengan kebutuhan pengguna dan bebas dari kesalahan teknis (*bug*). Pengujian berfokus pada kesesuaian antara masukan (*input*) dan keluaran (*output*) yang dihasilkan sistem tanpa memperhatikan struktur kode program maupun proses komputasi internal model. Pengujian dilakukan terhadap empat halaman utama sistem sesuai dengan skenario yang telah dirancang, yaitu halaman Beranda, halaman *Single CV*, halaman *Leaderboard*, dan halaman *Bulk CV*.

Tabel 19. Hasil Pengujian Halaman Beranda

No.	Skenario Pengujian	Input	Output yang Diharapkan	Hasil
1	Akses halaman beranda	Membuka aplikasi	Halaman beranda tampil dengan deskripsi sistem dan navigasi menu yang lengkap	Berhasil

Tabel 20. Hasil Pengujian Halaman *Single CV*

No.	Skenario Pengujian	Input	Output yang Diharapkan	Hasil
1	Unggah berkas PDF kandidat	File PDF berbasis teks	Sistem berhasil membaca dan mengekstraksi teks dokumen CV	Berhasil
2	Tampil grafik skor parsial per komponen	File PDF kandidat	Grafik batang skor pendidikan, pengalaman, dan kemampuan tampil dengan nilai yang sesuai	Berhasil
3	Tampil kartu metrik skor global	File PDF kandidat	Kartu skor kecocokan global (<i>matching score</i>) tampil dengan nilai yang benar	Berhasil
4	Tombol integrasi WhatsApp	Data kandidat tersedia	Tombol WhatsApp aktif dan mengarahkan untuk pesan pemanggilan kandidat	Berhasil
5	Tampil tabel <i>Top-5 Job</i>	File PDF kandidat	Tabel rekomendasi jabatan teratas tampil dengan urutan skor tertinggi	Berhasil
6	Tampil kolom narasi analisis kompetensi	File PDF kandidat	Kolom narasi analisis dan saran pengembangan kompetensi kandidat berhasil tampil dengan konten yang relevan	Berhasil

Tabel 21. Hasil Pengujian Halaman *Leaderboard*

No.	Skenario Pengujian	Input	Output yang Diharapkan	Hasil
1	Filter data berdasarkan posisi jabatan	Pilihan jabatan via <i>sidebar</i>	Data kandidat tersaring sesuai posisi jabatan yang dipilih	Berhasil
2	Tombol <i>refresh</i> grafik peringkat	Klik tombol <i>refresh</i>	Grafik batang persentase skor kecocokan diperbarui secara dinamis	Berhasil
3	Pengurutan tabel peringkat kandidat	Data kandidat tersedia (mode <i>Single CV</i> / <i>Bulk CV</i>)	Tabel terurut dari skor tertinggi hingga terendah secara akurat	Berhasil
4	Tombol integrasi WhatsApp pada <i>Leaderboard Single CV</i>	Data kandidat dengan nomor WhatsApp terisi (mode <i>Single CV</i>)	Tombol WhatsApp tampil pada tabel baris kandidat dan mengarahkan untuk pesan pemanggilan kandidat	Berhasil

Tabel 22. Hasil Pengujian Halaman *Bulk CV*

No.	Mode	Skenario Pengujian	Input	Output yang Diharapkan	Hasil
1	Otomatis	Unggah massal berkas PDF	Beberapa file PDF sekaligus	Sistem menerima unggahan massal dan memproses seluruh berkas secara bersamaan	Berhasil
2	Otomatis	Deteksi posisi jabatan otomatis	Berkas PDF massal	Sistem mendeteksi dan mengelompokkan posisi jabatan paling relevan bagi setiap pelamar secara mandiri	Berhasil
3	Otomatis	Tampil grafik distribusi skor	Berkas PDF massal	Grafik distribusi skor kelompok tampil dengan benar	Berhasil
4	Manual	Kunci posisi jabatan via <i>sidebar</i>	Pilihan jabatan via <i>sidebar</i>	Sistem mengunci satu formasi jabatan target sesuai pilihan pengguna	Berhasil
5	Manual	Kalkulasi skor massal pada formasi terkunci	Berkas PDF massal + jabatan terkunci	Sistem menghitung skor kesesuaian seluruh pelamar khusus pada formasi jabatan yang dipilih	Berhasil
6	Manual	Tampil tabel detail penilaian	Berkas PDF massal + jabatan terkunci	Tabel detail penilaian seluruh pelamar tampil dengan urutan skor tertinggi secara akurat	Berhasil

Berdasarkan hasil pengujian *Black-Box Testing* terhadap seluruh halaman sistem sebagaimana dirangkum pada Tabel 19, Tabel 20, Tabel 21, hingga Tabel 22, seluruh 17 skenario pengujian yang mencakup halaman Beranda, *Single CV*, *Leaderboard*, dan *Bulk CV* menghasilkan *output* yang sesuai dengan yang diharapkan tanpa ditemukan kegagalan fungsional (*bug*) maupun ketidaksesuaian antara masukan (*input*) dan keluaran (*output*). Berdasarkan hasil pengujian tersebut, Sistem Pendukung Keputusan berbasis *website* yang mengintegrasikan model *Sentence-BERT* untuk mengukur tingkat kesesuaian antara CV dan *Job Profile* dinilai telah berfungsi dengan baik dan memenuhi tujuan penelitian, yaitu membantu tim HRD Kalla Aspal dalam melakukan penilaian kesesuaian CV dan *Job Profile* secara lebih cepat, objektif, dan efisien dibandingkan metode manual yang selama ini digunakan.

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan hasil penelitian mengenai perbandingan kinerja *Sentence-BERT* (SBERT) dan *Universal Sentence Encoder* (USE) untuk penilaian kesesuaian CV dan *Job Profile* pada Sistem Pendukung Keputusan (SPK) HRD dengan studi kasus Kalla Aspal, maka dapat ditarik kesimpulan sebagai berikut.

1. *Sentence-BERT* (SBERT) varian *all-MiniLM-L6-v2* menunjukkan performa yang lebih baik dibandingkan *Universal Sentence Encoder* (USE) pada seluruh aspek evaluasi yang diukur berdasarkan 95 dokumen CV *Ground truth* dalam penelitian ini. SBERT unggul pada keenam metrik *Information Retrieval* yang digunakan, dengan nilai MRR 62.25%, ARHR@5 61.53%, nDCG@5 69.48%, *Precision@5* 18.74%, *Recall@5* 93.68%, dan *F1@5* 31.22%, melampaui USE yang memperoleh nilai masing-masing 57.56%, 55.16%, 60.88%, 15.58%, 77.89%, dan 25.96%, sehingga menunjukkan efektivitas pemeringkatan rekomendasi SBERT yang lebih baik. Rata-rata nilai *Cosine similarity* (*Average True Score*) SBERT terhadap kandidat *Ground truth* juga lebih tinggi, yaitu 44.16%, dibandingkan 35.33% milik USE. Dari sisi efisiensi komputasi, SBERT tercatat sedikit lebih cepat dibandingkan USE, dengan waktu proses 5.8235 detik berbanding 6.0395 detik. Dengan demikian, SBERT terbukti unggul secara konsisten pada seluruh aspek evaluasi yang diukur, baik dari nilai *Cosine similarity*, efektivitas pemeringkatan rekomendasi, maupun waktu proses komputasi. Keunggulan ini tetap konsisten pada pengujian *Dataset* penuh sebanyak 851 CV, meskipun kedua model mengalami penurunan performa yang wajar seiring meningkatnya volume dan kompleksitas data.
2. Model SBERT berhasil diimplementasikan ke dalam Sistem Pendukung Keputusan (SPK) HRD berbasis *website* menggunakan *framework* Streamlit. Sistem mampu melakukan penilaian kesesuaian CV dan *Job Profile* secara otomatis berdasarkan aspek pendidikan, pengalaman, dan kemampuan dengan skema pembobotan yang telah ditentukan. Hasil *Black-Box Testing* terhadap 17 skenario fungsional pada halaman Beranda, *Single CV*, *Leaderboard*, dan *Bulk CV* menunjukkan seluruh fungsi berjalan tanpa kegagalan, sehingga sistem dinilai mampu mendukung proses *screening* CV secara lebih cepat, efisien, dan objektif dibandingkan seleksi manual yang sebelumnya diterapkan di Kalla Aspal.

4.2 Saran

Berdasarkan keterbatasan yang telah diidentifikasi, beberapa saran untuk penelitian dan pengembangan sistem selanjutnya adalah sebagai berikut.

1. Menggunakan *Dataset* CV dan *Job Profile* yang lebih besar disertai proses *fine-tuning* model *sentence embedding*, serta melibatkan lebih dari satu

penilai (*multi-rater*) dalam pelabelan data *Ground truth*, agar representasi semantik yang dihasilkan lebih sesuai dengan karakteristik dokumen rekrutmen berbahasa Indonesia dan data acuan yang digunakan menjadi lebih objektif.

2. Memperluas pengujian pada perusahaan atau sektor industri yang berbeda serta membandingkan dengan model berbasis bahasa Indonesia seperti IndoBERT dan IndoSBERT untuk mengetahui efektivitas model pada dokumen rekrutmen berbahasa Indonesia secara lebih akurat.

DAFTAR PUSTAKA


- Adhikari, N. S., & Agarwal, S. (2025). A Comparative Study of PDF Parsing Tools Across Diverse Document Categories. <http://arxiv.org/abs/2410.09871>
- Ajjam, M. H., & Al-Raweshidy, H. S. (2025). AI-driven semantic similarity-based job matching framework for recruitment systems. *Information Sciences*, 724. <https://doi.org/10.1016/j.ins.2025.122728>
- Alsaif, S. A., Sassi Hidri, M., Eleraky, H. A., Ferjani, I., & Amami, R. (2022). Learning-Based Matched Representation System for Job Recommendation. *Computers*, 11(11). <https://doi.org/10.3390/computers11110161>
- Anggraini, T., Lassa, A., & Suni, M. (2021). Pelatihan Pembuatan Curriculum Vitae (Cv) Untuk Mempersiapkan Lulusan Sekolah Kejuruan Dalam Menghadapi Dunia Kerja. 5(4), 1202–1213. <https://doi.org/10.31764/jmm.v5i4.4732>
- Ariantini, D. A. R., Lumenta, A. S. M., & Jacobus, A. (2016). Pengukuran Kemiripan Dokumen Teks Bahasa Indonesia Menggunakan Metode Cosine Similarity. *Jurnal Teknik Informatika Unsrat*, 9. <https://doi.org/10.35793/jti.9.1.2016.13752>
- Cer, D., Yang, Y., Kong, S., Hua, N., Limtiaco, N., John, R. S., Constant, N., Céspedes Guajardo, M., Yuan, S., Tar, C., Sung, Y.-H., Strobe, B., & Kurzweil, R. (2018). Universal Sentence Encoder. <http://arxiv.org/abs/1803.11175>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. <http://arxiv.org/abs/1810.04805>
- Firmansyah, R. (2025). Penerapan Metode Optical Character Recognition Dan Pattern Matching Dalam Proses Screening Curriculum Vitae Rekrutmen. 1(1), 1–12.
- Gupta, V., Dixit, A., & Sethi, S. (2022). A Comparative Analysis of Sentence Embedding Techniques for Document Ranking. *Journal of Web Engineering*, 21(7), 2149–2186. <https://doi.org/10.13052/jwe1540-9589.2177>
- Hastomo, W., Aini, N., Satyo, A., Karno, B., & Rere, L. M. R. (2022). Metode Pembelajaran Mesin untuk Memprediksi Emisi Manure Management. *Jurnal Nasional Teknik Elektro Dan Teknologi Informasi*, 11(2), 131–139. <https://doi.org/10.22146/jnteti.v11i2.2586>
- Hidayah, A. N., Hamdi, E., Yanuar, T., Syah, R., & Sutawijaya, A. H. (2026). Strategi dan Operasional TalentHub 360 sebagai Platform Pencarian Kerja Digital. *Jurnal Media Informatika*, 7, 698–708. <https://doi.org/10.55338/jumin.v7i2.8711>

- Ikah, & Fitriani, R. (2022). Penentuan Prioritas Kriteria Proses Rekrutmen dan Seleksi Karyawan Menggunakan Metode Analytic Hierarchy Process di PT Citatah Tbk. *Serambi Engineering*, VII(2). <https://ojs.serambimekkah.ac.id/jse/article/view/2870%20-%202880>
- Jadon, A., & Patil, A. (2024). A Comprehensive Survey of Evaluation Techniques for Recommendation Systems. <http://arxiv.org/abs/2312.16015>
- Kartodikromo, E. A., Tewal, B., & Trang, I. (2017). Proses Rekrutmen, Seleksi, Pelatihan Kerja Dan Pengaruhnya Pada Kinerja Karyawan Cv. Celebes Indonesia Sakti Mer 99 Mega Mas Manado. 5(2), 354–372. <https://doi.org/10.35794/emba.5.2.2017.15625>
- Kusumo, H., & Rakasiwi, S. (2020). Sistem Pendukung Keputusan Rekrutmen Pada Perusahaan Outsourcing Berbasis Web. <https://doi.org/10.51903/e-bisnis.v13i1.177>
- Li, B., Zhou, H., He, J., Wang, M., Yang, Y., & Li, L. (2020). On the Sentence Embeddings from Pre-trained Language Models. <https://doi.org/10.18653/v1/2020.emnlp-main.733>
- Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. <http://arxiv.org/abs/1301.3781>
- Purnomo, D. (2017). Model Prototyping Pada Pengembangan Sistem Informasi. *JIMP-Jurnal Informatika Merdeka Pasuruan*, 2(2). <https://doi.org/10.37438/jimp.v2i2.67>
- Raharjo, M., Napiah, M., Heristian, S., & Purnama, R. A. (2026). Pengembangan Aplikasi Check Font Versi 2 Deteksi Font Pada Dokumen PDF Dengan Algoritma Distribusi Font. *Sains Teknik Elektro*, 7(1). <http://jurnal.bsi.ac.id/index.php/insantek>
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. <https://doi.org/10.18653/v1/D19-1410>
- Reimers, N., & Gurevych, I. (2020). Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation. <https://doi.org/10.18653/v1/2020.emnlp-main.365>
- Rikardo, Ash Shidqi, R. M., Sujana, A., Wibawa, S., Rohwadi, U., & Wuryo Handono, F. (2026). Sistem Screening Cv Otomatis Berbasis NLP Dan Rule-Based Untuk Seleksi Kandidat Berbasis Web. *Jurnal Sistem Dan Teknologi Informasi (JSTI)*, 08(1). <https://journalversa.com/s/index.php/jsti/article/view/5361>
- Satrio, D. A., & Suryadi, L. (2020). Sistem Penunjang Keputusan Seleksi Pelamar Kerja Pada Bni Life Insurance Menggunakan Metode Profile Matching Berbasis

- Object Oriented. *IDEALIS: InDonEsiA Journal Information System.*, 3, 532–538. <https://doi.org/10.36080/idealis.v3i1.2336>
- Setiaji, P. (2012). Sistem Pendukung Keputusan Dengan Metode Simple Additive Weighting. <https://doi.org/10.24176/simet.v1i1.117>
- Sowmiya, E., Sandhiya, K., Sathiya Priya, K., Sowmiya, R., & Kirthiga, M. (2024). Data Visualization Using Machine Learning Based On The Analysis Of Electroencephalogram. *International Journal of Creative Research Thoughts (IJCRT)*, 12(11). <http://www.ijcrt.org/papers/IJCRT2411233.pdf>
- Subramanian, A. (2026). Speed, Simplicity, and Fidelity: A Multi-Metric Benchmark of Python PDF Extraction Libraries for RAG Pipelines. <https://doi.org/10.13140/RG.2.2.29289.56168>
- Supiyanto, & Sriyono. (2023). Metode Cosine Similarity Untuk Mendeteksi Kemiripan Pada Dokumen Teks. <https://ejournal.uncen.ac.id/index.php/SAINS>
- Susanto, D. B., & Hamzali, S. (2024). Peran Teknologi dalam Meningkatkan Efektivitas Rekrutmen dan Seleksi Karyawan. *Jurnal Kolaboratif Sains*, 7(8), 2746–2757. <https://doi.org/10.56338/jks.v7i8.5898>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. <http://arxiv.org/abs/1706.03762>
- Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020). MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers. <http://arxiv.org/abs/2002.10957>
- Yang, Y., Cer, D., Ahmad, A., Guo, M., Law, J., Constant, N., Abrego, G. H., Yuan, S., Tar, C., Sung, Y.-H., Strope, B., & Kurzweil, R. (2020). Multilingual Universal Sentence Encoder for Semantic Retrieval. <https://doi.org/10.18653/v1/2020.acl-demos.12>

LAMPIRAN

Lampiran 1. Dokumentasi



Lampiran 2. Dashboard Streamlit



<https://penilaiancvkallaaspal.streamlit.app/>

Lampiran 3. Source Code Perbandingan Model



<https://bit.ly/perbandinganmodelsbetdanuse>