

**ANALISIS *VALUE AT RISK* (VaR) PADA PREDIKSI HARGA SAHAM
MENGUNAKAN ALGORITMA *GATED RECURRENT UNIT* (GRU)**



RISMAYANTI

H081221028



**PROGRAM STUDI ILMU AKTUARIA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN MAKASSAR**

2026

**ANALISIS *VALUE AT RISK* (VaR) PADA PREDIKSI HARGA
SAHAM MENGGUNAKAN ALGORITMA *GATED*
RECURRENT UNIT (GRU)**

**RISMAYANTI
H081221028**



**PROGRAM STUDI ILMU AKTUARIA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN MAKASSAR
2026**

ANALYSIS OF VALUE AT RISK (VAR) IN STOCK PRICE PREDICTION USING THE GATED RECURRENT UNIT (GRU) ALGORITHM

RISMAYANTI

H081221028



**PROGRAM STUDI ILMU AKTUARIA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN MAKASSAR
2026**

**ANALISIS VALUE AT RISK (VaR) PADA PREDIKSI HARGA SAHAM
MENGUNAKAN ALGORITMA GATED RECURRENT UNIT (GRU)**

RISMAYANTI

H081221028

Skripsi

sebagai salah satu syarat untuk mencapai gelar sarjana

Program Studi Ilmu Aktuaria

pada

**PROGRAM STUDI ILMU AKTUARIA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS HASANUDDIN
MAKASSAR
2026**

SKRIPSI

**ANALISIS *VALUE AT RISK* (VaR) PADA PREDIKSI HARGA SAHAM
MENGUNAKAN ALGORITMA GATED RECURRENT UNIT (GRU)****RISMAYANTI****H081221028**

Skripsi,


Analisis Value at Risk (VaR) Pada Prediksi Harga Saham Menggunakan Algoritma
Gated Recurrent Unit (GRU)

telah dipertahankan di depan Panitia Ujian Sarjana Aktuaria pada tanggal 16 bulan
Juli tahun 2026 dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Ilmu Aktuaria
Departemen Matematika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Hasanuddin
Makassar

Mengesahkan:
Pembimbing tugas akhir,



Dr. Amran, S.Si., M.Si.
NIP 197011011998021001



Mengetahui:
Ketua Program Studi,



Prof. Dr. Hasmawati, M.Si.
NIP 196412311990032007

PERNYATAAN KEASLIAN SKRIPSI DAN PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa, skripsi berjudul "*Analisis Value at Risk (VaR) pada Prediksi Harga Saham Menggunakan Algoritma Gated Recurrent Unit (GRU)*" adalah benar karya saya dengan arahan dari pembimbing Dr. Amran, S.Si., M.Si. Karya ilmiah ini belum diajukan dan tidak sedang diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka skripsi ini. Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan skripsi ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta (hak ekonomis) dari karya tulis saya berupa skripsi ini kepada Universitas Hasanuddin.

Makassar. 16 Juli 2026



Rismayanti
H081221028

UCAPAN TERIMA KASIH

Alhamdulillah, puji dan syukur penulis panjatkan ke hadirat Allah *Subhanahu wa Ta'ala* atas segala limpahan rahmat, taufik, dan hidayah-Nya sehingga penulis dapat menyelesaikan penyusunan skripsi ini, yang berjudul “**Analisis Value at Risk (VaR) pada Prediksi Harga Saham Menggunakan Algoritma Gated Recurrent Unit (GRU)**”. Penulis menyadari bahwa skripsi ini dapat diselesaikan dengan baik karena adanya bantuan, dukungan, serta bimbingan dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan terima kasih kepada pihak-pihak yang telah membantu dalam penyusunan skripsi ini.

Kepada yang terhormat Bapak **Dr. Amran, S.Si., M.Si.** selaku dosen pembimbing, penulis menyampaikan terima kasih yang sebesar-besarnya atas kesabaran, serta kesediaan meluangkan waktu, tenaga, dan pikiran dalam membimbing penulis selama proses penyusunan skripsi ini. Ucapan terima kasih juga penulis sampaikan kepada Bapak **Prof. Dr. Amir Kamal Amir, M.Sc.** dan Bapak **Dr. Andi Muhammad Anwar, S.Si., M.Si.** selaku dosen penguji yang telah meluangkan waktunya untuk menguji penulis, mengkritisi, serta memberikan saran dan masukan demi penyempurnaan skripsi ini.

Teristimewa, penulis mengucapkan terima kasih yang sebesar-besarnya kepada kedua orang tua tercinta, **Mama dan Bapak**, dua sosok yang paling berjasa dalam kehidupan penulis. Terima kasih sudah menjadi orang tua yang selalu memberikan kasih sayang, semangat, doa, serta dukungan baik secara moril maupun materil yang tiada hentinya kepada penulis. Untuk kakak penulis, **Usman**, terima kasih atas segala bantuan dan pengorbanan yang selama ini diberikan kepada penulis selama proses penyusunan skripsi ini. Serta tak lupa kepada teman-teman **Mancing Mania Mantap, Ilmu Aktuaria 2022** serta **KKN-T 114 Salomallori**, terima kasih atas kebersamaan, dukungan, dan kehadiran yang begitu berharga sejak awal masa perkuliahan hingga penyusunan skripsi ini. Dan seluruh pihak yang telah terlibat, memberikan doa, serta dukungan dalam proses penyusunan skripsi ini yang tidak dapat penulis sebutkan satu per satu.

Terakhir, penulis ingin mengucapkan terima kasih kepada diri sendiri. Terima kasih sudah bertahan sejauh ini, berani melawan ketakutan, dan berjuang untuk menyelesaikan apa yang telah dimulai. Penulis menyadari bahwa skripsi ini masih jauh dari kata sempurna, sehingga penulis mengucapkan mohon maaf atas segala kekurangan. Akhir kata, penulis berharap skripsi ini dapat memberikan manfaat bagi para pembaca.

Penulis,

Rismayanti

ABSTRAK

RISMAYANTI. **Analisis *Value at Risk* (Var) pada Prediksi Harga Saham Menggunakan Algoritma *Gated Recurrent Unit* (GRU)** (dibimbing oleh Dr. Amran, S.Si., M.Si.).

Latar Belakang. Ketidakpastian ekonomi global meningkatkan minat investasi pada saham *blue chip* seperti PT Astra International Tbk (ASII.JK), yang menuntut metode analisis risiko lebih akurat. **Tujuan.** Penelitian ini bertujuan untuk menganalisis risiko return saham ASII.JK menggunakan metode *Value at Risk* (VaR) berbasis simulasi historis dengan memanfaatkan hasil prediksi dari model *Gated Recurrent Unit* (GRU). **Metode.** Metode penelitian mencakup pengumpulan data, *exploratory data analysis*, *preprocessing* data, pembangunan model GRU, serta pelatihan dan evaluasi model menggunakan metrik RMSE, MAE, dan MAPE. Tahap selanjutnya mencakup prediksi dengan model terbaik, konversi harga menjadi *return*, perhitungan VaR dengan simulasi historis, dan validasi melalui uji *backtesting* Kupiec Test. **Hasil.** Hasil penelitian menunjukkan bahwa model GRU memberikan performa terbaik pada *learning rate* 0,001, *batch size* 16, dan *epoch* dengan nilai RMSE 108,76, MAE 79,19, dan MAPE 1,37%. Estimasi VaR pada tingkat kepercayaan 95% dan 99% masing-masing sebesar -2,52% dan -4,02%., hasil Kupiec Test mengonfirmasi bahwa model risiko tersebut akurat dan valid. **Kesimpulan.** Sehingga pada penelitian ini dapat disimpulkan bahwa kombinasi model prediksi GRU dengan analisis VaR diharapkan menjadi pendekatan inovatif yang efektif menghasilkan analisis risiko yang komprehensif dalam menghadapi dinamika pasar saham.

Kata Kunci: GRU; Prediksi saham; VaR; *Backtesting*; Kupiec Test

ABSTRACT

RISMAYANTI. **Analysis of Value at Risk (VaR) in Stock Price Prediction Using the Gated Recurrent Unit (GRU) Algorithm** (supervised by Dr. Amran, S.Si., M.Si.).

Background. Global economic uncertainty increases investment interest in blue chip stocks such as PT Astra International Tbk (ASII. JK), which demands more accurate risk analysis methods. **Aim.** This study aims to analyze the risk of return on ASII shares. JK uses the Value at Risk (VaR) method based on historical simulation by utilizing the prediction results from the Gated Recurrent Unit (GRU) model. **Methods.** The research methods include data collection, exploratory data analysis, data preprocessing, GRU model development, and model training and evaluation using RMSE, MAE, and MAPE metrics. The next stage includes prediction with the best model, price conversion to return, VaR calculation with historical simulations, and validation through Kupiec Test backtesting. **Results.** The results showed that the GRU model provided the best performance at a learning rate of 0.001, batch size 16, and epoch with an RMSE value of 108.76, MAE 79.19, and MAPE 1.37%. VaR estimates at 95% and 99% confidence levels of -2.52% and -4.02% respectively, the results of the Kupiec Test confirm that the risk model is accurate and valid. **Conclusion.** Therefore, in this study, it can be concluded that the combination of the GRU prediction model with VaR analysis is expected to be an innovative approach that is effective in producing a comprehensive risk analysis in dealing with stock market dynamics.

Keywords: GRU; Stock prediction; VaR; Backtesting; Kupiec Test

DAFTAR ISI

	Halaman
HALAMAN JUDUL	i
HALAMAN PENGANTAR.....	iv
HALAMAN PENGESAHAN.....	v
PERNYATAAN KEASLIAN SKRIPSI.....	vi
UCAPAN TERIMA KASIH	vii
ABSTRAK	viii
ABSTRACT	ix
DAFTAR ISI.....	x
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
DAFTAR LAMPIRAN.....	xiv
DAFTAR SINGKATAN DAN LAMBANG	xv
BAB I . PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian.....	3
1.4 Batasan Masalah	3
1.5 Landasan Teori.....	4
1.5.1 Saham dan Pasar Modal	4
1.5.2 <i>Return</i> dan Risiko Saham	4
1.5.3 <i>Value at Risk</i> (VaR).....	5
1.5.4 Metode Simulasi Historis	5
1.5.5 <i>Time Series</i> dan Prediksi	6
1.5.6 Normalisasi	7
1.5.7 <i>Deep Learning</i>	7
1.5.8 <i>Recurrent Neural Network</i> (RNN)	7
1.5.9 <i>Gated Recurrent Unit</i> (GRU).....	8
1.5.10 <i>Hyperparameter</i>	10
1.5.11 Metrik Evaluasi	13

1.5.12 <i>Backtesting</i>	14
BAB II . METODOLOGI PENELITIAN	16
2.1 Pendekatan dan Jenis Penelitian.....	16
2.2 Jenis dan Sumber Data	16
2.3 Metode Analisis Data	16
2.4 Alur Kerja.....	17
BAB III . HASIL DAN PEMBAHASAN	19
3.1 Hasil	19
3.1.1 Pengumpulan Data	19
3.1.2 <i>Exploratory Data Analysis</i> (EDA)	19
3.1.3 <i>Preprocessing</i> Data.....	21
3.1.4 Pemodelan GRU	22
3.1.5 Pelatihan dan Validasi Model.....	24
3.1.6 Prediksi Harga Saham	24
3.1.7 Perhitungan <i>Return</i>	26
3.1.8 Perhitungan VaR	27
3.1.9 <i>Backtesting</i>	27
3.2 Pembahasan	28
3.2.1 Karakteristik Data Saham ASII.JK	28
3.2.2 Analisis Arsitektur Model GRU	29
3.2.3 Analisis Pengujian <i>Hyperparameter</i>	30
3.2.4 Analisis Hasil Prediksi	31
3.2.5 Analisis Risiko Berdasarkan VaR dan <i>Backtesting</i>	32
BAB IV . KESIMPULAN	33
DAFTAR PUSTAKA.....	34
LAMPIRAN	38

DAFTAR TABEL

Nomor Urut	Halaman
1. <i>Range MAPE Value</i>	14
2. Data Harga Penutupan Saham ASII.JK	19
3. Statistik Deskriptif Harga Penutupan Saham ASII.JK	20
4. Data Harga Penutupan Saham Setelah Dinormalisasi	21
5. Proporsi Pembagian Data	22
6. Ringkasan Model	22
7. Hasil Pengujian <i>Hyperparameter</i>	23
8. Perbandingan Hasil Prediksi & Data Uji Model	25
9. Hasil Prediksi ASII.JK Selama 7 Hari	26
10. Hasil Perhitungan <i>Return</i>	26
11. Hasil Perhitungan VaR	27
12. Hasil <i>Backtesting</i> VaR dengan Uji Kupiec Test	28

DAFTAR GAMBAR

Nomor Urut	Halaman
1. Arsitektur GRU.....	8
2. Alur Kerja	18
3. Plot Tren Harga Penutupan Saham ASII.JK.....	20
4. Distribusi Data Harga Penutupan Saham ASII.JK.....	21
5. Plot Training & Validation Loss	24
6. Plot Perbandingan Harga Prediksi & Aktual Hasil Pengujian Model	24
7. Plot Hasil Prediksi 7 Hari ke Depan	25
8. Plot <i>Backtesting</i>	27

DAFTAR LAMPIRAN

Nomor Urut	Halaman
1. Data Harga Saham ASII.JK	38
2. Kode Pemrograman	38
3. Hasil Eksperimen Arsitektur Model GRU.....	41
4. Tabel Distribusi Chi Square	42

DAFTAR SINGKATAN DAN LAMBANG

Lambang/singkatan	Arti dan penjelasan
BEI	Bursa Efek Indonesia
KSEI	Kustodian Sentral Efek Indonesia
SID	<i>Single Investor Identification</i>
GRU	<i>Gated Recurrent Unit</i>
RNN	<i>Recurrent Neural Network</i>
LSTM	<i>Long Short-Term Memory</i>
VaR	<i>Value at Risk</i>
ASII.JK	PT Astra International Tbk
RMSE	<i>Root Mean Square Error</i>
MAE	<i>Mean Absolute Error</i>
MAPE	<i>Mean Absolute Percentage Error</i>
MSE	<i>Mean Squared Error,</i>
LR	<i>Loglikelihood Ratio</i>
R_t	<i>Log return</i>
P_t	Harga saham pada periode ke-t
W_0	Besarnya investasi awal
P_α	Nilai persentil ke- α
t	Periode waktu atau <i>holding period</i>
α	Taraf signifikansi
n	Banyaknya data
X_{scaled}	Nilai data setelah melalui proses normalisasi
r_t	<i>Reset gate</i>
z_t	<i>Update gate</i>
h_t	<i>Hidden state</i>
σ	Fungsi aktivasi Sigmoid
$\tanh$	Fungsi aktivasi Hyperbolic Tangent
N	Banyaknya pelanggaran aktual dalam uji <i>backtesting</i>
$\hat{y}_i$	Nilai prediksi
y_i	Nilai aktual
$\chi^2_{(\alpha;1)}$	Distribusi Chi-Square

BAB I. PENDAHULUAN

1.1 Latar Belakang

Ketidakpastian ekonomi global terus meningkat dalam beberapa tahun terakhir akibat berbagai faktor, seperti krisis keuangan, pandemi COVID-19, perubahan regulasi pemerintah, krisis geopolitik, dan fluktuasi harga komoditas. Akibatnya, masyarakat semakin sadar akan pentingnya perencanaan keuangan yang baik, dan salah satu strategi yang banyak diminati saat ini adalah berinvestasi di pasar modal. Investasi adalah proses mengalokasikan dana secara bertahap ke instrumen atau produk keuangan dengan harapan dana tersebut akan berkembang dan menghasilkan keuntungan di masa depan (Hasan et al., 2024).

Pasar modal di Indonesia diatur dan dikelola oleh Bursa Efek Indonesia (BEI). Mengacu pada Undang-Undang Nomor 8 Tahun 1995 Pasal 1 Ayat (4) tentang Pasar Modal, bursa efek didefinisikan sebagai institusi yang berwenang untuk menyelenggarakan dan memfasilitasi pertemuan antara pihak-pihak yang ingin melakukan perdagangan efek. Saham menjadi salah satu jenis sekuritas yang diperdagangkan di bursa efek, dan merupakan instrumen investasi yang populer di kalangan masyarakat (Ismail et al., 2024). Hal ini karena saham menawarkan potensi keuntungan yang tinggi dengan akses yang luas ke pasar modal. Berdasarkan data Kustodian Sentral Efek Indonesia (KSEI), jumlah investor saham di Indonesia naik dari 4,44 juta *Single Investor Identification* (SID) pada tahun 2022 menjadi 8,60 juta SID per akhir Desember 2025 (PT Kustodian Sentral Efek Indonesia, 2025). Peningkatan ini menandakan bahwa minat masyarakat untuk berinvestasi pada pasar saham sangat tinggi.

Saham PT Astra International Tbk (ASII.JK) termasuk salah satu saham yang banyak diminati investor di Indonesia. Emiten ini masuk kategori *blue chip* dan terdaftar di indeks LQ45 serta IDX30, yang merupakan indikator perusahaan dengan likuiditas tinggi dan kapitalisasi pasar yang besar di BEI. Berdasarkan laporan keuangan ASII.JK pada triwulan IV tahun 2025, ASII.JK memiliki kapitalisasi pasar Rp 271 juta dengan jumlah saham yang beredar lebih dari 40 miliar lembar saham (PT Astra International Tbk, 2025). Karakteristik ini memberi ASII.JK prospek jangka panjang yang baik, sehingga investor tertarik berinvestasi dengan harapan memperoleh imbal hasil tinggi.

Berdasarkan prinsip ekonomi, kenaikan permintaan saham mendorong harga saham naik, dan *return* saham ikut meningkat (Akhmad & Damayanti, 2021). Namun, sesuai prinsip *high risk-high return*, potensi keuntungan itu tidak lepas dari risiko kerugian. Oleh sebab itu, investor perlu memahami pergerakan harga saham ASII.JK agar bisa menghadapi risiko dan ketidakpastian *return* di kemudian hari. Prediksi harga saham ASII.JK dapat menjadi salah satu cara untuk membantu

mengidentifikasi kemungkinan risiko tersebut. Metode ini menganalisis data historis untuk memperkirakan pergerakan harga saham di masa mendatang. Prediksi merupakan metode statistik yang menggunakan informasi masa lalu untuk memperkirakan kondisi di masa depan (Kruba et al., 2025). Hasil prediksi dapat memberi investor informasi tambahan untuk mengambil keputusan investasi yang lebih bijak. Kebanyakan investor saat ini masih mengandalkan analisis teknis, fundamental, dan sentimen untuk memprediksi harga saham, akan tetapi metode-metode ini dinilai kurang akurat. Pendekatan lain diperlukan, misalnya *Deep Learning* yang memiliki keunggulan dalam menghasilkan prediksi yang lebih akurat.

Deep Learning kini telah banyak dimanfaatkan dalam bidang keuangan, termasuk untuk memprediksi harga saham. *Gated Recurrent Unit* (GRU) merupakan salah satu algoritma dalam *Deep Learning* untuk tujuan tersebut. GRU merupakan varian dari *Recurrent Neural Network* (RNN) yang sering digunakan untuk data deret waktu yang bersifat berurutan karena mampu menangkap pola temporal dan hubungan non-linear, dengan arsitektur yang lebih sederhana dibandingkan dengan *Long Short-Term Memory* (LSTM). Hal ini karena GRU hanya memiliki dua gerbang utama, *update* dan *reset*, sehingga lebih efisien secara komputasi namun tetap efektif dalam mempelajari fluktuasi data harga saham (Danestiara et al., 2024).

Algoritma GRU memungkinkan investor memprediksi harga saham ASII.JK di masa depan berdasarkan data historis. Hasil prediksi ini menjadi dasar untuk menghitung nilai *return* saham, dan *return* tersebut dipakai untuk menganalisis risiko investasi melalui Value at Risk (VaR). Metode VaR merupakan pengukuran statistik untuk menghitung potensi kerugian maksimum investasi yang dapat terjadi dalam waktu tertentu pada tingkat kepercayaan tertentu. Terdapat tiga metode yang dapat digunakan untuk menghitung VaR, di antaranya simulasi historis, *variance-kovarian*, dan metode simulasi Monte Carlo. Penelitian ini menggunakan metode simulasi historis karena tidak mensyaratkan asumsi distribusi normal pada data. Metode ini lebih relevan dengan karakteristik data harga saham yang seringkali menunjukkan fenomena *fat tails* (Puspitorini & Risman, 2025).

Beberapa penelitian sebelumnya menggunakan GRU untuk memprediksi harga saham dan VaR untuk menganalisis risiko investasi. Penelitian oleh Danestiara et al. (2024) membuktikan bahwa GRU memiliki keunggulan dalam memprediksi harga penutupan saham indeks LQ45. Di sisi lain, penelitian oleh Puspitorini dan Risman (2025) membandingkan tiga metode VaR pada saham TLKM dan ICBP. Lebih lanjut, penelitian yang dilakukan oleh Dana et al. (2025) menggabungkan kedua metode ini pada saham ICBP. Namun, penelitian tersebut belum melakukan validasi pada nilai VaR yang diperoleh menggunakan *backtesting*. Validasi VaR penting bagi lembaga keuangan dan investor, guna memastikan bahwa estimasi VaR benar-benar mencerminkan risiko yang dihadapi di lapangan (Nurhaliza et al., 2025).

Berdasarkan uraian tersebut, penelitian ini bertujuan untuk menganalisis risiko kerugian investasi saham ASII.JK berdasarkan hasil prediksi algoritma GRU, di mana

hasil estimasi risiko tersebut divalidasi melalui *backtesting* untuk memastikan akurasi. Oleh sebab itu, penelitian ini berjudul **"Analisis Value at Risk (VaR) pada Prediksi Harga Saham Menggunakan Algoritma Gated Recurrent Unit (GRU)"**.

1.2 Rumusan Masalah

Merujuk pada latar belakang yang telah diuraikan sebelumnya, penelitian ini merumuskan dua masalah:

1. Bagaimana algoritma GRU dapat digunakan untuk memprediksi harga saham PT Astra International Tbk (ASII.JK)?
2. Bagaimana analisis risiko kerugian investasi saham PT Astra International Tbk (ASII.JK) menggunakan VaR?

1.3 Tujuan Penelitian

Berdasarkan pada rumusan masalah, penelitian ini bertujuan:

1. Menerapkan algoritma GRU untuk memprediksi harga saham PT Astra International Tbk (ASII.JK).
2. Menganalisis risiko kerugian investasi saham PT Astra International Tbk (ASII.JK) menggunakan VaR.

1.4 Batasan Masalah

Agar fokus dan ruang lingkup sesuai dengan tujuan yang telah dirumuskan, penelitian ini memiliki batasan sebagai berikut:

1. Penelitian ini hanya menggunakan data historis harga penutupan (*close price*) saham ASII.JK untuk periode 4 Januari 2021 hingga 31 Desember 2025.
2. Data dibagi menjadi tiga set, dengan proporsi 80% untuk data *training* (data latih), 10% untuk data *testing* (data uji), dan 10% untuk data *validation* (data validasi).
3. Arsitektur model dibangun dengan menggunakan dua *layer* GRU dengan 64 *neuron* pada masing-masing *layer*, *dropout* sebesar 0,1, dan *time step* 10.
4. Pengujian *hyperparameter* dilakukan pada kombinasi *batch size* (16, 32), *epoch* (50, 100), serta *learning rate* (0,0001, 0,001). Penentuan kombinasi *hyperparameter* optimal melalui metode *trial-and-error* berdasarkan nilai metrik evaluasi terendah.
5. Penelitian ini memprediksi harga saham untuk tujuh hari ke depan (peramalan jangka pendek). Hasil prediksi ini digabung dengan data aktual untuk mengestimasi nilai risiko.
6. Pengukuran tingkat risiko menggunakan VaR dengan pendekatan simulasi historis pada tingkat kepercayaan 95% dan 99%, mencakup tiga periode waktu,

yaitu 1 hari (VaR harian), 22 hari (VaR bulanan), dan 252 hari (VaR tahunan). Dengan asumsi modal awal investor sebesar Rp 1.000.000.

1.5 Landasan Teori

1.5.1 Saham dan Pasar Modal

Pasar modal didefinisikan sebagai tempat di mana transaksi terjadi antara pihak yang memiliki kelebihan dana (investor) dan pihak yang membutuhkan dana (emiten) melalui penerbitan instrumen keuangan jangka panjang seperti saham, obligasi, dan reksa dana (K et al., 2025). Purnamasari (2025) mendefinisikan saham sebagai instrumen yang secara langsung memberikan hak kepemilikan dalam sebuah perusahaan. Dengan membeli saham, investor dapat memperoleh potensi keuntungan (*return*) melalui dividen yang dibagikan oleh perusahaan atau melalui keuntungan modal (*capital gain*) jika harga saham mengalami kenaikan.

Namun, investasi pada saham juga memiliki risiko tinggi karena pergerakan harganya sangat fluktuatif, dipengaruhi oleh kinerja internal perusahaan, kondisi ekonomi makro, dan sentimen pasar global. Fluktuasi harga yang cepat (volatilitas) inilah yang menjadi sumber utama risiko pasar. Oleh karena itu, untuk mengelola ketidakpastian ini, investor memerlukan suatu alat ukur risiko yang cermat sebelum mengambil keputusan investasi.

1.5.2 Return dan Risiko Saham

Return dan risiko memiliki hubungan yang linear dan searah, artinya semakin tinggi *return* yang diharapkan, semakin tinggi pula tingkat risiko yang harus ditanggung. *Return* merupakan hasil yang diperoleh dari sebuah investasi, yang dapat berupa keuntungan ataupun kerugian (Fadhilah et al., 2024).

Salah satu cara yang banyak digunakan untuk menghitung *return* saham adalah dengan menggunakan metode *log return*. Jorion menjelaskan bahwa metode ini memiliki kelebihan dibanding dengan metode perhitungan *return* yang bersifat arimetrik, seperti saat harga aset berdistribusi normal maka *return* yang dihasilkan tidak akan bernilai negatif, metode dapat mempermudah investor saat ingin mengkonversi *return* atau risiko ke bentuk mata uang, dan mempermudah dalam ekspansi *multi periode* melalui penjumlahan linear. Persamaan untuk *return* saham menggunakan metode *log return* dituliskan dalam persamaan berikut.

$$R_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (1)$$

Dimana

R_t : log *return*

P_t : Harga saham pada periode ke- t

P_{t-1} : Harga saham pada periode ke t-1

Selain mempertimbangkan potensi *return*, investor wajib menilai tingkat risiko sebagai dasar dalam pengambilan keputusan investasi. Risiko didefinisikan sebagai tingkat potensi kerugian yang dihasilkan dari hasil investasi yang tidak terduga atau tidak sesuai harapan (Yulianti et al., 2023).

1.5.3 Value at Risk (VaR)

VaR didefinisikan sebagai metode statistik yang digunakan untuk mengukur potensi kerugian maksimum yang diharapkan (kerugian terburuk) dari suatu portofolio investasi selama periode waktu tertentu dalam tingkat kepercayaan tertentu (Jorion, 2007). Oleh karena itu, ada tiga komponen utama dalam perhitungan VaR, yaitu periode waktu (*holding period*), tingkat kepercayaan, dan besarnya kerugian. *Holding period* mewakili waktu yang dibutuhkan untuk melakukan lindung nilai terhadap risiko pasar. Semakin lama periode waktu investasi, maka semakin tinggi pula nilai VaR yang dimiliki. Pemilihan periode waktu bersifat subjektif dan tergantung dari jenis investasi yang dimiliki (Nurharyanto, 2011). Di sisi lain, pemilihan tingkat kepercayaan harus mencerminkan profil risiko investor, karena tingkat kepercayaan yang tinggi akan menghasilkan VaR yang lebih besar.

VaR dapat dihitung menggunakan metode *variance covariance*, metode simulasi historis, dan metode simulasi Monte Carlo. Ketiga metode ini memiliki perbedaan pada asumsi dan pendekatan yang digunakan. Metode *variance covariance* dan simulasi Monte Carlo bersifat parametrik, yang mengasumsikan *return* saham berdistribusi normal dan linear, sedangkan metode simulasi historis bersifat non-parametrik yang hanya menggunakan data historis sebenarnya tanpa asumsi distribusi (Puspitorini & Risman, 2025). Pendekatan parametrik memiliki kekurangan jika diaplikasikan pada data keuangan, karena sebagian besar data *return* aset keuangan memiliki ekor tebal (*fat tails*) pada distribusinya (Jorion, 2007). Kondisi ini sangat berisiko, mengingat VaR berfokus menangkap perilaku return portofolio pada ekor kiri. Sehingga model yang didasarkan pada distribusi normal akan meremehkan probabilitas kejadian ekstrem (*outlier*) dan nilai risiko yang sebenarnya.

1.5.4 Metode Simulasi Historis

Metode simulasi historis bersifat non-parametrik yang tidak memerlukan asumsi distribusi tertentu. Pendekatan ini mengandalkan harga aktual, sehingga memungkinkan non-linear dan distribusi non-normal. Menurut Jorion, metode ini memiliki kelebihan dibandingkan dengan metode lain, karena simulasi historis memperhitungkan distribusi *fat tails* sejauh distribusi tersebut ada dalam data historis. Metode ini juga kuat dan mudah dipahami, sehingga menjadikannya sebagai metode yang banyak digunakan untuk menghitung VaR. Berikut adalah persamaan yang digunakan untuk menghitung VaR dengan metode simulasi historis (Nurharyanto, 2011).

$$VaR = W_0 \times P_\alpha \times \sqrt{t} \quad (2)$$

Dimana

VaR : Besar potensi kerugian maksimum
 W_0 : Besarnya investasi awal
 P_α : Persentil ke- α
 t : Periode waktu

Dalam perhitungan VaR persentil menggambarkan ekspektasi kerugian investasi yang dapat diperoleh oleh investor pada taraf α . Penentuan letak persentil ke- α dari *return* yang telah diurutkan sebelumnya menggunakan persamaan berikut (Nuryanto et al., 2018).

$$P_\alpha = \alpha \times n \quad (3)$$

Dimana

α : Taraf signifikansi
 n : Banyaknya data historis

1.5.5 Time Series dan Prediksi

Data *time series* (deret waktu) merupakan jenis data yang dikumpulkan berdasarkan urutan waktu dalam suatu rentang waktu tertentu. Data deret Waktu mempunyai karakteristik autokorelasi, yaitu korelasi antara nilai pengamatan pada waktu t dengan nilai pada waktu-waktu sebelumnya ($t-1$, $t-2$,...) (Asrirawan et al., 2022), sehingga menjadikan data ini tidak bersifat independen.

Prediksi merupakan istilah lain untuk peramalan dan perkiraan. Menurut Sulastris dan Ramadhani (2025) peramalan adalah metode terstruktur untuk memperkirakan hasil yang mungkin terjadi di masa depan menggunakan informasi masa lalu dan masa kini, dengan tujuan untuk menghasilkan estimasi yang akurat. Tombilayuk (2025) mengklasifikasikan peramalan menjadi tiga jenis berbeda berdasarkan jangka waktunya, yaitu.

1. Peramalan jangka pendek, yaitu peramalan yang memproyeksikan hasil untuk masa dengan periode kurang dari 3 bulan.
2. Peramalan jangka menengah, mencakup rentang waktu 3 hingga 18 bulan ke depan.
3. Peramalan jangka panjang, yaitu peramalan dengan periode lebih dari 18 bulan ke depan.

1.5.6 Normalisasi

Normalisasi data merupakan teknik untuk mengubah rentang nilai dari berbagai variabel dalam sebuah data set, dengan menyesuaikan nilai-nilainya sehingga tidak ada satu variabel terlalu besar atau terlalu kecil. Tujuan dari proses ini untuk menciptakan keseimbangan skala antar variabel (Beti & Juliansa, 2024).

Salah satu pendekatan yang sering digunakan untuk normalisasi data adalah *Min-Max Normalization*, metode ini mengubah skala data ke dalam suatu rentang tertentu, umumnya antara 0 hingga 1. Berikut adalah persamaan dari metode ini (Reza & Ghuftron, 2025).

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (4)$$

Dimana

- X_{scaled} : Nilai data setelah dinormalisasi
- X : Nilai data asli.
- X_{min} : Nilai minimum dari seluruh data pada fitur tersebut
- X_{max} : Nilai maksimum dari seluruh data pada fitur tersebut

1.5.7 Deep Learning

Deep Learning merupakan salah satu cabang lanjutan dari *Machine Learning* yang dikembangkan dari model *perceptron* (jaringan saraf tiruan) yang terinspirasi dari jaringan syaraf otak manusia (Perdana et al., 2025). Konsep ini, pertama kali diperkenalkan oleh Ivakhnenko et al. pada tahun 1967. Di antara berbagai algoritmanya, dua di antaranya adalah *Convolutional Neural Network* (CNN) dan *Recurrent Neural Network* (RNN), di mana RNN sangat cocok untuk mengolah dan menganalisis data deret waktu, seperti data harga saham, karena arsitekturnya dirancang untuk mempertahankan informasi dari langkah waktu sebelumnya.

1.5.8 Recurrent Neural Network (RNN)


Recurrent Neural Network (RNN) merupakan pengembangan dari model *Artificial Neural Network* (ANN) yang didesain untuk menangani data *sequence* (Nielsen, 2022). Perbedaan utama dari kedua jaringan saraf ini terletak pada *loop* internalnya, pada RNN terdapat memori yang memungkinkan nilai-nilai sebelumnya sebagai output untuk prediksi di masa depan dengan hubungan berulang pada *hidden layers* (Marietta et al., 2025). Mekanisme ini memungkinkan RNN mengatasi masalah *overfitting* dan *underfitting* serta mempercepat proses pelatihan. Akan tetapi, RNN biasa memiliki keterbatasan dalam menangani informasi jangka panjang sehingga menyebabkan masalah *vanishing gradient* (gradien menghilang). Masalah ini

menyebabkan RNN tidak mampu menangkap pola ketergantungan jangka panjang, yang mengakibatkan berkurangnya akurasi prediksi. Ketidakmampuan ini mendorong pengembangan arsitektur yang lebih canggih, seperti *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU) (Marietta et al., 2025).

1.5.9 Gated Recurrent Unit (GRU)

Gated Recurrent Unit (GRU) pertama kali diperkenalkan oleh Cho et al. (2014), yang merupakan varian dari RNN dan alternatif sederhana dari model LSTM. Secara struktural GRU mirip dengan LSTM, namun GRU menggabungkan fungsi *input gate* dan *forget gate* menjadi satu mekanisme yang disebut *update gate* (Sezgin et al., 2025). Gerbang ini berfungsi mengontrol seberapa banyak informasi masa lalu yang dibutuhkan untuk *input* saat ini. GRU juga memiliki *reset gate* yang berfungsi mengontrol seberapa banyak informasi masa lalu yang tidak dibutuhkan. Lebih lanjut, GRU menggabungkan *cells state* dan *hidden state* menjadi satu representasi, sehingga parameter yang digunakan lebih sedikit dibanding LSTM. Penyederhanaan ini dapat meningkatkan efisiensi komputasi dan mempercepat proses konvergensi tanpa mengurangi akurasi prediksi (Perdana et al., 2025).

Mekanisme *gating* yang digunakan pada GRU dan LSTM memiliki kelebihan dalam mengatasi masalah ketergantungan jangka panjang, serta masalah *overfitting* dan *underfitting* pada jaringan saraf, sehingga menghasilkan kesalahan prediksi relatif kecil (Zhang et al., 2024). Oleh karena itu, GRU sering dipilih dalam berbagai aplikasi praktis. Arsitektur GRU dapat dilihat pada Gambar 1.



Sumber: Marietta et al., 2025

Gambar 1. Arsitektur GRU

Menurut Chung et al. dalam (Marietta et al., 2025) algoritma pada GRU adalah sebagai berikut.

1.5.9.1 Reset Gate

Reset gate menerima *input* saat ini dan *hidden state time step* sebelumnya. *Reset gate* akan menentukan banyaknya informasi dari *time step* sebelumnya yang akan dilupakan dengan menggunakan fungsi aktivasi sigmoid. Nilai *reset gate* mendekati

0 memaksa model untuk mengabaikan sebagian besar histori dan fokus pada *input* saat ini, yang berguna ketika terjadi perubahan tren yang signifikan di pasar. Persamaan *reset gate* dapat dilihat pada persamaan 5.

$$r_t = \sigma(b_r + U_r x_t + W_r h_{t-1}) \quad (5)$$

Dimana

r_t	: <i>Reset gate</i>
σ	: Fungsi aktivasi sigmoid
U_r dan W_r	: Bobot untuk <i>input</i> dan <i>hidden state</i>
x_t	: <i>Input</i> di waktu t
h_{t-1}	: <i>Hidden state time step</i> sebelumnya
b_r	: Bias <i>reset gate</i>

1.5.9.2 Update gate

Update gate mengontrol seberapa banyak informasi dari *hidden state* sebelumnya yang akan dipertahankan, menggunakan fungsi aktivasi sigmoid. Nilai *update gate* mendekati 0 berarti model mempertahankan hampir seluruh informasi masa lalu, sementara nilai mendekati 1 berarti model lebih mengandalkan kandidat *hidden state* baru. Persamaan *update gate* dapat dilihat pada persamaan 6.

$$z_t = \sigma(b_z + U_z x_t + W_z h_{t-1}) \quad (6)$$

Dimana

z_t	: <i>Update gate</i>
U_z dan W_z	: Bobot untuk <i>input</i> dan <i>hidden state</i>
h_{t-1}	: <i>Hidden state time step</i> sebelumnya
b_z	: Bias <i>update gate</i>

1.5.9.3 Hidden State Candidate

Hidden state candidate menyimpan informasi penting yang diproses di *reset gate*, dengan menerapkan perkalian *element wise* dan fungsi aktivasi *hyperbolic tangent* (tanh). Persamaan *Hidden state candidate* dapat dilihat pada persamaan 7.

$$\tilde{h}_t = \tanh(b_h + U_h x_t + W_h [r_t \odot h_{t-1}]) \quad (7)$$

Dimana

- $\tilde{h}_t$: *Hidden state candidate*
 $\tanh$: Fungsi aktivasi tanh
 W_h : Bobot lapisan *input hidden state candidate*
 U_h : Bobot lapisan *hidden state candidate*
 b_h : Bias *update gate hidden state candidate*

1.5.9.4 Hidden State

Hidden state baru dibentuk dengan menggabungkan nilai *update gate* dan *hidden state candidate* dengan *update gate* dengan *hidden state* sebelumnya. Persamaan *Hidden state* baru dapat dilihat pada persamaan 8. (Aryati et al., 2024)

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (8)$$

Dimana

h_t : *Hidden state* baru

Persamaan tersebut menunjukkan bahwa *hidden state* pada waktu ke- t merupakan kombinasi antara informasi historis dan informasi baru. Mekanisme ini memungkinkan GRU membentuk prediksi berdasarkan informasi historis yang telah dipelajari sebelumnya (Cho et al., 2014), sehingga saat terjadi perubahan pola harga secara mendadak, model akan membutuhkan beberapa langkah waktu untuk menyesuaikan diri dengan perubahan pola tersebut. Akibatnya, hasil prediksi akan terlihat sedikit tertinggal atau *lag* dibandingkan dengan data aktual pada waktu-waktu perubahan yang tajam.

1.5.10 Hyperparameter

Hyperparameter didefinisikan sebagai konfigurasi yang berada di luar model yang nilainya tidak dapat diperkirakan atau diukur dari data (Yudistira et al., 2023). *Hyperparameter* berfungsi untuk mengontrol perilaku model. Pemilihan konfigurasi *hyperparameter* yang tepat sangat penting dalam membangun model yang baik.

1.5.10.1 Neuron

Neuron merupakan salah satu parameter utama pada jaringan saraf tiruan yang berperan menentukan kapasitas model dalam mengenali pola data. Satu *neuron* pada lapisan tersembunyi mewakili satu dimensi *hidden state*, yang berfungsi sebagai memori internal untuk menyimpan informasi masa lalu. Semakin banyak *neuron* yang digunakan, kemampuan model dalam menangkap pola data juga semakin tinggi. Namun, *neuron* yang berlebihan dapat membuat model terlalu

mengafal data latih dan risiko menimbulkan *overfitting*. Dana et al. (2025) menyarankan pemilihan 64 *neuron* untuk model GRU yang lebih sederhana, konfigurasi ini menawarkan kapasitas yang cukup untuk menangkap pola temporal pada data tanpa menimbulkan kompleksitas yang berlebihan.

1.5.10.2 Layer

Layer memainkan peran dalam menentukan kedalaman model memproses sebuah data, menangkap pola serta berpengaruh pada kompleksitas komputasi. Kinerja keseluruhan model bergantung pada jumlah lapisan yang digunakan. Model dengan jumlah lapisan yang lebih banyak terkadang memiliki kemampuan yang lebih baik, seperti yang telah dibuktikan oleh Faris et al. (2025). Karena lapisan yang lebih banyak akan menangkap fitur yang lebih dalam dan hubungan non-linear pada data. Namun penambahan lapisan yang berlebih juga memiliki risiko *overfitting* dan beban komputasi yang tinggi.

1.5.10.3 Dropout

Dropout merupakan lapisan yang berfungsi sebagai regulasi untuk mencegah *overfitting* dengan menonaktifkan *neuron* secara acak selama proses pelatihan. *Dropout* dapat disesuaikan dari 0 hingga 0,5 untuk setiap lapisan (Sutarna et al., 2024).

1.5.10.4 Batch size

Batch size merujuk pada jumlah sampel data yang digunakan pada satu kali iterasi selama pelatihan. *Batch size* dapat mempengaruhi kecepatan pelatihan, konvergensi, dan akurasi model. Goodfellow menyatakan bahwa *batch size* yang lebih besar memberikan estimasi gradien yang lebih akurat, namun hasil yang diperoleh kurang linear karena jumlah memori yang dibutuhkan akan meningkat seiring bertambahnya *batch size*. Menurut Kandel dan Castelli (2020) *batch size* harus merupakan pangkat 2 agar menyesuaikan dengan pemrosesan GPU. Secara praktis, untuk menentukan *batch size* yang optimal beberapa penelitian menyarankan *batch size* yang lebih kecil terlebih dahulu yaitu 16, 32, dan 64 (Raiaan et al., 2024).

1.5.10.5 Learning Rate

Learning rate menentukan seberapa cepat model dalam memperbarui bobot dan biasanya di setiap iterasi selama proses pelatihan. Menurut Goodfellow, pemilihan *learning rate* yang tidak tepat, baik terlalu tinggi atau terlalu rendah. Ldapat mengakibatkan kegagalan optimisasi sehingga menghasilkan model dengan kapasitas efektif rendah. *Learning rate* yang terlalu rendah dapat memperlambat

proses pembelajaran sehingga beban komputasi jadi lebih tinggi. Menurut Sutarna et al. (2024) *learning rate* yang optimal berkisar antara 0,0001 hingga 0,1.

1.5.10.6 Epoch

Epoch merupakan *hyperparameter* yang menentukan berapa kali sebuah model melakukan iterasi pada keseluruhan dataset selama pelatihan. Satu *epoch* mewakili satu iterasi seluruh data training, pada setiap *epoch* model akan memperbarui bobot berdasarkan gradien dari kesalahan data training. *Epoch* yang terlalu kecil dapat mengakibatkan model tidak belajar secara efektif sehingga pelatihan model menjadi kurang baik. Menurut BJ et al. (2023) *epoch* yang lebih besar akan mendukung pelatihan mengenai pola yang kompleks dan dapat meminimalkan *error*.

1.5.10.7 Time Step

Time step merujuk pada jumlah langkah waktu yang digunakan untuk membentuk urutan data yang akan digunakan sebagai *input* untuk memprediksi nilai target. *Time step* yang besar memungkinkan model untuk menangkap lebih banyak informasi historis, namun akan dapat menghambat efisiensi proses pembelajaran. Penelitian yang dilakukan Aryati et al. (2024) meneliti pengaruh *time step* terhadap kinerja model GRU yang menunjukkan *time step* pendek memberikan hasil prediksi yang lebih baik karena struktur datanya sederhana sesuai dengan karakteristik arsitektur GRU.

1.5.10.8 Optimizer

Optimizer merujuk pada metode optimasi yang berbasis gradien stokastik yang digunakan untuk melatih model dengan menyesuaikan bobot dan *learning rate* untuk meminimalkan fungsi kerugian. Raiaan et al. (2024) menyarankan penggunaan *optimizer* Adam (*Adaptive Moment Estimation*), *optimizer* ini telah menggabungkan fitur RMSProp, momentum Nesterov dan *optimizer* AdGrad (*Adaptive Gradient*), yang dapat mempercepat proses konvergensi pada saat pelatihan. Selain itu *optimizer* Adam memiliki keunggulan pada efisiensi memorinya dibanding dengan *optimizer* lainnya.

1.5.10.9 Loss Function

Loss function merupakan fungsi yang digunakan untuk mengukur kesalahan yang terjadi pada model selama masa pelatihan. Semakin tinggi nilai *loss function* menandakan model menghasilkan akurasi yang buruk, sedangkan *loss function* yang rendah menunjukkan hasil yang baik (Raiaan et al., 2024).

1.5.11 Metrik Evaluasi

Untuk mengevaluasi kinerja model, penelitian ini menggunakan metrik *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE) dan *Mean Absolute Percentage Error* (MAPE). Metrik ini dipilih karena penggunaannya yang luas dalam analisis deret waktu dan kemampuannya memberikan gambaran performa model yang menyeluruh. Berikut ini merupakan penjelasan mengenai ketiga metrik yang digunakan.

1.5.11.1 Root Mean Square Error (RMSE)

RMSE merupakan akar kuadrat dari *Mean Square Error* (MSE) yang menggambarkan selisih antara hasil prediksi dengan nilai aktualnya. Persamaan RMSE dinyatakan sebagai berikut.

$$RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2} \quad (9)$$

Dimana

$\hat{y}_i$: Nilai prediksi
 y_i : Nilai aktual
 n : Banyaknya data

RMSE banyak digunakan dalam evaluasi model peramalan karena sifatnya yang lebih menekankan pada kesalahan yang besar dibanding dengan metrik lain (Jahin et al., 2025), sehingga memberikan gambaran yang seimbang tentang kinerja model secara menyeluruh.

1.5.11.2 Mean Absolute Error (MAE)

MAE didefinisikan sebagai rata-rata dari selisih absolut antara nilai prediksi dengan nilai aktual (Diqi et al., 2024). MAE dihitung menggunakan persamaan berikut ini.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (10)$$

Dimana

$\hat{y}_i$: Nilai prediksi
 y_i : Nilai aktual
 n : Banyaknya data

Menurut Jahin et al. (2025), MAE memberlakukan semua kesalahan secara adil dan apa adanya, bukan hanya memberikan hukuman berlebihan pada kesalahan yang besar saja. Hal tersebut menjadikan MAE sebagai metrik evaluasi yang cocok untuk hasil yang konsisten.

1.5.11.3 Mean Absolute Percentage Error (MAPE)

MAPE didefinisikan sebagai selisih rata-rata antara nilai prediksi dan nilai aktual, yang diinterpretasikan sebagai persentase. MAPE banyak digunakan untuk mengukur kesalahan prediksi karena nilai yang dihasilkan lebih mudah dipahami dan diinterpretasikan (Laras & Mujiono, 2019). Nilai ini dapat ditentukan dengan menggunakan persamaan berikut.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (11)$$

Dimana

$\hat{y}_i$: Nilai prediksi

y_i : Nilai aktual

n : Banyaknya data

Setelah memperoleh nilai MAPE, model peramalan dapat diklasifikasikan secara sistematis berdasarkan tingkat akurasinya. Klasifikasi ini memungkinkan interpretasi terstruktur terhadap kinerja prediktif model, seperti yang ditunjukkan pada tabel 1 di bawah ini.

Tabel 1. Range MAPE Value

Range MAPE	Arti
<10%	Tingkat akurasi sangat baik
10-20%	Tingkat akurasi baik
20%-50%	Tingkat akurasi layak
>50%	Tingkat akurasi buruk

Sumber : Khairunisa dan Hendikawati, 2024

1.5.12 Backtesting

Backtesting digunakan untuk menguji validitas hasil perhitungan VaR. Jorion mendefinisikan *backtesting* sebagai suatu metode statistik yang membandingkan antara kerugian aktual dengan nilai kerugian yang diestimasi. Dalam hal ini VaR dibandingkan dengan *return* portofolio saham atau verifikasi model berdasarkan

failure rate (tingkat kegagalan). Estimasi tingkat kegagalan dihitung dengan persamaan berikut (Rosyidah et al., 2024).

$$N = \sum_{t=1}^T I_t \quad (12)$$

dengan,

$$I_t = \begin{cases} 1, & \text{jika } R_t < VaR \\ 0, & \text{jika } R_t \geq VaR \end{cases} \quad (13)$$

Dimana

N : Banyaknya pelanggaran aktual

Selanjutnya, nilai tingkat kegagalan tersebut digunakan dalam pengujian statistik formal pada uji *Kupiec (Kupiec Test)* yang juga dikenal sebagai uji *Proportion of Failure (POF)*. Statistik uji pada *Kupiec test* menggunakan pendekatan *log likelihood ratio* dengan persamaan sebagai berikut (Bukit & Hendratno, 2021).

$$LR = -2 \ln[(1 - \alpha)^{T-N} \alpha^N] + 2 \ln \left\{ \left[1 - \frac{N}{T} \right]^{T-N} \left(\frac{N}{T} \right)^N \right\} \quad (14)$$

Dimana

LR : *Log likelihood ratio*

α : Taraf signifikan

T : Jumlah data

Pada taraf signifikansi α , jika nilai $LR < \chi^2_{(\alpha;1)}$ dan $p - value > \alpha$ maka perhitungan VaR diterima (valid). Sebaliknya, apabila nilai $LR > \chi^2_{(\alpha;1)}$ dan $p - value < \alpha$ maka model VaR ditolak (tidak valid).

BAB II. METODOLOGI PENELITIAN

2.1 Pendekatan dan Jenis Penelitian

Pada penelitian ini, metode yang diterapkan yaitu metode kuantitatif dengan pendekatan analitis untuk memprediksi harga saham menggunakan algoritma GRU. Hasil prediksi selanjutnya digunakan untuk mengukur potensi kerugian maksimum investasi saham menggunakan metode VaR dengan pendekatan simulasi historis dan validitas dengan *backtesting*.

2.2 Jenis dan Sumber Data

Penelitian ini menggunakan data sekunder yang diperoleh dari situs resmi Yahoo Finance, berupa data historis harga penutupan saham ASII.JK untuk periode 4 Januari 2021 hingga 31 Desember 2025. Rentang ini mencakup berbagai kondisi pasar, seperti pemulihan pasca-pandemi COVID-19 (2021-2022), periode normalisasi ekonomi (2023-2024), dan kondisi pasar terkini (tahun 2025).

2.3 Metode Analisis Data


Penelitian ini melakukan analisis data melalui tahapan berikut:

1. Mengumpulkan data harga penutupan saham ASII.JK dari situs www.finance.yahoo.com untuk periode waktu 4 Januari 2021 hingga 31 Desember 2025.
2. Melakukan *Exploratory Data Analysis* (EDA) untuk memberikan gambaran karakteristik data dan pola pergerakan harga penutupan saham ASII.JK.
3. Melakukan *preprocessing* data agar data yang masih mentah siap digunakan dalam pemodelan dan sesuai dengan kriteria model, sehingga menghasilkan hasil yang lebih optimal. Proses ini melalui tiga tahap yaitu:
 - a. Data *cleaning*, yaitu membersihkan data mentah untuk memastikan kualitas data yang digunakan. Dalam tahapan ini bisa dilakukan untuk menangani data yang hilang dan menghapus data duplikat.
 - b. Normalisasi data, yaitu mengubah data ke rentang 0-1 dengan teknik *Min-Max Normalization* menggunakan persamaan (4).
 - c. Membagi data menjadi tiga set, yaitu 80% data latih, 10% data uji, dan 10% data validasi.
4. Membangun arsitektur model GRU, mencakup konfigurasi lapisan GRU, *dropout*, *neuron* pada *hidden layer*, dan *time step*.
5. Melatih model menggunakan *optimizer* ADAM dengan memperhatikan konfigurasi *learning rate* dan *loss function*.

6. Menguji *hyperparameter* dengan mencoba setiap kombinasi untuk menentukan nilai *learning rate*, *epoch* dan *batch size* terbaik. Kombinasi terbaik dipilih berdasarkan nilai kesalahan terendah pada metrik RMSE, MAE, dan MAPE.
7. Memprediksi harga saham untuk tujuh hari ke depan menggunakan model terbaik.
8. Mengubah harga saham aktual dan prediksi menjadi *return* saham menggunakan persamaan (1).
9. Menghitung VaR dengan metode simulasi historis melalui tiga langkah:
 - a. Mengurutkan *return* dari yang terkecil ke terbesar
 - b. Menghitung nilai persentil ke- α dengan persamaan (3)
 - c. Menghitung VaR dengan persamaan (2)
10. Memvalidasi hasil perhitungan VaR melalui *backtesting* dengan Kupiec Test.

2.4 Alur Kerja

Alur kerja penelitian secara menyeluruh dapat dilihat pada Gambar 2. yang mewakili setiap tahapan dalam proses analisis data pada penelitian ini.



Gambar 2. Alur Kerja

BAB III.

HASIL DAN PEMBAHASAN

3.1 Hasil

3.1.1 Pengumpulan Data

Penelitian ini menggunakan data historis harga penutupan (*close price*) saham ASII.JK yang diambil dari web *Yahoo Finance*, dengan rentang waktu 4 Januari 2021 hingga 31 Desember 2025. Data mentah yang berhasil dikumpulkan berjumlah 1.208 observasi dan terdiri dari 2 kolom, yakni kolom *Date* dan *Close*, yang disajikan pada Tabel 2.

Tabel 2. Data Harga Penutupan Saham ASII.JK

Date	Close
2021-01-04	4361,848633
2021-01-05	4326,812988
2021-01-06	4309,295898
2021-01-07	4256,744141
2021-01-08	4501,987793
...	...
2025-12-25	6625,000000
2025-12-26	6625,000000
2025-12-29	6675,000000
2025-12-30	6700,000000
2025-12-31	6700,000000

Sumber : Yahoo Finance

3.1.2 Exploratory Data Analysis (EDA)

3.1.2.1 Statistik Deskriptif

Statistik deskriptif memberikan gambaran umum atau deskripsi mengenai data dalam bentuk rata-rata, simpangan baku, varians, nilai tertinggi, nilai terendah, jumlah, dan rentang. Jenis analisis ini hanyalah teknik untuk memberikan informasi tentang data yang ada, tanpa tujuan untuk menguji hipotesis apa pun. Adapun ringkasan statistik deskriptif harga penutupan saham ASII.JK selama periode penelitian dirangkum dalam Tabel 3.

Tabel 3. Statistik Deskriptif Harga Penutupan Saham ASII.JK


Parameter Statistik	Close
<i>Count</i>	1208
<i>Mean</i>	4607,075015
<i>Std</i>	654,185426
<i>Min</i>	3310, 616699
25%	4202,649902
50%	4515,879883
75%	4933,875610
<i>Max</i>	6725,000000

Sumber : Data diolah, 2025

Tabel 3 menyajikan statistik deskriptif harga penutupan saham ASII.JK selama periode penelitian. Berdasarkan tabel tersebut, harga saham ASII.JK bergerak dalam rentang harga Rp 3.310,61 hingga Rp 6.725,00, dengan nilai harga rata-rata sebesar Rp 4.607,08 dan standar deviasi sebesar 654,19.

3.1.2.2 Visualisasi Tren Data


Gambar 3 menyajikan tren pergerakan harga penutupan harian saham ASII.JK selama periode 2021 hingga 2025.

**Gambar 3.** Plot Tren Harga Penutupan Saham ASII.JK

Berdasarkan Gambar 3, pergerakan harga penutupan saham ASII.JK selama lima tahun terakhir menunjukkan fluktuasi yang cukup tinggi, terlihat dengan pola musiman yang diikuti oleh tren naik dan turun.

3.1.2.3 Visualisasi Distribusi Data

Gambar 4 menyajikan distribusi harga penutupan saham ASII.JK selama periode pengamatan menggunakan histogram dan plot *Kernel Density Estimation* (KDE).



Gambar 4. Distribusi Data Harga Penutupan Saham ASII.JK

Berdasarkan Gambar 4, dapat dilihat bahwa sebagian besar data terpusat pada kisaran harga Rp 4.200 hingga Rp 4.600, dan terdapat sebaran data tambahan pada rentang harga sekitar Rp 6.500.

3.1.3 Preprocessing Data

3.1.3.1 Normalisasi Data

Data harga penutupan saham diproses menggunakan pendekatan *Min-Max Normalization* sehingga semua data berada dalam rentang 0 hingga 1. Hasil dari proses normalisasi ini disajikan dalam tabel 4.

Tabel 4. Data Harga Penutupan Saham Setelah Dinormalisasi

Date	Sebelum Normalisasi	Setelah Normalisasi
2021-01-04	4361,848633	0,307883
2021-01-05	4326,812988	0,297622
2021-01-06	4309,295898	0,292492
2021-01-07	4256,744141	0,2771
2021-01-08	4501,987793	0,348927
...	...	...
2025-10-27	6625,000000	0,970712
2025-10-28	6625,000000	0,970712

Lanjutan Tabel 4.

Date	Sebelum Normalisasi	Setelah Normalisasi
2025-10-29	6675,000000	0,985356
2025-10-30	6700,000000	0,992678
2025-10-31	6700,000000	0,992678

Sumber : Data diolah, 2026

Tabel 4 menyajikan perbandingan data sebelum dan sesudah proses normalisasi, dengan nilai asli 6.675,00 dan telah dinormalisasi menjadi 0,985356.

3.1.3.2 Pembagian Data

Pembagian *dataset* dalam penelitian ini terdiri atas data *training*, *validation*, dan *testing*. Data *training* digunakan untuk pelatihan model, data *validation* untuk penyesuaian *hyperparameter*, dan data *testing* untuk pengujian performa akhir model. Hasil pembagian *dataset* ini dapat dilihat pada Tabel 5.

Tabel 5. Proporsi Pembagian Data

Proporsi	Data Latih	Data Validasi	Data Uji
80:10:10	967	121	121

Sumber : Data diolah, 2026

3.1.4 Pemodelan GRU

3.1.4.1 Desain Arsitektur GRU

Arsitektur model GRU yang dibangun merupakan model sekuensial (berurutan), dengan pengoptimalan jumlah lapisan, *unit*, *time step* serta tingkat *dropout*. Tabel 6. menyajikan arsitektur model GRU yang dibangun.

Tabel 6. Ringkasan Model

Layer (Type)	Output Shape	Param (#)
gru (GRU)	(None, 10, 64)	12,864
dropout (Dropout)	(None, 10, 64)	0
gru_1 (GRU)	(None, 64)	24,96
dropout_1 (Dropout)	(None, 64)	0
Dense (Dense)	(None, 1)	65

Sumber : Data diolah, 2026

Tabel 6. menyajikan arsitektur model GRU yang dibangun, terdiri atas lima *layer*: dua *layer* GRU, dua *layer Dropout*, dan satu *layer Dense*. *Layer* GRU pertama memiliki 64 unit dengan panjang 10 *time step* dan konfigurasi *return_sequences=True*. *Layer Dropout* pertama menonaktifkan 10% *neuron* secara acak selama pelatihan. *Layer* GRU kedua memiliki 64 unit dengan konfigurasi *return_sequences=False*. *Layer Dropout* kedua menonaktifkan 10% *neuron*. *Layer* terakhir berupa *Dense* dengan 1 unit sebagai *output*.

3.1.4.2 Pengujian *Hyperparameter*

Pengujian *Hyperparameter* dilakukan terhadap 12 kombinasi parameter menggunakan tiga metrik evaluasi, yaitu RMSE, MAE, dan MAPE. Hasil Pengujian dapat dilihat pada Tabel 7.

Tabel 7. Hasil Pengujian *Hyperparameter*


Learning Rate	Batch size	Epoch	RMSE	MAE	MAPE
0,0001	16	50	134,69	102,50	1,75%
		100	136,04	107,42	1,82%
	32	50	155,60	115,39	1,97%
		100	133,13	102,08	1,74%
	64	50	153,62	109,14	1,88%
		100	143,74	105,49	1,81%
0,001	16	50	111,61	80,47	1,39%
		100	108,76	79,19	1,37%
	32	50	116,18	86,87	1,49%
		100	111,18	80,46	1,39%
	64	50	116,52	88,89	1,52%
		100	116,68	87,31	1,49%

Sumber : Data diolah, 2026

Berdasarkan Tabel 7. hasil pengujian *hyperparameter* menunjukkan bahwa model optimal diperoleh dari konfigurasi model dengan *learning rate* 0,001, *batch size* 16, dan *epoch* 100, yang menghasilkan nilai RMSE 108,76, MAE 79,19, dan MAPE 1,37%.

3.1.5 Pelatihan dan Validasi Model

Gambar 5. menyajikan grafik *train loss* dan *validation loss* selama proses pelatihan model dengan konfigurasi terbaik.




Gambar 5. Plot Training & Validation Loss

Berdasarkan Gambar 5. *nilai train loss* dan *validation loss* mengalami penurunan tajam pada awal proses pelatihan dengan fluktuasi kecil namun cenderung stabil seiring bertambahnya *epoch*.

3.1.6 Prediksi Harga Saham

3.1.6.1 Prediksi Data Uji

Grafik perbandingan antara harga aktual dan harga yang prediksi untuk data uji menggunakan model terbaik ditampilkan pada Gambar 6. Garis biru menunjukkan harga aktual, sedangkan garis putus-putus merah menunjukkan harga yang diprediksi oleh model.



Gambar 6. Plot Perbandingan Harga Prediksi & Aktual Hasil Pengujian Model

Berdasarkan Gambar 6. dapat dilihat bahwa model mampu menangkap pola dan tren pergerakan harga dengan cukup baik, meskipun pada beberapa titik terdapat penyimpangan yang signifikan antara harga yang diprediksi dan harga aktual. Hasil

prediksi dengan data aktual yang diambil dari 14 Juli 2025 hingga 31 Desember 2025, ditunjukkan pada Tabel 8.

Tabel 8. Perbandingan Hasil Prediksi & Data Uji Model


Date	Harga Aktual	Harga Prediksi
2025-07-14	4620,586426	4627,000000
2025-07-15	4620,586426	4625,000000
2025-07-16	4669,741211	4622,000000
2025-07-17	4709,065430	4665,000000
2025-07-18	4669,741211	4706,000000
...	...	...
2025-12-25	6625,000000	6597,000000
2025-12-26	6625,000000	6623,000000
2025-12-29	6675,000000	6615,000000
2025-12-30	6700,000000	6659,000000
2025-12-31	6700,000000	6691,000000

Sumber : Data diolah, 2026

Secara keseluruhan, Tabel 8. menunjukkan bahwa model GRU menghasilkan prediksi yang sangat mendekati harga aktual, terlihat harga prediksi memiliki selisih yang relatif kecil dari harga sebenarnya.

3.1.6.2 Prediksi Harga Saham ASII.JK 7 Hari ke Depan

Setelah proses pelatihan dan evaluasi model menggunakan data uji menunjukkan hasil prediksi yang cukup baik, dilanjutkan dengan memprediksi harga saham ASII.JK untuk jangka pendek, yaitu untuk 7 hari ke depan. Prediksi harga saham ASII.JK untuk 7 hari ke depan dilakukan menggunakan metode *recursive forecasting*, dengan output prediksi sebelumnya digunakan sebagai *input* pada prediksi hari berikutnya. Dengan kata lain, hasil tersebut sebagai kelanjutan dari pola pergerakan harga yang telah dipelajari oleh model. Grafik hasil prediksi dapat dilihat pada Gambar 7.



Gambar 7. Plot Hasil Prediksi 7 Hari ke Depan

Berdasarkan Gambar 7. hasil prediksi menunjukkan tren kenaikan yang stabil, dengan harga yang naik secara bertahap dibandingkan dengan harga penutupan pada periode data historis. Hasil prediksi harga saham dapat dilihat pada Tabel 9.

Tabel 9. Hasil Prediksi ASII.JK Selama 7 Hari

Date	Harga Prediksi
2026-01-01	6691,963379
2026-01-02	6688,767090
2026-01-05	6688,829102
2026-01-06	6689,012695
2026-01-07	6688,761719
2026-01-08	6688,400879
2026-01-09	6688,080566

Sumber : Data diolah, 2026

Berdasarkan hasil pada Tabel 9. terlihat bahwa model memberikan perkiraan yang cukup stabil mengenai arah pergerakan harga saham ASII.JK. dalam kisaran 6.691,963379 hingga 6.688,829102 untuk 7 hari ke depan.

3.1.7 Perhitungan *Return*

Data hasil prediksi 7 hari kemudian digabung dengan data harga penutupan sebelumnya untuk menghitung *return* harian menggunakan persamaan 1 . Hasil perhitungan *return* ini disajikan dalam Tabel 10.

Tabel 10. Hasil Perhitungan *Return*

Date	Close	Log Return
2021-01-04	4361,848633	
2021-01-05	4326,812988	-0,008064
2021-01-06	4309,295898	-0,004057
2021-01-07	4256,744141	-0,012270
2021-01-08	4501,987793	0,056015
...	...	...
2026-01-05	6688,829102	0,000009
2026-01-06	6689,012695	0,000027
2026-01-07	6688,761719	-0,000038
2026-01-08	6688,400879	-0,000054
2026-01-09	6688,080566	-0,000048

Sumber : Data diolah, 2026

Tabel 10. menyajikan hasil perhitungan *log return* untuk periode 4 Januari 2021 hingga 9 Januari 2026. *Return* yang bernilai negatif menunjukkan adanya kerugian dan yang positif menunjukkan keuntungan.

3.1.8 Perhitungan VaR

Perhitungan VaR menggunakan metode simulasi historis dengan tingkat kepercayaan 95% dan 99% untuk periode 1 hari, 22 hari, dan 225 hari. Perhitungan didasarkan pada asumsi investasi awal sebesar Rp 1.000.000. Ringkasan hasil perhitungan tersebut disajikan pada Tabel 11.

Tabel 11. Hasil Perhitungan VaR


Tingkat Kepercayaan	Modal (Rp)	VaR	VaR		
			1 Hari	22 Hari	252 Hari
95%	1.000.000	-0,0252	-25.190,20	-118.152,51	-399.882,03
99%		-0,0402	-40.224,91	-188.671,54	-638.550,60

Sumber : Data diolah, 2026

Berdasarkan hasil perhitungan VaR yang diperoleh pada Tabel 11. Pada tingkat kepercayaan 95%, VaR diestimasi sebesar -0,0252, dengan estimasi kerugian harian, bulanan, dan tahunan masing-masing sebesar Rp 25.190,20, Rp 118.152,51, dan Rp 399.882,03. Sementara itu, pada tingkat kepercayaan 99%, VaR meningkat menjadi -0,0402, dengan estimasi kerugian harian, bulanan, dan tahunan masing-masing sebesar Rp 40.224,91, Rp 188.671,54, dan Rp 638.550,60.

3.1.9 Backtesting

Gambar 8. menyajikan visualisasi perbandingan antara nilai *return* aktual dan batas VaR pada masing-masing tingkat kepercayaan.



Gambar 8. Plot *Backtesting*

Berdasarkan Gambar 8. pada tingkat kepercayaan 95% ditemukan sebanyak 61 titik pelanggaran dan 12 titik pelanggaran pada tingkat kepercayaan 99%. Hasil ini

kemudian digunakan sebagai dasar untuk pengujian secara statistik melalui Kupiec Test. Tabel 12 menyajikan hasil pengujian Kupiec Test.

Tabel 12. Hasil *Backtesting* VaR dengan Uji Kupiec Test

Parameter	Nilai (VaR 95%)	Nilai (VaR 99%)
Pelanggaran (N)	61	12
Taraf Signifikansi (α)	5%	1%
Jumlah Data (T)	1214	1214
LR Statistik	0,0085	0,0016
Nilai Kritis ($\chi^2_{(\alpha;1)}$)	3,841	6,635
<i>P-value</i>	0,9264	0,9677

Sumber : Data diolah, 2026

Berdasarkan Tabel 12. Diperoleh nilai LR sebesar 0,0085 pada tingkat kepercayaan 95%, yang lebih kecil dari nilai kritis $\chi^2_{(\alpha;1)}$ sebesar 3,841 dengan *p-value* sebesar 0,9264. Demikian pula pada tingkat kepercayaan 99%, diperoleh nilai LR sebesar 0,0016 yang juga lebih kecil dari nilai kritis $\chi^2_{(\alpha;1)}$ sebesar 6,635 dengan *p-value* sebesar 0,9677. Berdasarkan kriteria pengujian, VaR dinyatakan valid pada kedua tingkat kepercayaan karena nilai LR lebih kecil dari nilai kritis dan *p-value* lebih besar dari taraf signifikansi α .

3.2 Pembahasan

3.2.1 Karakteristik Data Saham ASII.JK

Berdasarkan statistik deskriptif yang diperoleh, dapat diketahui bahwa harga saham ASII.JK cukup fluktuatif yang tergambar dari rentang harga minimum dan maksimum yang dimiliki, selain itu standar deviasi juga menunjukkan harga saham ASII.JK cukup volatil, suatu hal yang umum terjadi pada instrumen keuangan. Hal ini juga tercermin pada hasil visualisasi yang menunjukkan pola pergerakan harga saham ASII.JK yang berfluktuasi secara dinamis sepanjang periode pengamatan, mencerminkan dinamika pasar yang dipengaruhi oleh berbagai faktor fundamental dan teknikal. Hasil tersebut menandakan bahwa harga saham ASII.JK memiliki karakteristik non-linear dengan volatilitas yang tinggi.

Pergerakan harga penutupan (close price) saham BBKA pada periode penelitian menunjukkan karakteristik yang volatil dan non-linear, sebagaimana umumnya terjadi pada instrumen finansial. Secara visual, dapat diamati bahwa harga saham BBKA mengalami fluktuasi yang signifikan sepanjang periode observasi, mencerminkan dinamika pasar yang dipengaruhi oleh berbagai faktor fundamental dan teknikal.

Data dengan karakteristik seperti ini, membutuhkan metode pemodelan yang lebih adaptif untuk hasil yang lebih akurat. Sehingga penggunaan *Deep Learning* dengan metode GRU cocok digunakan pada data ini. Penggunaan model ini didukung oleh teori Cho et al. (2014) dan Zhang et al. (2024), yang menyatakan bahwa GRU memiliki kelebihan dalam memodelkan data deret waktu yang bersifat non-linear melalui mekanisme *update gate* dan *reset gatenya*. Selain itu, beberapa penelitian terdahulu seperti (Perdana et al., 2025) dan Lestari et al. (2025), telah membuktikan keunggulan GRU dalam pemodelan harga saham *blue chip* yang cukup berfluktuasi. Penelitian-penelitian tersebut menyatakan bahwa GRU mampu menangkap detail fluktuasi dan lebih responsif terhadap perubahan arah tren harga. Dengan demikian, penggunaan model GRU dalam penelitian dinilai dapat memodelkan harga saham ASII.JK yang fluktuatif.

Berdasarkan plot distribusi harga saham ASII.JK, menunjukkan bahwa terdapat kecenderungan data berkumpul pada suatu rentang harga tertentu, sehingga menyebabkan ketidaksimetrisan. Selain itu, ditemukan sebaran tambahan pada level harga yang lebih tinggi tepatnya bagian ekor sebelah kanan, temuan ini menandakan bahwa harga saham ASII.JK memiliki ekor distribusi yang tebal (*fat tails*). Kondisi ini mengindikasikan bahwa *return* saham ASII.JK juga tidak mengikuti pola distribusi normal. Temuan ini sejalan dengan pernyataan Jorion, bahwa sebagian besar aset keuangan memiliki karakteristik *fat tails*, sehingga dalam mengukur nilai risiko penggunaan metode parametrik yang mengasumsikan data berdistribusi normal dapat menghasilkan nilai yang bias. Sehingga untuk hasil yang lebih baik, maka perhitungan VaR saham ASII.JK lebih baik menggunakan metode non-parametrik. Lebih lanjut, penelitian oleh Puspitorini dan Risman (2025) memperkuat justifikasi pemilihan metode simulasi historis dalam perhitungan VaR, yang menunjukkan hasil yang lebih realistis dalam mengestimasi nilai risiko dibandingkan dengan pendekatan parametrik terutama ketika *return* tidak memenuhi asumsi normalitas. Oleh karena itu, penggunaan metode simulasi historis dalam menghitung VaR saham ASII.JK pada penelitian ini menjadi relevan.

3.2.2 Analisis Arsitektur Model GRU

Arsitektur model GRU yang digunakan dalam penelitian ini terdiri dari lima lapisan, dua lapisan GRU dengan 64 *neuron*, dua lapisan *Dropout* dengan *rate* 10%, dan satu lapisan *Dense* sebagai *output*. Lapisan GRU yang pertama dikonfigurasi dengan *return_sequences=True*, agar seluruh *output* dari setiap *time step* diteruskan ke *layer* berikutnya, sedangkan lapisan GRU kedua menggunakan hanya menggunakan *return_sequence=False*, agar hanya *output* dari *time step* terakhir yang diteruskan ke *layer* berikutnya. Lapisan *Dropout* 10% berfungsi menonaktifkan 0,1 *neuron* secara acak selama proses pelatihan guna mengurangi risiko *overfitting*. Lapisan *Dense* dengan 1 unit berfungsi sebagai lapisan *output* yang menghasilkan nilai prediksi harga penutupan saham ASII.JK.

Arsitektur ini didasarkan pada model sekuens dengan mekanisme *reset gate* dan *update gate* yang diperkenalkan oleh Cho et al. (2014), yang membuat model dapat menyimpan sekaligus melupakan informasi secara selektif dengan arsitekturnya yang lebih sederhana dibandingkan dengan LSTM, namun tetap mampu menangkap ketergantungan jangka panjang. Penggunaan 64 *neuron* pada setiap *layer* GRU, memberikan kapasitas pembelajaran yang memadai dalam menangkap pola dan dependensi temporal yang kompleks dari data harga historis, tanpa menimbulkan kompleksitas komputasi yang berlebihan. Hal ini sesuai dengan temuan penelitian Dana et al. (2025) dan Labibah et al. (2024) yang menunjukkan bahwa konfigurasi dengan 64 *neuron* cukup efektif untuk data deret waktu. Dengan demikian, arsitektur yang digunakan pada penelitian ini sudah disusun secara sistematis berdasarkan landasan teoritis dan empiris.

3.2.3 Analisis Pengujian *Hyperparameter*

Berdasarkan hasil pengujian *hyperparameter*, menunjukkan bahwa *learning rate* 0,001 cenderung menghasilkan nilai kesalahan yang lebih rendah dibandingkan dengan *learning rate* 0,0001. Hasil ini menunjukkan bahwa *learning rate* merupakan salah satu *hyperparameter* yang berpengaruh terhadap hasil evaluasi kinerja model. Temuan ini sesuai dengan konsep *learning rate* yang dijelaskan oleh Goodfellow, di mana pemilihan nilai yang tidak tepat dapat mengakibatkan kegagalan optimasi pada model. Lebih lanjut, hasil penelitian ini sejalan dengan temuan dari Khairunisa dan Hendikawati (2024), yang menyatakan bahwa *learning rate* yang lebih besar cenderung menghasilkan prediksi lebih baik, karena dapat mempercepat proses konvergensi model. Namun, berbeda dengan temuan dari Labibah et al. (2024), yang justru menemukan bahwa *learning rate* lebih kecil menghasilkan performa lebih optimal karena, memungkinkan model mencapai konvergensi yang lebih presisi meskipun dengan proses pelatihan yang lebih lambat. Perbedaan ini menunjukkan bahwa pemilihan *learning rate* sangat berpengaruh pada kinerja model, dan *learning rate* yang optimal bergantung pada karakteristik data dan arsitektur model yang digunakan.

Selain *learning rate*, penggunaan *batch size* 16, 32, dan 64 juga memberikan pengaruh terhadap nilai metrik evaluasi. *Batch size* 16 menghasilkan nilai evaluasi yang relatif lebih rendah dibandingkan *batch size* 32 dan 64. Hal ini dapat terjadi karena fungsi dari *batch size* itu sendiri sebagai jumlah sampel yang digunakan pada setiap iterasi selama proses pelatihan, sehingga semakin besar *batch size* yang digunakan akan membutuhkan memori yang juga lebih besar dan dapat mengurangi pembaruan yang diperlukan untuk mencapai konvergensi. Temuan ini sejalan dengan penelitian oleh Aryati et al. (2024), yang menyatakan bahwa penggunaan *batch size* yang lebih kecil cenderung menghasilkan nilai evaluasi yang lebih rendah dibandingkan dengan *batch size* yang lebih besar.

Lebih lanjut, jumlah *epoch* juga terbukti memberikan pengaruh terhadap kinerja model. Peningkatan jumlah *epoch* dari 50 ke 100 menunjukkan adanya peningkatan

kinerja model, yang mengindikasikan bahwa penambahan *epoch* dapat meningkatkan kemampuan model dalam memahami pola data yang lebih kompleks. Temuan ini sejalan dengan penelitian dari Khairunisa dan Hendikawati (2024) serta Aryati et al. (2024), yang menunjukkan bahwa peningkatan jumlah *epoch* dari 50 ke 100 cenderung meningkatkan performa model. Namun, peningkatan *epoch* dari 100 ke 150 tidak selalu memberikan peningkatan yang signifikan, karena penambahan *epoch* yang terlalu banyak justru dapat menyebabkan *overfitting* pada model.

3.2.4 Analisis Hasil Prediksi

Berdasarkan grafik hasil prediksi data uji, model GRU mampu mengikuti tren pergerakan harga saham ASII.JK dengan baik, terutama pada pergerakan harga normal. Namun, pada beberapa periode yang mengalami kenaikan atau penurunan yang tajam, kurva hasil prediksi sedikit menyimpang dan tertinggal dari kurva harga aktual. Fenomena ini dapat terjadi karena adanya mekanisme *update gate* pada GRU. Cho et al. (2014) menjelaskan bahwa *hidden state* dibentuk dari kombinasi informasi historis dan informasi baru yang dikendalikan oleh *update gate*, sehingga informasi dari periode sebelumnya tetap berkontribusi pada prediksi periode berikutnya. Akibatnya, ketika harga saham berubah secara mendadak akibat meningkatnya volatilitas pasar atau faktor lain, model akan merespons secara bertahap, sehingga hasil prediksi cenderung tertinggal dari data aktual. Selain itu, penggunaan *loss function* berbasis MSE yang meminimalkan rata-rata kesalahan kuadrat di seluruh data latih. Karena perubahan harga mendadak itu jarang secara frekuensi dibanding pergerakan harga normal, maka kontribusi terhadap total *loss* relatif kecil, yang mengakibatkan hasil prediksi yang lebih *smooth* terhadap perubahan mendadak. Fenomena ini juga dijelaskan pada penelitian Jhin et al. (2024), yang menyatakan bahwa salah satu tantangan dalam peramalan deret waktu, adalah adanya fenomena keterlambatan prediksi atau *prediction delay*. Dalam penelitian tersebut, menyebutkan bahwa penyebab terjadinya fenomena ini adalah adanya ketergantungan temporal pada data deret waktu dan keterbatasan fungsi kerugian yang berbasis MSE.

Selain itu, hasil ini sejalan dengan penelitian Reza dan Ghufroon (2025), yang menemukan bahwa model GRU mampu menangkap dan mengikuti *tren* pergerakan harga dengan sangat baik, meski terdapat sedikit keterlambatan atau *lag* pada puncak dan lembah ekstrem, merupakan hal yang wajar ditemukan dalam peramalan deret waktu. Lebih lanjut, hasil evaluasi MAPE sebesar 1,37% menandakan model memprediksi dengan akurasi rata-rata 98,63%, dan tergolong kategori sangat baik. Temuan ini sejalan dengan penelitian oleh Labibah et al. (2024), menyatakan bahwa meski garis prediksi dan data aktual berbeda pada titik-titik pergerakan ekstrem akibat fluktuasi tak terduga, hasil peramalan tetap tergolong sangat baik selama nilai MAPE rendah. Sehingga model GRU yang dibangun dapat dijadikan referensi untuk peramalan harga saham terutama peramalan jangka pendek. Hasil prediksi harga

saham ASII.JK untuk 7 hari ke depan, dan menunjukkan arah kenaikan yang stabil. Investor dapat menggunakan informasi ini sebagai bahan pertimbangan selanjutnya.

3.2.5 Analisis Risiko Berdasarkan VaR dan *Backtesting*

Merujuk pada hasil perhitungan VaR menggunakan metode simulasi historis pada saham ASII.JK, dengan berbagai tingkat kepercayaan, estimasi risiko maksimum yang mungkin terjadi mengalami peningkatan seiring dengan bertambahnya tingkat kepercayaan. Pada tingkat kepercayaan 95%, kerugian investasi saham bernilai -0,0252 atau -2,52%. Dengan kata lain, terdapat kemungkinan 5% kerugian yang dialami investor dapat melebihi nilai tersebut dalam kondisi pasar normal. Pada tingkat kepercayaan 99%, estimasi kerugian maksimum meningkat menjadi -0,0402 atau -4,02%, yang mencerminkan ekspektasi kerugian pada kondisi pasar yang lebih ekstrem. Lebih lanjut, hasil penelitian juga menunjukkan adanya akumulasi risiko seiring bertambahnya periode waktu investasi, di mana VaR yang diperoleh pada *holding period* yang lebih panjang lebih tinggi dibandingkan *holding period* yang lebih singkat. Hasil ini menunjukkan bahwa tingkat kepercayaan dan *holding period* berpengaruh terhadap VaR, yang berarti semakin tinggi tingkat kepercayaan yang digunakan, semakin besar VaR yang diestimasi, begitu pula semakin panjang periode penahanan aset, semakin besar potensi risiko kerugian yang terakumulasi. Temuan ini sejalan dengan teori yang dikemukakan oleh Jorion, yang menyatakan bahwa VaR mengukur potensi kerugian maksimum selama periode waktu tertentu pada tingkat kepercayaan tertentu, sehingga kedua komponen ini secara langsung menentukan besar kecilnya VaR yang dihasilkan.

Berdasarkan hasil *backtesting* menggunakan Kupiec Test, VaR yang dihasilkan dengan metode simulasi historis dinyatakan valid pada masing-masing tingkat kepercayaan. Dengan tingkat kepercayaan 95% nilai LR yang dihasilkan sebesar 0,0085 yang lebih kecil dari nilai kritis $\chi^2_{(\alpha;1)} = 3,841$, sedangkan pada tingkat kepercayaan 99% nilai LR sebesar 0,0016 yang juga lebih kecil dari nilai kritis $\chi^2_{(\alpha;1)} = 6,635$. Temuan ini konsisten dengan beberapa penelitian terdahulu mengenai pengukuran risiko saham menggunakan metode simulasi historis dan metode VaR lainnya. Penelitian oleh Saniah (2024), yang mengevaluasi tiga metode pengukuran risiko pada tiga saham, menunjukkan bahwa rata-rata VaR yang dihasilkan dengan metode simulasi historis lebih rendah dibandingkan dengan metode parametrik lainnya dan akurat berdasarkan hasil *backtesting* Kupiec Test. Lebih lanjut, penelitian Nurhaliza et al. (2025) yang mengukur VaR dengan metode simulasi historis pada tingkat kepercayaan 95% dan 99%. Penelitian tersebut menyimpulkan bahwa keduanya valid setelah dilakukan uji *backtesting*. Dengan demikian, secara keseluruhan hasil penelitian ini telah membuktikan bahwa metode simulasi historis cukup efektif dalam mengukur risiko saham ASII.JK, tanpa perlu asumsi distribusi normal serta mampu menangkap perilaku ekstrem yang terjadi di pasar modal

BAB IV.

KESIMPULAN

Berdasarkan hasil penelitian dan pembahasan yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut:

1. Algoritma GRU berhasil memprediksi harga saham ASII.JK melalui model dengan dua *layer* GRU berisi 64 *neuron*, dua *layer Dropout* 10% sebagai regulasi, dan satu *layer Dense*. Kombinasi *hyperparameter learning rate* 0,001, *batch size* 16, dan *epoch* 100 menghasilkan model terbaik dengan RMSE 108,76, MAE 79,19, dan MAPE 1,37%, angka yang menandakan akurasi tinggi. Meskipun grafik menunjukkan adanya *lag* pada beberapa titik fluktuasi tajam, hal ini merupakan fenomena yang wajar dalam peramalan deret waktu. Model tetap akurat secara keseluruhan dan mampu menggeneralisasi data yang belum pernah dilihat sebelumnya. Algoritma GRU terbukti efektif memprediksi harga saham ASII.JK.
2. Metode VaR dengan simulasi historis mengestimasi risiko kerugian investasi saham ASII.JK, pada tingkat kepercayaan 95%, estimasi risiko harian sebesar -2,52%, artinya terdapat kemungkinan 5% kerugian dalam satu hari melebihi nilai tersebut. Pada tingkat kepercayaan 99%, estimasi risiko sebesar -4,02%, dengan kemungkinan 1% kerugian melebihi batas tersebut. Uji *backtesting* menyatakan kedua estimasi ini valid. Metode simulasi historis terbukti efektif mengukur risiko investasi tanpa memerlukan asumsi distribusi normal dan mampu menangkap perilaku ekstrem di pasar saham. Secara keseluruhan, kombinasi model prediksi GRU dengan analisis VaR menghasilkan pengukuran risiko investasi yang lebih akurat. Pendekatan ini memanfaatkan data prediksi untuk menghasilkan analisis risiko yang komprehensif dalam menghadapi dinamika pasar saham.

DAFTAR PUSTAKA

- Akhmad, I. M., & Damayanti, C. R. (2021). Perbedaan Saham Blue Chip dan Non Blue Chip: Analisis Volume Perdagangan dan Return Saham Atas Kebijakan Stock Split. *Jurnal Bisnis Strategi*, 30(2), 139–153. <https://doi.org/10.14710/jbs.30.2.139-153>
- Aryati, N. W. M., Wiguna, I. K. A. G., Putri, N. W. S., Widiartha, I. K. K., & Ginantra, N. L. W. S. R. (2024). Komparasi Metode LSTM dan GRU dalam Memprediksi Harga Saham. *Jurnal Media Informatika Budidarma*, 8(2), 1131. <https://doi.org/10.30865/mib.v8i2.7342>
- Asrirawan, Permata, S. U., & Fauzan, M. I. (2022). Pendekatan Univariate Time Series Modelling untuk Prediksi Kuartalan Pertumbuhan Ekonomi Indonesia Pasca Vaksinasi COVID-19. *Jambura Journal of Mathematics*, 4(1), 86–103. <https://doi.org/10.34312/jjom.v4i1.11717>
- Beti, I. Y., & Juliansa, H. (2024). Normalisasi Data Metode Decimal Scaling Dan Metode K-Means Dalam Mengelompokkan Kasus Demam Berdarah. *KLIK: Kajian Ilmiah Informatika Dan Komputer*, 4(6), 2928–2936. <https://www.djournals.com/klik/article/view/1925>
- BJ, B. J., Nugroho, K. T., Maharani, T., & Saifullah, D. F. N. M. (2023). Pengaruh Jumlah Epoch dan Step Per Epoch Terhadap Performa Mask-RCNN pada Deteksi Objek Tanda Tangan. *Journal of Electrical, Electronic, Mechanical, Informatic and Social Applied Science*, 2(1), 7–16. <https://doi.org/10.58991/eemisas.v2i1.20>
- Bukit, G. C., & Hendratno. (2021). Analisis Backtesting Dan Value At Risk (Var) Dengan Metode Simulasi Historis Dalam Sub Sektor Bank (Studi Kasus Pada Saham Pt. Bank Rakyat Indonesia Tbk. Dan Pt. Bank Cimb Niaga Tbk.). *E-Proceeding of Management*, 8(2), 772–778. <https://openlibrarypublications.telkomuniversity.ac.id/index.php/managemen%0A/article/view/14746>
- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. In A. Moschitti, B. Pang, & W. Daelemans (Eds.), *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing ({EMNLP})* (pp. 1724–1734). Association for Computational Linguistics. <https://doi.org/10.3115/v1/D14-1179>
- Dana, A. R., Trimono, T., & Idhom, M. (2025). Predicting Price and Risk ICBP Stocks Using GRU and VaR. *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, 19(1), 73. <https://doi.org/10.22146/ijccs.101974>
- Danestiara, V. R., Setiana, E., Akbar, I., & Hidayah, T. (2024). Algoritma Gated Recurrent Unit untuk Prediksi Harga Indeks Penutupan Saham LQ45. *Jurnal Accounting Information System (AIMS)*, 7(1), 1–8. <https://doi.org/10.32627/aims.v7i1.814>
- Diqi, M., Hiswati, M. E., & Wijaya, N. (2024). Stacked Gated Recurrent Units and Indonesian Stock Predictions: A New Approach to Financial Forecasting. *Jurnal Ilmu Komputer Dan Teknologi*, 5(1), 11–17. <https://doi.org/10.35960/ikomti.v5i1.1106>
- Faris, F. Al, Taqwa, A., Handayani, A. S., Husni, N. L., Caesarendra, W., Asriyadi, A., Novianti, L., & Rahman, M. A. (2025). Comparative Analysis of LSTM and GRU for River Water Level Prediction. *Jurnal Teknik Informatika (Jutif)*, 6(5),

- 3481–3494. <https://doi.org/10.52436/1.jutif.2025.6.5.5054>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Hasan, A., Sholikhathunnisa, S., Alvadia, W. R., Fachrini, A., & Dwi Putri, N. (2024). Fungsi Investasi Dalam Perspektif Ekonomi Islam. *Journal of Applied Islamic Economics and Finance*, 5(1), 47–57. <https://doi.org/10.35313/jaief.v5i1.5072>
- Ismail, A., Herbenita, H., Desliniati, N., & Andriyat, Y. (2024). *Mengenal Investasi di Pasar Modal: Melalui Sekolah Pasar Modal Bursa Efek* (1st ed.). Asadel Liamsindo Teknologi.
- Jahin, M. A., Shahriar, A., & Amin, M. Al. (2025). *MCDFN: Supply Chain Demand Forecasting via an Explainable Multi-Channel Data Fusion Network Model*. <http://arxiv.org/abs/2405.15598>
- Jorion, P. (2007). *Value at risk: The New Benchmark for Managing Financial Risk* (Third edit). McGraw-Hill. <https://ebookcentral.proquest.com/lib/londonschoolecons/detail.action?docID=6262400>
- K, H. J., Wahyuni, S., Sari, T. E., Fitradinata, K., & Anes, M. R. (2025). Determinasi harga saham pada pt aneka tambang tbk (antm) tahun 2019-2023. *Innovative: Journal Of Social Science Research*, 5, 1336–1347. <https://j-innovative.org/index.php/Innovative>
- Kandel, I., & Castelli, M. (2020). The effect of batch size on the generalizability of the convolutional neural networks on a histopathology dataset. *ICT Express*, 6(4), 312–315. <https://doi.org/10.1016/j.ict.2020.04.010>
- Khairunisa, N., & Hendikawati, P. (2024). Long Short-Term Memory and Gated Recurrent Unit Modeling for Stock Price Forecasting. *Jurnal Matematika, Statistika Dan Komputasi*, 21(1), 321–333. <https://doi.org/10.20956/j.v21i1.35930>
- Kruba, R., Sofyan, H., Marshanda, D., Rizki, D., Syazana, N., & Rahmadhan. (2025). Peramalan Saham Indofood di Indonesia Menggunakan Metode Seasonal Autoregressive Integrated Moving Average (SARIMA). *Jurnal Manajemen Dan Keuangan*, 14(1), 13–22. <https://ejurnalunsam.id/index.php/jmk/article/view/11501>
- Labibah, B., Guntara, R. G., & Maesaroh, S. S. (2024). *Kombinasi Inisialisasi Hyperparameter dan Algoritma Adam untuk Optimasi Model Gated Recurrent Unit dalam Meramalkan Harga Penutupan Saham Pasca Isu Boikot*. 6(3). <https://doi.org/10.47065/bits.v6i3.6202>
- Laras, W., & Mujiono, S. (2019). Penerapan Long Short Term Memory pada Data Time Series untuk Memprediksi Penjualan Produk PT. Metiska Farma. *Jurnal Nasional Pendidikan Teknik Informatika (JANAPATI)*, 8(3), 184–196. <https://doi.org/10.23887/janapati.v8i3.19139>
- Lestari, S. A., Atina, V., & Hasanah, H. (2025). *Perbandingan Model Gated Recurrent Unit dan Long Short- Term Memory Dalam Prediksi Harga Saham*. 393–400. <https://ojs.udb.ac.id/Senatib/article/view/5385>
- Marietta, B., Santoso, R., & Sa'adah, A. A. (2025). Peramalan Nilai Tukar Rupiah Terhadap Dollar Amerika Dengan Metode Long Short-Term Memory Dan Gated Recurrent Unit. *Jurnal Gaussian*, 14(1), 13–22. <https://doi.org/10.14710/j.gauss.14.1.13-22>
- Nilsen, A. (2022). Perbandingan Model RNN, Model LSTM, dan Model GRU dalam Memprediksi Harga Saham-Saham LQ45. *Jurnal Statistika Dan Aplikasinya*, 6(1), 137–147. <https://doi.org/10.21009/JSA.06113>
- Nurhaliza, A., Saputra, A., & Mirtawati. (2025). *Evaluasi Akurasi Value at Risk Metode*

- Simulasi Historis melalui Backtesting pada Saham BBKA Tahun 2024*. 4(3). <https://doi.org/10.59818/kontan.v4i3.2269>
- Nurharyanto. (2011). *Analisis Risiko Pasar Portofolio Investasi Saham dengan Metode Value at Risk: (Studi Kasus pada Dana Pensiun RST)* [Univeristas Indonesia]. <https://lib.ui.ac.id/detail?id=20284433>
- Nuryanto, T. S., Prahutama, A., & Hoyyi, A. (2018). HISTORICAL SIMULATION UNTUK MENGHITUNG VALUE AT RISK PADA PORTOFOLIO OPTIMAL BERDASARKAN SINGLE INDEX MODEL MENGGUNAKAN GUI MATLAB (Studi Kasus: Kelompok Saham JII Periode Juni - November 2017). *Jurnal Gaussian*, 7(4), 408–418. <https://doi.org/10.14710/j.gauss.v7i4.28869>
- Perdana, Y., Raisa Hanum, N., Rabiula, A., & Anzari, Y. (2025). ANALISIS PERBANDINGAN MODEL GRU DAN LSTM UNTUK PREDIKSI HARGA SAHAM BANK RAKYAT INDONESIA. *JURNAL AKADEMIKA*, 17(2), 54–60. <https://doi.org/10.53564/akademika.v17i2.1692>
- PT Astra International Tbk. (2025). *Laporan Tahunan 2025: Mempertahankan Pertumbuhan melalui Ketangguhan*. <https://www.astra.co.id/investor-relations/annually-update>
- PT Kustodian Sentral Efek Indonesia. (2025). Statistik Pasar Modal Indonesia Pertumbuhan Investor. In *Kustodian Sentral Efek Indonesia*. <https://web.ksei.co.id/files/Statistik Publik Desember 2025.pdf>
- Purnamasari, S. A. (2025). Mekanisme Perkembangan Pasar Modal Sebagai Salah Satu Produk Investasi di Masyarakat. *Jurnal Rumpun Manajemen Dan Ekonomi*, 2(3), 499–515. <https://doi.org/10.61722/jrme.v2i3.4739>
- Puspitorini, J., & Risman, A. (2025). Analisis Value at Var (VaR) Menggunakan Metode Analisis Variance-Covariance, Historical Simulation, dan Monte Carlo Simulation. *Fakultas Ekonomi Dan Bisnis, Universitas Mercu Buana*, (April). <https://doi.org/10.13140/RG.2.2.10501.67042>
- Raiaan, M. A. K., Sakib, S., Fahad, N. M., Mamun, A. Al, Rahman, M. A., Shatabda, S., & Mukta, M. S. H. (2024). A systematic review of hyperparameter optimization techniques in Convolutional Neural Networks. In *Decision Analytics Journal* (Vol. 11). Elsevier Inc. <https://doi.org/10.1016/j.dajour.2024.100470>
- Reza, M. F., & Ghufro. (2025). IMPLEMENTASI MODEL GATED RECURRENT UNIT (GRU) ATAU EXTREME GREDIENT BOOSTING (XGBOOST) UNTUK PREDIKSI HARGA CRYPTOCURRENCY ETHEREUM. *Jurnal Rekayasa Sistem Informasi Dan Teknologi*, 3(1), 209–222. <https://doi.org/10.70248/jrsit.v3i1.3031>
- Rosyidah, H., Maruddani, D. A. I., & Safitri, D. (2024). Analisis Backtesting Untuk Value At Risk Metode Ekspansi Cornish-Fisher Dengan Uji Kupiec. *Jurnal Gaussian*, 13(2), 405–414. <https://doi.org/10.14710/j.gauss.13.2.405-414>
- Saniah, A. P. (2024). *Pengukuran Risiko Menggunakan Value at Risk dengan Metode Variance Covariance, Simulasi Historis dan Monte Carlo*. https://www.researchgate.net/publication/384912835_Pengukuran_Risiko_Menggunakan_Value_at_Risk_dengan_Metode_Variance_Covariance_Simulasi_Historis_dan_Monte_Carlo
- Sezgin, F. H., Algorabi, Ö., Sart, G., & Güler, M. (2025). *Hyperparameter-Optimized RNN , LSTM , and GRU Models for Airline Stock Price Prediction : A Comparative Study on THYAO and PGSUS*. 1–19. <https://doi.org/10.3390/sym17111905>
- Sulastri, S., & Ramadhani, I. W. (2025). Forecasting The Value of Non-Oil and Gas

- Exports in Indonesia Using Triple Exponential Smoothing. *Sainsmat : Jurnal Ilmiah Ilmu Pengetahuan Alam*, 14(2), 208. <https://doi.org/10.35580/sainsmat142764142025>
- Sutarna, N., Tjahyadi, C., Oktivasari, P., Dwiyaniti, M., & Tohazen. (2024). Hyperparameter Tuning Impact on Deep Learning Bi-LSTM for Photovoltaic Power Forecasting. *Journal of Robotics and Control (JRC)*, 5(3), 677–693. <https://doi.org/10.18196/jrc.v5i3.21120>
- Tombilayuk, L. (2025). Penerapan Metode Triple Exponential Smoothing pada Sistem Prediksi Penjualan Barang Master Komputer. *Jurnal Nasional Komputasi Dan Teknologi Informasi (JNKTI)*, 8(2), 656–662. <https://doi.org/10.32672/jnkti.v8i2.8895>
- Yahoo Finance. (2026). *PT Astra International Tbk (ASII.JK)*. Yahoo Finance. <https://finance.yahoo.com/quote/ASII.JK/history/>
- Yudistira, N., Alfiansih, L. M. D., Andriyani, N. I., Essayem, W., Maulida, N., Maghfiroh, N. A., & Nurdian, I. W. (2023). *Prediksi Deret Waktu Menggunakan Deep Learning* (Pertama). UB Press
- Zhang, S., Robinson, E., & Basu, M. (2024). Wind power forecasting based on a novel gated recurrent neural network model. *Wind Energy and Engineering Research*, 1, 100004. <https://doi.org/10.1016/j.weer.2024.100004>

LAMPIRAN

Lampiran 1. Data Harga Saham ASII.JK

Date	Close	High	Low	Open	Volume
2021-01-04	4361,848	4379,365	4221,708	4274,26	34840200
2021-01-05	4326,813	4379,366	4309,296	4361,848	27318400
2021-01-06	4309,296	4361,848	4169,156	4326,813	42778200
2021-01-07	4256,744	4344,331	4256,744	4326,814	33536400
2021-01-08	4501,989	4537,024	4274,262	4309,297	88590400
2021-01-11	4572,058	4624,61	4537,023	4554,541	57622400
...	...	...	...	...	...
2025-12-25	6625	6625	6625	6625	0
2025-12-26	6625	6625	6625	6625	0
2025-12-29	6675	6725	6600	6625	20982300
2025-12-30	6700	6725	6600	6675	23486000
2025-12-31	6700	6700	6700	6700	0

Lampiran 2. Kode Pemrograman

Link kodingan :

https://github.com/rsmaaynt/Prediksi-Harga-Saham-dengan-GRU-TA/blob/00d2e70f76dd8fff41e09c11c06fbc0ebccea33/kodingan_gru_fix.ipynb

Import library yang diperlukan

```
import math
import pandas as pd
import tensorflow as tf
import random
import numpy as np
from matplotlib import pyplot as plt
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler
from keras.models import Sequential
from keras.layers import Dense, Dropout, GRU
from sklearn.metrics import mean_squared_error as MSE,
mean_absolute_error as MAE
from keras.optimizers import Adam
import tensorflow as tf
import os
from tensorflow.keras.callbacks import EarlyStopping,
ModelCheckpoint
from sklearn import state
```

Preprocessing data

```
# Cek Missing Value
null_count = data.isnull().sum().sum()
print(f"Jumlah data kosong: {null_count}")

# Cek Duplikat
duplicate_count = data.duplicated().sum()
print(f"Jumlah data duplicated: {duplicate_count}")

# Normalisasi data
sc = MinMaxScaler (feature_range=(0, 1))
data_sc = sc.fit_transform(data[['Close']].values)
data_sc_df = pd.DataFrame(data_sc, columns=['Close_scaled'])
data_sc_df

#Melakukan pembagian data dengan Hold-Out Validation
train_len = math.ceil(len(data_sc) *.8)
val_len = math.ceil(len(data_sc) *.10)
test_len = math.ceil(len(data_sc) *.10)
```

Arsitektur model GRU

```
# Inisiasi Model GRU
model = Sequential()
model.add(GRU(units=64, return_sequences=True,
input_shape=(x_train.shape[1],1)))
model.add(Dropout(0.1))
model.add(GRU(units=64, return_sequences=False))
model.add(Dropout(0.1))
model.add(Dense(units=1))
model.summary()
```

Training Model

```
history = model.fit(x_train, y_train, batch_size=16, epochs=100,
validation_data=(x_val, y_val), callbacks=[checkpoint])
```

Evaluasi model

```
rmse = np.sqrt(MSE(y_test, y_pred))
mae = MAE(y_test, y_pred)
mape_test = np.mean(np.abs((y_test- y_pred) / y_test)) * 100
```

Prediksi untuk 7 hari ke depan

```

periode = 7
# Ambil data terakhir sesuai panjang window input
last_days = data_sc[- time_step:]
forecast = []

# Loop prediksi ke depan sebanyak 'periode'
for _ in range(periode):
    input_data = last_days.reshape(1, time_step, 1)
    pred = model.predict(input_data, verbose=0)[0][0]
    forecast.append(pred)
    # Geser window dengan menambahkan prediksi terbaru
    last_days = np.append(last_days[1:], [[pred]], axis=0)

# Kembalikan hasil ke skala asli
forecast = sc.inverse_transform(np.array(forecast).reshape(-1, 1))

# Buat tanggal prediksi mulai setelah data terakhir
start_date = pd.to_datetime(data['Date'].iloc[-1])
dates = pd.bdate_range(start=start_date + pd.Timedelta(days=1),
periods=periode)

# Susun DataFrame hasil prediksi
prediction = pd.DataFrame({
    'Date': dates,
    'Nilai Prediksi': forecast.flatten()
})

```

Hitung Return

```

gabungan_df['Date'] = pd.to_datetime(gabungan_df['Date'])
gabungan_df['Log Return'] = np.log(gabungan_df['Nilai Gabungan'] /
gabungan_df['Nilai Gabungan'].shift(1))
log_returns = gabungan_df[['Date', 'Log Return']]

```

Menghitung VaR

```

n = len(log_returns_sorted)
alfa_95 = int(1 - 0.95)
perc_95 = int(0.05 * n) # atau math.ceil()
perc_99 = int(0.01 * n)
var_95 = log_returns_sorted.iloc[perc_95]['Log Return']
var_99 = log_returns_sorted.iloc[perc_99]['Log Return']

```

Backtesting

```

exceed_95 = log_returns['Log Return'] < var_95
exceed_99 = log_returns['Log Return'] < var_99
jumlah_pelanggaran_95 = exceed_95.sum()
jumlah_pelanggaran_99 = exceed_99.sum()

```

Uji Kupiec

```
def kupiec_test(total_data, jumlah_pelanggaran, alpha):
    """
    Menghitung Likelihood Ratio (LR) untuk Kupiec POF Test.
    alpha: tingkat signifikansi (misal 0.05 untuk VaR 95%, 0.01
    untuk VaR 99%)
    """
    p = alpha # Probabilitas kegagalan teoritis
    p_hat = jumlah_pelanggaran / total_data # Probabilitas
    kegagalan aktual (observasi)

    # Rumus Likelihood Ratio (LR) POF
    part_numerator = ((1 - p)**(total_data - jumlah_pelanggaran)) *
    (p**jumlah_pelanggaran)
    part_denominator = ((1 - p_hat)**(total_data -
    jumlah_pelanggaran)) * (p_hat**jumlah_pelanggaran)

    lr_statistic = -2 * np.log(part_numerator / part_denominator)

    # P-value dari distribusi Chi-Square dengan df=1
    p_value = 1 - stats.chi2.cdf(lr_statistic, df=1)

    return lr_statistic, p_value

# Informasi tambahan
N = len(log_returns) # Total data observasi
```

Lampiran 3. Hasil Eksperimen Arsitektur Model GRU

Time step	Unit	Dropout	Layer	RMSE	MAE	MAPE
10	32	0,1	1	127,78	97,37	1,66%
			2	114,20	88,99	1,53%
		0,2	1	127,56	97,22	1,66%
			2	124,72	97,75	1,67%
		0,3	1	139,08	108,50	1,84%
			2	111,90	84,54	1,46%
	64	0,1	1	109,97	80,76	1,39%
			2	108,76	79,19	1,37%
		0,2	1	109,99	80,55	1,39%
			2	110,92	84,63	1,46%
		0,3	1	109,40	80,08	1,38%
			2	108,80	81,76	1,41%

Time step	Unit	Dropout	Layer	RMSE	MAE	MAPE
20	32	0,1	1	168,73	119,16	2,07%
			2	147,63	108,20	1,85%
		0,2	1	145,30	102,44	1,78%
			2	168,69	127,38	2,16%
		0,3	1	184,39	136,18	2,34%
			2	201,11	159,01	2,68%
	64	0,1	1	122,34	91,56	1,56%
			2	111,59	81,60	1,40%
		0,2	1	115,42	84,91	1,46%
			2	109,26	79,63	1,38%
		0,3	1	124,50	94,05	1,60%
			2	110,64	80,48	1,39%

Lampiran 4. Tabel Distribusi Chi Square

Chi-Square Table

Table 5-2
Critical Values of the χ^2 Distribution

df \ p	0.995	0.975	0.9	0.5	0.1	0.05	0.025	0.01	0.005	df
1	.000	.000	0.016	0.455	2.706	3.841	5.024	6.635	7.879	1
2	0.010	0.051	0.211	1.386	4.605	5.991	7.378	9.210	10.597	2
3	0.072	0.216	0.584	2.366	6.251	7.815	9.348	11.345	12.838	3
4	0.207	0.484	1.064	3.357	7.779	9.488	11.143	13.277	14.860	4
5	0.412	0.831	1.610	4.351	9.236	11.070	12.832	15.086	16.750	5
6	0.676	1.237	2.204	5.348	10.645	12.592	14.449	16.812	18.548	6
7	0.989	1.690	2.833	6.346	12.017	14.067	16.013	18.475	20.278	7
8	1.344	2.180	3.490	7.344	13.362	15.507	17.535	20.090	21.955	8
9	1.735	2.700	4.168	8.343	14.684	16.919	19.023	21.666	23.589	9
10	2.156	3.247	4.865	9.342	15.987	18.307	20.483	23.209	25.188	10
11	2.603	3.816	5.578	10.341	17.275	19.675	21.920	24.725	26.757	11
12	3.074	4.404	6.304	11.340	18.549	21.026	23.337	26.217	28.300	12
13	3.565	5.009	7.042	12.340	19.812	22.362	24.736	27.688	29.819	13
14	4.075	5.629	7.790	13.339	21.064	23.685	26.119	29.141	31.319	14
15	4.601	6.262	8.547	14.339	22.307	24.996	27.488	30.578	32.801	15